

更多资料请关注公众号【数学建模老哥】课件或代码请公众号回复“课件”，粉丝QQ群：1077734962

2023数学建模美赛保奖培训班

预测类模型基本原理及编程实现

主讲人：韩老师

微信公众号 / B站号：数学建模老哥



数学建模老哥

这里写本节课的内容目录

目录

CONTENTS

01. 线性回归基本原理与应用

02. 决策树基本原理与应用

03. 朴素贝叶斯基本原理与应用

04. 神经网络基本原理与应用

03. 分类工具箱、神经网络工具箱及实战案例分析

机器学习



机器学习是一门多领域交叉学科，涉及概率论、统计学、逼近论、凸分析、算法复杂度理论等多门学科。专门研究计算机怎样模拟或实现人类的学习行为，以获取新的知识或技能，重新组织已有的知识结构使之不断改善自身的性能。



2021 年高教社杯全国大学生数学建模竞赛题目

(请先阅读“全国大学

C 题 生产企

某建筑和装饰板材的生产企业所生产的产品总体可分为 A, B, C 三种类型。该企业根据材料订购和转运计划,即根据产能要求和相应每周的原材料订购数量(称为“商”)并委托其将供应商每周的原材料

该企业每周的产能为 2.82 万立方米,或 B 类原材料 0.66 立方米,或 C 类原材料 0.66 立方米,实际供货量不能保证严格按照订货量供货,实际供货量需要,该企业要尽可能保持不少于满足供应商实际提供的原材料总是全部收购。

在实际转运过程中,原材料会有一定的损耗(称为“率”),转运商实际运送到企业仓库的能力为 6000 立方米/周。通常情况下,运输。

原材料的采购成本直接影响到企业的成本,价格分别比 C 类原材料高 20%和 10%。三附件 1 给出了该企业近 5 年 402 家供应商的运输损耗率数据。请分析,研究下列问题:

1. 根据附件 1,对 402 家供应商的重要性进行数学模型,在此基础上确定 5 家最重要的供应商。
2. 参考问题 1,该企业至少应选择 5 家供应商,为企业制定未来 5 年损耗最少的转运方案。试对订购方案和转运方案进行分析。
3. 该企业为了压缩生产成本,现拟制定转运方案,并分析方案的实施效果。
4. 该企业通过技术改造已具备了供应商的实际情况,确定该企业每周的产能方案。

注:请将问题 2、问题 3 和问题 4 的结果填入附件 B,并作为支撑材料。

2020 年高教社杯全国大学生数学建模竞赛题目

(请先阅读“全国大学生数学建模竞赛论文格式规范”)

C 题

在实际中,由于中小微企业的信贷政策、企业的交易票据信息和企业提供贷款,并可以对信誉高、信用企业的实力、信誉对其信贷风险、贷款额度、利率和期限等信贷政策。

某银行对确定要放贷企业的期限为 1 年。附件 1~3 分别给出了企业的相关数据和贷款利率与客户根据实际和附件中的数据信息,解决下列问题:

- (1) 对附件 1 中 123 家企业的固定时对这些企业的信贷策略。
- (2) 在问题 1 的基础上,对附该银行在年度信贷总额为 1 亿元时。
- (3) 企业的生产经营和经济效益对不同的行业、不同类型的企业会有可能的突发因素(例如:新冠病毒)为 1 亿元时的信贷调整策略。

- 附件 1 123 家有信贷记录企业的
附件 2 302 家无信贷记录企业的
附件 3 银行贷款年利率与客户流

附件中数据说明:

- (1) 进项发票:企业进货(购买产品)
- (2) 销项发票:企业销售产品时为
- (3) 有效发票:为正常的交易活动
- (4) 作废发票:在为交易活动开具时,需开具的负数发票。
- (5) 负数发票:在为交易活动开具时,需开具的负数发票。
- (6) 信用评级:银行内部根据企业不予放贷。
- (7) 客户流失率:因为贷款利率等

2021 MCM
Problem C: Confirming the Buzz about Hornets

In September 2019, a colony of *Vespa mandarinia* (also known as the Asian giant hornet) was discovered on Vancouver Island in British Columbia, Canada. The nest was quickly destroyed, but the news of the event spread rapidly throughout the area. Since that time, several confirmed sightings of the pest have occurred in neighboring Washington State, as well as a multitude of mistaken sightings. See Figure 1 below for a map of detections, hornet watches, and public sightings.




Figure 1: Map depicting Asian Giant Hornet Detections, as well as Hornet Watch and Public Sighting locations.¹

2021 MCM Problem A: Fungi

The **carbon cycle** describes the process of the exchange of carbon throughout the **geochemical cycle** of the Earth, and is a vital component for life on the planet. Part of the carbon cycle includes the decomposition of compounds, allowing carbon to be renewed and used in other forms. One key component of this part of the process is the decomposition of plant material and woody fibers.

Some of the key agents in decomposing woody fibers are **fungi**. The authors of a recent research article on wood decomposition by fungi identified fungi traits that determine decomposition rates and also noted links between certain traits^[1]. In particular, the slow growing strains of fungi tend to be better able to survive and grow in the presence of environmental changes with respect to moisture and temperature, while the faster growing strains tend to be less robust to the same changes. A synopsis of this article can be found below on page 3.

These researchers examined a large number of traits associated with different fungi and their role in the decomposition of ground litter (dead plant material) and woody fibers. For this MCM Problem you should focus on just two traits of a fungus: the growth rate of the fungus and the fungus' tolerance to moisture. Your primary goal is to model the decomposition of woody fibers in a given patch of land, and do so in the presence of multiple types of fungi breaking down woody fibers in the same area.

As you explore the relationship of the two traits of interest, growth rate and **moisture tolerance**, with the rate of decomposition, several questions may arise to include: Using these two traits, how do the different fungi interact and decompose ground litter in a fixed patch of land in different environments? Within these different environments, how will the decomposition be impacted over time as conditions vary? How do environmental changes and the variation in environmental change impact the long-term dynamics with respect to decomposition, as well as competition between fungi in a given environment? The estimation for the decomposition rates, given the growth rate, is shown in **Figure 1**. The estimation of the decomposition rates, given the relative moisture tolerance, is shown in **Figure 2**.




Figure 1: The relationship between the hyphal extension rate (mm/day) of various fungi and the resulting wood decomposition rate (% mass loss over 122 days) at various temperatures. (Figure 1C in [1]).




Figure 2: The relationship between the moisture tolerance (difference of each isolate's competitive ranking and their moisture niche width, both scaled to [0,1]) of various fungi and the resulting wood decomposition rate (% mass loss over 122 days, log transformed). (Figure 4A in [1]).

2021 MCM Problem B: Fighting Wildfires

Background

The 2019-2020 fire season in Australia saw devastating wildfires in every state, with the worst impact in New South Wales and eastern Victoria. The wildfires occurred during a severe drought and persistent heat wave exacerbated by climate-change. **Figure 1** shows the wildfire hot spots in this area from October 1, 2019 to January 7, 2020, with yellow showing fires from October 1st to January 6th, and red showing active fires on January 7, 2020.

Firefighters have used drones for **surveillance** and **situational awareness** (SSA) for several years; SSA drones carry high definition & thermal imaging cameras and telemetry sensors that monitor and report data from wearable devices on front-line personnel. Wearable devices can be used as Personal Locator Beacons or more complex environmental monitors. SSA drones help monitor the evolving situation, letting the **Emergency Operations Center (EOC)** best direct active crews for optimal effect and maximal safety.




Figure 1: Wildfire Hot Spots in Southeast Australia, Oct 1, 2019 to Jan 7, 2020. Source: Australian Government Bureau of Meteorology; NASA Fire Information for Resource Management System.

Two-way radio communication allows **“boots-on-the-ground” forward teams** to give status reports to the EOC and allows the EOC to give orders directly to forward teams. Deployed personnel carry handheld two-way radios operating in the **VHF/UHF** bands. The range of handheld radios is limited by their low transmitting power, typically a maximum of 5 watts, and is determined mainly by distance and physical topography in rural areas or “building topography” in urban areas; weather has little effect on VHF/UHF signals. A 5-watt radio has a nominal range of 5 km over flat, unobstructed ground, but drops to 2 km in an urban area. **Repeaters, transceivers** that automatically rebroadcast signals at higher powers, can extend radio range. A repeater located between the front lines and the EOC can relay radio signals both from the front lines to the EOC and from the EOC to the front lines. The range of a repeater is also determined by distance and topography, but is significantly greater than lower power handheld radios.

Recently, hovering drones carrying repeaters have been used to dramatically extend the range of low power radios on the front lines. A 10-watt repeater, weighing 1.3 kg carried by a drone hovering well above ground level, can achieve a range of 20 km. Akme Corporation's prototype WileE-15.2X hybrid drone is projected to cost approximately \$10,000 (AUD) when equipped with either a radio repeater or video & telemetry capability. Tests have shown this drone has the capabilities listed in **Table 1**.

Table 1. WileE-15.2X Hybrid Drone Capabilities

Flight range: 30 km	Maximum speed: 20 m/s	Maximum flight time: 2.50 hr
1.75 hour recharge time for the built-in battery.		
Note: Auxiliary batteries for radios or video/telemetry can be swapped while the built-in battery recharges.		

2022 MCM Problem C: Trading Strategies



Background

Market traders buy and sell volatile assets frequently, with a goal to maximize their total return. There is usually a commission for each purchase and sale. Two such assets are gold and bitcoin.



Figure 1: Gold daily prices, U.S. dollars per troy ounce. Source: London Bullion Market Association, 9/11/2021



Figure 2: Bitcoin daily prices, U.S. dollars per bitcoin. Source: NASDAQ, 9/11/2021

Requirement

You have been asked by a trader to develop a model that uses **only** the past stream of daily prices to date to determine each day if the trader should buy, hold, or sell their assets in their portfolio.

You will start with \$1000 on 9/11/2016. You will use the five-year trading period, from 9/11/2016 to 9/10/2021. On each trading day, the trader will have a portfolio consisting of cash, gold, and bitcoin [C, G, B] in U.S. dollars, troy ounces, and bitcoins, respectively. The initial state is [1000, 0, 0]. The commission for each transaction (purchase or sale) costs $\alpha\%$ of the amount traded. Assume $\alpha_{\text{gold}} = 1\%$ and $\alpha_{\text{bitcoin}} = 2\%$. There is no cost to hold an asset.



度的关系，并对附件 2 中 350 度时给定的催化剂组合在一次实验不同时间的测试结果进行分析。

- (2) 探讨不同催化剂组合及温度对乙醇转化率以及 C4 烯烃选择性大小的影响。
- (3) 如何选择催化剂组合与温度，使得在相同实验条件下 C4 烯烃收率尽可能高。若使温度低于 350 度，又如何选择催化剂组合与温度，使得 C4 烯烃收率尽可能高。

2021 年高教社杯全国大学生数学建模竞赛题目

(请先阅读“全国大学生数学建模竞赛论文格式规范”)

B 题 乙醇偶合制备 C4 烯烃

C4 烯烃广泛应用于化工产品 & 医药的生产，乙醇是生产制备 C4 烯烃的原料。在制备过程中，催化剂组合（即：Co 负载量、Co/SiO₂ 和 HAP 装料比、乙醇浓度的组合）与温度对 C4 烯烃的选择性和 C4 烯烃收率将产生影响（名词解释见附录）。因此通过对催化剂组合设计，探索乙醇催化偶合制备 C4 烯烃的工艺条件具有重要的意义和价值。

某化工实验室针对不同催化剂在不同温度下做了一系列实验，结果如附件 1 和附件 2 所示。请通过数学建模完成下列问题：

- (1) 对附件 1 中每种催化剂组合，分别研究乙醇转化率、C4 烯烃的选择性与温度的关系，并对附件 2 中 350 度时给定的催化剂组合在一次实验不同时间的测试结果进行分析。
- (2) 探讨不同催化剂组合及温度对乙醇转化率以及 C4 烯烃选择性大小的影响。
- (3) 如何选择催化剂组合与温度，使得在相同实验条件下 C4 烯烃收率尽可能高。若使温度低于 350 度，又如何选择催化剂组合与温度，使得 C4 烯烃收率尽可能高。
- (4) 如果允许再增加 5 次实验，应如何设计，并给出详细理由。

附录：名词解释与附件说明

温度：反应温度。

选择性：某一个产物在所有产物中的占比。

时间：催化剂在乙醇氛围下的反应时间，单位分钟（min）。

Co 负载量：Co 与 SiO₂ 的重量之比。例如，“Co 负载量为 1wt%”表示 Co 与 SiO₂ 的重量之比为 1:100，记作“1wt%Co/SiO₂”，依次类推。

HAP：一种催化剂载体，中文名称羟基磷灰石。

2021 高教社杯全国大学生数学建模竞赛 B 题评阅要点

[说明]本要点仅供参考，各赛区评阅组应根据对题目的理解及学生的解答，自主地进行评阅。

本题要求探究催化剂组合（Co 负载量、Co/SiO₂ 和 HAP 装料比、乙醇浓度的组合）、温度对 C4 烯烃的选择性和 C4 烯烃收率的影响，以更好地进行催化剂结构设计并提高乙醇偶合制备 C4 烯烃收率。本题目主要考察学生对实验数据的认识处理以及数据对模型影响的分析能力，包括数据处理和可视化、相关性分析、检验、多元非线性回归分析、实验设计、误差分析以及影响因素的分析能力。


（1）对实验数据进行探索性分析，包括对数据的预处理、可视化以及简单的数据相关性展示，对不同催化剂作用下乙醇转化率、C4 烯烃的选择性与温度进行相关分析，并说明其显著性。尝试多种拟合模型，选择较优的拟合函数，并得到乙醇转化率、C4 烯烃的选择性与温度的函数关系。在对给定催化剂在温度为 350℃ 的情况下进行稳定性分析时可以使用最值差值法或方差分析。如果用某类函数（比如一次，二次等）直接拟合得到关系，且没有进行误差分析或检验，则不是好的做法。


（2）以 Co 负载量、Co/SiO₂ 和 HAP 装料比、乙醇浓度、温度为自变量，分别对乙醇转化率、C4 烯烃的选择性影响进行分析（如多因素方差分析），给出他们对乙醇转化率、C4 烯烃的选择性的影响程度。考虑到乙醇转化率和 C4 烯烃选择性数据特点，可以先将数据进行某些变换，然后建立回归等模型，并与数据转换前的拟合结果进行比较。如能给出模型的预测精度，则应当鼓励。

（3）分别讨论 Co 负载量、Co/SiO₂ 和 HAP 装料比、乙醇浓度、温度对乙醇转化率和 C4 烯烃的选择性的影响，分析各个影响因素之间的交互作用，建立 C4 烯烃收率与温度、装料比、Co 负载量、乙醇浓度之间的模型，并给出 C4 烯烃收率最大时的催化剂组合。也可以将 C4 烯烃的选择性最大为目标进行类似处理。化学反应是在以上影响因素的共同作用下的结果，如果没有进行交互作用分析，没有给出最佳的催化剂组合，则不是好的做法。如果 C4 烯烃收率最大时温度远高于实验最高温度，不是好的结果。


（4）学生应该先给出新实验设计的思路、准则或模型，在此基础上给出 5 次具体的实验方案，包括催化剂组合与温度。最好能考虑实验样本点空间均匀分布性，也希望包括 C4 烯烃收率最大的实验。若只给出 5 次实验，而且缺少必要的模型或者实验设计，则不是好做法。









Classification




Regression





线性回归基本原理与应用





回归分析 (Regression Analysis)是确定两种或两种以上变量间相互依赖的定量关系的一种统计分析方法。


- 按涉及变量个数划分
 - 一元回归分析
 - 多元回归分析
- 按自变量和因变量之间关系划分
 - 线性回归分析
 - 非线性回归分析

回归分析主要解决两个问题

- 一是确定几个变量之间是否存在相关关系，如果存在，找出它们之间适当的数学表达式。
- 二是根据一个或几个变量的值，预测或控制另一个或几个变量的值。









$$y^{(i)} = w_0 + w_1 x^{(i)} + \varepsilon^{(i)} = h_w(x^{(i)}) + \varepsilon^{(i)}$$






$$J(w) = \frac{1}{2m} \sum_{i=1}^m (y^{(i)} - h_w(x^{(i)}))^2 = \frac{1}{2m} \sum_{i=1}^m (y^{(i)} - w_0 - w_1 x^{(i)})^2$$







$$J(w) = \frac{1}{2m} \sum_{i=1}^m (y^{(i)} - h_w(x^{(i)}))^2 = \frac{1}{2m} \sum_{i=1}^m (y^{(i)} - w_0 - w_1 x^{(i)})^2$$

求解过程：

1. 分别对 w_0 和 w_1 求一阶偏导，并令其一阶偏导值为0。即：

$$\frac{\partial J}{\partial w_0} = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} - w_0 - w_1 x^{(i)}) = 0$$

$$\frac{\partial J}{\partial w_1} = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} - w_0 - w_1 x^{(i)}) x^{(i)} = 0$$



2. 根据上述两式即可求解得到 w_0 和 w_1 的值，即：

$$\frac{\partial J}{\partial w_0} = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} - w_0 - w_1 x^{(i)}) = 0$$

$$w_1 = \frac{\overline{x \cdot y} - \overline{x} \overline{y}}{\overline{x^2} - \overline{x}^2}$$

$$\frac{\partial J}{\partial w_1} = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} - w_0 - w_1 x^{(i)}) x^{(i)} = 0$$

$$w_0 = \overline{y} - w_1 \overline{x}$$



例： 某种商品与家庭平均消费量的关系

以某家庭为调查单位，某种商品在某年各月的家庭平均月消费量 Y (kg)与其价格 X (元/kg) 间的调查数据如表所示。

价格X	5.0	5.2	5.8	6.4	7.0	7.0	8.0	8.3	8.7	9.0	10.0	11
消费量Y	4.0	5.0	3.6	3.8	3.0	3.5	2.9	3.1	2.9	2.2	2.5	2.6

$$w_0 = \bar{y} - w_1 \bar{x} \quad w_1 = \frac{\overline{x \cdot y} - \bar{x} \bar{y}}{\overline{x^2} - \bar{x}^2}$$

价格X	5.0	5.2	5.8	6.4	7.0	7.0	8.0	8.3	8.7	9.0	10.0	11
消费量Y	4.0	5.0	3.6	3.8	3.0	3.5	2.9	3.1	2.9	2.2	2.5	2.6


拟合优度指所求得的回归直线对观测值的拟合程度。

离差 = $y_i - \bar{y}$ ，表示实际值与平均值之差。

回归差 = $\hat{y}_i - \bar{y}$ ，表示估计值与平均值之差。

残差 = $y_i - \hat{y}_i$ ，表示实际值与估计值之差。

其中，离差=回归差+残差。三者关系如下：



总平方和TSS表示因变量的 n 个观察值与其均值的误差总和， TSS 是各个数据离差的平方和，即：

$$TSS = \sum_{i=1}^n (y_i - \bar{y})^2$$

回归平方和ESS表示自变量 x 的变化对因变量 y 取值变化的影响，ESS是各个数据回归差的平方和，即：

$$ESS = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

残差平方和RSS表示实际值与拟合值之间的差异程度， RSS 是各个数据残差的平方和。即：

$$RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

TSS、ESS、RSS三者之间关系为： $TSS=ESS+RSS$ 。

拟合优度 (Goodness of Fit) 是指回归直线对观测值的拟合程度。度量拟合优度的统计量是决定系数 (亦称确定系数) R^2 , 计算公式为:

$$R^2 = \frac{ESS}{TSS} = \frac{TSS - RSS}{TSS} = 1 - \frac{RSS}{TSS}$$


其中, $R^2 \in [0,1]$, R^2 越接近于1, 说明回归曲线拟合度越好; 越小, 说明回归曲线拟合度越差。

$R^2=0$ 时, 表示自变量 与因变量 没有线性关系。 $R^2=1$ 时, 表示回归曲线与样本点重合。



回归分析的步骤

- **确定变量。**寻找与预测目标的相关影响因素，即自变量，并从中选出主要的影响因素。
- **建立预测模型。**依据自变量和因变量的历史统计资料进行计算，在此基础上建立回归分析预测模型。
- **计算预测误差。**回归预测模型是否可用于实际预测，取决于对回归预测模型的检验和对预测误差的计算。
- **确定预测值。**利用回归预测模型计算预测值，并对预测值进行综合分析，确定最后的预测值。



2021 年高教社杯全国大学生数学建模竞赛题目

(请先阅读“全国大学生数学建模竞赛论文格式规范”)

B 题 乙醇偶合制备 C4 烯烃

C4 烯烃广泛应用于化工产品 & 医药的生产，乙醇是生产制备 C4 烯烃的原料。在制备过程中，催化剂组合（即：Co 负载量、Co/SiO₂ 和 HAP 装料比、乙醇浓度的组合）与温度对 C4 烯烃的选择性和 C4 烯烃收率将产生影响（名词解释见附录）。因此通过对催化剂组合设计，探索乙醇催化偶合制备 C4 烯烃的工艺条件具有重要的意义和价值。

某化工实验室针对不同催化剂在不同温度下做了一系列实验，结果如附件 1 和附件 2 所示。请通过数学建模完成下列问题：

- (1) 对附件 1 中每种催化剂组合，分别研究乙醇转化率、C4 烯烃的选择性与温度的关系，并对附件 2 中 350 度时给定的催化剂组合在一次实验不同时间的测试结果进行分析。
- (2) 探讨不同催化剂组合及温度对乙醇转化率以及 C4 烯烃选择性大小的影响。
- (3) 如何选择催化剂组合与温度，使得在相同实验条件下 C4 烯烃收率尽可能高。若使温度低于 350 度，又如何选择催化剂组合与温度，使得 C4 烯烃收率尽可能高。
- (4) 如果允许再增加 5 次实验，应如何设计，并给出详细理由。

附录：名词解释与附件说明

温度：反应温度。

选择性：某一个产物在所有产物中的占比。

时间：催化剂在乙醇氛围下的反应时间，单位分钟（min）。

Co 负载量：Co 与 SiO₂ 的重量之比。例如，“Co 负载量为 1wt%”表示 Co 与 SiO₂ 的重量之比为 1:100，记作“1wt%Co/SiO₂”，依次类推。

HAP：一种催化剂载体，中文名称羟基磷灰石。

度的关系，并对附件 2 中 350 度时给定的催化剂组合在一次实验不同时间的测试结果进行分析。

- (2) 探讨不同催化剂组合及温度对乙醇转化率以及 C4 烯烃选择性大小的影响。
- (3) 如何选择催化剂组合与温度，使得在相同实验条件下 C4 烯烃收率尽可能高。若使温度低于 350 度，又如何选择催化剂组合与温度，使得 C4 烯烃收率尽可能高。

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q
	催化剂组合 编号	催化剂组合	温度	乙醇转化率 (%)	乙烯选择 性 (%)	C4烯烃选择 性(%)	乙醛选择性 (%)	碳数为4-12脂肪 醇 选择性 (%)	甲基苯甲醛和甲基 苯甲醇选择性(%)	其他生成物 的选择性(%)							
1																	
2			250	2.07	1.17	34.05	2.41	52.59	0	9.78							
3			275	5.85	1.63	37.43	1.42	53.21	0	6.31							
4	A1	200mg 1wt%Co/SiO2-	300	14.97	3.02	46.94	4.71	35.16	1	9.17							
5		200mg HAP-乙醇浓度	325	19.68	7.97	49.7	14.69	15.16	2.13	10.35							
6		1.68ml/min	350	36.80	12.46	47.21	18.66	9.22	1.69	10.76							
7			250	4.60	0.61	18.07	0.94	72.99	0	7.39							
8			275	17.20	0.51	17.28	1.43	72.62	0	8.16							
9	A2	200mg 2wt%Co/SiO2-	300	38.92	0.85	19.6	2.21	67.5	0	9.84							
10		200mg HAP-乙醇浓度	325	56.38	1.43	30.62	3.79	51.21	0	12.95							
11		1.68ml/min	350	67.88	2.76	39.1	4.2	36.92	1.87	15.15							
12			250	9.7	0.13	5.5	1.23	85.09	3.97	4.08							
13			275	19.2	0.33	8.04	1.71	82.07	2.88	4.97							
14			300	29.3	0.71	17.01	3.63	66.9	3.18	8.57							
15	A3	200mg 1wt%Co/SiO2-	325	37.6	1.83	28.72	5.72	49.77	3.44	10.52							
16		200mg HAP-乙醇浓度	350	48.9	2.85	36.85	7.23	38.29	3.51	11.27							
17		0.9ml/min	400	83.7	6.76	53.43	8.95	14.37	3.38	13.11							
18			450	86.4	14.84	49.9	8.39	12.41	2.09	12.37							
19			250	4.0	0.27	9.62	1.49	79.51	6.53	2.58							
20			275	12.1	0.36	8.62	1.66	81.44	5.18	2.74							
21	A4	200mg	300	29.5	0.54	10.72	2.41	76.32	5.88	4.13							
22		0.5wt%Co/SiO2-	325	43.3	1.02	18.89	4.42	59.65	7.64	8.38							
		200mg HAP-乙醇浓度															

$$y^{(i)} = h_w(x^{(i)}) + \varepsilon^{(i)}$$

$$J(w) = \frac{1}{2m} \sum_{i=1}^m (y^{(i)} - h_w(x^{(i)}))^2$$

$$y^{(i)} = h_w(x^{(i)}) + \varepsilon^{(i)}$$

$$= w_0 + w_1 x_1^{(i)} + w_2 x_2^{(i)} + w_n x_n^{(i)}$$

$$J(w) = \frac{1}{2m} \sum_{i=1}^m (y^{(i)} - h_w(x^{(i)}))^2$$

$$= \frac{1}{2m} \sum_{i=1}^m (w_0 + w_1 x_1^{(i)} + w_2 x_2^{(i)} + w_n x_n^{(i)} - h_w(x^{(i)}))^2$$



例：某商品销售量与商品价格和人均月收入之间的关系

已知某商品的销售量受商品价格和人均月收入这两个因素的影响，下表是该商品在某年1月至10月间每个月的销售量情况。

月份	1	2	3	4	5	6	7	8	9	10
商品价格 (元/件)	89	78	70	60	69	52	45	56	32	45
人均月收入 (元)	560	530	600	680	750	830	880	830	980	1100
商品销售量 (件)	5800	5890	6200	6800	7100	8900	9000	8100	9990	9800

$$\mathbf{y} = \mathbf{X}\mathbf{w} + \boldsymbol{\varepsilon}$$

$$\begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(i)} \\ \vdots \\ y^{(m)} \end{bmatrix} = \begin{bmatrix} x_0^{(1)} & x_1^{(1)} & \cdots & x_j^{(1)} & \cdots & x_n^{(1)} \\ x_0^{(2)} & x_1^{(2)} & \cdots & x_j^{(2)} & \cdots & x_n^{(2)} \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ x_0^{(i)} & x_1^{(i)} & \cdots & x_j^{(i)} & \cdots & x_n^{(i)} \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ x_0^{(m)} & x_1^{(m)} & \cdots & x_j^{(m)} & \cdots & x_n^{(m)} \end{bmatrix} \times \begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_j \\ \vdots \\ w_n \end{bmatrix} + \begin{bmatrix} \varepsilon^{(1)} \\ \varepsilon^{(2)} \\ \vdots \\ \varepsilon^{(i)} \\ \vdots \\ \varepsilon^{(m)} \end{bmatrix}$$

$$x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix} \quad c = \begin{bmatrix} c_1 \\ \vdots \\ c_m \end{bmatrix}$$

$$A = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix}$$

$$x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix} \quad c = \begin{bmatrix} c_1 \\ \vdots \\ c_m \end{bmatrix} \quad A = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix}$$

$$y = c^T x = \sum_{i=1}^n c_i x_i$$

$$y = Ax = \left[\sum_{i=1}^n a_{1i} x_i \quad \cdots \quad \sum_{i=1}^n a_{mi} x_i \right]^T$$

$$y = x^T Ax = \sum_{i=1}^n \sum_{j=1}^m a_{ij} x_i x_j$$



$$\begin{aligned}y^{(i)} &= h_w(x^{(i)}) + \varepsilon^{(i)} \\&= w_0 + w_1 x_1^{(i)} + w_2 x_2^{(i)} + w_n x_n^{(i)}\end{aligned}$$

$$\begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(i)} \\ \vdots \\ y^{(m)} \end{bmatrix} = \begin{bmatrix} x_0^{(1)} & x_1^{(1)} & \cdots & x_j^{(1)} & \cdots & x_n^{(1)} \\ x_0^{(2)} & x_1^{(2)} & \cdots & x_j^{(2)} & \cdots & x_n^{(2)} \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ x_0^{(i)} & x_1^{(i)} & \cdots & x_j^{(i)} & \cdots & x_n^{(i)} \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ x_0^{(m)} & x_1^{(m)} & \cdots & x_j^{(m)} & \cdots & x_n^{(m)} \end{bmatrix} \times \begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_j \\ \vdots \\ w_n \end{bmatrix} + \begin{bmatrix} \varepsilon^{(1)} \\ \varepsilon^{(2)} \\ \vdots \\ \varepsilon^{(i)} \\ \vdots \\ \varepsilon^{(m)} \end{bmatrix}$$

$$\mathbf{y} = \mathbf{X}\mathbf{w} + \boldsymbol{\varepsilon}$$

$$y^{(i)} = h_w(x^{(i)}) + \varepsilon^{(i)}$$



$$\mathbf{y} = \mathbf{X}\mathbf{w} + \boldsymbol{\varepsilon}$$

$$J(w) = \frac{1}{2m} \sum_{i=1}^m (y^{(i)} - h_w(x^{(i)}))^2$$



$$J(w) = \frac{1}{2m} \boldsymbol{\varepsilon}^T \boldsymbol{\varepsilon} = \frac{1}{2m} (\mathbf{y} - \mathbf{X}\mathbf{w})^T (\mathbf{y} - \mathbf{X}\mathbf{w})$$



$$x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix} \quad c = \begin{bmatrix} c_1 \\ \vdots \\ c_m \end{bmatrix} \quad A = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix}$$

$$y = c^T x = \sum_{i=1}^n c_i x_i \quad \frac{\partial y}{\partial x} = c$$

$$x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix} \quad c = \begin{bmatrix} c_1 \\ \vdots \\ c_m \end{bmatrix} \quad A = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix}$$

$$y = Ax = \left[\sum_{i=1}^n a_{1i} x_i \quad \cdots \quad \sum_{i=1}^n a_{mi} x_i \right]^T \quad \frac{\partial y}{\partial x} = A^T$$

$$x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix} \quad c = \begin{bmatrix} c_1 \\ \vdots \\ c_m \end{bmatrix} \quad A = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix}$$

$$y = x^T A x = \sum_{i=1}^n \sum_{j=1}^m a_{ij} x_i x_j$$

$$\frac{\partial y}{\partial x} = (A^T + A)x$$



$$J(\mathbf{w}) = \frac{1}{2m} \boldsymbol{\varepsilon}^T \boldsymbol{\varepsilon} = \frac{1}{2m} (\mathbf{y} - \mathbf{X}\mathbf{w})^T (\mathbf{y} - \mathbf{X}\mathbf{w})$$

$$\frac{\partial J}{\partial \mathbf{w}} = \frac{1}{m} \mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{y}) \quad \Rightarrow \quad \mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

例：某商品销售量与商品价格和人均月收入之间的关系

已知某商品的销售量受商品价格和人均月收入这两个因素的影响，下表是该商品在某年1月至10月间每个月的销售量情况。


月份	1	2	3	4	5	6	7	8	9	10
商品价格 (元/件)	89	78	70	60	69	52	45	56	32	45
人均月收入 (元)	560	530	600	680	750	830	880	830	980	1100
商品销售量 (件)	5800	5890	6200	6800	7100	8900	9000	8100	9990	9800

回归分析的步骤


- **确定变量。** 寻找与预测目标的相关影响因素，即自变量，并从中选出主要的影响因素。
- **建立预测模型。** 依据自变量和因变量的历史统计资料进行计算，在此基础上建立回归分析预测模型。
- **计算预测误差。** 回归预测模型是否可用于实际预测，取决于对回归预测模型的检验和对预测误差的计算。
- **确定预测值。** 利用回归预测模型计算预测值，并对预测值进行综合分析，确定最后的预测值。

什么是分类？

- 分类就是根据以往的数据和结果对另一部分数据进行结果的预测。
- 使用训练数据集中得到的规则进行新数据的分类。



Classification



Regression

分类与预测

- 不同点
 - 分类是预测类对象的分类标号（或离散值），根据训练数据集和类标号属性，构建模型来分类现有数据，并用来分类新数据。
 - 预测是建立连续函数值模型评估无标号样本类，或评估给定样本可能具有的属性值或值区间，即用来估计连续值或量化属性值，比如预测空缺值。
- 相同点
 - 分类和预测的共同点是两者都需要构建模型，都用模型来估计未知值。预测中主要的估计方法是回归分析。

回归


商品价格 (元/件)	人均月收入 (元)	商品销售量 (件)
89	560	5800
78	530	5890
70	600	6200
60	680	6800
69	750	7100
52	830	8900
45	880	9000
56	830	8100
32	980	9990
45	1100	9800

分类

年龄	吸烟史	有无家族病史	体重范围	患病与否
青年	无	无	较低	否
青年	无	无	中	否
青年	0-5年	无	中	否
青年	0-5年	有	低	是
中年	无	无	较低	否
中年	无	无	低	否
中年	无	无	高	否
中年	5年以上	有	高	是
中年	无	有	高	是
中年	无	有	高	是
老年	无	有	较高	是
老年	无	有	高	是
老年	5年以上	无	高	是
老年	5年以上	无	较高	是
老年	0-5年	无	中	否

A: 给你介绍一位男士。
B: 好看吗?
A: 一般。
B: 性格怎样?
A: 不好。
B: 不见!


A: 给你介绍一位男士。
B: 好看吗?
A: 难看。
B: 收入高吗?
A: 不高。
B: 不见!



A: 给你介绍一位男士。
B: 好看吗?
A: 好看。
B: 见!

A: 给你介绍一位男士。
B: 好看吗?
A: 一般。
B: 性格好吗?
A: 好。
B: 见!

A: 给你介绍一位男士。
B: 好看吗?
A: 难看。
B: 收入高吗?
A: 高。
B: 见!



分类的相关知识：

– 1、信息熵

信息熵用来衡量事件的不确定性的的大小，计算公式如下：

$$Infor(x) = -p(x) \times \log_2 p(x)$$

信息熵具有可加性，即多个期望信息，计算公式如下：

$$Infor(X) = - \sum_{i=1}^m p(x_i) \times \log_2 p(x_i)$$



分类的相关知识：

– 2、信息增益

信息增益表示某一特征的信息对类标签的不确定性减少的程度。

$$g(D|A) = Infor(D) - Infor(D|A)$$

其中 $Infor(D|A)$ 是在特征 A 给定条件下对数据集 D 进行划分所需要的期望信息，它的值越小表示分区的纯度越高，计算公式如下所示。

$$Infor(D|A) = \sum_{j=1}^n \frac{|D_j|}{|D|} \times Info(D_j)$$

其中 n 是数据分区数， $|D_j|$ 表示第 j 个数据分区的长度， $\frac{|D_j|}{|D|}$ 表示第 j 个数据分区的权重。



- 例 信息增益的计算
- 下表是带有标记类的训练集 D ，训练集的列是一些特征，表中最后一列的类标号为是否提供贷款，有两个不同的取值，计算按照每个特征进行划分的信息增益。

ID	学历	婚否	是否有车	收入水平	类别
1	专科	否	否	中	否
2	专科	否	否	高	否
3	专科	是	否	高	是
4	专科	是	是	中	是
5	专科	是	否	中	否
6	本科	否	否	中	否
7	本科	否	否	高	否
8	本科	是	是	高	是
9	本科	是	是	很高	是
10	本科	否	是	很高	是
11	研究生	否	是	很高	是
12	研究生	否	是	高	是
13	研究生	是	否	高	是
14	研究生	是	否	很高	是
15	研究生	否	否	中	否

①根据公式计算信息熵 $Inf(D)$ 。

$$Inf(D) = -\frac{9}{15} \times \log_2 \frac{9}{15} - \frac{6}{15} \times \log_2 \frac{6}{15} = 0.971$$

②计算按照每个特征进行划分的期望信息， A 代表特征“学历”， B 代表特征“婚否”， C 代表特征“是否有车”， E 代表特征“收入水平”。

$$\begin{aligned} Inf(D|A) = & \frac{5}{15} \times \left(-\frac{2}{5} \log_2 \frac{2}{5} - \frac{3}{5} \log_2 \frac{3}{5} \right) + \frac{5}{15} \times \left(-\frac{3}{5} \log_2 \frac{3}{5} - \frac{2}{5} \log_2 \frac{2}{5} \right) \\ & + \frac{5}{15} \times \left(-\frac{4}{5} \log_2 \frac{4}{5} - \frac{1}{5} \log_2 \frac{1}{5} \right) = 0.888 \end{aligned}$$

$$Inf(D|B) = \frac{10}{15} \times \left(-\frac{4}{10} \log_2 \frac{4}{10} - \frac{6}{10} \log_2 \frac{6}{10} \right) + \frac{5}{15} \times \left(-\frac{5}{5} \log_2 \frac{5}{5} \right) = 0.667$$

$$Inf(D|C) = \frac{9}{15} \times \left(-\frac{6}{9} \log_2 \frac{6}{9} - \frac{3}{9} \log_2 \frac{3}{9} \right) + \frac{6}{15} \times \left(-\frac{6}{6} \log_2 \frac{6}{6} \right) = 0.951$$

$$\begin{aligned} Inf(D|E) &= \frac{5}{15} \times \left(-\frac{4}{5} \log_2 \frac{4}{5} - \frac{1}{5} \log_2 \frac{1}{5} \right) + \frac{6}{15} \times \left(-\frac{2}{6} \log_2 \frac{2}{6} - \frac{4}{6} \log_2 \frac{4}{6} \right) + \frac{4}{15} \times \left(-\frac{4}{4} \log_2 \frac{4}{4} \right) \\ &= 0.608 \end{aligned}$$



②计算按照每个特征进行划分的期望信息， A 代表特征“学历”， B 代表特征“婚否”， C 代表特征“是否有车”， E 代表特征“收入水平”。

$$\begin{aligned} Infor(D|A) &= \frac{5}{15} \times \left(-\frac{2}{5} \log_2 \frac{2}{5} - \frac{3}{5} \log_2 \frac{3}{5} \right) + \frac{5}{15} \times \left(-\frac{3}{5} \log_2 \frac{3}{5} - \frac{2}{5} \log_2 \frac{2}{5} \right) \\ &\quad + \frac{5}{15} \times \left(-\frac{4}{5} \log_2 \frac{4}{5} - \frac{1}{5} \log_2 \frac{1}{5} \right) = 0.888 \end{aligned}$$

$$Infor(D|B) = \frac{10}{15} \times \left(-\frac{4}{10} \log_2 \frac{4}{10} - \frac{6}{10} \log_2 \frac{6}{10} \right) + \frac{5}{15} \times \left(-\frac{5}{5} \log_2 \frac{5}{5} \right) = 0.667$$

$$Infor(D|C) = \frac{9}{15} \times \left(-\frac{6}{9} \log_2 \frac{6}{9} - \frac{3}{9} \log_2 \frac{3}{9} \right) + \frac{6}{15} \times \left(-\frac{6}{6} \log_2 \frac{6}{6} \right) = 0.951$$

$$\begin{aligned} Infor(D|E) &= \frac{5}{15} \times \left(-\frac{4}{5} \log_2 \frac{4}{5} - \frac{1}{5} \log_2 \frac{1}{5} \right) + \frac{6}{15} \times \left(-\frac{2}{6} \log_2 \frac{2}{6} - \frac{4}{6} \log_2 \frac{4}{6} \right) + \frac{4}{15} \times \left(-\frac{4}{4} \log_2 \frac{4}{4} \right) \\ &= 0.608 \end{aligned}$$

③计算信息增益

$$g(D|A) = Infor(D) - Infor(D|A) = 0.083$$



$$g(D|B) = Infor(D) - Infor(D|B) = 0.304$$

$$g(D|C) = Infor(D) - Infor(D|C) = 0.019$$

$$g(D|E) = Infor(D) - Infor(D|E) = 0.363$$

决策树基本概念：

决策树算法的基础是二叉树，但不是所有的决策树都是二叉树，还有可能是多叉树，如下图所示。



(1) 构造决策树。

决策树构造过程如下。

- ①输入数据，主要包括训练集的特征和类标号。
- ②选取一个属性作为根节点的分裂属性进行分裂。
- ③对于分裂的每个分支，如果已经属于同一类就不再分了，如果不是同一类，依次选取不同的特征作为分裂属性进行分裂，同时删除已经选过的分裂属性。
- ④不断的重复③，直到到达叶子节点，也就是决策树的最后一层，这时这个节点下的数据都是一类了。
- ⑤最后得到每个叶子节点对应的类标签以及到达这个叶子节点的路径。

(2) 决策树的预测

得到由训练数据构造的决策树以后就可以进行预测了，当待预测的数据输入决策树的时候，根据分裂 属性以及分裂规则进行分裂，最后即可确定所属的类别。

ID	年龄	吸烟史	有无家族病史	体重范围	患病与否
1	23	无	无	较低	否
2	25	无	无	中	否
3	27	0-5年	无	中	否
4	30	0-5年	有	低	是
5	39	无	无	较低	否
6	41	无	无	低	否
7	43	无	无	高	否
8	45	5年以上	有	高	是
9	46	无	有	高	是
10	47	无	有	高	是
11	62	无	有	较高	是
12	63	无	有	高	是
13	66	5年以上	无	高	是
14	66	5年以上	无	较高	是
15	68	0-5年	无	中	否

ID	年龄	吸烟史	有无家族病史	体重范围	患病与否
1	25	无	无	较低	?
2	42	无	无	高	?
3	67	5年以上	无	较高	?

解：①连续型数据的离散化。ID3算法不能直接处理连续型数据，只有通过离散化将连续型数据转化成离散型数据再进行处理。

此例采用等宽分箱法对连续型特征“年龄”离散化：


设定区域范围（设箱子数为3，箱子宽度为 $(68-23)/3=15$ ），

分箱结果为：

箱1：23 25 27 30

箱2：39 41 43 45 46 47

箱3：62 63 66 66 68



ID	年龄	吸烟史	有无家族病史	体重范围	患病与否
1	青年	无	无	较低	否
2	青年	无	无	中	否
3	青年	0-5年	无	中	否
4	青年	0-5年	有	低	是
5	中年	无	无	较低	否
6	中年	无	无	低	否
7	中年	无	无	高	否
8	中年	5年以上	有	高	是
9	中年	无	有	高	是
10	中年	无	有	高	是
11	老年	无	有	较高	是
12	老年	无	有	高	是
13	老年	5年以上	无	高	是
14	老年	5年以上	无	较高	是
15	老年	0-5年	无	中	否



②根据训练数据构造ID3算法的决策树，其中Z代表训练集，A、B、C、D分别代表特征“年龄”、“吸烟史”、“有无家族病史”、“体重范围”，按照每个特征计算其分裂的信息增益。

$$Infor(Z) = -\frac{8}{15} \times \log_2 \frac{8}{15} - \frac{7}{15} \times \log_2 \frac{7}{15} = 0.997$$

$$Infor(Z|A)$$

$$= \frac{4}{15} \times \left(-\frac{3}{4} \times \log_2 \frac{3}{4} - \frac{1}{4} \times \log_2 \frac{1}{4} \right) + \frac{6}{15} \times \left(-\frac{3}{6} \times \log_2 \frac{3}{6} - \frac{3}{6} \times \log_2 \frac{3}{6} \right) + \frac{5}{15} \times \left(-\frac{4}{5} \times \log_2 \frac{4}{5} - \frac{1}{5} \times \log_2 \frac{1}{5} \right) = 0.857$$

$$Infor(Z|B)$$

$$= \frac{9}{15} \times \left(-\frac{5}{9} \times \log_2 \frac{5}{9} - \frac{4}{9} \times \log_2 \frac{4}{9} \right) + \frac{3}{15} \times \left(-\frac{2}{3} \times \log_2 \frac{2}{3} - \frac{1}{3} \times \log_2 \frac{1}{3} \right) + \frac{3}{15} \times \left(-\frac{3}{3} \times \log_2 \frac{3}{3} \right) = 0.778$$

$$Infor(Z|C) = \frac{9}{15} \times \left(-\frac{7}{9} \times \log_2 \frac{7}{9} - \frac{2}{9} \times \log_2 \frac{2}{9} \right) + \frac{6}{15} \times \left(-\frac{6}{6} \times \log_2 \frac{6}{6} \right) = 0.459$$

$$Infor(Z|D)$$

$$= \frac{2}{15} \times \left(-\frac{2}{2} \times \log_2 \frac{2}{2} \right) + \frac{2}{15} \times \left(-\frac{1}{2} \times \log_2 \frac{1}{2} - \frac{1}{2} \times \log_2 \frac{1}{2} \right) + \frac{3}{15} \times \left(-\frac{3}{3} \times \log_2 \frac{3}{3} \right) + \frac{6}{15} \times \left(-\frac{5}{6} \times \log_2 \frac{5}{6} - \frac{1}{6} \times \log_2 \frac{1}{6} \right) + \frac{2}{15} \times \left(-\frac{2}{2} \times \log_2 \frac{2}{2} \right) = 0.393$$



$$g(Z|A) = \text{Infor}(Z) - \text{Infor}(Z|A) = 0.997 - 0.857 = 0.140$$

$$g(Z|B) = \text{Infor}(Z) - \text{Infor}(Z|B) = 0.997 - 0.778 = 0.219$$

$$g(Z|C) = \text{Infor}(Z) - \text{Infor}(Z|C) = 0.997 - 0.459 = 0.538$$

$$g(Z|D) = \text{Infor}(Z) - \text{Infor}(Z|D) = 0.997 - 0.393 = 0.604$$

选择信息增益最大特征“体重范围”作为根结点的分裂属性，将训练集Z划分为5个子集 Z_1 、 Z_2 、 Z_3 、 Z_4 和 Z_5 ，对应的“体重范围”取值分别为“低”、“较低”、“中”、“较高”、“高”。由于 Z_2 、 Z_3 和 Z_4 只有一类数据，所以它们各自成为一个叶结点，三个结点的类标签分别为“否”、“否”、“是”。



③对于 Z_1 继续进行分裂，选择剩余特征中信息增益最大的作为分裂属性。 $Inf_{or}(Z_1) = -\frac{1}{2} \times \log_2 \frac{1}{2} - \frac{1}{2} \times \log_2 \frac{1}{2} = 1$

$$Inf_{or}(Z_1|A) = \frac{1}{2} \times \left(-\frac{1}{1} \times \log_2 \frac{1}{1} \right) + \frac{1}{2} \times \left(-\frac{1}{1} \times \log_2 \frac{1}{1} \right) = 0$$

$$Inf_{or}(Z_1|B) = \frac{1}{2} \times \left(-\frac{1}{1} \times \log_2 \frac{1}{1} \right) + \frac{1}{2} \times \left(-\frac{1}{1} \times \log_2 \frac{1}{1} \right) = 0$$

$$Inf_{or}(Z_1|C) = \frac{1}{2} \times \left(-\frac{1}{1} \times \log_2 \frac{1}{1} \right) + \frac{1}{2} \times \left(-\frac{1}{1} \times \log_2 \frac{1}{1} \right) = 0$$

$$g(Z_1|A) = Inf_{or}(Z_1) - Inf_{or}(Z_1|A) = 1 - 0 = 1$$

$$g(Z_1|B) = Inf_{or}(Z_1) - Inf_{or}(Z_1|B) = 1 - 0 = 1$$

$$g(Z_1|C) = Inf_{or}(Z_1) - Inf_{or}(Z_1|C) = 1 - 0 = 1$$

选择信息增益最大特征作为 Z_1 结点的分裂属性，由于三个属性的信息增益相同，随机挑选一个作为分裂属性，此处选取“有无家族病史”作为分裂属性，它将数据集 Z_1 分成2个子集 Z_{21} 和 Z_{22} ，对应的“有无家族病史”的取值分别为“有”和“无”，在这2个子集中的数据都各自属于同一类，于是就不需要再继续分裂。



④对于 Z_5 继续进行分裂，选择剩余特征中信息增益最大的作为分裂属性。

$$Infor(Z_5) = -\frac{1}{6} \times \log_2 \frac{1}{6} - \frac{5}{6} \times \log_2 \frac{5}{6} = 0.650$$

$$Infor(Z_5|A) = \frac{4}{6} \times \left(-\frac{1}{4} \times \log_2 \frac{1}{4} - \frac{3}{4} \times \log_2 \frac{3}{4} \right) + \frac{2}{6} \times \left(-\frac{2}{2} \times \log_2 \frac{2}{2} \right) = 0.541$$

$$Infor(Z_5|B) = \frac{4}{6} \times \left(-\frac{3}{4} \times \log_2 \frac{3}{4} - \frac{1}{4} \times \log_2 \frac{1}{4} \right) + \frac{2}{6} \times \left(-\frac{2}{2} \times \log_2 \frac{2}{2} \right) = 0.541$$

$$Infor(Z_5|C) = \frac{4}{6} \times \left(-\frac{4}{4} \times \log_2 \frac{4}{4} \right) + \frac{2}{6} \times \left(-\frac{1}{2} \times \log_2 \frac{1}{2} - \frac{1}{2} \times \log_2 \frac{1}{2} \right) = 0.333$$

$$g(Z_5|A) = Infor(Z_5) - Infor(Z_5|A) = 0.650 - 0.541 = 0.109$$

$$g(Z_5|B) = Infor(Z_5) - Infor(Z_5|B) = 0.650 - 0.541 = 0.109$$

$$g(Z_5|C) = Infor(Z_5) - Infor(Z_5|C) = 0.650 - 0.333 = 0.317$$

选择信息增益最大特征“有无家族病史”作为 Z_5 结点的分裂属性，将数据集 Z_5 分成2个子集 Z_{51} 和 Z_{52} ，对应的“有无家族病史”的取值分别为“有”和“无”，“有”对应的 Z_{51} 中的数据都属于同一类，不需要再继续分裂，“无”对应的 Z_{52} 中的数据属于不同类，需要对其进行分裂。



⑤对于 Z_{52} 继续进行分裂，选择剩余特征中信息增益最大的作为分裂属性。

$$Infor(Z_{52}) = -\frac{1}{2} \times \log_2 \frac{1}{2} - \frac{1}{2} \times \log_2 \frac{1}{2} = 1$$

$$Infor(Z_{52}|A) = \frac{1}{2} \times \left(-\frac{1}{1} \times \log_2 \frac{1}{1} \right) + \frac{1}{2} \times \left(-\frac{1}{1} \times \log_2 \frac{1}{1} \right) = 0$$


$$Infor(Z_{52}|B) = \frac{1}{2} \times \left(-\frac{1}{1} \times \log_2 \frac{1}{1} \right) + \frac{1}{2} \times \left(-\frac{1}{1} \times \log_2 \frac{1}{1} \right) = 0$$

$$g(Z_{52}|A) = Infor(Z_{51}) - Infor(Z_{52}|A) = 1 - 0 = 1$$

$$g(Z_{52}|B) = Infor(Z_{51}) - Infor(Z_{52}|B) = 1 - 0 = 1$$

由于两个属性的信息增益相同，随机挑选一个作为分裂属性，此处选取“吸烟史”作为 Z_{52} 结点的分裂属性，将数据集 Z_{52} 分成2个子集 Z_{521} 和 Z_{522} ，对应的“吸烟史”的取值分别为“无”和“5年以上”，在这两个子集中的数据都各自属于同一类，于是就不需要再继续分裂，决策树构造完毕。





根据构建的决策树，可以提取分类规则如下。

- ①IF “体重范围” = “低” AND “有无家族病史” = “有” THEN 患病
- ②IF “体重范围” = “低” AND “有无家族病史” = “无” THEN 没有患病
- ③IF “体重范围” = “较低” THEN 没有患病
- ④IF “体重范围” = “中” THEN 没有患病
- ⑤IF “体重范围” = “较高” THEN 患病
- ⑥IF “体重范围” = “高” AND “有无家族病史” = “有” THEN 患病
- ⑦IF “体重范围” = “高” AND “有无家族病史” = “无” AND “吸烟史” = “无” THEN 没有患病
- ⑧IF “体重范围” = “高” AND “有无家族病史” = “无” AND “吸烟史” = “5年以上” THEN 患病

ID	年龄	吸烟史	有无家族病史	体重范围	患病与否
1	25	无	无	较低	?
2	42	无	无	高	?
3	67	5年以上	无	较高	?

课件代码下载地址



关注公众号：“**数学建模老哥**” 回复“**课件**” 即可免费获取

更多模型、代码、优秀论文等请加QQ群：**1077734962**

更多资料请关注微信公众号：数学建模老哥



更多资料请关注公众号【老哥带你学数模】课件或代码请公众号回复“课件”，QQ群：720736320

THE END



数学建模老哥