

全国大学生数学建模竞赛

2000 年赛题

A 题 DNA 序列分类

2000 年 6 月, 人类基因组计划中 DNA 全序列草图完成, 预计 2001 年可以完成精确的全序列图, 此后人类将拥有一本记录着自身生老病死及遗传进化的全部信息的“天书”。这本大自然写成的“天书”是由 4 个字符 A, T, C, G 按一定顺序排成的长约 30 亿的序列, 其中没有“断句”也没有标点符号, 除了这 4 个字符表示 4 种碱基以外, 人们对它包含的“内容”知之甚少, 难以读懂。破译这部世界上最巨量信息的“天书”是二十一世纪最重要的任务之一。在这个目标中, 研究 DNA 全序列具有什么结构, 由这 4 个字符排成的看似随机的序列中隐藏着什么规律, 又是解读这部天书的基础, 是生物信息学 (Bioinformatics) 最重要的课题之一。

虽然人类对这部“天书”知之甚少, 但也发现了 DNA 序列中的一些规律性和结构。例如, 在全序列中有一些是用于编码蛋白质的序列片段, 即由这 4 个字符组成的 64 种不同的 3 字符串, 其中大多数用于编码构成蛋白质的 20 种氨基酸。又例如, 在不用于编码蛋白质的序列片段中, A 和 T 的含量特别多些, 于是以某些碱基特别丰富作为特征去研究 DNA 序列的结构也取得了一些结果。此外, 利用统计的方法还发现序列的某些片段之间具有相关性, 等等。这些发现让人们相信, DNA 序列中存在着局部的和全局性的结构, 充分发掘序列的结构对理解 DNA 全序列是十分有意义的。目前在这项研究中最普通的思想是省略序列的某些细节, 突出特征, 然后将其表示成适当的数学对象。这种被称为粗粒化和模型化的方法往往有助于研究规律性和结构。

作为研究 DNA 序列的结构的尝试, 提出以下对序列集合进行分类的问题:

1) 下面有 20 个已知类别的人工制造的序列, 其中序列标号 1—10 为 A 类, 11—20 为 B 类。请从中提取特征, 构造分类方法, 并用这些已知类别的序列, 衡量你的方法是否足够好。然后用你认为满意的方法, 对另外 20 个未标明类别的人工序列 (标号 21—40) 进行分类, 把结果用序号 (按从小到大的顺序) 标明它们的类别 (无法分类的不写入):

A 类 _____ ; B 类 _____。

请详细描述你的方法, 给出计算程序。如果你部分地使用了现成的分类方法, 也要将方法名称准确注明。

这 40 个序列放在如下地址的网页上, 用数据文件 Art-model-data 标识, 供下载:

网易网址: www.163.com 教育频道 在线试题;

教育网: www.cbi.pku.edu.cn News mcm2000

教育网: www.csiam.edu.cn/mcm

[注] 目前这些网站上不一定还保存有该文件, 这里将该文件的内容附于本题后。

2) 在同样网址的数据文件 Nat-model-data 中给出了 182 个自然 DNA 序列, 它们都较长。用你的分类方法对它们进行分类, 像 1) 一样地给出分类结果。

提示: 衡量分类方法优劣的标准是分类的正确率, 构造分类方法有许多途径, 例如提取序列的某些特征, 给出它们的数学表示: 几何空间或向量空间的元素等, 然后再选择或构造适合这种数学表示的分类方法; 又例如构造概率统计模型, 然后用统计方法分类等。

(北京工业大学孟大志提供)

[附] 数据文件 Art-model-data 的内容如下:

附录 1: 已知类别的序列 (用于提取特征及检验方法)

A 类 10 个序列:

```
>aggcacggaaaaacgggaataacggaggaggacttggcacggcattacacggaggacgaggtaaaggaggcttctctac
ggccggaagtgaagggggatgatccgcttgaattgtctg
>cggaggacaaacgggatggcggtattggagggtggcgactgttcgggaattattcggtttaaacgggacaaggaaggc
ggctggaacaaccggacgggtggcagcaaaaggaacggacacg
>gggacggatacggattctggccacggacggaaggaggacacggcgacatacacggcggaacggacggaacggaggga
aggaggcggaatcggtacggaggcgcgacggacggag
>atggataacggaaacaaccagacaaacttcggtagaatacagaagcttagatgcatatgttttaataaaattttg
tattattatggtatcataaaaaaagggttcgagataacata
>cggctggcggaacggactggcggttccaaaacggaggaggcgacggaggctacaccacggttcggcggaagg
cggagggtggcaggaggctcattacggggagcggaggcg
```

```

>atggaaaattttcgaaaaggcggcaggcaggaggcaaaggcggaaaaggaaggaacggcggtatattcggaagtggata
ttaggagggcggaataaaaggaacggcggcacaaaggaggcg
>atgggattattgaatggcggaggaagatccggaataaaatatggcggaaagaactgttttcggaatggaaaaaggac
taggaatcgcgcggaaggataggaggcggaaaggacgg
>atggccgctcggcttaggctggaaggacaataaggcggaaattaagggaaggcgttctcgttttcgacaaggaggcgga
ccataggaggcggattaggaacgggtatgaggaggactcgg
>atggcggaaaaaggaaatgttggcatcgcgggctccggcaactggagggtcggccatggaggcgaaaatcgtgggcg
gcggcagcgctggccggagttaggagcgcggcacaaatgt
>tggccgaggaggggcccgctggcgcggttctacaagggtctcgttaaggagggtggcatccaggcgctgcacgct
cggcgcgcgaggaggcacgcgggaaaaaacggggaggcggt

```

B 类 10 个序列:

```

>gtagatttaacgtttttatggaatttatggaattataaaatttaaaatttatatttttagtaagtaaccaacgt
ttttattacttttaaaattaaatatttttaaaatccag
>gtttaattactttatcatttaatttaggttttaatttaaaatttaatttagtaagatgaatttggttttttaaggt
agttatttaattatcgtaaggaaagttaaaatctaagatt
>gtattacaggcagaccttatttaggtattattattttggatttttttttttttaagtaaccgaattat
tttcttaaagacgttacttaatgtcaatgctttatgcagg
>gtagtcttttttagattaaattatgattatgcagttttttacataagaaaatttttttcggagttcatattct
aatctgtctttataaatcttagagatattatccgttaatt
>gtattatattttttattttatttttagaataaattgaggatgtgttaaaaaaaattttttttttttt
tttttttttttttaaaattataaatttaaaatttaaaact
>gttatttttaaaatttaatttttaaaatacaaaatttttactttctaaaattggctctcgatcgataatgtaa
cttattgaatctatagaattacattattgatttttccaga
>gtatgtctatttcacggaagaatgcaccactatagatttgaaattatctatggctaaaaaccctcagtaaaatcaatc
cctaaacccttaaaaaacggcgctatcccgtcagtcgag
>gttaattatttcttaccggcaattaattatttaccggtttatttacaattttttttgtcctatagaga
aattacttacaaaacgtttttacatactattttttgtc
>gttacattatttattatccgttatcgataatttttacctcttttgcgtgagttttattcttacttttttct
tctttataggaatctcatttaataatcttaattttcttag
>gtatttaactctcttacttttttctactctctacattttcatcttctaaaactgttgatttaaaactttgtttct
ttaaggatttttttacttatcctctgttatgttttag

```

附录 2: 测试集 (人工制造)

```

1:
tttagctcagtcagctagctagtttacaatttcgacaccagtttcgaccatctaaatttcgatccgtaccgtaatttagcttagatttggaattaaaggattt
agattgacc
2:
tttagtacagtagctcagtcgaagacgatgtttaccgtaacdgtqacgtaccgtacgctaccgttaccggattccggaagccgattaaggaccgatc
gaaaggga
3:
cggcgaggatttagcgccgacggggaccgggattcgggacccgaggaaattcccggattaagggttagcttccgggattaggggcccgatggctg
ggaccgc
4:
tttagctagctacttttagctatttttagtagtagccagccttaaggctagcttttagctagcattgttcttattgggaccaagttcgactttacgatttagt
ttgaccgta
5:
gaccaaagggtgggctttagggaccgatgcttttagtcgcagctggaccaggtccccagggtattaggcaaaagctgacgggcaattgcaatttaggct
taggccag
6:
gatttacttttagcatttttagctgacgttagcaagcattagcttttagccaatttcgatttgcagtttcgcagctcagtttaacgcgggatcttttagcttcaa
gctttttacg
7:
ggattcggatttaccggggattggcggaacgggaccttttaggtcgggaccattaggagtaaatgcaaaggacgctggtttagccagtccg5tta
aggcttagg
8:
tccttagatttcagttactatattgacttacagtccttgagatttcccttacgattttgacttaaaatttagacgttagggcttatcagttatggattaatttagctt

```

attttcgaga
 9:
 ggccaattccggttaggaaggtgatggccgggggttccgggaggatttaggctgacgggcccatttcggttagggaggccgggacgcgt
 tagggacg
 10:
 cgctaagcagctcaagctcagtcagtcacgtttccaagtcagtaattgccaagttaaccgttagctgacgctgaacgtaaacgatttagctgatg
 actcgtacg
 11:
 ttaaggacttaggctttagcagttacttttagtttagtccaagctacgtttacgggaccagatgctagctagcaatttattatccgtattaggcttaccgtagg
 ttttagcggg
 12:
 tgctaccgggagcttctaagctagctaccgttttagtttgggcccagccttgcgggtttcggattaaattcgttgcagtcgctcrtgggttagtcattcc
 caaaaggt
 13:
 cagttagctgaatcgttttagccatttgacgtaaacatgattttacgtacgtaaatttttagccctgacgttttagctaggaatttatgctgacgtagcgtacgac
 ttttagcacc
 14:
 cggtagggcaaaaggttggtattcgacccagggggaaagcccgggacccgaaccagggcttagcgtaggctgacgctaggcttaggttgaac
 ccggaaag
 15:
 gcggaaggcgtaggttthgggatgcttagccgtaggctagctttcgacacgatcgattcgaccacaggataaaagttaagggaccggttaagtcg
 cggtagccg
 16:
 ctactgacgaacgttttaggcgccccgggagtagtcgttaccgttagtatagcagtcgagtcgcaattcgcaaaagtccttagccttagcccccaga
 gtcgacgct
 17:
 gggatgctgacgctggtagcttttaggcttagcgtagcttttagggcccagctctgcaggaaatgccaaaggaggcccaccgggtagatgccasagt
 gcaccgta
 18:
 aacttttagggcatttccagttttacgggttattttccagtttaactttgcaccattttacgtgttacgatttacgtataatttgacctattttggaccttttagtt
 tgggttacc
 19:
 ttagggccaagtccdcgaggcaahggaattctgatccaagtccaatcacgtacagtcgaagtcacggtttgcagctaccgtttaccgtacgttgaagt
 caaatccat
 20:
 ccattagggtttatttacctgtttattttcccgagaccttaggtttaccgtacttttaacgggtttacgtttgaaattttggactagcttaccctggatttaacg
 gccagttgt


B 题 钢管订购和运输

要铺设一条 $A_1 \rightarrow A_2 \rightarrow \cdots \rightarrow A_{15}$ 的输送天然气的主管道，如图一所示。经筛选后可以生产这种主管道钢管的钢厂有 $S_1, S_2, \dots, S_7$ 。图中粗线表示铁路，单细线表示公路，双细线表示要铺设的管道(假设沿管道或者原来有公路，或者建有施工公路)，圆圈表示火车站，每段铁路、公路和管道旁的阿拉伯数字表示里程(单位 km)。

为方便计，1km 主管道钢管称为 1 单位钢管。

一个钢厂如果承担制造这种钢管，至少需要生产 500 个单位。钢厂 S_i 在指定期限内能生产该钢管的最大数量为 s_i 个单位，钢管出厂销价 1 单位钢管为 p_i 万元，如下表：

i	1	2	3	4	5	6	7
s_i	800	800	1000	2000	2000	2000	3000
p_i	160	155	155	160	155	150	160



图一

1 单位钢管的铁路运价如下表:

里程(km)	≤ 300	301~350	351~400	401~450	451~500
运价(万元)	20	23	26	29	32

里程(km)	501~600	601~700	701~800	801~900	901~1000
运价(万元)	37	44	50	55	60

1000km 以上每增加 1 至 100km 运价增加 5 万元。


公路运输费用为 1 单位钢管每公里 0.1 万元 (不足整公里部分按整公里计算)。

钢管可由铁路、公路运往铺设地点 (不只是运到点 $A_1, A_2, \dots, A_{15}$, 而是管道全线)。

(1) 请制定一个主管道钢管的订购和运输计划, 使总费用最小 (给出总费用)。

(2) 请就 (1) 的模型分析: 哪个钢厂钢管的销价的变化对购运计划和总费用影响最大, 哪个钢厂钢管的产量的上限的变化对购运计划和总费用的影响最大, 并给出相应的数字结果。

(3) 如果要铺设的管道不是一条线, 而是一个树形图, 铁路、公路和管道构成网络, 请就这种更一般的情形给出一种解决办法, 并对图二按 (1) 的要求给出模型和结果。



图二

(武汉大学费浦生提供)

C 题 飞越北极(大专组)

今年 6 月, 扬子晚报发布消息: “中美航线下月可飞越北极, 北京至底特律可节省 4 小时”, 摘要如下:

7 月 1 日起, 加拿大和俄罗斯将允许民航班机飞越北极, 此改变可大幅度缩短北美与亚洲间的飞行时间, 旅客可直接从休斯敦, 丹佛及明尼阿波利斯直飞北京等地。据加拿大空中交通管制局估计, 如飞越北极, 底特律至北京的飞行时间可节省 4 个小时。由于不需中途降落加油, 实际节省的时间不止此数。

假设: 飞机飞行高度约为 10 公里, 飞行速度约为每小时 980 公里; 从北京至底特律原来的航线飞经以下 10 处:

- | | |
|-------------------------|-------------------------|
| A1 (北纬 31 度, 东经 122 度); | A2 (北纬 36 度, 东经 140 度); |
| A3 (北纬 53 度, 西经 165 度); | A4 (北纬 62 度, 西经 150 度); |
| A5 (北纬 59 度, 西经 140 度); | A6 (北纬 55 度, 西经 135 度); |
| A7 (北纬 50 度, 西经 130 度); | A8 (北纬 47 度, 西经 125 度); |
| A9 (北纬 47 度, 西经 122 度); | A10 (北纬 42 度, 西经 87 度)。 |

请对 “北京至底特律的飞行时间可节省 4 小时” 从数学上作出一个合理的解释, 分两种情况讨论:

- (1) 设地球是半径为 6371 千米的球体;
- (2) 设地球是一旋转椭球体, 赤道半径为 6378 千米, 子午线短半轴为 6357 千米。

(复旦大学谭永基提供)


D 题 空洞探测（大专组）

山体、隧洞、坝体等的某些内部结构可用弹性波测量来确定。一个简化问题可描述为，一块均匀介质构成的矩形平板内有一些充满空气的空洞，在平板的两个邻边分别等距地设置若干波源，在它们的对边对等地安放同样多的接收器，记录弹性波由每个波源到达对边上每个接收器的时间，根据弹性波在介质中和在空气中不同的传播速度，来确定板内空洞的位置。现考察如下的具体问题：

一块 240（米） $\times$ 240（米）的平板（如图），在 AB 边等距地设置 7 个波源 P_i ($i=1,\cdots,7$)，CD 边对等地安放 7 个接收器 Q_j ($j=1,\cdots,7$)，记录由 P_i 发出的弹性波到达 Q_j 的时间 t_{ij} (秒)；在 AD 边等距地设置 7 个波源 R_i ($i=1,\cdots,7$)，BC 边对等地安放 7 个接收器 S_j ($j=1,\cdots,7$)，记录由 R_i 发出的弹性波到达 S_j 的时间 τ_{ij} (秒)。已知弹性波在介质和空气中的传播速度分别为 2880（米/秒）和 320（米/秒），且弹性波沿板边缘的传播速度与在介质中的传播速度相同。

1) 确定该平板内空洞的位置。

2) 只根据由 P_i 发出的弹性波到达 Q_j 的时间 t_{ij} ($i,j=1,\cdots,7$)，能确定空洞的位置吗？讨论在同样能够确定空洞位置的前提下，减少波源和接受器的方法。



t_{ij}	Q_1	Q_2	Q_3	Q_4	Q_5	Q_6	Q_7
P_1	0.0611	0.0895	0.1996	0.2032	0.4181	0.4923	0.5646
P_2	0.0989	0.0592	0.4413	0.4318	0.4770	0.5242	0.3805
P_3	0.3052	0.4131	0.0598	0.4153	0.4156	0.3563	0.1919
P_4	0.3221	0.4453	0.4040	0.0738	0.1789	0.0740	0.2122
P_5	0.3490	0.4529	0.2263	0.1917	0.0839	0.1768	0.1810
P_6	0.3807	0.3177	0.2364	0.3064	0.2217	0.0939	0.1031
P_7	0.4311	0.3397	0.3566	0.1954	0.0760	0.0688	0.1042

τ_{ij}	S_1	S_2	S_3	S_4	S_5	S_6	S_7
R_1	0.0645	0.0602	0.0813	0.3516	0.3867	0.4314	0.5721
R_2	0.0753	0.0700	0.2852	0.4341	0.3491	0.4800	0.4980
R_3	0.3456	0.3205	0.0974	0.4093	0.4240	0.4540	0.3112
R_4	0.3655	0.3289	0.4247	0.1007	0.3249	0.2134	0.1017
R_5	0.3165	0.2409	0.3214	0.3256	0.0904	0.1874	0.2130
R_6	0.2749	0.3891	0.5895	0.3016	0.2058	0.0841	0.0706
R_7	0.4434	0.4919	0.3904	0.0786	0.0709	0.0914	0.0583

（东北电力学院关信提供）

注 优秀论文及评阅人文章刊登在《数学的实践与认识》2001 年第 1 期上。