

微信公众号-科研交流


荣誉出品



MATLAB零基础入门与进阶提高

规划问题

科研交流咨询师 杨学长



绪论

- 最优化理论与算法是运筹学的一个重要分支
- 随着最优化理论与算法的迅速发展，最优化理论出现了线性规划、整数规划、非线性规划、几何规划、动态规划、随机规划、网络流等许多分支。
- 研究的问题：（1）在众多的方案中什么样的方案最优。（2）怎样找出最优方案。
- 应用广泛、实用性强。可应用于工程设计参数的选择、资源分配、生产计划安排、原料配比、城建规划、农田规划、军事指挥等方面。
- “最”往往是过分理想了，实际生活中往往运用次优、满意等概念代替最优。
- 给出问题坏的结果的艺术，否则的话，问题的结果只会更坏。
- 线性规划和非线性规划有着广泛的实际背景，许多实际问题抽象为数学模型后，都可以归为这类问题。

例 1.2.1 生产计划问题

设某工厂用 4 种资源生产 3 种产品, 每单位第 j 种产品需要第 i 种资源的数量为 a_{ij} , 可获利润为 c_j , 第 i 种资源总消耗量不能超过 b_i , 由于市场限制, 第 j 种产品的产量不超过 d_j , 试问如何安排生产才能使总利润最大?

解析 下面分析怎样建立数学模型. 设 3 种产品的产量分别为 x_1, x_2, x_3 , 这是决策变量, 目标函数是总利润 $c_1x_1 + c_2x_2 + c_3x_3$, 约束条件有资源限制 $a_{i1}x_1 + a_{i2}x_2 + a_{i3}x_3 \leq b_i$ ($i=1, 2, 3, 4$), 市场销量限制, $x_j \leq d_j$ ($j=1, 2, 3$), 及产量非负限制 $x_j \geq 0$ ($j=1, 2, 3$). 问题概括为, 在一组约束条件下, 确定一个最优生产方案 $x^* = (x_1^*, x_2^*, x_3^*)$, 使目标函数值最大. 数学模型如下:

$$\begin{aligned} \max \quad & \sum_{j=1}^3 c_j x_j \\ \text{s. t.} \quad & \sum_{j=1}^3 a_{ij} x_j \leq b_i, \quad i = 1, \dots, 4, \\ & x_j \leq d_j, \quad j = 1, 2, 3, \\ & x_j \geq 0, \quad j = 1, 2, 3, \end{aligned}$$

其中 $\max$ 表示 maximize, 读作“极大化”, s. t. 表示 subject to, 读作“约束条件是”.

例 1.2.2 食谱问题

设市场上可买到 n 种不同的食品, 第 j 种食品单位售价为 c_j . 每种食品含有 m 种基本营养成分, 第 j 种食品每一个单位含第 i 种营养成分为 a_{ij} . 又设每人每天对第 i 种营养成分的需要量不少于 b_i . 试确定在保证营养要求条件下的最经济食谱.

解析 建立食谱问题的数学模型. 设每人每天需要各种食品的数量分别为 $x_1, x_2, \dots, x_n$. 我们的目标是使伙食费用最少, 即使 $c_1x_1 + c_2x_2 + \dots + c_nx_n$ 最小. 条件是保证用餐者对各种营养成分的基本需要, 即满足 $a_{i1}x_1 + a_{i2}x_2 + \dots + a_{in}x_n \geq b_i (i=1, 2, \dots, m)$. 数学模型是

$$\begin{aligned} \min \quad & \sum_{j=1}^n c_j x_j \\ \text{s. t.} \quad & \sum_{j=1}^n a_{ij} x_j \geq b_i, \quad i = 1, \dots, m, \\ & x_j \geq 0, \quad j = 1, \dots, n, \end{aligned}$$

其中 $\min$ 表示 minimize, 读作“极小化”.

例 1.2.4 选址问题

设有 n 个市场, 第 j 个市场的位置为 (a_j, b_j) , 对某种货物的需要量为 $q_j (j=1, \dots, n)$. 现计划建立 m 个货栈, 第 i 个货栈的容量为 $c_i (i=1, \dots, m)$. 试确定货栈的位置, 使各货栈到各市场的运输量与路程乘积之和最小.

解析 现在来建立数学模型. 设第 i 个货栈的位置为 $(x_i, y_i) (i=1, \dots, m)$. 第 i 个货栈供给第 j 个市场的货物量为 $W_{ij} (i=1, \dots, m; j=1, \dots, n)$. 第 i 个货栈到第 j 个市场的距离为 d_{ij} , 一般定义为

$$d_{ij} = \sqrt{(x_i - a_j)^2 + (y_i - b_j)^2} \quad (1.2.1)$$

或

$$d_{ij} = |x_i - a_j| + |y_i - b_j|. \quad (1.2.2)$$

我们的目标是使运输量与路程乘积之和最小, 如果距离按 (1.2.1) 式定义, 就是使

$$\sum_{i=1}^m \sum_{j=1}^n W_{ij} \sqrt{(x_i - a_j)^2 + (y_i - b_j)^2}$$

最小, 约束条件是:

- (1) 每个货栈向各市场提供的货物量之和不能超过它的容量
- (2) 每个市场从各货栈得到的货物量之和应等于它的需要量
- (3) 运输量不能为负数.

因此, 问题的数学模型如下:

$$\begin{aligned} \min \quad & \sum_{i=1}^m \sum_{j=1}^n W_{ij} \sqrt{(x_i - a_j)^2 + (y_i - b_j)^2} \\ \text{s. t.} \quad & \sum_{j=1}^n W_{ij} \leq c_i, \quad i = 1, \dots, m, \\ & \sum_{i=1}^m W_{ij} = q_j, \quad j = 1, \dots, n, \\ & W_{ij} \geq 0, \quad i = 1, \dots, m, j = 1, \dots, n. \end{aligned}$$

在上述例 1.2.1 和例 1.2.2 的数学模型中，目标函数和约束函数都是线性的，称之为线性规划问题；而例 1.2.3 和例 1.2.4 的数学模型中含有非线性函数，因此称为非线性规划问题。

在线性规划与非线性规划中，满足约束条件的点称为可行点，全体可行点组成的集合称为可行集或可行域。如果一个问题的可行集是整个空间，那么此问题就称为无约束问题。

定义 1.2.1 设 $f(x)$ 为目标函数, S 为可行域, $\bar{x} \in S$, 若对每个 $x \in S$, 成立 $f(x) \geq f(\bar{x})$, 则称 $\bar{x}$ 为 $f(x)$ 在 S 上的全局极小点。

定义 1.2.2 设 $f(x)$ 为目标函数, S 为可行域, 若存在 $\bar{x} \in S$ 的 $\epsilon > 0$ 邻域 $N(\bar{x}, \epsilon) = \{x \mid \|x - \bar{x}\| < \epsilon\}$, 使得对每个 $x \in S \cap N(\bar{x}, \epsilon)$ 成立 $f(x) \geq f(\bar{x})$, 则称 $\bar{x}$ 为 $f(x)$ 在 S 上的一个局部极小点。

对于极大化问题, 可类似地定义全局极大点和局部极大点, 这里不再叙述。

根据上述定义, 全局极小点也是局部极小点, 而局部极小点不一定是全局极小点。但是对于某些特殊情形, 如将在后面介绍的凸规划, 局部极小点也是全局极小点。

- 向量范数和矩阵范数
- 序列的极限和聚点
- 梯度和导数的概念
- 凸集和凸函数
- 凸规划

定义 1.3.1 若实值函数 $\| \cdot \| : \mathbb{R}^n \rightarrow \mathbb{R}$ 满足下列条件:

- (1) $\|x\| \geq 0, \forall x \in \mathbb{R}^n; \|x\| = 0$ 当且仅当 $x=0$;
- (2) $\|\alpha x\| = |\alpha| \|x\|, \forall \alpha \in \mathbb{R}, x \in \mathbb{R}^n$;
- (3) $\|x+y\| \leq \|x\| + \|y\|, \forall x, y \in \mathbb{R}^n$.

则称 $\|\cdot\|$ 为向量范数, 其中 $\mathbb{R}^n$ 表示 n 维向量空间.

设 $x = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n$, 常用的向量范数有 L_1 范数, L_2 范数和 L_∞ 范数, 分别为

$$\|x\|_1 = \sum_{j=1}^n |x_j|,$$

$$\|x\|_2 = \left(\sum_{j=1}^n x_j^2 \right)^{\frac{1}{2}},$$

$$\|x\|_\infty = \max_j |x_j|.$$

一般地, 对于 $1 \leq p < \infty$, L_p 范数为

$$\|x\|_p = \left(\sum_{j=1}^n |x_j|^p \right)^{\frac{1}{p}}.$$

关于范数的等价性，有下列定义。

定义 1.3.2 设 $\|\cdot\|_\alpha$ 和 $\|\cdot\|_\beta$ 是 $\mathbb{R}^n$ 上任意两个范数，如果存在正数 c_1 和 c_2 ，使得对每个 $x \in \mathbb{R}^n$ 成立 $c_1 \|x\|_\alpha \leq \|x\|_\beta \leq c_2 \|x\|_\alpha$ ，则称范数 $\|x\|_\alpha$ 和范数 $\|x\|_\beta$ 等价。

在 $\mathbb{R}^n$ 中任何两种范数均等价。

这里应指出，上述向量范数中， $\|x\|_2$ 称为 Euclid 范数，如无特殊指明，后面将用 $\mathbb{R}^n$ 表示 n 维 Euclid 空间。

关于矩阵范数，定义如下。

定义 1.3.3 设 A 为 $m \times n$ 矩阵， $\|\cdot\|_\alpha$ 是 $\mathbb{R}^m$ 上向量范数， $\|\cdot\|_\beta$ 是 $\mathbb{R}^n$ 上向量范数，定义矩阵范数 $\|A\| = \max_{\|x\|_\beta=1} \|Ax\|_\alpha$ 。

根据矩阵范数定义，对于单位矩阵 I ，总有 $\|I\| = 1$ 。关于矩阵范数有下列结论。

定理 1.3.1 矩阵范数具有下列性质:

- (1) $\|Ax\|_\alpha \leq \|A\| \|x\|_\beta$;
- (2) $\|\lambda A\| = |\lambda| \|A\|$;
- (3) $\|A+B\| \leq \|A\| + \|B\|$;
- (4) $\|AD\| \leq \|A\| \|D\|$.

其中 A, B 为 $m \times n$ 矩阵, D 是 $n \times p$ 矩阵, λ 为实数, $x \in \mathbb{R}^n$.

设矩阵 $A = (a_{ij})_{m \times n}$, 下面给出 3 种常用的矩阵范数, 分别记作 $\|A\|_1$, $\|A\|_2$, $\|A\|_\infty$:

- (1) $\|A\|_1 = \max_j \sum_{i=1}^m |a_{ij}|$;
- (2) $\|A\|_2 = \sqrt{\lambda_{A^T A}}$;
- (3) $\|A\|_\infty = \max_i \sum_{j=1}^n |a_{ij}|$.

其中 $\lambda_{A^T A}$ 表示 $A^T A$ 的最大特征值, $\|A\|_2$ 称为 A 的谱范数.

定义 1.3.4 设 $\{x^{(k)}\}$ 是 $\mathbb{R}^n$ 中一个向量序列, $\bar{x} \in \mathbb{R}^n$, 如果对每个任给的 $\epsilon > 0$ 存在正整数 K_ϵ , 使得当 $k > K_\epsilon$ 时就有 $\|x^{(k)} - \bar{x}\| < \epsilon$, 则称序列收敛到 $\bar{x}$, 或称序列以 $\bar{x}$ 为极限, 记作 $\lim x^{(k)} = \bar{x}$.

按此定义, 序列若存在极限, 则任何子序列有相同的极限, 即序列的极限是惟一的。

定义 1.3.5 设 $\{x^{(k)}\}$ 是 $\mathbb{R}^n$ 中一个向量序列, 如果存在一个子序列 $\{x^{(k_j)}\}$, 使 $\lim x^{(k_j)} = \hat{x}$, 则称 $\hat{x}$ 是序列 $\{x^{(k)}\}$ 的一个聚点。

根据定义易知, 如果无穷序列有界, 即存在正数 M , 使得对所有 k 均有 $\|x^{(k)}\| \leq M$.

则这个序列必有聚点.

定义 1.3.6 设 $\{x^{(k)}\}$ 是 $\mathbb{R}^n$ 中一个向量序列, 如果对任意给定的 $\epsilon > 0$, 总存在正整数 K_ϵ , 使得当 $m, l > K_\epsilon$ 时, 就有 $\|x^{(m)} - x^{(l)}\| < \epsilon$, 则 $\{x^{(k)}\}$ 称为 Cauchy 序列.

在 $\mathbb{R}^n$ 中, Cauchy 序列有极限.

定理 1.3.2 设 $\{x^{(j)}\} \subset \mathbb{R}^n$ 为 Cauchy 序列, 则 $\{x^{(j)}\}$ 的聚点必为极限点. (证明从略)

后面算法介绍和理论分析中, 还常涉及闭集、开集、紧集等概念. 定义如下: 设 S 为 $\mathbb{R}^n$ 中一个集合, 如果 S 中每个收敛序列的极限均属于 S , 则称 S 为闭集. 如果对每一点 $\hat{x} \in S$, 存在正数 ϵ , 使得 $\hat{x}$ 的 ϵ 邻域 $N(\hat{x}, \epsilon) = \{x \mid \|x - \hat{x}\| < \epsilon\} \subset S$, 则称 S 为开集. 如果 S 是有界闭集, 则称 S 为紧集.

设集合 $S \subset \mathbb{R}^n$ 非空, $f(x)$ 为定义在 S 上的实函数, 如果 f 在每一点 $x \in S$ 连续, 则称 f 在 S 上连续, 记作 $f \in C(S)$. 再设 S 为开集, 如果在每一点 $x \in S$, 对所有 $j=1, \dots, n$, 偏导数 $\frac{\partial f(x)}{\partial x_j}$ 存在且连续, 则称 f 在开集 S 上连续可微, 记作 $f \in C^1(S)$. 如果在每一点 $x \in S$, 对所有 $i=1, \dots, n$ 和 $j=1, \dots, n$, 二阶偏导数 $\frac{\partial^2 f(x)}{\partial x_i \partial x_j}$ 存在且连续, 则称 f 在开集 S 上二次连续可微, 记作 $f \in C^2(S)$.

函数 f 在 x 处的梯度为 n 维列向量:

$$\nabla f(x) = \left[\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_n} \right]^T. \quad (1.3.1)$$

f 在 x 处的 Hesse 矩阵为 $n \times n$ 矩阵 $\nabla^2 f(x)$, 第 i 行第 j 列元素为

$$[\nabla^2 f(x)]_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j}, \quad 1 \leq i, j \leq n. \quad (1.3.2)$$

当 $f(x)$ 为二次函数时, 梯度及 Hesse 矩阵很容易求得. 二次函数可以写成下列形式:

$$f(x) = \frac{1}{2} x^T A x + b^T x + c,$$

其中 A 是 n 阶对称矩阵, b 是 n 维列向量, c 是常数. 函数 $f(x)$ 在 x 处的梯度 $\nabla f(x) = Ax + b$, Hesse 矩阵 $\nabla^2 f(x) = A$.

设集合 $S \subset \mathbb{R}^n$ 非空, $f(x)$ 为定义在 S 上的实函数, 如果 f 在每一点 $x \in S$ 连续, 则称 f 在 S 上连续, 记作 $f \in C(S)$. 再设 S 为开集, 如果在每一点 $x \in S$, 对所有 $j=1, \dots, n$, 偏导数 $\frac{\partial f(x)}{\partial x_j}$ 存在且连续, 则称 f 在开集 S 上连续可微, 记作 $f \in C^1(S)$. 如果在每一点 $x \in S$, 对所有 $i=1, \dots, n$ 和 $j=1, \dots, n$, 二阶偏导数 $\frac{\partial^2 f(x)}{\partial x_i \partial x_j}$ 存在且连续, 则称 f 在开集 S 上二次连续可微, 记作 $f \in C^2(S)$.

函数 f 在 x 处的梯度为 n 维列向量:

$$\nabla f(x) = \left[\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_n} \right]^T. \quad (1.3.1)$$

f 在 x 处的 Hesse 矩阵为 $n \times n$ 矩阵 $\nabla^2 f(x)$, 第 i 行第 j 列元素为

$$[\nabla^2 f(x)]_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j}, \quad 1 \leq i, j \leq n. \quad (1.3.2)$$

当 $f(x)$ 为二次函数时, 梯度及 Hesse 矩阵很容易求得. 二次函数可以写成下列形式:

$$f(x) = \frac{1}{2} x^T A x + b^T x + c,$$

其中 A 是 n 阶对称矩阵, b 是 n 维列向量, c 是常数. 函数 $f(x)$ 在 x 处的梯度 $\nabla f(x) = Ax + b$, Hesse 矩阵 $\nabla^2 f(x) = A$.

定义 1.4.1 设 S 为 n 维欧氏空间 $\mathbb{R}^n$ 中一个集合. 若对 S 中任意两点, 联结它们的线段仍属于 S ; 换言之, 对 S 中任意两点 $x^{(1)}, x^{(2)}$ 及每个实数 $\lambda \in [0, 1]$, 都有

$$\lambda x^{(1)} + (1 - \lambda)x^{(2)} \in S.$$

则称 S 为凸集.

定义 1.4.4 设 S 为非空凸集, $x \in S$, 若 x 不能表示成 S 中两个不同点的凸组合; 换言之, 若假设 $x = \lambda x^{(1)} + (1 - \lambda)x^{(2)}$ ($\lambda \in (0, 1)$), $x^{(1)}, x^{(2)} \in S$, 必推得 $x = x^{(1)} = x^{(2)}$, 则称 x 是凸集 S 的极点.




图 1.4.2

定理 1.4.6(Farkas 定理) 设 A 为 $m \times n$ 矩阵, c 为 n 维向量, 则 $Ax \leq 0, c^T x > 0$ 有解的充要条件是 $A^T y = c, y \geq 0$ 无解.

定理 1.4.7(Gordan 定理) 设 A 为 $m \times n$ 矩阵, 那么, $Ax < 0$ 有解的充要条件是不存在非零向量 $y \geq 0$, 使 $A^T y = 0$.

定义 1.4.7 设 S 为 $\mathbb{R}^n$ 中的非空凸集, f 是定义在 S 上的实函数. 如果对任意的 $x^{(1)}, x^{(2)} \in S$ 及每个数 $\lambda \in (0, 1)$, 都有

$$f(\lambda x^{(1)} + (1 - \lambda)x^{(2)}) \leq \lambda f(x^{(1)}) + (1 - \lambda)f(x^{(2)}),$$

则称 f 为 S 上的凸函数.

定理 1.4.8 设 f 是定义在凸集 S 上的凸函数, 实数 $\lambda \geq 0$, 则 λf 也是定义在 S 上的凸函数.

定理 1.4.9 设 f_1 和 f_2 是定义在凸集 S 上的凸函数, 则 $f_1 + f_2$ 也是定义在 S 上的凸函数.

推论 设 $f_1, f_2, \dots, f_k$ 是定义在凸集 S 上的凸函数, 实数 $\lambda_1, \lambda_2, \dots, \lambda_k \geq 0$, 则 $\sum_{i=1}^k \lambda_i f_i$ 也是定义在 S 上的凸函数.

定理 1.4.10 设 S 是 $\mathbb{R}^n$ 中一个非空凸集, f 是定义在 S 上的凸函数, α 是一个实数, 则水平集 $S_\alpha = \{x | x \in S, f(x) \leq \alpha\}$ 是凸集.

定理 1.4.13 设 S 是 $\mathbb{R}^n$ 中非空凸集, f 是定义在 S 上的凸函数, 则 f 在 S 上的局部极小点是全局极小点, 且极小点的集合为凸集.

定理 1.4.15 设 S 是 $\mathbb{R}^n$ 中非空开凸集, $f(x)$ 是定义在 S 上的二次可微函数, 则 $f(x)$ 为凸函数的充要条件是在每一点 $x \in S$ 处 Hesse 矩阵半正定.




图 1.4.6

定理 1.4.16 设 S 是 $\mathbb{R}^n$ 中非空开凸集, $f(x)$ 是定义在 S 上的二次可微函数, 如果在每一点 $x \in S$, Hesse 矩阵正定, 则 $f(x)$ 为严格凸函数.

定理 1.4.16 的证明可仿照定理 1.4.15. 值得注意, 逆定理并不成立, 若 $f(x)$ 是定义在 S 上的严格凸函数, 则在每一点 $x \in S$ 处, Hesse 矩阵是半正定的.

利用以上几个定理容易判别一个可微函数是否为凸函数, 特别是对于二次函数, 用上述定理判别是很方便的.

我们考虑下列极小化问题：

$$\begin{aligned} & f(x) \\ \text{s. t. } & g_i(x) \geq 0, \quad i = 1, \dots, m, \\ & h_j(x) = 0, \quad j = 1, \dots, l. \end{aligned}$$

设 $f(x)$ 是凸函数, $g_i(x)$ 是凹函数, $h_j(x)$ 是线性函数. 问题的可行域是

$$S = \{x \mid g_i(x) \geq 0, i = 1, \dots, m; h_j(x) = 0, j = 1, \dots, l\}.$$

由于 $g_i(x)$ 是凸函数, 因此满足 $g_i(x) \geq 0$, 即满足 $-g_i(x) \leq 0$ 的点的集合是凸集, 根据凸函数和凹函数的定义, 线性函数 $h_j(x)$ 既是凸函数也是凹函数, 因此满足 $h_j(x) = 0$ 的点的集合也是凸集. S 是 $m+l$ 个凸集的交, 因此也是凸集. 这样, 上述问题是求凸函数在凸集上的极小点. 这类问题称为凸规划.

值得注意, 如果 $h_j(x)$ 是非线性的凸函数, 满足 $h_j(x) = 0$ 的点的集合不是凸集, 因此问题就不属于凸规划.

我们考虑下列极小化问题：

$$\begin{aligned} & f(x) \\ \text{s. t. } & g_i(x) \geq 0, \quad i = 1, \dots, m, \\ & h_j(x) = 0, \quad j = 1, \dots, l. \end{aligned}$$

设 $f(x)$ 是凸函数, $g_i(x)$ 是凹函数, $h_j(x)$ 是线性函数. 问题的可行域是

$$S = \{x \mid g_i(x) \geq 0, i = 1, \dots, m; h_j(x) = 0, j = 1, \dots, l\}.$$

由于 $g_i(x)$ 是凸函数, 因此满足 $g_i(x) \geq 0$, 即满足 $-g_i(x) \leq 0$ 的点的集合是凸集, 根据凸函数和凹函数的定义, 线性函数 $h_j(x)$ 既是凸函数也是凹函数, 因此满足 $h_j(x) = 0$ 的点的集合也是凸集. S 是 $m+l$ 个凸集的交, 因此也是凸集. 这样, 上述问题是求凸函数在凸集上的极小点. 这类问题称为凸规划.

值得注意, 如果 $h_j(x)$ 是非线性的凸函数, 满足 $h_j(x) = 0$ 的点的集合不是凸集, 因此问题就不属于凸规划.

线性规划是数学规划的一个重要分支. 它在理论和算法上都比较成熟, 在实践上有着广泛的应用, 不仅许多实际课题属于线性规划问题, 而且运筹学其他分支中的一些问题也可以转化为线性规划来计算, 因此线性规划在最优化学科中占有重要地位.

一般线性规划问题总可以写成下列标准形式：

$$\begin{aligned} \min \quad & \sum_{j=1}^n c_j x_j \\ \text{s. t.} \quad & \sum_{j=1}^n a_{ij} x_j = b_i, \quad i = 1, \dots, m, \\ & x_j \geq 0, \quad j = 1, \dots, n, \end{aligned} \quad (2.1.1)$$

或用矩阵表示：

$$\begin{aligned} \min \quad & cx \\ \text{s. t.} \quad & Ax = b, \\ & x \geq 0, \end{aligned} \quad (2.1.2)$$

其中 A 是 $m \times n$ 矩阵, c 是 n 维行向量, b 是 m 维列向量.

为了计算的需要, 一般假设 $b \geq 0$, 即 b 的每个分量是非负数. 如果不是这样, 可将方程两端乘以 (-1) , 从而将右端化为非负.

在线性规划中，约束条件均为线性等式及不等式，满足这些条件的点的集合是凸集。然，线性规划如果存在最优解，那么最优值一定能够在某极点上达到，这是线性规划的一般规律。

在线性规划 (2.1.2) 中，设矩阵 A 的秩为 m ，又假设 $A=[B, N]$ ，其中 B 是 m 阶可逆矩阵，如果 A 的前 m 列是线性相关的，可以通过列调换，使前 m 列成为线性无关的，因此关于 B 可逆的假设不失一般性。同时记作

$$x = \begin{bmatrix} x_B \\ x_N \end{bmatrix},$$

其中 x_B 的分量与 B 中的列对应， x_N 的分量与 N 的列对应。这样，可把 $Ax=b$ 写成

$$(B, N) \begin{bmatrix} x_B \\ x_N \end{bmatrix} = b,$$

即

$$Bx_B + Nx_N = b. \quad (2.2.7)$$

上式两端左乘 B^{-1} , 并移项, 得到

$$x_B = B^{-1}b - B^{-1}Nx_N. \quad (2.2.8)$$

x_N 的分量就是线性代数中所谓的自由未知量, 它们取不同的值, 就会得到方程组的不同解. 特别地, 令 $x_N = 0$, 则得到解

$$x = \begin{bmatrix} x_B \\ x_N \end{bmatrix} = \begin{bmatrix} B^{-1}b \\ 0 \end{bmatrix}. \quad (2.2.9)$$

定义 2.2.1

$$x = \begin{bmatrix} x_B \\ x_N \end{bmatrix} = \begin{bmatrix} B^{-1}b \\ 0 \end{bmatrix}$$

称为方程组 $Ax=b$ 的一个基本解. B 称为基矩阵. 简称为基. x_B 的各分量称为基变量, 基变量的全体 $x_{B_1}, x_{B_2}, \dots, x_{B_m}$ 称为一组基. x_N 的各分量称为非基变量. 又若 $B^{-1}b \geq 0$, 则称

$$x = \begin{bmatrix} x_B \\ x_N \end{bmatrix} = \begin{bmatrix} B^{-1}b \\ 0 \end{bmatrix}$$

为约束条件 $Ax=b, x \geq 0$ 的基本可行解. 相应地, 称 B 为可行基矩阵, $x_{B_1}, x_{B_2}, \dots, x_{B_m}$ 为一组可行基. 若 $B^{-1}b > 0$, 即基变量的取值均为正数, 则称基本可行解是非退化的. 如果满足 $B^{-1}b \geq 0$ 且至少有一个分量是零, 则称基本可行解是退化的基本可行解.

考虑问题

$$\begin{aligned} \min \quad & f \stackrel{\text{def}}{=} \mathbf{c}\mathbf{x} \\ \text{s. t.} \quad & \mathbf{A}\mathbf{x} = \mathbf{b}, \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned} \quad (3.1.1)$$

其中 $\mathbf{A}$ 是 $m \times n$ 矩阵, 秩为 m . $\mathbf{c}$ 是 n 维行向量, $\mathbf{x}$ 是 n 维列向量, $\mathbf{b} \geq \mathbf{0}$ 是 m 维列向量. 符号 $\stackrel{\text{def}}{=}$ 表示右端的表达式是左端的定义式, 即目标函数 f 的具体形式就是 $\mathbf{c}\mathbf{x}$, 以后其他章节遇到此符号时, 其含义作同样规定.

记

$$\mathbf{A} = (\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_n).$$

现将 $\mathbf{A}$ 分解成 $(\mathbf{B}, \mathbf{N})$ (可能经列调换), 使得其中 $\mathbf{B}$ 是基矩阵, $\mathbf{N}$ 是非基矩阵, 设

$$\mathbf{x}^{(0)} = \begin{bmatrix} \mathbf{B}^{-1}\mathbf{b} \\ \mathbf{0} \end{bmatrix}$$

是基本可行解, 在 $\mathbf{x}^{(0)}$ 处的目标函数值

$$\begin{aligned} f_0 = \mathbf{c}\mathbf{x}^{(0)} &= (\mathbf{c}_B, \mathbf{c}_N) \begin{bmatrix} \mathbf{B}^{-1}\mathbf{b} \\ \mathbf{0} \end{bmatrix} \\ &= \mathbf{c}_B \mathbf{B}^{-1} \mathbf{b}, \end{aligned} \quad (3.1.2)$$

其中 c_B 是 c 中与基变量对应的分量组成的 m 维行向量. c_N 是 c 中与非基变量对应的分量组成的 $n-m$ 维行向量.

现在分析怎样从基本可行解 $x^{(0)}$ 出发, 求一个改进的基本可行解.

设

$$x = \begin{bmatrix} x_B \\ x_N \end{bmatrix}$$

是任一个可行解, 则由 $Ax=b$ 得到

$$x_B = B^{-1}b - B^{-1}Nx_N, \quad (3.1.3)$$

在点 x 处的目标函数值

$$\begin{aligned} f = cx &= (c_B, c_N) \begin{bmatrix} x_B \\ x_N \end{bmatrix} \\ &= c_B x_B + c_N x_N \\ &= c_B (B^{-1}b - B^{-1}Nx_N) + c_N x_N \\ &= c_B B^{-1}b - (c_B B^{-1}N - c_N) x_N \\ &= f_0 - \sum_{j \in R} (c_B B^{-1}p_j - c_j) x_j \\ &= f_0 - \sum_{j \in R} (z_j - c_j) x_j, \end{aligned} \quad (3.1.4)$$

其中 R 是非基变量下标集,

$$z_j = c_B B^{-1} p_j.$$

由(3.1.4)式可知,适当选取自由未知量 $x_j (j \in R)$ 的数值就有可能使得

$$\sum_{j \in R} (z_j - c_j) x_j > 0,$$

从而得到使目标函数值减少的新的基本可行解。为此,在原来的 $n-m$ 个非基变量中,使得 $n-m-1$ 个变量仍然取零值,而令一个非基变量,比如 x_k 增大,即取正值,以便实现我们的目的。那么怎样确定下标 k 呢? 根据(3.1.4)式,当 $x_j (j \in R)$ 取值相同时, $z_j - c_j$ (正数) 越大,目标函数值下降越多,因此选择 x_k , 使

$$z_k - c_k = \max_{j \in R} \{z_j - c_j\}, \quad (3.1.6)$$

这里假设 $z_k - c_k > 0$, x_k 由零变为正数后,得到方程组 $Ax = b$ 的解

$$x_B = B^{-1}b - B^{-1}p_k x_k = \bar{b} - y_k x_k. \quad (3.1.7)$$

其中 $\bar{b}$ 和 y_k 是 m 维列向量, $\bar{b} = B^{-1}b$, $y_k = B^{-1}p_k$, 把 x_B 按分量写出, 即

$$x_B = \begin{bmatrix} x_{B_1} \\ x_{B_2} \\ \vdots \\ x_{B_m} \end{bmatrix} = \begin{bmatrix} \bar{b}_1 \\ \bar{b}_2 \\ \vdots \\ \bar{b}_m \end{bmatrix} - \begin{bmatrix} y_{1k} \\ y_{2k} \\ \vdots \\ y_{mk} \end{bmatrix} x_k, \quad (3.1.8)$$

$$x_N = (0, \dots, 0, x_k, 0, \dots, 0)^T. \quad (3.1.9)$$

在新得到的点, 目标函数值是

$$f = f_0 - (z_k - c_k)x_k. \quad (3.1.10)$$

再来分析怎样确定 x_k 的取值. 一方面, 根据(3.1.10)式, x_k 取值越大函数值下降越多; 另一方面, 根据(3.1.8)式, x_k 的取值受到可行性的限制, 它不能无限增大 (当 $y_k \leq 0$ 时), 对某个 i , 当 $y_{ik} \leq 0$ 时, x_k 取任何正值时, 总成立 $x_{B_i} \geq 0$, 而当 $y_{ik} > 0$ 时, 为保证

$$x_{B_i} = b_i - y_{ik}x_k \geq 0.$$

就必须取值

$$x_k \leq \frac{\bar{b}_i}{y_{ik}}.$$

因此, 为使 $x_B \geq 0$, 应令

$$x_k = \min \left\{ \frac{\bar{b}_i}{y_{ik}} \mid y_{ik} > 0 \right\} = \frac{\bar{b}_r}{y_{rk}}, \quad (3.1.11)$$

x_k 取值 $\bar{b}_r/y_{rk}$ 后, 原来的基变量 $x_{B_r} = 0$, 得到新的可行解

$$x = (x_{B_1}, \dots, x_{B_{r-1}}, 0, x_{B_{r+1}}, 0, \dots, x_k, 0, \dots, 0)^T.$$

这个解一定是基本可行解。这是因为原来的基

$$B = (p_{B_1}, \dots, p_{B_r}, \dots, p_{B_m})$$

中的 m 个列是线性无关的，其中不包含 p_k 。由于 $y_k = B^{-1}p_k$ ，故

$$p_k = By_k = \sum_{i=1}^m y_{ik} p_{B_i},$$

即 p_k 是向量组 $p_{B_1}, \dots, p_{B_r}, \dots, p_{B_m}$ 的线性组合，且系数 $y_{rk} \neq 0$ 。因此用 p_k 取代 p_{B_r} 后，得到的向量组

$$p_{B_1}, \dots, p_k, \dots, p_{B_m}$$

也是线性无关的。因此新的可行解 x 的正分量对应的列线性无关，故 x 为基本可行解。

经上述转换， x_k 由原来的非基变量变成基变量，而原来的基变量 x_{B_r} 变成非基变量。在新的基本可行解处，目标函数值比原来减少了 $(z_k - c_k)x_k$ 。重复以上过程，可以进一步改进基本可行解，直到在 (3.1.4) 式中所有 $z_j - c_j$ 均非正数，以致任何一个非基变量取正值都不能使目标函数值减少时为止。

定理 3.1.1 若在极小化问题中, 对于某个基本可行解, 所有 $z_j - c_j \leq 0$, 则这个基本可行解是最优解; 若在极大化问题中, 对于某个基本可行解, 所有 $z_j - c_j \geq 0$, 则这个基本可行解是最优解. 其中

$$z_j - c_j = \mathbf{c}_B \mathbf{B}^{-1} \mathbf{p}_j - c_j, \quad j = 1, \dots, n.$$

在线性规划中, 通常称 $z_j - c_j$ 为判别数或检验数.

我们以极小化问题为例给出计算步骤. 首先要给定一个初始基本可行解. 设初始基为 B , 然后执行下列主要步骤:

(1) 解 $Bx_B = b$, 求得 $x_B = B^{-1}b = \bar{b}$, 令 $x_N = 0$, 计算目标函数值 $f = c_B x_B$.

(2) 求单纯形乘子 w , 解 $wB = c_B$, 得到 $w = c_B B^{-1}$. 对于所有非基变量, 计算判别数 $z_j - c_j = wp_j - c_j$. 令

$$z_k - c_k = \max_{j \in R} \{z_j - c_j\}.$$

若 $z_k - c_k \leq 0$, 则对于所有非基变量 $z_j - c_j \leq 0$, 对应基变量的判别数总是零, 因此停止计算, 现行基本可行解是最优解. 否则, 进行下一步.

(3) 解 $By_k = p_k$, 得到 $y_k = B^{-1}p_k$, 若 $y_k \leq 0$, 即 y_k 的每个分量均非正数, 则停止计算, 问题不存在有限最优解. 否则, 进行步骤(4).

(4) 确定下标 r , 使

$$\frac{\bar{b}_r}{y_{rk}} = \min \left\{ \frac{\bar{b}_i}{y_{ik}} \mid y_{ik} > 0 \right\},$$

x_{B_r} 为离基变量, x_k 为进基变量. 用 p_k 替换 p_{B_r} , 得到新的基矩阵 B , 返回步骤(1).

对于极大化问题, 可给出完全类似的步骤, 只是确定进基变量的准则不同. 对于极大化问题, 应令

$$z_k - c_k = \min_{j \in R} \{ z_j - c_j \}.$$

(1) $z_k - c_k \leq 0$. 这时现行基本可行解就是最优解.

(2) $z_k - c_k > 0$ 且 $y_k \leq 0$. 对于此种情形, 由(3.1.8)式可知, x_k 取任何正数, 总能得到可行解. 又由(3.1.10)式知, 当 x_k 无限增大时, 目标函数值 $f \rightarrow -\infty$, 因此问题属于无界情形.

(3) $z_k - c_k > 0$ 且 $y_k > 0$. 这时可求出新的基本可行解. 若

$$x_k = \frac{\bar{b}_r}{y_{rk}} > 0,$$

则经迭代, 目标函数值下降.

例 3.1.1 用单纯形方法解下列问题：

$$\begin{aligned} \min \quad & -4x_1 - x_2 \\ \text{s. t.} \quad & -x_1 + 2x_2 \leq 4, \\ & 2x_1 + 3x_2 \leq 12, \\ & x_1 - x_2 \leq 3, \\ & x_1, x_2 \geq 0. \end{aligned}$$

解 为了用单纯形方法求解上述问题，先要引入松弛变量 x_3, x_4, x_5 ，把问题化成如下标准形式：

$$\begin{aligned} \min \quad & -4x_1 - x_2 \\ \text{s. t.} \quad & -x_1 + 2x_2 + x_3 = 4, \\ & 2x_1 + 3x_2 + x_4 = 12, \\ & x_1 - x_2 + x_5 = 3, \\ & x_j \geq 0, \quad j = 1, \dots, 5, \end{aligned}$$

系数矩阵

$$A = (p_1, p_2, p_3, p_4, p_5) = \begin{bmatrix} -1 & 2 & 1 & 0 & 0 \\ 2 & 3 & 0 & 1 & 0 \\ 1 & -1 & 0 & 0 & 1 \end{bmatrix}.$$

第 1 次迭代.

$$B = (p_3, p_4, p_5) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix},$$

$$B^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix},$$

$$x_B = \begin{bmatrix} x_3 \\ x_4 \\ x_5 \end{bmatrix} = \begin{bmatrix} 4 \\ 12 \\ 3 \end{bmatrix},$$

$$x_N = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix},$$

$$f_1 = c_B x_B = (0, 0, 0)(4, 12, 3)^T = 0,$$

$$w = c_B B^{-1} = (0, 0, 0) \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = (0, 0, 0),$$

$$z_1 - c_1 = wp_1 - c_1 = (0, 0, 0)(-1, 2, 1)^T + 4 = 4,$$

$$z_2 - c_2 = wp_2 - c_2 = (0, 0, 0)(2, 3, -1)^T + 1 = 1.$$

又知对应基变量的判别数均为零, 因此最大判别数是 $z_1 - c_1 = 4$, 下标 $k=1$. 计算 y_1 , 有

$$y_1 = B^{-1} p_1 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} -1 \\ 2 \\ 1 \end{bmatrix} = \begin{bmatrix} -1 \\ 2 \\ 1 \end{bmatrix},$$

$$\bar{b} = x_B = (4, 12, 3)^T.$$

根据(3.1.11)式确定下标 r , 有

$$\frac{\bar{b}_r}{y_{r1}} = \min \left\{ \frac{\bar{b}_2}{y_{21}}, \frac{\bar{b}_3}{y_{31}} \right\} = \min \left\{ \frac{12}{2}, \frac{3}{1} \right\} = \frac{3}{1},$$

因此 $r=3$. x_B 中第 3 个分量 x_5 为离基变量, x_1 为进基变量,

$$x_1 = b_3 / y_{31} = 3.$$

用 p_1 替换 p_5 , 得到新基, 进行下一次迭代.

第 2 次迭代.

$$\mathbf{B} = (\mathbf{p}_3, \mathbf{p}_4, \mathbf{p}_1) = \begin{bmatrix} 1 & 0 & -1 \\ 0 & 1 & 2 \\ 0 & 0 & 1 \end{bmatrix},$$

$$\mathbf{B}^{-1} = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & -2 \\ 0 & 0 & 1 \end{bmatrix},$$

$$\mathbf{x}_B = \begin{bmatrix} x_3 \\ x_4 \\ x_1 \end{bmatrix} = \begin{bmatrix} 7 \\ 6 \\ 3 \end{bmatrix} = \begin{bmatrix} \bar{b}_1 \\ \bar{b}_2 \\ \bar{b}_3 \end{bmatrix},$$

$$\mathbf{x}_N = \begin{bmatrix} x_2 \\ x_5 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix},$$

$$f_2 = 12,$$

$$w = c_B B^{-1} = (0, 0, -4) \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & -2 \\ 0 & 0 & 1 \end{bmatrix} = (0, 0, -4),$$

$$z_2 - c_2 = wp_2 - c_2 = (0, 0, -4)(2, 3, -1)^T + 1 = 5,$$

$$z_5 - c_5 = wp_5 - c_5 = (0, 0, -4)(0, 0, 1)^T - 0 = -4.$$

最大判别数为 $z_2 - c_2 = 5$, 指标 $k=2$. 计算 y_2 , 有

$$y_2 = B^{-1} p_2 = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & -2 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ 3 \\ -1 \end{bmatrix} = \begin{bmatrix} 1 \\ 5 \\ -1 \end{bmatrix},$$

$$\frac{\bar{b}_r}{y_{r2}} = \min \left\{ \frac{7}{1}, \frac{6}{5} \right\} = \frac{6}{5} = \frac{\bar{b}_2}{y_{22}},$$

因此, $x_{B_r} = x_4$ 为离基变量, x_2 为进基变量, 用 p_2 替换 p_4 , 得到新基, 进行下一次迭代.

第 3 次迭代。

$$\mathbf{B} = (\mathbf{p}_3, \mathbf{p}_2, \mathbf{p}_1) = \begin{bmatrix} 1 & 2 & -1 \\ 0 & 3 & 2 \\ 0 & -1 & 1 \end{bmatrix},$$

$$\mathbf{B}^{-1} = \begin{bmatrix} 1 & -\frac{1}{5} & \frac{7}{5} \\ 0 & \frac{1}{5} & -\frac{2}{5} \\ 0 & \frac{1}{5} & \frac{3}{5} \end{bmatrix},$$

$$\mathbf{x}_B = \begin{bmatrix} x_3 \\ x_2 \\ x_1 \end{bmatrix} = \begin{bmatrix} \frac{29}{5} \\ \frac{6}{5} \\ \frac{21}{5} \end{bmatrix}, \quad \mathbf{x}_N = \begin{bmatrix} x_4 \\ x_5 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix},$$

$$f_3 = -18.$$

$$\mathbf{w} = \mathbf{c}_B \mathbf{B}^{-1} = (0, -1, -4) \begin{bmatrix} 1 & -\frac{1}{5} & \frac{7}{5} \\ 0 & \frac{1}{5} & -\frac{2}{5} \\ 0 & \frac{1}{5} & \frac{3}{5} \end{bmatrix} = (0, -1, -2),$$

$$z_4 - c_4 = \mathbf{w} \mathbf{p}_4 - c_4 = (0, -1, -2)(0, 1, 0)^T = -1,$$

$$z_5 - c_5 = \mathbf{w} \mathbf{p}_5 - c_5 = (0, -1, -2)(0, 0, 1)^T = -2.$$

由于所有 $z_j - c_j \leq 0$, 因此得到最优解

$$x_1 = \frac{21}{5}, \quad x_2 = \frac{6}{5},$$

目标函数的最优值

$$f_{\min} = -18.$$

- 表格形式
- 大M法
- 两阶段法
- 退化情形与修正单纯形法
- 对偶单纯形法

定理 7.1.2 设函数 $f(x)$ 在点 $\bar{x}$ 可微, 若 $\bar{x}$ 是局部极小点, 则梯度 $\nabla f(x) = 0$.

定理 7.1.4 设函数 $f(x)$ 在点 x 处二次可微, 若梯度 $\nabla f(\bar{x}) = 0$, 且 Hesse 矩阵 $\nabla^2 f(\bar{x})$ 正定, 则 x 是局部极小点.

定理 7.1.5 设 $f(x)$ 是定义在 $\mathbb{R}^n$ 上的可微凸函数, $\bar{x} \in \mathbb{R}^n$, 则 $\bar{x}$ 为全局极小点的充分必要条件是梯度 $\nabla f(x) = 0$

- 无约束极值问题
- 有约束极值问题
- 可行方向与下降方向

定理 7.2.8(Fritz John 条件) 设在问题 (7.2.1) 中, $\bar{x}$ 为可行点, $I = \{i | g_i(\bar{x}) = 0\}$, f 和 $g_i (i \in I)$ 在点 $\bar{x}$ 可微, $g_i (i \notin I)$ 在点 $\bar{x}$ 连续, $h_j (j = 1, \dots, l)$ 在点 $\bar{x}$ 连续可微. 如果 $\bar{x}$ 是局部最优解, 则存在不全为零的数 $w_0, w_i (i \in I)$ 和 $v_j (j = 1, \dots, l)$, 使得

$$w_0 \nabla f(\bar{x}) - \sum_{i \in I} w_i \nabla g_i(\bar{x}) - \sum_{j=1}^l v_j \nabla h_j(\bar{x}) = \mathbf{0}, \quad w_0, w_i \geq 0, \quad i \in I.$$

定理 7.2.9(K-T 必要条件) 设在问题 (7.2.1) 中, $\bar{x}$ 为可行点, $I = \{i | g_i(\bar{x}) = 0\}$, f 和 $g_i (i \in I)$ 在点 $\bar{x}$ 可微, $g_i (i \notin I)$ 在点 $\bar{x}$ 连续, $h_j (j = 1, \dots, l)$ 在点 $\bar{x}$ 连续可微, 向量集

$$\{\nabla g_i(\bar{x}), \nabla h_j(\bar{x}) \mid i \in I, j = 1, \dots, l\}$$

线性无关. 如果 $\bar{x}$ 是局部最优解, 则存在数 $w_i (i \in I)$ 和 $v_j (j = 1, \dots, l)$, 使得

$$\nabla f(\bar{x}) - \sum_{i \in I} w_i \nabla g_i(\bar{x}) - \sum_{j=1}^l v_j \nabla h_j(\bar{x}) = \mathbf{0}, \quad w_i \geq 0, \quad i \in I.$$

定理 7.2.10 设在问题 (7.2.1) 中, f 是凸函数, g_i ($i=1, \dots, m$) 是凹函数, h_j ($j=1, \dots, l$) 是线性函数, 可行域为 $S, \bar{x} \in S, I = \{i | g_i(\bar{x}) = 0\}$, 且在 x 处 K-T 必要条件成立, 即存在 $w_i \geq 0$ ($i \in I$) 及 v_j ($j=1, \dots, l$), 使得

$$\nabla f(\bar{x}) - \sum_{i \in I} w_i \nabla g_i(\bar{x}) - \sum_{j=1}^l v_j \nabla h_j(\bar{x}) = \mathbf{0}, \quad (7.2.50)$$

则 x 是全局最优解。

在许多迭代下降算法中, 具有一个共同点, 这就是得到点 $x^{(k)}$ 后, 需要按某种规则确定一个方向 $d^{(k)}$, 再从 $x^{(k)}$ 出发, 沿方向 $d^{(k)}$ 在直线 (或射线) 上求目标函数的极小点, 从而得到 $x^{(k)}$ 的后继点 $x^{(k+1)}$, 重复以上做法, 直至求得问题的解。这里所谓求目标函数在直线上的极小点, 称为一维搜索, 或称为线搜索。

一维搜索的方法很多，归纳起来，大体可分成两类：

一类是试探法。采用这类方法，需要按某种方式找试探点，通过一系列试探点来确定极小点。

另一类是函数逼近法，或称插值法。这类方法是用某种较简单的曲线逼近本来的函数曲线，通过求逼近函数的极小点来估计目标函数的极小点。

这两类方法一般只能求得极小点的近似值。

- 0.618法
- Fibonacci法
- 进退法
- 牛顿法
- 多项式法
- 三次插值法

$$\lambda_k = a_k + 0.382(b_k - a_k) \quad (9.2.10)$$

$$\mu_k = a_k + 0.618(b_k - a_k) \quad (9.2.11)$$

综上所述,运用 0.618 法,初始搜索区间记作 $[a_1, b_1]$,第 1 次迭代取两个试探点 λ_1 和 μ_1 ,以后每次迭代中,只需按照公式 (9.2.10) 式或 (9.2.11) 式新计算一点,详细计算步骤如下:

(1) 置初始区间 $[a_1, b_1]$ 及精度要求 $L > 0$, 计算试探点 λ_1 和 μ_1 , 计算函数值 $f(\lambda_1)$ 和 $f(\mu_1)$. 计算公式是

$$\lambda_1 = a_1 + 0.382(b_1 - a_1), \quad \mu_1 = a_1 + 0.618(b_1 - a_1).$$

令 $k=1$.

(2) 若 $b_k - a_k < L$, 则停止计算. 否则, 当 $f(\lambda_k) > f(\mu_k)$ 时, 转步骤(3); 当 $f(\lambda_k) \leq f(\mu_k)$ 时, 转步骤(4).

(3) 置 $a_{k+1} = \lambda_k, b_{k+1} = b_k, \lambda_{k+1} = \mu_k$,

$$\mu_{k+1} = a_{k+1} + 0.618(b_{k+1} - a_{k+1}),$$

计算函数值 $f(\mu_{k+1})$, 转步骤(5).

(4) 置 $a_{k+1} = a_k, b_{k+1} = \mu_k, \mu_{k+1} = \lambda_k$,

$$\lambda_{k+1} = a_{k+1} + 0.382(b_{k+1} - a_{k+1})$$

计算函数值 $f(\lambda_{k+1})$, 转步骤(5).

(5) 置 $k := k+1$, 返回步骤(2).

Fibonacci 法计算步骤如下:

(1) 给定初始区间 $[a_1, b_1]$ 和最终区间长度 L , 求计算函数值的次数 n , 使

$$F_n \geq (b_1 - a_1)/L.$$

置辨别常数 $\delta > 0$, 计算试探点 λ_1 和 μ_1 .

$$\lambda_1 = a_1 + \frac{F_{n-2}}{F_n}(b_1 - a_1), \quad \mu_1 = a_1 + \frac{F_{n-1}}{F_n}(b_1 - a_1).$$

计算函数值 $f(\lambda_1)$ 和 $f(\mu_1)$. 置 $k=1$.

(2) 若 $f(\lambda_k) > f(\mu_k)$, 则转步骤(3); 若 $f(\lambda_k) \leq f(\mu_k)$, 则转步骤(4).

(3) 令 $a_{k+1} = \lambda_k$, $b_{k+1} = b_k$, $\lambda_{k+1} = \mu_k$, 计算试探点 μ_{k+1} .

$$\mu_{k+1} = a_{k+1} + \frac{F_{n-k-1}}{F_{n-k}}(b_{k+1} - a_{k+1}).$$

若 $k = n-2$, 则转步骤(6); 否则, 计算函数值 $f(\mu_{k+1})$, 转步骤(5).

(4) 令 $a_{k+1} = a_k$, $b_{k+1} = \mu_k$, $\mu_{k+1} = \lambda_k$ 计算 λ_{k+1} .

$$\lambda_{k+1} = a_{k+1} + \frac{F_{n-k-2}}{F_{n-k}}(b_{k+1} - a_{k+1}).$$

若 $k = n-2$, 则转步骤 (6); 否则, 计算 $f(\lambda_{k+1})$, 转步骤 (5).

(5) 置 $k := k+1$, 转步骤 (2).

(6) 令 $\lambda_n = \lambda_{n-1}$, $\mu_n = \lambda_{n-1} + \delta$, 计算 $f(\lambda_n)$ 和 $f(\mu_n)$.

若 $f(\lambda_n) > f(\mu_n)$, 则令

$$a_n = \lambda_n , \quad b_n = b_{n-1}.$$

若 $f(\lambda_n) \leq f(\mu_n)$, 则令

$$a_n = a_{n-1} , \quad b_n = \lambda_n.$$

停止计算, 极小点含于 $[a_n, b_n]$.

进退法也是一种试探法，思路极为简单，就是从一点出发，按一定的步长，试图确定出函数值呈现“高-低-高”的三点。一个方向不成功，就退回来，再沿相反方向寻找。

下面给出进退法的计算步骤：

(1) 给定初点 $x^{(0)} \in \mathbb{R}^1$ ，初始步长 $h_0 > 0$ ，置 $h = h_0$ ， $x^{(1)} = x^{(0)}$ ，计算 $f(x^{(1)})$ ，并置 $k = 0$ 。

(2) 令 $x^{(2)} = x^{(1)} + h$ ，计算 $f(x^{(2)})$ ，置 $k := k + 1$ 。

(3) 若 $f(x^{(2)}) < f(x^{(1)})$ ，则转步骤(4)；否则，转步骤(5)。

(4) 令 $x^{(2)} = x^{(1)}$ ， $x^{(1)} = x^{(2)}$ ， $f(x^{(2)}) = f(x^{(1)})$ ， $f(x^{(1)}) = f(x^{(2)})$ ，置 $h := 2h$ ，转步骤(2)。

(5) 若 $k = 1$ ，则转步骤(6)；否则，转步骤(7)。

(6) 置 $h := -h$ ， $x^{(2)} = x^{(1)}$ ， $f(x^{(2)}) = f(x^{(1)})$ ，转步骤(2)。

(7) 令 $x^{(3)} = x^{(2)}$ ， $x^{(2)} = x^{(1)}$ ， $x^{(1)} = x^{(3)}$ ，停止计算。

这样，得到含有极小点的区间 $[x^{(1)}, x^{(3)}]$ 或者 $[x^{(3)}, x^{(1)}]$ 。

牛顿法的计算步骤如下:

- (1) 给定初点 $x^{(0)}$, 允许误差 $\epsilon > 0$, 置 $k=0$.
- (2) 若 $|f'(x^{(k)})| < \epsilon$, 则停止迭代, 得到点 $x^{(k)}$.
- (3) 计算点 $x^{(k+1)}$.

$$x^{(k+1)} = x^{(k)} - \frac{f'(x^{(k)})}{f''(x^{(k)})},$$

置 $k := k+1$, 转步骤 (2).

运用牛顿法时, 初点选择十分重要。如果初始点靠近极小点, 则可能很快收敛; 如果初始点远离极小点, 迭代产生的点列可能不收敛于极小点。

$$s = \frac{3[f(x^{(2)}) - f(x^{(1)})]}{x^{(2)} - x^{(1)}}, \quad (9.3.41)$$

$$z = s - f'(x^{(1)}) - f'(x^{(2)}), \quad (9.3.42)$$

$$w^2 = z^2 - f'(x^{(1)})f'(x^{(2)}), \quad (9.3.43)$$

$$\bar{x} = x^{(1)} + (x^{(2)} - x^{(1)}) \left(1 - \frac{f'(x^{(2)}) + w + z}{f'(x^{(2)}) - f'(x^{(1)}) + 2w} \right). \quad (9.3.51)$$

(1) 给定初始点 $x^{(1)}, x^{(2)}$, 计算 $f(x^{(1)}), f(x^{(2)}), f'(x^{(1)}), f'(x^{(2)})$, 要求满足条件

$$x^{(2)} > x^{(1)}, \quad f'(x^{(1)}) < 0, \quad f'(x^{(2)}) > 0.$$

给定允许误差 $\delta > 0$.

(2) 按照(9.3.41)式, (9.3.42)式, (9.3.43)式和(9.3.51)式计算 s, z, w 和 $\bar{x}$.

(3) 若 $|x^{(2)} - x^{(1)}| \leq \delta$, 则停止计算, 得到点 x ; 否则, 进行步骤(4).

(4) 计算 $f(\bar{x}), f'(\bar{x})$. 若 $f'(\bar{x}) = 0$, 则停止计算, 得到点 $\bar{x}$.

若 $f'(\bar{x}) < 0$, 则令 $x^{(1)} = \bar{x}, f(x^{(1)}) = f(\bar{x}), f'(x^{(1)}) = f'(\bar{x})$, 转步骤(2).

若 $f'(\bar{x}) > 0$, 则令 $x^{(2)} = \bar{x}, f(x^{(2)}) = f(\bar{x}), f'(x^{(2)}) = f'(\bar{x})$, 转步骤(2).

➤ 无约束极值问题的直接方法

- ◆ 模式搜索法
- ◆ Rosen Brock法
- ◆ 单纯形搜索法
- ◆ Powell方法

➤ 可行方向法

- ◆ Zoutendijk可行方向法
- ◆ Rosen梯度投影法
- ◆ 既约梯度法
- ◆ Frank-Wolfe方法

➤ 惩罚函数法

- ◆ 内点法
- ◆ 外点法
- ◆ 乘子法

➤ 使用导数的优化方法

- ◆ 最速下降法
- ◆ 牛顿法
- ◆ 拟牛顿法
- ◆ 共轭梯度法
- ◆ 拟牛顿法
- ◆ DFP方法

➤ 二次终止性

◆ 牛顿法

◆ 共轭梯度法

◆ 拟牛顿法

◆ Powell方法

➤ 凸函数与凸优化

Purpose

- Solve a linear programming problem
- $\min f^T x$ such that
- $A \cdot x \leq b$
- $A_{eq} \cdot x = b_{eq}$
- $lb \leq x \leq ub$
- where f , x , b , b_{eq} , lb , and ub are vectors and A and A_{eq} are matrices.

Syntax

- `x = linprog(f,A,b,Aeq,beq)`
- `x = linprog(f,A,b,Aeq,beq,lb,ub)`
- `x = linprog(f,A,b,Aeq,beq,lb,ub,x0)`
- `x = linprog(f,A,b,Aeq,beq,lb,ub,x0,options)`
- `[x,fval] = linprog(...)`
- `[x,fval,exitflag] = linprog(...)`
- `[x,fval,exitflag,output] = linprog(...)`
- `[x,fval,exitflag,output,lambda] = linprog(...)`

Description

linprog solves linear programming problems.

- $x = \text{linprog}(f,A,b)$ solves $\min f'x$ such that $A*x \leq b$.
- $x = \text{linprog}(f,A,b,Aeq,beq)$ solves the problem above while additionally satisfying the equality constraints $Aeq*x = beq$. Set $A=[]$ and $b=[]$ if no inequalities exist.
- $x = \text{linprog}(f,A,b,Aeq,beq,lb,ub)$ defines a set of lower and upper bounds on the design variables, x , so that the solution is always in the range $lb \leq x \leq ub$. Set $Aeq=[]$ and $beq=[]$ if no equalities exist.

Description

- `[x,fval] = linprog(...)` returns the value of the objective function fun at the solution x: $fval = f' * x$.
- `[x,lambda,exitflag] = linprog(...)` returns a value exitflag that describes the exit condition.
- `[x,lambda,exitflag,output] = linprog(...)` returns a structure output that contains information about the optimization.

Example

- $\min f(x) = -5x_1 - 4x_2 - 6x_3$ subject to
$$x_1 - x_2 + x_3 \leq 20$$
$$3x_1 + 2x_2 + 4x_3 \leq 42$$
$$3x_1 + 2x_2 \leq 30$$
$$0 \leq x_1, \quad 0 \leq x_2, \quad 0 \leq x_3$$
- First, enter the coefficients
$$f = [-5; -4; -6];$$
$$A = \begin{bmatrix} 1 & -1 & 1 \\ 3 & 2 & 4 \\ 3 & 2 & 0 \end{bmatrix};$$
$$b = [20; 42; 30];$$
$$lb = \text{zeros}(3,1);$$

Example

- Next, call a linear programming routine:

```
[x,fval,exitflag] = linprog(f,A,b,[],[],lb);
```

- Entering x, fval gets:

x =

0.0000

15.0000

3.0000

fval=

例 2-1 某机床厂生产甲、乙两种机床，每台销售后的利润分别为 4 000 元与 3 000 元。生产甲机床需用 A, B 机器加工，加工时间分别为每台 2 小时和 1 小时；生产乙机床需用 A, B, C 三种机器加工，加工时间为每台各一小时。若每天可用于加工的机器时数分别为 A 机器 10 小时、B 机器 8 小时和 C 机器 7 小时，问该厂应生产甲、乙机床各几台，才能使总利润最大？

模型建立 设该厂生产 x_1 台甲机床和 x_2 台乙机床

(目标函数) $\max z = 4\,000x_1 + 3\,000x_2$

$$\text{(约束条件) } s. t. \begin{cases} 2x_1 + x_2 \leq 10 \\ x_1 + x_2 \leq 8 \\ x_2 \leq 7 \\ x_1, x_2 \geq 0 \end{cases}$$

MATLAB 中线性规划的标准型为

$$\begin{aligned} \min z &= c^T x \\ s. t. \quad &\begin{cases} Ax \leq b \\ Aeq \cdot x = beq \\ lb \leq x \leq ub \end{cases} \end{aligned}$$

基本函数形式为 `linprog (c, A, b)`，它的返回值是向量 x 的值。还有其他的一些函数调用形式（在 MATLAB 指令窗运行 `help linprog` 可以看到所有的函数调用形式），如：

$$[x, fval] = \text{linprog} (c, A, b, Aeq, beq, lb, ub, x_0, \text{OPTIONS})$$

这里 `fval` 返回目标函数的值，`lb` 和 `ub` 分别是变量 x 的下界和上界， x_0 是 x 的初始值，`OPTIONS` 是控制参数。

很多看起来不是线性规划的问题也可以通过变换转化为线性规划的问题来解决.

例 2-3 规划问题为

$$\begin{aligned} \min & (|x_1| + |x_2| + \cdots + |x_n|) \\ \text{s. t. } & \mathbf{Ax} \leq \mathbf{b} \end{aligned}$$

其中 $\mathbf{x} = (x_1, x_2, \cdots, x_n)^T$, $\mathbf{A}$ 和 $\mathbf{b}$ 为相应维数的矩阵和向量.

要把上面的问题变换成线性规划问题, 只要注意到事实: 对任意的 x_i , 存在 $u_i, v_i > 0$ 满足 $x_i = u_i - v_i$, $|x_i| = u_i + v_i$

事实上, 我们只要取 $u_i = \frac{|x_i| + x_i}{2}$, $v_i = \frac{|x_i| - x_i}{2}$ 就可以满足上面的条件.

从而我们可以把上面的问题变成

$$\begin{aligned} \min & \sum_{i=1}^n (u_i + v_i) \\ \text{s. t. } & \begin{cases} \mathbf{A}(u - v) \leq \mathbf{b} \\ u, v \geq 0 \end{cases} \end{aligned}$$

fminunc

- Consider the problem of finding a set of values $[x_1, x_2]$ that solves

Minimize $f(x)$

x

$$= e^{x_1} (4x_1^2 + 2x_2^2 + 4x_1x_2 + 2x_2 + 1)$$

- To solve this two-dimensional problem, write an M-file that returns the function value
- Then, invoke the unconstrained minimization routine `fminunc`

Step 1: Write an M-file objfun.m

```
function f = objfun(x)
```

```
f=exp(x(1))*(4*x(1)^2+2*x(2)^2+  
4*x(1)*x(2)+2*x(2)+1)
```

Step 2: Invoke one of the unconstrained optimization routines

- `x0 = [-1,1]; % Starting guess`
- `options =
optimset('LargeScale','off');`
- `[x,fval,exitflag,output] =
fminunc(@objfun,x0,options);`

- After 40 function evaluations, this produces the solution
 $x =$
 $0.5000 \ -1.0000$
- The function at the solution x is returned in $fval$.
 $fval =$
 $1.3030e-10$
- The $exitflag$ tells if the algorithm converged. An $exitflag > 0$ means a local minimum was found.
 $exitflag =$
 1

Note

- When more than one local minimum exists, the initial guess for the vector $[x1, x2]$ affects both the number of function evaluations and the value of the solution point

fmincon

- For example, find x that solves
- Minimize $f(x) = e^{x_1} (4x_1^2 + 2x_2^2 + 4x_1x_2 + 2x_2 + 1)$
- subject to the constraints

$$x_1x_2 - x_1 - x_2 \leq -1.5$$

$$x_1x_2 \geq -10$$

- You can create a second M-file confun.m that returns the value at both constraints at the current x in a vector c
- The constrained optimizer, fmincon, is then invoked

Note

- Because fmincon expects the constraints to be written in the form , you must rewrite your constraints in the form $c(x) \leq 0$

$$x_1 x_2 - x_1 - x_2 + 1.5 \leq 0$$

$$-x_1 x_2 - 10 \leq 0$$

Step 1: Write an M-file confun.m for the constraints

```
function [c, ceq] = confun(x)
    % Nonlinear inequality constraints
    c = [1.5 + x(1)*x(2) - x(1) - x(2); -x(1)*x(2) - 10];
    % Nonlinear equality constraints in the form
    % ceq ( x ) = 0
    ceq = [];
```


Step 2: Invoke constrained optimization routine

```
x0 = [-1,1]; % Make a starting guess at the  
           % solution
```

```
options = optimset('LargeScale','off');
```

```
[x, fval] =  
    fmincon(@objfun,x0,[],[],[],[],[],[],@confun,  
    options)
```

- After 38 function calls, the solution x produced with function value fval is

x =

-9.5474 1.0474

fval =

0.0236

- We can evaluate the constraints at the solution

[c,ceq] = confun(x)

c=

1.0e-14 *

0.1110

-0.1776

ceq =

[]

Note

- It is, therefore, good practice to bound and constrain problems, where possible, to promote fast convergence to a solution

MATLAB 中非线性规划的数学模型写成以下形式

$$\begin{aligned} & \min f(x) \\ & s. t. \quad \begin{cases} Ax \leq B \\ Aeq \cdot x = Beq \\ C(x) \leq 0 \\ Ceq(x) = 0 \end{cases} \end{aligned}$$

其中, $f(x)$ 是标量函数, A, B, Aeq, Beq 是相应维数的矩阵和向量, $C(x), Ceq(x)$ 是非线性向量函数.

MATLAB 中的命令是:

`X = fmincon(FUN, X0, A, B, Aeq, Beq, LB, UB, NONLCON, OPTIONS)`

它的返回值是向量 x , 其中 FUN 是用 M 文件定义的函数 $f(x)$; X_0 是 x 的初始值; A, B, Aeq, Beq 定义了线性约束 $A \cdot X \leq B, Aeq \cdot X \leq Beq$, 如果没有线性约束, 则 $A = [], B = [], Aeq = [], Beq = []$; LB 和 UB 是变量 x 的下界和上界, 如果上界和下界没有约束, 则 $LB = [], UB = []$, 如果 x 无下界, 则 LB 的各分量都为 $-\inf$, 如果 x 无上界, 则 UB 的各分量都为 $\inf$; NONLCON 是用 M 文件定义的非线性向量函数 $C(x), Ceq(x)$; OPTIONS 定义了优化参数, 可以使用 MATLAB 缺省的参数设置.

例 2-8 求下列非线性规划

$$\min f(x) = x_1^2 + x_2^2 + x_3^2 + 8$$

$$s. t. \begin{cases} x_1^2 - x_2 + x_3^2 \geq 0 \\ x_1 + x_2^2 + x_3^2 \leq 20 \\ -x_1 - x_2^2 + 2 = 0 \\ x_2 + 2x_3^2 = 3 \\ x_1, x_2, x_3 \geq 0 \end{cases}$$

解 (i) 编写 M 文件 fun1.m 定义目标函数:

```
function f= fun1(x);
```

```
f= sum(x.^2)+ 8;
```

(ii) 编写 M 文件 fun2.m 定义非线性约束条件:

```
function [g,h]= fun2(x);
```



```
g = [- x(1)^2 + x(2) - x(3)^2  
x(1) + x(2)^2 + x(2)^2 - 20]; %非线性不等式约束  
h = [- x(1) - x(2)^2 + 2  
x(2) + 2* x(3)^2 - 3]; %非线性等式约束
```

(iii) 编写主程序文件 example2.m 如下:

```
options = optimset('largescale','off');  
[x,y] = fmincon('fun1', rand(3,1), [], [], [], [], zeros(3,1), [], 'fun2',  
options)
```

可以求得当 $x_1=0.5522$, $x_2=1.2033$, $x_3=0.9478$ 时, 最小值 $y=10.6511$.

一贸易公司专门经营某种杂粮的批发业务。公司现有库容 5 000 担的仓库。1 月 1 日,公司拥有库存 1 000 担杂粮,并有资金 20 000 元。估计第一季度杂粮价格如表 1-9 所示。

表 1-9

	进货价/元/担	出货价/元/担
1 月	2.85	3.10
2 月	3.05	3.25
3 月	2.90	2.95

如买进的杂粮当月到货,但需到下月才能卖出,且规定“货到付款”。公司希望本季末库存为 2 000 担,问应采取什么样的买进与卖出的策略使 3 个月总的获利最大?(列出问题的线性规划模型,不求解)

微信公众号-科研交流

荣誉出品

THANK YOU!!!

