

第一章 预备知识

§1 矩阵与向量

§ 1.1 定义及基本运算

nm 个实数 $a_{ij}, i=1, 2, \dots, n; j=1, 2, \dots, m$ 作如下排列, 称为一个 n 行 m 列的矩阵, 简称为 $n \times m$ 矩阵, 并用 A 表示

$$A \triangleq \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2m} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nm} \end{pmatrix}$$

有时也简记作 $A=(a_{ij})_{n \times m}$, 或更简单记作 $A=(a_{ij})$, 当 $n=m$ 时, 称它为 n 阶方阵, a_{ij} 称为 A 的第 i 行第 j 列元, 或 (i, j) 元。各元全为 0 的 $n \times m$ 矩阵简记作 O , 称它为零矩阵。

$n \times 1$ 矩阵称为 n 维向量, 通常记作

$$x \triangleq \begin{pmatrix} x^{(1)} \\ x^{(2)} \\ \vdots \\ x^{(n)} \end{pmatrix}$$

其中 $x^{(i)}$ 称为 x 的第 i 个分量。

设 $A=(a_{ij})$, 我们把原矩阵的行和列互调所成的矩阵称为 A 的转置, 记为 A^T , 它是一个 $m \times n$ 矩阵

$$A^T \triangleq \begin{pmatrix} a_{11} & a_{21} & \cdots & a_{n1} \\ a_{12} & a_{22} & \cdots & a_{n2} \\ \vdots & \vdots & & \vdots \\ a_{1m} & a_{2m} & \cdots & a_{nm} \end{pmatrix},$$

显然 $(A^T)^T = A$ 。特别, n 维向量 x 的转置 x^T 是一个 $1 \times n$ 矩阵

$$x^T = (x^{(1)}, x^{(2)}, \dots, x^{(n)}).$$

下面定义矩阵的运算

i) 两个 $n \times m$ 矩阵 $A = (a_{ij}), B = (b_{ij})$ 的和, 记作 $A + B$ 是 $n \times m$ 矩阵, 它的元是 A 与 B 相应元之和:

$$A + B \triangleq (a_{ij} + b_{ij}).$$

ii) 实数 α 和 $n \times m$ 矩阵 A 的积记作 αA , 仍是 $n \times m$ 矩阵, 它的元是 α 乘 A 的相应元:

$$\alpha A \triangleq (\alpha a_{ij}),$$

(-1) A 记为 $-A$ 。

iii) $n \times m$ 矩阵 $A = (a_{ij})$ 和 $m \times l$ 矩阵 $B = (b_{jk})$ 的积记作 AB , 是 $n \times l$ 矩阵, 它的第 (i, k) 元为 $\sum_{j=1}^m a_{ij} b_{jk}$, 即

$$AB \triangleq \left(\sum_{j=1}^m a_{ij} b_{jk} \right)$$

注意: 只有行数与列数分别相等的两个矩阵才能相加, 只有前一矩阵的列数等于后一矩阵的行数的两个矩阵才能相乘。对于矩阵的加, 数乘与乘的运算, 容易验证:

对加法满足结合律和交换律

$$(A + B) + C = A + (B + C), A + B = B + A.$$

对乘法满足结合律

$$(\alpha\beta)A = \alpha(\beta A), (\alpha A)B = \alpha(AB),$$

$$(AB)C = A(BC).$$

对乘法和加法满足分配律

$$\alpha(A + B) = \alpha A + \alpha B, (\alpha + \beta)A = \alpha A + \beta A,$$

$$A(B + C) = AB + AC, (B + C)A = BA + CA.$$

此外, 对矩阵的转置运算还有如下关系式

$$(A + B)^T = A^T + B^T, (\alpha A)^T = \alpha A^T, (AB)^T = B^T A^T.$$

特别要注意的是, 矩阵乘法一般不满足交换律, 即 $AB \neq BA$

一般不成立,而且常常是当 AB 有意义时, BA 并不一定有意义,因为前者要求 A 的列数等于 B 的行数,却并非要求 B 的列数等于 A 的行数,故 BA 不一定有意义。即使有意义,它们之间也不一定进行比较,例如,设 x 和 y 都是 n 维向量时,

$$x^T y = \left(\sum_{i=1}^n x^{(i)} y^{(i)} \right)_{1 \times 1} = \sum_{i=1}^n x^{(i)} y^{(i)}$$

是一个数,而 $yx^T = (y^{(i)} x^{(j)})_{n \times n}$ 是一个 $n \times n$ 的矩阵。最后,即使 A 与 B 的行数和列数都彼此相等,即它们都是同阶方阵时,乘法交换律一般仍不成立,例如

$$A = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}, \quad B = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$$

则

$$AB = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}, \quad BA = \begin{pmatrix} 1 & 1 \\ 0 & 0 \end{pmatrix},$$

所以 $AB \neq BA$ 。另外还应注意,与数的情况不同,由 $AB = 0$ 一般并不能推出 A 或 B 为零矩阵,例如

$$\begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}.$$

在矩阵运算中,有时先将矩阵元“分块”,再进行运算,往往比较简便。例如,将两个 $n \times m$ 矩阵 A, B 分别分成对立的四块:

$$A = \begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix}, \quad B = \begin{pmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{pmatrix}$$

其中 A_{ij}, B_{ij} 为 $n_i \times m_j$ 矩阵, $i=1, 2; j=1, 2; n_1 + n_2 = n; m_1 + m_2 = m$, 则有

$$A^T = \begin{pmatrix} A_{11}^T & A_{21}^T \\ A_{12}^T & A_{22}^T \end{pmatrix} \quad A + B = \begin{pmatrix} A_{11} + B_{11} & A_{12} + B_{12} \\ A_{21} + B_{21} & A_{22} + B_{22} \end{pmatrix}$$

$$\alpha A = \begin{pmatrix} \alpha A_{11} & \alpha A_{12} \\ \alpha A_{21} & \alpha A_{22} \end{pmatrix}.$$

又如,将 $n \times m$ 矩阵 A 分成如上的四块,而将 $m \times l$ 矩阵 C 分成如

下的四块

$$C = \begin{pmatrix} C_{11} & C_{12} \\ C_{21} & C_{22} \end{pmatrix}$$

其中 C_{ij} 为 $m_i \times l_j$, $i=1,2$, $j=1,2$, $l_1+l_2=l$, 则容易验证有下列分块乘法规律

$$AC = \begin{pmatrix} A_{11}C_{11} + A_{12}C_{21} & A_{11}C_{12} + A_{12}C_{22} \\ A_{21}C_{11} + A_{22}C_{21} & A_{21}C_{12} + A_{22}C_{22} \end{pmatrix}$$

当然,还可以按以上原则将矩阵分成更多的块进行运算,行块和列块的数目也不必相同。

§ 1.2 方阵的行列式、迹与逆

$n \times n$ 矩阵即行数等于列数的矩阵,称为 n 阶方阵。主对角线(从左上角到右下角的对角线)元全为 1 而其余的元全为 0 的 n 阶方阵,称为 n 阶单位阵,记作 I_n ,在不会使人误解时,也简记作 I

$$I_n \triangleq \begin{pmatrix} 1 & & 0 \\ & \ddots & \\ 0 & & 1 \end{pmatrix}_{n \times n}$$

我们把次对角线(从右上角到左下角的对角线)元全为 1 而其余的元全为 0 的 n 阶方阵,记作 T_n 或 T

$$T_n = \begin{pmatrix} 0 & & 1 \\ & \ddots & \\ 1 & & 0 \end{pmatrix}_{n \times n}$$

由矩阵乘法规则易知,对任一 $n \times m$ 矩阵 A

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2m} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nm} \end{pmatrix}$$

有

$$I_n A = A = A I_m$$

$$T_n A = \begin{pmatrix} a_{n1} & a_{n2} & \cdots & a_{nm} \\ \vdots & \vdots & & \vdots \\ a_{21} & a_{22} & \cdots & a_{2m} \\ a_{11} & a_{12} & \cdots & a_{1m} \end{pmatrix}$$

$$AT_m = \begin{pmatrix} a_{1m} & \cdots & a_{12} & a_{11} \\ a_{2m} & \cdots & a_{22} & a_{21} \\ \vdots & & \vdots & \vdots \\ a_{nm} & \cdots & a_{n2} & a_{n1} \end{pmatrix}$$

由此可见, T_n 左乘 (T_m 右乘) A 所成矩阵是 A 的各 行 (列) 向量倒序排列所成的矩阵。特别,

$$\text{设 } x = \begin{pmatrix} x^{(1)} \\ x^{(2)} \\ \vdots \\ x^{(n)} \end{pmatrix}, \quad \text{则 } T_n x = \begin{pmatrix} x^{(n)} \\ x^{(n-1)} \\ \vdots \\ x^{(1)} \end{pmatrix}.$$

对于 n 阶方阵 A , 可以求 A 的行列式, 记为 $|A|$ 或 $\det A$, 它有下列一些熟知的性质

$$|A^T| = |A|, \quad |\alpha A| = \alpha^n |A|,$$

$$|AB| = |A| |B|,$$

其中 B 也是 n 阶方阵。

n 阶方阵 A 的迹定义为它的主对角线元之和, 记作 $\text{Tr} A$, 即

$$\text{Tr} A = \sum_{i=1}^n a_{ii}. \quad (1.1.1)$$

显然有

$$\text{Tr} A^T = \text{Tr} A, \quad \text{Tr}(A + B) = \text{Tr} A + \text{Tr} B,$$

$$\text{Tr}(\alpha A) = \alpha \text{Tr} A.$$

又如果 A, B 分别为 $n \times m$ 和 $m \times n$ 矩阵, 则有

$$\text{Tr}(AB) = \sum_{i=1}^n \left(\sum_{j=1}^m a_{ij} b_{ji} \right) = \sum_{j=1}^m \left(\sum_{i=1}^n b_{ji} a_{ij} \right) = \text{Tr}(BA)$$

设 x 是 n 维向量, A 是 n 阶方阵, 则有

$$x^T A x = \sum_{i=1}^n \sum_{j=1}^n x^{(i)} a_{ij} x^{(j)} = \text{Tr}(A x x^T).$$

设 A 为 n 阶方阵, 如果 $|A| \neq 0$, 称 A 为非奇异阵或可逆阵, 这时定义 A 的逆 A^{-1} 为如下的 n 阶方阵

$$A^{-1} \triangleq \left((-1)^{i+j} \frac{|A_{ji}|}{|A|} \right) \quad (1.1.2)$$

其中 $(-1)^{i+j} \frac{|A_{ji}|}{|A|}$ 是 A^{-1} 的第 i 行第 j 列的元, 而 A_{ji} 表示 A 中去掉第 j 行和第 i 列后所成的 $n-1$ 阶方阵。由行列式的性质可以证明下面的基本关系式

$$A A^{-1} = A^{-1} A = I$$

而且可以证明满足上述方程的 A^{-1} 是唯一存在的, 因为若有另一个 n 阶方阵 B , 满足

$$AB = BA = I$$

则 $B = IB = A^{-1}AB = A^{-1}I = A^{-1}$ 。从这个基本关系式出发, 容易验证如下的性质

$$|A^{-1}| = |A|^{-1}, \quad (A^{-1})^T = (A^T)^{-1}, \quad (A^{-1})^{-1} = A,$$

$$(\alpha A)^{-1} = \alpha^{-1} A^{-1}, \quad (AB)^{-1} = B^{-1} A^{-1}.$$

下面我们来证明一个有关求分块方阵的行列式和逆的公式, 这在今后多处用到。

首先考虑 A 是如下 $k+l$ 阶分块矩阵的情形

$$A = \begin{pmatrix} A_{11} & A_{12} \\ 0 & A_{22} \end{pmatrix} \quad \text{或} \quad A = \begin{pmatrix} A_{11} & 0 \\ A_{21} & A_{22} \end{pmatrix}$$

其中 A_{11} 和 A_{22} 分别为 k 阶和 l 阶方阵。由行列式性质知, $|A| = |A_{11}| |A_{22}|$, 又如果加上 A_{11} 和 A_{22} 都是可逆阵这个条件, 则 A 也是可逆阵, 且依 A 的上述两种形式分别为

$$A^{-1} = \begin{pmatrix} A_{11}^{-1} & -A_{11}^{-1} A_{12} A_{22}^{-1} \\ 0 & A_{22}^{-1} \end{pmatrix}$$

或

$$A^{-1} = \begin{pmatrix} A_{11}^{-1} & 0 \\ -A_{22}^{-1}A_{21}A_{11}^{-1} & A_{22}^{-1} \end{pmatrix}$$

这只需验证 $AA^{-1} = A^{-1}A = I$ 是否成立即可, 这里仅对前一式作验证如下, 由分块矩阵乘法知

$$\begin{aligned} AA^{-1} &= \begin{pmatrix} A_{11} & A_{12} \\ 0 & A_{22} \end{pmatrix} \begin{pmatrix} A_{11}^{-1} & -A_{11}^{-1}A_{12}A_{22}^{-1} \\ 0 & A_{22}^{-1} \end{pmatrix} \\ &= \begin{pmatrix} I_k & -A_{12}A_{22}^{-1} + A_{12}A_{22}^{-1} \\ 0 & I_l \end{pmatrix} = I_{k+l} \end{aligned}$$

同理 $A^{-1}A = I_{k+l}$

再进一步考虑一般的 $k+l$ 阶分块方阵

$$A = \begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix}$$

其中 A_{11} 和 A_{22} 分别为 k 阶和 l 阶可逆阵, A 分别用以下两种方式分解为两个分块三角形阵之乘积

$$\begin{aligned} A &= \begin{pmatrix} I_k & 0 \\ A_{21}A_{11}^{-1} & I_l \end{pmatrix} \begin{pmatrix} A_{11} & A_{12} \\ 0 & A_{22} - A_{21}A_{11}^{-1}A_{12} \end{pmatrix} \\ A &= \begin{pmatrix} I_k & A_{12}A_{22}^{-1} \\ 0 & I_l \end{pmatrix} \begin{pmatrix} A_{11} - A_{12}A_{22}^{-1}A_{21} & 0 \\ A_{21} & A_{22} \end{pmatrix} \end{aligned}$$

分别求上式中诸方阵的行列式, 便得到求分块方阵的行列式公式为

$$\begin{aligned} |A| &= |A_{11}| |A_{22} - A_{21}A_{11}^{-1}A_{12}| \\ &= |A_{11} - A_{12}A_{22}^{-1}A_{21}| |A_{22}| \end{aligned} \quad (1.1.3)$$

我们分别对 A 的上述两种分解形式求逆, 有

$$\begin{aligned} A^{-1} &= \begin{pmatrix} A_{11} & A_{12} \\ 0 & A_{22} - A_{21}A_{11}^{-1}A_{12} \end{pmatrix}^{-1} \begin{pmatrix} I_k & 0 \\ A_{21}A_{11}^{-1} & I_l \end{pmatrix}^{-1} \\ A^{-1} &= \begin{pmatrix} A_{11} - A_{12}A_{22}^{-1}A_{21} & 0 \\ A_{21} & A_{22} \end{pmatrix}^{-1} \begin{pmatrix} I_k & A_{12}A_{22}^{-1} \\ 0 & I_l \end{pmatrix}^{-1} \end{aligned}$$

根据三角阵求逆公式, 得两式可分别表为

$$A^{-1} = \begin{pmatrix} A_{11}^{-1} & -A_{11}^{-1}A_{12}(A_{22} - A_{21}A_{11}^{-1}A_{12})^{-1} \\ 0 & (A_{22} - A_{21}A_{11}^{-1}A_{12})^{-1} \end{pmatrix} \begin{pmatrix} I_k & 0 \\ -A_{21}A_{11}^{-1} & I_l \end{pmatrix}$$

$$= \begin{pmatrix} A_{11}^{-1} + A_{11}^{-1}A_{12}\tilde{A}_{22}^{-1}A_{21}A_{11}^{-1} & -A_{11}^{-1}A_{12}\tilde{A}_{22}^{-1} \\ -\tilde{A}_{22}^{-1}A_{21}A_{11}^{-1} & \tilde{A}_{22}^{-1} \end{pmatrix} \quad (1.1.4)$$

其中

$$\tilde{A}_{22} = A_{22} - A_{21}A_{11}^{-1}A_{12}$$

以及

$$\begin{aligned} A^{-1} &= \begin{pmatrix} (A_{11} - A_{12}A_{22}^{-1}A_{21})^{-1} & 0 \\ -A_{22}^{-1}A_{21}(A_{11} - A_{12}A_{22}^{-1}A_{21})^{-1} & A_{22}^{-1} \end{pmatrix} \begin{pmatrix} I_k & -A_{12}A_{22}^{-1} \\ 0 & I_l \end{pmatrix} \\ &= \begin{pmatrix} \tilde{A}_{11}^{-1} & -\tilde{A}_{11}^{-1}A_{12}A_{22}^{-1} \\ -A_{22}^{-1}A_{21}\tilde{A}_{11}^{-1} & A_{22}^{-1}A_{21}\tilde{A}_{11}^{-1}A_{12}A_{22}^{-1} + A_{22}^{-1} \end{pmatrix} \end{aligned} \quad (1.1.5)$$

其中

$$\tilde{A}_{11} = A_{11} - A_{12}A_{22}^{-1}A_{21}$$

公式(1.1.4)和(1.1.5)都称为方阵 A 的分块求逆公式。又因为一个可逆方阵的逆是唯一的，所以(1.1.4)和(1.1.5)中对应的块必然相等。于是，对比(1.1.4)和(1.1.5)的右边矩阵的左上角块，可以得到一个重要的矩阵等式，此等式称为矩阵的反演公式

$$\begin{aligned} (A_{11} - A_{12}A_{22}^{-1}A_{21})^{-1} &= A_{11}^{-1} + A_{11}^{-1}A_{12}(A_{22} - \\ &\quad - A_{21}A_{11}^{-1}A_{12})^{-1}A_{21}A_{11}^{-1} \end{aligned} \quad (1.1.6)$$

此外，对比它们的右上角块，还可得到公式

$$A_{11}^{-1}A_{12}(A_{22} - A_{21}A_{11}^{-1}A_{12})^{-1} = (A_{11} - A_{12}A_{22}^{-1}A_{21})^{-1}A_{12}A_{22}^{-1} \quad (1.1.7)$$

公式(1.1.6)和(1.1.7)对于任意的 k 阶方阵 A_{11} ， l 阶方阵 A_{22} ， $k \times l$ 矩阵 A_{12} 和 $l \times k$ 矩阵 A_{21} ，只要表示式中出现的逆都存在，总是成立。这些公式当然也可以直接验证。

§ 1.3 矩阵的秩、范数与对称阵

给定一组 n 维向量 $x_1, x_2, \dots, x_m$ ，如果存在不全为零的数 $\alpha_1, \alpha_2, \dots, \alpha_m$ ，使得

$$\alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_m x_m = 0 \quad (1.1.8)$$

则称此向量组 $x_1, x_2, \dots, x_m$ 是线性相关；否则称为线性无关，即只有在 $\alpha_1 = \alpha_2 = \dots = \alpha_m = 0$ 时，(1.1.8)式才成立。

设 $x_{i_1}, x_{i_2}, \dots, x_{i_r}$ 为 n 维向量组 $x_1, x_2, \dots, x_m$ 中的一个线性无关部分组, 如果任意 r 个以上向量构成的部分组均线性相关, 则称 $x_{i_1}, x_{i_2}, \dots, x_{i_r}$ 为 $x_1, x_2, \dots, x_m$ 的一个极大线性无关组。注意, 一个向量组中, 极大线性无关组可以不只有一个。例如, $x_1 = (1, 0), x_2 = (0, 1), x_3 = (1, 1)$, 不难验证 x_1, x_2 是 x_1, x_2, x_3 的一个极大线性无关组, 但 x_2, x_3 也是一个极大线性无关组。

n 维向量组 $x_1, x_2, \dots, x_m$ 的秩, 定义为这个向量组内的极大线性无关组的向量个数。

矩阵 A 的秩, 定义为它的全体行向量组的秩。可以证明, 矩阵 A 的全体行向量组的秩与 A 的全体列向量组的秩相等, 故矩阵 A 的秩也可由全体列向量组的秩来定义。 $n \times m$ 矩阵 A 的秩, 记作 $\text{rank} A$, $\text{rank} A \leq \min(n, m)$, 如果等号成立, 则称 A 为满秩矩阵。一个满秩的方阵, 称为非奇异阵, 它是可逆的。

设 A 为任一 $n \times m$ 矩阵, 定义 A 的范数为

$$\|A\| \triangleq (\text{Tr}(A^T A))^{\frac{1}{2}} = \left(\sum_{i=1}^n \sum_{j=1}^m a_{ij}^2 \right)^{\frac{1}{2}} \quad (1.1.9)$$

特别, 如果 x 是 n 维向量, 则

$$\|x\| = (x^T x)^{\frac{1}{2}} = \left(\sum_{i=1}^n x^{(i)2} \right)^{\frac{1}{2}} \quad (1.1.10)$$

由此可见, 范数的概念是普通欧氏空间向量长度这一概念的推广。显然, $\|A^T\| = \|A\|$ 。由范数的定义及熟知的柯西(Cauchy)不等式和许瓦茨(Schwarz)不等式, 容易推出关于范数的如下一些基本性质:

- i) $\|A\| = 0$ 当且仅当 $A = 0$;
- ii) $\|A + B\| \leq \|A\| + \|B\|$;
- iii) $\|\alpha A\| = |\alpha| \|A\|$;
- iv) $\|AB\| \leq \|A\| \|B\|$ 。

这里, 我们仅给出性质 iv) 的证明。设 A, B 分别为 $n \times m$ 、

$m \times l$ 矩阵, 则由定义及许瓦茨不等式, 有

$$\begin{aligned}\|AB\|^2 &= \text{Tr}(B^r A^r AB) = \sum_{i=1}^l \sum_{i=1}^n \left(\sum_{k=1}^m a_{ik} b_{ki} \right)^2 \\ &\leq \sum_{i=1}^l \sum_{i=1}^n \left(\sum_{k=1}^m a_{ik}^2 \right) \left(\sum_{k=1}^m b_{ki}^2 \right) = \\ &= \left(\sum_{i=1}^n \sum_{k=1}^m a_{ik}^2 \right) \left(\sum_{i=1}^l \sum_{k=1}^m b_{ki}^2 \right) = \|A\|^2 \|B\|^2\end{aligned}$$

两边开方即为性质 iv 中的式子。

范数的定义有多种, “ $A^r A$ 最大特征根的方根”也是常用的一种范数形式, 不难验证, 这种 $\|A\|$ 同样满足上面的四个性质。

一个 n 阶方阵 A , 如果满足 $A^r = A$, 即 $a_{ij} = a_{ji}$, $i, j = 1, 2, \dots, n$, 则称 A 为对称阵。显然, 两个同阶对称阵之和、实数与对称阵之积以及可逆对称阵之逆, 都仍是对称阵。但是两个同阶对称阵之积却不一定是对称阵, 例如

$$\begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 2 & 0 \end{pmatrix}.$$

对称阵中的非负定性及正定性是非常重要的。一个 n 阶对称阵 A , 如果对于任意 n 维向量 x , 恒成立

$$x^r A x = \sum_{i=1}^n \sum_{j=1}^m a_{ij} x^{(i)} x^{(j)} \geq 0.$$

则称 A 是非负定阵, 记作 $A \geq 0$; 如果对于任意非零向量 x , 恒有 $x^r A x > 0$, 则称 A 为正定阵, 记作 $A > 0$ 。显然, 单位阵 $I > 0$, 两个同阶非负定阵之和仍为非负定阵; 若其中一个为正定阵, 其和也是正定阵, 正实数与非负定(正定)阵之积仍然是非负定(正定)阵。任何正定阵必为可逆阵, 而且它的逆也是正定阵。事实上, 首先反设 n 阶正定阵 A 不可逆, 即 $|A| = 0$, 则由行列式性质易知其中一列必为其它列的线性组合, 即存在 n 维向量 $x \neq 0$, 使 $Ax = 0$, 从而 $x^r A x = 0$, 这与 A 的正定性矛盾, 故 A^{-1} 一定存在; 其次, 对任意 $x \neq 0$, 则 $A^{-1}x \neq 0$, 由 A 的正定性知 $x^r A^{-1}x = x^r$

$(A^{-1}AA^{-1})x = (A^{-1}x)^T A(A^{-1}x) > 0$, 这就证明了 A^{-1} 的正定性。

两个 n 阶对称阵 A 和 B , 如果满足 $A - B \geq 0$, 即对于任意 n 维向量 x , 恒有

$$x^T Ax \geq x^T Bx$$

则称 A 不小于 B , 并记作 $A \geq B$ (或 $B \leq A$)。注意: 与普通的实数不同, 并不是任意两个同阶的对称阵 A 、 B 都能比较大小, 即并非 $A \geq B$ 或 $A \leq B$ 两者之中必有一个成立。

如果 A 是 n 阶非负定阵, C 是任意 $n \times m$ 矩阵, 则易证 $C^T AC$ 是 m 阶非负定阵 (特别 $C^T C = C^T I C$ 是非负定阵), 因为 $(C^T AC)^T = C^T A^T C = C^T AC$, 故 $C^T AC$ 为对称阵, 而且由 A 的非负定性可知, 对于任意 m 维向量 Z ,

$$Z^T (C^T AC) Z = (CZ)^T A (CZ) \geq 0$$

反之, 用通常配二次型为线性型的平方和的方法可以证明, 任一非负定阵 A 必能表成 $C^T C$ 的形式。

§ 1.4 矩阵微分运算

设 $n \times m$ 矩阵 A 、 B 与 $m \times 1$ 矩阵 C 的元都是 α 的函数, $\lambda = \lambda(\alpha)$ 为 α 的函数, 我们定义矩阵 A 对 α 的微商为如下的 $n \times m$ 矩阵

$$\frac{dA}{d\alpha} = \left(\frac{da_{ij}}{d\alpha} \right), \quad (1.1.11)$$

即 A 中的每一元对 α 微商后所成的矩阵。由矩阵加法、数乘和乘法的运算规则容易验证如下的微分规则:

$$\begin{aligned} \frac{d}{d\alpha}(A+B) &= \frac{dA}{d\alpha} + \frac{dB}{d\alpha}, \\ \frac{d}{d\alpha}(\lambda A) &= \frac{d\lambda}{d\alpha} A + \lambda \frac{dA}{d\alpha}, \\ \frac{d}{d\alpha}(AC) &= \frac{dA}{d\alpha} C + A \frac{dC}{d\alpha}. \end{aligned}$$

又设 f 、 g 是以 $n \times m$ 矩阵 X 的 nm 个元 x_{ij} 为自变元的函数, 定义 f 对 X 的微商为如下的 $n \times m$ 矩阵

$$\frac{df}{dX} = \left(\frac{\partial f}{\partial x_{ij}} \right)_{n \times m} \quad (1.1.12)$$

同样可以验证如下的微分规则

$$\begin{aligned} \frac{d}{dX}(f+g) &= \frac{df}{dX} + \frac{dg}{dX}, \\ \frac{d}{dX}(fg) &= \frac{df}{dX}g + f\frac{dg}{dX}. \end{aligned}$$

因为向量是矩阵的特殊情形，所以上述定义对向量也适用。设 $\mathbf{c} = (c_1, \dots, c_n)^T$, $\mathbf{a} = (a_1, \dots, a_m)^T$, 我们定义 $\mathbf{c}$ 对 $\mathbf{a}^T$ 的微商为

$$\frac{d\mathbf{c}}{d\mathbf{a}^T} = \left(\frac{\partial c_i}{\partial a_j} \right)_{n \times m} \quad (1.1.13)$$

根据定义及上述微商法则，可以证明下面这些有用的微商公式

i) 设 A 为 n 阶方阵，它的元是 α 的函数，则

$$\frac{dA^{-1}}{d\alpha} = -A^{-1} \frac{dA}{d\alpha} A^{-1} \quad (1.1.14)$$

因为， $I = AA^{-1}$ ，故 $0 = \frac{dI}{d\alpha} = \frac{dA}{d\alpha} A^{-1} + A \frac{dA^{-1}}{d\alpha}$ ，由此得到 (1.1.14)。

ii) 在 i 的条件下，则

$$\frac{d|A|}{d\alpha} = |A| \operatorname{Tr} \left(A^{-1} \frac{dA}{d\alpha} \right) \quad (1.1.15)$$

$$\begin{aligned} \text{因为, } \operatorname{Tr} \left(A^{-1} \frac{dA}{d\alpha} \right) &= \sum_{i=1}^n \left(\sum_{j=1}^n (-1)^{i+j} \frac{A_{ji}}{|A|} \frac{da_{ji}}{d\alpha} \right) \\ &= \frac{1}{|A|} \sum_{i=1}^n \sum_{j=1}^n (-1)^{i+j} A_{ji} \frac{da_{ji}}{d\alpha} = \frac{1}{|A|} \frac{d|A|}{d\alpha} \end{aligned}$$

$$\text{所以} \quad \frac{d|A|}{d\alpha} = |A| \operatorname{Tr} \left(A^{-1} \frac{dA}{d\alpha} \right).$$

iii) 设 X 为 $n \times m$ 变元矩阵， A 、 B 分别为 $n \times n$ 和 $n \times m$ 常数矩阵，则

$$(a) \quad \frac{d\operatorname{Tr}(BX)}{dX} = \frac{d\operatorname{Tr}(X^T B^T)}{dX} = B^T, \quad (1.1.16)$$

$$(b) \frac{d\text{Tr}(X^r A X)}{dX} = (A + A^r)X. \quad (1.1.17)$$

$$\text{因为 } \text{Tr } X^r B^r = \sum_{j=1}^n \left(\sum_{i=1}^m x_{ji} b_{ij} \right)$$

$$\frac{d\text{Tr}(X^r B^r)}{dX} = \left(\frac{\partial \left(\sum_{j=1}^n \sum_{i=1}^m x_{ji} b_{ij} \right)}{\partial x_{kl}} \right) = (b_{lk}) = B^r$$

即得(a)。

又由(a)知

$$\frac{d\text{Tr}(X^r A X)}{dX} = AX + (X^r A)^r = (A + A^r)X$$

即得(b)。

iv) 作为 iii) 的应用, 设 x 为 n 维变向量(每一分量为变元), μ 为 n 维常数向量, A 为 n 阶常数对称阵, 则

$$\begin{aligned} \frac{d}{dx} [(x - \mu)^r A (x - \mu)] &= \frac{d}{dx} \text{Tr} [(x - \mu)^r A (x - \mu)] \\ &= (A + A^r)(x - \mu) = 2A(x - \mu). \end{aligned} \quad (1.1.18)$$

§ 2 随机事件与概率

§ 2.1 随机事件

设在某些不变的条件下重复进行试验或观测, 试验或观测的结果称为事件。每次试验或观测一定发生的事件称为必然事件, 用 Ω 表示。例如“在标准大气压下, 水加热到 100°C 时要沸腾”是一个必然事件。如果每次试验一定不发生的事件, 称为不可能事件, 用 ϕ 表示。例如“北京地区 9 月份平均温度为 5°C 是不可能事件。如果每次试验可能发生也可能不发生的事件, 称为随机事件(或偶然事件), 用 A, B, C 等等表示。这类事件在自然界中广泛存在着, 例如“北京地区 6 月份平均温度不高于 30°C , 便是一个随机事件, 因为有的年份高于, 有的年份不高于, 也就是这件事情可能发生也

可能不发生,因而它是一个随机事件。又例如“每年 6 至 8 月间某河流的最高水位高于 6 米”也是一个随机事件,要问 1990 年该事件是否发生? 我们无法准确断言,但是由于对以往历年的多次观测,我们可以去确定这些事件发生的可能性大小,这正是概率统计的研究内容。

应该指出,必然事件与不可能事件有着紧密的联系,如果每次试验时某个结果一定发生,则该结果的反面就一定不发生,即为不可能事件。无论必然事件、不可能事件还是随机事件都是相对于一定的事件而言的,如果条件改变了,事件的性质也会改变。例如在生产力落后的条件下,小麦亩产 1000 斤以上是不可能事件,而当生产力高度发达时,小麦亩产 1000 斤以上就变为随机事件或必然事件。故把必然事件与不可能事件包含在随机事件之内一起考虑,作为随机事件的两个极端情况。

有些随机事件可以看作是由多个随机事件组成的,例如掷一颗均匀正六面体骰子,“出现奇数点”这一随机事件是由出现么点、三点、五点组成的随机事件,而有的随机事件则不能分解为多个随机事件的组合,如上面的掷骰子试验,“出现三点”这一随机事件,再也不能分解为其它随机事件,称它为基本事件。今后为了简单起见称随机事件为事件。

§ 2.2 随机事件的关系与运算

1. 事件的包含:如果事件 A 发生蕴含着事件 B 也发生,称 B 包含 A ,记作 $B \supset A$ (或 $A \subset B$)。例如对某河流,事件“6 月至 8 月最高水位不超过 6 米”包含事件“6 月至 8 月最高水位不超过 5.8 米”。

2. 事件相等:如果 $A \subset B$ 且 $B \subset A$,则称 A 与 B 相等 (或等价),记作 $A = B$ 。例如事件“一批产品中废品数少于 4 个”与事件“这批产品中废品不超过 3 个”是相等。

3. 事件之和:两事件 A 、 B 至少有一个发生所构成的事件,则称为 A 与 B 之和,记作 $A \cup B$,显然它表示的事件“ A 或 B 至少有一个发生,即或 A 发生或 B 发生。类似地,事件“ $A_1, A_2, \dots, A_n$

中至少有一个发生”,称为 $A_1, A_2, \dots, A_n$ 之和,记作 $\bigcup_{i=1}^n A_i$;事件“ $A_1, A_2, \dots$ 中至少有一个发生”,称为 $A_1, A_2, \dots$ 之和,记作 $\bigcup_{i=1}^{\infty} A_i$ 。

4. 事件之差: 事件“ A 发生而 B 不发生”所构成的事件,称为 A 与 B 之差,记作 $A-B$ 。

5. 事件之交: 事件“ A 和 B 同时发生”,称为 A 与 B 之交,记作 $A \cap B$ (或简记为 AB)。类似地,事件“ $A_1, A_2, \dots, A_n$ 都发生”,称为 $A_1, A_2, \dots, A_n$ 之交,记作 $\bigcap_{i=1}^n A_i$ (或 $A_1 A_2 \dots A_n$)。类似地,我们定义 $\bigcap_{i=1}^{\infty} A_i$ 。例如 A 表示“明天最高温度 $30-32^\circ\text{C}$ ”, B 表示“明天最大风力4级”,则事件 AB 表示“明天最高温度 $30-32^\circ\text{C}$,最大风力为4级”。

6. 互斥事件: 事件 A 和事件 B 不可能同时发生所构成的事件,称 A 与 B 是互斥(或称不相容)事件,记作 $AB = \phi$ 。例如 A 表示“明天最高温度小于 25°C ”, B 表示“明天最高温度超过 30°C ”,则 A 与 B 不可能同时发生。

7. 对立事件: 若事件 A 与 B 互斥,且 A 与 B 必发生其一,则称 A 与 B 为对立事件或称 A 和 B 互补或互逆,记 $B = A^c$ 。例如 A 表示“明天最高温度不大于 25°C ”, B 表示“明天最高温度超过 25°C ”,则 A 与 B 为对立事件。

8. 完备事件组: 若事件 $A_1, A_2, \dots, A_n$ 为两两互斥,且必发生其一,即对 $A_i A_j = \phi$ $i \neq j, i, j = 1, 2, \dots, n$,且 $\bigcup_{i=1}^n A_i = \Omega$,称 $A_1, A_2, \dots, A_n$ 构成完备事件组。当然 n 可为 ∞ 。

§ 2.3 概率的定义及其运算

在试验中仅研究出现哪些随机事件是不够的,必须对事件发生的情形给予量的描述,首先提出事件发生的可能性大小的问题。

设在某组不变条件下,事件 A 在 n 次重复试验中发生 m 次,则称 $\frac{m}{n}$ 为事件 A 在 n 次试验中发生的频率,显然频率满足 $0 \leq \frac{m}{n} \leq 1$ 。如

果 A 是必然事件, 则 $m=n$, 故 $\frac{m}{n}=1$; 如果 A 是不可能事件, 则 $m=0$, 故 $\frac{m}{n}=0$, 所以必然事件的频率是 1, 不可能事件的频率是 0。经验可知, 在某组不变条件下, 多次重复试验时, 随机现象呈现出一定的规律性, 具体地说, 重复次数越大, 随机事件 A 发生的频率越趋于某一稳定值, 即当 n 渐渐增大时, 频率徘徊于此数值附近, 且变化幅度越来越小, 这个数值称为事件 A 的概率, 记作 $P(A)$ 。例如某工厂生产某种产品, 它有废品, 现抽出 n 个, 其中有 m 个废品, 下表给出部分数值:

n	40	50	60	490	500	510	4900	5000	5100
m	2	2	4	20	23	25	247	251	258
$\frac{m}{n}$	0.05	0.04	0.066	0.041	0.046	0.049	0.0504	0.0502	0.05019

可以发现, 当 n 在 50 附近时, $\frac{m}{n}$ 在 0.05 附近振幅较大; 当 n 在 5000 附近时, $\frac{m}{n}$ 几乎都是 0.05 了。因此我们说它生产的废品率是 5% 或 $P(\text{一个产品是废品})=0.05$, 显然, 一事件 A , $0 \leq P(A) \leq 1$, $P(\phi)=0$, $P(\Omega)=1$ 。

概率论与其它数学一样, 由经验提出一些基本概念, 建立了一些基本法则, 再利用逻辑推理和符合基本概念的计算方法, 推得一些新的运算法则, 从而可以不必借助于原始概念, 就可求出随机事件发生的概率。最基本的有下面两条运算法则。

1. 概率加法法则: 设某厂有甲乙两个车间, 它们共生产 100 件产品, 其中甲车间生产 52 件产品中有 50 件为合格品, 乙车间生产 48 件产品中有 45 件合格品, 今从该厂产品中购到一件是合格品的概率是多少?

设事件 A 表示“购到一件是甲车间生产的合格品”, 事件 B 表示“购到一件是乙车间生产的合格品”。由于 A 与 B 互斥事件, A

$A \cup B$ 表示购到一件是该厂生产的合格品。由题意知

$$P(A) = \frac{50}{100} \quad P(B) = \frac{45}{100} \quad P(A \cup B) = \frac{95}{100}$$

所以 $P(A \cup B) = P(A) + P(B)$

一般地有

定理 1 两个互斥事件 A 、 B 之和的概率等于两事件 A 、 B 的概率之和, 即若 $AB = \phi$ 则

$$P(A \cup B) = P(A) + P(B) \quad (1.2.1)$$

称此定理为加法定理(或称为加法法则)。从定理 1 可以推得如下的一些结果

推论 1 $P(A^c) = 1 - P(A)$

推论 2 若 $A \subset B$ 则 $P(B - A) = P(B) - P(A)$

推论 3 若 $A_1, A_2, \dots$ 为两两互斥事件, 则

$$P\left(\sum_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

推论 4 对于任意两个事件 A 、 B 则

$$P(A \cup B) = P(A) + P(B) - P(AB) \quad (1.2.2)$$

这里, 我们给出推论 4 的证明, 因为 $A \cup B = A \cup (B - AB)$, 而 A 与 $B - AB$ 是两个互斥事件, 又 $AB \subset B$, 故由定理 1 与推论 2 得到

$$\begin{aligned} P(A \cup B) &= P(A) + P(B - AB) \\ &= P(A) + P(B) - P(AB) \end{aligned}$$

2. 概率乘法法则: 首先要介绍条件概率的概念, 在概率加法法则的例子中, 若从该厂生产产品中购到一件已知是合格品, 问此件产品是甲车间生产的概率为多少?

设事件 C 表示“购到一件是合格品”, 记此件合格品是甲车间生产的概率为 $P(A|C)$, 由于全部合格品为 95 件, 甲车间生产的合格品为 50 件, 故

$$P(A|C) = \frac{50}{95}$$

$$\text{而 } P(AC) = \frac{50}{100}, \quad P(C) = \frac{95}{100}$$

$$\text{所以 } P(A|C) = \frac{P(AC)}{P(C)}.$$

一般地,对于任意两个随机事件 A, B , 如果 $P(B) \neq 0$ 则称

$P(A|B) = \frac{P(AB)}{P(B)}$ 为已知事件 B 发生的条件下, 事件 A 发生的概率, 简称为 A 在给定 B 下的条件概率。

定理 2 两个事件 A, B 同时发生的概率, 等于其中一事件(概率不为零)的概率乘以此事件发生的条件下另一事件的条件概率。即若 $P(B) \neq 0$

$$\text{有 } P(AB) = P(B)P(A|B) \quad (1.2.3)$$

或若 $P(A) \neq 0$ 有 $P(AB) = P(A)P(B|A)$

如果事件 A 发生与否和事件 B 发生与否互不影响, 则称事件 A 与事件 B 是相互独立的(简称独立), 反之称事件 A 与事件 B 是相依的。显然, 当 A, B 独立时有

$$P(A|B) = P(A), \quad P(B|A) = P(B)$$

由此对于两个独立事件 A, B 有

$$P(AB) = P(A)P(B)。$$

一般地有

i) 对于任意 n 个事件 $A_1, A_2, \dots, A_n, n \geq 2$, 满足 $P(A_1 A_2 \dots A_n) > 0$ 则

$$P(A_1 A_2 \dots A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1 A_2) \dots P(A_n|A_1 A_2 \dots A_{n-1})。$$

ii) 如果 n 个事件 $A_1, A_2, \dots, A_n$ 相互独立, 则

$$P(A_1 A_2 \dots A_n) = P(A_1)P(A_2) \dots P(A_n)。$$

例: 设有两个工厂生产同种产品, 甲厂产品占全部的 70 %。而乙厂产品占 30 %。甲厂产品的合格率为 95 %, 乙厂为 80 %。求(a)顾客买到一件合格品的概率。(b)顾客买到的合格品是由甲厂生产的概率。

设事件 A_1, A_2 分别表示为“顾客买到甲、乙厂产品”, 事件 B 表

示“顾客买到合格产品”。显然， A_1, A_2 构成完备事件组，因为买到的产品总是甲乙两厂生产的，按题意有

$$\begin{aligned} P(A_1) &= 0.7 & P(A_2) &= 0.3 \\ P(B|A_1) &= 0.95 & P(B|A_2) &= 0.8 \end{aligned}$$

所以 (a) $P(B) = 0.7 \times 0.95 + 0.3 \times 0.8 = 0.91$

$$= P(A_1)P(B|A_1) + P(A_2)P(B|A_2)$$

$$\begin{aligned} \text{(b)} P(A_1|B) &= \frac{P(A_1B)}{P(B)} = \frac{P(A_1)P(B|A_1)}{P(B)} = \frac{0.7 \times 0.95}{0.91} \\ &= 0.73 \end{aligned}$$

一般地有

定理 3 设 $A_1, A_2, \dots$ 为有穷或可列无穷多个事件，且构成完备事件组， $P(A_i) > 0, i=1, 2, \dots$ 则对任一事件 A ，有

$$P(A) = \sum_{i=1}^{\infty} P(A_i)P(A|A_i) \quad (1.2.4)$$

称公式(1.2.4)为全概率公式。

证：因为 $A = \Omega A = \left(\sum_{i=1}^{\infty} A_i \right) A = \sum_{i=1}^{\infty} A_i A$ ，由于 A_1, A_2

$\dots$ 构成完备事件组，故 $A_1 A, A_2 A, \dots$ 为互斥事件，于是

$$P(A) = \sum_{i=1}^{\infty} P(A_i A) = \sum_{i=1}^{\infty} P(A_i)P(A|A_i)$$

定理 4 设 $A_1, A_2, \dots$ 为有穷或可列无穷多个事件，且构成完备事件组， $P(A_i) > 0, i=1, 2, \dots$ 则在任一事件 $B (P(B) > 0)$ 已发生的条件下，事件 $A_k (k=1, 2, \dots)$ 发生的概率为

$$P(A_k|B) = \frac{P(A_k)P(B|A_k)}{\sum_{i=1}^{\infty} P(A_i)P(B|A_i)} \quad k=1, 2, \dots \quad (1.2.5)$$

称公式(1.2.5)为贝叶斯(Bayes)公式。

证：由条件概率定义和定理 3 知

$$P(A_k|B) = \frac{P(A_k(B))}{P(B)} = \frac{P(A_k)P(B|A_k)}{\sum_{i=1}^{\infty} P(A_i)P(B|A_i)}$$

$$k=1,2,\cdots$$

§ 3 随机变量及其分布

§ 3.1 随机变量与概率密度

动态数据分析处理的对象是随机现象。用数学方法处理随机现象时，除了需知 § 2 中介绍的随机事件和随机事件发生的概率之外，还要用到随机变量和概率分布这两个重要概念。

例如从一批同类产品中任意抽取其中一件产品，这件产品是否为正品就是一种随机现象。用数学方法来处理这个随机现象时，需要以数量来描述，我们定义

$$X = \begin{cases} 1, & \text{若抽出的产品为正品} \\ 0, & \text{若抽出的产品为次品。} \end{cases}$$

如果在确定的生产条件下，已知这批产品的次品率为 p ，则

$$P(X=0)=p \quad P(X=1)=1-p。$$

这样的 X 称为随机变量，而 $P(X=0)=p$, $P(X=1)=1-p$ 称为随机变量 X 的概率分布。这样的 X 完整地刻划了这个随机现象，它不仅告诉我们 X 取各种可能值(本例中取值 1 或 0)，而且知道了 X 取各种可能值的机会是多少(本例中相应为 p 或 $1-p$)。

上述例子可推广到随机变量的可能取值为有穷个或可列无穷多个 $a_1, a_2, \cdots$ 的情形，这时它的概率分布为

$$P(X=a_i)=p_i \quad i=1,2,\cdots$$

其中
$$\sum_{i=1}^{\infty} p_i = 1,$$

称这样的随机变量 X 为离散型随机变量。

随机变量的可能取值也可以的任何实数值，例如在量测某个

时刻的噪声时，如果 X 表示噪声的大小，而它的可能取值可以是 $(-\infty, \infty)$ 中的任何值。又如炮弹落点与目标距离用 X 表示，则它的可能取值是 $(-\infty, \infty)$ 中任何值（实际上是 $[0, \infty)$ ，不过在 $(-\infty, 0)$ 出现的概率为零）。在描述这种 X 的所有可能结果出现的概率时，需要知道如下的概率分布

$$P\{X \in [a, b)\}, \quad -\infty < a < b < \infty$$

它表示噪声大小（或炮弹落点与目标距离）在区间 $[a, b)$ 中的概率，显而易见

$$P\{X \in [a, b)\} \geq 0 \quad P\{X \in (-\infty, \infty)\} = 1$$

如果存在一个非负函数 $p(x)$ ，对任意 $X \in (-\infty, \infty)$ 有

$$P\{X \in [x, x + \Delta x)\} \approx p(x) \Delta x$$

其中记号“ $\approx$ ”表示渐近相等，即两边之比，当 $\Delta x \rightarrow 0$ 时等于 1，则称 $p(x)$ 为随机变量 X 的概率密度，称这种随机变量 X 为连续型随机变量。因为有

$$P\{X \in [a, b)\} = P\{X \in [a, a + \Delta x)\} + P\{X \in [a + \Delta x, a + 2\Delta x)\} + \cdots + P\{X \in [a + \left[\frac{b-a}{\Delta x}\right]\Delta x, b)\}$$

$$\approx p(a)\Delta x + p(a + \Delta x)\Delta x + \cdots + p\left(a + \left[\frac{b-a}{\Delta x}\right]\Delta x\right)\Delta x$$

其中 $\left[\frac{b-a}{\Delta x}\right]$ 表示不超过 $\frac{b-a}{\Delta x}$ 的最大整数，令 $\Delta x \rightarrow 0$ ，就得到概率分布与概率密度之间的如下积分关系式

$$P\{X \in [a, b)\} = \int_a^b p(x) dx$$

由概率分布的性质知

$$\text{i) } p(x) \geq 0$$

$$\text{ii) } \int_{-\infty}^{\infty} p(x) dx = P\{X \in (-\infty, \infty)\} = 1.$$

上述讨论中，我们用密度函数 $p(x)$ 去描述随机变量 X 的概率分布，自然也可用如下分布函数 $F(x)$ 去描述 X 的概率分布， X 的分布函数定义如下

$$F(x) \triangleq P(X < x)$$

它与 X 的密度函数的关系为

$$F(x) = \int_{-\infty}^x p(u) du.$$

它表示随机变量 X 落在 $(-\infty, x)$ 的概率。

下面列举两种常用的概率密度。

i) 在固定区间 $[a, b]$ 上均匀分布的概率密度(见图 1.1)

$$p(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{其它情况} \end{cases} \quad (1.3.1)$$




图 1.1

ii) 正态(Gauss)分布概率密度(见图1.2)

$$P(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(x-\mu)^2} \quad -\infty < x < \infty \quad (1.3.2)$$




图 1.2

其中 $p(x)$ 的峰点在 μ 处, 在 $\mu \pm \sigma$ 处 $p(x)$ 有两个拐点, $y = 0$ 是 $y = p(x)$ 的水平渐近线。可以近似地算出

$$P(|X-\mu|<\sigma)\cong 68.3\%$$

$$P(|X-\mu|<2\sigma)\cong 95.5\% \quad (1.3.3)$$

$$P(|X-\mu|<3\sigma)\cong 99.7\%$$

也就是说, 正态随机变量 X 的可能取值, 以接近于 1 的概率落在区间 $(\mu-3\sigma, \mu+3\sigma)$ 内。正态密度是以后最常用的。如果 X 具有这样的概率密度, 常用下列符号表示

$$X \sim \mathcal{N}(\mu, \sigma^2)$$

下一小节中还要介绍两种常用的概率分布。

§ 3.2 随机向量与多维概率密度

上面所介绍的是一维随机变量及其概率分布, 下面再介绍多维随机变量 (或称随机向量) 及其联合概率分布。例如在 n 批具有相同次品率 p 的产品中, 各抽取一件产品, 以 $\mathbf{X}^r = (X^{(1)}, X^{(2)}, \dots, X^{(n)})$ 表示它们分别为正品、次品的结果, 这时 $\mathbf{X}$ 就是一个 n 维随机向量; 这个随机向量的可能取值的集合是其分量取值为 1 或 0 的 n 维向量全体, 共有 2^n 个, 其中有 m 个分量为 0 的概率等于 $p^m(1-p)^{n-m}$ 。

这个例子是属于随机向量取离散值的情形。对于取连续值的随机向量 $\mathbf{X}$ 与一维情形类似, 通常用联合概率密度给出它的概率分布, 即存在一个 n 个自变量的函数 $p(x^{(1)}, x^{(2)}, \dots, x^{(n)}) \triangleq p(\mathbf{x})$, 使得对于任意 n 维向量 $\mathbf{x}$ 有

$$\begin{aligned} & P\{\mathbf{X} \in [\mathbf{x}, \mathbf{x} + \Delta \mathbf{x}]\} \\ & \triangleq P\{x^{(1)} \leq X^{(1)} < x^{(1)} + \Delta x^{(1)}, \dots, x^{(n)} \leq X^{(n)} < x^{(n)} + \Delta x^{(n)}\} \\ & \approx p(x^{(1)}, x^{(2)}, \dots, x^{(n)}) \Delta x^{(1)} \Delta x^{(2)} \dots \Delta x^{(n)} \end{aligned}$$

则称 $p(x^{(1)}, x^{(2)}, \dots, x^{(n)})$ 为 n 个随机分量 $X^{(1)}, X^{(2)}, \dots, X^{(n)}$ 的联合概率密度。由概率分布的性质知

i) 对任意 n 维实值向量 $\mathbf{x} = (x^{(1)}, x^{(2)}, \dots, x^{(n)})$

$$p(x^{(1)}, x^{(2)}, \dots, x^{(n)}) \geq 0$$

$$\text{ii) } \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} p(x^{(1)}, x^{(2)}, \dots, x^{(n)}) dx^{(1)} dx^{(2)} \dots$$

$$dx^{(n)} = 1$$

n 维随机向量 $\mathbf{X}^r = (X^{(1)}, X^{(2)}, \dots, X^{(n)})$ 的联合分布函数为

$F(x^{(1)}, x^{(2)}, \dots, x^{(n)}) \triangleq P\{X^{(1)} < x^{(1)}, X^{(2)} < x^{(2)}, \dots, X^{(n)} < x^{(n)}\}$ 它与 $\mathbf{X}$ 的联合密度函数 $p(x^{(1)}, x^{(2)}, \dots, x^{(n)})$ 关系为

$$F(x^{(1)}, x^{(2)}, \dots, x^{(n)}) = \int_{-\infty}^{x^{(1)}} \int_{-\infty}^{x^{(2)}} \cdots \int_{-\infty}^{x^{(n)}} p(u_1, u_2, \dots, u_n) du_1 du_2 \cdots du_n.$$

一般地, 如果 $A \subset R^n$ 即 A 是 n 维向量空间 R^n 中的适当集合, 则随机事件 $\mathbf{X} \in A$ 发生的概率为

$$\begin{aligned} P(\mathbf{X} \in A) &= \int_A \cdots \int p(x^{(1)}, x^{(2)}, \dots, x^{(n)}) dx^{(1)} dx^{(2)} \cdots \\ &\quad dx^{(n)} \\ &\triangleq \int_A p(\mathbf{x}) d\mathbf{x} \end{aligned} \quad (1.3.4)$$

在时间序列分析中最常见的随机向量是正态随机向量, 它的联合概率密度称为多维正态密度, 其形式如下

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{n}{2}} |\Gamma|^{\frac{1}{2}}} e^{-\frac{1}{2}(\mathbf{x}-\mu)^r \Gamma^{-1}(\mathbf{x}-\mu)}, \mathbf{x} \in R^n \quad (1.3.5)$$

其中 μ 是一个 n 维常值向量, Γ 是一个 n 阶正定阵。对于具有这种密度的随机向量 $\mathbf{X}$, 常用如下符号表示

$$\mathbf{X} \sim \mathcal{N}(\mu, \Gamma)$$

随机向量 $\mathbf{X}$ 的每一分量 $X^{(j)}$ 的概率分布或部分分量的联合概率分布, 可由 $\mathbf{X}$ 的联合概率分布求得, 称它们为 $p(\mathbf{x})$ 的边缘分布。举三维情形为例, 设 $\mathbf{X}^r = (X^{(1)}, X^{(2)}, X^{(3)})$, 其概率密度为 $p(x^{(1)}, x^{(2)}, x^{(3)})$, 于是

$$\begin{aligned} p_1(x^{(1)}) \Delta x^{(1)} &\approx P\{x^{(1)} \leq X^{(1)} < x^{(1)} + \Delta x^{(1)}\} \\ &= P\{x^{(1)} \leq X^{(1)} < x^{(1)} + \Delta x^{(1)}, -\infty < X^{(2)} < \infty, \\ &\quad -\infty < X^{(3)} < \infty\} \end{aligned}$$

$$\approx \left(\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} p(x^{(1)}, x^{(2)}, x^{(3)}) dx^{(2)} dx^{(3)} \right) \Delta x^{(1)}$$

所以得到

$$p_1(x^{(1)}) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} p(x^{(1)}, x^{(2)}, x^{(3)}) dx^{(2)} dx^{(3)}$$

$p_1(x^{(1)})$ 是分量 $X^{(1)}$ 的概率密度。同理有

$$p_{23}(x^{(2)}, x^{(3)}) = \int_{-\infty}^{\infty} p(x^{(1)}, x^{(2)}, x^{(3)}) dx^{(1)}$$

是 $X^{(2)}$ 和 $X^{(3)}$ 的联合概率密度, 其它类似。 $p_1(x^{(1)})$, $p_{23}(x^{(2)}, x^{(3)})$ 等等都称 $p(\mathbf{x})$ 的边缘概率密度。

进一步, 如果 $\mathbf{Y}$ 与 n 维随机向量 $\mathbf{X}$ 有如下的线性关系

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$$

其中 $\mathbf{A}$ 是 $m \times n$ 常数矩阵, $\mathbf{b}$ 是 m 维常数向量, 则 m 维随机向量 $\mathbf{Y}$ 的概率分布也可由 $\mathbf{X}$ 的概率分布确定。这里, 我们要特别指出关于多维正态分布的一个基本性质, 但不加以证明, 即在上面的线性关系式中, 如果 $m \leq n$, 且 $\mathbf{A}$ 的秩为 m 而 $\mathbf{X}$ 是 n 维正态随机向量, 则 $\mathbf{Y}$ 必是 m 维正态随机向量, 换言之, 任何正态随机向量的线性变换仍然是正态随机向量^[1]。由此可以得到, 正态随机向量的部分分量所构成一个低维的正态随机向量。

§ 3.3 条件概率密度

在§ 2 中已经介绍了事件的条件概率, 本节引进条件概率密度的概念。考虑联合概率密度为 $p(x, y)$ 的随机变量 X, Y , 令 A, B 分别表示如下的两个事件

$$A = \{X < \alpha\}, B = \{\beta_1 \leq Y < \beta_2\}$$

其中 α, β_1, β_2 为实数, 由条件概率的定义可知

$$\begin{aligned} P(A|B) &= \frac{P(AB)}{P(B)} = \frac{P\{X < \alpha, \beta_1 \leq Y < \beta_2\}}{P\{\beta_1 \leq Y < \beta_2\}} \\ &= \frac{\int_{-\infty}^{\alpha} \int_{\beta_1}^{\beta_2} p(x, y) dx dy}{\int_{\beta_1}^{\beta_2} p_2(y) dy} \end{aligned}$$

其中 $p_2(y) = \int_{-\infty}^{\infty} p(x, y) dx$ 为 Y 的概率密度。当然还可以进一

步求出 X 的条件概率密度如下

$$P\{x \leq X < x + \Delta x | \beta_1 \leq Y < \beta_2\} \approx \frac{\left(\int_{\beta_1}^{\beta_2} p(x, y) dy\right) \Delta x}{\int_{\beta_1}^{\beta_2} p_2(y) dy}$$

若取 $\beta_1 = y, \beta_2 = y + \Delta y$ 时, 则上式有渐近等式

$$\begin{aligned} P\{x \leq X < x + \Delta x | y \leq Y < y + \Delta y\} \\ \approx \frac{p(x, y) \Delta x \Delta y}{p_2(y) \Delta y} = \frac{p(x, y)}{p_2(y)} \cdot \Delta x \end{aligned}$$

令 $\Delta y \rightarrow 0$, 我们得到在给定随机变量 $Y = y$ 的条件下, 随机变量 X 的条件概率密度, 记作 $p(x|y)$,

$$p(x|y) \triangleq p(x|Y=y) = \frac{p(x, y)}{p_2(y)} \quad (1.3.6)$$

当然, 这里首先要求 $p_2(y) \neq 0$, 同理, 当 $p_1(x) \neq 0$ 时有

$$p(y|x) \triangleq p(y|X=x) = \frac{p(x, y)}{p_1(x)} \quad (1.3.7)$$

其中

$$p_1(x) = \int_{-\infty}^{\infty} p(x, y) dy$$

是 X 的概率密度。由 (1.3.6) 和 (1.3.7) 知

$$p(x|y) = \frac{p(x, y)}{p_2(y)} = \frac{p_1(x)p(y|x)}{p_2(y)} \quad (1.3.8)$$

或表为对称形式

$$p(x, y) = p_1(x)p(y|x) = p_2(y)p(x|y) \quad (1.3.9)$$

在 § 2 中定义了两个随机事件的相互独立性, 现在定义两个随机变量的相互独立性。称两个随机变量 X, Y 为相互独立的, 如果在给定其中一个随机变量的条件下, 另一个随机变量的条件概率密度不依赖于给定的条件, 即

$$p(x|y) = p_1(x)$$

$$p(y|x) = p_2(y).$$

由贝叶斯公式可知, 两个随机变量 X, Y 为相互独立的充分必要条件是

$$p(x, y) = p_1(x)p_2(y) \quad (1.3.10)$$

一般地,对任意 n 个随机变量 $X^{(1)}, X^{(2)}, \dots, X^{(n)}$, 如果有

$$p(x^{(1)}, x^{(2)}, \dots, x^{(n)}) = p_1(x^{(1)})p_2(x^{(2)}) \cdots p_n(x^{(n)})$$

称 n 个随机变量为相互独立。其中 $p(x^{(1)}, x^{(2)}, \dots, x^{(n)})$ 为 $X^{(1)}, X^{(2)}, \dots, X^{(n)}$ 的联合概率密度, $p_i(x^{(i)})$ $i=1, 2, \dots, n$ 为 $X^{(i)}$ 的概率密度。以上的内容对随机向量也同样成立。

在§ 3.1 中介绍了两种概率分布即均匀分布和正态分布, 今后还需经常用到如下两种分布:

i) χ_n^2 分布密度: 考虑 n 个相互独立随机变量 X_k , $k=1, 2, \dots, n$, 它们都服从同一正态分布

$$X_k \sim \mathcal{N}(0, 1), \quad k=1, 2, \dots, n$$

则 $\chi_n^2 = \sum_{k=1}^n X_k^2$ 的概率密度为

$$p_n(x) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} e^{-\frac{x}{2}} x^{\frac{n}{2}-1}, & \text{当 } x > 0 \\ 0, & \text{当 } x \leq 0 \end{cases} \quad (1.3.11)$$

其中 $\Gamma(\frac{n}{2})$ 是 Γ 函数在 $\frac{n}{2}$ 处的值, 称 χ_n^2 为自由度 n 的中心 χ^2 分布密度, 密度曲线如图 1.3 所示。




图 1.3

ii) F_{mn} 分布密度: 设 $m+n$ 个随机变量 $X_1, X_2, \dots, X_m,$

$Y_1, Y_2, \dots, Y_n$ 为相互独立且有相同分布 $\sim \mathcal{N}(0, \sigma^2)$, 令

$$X = \sum_{k=1}^m X_k^2, \quad Y = \sum_{k=1}^n Y_k^2$$

则

$$F_{mn} = \frac{\frac{1}{m} X}{\frac{1}{n} Y}$$

的概率密度为

$$p_{mn}(x) = \begin{cases} \frac{\Gamma\left(\frac{m+n}{2}\right)}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)} m^{\frac{m}{2}} n^{\frac{n}{2}} \frac{x^{\frac{m}{2}-1}}{(n+mx)^{\frac{m+n}{2}}}, & \text{当 } x > 0 \\ 0, & \text{当 } x \leq 0 \end{cases} \quad (1.3.12)$$

称 F_{mn} 为有自由度 m, n 的中心 F 分布, 密度曲线如图 1.4 所示。




图 1.4

设两个正态随机变量 $X^{(1)} \sim \mathcal{N}(\mu_1, \sigma_1^2)$, $X^{(2)} \sim \mathcal{N}(\mu_2, \sigma_2^2)$ 为相互独立, 则它们的联合概率密度为

$$\begin{aligned} p(x^{(1)}, x^{(2)}) &= p_1(x^{(1)}) p_2(x^{(2)}) \\ &= \frac{1}{2\pi\sigma_1\sigma_2} e^{-\frac{1}{2}\left[\frac{(x^{(1)}-\mu_1)^2}{\sigma_1^2} + \frac{(x^{(2)}-\mu_2)^2}{\sigma_2^2}\right]} \end{aligned}$$

显然这是一种特殊的二维正态密度。

考虑一般的二维正态随机向量 $\mathbf{X} = (X^{(1)}, X^{(2)})^T$, 它的概率

密度为如下形式

$$p(x^{(1)}, x^{(2)}) = \frac{1}{2\pi(\sigma_1^2\sigma_2^2 - \sigma_{12}^2)^{\frac{1}{2}}} \cdot e^{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{pmatrix}^{-1} (\mathbf{x} - \boldsymbol{\mu})} \quad (1.3.13)$$

其中 $\mathbf{x} = (x^{(1)}, x^{(2)})^T$, $\boldsymbol{\mu} = (\mu_1, \mu_2)^T$, $\sigma_{12} = E(X^{(1)} - \mu_1)(X^{(2)} - \mu_2)$ 。
由正定性要求 $\sigma_{12} = \sigma_{21}$, $\sigma_1^2\sigma_2^2 - \sigma_{12}^2 > 0$, 又可算出

$$\begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{pmatrix}^{-1} = \frac{1}{\sigma_1^2\sigma_2^2 - \sigma_{12}^2} \begin{pmatrix} \sigma_2^2 & -\sigma_{12} \\ -\sigma_{12} & \sigma_1^2 \end{pmatrix}$$

于是可以表为

$$p(x^{(1)}, x^{(2)}) = \frac{1}{2\pi(\sigma_1^2\sigma_2^2 - \sigma_{12}^2)^{\frac{1}{2}}} e^{-\frac{1}{2(\sigma_1^2\sigma_2^2 - \sigma_{12}^2)} g(x^{(1)}, x^{(2)})}$$

其中

$$\begin{aligned} g(x^{(1)}, x^{(2)}) &= \sigma_2^2(x^{(1)} - \mu_1)^2 - 2\sigma_{12}(x^{(1)} - \mu_1)(x^{(2)} - \mu_2) + \\ &\quad + \sigma_1^2(x^{(2)} - \mu_2)^2 \\ &= \frac{\sigma_1^2\sigma_2^2 - \sigma_{12}^2}{\sigma_1^2}(x^{(1)} - \mu_1)^2 + \sigma_1^2 \left[(x^{(2)} - \mu_2) - \right. \\ &\quad \left. - \frac{\sigma_{12}}{\sigma_1^2}(x^{(1)} - \mu_1) \right]^2. \end{aligned}$$

显然当 $\sigma_{12} = 0$ 时, 就变成 $X^{(1)}, X^{(2)}$ 相互独立的情形。

由(1.3.13)式可以算出 $X^{(1)}$ 的边缘概率密度为正态密度, 因为

$$\begin{aligned} p_1(x^{(1)}) &= \int_{-\infty}^{\infty} p(x^{(1)}, x^{(2)}) dx^{(2)} \\ &= \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{1}{2\sigma_1^2}(x^{(1)} - \mu_1)^2} \end{aligned}$$

又由求条件概率密度的公式有

$$p(x^{(2)} | x^{(1)}) = \frac{p(x^{(1)}, x^{(2)})}{p_1(x^{(1)})}$$

在此式右边, 将 $p(x^{(1)}, x^{(2)})$ 和 $p_1(x^{(1)})$ 的表示式代入, 然后将其中 e 的指数项进行如下简化

$$-\frac{1}{2(\sigma_1^2\sigma_2^2 - \sigma_{12}^2)} g(x^{(1)}, x^{(2)}) + \frac{1}{2\sigma_1^2}(x^{(1)} - \mu_1)^2$$

$$= -\frac{\sigma_1^2}{2(\sigma_1^2\sigma_2^2 - \sigma_{12}^2)} \left[(x^{(2)} - \mu_2) - \frac{\sigma_{12}}{\sigma_1^2} (x^{(1)} - \mu_1) \right]^2.$$

由此得知

$$p(x^{(2)} | x^{(1)}) = \frac{\sigma_1}{\sqrt{2\pi}(\sigma_1^2\sigma_2^2 - \sigma_{12}^2)^{\frac{1}{2}}} \cdot e^{-\frac{\sigma_1^2}{2(\sigma_1^2\sigma_2^2 - \sigma_{12}^2)} \left[(x^{(2)} - \mu_2) - \frac{\sigma_{12}}{\sigma_1^2} (x^{(1)} - \mu_1) \right]^2} \quad (1.3.14)$$

同理可求得

$$p(x^{(1)} | x^{(2)}) = \frac{\sigma_2}{\sqrt{2\pi}(\sigma_1^2\sigma_2^2 - \sigma_{12}^2)^{\frac{1}{2}}} \cdot e^{-\frac{\sigma_2^2}{2(\sigma_1^2\sigma_2^2 - \sigma_{12}^2)} \left[(x^{(1)} - \mu_1) - \frac{\sigma_{12}}{\sigma_2^2} (x^{(2)} - \mu_2) \right]^2} \quad (1.3.15)$$

也可把在给定 $X^{(2)} = x^{(2)}$ 的条件下, $X^{(1)}$ 的条件分布密度表为

$$\mathcal{N}\left(\mu_1 + \frac{\sigma_{12}}{\sigma_2^2} (x^{(2)} - \mu_2), \sigma_1^2 - \frac{\sigma_{12}^2}{\sigma_2^2}\right).$$

从这里可以得出关于正态分布的另一个重要性质, 二维正态随机向量的一个分量对另一个分量的条件分布, 仍然是正态的。二维正态随机向量可以推广到高维的情形, 详情见下节。

§ 4 数学期望与方差

§ 4.1 定义及性质

为了要完满地表达随机变量 X 的概率性质, 需要知道它的概率分布或概率密度函数。然而在许多实际问题中, 并非需要知道 X 的全部概率性质, 而只需了解它的某些性质就够了。下面我们将要讨论概率分布的某些重要的数字表征, 特别是它的数学期望与方差。

仍然举 § 3.1 开头的那个产品抽样的例子, 这时

$$P\{X=0\}=p, P\{X=1\}=1-p$$

我们定义这个最简单的离散型随机变量 X (或概率分布) 的数学期

望(又称均值)为

$$EX = 0 \cdot p + 1 \cdot (1-p) = 1-p.$$

数学期望的直观意义是在某组不变条件下,大量重复这一试验时,其结果的平均值;如果我们把 X 看作产品的价格(按正品价格等于 1,次品价格等于 0),那末上面求得 $EX = 1-p$ 就相当于从一批产品中随机地抽取一件,其价格的平均值。

根据这一思想,对任何离散型的随机变量 X : $P\{X=a_i\}$

$=p_i$ $i=1,2,\dots$, 若 $\sum_{i=1}^{\infty} |a_i| p_i < \infty$, 定义 X 的均值为

$$EX \triangleq \sum_{i=1}^{\infty} a_i p_i \quad (1.4.1)$$

对于任意具有概率密度为 $p(x)$ 的连续型随机变量 X , 如果 $\int_{-\infty}^{\infty} |x| p(x) dx$ 存在, 定义 X 的均值为

$$EX \triangleq \int_{-\infty}^{\infty} x p(x) dx \quad (1.4.2)$$

对于随机变量 X , k 为正整数, 称 X^k 的均值为 X 的 k 阶原点矩, 记作 EX^k , 它可表为

$$EX^k = \int_{-\infty}^{\infty} x^k p(x) dx \quad (1.4.3)$$

还可以求 X 的 k 阶中心矩, 即 $(X-EX)^k$ 的均值

$$E(X-EX)^k = \int_{-\infty}^{\infty} (x-EX) p(x) dx \quad (1.4.4)$$

其中最重要的是 $k=2$ 的情形。如果把概率分布与总质量为 1 的质量分布相对比, 则 $p(x)$ 相应于质量密度, EX 相应于重心, $E(X-EX)^2$ 相应于转动惯量。在概率论里, $E(X-EX)^2$ 称为随机变量 X 的方差, 简单记作 $\text{var} X$ (或 DX), 它表示分布的疏密程度, 即 X 对它的均值 EX 的分散程度, 恰如转动惯量表示质量分布的疏密程度一样。方差越小, 表示分布越集中于均值附近, 也就是随机变量 X 取远离于均值的值的概率很小。

例 1. 设 $X \sim \mathcal{N}(\mu, \sigma^2)$, 即概率密度为

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(x-\mu)^2}$$

则

$$\begin{aligned} EX &= \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\infty} x e^{-\frac{1}{2\sigma^2}(x-\mu)^2} dx \\ &= \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\infty} (x-\mu) e^{-\frac{1}{2\sigma^2}(x-\mu)^2} dx + \\ &\quad + \frac{\mu}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\infty} e^{-\frac{1}{2\sigma^2}(x-\mu)^2} dx \\ &= \frac{\sigma^2}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\infty} e^{-y^2} dy^2 + \mu = \mu. \end{aligned}$$

又由分部积分法, 不难算出

$$\begin{aligned} \text{var } X &\triangleq E(X-\mu)^2 \\ &= \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\infty} (x-\mu)^2 e^{-\frac{1}{2\sigma^2}(x-\mu)^2} dx = \sigma^2. \end{aligned}$$

由此可以看出, 一个正态分布由它的均值 μ 及方差 σ^2 完全确定, 但对一般的概率分布并不一定如此。

§ 4.2 随机向量的均值与协方差阵

对于 n 维随机向量 X , 它的均值向量及协方差阵也可以类似地定义, 其均值向量定义为

$$EX \triangleq \begin{pmatrix} EX^{(1)} \\ EX^{(2)} \\ \vdots \\ EX^{(n)} \end{pmatrix} = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \begin{pmatrix} x^{(1)} \\ x^{(2)} \\ \vdots \\ x^{(n)} \end{pmatrix} p(x^{(1)}, x^{(2)}, \dots, x^{(n)}) dx^{(1)} dx^{(2)} \cdots dx^{(n)}$$

简记为

$$EX = \int_{-\infty}^{\infty} x p(x) dx.$$

其协方差阵定义为如下的 n 阶方阵

$$\begin{aligned} \text{var } X &\triangleq E(X - EX)(X - EX)^T \\ &= (E(X^{(i)} - EX^{(i)})(X^{(j)} - EX^{(j)}))_{n \times n} \end{aligned}$$

$$= \left(\int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} (x^{(i)} - EX^{(i)}) (x^{(j)} - EX^{(j)}) p(x^{(1)}, \dots, x^{(n)}) dx^{(1)} \cdots dx^{(n)} \right)_{n \times n}$$

简记为

$$\text{var } X = \int_{-\infty}^{\infty} (x - EX)(x - EX)^T p(x) dx \quad (1.4.5)$$

对于任意 n 维向量 α , 有

$$\begin{aligned} \alpha^T (\text{var } x) \alpha &= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \sum_{i,j=1}^n \alpha_i \alpha_j (x^{(i)} - EX^{(i)}) (x^{(j)} - EX^{(j)}) \cdot p(x^{(1)}, \dots, x^{(n)}) dx^{(1)} \cdots dx^{(n)} \\ &= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \left(\sum_{i=1}^n \alpha_i (x^{(i)} - EX^{(i)}) \right)^2 p(x^{(1)}, \dots, x^{(n)}) dx^{(1)} \cdots dx^{(n)} \geq 0 \end{aligned}$$

所以 n 维随机向量 X 的协方差阵是一个 n 阶非负定阵。

设 n 维随机向量 X 和 m 维随机向量 Y 的联合密度为 $p(x, y)$, 我们定义它们的协方差阵 $\text{cov}(X, Y)$ 为如下的 $n \times m$ 矩阵:

$$\begin{aligned} \text{cov}(X, Y) &\triangleq E(X - EX)(Y - EY)^T \\ &= \int_{-\infty}^{\infty} (x - EX)(y - EY)^T p(x, y) dx dy \quad (1.4.6) \end{aligned}$$

显然 $\text{cov}(Y, X) = \text{cov}(X, Y)^T$ 。由定义可知, 一个随机向量的协方差阵, 其主对角线元是各分量的方差, 而其第 i 行第 j 列元 ($i \neq j$) 是第 i 分量与第 j 分量的协方差。

此外还须指出, 由均值的定义容易得到, “取均值”这一运算具有如下的线性特性, 设 X, Y 分别为 n 维和 m 维随机向量, A, B 和 C 分别为 $r \times n, r \times m$ 和 $s \times m$ 常数矩阵, 则

$$\begin{aligned} E(AX + BY) &= AEX + BEY \\ E(AX)(CY)^T &= A(EXY^T)C^T \end{aligned}$$

其中第一式是 r 维向量, 后式为 $r \times s$ 矩阵。另外还可以得到下面的等式

$$EXY^T = E(X - EX + EX)(Y - EY + EY)^T$$

$$\begin{aligned}
&= E(X - EX)(Y - EY)^T + (EX)(EY)^T \\
&= \text{cov}(X, Y) + (EX)(EY)^T.
\end{aligned}$$

两个随机向量 X, Y , 如果 $EXY^T = 0$, 则称 X 和 Y 正交。如果它们的协方差阵为零矩阵, 即 $E(X - EX)(X - EX)^T = 0$ 或 $EXY^T = (EX)(EY)^T$, 则称 X 和 Y 不相关。显然当 X 和 Y 中有一个均值为零, 则 X 和 Y 正交性等价于不相关性。又 X 和 Y 相互独立性可以推出它们不相关性。事实上, 设 X 和 Y 相互独立, 即有

$$p(x, y) = p_1(x)p_2(y)$$

则

$$\begin{aligned}
EXY^T &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy^T p(x, y) dx dy \\
&= \int_{-\infty}^{\infty} x p_1(x) dx \int_{-\infty}^{\infty} y^T p_2(y) dy = (Ex)(Ey)^T.
\end{aligned}$$

一般地, 两个不相关的随机向量不见得是相互独立的。但对于正态情形, 从不相关性也可推出独立性, 当 X 和 Y 是两个正态向量, 如果其中之一是零均值, 则 X 和 Y 的正交性、不相关性与独立性三者等价。

例 2. 设 n 维随机向量 $X \sim \mathcal{N}(\mu, \Gamma)$, 即它的概率密度为

$$p(x) = \frac{1}{(2\pi)^{\frac{n}{2}} |\Gamma|^{\frac{1}{2}}} e^{-\frac{1}{2}(x-\mu)^T \Gamma^{-1}(x-\mu)} \quad (1.4.7)$$

那么可以算出

$$EX = \mu, \quad \text{var} X = \Gamma$$

因此多维正态分布也由它的均值向量 μ 及协方差阵 Γ 完全确定。特别, 如果

$$\Gamma = \begin{pmatrix} \sigma_1^2 & 0 \\ & \sigma_2^2 \\ & & \ddots \\ 0 & & & \sigma_n^2 \end{pmatrix}$$

即

$\text{var} X^{(i)} = \sigma_i^2, \quad \text{cov}(X^{(i)}, X^{(j)}) = 0 \quad i \neq j, i, j = 1, 2, \dots, n$, 则此

时 X 的概率密度可表为

$$\begin{aligned} p(\mathbf{x}) &= \frac{1}{(2\pi)^{\frac{n}{2}} \sigma_1 \sigma_2 \cdots \sigma_n} e^{-\frac{1}{2} \sum_{i=1}^n \frac{(x^{(i)} - \mu_i)^2}{\sigma_i^2}} \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi} \sigma_i} e^{-\frac{1}{2} \frac{(x^{(i)} - \mu_i)^2}{\sigma_i^2}} = \prod_{i=1}^n p_i(x^{(i)}) \end{aligned}$$

其中 $p_i(x^{(i)})$ 为 $X^{(i)}$ 的正态密度。于是 X 的各分量是相互独立的。由此可知,对于正态随机向量,其各分量为两两相互独立的充分必要条件是两两不相关。同样可以证明,两个有联合正态密度的随机向量相互独立的充分必要条件是它们不相关。这是正态分布的又一个重要性质。

§ 4.3 条件期望与条件方差

对于两个随机向量 X 和 Y ,可以定义在给定 $Y=y$ 的条件下, X 的条件期望(或条件均值) $E(X|y)$ 与条件方差 $\text{var}(X|y)$, 它们分别由下面两式给出

$$E(X|y) \triangleq \int_{-\infty}^{\infty} x p(x|y) dx \quad (1.4.8)$$

$$\begin{aligned} \text{var}(X|y) &\triangleq E[(X - E(X|y))(X - E(X|y))^T | y] \\ &= \int_{-\infty}^{\infty} (x - E(X|y))(x - E(X|y))^T p(x|y) dx \end{aligned} \quad (1.4.9)$$

由(1.4.8)知, $E(X|y)$ 是 y 的向量函数。若令 y 为随机向量 Y 的任意取值,则可将(1.4.8)推广来定义随机向量 X 对于随机向量 Y 的条件期望,记作 $E(X|Y)$ 。由此不难得出条件期望一系列的性质,这在讨论预报和估计问题中经常用到。

i) $E(X|Y)$ 是随机向量 Y 的函数,和 X 的维数相同,因此它是一个随机向量。

ii) $E(X|Y)$ 有线性性质,即若 $X_1, X_2, \dots, X_l$ 为 l 个同维数随机向量, $c_1, c_2, \dots, c_l$ 为 l 个实数,则

$$E\left(\sum_{i=1}^l c_i X_i | Y\right) = \sum_{i=1}^l c_i E(X_i | Y) \quad (1.4.10)$$

以上两个性质由(1.4.8)及积分性质即得。

$$\text{iii) } E(E(\mathbf{X}|\mathbf{Y})) = E\mathbf{X} \quad (1.4.11)$$

$$\begin{aligned} \text{因为 } E(E(\mathbf{X}|\mathbf{Y})) &= \int_{-\infty}^{\infty} \left[\int_{-\infty}^{\infty} \mathbf{x} p(\mathbf{x}|\mathbf{y}) d\mathbf{x} \right] p_2(\mathbf{y}) d\mathbf{y} \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \mathbf{x} p(\mathbf{x}|\mathbf{y}) p_2(\mathbf{y}) d\mathbf{x} d\mathbf{y} \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \mathbf{x} p(\mathbf{x}, \mathbf{y}) d\mathbf{x} d\mathbf{y} \\ &= \int_{-\infty}^{\infty} \mathbf{x} \left[\int_{-\infty}^{\infty} p(\mathbf{x}, \mathbf{y}) d\mathbf{y} \right] d\mathbf{x} \\ &= \int_{-\infty}^{\infty} \mathbf{x} p_1(\mathbf{x}) d\mathbf{x} = E\mathbf{X} . \end{aligned}$$

iv) 设 $\mathbf{X}, \mathbf{Y}$ 为相互独立随机向量, 则

$$E(f(\mathbf{X})|\mathbf{Y}) = Ef(\mathbf{X}) \quad (1.4.12)$$

其中 $f(\cdot)$ 为适当的向量实函数, 在 $\mathbf{X}$ 为随机向量且与 $\mathbf{Y}$ 独立的条件下, $f(\mathbf{X})$ 也是与 $\mathbf{Y}$ 相互独立的随机向量函数。

$$\text{v) } E(f(\mathbf{Y})|\mathbf{Y}) = f(\mathbf{Y}) \quad (1.4.13)$$

其中 $f(\cdot)$ 与 iv) 相同。

以上两个性质由定义(1.4.8)及(1.3.9)(1.3.10)得到。

$$\text{vi) } E[(\mathbf{X} - E(\mathbf{X}|\mathbf{Y}))f(\mathbf{Y})] = 0 \quad (1.4.14)$$

$$\begin{aligned} E[(\mathbf{X} - E(\mathbf{X}|\mathbf{Y}))f(\mathbf{Y})] &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (\mathbf{x} - E(\mathbf{X}|\mathbf{y})) f(\mathbf{y}) p(\mathbf{x}, \\ &\quad \mathbf{y}) d\mathbf{x} d\mathbf{y} \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (\mathbf{x} - E(\mathbf{X}|\mathbf{y})) f(\mathbf{y}) p(\mathbf{x}|\mathbf{y}) p_2(\mathbf{y}) d\mathbf{x} d\mathbf{y} \\ &= \int_{-\infty}^{\infty} f(\mathbf{y}) \left[\int_{-\infty}^{\infty} (\mathbf{x} - E(\mathbf{X}|\mathbf{y})) p(\mathbf{x}|\mathbf{y}) d\mathbf{x} \right] p_2(\mathbf{y}) d\mathbf{y} \\ &= \int_{-\infty}^{\infty} f(\mathbf{y}) [E(\mathbf{X}|\mathbf{y}) - E(\mathbf{X}|\mathbf{y})] p_2(\mathbf{y}) d\mathbf{y} = 0 \end{aligned}$$

下面, 我们从几个例子进一步讨论正态随机向量条件密度的性质。

例 3. 考虑二维正态随机向量

$$\mathbf{X} = \begin{pmatrix} x^{(1)} \\ x^{(2)} \end{pmatrix} \sim \mathcal{N}(\boldsymbol{\mu}, \Gamma)$$

其中 $\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}$, $\Gamma = \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{pmatrix}$ 。

我们在§ 3 的末尾已经求出了 $p(x^{(2)}|x^{(1)})$ 和 $p(x^{(1)}|x^{(2)})$ 的表达式, 并且知道它们仍然是正态密度。于是

$$\begin{aligned} E\mathbf{X} &= \begin{pmatrix} EX^{(1)} \\ EX^{(2)} \end{pmatrix} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} \\ \text{var}\mathbf{X} &= \begin{pmatrix} \text{var}X^{(1)} & \text{cov}(X^{(1)}, X^{(2)}) \\ \text{cov}(X^{(2)}, X^{(1)}) & \text{var}X^{(2)} \end{pmatrix} = \\ &= \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{pmatrix} \end{aligned}$$

$$\begin{aligned} E(X^{(1)}|x^{(2)}) &= \mu_1 + \frac{\sigma_{12}}{\sigma_2^2}(x^{(2)} - \mu_2) \\ &= EX^{(1)} + \text{cov}(X^{(1)}, X^{(2)})(\text{var}X^{(2)})^{-1}(x^{(2)} - EX^{(2)}) \end{aligned} \quad (1.4.15)$$

$$\begin{aligned} \text{var}(X^{(1)}|x^{(2)}) &= \sigma_1^2 - \frac{\sigma_{12}^2}{\sigma_2^2} \\ &= \text{var}X^{(1)} - \text{cov}(X^{(1)}, X^{(2)})(\text{var}X^{(2)})^{-1}\text{cov}(X^{(2)}, X^{(1)}) \end{aligned} \quad (1.4.16)$$

同理有

$$\begin{aligned} E(X^{(2)}|x^{(1)}) &= EX^{(2)} + \text{cov}(X^{(2)}, X^{(1)})(\text{var}X^{(1)})^{-1}(x^{(1)} - EX^{(1)}) \\ \text{var}(X^{(2)}|X^{(1)}) &= \text{var}X^{(2)} - \text{cov}(X^{(2)}, X^{(1)})(\text{var}X^{(1)})^{-1} \\ &\quad \cdot \text{cov}(X^{(1)}, X^{(2)})。 \end{aligned}$$

例 4. 我们将例 3 的模型再推广一步, 考虑 $k+l$ 维正态随机向量

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{pmatrix} \sim \mathcal{N}(\boldsymbol{\mu}, \Gamma)$$

其中 $\boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{pmatrix}$, $\Gamma = \begin{pmatrix} \Gamma_{11} & \Gamma_{12} \\ \Gamma_{21} & \Gamma_{22} \end{pmatrix}$, $\mathbf{X}_1$ 和 $\mathbf{X}_2$ 分别是由 $\mathbf{X}$ 的前 k

个分量和后 l 个分量构成的 k 维和 l 维随机向量, 而且有

$$\begin{aligned} E\mathbf{X}_1 &= \boldsymbol{\mu}_1, & E\mathbf{X}_2 &= \boldsymbol{\mu}_2, \\ \text{var}\mathbf{X}_1 &= \Gamma_{11}, & \text{var}\mathbf{X}_2 &= \Gamma_{22} \\ \text{cov}(\mathbf{X}_1, \mathbf{X}_2) &= \Gamma_{12}, & \text{cov}(\mathbf{X}_2, \mathbf{X}_1) &= \Gamma_{21} = \Gamma_{12}^T. \end{aligned}$$

由分块矩阵的行列式公式(1.1.3)和求逆公式(1.1.4)(1.1.5)知

$$\begin{aligned} |\Gamma| &= \begin{vmatrix} \Gamma_{11} & \Gamma_{12} \\ \Gamma_{21} & \Gamma_{22} \end{vmatrix} = |\tilde{\Gamma}_{11}| |\Gamma_{22}| \\ \Gamma^{-1} &= \begin{pmatrix} \Gamma_{11} & \Gamma_{12} \\ \Gamma_{21} & \Gamma_{22} \end{pmatrix}^{-1} = \\ &= \begin{pmatrix} \tilde{\Gamma}_{11}^{-1} & -\tilde{\Gamma}_{11}^{-1}\Gamma_{12}\Gamma_{22}^{-1} \\ -\Gamma_{22}^{-1}\Gamma_{12}\tilde{\Gamma}_{11}^{-1} & \Gamma_{22}^{-1} + \Gamma_{22}^{-1}\Gamma_{12}\tilde{\Gamma}_{11}^{-1}\Gamma_{12}\Gamma_{22}^{-1} \end{pmatrix} = \\ &= \begin{pmatrix} I_k & \\ -\Gamma_{22}^{-1}\Gamma_{12}^T & \end{pmatrix} \tilde{\Gamma}_{11}^{-1} (I_k - \Gamma_{12}\Gamma_{22}^{-1}) + \begin{pmatrix} 0 & 0 \\ 0 & \Gamma_{22}^{-1} \end{pmatrix} \end{aligned}$$

其中 $\tilde{\Gamma}_{11} = \Gamma_{11} - \Gamma_{12}\Gamma_{22}^{-1}\Gamma_{12}^T$. 于是随机向量 $\mathbf{X}$ 的概率密度为

$$p(\mathbf{x}) = p(\mathbf{x}_1, \mathbf{x}_2) = \frac{1}{(2\pi)^{\frac{k+l}{2}} |\Gamma|^{\frac{1}{2}}} e^{-\frac{1}{2} \begin{pmatrix} \mathbf{x}_1 - \boldsymbol{\mu}_1 \\ \mathbf{x}_2 - \boldsymbol{\mu}_2 \end{pmatrix}^T \Gamma^{-1} \begin{pmatrix} \mathbf{x}_1 - \boldsymbol{\mu}_1 \\ \mathbf{x}_2 - \boldsymbol{\mu}_2 \end{pmatrix}}$$

将 $|\Gamma|, \Gamma^{-1}$ 表达式代入得到

$$\begin{aligned} p(\mathbf{x}_1, \mathbf{x}_2) &= \\ &= \frac{1}{(2\pi)^{\frac{k}{2}} |\tilde{\Gamma}_{11}|^{\frac{1}{2}}} e^{-\frac{1}{2} [\mathbf{x}_1 - \boldsymbol{\mu}_1 - \Gamma_{12}\Gamma_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2)]^T \tilde{\Gamma}_{11}^{-1} [\mathbf{x}_1 - \boldsymbol{\mu}_1 - \Gamma_{12}\Gamma_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2)]} \\ &\quad \cdot \frac{1}{(2\pi)^{\frac{l}{2}} |\Gamma_{22}|^{\frac{1}{2}}} e^{-\frac{1}{2} (\mathbf{x}_2 - \boldsymbol{\mu}_2)^T \Gamma_{22}^{-1} (\mathbf{x}_2 - \boldsymbol{\mu}_2)} \quad (1.4.17) \end{aligned}$$

由上式容易算出 $\mathbf{X}_2$ 的概率密度为

$$\begin{aligned} p_2(\mathbf{x}_2) &= \int_{-\infty}^{\infty} p(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_1 \\ &= \frac{1}{(2\pi)^{\frac{l}{2}} |\Gamma_{22}|^{\frac{1}{2}}} e^{-\frac{1}{2} (\mathbf{x}_2 - \boldsymbol{\mu}_2)^T \Gamma_{22}^{-1} (\mathbf{x}_2 - \boldsymbol{\mu}_2)} \quad (1.4.18) \end{aligned}$$

类似地, 利用(1.1.3)和(1.4.14)可以算出 $\mathbf{X}$ 的前 k 个分量组成的随机向量 $\mathbf{X}_1$ 的概率密度为

$$\begin{aligned}
p_1(\mathbf{x}_1) &= \int_{-\infty}^{\infty} p(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2 \\
&= \frac{1}{(2\pi)^{\frac{k}{2}} |\Gamma_{11}|^{\frac{1}{2}}} e^{-\frac{1}{2}(\mathbf{x}_1 - \mu_1)' \Gamma_{11}^{-1}(\mathbf{x}_1 - \mu_1)} \quad (1.4.19)
\end{aligned}$$

因此我们证明了, 由正态随机向量的部分分量构成的随机向量仍然是正态的。

此时, 根据条件概率密度公式, 容易求得在给定 $\mathbf{X}_2 = \mathbf{x}_2$ 的条件下, $\mathbf{X}_1$ 的条件概率密度, 由 (1.4.17) 和 (1.4.18) 知

$$\begin{aligned}
p(\mathbf{x}_1 | \mathbf{x}_2) &= p(\mathbf{x}_1, \mathbf{x}_2) / p_2(\mathbf{x}_2) = \frac{1}{(2\pi)^{\frac{k}{2}} |\tilde{\Gamma}_{11}|^{\frac{1}{2}}} \\
&\cdot e^{-\frac{1}{2}[\mathbf{x}_1 - \mu_1 - \Gamma_{12}\Gamma_{22}^{-1}(\mathbf{x}_2 - \mu_2)]' \tilde{\Gamma}_{11}^{-1}[\mathbf{x}_1 - \mu_1 - \Gamma_{12}\Gamma_{22}^{-1}(\mathbf{x}_2 - \mu_2)]} \quad (1.4.20)
\end{aligned}$$

类似地, 在给定 $\mathbf{X}_1 = \mathbf{x}_1$ 的条件下, $\mathbf{X}_2$ 的条件概率密度为

$$\begin{aligned}
p(\mathbf{x}_2 | \mathbf{x}_1) &= \frac{1}{(2\pi)^{\frac{k}{2}} |\tilde{\Gamma}_{22}|^{\frac{1}{2}}} \\
&\cdot e^{-\frac{1}{2}[\mathbf{x}_2 - \mu_2 - \Gamma_{21}\Gamma_{11}^{-1}(\mathbf{x}_1 - \mu_1)]' \tilde{\Gamma}_{22}^{-1}[\mathbf{x}_2 - \mu_2 - \Gamma_{21}\Gamma_{11}^{-1}(\mathbf{x}_1 - \mu_1)]} \quad (1.4.21)
\end{aligned}$$

其中 $\tilde{\Gamma}_{22} = \Gamma_{22} - \Gamma_{21}\Gamma_{11}^{-1}\Gamma_{12}$ 。由此可见 $p(\mathbf{x}_1 | \mathbf{x}_2)$ 和 $p(\mathbf{x}_2 | \mathbf{x}_1)$ 仍然是正态密度。也就是, 正态随机向量的一部分分量构成的随机向量对另一部分分量构成的随机向量的条件概率密度, 仍然是正态密度。

再由条件均值与条件方差的定义以及正态密度的性质 (见例 2), 可知在给定 $\mathbf{X}_2 = \mathbf{x}_2$ 的条件下, $\mathbf{X}_1$ 的条件均值向量与条件方差阵分别为

$$\begin{aligned}
E(\mathbf{X}_1 | \mathbf{x}_2) &= \mu_1 + \Gamma_{12}\Gamma_{22}^{-1}(\mathbf{x}_2 - \mu_2) \\
&= E\mathbf{X}_1 + \text{cov}(\mathbf{X}_1, \mathbf{X}_2)(\text{var}\mathbf{X}_2)^{-1}(\mathbf{x}_2 - E\mathbf{X}_2) \quad (1.4.22)
\end{aligned}$$

$$\text{var}(\mathbf{X}_1 | \mathbf{x}_2) = \tilde{\Gamma}_{11} = \Gamma_{11} - \Gamma_{12}\Gamma_{22}^{-1}\Gamma_{12}$$

$$= \text{var} X_1 - \text{cov}(X_1, X_2)(\text{var} X_2)^{-1} \text{cov}(X_2, X_1) \quad (1.4.23)$$

类似地有

$$\begin{aligned} E(X_2 | x_1) &= \mu_2 + \Gamma_{12} \Gamma_{11}^{-1} (x_1 - \mu_1) \\ &= E X_2 + \text{cov}(X_2, X_1)(\text{var} X_1)^{-1} (x_1 - E X_1) \end{aligned} \quad (1.4.24)$$

$$\begin{aligned} \text{var}(X_2 | x_1) &= \tilde{\Gamma}_{22} = \Gamma_{22} - \Gamma_{12} \Gamma_{11}^{-1} \Gamma_{12} \\ &= \text{var} X_2 - \text{cov}(X_2, X_1)(\text{var} X_1)^{-1} \text{cov}(X_1, X_2) \end{aligned} \quad (1.4.25)$$

这恰好与例3中一维的结果相对应的, 这些公式在时间序列分析中要用到。

§ 5 随机序列

§ 5.1 随机序列的定义

前面我们讨论的仅仅涉及到一个随机变量 X 或一个随机向量 $\mathbf{X}$ 。动态数据分析所考虑的对象, 常常不是单个随机变量或随机向量, 而是一族随机变量或一族随机向量, 例如 X_t 表示 t 时刻的气温, 显然是一个随机变量, 当 t 在某个时间间隔 $[a, b]$ 内考察的话, 得到一族随机变量为 $\{X_t; t \in [a, b]\}$ 。又如 X_t 表示某地区第 t 天的降雨量也是一个随机变量, 将 t 从某年某日开始记录下来, 就得到一系列随机变量。因此, 一般地需要引进随机过程和随机序列的概念。

设 T 是某个集合, 对固定的 $t \in T$, X_t 是随机变量; 令 t 在 T 中变动, 得到随机变量全体 $\{X_t; t \in T\}$, 称它为随机函数, 简记为 X_T 。 T 称为足标集, 一般表示时间, 通常 T 取为

$$\text{i) } T = (-\infty, \infty), T = [0, \infty)$$

$$\text{ii) } T = \{\dots, -2, -1, 0, 1, 2, \dots\}, T = \{1, 2, \dots\}.$$

随机函数 X_T 中 T 取 i) 的情形, 称 X_T 为随机过程; T 取 ii) 的情形, 称 X_T 为随机序列, 后者简记为 $\{X_k\}$ 。

具有概率统计基本概念的读者便可知道, 若 X 为表示某一随

机试验结果的随机变量,那么做一次试验,就能获得 X 的一个取值 x ,称 x 为 X 的一个样本值, x 是一个普通数。对于随机过程而言,它的一个样本函数 x_T 是 T 上普通函数,在 1° 的情形就是一条曲线,在很多实际情形,可由自动记录仪记录下来,我们称这函数为随机过程 X_T 的一个现实,对于随机序列而言,它的一个样本函数 $\{x_k\}$ 是一串普通数列,称 $\{x_k\}$ 为随机序列 $\{X_k\}$ 的一个现实,在大量的实际问题中,因为随时间 t 的流逝而不能再重复,我们往往仅能获得随机过程(或序列)的一个现实。而长度为 N 的动态数据 $x_1, x_2, \dots, x_N$ 常常是对一个随机过程 X_T 在离散时刻采样值,今后称动态数据 $x_1, x_2, \dots, x_N$ 为随机序列 $\{X_k\}$ 的长度为 N 的样本值。

另外,随机序列 $\{X_k\}$ 的整数变量 k ,通常表示为等间隔 Δ 的 k 倍,例如 k 表示第 k 小时,第 k 天,第 k 次等,所以,人们常称随机序列为时间序列,其实,它也可表示其它的非时间量,比如表示地质上的第 k 层,动植物的第 k 代。

§ 5.2 随机序列的概率分布与参数表征

一个随机变量的统计特性完全由它的分布函数或分布密度所确定。同样,一个随机向量 $\mathbf{X}^T = (X_1, X_2, \dots, X_n)$ 的统计特性也完全由它的联合分布函数 $F(x_1, x_2, \dots, x_n)$ 或联合分布密度 $p(x_1, x_2, \dots, x_n)$ 所确定。对于随机序列而言,由于它是无穷可列个随机变量构成的,因此,它的全部统计特性需要由任意有穷多个时刻 $t_1, t_2, \dots, t_m$ 相应的随机变量 $X_{t_1}, X_{t_2}, \dots, X_{t_m}$ 的联合分布函数 $F_{t_1, t_2, \dots, t_m}(x_1, x_2, \dots, x_m)$ 或其联合分布密度 $p_{t_1, t_2, \dots, t_m}(x_1, x_2, \dots, x_m)$ 来确定。我们称 $\{F_{t_1, t_2, \dots, t_m}(x_1, x_2, \dots, x_m); \text{任意正整数 } m, t_1, t_2, \dots, t_m \text{ 属于足标集}\}$ 为随机序列 $\{X_k\}$ 的有穷维分布族。它具有如下的性质

i) 对称性,即

$$F_{t_1, t_2, \dots, t_m}(x_1, x_2, \dots, x_m) = F_{t_{j_1}, t_{j_2}, \dots, t_{j_m}}(x_{j_1}, x_{j_2}, \dots, x_{j_m})$$

其中 $(j_1, j_2, \dots, j_m)$ 是 $(1, 2, \dots, m)$ 的任一排列。

ii) 相容性,即任意 $n < m$ 有

$$F_{t_1, t_2, \dots, t_n}(x_1, x_2, \dots, x_n, \infty, \dots, \infty) =$$

$$= F_{t_1, t_2, \dots, t_n}(x_1, x_2, \dots, x_n)$$

也就是说,由高维联合分布推出的低维分布应与原给定的低维分布相同,它们之间不能矛盾。随机序列的统计特性需用有穷维分布族来完整地描述。

如果随机序列 $\{X_k\}$ 的任意有穷维分布满足 $F_{t_1, t_2, \dots, t_m}(x_1, x_2, \dots, x_m) = F_{t_1}(x_1)F_{t_2}(x_2) \cdots F_{t_m}(x_m)$,即序列中任意有穷个随机变量 $X_{t_1}, X_{t_2}, \dots, X_{t_m}$ 都相互独立,则称 $\{X_k\}$ 为独立随机序列。实际应用中常见的电路热噪声往往近似于独立随机序列。

如果随机序列 $\{X_k\}$ 的任意有穷维分布具有如下性质

$$F_{t_1, t_2, \dots, t_m}(x_1, x_2, \dots, x_m) = F_{t_1+\tau, t_2+\tau, \dots, t_m+\tau}(x_1, x_2, \dots, x_m)$$

其中 τ 是任意整数,则称 $\{X_k\}$ 为严平稳序列(又称狭义平稳序列或强平稳序列),对于严平稳序列 $(X_{t_1}, X_{t_2}, \dots, X_{t_m})$ 与 $(X_{t_1+\tau}, X_{t_2+\tau}, \dots, X_{t_m+\tau})$ 具有相同的联合分布。

虽然,有穷维分布族完整地决定了随机序列的全部统计特性,但是随机序列的有穷维分布族一般难以完全掌握,即使知道了也不便于分析和实际应用。正如只须知道随机变量的均值、方差就能大致地刻划随机变量本身一样,对于随机序列有时也只须掌握它的某些参数特征,就可以描述随机序列的主要特性,或就能够满足应用的需要。因此,下面我们引入随机序列的均值函数、自协方差函数和自相关函数等主要参数表征的定义。

1. 均值函数:对于每个 t 而言,若把随机变量 X_t 的均值记作 $EX_t = \mu_t$,那么随机序列 $\{X_t\}$ 的均值函数就是 $\{\mu_t\}$,有时简称 $\{\mu_t\}$ 为随机序列 $\{X_t\}$ 的均值。

若 X_t 的分布函数为 $F_t(x)$,密度函数为 $p_t(x)$ 则

$$\mu_t = EX_t = \int_{-\infty}^{\infty} x dF_t(x) = \int_{-\infty}^{\infty} x p_t(x) dx \quad (1.5.1)$$

由此可见,随机序列的均值和随机序列的分布有关。

2. 自协方差函数:为了分析随机序列 $\{X_t\}$ 中不同时刻随机变量之间的统计关系,需要对任意 t, s 考虑 X_t 与 X_s 的相关关系,令

$$\gamma_{t,s} = E(X_t - EX_t)(X_s - EX_s) =$$

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - \mu_t)(y - \mu_s) p_{ts}(x, y) dx dy \quad (1.5.2)$$

其中 $p_{ts}(x, y)$ 是 X_t 与 X_s 的联合密度, 则称 $\{\gamma_{ts}\}$ 为随机序列 $\{X_t\}$ 的自协方差函数, 记作 $\gamma_{ts} = \text{cov}(X_t, X_s)$, 显然 γ_{ts} 是二元对称函数, 即 $\gamma_{ts} = \gamma_{st}$ 。特别 $t = s$ 时, $\gamma_{tt} = E(X_t - EX_t)^2$, 称 $\{\gamma_{tt}\}$ 为随机序列 $\{X_t\}$ 的方差函数, 简称方差, 记作 $\gamma_{tt} = \text{var } X_t$ 。

随机序列中特别重要的是正态随机序列, 即它的任意有限个随机变量 $X_{t_1}, X_{t_2}, \dots, X_{t_m}$ 看作为一个 m 维随机向量, 则此向量必具有正态密度

$$p_{t_1, t_2, \dots, t_m}(x_1, x_2, \dots, x_m) = (2\pi)^{-\frac{m}{2}} |\Gamma_m|^{-\frac{1}{2}} \cdot \exp\left\{-\frac{1}{2}(\mathbf{x}_m - \boldsymbol{\mu}_m)^T \cdot \Gamma_m^{-1}(\mathbf{x}_m - \boldsymbol{\mu}_m)\right\} \quad (1.5.3)$$

其中

$$\mathbf{x}_m^T = (x_1, x_2, \dots, x_m), \quad \boldsymbol{\mu}_m^T = (\mu_{t_1}, \mu_{t_2}, \dots, \mu_{t_m})$$

$$\Gamma_m = \begin{pmatrix} \gamma_{t_1 t_1} & \gamma_{t_1 t_2} \cdots \gamma_{t_1 t_m} \\ \gamma_{t_2 t_1} & \gamma_{t_2 t_2} \cdots \gamma_{t_2 t_m} \\ \vdots & \vdots & \ddots \\ \gamma_{t_m t_1} & \gamma_{t_m t_2} \cdots \gamma_{t_m t_m} \end{pmatrix}$$

对于正态随机序列作数学处理有许多方便之处。由(1.5.3)式可见, 只要有了随机序列的均值和自协方差函数, 就可以确定任意有穷个随机变量的联合正态密度, 且由 § 4 可知, 还能确定随机序列的条件概率密度, 条件均值和条件方差。在实际应用中, 许多随机序列可以近似地看做正态随机序列。

3. 自相关函数: 随机序列的自相关函数 $\{\rho_{ts}\}$ 定义为

$$\rho_{ts} \triangleq \frac{\gamma_{ts}}{\sqrt{\gamma_{tt} \gamma_{ss}}} \quad (1.5.4)$$

ρ_{ts} 与 γ_{ts} 一样地刻划了 $\{X_t\}$ 中不同时刻 t 与 s 的随机变量 X_t 与 X_s 的相关程度, 由 $\rho_{tt} = 1$, 所以 ρ_{ts} 是 γ_{ts} 的归一化。

显见, $\{\mu_t\}$, $\{\gamma_{ts}\}$ 和 $\{\rho_{ts}\}$ 都由 $\{X_t\}$ 有限维分布族唯一确定。然而仅由这三种参数表征, 一般并不能够唯一确定 $\{X_t\}$ 的有限维

分布族。这就是说,具有不同的有限维分布族的随机序列可能具有相同均值,自协方差函数和自相关函数。

§ 6 平稳随机序列

§ 5.2 已经引入严平稳随机序列的概念,对这类随机序列的一般性质,我们不去深入研究。本书介绍的动态数据分析是以宽平稳序列为基础,下面我们叙述它的定义及其性质。

§ 6.1 宽平稳序列

若随机序列 $\{X_t, t=0, \pm 1, \dots\}$ 对任意整数 $t, EX_t^2 < \infty$, 并且满足如下条件

i) 对任意整数 t , 均值恒为常数, 即

$$EX_t = \mu.$$

ii) 对任意整数 t 和 s, γ_{ts} 只和 $t-s$ 有关, 即 $\gamma_{ts} = \gamma_{t-s}$, 其中 $\gamma_{ts} = E(x_t - \mu)(X_s - \mu)$, 则称 $\{X_t\}$ 为宽平稳序列 (又称广义平稳序列或弱平稳序列), 如果严平稳序列的二阶矩有穷, 那么一定是宽平稳序列。反之则不然, 例如 $X_k = \sin 2\pi k\xi, k=1, 2, \dots$, 其中 ξ 是 $[0, 1]$ 上均匀分布的随机变量。由于对任意正整数 k ,

$$EX_k = \int_0^1 \sin 2\pi kx dx = 0$$

$$EX_k X_l = \int_0^1 \sin 2\pi kx \sin 2\pi lx dx = \frac{1}{2} \delta_{kl}$$

其中

$$\delta_{kl} = \begin{cases} 1, & k=l \\ 0, & k \neq l \end{cases}$$

所以 $\{X_k\}$ 是宽平稳序列, 但显然不是严平稳序列。对于正态随机序列来说, 它的宽平稳性与严平稳性是一致的, 这是由于联合正态分布完全由均值与自协方差阵所唯一确定。今后本书中所说的平稳序列都指宽平稳序列。当然, 在实际中, 真正平稳序列是很难找到的, 但很多真实随机序列可用它近似描述。例如电路中的热

噪声,陀螺仪的随机漂移率,纺纱过程中纱的粗细的不均匀性等,都可以用平稳序列来近似描述。

§ 6.2 自协方差函数与谱分布

平稳序列是时间序列分析所研究的主要对象,序列的自协方差函数和谱分布函数分别在时间序列的时域和频域分析中起着重要的作用。平稳序列的自协方差函数有如下性质

- i) $\gamma_0 \geq 0$;
- ii) $\gamma_{-\tau} = \gamma_\tau$, 即自协方差函数具有对称性;
- iii) $|\gamma_\tau| \leq \gamma_0$;
- iv) γ_τ 是一个有非负定性的数列, 即对任意正整数 m , 实数 $\alpha_1, \alpha_2, \dots, \alpha_m$ 及整数 $t_1, t_2, \dots, t_m$ 有

$$\sum_{i=1}^m \sum_{j=1}^m \gamma_{t_i - t_j} \alpha_i \alpha_j \geq 0 \quad (1.6.1)$$

或者 m 阶方阵

$$\Gamma_m = \begin{pmatrix} \gamma_0 & \gamma_{t_1 - t_2} & \cdots & \gamma_{t_1 - t_m} \\ \gamma_{t_2 - t_1} & \gamma_0 & \cdots & \gamma_{t_2 - t_m} \\ \vdots & \vdots & \ddots & \vdots \\ \gamma_{t_m - t_1} & \gamma_{t_m - t_2} & \cdots & \gamma_0 \end{pmatrix} \quad (1.6.2)$$

是非负定阵。

这是因为

- (a) $\gamma_0 = E(X_t - \mu)^2 \geq 0$;
- (b) $\gamma_{-\tau} = E(X_t - \mu)(X_{t+\tau} - \mu) = E(X_{t+\tau} - \mu)(X_t - \mu) = \gamma_\tau$;
- (c) $|\gamma_\tau| = |E(X_{t+\tau} - \mu)(X_t - \mu)|$
 $\leq \sqrt{E(X_{t+\tau} - \mu)^2 E(X_t - \mu)^2}$
 $= \gamma_0$;

$$\begin{aligned} \text{(d)} \quad \sum_{i=1}^m \sum_{j=1}^m \gamma_{t_i - t_j} \alpha_i \alpha_j &= \sum_{i=1}^m \sum_{j=1}^m E(X_{t_i} - \mu)(X_{t_j} - \mu) \alpha_i \alpha_j \\ &= E\left(\sum_{i=1}^m \alpha_i (X_{t_i} - \mu)\right)^2 \geq 0. \end{aligned}$$

我们称具有对称性和非负定性的实数列 $\gamma_0, \gamma_1, \dots$ 为非负定列。

以上表明, 平稳序列的自协方差函数为非负定列, 这一结论的逆命题也是成立的, 即任意一个非负定列必为某一个平稳序列的自协方差函数。

下面, 为了从频率域研究平稳序列, 我们引入谱的概念。

设 $\{\gamma_k\}$ 为平稳序列 $\{X_t\}$ 的自协方差函数, 则存在一个有界非降函数 $G(\lambda)$, 使得

$$\gamma_k = \int_{-\frac{1}{2}}^{\frac{1}{2}} e^{i2\pi k\lambda} dG(\lambda) \quad (1.6.3)$$

称 $G(\lambda)$ 为平稳序列 $\{X_t\}$ 的谱分布函数 (简称谱函数或谱分布),

如果 $G(\lambda)$ 可以微分, 并记为 $g(\lambda) \triangleq \frac{dG(\lambda)}{d\lambda}$, 则

$$\gamma_k = \int_{-\frac{1}{2}}^{\frac{1}{2}} e^{i2\pi k\lambda} g(\lambda) d\lambda \quad (1.6.4)$$

称 $g(\lambda)$ 为平稳序列 $\{X_t\}$ 的谱密度函数 (简称谱密度)。当 $\sum_{k=-\infty}^{\infty}$

$|\gamma_k| < \infty$ 时, $g(\lambda)$ 一定存在, 而且有

$$g(\lambda) = \sum_{k=-\infty}^{\infty} \gamma_k e^{-i2\pi k\lambda} \quad (1.6.5)$$

在一些工程技术书籍中, $g(\lambda)$ 被称为平稳序列的功率谱密度。

特别, 如果随机序列 $\{X_t\}$ 对任意 X_t 与 X_s 不相关且均值为零, 方差为 σ^2 , 即

$$\text{cov}(X_t, X_s) = \sigma^2 \delta_{ts}, \quad (1.6.6)$$

这时, 我们称随机序列 $\{X_t\}$ 为白噪声序列。如果一个白噪声序列同时又是正态随机序列, 则称这个随机序列为正态白噪声序列, 这时, $\{X_t\}$ 是独立同分布的正态序列, 对任意时刻 t , $X_t \sim \mathcal{N}(0, \sigma^2)$ 。

若 $\{a_t\}$ 为白噪声序列, 则它的自协方差函数为

$$\gamma_k = \sigma_a^2 \delta_{k0}$$

由 (1.6.5) 知, 它的谱密度为

$$g_a(\lambda) = \sum_{k=-\infty}^{\infty} \sigma_a^2 \delta_{k0} e^{-i2\pi k\lambda} = \sigma_a^2 \quad (1.6.7)$$

这表明白噪声序列 $\{a_t\}$ 的谱密度 $g_a(\lambda)$ 在各个频率 λ 上相同。光谱分析中我们知道,白光的光谱在各频率上有相同的强度。因此,白噪声与白光有类似的特性,对于不具备上述特性的噪声,统称为有色噪声。虽然,在自然界中,纯粹的白噪声序列是很难遇到的,但许多实际的随机序列可以近似地作为白噪声来处理,而更重要的是一些有色噪声可以通过白噪声表示出来。

§ 6.3 平稳序列的线性运算

在概率统计中,经常要对随机变量进行加减等线性运算。对于随机序列,同样也可进行不同时刻随机变量之间的线性运算。

设 $\{X_t\}$ 为零均值平稳序列, α, β 为两个实数, τ 是某一固定整数,令

$$Y_t = \alpha X_t + \beta X_{t-\tau} \quad (1.6.8)$$

则 $\{Y_t\}$ 仍然是零均值平稳序列。因为

$$\begin{aligned} EY_t &= \alpha EX_t + \beta EX_{t-\tau} = 0 \\ EY_t Y_s &= E(\alpha X_t + \beta X_{t-\tau})(\alpha X_s + \beta X_{s-\tau}) \\ &= \alpha^2 EX_t X_s + \alpha\beta E(X_t X_{s-\tau} + X_{t-\tau} X_s) + \beta^2 EX_{t-\tau} X_{s-\tau} \\ &= \alpha^2 \gamma_{t-s}^X + \alpha\beta(\gamma_{t-s+\tau}^X + \gamma_{t-\tau-s}^X) + \beta^2 \gamma_{t-s}^X \end{aligned}$$

只与 $t-s$ 有关,所以 $\{Y_t\}$ 为零均值平稳序列。其中 γ_t^X 为 $\{X_t\}$ 的自协方差函数。

线性运算(1.6.8)可推广到无穷求和。设 $\{X_t\}$ 为零均值平稳序列, $\{\alpha_k\}$ 为实数列,且 $\sum_{k=-\infty}^{\infty} |\alpha_k| < \infty$, 令

$$Y_t = \sum_{k=-\infty}^{\infty} \alpha_k X_{t-k} \quad (1.6.9)$$

则 $\{Y_t\}$ 也是零均值平稳序列。因为

$$EY_t = \sum_{k=-\infty}^{\infty} a_k EX_{t-k} = 0$$

$$\begin{aligned} EY_t Y_s &= E \left(\sum_{k=-\infty}^{\infty} a_k X_{t-k} \cdot \sum_{l=-\infty}^{\infty} a_l X_{s-l} \right) \\ &= \sum_{k,l=-\infty}^{\infty} a_k a_l EX_{t-k} X_{s-l} = \sum_{k,l=-\infty}^{\infty} a_k a_l \gamma_{t-s+l-k}^X \end{aligned}$$

$$\begin{aligned} \text{由于 } EY_t^2 &= \sum_{k,l=-\infty}^{\infty} a_k a_l \gamma_{t-k}^X \leq \gamma_0^X \sum_{k,l=-\infty}^{\infty} |a_k| |a_l| = \\ &= \gamma_0^X \left(\sum_{k=-\infty}^{\infty} |a_k| \right)^2 < \infty \end{aligned}$$

即 $\{Y_t\}$ 的二阶矩有穷, 因此, $\{Y_t\}$ 为零均值平稳序列。

如果在 (1.6.9) 式中 $X_t = a_t$, $\{a_t\}$ 为白噪声, 则称 $\{Y_t\}$ 为 $\{a_t\}$ 的滑动和。我们今后常遇到的是单边的滑动和, 即

$$Y_t = \sum_{k=0}^{\infty} a_k a_{t-k} \quad (1.6.10)$$

特别如下的有穷和

$$Y_t = \sum_{k=0}^q a_k a_{t-k} \quad (1.6.11)$$

在满足适当条件时, 称 (1.6.11) 表示的 $\{Y_t\}$ 为 $\{a_t\}$ 的 q 阶滑动平均。

以上两种特例 (1.6.10) 和 (1.6.11) 是非常有用的特殊平稳序列, 它们的自协方差函数和谱密度可以利用 $\{a_t\}$ 的噪声性质很方便地求出, 以 (1.6.10) 为例

$$Y_t = \sum_{k=0}^{\infty} a_k a_{t-k}$$

$$\gamma_{s-t}^Y = \gamma_{t-s}^Y = E \left(\sum_{k=0}^{\infty} a_k a_{t-k} \cdot \sum_{l=0}^{\infty} a_l a_{s-l} \right)$$

$$= \sum_{k, l=0}^{\infty} \alpha_k \alpha_l E a_{l-k} a_{s-l} = \sigma_a^2 \sum_{k, l=0}^{\infty} \alpha_k \alpha_l \delta_{l-s+l-k}$$

$$= \sigma_a^2 \sum_{k=0}^{\infty} \alpha_k \alpha_k \quad (s=0)$$

$$g_Y(\lambda) = \sum_{\tau=-\infty}^{\infty} \gamma_Y^{\tau} e^{-i2\pi\tau\lambda}$$

$$= \sigma_a^2 \sum_{\tau=-\infty}^{\infty} \sum_{k=0}^{\infty} \alpha_k \alpha_{k+\tau} e^{-i2\pi\tau\lambda}$$

$$= \sigma_a^2 \sum_{k=0}^{\infty} \sum_{\tau=-k}^{\infty} \alpha_k \alpha_{k+\tau} e^{-i2\pi\tau\lambda}$$

$$= \sigma_a^2 \sum_{k=0}^{\infty} \sum_{\tau=-k}^{\infty} \overline{\alpha_k e^{-i2\pi k\lambda}} \cdot \alpha_{k+\tau} e^{-i2\pi(\tau+k)\lambda}$$

$$= \sigma_a^2 \sum_{k=0}^{\infty} \sum_{l=0}^{\infty} \overline{\alpha_k e^{-i2\pi k\lambda}} \cdot \alpha_l e^{-i2\pi l\lambda}$$

$$= \sigma_a^2 \left| \sum_{k=0}^{\infty} \alpha_k e^{-i2\pi k\lambda} \right|^2$$

若令

$$A(w) = \sum_{k=0}^{\infty} \alpha_k w^k$$

则有

$$g_Y(\lambda) = \sigma_a^2 |A(e^{-i2\pi\lambda})|^2 \quad (1.6.12)$$

由此可见,虽然白噪声序列 $\{a_t\}$ 具有最简单的常值谱密度,但它的线性运算所得到的 $\{Y_t\}$ 可以具有比较复杂的连续谱密度。

§ 6.4 具有有理谱的平稳序列

对于平稳序列 $\{X_t\}$,只要知道了它的自协方差函数 $\{\gamma_k\}$ 或谱函数 $G(\lambda)$ (相应谱密度 $g(\lambda)$),基本上就掌握了它的统计性质,而欲求得 $\{\gamma_k\}$ 或 $g(\lambda)$,除了从实际问题的物理意义出发进行分

析之外,主要是根据 $\{X_t\}$ 的长度为 N 的样本 $x_1, x_2, \dots, x_N$ 来对 $\{\gamma_k\}$ 或 $g(\lambda)$ 进行估计。但是自协方差函数 $\gamma_k, k=0, 1, 2, \dots$ 是个无穷序列,谱函数是在 $\left[-\frac{1}{2}, \frac{1}{2}\right]$ 上的函数,故用有穷个样本值来估计函数 $g(\lambda)$ 是很困难的,即使勉强作出估计,也是因为估计函数形状复杂而不利于进一步的分析、模拟、预报和控制。为了克服上述困难,同时又不失普遍性,可将 $g(\lambda)$ 局限于一个较窄的函数类范围内进行讨论。具体地讲,我们只讨论这样一类平稳序列,它们的谱函数 $G(\lambda)$ 不仅可微,而且谱密度函数 $g(\lambda) = \frac{dG(\lambda)}{d\lambda}$ 是 $e^{-i2\pi\lambda}$ 的有理函数,

$$g(\lambda) = \sigma_a^2 \left| \frac{\theta(e^{-i2\pi\lambda})}{\varphi(e^{-i2\pi\lambda})} \right|^2 \quad (1.6.13)$$

其中 $\theta(w)$ 和 $\varphi(w)$ 为 w 的实系数多项式

$$\begin{aligned} \theta(w) &= 1 - \theta_1 w - \theta_2 w^2 - \dots - \theta_q w^q \\ \varphi(w) &= 1 - \varphi_1 w - \varphi_2 w^2 - \dots - \varphi_p w^p \end{aligned} \quad (1.6.14)$$

$\theta(w)$ 和 $\varphi(w)$ 无公共因子,否则我们可把它约简,并且限制 $\theta(w) = 0$ 和 $\varphi(w) = 0$ 的根全在复平面的单位圆外,这样就把对 $G(\lambda)$ 或 $g(\lambda)$ 的估计归结为对有限参数 p, q, σ_a^2 及 $\varphi_j (j=1, 2, \dots, p), \theta_j (j=1, 2, \dots, q)$ 的估计问题,从而使问题大大地简化。另外,任意一个连续函数都可以由有理函数逼近,故形如(1.6.13)的 $g(\lambda)$ 可以逼近于任意一个连续谱密度函数,从而研究形如(1.6.13)的 $g(\lambda)$,既有广泛意义又简便易行。这种以 $e^{-i2\pi\lambda}$ 的有理函数 $g(\lambda)$ ((1.6.13)式)作为谱密度的平稳序列,称为具有有理谱的平稳序列。

§ 0.5 平稳序列的遍历性

前面已经讲过,均值和自协方差函数是平稳序列统计特性的主要表征,而且今后会看到,为了对一个平稳序列建模或研究预报和控制等问题,也常常首先要求出均值和自协方差函数。然而,对于一个平稳序列,我们只能观测到一个现实中的有限个数据,例如 $x_1, x_2, \dots, x_N$,即在每个固定的时刻 t ,只有 X_t 的一个具体的取

值,用它是得不到 EX_i 或它的合理的估计的。同样,用 X_i 和 X_j 的一个具体取值也是不可能得到合理的 γ_{i-j} 的估计。为了解决这一问题,要引入所谓的“遍历性”的概念。

遍历性定义:设 $\{X_i\}$ 为随机序列, $h(X_i)$ 为 $\{X_i\}$ 的函数,且 $\{h(X_i)\}$ 仍为随机序列,例如 $h(X_i)$ 为 $|X_i|, X_i^2, X_i X_{i+k}$ 等等,如果对于任意使 $E|h(X_i)| < \infty$ 的函数 $h(\cdot)$, 概率为 1 地有

$$Eh(X_i) = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{j=1}^N h(X_j) \quad (1.6.15)$$

称 $\{h(X_i)\}$ 有遍历性。

本书主要讨论的是正态有理谱平稳序列,根据随机过程理论,它们是具备遍历性的。遍历性的定义还有其它一些形式,我们这里不予详述。

遍历性是从大量实践中总结出来的一种抽象概念。它的物理意义大致叙述如下:正态平稳序列 $\{X_i\}$ 的函数列 $\{h(X_i)\}$ 也是一个平稳序列,它的均值 $Eh(X_i)$ 是依 $h(X_i)$ 的分布求得的,称 $Eh(X_i)$ 为 $h(X_i)$ 的总体平均或系集平均,由平稳性知其值对任意 t 都相同,又 $\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{j=1}^N h(X_j)$ 就是 $\{h(X_i)\}$ 按时间平均。因此,等式 (1.6.15) 所定义的遍历性就是 $h(X_i)$ 的总体平均等于它的时间平均。这就意味着 $\{X_i\}$ 的任何一个现实随着 t 的变化所能取的值,能够历经平稳序列依概率分布所能取到的各种值。

最后,举例说明遍历性的用处,设 $\{X_i\}$ 为平稳序列,取 $h(X_i) = X_i$,则由遍历性知,依概率为 1 地有

$$\mu = EX_i = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{j=1}^N X_j \quad (1.6.16)$$

由此可见,利用平稳序列 $\{X_i\}$ 的一个足够长度的样本数据 $x_1, x_2, \dots, x_N$ 近似地有

$$\mu \approx \frac{1}{N} \sum_{j=1}^N x_j \quad (1.6.17)$$

今后记 $\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$, 称 $\bar{x}$ 为样本均值。

同理, 若 $\{X_i\}$ 为零均值平稳序列, 取 $h(X_i) = X_i X_{i+l}$, 则由遍历性知, 依概率为 1 地有

$$\gamma_l = E X_i X_{i+l} = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{i=1}^N X_i X_{i+l} \quad (1.6.18)$$

因此, 利用零均值平稳序列 $\{X_i\}$ 的一个足够长度 N 的数据 $x_1, x_2, \dots, x_N$ 可得 $\{X_i\}$ 的自协方差函数 γ_l 的近似值 $\hat{\gamma}_l = \frac{1}{N} \sum_{i=1}^{N-l} x_{i+l} x_i$ 。

这里本应除以 $N-l$, 但在 N 很大时, $\frac{N-l}{N}$ 近似于 1, 又为了使 $\{\hat{\gamma}_l\}$ 为正定列, 故改用 N 除。

对于非零均值平稳序列 $\{X_i\}$ 有

$$\hat{\gamma}_l = \frac{1}{N} \sum_{i=1}^{N-l} (x_{i+l} - \bar{x})(x_i - \bar{x}) \quad (1.6.19)$$

称 $\{\hat{\gamma}_l\}$ 为样本自协方差函数, (1.6.19) 的 $\hat{\gamma}_l$ 在 N 充分大时是 γ_l 的一个很好的估计值。

由此可见, 对于平稳序列 $\{X_i\}$, 遍历性的实际意义是平稳序列的均值 μ , 自协方差函数 $\{\gamma_l\}$ 等可由它的长度为 N 的样本值 $x_1, x_2, \dots, x_N$ 按时间平均所求得的值很好地逼近它们。

§ 7 多维随机序列

§ 7.1 多维随机序列的定义

前面两节讨论的都是一维随机序列, 在许多情况下, 我们需要同时考察多个随时间变化的指标, 需要分析它们彼此之间和时间前后之间的相互统计关系。例如在进行雨量预报问题时, 需要分析该地区与雨量有关的气温, 气压, 湿度等气象因素; 在炼钢过程中, 钢水温度和炉气中的二氧化碳含量都与钢的脱碳量有关, 为了

更好地进行在线定碳,应当考虑多个随机序列;在一般的控制和滤波系统中,也常要考虑多个随机输入输出、控制量和被控量等,因此,需要研究多维随机序列。

一维随机序列的定义不难推广到多维随机序列的情形。我们称 $\{X_t\} = \{(X_t^{(1)}, \dots, X_t^{(r)})^T, t=0, \pm 1, \dots\}$ 为 r 维随机序列,是指对每个固定的整数 t , X_t 是一个 r 维随机向量。它也看成把 r 个一维的随机序列 $\{X_t^{(i)}\} i=1, 2, \dots, r$ 放在一起,而它们相互之间又有一定的统计关系,为了叙述这些统计关系,需要将上两节的概念做适当的推广。

§ 7.2 多维随机序列的参数表征

1. 均值函数:设 $\{X_t\}$ 为 r 维随机序列,对任意固定 t , EX_t 不再是一个实数,而是一个 r 维实数向量,即

$$EX_t = (EX_t^{(1)}, EX_t^{(2)}, \dots, EX_t^{(r)})^T \quad (1.7.1)$$

而随着 t 的变化 (EX_t) 给出一个非随机的 r 维向量序列,称 $\{EX_t\}$ 为 $\{X_t\}$ 的均值向量。

2. 方差阵和方差函数:对于 r 维随机向量序列 $\{X_t\}$, $E(X_t^{(k)} - EX_t^{(k)})^2 = \text{var} X_t^{(k)}$ ($k=1, 2, \dots, r$) 是 X_t 的第 k 分量 $X_t^{(k)}$ 的方差,称 $\{\text{var} X_t^{(k)}\}$ 为 $\{X_t^{(k)}\}$ 的方差函数。只用 r 个方差函数 $\{\text{var} X_t^{(k)}\} k=1, 2, \dots, r$ 不能较完全地反映出 $\{X_t\}$ 的方差特性,因为它们不能描述各分量之间的联系。因此,我们定义

$$R_t \triangleq E(X_t - EX_t)(X_t - EX_t)^T \quad (1.7.2)$$

称 $\{R_t\}$ 为 r 维随机序列 $\{X_t\}$ 的方差阵函数,由于对任意非零 r 维向量 $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_r)^T$

$$\alpha^T R_t \alpha = E \left[\sum_{k=1}^r \alpha_k (X_t^{(k)} - EX_t^{(k)}) \right]^2 \geq 0$$

所以 R_t 为一个 r 阶非负定阵。它的主对角线上的元恰好是 $X_t^{(k)}$ $k=1, 2, \dots, r$ 的方差,而第 i 行第 j 列元为 $E(X_t^{(i)} - EX_t^{(i)})(X_t^{(j)} - EX_t^{(j)})$,称它为 $X_t^{(i)}$ 和 $X_t^{(j)}$ 的互协方差,记作 $\text{cov}(X_t^{(i)}, X_t^{(j)})$ 。

3. 自协方差阵和互协方差函数:为了掌握 $\{X_t\}$ 在不同时刻

的统计联系, 我们还需定义

$$R_{ts} \triangleq E(\mathbf{X}_t - E\mathbf{X}_t)(\mathbf{X}_s - E\mathbf{X}_s)^T \quad (1.7.3)$$

为 $\{\mathbf{X}_t\}$ 的自协方差阵, R_{ts} 的主对角线元是 $\{X_t^{(k)}\} k=1, 2, \dots, r$ 的自协方差函数, 而第 i 行第 j 列元是 $E(X_t^{(i)} - EX_t^{(i)})(X_s^{(j)} - EX_s^{(j)})$, 称它为 $X_t^{(i)}$ 与 $X_s^{(j)}$ 的互协方差, 记作 $\text{cov}(X_t^{(i)}, X_s^{(j)})$ 。当 $t=s$ 时, R_{ts} 即为 R_t 。由此可见, $\{R_{ts}\}$ 揭示了 $\{\mathbf{X}_t\}$ 的各分量之间及前后时刻之间的相互联系。另外, 还可定义自相关阵和互相关函数, 将 R_{ts} 中每一元 $E(X_t^{(i)} - EX_t^{(i)})(X_s^{(j)} - EX_s^{(j)})$ 标准化, 即定义 $r \times r$ 方阵 (ρ_{ts}) 为

$$\rho_{ts} = \left(\frac{E(X_t^{(i)} - EX_t^{(i)})(X_s^{(j)} - EX_s^{(j)})}{\sqrt{E(X_t^{(i)} - EX_t^{(i)})^2 E(X_s^{(j)} - EX_s^{(j)})^2}} \right)_{r \times r}$$

称 (ρ_{ts}) 为 $\{\mathbf{X}_t\}$ 的自相关函数阵, (ρ_{ts}) 的主对角线上的元为 $\{\mathbf{X}_t\}$ 的各分量的自相关函数, 非对角线上的元为 $\{\mathbf{X}_t\}$ 的各分量间的互相关函数。

§ 7.3 多维平稳序列

对于 r 维随机序列 $\{\mathbf{X}_t\}$ 也可引进平稳性的概念, 为此, 除要求 $\{\mathbf{X}_t\}$ 的每一个分量随机序列 $\{X_t^{(k)}\} k=1, 2, \dots, r$ 本身是平稳序列之外, 还要求它们分量之间的统计关系是平稳的, 称两个随机序列 $\{X_t^{(i)}\}$ 和 $\{X_t^{(j)}\}$ 为平稳相关的, 如果对任意整数 t, s 和 h 有如下等式

$$EX_{t+h}^{(i)} X_{s+h}^{(j)} = EX_t^{(i)} X_s^{(j)} \quad (1.7.4)$$

总之, r 维随机序列 $\{\mathbf{X}_t\}$, 如果它的每一分量序列是平稳序列, 不同分量之间是平稳相关的, 则称 $\{\mathbf{X}_t\}$ 为 r 维平稳序列, 这时, $\{\mathbf{X}_t\}$ 满足

- i) 对任意整数 $t, E\mathbf{X}_t = \boldsymbol{\mu}$;
- ii) 对任意整数 $t, s, E(\mathbf{X}_t - \boldsymbol{\mu})(\mathbf{X}_s - \boldsymbol{\mu})^T = R_{t-s}$.

$$(1.7.5)$$

其中 $\boldsymbol{\mu}$ 是 r 维常值向量。称 R_t 为 $\{\mathbf{X}_t\}$ 的自协方差阵, 如果 $\{\mathbf{X}_t\}$ 的自协方差阵 R_t 满足

$$R_t = S\delta_{t,0} \quad (1.7.6)$$

其中 S 为正定阵, 则称 $(\mathbf{X}_t)$ 为 r 维白噪声序列。它在多维时间序列分析中扮演重要的角色。

有关一维平稳序列的一些概念和性质, 同样可以推广到多维平稳序列的情形, 我们不再一一列举。

§ 8 统计估计

对于未知参数或未知随机向量进行统计估计, 是时间序列分析的重要内容, 本节将介绍几种常用的统计估计方法, 并讨论参数估计的优效性。

§ 8.1 极大似然估计

极大似然估计又简记为 ML 估计 (Maximum Likelihood Estimation), 它是一种建立在极大似然准则上的估计。

设 $\{Y_t\}$ 为随机序列, 它的有穷维分布具有概率密度, 能被一组参数 $\beta = (\beta_1, \beta_2, \dots, \beta_r)^T$ 唯一确定。记 $\mathbf{Y}_n = (Y_1, Y_2, \dots, Y_n)^T$, 用 $p(\mathbf{y}_n | \beta)$ 表示在 β 给定条件下的 $\mathbf{Y}_n$ 的概率密度, 当 $\mathbf{Y}_n$ 的实验结果已知 (即 $\mathbf{Y}_n$ 的样本值给定) 时, $p(\mathbf{y}_n | \beta)$ 又可看成是 β 的函数, 可表成 $p(\mathbf{y}_n | \beta) = L(\beta | \mathbf{y}_n)$, 称 $L(\beta | \mathbf{y}_n)$ 为似然函数, 使 $L(\beta | \mathbf{y}_n)$ 取极大的那组参数 β 记为 $\hat{\beta}_{ML}$, 称它为参数向量 β 的极大似然估计值。现举一个例子, 直观地说明一下极大似然估计的合理性。设一个小学校六个年级中每个年级的学生身高 Y 近似地看为 $\mathcal{N}(\mu_j, \sigma^2)$ 分布 $j = 1, 2, \dots, 6$, 当然 $\mu_1 < \mu_2 < \dots < \mu_6$ 。现在我们来到某个年级的教室门口, 我们并非知道它是那个年级, 而随机地叫出一个学生测量一下身高记为 y_0 , 然后猜猜这个教室是几年级的。以 $p(y | j)$ 表示 $\mathcal{N}(\mu_j, \sigma^2)$ 的分布密度, 如果 $L(j_0 | y_0) = p(y_0 | j_0)$ 比其余的 $L(j | y_0)$ ($j \neq j_0$) 都大的话 (见图 1.5), 那么可以猜这是 j_0 年级, 这并不是说能百分之百猜对, 但是这样猜测犯错误的可能性比别的猜测都小。

从图 1.5 中可见, $j_0 = 3$, 即认为是三年级。在这个例子中, 参数 β




图 1.5

是一维向量(标量)年级号,它可从六个值中选取,但在很多情况下, β 可取无穷多值又可连续地取值。

由于对数函数是严格单调增函数,所以 $l(\beta|y_n) = \log L(\beta|y_n)$ 与 $L(\beta|y_n)$ 在相同的 β 值上达到极大,我们常用求 $l(\beta|y_n)$ 的极大值来求得极大似然估计,特别当 $l(\beta|y_n)$ 是 β 的可微函数时,极值可通过求导数得到。以 $\hat{\beta}_{ML}$ 表示 β 的极大似然估计,那么它可由下式解出

$$\left. \frac{\partial l(\beta|y_n)}{\partial \beta} \right|_{\beta=\hat{\beta}_{ML}} = 0 \quad (1.8.1)$$

方程 $\frac{\partial l(\beta|y_n)}{\partial \beta} = 0$ 称为似然方程。

极大似然估计在历史上出现很早,在实际应用中,如果能够得知随机样本的所属函数类,而对于参数本身缺乏任何验前信息,那么经常采用极大似然估计。上述似然方程中取对数后求导数常常是为了计算上简便。

§ 8.2 最小二乘估计

最小二乘估计简记为 LS 估计(Least Square Estimation),它是大家所熟知的一种参数估计。

首先介绍线性模型的参数最小二乘估计。

设有一个线性模型

$$X_k = u_{k1}\beta_1 + u_{k2}\beta_2 + \cdots + u_{kr}\beta_r + e_k \quad (1.8.2)$$

$$k = 1, 2, \cdots, n$$

其中 $u_{k1}, u_{k2}, \cdots, u_{kr} (k=1, 2, \cdots, n)$ 是已知量, $\beta = (\beta_1, \beta_2, \cdots, \beta_r)^T$ 是未知参数, 它的真值设为 $\beta^0 = (\beta_1^0, \beta_2^0, \cdots, \beta_r^0)^T$. $e_k (k=1, 2, \cdots, n)$ 称为模型的残差, 它是在零值上下起伏的量, 且与 $u_{kj} (k=1, 2, \cdots, n; j=1, 2, \cdots, r)$ 无关。如果测量得到 $X_1, X_2, \cdots, X_n$ 的 n 个数据, 则使得残差平方和

$$S(\beta) \triangleq \sum_{k=1}^n e_k^2 = \sum_{k=1}^n (X_k - u_{k1}\beta_1 - \cdots - u_{kr}\beta_r)^2 \quad (1.8.3)$$

达到最小的 β , 可用来估计真值 β^0 , 记为 $\hat{\beta}_{LS}$, 称它为 β^0 的最小二乘估计。将(1.8.2)表为矩阵形式

$$\begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{pmatrix} = \begin{pmatrix} u_{11} & u_{12} & \cdots & u_{1r} \\ u_{21} & u_{22} & \cdots & u_{2r} \\ \vdots & \vdots & & \vdots \\ u_{n1} & u_{n2} & \cdots & u_{nr} \end{pmatrix} \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_r \end{pmatrix} + \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{pmatrix} \quad (1.8.4)$$

令

$$X_n = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{pmatrix} \quad U = \begin{pmatrix} u_{11} & u_{12} & \cdots & u_{1r} \\ u_{21} & u_{22} & \cdots & u_{2r} \\ \vdots & \vdots & & \vdots \\ u_{n1} & u_{n2} & \cdots & u_{nr} \end{pmatrix}$$

$$e_n = \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{pmatrix}$$

则(1.8.4)表为

$$X_n = U\beta + e_n$$

$$e_n^T e_n = (X_n - U\beta)^T (X_n - U\beta) \quad (1.8.5)$$

由

$$\frac{d\mathbf{e}_n^T \mathbf{e}_n}{d\boldsymbol{\beta}} = -2 \mathbf{U}^T (\mathbf{X}_n - \mathbf{U}\boldsymbol{\beta}) = 0 \quad (1.8.6)$$

解得

$$\hat{\boldsymbol{\beta}}_{LS} = (\mathbf{U}^T \mathbf{U})^{-1} \mathbf{U}^T \mathbf{X}_n \quad (1.8.7)$$

现在将线性模型加以推广, 考虑非线性模型

$$\begin{aligned} X_k &= f_k(\boldsymbol{\beta}; u_{k1}, u_{k2}, \dots, u_{kr}) + e_k \\ k &= 1, 2, \dots, n \end{aligned} \quad (1.8.8)$$

其中 f_k 是 $\boldsymbol{\beta}, u_{k1}, u_{k2}, \dots, u_{kr}$ 的非线性函数, 如果对每组固定的 $u_{k1}, u_{k2}, \dots, u_{kr}$, 获得了测量值 $X_k, k=1, 2, \dots, n$, 那么, 使残差平方和

$$S(\boldsymbol{\beta}) \triangleq \sum_{k=1}^n e_k^2 = \sum_{k=1}^n [X_k - f_k(\boldsymbol{\beta}; u_{k1}, u_{k2}, \dots, u_{kr})]^2 \quad (1.8.9)$$

达到最小的 $\hat{\boldsymbol{\beta}}_{LS}$ 就是 $\boldsymbol{\beta}$ 的非线性最小二乘估计值。

一般地讲, 对于非线性参数 $\hat{\boldsymbol{\beta}}_{LS}$ 的求解要比线性情形麻烦得多, 而且常常只能给出数值解, 得不到线性情形的解析表达式, 有时 f_k 还可能用叠代方式给出, 不一定有明显表达式, 本书在第六章里将要详细地讨论非线性最小二乘的各种求解方法。由于最小二乘估计对于模型的统计特性不加任何条件, 因此, 许多复杂模型的参数都可借助于最小二乘法来进行估计。

§ 8.3 最小方差估计

最小方差估计简记为 MV 估计 (Minimum Variance Estimation), 我们结合一个例子, 将这种估计的准则叙述如下:

在防空中需要随时估计敌机飞行的状态, 例如敌机的位置、飞行速度和加速度等, 这些量都称为状态。一般可以将某个时刻的状态表为随机向量 $\mathbf{X}$ 。当然需要对 $\mathbf{X}$ 进行量测, 但量测手段通常只可能得到 $\mathbf{X}$ 的某一部分分量或它的某些分量的函数, 例如防空中量测到 $\mathbf{X}$ 的距离分量。而且量测必然会带有误差。因此一般

地也可以把量测表为一个随机向量 Z , 它与 X 的维数可以不相同, 一般 Z 的维数小于 X 的维数。例如防空中, X 可以是九维向量, 包括三个方向上的位置、速度和加速度, 而 Z 仅仅是位置的三个坐标构成的三维向量。

现在, 令 $\hat{X} = \hat{X}(Z)$ 表示依据量测 Z 对 X 所求得的某种估计, 称为估计量, 它是一个与 X 的维数相同的随机向量, 而且是 Z 的函数。我们记这个估计的误差为

$$\tilde{X} = X - \hat{X}(Z) \quad (1.8.10)$$

当然, 估计误差 $\tilde{X}$ 是与 X 同维数的随机向量。由于量测误差的存在, 即使其它条件都相同, 每次量测后所得的估计误差也不可能完全相同。所以要评价一个估计量的优劣, 应当研究这个估计误差的整个统计规律。当然希望估计量 $\hat{x}(Z)$ 与被估计量 X 之间越接近越好, 也就是说希望 $\tilde{X}$ 越小越好。按照统计规律而言, 在相同条件下, 不管对 X 重复多少次量测, 用相同的估计方法, 由每次量测得到的估计误差, 绝大部分应当密集于零的附近, 才可以认为这一估计方法是好的。我们知道, 估计误差 $\tilde{X}$ 的二阶原点矩 $E \tilde{X} \tilde{X}^T$ 正是表示误差分布在零附近密集的程度, 称 $E \tilde{X} \tilde{X}^T$ 为均方误差阵。所以, 如果存在某种估计, 能使其均方误差阵比其它任何估计的均方误差阵都小, 则称这个估计是最优的。于是在上述意义下的最优估计就是求一个适当的 Z 的函数 $\hat{X}_{MV} = \hat{X}_{MV}(Z)$, 较之其它 $\hat{X}(Z)$, 相应的均方误差阵 $E \tilde{X} \tilde{X}^T$ 达到极小, 即

$$E \tilde{X}_{MV} \tilde{X}_{MV}^T \leq E \tilde{X} \tilde{X}^T。$$

我们记 X 的联合分布密度为 $p_1(x)$, Z 的联合分布密度为 $p_2(z)$, X 与 Z 的联合分布密度为 $p(x, z)$, 在给定 $X=x$ 的条件下, Z 的条件分布密度为 $p(z|x)$, 在给定 $Z=z$ 的条件下, X 的条件分布密度为 $p(x|z)$, 则由条件密度公式 (1.3.6) 公式有

$$p(x, z) = p(x|z)p_2(z) = p(z|x)p_1(x) \quad (1.8.11)$$

因此, 对于某一估计量 $\hat{\mathbf{x}}(\mathbf{Z})$, 它的均方误差阵 $E\hat{\mathbf{X}}\hat{\mathbf{X}}^r$ 可表为

$$\begin{aligned} E\hat{\mathbf{X}}\hat{\mathbf{X}}^r &= E[\mathbf{X} - \hat{\mathbf{x}}(\mathbf{Z})][\mathbf{X} - \hat{\mathbf{x}}(\mathbf{Z})]^r \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} [\mathbf{x} - \hat{\mathbf{X}}(\mathbf{z})][\mathbf{x} - \hat{\mathbf{X}}(\mathbf{z})]^r p(\mathbf{x}, \mathbf{z}) d\mathbf{x} d\mathbf{z} \\ &= \int_{-\infty}^{\infty} \left\{ \int_{-\infty}^{\infty} [\mathbf{x} - \hat{\mathbf{X}}(\mathbf{z})][\mathbf{x} - \hat{\mathbf{X}}(\mathbf{z})]^r p(\mathbf{x}|\mathbf{z}) \right. \\ &\quad \left. d\mathbf{x} \right\} p_2(\mathbf{z}) d\mathbf{z} \end{aligned} \quad (1.8.12)$$

(1.8.12)式对任何估计量 $\hat{\mathbf{X}}(\mathbf{Z})$ 都成立, 积分的重数分别与 $\mathbf{X}$ 和 $\mathbf{Z}$ 的维数相同。我们的目的是要选择一个估计量 $\hat{\mathbf{X}}_{\text{MV}}(\mathbf{Z})$, 使得 (1.8.12) 式达到极小。由 (1.8.12) 中最后的等式中可看出, 若 $\hat{\mathbf{X}}_{\text{MV}}(\mathbf{z})$ 对每个固定的 $\mathbf{z}$ 都使下式达极小

$$\int_{-\infty}^{\infty} [\mathbf{x} - \hat{\mathbf{X}}(\mathbf{z})][\mathbf{x} - \hat{\mathbf{X}}(\mathbf{z})]^r p(\mathbf{x}|\mathbf{z}) d\mathbf{x} \quad (1.8.13)$$

那么它也就使 (1.8.12) 达极小。

下面我们来证明如下事实, 使 (1.8.13) 达到极小的 $\hat{\mathbf{X}}(\mathbf{z})$ 恰好是在给定 $\mathbf{Z}=\mathbf{z}$ 的条件下, $\mathbf{X}$ 的条件期望, 即

$$\hat{\mathbf{X}}_{\text{MV}}(\mathbf{z}) = E(\mathbf{X}|\mathbf{Z}=\mathbf{z}) \quad (1.8.14)$$

事实上, 设 $\hat{\mathbf{X}}(\mathbf{z})$ 是 $\mathbf{z}$ 的任一函数向量, 则从 (1.8.13) 出发, 可以推出如下的关系式

$$\begin{aligned} &E[(\mathbf{X} - \hat{\mathbf{X}}(\mathbf{Z}))(\mathbf{X} - \hat{\mathbf{X}}(\mathbf{Z}))^r | \mathbf{Z}=\mathbf{z}] \\ &= E[\{\mathbf{X} - E(\mathbf{X}|\mathbf{z}) + E(\mathbf{X}|\mathbf{z}) - \hat{\mathbf{X}}(\mathbf{z})\} \\ &\quad \cdot \{\mathbf{X} - E(\mathbf{X}|\mathbf{z}) + E(\mathbf{X}|\mathbf{z}) - \hat{\mathbf{X}}(\mathbf{z})\}^r | \mathbf{Z}=\mathbf{z}] \\ &= E[(\mathbf{X} - E(\mathbf{X}|\mathbf{z}))(\mathbf{X} - E(\mathbf{X}|\mathbf{z}))^r | \mathbf{Z}=\mathbf{z}] \\ &\quad + E[(\mathbf{X} - E(\mathbf{X}|\mathbf{z}))(E(\mathbf{X}|\mathbf{z}) - \hat{\mathbf{X}}(\mathbf{z}))^r | \mathbf{Z}=\mathbf{z}] \\ &\quad + E[(E(\mathbf{X}|\mathbf{z}) - \hat{\mathbf{X}}(\mathbf{z}))(\mathbf{X} - E(\mathbf{X}|\mathbf{z}))^r | \mathbf{Z}=\mathbf{z}] \\ &\quad + E[(E(\mathbf{X}|\mathbf{z}) - \hat{\mathbf{X}}(\mathbf{z}))(E(\mathbf{X}|\mathbf{z}) - \hat{\mathbf{X}}(\mathbf{z}))^r | \mathbf{Z}=\mathbf{z}] \\ &= E[(\mathbf{x} - E(\mathbf{X}|\mathbf{z}))(\mathbf{X} - E(\mathbf{X}|\mathbf{z}))^r | \mathbf{Z}=\mathbf{z}] \\ &\quad + E[(E(\mathbf{X}|\mathbf{z}) - \hat{\mathbf{X}}(\mathbf{z}))(E(\mathbf{X}|\mathbf{z}) - \hat{\mathbf{X}}(\mathbf{z}))^r | \mathbf{Z}=\mathbf{z}] \end{aligned} \quad (1.8.15)$$

上式成立是由于

$$\begin{aligned} & E[(X - E(X|z))(E(X|z) - \hat{X}(z))^T | Z=z] \\ &= (E(X|z) - E(X|z))(E(X|z) - \hat{X}(z))^T \\ &= 0 \end{aligned}$$

同理 $E[(E(X|z) - \hat{X}(z))(X - E(X|z))^T | Z=z] = 0$
(1.8.15)式中

$$\begin{aligned} & E[(E(X|z) - \hat{X}(z))(E(X|z) - \hat{X}(z))^T | Z=z] \\ &= E(X|z) - \hat{X}(z)(E(X|z) - \hat{X}(z))^T \end{aligned}$$

由 § 1.3 知它总是一个非负定阵，所以由(1.8.15)得到如下的不等式

$$\begin{aligned} & E[(X - \hat{X}(z))(X - \hat{X}(z))^T | Z=z] \\ & \geq E[(X - E(X|z))(X - E(X|z))^T | Z=z] \quad (1.8.16) \end{aligned}$$

显然(1.8.15)等号成立的充分必要条件是

$$\hat{X}(z) = E(X|z)$$

即

$$\hat{X}_{MV}(z) = E(X|Z=z)$$

此即证明了(1.8.14)式。由此可见

$$\begin{aligned} E\hat{X}_{MV}(z) &= \int_{-\infty}^{\infty} E(X|Z=z)p_2(z)dz \\ &= \int_{-\infty}^{\infty} \left[\int_{-\infty}^{\infty} x p(x|z)dx \right] p_2(z)dz \\ &= \int_{-\infty}^{\infty} x \left[\int_{-\infty}^{\infty} p(x|z)p_2(z)dz \right] dx \\ &= \int_{-\infty}^{\infty} x \left[\int_{-\infty}^{\infty} p(x, z)dz \right] dx \\ &= \int_{-\infty}^{\infty} x p_1(x)dx = EX \end{aligned} \quad (1.8.17)$$

即估计量 $\hat{X}_{MV}(Z)$ 的均值等于被估计量 X 的均值，凡是具有这样性质的估计称为无偏估计。此时，最小均方误差阵 $E[X - \hat{X}_{MV}(Z)][X - \hat{X}_{MV}(Z)]^T$ 就是最优估计误差 $X - \hat{X}_{MV}(Z)$ 的方差阵

$\text{var}(\mathbf{X} - \hat{\mathbf{X}}_{\text{MV}}(\mathbf{Z}))$, 而且由(1.8.12)和(1.8.14)知

$$\begin{aligned} E[\mathbf{X} - \hat{\mathbf{X}}_{\text{MV}}(\mathbf{Z})][\mathbf{X} - \hat{\mathbf{X}}_{\text{MV}}(\mathbf{Z})]^T &= \text{var}[\mathbf{X} - \hat{\mathbf{X}}_{\text{MV}}(\mathbf{Z})] \\ &= \int_{-\infty}^{\infty} \left\{ \int_{-\infty}^{\infty} [\mathbf{x} - E(\mathbf{X}|\mathbf{z})][\mathbf{x} - E(\mathbf{X}|\mathbf{z})]^T p(\mathbf{x}|\mathbf{z}) d\mathbf{x} \right\} p_2(\mathbf{z}) d\mathbf{z} \\ &= \int_{-\infty}^{\infty} \text{var}(\mathbf{X}|\mathbf{z}) p_2(\mathbf{z}) d\mathbf{z} \end{aligned} \quad (1.8.18)$$

常把 $\hat{\mathbf{X}}_{\text{MV}}(\mathbf{z})$ 简记为 $\hat{\mathbf{X}}_{\text{MV}}$, 称它为依据量测 $\mathbf{Z}$ 的 $\mathbf{X}$ 的最小方差估计, $\text{var}(\mathbf{X} - \hat{\mathbf{X}}_{\text{MV}})$ 为它的估计误差方差阵。由于 (1.8.14) 式成立, 故有时又称 $\hat{\mathbf{X}}_{\text{MV}}$ 为 $\mathbf{X}$ 的条件均值估计。

§ 8.4 线性最小方差估计

在许多场合, 量测 $\mathbf{Z}$ 和被估计量 $\mathbf{X}$ 的概率密度未必知道, 那么上述最小方差估计就无法得到, 这时怎么办呢? 下面我们限定所求的估计 $\hat{\mathbf{X}}(\mathbf{Z})$ 必须是量测 $\mathbf{Z}$ 的线性函数

$$\hat{\mathbf{X}}(\mathbf{Z}) = \boldsymbol{\alpha} + B\mathbf{Z} \quad (1.8.19)$$

其中 $\boldsymbol{\alpha}$ 是非随机向量, 维数与 $\mathbf{X}$ 相同, B 是行数等于 $\mathbf{X}$ 的维数, 列数等于 $\mathbf{Z}$ 的维数的常值矩阵。仍然以估计的均方误差达到极小作为最优准则, 这样得到的最优估计称为线性最小方差估计。

记为 $\hat{\mathbf{X}}_{\text{LMV}}$, 其中 L 表示线性。

对于(1.8.19)的这种估计, 它的均方误差阵为

$$\begin{aligned} E[\mathbf{X} - \hat{\mathbf{X}}(\mathbf{Z})][\mathbf{X} - \hat{\mathbf{X}}(\mathbf{Z})]^T \\ = E[\mathbf{X} - \boldsymbol{\alpha} - B\mathbf{Z}][\mathbf{X} - \boldsymbol{\alpha} - B\mathbf{Z}]^T \end{aligned} \quad (1.8.20)$$

此式对任意的线性估计(1.8.19)都是成立的, 现在我们的目的是选择向量 $\boldsymbol{\alpha}$ 和矩阵 B 使(1.8.20)式达到最小, 并把这样选择到的 $\boldsymbol{\alpha}$ 和 B 分别记为 $\hat{\boldsymbol{\alpha}}$ 和 $\hat{B}$, 于是估计量

$$\hat{\mathbf{X}}_{\text{LMV}} = \hat{\boldsymbol{\alpha}} + \hat{B}\mathbf{Z} \quad (1.8.21)$$

即为 $\mathbf{X}$ 的线性最小方差估计。为了求得 $\hat{\boldsymbol{\alpha}}$ 和 $\hat{B}$, 令

$$\mathbf{b} = \boldsymbol{\alpha} - E\mathbf{X} + BE\mathbf{Z} \quad (1.8.22)$$

则由(1.8.20)和(1.8.22)有

$$\begin{aligned}
& E[\mathbf{X} - \hat{\mathbf{X}}(\mathbf{Z})][\mathbf{X} - \hat{\mathbf{X}}(\mathbf{Z})]^T \\
&= E[\mathbf{X} - \mathbf{a} - B\mathbf{Z}][\mathbf{X} - \mathbf{a} - B\mathbf{Z}]^T \\
&= E[(\mathbf{X} - E\mathbf{X}) - \mathbf{b} - B(\mathbf{Z} - E\mathbf{Z})][(\mathbf{X} - E\mathbf{X}) - \mathbf{b} - B(\mathbf{Z} - E\mathbf{Z})]^T \\
&= \text{var } \mathbf{X} + \mathbf{b}\mathbf{b}^T + B(\text{var } \mathbf{Z})B^T - \text{cov}(\mathbf{X}, \mathbf{Z})B^T - B\text{cov}(\mathbf{Z}, \mathbf{X}) \\
&= \mathbf{b}\mathbf{b}^T + [B - \text{cov}(\mathbf{X}, \mathbf{Z})(\text{var } \mathbf{Z})^{-1}](\text{var } \mathbf{Z})[B - \text{cov}(\mathbf{X}, \mathbf{Z}) \\
&\quad \cdot (\text{var } \mathbf{Z})^{-1}]^T \\
&\quad + [\text{var } \mathbf{X} - \text{cov}(\mathbf{X}, \mathbf{Z})(\text{var } \mathbf{Z})^{-1}\text{cov}(\mathbf{X}, \mathbf{Z})^T] \quad (1.8.23)
\end{aligned}$$

注意(1.8.23)中右边的头两项都是非负定阵，而第三项与 $\mathbf{b}$ 、 B 无关。显然，要使(1.8.23)式达到极小的唯一解就是选择 $\mathbf{b}$ 和 B ，使(1.8.23)式右边的头两项为零矩阵，即选择

$$\hat{\mathbf{b}} = 0 \quad (1.8.24)$$

$$\hat{B} = \text{cov}(\mathbf{X}, \mathbf{Z})(\text{var } \mathbf{Z})^{-1} \quad (1.8.25)$$

将(1.8.24)和(1.8.25)代入(1.8.22)得

$$\hat{\mathbf{a}} = E\mathbf{X} - \text{cov}(\mathbf{X}, \mathbf{Z})(\text{var } \mathbf{Z})^{-1}E\mathbf{Z} \quad (1.8.26)$$

再将(1.8.25)和(1.8.26)代入(1.8.21)，即得线性最小方差估计为

$$\begin{aligned}
\hat{\mathbf{X}}_{\text{LMV}} &= E\mathbf{X} - \text{cov}(\mathbf{X}, \mathbf{Z})(\text{var } \mathbf{Z})^{-1}E\mathbf{Z} + \text{cov}(\mathbf{X}, \\
&\quad \mathbf{Z})(\text{var } \mathbf{Z})^{-1}\mathbf{Z} \\
&= E\mathbf{X} + \text{cov}(\mathbf{X}, \mathbf{Z})(\text{var } \mathbf{Z})^{-1}(\mathbf{Z} - E\mathbf{Z}) \quad (1.8.27)
\end{aligned}$$

从而由(1.8.23)还可求得线性最小方差估计的均方误差阵为

$$\begin{aligned}
& E(\mathbf{X} - \hat{\mathbf{X}}_{\text{LMV}})(\mathbf{X} - \hat{\mathbf{X}}_{\text{LMV}})^T \\
&= \text{var } \mathbf{X} - \text{cov}(\mathbf{X}, \mathbf{Z})(\text{var } \mathbf{Z})^{-1}\text{cov}(\mathbf{X}, \mathbf{Z})^T \quad (1.8.28)
\end{aligned}$$

这里使用的求(1.8.20)式的极小值的方法是称为配平方法。

如果把最优准则，由原来使均方误差阵(1.8.20)达到极小，改为使均方误差阵(1.8.20)的迹达到极小，即估计的均方误差的各分量之和

$$\text{Tr } E(\mathbf{X} - \mathbf{a} - B\mathbf{Z})(\mathbf{X} - \mathbf{a} - B\mathbf{Z})^T = E(\mathbf{X} - \mathbf{a} - B\mathbf{Z})^T(\mathbf{X} - \mathbf{a} - B\mathbf{Z}) \quad (1.8.29)$$

达到极小，那么，最优估计是什么呢？这时我们可以采用令其导

数等于零求极值的解法。因为我们的目的是要求出使(1.8.29)取极小值的 α 和 B ，记为 α^* 和 B^* ，为止，将(1.8.29)式分别对 α 和 B 求导数，由于导数运算与求均值运算可以交换，得到下列两个等式

$$\begin{aligned} & \frac{\partial}{\partial \alpha} E(X - \alpha - BZ)^T (X - \alpha - BZ) \\ &= E \left[\frac{\partial}{\partial \alpha} \{ (X - \alpha - BZ)^T (X - \alpha - BZ) \} \right] \\ &= 2(\alpha + BEZ - EX) \end{aligned} \quad (1.8.30)$$

$$\begin{aligned} & \frac{\partial}{\partial B} E(X - \alpha - BZ)^T (X - \alpha - BZ) \\ &= E \left[\frac{\partial}{\partial B} \{ (X - \alpha - BZ)^T (X - \alpha - BZ) \} \right] \\ &= 2[\alpha(EZ)^T + BEZZ^T - EXZ^T] \end{aligned} \quad (1.8.31)$$

令(1.8.30)和(1.8.31)等于零，即可解出 α^* 和 $\hat{B}^*$ 。将它代入(1.8.30)且等于零，得到

$$\alpha^* = EX - \hat{B}^* EZ \quad (1.8.32)$$

将 α^* 和 $\hat{B}^*$ 代入(1.8.31)且等于零，得到

$$(EX - \hat{B}^* EZ)(EZ)^T + \hat{B}^* EZZ^T - EXZ^T = 0$$

故 $\hat{B}^*[EZZ^T - (EZ)(EZ)^T] - [EXZ^T - (EX)(EZ)^T] = 0$
可表为

$$\hat{B}^* \text{var } Z - \text{cov}(X, Z) = 0$$

由此解得

$$\hat{B}^* = \text{cov}(X, Z)(\text{var } Z)^{-1} \quad (1.8.33)$$

将它代入(1.8.32)得

$$\alpha^* = EX - \text{cov}(X, Z)(\text{var } Z)^{-1} EZ \quad (1.8.34)$$

由(1.8.34)、(1.8.33)与(1.8.26)、(1.8.27)比较可看出，在线性估计中，以均方误差阵各分量之和达到极小为最优准则与以均方误差阵达极小为准则所得的估计是完全一致的，即

$$\hat{\alpha} = \alpha^*, \quad \hat{B} = \hat{B}^*.$$

如果设被估计的随机向量 X 和量测随机向量 Z 有联合正态

概率密度, 则由 § 4.3 的(1.4.19) 和 (1.4.20) 知, 在给定 $Z=z$ 的条件下, X 的条件均值和条件方差阵分别为

$$E(X|z) = EX + \text{cov}(X, Z)(\text{var } Z)^{-1}(z - EZ)$$

$$\text{var}(X|z) = \text{var } X - \text{cov}(X, Z)(\text{var } Z)^{-1}\text{cov}(X, Z)^T.$$

对于 X 的最小方差估计有

$$\hat{X}_{MV} = \hat{X}_{MV}(Z) = E(X|Z)$$

这等式与(1.8.27)式完全一致。所以得到一个很重要的结论: 当被估计量 X 与量测 Z 的联合分布为正态时, X 的最小方差估计等于它的线性最小方差估计, 即有

$$\hat{X}_{MV} = \hat{X}_{LMV} \quad (1.8.35)$$

而它的误差方差阵即为在给定 $Z=z$ 的条件下, X 的条件方差阵。也就是说, 正态分布时, 在最小方差估计的原则下, 在量测 Z 的线性函数范围内求得最优估计, 它也必定是在量测 Z 的一切函数中最优的。

下面讨论 $\hat{X}_{LMV}$ 的性质, 首先由(1.8.27)有

$$E \hat{X}_{LMV} = EX + \text{cov}(X, Z)(\text{var } Z)^{-1}(EZ - EZ) = EX \quad (1.8.36)$$

称 $\hat{X}_{LMV}$ 是 X 的无偏估计。估计误差为 $\tilde{X} = X - \hat{X}_{LMV}$, $E \tilde{X} = 0$, 估计误差方差阵为 $E \tilde{X} \tilde{X}^T$ 。其次, 估计误差可表为

$$\tilde{X} = X - \hat{X}_{LMV} = (X - EX) - \text{cov}(X, Z)(\text{var } Z)^{-1}(Z - EZ)$$

可以得到

$$\begin{aligned} E \tilde{X} Z^T &= E \tilde{X} (Z - EZ)^T \\ &= E \{ [(X - EX) - \text{cov}(X, Z)(\text{var } Z)^{-1}(Z - EZ)] (Z - EZ)^T \} \\ &= \text{cov}(X, Z) - \text{cov}(X, Z)(\text{var } Z)^{-1}(\text{var } Z) = 0 \end{aligned} \quad (1.8.37)$$

说明 $\tilde{X}$ 与 Z 为不相关。而 $E \tilde{X} Z^T = 0$, 借助于几何的语言, 称 $\tilde{X}$ 与 Z 正交。(1.8.37)式表明, 原来 X 与 Z 不正交, 但从 X 中减去一个关于 Z 的线性最小方差估计 $\hat{X}_{LMV}$ 后(得 $\tilde{X}$), 其就与 Z 正交,

因此可以说, $\hat{X}_{LMV}$ 是 X 在由 Z 的分量所生成的线性空间上的投影, 简称 $\hat{X}_{LMV}$ 是 X 在 Z 上的投影, 记作

$$\hat{X}_{LMV} = \hat{E}(X|Z)$$

从几何的观点, 把线性最小方差估计看作为被估计量 X 在量测 Z 上的投影, 这在时间序列分析的预报理论中是很有用的。当 X 与 Z 为联合正态分布的情形, 投影就是条件均值, 即

$$\hat{X}_{LMV} = \hat{E}(X|Z) = E(X|Z) \quad (1.8.38)$$

以上我们给出了三种统计估计方法。极大似然估计要求事先了解被估计随机向量的概率分布类型, 例如预先知道为正态分布, 但参数未知需要待估。最小方差估计对于概率分布的要求有所放宽, 只需知道它们的一、二阶矩就可以了。最小二乘估计则对随机向量根本不作任何统计假定。这三种估计准则对于统计假设要求渐次减少。因此, 它们的估计精度自然也就渐差。本书中, 极大似然估计和最小二乘估计用于依据量测到的随机向量的样本去估计未知参数以建立模型。最小方差估计或线性最小方差估计用于依据随机向量的样本对另一随机向量作出估计, 因此主要用于预报问题。

§ 8.5 参数估计的优效性

在时间序列分析中, 参数估计是十分重要的课题。所谓参数估计, 确切地说, 是根据某种原则, 由随机序列 (或随机向量) 的长度为 N 的样本 $X_1, X_2, \dots, X_N$, 构造函数 $\hat{\beta}_N = \hat{\beta}(X_1, X_2, \dots, X_N)$ 来估计未知参数向量 $\beta = (\beta_1, \beta_2, \dots, \beta_k)^T$, 为了记号的方便, 我们还常常略去下标 N , 把 $\hat{\beta}_N$ 记为 $\hat{\beta}$ 。衡量估计量 $\hat{\beta}$ 与真值 β 的接近程度, 即衡量参数估计的优劣, 是一个很重要的问题, 也就是说, 首先要建立估计量好坏的标准, 为此, 需要引进以下的概念:

1. 无偏性与渐近无偏性: 若估计量 $\hat{\beta}$ 满足

$$E \hat{\beta} = \beta \quad (1.8.39)$$

称 $\hat{\beta}$ 为 β 的无偏估计。

若估计量 $\hat{\beta}_N$ 不满足无偏性, 但有

$$\lim_{N \rightarrow \infty} E \hat{\beta}_N = \hat{\beta} \quad (1.8.40)$$

称 $\hat{\beta}_N$ 为 β 的渐近无偏估计。

例: 设 $\{x_i\}$ 为零均值平稳序列, $x_1, x_2, \dots, x_N$ 是它的长度为 N 的样本。令

$$\hat{\gamma}'_t = \frac{1}{N-t} \sum_{i=1}^{N-t} x_{i+t} x_i \quad t=0, 1, 2, \dots, N-1 \quad (1.8.41)$$

则有

$$E \hat{\gamma}'_t = \frac{1}{N-t} \sum_{i=1}^{N-t} E x_{i+t} x_i = \frac{1}{N-t} \sum_{i=1}^{N-t} \gamma_i = \gamma_t \\ t=0, 1, 2, \dots, N-1 \quad (1.8.42)$$

所以 $\hat{\gamma}'_t$ 是 γ_t 的无偏估计。

另外, 设估计量为

$$\hat{\gamma}_t = \frac{1}{N} \sum_{i=1}^{N-t} x_{i+t} x_i \quad t=0, 1, 2, \dots, N-1 \quad (1.8.43)$$

则有

$$E \hat{\gamma}_t = \frac{1}{N} \sum_{i=1}^{N-t} E x_{i+t} x_i = \frac{N-t}{N} \gamma_t \quad t=1, 2, \dots, N-1$$

$\hat{\gamma}_t$ 不是 γ_t 的无偏估计, 但它满足

$$\lim_{N \rightarrow \infty} E \hat{\gamma}_t = \lim_{N \rightarrow \infty} \frac{N-t}{N} \gamma_t = \gamma_t \quad t=1, 2, \dots, N-1 \quad (1.8.44)$$

故 $\hat{\gamma}_t$ 是 γ_t 的渐近无偏估计。

在许多情况下, 寻找无偏估计是困难的, 但较容易找到渐近无偏估计。

2. 相容性: 若样本长度 N 趋于无穷时, 估计量 $\hat{\beta}_N$ 以概率收

敛于 β , 即对于任意小的 $\varepsilon > 0$, 有

$$\lim_{N \rightarrow \infty} P(\|\hat{\beta}_N - \beta\| > \varepsilon) = 0 \quad (1.8.45)$$

称 $\hat{\beta}_N$ 为 β 的弱相容估计 (或称弱一致估计), 记为 $\hat{\beta}_N \xrightarrow[N \rightarrow \infty]{P} \beta$ 。

若样本长度 N 趋于无穷时, $\hat{\beta}_N$ 以概率为 1 地收敛于 β , 即对于任意小的 $\varepsilon > 0$, 有

$$P(\lim_{N \rightarrow \infty} \|\hat{\beta}_N - \beta\| > \varepsilon) = 0 \quad (1.8.46)$$

称 $\hat{\beta}_N$ 为 β 的强相容估计, 记为 $\hat{\beta}_N \xrightarrow[N \rightarrow \infty]{a.s.} \beta$ 。

(a.s 是 almost surely 的缩写)

这两种收敛性的概率意义在数学理论上的差异是很大的, 但在实用上没多大区别, 对于概率论不太熟悉的读者不必过多地追究, 此两种极限的直观含义是, 当 N 逐渐增大时, $\hat{\beta}_N$ 与 β 之间距离越来越趋于零。

3. 优效性与渐近优效性: 在通常情况下, 参数估计的误差方差阵 $E\tilde{\beta}\tilde{\beta}^T$ ($\tilde{\beta} \triangleq \hat{\beta} - \beta$) 总是有下界的, 即成立所谓 Cramer-Rao 不等式

$$\begin{aligned} E(\hat{\beta} - \beta)(\hat{\beta} - \beta)^T &\geq \left[E\left(\frac{\partial \log p(\mathbf{X}|\beta)}{\partial \beta}\right) \right. \\ &\quad \left. \cdot \frac{\partial \log p(\mathbf{X}|\beta)}{\partial \beta^T} \right]^{-1} \\ &\triangleq J_N^{-1}(\beta) \end{aligned} \quad (1.8.47)$$

其中 $p(\mathbf{X}|\beta)$ 为带有参数为 β 的 $X_1, X_2, \dots, X_N$ 的联合概率密度。我们称 $J_N(\beta)$ 为信息阵, 它是 k 阶方阵, 而称 $J_N^{-1}(\beta)$ 为 Cramer-Rao 下界, 任何估计误差的方差阵都不可能小于它。

如果有估计量 $\hat{\beta}$ 能使 (1.8.47) 式中等号成立, 称 $\hat{\beta}$ 为 β 的优效估计, 也就是说, 从统计观点看来, 这个估计也不能再改进了。

因此, 如果有估计量 $\hat{\beta}$ 能使如下极限关系式成立

$$\lim_{N \rightarrow \infty} J_N^{\frac{1}{2}}(\beta) [E(\hat{\beta} - \beta)(\hat{\beta} - \beta)^T] J_N^{\frac{1}{2}}(\beta) = I \quad (1.8.48)$$

其中 I 表示 k 阶单位阵, 则称 $\hat{\beta}$ 为 β 的渐近优效估计。由 (1.8.48) 知, 渐近优效估计就是渐近最小方差估计。

4. 渐近正态性: 设 $\hat{\beta}$ 是 β 的估计量, 若存在一个矩阵列 $\{B_N\}$, 当 N 趋于无穷时, $B_N B_N^T$ 的主对角线上的元都无限增大, 而且使 $B_N(\hat{\beta} - \beta)$ 的联合概率分布 $F_N(x)$ 收敛于正态分布 $\mathcal{N}(0, I)$, 则称 $\hat{\beta}$ 具有渐近正态性, 简记为

$$B_N(\hat{\beta} - \beta) \sim \mathcal{N}(0, I) \quad (1.8.49)$$

在具体使用参数估计方法时, 我们总希望所获得的估计量具有上述各种性质。也就是说, 这些性质是检验估计优劣的重要标准。比如, 估计具有优效性或渐近优效性, 不仅可使我们知道估计误差已达到极小程度, 而且可以根据 Cramer-Rao 下界具体地算出估计误差。又如, 估计具有渐近正态性就便于我们建立各种检验手段, 以判断关于模型的假定的合理性。这些问题在以后章节中还要具体地讨论。

§ 9 线性差分方程

在时间序列的时域分析中, 线性差分方程是很重要的工具。本节将简略地介绍它的一般形式和求解公式。

§ 9.1 确定性的线性差分方程*

设 $\{u_t, t=0, \pm 1, \dots\}$ 为实数列, 若满足如下关系式

$$u_t - \varphi_1 u_{t-1} - \dots - \varphi_p u_{t-p} = h(t) \quad (1.9.1)$$

其中 $\varphi_1, \varphi_2, \dots, \varphi_p$ 为实数, $h(t)$ 为 t 的已知实函数, 则称 (1.9.1) 式为 $\{u_t\}$ 所满足的线性差分方程。特别, 若

* 此节可参阅 B.P. 拉斯著, 卢伯英译, 科学出版社 1983 年出版的“信号、系统和控制”一书第七章 7.4 节。

$$u_t - \varphi_1 u_{t-1} - \cdots - \varphi_p u_{t-p} = 0 \quad (1.9.2)$$

则称 $\{u_t\}$ 满足齐次线性差分方程。为了简化线性差分方程的表达形式和计算步骤,我们引进记号 B ,称 B 为后移算子, B 满足 $Bu_t = u_{t-1}$ 。算子 B 有如下性质:

- i) $B^0 u_t = u_t$, 即 $B^0 \equiv 1$ 称 B^0 为恒等算子。
- ii) 若 c 是某个常数, 则 $B(cu_t) = cBu_t = cu_{t-1}$ 。
- iii) 对任意两个序列 $\{u_t\}$ 和 $\{v_t\}$ 有

$$B(u_t \pm v_t) = Bu_t \pm Bv_t = u_{t-1} \pm v_{t-1}。$$
- iv) $B^n u_t = B^{n-1}(Bu_t) = B^{n-1}u_{t-1} = \cdots = u_{t-n}$ 。
- v) 由 iv) 得到

$$\left(\sum_{k=1}^n c_k B^k \right) u_t = \sum_{k=1}^n c_k B^k u_t = \sum_{k=1}^n c_k u_{t-k}。$$

由此可见, (1.9.1) 和 (1.9.2) 可由后移算子 B 表示为

$$-\left(\sum_{k=0}^p \varphi_k B^k \right) u_t = h(t) \quad (1.9.3)$$

和
$$\left(\sum_{k=0}^p \varphi_k B^k \right) u_t = 0 \quad (1.9.4)$$

其中 $\varphi_0 = -1$ 。为了简单起见, 记

$$\varphi(B) \triangleq - \sum_{k=0}^p \varphi_k B^k \quad (1.9.5)$$

今后称方程 $\sum_{k=0}^p \varphi_k \lambda^{p-k} = 0$ 为相应于 (1.9.3) 的特征方程, 它和方

程 $\sum_{k=0}^p \varphi_k B^k = 0$ 的根 (这时把 B 当成变量) 是互为倒数的。为了节

省记号, 我们有时把 B 作为后移算子, 有时作为方程中的变量, 根据式子含意自明。

我们首先讨论齐次差分方程 (1.9.2) 的求解方法, 设 $\lambda_1, \lambda_2, \cdots, \lambda_p$ 为相应特征方程 $\sum_{k=0}^p \varphi_k \lambda^{p-k} = 0$ 的根, 根据根的不同性质,

下面分三种情形加以讨论:

i) $\lambda_1, \lambda_2, \dots, \lambda_p$ 为不同的实根, 则(1.9.2) 的解为

$$u_t = c_1 \lambda_1^t + c_2 \lambda_2^t + \dots + c_p \lambda_p^t \quad (1.9.6)$$

其中 $c_1, c_2, \dots, c_p$ 为任意实常数。

事实上, 我们只须验证(1.9.6)式右端确是方程 (1.9.2) 的解即可。将(1.9.6)右端代入(1.9.2)的左端得

$$\begin{aligned} & \varphi_0 \sum_{k=1}^p c_k \lambda_k^t + \varphi_1 \sum_{k=1}^p c_k \lambda_k^{t-1} + \dots + \varphi_p \sum_{k=1}^p c_k \lambda_k^{t-p} \\ &= \sum_{k=1}^p c_k \lambda_k^{t-p} \left(\sum_{i=0}^p \varphi_i \lambda_k^{p-i} \right) = 0 \end{aligned}$$

所以结论成立。

ii) $\lambda_1, \lambda_2, \dots, \lambda_p$ 中有相同的实根(即有重根), 不妨设 $\lambda_1 = \lambda_2 = \dots = \lambda_d$ 而 $\lambda_d, \lambda_{d+1}, \dots, \lambda_p$ 为两两不相等, 则(1.9.2)的解为

$$u_t = (c_1 + c_2 t + \dots + c_d t^{d-1}) \lambda_1^t + c_{d+1} \lambda_{d+1}^t + \dots + c_p \lambda_p^t \quad (1.9.7)$$

其中 $c_1, c_2, \dots, c_p$ 为任意常数。

我们以 $p=2$ 来验证, (1.9.2) 的特征方程为

$$\lambda^2 - \varphi_1 \lambda - \varphi_2 = 0$$

若 $\varphi_2 = -\left(\frac{\varphi_1}{2}\right)^2$, 则有重根为 $\lambda_1 = \lambda_2 = \frac{\varphi_1}{2}$, 将 $u_t = (c_1 + c_2 t) \lambda_1^t$ 代入(1.9.2)式左端, 得

$$\begin{aligned} & u_t - \varphi_1 u_{t-1} - \varphi_2 u_{t-2} \\ &= (c_1 + c_2 t) \lambda_1^t - \varphi_1 [c_1 + c_2(t-1)] \lambda_1^{t-1} - \varphi_2 [c_1 + c_2(t-2)] \lambda_1^{t-2} \\ &= \lambda_1^{t-2} c_1 (\lambda_1^2 - \varphi_1 \lambda_1 - \varphi_2) + \lambda_1^{t-2} c_2 [(\lambda_1^2 - \varphi_1 \lambda_1 - \varphi_2)t + \varphi_1 \lambda_1 + 2\varphi_2] = c_2 (\varphi_1 \lambda_1 + 2\varphi_2) \lambda_1^{t-2} \\ &= c_2 \left(\frac{\varphi_1^2}{2} + 2\varphi_2 \right) \lambda_1^{t-2} \\ &= 2c_2 \left(\frac{\varphi_1^2}{4} + \varphi_2 \right) \lambda_1^{t-2} = 0 \end{aligned}$$

故 $u_i = (c_1 + c_2 t) \lambda_1^i$ 确实为 (1.9.2) 的解。

iii) $\lambda_1, \lambda_2, \dots, \lambda_p$ 中有复根, 由于方程 (1.9.2) 中的系数 $\varphi_1, \varphi_2, \dots, \varphi_p$ 为实数, 故复根一定呈共轭对出现, 此时方程的解 u_i 中必含正弦余弦项。再以 $p = 2$ 为例验证。此时特征方程的根为

$$\lambda_1 = \frac{\varphi_1 + \sqrt{\varphi_1^2 + 4\varphi_2}}{2}, \quad \lambda_2 = \frac{\varphi_1 - \sqrt{\varphi_1^2 + 4\varphi_2}}{2}$$

且 $\varphi_1^2 + 4\varphi_2 < 0$, 因此, λ_1 和 λ_2 为共轭复根, 记为

$$\lambda_1 = a + ib = r e^{i\omega}, \quad \lambda_2 = a - ib = r e^{-i\omega}$$

其中 $a = \frac{\varphi_1}{2}$, $b = \frac{1}{2} \sqrt{-(\varphi_1^2 + 4\varphi_2)}$, $r = \sqrt{a^2 + b^2} = \sqrt{-\varphi_2}$,

$$\omega = \operatorname{tg}^{-1} \frac{b}{a} = \operatorname{tg}^{-1} \left[\frac{1}{\varphi_1} \sqrt{-(\varphi_1^2 + 4\varphi_2)} \right]$$

因此有

$$\begin{aligned} u_i &= c_1 \lambda_1^i + c_2 \lambda_2^i = r^i (c_1 e^{i i \omega} + c_2 e^{-i i \omega}) \\ &= r^i [(c_1 + c_2) \cos i \omega + i(c_1 - c_2) \sin i \omega] \end{aligned} \quad (1.9.8)$$

由于齐次线性差分方程 (1.9.2) 的解 u_i 包含有 p 个任意常数, 称为 (1.9.2) 的通解。只有它满足 p 个初始条件才能唯一地确定解。非齐次线性差分方程 (1.9.1) 的解的一般形式是由相应于 (1.9.2) 的通解加上非齐次方程 (1.9.1) 的特解。所谓 (1.9.1) 的特解是指满足

$$\varphi(B) u_i = h(t) \quad (1.9.9)$$

的任意一个解 (满足 (1.9.9) 的不只一个解, 找出任一个都行)。因为设 u'_i 是 $\varphi(B) u_i = h(t)$ 的特解, 则有

$$\varphi(B) u'_i = h(t) \quad (1.9.10)$$

(1.9.9) 减去 (1.9.10) 得

$$\varphi(B) (u_i - u'_i) = 0$$

令 $u''_i = u_i - u'_i$, 由上式知 u''_i 是齐次线性方程 (1.9.2) 的通解, 故非齐次线性方程 (1.9.1) 的解 u_i 为

$$u_i = u'_i + u''_i \quad (1.9.11)$$

它是非齐次线性方程(1.9.1)的特解与相应齐次线性方程(1.9.2)的通解之和。

§ 9.2 线性随机差分方程

若将 § 9.1 (1.9.1)式中的确定性函数 $u_t, h(t)$ 代之以统计特性已知的随机序列, 那么(1.9.1)式便可表示线性随机差分方程。本书中不讨论这样广泛的模型, 而仅限于讨论如下情形:

设 $\varphi_1, \varphi_2, \dots, \varphi_p$ 及 $\theta_1, \theta_2, \dots, \theta_q$ 为实数, 记

$$\varphi(B) = 1 - \varphi_1 B - \varphi_2 B^2 - \dots - \varphi_p B^p$$

$$\theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q$$

如果零均值的平稳序列 $\{X_t\}$ 满足如下关系式

$$\varphi(B)X_t = \theta(B)a_t, \quad (1.9.12)$$

$$t = 0, \pm 1, \dots$$

其中 $\{a_t\}$ 为白噪声序列, $E a_t^2 = \sigma_a^2$, 且当 $s > t$ 时, $E X_t a_s = 0$, 则(1.9.12)式即表示一种特殊的线性随机差分方程。根据平稳序列的谱分解理论可知, 满足(1.9.12)的平稳解 $\{X_t\}$ 是有如下有理谱密度的平稳序列

$$g(\lambda) = \sigma_a^2 \left| \frac{\theta(e^{-i2\pi\lambda})}{\varphi(e^{-i2\pi\lambda})} \right|^2. \quad (1.9.13)$$

反之具有谱密度为(1.9.13)的平稳序列 $\{X_t\}$ 一定是(1.9.12)的线性随机差分方程的平稳解, 对于上述从时间域和频率域两种不同角度得出的对应关系, 第二章中将会详细讨论。

在(1.9.12)中两边右乘 X_{t-k} 并求均值得到

$$E \varphi(B) X_t X_{t-k} = E \theta(B) a_t X_{t-k}$$

由于均值运算与算子 B 多项式可交换, 且当 $k > q$ 时, 上式右端为零, 故可得到自协方差函数满足的差分方程

$$\varphi(B)\gamma_k = 0 \quad k > q \quad (1.9.14)$$

另外, $E[\varphi(B)X_t][\varphi(B)X_{t-k}] = E\varphi(B)X_t(X_{t-k} -$

$$\varphi_1 X_{t-k-1} - \dots - \varphi_p X_{t-k-p})$$

$$= \varphi(B) E X_t (X_{t-k} - \varphi_1 X_{t-k-1} - \dots - \varphi_p X_{t-k-p})$$

$$= \varphi(B) (\gamma_k - \varphi_1 \gamma_{k+1} - \dots - \varphi_p \gamma_{k+p})$$

$$= \varphi(B)\varphi(B^{-1})\gamma_k.$$

其中 $B^{-1}X_t = X_{t+1}$, 称 B^{-1} 为向前推移算子。

综上所述, 我们得到以下两个有用的公式:

$$\begin{aligned} \text{i)} \quad E\varphi(B)X_t X_{t-k} &= \varphi(B)EX_t X_{t-k} = \varphi(B)\gamma_k. \\ \text{ii)} \quad E\{\varphi(B)X_t \varphi(B)X_{t-k}\} &= \varphi(B)\varphi(B^{-1})EX_t X_{t-k} \\ &= \varphi(B)\varphi(B^{-1})\gamma_k. \end{aligned} \quad (1.9.15)$$

我们可以把一维情形推广到多维线性随机差分方程。

设 $A_1, A_2, \dots, A_p$ 和 $M_1, M_2, \dots, M_q$ 都是实的 r 阶方阵, 定义以它们为系数的两个矩阵多项式

$$A(B) \triangleq I - A_1 B - \dots - A_p B^p \quad (1.9.16)$$

$$M(B) \triangleq I - M_1 B - \dots - M_q B^q$$

并设 $A(B)$ 与 $M(B)$ 是左既约的, 即如果

$$A(B) = H(B)A_1(B)$$

$$M(B) = H(B)M_1(B)$$

则 $|H(B)|$ 为常数, 而且 $\text{rank}(A_p, B_p) = r$, 此外还约定 $|A(B)| \neq 0, |M(B)| \neq 0$ 的根全部在单位圆外。

如果 r 维零均值平稳序列 $\{X_t\}$ 满足如下方程

$$\begin{aligned} X_t - A_1 X_{t-1} - \dots - A_p X_{t-p} &= V_t - M_1 V_{t-1} - \dots - \\ &\quad M_q V_{t-q} \end{aligned} \quad (1.9.17)$$

其中 $A_1, A_2, \dots, A_p$ 和 $M_1, M_2, \dots, M_q$ 满足上述要求, $\{V_t\}$ 为 r 维白噪声序列, 即

$$EV_t = 0, EV_t V_s^T = Q\delta_{ts}, Q > 0,$$

且当 $t < s$ 时, $EX_t V_s^T = 0$ 。称 $\{X_t\}$ 为 r 维线性随机差分方程的一个平稳解。(1.9.17)式可简记为

$$A(B)X_t = M(B)V_t \quad (1.9.18)$$

相应地 X_t 的谱密度矩阵为

$$f(\lambda) = K(e^{-i2\pi\lambda})QK^*(e^{-i2\pi\lambda})$$

其中 $K(B) = A(B)^{-1}M(B)$, $*$ 表示共轭转置。 $f(\lambda)$ 中的主对角线元为 $\{X_t\}$ 的各分量的谱密度, $f(\lambda)$ 的第 i 行第 j 列元为 $\{X_t\}$ 的第 i 分量 $\{X_t^{(i)}\}$ 与第 j 分量 $\{X_t^{(j)}\}$ 的互谱密度, $i, j = 1, 2, \dots, r$ 。

第二章 ARMA 模型

“时间序列分析”所研究的对象，是一串随时间变化而又相互关联的数字序列(动态数据)。客观世界中，这种数字序列是非常多见的，由于各自的物理背景不同，它们包含的信息和呈现的规律又是千变万化、错综复杂的。各行各业的研究和技术工作人员，正是希望通过分析这些数据，达到认识事物、掌握事物的目的。然而，如果仅从数据本身作一些简单处理(画点值图，做简单的统计分析)是远远不能满足要求的。为此，本书向科学技术工作者介绍一套处理动态数据的参数化时域分析方法，它的主要手段，是对各类型数据，用相应的数学模型去近似描述。通过对于相应模型的研究分析，可以更本质地了解数据的内在结构和复杂特性，进一步达到由表及里、控制规律和预测未来的目的。从本章开始，将逐步引入描述动态数据的数学模型，分析它们的特性，介绍用模型拟合数据的手段及更深入一些的方法和结果。

为了简化符号，从本章至第九章对于随机变量及其样本值不再用两类字母区别表示，即不再用 X 表示随机变量， x 表示样本值，而是统一地由 x 表示，读者自然能够区分，哪些地方它表示随机变量，哪些地方又代表样本值。

§ 1 ARMA 模型的定义

了解数理统计的读者，对于回归模型

$$\begin{aligned} y_t &= \beta_1 x_{1t} + \beta_2 x_{2t} + \cdots + \beta_r x_{rt} + e_t \\ t &= 1, 2, \cdots, N \end{aligned} \quad (2.1.1)$$

都很熟悉。它表示观测值 y_t 对于另一组观测值 $(x_{1t}, x_{2t}, \cdots, x_{rt})$ 的相关性。模型(2.1.1)将随机变量 y_t 分解成两部分，一部分是因变量 $(x_{1t}, x_{2t}, \cdots, x_{rt})$ ，它们所代表的是某些已知的可变化因

素(通常作为非随机因素);另一部分,则是残量 e_i ,它是由一些不可捉摸的因素及测量误差产生,通常可假定 $\{e_i\}$ 是零均值的独立序列,和前一部分相互独立。由此可见,观测序列 $\{y_i\}$ 是相互独立或不相关的。

对统计回归模型(2.1.1)作适当修改,就可得到一类新的线性模型,用以描述某些时间序列 $\{x_i\}$ (这时 $\{x_i\}$ 一般假定平稳、均值为零)

$$x_i = \varphi_1 x_{i-1} + \varphi_2 x_{i-2} + \cdots + \varphi_p x_{i-p} + a_i \quad (2.1.2)$$

$i=1, 2, \cdots, N; \{a_i\}$ 为白噪声序列

模型(2.1.1)和(2.1.2)形式非常相似,后者又是前者的直接推广,但这两类模型有着本质的区别。在统计回归模型(2.1.1)中,因变量 $(x_{1i}, x_{2i}, \cdots, x_{ri})$ 是确定性因素, $\{y_i\}$ 的统计性质由 $\{e_i\}$ 来确定,因而所描述的数字序列彼此间是相互独立的,它们都是同一总体 y 的不同次独立随机抽样值。(2.1.1)是一种静态数据模型。而模型(2.1.2)中, x_i 和 $x_{i-1}, x_{i-2}, \cdots, x_{i-p}$ 同属于时间序列 $\{x_i\}$,是序列中不同时刻的随机变量,它们彼此间有一定的相互关系,因此,(2.1.2)是一种动态数据模型。

模型(2.1.2)中描述的,是序列 $\{x_i\}$ 自身某一时刻和前 p 个时刻之间的相互关系,因此,当模型参数满足一定条件时,称作 p 阶自回归模型,记为AR(p)

与统计中的回归模型类似,AR(p)模型对于 a_i 也有两个假定,一是 $\{a_i\}$ 作为随机序列,在不同时刻互不相关,二是 a_i 和前时刻的序列观测值 $x_k (k < i)$ 不相关。如果对于某序列 $\{x_i\}$ 作(2.1.2)形式的模拟,残量序列 $\{a_i\}$ 不符合上述假定,即 $\{a_i\}$ 不是白噪声,那么,用AR(p)描述序列是不合适的。然而,这时我们可对(2.1.2)作适当修改,用如下更广泛的一类线性模型来描述

$$x_i - \varphi_1 x_{i-1} - \cdots - \varphi_p x_{i-p} = a_i - \theta_1 a_{i-1} - \cdots - \theta_q a_{i-q} \quad (2.1.3)$$

用 B^k 表示 k 步线性推移算子,即

$$B^k x_i = x_{i-k}, B^k a_i = a_{i-k}, B^k c \equiv c, c \text{ 为常数}$$

并令

$$\begin{aligned}\varphi(B) &= 1 - \varphi_1 B - \varphi_2 B^2 - \cdots - \varphi_p B^p \\ \theta(B) &= 1 - \theta_1 B - \theta_2 B^2 - \cdots - \theta_q B^q\end{aligned}\quad (2.1.4)$$

(2.1.3)式又可简写为

$$\varphi(B)x_t = \theta(B)a_t \quad (2.1.5)$$

把 $\varphi(B)$ 和 $\theta(B)$ 作为算子 B 的多项式, 通常假定它们之间不出现公共因子。

为方便起见, (2.1.5) 式中的参量常用下列形式的向量表示

$$\begin{aligned}\varphi &\triangleq (\varphi_1, \varphi_2, \cdots, \varphi_p)^T \\ \theta &\triangleq (\theta_1, \theta_2, \cdots, \theta_q)^T \\ \beta &\triangleq (\varphi^T, \theta^T)^T \\ \alpha &\triangleq (\beta^T, \sigma_a^2)^T\end{aligned}\quad (2.1.6)$$

模型(2.1.3)和(2.1.5)中, 用线性差分方程描述了 $\{x_t\}$ 和 $\{a_t\}$ 这两个序列不同时刻之间的线性关系, 因此是一种线性时序模型。

特别地, 如果序列 $\{x_t\}$ 是平稳零均值的, 且模型(2.1.5) 满足如下条件

- i) $\varphi(B)$ 与 $\theta(B)$ 无公共因子;
- ii) $\varphi_p \neq 0$ 且 $\theta_q \neq 0$;
- iii) B 算子多项式 $\varphi(B)$ 和 $\theta(B)$ 的根全在单位圆外;

iv) t 时刻的白噪声 a_t 与前时刻的 $x_{t-\tau}$ ($\tau > 0$) 不相关, 即 $E a_t x_{t-\tau} = E x_{t-\tau} a_t = 0$ ($\tau > 0$) 这一模型就称作 p 阶自回归- q 阶滑动平均混合模型, 记为 $\text{ARMA}(p, q)$ 模型。等式左边是模型的自回归部分, 非负整数 p 称为自回归阶数, 实参数 $(\varphi_1, \varphi_2, \cdots, \varphi_p)$ 称为自回归系数; 等式右边, 是模型的滑动平均部分, 非负整数 q 称为滑动平均阶数, 实参数 $(\theta_1, \theta_2, \cdots, \theta_q)$ 称为滑动平均系数。特殊地, 若 $p=0$, 模型称作纯滑动平均模型, 记为 $\text{MA}(q)$; 若 $q=0$, 模型称作纯自回归模型, 记为 $\text{AR}(p)$ 。若 $p=q=0$, 模型(2.1.3)退化为 $x_t = a_t$, 即 $\{x_t\}$ 为白噪声列。

我们称满足 $\text{ARMA}(p, q)$ 模型的序列 $\{x_t\}$ 为 $\text{ARMA}(p, q)$ 序

列,类似地,有 $AR(p)$ 序列或 $MA(q)$ 序列。在今后章节中,对于这几类序列,我们专门用 $\{w_t\}$ 表示,而且也不再注明它们作为 $ARMA(p,q)$ 序列所应满足的条件。

用 $ARMA(p,q)$ 模型描述和讨论时间序列有许多优点:

首先,在一定的条件下, $ARMA(p,q)$ 模型和具有有理谱密度的平稳零均值序列之间,存在着相互对应的关系。具体地我们有如下的定理

定理 如果 $\varphi(B)$ 没有模为 1 的因子 (即 $\varphi(e^{-i2\pi\lambda}) \neq 0$), 若 $\{w_t\}$ 为差分方程 (2.1.3) 的平稳解 (即它是平稳序列且满足 (2.1.3)), 则 $\{w_t\}$ 有如下形式的谱密度

$$g(\lambda) = \sigma_a^2 \left| \frac{\theta(e^{-i2\pi\lambda})}{\varphi(e^{-i2\pi\lambda})} \right|^2 \quad (2.1.7)$$

反之,若平稳序列 $\{w_t\}$ 有此谱密度, 则 $\{w_t\}$ 可表成 (2.1.3) 的形式。

证明 由平稳过程的谱表示可知,

$$a_t = \int_{-\frac{1}{2}}^{\frac{1}{2}} e^{i2\pi t\lambda} d\xi_a(\lambda)$$

式中 $\xi_a(\lambda)$ 为相应于 a_t 的正交增量过程, 且

$$E |d\xi_a(\lambda)|^2 = \sigma_a^2 d\lambda$$

同理

$$w_t = \int_{-\frac{1}{2}}^{\frac{1}{2}} e^{i2\pi t\lambda} d\xi_w(\lambda)$$

$$E |d\xi_w(\lambda)|^2 = dG(\lambda)$$

式中, $G(\lambda)$ 为 w_t 的谱分布函数。将以上结果代入 (2.1.3) 式, 即得

$$\int_{-\frac{1}{2}}^{\frac{1}{2}} e^{i2\pi t\lambda} \varphi(e^{-i2\pi\lambda}) d\xi_w(\lambda) = \int_{-\frac{1}{2}}^{\frac{1}{2}} e^{i2\pi t\lambda} \theta(e^{-i2\pi\lambda}) d\xi_a(\lambda)$$

由上等式及协方差函数的谱表示得

$$\int_{-\frac{1}{2}}^{\frac{1}{2}} e^{i2\pi k\lambda} |\varphi(e^{-i2\pi\lambda})|^2 dG(\lambda) = \int_{-\frac{1}{2}}^{\frac{1}{2}} e^{i2\pi k\lambda} |\theta(e^{-i2\pi\lambda})|^2 \sigma_a^2 d\lambda$$

$$k=0, \pm 1, \pm 2, \dots$$

因此

$$|\varphi(e^{-i2\pi\lambda})|^2 dG(\lambda) = |\theta(e^{-i2\pi\lambda})|^2 \sigma_a^2 d\lambda$$

由于 $\varphi(w)$ 在单位圆上无零点, 即 $\varphi(e^{-i2\pi\lambda}) \neq 0$,

故得

$$g(\lambda) = \frac{dG(\lambda)}{d\lambda} = \sigma_a^2 \left| \frac{\theta(e^{-i2\pi\lambda})}{\varphi(e^{-i2\pi\lambda})} \right|^2, \text{ 此即 (2.1.7) 式。}$$

再证逆命题。

若已知 $\{w_t\}$ 具有 (2.1.7) 式的有理谱密度, 则它的协方差函数为

$$\begin{aligned} \gamma_k &= \int_{-\frac{1}{2}}^{\frac{1}{2}} e^{i2\pi k\lambda} g(\lambda) d\lambda \\ &= \int_{-\frac{1}{2}}^{\frac{1}{2}} e^{i2\pi k\lambda} \left| \frac{\theta(e^{-i2\pi\lambda})}{\varphi(e^{-i2\pi\lambda})} \right|^2 \sigma_a^2 d\lambda \end{aligned}$$

相应地, 序列 $\{w_t\}$ 也有谱表示

$$w_t = \int_{-\frac{1}{2}}^{\frac{1}{2}} e^{i2\pi t\lambda} \frac{\theta(e^{-i2\pi\lambda})}{\varphi(e^{-i2\pi\lambda})} d\xi_a(\lambda)$$

其中 $\xi_a(\lambda)$ 为正交增量过程, $E|d\xi_a(\lambda)|^2 = \sigma_a^2 d\lambda$

由此便得到

$$\begin{aligned} w_t - \varphi_1 w_{t-1} - \dots - \varphi_p w_{t-p} &= \int_{-\frac{1}{2}}^{\frac{1}{2}} e^{i2\pi t\lambda} \theta(e^{-i2\pi\lambda}) d\xi_a(\lambda) \\ &= a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \dots - \theta_q a_{t-q} \end{aligned}$$

其中

$$a_t \triangleq \int_{-\frac{1}{2}}^{\frac{1}{2}} e^{i2\pi t\lambda} d\xi_a(\lambda)$$

$$E a_t \bar{a}_s = \sigma_a^2 \int_{-\frac{1}{2}}^{\frac{1}{2}} e^{i2\pi(t-s)\lambda} d\lambda = \begin{cases} \sigma_a^2 & t=s \\ 0 & t \neq s \end{cases}$$

即 $\{a_t\}$ 为白噪声列。定理证明完毕。

由于差分方程(2.1.3)的平稳解和有理谱密度之间存在上述一一对应关系,也由于有理谱能很好地逼近连续谱,因此,ARMA(p, q)模型用来拟合具有连续谱的平稳零均值随机序列,也是行之有效的。

模型ARMA(p, q)的另一个优点还体现在它的形式很简单,只要给定 p, q 和相应参数 $\varphi, \theta, \sigma_a^2$,模型就完全确立。因此,用这种模型对数据进行拟合是比较方便的。

最后,模型ARMA(p, q)便于分析数据的结构和内在性质,也便于在最小方差的意义下进行最佳预报和控制。

§ 2 ARMA模型的等价形式

ARMA(p, q)模型不仅可由(2.1.3)式来表示,还可表成另外两种经过某种线性变换而得的等价形式,一种叫做传递形式,一种称为逆转形式。这三种不同的等价形式,可从不同的角度揭示由它们描述的平稳序列的内在特性。下面分别进行讨论。

§ 2.1 传递形式和格林函数

ARMA(p, q)模型可以经过线性变换,将 w_t 表示成既往的白噪声 a_t 的加权求和形式

$$w_t = \sum_{k=0}^{\infty} G_k a_{t-k} = G(B) a_t \quad (2.2.1)$$

其中

$$G(B) = \sum_{j=0}^{\infty} G_j B^j, G_0 = 1 \quad (2.2.2)$$

且 G_j 是负指数下降的。

线性模型ARMA(p, q)的这种等价形式称为模型的传递形式。式中的 $G_j, j=1, 2, \dots$ 称为格林函数。如果ARMA($p,$

g)具有(2.2.1)式的等价形式,就表明平稳序列 $\{w_t\}$ 可由现时刻以前的白噪声(输入随机冲量)通过系统 $G(B)$ 作用而生成。也就是说, $\{w_t\}$ 是物理可实现的。可以证明,当 $\varphi(B)$ 没有模为1的根时, $\{w_t\}$ 物理可实现的充分必要条件是 $\varphi(B)$ 的根全部在 B 平面的单位圆外。下面就来证明这个结论。

证明 为了证明方便起见,假设 $\varphi(B)$ 的根都是单根情形,重根情形的讨论是完全类似的。

设 $\lambda_1, \lambda_2, \dots, \lambda_p$ 是 $\varphi(B)$ 的 p 个单根,且

$$|\lambda_1| > |\lambda_2| > \dots > |\lambda_k| > 1 > |\lambda_{k+1}| > \dots > |\lambda_p|$$

将 $\theta(B)/\varphi(B)$ 化成整式和真有理分式的和,即

$$\frac{\theta(B)}{\varphi(B)} = \theta'(B) + \frac{\theta''(B)}{\varphi(B)}$$

$\theta''(B)$ 的次数低于 p 。于是

$$\begin{aligned} \frac{\theta''(B)}{\varphi(B)} &= \sum_{i=1}^p \frac{A_i}{\lambda_i - B} = \sum_{i=1}^k \frac{A_i}{\lambda_i \left(1 - \frac{B}{\lambda_i}\right)} - \sum_{i=k+1}^p \frac{A_i}{B \left(1 - \frac{\lambda_i}{B}\right)} \\ &= \sum_{i=1}^k \frac{A_i}{\lambda_i} \sum_{v=0}^{\infty} \left(\frac{B}{\lambda_i}\right)^v - \sum_{i=k+1}^p A_i \sum_{v=0}^{\infty} \lambda_i^v B^{-(v+1)} \\ &= \sum_{v=0}^{\infty} \left(\sum_{i=1}^k \frac{A_i}{\lambda_i^{v+1}} \right) B^v - \sum_{v=0}^{\infty} \left(\sum_{i=k+1}^p A_i \lambda_i^v \right) B^{-(v+1)} \end{aligned}$$

由平稳序列的谱表示得

$$\begin{aligned} w_t &= \int_{-\frac{1}{2}}^{\frac{1}{2}} e^{i2\pi t\lambda} \frac{\theta(e^{-i2\pi\lambda})}{\varphi(e^{-i2\pi\lambda})} d\xi_a(\lambda) \\ &= \int_{-\frac{1}{2}}^{\frac{1}{2}} e^{i2\pi t\lambda} \left[\theta'(e^{-i2\pi\lambda}) + \sum_{v=0}^{\infty} \left(\sum_{i=1}^k \frac{A_i}{\lambda_i^{v+1}} \right) e^{-i2\pi v\lambda} \right. \\ &\quad \left. - \sum_{v=0}^{\infty} \left(\sum_{i=k+1}^p A_i \lambda_i^v \right) e^{i2\pi(v+1)\lambda} \right] d\xi_a(\lambda) \end{aligned}$$

由于 $|\lambda_i| \neq 1$,被积函数在包含单位圆周而不包含 λ_i 的一个闭环上一致收敛,因此积分可与求和号交换,于是上式得

$$w_i = \theta'(B)a_i + \sum_{v=0}^{\infty} \left(\sum_{j=1}^k A_j \lambda_j^{-(v+1)} \right) a_{i-v} - \sum_{v=0}^{\infty} \left(\sum_{j=k+1}^p A_j \lambda_j^v \right) a_{i+v+1} \quad (2.2.3)$$

由于 $|\lambda_j| > 1$, 当 $j \leq k$ 及 $|\lambda_j| < 1$, 当 $j > k$, 上式两个级数的系数都是负指数下降的, 因此, $\{w_i\}$ 由 (2.2.3) 表示是有意义的。显然, 如果 $\varphi(B)$ 没有单位圆内的根 (即 $k \equiv p$), 则 (2.2.3) 式为

$$w_i = \theta'(B)a_i + \sum_{v=0}^{\infty} \left(\sum_{j=1}^p A_j \lambda_j^{-(v+1)} \right) a_{i-v} = \sum_{v=0}^{\infty} G_v a_{i-v}$$

其中, $\{G_i\}$ 是负指数下降的, 因而 w_i 是物理可实现的。这就证明了定理的充分性。定理的必要性显然成立。

格林函数 G_i 可以通过形式算子的运算, 比较等式两边 B 的同次幂的系数而求得。

由 $\varphi(B)w_i = \theta(B)a_i$ 及 $w_i = G(B)a_i$, 形式地可得

$$\varphi(B)G(B) = \theta(B)$$

比较等式两边 B^l 的系数, 可以得到

$$\sum_{j=0}^l \varphi_j^* G_{l-j} = \theta_l^*, \quad l = 1, 2, \dots \quad (2.2.4)$$

这里约定 $\varphi_0 = -1, G_0 = 1$

$$\varphi_i^* = \begin{cases} \varphi_i & i \leq p \\ 0 & i > p \end{cases} \quad \theta_i^* = \begin{cases} \theta_i & i \leq q \\ 0 & i > q \end{cases} \quad (2.2.5)$$

由此可见, G_i 可从 $l=1$ 开始依次递推计算, 而且对任意 l 全是实数。

特殊地, 对于纯滑动平均模型 $MA(q)$, 由于 $\varphi(B) \equiv 1$, $G(B) \equiv \theta(B)$, 这时, 模型本身就是一种特殊的传递形式

$$G_i = \begin{cases} -\theta_i & i \leq q \\ 0 & i > q \end{cases} \quad (2.2.6)$$

由 (2.2.4) 和 (2.2.5) 式可见, 当 $l \geq \max(p, q+1)$ 时, 格林函数满足如下形式的齐次差分方程

$$\varphi(B)G_l=0$$

即

$$G_l - \varphi_1 G_{l-1} - \cdots - \varphi_p G_{l-p} = 0 \quad (2.2.7)$$

由第一章 §9 差分方程的求根理论得知, 如果 $\lambda_1, \lambda_2, \dots, \lambda_p$ 是 $\varphi(B)$ 的根, 那么 G_l 可由 $\lambda_1, \lambda_2, \dots, \lambda_p$ 的负指数幂线性组合表示。因此, 如果 $\varphi(B)$ 的根全在 B 平面的单位圆外 (即 $|\lambda_j| > 1, 1 \leq j \leq p$), 那么, G_l 显然是负指数下降的, 因此, 存在正实常数 g_1, g_2 , 使

$$|G_l| < g_2 e^{-g_1 l} \quad (2.2.8)$$

即 G_l 可被负指数函数控制。

G_l 负指数下降的性质保证了当 l 趋于无穷时, $|G_l|$ 依负指数律趋于零。因此, a_l 作为随机输入冲量, 对于系统的影响是随时间的推移以负指数律衰减的。衰减的速度和方式, 完全由 $|\lambda_j|$ 的大小和它在 B 平面内的分布特性而决定。由此可见, 如果将模型 $\text{ARMA}(p, q)$ 的传递形式看成一个动态系统, 那么, $\varphi(B)$ 的根在 B 平面内的分布特性就反映了动态系统的稳定程度。显然, 只有当 $\varphi(B)$ 的根全在单位圆外 (物理可实现) 时, 系统对于序列 $\{w_l\}$ 才能实现稳定地向前递推。

下面, 我们给出几个低阶模型的格林函数和传递形式

1. AR(1) 模型: $w_l - \varphi_1 w_{l-1} = a_l$

由于 $\varphi(B)G(B) = \theta(B) \equiv 1$, 可见

$$G(B) = \varphi^{-1}(B) = (1 - \varphi_1 B)^{-1} = \sum_{j=0}^{\infty} \varphi_1^j B^j$$

$$G_j = \varphi_1^j, \quad j = 0, 1, 2, \dots \quad (2.2.9)$$

显然, 当 $|\varphi_1| < 1$ 时, $G(B)$ 作为 B^j 的形式幂级数是收敛的。模型的传递形式为

$$w_l = \sum_{j=0}^{\infty} \varphi_1^j a_{l-j}$$

2. AR(2) 模型: $w_l - \varphi_1 w_{l-1} - \varphi_2 w_{l-2} = a_l$

$$\varphi(B) = 1 - \varphi_1 B - \varphi_2 B^2, \quad \theta(B) = 1.$$

由于

$$\varphi(B)G(B) = \theta(B) = 1,$$

比较等式两端 B^j 的系数,得如下关于 G_j 的递推关系式

$$\begin{aligned} G_0 &= 1, \quad G_1 = -\varphi_1, \\ G_j &= \varphi_1 G_{j-1} + \varphi_2 G_{j-2} \quad j \geq 2 \end{aligned} \quad (2.2.10)$$

3. ARMA(1,1) 模型: $w_t - \varphi_1 w_{t-1} = a_t - \theta_1 a_{t-1}$

$$\varphi(B) = 1 - \varphi_1 B, \quad \theta(B) = 1 - \theta_1 B$$

由 $(1 - \varphi_1 B)G(B) = 1 - \theta_1 B$ 两边比较 B^j 系数,得

$$G_0 = 1, \quad G_j = \varphi_1^{j-1}(\varphi_1 - \theta_1) \quad j \geq 1 \quad (2.2.11)$$

另外,对 B 算子形式地展开幂级数

$$\begin{aligned} G(B) &= (1 - \varphi_1 B)^{-1}(1 - \theta_1 B) = (1 - \theta_1 B) \sum_{i=0}^{\infty} \varphi_1^i B^i \\ &= 1 + \sum_{i=1}^{\infty} \varphi_1^{i-1}(\varphi_1 - \theta_1) B^i \end{aligned}$$

也可得到(2.2.11)中的结果。

§ 2.2 逆转形式和逆函数

§ 2.1 中介绍的 ARMA 模型的传递形式,是将随机序列 $\{w_t\}$ 通过既往的白噪声 a_t 加权求和来表示。现在,我们来讨论一种相反的等价形式,即由随机序列的加权和来表示白噪声序列

$$a_t = w_t - \sum_{i=1}^{\infty} I_i w_{t-i} = I(B)w_t \quad (2.2.12)$$

式中

$$I(B) = 1 - \sum_{i=1}^{\infty} I_i B^i = - \sum_{i=0}^{\infty} I_i B^i, \quad I_0 = -1 \quad (2.2.13)$$

且 I_i 满足负指数下降的性质。

线性模型 ARMA(p, q)的这种等价形式称为模型的逆转形式。式中的 $I_i, i=1, 2, \dots$ 称为逆函数。

模型的逆转形式反映了随机序列现时刻和以往各时刻之间的

关系。类似于§2.1,也可以证明,模型能够表示成逆转形成的充分必要条件是 $\theta(B)$ 的根全在单位圆外。这时,称模型具有可逆性

逆函数 I_l 也可以通过形式算子运算,对等式两端的 B 的同次幂比较系数而求得。

由 $\varphi(B)w_t = \theta(B)a_t$ 及 $a_t = I(B)w_t$
形式地可得到 $\varphi(B) = \theta(B)I(B)$
比较等式两边 B^l 的系数,则有

$$I_l = \varphi_l^* + \sum_{j=0}^{l-1} I_j \theta_{l-j}^*, \quad l=1,2,\dots \quad (2.2.14)$$

这里约定 $I_0 = -1$, φ_l^* , θ_l^* 定义同(2.2.5)。

特殊地,对于纯自回归模型,由于 $\theta(B) \equiv 1$, $\varphi(B) \equiv I(B)$, 模型本身就是一种特殊的逆转形式

$$I_l = \begin{cases} \varphi_l & l \leq p \\ 0 & l > p \end{cases} \quad (2.2.15)$$

由(2.2.14)和(2.2.5)可见,当 $l \geq \max(p+1, q)$ 时, I_l 满足如下的齐次差分方程

$$\theta(B)I_l = 0 \quad (2.2.16)$$

类似于格林函数的讨论,可得到如下完全平行的结论,即如果 $\theta(B)$ 的根模全大于1(即根全在单位圆外),那么 I_l 可以被负指数控制。即存在正实常数 g_1, g_2 ,使

$$|I_l| < g_2 e^{-g_1 l} \quad (2.2.17)$$

注意,在传递形式中, $G(B) = 1 + \sum_{j=1}^{\infty} G_j B^j$,而在逆转形式中,

$$I(B) = 1 - \sum_{l=1}^{\infty} I_l B^l, \text{ 这种符号上的差异是为了今后讨论预报等}$$

问题的方便。

下面,给出几种低阶模型的逆函数和逆转形式

1. MA(1) 模型: $w_t = (1 - \theta_1 B)a_t$

$$I(B) = (1 - \theta_1 B)^{-1} = \sum_{i=0}^{\infty} \theta_1^i B^i = 1 - \sum_{i=1}^{\infty} (-\theta_1^i) B^i$$

从而得

$$I_i = -\theta_1^i \quad (2.2.18)$$

当 $|\theta_1| < 1$ 时, 幂级数 $I(B)$ 收敛。

2. MA(2) 模型: $w_t = (1 - \theta_1 B - \theta_2 B^2) a_t$

由 $\theta(B)I(B) = (1 - \theta_1 B - \theta_2 B^2)I(B) = 1$

比较等式两边 B^k 的同次幂系数, 得

$$I_1 = -\theta_1, \quad I_k = \theta_1 I_{k-1} + \theta_2 I_{k-2} \quad k \geq 2 \quad (2.2.19)$$

3. ARMA(1,1) 模型: $(1 - \varphi_1 B)w_t = (1 - \theta_1 B)a_t$

由 $(1 - \theta_1 B)I(B) = 1 - \varphi_1 B$

比较等式两边 B^l 的同次幂系数, 得

$$I_l = \theta_1^{l-1}(\varphi_1 - \theta_1) \quad l \geq 1 \quad (2.2.20)$$

§ 3 模型参数的平稳域和可逆域

由§ 2 可见, 当多项式 $\varphi(B)$ (或 $\theta(B)$) 的根全部在单位圆外的時候, ARMA(p, q) 模型的格林函数 G_t (或逆函数 I_t) 才能被负指数函数所控制, 相应的传递形式 (或逆转形式) 才能有意义。对于具有上述性质的模型, 我们称为平稳的 (可逆的)。模型的平稳性和可逆性是讨论线性模型的前提条件, 无论是由已知模型来讨论递推系统的稳定性, 还是从数据出发建立线性模型, 都需判断我们所研究的模型是否满足平稳性和可逆性。由定义可知, 以上性质可以通过检验 $\varphi(w) = 0$ 及 $\theta(w) = 0$ 的根是否全在单位圆外来判断, 但也可通过另外一个途径来讨论。也就是说, 可以根据代数方程根和系数之间的关系, 把判定模型平稳性和可逆性的条件转化为关于参数 φ 和 θ 的约束条件。这种做法有时更便于问题的讨论。为此, 需要引进模型参数的平稳域和可逆域的概念。

§ 3.1 平稳域和可逆域的定义, 低阶模型的平稳、可逆域

设 ARMA 模型的自回归阶数为 p , 使 $\varphi(w) = 0$ 的根全部在

单位圆外的系数矢量 $\varphi = (\varphi_1, \varphi_2, \dots, \varphi_p)^T$ 全体构成一个 p 维矢量空间上的子集, 记做

$$\Phi^{(p)} = \left\{ \varphi: \begin{array}{l} \varphi = (\varphi_1, \varphi_2, \dots, \varphi_p)^T \\ \varphi(w) = 0 \text{ 的根全部在单位圆外} \end{array} \right\} \quad (2.3.1)$$

$\Phi^{(p)}$ 称为模型 $\text{ARMA}(p, q)$ 的平稳域, 模型平稳的充分必要条件是 φ 属于 $\Phi^{(p)}$ 。

设 ARMA 模型的滑动平均阶数为 q , 使 $\theta(w) = 0$ 的根全部在单位圆外的系数矢量 $\theta = (\theta_1, \theta_2, \dots, \theta_q)^T$ 全体构成一个 q 维矢量空间上的子集, 记做

$$\Theta^{(q)} = \left\{ \theta: \begin{array}{l} \theta = (\theta_1, \theta_2, \dots, \theta_q)^T \\ \theta(w) = 0 \text{ 的根全部在单位圆外} \end{array} \right\} \quad (2.3.2)$$

$\Theta^{(q)}$ 称为模型 $\text{ARMA}(p, q)$ 的可逆域, 模型可逆的充分必要条件是 θ 属于 $\Theta^{(q)}$ 。

当 $\text{ARMA}(p, q)$ 的阶数 p 和 q 不超过 2 时, 模型的平稳域和可逆域可以具体用解析形式表示。

1. AR(1) 和 ARMA(1, q) 模型的平稳域

模型形式为 $w_t - \varphi_1 w_{t-1} = \theta(B) a_t$

$\varphi(B)$ 相应的代数方程为 $\varphi(w) = 1 - \varphi_1 w = 0$

此方程有根 $\lambda_1 = \frac{1}{\varphi_1}$

欲使 $|\lambda_1| = |\varphi_1^{-1}| > 1$, 必须且只须 $|\varphi_1| < 1$, 因此

$$\Phi^{(1)} = \{\varphi_1: -1 < \varphi_1 < 1\} \quad (2.3.3)$$

$\Phi^{(1)}$ 就是 AR(1) 或 ARMA(1, q) 模型的平稳域。

2. AR(2) 和 ARMA(2, q) 模型的平稳域

模型形式为 $w_t - \varphi_1 w_{t-1} - \varphi_2 w_{t-2} = \theta(B) a_t$

$\varphi(B)$ 相应的代数方程为 $\varphi(w) = 1 - \varphi_1 w - \varphi_2 w^2 = 0$

此方程有两个根

$$\lambda_1 = \frac{-\varphi_1 - \sqrt{\varphi_1^2 + 4\varphi_2}}{2\varphi_2} \quad \lambda_2 = \frac{-\varphi_1 + \sqrt{\varphi_1^2 + 4\varphi_2}}{2\varphi_2}$$

由二次方程根与系数的关系可得

$$\lambda_1 \cdot \lambda_2 = -\frac{1}{\varphi_2} \quad \lambda_1 + \lambda_2 = -\frac{\varphi_1}{\varphi_2}$$

因此,由平稳性条件 $|\lambda_i| > 1 (i=1, 2)$ 及 $\lambda_1 \cdot \lambda_2 = -\frac{1}{\varphi_2}$ 可得

$$|\varphi_2| = \frac{1}{|\lambda_1 \cdot \lambda_2|} < 1$$

另一方面,利用根和系数的关系,又可得

$$\begin{aligned} \varphi_2 \pm \varphi_1 &= -\frac{1}{\lambda_1 \lambda_2} \pm \frac{\lambda_1 + \lambda_2}{\lambda_1 \lambda_2} \\ &= -\frac{1}{\lambda_1 \lambda_2} \pm \left(\frac{1}{\lambda_1} + \frac{1}{\lambda_2} \right) \\ &= 1 - \left(1 \mp \frac{1}{\lambda_1} \right) \left(1 \mp \frac{1}{\lambda_2} \right) \end{aligned}$$

无论 λ_1 和 λ_2 全为实数或者互为共轭复数,当 $|\lambda_i| > 1$ 时($i=1, 2$), 都有 $\left(1 \mp \frac{1}{\lambda_1}\right)\left(1 \mp \frac{1}{\lambda_2}\right) > 0$,从而得 $\varphi_2 \pm \varphi_1 < 1$ 。

综上所述,当 $|\lambda_i| > 1 (i=1, 2)$ 时,AR(2)或ARMA(2, q)模型的自回归参数范围

$$|\varphi_2| < 1, \quad \varphi_2 \pm \varphi_1 < 1 \quad (2.3.4)$$

反过来也可证明,如果 φ_1, φ_2 在(2.3.4)所给定的范围内,则 $\varphi(w) = 1 - \varphi_1 w - \varphi_2 w^2 = 0$ 的根 λ_1 和 λ_2 必定在单位圆外。事实上,由 $|\varphi_2| = \frac{1}{|\lambda_1 \lambda_2|} < 1$ 可见, $|\lambda_1|$ 和 $|\lambda_2|$ 至少有一个大于1,不妨设 $|\lambda_1| > 1$,若 λ_1 和 λ_2 互为共轭复数,则显然 $|\lambda_2| > 1$;而若 λ_1 和 λ_2 为实数时,由 $|\lambda_1| > 1$ 得 $1 \mp \frac{1}{\lambda_1} > 0$,因而从 $\varphi_2 \pm \varphi_1 < 1$ 又推得 $1 \mp \frac{1}{\lambda_2} > 0$,从而得 $|\lambda_2| > 1$ 。

综上所述,即可得到AR(2)和ARMA(2, q)模型参数的平稳域为

$$\Phi^{(2)} = \{\varphi; \varphi = (\varphi_1, \varphi_2)^T, -1 < \varphi_2 < 1, \varphi_2 \pm \varphi_1 < 1, \varphi_2 - \varphi_1 < 1\} \quad (2.3.5)$$

图 2.1(a)给出了 $\Phi^{(2)}$ 的区域。

3. MA(1)和 ARMA($p, 1$)模型的可逆域

类似于 1. 中关于 $p=1$ 的平稳域的讨论, 可得 MA (1) 和 ARMA($p, 1$)模型的可逆域为

$$\Theta^{(1)} = \{\theta_1: -1 < \theta_1 < 1\} \quad (2.3.6)$$

4. MA(2)和 ARMA($p, 2$)模型的可逆域

类似于 (2.3.5) 式, 可得

$$\begin{aligned} \Theta^{(2)} = \{\theta; \theta = (\theta_1, \theta_2)^T, -1 < \theta_2 < 1, \theta_2 + \theta_1 < 1, \\ \theta_2 - \theta_1 < 1\} \end{aligned} \quad (2.3.7)$$

图 2.1(b)给出了这个区域。

5. ARMA(1,1)模型的平稳可逆域

如果 ARMA(p, q) 模型的自回归参数属于平稳域, 同时滑动平均参数属于可逆域, 我们就称 ARMA(p, q) 模型的参数 $(\varphi^T, \theta^T)^T$ 属于平稳可逆域内。模型的平稳可逆域用 $(\Phi^{(p)}, \Theta^{(q)})$ 表示。显然, ARMA(1,1)模型的平稳可逆域为

$$(\Phi^{(1)}, \Theta^{(1)}) = \{(\varphi_1, \theta_1): -1 < \varphi_1 < 1, -1 < \theta_1 < 1\} \quad (2.3.8)$$

图 2.1(c)给出了这个区域。




图 2.1 低阶模型的平稳域和可逆域

§ 3.2 高阶模型参数的平稳可逆性检验 Jury 准则*

由 § 3.1 可知, 当模型 ARMA(p, q) 的阶数 p 或 q 不超过 2 时, 参数的平稳域或可逆域可以具体地给出。然而, 当 p 和 q 超过 2 时, 模型的平稳域和可逆域就变得比较复杂, 不可能用简单的关系式表示。不过, 可以有办法检验模型参数是否属于平稳可逆域内, 而且这种检验问题往往更为常见。当然, 最直接的办法是求解代数方程, 检查方程的根是否全在单位圆外。但这种方法往往计算量较大, 况且有时并不需要了解这些根的具体数值。本节介绍一种由模型参数直接判断的检验方法, 它借助于一种简单的判别准则——Jury 准则。

下面具体介绍 Jury 准则的内容。

设多项式 $F(Z)$ 有如下形状

$$F(Z) = a_n Z^n + a_{n-1} Z^{n-1} + \cdots + a_2 Z^2 + a_1 Z + a_0, \quad a_n > 0 \quad (2.3.9)$$

那么, $F(Z)$ 在单位圆上和圆外无根的充分必要条件是

$$F(1) > 0, F(-1) \begin{cases} < 0 & n \text{ 为奇数} \\ > 0 & n \text{ 为偶数} \end{cases},$$

以及

$$|a_0| < a_n, |b_0| > |b_{n-1}|, |c_0| > |c_{n-2}|, \cdots, |q_0| > |q_2| \quad (2.3.10)$$

这 $n-1$ 个关系式全都成立。上式中, a_k 是 $F(Z)$ 的多项式系数, $b_k, c_k, \cdots, q_k$ 依次由下法求得

$$b_k = \begin{vmatrix} a_0 & a_{n-k} \\ a_n & a_k \end{vmatrix} \quad k=0, 1, 2, \cdots, n-1$$

$$c_k = \begin{vmatrix} b_0 & b_{n-1-k} \\ b_{n-1} & b_k \end{vmatrix} \quad k=0, 1, 2, \cdots, n-2 \quad (2.3.11)$$

* E.I. Jury, Theory and Application of the Z-Transform Method (New York, Wiley, 1964).

$$d_k = \begin{vmatrix} c_0 & c_{n-2-k} \\ c_{n-2} & c_k \end{vmatrix} \quad k=0,1,2,\dots,n-3$$

... ..

若求到相应于 p_k 的一步, k 只取 $0,1,2,3$, 那么最后一步 q_k 为

$$q_0 = \begin{vmatrix} p_0 & p_3 \\ p_3 & p_0 \end{vmatrix} \quad q_1 = \begin{vmatrix} p_0 & p_2 \\ p_3 & p_1 \end{vmatrix} \quad q_2 = \begin{vmatrix} p_0 & p_1 \\ p_3 & p_2 \end{vmatrix}$$

注意,在(2.3.10)的 $n-1$ 个不等式中,第一式和其余是反向的。

应用上述结果对 ARMA 模型进行平稳可逆性检验时,要注意先将 $\varphi(B), \theta(B)$ 化为(2.3.9)的形式,然后再作进一步的讨论。例如,要检验 $\varphi(B) = 1 - \varphi_1 B - \varphi_2 B^2 - \dots - \varphi_p B^p$ 的根是否全在单位圆外,就应该通过反演变换,令 $Z = B^{-1}$, 由 $\varphi(B)$ 得到对应的多项式

$$F(Z) = Z^p - \varphi_1 Z^{p-1} - \dots - \varphi_p \quad (2.3.12)$$

不难看出, $\varphi(B)$ 的根全在单位圆外, 当且仅当上式中 $F(Z)$ 的根全在单位圆内, 相应的 $F(Z)$ 的多项式系数应依次为 $(-\varphi_p, -\varphi_{p-1}, \dots, -\varphi_1, 1)$ 。同理关于 $\theta(B)$ 的可逆性检验应化为对于 $(-\theta_q, -\theta_{q-1}, \dots, -\theta_1, 1)$ 的讨论。

由 Jury 准则还可推导出一个应用中更为方便的结果, 在今后进行参数估计时要用到。即多项式 $F(Z)$ 的根全部在单位圆内的一个充分条件是

$$a_n > a_{n-1} > a_{n-2} > \dots > a_0 > 0 \quad (2.3.13)$$

这就是说, 当(2.3.13)式成立时, 多项式 $F(Z)$ 的根全都在单位圆内(当然, 这种情况不是经常发生的)。下面我们来证明这个结论。

证明: 问题等价于当(2.3.13)式成立时, Jury 准则检验能够通过。显然, $F(1) > 0$, 且

当 n 为奇数时

$$F(-1) = -(a_n - a_{n-1}) - (a_{n-2} - a_{n-3}) - \dots - (a_1 - a_0) < 0$$

当 n 为偶数时

$$F(-1) = (a_n - a_{n-1}) + (a_{n-2} - a_{n-3}) + \dots + (a_2 - a_1) + a_0 > 0$$

剩下需检验(2.3.10)的 $n-1$ 个不等式成立。

$$|a_0| < a_n \quad \text{显然成立。}$$

由

$$b_k = a_0 a_k - a_{n-k} a_n < a_0 a_{k+1} - a_{n-k-1} a_n = b_{k+1} < 0$$

可得

$$b_0 < b_1 < b_2 < \cdots < b_{n-1} < 0$$

同理, 可得关于 $c_k, d_k, \cdots, p_k, q_k$ 的一系列类似的不等式

$$c_0 < c_1 < \cdots < c_{n-2} < 0,$$

$$d_0 < d_1 < \cdots < d_{n-3} < 0,$$

$$\cdots \cdots$$

$$q_0 < q_1 < q_2 < 0$$

因此证得(2.3.10)式。

将此结果应用到 ARMA 模型, 可以得到相应的结果, 即当 $\varphi_1 < \varphi_2 < \cdots < \varphi_p < 0$ 或 $\theta_1 < \theta_2 < \cdots < \theta_q < 0$ 时, $\varphi(B)$ 或 $\theta(B)$ 满足平稳性或可逆性。

最后, 需要说明的是, Jury 准则当条件不全成立时, 可以判断出 $F(Z)$ 至少有一个根不在单位圆内, 但不能判断出究竟有几个根, 也不能判断这些根是在单位圆外还是在单位圆上。

§ 4 ARMA序列的自相关函数

利用 ARMA 序列的传递形式 $w_t = \sum_{i=0}^{\infty} G_i a_{t-i}$, 和白噪声 a_t 的特性 $E a_t a_\tau = \delta_{t\tau} \sigma_a^2$, 可得 ARMA 序列 $\{w_t\}$ 的协方差函数为

$$\gamma_k = E w_t w_{t+k} = \sigma_a^2 \sum_{i=0}^{\infty} G_i G_{k+i} = \gamma_{-k} \quad k \geq 0 \quad (2.4.1)$$

由此得到 $\{w_t\}$ 的自相关函数为

$$\begin{aligned} \rho_k &= \frac{E w_t w_{t+k}}{\sqrt{E w_t^2 E w_{t+k}^2}} = \left(\sum_{i=0}^{\infty} G_i G_{k+i} \right) \left(\sum_{i=0}^{\infty} G_i^2 \right)^{-1} \\ &= \rho_{-k}, \quad k \neq 0, \quad \rho_0 = 1 \end{aligned} \quad (2.4.2)$$

由 § 2 可知, 格林函数在平稳域内是负指数衰减的。而 γ_k 或 ρ_k 与 G_t 之间又有上述关系, 因此, ARMA 序列的自协方差函数在平稳域内也必定是负指数衰减的。如果一个随机序列的自协方差函数不服从负指数衰减, 就可以判定它不适宜于用 ARMA 模型来描述。

式(2.4.1)和(2.4.2)给出了 ARMA 序列 γ_k 和 ρ_k 的一类表达形式。下面, 我们将分别对于 MA(q)、AR(p)和 ARMA(p, q)序列, 讨论它们的自协方差函数和自相关函数的具体特性, 并给出其它的表达形式。

§ 4.1 MA(q)序列的自相关函数

将(2.2.6)式代入(2.4.1)和(2.4.2)式, 可得

$$\gamma_k = E w_t w_{t+k} = \begin{cases} \sigma_a^2(1 + \theta_1^2 + \theta_2^2 + \cdots + \theta_q^2) & k=0 \\ \sigma_a^2(-\theta_k + \theta_1\theta_{k+1} + \cdots + \theta_{q-k}\theta_q) & 1 \leq k \leq q \\ 0 & k > q \end{cases} \quad (2.4.3)$$

$$\rho_k = \frac{E w_t w_{t+k}}{\sqrt{E w_t^2 E w_{t+k}^2}} = \begin{cases} \frac{-\theta_k + \theta_1\theta_{k+1} + \cdots + \theta_{q-k}\theta_q}{1 + \theta_1^2 + \theta_2^2 + \cdots + \theta_q^2} & 1 \leq k \leq q \\ 0 & k > q \end{cases} \quad (2.4.4)$$

(2.4.3)和(2.4.4)表明, 当 w_t 和 w_τ 之间的间隔 $k=t-\tau$ 满足条件 $k > q$ 时, w_t 和 w_τ 是不相关的, 也就是说, MA(q) 序列的自协方差函数 γ_k (自相关函数 ρ_k) 当 $k > q$ 以后全部都为零, 而 $\gamma_q \neq 0$ 。这种性质, 我们称之为自协方差函数(自相关函数)的“截尾性”。

定理 如果平稳零均值序列 $\{w_t\}$ 有谱密度 $g(\lambda) > 0$, 那么它可表成 q 阶滑动平均序列的充分必要条件是 $\{w_t\}$ 的自协方差函数(自相关函数) q 步截尾。

证明 必要性由(2.4.3)和(2.4.4)式显然可得, 只需证明充分性。

设 $\{w_t\}$ 为平稳零均值序列, 由于 γ_k 为 q 步截尾, 因此有谱密度

$$g(\lambda) = \sum_{k=-q}^q \gamma_k e^{-i2\pi k\lambda}, \gamma_k = 0, k > q$$

为了证明 $g(\lambda)$ 是有理谱密度, 将 $g(\lambda)$ 进一步表成

$$\begin{aligned} g(\lambda) &= e^{i2\pi q\lambda} \sum_{k=-q}^q \gamma_k e^{-i2\pi(k+q)\lambda} \\ &= e^{i2\pi q\lambda} \sum_{j=0}^{2q} \gamma_{j-q} (e^{-i2\pi\lambda})^j \\ &= \gamma_q e^{i2\pi q\lambda} \prod_{j=1}^{2q} (e^{-i2\pi\lambda} - \mu_j) \end{aligned}$$

其中 μ_j 是 $2q$ 次多项式 $\sum_{j=0}^{2q} \gamma_{j-q} Z^j = \gamma_q \prod_{j=1}^{2q} (Z - \mu_j)$ 的根。由于

$\gamma_q = \gamma_{-q} \neq 0$, 在多项式 $\sum_{j=0}^{2q} \gamma_{j-q} Z^j$ 中提出了系数 γ_q 后, 常数项的

系数为 1, 于是得 $\prod_{j=1}^{2q} \mu_j = 1$, 则 $\mu_j \neq 0$ ($1 \leq j \leq 2q$)。另一方面, 由

$g(\lambda)$ 是实函数得

$$\bar{g}(\lambda) = g(\lambda)$$

$$\text{即 } \gamma_q e^{i2\pi q\lambda} \prod_{j=1}^{2q} (e^{-i2\pi\lambda} - \mu_j) = \gamma_q e^{-i2\pi q\lambda} \prod_{j=1}^{2q} (e^{i2\pi\lambda} - \bar{\mu}_j)$$

$$= c \gamma_q e^{i2\pi q\lambda} \prod_{j=1}^{2q} \left(\frac{1}{\bar{\mu}_j} - e^{-i2\pi\lambda} \right)$$

其中

$$c = \prod_{j=1}^{2q} \bar{\mu}_j$$

式中 $\bar{g}(\lambda)$ 和 $\bar{\mu}_j$ 分别表示 $g(\lambda)$ 和 μ_j 的共轭复数。显然, $g(\lambda)$ 的 $2q$ 个根中, μ_j 和 $\frac{1}{\bar{\mu}_j}$ 成对出现, $j=1, 2, \dots, q$ 。注意到每一对

$\{\mu_j, \frac{1}{\bar{\mu}_j}\}$ 中, 一个在单位圆内时, 另一个必在圆外, 或者两个都在圆上, 不妨设 μ_j 在圆外或圆上, 因此 $g(\lambda)$ 可表为

$$g(\lambda) = c \gamma_q e^{i2\pi q \lambda} \prod_{j=1}^q (e^{-i2\pi \lambda} - \mu_j) \prod_{j=1}^q \left(e^{-i2\pi \lambda} - \frac{1}{\bar{\mu}_j} \right)$$

从而由谱密度 $g(\lambda)$ 的非负性得

$$\begin{aligned} g(\lambda) &= |g(\lambda)| = |c \gamma_q| \prod_{j=1}^q \left| (e^{-i2\pi \lambda} - \mu_j) \left(e^{-i2\pi \lambda} - \frac{1}{\bar{\mu}_j} \right) \right| \\ &= |c \gamma_q| \prod_{j=1}^q | (1 - \mu_j^{-1} e^{-i2\pi \lambda}) (1 - \bar{\mu}_j^{-1} e^{i2\pi \lambda}) | \cdot \prod_{j=1}^q |\mu_j| \\ &= \sigma^2 \left| \prod_{j=1}^q (1 - \mu_j^{-1} e^{-i2\pi \lambda}) \right|^2 \\ &\triangleq \sigma^2 \left| \sum_{j=0}^q \theta_j e^{-i2\pi j \lambda} \right|^2 \end{aligned}$$

其中

$$\sigma^2 \triangleq |\gamma_q| |c|^2 > 0$$

且 $\sum_{j=0}^q \theta_j Z^j$ 的根全在单位圆外或圆上。

由谱表示得

$$w_t = \int_{-\frac{1}{2}}^{\frac{1}{2}} e^{i2\pi t \lambda} \left(\sum_{j=0}^q \theta_j e^{-i2\pi j \lambda} \right) d\xi(\lambda)$$

其中 $\xi(\lambda)$ 为正交增量过程 $E|d\xi(\lambda)|^2 = \sigma^2 d\lambda$

$$\text{令 } a_t = \int_{-\frac{1}{2}}^{\frac{1}{2}} e^{i2\pi t \lambda} d\xi(\lambda)$$

由 §1 可知, $\{a_t\}$ 为白噪声列, 从而得

$$w_t = \sum_{j=0}^q \theta_j a_{t-j}$$

即 w_t 有 q 阶滑动平均表示。

又由假设 $g(\lambda) > 0$, 即 $g(\lambda)$ 的根都不在单位圆上, 那么, 由上述知 $\sum_{j=0}^q \theta_j Z^j$ 的根全在单位圆外, 因此, $\{w_t\}$ 是可逆 MA(q) 序列, 定理证毕。

由此结果, 还可引出一个有用的推论:

如果 $w_t^{(1)} = \theta^{(1)}(B) a_t^{(1)}$ 和 $w_t^{(2)} = \theta^{(2)}(B) a_t^{(2)}$ 是两个相互独立的 MA(q_1) 和 MA(q_2) 序列, 而且

$$\sigma_a^2(1) |\theta^{(1)}(e^{-i2\pi\lambda})|^2 + \sigma_a^2(2) |\theta^{(2)}(e^{-i2\pi\lambda})|^2 > 0, \quad -\frac{1}{2} \leq$$

$$\lambda \leq \frac{1}{2}$$

那么 $w_t = w_t^{(1)} + w_t^{(2)}$ 必是一个 MA(q) 序列, 且

$$q \leq \max(q_1, q_2)$$

这个推论的证明是显然的。因为 $w_t^{(1)}$ 和 $w_t^{(2)}$ 相互独立, 且 $\gamma_k(w^{(1)})$ 和 $\gamma_k(w^{(2)})$ 分别以 q_1 和 q_2 步截尾, 所以 w_t 的自协方差函数 $\gamma_k(w) = \gamma_k(w^{(1)}) + \gamma_k(w^{(2)})$ 显然是截尾的, 且有 $q \leq \max(q_1, q_2)$ 。又由于

$$\begin{aligned} g(\lambda) &= g^{(1)}(\lambda) + g^{(2)}(\lambda) \\ &= \sigma_a^2(1) |\theta^{(1)}(e^{-i2\pi\lambda})|^2 + \sigma_a^2(2) |\theta^{(2)}(e^{-i2\pi\lambda})|^2 > 0, \\ -\frac{1}{2} &\leq \lambda \leq \frac{1}{2} \end{aligned}$$

即 $g(\lambda)$ 作为 w_t 的谱密度在 $\lambda \in \left[-\frac{1}{2}, \frac{1}{2}\right]$

是存在的, 因此, $\{w_t\}$ 是 MA(q) 序列。

注意, 只有当 $q_1 = q_2$ 且 $\theta_{q_1}^{(1)} = -\theta_{q_2}^{(2)}$ 时, 才有 $q < \max(q_1, q_2)$, 一般情形, 总是 $q = \max(q_1, q_2)$ 。

§ 4.2 AR(p) 序列的自相关函数

将模型 AR(p) 写成如下形式

$$w_t = \varphi_1 w_{t-1} + \varphi_2 w_{t-2} + \cdots + \varphi_p w_{t-p} + a_t$$

用 w_{t-k} ($k > 0$) 乘以上式两边, 并求均值得

$$E w_t w_{t-k} = \varphi_1 E w_{t-1} w_{t-k} + \varphi_2 E w_{t-2} w_{t-k} + \cdots \\ + \varphi_p E w_{t-p} w_{t-k} + E a_t w_{t-k}$$

由于

$$w_{t-k} = \sum_{j=0}^{\infty} G_j a_{t-k-j}$$

因此

$$E a_t w_{t-k} \equiv 0$$

故得 AR(p)模型的协方差函数满足如下差分方程

$$\gamma_k = \varphi_1 \gamma_{k-1} + \varphi_2 \gamma_{k-2} + \cdots + \varphi_p \gamma_{k-p} \quad (k > 0)$$

即

$$\varphi(B) \gamma_k = 0 \quad (k > 0) \quad (2.4.5)$$

由自相关函数和自协方差函数的关系, 可得自相关函数也满足同样的差分方程

$$\varphi(B) \rho_k = 0 \quad (k > 0) \quad (2.4.6)$$

由差分方程求根理论知, AR(p)序列的自相关函数序列 $\{\rho_k\}$ 和自协方差函数序列 $\{\gamma_k\}$ 在模型的平稳域内是被负指数函数控制的。它们不能在某步之后截尾, 而只是按负指数律衰减。 $\{\rho_k\}$ 和 $\{\gamma_k\}$ 的这种性质, 称之为“拖尾”性。

由于 γ_k 和 ρ_k 满足差分方程 (2.4.5) 和 (2.4.6), 运用差分方程的求根理论, 可以从模型 AR(p) 的参数矢量 φ 和给定的 γ_k 或 ρ_k 的初值, 求解出任意时刻的自协方差函数或自相关函数值来。不过在实际计算中很少遇到这样的问题, 今后常用的倒是如何从 ρ_k 或 γ_k 求出参数 φ 的方法。

由 (2.4.6) 式, 取 $k=1, 2, \cdots, p$, 利用 $\rho_k = \rho_{-k}$ 和 $\rho_0 = 1$, 可得方程组

$$\begin{cases} \rho_1 = \varphi_1 + \varphi_2 \rho_1 + \cdots + \varphi_p \rho_{p-1} \\ \rho_2 = \varphi_1 \rho_1 + \varphi_2 + \cdots + \varphi_p \rho_{p-2} \\ \quad \cdots \quad \cdots \\ \rho_p = \varphi_1 \rho_{p-1} + \varphi_2 \rho_{p-2} + \cdots + \varphi_p \end{cases} \quad (2.4.7)$$

显然, 参数矢量 $\varphi = (\varphi_1, \varphi_2, \dots, \varphi_p)^T$ 是线性方程组 (2.4.7) 的解。此方程组称为 Yule-Walker 方程, 系数矩阵称为 Toeplitz 矩阵, 它由 $\rho_1, \rho_2, \dots, \rho_{p-1}$ 组成

$$\begin{pmatrix} 1 & \cdot & \cdot & \rho_1 & \cdots & \rho_{p-1} \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ \rho_1 & \cdot & \cdot & \cdot & \cdot & \rho_{p-2} \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ \vdots & \cdot & \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot & \cdot & \rho_1 \\ \rho_{p-1} & \rho_{p-2} & \cdots & \rho_1 & \cdot & 1 \end{pmatrix} \quad (2.4.8)$$

由自协方差函数的性质可知, 此矩阵非负定。

将 (2.4.7) 和 (2.4.8) 式中的 ρ_k 改换成 γ_k , 即可得到关于自协方差函数 γ_k 相应的关系式。

可以证明, 只要 Toeplitz 矩阵正定, 则由 Yule-Walker 方程解得的自回归参数必定在平稳域内。

最后, 由 AR(p) 模型导出 σ_a^2 和 $\varphi, \{\gamma_k\}$ 之间的关系

$$\begin{aligned} \sigma_a^2 &= E a_t^2 = E (w_t - \varphi_1 w_{t-1} - \cdots - \varphi_p w_{t-p})^2 \\ &= \gamma_0 - 2 \sum_{i=1}^p \varphi_i \gamma_i + \sum_{i,j=1}^p \varphi_i \varphi_j \gamma_{i-j} \end{aligned} \quad (2.4.9)$$

利用 (2.4.5) 式可得

$$\sum_{i,j=1}^p \varphi_i \varphi_j \gamma_{i-j} = \sum_{i=1}^p \varphi_i \left(\sum_{j=1}^p \varphi_j \gamma_{j-i} \right) = \sum_{j=1}^p \varphi_j \gamma_j$$

代入 (2.4.9) 式, 又得

$$\sigma_a^2 = \gamma_0 - \sum_{j=1}^p \varphi_j \gamma_j = \gamma_0 - \sum_{i,j=1}^p \varphi_i \varphi_j \gamma_{i-j} \quad (2.4.10)$$

§ 4.3 ARMA(p, q) 序列的自相关函数

ARMA 序列的自相关函数比 AR 序列的更复杂一些。从模型出发求出 γ_k 的表达式, 需要分几步来完成。

首先, 求出序列 $\{w_t\}$ 和 $\{a_t\}$ 的互协方差函数

$$\gamma_k(w, a) = E w_t a_{t+k} = E \left(\sum_{j=0}^{\infty} G_j a_{t-j} \right) a_{t+k}$$

$$\begin{aligned}
&= \sum_{i=0}^{\infty} G_i E a_{i-i} a_{i+k} \\
&= \begin{cases} \sigma_a^2 G_{-k} & k \leq 0 \\ 0 & k > 0 \end{cases} \quad (2.4.11)
\end{aligned}$$

然后, 将模型

$w_t - \varphi_1 w_{t-1} - \cdots - \varphi_p w_{t-p} = a_t - \theta_1 a_{t-1} - \cdots - \theta_q a_{t-q}$ 两边同乘以 w_{t-k} 再求均值, 即得

$$\begin{aligned}
\gamma_k - \varphi_1 \gamma_{k-1} - \cdots - \varphi_p \gamma_{k-p} &= \gamma_k(w, a) - \\
&\quad - \theta_1 \gamma_{k-1}(w, a) - \cdots - \theta_q \gamma_{k-q}(w, a)
\end{aligned}$$

此式可写成

$$\varphi(B) \gamma_k = \theta(B) \gamma_k(w, a) \quad (2.4.12)$$

将(2.4.11)式代入(2.4.12)式的右端, 进一步可得 ARMA(p, q)序列的自协方差函数满足如下的差分方程

$$\varphi(B) \gamma_k = \begin{cases} 0 & k > q \\ C \neq 0 & k = q \end{cases} \quad (2.4.13)$$

(注意 $C = \varphi(B) \gamma_q = \cdots = \theta_q G_j \sigma_a^2 = \cdots = \theta_q \sigma_a^2 \neq 0$)

此结论的逆命题也成立, 即

定理 如果序列 $\{w_t\}$ 的自协方差函数满足(2.4.13), 那么它必定是 ARMA(p, q)序列。

证明 记 $y_t = \varphi(B)w_t$, 显然 $\{y_t\}$ 是平稳零均值序列, 且由(2.4.13)得

$$\begin{aligned}
E(y_{t+k} w_t) &= E\{\varphi(B)w_{t+k}\} w_t = \varphi(B) \gamma_k = \\
&= \begin{cases} 0 & k > q \\ C \neq 0 & k = q \end{cases}
\end{aligned}$$

进一步得

$$\begin{aligned}
E y_{t+k} y_t &= E\{\varphi(B)w_{t+k}\}[\varphi(B)w_t] = \\
&= \varphi(B)\varphi(B^{-1})E w_{t+k} w_t = \varphi(B^{-1})[\varphi(B) \gamma_k]
\end{aligned}$$

仍由(2.4.13)可见, 上式为

$$E y_{t+k} y_t = \begin{cases} 0 & k > q \\ (1 - \varphi_1 - \cdots - \varphi_p) C \neq 0 & k = q \end{cases}$$

(注意, 因为 $\varphi(B)$ 在单位圆上无根, 故

$$1 - \varphi_1 - \cdots - \varphi_p \neq 0)$$

这就是说, 序列 $\{y_t\}$ 的自协方差序列是 q 步截尾的。由 § 4.1 的充分必要条件知, $\{y_t\}$ 是 $MA(q)$ 序列, 从而得

$$\varphi(B)w_t = y_t = \theta(B)a_t$$

定理得证。

由于 $AR(p)$ 序列是 $ARMA(p, q)$ 序列 $q=0$ 时的特殊情形, 因此, 上述充分必要性结论对于 $AR(p)$ 序列也适用, 只需将 $q=0$ 即可。

将 (2.4.13) 式中的 γ_k 换成 ρ_k , 可得到关于 ρ_k 的同样结论。根据差分方程求根理论 (注意, 我们总设 $\varphi(B)$ 的根全在单位圆外), 得知 $ARMA(p, q)$ 序列的 $\{\gamma_k\}$ 和 $\{\rho_k\}$ 是被负指数函数控制的, 因而也是拖尾序列。

由自相关函数序列出发, 也可求出 $ARMA(p, q)$ 模型的自回归参数向量 φ 和滑动平均参数向量 θ 。首先, 令 $k=q+1, q+2, \dots, q+p$, 利用 $\gamma_k = \gamma_{-k}$, 由 (2.4.13) 式可得到关于 φ 的 p 阶线性方程组

$$\begin{cases} \rho_{q+1} = \varphi_1 \rho_q + \varphi_2 \rho_{q-1} + \cdots + \varphi_p \rho_{q-p+1} \\ \rho_{q+2} = \varphi_1 \rho_{q+1} + \varphi_2 \rho_q + \cdots + \varphi_p \rho_{q-p+2} \\ \cdots \\ \rho_{q+p} = \varphi_1 \rho_{q+p-1} + \varphi_2 \rho_{q+p-2} + \cdots + \varphi_p \rho_q \end{cases} \quad (2.4.14)$$

当此方程组的系数矩阵可逆时, 由此线性方程组可求解得到 $\varphi = (\varphi_1, \varphi_2, \dots, \varphi_p)^T$ 。

再令 $\bar{w}_k = w_k - \varphi_1 w_{k-1} - \cdots - \varphi_p w_{k-p} = \sum_{i=0}^p \varphi_i w_{k-i}$, $\varphi_0 \triangleq -1$ 则 $\bar{w}_k$

是以 $\theta = (\theta_1, \theta_2, \dots, \theta_q)^T$ 为参数的 $MA(q)$ 序列。可以通过 γ_k 来计算 $\bar{w}_t$ 的自协方差函数 $\gamma_k(\bar{w})$

$$\gamma_k(\bar{w}) = E \left(\sum_{i=0}^n \varphi_i w_{t-i} \right) \left(\sum_{i=0}^p \varphi_i w_{t+k-i} \right)$$

$$= \sum_{i,j=0}^p \varphi_i \varphi_j \gamma_{k+i-j} \quad (2.4.15)$$

由 § 4.1(2.4.3)式, 可从 $\gamma_k(\bar{w})$ 计算出滑动平均参数 θ 和 σ_a^2 来。

§ 4.1 至 § 4.3 分别介绍了各类模型 $\{\gamma_k\}$ 和 $\{\rho_k\}$ 的性质和表达形式, 现简单归纳于下: 当 $p=0$ 时, 序列为 MA(q)型, $\{\rho_k\}$ 和 $\{\gamma_k\}$ 是 q 步截尾, 当 $q=0$ 时, 序列为 AR(p)型, $\{\rho_k\}$ 和 $\{\gamma_k\}$ 拖尾, 且当 $k>0$ 时, 满足差分方程 $\varphi(B)\rho_k=0$ 及 $\varphi(B)\gamma_k=0$; 而当 p 和 q 均不为零时, $\{\rho_k\}$ 和 $\{\gamma_k\}$ 也拖尾, 且当 $k>q$ 时, 满足上述差分方程。以上这些特点, 有助于今后对于序列的类型进行判别。

§ 4.4 自相关函数的允许域

第一章曾论述过, 只要 $\{\gamma_k\}$ 序列满足对称性和非负定性, 它就一定是某一平稳序列的自协方差函数。然而, 为使 $\{\gamma_k\}$ 或 $\{\rho_k\}$ 成为 ARMA 序列的自协方差函数或自相关函数, 除要符合对称性和正定性外, 还应保证它相应的模型具有平稳性和可逆性。由 § 4.1 和 § 4.3 的讨论可知, 当给定前 $p+q+1$ 个 γ_k 或 ρ_k 后, 即可由一些方程式解得模型参数 φ 和 θ , 也就是说, 模型 ARMA(p, q) 完全由这前 $p+q+1$ 个 γ_k 或 ρ_k 来决定。为了能使模型平稳可逆, ARMA(p, q) 序列的前 $p+q+1$ 个自协方差函数(或自相关函数)所能允许的取值范围, 就称之为它们的允许域。只有当 $\{\gamma_k\}$ 和 $\{\rho_k\}$ 的前 $p+q+1$ 个值属于相应的允许域内时, 才可能是 ARMA(p, q) 序列的自协方差函数或自相关函数。由上可见, 原则上, 可利用允许域来检验 $\{\rho_k\}$, $\{\gamma_k\}$ 能否是阶为 (p, q) 的 ARMA 序列的自相关函数和自协方差函数。但是, 由于一般的 ARMA(p, q) 模型, 参数 φ, θ 与 $\{\gamma_k\}$, $\{\rho_k\}$ 之间关系复杂, 允许域不可能全都用解析形式表示出来, 因此, 对一般模型的允许域, 无法仔细讨论。本节仅举几个低阶情形为例, 而且由于推导过程纯属烦琐的初等运算, 我们只给出最后的结果。

1. MA(1)序列: 模型 $w_t = a_t - \theta_1 a_{t-1}$

由(2.4.3)和(2.4.4)得

$$\gamma_0 = (1 + \theta_1^2) \sigma_a^2, \quad \gamma_1 = -\theta_1 \sigma_a^2, \quad \gamma_k = 0, k \geq 2$$

$$\rho_0 = 1, \quad \rho_1 = -\frac{\theta_1}{1 + \theta_1^2}, \quad \rho_k = 0, k \geq 2 \quad (2.4.16)$$

由于 MA(1) 的可逆域为 $|\theta_1| < 1$, 在此范围内, 因为

$$-\frac{d\rho_1}{d\theta_1} = \frac{1 + \theta_1^2 - 2\theta_1^2}{(1 + \theta_1^2)^2} = \frac{1 - \theta_1^2}{(1 + \theta_1^2)^2} > 0$$

故 $-\rho_1$ 在 $\theta_1 \in (-1, 1)$ 内为上升函数, 从而得 MA(1) 序列的自相关函数 ρ_1 有允许域

$$|\rho_1| = \left| \frac{\theta_1}{1 + \theta_1^2} \right| < \frac{1}{2} \quad (2.4.17)$$

模型系数与 ρ_1 的关系如图 2.2(a) 所示。

2. MA(2) 序列: 模型 $w_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2}$

仍由 (2.4.3) 和 (2.4.4) 得

$$\gamma_0 = (1 + \theta_1^2 + \theta_2^2) \sigma_a^2, \quad \gamma_1 = (-\theta_1 + \theta_1 \theta_2) \sigma_a^2,$$

$$\gamma_2 = -\theta_2 \sigma_a^2, \quad \gamma_k = 0, k \geq 3$$

$$\rho_1 = \frac{-\theta_1 + \theta_1 \theta_2}{1 + \theta_1^2 + \theta_2^2}, \quad \rho_2 = \frac{-\theta_2}{1 + \theta_1^2 + \theta_2^2}, \quad \rho_k = 0, k \geq 3 \quad (2.4.18)$$

由此算得 MA(2) 序列 ρ_1, ρ_2 的允许域如图 2.2(b)。

$$\begin{cases} \rho_2 + \rho_1 > -\frac{1}{2} \\ \rho_2 - \rho_1 < -\frac{1}{2} \\ \rho_1^2 < 4\rho_2(1 - 2\rho_2), (\text{当 } \rho_2 \geq \frac{1}{6} \text{ 时}) \end{cases} \quad (2.4.19)$$

最后一式等价于 $\left(\frac{\rho_1}{\frac{1}{\sqrt{2}}} \right)^2 + \left(\frac{\rho_2 - \frac{1}{4}}{\frac{1}{4}} \right)^2 \leq 1$ 。

3. AR(1) 序列: 模型 $w_t - \varphi_1 w_{t-1} = a_t$

由 (2.4.5) 和 (2.4.6) 可算得

$$\gamma_k = \gamma_0 \varphi_1^k, \quad \rho_k = \varphi_1^k, \quad k \geq 0 \quad (2.4.20)$$

显然, AR(1) 序列自相关函数 ρ_1 的允许域为

$$|\rho_1| = |\varphi_1| < 1$$

由关系式(2.4.20)得 ρ_k 的衰减曲线如图(2.2(c))。

4. AR(2)序列: 模型 $w_t - \varphi_1 w_{t-1} - \varphi_2 w_{t-2} = a_t$,
由(2.4.6)可得 ρ_k 满足如下递推关系

$$\rho_k = \varphi_1 \rho_{k-1} + \varphi_2 \rho_{k-2}, \quad k > 0 \quad (2.4.21)$$

由关系式

$$\begin{cases} \rho_0 = 1 \\ \rho_1 = \varphi_1 \rho_0 + \varphi_2 \rho_{-1} = \varphi_1 \rho_0 + \varphi_2 \rho_1 \\ \rho_2 = \varphi_1 \rho_1 + \varphi_2 \rho_0 \end{cases}$$

可解得

$$\rho_1 = \frac{\varphi_1}{1 - \varphi_2} \quad \rho_2 = \frac{\varphi_1^2}{1 - \varphi_2} + \varphi_2$$

利用 AR(2) 的平稳域 (2.3.5), 可算得 ρ_1, ρ_2 的允许域 (图 2.2(d))

$$-1 < \rho_1 < 1, -1 < \rho_2 < 1, \rho_1^2 < \frac{1}{2}(1 + \rho_2). \quad (2.4.22)$$

5. ARMA(1,1)序列: 模型 $w_t - \varphi_1 w_{t-1} = a_t - \theta_1 a_{t-1}$
可以算得

$$\gamma_k = \begin{cases} \frac{1 + \theta_1^2 - 2\varphi_1\theta_1}{1 - \varphi_1^2} \sigma_a^2 & k=0 \\ \frac{(1 - \varphi_1\theta_1)(\varphi_1 - \theta_1)}{1 - \varphi_1^2} \sigma_a^2 \varphi_1^{k-1} & k \geq 1 \end{cases} \quad (2.4.23)$$

$$\rho_k = \begin{cases} 1 & k=0 \\ \frac{(1 - \varphi_1\theta_1)(\varphi_1 - \theta_1)}{1 + \theta_1^2 - 2\varphi_1\theta_1} \varphi_1^{k-1} & k \geq 1 \end{cases}$$

由此关系式及 ARMA(1,1)模型的平稳可逆域 $|\varphi_1| < 1, |\theta_1| < 1$,
可以算出自相关函数的允许域为(图 2.2(e))

$$\begin{aligned} |\rho_2| &< |\rho_1|, \quad \rho_2 > \rho_1(2\rho_1 + 1) \quad (\rho_1 > 0 \text{ 时}) \\ \rho_2 &> \rho_1(2\rho_1 - 1) \quad (\rho_1 < 0 \text{ 时}) \end{aligned} \quad (2.4.24)$$




图 2.2 低阶模型自相关函数的允许域及与模型系数的关系曲线

§ 5 ARMA 序列的偏相关函数

由 § 4 得知, 自相关函数的截尾性是 MA 序列特有的标志, 而拖尾性是 AR 和 ARMA 序列共有的特性。自然地, 会产生如下的问题: 有没有某种参数表征体现出 AR 序列独有的特性呢? 本节的内容将给出这个问题的答案。

§ 5.1 偏相关函数的定义

设 $\{w_t\}$ 为平稳、零均值序列, 考虑由 $w_{t-1}, w_{t-2}, \dots, w_{t-k}$ 对 w_t 的线性最小方差估计, 即选择系数 $\varphi_{k1}, \varphi_{k2}, \dots, \varphi_{kk}$, 使得

$$\delta \triangleq E \left(w_t - \sum_{j=1}^k \varphi_{kj} w_{t-j} \right)^2 = \gamma_0 - 2 \sum_{j=1}^k \varphi_{kj} \gamma_j + \sum_{i,j=1}^k \varphi_{ki} \varphi_{kj} \gamma_{i-j}$$

达到极小。为达目的, 对 δ 的右端分别求偏导数 $\frac{\partial \delta}{\partial \varphi_{kj}}$, $j=1, 2, \dots, k$, 并令其为零, 便得到 φ_{kj} 应该满足的线性方程组

$$\begin{pmatrix} 1 & \rho_1 & \cdots & \rho_{k-1} \\ \rho_1 & 1 & \cdots & \rho_{k-2} \\ & \cdots & & \\ \rho_{k-1} & \rho_{k-2} & \cdots & 1 \end{pmatrix} \begin{pmatrix} \varphi_{k1} \\ \varphi_{k2} \\ \vdots \\ \varphi_{kk} \end{pmatrix} = \begin{pmatrix} \rho_1 \\ \rho_2 \\ \vdots \\ \rho_k \end{pmatrix} \quad (2.5.1)$$

此式与 (2.4.7) 式形式相同, 亦称为 Yule-Walker 方程, 系数矩阵为 Toeplitz 矩阵, 今后将会多处出现。

由线性方程组 (2.5.1) 求得的序列 φ_{kk} , ($k=1, 2, \dots$) 称为 $\{w_t\}$ 的偏相关函数, 在 § 5.3 里, 将解释参数表征 φ_{kk} 的概率含义。

§ 5.2 φ_{kj} 的计算. 递推算法

φ_{kj} 原则上可由线性方程组 (2.5.1) 直接求得

$$\begin{pmatrix} \varphi_{k1} \\ \varphi_{k2} \\ \vdots \\ \varphi_{kk} \end{pmatrix} = \begin{pmatrix} 1 & \rho_1 & \cdots & \rho_{k-1} \\ \rho_1 & 1 & \cdots & \rho_{k-2} \\ & \cdots & \cdots & \cdots \\ \rho_{k-1} & \rho_{k-2} & \cdots & 1 \end{pmatrix}^{-1} \begin{pmatrix} \rho_1 \\ \rho_2 \\ \vdots \\ \rho_k \end{pmatrix}$$

例如,求 MA(1) 序列的偏相关函数。由 § 4.4 例 1 得知, $\rho_0=1$,

$$\rho_1 = \frac{-\theta_1}{1+\theta_1^2}, \rho_k = 0, k \geq 2$$

由(2.5.1)知,应有

$$\begin{pmatrix} 1 & \rho_1 & 0 \\ \rho_1 & \ddots & \vdots \\ 0 & \ddots & \rho_1 & 1 \end{pmatrix} \begin{pmatrix} \varphi_{k1} \\ \varphi_{k2} \\ \vdots \\ \varphi_{kk} \end{pmatrix} = \begin{pmatrix} \rho_1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \quad \rho_1 = \frac{-\theta_1}{1+\theta_1^2}$$

方程组等价于

$$\begin{pmatrix} 1+\theta_1^2 & -\theta_1 & 0 \\ & \ddots & \vdots \\ -\theta_1 & \ddots & -\theta_1 \\ 0 & -\theta_1 & 1+\theta_1^2 \end{pmatrix} \begin{pmatrix} \varphi_{k1} \\ \varphi_{k2} \\ \vdots \\ \varphi_{kk} \end{pmatrix} = \begin{pmatrix} -\theta_1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

将等式左端系数矩阵的行列式记为 Δ_k , 由行列式展开可得

$$\Delta_k = (1+\theta_1^2)\Delta_{k-1} - \theta_1^2\Delta_{k-2} \quad (k \geq 3)$$

此为 Δ_k 的二阶差分方程, 通解为

$$\Delta_k = c_1\lambda_1^k + c_2\lambda_2^k$$

其中 $\lambda_1=1, \lambda_2=\theta_1^2$, 是相应的特征方程

$$\lambda^2 - (1+\theta_1^2)\lambda - \theta_1^2 = 0 \text{ 的根。}$$

由于 $\Delta_1 = 1 + \theta_1^2$

$$\Delta_2 = \begin{vmatrix} 1+\theta_1^2 & -\theta_1 \\ -\theta_1 & 1+\theta_1^2 \end{vmatrix} = (1+\theta_1^2)^2 - \theta_1^2 = 1 + \theta_1^2 + \theta_1^4$$

从而求解方程组 $\begin{cases} c_1\lambda_1 + c_2\lambda_2 = \Delta_1 \\ c_1\lambda_1^2 + c_2\lambda_2^2 = \Delta_2 \end{cases}$

得 $c_1 = (1-\theta_1^2)^{-1}, c_2 = -\theta_1^2(1-\theta_1^2)^{-1}$

于是 $\Delta_k = c_1 \lambda_1^k + c_2 \lambda_2^k = (1 - \theta_1^{2k+2})(1 - \theta_1^2)^{-1}$

最后解得


$$\begin{cases} \varphi_{11} = \rho_1 = -\frac{\theta_1}{1 + \theta_1^2} \\ \varphi_{kk} = \frac{\Delta_k^{(k)}}{\Delta_k} = \frac{(1 - \theta_1^2)(-1)^{k+1}(-\theta_1)^k}{1 - \theta_1^{2k+2}} = \frac{(\theta_1^2 - 1)\theta_1^k}{1 - \theta_1^{2k+2}} \end{cases} \quad k \geq 2 \quad (2.5.2)$$

式中 $\Delta_k^{(k)}$ 表示 Δ_k 最后一列由 $(-\theta_1, 0, \dots, 0)$ 置换后产生的新行列式。

由此例可见，对于一般阶数较高的 ARMA 序列，由 (2.5.1) 式直接计算偏相关函数是比较复杂的。通常我们用下面的递推算法求 $\varphi_{k,j}$

$$\begin{cases} \varphi_{11} = \rho_1 \\ \varphi_{k+1,k+1} = \left(\rho_{k+1} - \sum_{j=1}^k \rho_{k+1-j} \varphi_{kj} \right) \left(1 - \sum_{j=1}^k \rho_j \varphi_{kj} \right)^{-1} \\ \varphi_{k+1,j} = \varphi_{kj} - \varphi_{k+1,k+1} \varphi_{k,k+1-j}, \quad j = 1, 2, \dots, k \end{cases} \quad (2.5.3)$$

公式 (2.5.3) 表明，从初值 $\varphi_{11} = \rho_1$ 出发，随着 k 的增加， $\varphi_{k+1,j}$ ($j = 1, 2, \dots, k+1$) 的值可由 φ_{kj} ($j = 1, 2, \dots, k$) 递推算出，具体步骤如以下流程图所示



在具体编制计算机程序来实现关于 $\varphi_{k+1,j}$ 的递推运算时，我们将采用把 $\varphi_{k+1,j}$ 和 $\varphi_{k+1,k+1-j}$ 同时成对计算出来的技巧。由公式

$$\begin{cases} \varphi_{k+1,j} = \varphi_{kj} - \varphi_{k+1,k+1} \varphi_{k,k+1-j} \\ \varphi_{k+1,k+1-j} = \varphi_{k,k+1-j} - \varphi_{k+1,k+1} \varphi_{kj} \end{cases}$$

可见, 计算 $\varphi_{k+1,j}$ 与 $\varphi_{k+1,k+1-j}$ 都只需用到 $\varphi_{kj}, \varphi_{k+1,k+1}, \varphi_{k,k+1-j}$ 这三个过去结果, 同步计算 $\varphi_{k+1,j}$ 与 $\varphi_{k+1,k+1-j}$ 将有利于节省存贮, 减少计算量。

这一算法的运算次数与 k^2 成比例, 较一般消去法求解线性方程组为快, 在实用上非常方便。

下面给出递推公式(2.5.3)的证明
记

$$\begin{aligned} \xi_k &= \begin{pmatrix} \rho_1 \\ \rho_2 \\ \vdots \\ \rho_k \end{pmatrix} & \bar{\xi}_k &= \begin{pmatrix} \rho_k \\ \rho_{k-1} \\ \vdots \\ \rho_1 \end{pmatrix} & \eta_k &= \begin{pmatrix} \varphi_{k1} \\ \varphi_{k2} \\ \vdots \\ \varphi_{kk} \end{pmatrix} \\ \zeta_k &= \begin{pmatrix} \varphi_{k1} \\ \varphi_{k2} \\ \vdots \\ \varphi_{k,k-1} \end{pmatrix} & R_k &= \begin{pmatrix} 1 & \rho_1 & \cdots & \rho_{k-1} \\ \rho_1 & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \rho_1 \\ \rho_{k-1} & \cdots & \rho_1 & 1 \end{pmatrix} & T &= \begin{pmatrix} 0 & & 1 \\ & \ddots & \\ 1 & & 0 \end{pmatrix} \end{aligned} \quad (2.5.4)$$

易见

$$T^{-1}=T, TR_kT=R_k, T\xi_k=\bar{\xi}_k$$

于是(2.5.1)式对于 $k+1$ 可以表为

$$R_{k+1}\eta_{k+1}=\xi_{k+1}$$

或

$$\begin{pmatrix} R_k & \bar{\xi}_k \\ \bar{\xi}_k^T & 1 \end{pmatrix} \begin{pmatrix} \zeta_{k+1} \\ \varphi_{k+1,k+1} \end{pmatrix} = \begin{pmatrix} \xi_k \\ \rho_{k+1} \end{pmatrix}$$

由矩阵分块运算法则, 可得如下等式

$$\begin{cases} R_k \zeta_{k+1} + \bar{\xi}_k \varphi_{k+1,k+1} = \xi_k \\ \bar{\xi}_k^T \zeta_{k+1} + \varphi_{k+1,k+1} = \rho_{k+1} \end{cases}$$

由前一等式得

$$\begin{aligned} \zeta_{k+1} &= R_k^{-1} \xi_k - \varphi_{k+1,k+1} R_k^{-1} \bar{\xi}_k \\ &= \eta_k - \varphi_{k+1,k+1} (TR_kT)^{-1} \bar{\xi}_k \\ &= \eta_k - \varphi_{k+1,k+1} TR_k^{-1} (T\bar{\xi}_k) \end{aligned}$$

$$\begin{aligned}
&= \eta_k - \varphi_{k+1, k+1} T R_k^{-1} \xi_k \\
&= \eta_k - \varphi_{k+1, k+1} T \eta_k
\end{aligned} \tag{2.5.5}$$

以此代入第二等式, 得

$$\begin{aligned}
\rho_{k+1} &= \varphi_{k+1, k+1} + \bar{\xi}_k^T (\eta_k - \varphi_{k+1, k+1} T \eta_k) \\
&= \varphi_{k+1, k+1} - \varphi_{k+1, k+1} \bar{\xi}_k^T \eta_k + \bar{\xi}_k^T \eta_k
\end{aligned}$$

由此解得

$$\varphi_{k+1, k+1} = (\rho_{k+1} - \bar{\xi}_k^T \eta_k) (1 - \bar{\xi}_k^T \eta_k)^{-1} \tag{2.5.6}$$

(2.5.5)式和(2.5.6)式即为(2.5.3)中的后两式, 又 $\varphi_{11} = \rho_1$ 显然成立。至此, 递推公式证完。

§ 5.3 偏相关函数的概率含义

偏相关函数 φ_{kk} 是在给定了 $w_{i-1}, w_{i-2}, \dots, w_{i-k+1}$ 的条件下, w_i 与 w_{i-k} 之间的条件相关函数。

设 $\hat{w}_i$ 和 $\hat{w}_{i-k}^*$ 分别表示在给定 $w_{i-1}, \dots, w_{i-k+1}$ 的条件下, w_i 和 w_{i-k} 的线性最小方差估计, 且分别记为

$$\begin{aligned}
\hat{w}_i &\triangleq \hat{E}(w_i | w_{i-1}, w_{i-2}, \dots, w_{i-k+1}) \\
\hat{w}_{i-k}^* &\triangleq \hat{E}(w_{i-k} | w_{i-1}, w_{i-2}, \dots, w_{i-k+1})
\end{aligned} \tag{2.5.7}$$

由线性最小方差估计的性质可得, $\hat{w}_i, \hat{w}_{i-k}^*$ 是在 $\{w_{i-1}, \dots, w_{i-k+1}\}$ 所张成的线性空间上的正交投影。正态情形下, 投影就是条件均值。令

$$\tilde{w}_i = w_i - \hat{w}_i, \tilde{w}_{i-k}^* = w_{i-k} - \hat{w}_{i-k}^* \tag{2.5.8}$$

于是上面的结论可以写成如下的定理:

定理 设 φ_{kk} 是 $\{w_i\}$ 的偏相关函数, 则

$$\varphi_{kk} = (E \tilde{w}_i \tilde{w}_{i-k}^*) (E \tilde{w}_i^2 E \tilde{w}_{i-k}^{*2})^{-\frac{1}{2}} \tag{2.5.9}$$

证明 令 $\mathbf{x} = (w_i, w_{i-k})^T, \mathbf{y} = (w_{i-1}, w_{i-2}, \dots, w_{i-k+1})^T$ 利用 $\{w_i\}$ 的零均值性, 由(1.4.15)和(1.4.16)式得

$$\begin{aligned}
\hat{\mathbf{x}} &= E(\mathbf{x} | \mathbf{y}) = E(\mathbf{x} \mathbf{y}^T) E(\mathbf{y} \mathbf{y}^T)^{-1} \mathbf{y} \\
E \hat{\mathbf{x}} \hat{\mathbf{x}}^T &= E(\mathbf{x} - \hat{\mathbf{x}})(\mathbf{x} - \hat{\mathbf{x}})^T \\
&= E \mathbf{x} \mathbf{x}^T - E \mathbf{x} \hat{\mathbf{x}}^T - E \hat{\mathbf{x}} \mathbf{x}^T + E \hat{\mathbf{x}} \hat{\mathbf{x}}^T
\end{aligned}$$

由于 $\hat{\mathbf{x}}$ 是 $\mathbf{x}$ 在 $\mathbf{y}$ 张成的线性空间上的投影, 因此

$$E(\mathbf{x} - \hat{\mathbf{x}})\hat{\mathbf{x}}^T = 0, \text{ 即 } E\mathbf{x}\hat{\mathbf{x}}^T = E\hat{\mathbf{x}}\hat{\mathbf{x}}^T$$

将此结果代入上式, 得

$$\begin{aligned} E\tilde{\mathbf{x}}\tilde{\mathbf{x}}^T &= E\mathbf{x}\mathbf{x}^T - E\hat{\mathbf{x}}\hat{\mathbf{x}}^T \\ &= E\mathbf{x}\mathbf{x}^T - (E\mathbf{x}\mathbf{y}^T)(E\mathbf{y}\mathbf{y}^T)^{-1}(E\mathbf{y}\mathbf{x}^T) \end{aligned}$$

利用 § 5.2 中的关系式(2.5.4), 并注意到

$$E\mathbf{x}\mathbf{x}^T = \gamma_0 \begin{pmatrix} 1 & \rho_k \\ \rho_k & 1 \end{pmatrix}$$

$$E\mathbf{y}\mathbf{y}^T = \gamma_0 R_{k-1}$$

$$E\mathbf{x}\mathbf{y}^T = \gamma_0 \begin{pmatrix} \rho_1 & \rho_2 & \cdots & \rho_{k-1} \\ \rho_{k-1} & \rho_k & \cdots & \rho_1 \end{pmatrix} = \gamma_0 \begin{pmatrix} \xi_{k-1}^T \\ \bar{\xi}_{k-1}^T \end{pmatrix}$$

得

$$\begin{aligned} E(\tilde{\mathbf{x}}\tilde{\mathbf{x}}^T) &= \begin{pmatrix} E\tilde{w}_i^2 & E\tilde{w}_i\tilde{w}_{i-k}^* \\ E\tilde{w}_{i-k}^*\tilde{w}_i & E\tilde{w}_{i-k}^{*2} \end{pmatrix} \\ &= \gamma_0 \left\{ \begin{pmatrix} 1 & \rho_k \\ \rho_k & 1 \end{pmatrix} - \begin{pmatrix} \xi_{k-1}^T \\ \bar{\xi}_{k-1}^T \end{pmatrix} R_{k-1}^{-1} (\xi_{k-1}, \bar{\xi}_{k-1}) \right\} \\ &= \gamma_0 \left\{ \begin{pmatrix} 1 & \rho_k \\ \rho_k & 1 \end{pmatrix} - \begin{pmatrix} \xi_{k-1}^T \\ \bar{\xi}_{k-1}^T \end{pmatrix} (R_{k-1}^{-1} \xi_{k-1}, R_{k-1}^{-1} \bar{\xi}_{k-1}) \right\} \\ &= \gamma_0 \left\{ \begin{pmatrix} 1 & \rho_k \\ \rho_k & 1 \end{pmatrix} - \begin{pmatrix} \xi_{k-1}^T \\ \bar{\xi}_{k-1}^T \end{pmatrix} (\eta_{k-1}, T\eta_{k-1}) \right\} \\ &= \gamma_0 \left\{ \begin{pmatrix} 1 & \rho_k \\ \rho_k & 1 \end{pmatrix} - \begin{pmatrix} \xi_{k-1}^T \eta_{k-1} & \xi_{k-1}^T T\eta_{k-1} \\ \bar{\xi}_{k-1}^T \eta_{k-1} & \bar{\xi}_{k-1}^T T\eta_{k-1} \end{pmatrix} \right\} \end{aligned}$$

从而

$$\begin{pmatrix} E\tilde{w}_i^2 & E\tilde{w}_i\tilde{w}_{i-k}^* \\ E\tilde{w}_{i-k}^*\tilde{w}_i & E\tilde{w}_{i-k}^{*2} \end{pmatrix} = \gamma_0 \begin{pmatrix} 1 - \xi_{k-1}^T \eta_{k-1} & \rho_k - \xi_{k-1}^T T\eta_{k-1} \\ \rho_k - \bar{\xi}_{k-1}^T T\eta_{k-1} & 1 - \bar{\xi}_{k-1}^T \eta_{k-1} \end{pmatrix} \quad (2.5.10)$$

由此式及(2.5.6)式即得

$$\begin{aligned} & (E\tilde{w}_i\tilde{w}_{i-k}^*)(E\tilde{w}_i^2 E\tilde{w}_{i-k}^{*2})^{-\frac{1}{2}} \\ &= (\rho_k - \xi_{k-1}^T T\eta_{k-1})(1 - \xi_{k-1}^T \eta_{k-1})^{-1} \\ &= \varphi_{kk} \end{aligned}$$

定理证毕。

§ 5.4 AR(p)序列偏相关函数的截尾性

现在,我们来回答 § 5 开头所提出的问题:什么样的参数表征体现了 AR(p)序列的独有特性。

定理 平稳零均值序列 $\{w_t\}$ 为 p 阶自回归序列的充分必要条件是 $\{w_t\}$ 的偏相关函数 p 步截尾。

证明 先证明定理的必要性,即 AR(p) 序列的偏相关函数 φ_{kk} 必定 p 步截尾。

将 $w_t = \sum_{i=1}^p \varphi_i w_{t-i} + a_t$ 代入 § 5.1 开头偏相关函数的定义式,得

$$\delta = E \left(\sum_{j=1}^p \varphi_j w_{t-j} + a_t - \sum_{j=1}^k \varphi_{kj} w_{t-j} \right)^2$$

令 $k \geq p$, 利用性质 $E a_t w_{t-j} = 0 (j > 0)$, 上式为

$$\begin{aligned} \delta &= E \left(a_t + \sum_{j=1}^p (\varphi_j - \varphi_{kj}) w_{t-j} - \sum_{j=p+1}^k \varphi_{kj} w_{t-j} \right)^2 \\ &= \sigma_a^2 + E \left(\sum_{j=1}^p (\varphi_j - \varphi_{kj}) w_{t-j} - \sum_{j=p+1}^k \varphi_{kj} w_{t-j} \right)^2 \geq \sigma_a^2 \end{aligned}$$

显然,为使 δ 达极小,应当取

$$\varphi_{kj} = \begin{cases} \varphi_j & 1 \leq j \leq p \\ 0 & p+1 \leq j \leq k \end{cases} \quad (2.5.11)$$

这就是说 AR(p)模型的 φ_{kk} 是 p 步截尾的。由证明过程还得到,对于 AR(p)序列,恒有 $\varphi_{pj} \equiv \varphi_j$ 。这个性质在今后常用到。

再证充分性。即若 $\{\varphi_{kk}\}$ 为 p 步截尾,则平稳零均值序列必为 AR(p)序列。

由条件 $\varphi_{pp} \neq 0, \varphi_{kk} = 0 (k > p)$ 及偏相关函数的递推式

$$\varphi_{k+1,j} = \varphi_{kj} - \varphi_{k+1,k+1} \varphi_{k,k+1-j}, k \geq 1$$

用数学归纳法容易推得,对于 $k \geq p+1$,有

$$\varphi_{kj} = \begin{cases} \varphi_{pj}, & 1 \leq j \leq p \\ 0 & p+1 \leq j \leq k \end{cases}$$

由此式及

$$\varphi_{k+1,k+1} = \left(\rho_{k+1} - \sum_{i=1}^k \rho_{k+1-i} \varphi_{ki} \right) \left(1 - \sum_{i=1}^k \rho_i \varphi_{ki} \right)^{-1}$$

得
$$\rho_{k+1} - \sum_{i=1}^p \rho_{k+1-i} \varphi_{pi} = 0, \quad k \geq p$$

另一方面,由偏相关函数的定义(2.5.1)式知,此式对于 $0 < k < p$ 也成立,归结起来,即得如下的差分方程

$$\rho_k = \sum_{i=1}^p \rho_{k-i} \varphi_{pi}, \quad k \geq 1$$

等价地,自协方差函数 γ_k 也满足差分方程

$$\gamma_k = \sum_{i=1}^p \gamma_{k-i} \varphi_{pi}, \quad k \geq 1$$

令
$$\varphi(B) = 1 - \sum_{i=1}^p \varphi_{pi} B^i$$

上式即为
$$\varphi(B) \gamma_k = 0 \quad k \geq 1$$

令
$$\varphi(B) w_t \triangleq a_t$$

则有
$$E a_{t+k} a_t = E \{ \varphi(B) w_{t+k} \varphi(B) w_t \}$$

$$= \varphi(B) E \left\{ w_{t+k} \left(w_t - \sum_{i=1}^p \varphi_{pi} w_{t-i} \right) \right\}$$

$$= \varphi(B) \left\{ \gamma_k - \sum_{i=1}^p \varphi_{pi} \gamma_{k+i} \right\}$$

$$= \varphi(B) \gamma_k - \sum_{i=1}^p \varphi_{pi} \varphi(B) \gamma_{k+i}$$

$$= \begin{cases} 0 & k \geq 1 \\ \varphi(B) \gamma_0 \triangleq 0 & k = 0 \end{cases}$$

由此证得 $\{a_i\}$ 为白噪声列, 且当 $k \geq 1$ 时,

$$E a_{i+k} w_i = \varphi(B) E w_{i+k} w_i = \varphi(B) \gamma_k = 0$$

最后, 由于 φ_{pi} 是 Yule-Walker 方程的解, 因此, $\varphi(B)$ 的根全都在单位圆外, 故 $\{w_i\}$ 必为 AR(p) 序列。定理证毕。

§ 5.5 MA 和 ARMA 序列偏相关系数的拖尾性

利用 § 5.3 中的记号和结果, 不难证明 MA 和 ARMA 序列的偏相关函数被负指数函数所控制, 即它们的 φ_{kk} 具有拖尾性。

$$\text{令 } u_k = \sum_{l=1}^{k-1} I_l w_{i-l} \quad v_k = \sum_{l=k}^{\infty} I_l w_{i-l}$$

式中 I_l 是逆函数。由 w_i 的逆转形式 (2.2.12) 式和线性最小方差估计的性质, 可得

$$\begin{aligned} w_i &= a_i + u_k + v_k \\ \tilde{w}_i &= w_i - \hat{w}_i = a_i + u_k + v_k - \hat{E}(a_i + u_k + v_k | w_{i-1}, \dots, w_{i-k+1}) \\ &= a_i + u_k + v_k - u_k - \hat{v}_k = a_i + \tilde{v}_k \end{aligned}$$

由此知

$$E \tilde{w}_i^2 = E a_i^2 + E \tilde{v}_k^2 \geq \sigma_a^2 \quad (2.5.12)$$

另一方面, 由 (2.5.10) 式可得

$$E \tilde{w}_{i-k}^{*2} = E \tilde{w}_i^2 \geq \sigma_a^2 \quad (2.5.13)$$

利用 I_l 的负指数衰减性, 由 (2.2.17) 式可得

$$\begin{aligned} E v_k^2 &= \sum_{j,l=k}^{\infty} I_j \gamma_{j-l} I_l \leq \gamma_0 \sum_{j,l=k}^{\infty} I_j I_l \\ &\leq \gamma_0 \left(\sum_{l=k}^{\infty} |I_l| \right)^2 \leq \gamma_0 g_2^2 \left(\sum_{l=k}^{\infty} e^{-g_1 l} \right)^2 \\ &\leq g_3 e^{-g_4 k} \end{aligned}$$

式中 g_1, g_2, g_3, g_4 均为某适当的正常数。

另外, 利用 $E a_i w_{i-j} = 0 (j > 0)$ 可得

$$\begin{aligned} |E \tilde{w}_i \tilde{w}_{i-k}^*| &= |E \tilde{v}_k \tilde{w}_{i-k}^*| \leq (E \tilde{v}_k^2 E \tilde{w}_{i-k}^{*2})^{\frac{1}{2}} \\ &\leq (E v_k^2 E w_{i-k}^2)^{\frac{1}{2}} \leq \sqrt{\gamma_0} \sqrt{g_3} e^{-\frac{1}{2} g_4 k} \\ &= g_5 e^{-g_4 k} \end{aligned} \quad (2.5.14)$$

由(2.5.12)—(2.5.14)得

$$|\varphi_{kk}| = \frac{|E\tilde{w}_t \tilde{w}_{t-k}^*|}{(E\tilde{w}_t^2 E\tilde{w}_{t-k}^{*2})^{\frac{1}{2}}} \leq \frac{1}{\sigma_a^2} g_5 e^{-g_6 k} - g_7 e^{-g_8 k}$$

式中 g_5, g_6, g_7 同前定义。至此证明了本节的结论。

至此为止,我们已经介绍了 ARMA 模型的分类、性质及其自相关函数与偏相关函数的概念。现将本章主要内容综合列于下表:

表 2.1 ARMA 序列的分类性质一览表

模型类别	AR(p)	MA(q)	ARMA(p, q)
模型方程	$\varphi(B)w_t = a_t$	$w_t = \theta(B)a_t$	$\varphi(B)w_t = \theta(B)a_t$
平稳条件	$\varphi(w) = 0$ 的根模大于 1	无条件平稳	$\varphi(w) = 0$ 的根模大于 1
可逆条件	无条件可逆	$\theta(w) = 0$ 的根模大于 1	$\theta(w) = 0$ 的根模大于 1
传递形式	$w_t = \varphi^{-1}(B)a_t$	$w_t = \theta(B)a_t$	$w_t = \varphi^{-1}(B)\theta(B)a_t$
逆转形式	$a_t = \varphi(B)w_t$	$a_t = \theta^{-1}(B)w_t$	$a_t = \theta^{-1}(B)\varphi(B)w_t$
格林函数	拖尾	截尾	拖尾
逆函数	截尾	拖尾	拖尾
自相关函数	拖尾	截尾	拖尾
偏相关函数	截尾	拖尾	拖尾

第三章 ARMA 序列的参数估计

时序分析的主要手段,是对数据用数学模型去近似描述,进而从模型入手,研究数据的本质,达到预测和控制的目的。因此,在掌握了 ARMA 模型基本概念的基础上,就应该进一步探讨如何对数据进行模型识别和拟合的问题。

由第二章论证的“差分方程平稳解与有理谱密度之间一一对应”的关系可见,一个零均值的平稳序列 $\{w_t\}$ 一定可以用 ARMA (p, q) 模型去(近似)描述。因此,本章着重研究的问题是,如何对平稳零均值随机序列 $\{w_t\}$ 的一个长度为 N 的“现实”,建立 ARMA (p, q) 模型。对于不满足上述条件的序列,留待第四章和第五章去讨论。

由 ARMA (p, q) 模型的结构和性质可知,序列 $\{w_t\}$ 的建模主要包含参数估计和阶数识别两大内容,大致分为以下几个步骤:

1. 相关分析判别模型类别。这一步的任务是计算序列 $\{w_t\}$ 的样本自相关函数与样本偏相关函数,并由它们的截尾性和拖尾性来进行模型类别的判断。
2. 在阶数给定的情形下,进行模型参数的初步估计。
3. 在初估计基础上作参数的精细估计。
4. 识别模型的阶数。

本章将围绕关于参数估计的前三步内容,介绍有关的原理、计算方法和技巧。而序列的统计检验与模型阶的判别,留待第四章讨论。

§ 1 随机序列的相关矩估计

模型类别的相关分析

§ 1.1 自协方差函数 γ_k 和自相关函数 ρ_k 的估计

γ_k 和 ρ_k 的样本估计量通常有如下两种类型:

$$\begin{aligned}\hat{\gamma}_k &= \hat{\gamma}_{-k} \triangleq \frac{1}{N} \sum_{i=1}^{N-k} w_i w_{i+k} \\ \hat{\rho}_k &= \hat{\rho}_{-k} \triangleq \hat{\gamma}_k / \hat{\gamma}_0 \quad k=0, 1, 2, \dots\end{aligned}\quad (3.1.1)$$

或

$$\begin{aligned}\hat{\gamma}_k^* &= \hat{\gamma}_{-k}^* \triangleq \frac{1}{N-k} \sum_{i=1}^{N-k} w_i w_{i+k} \\ \hat{\rho}_k^* &= \hat{\rho}_{-k}^* \triangleq \hat{\gamma}_k^* / \hat{\gamma}_0^* \quad k=0, 1, 2, \dots\end{aligned}\quad (3.1.2)$$

式中 N 表示样本的长度。

显然, $\hat{\gamma}_k^*$ 是 γ_k 的无偏估计, 而 $\hat{\gamma}_k$ 是有偏的。比较 (3.1.1) 和 (3.1.2) 式可见, $\hat{\gamma}_k = \frac{N-k}{N} \hat{\gamma}_k^*$, 因此, $\hat{\gamma}_k$ 和 $\hat{\gamma}_k^*$ 是渐近相等的。

通常都以 $\hat{\gamma}_k$ 和 $\hat{\rho}_k$ 作为 ARMA 序列 $\{w_i\}$ 的 γ_k 和 ρ_k 的样本估计量, 而较少用到 $\hat{\gamma}_k^*$ 和 $\hat{\rho}_k^*$, 这是因为 (3.1.1) 所给出的 $\hat{\gamma}_k$ 具有正定性。

可以证明, 只要 $\{w_i\}$ 中的样本值不全为零, $\{\hat{\gamma}_k\}$ 必是正定序列, 而 $\{\hat{\gamma}_k^*\}$ 不一定有此性质。正定性常常是相关分析和参数估计的前提条件。

事实上, 若令

$$F_N = \begin{pmatrix} w_1 & w_2 & \cdots & w_N & 0 \\ 0 & \cdot & \cdot & \cdot & \cdot \\ & w_1 & w_2 & \cdots & w_N \end{pmatrix}$$

它是一个 $m \times (m + N - 1)$ 阶矩阵, m 为任一给定的正整数, 则显然样本自协方差阵可以表示成

$$\hat{\Gamma}_N = (\hat{\gamma}_{ij})_{m \times m} = \frac{1}{N} F_N F_N^T$$

其第 i 行 j 列元

$$\hat{\gamma}_{ij} = \hat{\gamma}_{|i-j|} = \frac{1}{N} \sum_{t=1}^{N-|i-j|} w_t w_{t+|i-j|}$$

设 $\xi = (\xi_1, \xi_2, \dots, \xi_m)^T$ 是任一非零向量, 则由已知条件“ $\{w_i\}$ 中样

本值不全为零”不难证明, $\xi^r F_N$ 的 $(m+N-1)$ 个分量中, 至少有一个不为零, 于是 $\xi^r \hat{\Gamma}_N \xi = \frac{1}{N} \xi^r F_N F_N^r \xi = \frac{1}{N} \xi^r F_N (\xi^r F_N)^r > 0$ 由此证明了 $\{\hat{\gamma}_k\}$ 是正定列。

下面, 我们举例说明 $\hat{\gamma}_k^*$ 的不定性。

设 $\{w_i\}$ 是长度等于 3 的样本列 $\{a, 0, -a\}$, 经计算可得

$$\hat{\gamma}_0^* = \frac{2}{3}a^2 \quad \hat{\gamma}_1^* = 0 \quad \hat{\gamma}_2^* = -a^2$$

$$\hat{\Gamma}_3^* = \begin{pmatrix} \frac{2}{3}a^2 & 0 & -a^2 \\ 0 & \frac{2}{3}a^2 & 0 \\ -a^2 & 0 & \frac{2}{3}a^2 \end{pmatrix}$$

若取 $\xi^r = (1, 0, 0)$, 则

$$\xi^r \hat{\Gamma}_3^* \xi = \frac{2}{3}a^2 > 0$$

若取 $\xi^r = (1, 0, 1)$, 则

$$\xi^r \hat{\Gamma}_3^* \xi = -\frac{2}{3}a^2 < 0$$

由 (3.1.1) 和 (3.1.2) 式可见, $\hat{\gamma}_k^*$ 是 γ_k 的无偏估计, $E\hat{\gamma}_k^* = \gamma_k$, 而 $\hat{\gamma}_k$ 是 γ_k 的有偏估计, $E\hat{\gamma}_k = \frac{N-k}{N}\gamma_k$ 。然而, 当 N 充分大后, $\hat{\gamma}_k$ 和 $\hat{\rho}_k$ 就是 γ_k 和 ρ_k 的渐近无偏估计:

$$\lim_{N \rightarrow \infty} E\hat{\gamma}_k = \gamma_k, \quad \lim_{N \rightarrow \infty} E\hat{\rho}_k = \rho_k。$$

此外, $\hat{\gamma}_k$ 和 $\hat{\rho}_k$ 还是 γ_k 和 ρ_k 的相容估计, 且具有渐近正态性。 $\hat{\gamma}_k$ 和 $\hat{\rho}_k$ 的渐近误差方差为

$$\begin{aligned} \text{var}(\hat{\gamma}_k) &\triangleq E\hat{\gamma}_k^2 = E(\hat{\gamma}_k - \gamma_k)^2 \approx \frac{1}{N} \sum_{l=-\infty}^{\infty} (\gamma_k^2 - \gamma_{l+k}\gamma_{l-k}) \\ \text{var}(\hat{\rho}_k) &\triangleq E\hat{\rho}_k^2 = E(\hat{\rho}_k - \rho_k)^2 \end{aligned} \quad (3.1.3)$$

$$\approx \frac{1}{N} \sum_{l=-\infty}^{\infty} (\rho_l^2 + \rho_{l+k} \rho_{l-k} + 2 \rho_k^2 \rho_l - 4 \rho_k \rho_l \rho_{l-k})$$

此公式称为 Bartlett 公式。由公式可见, $\hat{\gamma}_k$ 和 $\hat{\rho}_k$ 的渐近误差方差, 与样本长度 N 成反比, 比例常数和真值 γ_k 及 ρ_k 有关。因此, 可以通过加大样本长度的方法来达到提高估计精度的目的。

由公式(3.1.3)还可从估计精度来推算所需样本量 N 的大小。例如, 我们希望估计量 $\hat{\rho}_k$ 和 $\hat{\gamma}_k$ 的均方误差达到一定的精度要求, 比如, 要求 $\text{var}(\hat{\gamma}_0) < 0.01$ 或 $\text{var}(\hat{\gamma}_0) < 0.01 \gamma_0$ (前者为绝对精度, 后者为相对精度)。首先, 我们利用已有的 N 个观测数据, 由(3.1.1)式计算出 $\hat{\gamma}_k$ 和 $\hat{\rho}_k$, 用以代替(3.1.3)式右端的 γ_k 和 ρ_k , 并以有穷和近似代替式中的无穷和 (由于 γ_k 和 ρ_k 具有指数衰减性, 此种代替是可行的)。由(3.1.3)中的两式分别算得 $\text{var}(\hat{\gamma}_k)$ 和 $\text{var}(\hat{\rho}_k)$, 如果达到了预定精度, 就认为样本长度取 N 是合适的, 否则就需加大样本长度。重复上述步骤, 直至合适为止。一般情形下, 重复一、两次便可达到目的。否则序列就可能不适宜用 ARMA 模型描述。

§ 1.2 偏相关函数 φ_{kk} 的估计

有了样本自相关函数, 就可以给出样本偏相关函数的定义。将第二章(2.5.1)式中的各个量代换成相应的样本估计量, 即得

$$\begin{pmatrix} 1 & \hat{\rho}_1 & \cdots & \hat{\rho}_{k-1} \\ \hat{\rho}_1 & 1 & \cdots & \hat{\rho}_{k-2} \\ \cdots & \cdots & \cdots & \cdots \\ \hat{\rho}_{k-1} & \hat{\rho}_{k-2} & \cdots & 1 \end{pmatrix} \begin{pmatrix} \hat{\varphi}_{k1} \\ \hat{\varphi}_{k2} \\ \vdots \\ \hat{\varphi}_{kk} \end{pmatrix} = \begin{pmatrix} \hat{\rho}_1 \\ \hat{\rho}_2 \\ \vdots \\ \hat{\rho}_k \end{pmatrix} \quad (3.1.4)$$

由(3.1.4)式解得的 $\hat{\varphi}_{kk}$ 就是序列 $\{w_t\}$ 的样本偏相关函数。同样地, 关于 φ_{kk} 的递推公式(2.5.3)也适用于 $\hat{\varphi}_{kk}$, 只要将式中各量都换成相应的样本估计量即可。

如果在 $\hat{\varphi}_{kk}$ 的计算中, 对 ρ_k 使用的是(3.1.1)式的估计量, 那么和 $\hat{\rho}_k$ 一样, $\hat{\varphi}_{kk}$ 也具备一些好的渐近性质。可以证明, 对于平稳正态序列 $\{w_t\}$, 当样本长度 N 充分大以后, $\hat{\varphi}_{kk}$ 是 φ_{kk} 的渐近无偏

估计和相容估计, $\hat{\varphi}_{kk}$ 的分布渐近正态, 且 $E\hat{\varphi}_{kk}^2 \triangleq E(\varphi_{kk} - \hat{\varphi}_{kk})^2 \approx \frac{1}{N}$ 。

§ 1.3 模型的初步识别 · 样本矩的截尾性检验

第二章讨论了序列自、偏相关函数截尾的充分必要条件, 因此我们可以这些理论为依据, 在对于样本数据建立模型之前, 通过对于 $\hat{\rho}_k$ 和 $\hat{\varphi}_{kk}$ 的计算和分析, 初步判别模型应属的类型。这一工作, 称为相关分析。显然, 如果样本自相关函数 $\hat{\rho}_k$ 在 q 步截尾, 即可判断 $\{w_t\}$ 是 $MA(q)$ 序列; 如果样本偏相关函数 $\hat{\varphi}_{kk}$ 是在 p 步截尾, 即可判断 $\{w_t\}$ 是 $AR(p)$ 序列; 而如果 $\hat{\rho}_k$ 和 $\hat{\varphi}_{kk}$ 都不截尾, 只是负指数衰减(拖尾), 那么可认为 $\{w_t\}$ 是 $ARMA$ 序列。对于截尾性序列, 模型阶数随着模型类别的判断而确定, 只需估计相应的参数即可; 而对于拖尾性序列, 参数估计和模型阶数的识别都将比较复杂。然而, 客观的大量数字序列中, 明显地具有截尾性的并不多见, 而多数都要用 $ARMA$ 混合模型去进行拟合。

理论自相关函数 ρ_k 和理论偏相关函数 φ_{kk} 的截尾性, 是指它们在某一步之后全部为零值。而对于估计量 $\hat{\rho}_k$ 和 $\hat{\varphi}_{kk}$ 来说, 它们是随机变量, 这几乎是不可能做到的。即使真正的 ρ_k 或 φ_{kk} 具有截尾性, 由数据求得的 $\hat{\rho}_k$ 或 $\hat{\varphi}_{kk}$ 也只能做到于某步之后在零的上下波动。因此, 对于 $\hat{\rho}_k$ 和 $\hat{\varphi}_{kk}$ 的截尾性, 只可能凭借统计手段来进行检验和判别。

对于 $MA(q)$ 序列, 由于当 $k > q$ 时, $\rho_k \equiv 0$, 故由 (3.1.3) 式可见, $\hat{\rho}_k, k > q$ 的分布将渐近于正态 $\mathcal{N}\left(0, \frac{1}{N}\left(1 + 2 \sum_{i=1}^q \rho_i^2\right)\right)$ 。因此, 由正态分布的性质, 当 N 充分大时, 下面的等式应当近似地成立

$$\begin{aligned} P\left(|\hat{\rho}_k| \leq \frac{1}{\sqrt{N}}\left(1 + 2 \sum_{i=1}^q \rho_i^2\right)^{\frac{1}{2}}\right) &= 68.3\% \\ P\left(|\hat{\rho}_k| \leq \frac{2}{\sqrt{N}}\left(1 + 2 \sum_{i=1}^q \rho_i^2\right)^{\frac{1}{2}}\right) &= 95.5\% \end{aligned} \quad (3.1.5)$$

利用这一性质, 可以判别 $\hat{\rho}_k$ 的截尾性。对于每一个 $q > 0$, 检查

$\hat{\rho}_{q+1}, \hat{\rho}_{q+2}, \dots, \hat{\rho}_{q+M}$ (根据经验, M 一般取 $\sqrt{N}$ 左右) 中满足 $|\hat{\rho}_{k,i}| \leq \frac{1}{\sqrt{N}} \left(1 + 2 \sum_{i=1}^q \hat{\rho}_i^2\right)^{\frac{1}{2}}$ 或 $|\hat{\rho}_k| \leq \frac{2}{\sqrt{N}} \left(1 - 2 \sum_{i=1}^q \hat{\rho}_i^2\right)^{\frac{1}{2}}$ 的个数是否占全体 (M 个) 的 68.3% 或 95.5%, 如果在某个 q_0 之前, $\hat{\rho}_k$ 都明显地不能认为是 0, 而当 $q = q_0$ 时, $\hat{\rho}_{q_0+1}, \dots, \hat{\rho}_{q_0+M}$ 中满足不等式的次数达到了比例, 则可以近似地认为 $\hat{\rho}_k$ 是在 q_0 处截尾, 因而 $\{w_t\}$ 判定为 $MA(q_0)$ 序列。

对于 $\hat{\phi}_{kk}$ 的截尾性判别, 方法原则上与 $\hat{\rho}_k$ 类似, 可利用 $\hat{\phi}_{kk}$ 的渐近性, 即对于 $k > p$, 渐近地有 $\hat{\phi}_{kk} \sim \mathcal{N}\left(0, \frac{1}{N}\right)$ 且相互独立。

上面给出的截尾性判别方法是相当粗糙的, 很可能判出的结果与真实模型有较大的出入。在对实际数据建模时, 除非经过大量的统计判别, 或有可靠的物理背景, 能有把握判定模型的类别, 一般我们都用 ARMA 或高阶的 AR(M) (M 相当大) 去拟合, 有时也可在一般形式的模型确立后, 再从参数的特性来简化模型 (例如, 建立的 ARMA 模型经检验后可判定其自回归参数为零, 则可简化为滑动平均形式)。

§ 2 模型参数的初步估计——矩估计

根据 § 1 的原理初步识别了序列的类别之后, 我们就可以对于选定的某一组阶数 (p, q) , 进行模型的参数估计了。模型的参数估计, 一般情形下分两步进行, 第一步, 要设法找出参数的初步估计; 第二步, 在初步估计的基础上, 根据一定的估计准则, 求得模型参数在某种意义下的精细估计。参数的初估计往往手段比较直接, 方法也较简单, 但由于一些好的渐近性和优效性不一定能保证, 因此, 往往只是作为求精细估计的迭代初值。不过, 对于自回归模型, 本节给出的初估计在样本充分大后, 与 § 4 中的精估计几乎没有区别, 都可以作为最终的估计, 这一点将在今后详细讨论。

本节主要介绍在模型阶数给定的前提下, 用样本相关矩 $\hat{\rho}_{kk}$,

$\hat{\varphi}_k, \hat{\varphi}_{kk}$ 对模型参数进行估计的方法(简称矩估计法)。下面,我们对各类模型分别进行讨论。

§ 2.1 AR(p)模型参数的矩估计

由第二章§ 5.5 的(2.5.14)式可知,对于自回归模型 AR(p),恒有 $\varphi_{p,j} = \varphi_j, j = 1, 2, \dots, p$, 因此, 由(3.1.4)式, 即可得到 AR(p)模型自回归参数

$$\varphi = (\varphi_1, \varphi_2, \dots, \varphi_p)^T$$

的矩估计(显然,也可将式中的 $\hat{\rho}_j$ 都换成 $\hat{\gamma}_j$)

$$\begin{pmatrix} \hat{\varphi}_1 \\ \hat{\varphi}_2 \\ \vdots \\ \hat{\varphi}_p \end{pmatrix} = \begin{pmatrix} 1 & \hat{\rho}_1 & \cdots & \hat{\rho}_{p-1} \\ \hat{\rho}_1 & 1 & \cdots & \hat{\rho}_{p-2} \\ \vdots & \vdots & \ddots & \vdots \\ \hat{\rho}_{p-1} & \cdots & \hat{\rho}_1 & 1 \end{pmatrix}^{-1} \begin{pmatrix} \hat{\rho}_1 \\ \hat{\rho}_2 \\ \vdots \\ \hat{\rho}_p \end{pmatrix} \quad (3.2.1)$$

由此式求得的 $\hat{\varphi} = (\hat{\varphi}_1, \hat{\varphi}_2, \dots, \hat{\varphi}_p)^T$, 称为参数 φ 的 Yule-Walker 估计。§ 1.1 中证明了 $\{\hat{\gamma}_k\}$ 的正定性, 因此, (3.2.1)式中的逆矩阵存在, 自回归参数的矩估计存在唯一, 而且可以证明, $\hat{\varphi}$ 是属于平稳可逆域 $\Phi^{(p)}$ 的^[8]。

将(2.4.10)式中的诸量用相应的估计值代替, 便可得到 $\{a_i\}$ 序列的方差 σ_a^2 的矩估计

$$\hat{\sigma}_a^2 = \hat{\gamma}_0 - \sum_{j=1}^p \hat{\varphi}_j \hat{\gamma}_j = \hat{\gamma}_0 - \sum_{i,j=1}^p \hat{\varphi}_i \hat{\varphi}_j \hat{\gamma}_{j-i} \quad (3.2.2)$$

(3.2.1)和(3.2.2)式便是 AR(p)模型参数矩估计的全部公式。可见, AR(p)模型的矩估计非常简单, 它不仅具有平稳性和唯一性, 当 $\{w_t\}$ 是正态序列时, 和§ 1.2 中对于 $\hat{\varphi}_{kk}$ 的讨论类似, $\hat{\varphi} = (\hat{\varphi}_1, \hat{\varphi}_2, \dots, \hat{\varphi}_p)^T$ 也是 φ 的渐近无偏估计和相容估计, 且服从渐近正态分布。

下面, 举两个低阶 AR(p)模型的 Y-W 估计。

AR(1)模型

$$w_t - \varphi_1 w_{t-1} = a_t$$

由公式(3.2.1)和(3.2.2)得

$$\hat{\phi}_1 = \hat{\rho}_1 = \hat{\gamma}_1 / \hat{\gamma}_0 \quad \sigma_a^2 = \hat{\gamma}_0 - \hat{\gamma}_1 \hat{\phi}_1 = \hat{\gamma}_0 (1 - \hat{\rho}_1^2) \quad (3.2.3)$$

AR(2)模型

$$\begin{aligned} w_t - \varphi_1 w_{t-1} - \varphi_2 w_{t-2} &= a_t \\ \begin{pmatrix} \hat{\phi}_1 \\ \varphi_2 \end{pmatrix} &= \begin{pmatrix} 1 & \hat{\rho}_1 \\ \hat{\rho}_1 & 1 \end{pmatrix}^{-1} \begin{pmatrix} \hat{\rho}_1 \\ \hat{\rho}_2 \end{pmatrix} \\ \hat{\phi}_1 &= \frac{\hat{\rho}_1 (1 - \hat{\rho}_2)}{1 - \hat{\rho}_1^2} \quad \hat{\phi}_2 = \frac{\hat{\rho}_2 - \hat{\rho}_1^2}{1 - \hat{\rho}_1^2} \\ \hat{\sigma}_a^2 &= \hat{\gamma}_0 (1 - \hat{\phi}_1 \hat{\rho}_1 - \hat{\phi}_2 \hat{\rho}_2) \end{aligned} \quad (3.2.4)$$

具体计算 φ 的矩估计时, 也可借用第二章(2.5.3)式关于 φ_{kk} 的递推算法, 当 k 从 1 起递推到 $k = p$ 时, 求出的即是 $\varphi = (\varphi_1, \varphi_2, \dots, \varphi_p)^T$ 的矩估计, 只是式中诸量要改换成相应的估计值。

§ 2.2 MA(q)模型参数的矩估计

将第二章(2.4.3)式中的各量冠以“ $\hat{}$ ”号, 即可得到 MA(q)模型参数 $\theta = (\theta_1, \theta_2, \dots, \theta_q)^T$ 和 σ_a^2 与样本自协方差函数 $\hat{\gamma}_k$ 之间的关系式

$$\hat{\gamma}_k = \begin{cases} \hat{\sigma}_a^2 (1 + \hat{\theta}_1^2 + \hat{\theta}_2^2 + \dots + \hat{\theta}_q^2) & k=0 \\ \hat{\sigma}_a^2 (-\hat{\theta}_k + \hat{\theta}_1 \hat{\theta}_{k+1} + \dots + \hat{\theta}_{q-k} \hat{\theta}_q) & 1 \leq k \leq q \end{cases} \quad (3.2.5)$$

(3.2.5)式是含有 $q+1$ 个未知元的二次方程组, 为了要由此式求得 θ 和 σ_a^2 的矩估计, 我们需进一步讨论这个二次方程的求解方法

1. 直接解法: 当 $q=1$ 时, (3.2.5)式为

$$\begin{cases} \hat{\gamma}_0 = \hat{\sigma}_a^2 (1 + \hat{\theta}_1^2) \\ \hat{\gamma}_1 = -\hat{\sigma}_a^2 \hat{\theta}_1 \end{cases}$$

由后一式解得 $\hat{\theta}_1 = -\hat{\gamma}_1 / \hat{\sigma}_a^2$, 代入前一式得

$$\hat{\sigma}_a^4 - \hat{\gamma}_0 \hat{\sigma}_a^2 + \hat{\gamma}_1^2 = 0$$

由此解得

$$\begin{cases} \hat{\sigma}_a^2 = \frac{\hat{\gamma}_0}{2} (1 \pm \sqrt{1 - 4 \hat{\rho}_1^2}) \\ \hat{\theta}_1 = -\hat{\gamma}_1 / \hat{\sigma}_a^2 = \frac{-2 \hat{\rho}_1}{1 \pm \sqrt{1 - 4 \hat{\rho}_1^2}} \end{cases}$$

式中给出了 MA(1) 参数矩估计的两种可能形式, 究竟应取哪一种, 需由可逆性条件来判断。由第二章(2.3.6)式知 MA(1) 的可逆域限制了 $|\theta_1| < 1$, 因此, 必需选择模小于 1 的值作为 θ_1 的矩估计。

由于
$$\frac{2\hat{\rho}_1}{1 + \sqrt{1 - 4\hat{\rho}_1^2}} \cdot \frac{2\hat{\rho}_1}{1 - \sqrt{1 - 4\hat{\rho}_1^2}} = 1$$

因此

$$\left| \frac{2\hat{\rho}_1}{1 + \sqrt{1 - 4\hat{\rho}_1^2}} \right| < 1$$

符合可逆性条件的 MA(1) 参数的矩估计应为

$$\hat{\sigma}_a^2 = \hat{\gamma}_0 \frac{1 + \sqrt{1 - 4\hat{\rho}_1^2}}{2} \quad \hat{\theta}_1 = \frac{-2\hat{\rho}_1}{1 + \sqrt{1 - 4\hat{\rho}_1^2}} \quad (3.2.6)$$

当 $q=2$ 时, (3.2.5) 式为

$$\begin{cases} \hat{\gamma}_0 = \hat{\sigma}_a^2 (1 + \hat{\theta}_1^2 + \hat{\theta}_2^2) \\ \hat{\gamma}_1 = \hat{\sigma}_a^2 (-\hat{\theta}_1 + \hat{\theta}_1 \hat{\theta}_2) \\ \hat{\gamma}_2 = -\hat{\sigma}_a^2 \hat{\theta}_2 \end{cases}$$

由此方程组后两式解出

$$\hat{\theta}_2 = -\hat{\gamma}_2 / \hat{\sigma}_a^2 \quad \hat{\theta}_1 = -\frac{\hat{\gamma}_1}{\hat{\sigma}_a^2 + \hat{\gamma}_2}$$

代入方程组中第一式, 得

$$\hat{\gamma}_0 = \hat{\sigma}_a^2 \left(1 + \frac{\hat{\gamma}_2^2}{\hat{\sigma}_a^4} + \frac{\hat{\gamma}_1^2}{(\hat{\sigma}_a^2 + \hat{\gamma}_2)^2} \right)$$

此式可化为关于 $\hat{\sigma}_a^2$ 的三次方程, 因此应得到 $\hat{\sigma}_a^2$ 的三种可能解, 相应地, $\hat{\theta}_1, \hat{\theta}_2$ 也有三种可能解。同样, 根据可逆性条件, 从中可选出唯一的合理解来。事实上, 由第二章给出的 MA(2) 的可逆域(2.3.7)式, 经过初等但很烦琐的讨论, 可以解出 θ_1, θ_2 和 $\hat{\sigma}_a^2$ 的矩估计分别为

$$\hat{\theta}_2 = \frac{1}{2} - \frac{1}{4\hat{\rho}_2} - \frac{1}{2\hat{\rho}_2} \sqrt{\left(\hat{\rho}_2 + \frac{1}{2} \right)^2 - \hat{\rho}_1^2}$$

$$\pm \sqrt{\left(\frac{1}{2} - \frac{1}{4\hat{\rho}_2} - \frac{1}{2\hat{\rho}_2} \sqrt{\left(\hat{\rho}_2 + \frac{1}{2}\right)^2 - \hat{\rho}_1^2}\right)^2 - 1}$$

(式中的“±”号依 $\hat{\rho}_2 > 0$ 或 < 0 而分别取“+”或“-”)

$$\hat{\theta}_1 = \frac{\hat{\rho}_1 \hat{\theta}_1}{\hat{\rho}_2 (1 - \hat{\theta}_2)} \quad \hat{\sigma}_a^2 = -\hat{\rho}_0 \frac{\hat{\rho}_2}{\hat{\theta}_2} \quad (3.2.7)$$

由上两例可见,由(3.2.5)式直接用消去法求解 MA(q) 模型参数的矩估计时,最后总要求解关于 $\hat{\sigma}_a^2$ 的高次方程,这在 $q \geq 3$ 后一般是不易办到的。因此,这种直接解法一般只适宜于 q 较小或 q 虽大而高次方程易解的情形。对于 q 较大的一般情形,可以用下面的迭代法作矩估计。

2. 线性迭代算法: 将(3.2.5)式改写为

$$\begin{cases} \hat{\sigma}_a^2 = \hat{\rho}_0 (1 - \hat{\theta}_1^2 + \cdots + \hat{\theta}_q^2)^{-1} \\ \hat{\theta}_k = -\left(\frac{\hat{\rho}_k}{\hat{\sigma}_a^2} - \hat{\theta}_1 \hat{\theta}_{k+1} - \cdots - \hat{\theta}_{q-k} \hat{\theta}_q\right) \quad k=1, 2, \dots, q \end{cases} \quad (3.2.8)$$

在可逆域内,给出 $\hat{\theta}$ 和 $\hat{\sigma}_a^2$ 的一组初值(例如 $\hat{\theta} = 0, \hat{\sigma}_a^2 = \hat{\rho}_0$),代入(3.2.8)式右边,得到一步迭代值 $\hat{\sigma}_a^2(1)$ 和 $\hat{\theta}(1) = (\hat{\theta}_1(1), \dots, \hat{\theta}_q(1))^T$,再将其代入(3.2.8)式右端,求出第二步迭代值 $\hat{\sigma}_a^2(2)$ 和 $\hat{\theta}(2)$,以此方法重复迭代下去,直到某步 $\hat{\sigma}_a^2(m), \hat{\theta}(m)$ 与前一步 $\hat{\sigma}_a^2(m-1)$ 和 $\hat{\theta}(m-1)$ 出入不大时(即差别在预定的精度范围内),便停止迭代,以最后所得的 $\hat{\sigma}_a^2(m)$ 和 $\hat{\theta}(m)$ 作为 $\hat{\sigma}_a^2$ 和 $\hat{\theta}$ 的近似解。

3. Newton-Raphson 算法: 将(3.2.5)式改写为

$$\begin{cases} \hat{\rho}_0 = \hat{\sigma}_a^2 + (-\hat{\theta}_1 \hat{\sigma}_a)^2 + \cdots + (-\hat{\theta}_q \hat{\sigma}_a)^2 \\ \hat{\rho}_1 = \hat{\sigma}_a (-\hat{\theta}_1 \hat{\sigma}_a) + (-\hat{\theta}_1 \hat{\sigma}_a)(-\hat{\theta}_2 \hat{\sigma}_a) + \cdots + \\ \quad + (-\hat{\theta}_{q+1} \hat{\sigma}_a)(-\hat{\theta}_q \hat{\sigma}_a) \\ \dots \dots \\ \hat{\rho}_q = \hat{\sigma}_a (-\hat{\theta}_q \hat{\sigma}_a) \end{cases}$$

暂记 $\hat{\sigma}_k \triangleq -\hat{\sigma}_a \hat{\theta}_k (1 \leq k \leq q), \hat{\sigma}_0 \triangleq \hat{\sigma}_a$, 上式又可写成

$$\begin{cases} \hat{\sigma}_0^2 + \hat{\sigma}_1^2 + \cdots + \hat{\sigma}_q^2 - \hat{p}_0 = 0 \\ \hat{\sigma}_0 \hat{\sigma}_1 + \hat{\sigma}_1 \hat{\sigma}_2 + \cdots + \hat{\sigma}_{q-1} \hat{\sigma}_q - \hat{p}_1 = 0 \\ \cdots \\ \hat{\sigma}_0 \hat{\sigma}_q - \hat{p}_q = 0 \end{cases} \quad (3.2.9)$$

将上方程组左边各式依次记作 $\hat{f}_k \equiv \hat{f}_k(\hat{\sigma}_0, \hat{\sigma}_1, \cdots, \hat{\sigma}_q)$, $k=0, 1, \cdots, q$, 并记

$$\hat{\sigma} \triangleq \begin{pmatrix} \hat{\sigma}_0 \\ \hat{\sigma}_1 \\ \vdots \\ \hat{\sigma}_q \end{pmatrix} \quad \hat{f} \triangleq \begin{pmatrix} \hat{f}_0 \\ \hat{f}_1 \\ \vdots \\ \hat{f}_q \end{pmatrix}$$

$$F \triangleq \frac{\partial \hat{f}}{\partial \hat{\sigma}^T} = \begin{pmatrix} \frac{\partial \hat{f}_0}{\partial \hat{\sigma}_0} & \cdots & \frac{\partial \hat{f}_0}{\partial \hat{\sigma}_q} \\ \cdots & \cdots & \cdots \\ \frac{\partial \hat{f}_q}{\partial \hat{\sigma}_0} & \cdots & \frac{\partial \hat{f}_q}{\partial \hat{\sigma}_q} \end{pmatrix}$$

易见

$$F = \begin{pmatrix} \hat{\sigma}_0 & \hat{\sigma}_1 & \cdots & \hat{\sigma}_q \\ \hat{\sigma}_1 & \hat{\sigma}_2 & \cdots & \hat{\sigma}_q \\ \vdots & & \ddots & 0 \\ \hat{\sigma}_q & & & \hat{\sigma}_q \end{pmatrix} + \begin{pmatrix} \hat{\sigma}_0 & \hat{\sigma}_1 & \cdots & \hat{\sigma}_q \\ & \hat{\sigma}_0 & \cdots & \hat{\sigma}_{q-1} \\ 0 & & \ddots & \vdots \\ & & & \hat{\sigma}_q \end{pmatrix} \quad (3.2.10)$$

按照 Newton-Raphson 迭代原则, 如果第 i 步迭代值为 $\hat{\sigma}(i)$, 那么第 $i+1$ 步的 $\hat{\sigma}(i+1)$ 必须满足

$$\hat{f}(i) + F(i) (\hat{\sigma}(i+1) - \hat{\sigma}(i)) = 0$$

即

$$\hat{\sigma}(i+1) = \hat{\sigma}(i) - F^{-1}(i) \hat{f}(i) \quad (3.2.11)$$

给出了初值 $\hat{\sigma}(0)$, 便可依 (3.2.9) ~ (3.2.11) 式进行迭代计算, 并按线性迭代算法中的同样手段判断迭代的行止, 以迭代值 $\hat{\sigma}(m)$ 作为 (3.2.5) 式的近似解, 即

$$\hat{\sigma}_0^2 = \hat{\sigma}_0^2(m), \hat{\sigma}_k = -\hat{\sigma}_k(m) / \hat{\sigma}_0(m) \quad (1 \leq k \leq q) \quad (3.2.12)$$

§ 2.3 ARMA 模型参数的矩估计

对 ARMA(p, q) 模型求参数的矩估计, 比起前两类模型来, 就更为复杂了。具体说来, 可分以下三大步骤:

1. 给出自回归参数矢量 φ 的矩估计

$$\begin{pmatrix} \hat{\varphi}_1 \\ \hat{\varphi}_2 \\ \vdots \\ \hat{\varphi}_p \end{pmatrix} = \begin{pmatrix} \hat{\rho}_q & \hat{\rho}_{q-1} & \cdots & \hat{\rho}_{q-p+1} \\ \hat{\rho}_{q+1} & \hat{\rho}_q & \cdots & \hat{\rho}_{q-p+2} \\ \cdots & & & \\ \hat{\rho}_{q+p-1} & \hat{\rho}_{q+p-2} & \cdots & \hat{\rho}_q \end{pmatrix}^{-1} \begin{pmatrix} \hat{\rho}_{q+1} \\ \hat{\rho}_{q+2} \\ \vdots \\ \hat{\rho}_{q+p} \end{pmatrix} \quad (3.2.13)$$

由第二章(2.4.14)式知, 当逆矩阵存在时, 上式成立。

2. 令

$\bar{w}_t = w_t - \varphi_1 w_{t-1} - \cdots - \varphi_p w_{t-p}$, 对照(2.4.15)式知, 其协方差函数 $\gamma_k(\bar{w})$ 为

$$\gamma_k(\bar{w}) = \sum_{i,j=0}^p \varphi_i \varphi_j \gamma_{k+i-j}$$

再用样本矩估计值代入, 得

$$\hat{\gamma}_k(\bar{w}) = \sum_{i,j=0}^p \hat{\varphi}_i \hat{\varphi}_j \hat{\gamma}_{k+i-j} \quad (3.2.14)$$

3. 将 $\bar{w}_t$ 近似看作 MA(q) 序列, 即

$$\bar{w}_t \approx a_t - \theta_1 a_{t-1} - \cdots - \theta_q a_{t-q} \quad (3.2.15)$$

用 § 2.2 中介绍的方法, 求出 σ_a^2 和 θ 的矩估计。可以想见, 用这种方法估计出的 ARMA(p, q) 模型参数, 在通常情况下, 精度多半是比较差的, 且当样本长度 N 固定时, 模型参数的估计精度是随着总阶数 $p+q$ 的增大而渐次的。因此, 用上述方法进行初估计时, 阶数不宜过高。对于高阶模型求参数初估计时, 宜用下节介绍的方法。

§ 3 模型参数的初估计方法——逆函数法

上节我们对于各类模型, 讨论了模型参数的矩估计法, 本节将

介绍另一种初估计方法——逆函数法。这一方法的主要优点是它仅涉及到线性方程组的求解，因而计算简便、易于实现，利于对高阶 ARMA 模型参数进行初估计。

§ 3.1 ARMA(p, q)模型参数的逆函数估计法

我们知道, ARMA(p, q) 模型

$(1 - \varphi_1 B - \varphi_2 B^2 - \cdots - \varphi_p B^p) w_t = (1 - \theta_1 B - \theta_2 B^2 - \cdots - \theta_q B^q) a_t$ 具有逆转形式

$$a_t = (1 - I_1 B - I_2 B^2 - \cdots) w_t$$

将此式代入前一式, 得到算子 B 的恒等式

$$\begin{aligned} & 1 - \varphi_1 B - \varphi_2 B^2 - \cdots - \varphi_p B^p \\ &= (1 - \theta_1 B - \cdots - \theta_q B^q) \cdot (1 - I_1 B - I_2 B^2 - \cdots) \end{aligned} \quad (3.3.1)$$

比较等式两边 B 的相同幂次, 得

$$\begin{cases} \varphi_1 = \theta_1 + I_1 \\ \varphi_2 = \theta_2 - \theta_1 I_1 + I_2 \\ \varphi_3 = \theta_3 - \theta_1 I_2 - \theta_2 I_1 + I_3 \\ \cdots \\ \varphi_j = \theta_j - \theta_1 I_{j-1} - \theta_2 I_{j-2} - \cdots - \theta_{j-1} I_1 + I_j \\ \cdots \end{cases} \quad (3.3.2)$$

其中, 当 $j > q$ 时, 令 $\theta_j = 0$; $i > p$ 时, 令 $\varphi_i = 0$ 。特别, 当 $j > \max(p, q)$ 时, 有

$$(1 - \theta_1 B - \theta_2 B^2 - \cdots - \theta_q B^q) I_j = 0 \quad (3.3.3)$$

显然, 若已知逆函数 I_j 的估计值, 则由 (3.3.2) 与 (3.3.3) 可以求得 φ_i 与 θ_i ($i = 1, 2, \cdots, p$; $j = 1, 2, \cdots, q$) 的初估计。为了求 I_j 的估计值, 我们考虑自回归模型 AR(p^*)

$$w_t = \varphi_1^* w_{t-1} + \varphi_2^* w_{t-2} + \cdots + \varphi_{p^*}^* w_{t-p^*} + a_t$$

将其表示成

$$a_t = w_t - \varphi_1^* w_{t-1} - \varphi_2^* w_{t-2} - \cdots - \varphi_{p^*}^* w_{t-p^*} \quad (3.3.4)$$

不难看出, 其逆函数的前 p^* 个值就是它的 p^* 个自回归系数

$$I_j = \varphi_j^*, \quad j \leq p^*; \quad I_j = 0, \quad j > p^*$$

这样一个特性在 $q \neq 0$ 的 ARMA(p, q) 模型虽然并不成立, 但由

于可逆性保证了当 j 充分大时, I_j 是指数衰减的, 因此, 当取 p^* 充分大时, 由逆函数表示的前 p^* 项就产生了与原来的 $\text{ARMA}(p, q)$ 模型类似的 $\text{AR}(p^*)$ 模型。而对于自回归模型, 其系数可用 §2.1 中介绍的 Y-W 方程求解估出。这样, 从 $\text{AR}(p^*)$ 求得 I_j 的估计, 再利用 (3.3.3) 求出 $\hat{\theta}_j (j=1, 2, \dots, q)$, 最后将这些结果一齐代入 (3.3.2), 便可得到 $\varphi_i (i=1, 2, \dots, p)$, 整个过程都只涉及到线性方程组的求解, 因而可得到参数初估计的解析表示。

为了求得 $\text{ARMA}(p, q)$ 模型 q 个滑动平均参数的初估计, 需要求解由 q 个形如 (3.3.3) 的方程所构成的线性方程组。而 (3.3.3) 仅当 $j > \max(p, q)$ 时才成立, 因此, 为求逆函数 I_j 的近似值, 应取 $\text{AR}(p^*)$ 的阶数 p^* 为

$$p^* \geq \max(p, q) + q \quad (3.3.5)$$

由前面的分析知, 原则上, p^* 越大, I_j 的估计越精确。不过, 为节省计算量, 通常就取不等式的下界, 即

$$p^* = \max(p, q) + q \quad (3.3.6)$$

多数情形也能满足要求。

用逆函数法求参数估计初值的具体步骤可整理如下:

i) 令 $p^* = \max(p, q) + q$, 用 Y-W 方法估计 $\text{AR}(p^*)$ 的 p^* 个自回归参数, 近似地当作相应的 $\text{ARMA}(p, q)$ 模型的前 p^* 个逆函数值 $I_1, I_2, \dots, I_{p^*}$ 。

ii) 解下列线性方程组 (q 个方程, q 个未知数)

$$\begin{aligned} (1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q) I_j &= 0 \\ j &= \max(p, q) + 1, \dots, p^* \end{aligned}$$

得到 $\theta_1, \theta_2, \dots, \theta_q$ 的初估计。

iii) 将 i, ii 中结果代入 (3.3.2) 式右端, 得到 $\varphi_1, \varphi_2, \dots, \varphi_p$ 的初估计。

§ 3.2 模型参数初值的进一步调整

由 §3.1 的方法虽然可以简单直接地得到参数 φ 与 θ 的初估计, 然而并不能保证它们一定满足平稳可逆性条件。不过我们可以介绍一种方法, 使初估计所得到的模型经过适当调整后, 既满足

可逆性条件,又能保持动态系统的特性。

今设 ARMA(p, q)模型初估计的滑动平均部分为

$$\begin{aligned}\theta(B) &= 1 - \theta_1 B - \theta_2 B^2 - \cdots - \theta_q B^q \\ &= (1 - \mu_1 B)(1 - \mu_2 B) \cdots (1 - \mu_q B)\end{aligned}\quad (3.3.7)$$

我们知道,模型可逆当且仅当 $|\mu_i| < 1, i = 1, 2, \dots, q$ 。

可以证明,如果那些模大于 1 的根用其倒数来代替,那么产生的 $\theta^*(B)$ 既满足可逆性,又能保持模型的统计特性不变。

模大于 1 的根其倒数满足可逆性条件是显然的。至于后者,可以从 ARMA(p, q)模型的谱密度函数来论证。由于

$$g(\lambda) = \sigma_a^2 \left| \frac{\theta(e^{-i2\pi\lambda})}{\varphi(e^{-i2\pi\lambda})} \right|^2 = \sigma_a^2 \frac{\theta(e^{-i2\pi\lambda}) \overline{\theta(e^{-i2\pi\lambda})}}{\varphi(e^{-i2\pi\lambda}) \overline{\varphi(e^{-i2\pi\lambda})}}$$

因为 $\theta(B), \varphi(B)$ 都是实系数多项式,且 $\overline{e^{-i2\pi\lambda}} = e^{i2\pi\lambda}$, 上式

$$= \sigma_a^2 \frac{\theta(e^{-i2\pi\lambda}) \theta(e^{i2\pi\lambda})}{\varphi(e^{-i2\pi\lambda}) \varphi(e^{i2\pi\lambda})} \quad (3.3.8)$$

由此可见, $g(\lambda)$ 的分子和分母都可由实系数多项式表示。它们各自的根不仅当复根时成共轭对出现,而且还互为倒数。例如分子多项式 $\theta(\lambda)\theta(\lambda^{-1})$ 的根有形式

$$\mu, \bar{\mu}, \frac{1}{\mu}, \frac{1}{\bar{\mu}} \quad (3.3.9)$$

(实根情形,不出现共轭根)

将(3.3.8)式的分子按可逆性条件将因子重新组合,使产生的

$$\theta^*(B) = (1 - \mu_1^* B) \cdots (1 - \mu_q^* B) \quad (3.3.10)$$

满足 $|\mu_i^*| < 1$, 则显然有

$$\theta^*(B)\theta^*(B^{-1}) \equiv \theta(B)\theta(B^{-1})$$

因此(3.3.8)式中 $g(\lambda)$ 保持不变,从而相关函数 ρ_k 也不改变。

总之,用倒数代替模大于 1 的根之后,所产生的 $\theta^*(B)$ 既满足可逆性,又保持了系统原来的统计特性。至于自回归初值克服非平稳性的办法,可参照今后第四章中介绍的方法进行。

现在问题转化为,如何由 $\theta^*(B)$ 的 q 个根 $\mu_1^*, \mu_2^*, \dots, \mu_q^*$ 来得到调整后的滑动平均参数初值。此问题的实质是,若已知一个 m

次实系数多项式的根为 $\lambda_1, \lambda_2, \dots, \lambda_m$, 欲求出它的诸系数 $a_l, 1 \leq l \leq m$ 来。

当然, 我们可以直接由下式计算

$$a_l = (-1)^{l+1} \sum_{\substack{i_1, i_2, \dots, i_l=1 \\ i_1 < i_2 < \dots < i_l}}^m \lambda_{i_1} \lambda_{i_2} \cdots \lambda_{i_l} \quad (3.3.11)$$

但是, 这样做计算量比较大, 而且在上述问题中, 只需在原来的多项式中, 局步地进行根的置换. 因此, 采用如下的递推算法是比较适宜的。

今设多项式形式为

$$f(z) = z^m + a_1 z^{m-1} + \cdots + a_{m-1} z + a_m \quad (3.3.12)$$

$a_1, a_2, \dots, a_m$ 是多项式 $f(z)$ 的 m 个系数。假定 λ 和 $\bar{\lambda}$ 是它的一对共轭复根, $|\lambda| > 1$, 由

$$(z - \lambda)(z - \bar{\lambda}) = z^2 - \xi z + \eta$$

可以算得

$$\xi = \lambda + \bar{\lambda} \quad \eta = |\lambda|^2 \quad (3.3.13)$$

利用恒等式

$$\begin{aligned} & (z^2 - \xi z + \eta^2)(z^{m-2} + b_1 z^{m-3} + \cdots + b_{m-3} z + b_{m-2}) \\ &= z^m + a_1 z^{m-1} + \cdots + a_{m-1} z + a_m \end{aligned}$$

比较两边 z 的同幂次项系数, 可得递推公式

$$b_k = a_k + \xi b_{k-1} - \eta b_{k-2} \quad k = 1, 2, \dots, m-2 \quad (3.3.14)$$

其中 $a_1, \dots, a_m$ 已知, 递推初值为

$$b_{-1} = 0, \quad b_0 = 1 \quad (3.3.15)$$

现设 $\tilde{\lambda} = \frac{1}{\lambda}$, 则 $|\tilde{\lambda}| < 1$, 由

$$(z - \tilde{\lambda})(z - \overline{\tilde{\lambda}}) = z^2 - \tilde{\xi} z + \tilde{\eta}$$

可算得

$$\begin{aligned} \tilde{\xi} &= \tilde{\lambda} + \overline{\tilde{\lambda}} = \frac{1}{\lambda} + \frac{1}{\bar{\lambda}} = \frac{\xi}{\eta} \\ \tilde{\eta} &= |\tilde{\lambda}|^2 = \frac{1}{\eta} \end{aligned} \quad (3.3.16)$$

代入恒等式

$$\begin{aligned} & (z^2 - \tilde{\xi}z + \tilde{\eta})(z^{m-2} + b_1z^{m-1} + \cdots + b_{m-2}) \\ &= z^m + \tilde{a}_1z^{m-1} + \cdots + \tilde{a}_{m-1}z + \tilde{a}_m \end{aligned}$$

又得递推公式

$$\begin{aligned} \tilde{a}_k &= b_k - \tilde{\xi}b_{k-1} + \tilde{\eta}b_{k-2} \\ &= b_k - \frac{\xi}{\eta}b_{k-1} + \frac{1}{\eta}b_{k-2} \quad k=1, 2, \cdots, m \end{aligned} \quad (3.3.17)$$

式中 $b_1, b_2, \cdots, b_{m-2}$ 可由 (3.3.14) 式算得, ξ, η 由 (3.3.13) 得到, 递推初值为

$$b_{-1}=0, \quad b_0=1, \quad b_m=b_{m-1}=0 \quad (3.3.18)$$

由此算得的 $\tilde{a}_1, \tilde{a}_2, \cdots, \tilde{a}_m$ 便是将一对共轭复根用倒数置换后产生的新多项式的系数。利用这个方法, 就可将 $F(z)$ 中单位圆外的复根一对一对地置换到单位圆内。

对于 λ 为实根的情形, 由

$$\begin{aligned} & (z - \lambda)(z^{m-1} + b_1z^{m-2} + \cdots + b_{m-2}z + b_{m-1}) \\ &= z^m + a_1z^{m-1} + \cdots + a_{m-1}z + a_m \end{aligned}$$

比较等式两边同幂次系数, 得递推公式

$$b_k - \lambda b_{k-1} = a_k \quad k=1, 2, \cdots, m-1 \quad (3.3.19)$$

式中 a_k 为已知, 初值

$$b_0=1 \quad (3.3.20)$$

若 $|\lambda| > 1$, 令 $\tilde{\lambda} = \frac{1}{\lambda}$, 相应递推公式

$$\tilde{a}_k = -\tilde{\lambda}b_{k-1} + b_k = -\frac{1}{\lambda}b_{k-1} + b_k \quad (3.3.21)$$

其中 $b_1, b_2, \cdots, b_{m-1}$ 由 (3.3.19) 得到, 初值为

$$b_0=1, \quad b_m=0 \quad (3.3.22)$$

(3.3.14) — (3.3.22) 便是所需要的全部递推算式, 此方法不仅计算量不大, 而且方便于在计算机上实现。

最后还要说明的一点是, 当运用上述公式对 $\theta(B)$ 进行根置换的时候, 要将 B 算子多项式 (3.3.7) 式表示成相应的特征多项式形式

$$F(z) = z^m - \theta_1 z^{m-1} - \theta_2 z^{m-2} - \dots - \theta_{m-1} z - \theta_m \quad (3.3.23)$$

这样, $\theta(B)$ 的可逆化问题就等价于将 $F(z)$ 的单位圆外的根置换到单位圆内来。




图 3.1 特征根置换的程序框图

§ 3.3 用逆函数求参数初值的例子

为了说明这种求初值的方法, 我们讨论太阳黑子活动的 ARMA(2, 1) 模型。

对于 ARMA(2, 1) 模型, 我们取 $p^* = 2 + 1 = 3$, 首先拟合 AR(3) 模型, 由 Y-W 估计得到三个自回归参数, 相应地近似当

作模型 ARMA(2,1)的三个逆函数 I_1, I_2, I_3 , 即

$$I_1 = 1.268, \quad I_2 = -0.500, \quad I_3 = -0.111$$

残差平方和为 40167.805

利用(3.3.3)得

$$(1 - \theta_1 B)I_j = 0, \quad j > \max(p, q) = 2$$

即得

$$(1 - \theta_1 B)I_3 = 0$$

$$I_3 - \theta_1 I_2 = 0$$

$$\theta_1 = \frac{I_3}{I_2} = \frac{-0.111}{-0.500} = 0.222$$

由于 $|\theta_1| < 1$, 可逆性条件满足, 由 I_1, I_2, I_3, θ_1 , 可按(3.3.2)算出 φ_1 和 φ_2

$$\varphi_1 = I_1 + \theta_1 = 1.268 + 0.222 = 1.490$$

$$\varphi_2 = \theta_2 - \theta_1 I_1 - I_2 = 0 - 0.222 \times 1.268 - 0.500 = -0.780$$

$\varphi_1, \varphi_2, \theta_1$ 即为 ARMA(2,1)模型参数的初估计值。

表 3.1 1749—1924 年每年太阳黑子数

80.9	83.4	47.7	47.6	30.7	12.2	9.6	10.6	32.4	47.6
54.0	62.9	85.9	61.2	45.1	36.4	20.9	71.4	37.8	69.8
106.1	100.8	81.6	66.5	34.8	30.6	7.0	19.8	92.5	154.4
125.9	84.8	68.1	38.5	22.8	10.2	24.1	82.9	132.0	130.9
118.1	89.9	66.6	60.0	46.9	41.0	21.3	16.0	6.4	4.1
6.8	14.5	34.0	45.0	43.1	47.5	42.2	28.1	10.1	8.1
2.5	0.0	1.4	5.0	12.2	13.9	35.4	45.8	41.1	30.4
23.9	15.7	6.6	4.0	1.8	8.5	15.3	36.3	49.7	62.5
67.0	71.0	47.8	27.5	8.5	13.2	55.9	121.5	138.3	103.2
85.8	63.2	36.8	24.2	10.7	15.0	40.1	61.5	98.5	124.3
95.9	66.5	64.5	54.2	39.0	20.6	6.7	4.3	22.8	54.8
93.8	95.7	77.2	59.1	44.0	47.0	30.5	16.3	7.3	37.3
73.9	139.1	111.2	101.7	63.3	44.7	17.1	11.3	12.3	3.4
6.0	32.3	54.3	59.7	63.7	63.5	52.2	25.4	13.1	6.8
6.3	7.1	35.6	70.3	84.9	78.0	64.0	41.8	26.2	26.7
12.1	9.5	2.7	5.0	24.4	42.0	63.5	53.8	62.0	48.5
43.9	18.6	5.7	3.6	1.4	9.6	47.4	57.1	103.9	80.6
43.6	37.6	26.1	14.2	5.8	16.7				

由本例可见,逆函数法在计算机上容易实现,实践也表明,这种方法不论对于低阶还是高阶模型都很有效。总之,§2 和 §3 中列举了求参数初估计的两种常用方法。一般地说,初估计的效果在实际问题中往往带有不确定性,因此,初估计最好要尽可能地靠近真值。如果初估计选得粗糙,距离真值很远,这样做就会增加迭代次数,加大计算量。不过,如果无法估计出真值的大致位置,尽管初值选取得不太理想,只要在精估计迭代过程中,始终保持模型的平稳性和可逆性,由系统的稳定性也可保证终将迭代到理想的精估计。因此,有时对具体动态数据序列建立 $ARMA(p, q)$ 模型时,并不一定按步就班地进行参数的初估计,而是以平稳可逆域内某一组参数作为初值,直接在此域内进行精估计的迭代。例如,不妨将 $ARMA(p, q)$ 模型自回归初值恒取为零(即 $\varphi^0 = 0$),而滑动平均初值取下一数列的前 q 个值

$$\begin{aligned} & -0.90, -0.85, -0.80, -0.75, -0.70, -0.65, \\ & -0.60, -0.55, \dots, -0.05 \end{aligned} \quad (3.3.24)$$

第二章(2.3.13)式表明,此式中取 q 个值顺序作为滑动平均参数的初值 $\theta_1^0, \theta_2^0, \dots, \theta_q^0$ 时,相应的模型是具有可逆性的。

§ 4 模型参数的精估计

在初估计的基础上,我们将根据一定的估计准则,对于参数进行精细的估计。本节介绍最小二乘和极大似然这两种准则下的模型参数精估计方法,并以由极大似然估计近似化后所导出的最小平方和估计为重点。

§ 4.1 模型参数的最小二乘估计

由于最小二乘方法的内容比较丰富,我们将在第六章中专门讨论,本节仅叙述 $AR(p)$ 模型与 $ARMA(p, q)$ (包括 $MA(q)$) 模型最小二乘估计的原则和性质。

1. $AR(p)$ 序列参数的最小二乘估计:将模型 $\varphi(B)w_t = a_t$ 改写成

$$w_t = \varphi_1 w_{t-1} + \varphi_2 w_{t-2} + \cdots + \varphi_p w_{t-p} + a_t \quad (3.4.1)$$

(3.4.1)是参数 $\boldsymbol{\varphi} = (\varphi_1, \varphi_2, \cdots, \varphi_p)^T$ 的线性模型, 可以用线性最小二乘原理对参数 $\boldsymbol{\varphi}$ 进行估计, 即 $\boldsymbol{\varphi}$ 的估计值 $\hat{\boldsymbol{\varphi}}_L$ 应使下式的残差平方和达到极小

$$\begin{aligned} s(\boldsymbol{\varphi}) &= \sum_{t=p+1}^N a_t^2 \\ &= \sum_{t=p+1}^N (w_t - \varphi_1 w_{t-1} - \cdots - \varphi_p w_{t-p})^2 \end{aligned} \quad (3.4.2)$$

由

$$\left. \frac{\partial s(\boldsymbol{\varphi})}{\partial \boldsymbol{\varphi}} = 0 \right|_{\boldsymbol{\varphi} = \hat{\boldsymbol{\varphi}}_L}$$

可得线性方程组(未知数为 $\hat{\boldsymbol{\varphi}}_L$)

$$\sum_{t=p+1}^N w_{t-j} (w_t - \hat{\varphi}_1^L w_{t-1} - \cdots - \hat{\varphi}_p^L w_{t-p}) = 0 \quad j=1, 2, \cdots, p$$

此式可以改写为

$$\begin{aligned} & \frac{\hat{\varphi}_1^L}{N} \sum_{t=p+1}^N w_{t-1} w_{t-j} + \frac{\hat{\varphi}_2^L}{N} \sum_{t=p+1}^N w_{t-2} w_{t-j} + \cdots + \frac{\hat{\varphi}_p^L}{N} \sum_{t=p+1}^N w_{t-p} w_{t-j} \\ &= \frac{1}{N} \sum_{t=p+1}^N w_t w_{t-j} \quad j=1, 2, \cdots, p \end{aligned} \quad (3.4.3)$$

令

$$\hat{\gamma}_{ij}^L = \hat{\gamma}_{ji}^L \triangleq \frac{1}{N} \sum_{t=p+1}^N w_{t-i} w_{t-j} \quad (3.4.4)$$

代入(3.4.3), 即可求得 $\boldsymbol{\varphi}$ 的最小二乘估计 $\hat{\boldsymbol{\varphi}}_L$

$$\hat{\boldsymbol{\varphi}}_L = \begin{pmatrix} \hat{\varphi}_1^L \\ \hat{\varphi}_2^L \\ \vdots \\ \hat{\varphi}_p^L \end{pmatrix} = \begin{pmatrix} \hat{\gamma}_{11}^L & \hat{\gamma}_{12}^L & \cdots & \hat{\gamma}_{1p}^L \\ \hat{\gamma}_{21}^L & \hat{\gamma}_{22}^L & \cdots & \hat{\gamma}_{2p}^L \\ \cdots & \cdots & \cdots & \cdots \\ \hat{\gamma}_{p1}^L & \hat{\gamma}_{p2}^L & \cdots & \hat{\gamma}_{pp}^L \end{pmatrix}^{-1} \begin{pmatrix} \hat{\gamma}_{01}^L \\ \hat{\gamma}_{02}^L \\ \vdots \\ \hat{\gamma}_{0p}^L \end{pmatrix} \quad (3.4.5)$$

由此可见, AR(p)参数的最小二乘估计, 能够有简单的解析表达

式。

此外,由

$$\hat{a}_t^L = w_t - \hat{\phi}_1^L w_{t-1} - \cdots - \hat{\phi}_p^L w_{t-p}, \quad t = p+1, \cdots, N \quad (3.4.6)$$

可得到 σ_a^2 的最小二乘估计

$$\hat{\sigma}_a^2 = \frac{1}{N-p} \sum_{t=p+1}^N \hat{a}_t^2 = \frac{1}{N-p} s(\hat{\phi}_L) \quad (3.4.7)$$

将(3.4.4)式和(3.1.1)式比较,可以看出,当 N 充分大时, $\hat{\phi}_L^L = \hat{\phi}_L^L \approx \hat{\phi}_{L-1,1}$, 因此, (3.4.5)式和(3.2.1)式十分相近。这就得出如下的一个结论:当样本长度 N 充分大时, $AR(p)$ 模型的最小二乘估计 $\hat{\phi}_L$ 和由 $Y-W$ 方程获得的矩估计 $\hat{\phi}$ 是十分相近的。这一性质表明,尽管 $Y-W$ 估计是 $AR(p)$ 模型参数的初估计方法,然而在样本长度 N 充分大时,精估计与最小二乘估计具有相近的估计精度。在下一节还会看到, $AR(p)$ 模型 $Y-W$ 估计的精度也和极大似然估计渐近相等。因此, $AR(p)$ 模型参数的 $Y-W$ 估计(当 N 充分大时)就可作为模型参数的精估计。这一特点在 $AR(p)$ 建模中将会带来很大方便。

2. $ARMA(p, q)$ 与 $MA(q)$ 模型参数的最小二乘估计: 将模型改写成

$$w_t - \varphi_1 w_{t-1} + \varphi_2 w_{t-2} + \cdots + \varphi_p w_{t-p} - \theta_1 a_{t-1} - \cdots - \theta_q a_{t-q} + a_t \quad (3.4.8)$$

则非线性函数

$$f_t(\beta; u_t) = \varphi_1 w_{t-1} + \cdots + \varphi_p w_{t-p} - \theta_1 a_{t-1} - \cdots - \theta_q a_{t-q}$$

其中

$$\begin{aligned} \beta &= (\varphi_1, \varphi_2, \cdots, \varphi_p, \theta_1, \theta_2, \cdots, \theta_q)^T \\ u_t &= (w_{t-1}, w_{t-2}, \cdots, w_{t-p})^T \end{aligned} \quad (3.4.9)$$

由于 $q \neq 0$, $f_t(\beta; u_t)$ 中含有白噪声量, 由

$$a_t = \theta^{-1}(B) \varphi(B) w_t$$

知, a_{t-k} 与参数 β 及状态 u_t 呈非线性关系, 因此 $f_t(\beta; u_t)$ 是非线性函数。对这两类模型的参数进行最小二乘估计时, 只可用非线性方法, 由初估计出发, 通过迭代求得精估计 $\hat{\beta}_L$, 具体步骤与算

法，留待第六章中详细讨论。

§ 4.2 模型参数的近似极大似然估计——最小平方和估计

参照第一章§ 8.1 节可知，对于平稳、正态、零均值序列 $\{w_t\}$ ，当样本

$$\boldsymbol{w}_N = (w_1, w_2, \dots, w_N)^T \quad (3.4.10)$$

给定后，具有如下形式的对数似然函数

$$\begin{aligned} l(\boldsymbol{\alpha} | \boldsymbol{w}_N) &= \log p(\boldsymbol{w}_N | \boldsymbol{\alpha}) \\ &= \frac{1}{2} \log |M_N| - \frac{N}{2} \log 2\pi - \frac{1}{2} \log \sigma_a^2 - \frac{\boldsymbol{w}_N^T M_N \boldsymbol{w}_N}{2 \sigma_a^2} \end{aligned} \quad (3.4.11)$$

其中

$$\boldsymbol{\alpha} = (\boldsymbol{\varphi}^T, \boldsymbol{\theta}^T, \sigma_a^2)^T = (\boldsymbol{\beta}^T, \sigma_a^2)^T \quad (3.4.12)$$

为 ARMA(p, q) 的模型参数

$$M_N \triangleq \sigma_a^2 \Gamma_N^{-1} = \sigma_a^2 (\boldsymbol{E}_a \boldsymbol{w}_N \boldsymbol{w}_N^T)^{-1} \quad (3.4.13)$$

均值右下角的 $\boldsymbol{\alpha}$ 表示它是参数向量 $\boldsymbol{\alpha}$ 的函数。所谓极大似然估计，就是要选择适当的 $\boldsymbol{\alpha}$ ，使 (3.4.11) 式能取极大值。然而，由于公式复杂，由此式不能得出极值的解析表示，即使作数值求解，也都太烦杂。通常情况下，我们采用如下的近似极大似然方法。

可以证明，对于所有的样本长度 N ， $|M_N|$ 是有界的，又由 (3.4.11) 式可见， $\frac{N}{2} \log 2\pi$ 是只和 N 有关，而和参数 $\boldsymbol{\alpha}$ 无关的量，因此，只要 N 充分大时， $l(\boldsymbol{\alpha} | \boldsymbol{w}_N)$ 取极大值的点和

$$-\frac{N}{2} \log \sigma_a^2 + \frac{\boldsymbol{w}_N^T M_N \boldsymbol{w}_N}{2 \sigma_a^2} \quad (3.4.14)$$

取极小的点几乎是一样的，而对 (3.4.14) 求极小而得到的估计值 $\hat{\boldsymbol{\alpha}}$ ，就是模型 ARMA(p, q) 参数 (在样本 $\boldsymbol{w}_N$ 给定) 的近似极大似然估计。

$\boldsymbol{w}_N^T M_N \boldsymbol{w}_N$ 称为平方和函数，可以证明，它仅仅与参数向量 $\boldsymbol{\beta}$ 有关，而和 $\{\boldsymbol{a}_t\}$ 的方差 σ_a^2 无关。事实上，由于 $\{w_t\}$ 相应的时序模型具有传递形式

$$w_t = \sum_{j=0}^{\infty} G_j a_{t-j}$$

利用 $\{a_t\}$ 的白噪声特性得

$$\begin{aligned} \gamma_k &= E w_t w_{t+k} = E \left(\sum_{i=0}^{\infty} G_i a_{t-i} \right) \left(\sum_{j=0}^{\infty} G_j a_{t+k-j} \right) \\ &= \left(\sum_{i=0}^{\infty} G_i G_{i+k} \right) \sigma_a^2 \end{aligned}$$

此外

$$\begin{aligned} \Gamma_N &= E \mathbf{w}_N \mathbf{w}_N^T = (E w_t w_s)_{N \times N} = (\gamma_{t-s})_{N \times N} = (\gamma_{|t-s|})_{N \times N} \\ &= \sigma_a^2 \left(\sum_{i=0}^{\infty} G_i G_{i+|t-s|} \right)_{N \times N} \end{aligned}$$

由上式得

$$M_N = \sigma_a^2 \Gamma_N^{-1} = \left(\sum_{i=0}^{\infty} G_i G_{i+|t-s|} \right)_{N \times N}^{-1}$$

由于 G_i 仅由 $\beta = (\varphi^T, \theta^T)^T$ 而定,因此, M_N 也仅是参数 β 的函数。平方和函数中, $\mathbf{w}_N$ 是已获得的样本列, M_N 仅与参数 β 有关,所以,平方和函数也仅仅是参数 β 的函数。

$$\text{记 } s(\beta) = \mathbf{w}_N^T M_N \mathbf{w}_N \quad (3.4.15)$$

将(3.4.14)式对参数 α 求偏导数,得方程组

$$\begin{aligned} \left. \frac{\partial}{\partial \sigma_a^2} \left\{ \frac{N}{2} \log \sigma_a^2 + \frac{s(\beta)}{2 \sigma_a^2} \right\} \right|_{\alpha=\hat{\alpha}} &= \frac{N}{2 \hat{\sigma}_a^2} - \frac{s(\hat{\beta})}{2 \hat{\sigma}_a^4} = 0 \\ \left. \frac{\partial}{\partial \beta} \left\{ \frac{N}{2} \log \sigma_a^2 + \frac{s(\beta)}{2 \sigma_a^2} \right\} \right|_{\alpha=\hat{\alpha}} &= \frac{1}{2 \hat{\sigma}_a^2} \frac{\partial}{\partial \beta} s(\beta) \Big|_{\beta=\hat{\beta}} = 0 \end{aligned}$$

由此可得

$$\hat{\sigma}_a^2 = \frac{1}{N} s(\hat{\beta}) \quad (3.4.16)$$

而 $\hat{\beta}$ 是方程

$$\frac{\partial s(\beta)}{\partial \beta} = 0 \quad (3.4.17)$$

的解。于是,对于 ARMA(p, q)模型,我们得到了使 $s(\beta)$ 达极小的参数估计值 $\hat{\beta}$, 当样本长度充分大时,它近似地等于参数的极大似然估计。

可以证明,对于 $s(\hat{\beta})$ 成立如下关系式

$$s(\hat{\beta}) = \mathbf{w}_N^T \mathbf{M}_N \mathbf{w}_N |_{\beta = \hat{\beta}} = \sum_{k=-\infty}^N \hat{a}_k^2 \quad (3.4.18)$$

$$\text{式中 } \hat{a}_k = \hat{a}_k(\beta, \mathbf{w}_N) \triangleq E_{\beta}(a_k | w_1, w_2, \dots, w_N) \quad (3.4.19)$$

为参数 β 给定时,用 $\mathbf{w}_N$ 对 a_k 做的最小方差估计。因此, $s(\hat{\beta})$ 又称为模型的最小平方差和, $\hat{\beta}$ 称为模型参数的最小平方差估计。

下面来证明(3.4.18)式。

利用白噪声的不相关性和 ARMA(p, q)序列的传递形式

$$w_t = G(B)a_t = \sum_{j=0}^{\infty} G_j a_{t-j}$$

可以得到

$$E a_k w_t = \sum_{j=0}^{\infty} G_j E a_k a_{t-j} = \begin{cases} \sigma_a^2 G_{t-k} & k \leq t \\ 0 & k > t \end{cases}$$

形式地,约定 $G_l = 0 (l < 0)$, 上式可统一记为

$$E a_k w_t = \sigma_a^2 G_{t-k}$$

设 $1 \leq i \leq j \leq N$, 利用上述关系式,得

$$\begin{aligned} \gamma_{i-j} &= E w_i w_j = E \left(\sum_{k=0}^{\infty} G_k a_{i-k} \right) \left(\sum_{l=0}^{\infty} G_l a_{j-l} \right) \\ &= \sigma_a^2 \sum_{k=0}^{\infty} G_k G_{k+j-i} \end{aligned}$$

由此得到

$$\sum_{k=-\infty}^N E(a_k w_N) E(a_k w_N^T)$$

$$\begin{aligned}
&= \sigma_a^2 \sum_{k=-\infty}^N \begin{pmatrix} G_{1-k} \\ G_{2-k} \\ \vdots \\ G_{N-k} \end{pmatrix} (G_{1-k}, G_{2-k}, \dots, G_{N-k}) \\
&= \sigma_a^2 \Gamma_N
\end{aligned}$$

由第一章(1.8.26)式得

$$\hat{a}_k = E_{\beta}(a_k | \mathbf{w}_N) = (E a_k \mathbf{w}_N) (E \mathbf{w}_N \mathbf{w}_N^T)^{-1} \mathbf{w}_N$$

故

$$\begin{aligned}
\sum_{k=-\infty}^N \hat{a}_k^2 &= \sum_{k=-\infty}^N \mathbf{w}_N^T \Gamma_N^{-1} E(a_k \mathbf{w}_N) E(a_k \mathbf{w}_N^T) \Gamma_N^{-1} \mathbf{w}_N \\
&= \mathbf{w}_N^T \Gamma_N^{-1} \left(\sum_{k=-\infty}^N E(a_k \mathbf{w}_N) E(a_k \mathbf{w}_N^T) \right) \Gamma_N^{-1} \mathbf{w}_N \\
&= \sigma_a^2 \mathbf{w}_N^T \Gamma_N^{-1} \Gamma_N \Gamma_N^{-1} \mathbf{w}_N \\
&= \sigma_a^2 \mathbf{w}_N^T \Gamma_N^{-1} \mathbf{w}_N \\
&= \mathbf{w}_N^T M_N \mathbf{w}_N \\
&= s(\beta)
\end{aligned}$$

这就证明了(3.4.18)式。

依据最小平方和的估计原理,我们可以通过一定的方式,对于给定的模型参数 β , 求出相应的平方和 $s(\beta)$, 并在平稳可逆域内, 得到估计值 $\hat{\beta}$ 。对于 AR(p) 模型, 可以直接给出平方和关于参数向量的显表示, 且可直接求解参数 φ 的最小平方和估计 $\hat{\varphi}$ 。而对于其它两类模型, 给不出 $s(\beta)$ 关于 β 的显表示, 因此计算要复杂得多, 而且 $\hat{\beta}$ 的获得, 要在平稳可逆域内, 依据最小平方和原理, 遵照一定的程序, 进行比较复杂的搜索和迭代。以下的几小节将对上述问题分头进行讨论。

§ 4.3 AR(p)模型参数的最小平方和估计及 $s(\varphi)$ 的计算

对于 AR(p) 序列, 参数向量 $\beta = \varphi$, 平方和 $s(\varphi)$ 经过繁琐的计算可以由参数 φ 解析表示^[6]

$$s(\varphi) = \mathbf{w}_N^T M_N \mathbf{w}_N = \sum_{i,j=0}^p \varphi_i \varphi_j d_{ij} \quad N \geq 2p \quad (3.4.20)$$

其中

$$\varphi_0 \triangleq -1, d_{ij} = \sum_{k=1+j}^{N-1} w_{k+i-j} w_k = d_{ji}, \quad i, j = 0, 1, \dots, p \quad (3.4.21)$$

实际应用中, N 大于 $2p$ 通常都可做到。

记

$$D \triangleq \begin{pmatrix} d_{11} & d_{12} & \cdots & d_{1p} \\ d_{21} & d_{22} & \cdots & d_{2p} \\ \cdots & \cdots & \cdots & \cdots \\ d_{p1} & d_{p2} & \cdots & d_{pp} \end{pmatrix} \quad \mathbf{d} \triangleq \begin{pmatrix} d_{01} \\ d_{02} \\ \vdots \\ d_{0p} \end{pmatrix} \quad (3.4.22)$$

(3.4.20)式又可表为

$$s(\varphi) = \varphi^T D \varphi - 2 \varphi^T \mathbf{d} + d_{00} \quad (3.4.23)$$

这是 φ 的二次型函数, 使 $s(\varphi)$ 达极小的解为

$$\hat{\varphi}_s = D^{-1} \mathbf{d} \quad (3.4.24)$$

σ_s^2 的最小平方和估计为

$$\begin{aligned} \hat{\sigma}_s^2 &= \frac{1}{N} s(\hat{\varphi}_s) = \frac{1}{N} (\hat{\varphi}_s^T D \hat{\varphi}_s - 2 \hat{\varphi}_s^T \mathbf{d} + d_{00}) \\ &= \frac{1}{N} (d_{00} - \mathbf{d}^T D^{-1} \mathbf{d}) \end{aligned} \quad (3.4.25)$$

当 N 较大时,

$$\frac{d_{ij}}{N} = \frac{1}{N} \sum_{k=1+j}^{N-i} w_{k+i-j} w_k \approx \frac{1}{N} \sum_{l=j+1}^N w_{l-i} w_{l-j} = \hat{\gamma}_{ij}^L$$

同理也有

$$\frac{d_{ij}}{N} \approx \frac{1}{N} \sum_{l=1}^{N-i-j+1} w_l w_{l+i-j+1} = \hat{\gamma}_{i-j}^L$$

利用以上结果, 将(3.4.24)式和(3.2.1)及(3.4.5)式进行比较,

不难得出

$$\hat{\varphi}_s \approx \hat{\varphi}_L \approx \hat{\varphi} \quad (3.4.26)$$

即当 N 充分大时, $AR(p)$ 模型参数的最小平方和估计、最小二乘估计和 $Y-W$ 估计三者都非常接近, 它们都可作为参数 φ 的精估计。这是 $AR(p)$ 模型的独特优点, 因此, 有一种观点, 主张尽可能采用自回归模型来描述实际的数字序列, 即使真正模型是 MA 或 $ARMA$ 的, 也可用高阶 AR 模型来逼近。

$s(\varphi)$ 除可用 (3.4.22) 式表成参数 φ 的函数形式外, 还可直接由样本值来计算

$$s(\varphi) = \mathbf{w}_N^T M_N \mathbf{w}_N = \sum_{t,s=1}^N m_{st}^{(N)} w_s w_t$$

记 $m_{st}^{(N)}$ 表示矩阵 M_N 的第 s 行 t 列元素, 经过烦琐计算^[5], 可得其关于参数 φ 的解析表达式 ($N > p$)

$$m_{st}^{(N)} = \begin{cases} m_{st}^{(p)} + \sum_{i=p+1-t}^{\min(N-t, p, p+s-t)} \varphi_{i+t-s} \varphi_i & 1 \leq s, t \leq p \\ \sum_{i=\max(p+1-t, 0, s-t)}^{\min(N-t, p, p+s-t)} \varphi_{i+t-s} \varphi_i & p < \max(s, t) \leq N \end{cases}$$

其中 $m_{st}^{(p)}$ 是 M_p 的 s 行 t 列元素 (3.4.27)

$$m_{st}^{(p)} = \sum_{i=\max(0, s-t)}^{\min(s-1, p-t)} \varphi_i \varphi_{i+t-s} - \sum_{i=\max(s, p-t+1)}^{\min(p, p+s-t)} \varphi_i \varphi_{i+t-s}$$

(注意 $\varphi_0 \triangleq -1$)

公式 (3.4.27) 给出了 $M_N = \sigma_a^2 \Gamma_N^{-1}$ 矩阵各元的解析表达式, 这一公式是很有用处的。由公式可见, 当 $|s-t| > p$ 时, Γ_N^{-1} (或 M_N) 矩阵的第 s 行 t 列元素全为零, 其余各元均为 φ_i ($0 \leq i \leq p$) 的二次型函数。 $m_{st}^{(N)}$ 的表达式虽复杂, 但仔细分析其结构, 不难发现 M_N 矩阵各元之间的内在规律。充分利用这些规律, 可以大大简化矩阵 M_N 或二次型 $s(\varphi) = \mathbf{w}_N^T M_N \mathbf{w}_N$ 的计算程序。

首先, 我们发现, M_N 中各元关于主、付对角线为对称, 并且在范围

$\{1 \leq \min(s, t) < N - p\} \cap \{p < \max(s, t) \leq N\} \cap \{|s - t| \leq p\}$ 内, 主对角线的平行线上各元素相等。利用这一规律, M_N 矩阵中 N^2 个元的计算, 就减少为矩阵左上角 $p+1$ 阶子方阵的上半三角阵的计算。图 3.2 示意了 AR(p) 模型 M_N 矩阵元素计算的规律。图中 M_N 是 $N \times N$ 方阵, s 表示行号, t 表示列号。在平行线 $s=t$ 与 $s-t=p$ 所框定的范围内, 位于同条平行虚线上的元素 m_{st} 具有相同数值(包括 $s=t$ 及 $s-t=p$ 这两条线本身)。当 $s-t > p$ 时, $m_{st}=0$, 再利用 M_N 关于主、付对角线的对称性, M_N 中所有元素都可由左上三角的 $p+1$ 阶子阵而得到。




图 3.2 AR(p)模型的 M_N 矩阵

左上三角元素的通项可表为

$$m_{st} = \sum_{i=0}^{s-1} \varphi_i \varphi_{i+t-s}$$

第一行元素 m_{1i} 依次是

$$\varphi_0^2, \varphi_0\varphi_1, \varphi_0\varphi_2, \dots, \varphi_0\varphi_{p-1}, \varphi_0\varphi_p$$

沿着主对角线的平行线, 同一平行线后一位置上的 m_{st} 和前一位置上的 $m_{s-1, t-1}$ 呈如下关系

$$m_{st} = m_{s-1, t-1} + \varphi_{s-1}\varphi_{t-1}$$

利用以上规律, 可以大大简化计算程序。

§ 4.4 ARMA(p, q)模型平方和函数 $s(\beta)$ 的计算

在 MA(q) 与 ARMA(p, q) 模型中, 参数向量 β 与样本 w_k 之间呈非线性关系, 因此, 这些模型的 $s(\beta)$ 计算起来要比 AR(p) 的 $s(\varphi)$ 复杂得多。Box^[3] 的“转圈”法和图解法方法比较烦杂, 仅适用于低阶或特殊情形。本节将介绍几种 $s(\beta)$ 的计算方法, 并讨论这些方法的特点与适用的对象。不过无论哪种方法, 都只能得到 $s(\beta)$ 的近似值, 而参数的最小平方和估计, 还需通过在平稳可逆范围内对于 $s(\beta)$ (或 $\hat{\sigma}_a^2$) 进行搜索比较来得到。下面, 我们来讨论 $s(\beta)$ (或 $\hat{\sigma}_a^2$) 的几种求法。

1. $s_k = w_k^T M_k w_k$ 的逆推算法^[9]: 当样本大小为 k 时, 平方和 s_k 的值可由前一步的 s_{k-1} 递推获得。

$$\begin{cases} s_k = s_{k-1} + \frac{1}{\gamma_k} u_k^2 \\ u_k = y_k + \sum_{j=1}^q \theta_j^{(k)} u_{k-j} \\ y_k = w_k - \varphi_1 w_{k-1} - \dots - \varphi_p w_{k-p} \\ \gamma_k = 1 + \sum_{j=1}^q \theta_j^2 - \sum_{j=1}^q \gamma_{k-j} (\theta_j^{(k)})^2 \\ \theta_q^{(k)} = \theta_q / \gamma_{k-q}, \theta_j^{(k)} = \frac{1}{\gamma_{k-j}} \left\{ \sum_{i=j+1}^q \gamma_{k-i} \theta_i^{(k)} \theta_{i-j}^{(k-j)} - \sum_{i=j}^q \theta_i \theta_{i-j} \right\} \\ j = q-1, \dots, 1 \end{cases} \quad (3.4.28)$$

(3.4.28) 式中, w_k, φ, θ 作为已知输入量, 其余各量全随 k 的增长递推计算, 递推初值为

$$\begin{aligned} s_0 = u_{-q+1} = \cdots = u_0 = 0, \quad \gamma_{-q+1} = \cdots = \gamma_0 = 1, \\ w_0 = \cdots = w_{1-p} = 0, \theta_j^{(-q+1)} = \cdots = \theta_j^{(0)} = 0 (1 \leq j \leq q), \\ \theta_j^{(k)} = 0 (1 \leq k \leq q, k \leq j \leq q) \end{aligned} \quad (3.4.29)$$

可以证明, 当 k 充分大时, $\gamma_k \rightarrow 1$, 因此 $\theta_j^{(k)} \rightarrow \theta_j$, 模型 $\text{ARMA}(p, q)$ 的 $s(\beta)$ 计算可进一步简化为

$$\begin{cases} s_k = s_{k-1} + u_k^2 \\ u_k = y_k + \sum_{i=1}^q \theta_i u_{k-i} \\ y_k = w_k - \varphi_1 w_{k-1} - \cdots - \varphi_p w_{k-p} \end{cases} \quad (3.4.30)$$

特殊地, 如果模型是纯滑动平均的, 则有 $y_k \equiv w_k$, 这时, 如果取

$$\hat{\gamma}_j = \frac{1}{N-j} \sum_{i=j+1}^N w_i w_{i-j} \quad 0 \leq j \leq q$$

那么, 由(3.4.28)和(3.2.5)式可得出 $\hat{\theta}_j^{(k)}$ 的递推算式

$$\begin{cases} \hat{\gamma}_k = \hat{\gamma}_0 - \sum_{j=1}^q \hat{\gamma}_{k-j} (\hat{\theta}_j^{(k)})^2 \\ \hat{\theta}_q^{(k)} = -\hat{\gamma}_q / \hat{\gamma}_{k-q} \\ \hat{\theta}_j^{(k)} = \frac{1}{\gamma_{k-j}} \left\{ \sum_{i=j+1}^q \hat{\gamma}_{k-i} \hat{\theta}_i^{(k)} \hat{\theta}_{(i-j)}^{(k-j)} - \hat{\gamma}_j \right\} \quad j = q-1, \cdots, 1 \end{cases} \quad (3.4.31)$$

($\theta_j^{(k)}$ 取初值如前), 当 k 充分大时, (3.4.31) 递推算得的 $\hat{\theta}_j^{(k)}$ 可以作为 $\text{MA}(q)$ 模型参数 θ_j ($1 \leq j \leq q$) 的一种矩估计。

(3.4.28) 是关于二次型 $\mathbf{w}_N^T M_N \mathbf{w}_N$ 的严格递推计算公式, 具有精度高、收敛快的优点。但由于递推过程比较细致, 计算量(相对地)较大, 因此, 我们介绍下面一种方法, 它的算法简单, 计算速度快, 然而当样本量较小时, 精度稍次。

2. 改进的平方和算法: 由 § 4.2(3.4.18) 式知, 平方和 $s(\hat{\beta})$ 可以表为

$$s(\hat{\beta}) = \mathbf{w}_N^T M_N \mathbf{w}_N |_{\beta = \hat{\beta}} = \sum_{k=-\infty}^N \hat{a}_k^2$$

其中

$$\hat{a}_k = \hat{a}_k(\beta, w_N) \triangleq E_p(a_k | w_1, w_2, \dots, w_N)$$

近似地,取

$$\hat{a}_i^* \triangleq w_i - \hat{\varphi}_1 w_{i-1} - \dots - \hat{\varphi}_p w_{i-p} + \hat{\theta}_1 \hat{a}_{i-1}^* + \dots + \hat{\theta}_q \hat{a}_{i-q}^* \quad (3.4.32)$$

且约定

$$\hat{a}_k^* = 0, k \leq p$$

可以证明,当 k 充分大时, $\hat{a}_k^*$ 与 $\hat{a}_k$ 非常接近,即

$$\lim_{k \rightarrow \infty} (\hat{a}_k^* - \hat{a}_k) = 0 \quad (3.4.33)$$

根据以上原理,可以导出平方和 $s(\hat{\beta})$ 的另一种简便算法——改进的平方和算法。

由(3.4.33)知,当 M 充分大时,有

$$\sum_{i=M+1}^N \hat{a}_i^{*2} \cong \sum_{i=M+1}^N \hat{a}_i^2$$

又由(3.4.16)和(3.4.18)式知

$$\hat{\sigma}_a^2 = \frac{1}{N} s(\hat{\beta}) = \frac{1}{N} \sum_{k=-\infty}^N \hat{a}_k^2$$

因此,我们可以近似地取

$$\frac{1}{N-M} \sum_{i=M+1}^N \hat{a}_i^{*2} \quad (3.4.34)$$

作为 $\hat{\sigma}_a^2$ 的估计值,式中 $\hat{a}_k^*$ 由(3.4.32)递推, M 的大小要依模型和数据的具体情况而决定,经验地,取 $5q-10q$ 为宜。

以上我们介绍了改进的平方和算法,对由(3.4.34)算得的 $\hat{\sigma}_a^2$ 在平稳可逆域内进行迭代,也可得到参数 β 的最小平方差估计。显然,此方法的精度要次于前面的递推算法。然而,计算方法大为简便,计算时间也大为节省(可为前法的 $\frac{1}{8} \sim \frac{1}{4}$)。实例表明,当样本充分大时,二法在估计精度和预报效果方面都很接近,因此,此方法在实际应用中是可取的。

例 用重庆 1941—1977 年的月平均温度建立 ARMA(0,2) $\times$ (2,1)₁₂ 模型(这是一种季节性模型,详见第四章§2)并预报 1978

年全年的月平均温度。

从初估计模型

$$\begin{aligned} & (1 - 0.3426 B^{12} - 0.0771 B^{24})(x_{t+12} - x_t) \\ & = (1 - 0.3447 B + 0.2367 B^2)(1 + 0.4778 B^{12})a_t \end{aligned}$$

出发,用 Powell 方法(见本章 § 4.5)进行参数的迭代搜索,平方和值分别用递推法(i)与改进法(ii)计算,各自得到如下的精估计模型

$$\begin{aligned} \text{i)} \quad & (1 + 1.0999 B^{12} + 0.4329 B^{24})(x_{t+12} - x_t) \\ & = (1 - 0.0247 B + 0.0567 B^2)(1 + 0.4778 B^{12})a_t \end{aligned}$$

$$\begin{aligned} \text{ii)} \quad & (1 + 1.107 B^{12} + 0.4429 B^{24})(x_{t+12} - x_t) \\ & = (1 - 0.0347 B - 0.0267 B^2)(1 + 0.4778 B^{12})a_t \end{aligned}$$

预报效果如下表所示

表 3.2 两种 $s(\beta)$ 算法预报效果比较

月份	1	2	3	4	5	6	7	8	9	10	11	12
实际值	7.0	9.3	13.7	18.4	21.8	24.8	29.1	29.4	24.4	19.0	12.9	9.8
预报值 模 (I)	6.3	9.3	12.5	17.5	20.4	23.9	27.3	28.9	24.4	19.0	11.6	8.6
模 (II)	6.3	9.3	12.5	17.4	20.4	23.8	27.3	28.9	24.4	19.0	11.6	8.6

由此表看出,二法所算得的模型精估计相当接近,预报值误差也很小。

§ 4.5 最小平方和估计的实现

——Powell 方法^[10]

我们多次提及, ARMA 模型和 MA 模型参数的最小平方和估计,要通过在平稳可逆域内对平方和函数 $s(\beta)$ 的极小化程序来获得。这是运筹学中的非线性规划问题。本节我们介绍一种最优化方法——Powell 方法,来具体实现参数的最小平方和估计。

Powell 方法是一种通过线性搜索,在一定范围内求多变元凸函数极值的迭代算法。设

$$\mathbf{x} = (x_1, x_2, \dots, x_n)^T$$

是 n 维空间的实向量

$$f(\mathbf{x}) = f(x_1, x_2, \dots, x_n)$$

是以向量 $\mathbf{x}$ 为变元的正定凸函数。为获得函数 $f(\mathbf{x})$ 的近似最小值, 我们从允许范围内的某一点开始, 按一定的程序进行迭代。每一次迭代都是从前一次迭代的终点 $\mathbf{x}^{(i)}$ 出发, 沿 n 个有顺序的线性独立方向 $\mathbf{P}^{(1)}, \mathbf{P}^{(2)}, \dots, \mathbf{P}^{(n)}$ 搜索。第一次迭代的出发点可以在参数允许范围内任取, 也可通过其它某些方法来获得。而第一次的一组方向通常取为 n 个坐标轴方向(也可取其它方向)。在选定了出发点和搜索方向之后, 迭代按以下步骤进行:

i) 线性搜索。对于 $i=1, 2, \dots, n$, 依次确定 λ_i , 使

$$\mathbf{x}^{(i+1)} = \mathbf{x}^{(i)} + \lambda_i \mathbf{P}^{(i)}$$

的函数值满足

$$f_{i+1} = f(\mathbf{x}^{(i+1)}) = \min_{\lambda} f(\mathbf{x}^{(i)} + \lambda \mathbf{P}^{(i)}).$$

ii) 如果迭代达到预定精度(例如向量 $\mathbf{x}^{(i)} - \mathbf{x}^{(i+1)}$ ($i=1, 2, \dots, n$) 的长度不超过预先规定的精度, 或 $f_1 - f_{n+1}$ 足够地小), 就将 $\mathbf{x}^{(n+1)}$ 与 f_{n+1} 分别看成所求的近似最优点与近似最优值, 迭代过程至此结束, 否则将进行下一步。

iii) 确定 m ($1 \leq m \leq n$), 使

$$\Delta = f_m - f_{m+1}$$

为各个 $f_i - f_{i+1}$ ($i=1, 2, \dots, n$) 中的最大者。

iv) 计算

$$\bar{f} = f(2\mathbf{x}^{(n+1)} - \mathbf{x}^{(1)}) \text{ 的数值。}$$

v) 若

$$\frac{1}{2}(f_1 - 2f_{n+1} + \bar{f}) < \Delta$$

不成立, 就以 $\mathbf{x}^{(n+1)}$ 为下次迭代的出发点 $\mathbf{x}^{(1)}$, 而以原方向 $\mathbf{P}^{(1)}, \mathbf{P}^{(2)}, \dots, \mathbf{P}^{(n)}$ 作为下次迭代所用的方向, 继续进行迭代。

vi) 若上式不等号成立, 则命

$$\mathbf{P} = \mathbf{x}^{(n+1)} - \mathbf{x}^{(1)}$$


并确定 λ^* , 使

$$x^* = x^{(n+1)} + \lambda^* P$$

的目标函数值

$$f^* = f(x^*) = \min f(x^{(n+1)} + \lambda P)$$

然后以 x^* 与 $P^{(1)}, P^{(2)}, \dots, P^{(m-1)}, P^{(m+1)}, \dots, P^{(n)}, P$ 作为下






图 3.3 用 Powell 方法极小化平方和函数的程序框图

次迭代的出发点与方向，开始下一次迭代。

以上对于 Powell 方法作了一般性陈述，具体到 ARMA(p, q) 的参数精估计问题，目标函数 f 就相应于平方和函数 $s(\beta)$ ，变元 x 相应于参数 $\beta^T = (\varphi_1, \dots, \varphi_p, \theta_1, \dots, \theta_q)$ ，进行第 i 步的线性搜

索时,必须控制 λ 的大小,使 β 落在模型的平稳可逆域内。模拟计算表明,在参数的平稳可逆域内, $s(\beta)$ 满足凸性, Powell 方法能够有效地极小化 $s(\beta)$, 应用 Powell 方法的具体流程可见框图 3.3。

至此为止,我们介绍了在阶数给定的情形下,模型参数的几种主要的估计手段。关于如何确定模型阶数的问题,将留待第四章专门讨论。下一节我们将从另几种角度,对于自回归模型作进一步的讨论。

§ 5 长自回归模型和最大熵谱估计

从 § 2—§ 4 可知,自回归模型参数与样本之间呈线性关系,模型的参数估计具有简单的解析表达形式,而且当样本长度 N 充分大时,参数的矩估计(Y-W 估计)就可以作为参数的精估计。基于自回归模型的上述优点,有一种观点主张尽可能采用 AR 模型来描述实际的数字序列,即使真实模型是 MA 或 ARMA 的,也可用高阶 AR (长自回归) 模型来近似描述。本节我们将从谱估计角度,论证 AR 模型是带有一定约束条件的极大熵谱估计的模型形式,并给出一套自回归模型参数估计的 Burg 递推算法。另外,还介绍一种 ARMA 建模的近似办法——长自回归白噪化建模方法。

§ 5.1 以最大熵为准则的谱估计

我们知道,平稳序列 $\{w_t\}$ 的统计特性完全由其自协方差函数列 $\{\gamma_k\}$

$$\gamma_k = E w_t w_{t+k}$$

或谱密度函数 $g(\lambda)$

$$g(\lambda) = \sum_{k=-\infty}^{\infty} \gamma_k e^{-i2\pi k\lambda}$$

表示出来,而且 $\{\gamma_k\}$ 和 $g(\lambda)$ 是相互对应的。

如果给定 $\gamma_0, \gamma_1, \dots, \gamma_m$ 这 m 个实数,它们构成正定列,那么,可以给出 $\gamma_{m+1}, \gamma_{m+2}, \dots$, 使之构成(正定的)自协方差函数序

列。然而,满足条件的这种扩充并不是唯一的,即有无穷多个序列,它们的前 $m+1$ 个协方差都同为给定的 $\gamma_0, \gamma_1, \dots, \gamma_m$ 。因此,自然会提出这样一个问题:如何去构造 m 以后的 γ_k , 使产生的序列 $\{\gamma_k\}, k=0, 1, 2, \dots$ 不仅构成正定列,满足条件

$$\sum_{k=0}^{\infty} |\gamma_k| < \infty$$

而且它所对应的谱密度 $g(\lambda)$ 能含有序列 $\{w_i\}$ 中最多的信息。

用谱熵

$$H(g) = \int_{-\frac{1}{2}}^{\frac{1}{2}} \log g(\lambda) d\lambda \quad (3.5.1)$$

来表示 $g(\lambda)$ 所含信息量的大小(熵是信息论中的一个概念)。由上述知, $g(\lambda)$ 应满足约束条件

$$\int_{-\frac{1}{2}}^{\frac{1}{2}} g(\lambda) e^{i2\pi\lambda k} d\lambda = \gamma_k \quad k=0, \pm 1, \dots, \pm m \quad (3.5.2)$$

在所有满足上述条件的谱密度中选出一个使谱熵 $H(g)$ 达到最大的 $g(\lambda)$ 来。从信息论观点看来,这个 $g(\lambda)$ 所对应的序列 $\{w_i\}$ 随机性最强、最不带人为偏见和主观意识,因而含有的信息最多。由此可见,问题归结为寻找一种带约束条件的泛函极值。在满足约束条件 (3.5.2) 的前提下,使谱熵 (3.5.1) 达到最大的准则,叫做最大熵准则。

下面证明,使谱熵达到最大的是一个 m 阶自回归序列,它的前 m 阶自协方差函数等于已知值 $\gamma_0, \gamma_1, \dots, \gamma_m$ 。

证明:

记

$$\begin{aligned} J(g) &= \int_{-\frac{1}{2}}^{\frac{1}{2}} \log g(\lambda) d\lambda - \sum_{k=-m}^m \xi_k \int_{-\frac{1}{2}}^{\frac{1}{2}} g(\lambda) e^{i2\pi\lambda k} d\lambda \\ &\equiv \int_{-\frac{1}{2}}^{\frac{1}{2}} \left[\log g(\lambda) - \left(\sum_{k=-m}^m \xi_k e^{i2\pi\lambda k} \right) g(\lambda) \right] d\lambda \end{aligned}$$

其中 ξ_k 是 Lagrange 乘子, 它们都为实数。由于 $\gamma_k \equiv \gamma_{-k}$, 为了以下推导方便, 记

$$\xi_{-k} = \xi_k = \frac{1}{2} \eta_k \quad (k=1, 2, \dots, m), \quad \xi_0 = \eta_0$$

使泛函 $J(g)$ 达极值的条件是变分 $\delta J(g) = 0$

$$\delta J(g) = \int_{-\frac{1}{2}}^{\frac{1}{2}} \left[\frac{1}{g(\lambda)} - \sum_{k=-m}^m \xi_k e^{i2\pi\lambda k} \right] \delta g(\lambda) d\lambda$$

式中 $\delta g(\lambda)$ 表示在 $g(\lambda)$ 处的一个任意“增量”, 由于它的任意性, 因此 $\delta J(g) = 0$ 等价于

$$g(\lambda) = \left(\sum_{k=-m}^m \xi_k e^{i2\pi\lambda k} \right)^{-1}$$

记 $\xi(z) = \sum_{k=-m}^m \xi_k z^k$, 用 $\bar{z}$ 表示 z 的共轭复数, 则

$$\xi(\bar{z}) = \sum_{k=-m}^m \xi_k (\bar{z})^k = \overline{\left(\sum_{k=-m}^m \xi_k z^k \right)} = \overline{\xi(z)}$$

另外, $\xi(z^{-1}) = \sum_{k=-m}^m \xi_k z^{-k} = \sum_{k=-m}^m \xi_{-k} z^k = \sum_{k=-m}^m \xi_k z^k = \xi(z)$ 由上两

式可见, $\xi(z)$ 的零点是互为共轭并互为倒数的。也就是说, 如果某一个 z_k 是 $\xi(z)$ 的零点, 那么 $\bar{z}_k, z_k^{-1}, \bar{z}_k^{-1}$ 也都是 $\xi(z)$ 的零点。

另外, 我们总假设 $g(\lambda)$ 可积, 即

$$\begin{aligned} \gamma_0 &= \int_{-\frac{1}{2}}^{\frac{1}{2}} g(\lambda) d\lambda = \int_{-\frac{1}{2}}^{\frac{1}{2}} \frac{d\lambda}{\sum_{k=-m}^m \xi_k e^{i2\pi\lambda k}} \\ &= \frac{1}{2\pi i} \oint_{|z|=1} \frac{dz}{z \xi(z)} < \infty \end{aligned}$$

因此, $\xi(z)$ 不可能在单位圆上有零点。

记 $\tilde{\xi}(z) = z^m \xi(z)$

则 $\tilde{\xi}(z)$ 是 z 的 $2m$ 次多项式, 它与 $\xi(z)$ 具有完全相同的零点。因此

$$\begin{aligned}
\xi(z) &= cz^{-m} \prod_{k=1}^m (z - z_k^{-1})(z - \bar{z}_k) \\
&= c \prod_{k=1}^m (1 - z_k^{-1}z^{-1})(z - \bar{z}_k) \\
&= c' \prod_{k=1}^m (z^{-1} - z_k)(z - \bar{z}_k)
\end{aligned}$$

其中 c 和 c' 都表示某一常数。于是有

$$\begin{aligned}
g(\lambda) &= \xi^{-1}(e^{i2\pi\lambda}) = \left(c' \prod_{k=1}^m (e^{-i2\pi\lambda} - z_k)(e^{i2\pi\lambda} - \bar{z}_k) \right)^{-1} \\
&= \left(c' \prod_{k=1}^m (1 - z_k e^{i2\pi\lambda})(1 - \bar{z}_k e^{-i2\pi\lambda}) \right)^{-1} \\
&= \frac{1}{c' \left| \prod_{k=1}^m (1 - z_k e^{i2\pi\lambda}) \right|^2}
\end{aligned}$$

记 $\prod_{k=1}^m (1 - z_k e^{i2\pi\lambda}) = 1 - \varphi_1 e^{i2\pi\lambda} - \dots - \varphi_m e^{i2\pi\lambda m} = \varphi(e^{i2\pi\lambda})$ ，且由

于 $z_k, \bar{z}_k, z_k^{-1}, \bar{z}_k^{-1}$ 全为 $\xi(z)$ 的零点，可以将 $z_1, z_2, \dots, z_m$ 全都取在单位圆内。显然，它们或为实数，或为共轭复数成对出现。因此， $\varphi_1, \varphi_2, \dots, \varphi_m$ 全为实数，且 $\varphi(z)$ 的零点 z_k^{-1} 全都在单位圆外。

另外，由于 $g(\lambda) > 0$ ，因此， $c' > 0$ ，故可记

$$\sigma^2 \triangleq \frac{1}{c'}$$

最后，我们可将最大熵谱估计的 $g(\lambda)$ 表成

$$g(\lambda) = \frac{\sigma^2}{\varphi(e^{i2\pi\lambda})\overline{\varphi(e^{i2\pi\lambda})}} = \frac{\sigma^2}{|\varphi(e^{i2\pi\lambda})|^2}$$

这就是 m 阶自回归序列所具有的谱密度形式。

以上我们从最大熵谱准则论证了 $g(\lambda)$ 应具有 $AR(m)$ 模型

的谱密度形式。下面再进一步给出这 m 个自回归系数应满足的关系式。

由等式

$$g(\lambda) = \sigma^2 / |\varphi(e^{i2\pi\lambda})|^2$$

$$\text{得} \quad \int_{-\frac{1}{2}}^{\frac{1}{2}} g(\lambda) \overline{\varphi(e^{i2\pi\lambda})} e^{i2\pi k\lambda} d\lambda = \sigma^2 \int_{-\frac{1}{2}}^{\frac{1}{2}} \frac{e^{i2\pi k\lambda}}{\varphi(e^{i2\pi\lambda})} d\lambda$$

$$\text{左} = \int_{-\frac{1}{2}}^{\frac{1}{2}} g(\lambda) \varphi(e^{-i2\pi\lambda}) e^{i2\pi k\lambda} d\lambda = \gamma_k - \varphi_1 \gamma_{k-1} - \cdots - \varphi_m \gamma_{k-m}$$

$$\text{右} = \frac{\sigma^2}{2\pi i} \oint_{|z|=1} \frac{z^{k-1}}{\varphi(z)} dz = \sigma^2 \delta_{k0} \quad k=0, 1, \cdots, m$$

注意 $\gamma_k = \gamma_{-k}$, 上方程组即可写成如下的矩阵形式

$$\begin{pmatrix} \gamma_0 & \gamma_1 & \cdots & \gamma_m \\ \gamma_1 & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \gamma_1 \\ \gamma_m & \cdots & \gamma_1 & \gamma_0 \end{pmatrix} \begin{pmatrix} 1 \\ -\varphi_1 \\ \vdots \\ -\varphi_m \end{pmatrix} = \sigma^2 \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

取其后 m 个方程, 即得

$$\begin{pmatrix} \gamma_0 & \cdots & \gamma_m \\ \vdots & \ddots & \vdots \\ \gamma_m & \cdots & \gamma_0 \end{pmatrix} \begin{pmatrix} \varphi_1 \\ \vdots \\ \varphi_m \end{pmatrix} = \begin{pmatrix} \gamma_1 \\ \vdots \\ \gamma_m \end{pmatrix} \quad (3.5.3)$$

这正是 Y-W 方程, 由此解出的 $\varphi_1, \cdots, \varphi_m$ 就是所要求的 AR(m) 的模型参数。

§ 5.2 最大熵谱估计的计算方法

由 § 5.1 得知, 要想从最大熵准则得到一个 AR(m) 序列, 必先得知序列的前 $m+1$ 个自协方差函数 $\gamma_0, \gamma_1, \cdots, \gamma_m$ 。在实际问题中, 常常是先获得序列的有限样本值 $w_1, w_2, \cdots, w_N$, 然后用 $\hat{\gamma}_k, k=0, 1, 2, \cdots, m$ 代替 (3.5.3) 式中相应的 γ_k , 以求得 $\hat{\varphi}_1, \hat{\varphi}_2, \cdots, \hat{\varphi}_m$, 并将相应于 (3.5.2) 形式的谱作为序列的谱估计。这样一种估计方法, 就称为最大熵谱估计方法。

本章(3.1.1)和(3.1.2)式给出了两种自协方差函数的估计量,这两种估计量都各有其优缺点。本节我们给出一种 Burg 迭代算法,这种迭代算法不仅给出自协方差的一种新估计,而且可以迭代求解最大熵谱估计中诸自回归参数和白噪声方差。Burg 迭代需要运用 Wiggins-Robison 辅助系数迭代原理,此原理可用来求解以下形式的方程组

$$\begin{pmatrix} \gamma_0 & & & \gamma_n \\ & \ddots & & \\ & & \ddots & \\ \gamma_n & & & \gamma_0 \end{pmatrix} \begin{pmatrix} \psi_{n0} \\ \vdots \\ \psi_{nn} \end{pmatrix} = \begin{pmatrix} \alpha_n \\ 0 \\ \vdots \\ 0 \end{pmatrix} \quad (3.5.4)$$

方程组的系数构成 Toeplitz 矩阵,未知量有 $n+1$ 个,即 $\psi_{n1}, \psi_{n2}, \dots, \psi_{nn}, \alpha_n$ 。式中 $\psi_{n0} \equiv 1, \alpha_n > 0$ 。

W-R 原理的迭代方法如下:

设在 $n-1$ 阶情形,方程组 (3.5.4) 中各量已经迭代求得,即

$$\begin{pmatrix} \gamma_0 & & & \gamma_{n-1} \\ & \ddots & & \\ & & \ddots & \\ \gamma_{n-1} & & & \gamma_0 \end{pmatrix} \begin{pmatrix} \psi_{n-1,0} \\ \vdots \\ \psi_{n-1,n-1} \end{pmatrix} = \begin{pmatrix} \alpha_{n-1} \\ 0 \\ \vdots \\ 0 \end{pmatrix} \quad (3.5.5)$$

中, $\psi_{n-1,1}, \dots, \psi_{n-1,n-1}$ 和 α_{n-1} 已由迭代求得,则可得到

$$\begin{pmatrix} \gamma_0 & & & \gamma_n \\ & \ddots & & \\ & & \ddots & \\ \gamma_n & & & \gamma_0 \end{pmatrix} \begin{pmatrix} \psi_{n-1,0} \\ \vdots \\ \psi_{n-1,n-1} \\ 0 \end{pmatrix} = \begin{pmatrix} \alpha_{n-1} \\ 0 \\ \vdots \\ 0 \\ \alpha'_{n-1} \end{pmatrix} \quad (3.5.6)$$

$$\begin{pmatrix} \gamma_0 & & & \gamma_n \\ & \ddots & & \\ & & \ddots & \\ \gamma_n & & & \gamma_0 \end{pmatrix} \begin{pmatrix} 0 \\ \psi_{n-1,n-1} \\ \vdots \\ \psi_{n-1,0} \end{pmatrix} = \begin{pmatrix} \alpha'_{n-1} \\ 0 \\ \vdots \\ 0 \\ \alpha_{n-1} \end{pmatrix}$$

$$\text{其中} \quad \alpha'_{n-1} = \sum_{j=0}^{n-1} \gamma_{n-j} \psi_{n-1,j} \quad (3.5.7)$$

$$\text{令} \quad k_{n-1} = -\alpha'_{n-1} / \alpha_{n-1} \quad (3.5.8)$$

则有

$$\begin{pmatrix} \gamma_0 & \cdots & \gamma_n \\ \vdots & \ddots & \vdots \\ \gamma_n & \cdots & \gamma_0 \end{pmatrix} \begin{pmatrix} \psi_{n-1,0} \\ \vdots \\ \psi_{n-1,n-1} \\ 0 \end{pmatrix} + k_{n-1} \begin{pmatrix} \gamma_0 & \cdots & \gamma_n \\ \vdots & \ddots & \vdots \\ \gamma_n & \cdots & \gamma_0 \end{pmatrix} \begin{pmatrix} 0 \\ \psi_{n-1,n-1} \\ \vdots \\ \psi_{n-1,0} \end{pmatrix} \\ \begin{pmatrix} \alpha_{n-1} \\ 0 \\ \vdots \\ 0 \\ \alpha'_{n-1} \end{pmatrix} + k_{n-1} \begin{pmatrix} \alpha'_{n-1} \\ 0 \\ \vdots \\ 0 \\ \alpha_{n-1} \end{pmatrix} = \begin{pmatrix} \alpha_{n-1} + k_{n-1} \alpha'_{n-1} \\ 0 \\ \vdots \\ 0 \end{pmatrix} \quad (3.5.9)$$

由上可见

$$\begin{cases} (\psi_{n0}, \psi_{n1}, \dots, \psi_{nn})^T = (\psi_{n-1,0}, \dots, \psi_{n-1,n-1}, 0)^T \\ \quad + k_{n-1} (0, \psi_{n-1,n-1}, \dots, \psi_{n-1,0})^T \\ \alpha_n = \alpha_{n-1} + k_{n-1} \alpha'_{n-1} \\ \psi_{nn} = k_{n-1} \end{cases} \quad (3.5.10)$$

(3.5.7)~(3.5.10)式就构成了方程组(3.5.4)由低阶到高阶的迭代求解程序。

运用 W-R 原理, 可以实现 Burg 迭代。为此, 将 AR(m) 模型 $w_t = \varphi_1 w_{t-1} + \varphi_2 w_{t-2} + \cdots + \varphi_m w_{t-m} + a_t$ 改成

$$a_t = w_t - \varphi_1 w_{t-1} - \varphi_2 w_{t-2} - \cdots - \varphi_m w_{t-m}$$

这种形式称为“预报误差滤波器”, 其输出方差为

$$E a_t^2 = \sigma_m^2$$

自回归系数为 $\varphi_{m1}, \varphi_{m2}, \dots, \varphi_{mm}$

当 $m=0$ 时, “预报误差滤波器”的形式为

$$a_t = w_t$$

因此, $\sigma_0^2 = \frac{1}{N} \sum_{i=1}^N w_i^2 = \hat{\sigma}_0^2 > 0$

当 $m=1$ 时, 由极大熵谱估计和 W-R 迭代原理, 可得

$$\begin{aligned} \begin{pmatrix} \sigma_1^2 \\ 0 \end{pmatrix} &= \begin{pmatrix} \hat{\sigma}_0 & \hat{\sigma}_1 \\ \hat{\sigma}_1 & \hat{\sigma}_0 \end{pmatrix} \begin{pmatrix} 1 \\ -\varphi_{11} \end{pmatrix} = \begin{pmatrix} \hat{\sigma}_0 & \hat{\sigma}_1 \\ \hat{\sigma}_1 & \hat{\sigma}_0 \end{pmatrix} \left[\begin{pmatrix} 1 \\ 0 \end{pmatrix} - \varphi_{11} \begin{pmatrix} 0 \\ 1 \end{pmatrix} \right] \\ &= \begin{pmatrix} \sigma_0^2 \\ \hat{\sigma}_1 \end{pmatrix} - \varphi_{11} \begin{pmatrix} \hat{\sigma}_1 \\ \sigma_0^2 \end{pmatrix} \end{aligned}$$

由此得出

$$\hat{\sigma}_1 = \varphi_{11} \sigma_0^2$$

$$\sigma_1^2 = \sigma_0^2 - \varphi_{11} \hat{\sigma}_1 = (1 - \varphi_{11}^2) \sigma_0^2$$

式中的 φ_{11} 应使一阶预报误差滤波器的输出方差估计量

$$\frac{1}{2(N-1)} \left(\sum_{i=2}^N (w_i - \varphi_{11} w_{i-1})^2 + \sum_{i=2}^N (w_{i-1} - \varphi_{11} w_i)^2 \right)$$

达极小。上式中后一和号相当于把数据 $w_1, \dots, w_N$ 倒序再使用一次, 以提高信息利用率。由于平稳序列 $(w_1, w_2, \dots, w_N)$ 和 $(w_N, w_{N-1}, \dots, w_1)$ 有完全相同的统计特性, 这样做是合理的。

φ_{11} 应满足方程

$$\frac{\partial}{\partial \varphi_{11}} \left(\sum_{i=2}^N (w_i - \varphi_{11} w_{i-1})^2 + \sum_{i=2}^N (w_{i-1} - \varphi_{11} w_i)^2 \right) = 0$$

由此得

$$\varphi_{11} = 2 \sum_{i=2}^N w_i w_{i-1} / \left(\sum_{i=2}^N w_i^2 + \sum_{i=2}^N w_{i-1}^2 \right)$$

令 $m=2$, 仍由 W-R 原理, 有

$$\begin{aligned} \begin{pmatrix} \sigma_2^2 \\ 0 \\ 0 \end{pmatrix} &= \begin{pmatrix} \hat{\sigma}_0 & \hat{\sigma}_1 & \hat{\sigma}_2 \\ \hat{\sigma}_1 & \hat{\sigma}_0 & \hat{\sigma}_1 \\ \hat{\sigma}_2 & \hat{\sigma}_1 & \hat{\sigma}_0 \end{pmatrix} \begin{pmatrix} 1 \\ -\varphi_{21} \\ -\varphi_{22} \end{pmatrix} = \begin{pmatrix} \hat{\sigma}_0 & \hat{\sigma}_1 & \hat{\sigma}_2 \\ \hat{\sigma}_1 & \hat{\sigma}_0 & \hat{\sigma}_1 \\ \hat{\sigma}_2 & \hat{\sigma}_1 & \hat{\sigma}_0 \end{pmatrix} \left[\begin{pmatrix} 1 \\ -\varphi_{11} \\ 0 \end{pmatrix} \right. \\ &\quad \left. - \varphi_{22} \begin{pmatrix} 0 \\ -\varphi_{11} \\ 1 \end{pmatrix} \right] \end{aligned}$$

$$= \begin{pmatrix} \sigma_1^2 \\ 0 \\ \hat{p}_2 - \varphi_{11}\hat{p}_1 \end{pmatrix} - \varphi_{22} \begin{pmatrix} \hat{p}_2 - \varphi_{11}\hat{p}_1 \\ 0 \\ \sigma_1^2 \end{pmatrix}$$

得

$$\hat{p}_2 = \varphi_{11}\hat{p}_1 + \varphi_{22}\sigma_1^2$$

$$\sigma_2^2 = \sigma_1^2 - \varphi_{22}(\hat{p}_2 - \varphi_{11}\hat{p}_1) = (1 - \varphi_{22}^2)\sigma_1^2$$

$$\varphi_{21} = \varphi_{11} - \varphi_{22}\varphi_{11}$$

其中, φ_{22} 应使二阶预报误差滤波器的输出方差估计量

$$\begin{aligned} & \frac{1}{2(N-2)} \sum_{i=3}^N [(w_i - \varphi_{21}w_{i-1} - \varphi_{22}w_{i-2})^2 + \\ & \quad + (w_{i-2} - \varphi_{21}w_{i-1} - \varphi_{22}w_i)^2] \\ &= \frac{1}{2(N-2)} \sum_{i=3}^N \{ [(w_i - \varphi_{11}w_{i-1}) - \varphi_{22}(w_{i-2} - \varphi_{11}w_{i-1})]^2 + \\ & \quad + [(w_{i-2} - \varphi_{11}w_{i-1}) - \varphi_{22}(w_i - \varphi_{11}w_{i-1})]^2 \} \end{aligned}$$

达极小。由上式对 φ_{22} 求偏导数等于零, 解出 φ_{22} , 得

$$\varphi_{22} = \frac{2 \sum_{i=3}^N (w_i - \varphi_{11}w_{i-1})(w_{i-2} - \varphi_{11}w_{i-1})}{\sum_{i=3}^N [(w_i - \varphi_{11}w_{i-1})^2 + (w_{i-2} - \varphi_{11}w_{i-1})^2]}$$

依此类推, 如果对于 $j \leq m$, 已求得 $\hat{p}_m, \sigma_m^2, \varphi_m$, 则根据 W-R 原理, 考虑 $m+2$ 阶联立方程组

$$\begin{aligned} & \begin{pmatrix} \sigma_{m+1}^2 \\ 0 \\ \vdots \\ 0 \end{pmatrix} = \begin{pmatrix} \hat{p}_0 & \cdots & \hat{p}_{m+1} \\ \vdots & \ddots & \vdots \\ \hat{p}_{m+1} & \cdots & \hat{p}_0 \end{pmatrix} \begin{pmatrix} 1 \\ -\varphi_{m+1,1} \\ \vdots \\ -\varphi_{m+1,m+1} \end{pmatrix} \\ &= \begin{pmatrix} \hat{p}_0 & \cdots & \hat{p}_{m+1} \\ \vdots & \ddots & \vdots \\ \hat{p}_{m+1} & \cdots & \hat{p}_0 \end{pmatrix} \begin{pmatrix} 1 \\ -\varphi_{m1} \\ \vdots \\ -\varphi_{mm} \\ 0 \end{pmatrix} - \varphi_{m+1,m+1} \begin{pmatrix} 0 \\ -\varphi_{mm} \\ \vdots \\ -\varphi_{m,1} \\ 1 \end{pmatrix} \end{aligned}$$

$$= \begin{pmatrix} \sigma_m^2 \\ 0 \\ \vdots \\ 0 \\ \hat{y}_{m+1} - \sum_{j=1}^m \varphi_{mj} \hat{y}_{m+1-j} \\ \hat{y}_{m+1} - \sum_{j=1}^m \varphi_{mj} \hat{y}_{m+1-j} \\ 0 \\ \vdots \\ 0 \\ \sigma_m^2 \end{pmatrix} - \varphi_{m+1, m+1}$$

得

$$\hat{y}_{m+1} = \sum_{j=1}^m \varphi_{mj} \hat{y}_{m+1-j} - \varphi_{m+1, m+1} \sigma_m^2 \quad (3.5.11)$$

$$\begin{aligned} \sigma_{m+1}^2 &= \sigma_m^2 - \varphi_{m+1, m+1} \left(\hat{y}_{m+1} - \sum_{j=1}^m \varphi_{mj} \hat{y}_{m+1-j} \right) \\ &= (1 - \varphi_{m+1, m+1}^2) \sigma_m^2 \end{aligned} \quad (3.5.12)$$

$$\varphi_{m+1, j} = \varphi_{mj} - \varphi_{m+1, m+1} \varphi_{m, m+1-j} \quad j \leq m \quad (3.5.13)$$

其中 $\varphi_{m+1, m+1}$ 应使 $m+1$ 阶预报误差滤波器输出的方差估计量

$$\begin{aligned} & \frac{1}{2(N-m-1)} \sum_{t=m+2}^N \left[(w_t - \sum_{j=1}^{m+1} \varphi_{m+1, j} w_{t-j})^2 + \right. \\ & \quad \left. (w_{t-m-1} - \sum_{j=1}^{m+1} \varphi_{m+1, j} w_{t-m-1+j})^2 \right] \\ &= \frac{1}{2(N-m-1)} \sum_{t=m+2}^N \left\{ \left[(w_t - \sum_{j=1}^m \varphi_{mj} w_{t-j}) \right. \right. \\ & \quad \left. \left. - \varphi_{m+1, m+1} (w_{t-m-1} - \sum_{j=1}^m \varphi_{mj} w_{t-m-1+j}) \right]^2 \right\} \end{aligned}$$

$$+ \left[(w_{t-m-1} - \sum_{j=1}^m \varphi_{mj} w_{t-m-1+j}) - \varphi_{m+1, m+1} (w_t - \sum_{j=1}^m \varphi_{mj} w_{t-j}) \right]^2 \}$$

达极小。由上式对 $\varphi_{m+1, m+1}$ 求偏导数等于零, 得

$$\begin{aligned} \varphi_{m+1, m+1} = & \\ = & \frac{2 \sum_{t=m+2}^N (w_t - \sum_{j=1}^m \varphi_{mj} w_{t-j}) (w_{t-m-1} - \sum_{j=1}^m \varphi_{mj} w_{t-m-1+j})}{\sum_{t=m+2}^N [(w_t - \sum_{j=1}^m \varphi_{mj} w_{t-j})^2 + (w_{t-m-1} - \sum_{j=1}^m \varphi_{mj} w_{t-m-1+j})^2]} \end{aligned} \quad (3.5.14)$$

(3.5.11)~(3.5.14)式给出了最大熵谱估计关于 $\hat{\gamma}_m, \sigma_m^2, \varphi_{mj}, j=1, 2, \dots, m$ 的一整套 Burg 递推公式。

至此为止, 我们得知 AR(p)模型是极大熵谱准则下的最优线性模型形式, 而且其模型参数可以通过 Burg 递推来得到。通过与 ARMA(p, q)模型参数估计的比较可知, Burg 递推要简单方便得多。因此, 我们若不想运用非线性手段来进行参数估计和建模, 就应该充分运用 Burg 递推这一有效工具。式 (3.5.11)~(3.5.14)的递推将依如下次序来实现:

$$\begin{aligned} \text{递推初值} \quad \hat{\gamma}_0 = \sigma_0^2 &= \frac{1}{N} \sum_{i=1}^N w_i^2 \\ \varphi_{11} &= \frac{2 \sum_{i=2}^n w_i w_{i-1}}{\sum_{i=2}^n (w_i^2 + w_{i-1}^2)} \end{aligned}$$

递推次序 设递推已完成第 k 步, 则第 $k+1$ 步的结果将由如下次序计算

$$\dots \rightarrow \varphi_{k+1, k+1} \rightarrow \begin{cases} \hat{\gamma}_{k+1} \\ \hat{\sigma}_{k+1} \end{cases} \rightarrow \begin{cases} \varphi_{k+1, 1} \\ \varphi_{k+1, k} \end{cases}, \begin{cases} \varphi_{k+1, 2} \\ \varphi_{k+1, k-1} \end{cases}, \dots$$

其递推过程中, 关于 $\varphi_{k+1,i}$ 与 $\varphi_{k+1,k+1-i}$ 成对计算的技巧及分析, 可参照第二章 §5.2 的有关讨论。这是因为对于偏相关函数的递推与本节对于 AR(k) 模型自回归参数 φ_i 的 Burg 递推, 这两套公式有明显的类似之处, 所以, 在计算技巧上, 也同样可以借鉴。

可以证明, 由 Burg 递推得到的样本自协方差列 $\hat{\gamma}_0, \hat{\gamma}_1, \dots$ 是非负定的。从而可作为某一平稳序列的自协方差函数列。

首先, 由 (3.5.14) 式可知

$$\begin{aligned} |\varphi_{m+1,m+1}| &\leqslant \\ &\frac{2 \sum_{t=m+2}^N \left| \left(w_t - \sum_{j=1}^m \varphi_{m,j} w_{t-j} \right) \left(w_{t-m-1} - \sum_{j=1}^m \varphi_{m,j} w_{t-m-1+j} \right) \right|}{\sum_{t=m+2}^N \left| \left(w_t - \sum_{j=1}^m \varphi_{m,j} w_{t-j} \right)^2 + \left(w_{t-m-1} - \sum_{j=1}^m \varphi_{m,j} w_{t-m-1+j} \right)^2 \right|} \\ &\leqslant 1 \end{aligned}$$

以此代入 (3.5.12) 式, 即可得

$$0 \leqslant \sigma_{m+1}^2 \leqslant \sigma_m^2$$

另外, 令

$$\hat{F}_m = \begin{pmatrix} \hat{\gamma}_0 & & & \hat{\gamma}_m \\ & \ddots & & \\ & & \ddots & \\ \hat{\gamma}_m & & & \hat{\gamma}_0 \end{pmatrix}$$

由

$$\hat{F}_{m+1} \begin{pmatrix} 1 \\ -\varphi_{m+1,1} \\ \vdots \\ -\varphi_{m+1,m+1} \end{pmatrix} = \begin{pmatrix} \sigma_{m+1}^2 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

解线性方程组得

$$1 = \frac{\sigma_{m+1}^2 |\hat{F}_m|}{|\hat{F}_{m+1}|}$$

即

$$\frac{|\hat{\Gamma}_{m+1}|}{|\hat{\Gamma}_m|} = \sigma_{m+1}^2 \geq 0$$

注意到 $\hat{\sigma}_0^2 = \sigma_0^2 > 0$, 于是由归纳法可证得 $|\hat{\Gamma}_m| \geq 0$ 对任意 $m > 0$ 均成立, 从而得到矩阵 $\hat{\Gamma}_m \geq 0$ 。这就论证了序列 $\hat{\gamma}_0, \hat{\gamma}_1, \dots$ 的非负定性。

对于实际观测数据用最大熵谱估计作模型拟合时, 还存在一个定阶问题。原则上, 如果用 $AR(m)$ 来拟合 $ARMA$ 序列, 则由逆转形式可见, 阶数 m 应取无穷大, 因此样本长度为 N 时, 应取 m 为 $N-1$ 。但由于 $\hat{\gamma}_k$ 的精度随 k 增大而渐次, 取 $N-1$ 为阶数也未必最佳, 且当 N 较大时, 计算量也太大。理论上已证明, m 应不超过 $\sqrt{N}$ 才行。从实用经验来看, m 取 $\frac{N}{2}, \frac{N}{3}, \dots, \frac{N}{10}$ 的情形都有出现, 或者也可用下一章所介绍的方法来定阶。若序列本身原为 p 阶自回归的, 当然应当取 m 尽可能接近 p 。所以在作最大熵谱估计之前, 应检验偏相关函数的截尾性, 并以截尾数作为自回归模型的阶数。

§5.3 最大熵谱分析的应用实例

根据最大熵谱原理, 应用 Burg 递推算法, 对气象历史序列进行了若干实例计算^[11]。结果表明, 最大熵谱估计有利于揭发有天气意义的周期和显示气象资料的谱性质, 为天气预报提供了一种有用的分析工具。下面, 对两种气象资料举例分析:

1. 低纬等压面高度的谱分析: 对 1965—1975 年 100 毫巴月高度的数据进行最大熵谱分析。样本长度 $N = 12 \times 11 = 132$, 对于样本列 $\{x_1, x_2, \dots, x_{132}\}$ 进行气象上常采取的预处理——“距平 12 个月移动平均处理”(气象术语), 以消除年变化的影响

距平: 令 $y_{12k+i} = x_{12k+i} - \bar{x}_i, \quad k=0, 1, 2, \dots, 10$

$$\text{其中 } \bar{x}_i = \frac{1}{11} \sum_{k=0}^{10} x_{12k+i} \quad i=1, 2, 3, \dots, 12$$

(3.5.15)

12 个月移动平均:

$$H_i = \frac{1}{12} \sum_{j=i}^{i+11} y_j, \quad i=1, 2, \dots, 121 \quad (3.5.16)$$

图 3.4 给出了 H_i 值的曲线。由图可见, $\{H_i\}$ 存在着长度摆动在 34—41 个月的周期, 对 $\{H_i\}$ 建立了 AR(13) 模型, 并对相应的熵




图 3.4 曼谷 100 毫巴高度距平 12 个月移动平均值

谱进行分析, 由图 3.5 可知, 在 $T = 36$ 个月时, 功率谱有一个极大值存在, 谱值 $f(T)$ 比一般谱值大一个量级, 这和天气学分析的结果相一致。在 $T = 10—11$ 个月处有一次峰值, 但谱值远比主峰值小, 整个谱呈双峰型。而对数据 $\{H_i\}$ 进行通常的谱图估计, 所得的功率谱(图 3.6)呈单峰型, 主周期位于 44 个月, 与天气分析结




图 3.5 曼谷 100 毫巴高度的熵谱




图 3.6 曼谷 100 毫巴高度的 Tukey 谱

果有偏移。这一实例说明，熵谱分析能揭露或证实有价值的天气事实。

2. 单站资料的功率谱：用嘉兴 1954—1975 年逐月气压资料，计 $22 \times 12 = 264$ 个样本进行最大熵谱分析。先将数据进行“12 个月移动平均”处理，以消除年变化。然后用 Burg 递推拟合 AR (14) 模型。图 3.7 给出了嘉兴月气压的熵谱曲线，此曲线呈单峰型，在周期 $T = 17$ 处有很尖的峰值，这是熵谱分析分辨率高的表现。 $T = 17$ 的峰值表明嘉兴气压有 17 个月的显著周期。无疑，揭露出这类单站要素的长周期规律，对于长期预报、超长期预报都是有意义的。




图 3.7 嘉兴月气压的熵谱

由上两个实例可见，熵谱分析确实存在分辨率高，周期偏移小等突出优点。此外，由于熵谱分析对于短序列仍有高的周期分辨率，因此可以将一个长记录序列分成若干短序列分别作熵谱分

析,以研究某些序列周期随时间变化的情形,这对于数据分析和预报都将有实用价值。最大熵谱分析在许多科研领域里都有成功的应用,文献[12],[13]给出了天文方面的应用实例。

§ 5.4 长自回归白噪化建模方法

本节开头我们曾提及,由于纯自回归模型的定阶、参数估计都远比 ARMA 模型简单,不少统计学者曾提倡用高阶自回归(或称长自回归)来拟合 ARMA(p, q)序列。有人对此思想的可靠性进行了理论证明^[14],指出当自回归模型阶数 p_N 与 $\sqrt{\log N/N}$ 呈关系式

$$p_N \cdot \sqrt{\log N/N} \rightarrow 0 \text{ 时,} \quad (3.5.17)$$

则 AR(p_N)的谱与序列的真实谱之间能一致地接近到很好的程度。由此可见,对于大样本 ARMA(p, q)序列,用长自回归逼近拟合时,阶数 p_N 应随着样本增加而增长。因此,需要估计的参数是相当多的。为了充分利用长自回归拟合的近似可靠性,同时又适当控制被估参数个数,近年来国内外都有人提出了一种与前几节中介绍过的完全不同的 ARMA 建模的近似方法,它完全回避了求非线性最小二乘的极值问题,而代之以求解线性方程。此一方法不仅大大减少了计算量,而且不再担心迭代运算不收敛的麻烦。此方法的基本思想是,以承认长自回归拟合的近似可靠性为依据,用拟合得的长自回归模型与序列长为 N 的样本 $w_1, w_2, \dots, w_N$ 计算出 $a_{p_N}, a_{p_N+1}, \dots, a_N$ 的估计值 $\hat{a}_{p_N}, \dots, \hat{a}_N$, 认为它们是真值的很好近似,将它们作为样本值使用。联合原有样本序列,对 ARMA(p, q)的模型参数进行估计。这时,模型参数的最小二乘估计可以由求解线性方程组而得到,故此,上述方法可称为“长自回归白噪化建模方法”。现将此方法的建模步骤规纳如下(假定 $w_1, w_2, \dots, w_N$ 是平稳、零均值样本列):

i) 用 Y-W 方法建立长自回归模型 AR(p_N), 阶数 p_N 取 $\log N$ 的适当倍数, 即记 AR(p_N) 的自回归参数为

$$\alpha = (\alpha_1, \alpha_2, \dots, \alpha_{p_N})^T \quad (3.5.18)$$

其 Y-W 估计为

$$\hat{\alpha} = (\hat{\alpha}_1, \hat{\alpha}_2, \dots, \hat{\alpha}_{p_N})^T = \hat{\Gamma}_{p_N}^{-1} \hat{\eta}_{p_N} \quad (3.5.19)$$

其中

$$\hat{\Gamma}_{p_N} = \begin{pmatrix} \hat{\gamma}_0 & & & \hat{\gamma}_{p_N-1} \\ & \ddots & & \\ & & \ddots & \\ \hat{\gamma}_{p_N-1} & & & \hat{\gamma}_0 \end{pmatrix} \quad \hat{\eta}_{p_N} = \begin{pmatrix} \hat{\gamma}_1 \\ \hat{\gamma}_2 \\ \vdots \\ \hat{\gamma}_{p_N} \end{pmatrix} \quad (3.5.20)$$

模型白噪声方差的估计量为

$$\hat{\sigma}_{p_N}^2 = \hat{\gamma}_0 - \hat{\eta}_{p_N}^T \hat{\Gamma}_{p_N}^{-1} \hat{\eta}_{p_N} \quad (3.5.21)$$

ii) 应用i)所得的 $\hat{\alpha}$ 及样本值 $w_N = (w_1, \dots, w_N)^T$ 计算

$$\hat{\alpha}_k = w_k - \sum_{i=1}^{p_N} \hat{\alpha}_i w_{k-i} \quad k = p_{N+1}, p_{N+2}, \dots, N \quad (3.5.22)$$

并检验 $\{\hat{\alpha}_k\}$ 的独立性(办法见第四章),若不独立,则改变 p_N ,再重新进行i), ii)两步,否则进行下一步。

iii) 选定阶数 p 和 q , 根据样本 w_N 和 ii) 中所得的白噪声估值 $\hat{\alpha}_{p_N+1}, \hat{\alpha}_{p_N+2}, \dots, \hat{\alpha}_N$, 按最小平方和准则估计 ARMA(p ,

q)模型的诸参数值,即记 $\hat{s}(\beta) = \sum_{i=p_N+q}^N (w_i - \hat{\phi}_1 w_{i-1} - \dots - \hat{\phi}_p w_{i-p} +$

$w_{i-p} + \hat{\theta}_1 \hat{\alpha}_{i-1} + \hat{\theta}_2 \hat{\alpha}_{i-2} + \dots + \hat{\theta}_q \hat{\alpha}_{i-q})^2$ 由于这里 $\hat{\alpha}_k$ 作为已知量,

因此极小化 $S(\hat{\beta})$ 可得如下形式的线性方程组

$$\begin{cases} \frac{\partial \hat{s}(\beta)}{\partial \phi_j} = 2 \sum_{i=p_N+q}^N (w_i - \hat{\phi}_1 w_{i-1} - \dots - \hat{\phi}_p w_{i-p} + \\ \quad + \hat{\theta}_1 \hat{\alpha}_{i-1} + \dots + \hat{\theta}_q \hat{\alpha}_{i-q}) w_{i-j} = 0 \\ \quad j=1, 2, \dots, p \quad k=1, 2, \dots, q \\ \frac{\partial \hat{s}(\beta)}{\partial \theta_k} = 2 \sum_{i=p_N+q}^N (w_i - \hat{\phi}_1 w_{i-1} - \dots - \hat{\phi}_p w_{i-p} + \\ \quad + \hat{\theta}_1 \hat{\alpha}_{i-1} + \dots + \hat{\theta}_q \hat{\alpha}_{i-q}) \hat{\alpha}_{i-k} = 0 \end{cases}$$

当 N 很大时, 上面的方程组可被以下方程组近似

$$\hat{\beta} = \begin{pmatrix} \hat{\phi} \\ \hat{\theta} \end{pmatrix} = \begin{pmatrix} \hat{\Gamma}_{pp}^w & \hat{\Gamma}_{pq}^{wa} \\ \hat{\Gamma}_{qp}^{aw} & \hat{\Gamma}_{qq}^a \end{pmatrix}^{-1} \begin{pmatrix} \hat{\eta}_p^w \\ \hat{\eta}_q^{wa} \end{pmatrix} \quad (3.5.23)$$

$$\hat{\sigma}_{pq}^2 = \hat{\gamma}_0 = \begin{pmatrix} \hat{\phi} \\ \hat{\theta} \end{pmatrix}^T \begin{pmatrix} \hat{\eta}_p^w \\ \hat{\eta}_q^{wa} \end{pmatrix}$$

其中

$$\begin{aligned} \hat{\Gamma}_{jp}^w &= \hat{\Gamma}_p - (\hat{\gamma}_{j-k}) \quad 1 \leq j, k \leq p \\ \hat{\eta}_p^w &= (\hat{\gamma}_1, \hat{\gamma}_2, \dots, \hat{\gamma}_p)^T \end{aligned} \quad (3.5.24)$$

$$\hat{\Gamma}_{jq}^a = (\hat{\gamma}_{j-k}^a) \quad 1 \leq j, k \leq q$$

$$\hat{\gamma}_i^a = \frac{1}{N - p_N} \sum_{t=p_N+1}^{N-i} \hat{a}_{t+i} \hat{a}_t \approx \hat{\gamma}_{-i}^a$$

$$\hat{\Gamma}_{jq}^{wa} = (\hat{\gamma}_{j-k}^{wa}), \quad 1 \leq j \leq p \quad 1 \leq k \leq q$$

$$\hat{\gamma}_i^{wa} = \frac{1}{N - p_N} \sum_{t=p_N+1}^{N-i} w_{t+i} \hat{a}_t \approx \hat{\gamma}_{-i}^{wa}$$

$$\hat{\eta}_q^{wa} = (\hat{\gamma}_1^{wa}, \hat{\gamma}_2^{wa}, \dots, \hat{\gamma}_q^{wa})$$

$$\hat{\Gamma}_{qp}^{aw} = (\hat{\gamma}_{j-k}^{aw}) \quad 1 \leq j \leq q \quad 1 \leq k \leq p$$

$$\hat{\gamma}_i^{aw} = \frac{1}{N - p_N} \sum_{t=p_N+1}^{N-i} \hat{a}_{t+i} w_t \approx \hat{\gamma}_{-i}^{aw}$$

iv) 在适当阶数范围内(例如 $0 \leq p \leq p_N, 0 \leq q \leq \theta_N$), 依照某一定阶准则(见第四章)选定模型阶数。

由上可见, 因为 $\hat{a}_t$ 已在步骤 i) 中由长自回归估计得到, 因此在本算法中, 不涉及到非线性求极值问题, 和第四节中介绍的方法相比, 此方法有其突出的优点, 便于在计算机上实现。

第四章 模型的检验、改进和定阶

§ 1 时间序列的统计检验

由第二、三章的讨论可见,对于平稳、零均值序列,可以建立 $ARMA(p, q)$ 模型。因此,若有某一个长度为 N 的样本列(动态数据),欲建立 $ARMA$ 模型,应先判定其是否具备平稳性。有时,为能使用极大似然估计,还要检验序列的正态性。在通过了上述检验后,为判定对序列建立的模型是否合理,还应检验模型噪声(残量)序列的独立性。总之,在对样本序列的建模前后,为了判定模型的合理性,并为改进模型提供依据,都应该安排适当的检验。但是,由于通过统计检验合格的结论也可能非真,因此,时间序列的统计检验,只能作为建模的一个辅助手段,其所作出的判据,仅可作为参考。

§ 1.1 序列的正态性检验

通常情形,只有正态序列才能用时间序列的线性模型去拟合,而且,利用分布的正态性模型参数可实现极大似然估计,从而提高模型参数的估计精度。因此,序列是否符合正态性是首先值得关注的问题。下面介绍两种简单的检验方法。

1. 峰度偏度检验:检验序列正态性最简单的方法是检验序列三阶矩和四阶矩的性质。因为对于正态随机变量 $x \sim \mathcal{N}(\mu, \sigma^2)$, 有

均值	$E x = \mu$	
方差	$E (x - \mu)^2 = \sigma^2$	(4.1.1)
偏度	$E \left(\frac{x - \mu}{\sigma} \right)^3 = 0$	
峰度	$E \left(\frac{x - \mu}{\sigma} \right)^4 = 3$	

偏度反映了分布密度的对称性，峰度反映了分布密度函数曲线的状态。

自然地，对于一个长度为 N 的样本列 $\{x_i\}$ ，令

$$\begin{aligned}\bar{x} &= \frac{1}{N} \sum_{i=1}^N x_i \\ \hat{\sigma}^2 &= \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2 \\ g_3^* &= \frac{1}{N} \sum_{i=1}^N \left(\frac{x_i - \bar{x}}{\hat{\sigma}} \right)^3 \\ g_4^* &= \frac{1}{N} \sum_{i=1}^N \left(\frac{x_i - \bar{x}}{\hat{\sigma}} \right)^4 - 3\end{aligned}\quad (4.1.2)$$

当 N 充分大时，如果 g_3^* 和 g_4^* 近似于零，即可认为序列 $\{x_i\}$ 具有正态性。当然，这种检验法是比较粗糙的。

如果对序列 $\{x_i\}$ 作正态白噪声假设，还可进一步给出 g_3^* 和 g_4^* 的前二阶矩

$$\begin{aligned}E g_3^* &= 0, \quad \text{var } g_3^* = \frac{6(N-2)}{(N+1)(N+3)} \\ E g_4^* &= -\frac{6}{N+1}, \quad \text{var } g_4^* = \frac{24N(N-2)(N-3)}{(N+1)^2(N+3)(N+5)}\end{aligned}\quad (4.1.3)$$

当样本长度 N 充分大时，

$$\text{var } g_3^* \approx \frac{6}{N}, \quad \text{var } g_4^* \approx \frac{24}{N}$$

这时，应有

$$g_3 = \sqrt{\frac{N}{6}} g_3^*, \quad g_4 = \sqrt{\frac{N}{24}} \left(g_4^* + \frac{6}{N+1} \right)$$

渐近地服从正态 $\mathcal{N}(0, 1)$ 分布。由于服从 $\mathcal{N}(0, 1)$ 分布的 g_3 和 g_4 有性质

$$\begin{aligned}P(|g_3| > 2) &\cong 0.045 \\ P(|g_4| > 2) &\cong 0.045\end{aligned}\quad (4.1.4)$$

因此,由样本算出的 g_3 和 g_4 值若有一个超过 2,就应该否定序列 $\{x_i\}$ 的正态白噪声假设。

2. Колмогоров 检验法:对于通常的独立同分布序列,为判断其分布是否为某设想的类型,有一种 Колмогоров 检验法

设 $\{x_i\}$ 是独立同分布序列,则有经验分布函数

$$F_N(x) = \frac{1}{N} \sum_{k=1}^N I_{(-\infty, x)}(x_k) \quad (4.1.5)$$

其中 $I_{(-\infty, x)}(x_k)$ 为示性函数,即

$$I_{(-\infty, x)}(x_k) = \begin{cases} 1 & x_k < x \\ 0 & x_k \geq x \end{cases} \quad (4.1.6)$$

可见, $F_N(x)$ 表示 N 个样本中,小于 x 的 x_k 所占的比例。 $F_N(x)$ 是一个阶跃函数,它在 x_k 的取值点有 $\frac{1}{N}$ 的跳跃。如果 $\{x_i\}$ 的真正分布是 $F(x)$ (满足一些连续性条件),那么统计量

$$D_N = \sqrt{N} \sup_{-\infty < x < \infty} |F_N(x) - F(x)| \quad (4.1.7)$$

渐近地服从分布

$$Q(\alpha) = P(D_N < \alpha) = \sum_{k=-\infty}^{\infty} (-1)^k e^{-2k^2 \alpha^2} \quad (4.1.8)$$

下面,给出 $Q(\alpha)$ 的分布表:

表 4.1 Колмогоров 分布表

$1-Q(\alpha)$	0.01	0.05	0.10	0.20	0.25	0.30
α	1.63	1.36	1.22	1.07	1.02	0.97

当 D_N 大于表中的 α 值时,拒绝原假设,即 $\{x_i\}$ 不是原先设想的分布,此时,犯错误的概率是 $1-Q(\alpha)$ 。

由于函数 $F(x)$ 比较光滑,因此通常只需注意 $F_N(x)$ 的跳跃点上的值即可。也就是说,可以用下面的统计量 $\tilde{D}_N$ 来代替 D_N

$$\tilde{D}_N = \sqrt{N} \max_{x=x_k} |F_N(x) - F(x)| \quad (4.1.9)$$

在正态情形,若 $F(x)$ 是 $\mathcal{N}(\mu, \sigma^2)$ 的分布函数,即

$$F(x) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x e^{-\frac{(y-\mu)^2}{2\sigma^2}} dy$$

由 (4.1.9) 式计算出 $\tilde{D}_N$, 若在约定的犯错误概率 $1-Q(\alpha)$ 下, 算得 $\tilde{D}_N$ 值大于 α , 就拒绝正态假设。

§ 1.2 序列的平稳性检验

时间序列的平稳性是我们对之进行分析和建模的重要前提。由平稳序列的定义知, 欲检验时间序列的平稳性, 必须检验以下两个内容: 一是其均值和方差是否为常数, 二是其自协方差函数是否仅与时间间隔有关, 而与此间隔端点的位置无关。

一般来讲, 一个实际过程, 如果它的系统参数和实际条件基本保持不变, 即可视为平稳的。不过这只是一种定性判据, 单只从这样的物理背景来下结论, 有时是不太可靠的, 还需要依据一些统计方法进一步证实。更何况有时物理背景还不可能提供这种定性的假设。

平稳序列具有不随时间变化的均值、方差和相关函数。然而, 从数据本身直接判定是很困难的。下面简单介绍两类不同的平稳性检验方法。

1. 平稳性的参数检验: 当样本序列的长度 N 足够大时, 取 $N = kM$, M 为一个较大的正整数, 按长度 M 将样本列 $x_1, x_2, \dots, x_N$ 分为 k 个等长的子序列

$$\begin{aligned} & x_{11}, x_{12}, \dots, x_{1M}; \\ & x_{21}, x_{22}, \dots, x_{2M}; \\ & \dots\dots\dots \\ & x_{k1}, x_{k2}, \dots, x_{kM} \end{aligned} \tag{4.1.10}$$

这里

$$\begin{aligned} x_{ij} &= x_{(i-1)M+j} \\ i &= 1, 2, \dots, k; \quad j = 1, 2, \dots, M \end{aligned}$$

(在实际问题中, 也不一定要求子列长度都严格等于 M , 可略有出入, 上面写法是为方便)。

对 k 个子序列, 分别计算它们的样本参数

$$\text{均值} \quad \bar{x}_i = \frac{1}{M} \sum_{j=1}^M x_{ij}$$

$$\text{方差} \quad s_i^2 = \frac{1}{M} \sum_{j=1}^M (x_{ij} - \bar{x}_i)^2 \quad (4.1.11)$$

相关函数

$$\gamma_i(\tau) = \frac{1}{M} \sum_{j=1}^{M-\tau} (x_{ij} - \bar{x}_i)(x_{i,j+\tau} - \bar{x}_i) / s_i^2$$

$$i=1, 2, \dots, k; \quad \tau=1, 2, \dots, m; \quad m \ll M$$

根据平稳性假设, 当 M 足够大时, 由 (4.1.10) 和 (4.1.11) 计算得的统计量, 对于不同的 i 子列不应有显著的差异, 若此性质不成立, 应否定平稳性假设。下面介绍的检验手段就基于这个原理。

设 $\{x_i\}$ 具有已知的均值 μ , 方差 σ^2 和相关函数 ρ_τ , 则应有

$$\begin{aligned} E(\bar{x}_i) &= \frac{1}{M} \sum_{j=1}^M E(x_{ij}) = \mu \\ \sigma_1^2 = D(\bar{x}_i) &= \frac{1}{M^2} E\left(\sum_{j=1}^M \sum_{l=1}^M (x_{ij} - \mu)(x_{il} - \mu)\right) \\ &= \frac{\sigma^2}{M^2} \sum_{j=1}^M \sum_{l=1}^M \rho_{j-l} = \frac{\sigma^2}{M} \left[1 + 2 \sum_{j=1}^M \left(1 - \frac{j}{M}\right) \rho_j\right] \quad (4.1.12) \end{aligned}$$

利用正态分布随机变量四阶矩的计算公式, 可类似算出统计量 s_i^2 和 $\gamma_i(\tau)$ 的方差

$$\begin{aligned} \sigma_2^2 = D(s_i^2) &= \frac{2\sigma^2}{M} \left(1 + 2 \sum_{j=1}^M \left(1 - \frac{j}{M}\right) \rho_j^2\right) \quad (4.1.13) \\ \sigma_3^2(\tau) = D(\gamma_i(\tau)) &\approx \frac{1}{M-\tau} \left[1 + \rho_\tau^2 + \right. \\ &\quad \left. + 2 \sum_{j=1}^{M-\tau} \left(1 - \frac{j}{M-\tau}\right) (\rho_j^2 + \rho_{j+\tau} \rho_{j-\tau})\right] \end{aligned}$$

由上可见, 当 M 充分大时, 取显著水平 $\alpha = 0.05$, 当

$$\begin{aligned} |\bar{x}_i - \bar{x}_j| &> 1.96 \sqrt{2 \sigma_1^2} \\ |s_i^2 - s_j^2| &> 1.96 \sqrt{2 \sigma_2^2} \\ |\gamma_i(\tau) - \gamma_j(\tau)| &> 1.96 \sqrt{2 \sigma_3^2(\tau)} \end{aligned} \quad (4.1.14)$$

成立时,可拒绝平稳性假设。

在实际问题中,很难得知 $\{x_i\}$ 的真实方差与相关函数,因此无法直接得出 σ_1^2 , σ_2^2 和 $\sigma_3^2(\tau)$,仅能代之以它们的样本估计值。因此,这方法是很粗略的。

2. 平稳性的非参数检验:下面,给出一种检验时间序列是否含有趋势性的逆序检验法。

设由(4.1.10)和(4.1.11)得统计量

$$\bar{x}_1, \bar{x}_2, \dots, \bar{x}_k \quad (4.1.15)$$

定义随机变量

$$a_{ij} = \begin{cases} 1 & \text{当 } i < j \text{ 时 } \bar{x}_i > \bar{x}_j \\ 0 & \text{其它} \end{cases}$$

则统计量

$$A = \sum_{i=1}^{k-1} \sum_{j=i+1}^k a_{ij} \quad (4.1.16)$$

给出了(4.1.15)中按大小排列形成逆序的总次数。

如果总序列 $\{x_i\}$ 假设为平稳,则 $\bar{x}_k$ ($k=1, 2, \dots, K$) 应是独立同分布的,这时应有

$$\begin{aligned} E(A) &= \frac{1}{4} K(K-1) \\ D(A) &= \frac{1}{72} (2 K^3 + 3 K^2 - 5 K) \end{aligned} \quad (4.1.17)$$

以上结果可依下法求得

若随机变量 x_1, x_2 独立同分布,具有密度函数 $f(x)$ 和分布函数 $F(x)$,则有概率

$$\begin{aligned} P(x_1 < x_2) &= \int_{-\infty}^{\infty} \left[\int_{-\infty}^{x_2} f(x_1) dx_1 \right] f(x_2) dx_2 \\ &= \int_{-\infty}^{\infty} F(x_2) dF(x_2) = \int_0^1 t dt = \frac{1}{2} \end{aligned}$$

即随机变量 $a_{i,j}$ 以概率 0.5 取值 1 或 0, 故有

$$E(a_{i,j}) = \frac{1}{2}$$

$$\begin{aligned} E(A) &= \sum_{i=1}^{k-1} \sum_{j=i+1}^k E(a_{i,j}) = \frac{1}{2} \sum_{i=1}^{k-1} (K-i) \\ &= \frac{1}{2} \left(K(K-1) - \frac{1}{2} K(K-1) \right) = \frac{1}{4} K(K-1). \end{aligned}$$

类似地可算出 $D(A)$

当 K 充分大时 (例如 $K > 10$), 统计量

$$u = \frac{A + \frac{1}{2} - \frac{1}{4} K(K-1)}{\sqrt{(2K^3 + 3K^2 - 5K)/72}} \quad (4.1.18)$$

渐近服从 $\mathcal{N}(0, 1)$ 分布, 由此可对逆序数 A 进行统计检验, 从而达到检验 $\{x_t\}$ 是否平稳的目的。

由上两种方法可见, 平稳性检验要求一定的样本长度 N , 也就是说, 如果 N 不大, 就无法对于总体的平稳性作出判断。

§ 1.3 模型拟合残量的自相关检验

对序列通过了平稳性和正态性检验, 并建立了相应的 ARMA 模型之后, 为考核所建模型的优劣, 一般还需对模型残量 $a_1, a_2, \dots, a_N$ 检验是不是白噪声。也就是说, 如果经检验 $\{a_t\}$ 确是白噪声序列, 则可认为模型是合理的, 否则, 就应当进一步改进模型。

AR(p) 模型的残量容易计算

$$a_t = w_t - \varphi_1 w_{t-1} - \dots - \varphi_p w_{t-p}, \quad (4.1.19)$$

对于 $t = p+1, \dots, N$, a_t 均可由此式算出, 对于一般的 ARMA(p, q) 序列, a_t 可由下面的方法逆推得到

$$a_t = w_t - \varphi_1 w_{t-1} - \dots - \varphi_p w_{t-p} + \theta_1 a_{t-1} + \dots + \theta_q a_{t-q}, \quad t \geq 0 \quad (4.1.20)$$

当 $(\theta_1, \dots, \theta_q)$ 在可逆域内并远离可逆域边界时, (4.1.20) 式中的递推初值

$$a_0, a_{-1}, \dots, a_{1-q}$$

$$w_0, w_{-1}, \dots, w_{1-p}$$

均可取为零(它们的均值)。当然,若想提高估计精度,也可取他们的估计值,方法和第三章中条件平方和的计算类似。

下面介绍模型残量的自相关检验法。

设 $a_1, a_2, \dots, a_N$ 是白噪声序列,令

$$\hat{\rho}_k(N, a) = \frac{1}{N} \sum_{i=1}^{N-k} a_i a_{i+k}$$

$$\hat{\rho}_k(N, a) = \hat{\rho}_k(N, a) / \hat{\rho}_0(N, a) \quad (4.1.21)$$

$\hat{\rho}_0(N, a)$ 可作为 σ_a^2 的估计。

可以证明,当 N 趋于无穷时, $\sqrt{N} \hat{\rho}_k(N, a)$ 对于 $k=1, 2, \dots, K$, 依分布收敛于 K 个独立的正态 $\mathcal{N}(0, 1)$ 分布的随机变量。也就是说,当 $N \gg K$ 时, K 维随机向量

$$(\sqrt{N} \hat{\rho}_1(N, a), \sqrt{N} \hat{\rho}_2(N, a), \dots, \sqrt{N} \hat{\rho}_K(N, a))$$

可以近似地看成是 K 个独立的正态 $\mathcal{N}(0, 1)$ 分布所组成的随机向量。因此, $\{a_i\}$ 的独立性检验就转化为检验 $\sqrt{N} \hat{\rho}_k(N, a)$, $k=1, 2, \dots, K$ 是否为来自 $\mathcal{N}(0, 1)$ 总体的 K 个独立抽样。

一种比较简单粗略的方法是看这 K 个 $\sqrt{N} \hat{\rho}_k(N, a)$ 的绝对值是否有 68.3% 以上小于 1, 95.5% 以上小于 2。这是因为正态 $\mathcal{N}(0, 1)$ 分布的随机变量落在 $(-1, +1)$ 中的概率是 68.3%, 落在 $(-2, +2)$ 中的概率是 95.5%, 如果 $\sqrt{N} \hat{\rho}_k(N, a)$ ($k=1, 2, \dots, K$) 落在上述两个区间中的比例数明显地少于上述百分比, 那么就不能认为 $a_1, a_2, \dots, a_N$ 是白噪声序列了。

另一种简单办法是统计中常用的 χ^2 检验法。我们知道, K 个独立 $\mathcal{N}(0, 1)$ 随机变量的平方和服从自由度为 K 的 χ^2 -分布, 对于预先给定的信度 α , 由 χ^2 分布表可查出 $\chi_{K\alpha}^2$, 其中

$$P(\chi_K^2 \geq \chi_{K\alpha}^2) = \alpha$$

现假设 $\sqrt{N} \hat{\rho}_k(N, a)$, $k=1, 2, \dots, K$ 是 K 个独立的 $\mathcal{N}(0, 1)$ 分布随机变量, 则

$$Q_K = N \sum_{k=1}^K \hat{\rho}_k^2(N, a) \quad (4.1.22)$$

为自由度等于 K 的中心 χ^2 分布, 那么假设成立时, 应当以概率 $1-\alpha$ (α 很小) 有 $Q_K \leq \chi_{K\alpha}^2$, 因此, 若 $Q_K > \chi_{K\alpha}^2$, 就否定“ $\sqrt{N}\hat{\rho}_k(N, \alpha), k=1, 2, \dots, K$ 是独立 $\mathcal{N}(0, 1)$ 分布随机变量”的假设, 从而也就否定了“ $a_1, a_2, \dots, a_N$ 是白噪声序列”的原假设。下表给出常用的几个 $\chi_{K\alpha}^2$ (若不够用, 可查统计表)。

表 4.2 χ^2 分布的置信限

$\chi_{K\alpha}^2$ α	K	20	21	22	23	24	25	26	27	28	29	30
0.05		31.4	32.7	33.9	35.2	36.4	37.7	38.9	40.1	41.3	42.6	43.8
0.01		37.6	38.9	40.3	41.6	43.0	44.3	45.6	47.0	48.3	49.6	50.9

由于 φ, θ 一般未知, 在 (4.1.21) 和 (4.1.22) 式中, 它们由估计值 $\hat{\varphi}, \hat{\theta}$ 来代替。若 $\hat{\varphi}$ 和 $\hat{\theta}$ 是极大似然估计, Q_K 的自由度是 $K-p-q$ 。

§ 2 ARMA 模型的改进

前面几章中, 主要讨论了平稳时间序列的性质及 ARMA (p, q) 模型的参数估计。在实际问题中, 动态数据序列大多并不平稳, 而是呈现出各种趋势性和周期性。例如太阳黑子数据, 航运客票数目、电力负荷量等。本节着重讨论如何分析数据中隐含的趋势性和季节性 (周期性), 并研究如何建立表征这些特性的最合适而又最简练的模型。对一些较复杂的序列, 还将讨论序列的合成和分解, 以及确定性趋势的分离等问题。

§ 2.1 ARIMA 模型

在许多实际问题中, 被考虑的随机序列 $\{z_t\}$ 有时并不近似为平稳序列, 因此不能直接用 ARMA 模型去描述。然而, 有些序列经过某种预处理后, 可以产生一个平稳的新序列, 从而可用 ARMA (p, q) 模型去描述。例如, 下图给出两串随机序列, 图 4.1 (a)

所表示的随机序列 $\{z_t\}$ 显然是不平稳的, 但将 $\{z_t\}$ 进行一次差分运算

$$\nabla z_t = (1-B)z_t = z_t - z_{t-1}, \quad t \geq 1$$

由图 4.1(b)所表示的新序列 $\{\nabla z_t\}$ 几乎稳定在零附近, 可以看成(近似地)平稳序列了。由此可见, 一阶差分处理, 可以使某些非平稳序列平稳化。当然, 有些序列的平稳化, 需要经过多次差分处理。对于这类序列, 我们引进一种所谓自回归-求和-滑动平均模型。




图 4.1 (a) z_t
(b) ∇z_t

设 $\{z_t\}$ 为非平稳序列, 存在正整数 d , 使得

$$\nabla^d z_t \equiv W_t, \quad t \geq d \quad (4.2.1)$$

其中 ∇^d 是 d 阶差分算子

$$\begin{aligned} \nabla^d &= (1-B)^d = 1 - c_d^1 B + c_d^2 B^2 + \cdots + (-1)^{d-1} c_d^{d-1} B^{d-1} + \\ &\quad + (-1)^d B^d \\ c_d^r &= \frac{d!}{r!(d-r)!} \end{aligned} \quad (4.2.2)$$

$\{w_t\}$ 是 $\text{ARMA}(p, q)$ 序列, 这样的 $\{z_t\}$ 称作 ARMA 的 d 阶求和

序列,并用记号 $\text{ARIMA}(p, d, q)$ 表示,其中 d 为求和阶数, p 和 q 分别是 $w_t = \nabla^d z_t$ 的自回归和滑动平均阶数。 $\{z_t\}$ 可形式地写成

$$\varphi(B)\nabla^d z_t = \theta(B)a_t \quad t > d \quad (4.2.3)$$

设 $z_1, \dots, z_d$ 为初值,并设它和 $\{w_t\}$ 、 $\{a_t\}$ 都独立,则 $\{z_t\}$ 可表示成

$$\begin{aligned} Z_t &= \sum_{i=0}^{d-1} c_{t-d+i-1}^i \nabla^i z_d + \sum_{j=1}^{t-d} c_{t-j-1}^{d-1} w_{d+j} \\ &= \sum_{i=0}^{d-1} c_{t-k+i-1}^i \nabla^i z_k + \sum_{j=1}^{t-k} c_{t-k-j+d-1}^{d-1} w_{k+j}, \quad t \geq k \geq d \end{aligned} \quad (4.2.4)$$

这里,我们不去一般性地仔细推导公式(4.2.4),仅以两种简单常用的特殊情况为例。

$d=1$ 可表

$$\begin{aligned} z_t &= z_t - z_{t-1} + z_{t-1} - z_{t-2} + \dots + z_2 - z_1 + z_1 \\ &= z_1 + \sum_{j=1}^{t-1} (z_{j+1} - z_j) = z_1 + \sum_{j=1}^{t-1} w_{1+j} \\ &= z_k + \sum_{j=1}^{t-k} w_{k+j} \quad t > k \geq 1 \end{aligned} \quad (4.2.5)$$

$d=2$ 同上有

$$z_t = z_1 + \sum_{j=1}^{t-1} \nabla z_{j+1}$$

因而同理可得

$$\nabla z_{j+1} = \nabla z_2 + \sum_{i=1}^{j-1} \nabla^2 z_{i+2}$$

以此代入前式,得

$$\begin{aligned} z_t &= z_2 + (t-2)(z_2 - z_1) + \sum_{j=1}^{t-2} (t-j-1)w_{2+j} \\ &= z_k + (t-k)(z_k - z_{k-1}) + \sum_{j=1}^{t-k} (t-k-j+1)w_{k+j} \end{aligned}$$

$$l > k \geq 2 \quad (4.2.6)$$

对于 ARIMA 这一类非平稳序列的建模、预报、控制等问题,均可通过 d 阶差分为对与其相应的 ARMA(p, q) 序列来处理。因此,求和模型 ARIMA 虽然将平稳时序分析向非平稳序列推进了一步,但理论和方法上都不是本质的。有些更复杂的非平稳序列,还要用更复杂的线性模型以至于非线性模型才能描述。

§ 2.2 季节性乘积模型

在不少实际问题中,随机序列的变化包含很明显的周期性规律,例如气温、雨量、用电量、用水量等。这种规律是由于季节变化或其它周期因素的物理原因所引起的,我们称这类序列为季节性序列。当然,许多序列的周期并不是一目了然的,要在识别模型过程中来估计。

以电力负荷为例,如果以 z_t 表示 t 时刻的用电负荷量,以一小时为采样间隔,则序列 $\{z_t\}$ 将包含 24 小时的周期性变化,一般上午、晚上各有一个用电高峰,中午出现低谷,深夜则出现一天用电最少的低谷。如果纵观各年用电量序列,又可发现与四季相应的变化,而且各星期的电波起伏也有某种相似之处。可见电力负荷序列中包含了多种周期性变化的趋势。对于这类复杂随机序列,有很多描述方法,一种办法是,将原序列分成 s 个子序列 (s 为周期长度)每个子序列的采样间隔 s 倍于原序列,原序列 $\{z_t\}$ 被看成是这 s 个相互独立的,ARIMA 序列 $\{z_{st}\}, \{z_{st+1}\}, \dots, \{z_{st+s-1}\}$, $t=0, 1, 2, \dots$ 依次交替出现的结果。例如每天第 i 小时电力负荷 $\{z_{24t+i}\}$ (t 表示第 t 天) 看为总负荷量序列的第 i 个子序列,并用通常的 ARIMA 模型描述它,就可用 24 个这样的序列交替描述总负荷序列了。然而,由于 $\{z_{st}\}, \{z_{st+1}\}, \dots, \{z_{st+s-1}\}$ 之间往往并不相互独立,因此,上述方法并不能完整地反映序列 $\{z_t\}$ 的全部联系。为了全面研究序列的统计特性,还有一个方法是将 $(z_{st}, z_{st+1}, \dots, z_{st+s-1})$ 当作一个 s 维随机矢量进行分析,但这样做又会在计算上带来很大麻烦。本小节里,我们将介绍用一种疏系数 ARIMA 模型——季节性乘积模型来描述周期序列。下节还将介绍其它描

述季节性趋势的方法。

设 s 为一正整数, 如果一个随机序列 $\{z_t\}$ 符合如下模型

$$\Phi(B^s)\nabla_s^D z_t = \Theta(B^s)A_t \quad (4.2.7)$$

则称 $\{z_t\}$ 是周期为 s 的季节性序列。(4.2.7)式称为季节性模型。其中

$$\begin{aligned} \nabla_s &= 1 - B^s & \nabla_s^D &= (1 - B^s)^D \\ \Phi(B^s) &= 1 - \Phi_1 B^s - \Phi_2 B^{2s} - \dots - \Phi_p B^{ps} \\ \Theta(B^s) &= 1 - \Theta_1 B^s - \Theta_2 B^{2s} - \dots - \Theta_q B^{qs} \end{aligned} \quad (4.2.8)$$

对于 $D=0$ 的情形, 还应考虑稍广一点的模型

$$\Phi(B^s)z_t = c + \Theta(B^s)A_t \quad (4.2.9)$$

(4.2.7)和(4.2.9)式中的 $\{A_t\}$ 一般不必是白噪声, 而可以设它为另一 ARIMA(p, d, q)序列

$$\varphi(B)\nabla^d A_t = \theta(B)a_t \quad (4.2.10)$$

联合(4.2.7)和(4.2.10)式, 便得到

$$\varphi(B)\Phi(B^s)w_t = \theta(B)\Theta(B^s)a_t \quad (4.2.11)$$

其中

$$w_t = \nabla^d \nabla_s^D z_t \quad (4.2.12)$$

我们称(4.2.11)式为乘积型季节模型的一般形式, 阶数常用 $(p, d, q) \times (P, D, Q)$ 表示。显然, $\Phi(B^s)$ 和 $\Theta(B^s)$ 体现了序列中周期与周期之间的关系, $\varphi(B)$ 和 $\theta(B)$ 反映了序列相邻时刻之间的关系。(4.2.11)式可展开成通常的 ARIMA 形式, 例如将

$$w_t = (1 - \theta_1 B)(1 - \Theta_1 B^s)a_t$$

展开成

$$w_t = (1 - \theta_1 B - \Theta_1 B^s + \theta_1 \Theta_1 B^{s+1})a_t$$

就是 MA($s+1$)模型。用 $\theta_i^*, i=1, 2, \dots, s+1$ 表示它的滑动平均参数, 那么有

$$\begin{aligned} \theta_1^* &= \theta_1, \theta_s^* = \Theta_1, \theta_{s+1}^* = -\theta_1 \Theta_1, \\ \theta_2^* &= \dots = \theta_{s-1}^* = 0 \end{aligned}$$

可见, 尽管 $\{w_t\}$ 的模型阶数可以很高, 真正独立的参数并不多, 而且有许多参数取零值。这类模型我们称之为疏系数 ARIMA 模型。一般地, 可将(4.2.11)式化为疏系数 ARMA($p+Ps, q+Qs$)

模型

$$\varphi^*(B)w_t = \theta^*(B)a_t$$

其中

$$\begin{aligned}\varphi^*(B) &= \varphi(B)\Phi(B^s) \\ \theta^*(B) &= \theta(B)\Theta(B^s)\end{aligned}\quad (4.2.13)$$

对于季节性模型的识别、预报和控制问题,常可借用对一般ARMA模型讨论的方法,或干脆化为高阶疏系数模型(4.2.13)去讨论。此外,有些周期序列,可通过对其自协方差函数特性的研究直接识别模型的形状,这对简化建模程序,减少识别参数带来很大方便。表4.3列出了若干季节模型自协方差函数与模型参数之间的对应关系,对周期序列建模时,可以用来对照。

在§2.1中,我们引进了差分算子

$$\nabla = 1 - B$$

本章又给出了季节差分算子

$$\nabla_s = 1 - B^s$$

作为 B 算子多项式,它们都含有模为1的根。只是算子 ∇ 中根为实数1, ∇_s 中 s 个根在单位圆周上等幅角分布,因此是两种特殊情形。通常情形下,如果模型的 B 算子多项式具有一对共轭复根,就反映了数据序列隐含有 $\frac{2\pi}{\omega}$ 的季节(周期)特性,其中 ω 是共轭复根的正幅角。设

$$1 - \varphi_1 B - \varphi_2 B^2 = (1 - \lambda_1 B)(1 - \lambda_2 B), \lambda_1 = \bar{\lambda}_2 = \rho e^{\pm i\omega}$$

利用多项式根与系数之间的关系,不难算出 λ_1, λ_2 和算子 $1 - \varphi_1 B - \varphi_2 B^2$ 之间的对应

$$\begin{aligned}\lambda_1, \lambda_2 &= \frac{1}{2}(\varphi_1 \pm \sqrt{\varphi_1^2 + 4\varphi_2}) \\ \varphi_1 &= \lambda_1 + \lambda_2 = 2\rho \cos \omega \\ \varphi_2 &= -\lambda_1 \lambda_2 = -\rho^2\end{aligned}\quad (4.2.14)$$

表4.4列出了一些典型的周期性与算子二项式(共轭根在单位圆上)之间的对应关系。对有些准平稳序列,如果在建立模型后发现

表 4.3 季节性模型和自协方差函数

模 型	w_t 的自协方差/ σ_a^2	特 殊 性 质
(1) $w_t = (1 - \theta B)(1 - \Theta B^s)a_t$ $w_t = a_t - \theta a_{t-1} - \Theta a_{t-s} + \theta\Theta a_{t-s-1}$ $s \geq 3$	$\gamma_0 = (1 + \theta^2)(1 + \Theta^2)$ $\gamma_1 = -\theta(1 + \Theta^2)$ $\gamma_{s-1} = \theta\Theta$ $\gamma_s = -\Theta(1 + \theta^2)$ $\gamma_{s+1} = \gamma_{s-1}$ 其余全部自协方差全为零	(a) $\gamma_{s-1} = \gamma_{s+1}$ (b) $\rho_{s-1} = \rho_{s+1} = \rho_1 \rho_s$
(2) $(1 - \Phi B^j)w_t = (1 - \theta B)(1 - \Theta B^s)a_t$ $w_t - \Phi w_{t-j} = a_t - \theta a_{t-1} - \Theta a_{t-s} + \theta\Theta a_{t-s-1}$ $s \geq 3$	$\gamma_0 = (1 + \theta^2) \left[1 + \frac{(\Theta - \Phi)^2}{1 - \Phi^2} \right]$ $\gamma_1 = -\theta \left[1 + \frac{(\Theta - \Phi)^2}{1 - \Phi^2} \right]$ $\gamma_{s-1} = \theta \left[\Theta - \Phi - \frac{\Phi(\Theta - \Phi)^2}{1 - \Phi^2} \right]$ $\gamma_s = -(1 + \theta^2) \left[\Theta - \Phi - \frac{\Phi(\Theta - \Phi)^2}{1 - \Phi^2} \right]$ $\gamma_{s+1} = \gamma_{s-1}$ $\gamma_j = \Phi \gamma_{j-s} \quad j \geq s+2$ 对于 $s \geq 4, \gamma_2, \gamma_3, \dots, \gamma_{s-2}$ 全为零	(a) $\gamma_{s-1} = \gamma_{s+1}$ (b) $\gamma_j = \Phi \gamma_{j-s} \quad j \geq s+2$

模 型	w_i 的自协方差/ σ_a^2	特 殊 性 质
(3) $w_i = (1 - \theta_1 B - \theta_2 B^2) \times (1 - \Theta_1 B^s - \Theta_2 B^{2s}) a_i$ $w_i = a_i - \theta_1 a_{i-1} - \theta_2 a_{i-2} - \Theta_1 a_{i-s} + \theta_1 \Theta_1 a_{i-s-1} + \theta_2 \Theta_1 a_{i-s-2} - \Theta_2 a_{i-2s} + \theta_1 \Theta_2 a_{i-2s-1} + \theta_2 \Theta_2 a_{i-2s-2}$ $s \geq 5$	$\begin{aligned} \gamma_0 &= (1 + \theta_1^2 + \theta_2^2)(1 + \Theta_1^2 + \Theta_2^2) \\ \gamma_1 &= -\theta_1(1 - \theta_2)(1 + \Theta_1^2 + \Theta_2^2) \\ \gamma_2 &= -\theta_2(1 + \Theta_1^2 + \Theta_2^2) \\ \gamma_{s-2} &= \theta_2 \Theta_1(1 - \Theta_2) \\ \gamma_{s-1} &= \theta_1 \Theta_1(1 - \theta_2)(1 - \Theta_2) \\ \gamma_s &= -\Theta_1(1 + \theta_1^2 + \theta_2^2)(1 - \Theta_2) \\ \gamma_{s+1} &= \gamma_{s-1} \\ \gamma_{s+2} &= \gamma_{s-2} \\ \gamma_{2s-3} &= \theta_2 \Theta_2 \\ \gamma_{2s-1} &= \theta_1 \Theta_2(1 - \theta_2) \\ \gamma_{2s} &= -\Theta_2(1 + \theta_1^2 + \theta_2^2) \\ \gamma_{2s+1} &= \gamma_{2s-1} \\ \gamma_{2s+2} &= \gamma_{2s-2} \end{aligned}$ 其余全部自协方差全为零	(a) $\gamma_{s-2} = \gamma_{s+2}$ (b) $\gamma_{s-1} = \gamma_{s+1}$ (c) $\gamma_{2s-2} = \gamma_{2s+2}$ (d) $\gamma_{2s-1} = \gamma_{2s+1}$
(3a) 模型 3 的特殊情形 $w_i = (1 - \theta_1 B - \theta_2 B^2)(1 - \Theta B^s) a_i$ $w_i = a_i - \theta_1 a_{i-1} - \theta_2 a_{i-2} - \Theta a_{i-s} + \theta_1 \Theta a_{i-s-1} + \theta_2 \Theta a_{i-s-2}$ $s \geq 5$	$\begin{aligned} \gamma_0 &= (1 + \theta_1^2 + \theta_2^2)(1 + \Theta^2) \\ \gamma_1 &= -\theta_1(1 - \theta_2)(1 + \Theta^2) \\ \gamma_2 &= -\theta_2(1 + \Theta^2) \\ \gamma_{s-2} &= \theta_2 \Theta \\ \gamma_{s-1} &= \theta_1 \Theta(1 - \theta_2) \\ \gamma_s &= -\Theta(1 + \theta_1^2 + \theta_2^2) \\ \gamma_{s+1} &= \gamma_{s-1} \\ \gamma_{s+2} &= \gamma_{s-2} \end{aligned}$ 其余全部自协方差全为零	(a) $\gamma_{s-2} = \gamma_{s+2}$ (b) $\gamma_{s-1} = \gamma_{s+1}$

续表

模 型	w_t 的自协方差/ σ_a^2	特 殊 性 质
(3 b) 模型 3 的特殊情形 $w_t = (1 - \theta B)(1 - \Theta_1 B^s + \Theta_2 B^{2s})a_t$ $w_t = a_t - \theta a_{t-1} - \Theta_1 a_{t-s} + \theta \Theta_1 a_{t-s-1}$ $- \Theta_2 a_{t-2s} + \theta \Theta_2 a_{t-2s-1}$ $s \geq 3$	$\gamma_0 = (1 + \theta^2)(1 + \Theta_1^2 + \Theta_2^2)$ $\gamma_1 = -\theta(1 + \Theta_1^2 + \Theta_2^2)$ $\gamma_{s-1} = \theta \Theta_1(1 - \Theta_1)$ $\gamma_s = -\Theta_1(1 + \theta^2)(1 - \Theta_2)$ $\gamma_{s+1} = \gamma_{s-1}$ $\gamma_{2s-1} = \theta \Theta_2$ $\gamma_{2s} = -\Theta_2(1 + \theta^2)$ $\gamma_{2s+1} = \gamma_{2s-1}$ 其余全部自协方差全为零	(a) $\gamma_{s-1} = \gamma_{s+1}$ (b) $\gamma_{2s-1} = \gamma_{2s+1}$
(4) $w_t = (1 - \theta_1 B - \theta_2 B^s - \theta_{s+1} B^{s+1})a_t$ $w_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-s} - \theta_{s+1} a_{t-s-1}$ $s \geq 3$	$\gamma_0 = 1 + \theta_1^2 + \theta_2^2 + \theta_{s+1}^2$ $\gamma_1 = -\theta_1 + \theta_2 \theta_{s+1}$ $\gamma_{s-1} = \theta_1 \theta_s$ $\gamma_s = \theta_1 \theta_{s+1} - \theta_s$ $\gamma_{s+1} = -\theta_{s+1}$ 其余全部自协方差全为零	(a) 一般情形 $\gamma_{s-1} \neq \gamma_{s+1}$ $\gamma_1 \gamma_s \neq \gamma_{s+1}$
(4 a) 模型 4 的特殊情形 $w_t = (1 - \theta_1 B - \theta_2 B^s)a_t$ $w_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-s}$ $s \geq 3$	$\gamma_0 = 1 + \theta_1^2 + \theta_2^2$ $\gamma_1 = -\theta_1$ $\gamma_{s-1} = \theta_1 \theta_s$ $\gamma_s = -\theta_s$ 其余全部自协方差全为零	(a) 不同于模型 4 $\gamma_{s+1} = 0$


模 型	w_i 的自协方差/ σ_a^2	特 殊 性 质
(5) $(1-\Phi B^s)w_i = (1-\theta_1 B - \theta_2 B^2 - \theta_{s+1} B^{s+1})a_i$ $w_i - \Phi w_{i-1} = a_i - \theta_1 a_{i-1} - \theta_2 a_{i-2} - \dots - \theta_{s+1} a_{i-s-1}$ $s \geq 3$	$\gamma_0 = 1 + \theta_1^2 + \frac{(\theta_2 - \Phi)^2}{1 - \Phi^2} + \frac{(\theta_{s+1} + \theta_1 \Phi)^2}{1 - \Phi^2}$ $\gamma_1 = -\theta_1 + \frac{(\theta_2 - \Phi)(\theta_{s+1} + \theta_1 \Phi)}{1 - \Phi^2}$ $\gamma_{s-1} = (\theta_2 - \Phi) \left[\theta_1 + \Phi \frac{(\theta_{s+1} + \theta_1 \Phi)}{1 - \Phi^2} \right]$ $\gamma_s = -(\theta_2 - \Phi) \left[1 - \Phi \frac{(\theta_2 - \Phi)}{1 - \Phi^2} \right]$ $+ (\theta_{s+1} + \theta_1 \Phi) \left[\theta_1 + \Phi \frac{(\theta_{s+1} + \theta_1 \Phi)}{1 - \Phi^2} \right]$ $\gamma_{s+1} = -(\theta_{s+1} + \theta_1 \Phi) \left[1 - \Phi \frac{(\theta_2 - \Phi)}{1 - \Phi^2} \right]$ $\gamma_j = \Phi \gamma_{j-s}, \quad j \geq s+2$ 对于 $s \geq 4, \gamma_2, \dots, \gamma_{s-2}$ 全为零	(a) $\gamma_{s-1} \neq \gamma_{s+1}$ (b) $\gamma_j = \Phi \gamma_{j-s}, \quad j \geq s+2$
(5a) 模型 5 的特殊情形 $(1-\Phi B^s)w_i = (1-\theta_1 B - \theta_2 B^2)a_i$ $w_i - \Phi w_{i-1} = a_i - \theta_1 a_{i-1} - \theta_2 a_{i-2}$ $s \geq 3$	$\gamma_0 = 1 + \frac{\theta_1^2 + (\theta_2 - \Phi)^2}{1 - \Phi^2}$ $\gamma_1 = -\theta_1 \left[1 - \Phi \frac{(\theta_2 - \Phi)}{1 - \Phi^2} \right]$ $\gamma_{s-1} = \frac{\theta_1(\theta_2 - \Phi)}{1 - \Phi^2}$ $\gamma_s = \frac{\Phi \theta_1^2 - (\theta_2 - \Phi)(1 - \Phi \theta_2)}{1 - \Phi^2}$ $\gamma_j = \Phi \gamma_{j-s}, \quad j \geq s+1$ 对于 $s \geq 4, \gamma_2, \dots, \gamma_{s-2}$ 全为零	(a) 不同于模型 5 $\gamma_{s+1} = \Phi \gamma_1$

表 4.4 几种典型周期性和算子、特征根


周 期 P	算子 $1 - \varphi_1 B - \varphi_2 B^2$ ($\varphi_2 = -1$)	根 λ_1, λ_2
2	$1 + 2B + B^2$	$-1, -1$
3	$1 + B + B^2$	$-0.5 \pm i 0.866$
4	$1 + B^2$	$\pm i$
5	$1 - 0.618B + B^2$	$0.309 \pm i 0.951$
6	$1 - B + B^2$	$0.5 \pm i 0.866$
7	$1 - 1.247B + B^2$	$0.624 \pm i 0.782$
8	$1 - 1.414B + B^2$	$0.707 \pm i 0.707$
9	$1 - 1.532B + B^2$	$0.766 \pm i 0.643$
10	$1 - 1.618B + B^2$	$0.809 \pm i 0.588$
12	$1 - 1.732B + B^2$	$0.866 \pm i 0.500$
14	$1 - 1.802B + B^2$	$0.901 \pm i 0.434$
15	$1 - 1.827B + B^2$	$0.914 \pm i 0.407$
20	$1 - 1.902B + B^2$	$0.951 \pm i 0.309$
21	$1 - 1.911B + B^2$	$0.956 \pm i 0.295$
24	$1 - 1.932B + B^2$	$0.966 \pm i 0.259$
25	$1 - 1.937B + B^2$	$0.969 \pm i 0.249$
28	$1 - 1.950B + B^2$	$0.975 \pm i 0.222$
30	$1 - 1.956B + B^2$	$0.978 \pm i 0.209$
38	$1 - 1.968B + B^2$	$0.984 \pm i 0.178$
50	$1 - 1.984B + B^2$	$0.992 \pm i 0.126$
60	$1 - 1.989B + B^2$	$0.995 \pm i 0.105$
∞	$1 - 2.000B + B^2$	$1.00 \quad 1.00$

有单位圆周上的特征根,便可通过查表或计算分析出序列的周期。同样,如果事先知道序列的周期,也可先对数据进行二阶算子作用,再建立平稳 ARMA 模型。对模型算子多项式在单位圆内的


1-4



2



3



4




图 4.2 Wolf 的太阳黑子数

复根,可用类似方法分析,找出数据所隐含的周期。

例 太阳黑子活动周期

太阳黑子数据曲线如图 4.2 所示。图中共 176 年的数据中大约有 $15\frac{1}{2}$ 个尖峰。对此数据拟合的 AR(2) 模型(详见第五章 § 2.4 例 1) 参数为

$$\varphi_1 = 1.33 \quad \varphi_2 = -0.65$$

由参数可得

$$\cos \omega = \frac{\varphi_1}{2\sqrt{-\varphi_2}} = \frac{1.33}{2\sqrt{0.65}}$$

由此得出周期为

$$P = \frac{2\pi}{\omega} \cong 11(\text{年})$$

且 $\lambda_1, \lambda_2 \cong 0.665 \pm i 0.456$

由于 $|\varphi_2| < 1$, $|\lambda_1| = |\lambda_2| < 1$, 因此, 这种周期趋势带有相当大的阻尼, 周期趋势不很标准。

§ 2.3 序列的合成和分解

在实际问题中, 常常遇到两个以上相互独立的随机序列相迭加的问题, 例如信号接收机的输出量, 就是由有用信号与干扰噪声迭加而成的。一般干扰噪声又是几个噪声源所产生的噪声迭加而成。现在我们讨论两个相互独立的 ARIMA 序列的迭加问题, 多个情形是它的简单推广。

假定

$$z_t = z_t^{(1)} + z_t^{(2)} \quad (4.2.15)$$

其中 $\{z_t^{(1)}\}$ 和 $\{z_t^{(2)}\}$ 是两个相互独立的 ARIMA 序列。先考虑 $\{z_t^{(i)}\}$ 是滑动平均序列的情况, 即

$$z_t^{(i)} = \theta^{(i)}(B) \alpha_t^{(i)} \quad i=1, 2$$

其中

$$\theta^{(i)}(B) = 1 - \theta_1^{(i)} B - \theta_2^{(i)} B^2 - \dots - \theta_{q_i}^{(i)} B^{q_i} \quad i=1, 2$$

令

$$q = \max(q_1, q_2)$$

以及

$$\gamma_k^{(i)} \triangleq E(z_i^{(i)} z_{i+k}^{(i)}) \quad i=1, 2$$

由于 $\{z_i^{(1)}\}$ 和 $\{z_i^{(2)}\}$ 相互独立, 所以

$$\begin{aligned} \gamma_k &= E(z_i z_{i+k}) = E(z_i^{(1)} z_{i+k}^{(1)}) + E(z_i^{(2)} z_{i+k}^{(2)}) \\ &= \gamma_k^{(1)} + \gamma_k^{(2)} \end{aligned} \quad (4.2.16)$$

由于 $\gamma_k^{(1)}$ 和 $\gamma_k^{(2)}$ 都截尾, 所以 γ_k 也截尾, 且显然当 $k > q$ 时, $\gamma_k \equiv 0$, 因此 $\{z_i\}$ 是 $MA(q)$ 序列, 不妨记做

$$z_i = \theta(B) a_i$$

$\theta(B)$ 的系数可以由 $\theta^{(i)}(B) \quad i=1, 2$ 的系数求得。将关系式 (2.4.3) 代入 (4.2.16) 的等式两边, 得

$$\begin{aligned} &\sigma_a^2(1 + \theta_1^2 + \cdots + \theta_q^2) \\ &= \sigma_1^2(1 + (\theta_1^{(1)})^2 + \cdots + (\theta_{q_1}^{(1)})^2) + \sigma_2^2(1 + (\theta_1^{(2)})^2 + \cdots \\ &\quad + (\theta_{q_2}^{(2)})^2) \\ &\sigma_a^2(-\theta_k + \theta_1 \theta_{k+1} + \cdots + \theta_{q-k} \theta_q) \\ &= \sigma_1^2(-\theta_k^{(1)} + \theta_1^{(1)} \theta_{k+1}^{(1)} + \cdots + \theta_{q_1-k}^{(1)} \theta_{q_1}^{(1)}) + \\ &\quad + \sigma_2^2(-\theta_k^{(2)} + \theta_1^{(2)} \theta_{k+1}^{(2)} + \cdots + \theta_{q_2-k}^{(2)} \theta_{q_2}^{(2)}) \\ &\quad k=1, 2, \cdots, q \end{aligned} \quad (4.2.17)$$

式中 $\sigma_i^2 = E(a_i^{(i)})^2$, $\sigma_a^2 = E a_i^2$; (4.2.17) 式是 $q+1$ 个非线性联立方程式, 等式右边都是已知数, 左边有 $q+1$ 个未知数, 可按第三章 § 2.2 中介绍的方法求解。由 (4.2.16) 式知, $\{z_i\}$ 的谱密度应为

$$\begin{aligned} f(\lambda) &= |\theta(e^{-i2\pi\lambda})| \sigma^2 \\ &= |\theta^{(1)}(e^{-i2\pi\lambda})|^2 \sigma_1^2 + |\theta^{(2)}(e^{-i2\pi\lambda})|^2 \sigma_2^2 \end{aligned}$$

因此, 只要 $\theta^{(i)}(B), i=1, 2$ 中有一个可逆, $\theta(B)$ 在单位圆内就不会有零点, 所以, $\theta(B)$ 一定可逆。据此, 可由方程组 (4.2.17) 的多组解中挑出满足可逆性条件的一组来。对于 $q=1, 2$ 的低阶情形, 可以给出解的解析表达式, 对于高阶情形, 通常只能用数值法求解。一般情形下, $\theta_q \neq 0$, 即模型不退化, 但若 $q_1 = q_2 = q$, 且 $\theta_q^{(1)} \sigma_1^2 = -\theta_q^{(2)} \sigma_2^2$ 时, 由 (4.2.17) 可得 $\theta_q = 0$, 即在此特殊情形, 合成退化的

q 阶滑动平均模型。

现在, 考虑分序列为一般的 ARIMA 序列的情形, 即设 $\{z_i^{(i)}\}$ 为 $\text{ARIMA}(p_i, d_i, q_i)$ 序列

$$\varphi^{(i)}(B)\nabla^{d_i}z_i^{(i)} = \theta^{(i)}(B)\alpha_i^{(i)} \quad (4.2.18)$$

记参数为

$$\beta^{(i)} = (\varphi_1^{(i)}, \dots, \varphi_{p_i}^{(i)}, \theta_1^{(i)}, \dots, \theta_{q_i}^{(i)})^T \quad i=1, 2$$

令

$$d = \max(d_1, d_2) \quad (4.2.19)$$

则

$$\begin{aligned} & \varphi^{(1)}(B)\varphi^{(2)}(B)\nabla^d z_i \\ &= \varphi^{(1)}(B)\varphi^{(2)}(B)\nabla^d z_i^{(1)} + \varphi^{(1)}(B)\varphi^{(2)}(B)\nabla^d z_i^{(2)} \\ &= \varphi^{(2)}(B)\theta^{(1)}(B)\nabla^{d-d_1}\alpha_i^{(1)} + \varphi^{(1)}(B)\theta^{(2)}(B)\nabla^{d-d_2}\alpha_i^{(2)} \end{aligned}$$

记

$$\Theta^{(1)}(B) = \varphi^{(2)}(B)\theta^{(1)}(B)\nabla^{d-d_1} \quad (4.2.20)$$

$$\Theta^{(2)}(B) = \varphi^{(1)}(B)\theta^{(2)}(B)\nabla^{d-d_2}$$

注意到 $d-d_1$ 和 $d-d_2$ 至少有一为零, 若令

$$y_i^{(1)} = \theta^{(1)}(B)\alpha_i^{(1)}$$

$$y_i^{(2)} = \theta^{(2)}(B)\alpha_i^{(2)}$$

则其中至少有一个是可逆的, 因此, 合成序列 $y_i = y_i^{(1)} + y_i^{(2)}$ 是可逆的 $\text{MA}(q)$ 序列。其中

$$q = \max\{p_2 + d - d_1 + q_1, p_1 + d - d_2 + q_2\} \quad (4.2.21)$$

再令

$$\varphi^{(1)}(B)\varphi^{(2)}(B) \triangleq \varphi(B) \quad p = p_1 + p_2 \quad (4.2.22)$$

于是, $\{z_i\}$ 适合如下模型

$$\varphi(B)\nabla^d z_i = \theta(B)\alpha_i \quad (4.2.23)$$

这就表明, 两个独立的 ARIMA 序列之和仍是 ARIMA 序列, 其参数和阶数由以上诸式求得。

实际问题中最常见的合成是 $\text{ARIMA}(p_1, d_1, q_1)$ 和白噪声 $\{\alpha_i\}$ 的合成

$$z_t = z_t^{(1)} + a_t^{(2)}$$

由前面的分析知, z_t 为 $\text{ARIMA}(p_1, d_1, q)$ 序列, 其中 $q = \max\{q_1, p_1 + d_1\}$

$$\text{例如, } \nabla z_t^{(1)} = (1 - \theta^{(1)}(B)) a_t^{(1)} \quad z_t^{(2)} = a_t^{(2)}$$

则 $z_t = z_t^{(1)} + z_t^{(2)}$ 便是 $\text{ARIMA}(0, 1, 1)$ 序列

$$\nabla z_t = (1 - \theta B) a_t$$

$$\begin{aligned} \text{令} \quad w_t &= \nabla z_t = \nabla z_t^{(1)} + \nabla a_t^{(2)} \\ &= a_t^{(1)} - \theta^{(1)} a_{t-1}^{(1)} + a_t^{(2)} - a_{t-1}^{(2)} \end{aligned}$$

于是由(4.2.17)得

$$\begin{cases} (1 + \theta^2) \sigma_a^2 = [1 + (\theta^{(1)})^2] \sigma_1^2 + 2 \sigma_2^2 \\ -\theta \sigma_a^2 = -\theta^{(1)} \sigma_1^2 - \sigma_2^2 \end{cases}$$

分别以 A 和 B 代表等式右端的已知部分, 将上方程组改写成

$$\begin{cases} (1 + \theta^2) \sigma_a^2 = A \\ -\theta \sigma_a^2 = B \end{cases}$$

消去变元 σ_a^2 可得

$$\theta^2 + \frac{A}{B} \theta + 1 = 0$$

这是关于 θ 的一元二次方程组, 设共有解 x_1, x_2 , 并注意 $x_1 \cdot x_2 = 1$, 不妨设 $|x_1| < 1$, 则应取 $\theta = x_1$, 于是有 $\sigma_a^2 = -\frac{B}{x_1}$, 这就得到本例合成序列的模型参数值。

和序列的合成相反的问题, 是序列的分解问题, 亦即从已知的总模型如何求出分序列的模型和参数值来。这类问题较比分解问题更为常见, 例如, 在水泥生产的自动控制中, 要求知道窑内某处物料的温度, 但测量时常有随机误差, 这就要求从温度的量测值中分解出窑内的实在温度来。又如测量陀螺漂移率时, 测量系统也带有噪声, 也需要从测试记录中分解出陀螺漂移模型。一般来说, 如果不加约束条件, 序列的分解是不可能得到唯一解的。例如, $\text{ARMA}(1, 1)$ 序列既可由一个 $\text{ARMA}(1, 1)$ 序列和一个白噪声合成, 又可由一个 $\text{AR}(1)$ 序列和一个白噪声序列合成。可见为使分

解问题有意义,至少要假定每个分序列的模型阶数是预先知道的。即使如此,仍不一定得出唯一分解。比如要将一个白噪声序列 $\{a_i\}$ 分解成两个独立的白噪声之和,虽然它们都是 ARMA(0, 0) 模型

$$z_i^{(i)} = a_i^{(i)}, i=1, 2$$

但从关系式 $\sigma_a^2 = \sigma_1^2 + \sigma_2^2$ 中仍得不出 σ_1^2 和 σ_2^2 的唯一解来。事实上,序列的分解一般是难于解决的。实际中遇到较多的是将 ARMA(p, q) 序列分解成为一个 ARMA(p_1, q_1) 序列和一个白噪声序列的独立和。即

$$z_i = z_i^{(1)} + N_i \quad (4.2.24)$$

前面所举的水泥窑炉温和陀螺仪真实漂移都是属于此类。由 (4.2.21) 和 (4.2.22) 式可见,这类分解只有当 $p = p_1, q \geq p$ 时才是合理的。具体可分为: 1) 当 $q > p$ 时, $z_i^{(1)}$ 应为 ARMA(p, q) 模型; 2) 当 $q = p$ 时, $z_i^{(1)}$ 应从 ARMA($p, 0$), ARMA($p, 1$), $\dots$, ARMA(p, q) 选出合理的模型; 3) 当 $q < p$ 时, z_i 不能分解为 $z_i^{(1)} + n_i$ 。

如果对某一具体序列找不到一组合理的分解,则应拒绝“ $\{N_i\}$ 与 $\{z_i\}$ 独立”或“ $\{N_i\}$ 为白噪声”的假设,再考虑 $\{N_i\}$ 是 ARMA 序列的情形,当然这时的问题就更杂了。

§ 3 确定性趋势的分离·叠合模型

许多工程问题或科学实验中产生的时间序列常常呈现出明显的确定性趋势。分析它们的特性,常常发现这类数据包含两大成分:第一个成分实际上是序列随时间变化的均值,体现了序列的变化趋向,往往可由多项式、指数函数、正弦函数等描述,因此称为是序列的确定性部分;第二个成分是均值为零的平稳随机部分,可用 ARMA 模型拟合。用这样两个部分叠合起来共同描述具有上述特点的时间序列,常常得到令人满意的效果。本节将介绍各种叠合模型的建模方法和简单的实例,第五章还将作进一步的讨论。

§ 3.1 线性趋势

首先研究数据序列含有线性趋势的情形。这种情形最为简单。由于数据在某一直线周围散布,可以先用统计方法拟合回归直线,再对残量建立 $ARMA(p,q)$ 模型,最后,将分头估计得到的这两部分参数作为初值,用非线性最小二乘方法估计出叠合模型的最终参数来。

我们利用“断裂传播”数据实例来阐明对于线性趋向序列的建模方法。

例 断裂传播数据的建模

对于某金属材料的试样施加周期应力进行断裂测试,测得90个试样的断裂长度数据。由图 4.3 可见,这些数据和应力周期之间存在着很明显的线性趋势。




图 4.3 测量断裂长度的观测值(示意图)

对此序列建立以下形式的叠合模型

$$y_t = \beta_0 + \beta_1 t + x_t \quad (4.3.1)$$

其中 y_t 是观测得的断裂长度, t 表示应力周期数(不是时间),由线性回归公式得参数 β_0, β_1 的估计值为

$$\hat{\beta}_0 = 11.02703 \quad \hat{\beta}_1 = 0.10658$$

残差平方和

$$R_{ss} = \sum_{i=1}^{90} x_i^2 = \sum_{i=1}^{90} (y_i - \hat{\beta}_0 - \hat{\beta}_1 t)^2 = 1.3411$$

检验证明, 残量 $\{x_i\}$ 不是白噪声, 而是零均值的平稳随机序列, 因此可用 ARMA 模型拟合。经建模得 $\{x_i\}$ 服从 AR(1) 模型

$$x_i = \varphi_1 x_{i-1} + a_i$$

$$\hat{\varphi}_1 = 0.973$$

$$R_{ss} = \sum_{i=2}^{90} \hat{a}_i^2 = 0.1703$$

将模型随机部分与确定性部分合并, 得以下形式的叠合模型

$$y_i = \beta_0 + \beta_1 t + \varphi_1 x_{i-1} + a_i$$

$$x_i = y_i - \beta_0 - \beta_1 t$$

或表成

$$\begin{aligned} y_i &= \beta_0 + \beta_1 t + \varphi_1 (y_{i-1} - \beta_0 - \beta_1 (t-1)) + a_i \\ &= \varphi_1 y_{i-1} + \beta_0 (1 - \varphi_1) + \beta_1 \varphi_1 + \beta_1 (1 - \varphi_1) t + a_i \end{aligned} \quad (4.3.2)$$

这是关于参数 $\varphi_1, \beta_0, \beta_1$ 的非线性函数, 以分模型所得的 $\hat{\varphi}_1, \hat{\beta}_0, \hat{\beta}_1$ 为初值, 对这三个参数作非线性最小二乘估计 (估计方法在第六章介绍), 得到最终估计值为

$$\hat{\beta}_0 = 10.88075$$

$$\hat{\beta}_1 = 0.10800$$

$$\hat{\varphi}_1 = 0.95990$$

$$R_{ss} = \sum_{i=1}^{90} \hat{a}_i^2 = 0.1693$$

这时 R_{ss} 进一步下降, 模型得到了改进。

含有二次、三次或一般的 d 次多项式趋势的序列, 也可用类似的方法来建模。

§ 3.2 指数趋势

动态数据中常常含有一个或多个指数项混合而得的趋向。对

这类数据建立叠合模型当然要比线性趋向或多项式趋向的建模要复杂得多。本节仅限于讨论实指数趋向的情形，复指数情形留作下节讨论。

含有实指数趋向的序列可用以下的叠合模型来拟合

$$y_i = \sum_{j=1}^s A_j e^{k_j i} + x_i \quad (4.3.3)$$

式中 k_j, A_j 为实数, $\{x_i\}$ 为 ARMA(p, q) 序列。

建模的步骤和 § 3.1 基本上是一致的，只是对于多个指数趋向混合的情形，个数 s 的判断要烦琐一些。有的问题可由物理背景决定有 s 个加项，通常情形，采用使 $s=1, 2, \dots$ 等由低至高拟合的办法，直到叠合模型的残差平方和不再显著下降为止。本节我们仅举一简单实例，说明指数趋势叠合模型的建模步骤。多个指数趋向混合情形的实例，将在第五章 § 3 中介绍。

例 化学衰减数据的建模

利用一个温度跃变系统来研究快速化学反映中浓度变化的衰减过程。具体办法是产生电火花使溶液温度突然升高，破坏溶液平衡状态而激发起衰减过程，然后用一个吸收光谱的测量系统直接测量反应溶液的浓度变化。采样间隔为 0.02 秒的 100 个记录数据如图 4.4 所示。

由图可见，数据存在很强的指数衰减趋势，给出如下的组合模型形式

$$y_i = A_0 + A_1 e^{-\frac{i}{\tau}} + x_i$$

其中 $A_0 + A_1$ 是初始浓度， A_0 是最后平衡浓度， τ 是衰减时间常数。 A_0, A_1, τ 的初值可由图 4.4 来确定

$$\begin{aligned} t=0 \quad \text{时} \quad y_0 &\cong A_0 + A_1 = 55 \\ t \rightarrow \infty \quad y_i &\rightarrow A_0 \quad \text{从而} \quad A_0 \approx 33 \\ t=\tau \quad y_\tau &\cong A_0 + A_1 e^{-1} = 41.1 \end{aligned}$$

从而得到

$$\tau = 0.33 \quad A_0 = 33 \quad A_1 = 22$$




图 4.4 化学衰减数据(示意图)

以此为初值, 将 x_i 视作残量(粗略地当作独立残量), 用非线性最小二乘法得到指数趋向部分的参数估计

$$\hat{A}_0 = 31.343 \quad \hat{A}_1 = 22.575 \quad \hat{\tau} = 0.326$$

$$Rss = \sum_{i=1}^{100} x_i^2 = 58.05$$

残量 $x_i = y_i - \hat{A}_0 - \hat{A}_1 e^{-\frac{i}{\hat{\tau}}}$, 经检验 $\{x_i\}$ 是相关平稳列, 对它建立了 AR(1)模型, 从而得 $\{y_i\}$ 的叠合模型为

$$\begin{aligned} y_i &= A_0 + A_1 e^{-\frac{i}{\tau}} + x_i \\ &= A_0 + A_1 e^{-\frac{i}{\tau}} + \varphi_1 (y_{i-1} - A_0 - A_1 e^{-\frac{i-1}{\tau}}) + a_i \\ &= A_0(1 - \varphi_1) + A_1(e^{-\frac{1}{\tau}} - \varphi_1)e^{-\frac{i-1}{\tau}} + \varphi_1 y_{i-1} + a_i \end{aligned} \quad (4.3.4)$$

以与模型所得的估计为初值, 对叠合模型的参数统一进行非线性最小二乘估计, 得

$$\begin{aligned}\hat{A}_0 &= 30.545 \\ \hat{A}_1 &= 21.686 \\ \hat{\tau} &= 0.3789 \\ \hat{\phi}_1 &= 0.6172 \\ R_{ss} = \sum \hat{a}_i^2 &= 32.49.\end{aligned}$$

§ 3.3 周期趋势

如果序列本身不仅含有指数增长或衰减趋势,而且还显示出一定规律的周期性起伏,则可用如下形式的叠合模型去拟合

$$y_t = \sum_{j=1}^L R_j e^{\tau_j t} + \sum_{j=1}^K B_j e^{b_j t} \sin(j\omega t + \psi_j) + x_t \quad (4.3.5)$$

其中 $\{x_t\}$ 为ARMA(p, q)序列、 L 为序列中含有的指数趋势项数, K 相应于周期趋势项数, $R_j, \tau_j (j=1, 2, \dots, L)$ 与 $B_j, b_j, \psi_j (j=1, 2, \dots, K)$ 都是需要估计的未知参数。 ω 为基频,常由数据的物理性质决定,单位为弧度/秒, B_j 和 ψ_j 分别表示周期性趋向的振幅和相位, $e^{b_j t}$ 控制周期项的增长或衰减。由于 ψ_j 很难用非线性最小二乘法估计,因此将模型改成如下形式

$$y_t = \sum_{j=1}^L R_j e^{\tau_j t} + \sum_{j=1}^K B_j e^{b_j t} [c_j \sin(j\omega t) + \sqrt{1-c_j^2} \cos(j\omega t)] + x_t, \quad c_j = \cos \varphi_j \quad (4.3.6)$$

建模大致步骤为:首先拟合指数增长趋势,再逐个地增添周期趋势项,最后对残差 x_t 建立ARMA模型。当各个分模型的参数都估计出来后,再以它们作为初值对叠合模型(4.3.6)统一进行参数估计。整个过程中,主要以非线性最小二乘为工具。当然,由于模型结构比较复杂,待估参数个数较多,建模过程自然比较烦琐。但实例表明,对于规律复杂的数据,这种建模手段还是步骤明确、可以实现的。第五章 § 3 中将对航空客票和批发、另售价格的数据建立(4.3.6)形式的模型,逐步地进行细致分析,并和其它形式的模型进行比较。

本章 § 2.2 中, 我们曾介绍了季节性乘积模型(4.2.11), 模型(4.2.11)和(4.3.6)都可描述周期性序列, 从统计观点来看, 二者都是适用的。但它们的结构和意义却有根本的不同。模型(4.2.11)是一种非平稳的随机模型; 而模型(4.3.6)的前半是用确定性分量描述了数据的周期性趋势, 后半用平稳的随机模型描述了数据的剩余部分, 这种模型适于描述具有确定性物理规律而又受到随机干扰的数据序列。究竟选择何种模型, 需要具体判断和比较, 下章 § 3 的实例中对此将进行讨论。

§ 3.4 叠合模型的一般形式

总结前面三小节的内容, 可以看出, 叠合模型可用如下形式来统一描述

$$y_t = \sum_{i=0}^s A_i e^{k_i t} + x_t \quad (4.3.7)$$

式中 $\{x_t\}$ 是 $\text{ARMA}(p, q)$ 序列。

如果 A_i 全都为零, 那么

$$y_t \equiv x_t$$

就是普通的 $\text{ARMA}(p, q)$ 平稳序列。

如果仅有一个 A_i 非零, 但是与其相应的 k_i 等于零, 则模型就表示一个均值为常数 A_i 的平稳序列。

如果 s 个 k_i 中存在值很小而非零的实数时, 模型显示出多项式趋向(指数函数的泰勒展开仅有前几项较大)。

当 k_i 为较大的正负实数时, 模型显示出增长或衰减的指数趋向。

当复指数 k_i 具有负实部时, 模型显示出阻尼正、余弦趋向; 实部为零时, 就是带随机干扰的正、余弦趋向; 实部为正时, 则是振幅不断增大的正、余弦趋向。当然, 如果发现了数据的周期性, 线性或多项式趋向, 仍可直接用 § 3.1—§ 3.3 中各种具体的叠合模型形式去描述它们。

还要强调的一点是, 对于同一组动态数据, 有时可用不同形式的模型去描述。例如, 具有 d 阶多项式趋势的序列, 可用叠合模型

去模拟,也可用 $ARIMA(p, d, q)$ 模型去描述;具有周期趋势的序列,也有(4.2.11)和(4.3.6)两种形式可选择。这些不同类型的模型,都有各自的特点。§ 3.3 末尾对于两种周期模型的讨论,也同样适用于多项式趋势。究竟具体动态数据选用哪种模型描述适宜,要根据数据的具体物理性质及模型的模拟、预报效果来判定,也可以多建几个模型从中选择一个较理想的。

§ 4 模型阶的判别

至此为止,我们介绍了 $ARMA$ 、 $ARIMA$ 季节性乘积模型、叠合模型的参数估计和建模方法。本节将讨论如何判定模型阶数的问题。只有当模型的阶数和参数全都估计出来,模型识别才算完成。

§ 4.1 模型定阶的 F -检验准则

F -检验是数理统计学常用的统计检验方法。例如,我们已经由 N 个独立随机观测值

$$y_1, y_2, \dots, y_N$$

建立了随机变量 y 关于 r 个因素

$$x_1, x_2, \dots, x_r$$

的线性回归模型

$$y = \alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_r x_r + \varepsilon \quad (4.4.1)$$

为了判定其中 $s (s < r)$ 个因素对于 y 的影响是否显著,可以借助于 F -检验准则。

不妨假设要检验的回归因子就是

$$x_{r-s+1}, x_{r-s+2}, \dots, x_r$$

那么,此问题即等价于原假设

$$H_0: \alpha_{r-s+1} = \alpha_{r-s+2} = \dots = \alpha_r = 0 \quad (4.4.2)$$

是否成立。

$$\text{令 } A_0 = \sum_{i=1}^N (y_i - \hat{\alpha}_1^0 x_{i1} - \dots - \hat{\alpha}_r^0 x_{ir})^2 \quad (4.4.3)$$

$$A_1 = \sum_{t=1}^N (y_t - \hat{a}_1 x_{t,1} - \cdots - \hat{a}_{r-s} x_{t(r-s)})^2$$

显然,

$$F = \frac{A_1 - A_0}{s} \bigg/ \frac{A_0}{N-r} \sim F(s, N-r) \quad (4.4.4)$$

即此统计量服从自由度为 s 和 $N-r$ 的 F -分布。对于预先给定的置信度 α , 由 F -分布表查出满足

$$P(F \geq F_\alpha) = \alpha \quad (4.4.5)$$

的 F_α 值, 若算得 F 值大于 F_α , 就拒绝原假设 H_0 , 即后 s 个回归因子 $x_{r-s+1}, x_{r-s+2}, \cdots, x_r$ 对于随机变量 y 的影响是显著的; 反之, 则认为影响不显著, 这几个因素可以忽略。 α 通常取为 0.05 或 0.01。

这一检验准则平行地移用来对 ARMA 模型或组合模型定阶, 我们以 ARMA(p, q) 模型为例, 说明 F 检验的定阶方法。

第三章中曾经述及, 对动态数据序列建立 ARMA 模型的大致步骤是: 在框定的阶数范围内, 先对某些阶数组合, 估计相应的模型参数, 再对阶数进行选择。如果应用 F -检验方法来定价, 则可采用一种“过拟合”的手法, 即在建立了 ARMA(p, q) 模型后, 再假定 φ_s, θ_q 等高阶系数中某些值取零, 用 F -检验准则来判定阶数降低之后的模型与原 ARMA(p, q) 模型之间是否存在显著性差异。如果差异显著, 则阶数可能还要上升; 若低阶模型与之差异不显著, 则可认为 (p, q) 即为理想的阶数。根据以上原理, 我们得出了 ARMA(p, q) 模型定阶的 F -检验准则。

设 $H_0: \varphi_p = 0, \theta_q = 0$

记 A_0 为模型 ARMA(p, q) 的残差平方和

A_1 为模型 ARMA($p-1, q-1$) 的残差平方和

则当 N 充分大时, 近似地有

$$F = \frac{A_1 - A_0}{2} \bigg/ \frac{A_0}{N - (p+q)} \sim F(2, N - (p+q)) \quad (4.4.6)$$

其中 N 为样本长度, $r = p + q$ 是参数总个数, $s = 2$ 为被检验的参数

个数。如果 $F > F_\alpha$, 则 H_0 不成立, 模型阶数仍有上升的可能, 否则, 取 $\text{ARMA}(p-1, q-1)$ 为合适的模型。

其它类型的过拟合 F -检验方法与上面完全一致, 只是要相应改变 s 和 r 即可。

叠合模型中指数趋势项或周期趋势项的个数, 也可用 F -检验准则划定, 原则上也是从残差平方和变化的显著与否来判定各类趋势项的增减。第五章将通过实例讨论 F -检验准则的应用。

§ 4.2 模型定阶的 AIC 准则

从 § 4.1 的讨论不难想见, 时间序列的建模采用统计方法来确定阶数无疑是非常烦琐的, 而且作 F -检验时, 还要预先选择置信度 α , 这就不可避免地给定阶带来很大程度的人为性。为了克服上述缺点, 简化定阶程序, Akaike^[16] 给出了一个新的估计准则——最小信息准则(AIC)。运用这一准则, 能在模型参数极大似然估计的基础上, 对于 $\text{ARMA}(p, q)$ 模型的阶数和相应的参数, 同时给出一种最佳估计。准则对于 ARIMA 模型和季节性乘积模型都有相应的形式, 而且在多维自回归情形, 还等价于 Akaike 早些时候提出的另一个估计准则——FPE 准则(将在第八章讨论)。

下面, 我们来讨论 AIC 准则的原理, 并给出准则的一般形式。

AIC 准则起源于以下形式的 Kullback-Lelibler 信息量。设 $\mathbf{x}$ 为随机向量, 它的真正分布密度为 $f(\mathbf{x})$, $f(\mathbf{x})$ 属于分布函数族 $g(\mathbf{x}|\beta)$, 其中

$\beta = (\beta_1, \beta_2, \dots, \beta_k)^T$ 是参数向量

且 $f(\mathbf{x}) = g(\mathbf{x}|\beta^0)$

$K-L$ 信息量可用来刻划 $g(\mathbf{x}|\beta)$ 和 $f(\mathbf{x})$ 的接近程度, 其表达式为

$$\begin{aligned} I(f(\cdot); g(\cdot|\beta)) &= E \log f(\mathbf{x}) - E \log g(\mathbf{x}|\beta) \\ &= \int f(\mathbf{x}) \log f(\mathbf{x}) d\mathbf{x} - \int f(\mathbf{x}) \log g(\mathbf{x}|\beta) d\mathbf{x} \\ &= \int f(\mathbf{x}) \log \frac{f(\mathbf{x})}{g(\mathbf{x}|\beta)} d\mathbf{x} \end{aligned} \quad (4.4.7)$$

利用对数函数的凸性, 可得

$$I(f(\cdot); g(\cdot|\beta)) \geq 0$$

这是因为

$$\begin{aligned} I(f(\cdot); g(\cdot|\beta)) &= -E \log \frac{g(x|\beta)}{f(x)} \\ &\geq -\log E \frac{g(x|\beta)}{f(x)} = -\log \int \frac{g(x|\beta)}{f(x)} f(x) dx \\ &= -\log 1 = 0 \end{aligned}$$

由 $f(x) = g(x|\beta^\circ)$ 可见, 当 $\beta = \beta^\circ$ 时, K-L 信息量达到最小值, 即

$$I(f(\cdot); g(\cdot|\beta))|_{\beta=\beta^\circ} = 0$$

由以上的分析可以看出, K-L 信息量要求寻找最接近于 $f(x)$ 的参数密度函数 $g(x|\beta)$, 使得 $I(f; g(\cdot|\beta))$ 达到最小。AIC 准则就是由此原则而得出的。

今设 $\{x_t\}$ 为平稳时间序列, 记

$$x_N = (x_1, \dots, x_N)^T$$

有联合概率密度

$$f(x_N) = g(x_N|\beta^\circ)$$

其中 β 为参数向量

$$\beta \triangleq (\beta_1, \beta_2, \dots, \beta_K)^T$$

如果 β 的极大似然估计 $\hat{\beta} = \hat{\beta}(x_N)$ 是相容、渐近正态和优效的, 密度函数族 $g(\cdot|\beta)$ 在 β° 的邻域内存在一致可积的一阶、二阶偏导数, 且能保证以下关系式成立

$$\begin{aligned} E_\beta \left(\frac{\partial \log g(x_N|\beta)}{\partial \beta} \frac{\partial \log g(x_N|\beta)}{\partial \beta^T} \right) \\ = -E_\beta \left(\frac{\partial^2}{\partial \beta \partial \beta^T} \log g(x_N|\beta) \right) \end{aligned} \quad (4.4.8)$$

(此等式左端是信息阵 $J_N(\beta)$ 的定义)

则有

$$\begin{aligned} \text{AIC} &= -2 \log (\text{模型的最大似然度}) \\ &\quad + 2 (\text{模型的独立参数个数}) \\ &= -2 l(\hat{\beta}(x_N)) + 2K \end{aligned} \quad (4.4.9)$$

这就是最小信息准则 AIC 的一般形式。下面，我们给出它的证明。

$$\text{记 } l_N(\beta) = \log g(x_N | \beta)$$

则

$$\begin{aligned} l_N(\beta^\circ) &\cong l_N(\hat{\beta}) + \left. \frac{\partial l_N}{\partial \beta} \right|_{\tilde{\beta}} (\beta^\circ - \hat{\beta}) \\ &+ \frac{1}{2} (\hat{\beta} - \beta^\circ)^T \left. \frac{\partial^2 l_N(\beta)}{\partial \beta \partial \beta^T} \right|_{\tilde{\beta}} (\hat{\beta} - \beta^\circ) \end{aligned}$$

这里 $\tilde{\beta}$ 是介于 $\hat{\beta}$ 和 β° 之间的参数向量。

$$\text{由极大似然估计原理得 } \left. \frac{\partial l_N}{\partial \beta} \right|_{\hat{\beta}} = 0$$

将此式和(4.4.8)式代入上式，得

$$l_N(\beta^\circ) \cong l_N(\hat{\beta}) - \frac{1}{2} (\hat{\beta} - \beta^\circ)^T J_N(\tilde{\beta}) (\hat{\beta} - \beta^\circ)$$

从而有

$$2(l_N(\hat{\beta}) - l_N(\beta^\circ)) \cong (\hat{\beta} - \beta^\circ)^T J_N(\tilde{\beta}) (\hat{\beta} - \beta^\circ) \sim \chi^2_k \quad (4.4.10)$$

这就是说，当样本充分大时，统计量 $2(l_N(\hat{\beta}) - l_N(\beta^\circ))$ 渐近地服从 χ^2_k -分布，其中 k 为独立参数个数。

另一方面，对于 K-L 信息量

$$\begin{aligned} I_N(\beta) &= I(f(\cdot); g(\cdot | \beta)) \\ &= \int f(x_N) \log f(x_N) dx_N - \int f(x_N) \log g(x_N | \beta) dx_N \end{aligned}$$

类似地有展开式

$$\begin{aligned} I_N(\hat{\beta}) &= I_N(\beta^\circ) + \left. \frac{\partial I_N(\beta)}{\partial \beta} \right|_{\beta^\circ} (\hat{\beta} - \beta^\circ) \\ &+ \frac{1}{2} (\hat{\beta} - \beta^\circ)^T \left. \frac{\partial^2 I_N(\beta)}{\partial \beta \partial \beta^T} \right|_{\beta^\circ} (\hat{\beta} - \beta^\circ) + \gamma_N \end{aligned}$$

由于 $g(\cdot | \beta)$ 关于参数 β 的偏导数一致可积，可以算得

$$\left. \frac{\partial I_N(\beta)}{\partial \beta} \right|_{\beta^\circ} = - \left. \frac{\partial}{\partial \beta} \int f(x_N) \log g(x_N | \beta) dx_N \right|_{\beta^\circ}$$

$$\begin{aligned}
&= - \int f(\mathbf{x}_N) \frac{\partial}{\partial \beta} \log g(\mathbf{x}_N | \beta) d\mathbf{x}_N \Big|_{\beta^0} \\
&= - \frac{\partial}{\partial \beta} \int g(\mathbf{x}_N | \beta) d\mathbf{x}_N \Big|_{\beta^0} = 0 \\
\frac{\partial^2 I_N(\beta)}{\partial \beta_i \partial \beta_j} \Big|_{\beta^0} &= - \frac{\partial^2}{\partial \beta_i \partial \beta_j} \int f(\mathbf{x}_N) \log g(\mathbf{x}_N | \beta) d\mathbf{x}_N \Big|_{\beta^0} \\
&= \int \frac{f(\mathbf{x}_N)}{g^2(\mathbf{x}_N | \beta)} \frac{\partial g(\mathbf{x}_N | \beta)}{\partial \beta_i} \frac{\partial g(\mathbf{x}_N | \beta)}{\partial \beta_j} d\mathbf{x}_N \Big|_{\beta^0} \\
&\quad - \int \frac{\partial^2 g(\mathbf{x}_N | \beta)}{\partial \beta_i \partial \beta_j} d\mathbf{x}_N \Big|_{\beta^0} \\
&= E_{\beta^0} \left(\frac{\partial \log g(\mathbf{x}_N | \beta)}{\partial \beta_i} \frac{\partial \log g(\mathbf{x}_N | \beta)}{\partial \beta_j} \right) \Big|_{\beta^0} \\
&\quad - \frac{\partial^2}{\partial \beta_i \partial \beta_j} \int g(\mathbf{x}_N | \beta) d\mathbf{x}_N \Big|_{\beta^0} \\
&= J_{ij}(\beta^0) \quad (\text{即信息阵的第 } i \text{ 行 } j \text{ 列元}) \text{ 此外, 由于}
\end{aligned}$$

$$I_N(\beta^0) = 0$$

$$N \rightarrow \infty \quad a.e. \quad (\text{几乎处处收敛})$$

因此渐近地有

$$2 I_N(\hat{\beta}) \approx (\hat{\beta} - \beta^0)^T J_N(\beta^0) (\hat{\beta} - \beta^0) \rightsquigarrow \chi^2_k \quad (4.4.11)$$

利用(4.4.10)式和(4.4.11)式这两个极限分布, 将能导出 AIC 公式的一般形式。

为了明确标出所考虑的未知参数向量 β 的维数 k , 对于 $1 \leq k \leq L$ (L 为预先给定的某个整数), 我们记

$${}_k\beta = (\beta_1, \beta_2, \dots, \beta_k, 0_{k+1}, \dots, 0_L)^T$$

这里 0_j 表示第 j 个位置上的分量为零。设

$$\beta^0 = {}_l\beta^0 \quad (l \leq L)$$

是所取样本 $\mathbf{x}_N$ 概率密度的真正参数向量

$${}_k\hat{\beta} = {}_k\hat{\beta}(\mathbf{x}_N) \text{ 为 } {}_k\beta \text{ 的极大似然估计, 且设 } k \geq l.$$

由(4.4.11)式知, 当 $N \rightarrow \infty$ 时, 有

$$2 I_N({}_k\hat{\beta}) \rightsquigarrow \chi^2_k$$

因此,利用 χ^2 分布性质,可以近似地认为

$$2 E_{\infty} I_N({}_k \hat{\beta}) = K \quad (4.4.12)$$

其中 E_{∞} 表示对样本极限分布求期望。

由 K-L 信息量的性质知, (4.4.12) 式的值应当越小越好, 自然, l 应是理想的最小值。然而, l 是我们需要识别的未知量(通常表现为模型阶数), 所以(4.4.12)式在这里无法直接应用。

由 $I_N(\beta)$ 的定义, 可将(4.4.12)改写为

$$\begin{aligned} & -2 E_{\infty} \int f(x_N) \log g(x_N | {}_k \hat{\beta}(x_N)) dx_N \\ & = 2 E_{\infty} I_N({}_k \hat{\beta}) - 2 \int f(x_N) \log g(x_N | \beta^{\circ}) dx_N \\ & = K - 2 E_{\beta^{\circ}} l_N(\beta^{\circ}) \end{aligned} \quad (4.4.13)$$

(4.4.13)式右边第二项为(未知的)常量, 因此极小化(4.4.12)式和极小化(4.4.13)式是等价的。

由(4.4.10)式知, $2 l_N({}_k \hat{\beta}) - K$ 是 $2 E_{\beta^{\circ}} l_N(\beta^{\circ})$ 的渐近无偏相容估计, 将其代入(4.4.13), 即得可用

$$K - (2 l_N({}_k \hat{\beta}) - K) = -2 l_N({}_k \hat{\beta}) + 2 K$$

来估计

$$-2 E_{\infty} \int f(x_N) \log g(x_N | {}_k \hat{\beta}) dx_N$$

因此, 我们即定义

$$AIC(K) = -2 l_N({}_k \hat{\beta}) + 2 K$$

这正是(4.4.9)式, 使 $AIC(K)$ 为极小的 K_0 , 即作为模型阶数 l 的估计。

由(4.4.9)式可直观地看到, 当 $K < l$, 或估计模型与真实模型存在相当大的差异时, 极大对数似然比 $l_N({}_k \hat{\beta})$ 会显著变小, 因而(4.4.9)式中的第一项会显著变大, 第二项则不起主要作用; 而当 $K \geq l$ 时, 虽由于多余参数的估计会减小似然度, 但总的说来 $l_N({}_k \hat{\beta})$ 这时变化很小, 第二项在(4.4.9)式中起主要作用。对这两个方面加权平均(“2”相当于权系数), 就能根据样本识别出最经济的阶数以及相应的参数估计值 $\hat{\beta}$ 。

下面,对于时间序列的各类线性模型具体来讨论 AIC 准则的各种表现形式。

由第三章 § 4.2 的讨论知,当样本长度 N 充分大时,ARMA(p, q)模型的似然函数近似地可表示为

$$l_N(\hat{\beta}) = -\frac{N}{2} \log 2\pi - \frac{N}{2} \log \hat{\sigma}_a^2 - \frac{s(\hat{\beta})}{2\hat{\sigma}_a^2}$$

将

$$\hat{\sigma}_a^2 = \frac{1}{N} S(\hat{\beta}) \text{ 代入上式, 即得在 } N \text{ 充分大且固定的前提下,}$$

ARMA(p, q)模型拟合的最小信息准则应使

$$\text{AIC} = N \log \hat{\sigma}_a^2 + 2(p + q + 1) \quad (4.4.14)$$

达到最小,与之相应的阶数(p, q)及模型参数的极大似然估计

$$\hat{\varphi} = (\varphi_1, \varphi_2, \dots, \varphi_p)^T$$

$$\hat{\theta} = (\theta_1, \theta_2, \dots, \theta_q)^T$$

和 $\hat{\sigma}_a^2$,就是在 AIC 准则下得到的理想阶数和参数。

如果序列均值不为零,则均值应该作为一个独立参数进行估计,这时,上式应改为

$$\text{AIC} = N \log \hat{\sigma}_a^2 + 2(p + q + 2) \quad (4.4.15)$$

对于 ARIMA(p, d, q)序列,由于经过 d 阶差分运算后,样本有效长度已由 N 降至 $N - d$,而且差分运算后所产生的序列 $\{w_t\}$

$$w_t = \nabla^d z_t$$

的均值已为零,无需再作为被估计的参数,因此有

$$\text{AIC} = (N - d) \log \hat{\sigma}_a^2 + 2(p + q + 1 + \delta_{d0}) \quad (4.4.16)$$

其中

$$\delta_{d0} = \begin{cases} 1 & d = 0 \\ 0 & d \neq 0 \end{cases}$$

由于常数量并不影响 AIC 的极小点,因此,有时略去(4.4.14)或(4.4.16)式右端的常数量,将 ARIMA(p, d, q)序列的 AIC 表为

$$\text{AIC} = (N - d) \log \hat{\sigma}_a^2 + 2(p + q) \quad (4.4.17)$$

有些文献中对 ARIMA (p, d, q) 序列采用如下形式的准则

$$AIC = N \log \hat{\sigma}_a^2 + 2 \frac{N}{N-d} (p+q+1+\delta_{a0}) \quad (4.4.18)$$

对于周期性乘积型序列 ARMA $(p, d, q) \times (P, D, Q)_s$, 其独立参数个数为 $P+p+Q+q+1+\delta_{a0} \times \delta_{s0}$, 相应地

$$AIC = N \log \hat{\sigma}_a^2 + 2 \frac{N}{N-d-D \times s} (P+p+Q+q+1+\delta_{a0} \times \delta_{s0}) \quad (4.4.19)$$

AIC 准则也可用来对相应的多维时间序列模型定阶。只是对多维情形, 以上各式中的 $\hat{\sigma}_a^2$ 代之以自协方差阵的行列式 $|\Sigma_a|$, 自由参数个数由系数矩阵和 Σ_a 中的独立参数个数来决定。具体形式将在第八章中讨论。

AIC 准则对于时序模型的定阶带来了方便, 继 AIC 准则以后, 又产生过 BIC, DIC... 等多种模型定阶和估计准则, 它们从某些角度改进了 AIC 准则, 但迄今为止, AIC 准则仍被广泛应用。然而, 对于 AIC 准则的使用切不可过分迷信和绝对化, 它仅仅是关于模型优性的一种宏观度量, 已经证明^[19]用此准则确定的模型阶数在理论上并不是相容估计, 而且在具体运用准则时, 仍然需要人为地给定阶数的最大范围。一般情形下, 从经验来看, 阶数上限取 $\sqrt{N}, \frac{N}{10}, \log N$ 均可。在比较 AIC 值大小的过程中, 如果已接近阶数上限仍不能确定 AIC 的取值, 则应加大上限, 继续进行比较。对于多个坑点情形, 不宜机械地以这些坑点中的绝对最小值来选择模型阶数, 而是对这几个坑点所对应的模型进行多方比较, 最后再确定取舍。

§ 4.3 模型定阶的其它准则

上节介绍的 AIC 准则避免了统计检验中由于选取置信度而产生的人为性, 并且为时序模型的定阶带来许多方便。然而, AIC 准则也有不足的地方, 有人已从理论上证明了, AIC 方法不能给出相容估计。也就是说, 当样本长度 N 趋于无穷大时, 用 AIC 定出的模型阶数估计值, 并不能依概率收敛到真值。为了改进这些方

法, Akaike (1976) 提出了新的定阶准则 BIC

$$\text{BIC}(K) = -N \log \hat{\sigma}_a^2 + K \log N \quad (4.4.20)$$

其中, $K = p + q + 1$ 表示自由参数个数。

后来, E. J. Hannan 与 Quinn (1979, 1980) 又提出了一种定阶准则

$$\phi(K) = -N \log \hat{\sigma}_a^2 + CK \log \log N \quad (4.4.21)$$

常数 $C > 2$

并证明了, 如果预先知道模型阶数的上界, 那么, 在此范围内用使 $\phi(K)$ 或 $\text{BIC}(K)$ 达极小的阶数估计值 $\hat{p}$ 和 $\hat{q}$ 作为真正阶数 p 与 q 的估值, 它们是相容估计。类似于 AIC, 上述准则不难推广到其它线性模型或多维情形。

虽然 $\text{BIC}(K)$ 与 $\phi(K)$ 作为定阶准则, 可以给出阶的相容估计, 但它必须满足一个前提条件, 就是必需事先给出真实阶数的上界。因此, 自然会提出如下问题: 在阶数上界未知时, 能否确定模型的阶数? 这样对阶数作出的估计是否相容? 直观上可以想见, 如果取 K_N 为随 N 上升的数列, 以它作为阶数上界, 那么当样本 N 增加时, K_N 总可超过真阶, 在 K_N 的范围内用上述准则可望得到真实阶数的相容估计。

更一般的准则函数是

$$\text{ACH}(K) = \log \hat{\sigma}_a^2 + \frac{K}{N} C_N \quad (4.4.22)$$

在范围 K_N 内寻求 $\text{ACH}(K)$ 的最小值点。相应的 $\hat{p}_N, \hat{q}_N$ 便是所估计出的阶数。显然, 这一准则函数等价于

$$N \cdot \text{ACH}(K) = N \log \hat{\sigma}_a^2 + KC_N \quad (4.4.23)$$

当取 C_N 为 2 或 $\log N, C \log \log N$ 时, $N \cdot \text{ACH}(K)$ 分别相应于 AIC, BIC, $\phi(K)$ 中的函数。对于 AR 模型可以证明^[14], 在根据准则函数 ACH 估计模型阶数时, 取阶数上界 K_N 为 $\log N$ 的常数倍时, 取 $C_N = \log N$ 可以得到阶的相容估计。定性地说, C_N 越大, 阶数估计值越偏低; K_N 越大, $\text{ACH}(K)$ 的最小值可能越不明显。因此, 在实际应用中, 如果 C_N, K_N 选取适当, 且在 K_N 范围内估计得

的最小值点 $\hat{K}$ 又明显地小于 K_N , 这种情形下, 估计值 $\hat{K}$ 是比较好的; 反之, 若 C_N 与 K_N 稍有变化, $\hat{K}$ 就有明显改变, 或 $\hat{K}$ 与 K_N 过分接近, 这就意味着 $\hat{K}$ 的估计过多地带有“人为性”, 这种估计值一般不会太理想。

以上对于种种估计准则进行了讨论。在本小节结束之前, 还要回过头来强调的一点是, 尽管 $AIC(K)$ 给出的估计量 $\hat{K}$ 是不相容的, 但它仍不失其使用价值。在实际中, 仍被广泛使用。

第五章 时间序列的建模与实例

通过前面几章的讨论, 我们对于时间序列的基本概念及其处理动态数据的主要手段有了一定的了解。可以看到, 这门学科的应用性极强, 处理数据的方法也是既有理论根据而又切实可行的。然而, 由于要照顾到初学者循序渐进的需要, 对于各种动态数据进行处理的手段和方法是分散在各章各节中介绍的。为了使读者对于时间序列的建模手段能得到一个全貌的系统的了解, 也为了帮助读者运用所学的理论和方法在计算机上用程序实现, 有必要将从动态数据入手建立时序模型的步骤和流程, 整理出来供大家参考, 并在给出程序实现的流程同时, 还介绍相应的数字实例。希望通过这些实例的讨论, 使大家对于时序分析在动态数据处理中的应用得到一定的感性认识, 以便在各个领域中应用。本章着重介绍叠合模型与混合模型的几种建模程序, 关于自回归模型, 因为建模步骤和方法比较简单, 读者参照本章与第三章末尾的内容即可, 这里不再单独介绍。为了简化记号, 本章在不至于混淆的地方, 对参数估计值都免去“ $\wedge$ ”号。

§ 1 季节性乘积模型的建模和实例

§ 1.1 季节性乘积模型的建模步骤

在第4章§2中, 我们介绍了带有确定周期 s (s 为正整数) 的季节性乘积模型 $\text{ARIMA}(p, d, q) \times (P, D, Q)_s$,

$$\Phi(B^s)\varphi(B)\nabla_s^d\nabla^d x_t = \Theta(B^s)\theta(B)a_t \quad (5.1.1)$$

其中

$$\begin{aligned} \nabla^s &\triangleq (1-B)^s & \nabla_s^d &\triangleq (1-B^s)^d \\ \Phi(B^s) &\triangleq 1 - \Phi_1 B^s - \Phi_2 B^{2s} - \dots - \Phi_P B^{Ps} \\ \Theta(B^s) &\triangleq 1 - \Theta_1 B^s - \Theta_2 B^{2s} - \dots - \Theta_Q B^{Qs} \end{aligned}$$

$$\begin{aligned}\varphi(B) &\triangleq 1 - \varphi_1 B - \cdots - \varphi_p B^p \\ \theta(B) &\triangleq 1 - \theta_1 B - \cdots - \theta_q B^q\end{aligned}\quad (5.1.2)$$

$$B^l x_t \triangleq x_{t-l}$$

显然,算子 $\varphi(B), \theta(B)$ 的作用反映了相近样本或相近噪声之间的关系,算子 $\Phi(B^s)$ 和 $\Theta(B^s)$ 的作用反映了周期之间的关系。这种模型可以用来有效地描述带有确定周期 s 的序列。将模型(5.1.1)稍加推广,还可用来描述带有多个确定周期 $s_1, s_2, \cdots, s_r$ 的时间序列,并且当 P, D, Q 都取零值时,模型(5.1.1)还可退化到普通的 $\text{ARIMA}(p, d, q)$ 情形。因此,季节性乘积模型具有一定的代表性和广泛性,适宜于模拟常见的动态数据序列,有必要对这类模型的建模程序进行系统的讨论。这里我们介绍一种途径,供大家参考。

我们将对一组长度为 N 的动态数据建立周期性乘积模型的全过程分成以下几个步骤来进行。

1. 准备阶段:在得到一组动态数据之后,一般并不能立即着手对之进行建模,而是要根据第二、三、四章介绍的理论和方法,对数据进行一系列处理、分析和检验,以便为进入建模阶段做好准备。这一阶段主要进行数据预处理和相关分析这两方面的工作。

i) 检验动态数据序列的平稳性、正态性和零均值性(参照第四章 §1)。如果上述性质不能满足,则需作如下的预处理:

(a) 零均值化:所谓零均值化,就是将数据作如下的处理

$$\tilde{x}_t \triangleq x_t - \bar{x}_t = x_t - \frac{1}{N} \sum_{k=1}^N x_k \quad (5.1.3)$$

在此处理之后,对产生的新序列 $\{\tilde{x}_t\}$ 进行分析和建模。

这一工作在通常情形下都是必不可少的,即使是取自零均值总体的样本列也不例外。

(b) 平稳化:对于减去样本均值,实现零均值化处理而产生的新序列,还要进一步检验其是否具备平稳性(凭经验、物理性质、或用第四章 §1.2 中介绍的统计检验方法)。如果序列明显具有多项式或周期增长趋势,可通过差分或周期差分来消除。例如

$$\begin{aligned} d \text{ 阶差分: } \quad \tilde{x}_t &\triangleq D^d x_t, \quad t > d \\ D \text{ 阶差分: } \quad \tilde{x}_t &\triangleq \nabla_t^D x_t, \quad t > Ds \end{aligned} \quad (5.1.4)$$

这两种差分也可结合起来使用。通常 d 和 D 的大小可以从点值图或相关函数图的大致规律凭经验而定,也可以用统计手段,通过在一定范围内比较各种差分组合所对应的模型优劣来选定,即取 d_0 和 D_0 ,使

$$\min\{\hat{\sigma}_z^2(d, D) \mid x_t = \nabla_t^D \Delta_t^d x_t\} \quad (5.1.5)$$

在预先给定的 d 与 D 的范围内成立。式中 $\hat{\sigma}_z^2(d, D)$ 是相应模型的白噪声方差估计值。差分处理也可起到零均值化的作用。当 d 或 D 不为零时,数据一般不必再减样本均值。

对于具有其它复杂规律的动态数据,可按第4章§3中介绍的方法,进行分离趋势的平稳化处理。也可采用其它形式的处理手段(如气象数据的距平、移动平均等)。

(c) 正态化: 我们知道,对于正态序列,其模型参数可用极大似然方法进行估计,从而达到提高估计精度的目的。因此,在对数据建模之前,进行正态检验,或将非正态序列的分布进行适当变换使其产生的新序列服从正态,还是颇有意义的。后一步工作,就称之为数据的正态化处理。对于不能得以正态化的序列,在用线性模型 ARIMA 拟合时,参数通常只可采用最小二乘方法进行估计。有些复杂的序列,还不得不去建立非线性模型,这部分内容,将在本书第九章中讨论。

ii) 相关分析: 动态数据 $\{x_t\}$ 经过第 I 阶段的预处理后,就产生了平稳、正态、零均值的新序列 $\{w_t\}$ 。这时,需对此新序列进行相关分析,以便进一步判断用什么样的模型形式来拟合它们。

所谓相关分析,就是计算序列 $\{w_t\}$ 的样本自相关函数与样本偏相关函数,通过检验自相关函数或偏相关函数的截尾性、拖尾性和周期性,判断动态数据应该用何种模型形式来拟合。

在计算样本自协方差函数时,注意到取用

$$\hat{\gamma}_\tau = \frac{1}{N} \sum_{k=1}^{N-\tau} w_k w_{k+\tau} \quad \tau = 1, 2, \dots, M \quad (5.1.6)$$

以保证自协方差序列的正定性。偏相关函数的计算,采用第二章 § 5.2 中介绍的递推计算公式。

$\hat{\rho}_k$ 与 $\hat{\phi}_{kk}$ 的截尾性可按第三章 § 1.3 中所介绍的方法进行判断。如果 $\{w_t\}$ 的样本自相关(自协方差)函数在 q 步截尾,则可用 $MA(q)$ 模型拟合;如果偏相关函数 p 步截尾,则用 $AR(p)$ 模型拟合;如果自、偏相关函数都有拖尾现象,则 $\{w_t\}$ 序列应拟合混合模型 $ARMA$;若序列自、偏相关函数呈周期状,则应用周期性乘积模型拟合,不过周期性可凭数据的物理性质直接判断。

准备阶段工作基本完成后,动态数据处理便进入下一阶段。

2. 建模阶段: 根据准备阶段的分析结果,将采用选中的模型形式对数据进行拟合。自回归模型的拟合程序在第三章 § 5 中已有详尽介绍,这里仅讨论季节性乘积型 $ARIMA$ 模型。这种模型的建模步骤大致可分为以下几个阶段。

i) 给定模型阶数上限: 我们已指出,对于混合模型无法明显地判断其阶数,只能依一定准则将阶数由低至高地比较。因此,对于模型阶数就需给出一个可供选择的范围。阶数上限是人为臆定的,可由经验、计算机速度与容量来综合考虑。有时也从模型渐近性质来决定。例如 $ARMA$ 模型,阶数上限 L 可取 20;对于乘积模型,季节因子的阶数上限不宜过高;又如自回归模型,由第三章 § 5.4 的讨论知,如果样本长度 N 较大(几百以上),上界取 $\log N$ 的倍数比较合理。

ii) 选择某一个阶数组合 P_0, p_0, Q_0, q_0 , 对相应的模型参数进行初估计,为进一步的精估计准备初值。

在第三章 § 2, § 3 中,对于初估计方法有比较详细的讨论,可以根据经验或通过比较,决定选用矩估计法或逆函数法。对于季节模型,由于结构比较复杂,进行上述初估计都比较麻烦,不妨采用第三章 § 3.3 末尾所介绍的方法,在平稳可逆域内任选一组参数作为下一步作精估计的迭代初值。

iii) 进行参数精估计: 这是整个建模过程中的核心阶段,其任务是在前面一系列工作的基础上,依照一定准则,运用某种方

法,从初估计出发,最终迭代出参数的精估计 $\hat{\Phi}, \hat{\varphi}, \hat{\Theta}, \hat{\theta}$ 。

例如,对于满足正态性的序列,可进行最小平方和估计。平方和值 $s(\beta)$ 的计算可采用第三章 §4 中介绍的方法。这里要注意的是,对于季节性模型,计算平方和函数之前,要将模型转化成相应的高阶疏系数形式。

参数精估计问题实质上是一种带约束条件的非线性最优化问题。第三章 §4.5 介绍了一种 Powell 方法,能通过线性搜索,有效地在平稳可逆域内实现平方和函数的极小化。

iv) 模型的定阶和考核: 对于每一组给定的阶数与相应的参数精估计,按第 4 章 §4.2 介绍的方法进行模型阶数的比较判别,可最终确定对于数据进行拟合的理想模型,至此建模全过程基本结束。为了进一步考核模型的合理性,还需对于模型输出的残量 $\{a_t\}$ 按照第四章 §1.3 介绍的方法,进行自相关检验。

上述工作全部完成后,就可由此模型出发,进行预报、控制等工作。而且,预报或控制效果的好坏,又可进一步考核和验证模型的合理性。

图 5.1 给出了建模程序步骤的简单示意框图。

§ 1.2 实例

为了帮助大家运用时序分析方法处理实际动态数据,本节从不同侧面,介绍了三个季节性建模实例。第一个例以考核预报效果为主,第二例重在预处理的比较与物理意义分析,第三例对模型形式进行了选择比较,对相关函数进行了细致分析。下面逐一介绍这几个实例。

1. 上海月气温资料的建模和预报^[21]: 用上海 1952—1975 年逐月温度资料计 $24 \times 12 = 288$ 个样本,按 §1.1 介绍的方法建立季节性 ARIMA 模型。为消除年变化,对数据作一阶季节差分

$$D=1 \quad s=12$$

所得的模型为 $\text{ARIMA}(0,0,2) \times (2,1,1)_{12}$, 其相应的模型参数为




图 5.1 Box 建模步骤框图

$$\begin{array}{lll}
 \phi_1 = -0.09 & \phi_2 = -0.09 & \theta_1 = 0.90 \\
 \theta_1 = -0.19 & \theta_2 = 0.01 &
 \end{array}$$

后来,又增加三年资料,即取 324 个样本,求得的模型参数与 288 个样本时完全相同,这说明模型是稳定的。

图 5.2 给出了 1974 年 1 月—1978 年 12 月的拟合值和 1979 年的预报值曲线。由图可见,模型基本反映了温度的年变程,报准了月际变化趋势。这样的模型能预报出一年逐月的气温,无疑对事先估计年度的冷暖总趋势会有帮助。




图 5.2 上海月平均气温实况与计算值比较

74.1 表示 1974 年 1 月,余类推,——实况,---计算。竖虚线左侧为拟合,右侧为预报

2. 海口 100 毫巴高度月平均资料的分析: 取 1964—1975 年逐月 100 毫巴 20°N , 110°E 的网格点高度值 $\{x_t\}$ (计 $12 \times 12 = 144$ 个样本)进行模型识别。为消除年周期,对数据进行一阶季节差分处理

$$w_t = \nabla_{12} x_t = x_t - x_{t-12}$$

对不同的阶数组组合,按 §1.1 给出的步骤进行模型拟合,并通过比较 AIC 值和预报效果来选择理想的模型。例如,我们已从著

表 5.1 两组模型的比较

模型阶数	φ_1	φ_2	ϕ_1	ϕ_2	θ_1	θ_2	Θ_1	$s(\beta)$	AIC
(I) (1,0,2) × (2,1,1) ₁₂	0.4009		0.2945	-0.2	0.1778	-0.2955	0.922	9.6915	305.820
(II) (2,0,1) × (2,1,1) ₁₂	1.51	-0.7	-0.3	-0.2	0.81		0.9	13.020	344.783

多的阶数组组合中选出 AIC 值最小的两组模型(表 5.1)两种模型的预报与 1976 年实况的比较如表 5.2 所示。

表 5.2 不同模型的预报比较

模 型	1 (月)	2	3	4	5	6	7	8	9
(I)	53.7	52.0	60.8	57.7	68.4	67.2	66.0	70.2	61.9
(II)	27.6	30.5	42.9	47.9	66.2	64.8	62.4	68.0	57.4
实 况	56	52	60	57	74	69	72	69	69

由上表可见,模型 (I) 的预报效果明显优于模型 (II),可见以 AIC 值的大小来选择模型阶数是合理的。

为了比较不同的预处理手段对于建模的影响,我们对本例中的数据进行了三种预处理,并对处理后的三个新序列都建立 $ARIMA(1,0,2) \times (2,1,1)_{12}$ 模型,参数估计值列于下表

表 5.3 不同预处理比较

预 处 理	φ_1	ϕ_1	ϕ_2	θ_1	θ_2	θ_3	$s(\beta)$	AIC
不求距平 不作年差分	0.7	1.3	-0.5	0.21	-0.2	0.71	17.5744	418.782
不求距平 做年差分	0.4009	-0.2945	-0.2	0.1778	-0.2955	0.922	9.6915	305.820
求距平 做年差分	0.4752	-0.2993	-0.1955	0.2278	-0.2757	0.922	9.6215	304.833

由表 5.3 可见,距平处理(见第三章 (3.5.15) 式)对于降低 AIC 所起的作用不显著,且对模型参数的变化不产生主要影响,而年差分的作用非常显著。检验结果也表明,年差分处理后数据可认为是平稳的。

为了考察模型反映的天气气候含义,又选择了与海口纬度相近经度相差 $60^\circ E$ 的关岛,以及经度同是 $110^\circ E$ 而纬度相隔 $60^\circ N$ 的网格点(称极区),与海口同样年份的资料作了 $(1,0,2) \times (2,1,$

1)₁₂ 模型的计算, 结果见表 5.4。

表 5.4 不同地区 $(1, 0, 2) \times (2, 1, 1)_{12}$ 模型参数

地 点	φ_1	Φ_1	Φ_2	θ_1	θ_2	Θ_1	$s(\beta)$	AIC
海 口	0.4009	-0.2945	-0.200	0.1778	-0.2955	0.9220	9.6915	305.820
关 岛	0.5913	-0.2150	-0.2393	0.0093	-0.1993	0.9574	398.253	796.313
极 区	0.4703	-0.9430	-0.3325	0.0160	0.0100	-0.5588	116.177	633.699

· 此表说明, 海口与关岛的模型除参数 θ_1 有较大差别外, 其余都很相接近。这反映了纬度相同的低纬两地, 虽经度相隔不小, 但在 100 毫巴上空的自由大气里环流演变规律都是相似的。而海口与极区虽在同一经度, 但一个是低纬度, 一个是高纬度, 它们的环流演变规律就相差很大。因此, 相应的 100 毫巴高度场的时间序列模型也就显示出明显的差别。

3. 国际航空客票数的建模和分析: 表 5.5 列出了 1949—1960 年各月某国际航空公司接待的旅客数日 $\{x_t\}$

表 5.5 1949—1960 年某国际航空公司客票数 (单位: 千张)

(月)	1	2	3	4	5	6	7	8	9	10	11	12
1949	112	113	132	129	121	135	148	148	135	119	104	118
1950	115	123	141	135	135	143	170	170	158	133	114	140
1951	145	150	178	163	172	178	199	199	181	132	146	166
1952	171	180	193	181	183	218	230	242	209	191	172	194
1953	196	196	236	235	229	213	264	272	237	211	180	201
1954	204	183	235	227	231	264	302	293	259	229	203	229
1955	242	233	267	239	270	315	364	347	312	274	237	278
1956	284	277	317	313	318	374	413	405	355	306	271	306
1957	315	301	356	348	355	422	465	467	404	347	305	336
1958	340	313	362	348	363	435	491	505	404	359	310	337
1959	360	342	406	396	420	472	548	559	463	407	362	405
1960	417	391	419	461	472	535	622	606	508	461	390	432

由表中明显可见,这是个周期长度 $s=12$ 的季节性序列。可以看出,同年 7 月和 8 月份的飞机乘客是最多的,而不同年的各个月乘客数目有逐年增长的趋势。为了对此序列选择合适的平稳化处理手段,令 $z_t = \log_{10} x_t, t=1, 2, \dots, 144$, 并分别计算出 $\{z_t\}, \{\nabla z_t\}, \{\nabla_{12} z_t\}, \{\nabla \nabla_{12} z_t\}$ 和它们各自的样本自相关函数列。将这四组自相关函数列于表 5.6。不难看出, $\{z_t\}, \{\nabla z_t\}, \{\nabla_{12} z_t\}$ 的样本自相关函

表 5.6 四种预处理的自相关函数列

	k	自 相 关 函 数 r_k												
(a) z	1—12	0.95	0.90	0.85	0.81	0.78	0.76	0.74	0.73	0.73	0.74	0.76	0.76	
	13—24	0.72	0.66	0.62	0.56	0.51	0.52	0.50	0.49	0.50	0.50	0.52	0.52	
	25—36	0.48	0.44	0.40	0.36	0.31	0.31	0.30	0.29	0.30	0.30	0.31	0.32	
	37—48	0.29	0.26	0.21	0.17	0.15	0.12	0.11	0.10	0.10	0.11	0.12	0.13	
(b) ∇z	1—12	0.20	-0.12	-0.15	-0.22	-0.08	0.03	-0.11	-0.34	-0.12	-0.11	0.21	0.81	
	13—24	0.22	-0.14	-0.12	-0.28	-0.05	0.01	-0.11	-0.33	-0.11	-0.08	0.20	0.74	
	25—36	0.20	-0.12	-0.19	-0.21	-0.08	0.02	-0.12	-0.29	-0.13	-0.04	0.15	0.66	
	37—48	0.19	-0.13	-0.06	-0.16	-0.06	0.01	-0.11	-0.28	-0.11	-0.03	0.12	0.59	
(c) $\nabla_{12} z$	1—12	0.71	0.62	0.48	0.44	0.39	0.32	0.24	0.19	0.15	-0.01	-0.12	-0.24	
	13—24	-0.14	-0.14	-0.10	-0.15	-0.10	-0.11	-0.14	-0.16	-0.11	-0.08	0.00	-0.05	
	25—36	-0.10	-0.02	-0.13	-0.15	-0.19	-0.20	-0.19	-0.15	-0.22	-0.23	-0.27	-0.22	
	37—48	-0.16	-0.16	-0.14	-0.10	-0.05	0.02	0.04	0.10	0.13	0.22	0.29	0.30	
(d) $\nabla \nabla_{12} z$	1—12	-0.34	0.11	-0.20	0.02	0.06	0.03	-0.06	0.00	0.18	-0.08	0.06	-0.39	
	13—24	0.15	-0.09	0.15	-0.14	0.07	0.02	-0.01	-0.12	0.04	-0.09	0.23	0.02	
	25—36	-0.10	0.05	-0.03	0.05	-0.02	-0.05	-0.05	0.20	-0.12	-0.08	-0.15	-0.01	
	37—48	0.05	0.03	-0.02	-0.03	-0.07	0.10	-0.09	0.02	-0.04	-0.04	0.11	-0.05	

数都是起伏频繁,直至 k 很大后, $\hat{\rho}_k$ 仍有高值,而 $\{\nabla \nabla_{12} z_t\}$ 的 $\hat{\rho}_k$ 仅在 $k=1$ 和 $k=12$ 时取值较大,因此可以认为,对序列进行

$$w_t = \nabla \nabla_{12} z_t \quad (5.1.7)$$

的预处理是合理的。其实,在 ∇z_t 的自相关函数中,明显可见在 $k=12, 24, 36, 48$ 处的值特别大,这也启示我们应当对它作 ∇_{12} 处理。

对由(5.1.7)处理后所得的新序列 $\{w_t\}$ 进行 ARIMA 拟合,建立了乘积模型 $\text{ARMA}(0, 1, 1) \times (0, 1, 1)_{12}$

$$w_t = (1 - \theta_1 B)(1 - \Theta_1 B^{12})a_t = (1 - \theta_1 B - \Theta_1 B^{12} + \theta_1 \Theta_1 B^{13})a_t \quad (5.1.8)$$

其中

$$\hat{\theta}_1 = 0.40 \quad \hat{\Theta}_1 = 0.61$$

由(5.1.8)可导出序列的自协方差函数与参数之间的关系

$$\begin{aligned} \gamma_0 &= (1 + \theta_1^2)(1 + \Theta_1^2)\sigma_a^2 \\ \gamma_1 &= -\theta_1(1 + \Theta_1^2)\sigma_a^2 \\ \gamma_{11} &= \Theta_1\theta_1\sigma_a^2 \\ \gamma_{12} &= -\Theta_1(1 + \theta_1^2)\sigma_a^2 \\ \gamma_{13} &= \theta_1\Theta_1\sigma_a^2 \end{aligned} \quad (5.1.9)$$

其它的 γ_k 都恒为零, 且 $\rho_k = \gamma_k / \gamma_0$ 。显然, γ_1 和 γ_{12} 比较大, 和实际情形一致, 证明了对 $\{z_t\}$ 用季节性 ARIMA $(0, 1, 1) \times (0, 1, 1)_{12}$ 模型拟合的合理性。

乘积型季节模型可以节省模型参数。由 (5.1.8) 式可见, 只要估计出 θ_1 和 Θ_1 , 模型就完全确定。然而, 由(5.1.9)式知, 由于有关系式 $\rho_{13} = \gamma_{13} / \gamma_0 = \rho_1 \rho_{12}$, 就限制了满足模型 (5.1.8) 的数据, 它的 ρ_{13} 必须相对地小于 ρ_1 和 ρ_{12} 。因此, 如果实际序列不满足这一条件时, 就不宜采用模型(5.1.8), 而应采用更一般的非乘积模型

$$w_t = (1 - \theta_1^* B - \theta_2^* B^{12} - \theta_{13}^* B^{13}) a_t \quad (5.1.10)$$

最后, 我们还可以进一步较精细地看一看 $\hat{\rho}_k$ 的方差。由 Bartlett 公式 (见(3.1.3)式) 得

$$\text{var} \hat{\rho}_k \cong \frac{1}{N} \left(1 + 2(\hat{\rho}_1^2 + \hat{\rho}_{11}^2 + \hat{\rho}_{12}^2 + \hat{\rho}_{13}^2) \right) R > 13$$

即

$$[\text{var} \hat{\rho}_k]^{\frac{1}{2}} \cong 0.11$$

根据正态分布的性质: 值落在 $\pm \sigma$ 和 $\pm 2\sigma$ 之间的百分比为 68.3% 和 95.5%, 可以以此来考察本例的 $\hat{\rho}_{14}$ 至 $\hat{\rho}_{48}$ 这 35 个样本自相关函数值是不是正态 $\mathcal{N}(0, 0.11^2)$ 分布的。从表 5.7 可见, 这一结论是可以被接受的。且由此证明了 γ_k 在 $q=13$ 处截尾的合理性。

表 5.7 $\{\hat{\rho}_k\}$ 的正态性检验

绝对值范围	$N(0, 0.11^2)$ 分布的理论频数	样本实际频数
$[0, 0.11)$	23.9	27
$[0.11, 0.22)$	9.5	7
$[0.22, \infty)$	1.6	1
$[0, \infty)$	35	35

本章以后的几节中, 还将从其它角度对航空客票数据进行分析。




图 5.3 航空客票数据曲线和拟合

—— 数据
 ---- 预报

§ 2 ARMA($n, n-1$)模型的建模和实例

前一节介绍的建模方法, 是以相关分析为基础来实现的, 无论是模型形式和阶数的判别, 还是模型参数的初估计精估计, 都离不开相关函数。这是 Box 所提倡的一种建模思想, 它是从统计的观点出发而得到的。从所介绍的建模步骤可见, 这种方法比较稳妥可靠。然而, 对于混合模型, 由于需要由低至高地对阶数进行逐步

试探,在计算机实现过程中要进行人机配合,因此显得比较繁锁。

本节将向大家介绍另外一种建模方案,它是由美国威斯康辛大学吴贤铭教授提出的。他从分析系统特性出发,采用 $\text{ARMA}(n, n-1)$ 的模型形式对动态数据进行拟合,并给出一套具体的办法,方便于建模程序在计算机上实现。因此,尽管这一方法显得比较粗糙,但仍显示了很大的优越性。下面,我们就来讨论这种模型的建模程序。

§ 2.1 用 $\text{ARMA}(n, n-1)$ 模型拟合动态数据的合理性

第二章 §1 中曾论证过,一个平稳零均值序列在一定条件下可以用 $\text{ARMA}(p, q)$ 模型来拟合。而通过第三章的讨论,我们也认识到,模型拟合形式是不单一的,同样一组数据,可以用混合模型 $\text{ARMA}(p, q)$ 拟合,也可用纯自回归或纯滑动平均模型形式去拟合。例如,一个 $\text{ARMA}(2, 1)$ 模型

$$(1 - 0.6B + 0.08B^2)w_t = (1 + 0.1B)a_t$$

可以近似表成 $\text{MA}(5)$,也可近似表成 $\text{ARMA}(1, 4)$,我们给出近似表成 $\text{MA}(5)$ 模型的推算过程

$$\begin{aligned} w_t &= \frac{1 + 0.1B}{1 - 0.6B + 0.08B^2} a_t \\ &= (1 + 0.1B)(1 - 0.2B)^{-1}(1 - 0.4B)^{-1} a_t \\ &= (1 + 0.1B)(1 + 0.2B + 0.04B^2 + 0.008B^3 + 0.0016B^4 + \cdots)(1 - 0.4B)^{-1} a_t \\ &\cong (1 + 0.7B + 0.34B^2 + 0.148B^3 + 0.0616B^4 + 0.025B^5) a_t \\ &= a_t + 0.7a_{t-1} + 0.34a_{t-2} + 0.148a_{t-3} + 0.0616a_{t-4} + 0.025a_{t-5} \end{aligned}$$

因此,我们自然考虑到,能不能从可以拟合动态数据的模型形式中,找出一种比较合理的形式来,使数据的建模程序变得简单方便一些?

很显然, $\text{ARMA}(n, n-1)$ 的模型形式是比 $\text{ARMA}(p, q)$ 的模型形式要简便得多。因为,对数据拟合一般的 $\text{ARMA}(p, q)$ 模型

时,阶数需要随着 p 和 q 的变动,由低至高逐个试探来确定,计算量较大;而对 $\text{ARMA}(n, n-1)$ 模型,只要选择一个 n 就可以了。例如假设数据取自一个 $\text{ARMA}(5, 4)$ 模型,那么,为用 $\text{ARMA}(p, q)$ 对它进行模型拟合,用逐个增加 p 和 q 的方法,可能要依次计算到34个模型;而用 $\text{ARMA}(n, n-1)$ 的模型拟合,只要做5个就够了。因此,用 $\text{ARMA}(n, n-1)$ 的模型形式常常是很有好处的。

对动态系统特性的研究表明,当自回归阶数取为 n 时,滑动平均阶数为 $n-1$ 是合理的。

如果我们从系统观点出发,把时间序列看成是具有独立随机输入的动态系统的响应,那么,当模型的自回归阶数为 n 时,系统的动态响应特性就是由下式描述的格林函数给出

$$G_j = g_1 \lambda_1^j + g_2 \lambda_2^j + \cdots + g_n \lambda_n^j \quad j \geq 0 \quad (5.2.1)$$

式中 $\lambda_1, \lambda_2, \cdots, \lambda_n$ 若是 n 个线性独立的特征根(为方便计,设 $\lambda_j, j=1, 2, \cdots, n$ 为单根),则由第二章(2.3.4)式知, G_j 能满足的齐次差分方程是

$$(1 - \varphi_1 B - \varphi_2 B^2 - \cdots - \varphi_n B^n) G_j = 0 \quad j \geq n \quad (5.2.2)$$

且参数 φ_i 可由特征根表示成

$$\varphi_l = (-1)^{l+1} \sum_{\substack{i_1, i_2, \dots, i_l=1 \\ i_1 < i_2 < \dots < i_l}}^n \lambda_{i_1} \lambda_{i_2} \cdots \lambda_{i_l} \quad l=1, 2, \dots, n \quad (5.2.3)$$

为了能由(5.2.1)式中确定 G_j ,必须先能确定式中的 n 个常数 $g_1, g_2, \cdots, g_n$ 。由差分方程求根理论知,它们由 n 个初始条件来确定。注意到有一个条件

$$1 = G_0 = g_1 + g_2 + \cdots + g_n \quad (5.2.4)$$

总是满足的,因此只剩下 $n-1$ 个条件需要确定,仍由第二章(2.2.4)式知,这相当于求解非齐次差分方程的特解

$$\sum_{j=0}^l \varphi_j G_{l-j} = \theta_l \quad l=1, 2, \dots, n-1$$

$$G_0 = 1, \quad \varphi_0 = -1 \quad (5.2.5)$$

由上可见,将(5.2.1)式代入(5.2.5)式,并和(5.2.4)式一起,就可能解得 $g_1, g_2, \cdots, g_n$ 。当自回归阶数为 n 时,如果取滑动平

均阶数为 $n-1$ ，动态系统就能完全确定。因此，采用 $\text{ARMA}(n, n-1)$ 的形式来模拟动态数据是合理的。

下面的一个事实又从另一个角度提供了采用 $\text{ARMA}(n, n-1)$ 建模方案的合理性，即如果用线性微分方程来表示连续的自回归滑动平均系统(n 阶自回归任意阶滑动平均)，当以均匀间隔采样实现数据离散化时，所得的动态时间序列恰恰符合 $\text{ARMA}(n, n-1)$ 模型。关于这一点，我们在这里不作详细讨论。

§ 2.2 模型阶数的增量

§ 2.1 节中，我们从系统分析的观点出发，根据格林函数的特性，导出了由低至高逐次拟合 $\text{ARMA}(n, n-1)$ 模型的建模方案。按照这个方案，建模的步骤应该是首先拟合 $\text{AR}(1)$ 模型，然后是 $\text{ARMA}(2, 1)$ ， $\text{ARMA}(3, 2) \cdots$ 等等，即每步的增量为 1。

上述建模步骤在理论上是可行的。如果每组观测数据的数目不多(200 左右)，模型的阶数也不高(不超过 4 阶)，这样的建模步骤还是容易实现的。但是，在更多的实际情况，按 $n=1, 2, \cdots$ 的顺序，依次用 $\text{ARMA}(2n, 2n-1)$ 的模型来拟合，可以更快地找到适合的模型。这就是说，模型阶数的增量以选择 2 为合适。下面，我们从不同角度进一步来说明这种建模策略的合理性。

首先从系统的物理背景来看， ARMA 模型可以得自具有 n 个自由度的振荡系统。具体地说， $\text{ARMA}(2, 1)$ 模型可得自一个均匀采样的自由度为 1 的弹簧-质块-阻尼系统。该系统由二阶微分方程确定，并受白噪声激励。类似地，一个自由度为 2 的系统是由四阶微分方程确定，而由该系统均匀采样，便得到 $\text{ARMA}(4, 3)$ 序列。由此可见，动态系统每增加一个自由度，相应地自回归阶数就增加 2 阶。基于这种联系，采用 $\text{ARMA}(2n, 2n-1)$ ， $n=1, 2, \cdots$ 由低至高地依次拟合系统是合理的。

其次，从差分方程特征根的配置来看，模型自回归阶数取 2 为增量也是合理的。由于特征方程

$$\varphi(B) = (1 - \lambda_1 B)(1 - \lambda_2 B) \cdots (1 - \lambda_n B)$$

是 B 的 n 阶实系数多项式(因为 φ_i 总为实数)，因而复根只能以

共轭对的形式出现,这就意味着,当自回归阶为奇数时,至少必有一根为实数。如果采用增量为1的方式由低至高拟合数据,那么从偶数阶增加1时,就必然迫使模型相应地增加一个实根,这样往往会违反实际情况。例如数据的实际模型是自回归部分具有两对共轭复根的 $\text{ARMA}(4,3)$ 模型,当从 $\text{ARMA}(2,1)$ 模型依次增加1阶来拟合数据时,就会出现实根情形,偏离数据的本来面貌。而用 $\text{ARMA}(4,3)$ 模型就可避免发生这个问题。另一方面,即使真实模型为 $\text{ARMA}(3,2)$,从 $\text{ARMA}(2,1)$ 增至 $\text{ARMA}(4,3)$ 时也会发现,阶数增加2,新增加的必为两个实根,而且可以算出 φ_4 估计值置信区间包含零,仍可从 $\text{ARMA}(4,3)$ 模型降阶到真实的 $\text{ARMA}(3,2)$ 模型。

最后,从计算角度来看,模型阶数每次增加2也是经济合算的,特别是对需要用到较高阶模型拟合数据时,更显示出它的优越性。例如,假定适合的模型是 $\text{ARMA}(5,4)$,使用增量为2的方案,逐次拟合 $\text{ARMA}(2,1) \rightarrow \text{ARMA}(4,3) \rightarrow \text{ARMA}(6,5)$,这时会发现 φ_6 和 θ_5 近似于零,且它们的置信区间也包含零。但如果按每次增加一阶的方案进行拟合,需要依次从 $\text{AR}(1) \rightarrow \text{ARMA}(2,1) \rightarrow \text{ARMA}(3,2) \rightarrow \text{ARMA}(4,3) \rightarrow \text{ARMA}(5,4) \rightarrow \text{ARMA}(6,5)$,通过6个步骤才能发现 φ_6, θ_5 具有上述性质,计算量将近增加一倍。

综上所述,我们认为模型阶数取2为增量,对动态数据由低阶至高阶进行拟合是合理的。

§ 2.3 建模步骤

通过前面两小节的讨论,我们认为用 $\text{ARMA}(2n, 2n-1)$ 形式的时序模型由低至高地拟合数据,最后选中合适的模型,这种思想是简便的、合理的,具有一定的科学依据。这种建模方案的最大优点,就在于无需人机配合,能够在计算机上自动实现。当然,我们可以根据具体情况适当修改建模方案,例如根据实践经验可知,当观测值数目小的时候,模型的阶数不宜过高,因而可用 $\text{ARMA}(n, n-1)$ 序列而不必用 $\text{ARMA}(2n, 2n-1)$ 序列来对

数据进行拟合。下面,我们就来讨论运用吴贤铭建模方案对数据 $x_1, x_2, \dots, x_N$ 建立模型的具体步骤。

1. 从 ARMA(2,1)模型开始,以 2 为步长,建立如下形式的 ARMA(2n, 2n-1)模型

$$\tilde{x}_t - \varphi_1 \tilde{x}_{t-1} - \dots - \varphi_{2n} \tilde{x}_{t-2n} = \alpha_t - \theta_1 \alpha_{t-1} - \dots - \theta_{2n-1} \alpha_{t-2n+1}$$

式中

$$\tilde{x}_t = x_t - \frac{1}{N} \sum_{i=1}^N x_i$$

具体做法是

i) 对于给定的模型阶数和形式 ARMA(2n, 2n-1)用第三章 § 3.1 中介绍的逆函数法确定相应的模型型参数初值。

ii) 将上述初值所对应的模型按第三章 § 3.2 中的方法进行根的置换,使新产生的模型具有可逆性。

iii) 以上两步骤得到的模型参数为初值,用非线性阻尼最小二乘方法(将在第六章中介绍)迭代得到模型参数的精估计值。

iv) 每当 n 增加时,用第四章 § 4.1 介绍的 F-准则去检验 ARMA(2n, 2n-1)与 ARMA(2n+2, 2n+1)模型残差平方和的差异。如果在预定的显著信水平上 F-值下降不显著,就令阶数停止增加,选择 ARMA(2n, 2n-1)为所要模型;否则,就使阶数增加,对于 ARMA(2n+2, 2n+1)模型,再依次进行前面各步。

2. 用 F-检验和置信区间原则修改模型

通常取 95%置信区间为:以估计值为中点,区间左、右端为 1.96 乘以参数的估计方差(详见第六章(6.1.9)式)。

本阶段具体分以下几步:

i) 若 $\hat{\varphi}_{2n}$ 很小,且它的置信区间包含零,而 $\hat{\theta}_{2n-1}$ 不满足相应的条件,则需对 ARMA(2n-1, 2n-1)和 ARMA(2n, 2n-1)模型进行 F-检验,以决定取哪种模型。检验显著,则取 ARMA(2n, 2n-1)模型,否则还要逐次检验 ARMA(2n-1, m), $m \leq 2n-2$ 模型是否适用。

ii) 若 $\hat{\theta}_{2n-1}$ 很小且置信区间包含零,而 $\hat{\varphi}_{2n}$ 不满足相应的条件,则需对 ARMA(2n, 2n-2)和 ARMA(2n, 2n-1)两模型

作 F -检验; 若 $\text{ARMA}(2n, 2n-2)$ 模型合适, 则需进一步逐次检验 $\text{ARMA}(2n, m)$, $m \leq 2n-2$ 是否适用。

iii) 若 $\hat{\phi}_{2n}, \hat{\theta}_{2n}$ 都很小, 其置信区间都包含零, 则需对 $\text{ARMA}(2n, 2n-1)$ 和 $\text{ARMA}(2n-1, 2n-2)$ 模型作 F -检验; 若检验后 $\text{ARMA}(2n-1, 2n-2)$ 模型合适, 需要逐次检验 $\text{ARMA}(2n-1, m)$, $m \leq 2n-3$ 模型是否适用; 若 $\text{ARMA}(2n, 2n-1)$ 模型合适, 则需逐次检验 $\text{ARMA}(2n, m)$, $m \leq 2n-2$ 是否适用。

iv) 若模型降阶后, 发现有可能进一步简化成 $\text{AR}(n)$ 或 $\text{MA}(m)$ 等形式, 则可运用类似于以上的方法, 对数据拟合这类简化模型。阶数的增加仍用 F -检验, 直到检验不显著为止。

3. 求出模型特征多项式的根 (可引用多项式求根的专用程序), 进一步合理地改进模型。以下面三种情形为例:

i) 如果已拟合得到的 $\text{ARMA}(n, m)$ 模型, 相应的算子多项式 $\varphi(B)$ 有 d 个根近似于 1, 即模型为

$$\varphi(B) = (1 - \lambda_1 B)(1 - \lambda_2 B) \cdots (1 - \lambda_d B)(1 - \lambda_{d+1} B) \cdots (1 - \lambda_n B)$$

其中 $\lambda_1, \lambda_2, \dots, \lambda_d$ 近似于 1, 则设

$$\varphi^*(B) = (1 - \lambda_{d+1} B)(1 - \lambda_{d+2} B) \cdots (1 - \lambda_n B)$$

以 $(1-B)^d \varphi^*(B)$ 作为自回归部分的算子多项式, $\theta(B)$ 作为滑动平均部分的 B 算子多项式, 分别以原参数作为初值, 对简化模型 $\text{ARIMA}(n-d, d, m)$ 进行参数的精估计, 并与原模型 $\text{ARMA}(n, m)$ 通过 F -检验来决定取舍。

ii) 如果已拟合得的 $\text{ARMA}(n, m)$ 模型中, $\varphi(B)$ 含有靠近单位圆周的成对共轭复根, 例如 $\varphi(B) = \varphi^*(B)(1 - \lambda_1^{-1} B)(1 - \lambda_2^{-1} B)$ $\lambda_1 = \bar{\lambda}_2$, $|\lambda_1| = |\lambda_2| \approx 1$ 。则可利用 187 页的表 4.4, 找出与 $(1 - \lambda_1^{-1} B)(1 - \lambda_2^{-1} B)$ 接近的算子多项式 $(1 - 2B + B^2)$, 模型中其余参数需要重新估计, 并通过 F -检验来决定是否可用后者代替前者。若可代替, 则不仅简化了模型, 而且还找出了模型的隐含周期。

iii) 如果在参数 $\hat{\varphi}_i, 1 \leq i \leq n$ 或 $\hat{\theta}_j, 1 \leq j \leq m$ 中, 有一些值很小, 且它们的置信区间也包含零, 那么, 可以用取消这些小参数后所得的相应疏系数形式来拟合数据, 建立简化的疏系数模型或季节性乘积模型。

以上建模步骤简略地由框图 5.4 表出。

将本节介绍的建模方法与 § 1.1 进行比较, 可以看出, 它们在建模手段上是各有特点的。前者是通过预处理实现数据平稳化, 再以相关分析来选择模型形式; 后者是先对数据建立 ARMA($n, n-1$) 模型, 再通过对系统特性 (特征多项式根在单位圆上的分布) 的分析, 进一步简化模型形式。简而言之, 一个是先处理, 后建模, 一个是先建模, 后处理。前者我们简称为相关法, 后者简称为系统法。

§ 2.4 实例

本节举几个实例, 具体说明上述建模步骤, 并和 § 1 中介绍的建模方法进行比较。

1. 太阳黑子的活动: 第三章 § 3.3 已列出了 1749—1924 年每年的太阳黑子活动数据。为了寻求对它适用的模型, 我们从 ARMA(2,1) 开始, 以 2 为步长由低至高进行拟合。下面给出 ARMA(2,1) 和 ARMA(4,3) 模型参数估计的初值和终值 (95% 的置信区间上下限写在估计参数后面的括弧内)。

i) ARMA(2,1) 模型: 初始值

$\varphi_1 = 1.49$	$\varphi_2 = -0.78$	$\theta_1 = 0.22$
终值		95% 置信区间
$\varphi_1 = 1.41$		(1.25 ~ 1.57)
$\varphi_2 = -0.71$		(-0.85 ~ -0.57)
$\theta_1 = 0.136$		(-0.09 ~ 0.36)

残差平方和 $R_{ss} = 40788.00$

ii) ARMA(4,3) 模型: 初始值

$\varphi_1 = 0.7967$	$\theta_1 = -0.4845$
$\varphi_2 = -0.2231$	$\theta_2 = -0.3391$




图 5.4 系统法建模的程序框图

$$\varphi_3 = 0.2768$$

$$\theta_3 = 0.2652$$

$$\varphi_4 = -0.3785$$

终值

$$\varphi_1 = 1.226$$

$$(-0.291 \sim 2.823)$$

$$\varphi_2 = -0.837$$

$$(-3.050 \sim 1.379)$$

$$\varphi_3 = 0.392$$

$$(-1.616 \sim 2.400)$$

$$\varphi_4 = -0.254 \quad (-1.277 \sim 0.769)$$

$$\theta_1 = -0.035 \quad (-1.590 \sim 1.520)$$

$$\theta_2 = -0.336 \quad (-1.730 \sim 1.058)$$

$$\theta_3 = 0.112 \quad (-0.145 \sim 0.369)$$

残差平方和 $R_{ss} = 39624.58$

由上列数据可见, ARMA(4,3)模型的残差平方和小于 ARMA(2,1)模型。进一步用 F 准则检验如下

$$A_1 = 40788.00 \quad A_0 = 39624.58$$

$$N = 176 \quad s = 4 \quad r = n + m + 1 = 8 (\text{包括均值 } \hat{\mu})$$

$$F = \frac{A_1 - A_0}{s} \bigg/ \frac{A_0}{N - r} = \frac{40788.00 - 39624.58}{4} \bigg/ \frac{39624.58}{176 - 8} = 1.23$$

查 F -分布表, $F_{0.05}(4, \infty) = 2.37$, 因此, F -检验结果不显著, 模型无需超出 ARMA(2,1)。

iii) AR(2)模型, 检查 ARMA(2,1)模型的参数, 发现 θ_1 很小, 且置信区间包含零。如果舍弃滑动平均参数 θ_1 而拟合 AR(2)模型, 其结果为

参数	95%置信区间
$\varphi_1 = 1.32$	$(1.210 \sim 1.430)$
$\varphi_2 = -0.63$	$(-0.764 \sim -0.496)$

残差平方和 $R_{ss} = 41173.35$

用 F -准则对 ARMA(2,1)和 AR(2)模型进行检验, 得

$$A_1 = 41173.35 \quad A_0 = 40788.00$$

$$N = 176 \quad r = 4 \quad s = 1$$

$$F = \frac{41173.35 - 40788.00}{1} \bigg/ \frac{40788.00}{176 - 4} = 1.62$$

而 $F(1, \infty) = 3.84$ 。计算结果表明, F -检验不显著, 而且 AR(2)模型参数 φ_2 的置信区间不包含零, 因此, 用 AR(2)模型拟合太阳黑子活动数据是适宜的。

表 5.8 给出了太阳黑子序列建模的计算机输出结果。

2. 机械震动数据的建模: 表 5.9 列出了质块-弹簧-阻尼器机械震动系统响应的 130 个观测数据。根据建模方案, 依次拟合了

表 5.8 太阳黑子序列建模的计算机输出

参 数	ARMA 的阶			
	(2,1)	(4,3)	(1,0)	(2,0)
ϕ_1	$1.41 \pm 0.16^*$	1.27 ± 1.16	0.81 ± 0.09	1.32 ± 0.11
ϕ_2	-0.71 ± 0.14	-0.84 ± 2.22		-0.63 ± 0.14
ϕ_3		0.39 ± 2.01		
ϕ_4		-0.25 ± 1.02		
θ_1	0.14 ± 0.23	-0.04 ± 1.56		
θ_2		-0.34 ± 1.39		
θ_3		0.11 ± 0.26		
$\hat{\mu}$	44.8 ± 6.6	44.4 ± 6.8	44.7 ± 5.4	44.7 ± 7.4
残差平方和	40788.00	39624.58	71577.86	41173.35

适用的模型是 ARMA(2,0)

* (±)后的值为 $1.96 \times$ 参数估计的标准差

ARMA(2,1), ARMA(4,3), ARMA(6,5)和 ARMA(8,7)模型。因为较高阶的模型残差平方和的减少是显著的,由 F -检验判定, ARMA(6,5)模型是适用于机械震动数据的,详细结果在表 5.10 中给出。

表 5.9 质块-弹簧-阻尼器机械震动系统响应的数据

30.0	28.0	25.0	24.0	23.0	21.0	20.0	22.0	24.0	27.0
30.0	31.0	34.0	37.0	33.0	28.0	25.0	23.0	21.0	19.0
18.0	17.0	16.0	17.0	18.5	22.0	29.0	32.6	32.0	30.0
25.0	20.0	17.0	14.0	13.0	17.0	22.0	27.0	33.0	30.0
21.0	15.0	12.0	10.0	9.0	8.0	6.0	8.0	10.0	12.0
15.0	16.0	16.5	15.0	11.0	15.0	7.0	4.0	3.0	7.0
15.5	22.0	30.0	40.0	40.0	39.0	38.0	35.0	30.0	25.0
20.0	18.0	20.0	22.5	27.0	32.0	32.5	33.0	32.0	30.0
25.5	23.3	23.3	24.0	27.0	31.5	35.0	36.0	34.0	30.5
29.0	25.0	20.0	19.0	21.0	23.5	25.0	32.5	36.0	37.5
38.0	38.0	33.0	29.5	28.0	28.0	30.0	30.5	30.0	30.0
28.0	25.0	23.0	24.5	27.0	31.0	34.0	33.0	25.0	16.0
13.0	14.0	17.0	22.0	19.0	32.0	30.0	26.0	24.0	24.0

共 130 个观测值

表 5.10 机械震动建模的计算机输出

参 数	ARMA 的阶				
	(2,1)	(4,3)	(6,5)	(8,7)	(1,0)
ϕ_1	1.40 ± 0.17	0.66 ± 0.15	1.98 ± 0.23	1.68 ± 0.50	0.82 ± 0.07
ϕ_2	-0.59 ± 0.16	-0.41 ± 0.11	-2.20 ± 0.38	-1.23 ± 0.52	
ϕ_3		0.92 ± 0.07	2.04 ± 0.36	0.91 ± 0.33	
ϕ_4		-0.66 ± 0.16	-2.15 ± 0.34	-1.06 ± 0.44	
ϕ_5			1.56 ± 0.36	0.51 ± 0.45	
ϕ_6			-0.50 ± 0.23	0.52 ± 0.48	
ϕ_7				-0.64 ± 0.33	
ϕ_8				0.23 ± 0.25	
θ_1	-0.55 ± 0.17	-1.36 ± 0.21	0.00 ± 0.23	-0.27 ± 0.53	
θ_2		-1.53 ± 0.20	-0.73 ± 0.15	-0.23 ± 0.63	
θ_3		-0.59 ± 0.21	-0.08 ± 0.19	-0.16 ± 0.66	
θ_4			-0.72 ± 0.15	-0.21 ± 0.45	
θ_5			-0.62 ± 0.22	0.34 ± 0.46	
θ_6				0.35 ± 0.54	
θ_7				0.40 ± 0.37	
$\hat{\mu}$	24.1 ± 2.3	25.3 ± 1.6	22.33 ± 2.3	24.4 ± 5.0	27.0 ± 5.3
Rss	535.95	403.77	372.94	407.32	1808.23

适用的模型是 ARMA(6,5)

3. 国际航空客票的系统法建模：在 § 1.2 例 3 中，已将用对数形式表示的 1949 至 1960 年各月的航空客票数据用相关法进行了建模和分析。现在，我们对这组数据用系统法来建立模型。

用 $\text{ARMA}(2n, 2n-1)$ 模型逐渐增加阶数进行拟合，直到 $n=7$ ，即 $\text{ARMA}(14, 13)$ 模型时，可以得到显著减小的残差平方和。模型 $\text{ARMA}(14, 13)$ 的参数为

$$\begin{array}{lll} \varphi_1 = 0.9371 & \varphi_2 = -0.1206 & \varphi_3 = 0.1224 \\ \varphi_4 = -0.0625 & \varphi_5 = 0.0657 & \varphi_6 = -0.0620 \\ \varphi_7 = 0.0403 & \varphi_8 = -0.0773 & \varphi_9 = 0.0655 \\ \varphi_{10} = -0.0088 & \varphi_{11} = -0.0061 & \varphi_{12} = 0.9854 \\ \varphi_{13} = -0.8756 & \varphi_{14} = -0.0013 & \\ \theta_1 = 0.4368 & \theta_2 = -0.2508 & \theta_3 = 0.1268 \\ \theta_4 = -0.1760 & \theta_5 = -0.2653 & \theta_6 = 0.0954 \\ \theta_7 = -0.2079 & \theta_8 = -0.3031 & \theta_9 = -0.0365 \\ \theta_{10} = -0.0068 & \theta_{11} = -0.0940 & \theta_{12} = 1.1771 \\ \theta_{13} = -0.3041 & & \end{array}$$

残差平方和 $R_{ss} = 0.085878$

由上结果可见， $\text{ARMA}(14, 13)$ 模型的参数 φ_{14} 非常小 ($\varphi_{14} = -0.0013$)，因此，去掉 φ_{14} ，用 $\text{ARMA}(13, 13)$ 模型拟合数据，得模型参数为

$$\begin{array}{lll} \varphi_1 = 0.94297 & \varphi_2 = -0.06410 & \varphi_3 = 0.05856 \\ \varphi_4 = -0.0683 & \varphi_5 = 0.0718 & \varphi_6 = -0.0261 \\ \varphi_7 = 0.0076 & \varphi_8 = -0.0290 & \varphi_9 = 0.02329 \\ \varphi_{10} = 0.0414 & \varphi_{11} = -0.0311 & \varphi_{12} = 0.9824 \\ \varphi_{13} = -0.9066 & & \\ \theta_1 = 0.5278 & \theta_2 = -0.3029 & \theta_3 = 0.0451 \\ \theta_4 = -0.0358 & \theta_5 = -0.2244 & \theta_6 = -0.2142 \\ \theta_7 = -0.02812 & \theta_8 = -0.1295 & \theta_9 = -0.1418 \\ \theta_{10} = 0.0040 & \theta_{11} = -0.0178 & \theta_{12} = 1.1862 \\ \theta_{13} = -0.3850 & & \end{array}$$

残差平方和 $Rss=0.09102$

运用多项式求根的专用程序, 可以计算出模型自回归部分和滑动平均部分的特征根(见表 5.11 右半部分), 自回归部分的十三个特征根中, 只有一个是接近于 1 的实根, 其余的是六对接近于单位圆周的共轭复根。将它们在平面上的坐标值与单位圆上 12 等分的各点列表比较如下

由表 5.11 不难看出, 这 12 个复根似乎可由算子 $1-B^{12}$ 的根去代替, 而第 13 个根 1.0018 又导致算子 $1-B$ 的引入。而且 ARMA(13, 13) 模型的 13 个自回归参数的估计值中, 除了 φ_1 , φ_{12} , φ_{13} 接近于 1 比较大外, 其余都很接近于零。这和算子 $(1-B)(1-B^{12})$ 中相应的参数值是很相近的。

模型的滑动平均部分中, 前 12 个根也接近于单位根, 但不如自回归根接近得好, 因而这部分不妨用算子 $(1-\Theta_1 B^{12})$ 来替代。注




图 5.5 $1-B^{12}$ 算子在单位圆上特征根的位置

表 5.11 理论的和估计的特征根(航运数据)

理 论 的 根			估 计		的 根			
j	位 置	相 角	值	周 期	自 回 归 部 分		滑 动 平 均 部 分	
					值	周 期	值	周 期
0	R_0	0°	$e^0=1.00\pm i0.00$	/	$0.9154\pm i0.00$	/	$0.9187\pm i0.00$	/
1	R_1	30°	$e^{\pm\frac{42\pi}{12}}=0.866\pm i0.5$	12	$0.8659\pm i0.5049$	11.903	$0.9320\pm i0.5331$	12.093
2	R_2	60°	$e^{\pm\frac{84\pi}{12}}=0.5\pm i0.866$	6	$0.4977\pm i0.8708$	5.975	$0.5144\pm i0.8822$	6.025
3	R_3	90°	$e^{\pm\frac{126\pi}{12}}=0.0\pm i1.00$	4	$0.0015\pm i0.9927$	4.004	$0.0012\pm i1.041$	4.003
4	R_4	120°	$e^{\pm\frac{168\pi}{12}}=-0.5\pm i0.866$	3	$-0.4969\pm i0.8690$	3.006	$-0.4597\pm i0.8821$	3.063
5	R_5	150°	$e^{\pm\frac{210\pi}{12}}=-0.866\pm i0.5$	2.5	$-0.8622\pm i0.5105$	2.410	$-0.8540\pm i0.51451$	2.417
6	R_6	180°	$e^{\pm\frac{252\pi}{12}}=-1.00\pm i0.00$	/	$-0.9862\pm i0.00$	/	$-0.9867\pm i0.00$	/
					$1.0018\pm i0.00$	/	$0.3280\pm i0.00$	
建议的算子					$(1-B)(1-B^{12})$		$(1-\theta_1 B)(1-\theta_{12} B^{12})$	

意,这里不能再用算子 $(1-B^{12})$,这不仅是因为相应的12个根和单位圆上的理论分布有明显差别,更主要的是因为如果仍用 $(1-B^{12})$,就会导致在模型两边的因子 $(1-B^{12})$ 相消,而变成了ARMA(1,1)模型,这显然不能反映实际。

综上所述,由模型 ARMA(13,13)的参数和特征根分析,我们进一步得到了和 § 1.2 例 3 完全相同的模型形式

$$(1-B)(1-B^{12})x_t = (1-\theta_1 B)(1-\Theta_1 B^{12})a_t$$

模型参数估计值为

$$\theta_1 = 0.40 \pm 0.08 \quad \Theta_1 = 0.61 \pm 0.07$$

$$R_{ss} = 0.18252$$

由此可见,采用这种先建模后简化的手法,也可与先平稳化后建模导出一致的模型形式。

进一步,对这种简化模型与 ARMA(13,13)模型运用 F -准则进行比较,得

$$F = \frac{0.18252 - 0.09102}{(13+13)-2} \bigg/ \frac{0.18252}{144-(13+13)} \cong 2.465$$

然而

$$F_{0.05}(24,120) \cong 1.61$$

$$F_{0.01}(24,120) \cong 1.95$$

因此,这种简化后的模型并不见得是适宜的。其实 ARMA(13,13)模型除了因阶数较高使计算量相应有所增加外,并不会给参数估计与预报等带来什么困难。

本章下节,我们还将对这组顾客机票的原始数据进行更细致的分析,找出其蕴含的确定性趋势,对数据建立叠合模型。

4. 对零售和批发价格指数的建模:图 5.6 和图 5.7 给出了美国从 1953 年 7 月至 1970 年 4 月的每月零售价格指数(CPI)和批发价格指数(WPI)的曲线。对这两组数据用系统法建模,表 5.12~5.15 列出了建模的结果和分析。可以看出,在 5%显著水平上求到的 ARMA(4,3)模型是适用于 CPI 的,而 AR(1)模型适用于 WPI。




图 5.6 每月的美国零售价格指数(CPI)(示意图)




图 5.7 每月的美国批发价格指数(WPI)(示意图)

为了对 CPI 得到一个比较简单的模型,我们注意到在表 5.13 中,ARMA(4,3)模型的两个实根是接近于 1 的,这说明有利用算子 $\nabla = 1 - B$ 或 ∇^2 的可能性。引入 ∇ 和 ∇^2 后估计的结果列于表

5.12。表中的 F -检验结果表明,我们可以用 1 代替 0.9118,但不能用 1 代替另一个根 1.0145,因为由模型 ARMA(4, 3) 变为 ARIMA(2,2,3)时,平方和的增加是显著的。因此,对于 CPI,最终的简化模型是 ARIMA(3,1,3)。

CPI 数据的 ARMA(4,3)模型中,有特征根 1.0145, WPI 数据的模型 AR(1)中,有特征根 1.015,由于这两个根都是模大于 1,使得拟合到的模型不可能稳定,因此,序列本身是非平稳的。由图 5.6 与图 5.7 也可看出,这两组数据都存在明显的指数增长趋

表 5.12 对零售价格指数的建模

参 数	ARMA 模 型 的 阶 数				
	(2,1)	(4,3)	(6,5)	$\nabla(3,3)$	$\nabla^1(2,3)$
ϕ_1	1.970 ± 0.088	1.569 ± 0.142	1.322 ± 2.121	0.656 ± 0.069	-0.389 ± 0.134
ϕ_2	-0.969 ± 0.088	-1.174 ± 0.196	0.983 ± 0.801	-0.569 ± 0.090	-0.892 ± 0.790
ϕ_3		1.473 ± 0.190	1.539 ± 0.840	0.939 ± 0.068	
ϕ_4		-0.866 ± 0.136	-0.754 ± 0.538		
ϕ_5			0.101 ± 0.919		
ϕ_6			-0.222 ± 1.720		
θ_1	0.852 ± 0.145	0.352 ± 0.181	0.145 ± 1.342	0.443 ± 0.097	0.354 ± 0.132
θ_2		-0.662 ± 0.050	-0.789 ± 0.879	-0.624 ± 0.033	-0.585 ± 0.114
θ_3		0.785 ± 0.138	0.794 ± 0.397	0.876 ± 0.069	0.782 ± 0.097
θ_4			0.052 ± 0.338		
θ_5			0.231 ± 1.158		
均 值	93.48 ± 0.37	93.48 ± 0.34	93.51 ± 0.34	0.018 ± 0.20	0.004 ± 0.005
Rss	7.3413	6.9182	6.9073	6.9904	8.1143
F		2.95	0.074	2.02*	16.68*

适用的模型是 ARMA(4,3)

* 和 ARMA(4,3) 相比较, $\nabla^1(3,3) = \text{ARIMA}(3,i,3)$, $i=1,2$.

势。下一节我们将用带确定性趋势部分的叠合模型来描述它们，并对两种模型进行比较。

表 5.13 CPI 数据 ARMA 模型的特征根

根	ARMA 模型的阶数				
	(2,1)	(4,3)	(6,5)	$\nabla(3,3)$	$\nabla^2(2,3)$
λ_1	0.9537	0.9118	0.9502		
λ_2	1.0158	1.0145	1.0141	1.0116	
λ_3, λ_4		$-0.1784 \pm i0.9508$	$-0.1490 \pm i0.4728$	$-0.1777 \pm i0.9473$	$-0.1946 \pm i0.9239$
λ_5, λ_6			$0.1731 \pm i0.9515$		
ν_1	0.8514	0.7839	0.8414	0.8752	0.8140
ν_2, ν_3		$-0.2167 \pm i0.9768$	$-0.2181 \pm i0.9733$	$-0.2160 \pm i0.9733$	$-0.2310 \pm i0.9523$
ν_4, ν_5			$-0.1316 \pm i0.5057$		

表 5.14 批发价格指数(WPI)的建模

参 数	ARMA 模型的阶数		
	(1,0)	(2,1)	(4,3)
ϕ_1	1.015 ± 0.005	1.948 ± 0.200	1.524 ± 0.176
ϕ_2		-0.947 ± 0.283	-1.101 ± 0.190
ϕ_3			1.593 ± 0.137
ϕ_4			-0.924 ± 0.161
θ_1			0.433 ± 0.276
θ_2			-0.582 ± 0.155
θ_3			0.859 ± 0.207
均 值	93.48 ± 0.67	93.50 ± 0.66	93.53 ± 0.64
Rss	23.153	22.545	22.355
F		2.656	0.410

适用的模型是 ARMA(1,0)

表 5.15 WPI 数据 ARMA 模型的特征根

根	模 型 阶 数		
	(1,0)	(2,1)	(4,3)
λ_1	1.015	0.934	0.933
λ_2		1.014	1.013
λ_3, λ_4			$0.211 \pm i 0.966$
ν_1		0.879	0.880
ν_2, ν_3			$-0.223 \pm i 0.962$

§ 3 用叠合模型对动态数据建模的步骤和实例

第四章 § 3 中, 我们对于含有确定性分量和平稳随机分量的数据引入了叠合模型 (见 (4.3.6) 式) 并简单介绍了建模的大致步骤。本节我们结合两个实例, 具体介绍这类模型的建模程序。

1. 国际航线旅客数据的建模: 对于这类数据的对数表示, 我们已在 § 1 和 § 2 中进行过讨论, 本节将对数据本身直接分析, 并建立叠合模型。

图 5.8 绘出了这段数据曲线。由图可见, 数据本身显示出一个有规律的周期性趋势, 每年七、八月份出现一次大的峰值, 三月份出现一次较小的峰值。此外还存在总的增长趋势, 所有周期性趋向都迭加在增长趋势上, 因此可用叠合模型 (4.3.6) 式来描述它。

首先拟合模型

$$y_t = R_1 e^{r_1 t} + e_t \quad (5.3.1)$$

参数 R_1 和 r_1 的初值可由数据曲线 (见图 5.8) 来求得。

由 (5.3.1) 式得, 当 $t=0$ 时, 应有

$$R_1 \cong y_0$$

从图 5.8 可见, R_1 约为 130。




图 5.8 国际航线旅客每月总计数据(示意图)

又令 $t = \frac{1}{r_1}$, 则

$$\frac{y_1}{r_1} \cong R_1 e \approx 130 \times 2.7 = 351$$

由此结果并对照图 5.8, 可推算得

$$t = \frac{1}{r_1} \cong 100$$

从而

$$r_1 = 0.01$$

从以上所获得的初值出发, 可计算得参数 R_1 和 r_1 的非线性最小二乘估计值, 列在表 5.16 的第二列中。

由模型(5.3.1)算得的残差 $\{e_i\}$ 作出图 5.9。由图可见, 原始数据中指数增长趋势已分离出来, 而只剩下振幅不断增大的季节性趋势, 因此实指数项只需要一项就够了。

在模型(5.3.1)的残量 e_i 中, 再分离出一项季节性趋势, 考虑模型为

$$y_t = R_1 e^{r_1 t} + B_1 e^{b_1 t} (c_1 \sin \omega t + \sqrt{1 - c_1^2} \cos \omega t) + \varepsilon_t^{(1)}$$

其中

表 5.16 国际航线数据的叠合模型

(i, n, m)	$(0, 0, 0)$	$(1, 0, 0)$	$(2, 0, 0)$	$(3, 0, 0)$	$(4, 0, 0)$	$(5, 0, 0)$	$(5, 3, 3)$
参数总数 $2L + 3K + n + m$	2	5	8	11	14	17	23
参 数 (1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
R_1	130.83 ± 10.14	131.07 ± 5.85	130.43 ± 4.03	130.63 ± 3.71	130.63 ± 3.51	130.62 ± 3.36	127.48 ± 0.45
r_1	0.0095 ± 0.007	0.0095 ± 0.005	0.0095 ± 0.003	0.0095 ± 0.002	0.0095 ± 0.002	0.0095 ± 0.003	0.0096 ± 0.0007
B_1		-14.83 ± 6.56	-16.16 ± 4.83	-15.78 ± 4.36	-15.77 ± 4.132	-15.79 ± 3.96	-15.89 ± 4.063
b_1		0.0136 ± 0.0039	0.0126 ± 0.0027	0.0129 ± 0.0025	0.0129 ± 0.0024	0.0128 ± 0.0022	0.0128 ± 0.0020
c_1		0.426 ± 0.106	0.433 ± 0.076	0.433 ± 0.069	0.433 ± 0.065	0.434 ± 0.063	0.436 ± 0.059
B_2			-8.88 ± 4.961	-9.31 ± 4.708	-9.369 ± 4.49	-9.414 ± 4.30	-9.503 ± 2.40
b_2			0.0121 ± 0.0059	0.0115 ± 0.0046	0.0114 ± 0.0068	0.0113 ± 0.0041	0.0112 ± 0.0022
c_2			-0.997 ± 0.016	-0.9996 ± 0.015	-0.996 ± 0.12	-0.996 ± 0.012	-0.996 ± 0.006
B_3				4.529 ± 5.225	4.267 ± 4.76	4.187 ± 4.50	3.914 ± 1.652
b_3				0.0095 ± 0.0107	0.0103 ± 0.103	0.0105 ± 0.0098	0.0113 ± 0.0039
c_3				-0.431 ± 0.340	-0.433 ± 0.316	-0.432 ± 0.300	-0.411 ± 0.122
B_4					4.320 ± 5.536	4.379 ± 5.328	5.357 ± 2.642
b_4					0.0072 ± 0.0124	0.0071 ± 0.0118	-0.006 ± 0.0472

续表

(i, n, m)	(0,0,0)	(1,0,0)	(2,0,0)	(3,0,0)	(4,0,0)	(5,0,0)	(5,3,3)
c_4					0.912±0.191	0.903±0.191	0.423±0.425
B_5						2.289±4.114	2.383±1.785
b_5						1.0121±0.0103	0.0115±0.0068
e_5						0.995±0.049	0.994±0.025
ϕ_1							-0.087±0.163
ϕ_2							-0.140±0.110
ϕ_3							0.892±0.112
θ_1							-0.716±0.234
θ_2							-0.995±0.227
θ_3							0.180±0.256
Γ_{AS}	296.250	95.783	44.753	36.897	32.354	28.908	8.091

(均值 $\hat{\rho}=280.3$ 方差 $\hat{\sigma}_\rho^2=14.392$)

模型形式

$$Y_t = \sum_{j=1}^L R_j e^{j\omega t} + \sum_{j=1}^K B_j e^{j\omega t} [c_j \sin(j\omega t) + \sqrt{1-c_j^2} \cos(j\omega t)] + x_t$$

$$x_t = \sum_{i=1}^n \varphi_i x_{t-i} + \sum_{i=1}^m \theta_i a_{t-i} + a_t = e_t, \quad L=1, K \leq 5, n \leq 3, m \leq 3$$

$$\omega = \frac{2\pi}{12} \quad \text{为基波频率(每月弧度)}$$

式中各参数初值可由图 5.9 的残差曲线粗略地求得

$$\text{取 } t=0 \quad \text{得 } B_1 \sqrt{1-c_1^2} \cong 17$$

$$t=3 \quad B_1 e^{3b_1} c_1 \cong 5$$

$$t=6 \quad B_1 e^{6b_1} \sqrt{1-c_1^2} \cong 14$$

解得

$$B_1 \cong -20 \quad b_1 \cong 0.01 \quad c_1 \cong 0.7$$

由这些初值出发, 仍用非线性最小二乘法估计出参数值, 列于表 5.16 第三列中。这时, 残差平方和由 296.25 下降到 95.783。




图 5.9 根据指数模型得出的残差曲线

从 $e_t^{(1)}$ 中再分离出第二项季节性趋势, 即拟合模型

$$y_t = R_1 e^{r_1 t} + \sum_{j=1}^2 B_j e^{b_j t} (c_j \sin j \omega t + \sqrt{1-c_j^2} \cos j \omega t) + e_t^{(2)} \quad (5.3.2)$$

重复上述过程,直到 y_t 分解出如下模型

$$y_t = R_1 e^{rt} + \sum_{j=1}^5 B_j e^{i\omega_j t} (c_j \sin j\omega t + \sqrt{1-c_j^2} \cos j\omega t) + x_t \quad (5.3.3)$$

各步估计出的参数值都列于表 5.16 中。

在模型(5.3.3)拟合得后,再增加季节性趋势项时,残差平方和不再明显降低,即 F -检验不显著了。至此为止,确定性部分基本分离完毕。其中包含一个指数增长趋势项和 5 个周期季节性趋势项;周期分别为一年,半年,四个月,三个月和两个半月。图 5.10 表明,模型的确定性部分是适用的。




图 5.10 连续确定性趋向和实际数据的比较

对剩余的随机部分 $\{x_t\}$ 用 § 2 中介绍的系统法建模,拟合得 ARMA(3,3)模型

$$x_t = \varphi_1 x_{t-1} + \varphi_2 x_{t-2} + \varphi_3 x_{t-3} + a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \theta_3 a_{t-3} \quad (5.3.4)$$

最后,以模型(5.3.3)和(5.3.4) 分别拟合时所得的结果为初值,对(5.3.3)与(5.3.4)的叠合模型统一进行参数估计,所得结果列于表 5.16 中最后一列。由表中可见,当引入随机部分的 ARMA(3,3)模型后,残差平方和又从 28.908 下降到 8.091。

由本例可见,建立这类叠合模型时,要不断参考残差分布图。这类建模方法对于处理规律复杂的数据来说,仍然是步骤明确可以实现的。

2. 零售和批发价格指数:在§ 2 例 4 的末尾,我们已经指出,零售价和批发价显然存在着指数趋向,最好对它们拟合叠合模型。下面,我们分别对这两组数据建立如下形式的模型

$$y_t = A_0 + A_1 e^{b_1 t} + e_t \quad (5.3.5)$$

i) 零售价格指数:由图 5.6 找出 CPI 数据模型 (5.3.5) 中各参数的初值,用非线性最小二乘法得到参数估计值和 95% 的置信区间

$$\begin{aligned} A_0 &= 88.71377 \pm 1.56904 \\ A_1 &= 5.22648 \pm 1.11279 \\ b_1 &= 0.01022 \pm 0.00095 \end{aligned} \quad (5.3.6)$$

根据这一拟合结果,计算出 CPI 数据的残差序列 $\{e_t\}$,其曲线如图 5.11 所示。从图上已看不出还有附加的指数或季节的确定性趋向。而且再增加两个指数项进行拟合的结果也表明,残差平方和没有显著的改变。因此,对 CPI 数据的指数趋势,用一个指数项来拟合就足够了。

对图 5.11 中的残差 $\{e_t\}$ 应用 § 2 中介绍的系统法建模,结果列入表 5.17 中。在 5% 置信水平上认为 ARMA(6, 5)模型是适用的。模型自回归部分有三对共轭复根

$$\begin{aligned} \lambda_1, \lambda_2 &= -0.3792 \pm i 0.8438 \\ \lambda_3, \lambda_4 &= 0.0085 \pm i 1.0027 \\ \lambda_5, \lambda_6 &= 0.9990 \pm i 0.0528 \end{aligned} \quad (5.3.7)$$

利用第 4 章(4.2.14)式可以算出,上三对共轭复根中,第一对显示出周期 $s=3.18$ 月的阻尼振荡;第二对复根和 $\pm i$ 很接近,因




图 5.11 由一项指数项得到的 CPI 数据的残差

而显示出 4 个月的季节性周期，剩余的根 $0.9990 \pm i0.0528$ 给出了 118.99 个月的周期。图 5.11 中的曲线也显示出了上述规律。

以 (5.3.6) 式的结果与表 5.17 中 ARMA(6, 5) 参数作为初值，对叠合模型

$$y_t = A_0 + A_1 e^{b_1 t} + \text{ARMA}(6, 5) \quad (5.3.8)$$

中的参数进行非线性最小二乘估计，所得结果列于表 5.18 中。

ii) 批发价格指数：由图 5.7 找出 WPI 数据模型 (5.3.5) 中

表 5.17 CPI 残差的 ARMA 模型

参数	ARMA 模 型 阶 数				
	(1,0)	(2,1)	(4,3)	(6,5)	(8,7)
ϕ_1	1.098 ± 0.018	1.991 ± 0.42	1.289 ± 0.083	1.256 ± 0.089	2.967 ± 0.103
ϕ_2		-0.936 ± 0.541	-0.496 ± 0.146	-1.367 ± 0.150	-4.479 ± 0.306
ϕ_3			0.946 ± 0.151	2.203 ± 0.178	5.747 ± 0.498
ϕ_4			-0.837 ± 0.084	-1.215 ± 0.175	-6.326 ± 0.623
ϕ_5				0.971 ± 0.146	5.227 ± 0.615
ϕ_6				-0.861 ± 0.084	-3.749 ± 0.477
ϕ_7					2.466 ± 0.285
ϕ_8					-0.858 ± 0.093
θ_1		0.907 ± 0.087	0.223 ± 0.014	0.145 ± 0.095	1.849 ± 0.125
θ_2			-0.220 ± 0.034	-1.275 ± 0.078	-2.467 ± 0.174
θ_3			1.036 ± 0.009	1.082 ± 0.155	3.373 ± 0.239
θ_4				-0.294 ± 0.080	-3.344 ± 0.282
θ_5				0.932 ± 0.093	2.443 ± 0.235
θ_6					-1.864 ± 0.172
θ_7					0.879 ± 0.124
Rss	8.443	7.183	6.599	6.179	5.978
F		17.37	4.29	3.23	1.56

适用的模型是 ARMA(6,5)

各参数的初值,用非线性最小二乘法得到参数估计值和 95% 的置信区间

$$\begin{aligned}
 A_0 &= 87.09220 \pm 4.93165 \\
 A_1 &= 6.99470 \pm 4.36919 \\
 b_1 &= 0.00598 \pm 0.00223
 \end{aligned}
 \tag{5.3.9}$$

模型残差曲线如图 5.12 所示。图中看不出有附加的确定性趋向,

表 5.18 CPI 叠合模型

确定性部分的参数	随 机 部 分			
	自 回 归		滑 动 平 均	
	参 数	根	参 数	根
$A_0:$ 99.94 ± 3.27	$\phi_1:$ 1.26 ± 0.085	$-0.377 \pm$ 10.844	$\theta_1:$ 0.242 ± 0.068	1.0315
$A_1:$ 2.803 ± 3.20	$\phi_2:$ -1.37 ± 0.153	0.999 ± 10.053	$\theta_2:$ -1.18 ± 0.072	$-0.399 \pm$ 10.929
$K_1:$ 0.014 ± 0.005	$\phi_3:$ 2.21 ± 0.170	0.008 ± 11.00	$\theta_3:$ 1.28 ± 0.074	0.0045 ± 10.991
	$\phi_4:$ -1.22 ± 0.176		$\theta_4:$ -0.20 ± 0.073	
	$\phi_5:$ 0.97 ± 0.149		$\theta_5:$ 1.04 ± 0.070	
	$\phi_6:$ -0.86 ± 0.085			

残差平方和: 5.804

表 5.19 WPI 残差的 ARMA 模型

参 数	ARMA 模 型 阶 数		
	(1,0)	(2,1)	(4,3)
ϕ_1	0.995 ± 0.025	1.989 ± 0.032	1.997 ± 0.097
ϕ_2		-0.991 ± 0.033	-2.052 ± 0.207
ϕ_3			2.078 ± 0.207
ϕ_4			-1.026 ± 0.096
θ_1		1.039 ± 0.031	1.055 ± 0.101
θ_2			-1.052 ± 0.141
θ_3			1.085 ± 0.106
Rss	22.600	20.336	19.801
F		11.02	1.31

适用模型是 ARMA(2,1)




图 5.12 WPI 数据的一项指数残差

因此在提取了一次指数项的确定性因素后，就可对残差 $\{e_t\}$ 用系统法建模，结果列于表 5.19 和 5.20 中。由表 5.20 可见，ARMA(4,3)模型的两边有一对相同的共轭复根 $0.006 \pm i 1.020$ ，而且这一模型的残差平方和并不比 ARMA(2,1) 的有显著性改善。因此，取 ARMA(2,1) 模型来描述数据的随机部分是合适的。

WPI 序列叠合模型($b_0=0$, 一个指数项, x_t 为 ARMA(2,1))

表 5.20 WPI 残差 ARMA 模型的特征根

根	ARMA 模 型		
	(1,0)	(2,1)	(4,3)
λ_1, λ_2	$0.995 \pm i0.000$	$0.995 \pm i0.042$	$0.006 \pm i1.020$
λ_3, λ_4			$0.992 \pm i0.040$
γ_1		1.039	1.043
γ_2, γ_3			$0.006 \pm i1.019$

表 5.21 WPI 叠合模型

确定性部分的参数	随 机 部 分		
	自 回 归		滑 动 平 均
	参 数	根	参 数
$A_0: 86.62 \pm 12.66$	$\phi_1: 1.98 \pm 0.34$	$0.99 \pm i0.045$	$\phi_1: 1.043 \pm 0.042$
$A_1: 6.59 \pm 12.364$	$\phi_2: -0.98 \pm 0.35$		
$K_1: 0.007 \pm 0.007$			

残差平方和: 19.745

的估计结果列于表 5.21 中。与表 5.19 及(5.3.9)式的结果相比, 虽然确定性部分参数的置信区间较宽一点, 但叠合模型的参数估计值非常接近于分别估计的结果。

比较 CPI 和 WPI 的叠合模型可见, 它们的确定性参数置信区间是重迭的, 并且 WPI 的 ARMA(2,1)模型特征根也在 CPI 的 ARMA(6,5)模型中出现。另一方面, §2.4 例 4 中对这两组数据建立的纯随机模型中, CPI 的 ARMA(4,3)模型有特征根 1.0145, WPI 数据的 AR(1)模型中也有相应的特征根 1.015, 因此, CPI 数据的动态特性包含了 WPI 数据的动态特性。这一结论在直观上也很令人感兴趣, 因为零售价的起落除主要受批发价影响外, 还要和其它一些零售行情有关。例如从模型可分析出 CPI 受到大约三个月和四个月的季节效应的显著影响, 而 WPI 则不然。CPI

对于 WPI 这种依赖关系启发我们应该将它们两个按多元序列一起来建模。

在本节和 §2 中,都对于批发价和零售价数据进行了两种不同的建模处理,自然会产生这样一个问题:究竟应该用哪种模型更合适一些?运用 F -检验可以对此问题进行简单的统计判决。对于 CPI 数据,纯随机模型 ARMA(4,3) 有 8 个参数, R_{ss} 为 6.9182; 而叠合模型(一个指数项加 ARMA(6,5)) 有 14 个参数, R_{ss} 为 5.804。现有 201 个观测值,则 F -检验为

$$F = \frac{6.9182 - 5.804}{5.804} \bigg/ \frac{14 - 8}{201 - 14} \cong 6.2$$

而 $F_{0.05}(6,187) = 2.10$, 因此,叠合模型 R_{ss} 的减少(在 5% 的置信水平上)是显著的。同样,对于 WPI 序列,增加 5 个参数值后, R_{ss} 的减少也是显著的。因此,单纯统计观点得到的结论无疑应该是采用叠合模型要比纯随机模型显著地好。从预报角度看,叠合模型的预报误差要比纯随机模型减少 16%。这是因为一步预报误差就是残差方差 σ_a^2 (详细可见第七章),它和 R_{ss} 的关系为 $\sigma_a^2 = R_{ss}/201$; 纯随机模型的 σ_a^2 为 0.0344, 而组合模型的 σ_a^2 为 0.0289, 对于长期预报,这种减少将会更加显著。

然而,并不应当只根据统计检验来确定模型的选择,还应考虑有关价格特性的经济原理。通过 F -检验虽然支持模型确定性部分的存在,但还要用关于价格特性的知识加以证实。如果对于这两种模型的合理性都能找到理论上的依据,我们就可以应用上面的分析和检验来在它们之间进行选择。

第六章 最小二乘方法及其在 ARMA(p, q)建模中的应用

从前面几章的讨论可知,在 ARMA(p, q)建模中,参数估计通常是采用极大似然方法或最小二乘方法。在第三章中,我们只介绍了正态序列的极大似然估计方法。如果序列 $\{w_t\}$ 分布不服从正态或未知时,采用前面介绍的极大似然法进行参数估计,就缺乏理论根据。况且,通常我们很难确切知道一个序列是什么分布,这种情况下,采用最小二乘估计是最适宜的。

最小二乘方法原理简单,适用范围广,经常用来求解各类带约束条件的最优化问题。本章将介绍如何用最小二乘法估计线性模型 ARMA(p, q)的参数。读者还将从本书最后一章看到,对于非线性模型,最小二乘法更是不可多得的参数估计方法。另外,由于最小二乘法处理对象广泛,具体方法也就比较丰富多样,而且在总原理之下,对于各种不同的函数形式,实现最小二乘方法时还具有各自的特殊性。本章将对此方法的一般原理与几种常用迭代算法,进行比较细致深入的讨论。

§ 1 最小二乘方法的一般原理

§ 1.1 概述

设观测量 y_t 与 L 维向量 x_t 之间具有如下的函数关系

$$y_t = f_t(x_t, \theta) + \varepsilon_t \quad t=1, 2, \dots, N \quad (6.1.1)$$

其中, $\theta = (\theta_1, \theta_2, \dots, \theta_m)^T$ 是待估计的参数, ε_t 是观测误差, f_t 的函数形式已知。

最小二乘方法的问题是,要求从已经观测到的 N 组数据 (x_t^T, y_t) , $t=1, 2, \dots, N$ 出发,对于未知参数 $\theta = (\theta_1, \theta_2, \dots, \theta_m)^T$ 进

行估计,使目标函数(残差平方和)

$$s(\theta) = \sum_{i=1}^N e_i^2 = \sum_{i=1}^N [y_i - f_i(x_i, \theta)]^2 \quad (6.1.2)$$

达到最小。由此可见,这一类参数估计问题实际是带约束条件的最优化问题。

如果用向量形式表示,(6.1.1)式与(6.1.2)式对应地可以表示成

$$y = f(A, \theta) + \epsilon \quad (6.1.3)$$

$$s(\theta) = \epsilon^T \epsilon = \|y - f(A, \theta)\|^2 \quad (6.1.4)$$

其中

$\epsilon = (e_1, e_2, \dots, e_N)^T$, 是 $N \times 1$ 维误差向量;

$A = (x_1, x_2, \dots, x_N)^T$, 是 $N \times L$ 维观测矩阵;

$y = (y_1, y_2, \dots, y_N)^T$, 是另一组 $N \times 1$ 维观测向量, 在统计学中, 通常称为因变量;

$f = (f_1, f_2, \dots, f_N)^T$, 表示 y 与 A 之间的函数依赖关系。

一般情形下, f 与 θ 之间呈非线性关系, 因此, 对于 θ 的估计, 通常需采用非线性最小二乘方法。特殊地, 如果模型(6.1.3)可表示成

$$y = A\theta + \epsilon$$

则称 f 与参数 θ 之间呈线性关系。这种情形对参数 θ 的估计采用线性最小二乘方法。

§ 1.2 线性最小二乘方法

由 § 1.1 已知, 当 f 与 θ 呈线性关系

$$y = A\theta + \epsilon \quad (6.1.5)$$

时, 对参数 θ 可进行线性最小二乘估计。根据(6.1.2)式, 这时估计的残差平方和可表成

$$s(\theta) = \sum_{i=1}^N e_i^2 = \sum_{i=1}^N [y_i - x_i^T \theta]^2 = \|y - A\theta\|^2 \quad (6.1.6)$$

运用第一章 § 1.4 中给出的矩阵对于向量的微分法则, 可得

$$0 = \frac{\partial s(\theta)}{\partial \theta} = -2 A^T (y - A\theta) \quad (6.1.7)$$

从而得 θ 的线性最小二乘估计

$$\hat{\theta} = (A^T A)^{-1} A^T y \quad (6.1.8)$$

由(6.1.7)与(6.1.8)式不难看出,线性最小二乘估计具有以下的一些特点:

1. 式(6.1.7)是关于参数向量 θ 的线性方程,因此,很多解线性方程组的现成的计算方法可以直接应用,参数 θ 的估计值 $\hat{\theta}$ 可解析求得。

2. 式(6.1.8)表示, $\hat{\theta}$ 是观测值 y 的线性函数。

3. 若设误差向量 ε 是零均值的,则 $\hat{\theta}$ 是参数向量 θ 的无偏估计,因为

$$\begin{aligned} E\hat{\theta} &= (A^T A)^{-1} A^T E y = (A^T A)^{-1} A^T E (A\theta + \varepsilon) \\ &= (A^T A)^{-1} (A^T A) E \theta = E \theta \end{aligned}$$

4. 设零均值的误差向量具有协方差阵

$$E \varepsilon \varepsilon^T = \sigma^2 I \quad (\sigma \text{ 为非零实常数})$$

那么,线性最小二乘估计的估计误差方差阵为

$$\begin{aligned} &E[(\hat{\theta} - \theta)(\hat{\theta} - \theta)^T] \\ &= (A^T A)^{-1} A^T E \varepsilon \varepsilon^T A (A^T A)^{-1} \\ &= \sigma^2 (A^T A)^{-1} \end{aligned} \quad (6.1.9)$$

由此可见,第 j 个参数 θ_j 的估计方差 $E(\hat{\theta}_j - \theta_j)^2$ 就是(6.1.9)式右边矩阵对角线上的第 j 个元素 ($1 \leq j \leq m$)。这一关系在估计参数的置信区间时常要用到。

如果将 AR(p)模型表示成如下形式

$$\begin{aligned} w_t &= \varphi_1 w_{t-1} + \varphi_2 w_{t-2} + \cdots + \varphi_p w_{t-p} + a_t \\ t &= 1, 2, \cdots, N \end{aligned} \quad (6.1.10)$$

对照(6.1.1)与(6.1.5)式不难看出,对于 AR(p)的参数 $\varphi_1, \varphi_2, \cdots, \varphi_p$,可以实现线性最小二乘估计。这时,相应地有

$$y = (w_{p+1}, w_{p+2}, \cdots, w_N)^T \quad (6.1.11)$$

$$\theta = (\varphi_1, \varphi_2, \cdots, \varphi_p)^T \quad (6.1.12)$$

$$A = \begin{pmatrix} w_p & w_{p+1} & \cdots & w_{N-1} \\ \vdots & \vdots & & \vdots \\ w_1 & w_2 & \cdots & w_{N-p} \end{pmatrix}^T \quad (6.1.13)$$

$$\theta = (a_{p+1}, a_{p+2}, \cdots, a_N)^T \quad (6.1.14)$$

从而可由(6.1.8)式得到参数 $(\varphi_1, \varphi_2, \cdots, \varphi_p)^T$ 的线性最小二乘估计(具体计算方法在§4.1中讨论)。

§ 1.3 非线性最小二乘方法

对于线性最小二乘估计,由§1.2的讨论可知,残差平方和 $s(\theta)$ 是参数 θ 的二次函数,参数的最小二乘估计归结为求解由二次函数 $s(\theta)$ 求导得到的线性方程。如果 f 不是 θ 的线性函数,则 $s(\theta)$ 一般就不是参数 θ 的二次函数,一般也就不可能将估计值 $\hat{\theta}$ 这样简单直接地表示出来。通常非线性最小二乘方法的计算步骤是,从被估计参数的一组初值出发,使参数依某种规律沿着平方和减小的方向变化,得到参数空间中使平方和值较小的一点,再以此作为新的出发点进行下一步迭代。这种规则的迭代将一直进行到在预先给定的计算精度下平方和不能再下降为止。

对于ARMA(p, q)模型,当滑动平均阶数 q 不为零时,参数 $\theta = (\varphi_1, \varphi_2, \cdots, \varphi_p, \theta_1, \theta_2, \cdots, \theta_q)^T$ 的估计可由非线性最小二乘方法来实现。

将ARMA(p, q)模型表示成

$$w_t = \sum_{j=1}^p \varphi_j w_{t-j} - \sum_{k=1}^q \theta_k a_{t-k} + a_t$$

对照(6.1.1)式,不难得到如下的一组对应关系

$$\begin{aligned} y_t &= w_t, \quad e_t = a_t \\ x_t &= (w_{t-1}, w_{t-2}, \cdots, w_{t-p})^T \\ \theta &= (\varphi_1, \varphi_2, \cdots, \varphi_p, \theta_1, \cdots, \theta_q)^T \end{aligned} \quad (6.1.15)$$

在函数 $f_t(x_t, \theta)$ 的表达式中,出现了不能直接观测到的量 $a_{t-1}, a_{t-2}, \cdots, a_{t-q}$,但它们可以通过ARMA(p, q)模型的逆转形式表示为关于观测量 $\{w_t\}$ 线性而关于参数 θ 非线性的函数关系。

因此, 对于 ARMA(p, q) 模型, 参数 θ 只能用非线性最小二乘方法进行估计(具体计算方法在以下几节中讨论)。

§ 2 参数估计的几种非线性最小二乘迭代方法

当 f_i 关于参数 θ 呈非线性关系时, 对于不同的 f_i , 残差平方和曲面 $s(\theta)$ 的结构繁简差异很大, 对它实现最优化时, 不能简单地仅用某一种方法进行迭代。这里, 我们针对不同的函数类型, 介绍具有不同主要功能的三种迭代方法: 最速下降法, 高斯-牛顿法和阻尼最小二乘法(又称 Levenberg-Marquart 折衷法)。第一种方法适用于在稍偏离解的区域内迭代, 第二种方法在解的邻域内效果较好, 第三种方法是前两种方法的综合。下面, 我们就分别对这三种迭代方法进行讨论。

§ 2.1 最速下降法

设残差平方和曲面 $s(\theta)$ 在参数向量 θ_0 的邻域内具有一阶和二阶连续的偏导数, 记

$$s_e(\theta) \triangleq \left(\frac{\partial s(\theta)}{\partial \theta_1}, \frac{\partial s(\theta)}{\partial \theta_2}, \dots, \frac{\partial s(\theta)}{\partial \theta_m} \right)^T \quad (6.2.1)$$

$$s_{e,e}(\theta) \triangleq \left(\frac{\partial^2 s(\theta)}{\partial \theta_i \partial \theta_j} \right) \quad i, j = 1, 2, \dots, m \quad (6.2.2)$$

并以 $s_e(\theta^0)$ 等表示这些量在 θ^0 处的取值, 例如

$$\frac{\partial s(\theta^0)}{\partial \theta_i} = \frac{\partial s(\theta)}{\partial \theta_i} \Big|_{\theta=\theta^0} \quad \text{等等。}$$

最速下降法的直观思想是, 希望从某一个参数初值点 θ^0 出发, 沿着残差平方和 $s(\theta)$ 在 θ^0 处下降速度最快的方向, 寻找本次迭代的终点, 并以此点作为下次迭代的出发点。可以证明, 在 θ^0 处曲面 $s(\theta^0)$ 的最速下降方向, 恰好就是曲面 $s(\theta)$ 在点 θ_0 处的梯度反方向。因为, 由于约定曲面 $s(\theta)$ 在 θ^0 处具有连续的一阶和二阶偏导数, 故可将曲面在 θ^0 处进行全微分, 舍去高阶无穷小量, 于是得到关于 $s(\theta^0)$ 的近似全微分公式

$$\begin{aligned}
 ds(\theta^0) &= \frac{\partial s(\theta^0)}{\partial \theta_1} d\theta_1^0 + \frac{\partial s(\theta^0)}{\partial \theta_2} d\theta_2^0 + \dots + \frac{\partial s(\theta^0)}{\partial \theta_m} d\theta_m^0 \\
 &= (s,(\theta^0), d\theta^0)
 \end{aligned}$$

$s,(\theta^0)$ 就是 $s(\theta)$ 在 θ^0 处的梯度 $\text{grad } S(\theta^0)$ 。因此上式又可表为

$$(\text{grad } s(\theta^0), d\theta^0)$$

$$= |\text{grad } S(\theta^0)| |d\theta^0| \cos \langle \text{grad } S(\theta^0), d\theta \rangle \quad (6.2.3)$$

曲面 $s(\theta)$ 在 θ^0 处下降的速度, 将和 $\text{grad } S(\theta^0)$ 与 $d\theta^0$ 之间的夹角有关, 显然, 当二者之间夹角为 $\pi(180^\circ)$ 时,

$$\min dS(\theta^0) = -|\text{grad } S(\theta^0)| |d\theta^0| \quad (6.2.4)$$

这就表明, 当 $d\theta^0$ 取梯度 $\text{grad } s(\theta^0)$ 的相反方向时, $s(\theta)$ 在 θ^0 附近下降得最快, 从而得到了我们所希望的结论。

下面, 我们还要论证

$$\text{grad } s(\theta^0) = -2 X^T y^* \quad (6.2.5)$$

其中

$$\begin{aligned}
 X &\triangleq \begin{pmatrix} \frac{\partial f_1}{\partial \theta_1} & \dots & \frac{\partial f_1}{\partial \theta_m} \\ \dots & \dots & \dots \\ \frac{\partial f_N}{\partial \theta_1} & \dots & \frac{\partial f_N}{\partial \theta_m} \end{pmatrix}^{N \times m}, \quad y^* \triangleq \begin{pmatrix} y_1^* \\ y_2^* \\ \vdots \\ y_N^* \end{pmatrix} \\
 y_i^* &\triangleq y_i - f_i(x_i, \theta^0) \quad (6.2.6)
 \end{aligned}$$

这是因为

$$s(\theta) = \sum_{i=1}^N \{y_i - f_i(x_i, \theta)\}^2 = \sum_{i=1}^N y_i^{*2}$$

$$\frac{\partial s(\theta^0)}{\partial \theta_j} = -2 \sum_{i=1}^N \frac{\partial f_i}{\partial \theta_j} y_i^* \Big|_{\theta^0}, \quad j=1, 2, \dots, m$$

根据 $\text{grad } s(\theta)$ 的定义, 将上式表成向量形式, 即可得到 (6.2.5) 式。

根据以上分析, 不难导出最速下降的最小二乘迭代方法。

设迭代初始参数为 θ^0 , 迭代的增量为

$$\Delta \theta = \theta - \theta^0 \quad (6.2.7)$$

θ 为迭代终点。最速下降法应满足

$$\Delta \theta = \lambda_0 X^T y^*, \quad \lambda_0 \geq 0 \quad (6.2.8)$$

其中 λ_0 应使

$$s(\theta^0 + \lambda_0 X^T y^*) = \min_{\lambda \geq 0} S(\theta^0 + \lambda X^T y^*) \quad (6.2.9)$$

这样,就将非线性函数的最优化问题归结成了对于单变量 λ 求极值的问题。在求得了

$$\theta' = \theta^0 + \lambda_0 X^T y^*$$

之后,再以此为下一次迭代初值,重复上述步骤,直到求得 $S(\theta)$ 满足精度要求的最小值为止(即若再继续迭代,则 $\Delta \theta$ 在精度范围内, $s(\theta)$ 的改进可忽略)。

最速下降法的程序实现应按以下步骤进行

- i) 求参数 θ 的初始估计值 $\theta^0 = (\theta_1^0, \theta_2^0, \dots, \theta_m^0)^T$;
- ii) 按公式(6.2.5)计算 $\text{grad } s(\theta^0)$;
- iii) 按公式(6.2.9),用单变量求极值的方法选择 λ ,再由公式(6.2.8)计算出新的参数估计值 θ' 。

§ 2.2 高斯-牛顿法

如果函数 $f_i(x_i, \theta)$ 在 θ^0 附近邻域内具有连续二阶偏导数,那么,将 $f_i(x_i, \theta)$ 在此邻域内近似地看作线性,从而粗略地用线性最小二乘估计方法进行参数的迭代,这就是高斯-牛顿迭代法的直观思想。用数学公式来表示,即为

$$f_i(x_i, \theta) \approx f_i(x_i, \theta^0) + \frac{\partial f_i}{\partial \theta_1} \Delta \theta_1 + \dots + \frac{\partial f_i}{\partial \theta_m} \Delta \theta_m \quad (6.2.10)$$

将此近似式代入

$$s(\theta) = (y - f)^T (y - f) \quad (6.2.11)$$

即得

$$s(\theta) = (y^* - X \Delta \theta)^T (y^* - X \Delta \theta) \quad (6.2.12)$$

其中 y^* 与 X 仍为(6.2.6)所示。

由线性最小二乘原理,对照(6.1.8)式,即得参数 θ' 的迭代公式

$$\Delta \theta = \theta' - \theta^0 = (X^T X)^{-1} X^T y^* \quad (6.2.13)$$

综上所述,高斯-牛顿法在程序实现中的具体步骤为

- i) 求参数 θ 的初始估计 θ^0 ;
- ii) 计算模型在 θ^0 处的雅可比阵

$$X = \left(\frac{\partial f_i}{\partial \theta_j} \right) \Big|_{\theta^0} (i=1, 2, \dots, N; j=1, 2, \dots, m);$$

- iii) 由(6.2.13)算出近似线性最小二乘估计 θ' ;

iv) 以 θ' 作为下次迭代的初值, 重复上述各步, 直到求出合乎精度要求的平方和函数最小值及相应的参数。

§ 2.3 带阻尼的高斯-牛顿法

由前面的介绍可知, 最速下降法与高斯-牛顿法是对象不同、功能各异的两种非线性最小二乘参数估计的迭代方法。具体说来, 最速下降法对曲面性质要求不高。因为通常情形, 残差平方和曲面常能具有二阶连续偏导数。而且, 由于是通过寻找最速下降方向来实现参数迭代, 因此适宜于在迭代初始阶段, 即初始点远离真值时采用此法。在远离真值处, 二次曲面 $s(\theta)$ 通常变化比较激烈, 因此跨度 $\Delta\theta$ 不宜过大, 以免“差之毫厘, 失之千里”。而在真值附近, 曲面变化率 $\frac{\partial s(\theta)}{\partial \theta}$ 往往接近于零, 最速下降法此时多半是无能为力的。高斯-牛顿法就不同了, 首先, 它要求函数 $f_i, i=1, 2, \dots, N$ 对于全部参数都有一、二阶连续偏导数。这就等价于将函数 f_i 局部地看成线性函数, 把 $s(\theta)$ 近似当作二次曲面。这个要求一般是难于满足的, 因此, 高斯-牛顿法只可能在真值附近的小邻域内进行参数迭代。由于真值邻域内曲面渐趋光滑, 可取 $\Delta\theta$ 的跨度比最速下降法大一些。

总之, 最速下降法要求低, 宜于在迭代初阶, 从远离真值的大范围内, 进行小跨度的迭代; 而在真值附近, 由于 $\frac{\partial s}{\partial \theta}$ 近似为零, 最速下降将无能为力。高斯-牛顿法要求高, 宜于当迭代后期, 在参数估值与真值很接近的小范围内, 进行较大跨度的迭代。自然地, 我们希望充分发挥这两种迭代方法的优点, 将它们二者结合起来使用。迭代初期, 以最速下降为主, 在大范围内搜索, 进行较小跨度的迭代; 随着迭代的延续和真值的逼近, 最速下降法的功能渐

减,因此,迭代方式要渐渐转移到以高斯-牛顿法为主,在真值附近的小邻域内,实现较大跨度的迭代。为了实现上述想法,我们引进带阻尼的高斯-牛顿法。这方法实值上是前两种方法的综合,又称为 Levenberg-Marquart 折衷方法。下面,我们就来具体讨论这种迭代方法。

在最速下降法中,我们曾得到这样一个迭代公式

$$-\frac{1}{\lambda}\Delta\theta = X^T y^*$$

相应地,在高斯-牛顿法中,又有公式

$$X^T X \Delta\theta = X^T y^*$$

将上两个迭代公式综合起来, 引进一个参数 P (称为阻尼因子),即可得到如下带阻尼的高斯-牛顿迭代:

$$(X^T X + P I) \Delta\theta = X^T y^* \quad (6.2.14)$$

从而可得

$$\Delta\theta = (X^T X + P I)^{-1} X^T y^* \quad (6.2.15)$$

式中 X, y^* 等定义全都同于(6.2.6)。

由(6.2.14)及前面的一系列讨论不难看出, 当取 P 为正实数时, 曲面 $s(\theta)$ 必定沿着下降方向迭代, 而且 $\Delta\theta$ 与 P 的大小成反比。因此, P 应该具备如下的变化规律, 即在迭代初始阶段, 应取 P 比较大, 使迭代过程以最速下降为主, 进行小跨度的迭代。随着迭代的进行, P 应该渐渐变小, 使迭代渐渐转移到以高斯-牛顿法为主, 迭代跨度也渐渐增大。总之, P 的大小应随着迭代越趋于真值而渐渐减小。然而, 以上所述仅只是原则, 究竟如何选取 P 的迭代初值, 又按何种比例来缩小等等问题, 都有待于对阻尼因子作进一步深入讨论才能给予回答。

§ 3 阻尼因子的作用和选取

前面已经述及, 阻尼因子如何选取, 是阻尼迭代得以成功的关键所在。为了弄清阻尼因子本质, 实现有效的迭代, 我们还要从线

性方程组的误差分析谈起。

§ 3.1 线性方程组求解的误差分析

无论是线性还是非线性的最小二乘估计,都要涉及到线性方程组

$$Ax=b \quad (6.3.1)$$

的求解问题。其中, A 为 $n \times m$ 阶矩阵, x 为 m 维向量, b 为 n 维向量。

由于种种原因,在求解线性方程组时,都会产生误差的积累。比如算法对于误差的传播和积累,方程组本身对于误差的积累,都有重大的影响。为简单起见,我们仅考虑方程组对于误差的影响,分两种情形来讨论,一是向量 b 的误差所带来的影响,一是矩阵 A 的误差产生的影响。

首先我们来看向量 b 的误差带来的影响。假设方程组(6.3.1)中,向量 b 有一个小的误差 δb ,这时,方程组的解 x 也必然会产生误差 δx 。因此,方程组应改变为

$$A(x+\delta x)=b+\delta b \quad (6.3.2)$$

将此式减去(6.3.1)式,又可得到如下的关系式

$$A\delta x=\delta b$$

从而当 A^{-1} 存在时,有

$$\delta x=A^{-1}\delta b$$

利用矩阵范数的特性,我们可以得到以下两个范数不等式

$$\|\delta x\|=\|A^{-1}\delta b\|\leq\|A^{-1}\|\|\delta b\|$$

$$\|b\|=\|Ax\|\leq\|A\|\|x\|$$

由此两式不难得到

$$\frac{\|\delta x\|}{\|x\|}\leq\frac{\|A^{-1}\|\|\delta b\|}{\|A\|^{-1}\|b\|}=\|A\|\|A^{-1}\|\frac{\|\delta b\|}{\|b\|} \quad (6.3.3)$$

即向量 b 产生某相对误差时,向量 x 产生的相对误差将是前者的 $\|A\|\|A^{-1}\|$ 倍。

再来看矩阵 A 的误差所产生的影响。类似于上面的讨论,我们得关系式

$$(A + \delta A)(x + \delta x) = b$$

减去等式(6.3.1), 可整理得

$$A\delta x = -\delta A(x + \delta x)$$

因此有

$$\begin{aligned}\delta x &= -A^{-1}\delta A(x + \delta x) \\ \|\delta x\| &\leq \|A^{-1}\| \|\delta A\| \|x + \delta x\|\end{aligned}$$

从而得

$$\frac{\|\delta x\|}{\|x + \delta x\|} \leq \|A^{-1}\| \|A\| \frac{\|\delta A\|}{\|A\|} \quad (6.3.4)$$

此式与(6.3.3)式类似, 也得到 $\|A^{-1}\| \|A\|$ 是误差的放大率。

§ 3.2 矩阵 A 的条件数 $\kappa(A)$

由 § 3.1 可见, 对于线性方程组(6.3.1), 量 $\|A\| \|A^{-1}\|$ 表示了误差的放大率, 它的大小直接影响到方程组(6.3.1)的求解精度。因此, 我们定义

$$\kappa(A) = \|A\| \|A^{-1}\|$$

为矩阵 A 的条件数。显然, $\kappa(A)$ 越大, 条件越坏, 而条件坏的线性方程组, 一般难以理想地求解。

条件数 $\kappa(A)$ 具有以下的一些简单性质

$$\text{i) } \kappa(A) = \|A\| \|A^{-1}\| = \mu_m / \mu_1 \quad (6.3.5)$$

其中 $\mu_1^2 \leq \mu_2^2 \leq \cdots \leq \mu_m^2$ 是对称非负定方阵 $A^T A$ 的特征根。

由范数的定义显然可知,

$$\|A\| = \mu_m \quad \|A^{-1}\| = \mu_1$$

从而得性质 i)。

$$\text{ii) } \kappa(A) \geq 1 \quad \kappa(I) = 1 \quad (6.3.6)$$

此性质由(6.3.5)式显然可得。此外, 若 U 为正交矩阵, 即 $U^T U = I$, 则有 $\kappa(U) = 1$, 因此, 正交阵具有最好的条件数。

$$\text{iii) } \kappa(A) \geq \frac{\max_i \|a_i\|}{\min_i \|a_i\|} \quad (6.3.7)$$

其中 a_i 表示矩阵 A 的第 i 个列向量

$$A = (a_1, a_2, \cdots, a_m)$$

这一性质不难由矩阵变换推导得,记

$$\mathbf{e}_i = (0, \dots, 0, 1, 0, \dots, 0)^T$$

且矩阵 $A^T A$ 可以经过变换化为如下形式

$$A^T A = T^T \begin{pmatrix} \mu_1^2 & & \\ & \ddots & \\ & & \mu_m^2 \end{pmatrix} T$$

其中 T 为正交矩阵,即

$$T = (\mathbf{T}_1, \mathbf{T}_2, \dots, \mathbf{T}_m), \mathbf{T}_i^T \mathbf{T}_j = \delta_{ij}$$

$$\begin{aligned} \|\mathbf{a}_i\| &= (\mathbf{a}_i^T \mathbf{a}_i)^{\frac{1}{2}} = (\mathbf{e}_i^T A^T A \mathbf{e}_i)^{\frac{1}{2}} \\ &= \left(\mathbf{e}_i^T T^T \begin{pmatrix} \mu_1^2 & & \\ & \ddots & \\ & & \mu_m^2 \end{pmatrix} T \mathbf{e}_i \right)^{\frac{1}{2}} \\ &= \left(\mathbf{T}_i^T \begin{pmatrix} \mu_1^2 & & \\ & \ddots & \\ & & \mu_m^2 \end{pmatrix} \mathbf{T}_i \right)^{\frac{1}{2}} \\ &\leq \mu_m (\mathbf{T}_i^T \mathbf{T}_i)^{\frac{1}{2}} = \mu_m \end{aligned}$$

同理可得

$$\|\mathbf{a}_i\| \geq \mu_1 (\mathbf{T}_i^T \mathbf{T}_i)^{\frac{1}{2}} = \mu_1$$

两不等式结合,即得(6.3.7)式。

从这几个简单性质出发,将可进一步发现阻尼因子 P 在非线性阻尼最小二乘估计中的作用,帮助我们找到合理选择 P 的途径。

§ 3.3 阻尼因子 P 在非线性最小二乘估计中的作用

在 § 2.3 中,我们已经分析过,阻尼因子的一个重要作用,就是在参数初值 $\mathbf{b}^0$ 的邻域内,折衷使用最速下降法和高斯-牛顿法,以增强迭代的效率。本节在对线性方程组进行误差分析的基础上,引进了反映误差放大率的条件数 $\kappa(A)$,根据 $\kappa(A)$ 的简单性质,并对照公式(6.2.14),不难看出,阻尼因子 P 的大小对于条件数 $\kappa(X^T X + PI)$ 具有直接的影响。因为

设 $X^T X$ 有特征值 $0 \leq \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_m$

显然

$$\kappa(X^T X) = \lambda_m / \lambda_1 \quad (6.3.8)$$

$X^T X + P I$ 有特征值 $0 \leq \lambda_1 + P \leq \lambda_2 + P \leq \dots \leq \lambda_m + P$,

因而

$$\kappa(X^T X + P I) = (\lambda_m + P) / (\lambda_1 + P)$$

由于 $\lambda_m \geq \lambda > 0$ 及 $P > 0$, 显然

$$\kappa(X^T X + P I) < \kappa(X^T X)$$

且当 P 趋于无穷时, 有

$$\kappa(X^T X + P I) \rightarrow 1 \quad (6.3.9)$$

此时相应地, 有

$$\Delta \theta = (X^T X + P I)^{-1} X^T y^* \rightarrow 0 \quad (6.3.10)$$

由此可见, 适当增大阻尼因子, 还有改善方程组(6.2.14)性质的重要作用。因此, 虽然我们在 § 2.3 中论证过, 阻尼因子 P 在迭代过程中总趋势应是减小, 但为了改善方程条件, 保证迭代延续, 也存在着局步放大的可能性。以上讨论表明, 阻尼因子越小, 方程组与(6.2.14)越接近, 然而, 若阻尼因子取得过小, 又无法改善原方程组的条件数。因此, 需要适当选取与合理变化阻尼因子 P 。

§ 3.4 阻尼因子的选取

本节将从三个方面来讨论如何合理选取阻尼因子的问题。

1. 初始阻尼因子的选取: 初始阶段阻尼因子的选取, 将对整个迭代过程产生影响。无论初值 P_0 选得过大和过小, 都会增加平方和函数的计算次数和方程组的求解次数, 影响算法的收敛速度。

迄今为止, 对于初始阻尼因子的选法, 还未有完美的理论根据。因此通常是针对某一类型的函数, 经过多次试验, 找出合理的初值 P_0 来。一般 P_0 多取在 1 与 10 之间。也有一种方法是将 P_0 取做矩阵 X 全体元素平方的算术平均, 即,

$$X = (x_{ij}) \text{ 为 } N \text{ 行 } m \text{ 列矩阵}$$

则取

$$P_0 = \frac{1}{Nm} \sum_{i=1}^N \sum_{j=1}^m x_{ij}^2 \quad (6.3.11)$$

2. 阻尼因子的放大和缩小: 阻尼因子是否选择得合适, 检验标准是平方和函数是否得到较大的下降。因此, 阻尼因子在迭代过程中的放大或缩小, 也应以 $s(\theta)$ 的升降作为判断标准。一般的规律可以简单叙述如下:

设 θ_0 为参数迭代初值, P_0 为阻尼因子初值, $\theta' = \theta_0 + \Delta\theta$ 为以 P_0 作为阻尼因子进行非线性阻尼最小二乘迭代得到的参数迭代值。显然, 如果参数迭代值 θ' 的平方和函数 $s(\theta')$ 不小于原来参数初值 θ^0 相对应的平方和函数值 $s(\theta^0)$, 这就表明迭代是不理想的, 需要改善线性方程组的条件数, 即放大阻尼因子, 退回到原来的参数初始值 θ^0 , 重新进行迭代。

如果出现的情形是 $s(\theta') < s(\theta^0)$, 就说明这步迭代是成功的, 根据阻尼因子总趋势应当减小的原则, 应该改变迭代初值, 由 θ' 作为新的 θ^0 , 缩小阻尼因子, 进行下一步迭代。

阻尼因子放大和缩小的比例, 通常经验是取放大率为 1.5 左右, 缩小率为 0.7 或 0.5 等。

3. 近似最优阻尼因子: 由于在点 θ^0 处以不同的阻尼因子 P 来进行参数迭代会得到不同的平方和值 $s(\theta)$, 因此可将 $s(\theta)$ 看成是阻尼因子 P 的函数, 即

$$s(\theta) \triangleq \phi(P) = y \quad (6.3.12)$$

当迭代初值选定后, 能使 $\phi(P)$ 的下降量达到最大的阻尼因子就称作最优阻尼因子。

由 (6.2.15) 式显见, $\phi(\infty) = s(\theta^0) \triangleq y_0$, 因此 $\phi(P)$ 可近似地看作 $1/P$ 的二次函数

$$y = \phi(P) = y_0 + \alpha_1/P + \alpha_2/P^2 \quad (6.3.13)$$

α_1, α_2 为待定的系数, 可由下法求得

$$\text{取} \quad y_1 = \phi(P_1) \quad y_2 = \phi(P_2)$$

且设 $0 < P_2 < P_1$ (也可 $0 < P_1 < P_2$),

有 $y_1 < y_0 < y_2$

则由(6.3.13)式可得如下关于 α_1 和 α_2 的线性方程组

$$\begin{cases} y_1 = y_0 + \alpha_1/P_1 + \alpha_2/P_1^2 \\ y_2 = y_0 + \alpha_1/P_2 + \alpha_2/P_2^2 \end{cases}$$

由于 y_1, y_2, P_1, P_2 均为已知, 即可得

$$\begin{aligned} \lambda_1 &= \frac{(y_2 - y_0)/P_1^2 - (y_1 - y_0)/P_2^2}{P_1 P_2 (P_1 - P_2)} \\ \lambda_2 &= \frac{(y_1 - y_0)/P_2 - (y_2 - y_0)/P_1}{P_1 P_2 (P_1 - P_2)} \end{aligned} \quad (6.3.14)$$

将(6.3.13)式改写为

$$y = y_0 + \alpha_1 u + \alpha_2 u^2, \quad u \triangleq 1/P \quad (6.3.15)$$

则求最优阻尼因子 P^* 的问题就可通过将(6.3.15)式对 u 求偏导数来实现

$$0 = \frac{\partial y}{\partial u} = \alpha_1 + 2 \alpha_2 u$$

从而得

$$P^* = \frac{1}{u^*} = -\frac{2 \alpha_2}{\alpha_1} \quad (6.3.16)$$

§ 3.5 阻尼最小二乘法的程序实现

综合本节前三小节的讨论, 可将阻尼最小二乘方法的迭代过程表成一个简单的流程框图 (见图 6.1)。对于此框图, 作以下几点说明:

1. III 是示性指标: III 取零值, 标志着不改变迭代初值, 适当增大阻尼因子 P 来改善条件数; III=1, 即要求将本次迭代终值 θ' 作为下次迭代的新初值 θ^0 , 并适当减小 P 值。

2. IT 表示当 III=0 时, 以 θ^0 作为原点进行迭代的次数; IT-MAX 表示这种迭代的最大允许次数。

3. ϵ 代表迭代精度。 ϵ 和 ITMAX 都需作为迭代的初始条件预先给定。有时不仅要以 s' (即 $s(\theta')$) 和 s_0 (即 $s(\theta^0)$) 的差别来判断迭代能否终止, 还要参考 θ^0 和 θ' 的差, 即

$$|\theta^0 - \theta'| \leq \epsilon^*$$

是否成立, 对于这类情形, 只有当两个不等式




图 6.1 阻尼最小二乘法程序框图

$$|s' - s_0| < \varepsilon \text{ 和 } |\theta' - \theta^0| \leq \varepsilon^*$$

同时成立，才可改变迭代终点，减小阻尼因子 P ，进入下一次迭代。

4. 当退回原点，扩大阻尼系数进行迭代的次数超过 ITMAX 时，为了尽力争取得到参数估计的修正量，可再运用抛物线法或二分法在 s^0 和 s' 之间进行插值（当然也可采用其它办法，如分数优

选法等)。现将具体办法简单叙述如下:

将 θ' 与 θ^0 之间的平方和函数 $s(\theta)$ 看作实参量 λ 的函数 $s(\lambda)$

$$\theta = \theta^0 + \lambda \Delta\theta, \quad \Delta\theta = \theta' - \theta^0$$

$$\text{显然,} \quad s(0) = s(\theta^0) \quad s(1) = s(\theta') \quad (6.3.17)$$

令 $0 < \lambda < 1$, 当满足一定条件时

$$s(\theta) = \|y - f(A, \theta)\|^2 = (y - f(A, \theta))^r (y - f(A, \theta))$$

可以近似表成关于 λ 的抛物线函数。

利用已知值 $s(0), s(1)$ 及 f 在 θ^0 处的偏导数, 可以对于参数 λ 实现抛物插值, 以抛物线的最低点 λ^* 作为 $s(\lambda)$ 的极小点, 相应的

$$\theta^* = \theta^0 + \lambda^* \Delta\theta$$

可供来作为迭代起点的选择对象, 如果

$$s(\theta^*) < s(\theta^0)$$

则取 θ^* 为下次迭代的新起点, 否则说明抛物插值失效, 再改用二分法进一步尝试。

可以证明, 抛物插值的最优点 λ^* 可由下面的公式算出

$$\lambda^* = \frac{\Delta\theta^r X y^*}{s(\theta') - s(\theta^0) + 2 \Delta\theta^r X^r y^*} \quad (6.3.18)$$

$$\text{记} \quad s(\lambda) \approx s(0) + b\lambda + a\lambda^2$$

其中

$$\begin{aligned} b &= \left. \frac{\partial s(\lambda)}{\partial \lambda} \right|_{\lambda=0} \\ &= 2 \frac{\partial \theta^r}{\partial \lambda} \left[\frac{\partial}{\partial \theta} (y - f(A, \theta))^r \right] (y - f(A, \theta)) \Big|_{\lambda=0} \\ &= -2 \Delta\theta^r \left[\frac{\partial f(A, \theta)^r}{\partial \theta} \right] (y - f(A, \theta)) \Big|_{\lambda=0} \\ &= -2 \Delta\theta^r X y^* \\ a &= s(\theta') - s(\theta^0) + 2 \Delta\theta^r X y^* \end{aligned}$$

由于

$$\lambda^* = -\frac{b}{2a}$$

即得(6.3.18)式。

二分法的具体步骤如下: 分别取 λ 为 $\frac{\lambda^*}{2}, \frac{\lambda^*}{4}, \dots, \frac{\lambda^*}{2^7}$, 计

算 $s(\boldsymbol{\theta}^0 + \lambda \Delta \boldsymbol{\theta})$ 的值, 检查它们是否小于 $s(\boldsymbol{\theta}^0)$, 若有某一 λ 值使 $s(\boldsymbol{\theta}^0 + \lambda \Delta \boldsymbol{\theta}) < s(\boldsymbol{\theta}^0)$ 成立, 则取 $\boldsymbol{\theta} = \boldsymbol{\theta}^0 + \lambda \Delta \boldsymbol{\theta}$ 作为新的初值, 进行下一步迭代; 如果这七个 λ 值都不能使平方和值下降, 则宣告迭代结束, $\boldsymbol{\theta}_0$ 就是 $s(\boldsymbol{\theta})$ 的极小点。

§ 4 ARMA(p, q) 建模中最小二乘估计的计算方法

§ 4.1 AR(p) 模型

我们已经知道, 对于平稳零均值序列 $w_1, w_2, \dots, w_N$, AR(p) 模型自回归参数可由 (6.1.10) ~ (6.1.14) 式实现最小二乘估计。均值不为零时, 可先将序列减去样本均值, 再对模型进行参数估计。

由公式 (6.1.8) 知, 对于 AR(p) 模型, 参数 $\hat{\boldsymbol{\varphi}}$ 的最小二乘估计为

$$\hat{\boldsymbol{\varphi}} = \begin{pmatrix} \hat{\varphi}_1 \\ \vdots \\ \hat{\varphi}_p \end{pmatrix} = (A^T A)^{-1} A^T \mathbf{y} \quad (6.4.1)$$

式中矩阵 A 由 (6.1.13) 式给出。它是一个 $(N-p) \times p$ 阶矩阵, 如果形式地按照 (6.4.1) 式去估计这 p 个自回归参数, 就需要在计算机中存贮一个 $(N-p) \times p$ 阶的矩阵 A 和一个 $(N-p) \times 1$ 阶的向量 $\mathbf{y}$, 并且还要给出进行上述运算的工作单元。这种算法的计算量与存贮量都是相当可观的。然而对公式 (6.1.10) ~ (6.1.14) 进一步分析之后, 便可找到克服上述困难的途径。

将矩阵 A 表示成

$$A^T = \begin{pmatrix} w_p & w_{p+1} & \cdots & w_{N-1} \\ w_{p-1} & w_p & \cdots & w_{N-2} \\ \vdots & \vdots & & \vdots \\ w_1 & w_2 & \cdots & w_{N-p} \end{pmatrix} = (\mathbf{A}_p, \mathbf{A}_{p+1}, \dots, \mathbf{A}_{N-1})$$

(6.4.2)

式中 $A_k, p \leq k \leq N-1$ 是 $N-p$ 个 p 维列向量。于是

$$A^T A = (A_p, A_{p+1}, \dots, A_{N-1}) \begin{pmatrix} A_p^T \\ A_{p+1}^T \\ \vdots \\ A_{N-1}^T \end{pmatrix} = \sum_{k=p}^{N-1} A_k A_k^T \quad (6.4.3)$$

$$A^T y = (A_p, A_{p+1}, \dots, A_{N-1}) \begin{pmatrix} w_{p+1} \\ w_{p+2} \\ \vdots \\ w_N \end{pmatrix} = \sum_{k=p}^{N-1} w_{k+1} A_k \quad (6.4.4)$$

(6.4.3) 式中, 每一个 $A_k A_k^T$ 是 $p \times p$ 方阵, 不再出现高阶矩阵的运算, 而且由于 $A_k A_k^T$ 是对称阵, 对每个 k , 矩阵乘的运算 $A_k^T A_k$ 只要进行上半三角即可, 因此计算量大大减少。

由公式(6.4.2)可见, A_k^T 与 A_{k+1}^T 之间, 元素具有右移一步的规律, 即

$$A_k^T = (w_k, w_{k-1}, w_{k-2}, \dots, w_{k-p+1})$$

$$A_{k+1}^T = (w_{k+1}, w_k, w_{k-1}, \dots, w_{k-p+2})$$

因此, 在计算(6.4.3)和(6.4.4)时, 不仅可利用高阶的求和运算代替高阶的矩阵运算, 而且还可避免高阶矩阵的存贮。因为在每一步求和运算中, 仅需要存贮 A_k^T , 然后将存贮单元中各元右移一步, 且将 w_{k+1} 填入第一个空位, 即得到 A_{k+1}^T 的存贮, 为下一步 $A_{k+1}^T A_{k+1}$ 与 $w_{k+2} A_{k+1}$ 的计算做好了准备。程序实现的具体步骤如框图 6.2 所示。

§ 4.2 ARMA(p, q) 模型

§ 1.3 已经讨论过, ARMA(p, q) 模型的参数向量可以经非线性最小二乘法来估计。

设 $x_1, x_2, \dots, x_N$ 是均值未知的平稳数字序列, 满足 ARMA(p, q) 模型

$$\tilde{x}_t - \varphi_1 \tilde{x}_{t-1} - \dots - \varphi_p \tilde{x}_{t-p} = a_t - \theta_1 a_{t-1} - \dots - \theta_q a_{t-q}$$




图 6.2 $A'A, A'y$ 的计算框图

$$\tilde{x}_i \triangleq x_i - \frac{1}{N} \sum_{k=1}^N x_k \quad (6.4.5)$$

对照§2中关于非线性最小二乘估计的讨论,可得

$$\text{非线性函数 } f_i(x_i, \theta) = \sum_{j=1}^p \varphi_j \tilde{x}_{i-j} - \sum_{i=1}^q \theta_i a_{i-i}, \quad p+1 \leq i \leq N \quad (6.4.6)$$

$$\text{待估计参数 } \theta^r = (\varphi_1, \varphi_2, \dots, \varphi_p, \theta_1, \theta_2, \dots, \theta_q, \mu) \quad (6.4.7)$$

$$\text{残差量 } y_i^* = a_i - \tilde{x}_i - f_i(x_i, \theta) \quad (6.4.8)$$

$$\text{平方和 } s(\theta) = \sum_{i=p+1}^N y_i^{*2} \quad (6.4.9)$$

$$\text{参数迭代公式 } \boldsymbol{\theta}' = \boldsymbol{\theta}^0 + (\mathbf{X}'\mathbf{X} + P\mathbf{I})^{-1}\mathbf{X}'\mathbf{y}^* \quad (6.4.10)$$

其中, $\boldsymbol{\theta}^0$ 为初始参数, $\boldsymbol{\theta}'$ 为迭代参数, P 为阻尼因子。

$$\mathbf{X} = \begin{pmatrix} \frac{\partial f_1}{\partial \theta_1} & \cdots & \frac{\partial f_1}{\partial \theta_L} \\ \cdots & \cdots & \cdots \\ \frac{\partial f_N}{\partial \theta_1} & \cdots & \frac{\partial f_N}{\partial \theta_L} \end{pmatrix}, L = p + q + 1 \quad (6.4.11)$$

下面讨论矩阵 $\mathbf{X}$ 中元素的迭代计算方法。

将矩阵 $\mathbf{X}$ 用行向量表示

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_1^T \\ \mathbf{X}_2^T \\ \vdots \\ \mathbf{X}_N^T \end{pmatrix}$$

第 k 个行向量 $\mathbf{X}_k^T$ 中, 各元素可依下式算得

$$\begin{cases} \frac{\partial f_k}{\partial \varphi_j} = \tilde{x}_{k-j} - \sum_{i=1}^q \theta_i \frac{\partial a_{k-i}}{\partial \varphi_j} & 1 \leq j \leq p \\ \frac{\partial f_k}{\partial \theta_i} = -a_{k-i} - \sum_{j=1}^q \theta_j \frac{\partial a_{k-i}}{\partial \theta_i} & 1 \leq i \leq q \\ \frac{\partial f_k}{\partial \mu} = 1 - \varphi_1 - \cdots - \varphi_p - \sum_{i=1}^q \theta_i \frac{\partial a_{k-i}}{\partial \mu} \end{cases} \quad (6.4.12)$$

由于 $a_i = \tilde{x}_i - f_i(\mathbf{x}_i, \boldsymbol{\theta})$, 且 $\tilde{x}_i$ 为已知的样本观测量, 因此可得

$$\frac{\partial a_i}{\partial \boldsymbol{\theta}} = -\frac{\partial f_i}{\partial \boldsymbol{\theta}} \quad (6.4.13)$$

此式和(6.4.12)一起, 可实现向量 $\mathbf{X}_k^T$ 到 $\mathbf{X}_{k+1}^T$ 的迭代。在稳定性假设下, 迭代初值一律取为零值, 阻尼系数的选取可参见框图 6.1, $\mathbf{X}'\mathbf{X}$ 与 $\mathbf{X}'\mathbf{y}^*$ 的计算类似于 § 4.1 中叙述的技巧, 这里不再重复。图 6.3 给出了 $s(\boldsymbol{\theta})$ 的计算流程。




图 6.3 最小二乘残差平方和的计算框图

第七章 时间序列的预报

在许多实际应用的问题中,进行时序分析的目的,是在确定模型和参数的基础上,对于未来可能出现的结果进行数值预报。所谓预报,实质上就是根据现在与过去的随机序列的样本取值,对未来某一个时刻的随机变量进行估计。既然是估计问题,就要考虑取什么来作为衡量估计效果优劣的标准。本章着重讨论在线性最小方差意义下的平稳预报和适时预报方法。在讨论中,不仅要进行理论上的阐述和推导,而且还要介绍计算方法与实例。

§ 1 平稳线性最小方差预报

§ 1.1 定义和几何直观解释

设 $\{w_k\}$ 是平稳、零均值序列,用符号 $\hat{w}_k(l)$ 表示由 k 时刻以及以前的历史数据对 w_{k+l} 所做的 l 步平稳线性最小方差预报,它可以表示成如下形式

$$\hat{w}_k(l) = c_0^* w_k + c_1^* w_{k-1} + c_2^* w_{k-2} + \cdots \quad (7.1.1)$$

被选定的系数序列 $\{c_i^*\}$,应使预报误差

$$e_k(l) = w_{k+l} - \hat{w}_k(l) \quad (7.1.2)$$

的均方值

$$E(e_k(l))^2 = E(w_{k+l} - \hat{w}_k(l))^2 \quad (7.1.3)$$

达到最小。

运用线性空间的观点,可以清楚地解释最小方差预报的几何意义

记 $\mathscr{W}_k$ 是 $w_k, w_{k-1}, w_{k-2}, \cdots$ 的线性组合全体构成的线性空间,即

$$\mathscr{W}_k \triangleq \left\{ w; w = \sum_{i=0}^{\infty} c_i w_{k-i}, c_i \text{ 为实数}, \sum_{i=0}^{\infty} c_i^2 < \infty \right\} \quad (7.1.4)$$

$\{w_k, w_{k-1}, w_{k-2}, \dots\}$ 是 $\mathscr{W}_k$ 中的一组基。

事实上, $\mathscr{W}_k$ 是空间

$$\mathscr{W} = \{w: w \text{ 为随机变量, 方差有穷}\}$$

的一个子空间, 在 $\mathscr{W}$ 中, 两个元 x 和 y 的距离由二者之差的均方根表示, 即

$$\rho(x, y) \triangleq [E(x-y)^2]^{\frac{1}{2}}$$

线性最小方差预报, 就是要选择 $w^* \in \mathscr{W}_k$, 使 $\hat{w}_k(l) = w^*$ 在线性空间 $\mathscr{W}_k$ 中与 w_{k+l} 的距离较之其它任何一点都短。自然地, $\hat{w}_k(l)$ 应该是 w_{k+l} 在 $\mathscr{W}_k$ 上的正交投影, 对于这种意义下的估计, 用符号

$$\hat{w}_k(l) = \hat{E}(w_{k+l} | \mathscr{W}_k)$$

表示, 其中 $\hat{E}$ 就表示正交投影。

§ 1.2 预报值与误差方差的确定

由上小节给出的定义可见, 要得到 w_{k+l} 的平稳线性最小方差预报 $\hat{w}_k(l)$, 无非是要确定 (7.1.1) 式中的系数 $\{c_0^*, c_1^*, c_2^*, \dots\}$ 。然而, 由于 $E w_k w_l = r_{k-l} \neq 0$, 即 $\{w_k, w_{k-1}, w_{k-2}, \dots\}$ 不是空间 $\mathscr{W}_k$ 中的一组正交基, 因此, 系数 c_i^* 难以确定, 也不便于深入的讨论。为了克服这一困难, 类似于线性代数中的许密特正交化, 我们也需要找出 $\mathscr{W}_k$ 中的一组正交基 $\{\varepsilon_k, \varepsilon_{k-1}, \varepsilon_{k-2}, \dots\}$, 并以正交基的线性函数的全体来表示 $\mathscr{W}_k$, 即

$$\mathscr{W}_k = \left\{ w: w = \sum_{j=0}^{\infty} d_j \varepsilon_{k-j}, d_j \text{ 为实数}, \right. \\ \left. \sum_{j=0}^{\infty} d_j^2 < \infty, E \varepsilon_j \varepsilon_k = \sigma_\varepsilon^2 \delta_{kj} \right\} \quad (7.1.5)$$

因此, 预报值 $\hat{w}_k(l)$ 又可表示为

$$\hat{w}_k(l) = \sum_{j=0}^{\infty} d_j^* \varepsilon_{k-j} \quad (7.1.6)$$

且 d_j^* 的选择也应满足最小方差准则 (7.1.2), (7.1.3)。

根据线性空间理论, 很容易证明, 一步预报误差

$$e_{l-1}(1) = w_l - \hat{w}_{l-1}(1) \quad l \leq k$$

构成空间 $\mathscr{W}_k$ 的一组正交基。

设 $j < l \leq k$, 由 (7.1.5) 知

$\mathscr{W}_j \subset \mathscr{W}_{l-1}$, 且 $e_{l-1}(1) = w_l - \hat{w}_{l-1}(1) \perp \mathscr{W}_{l-1}$, 另一方面, $e_{j-1}(1) = w_j - \hat{w}_{j-1}(1) \in \mathscr{W}_j \subset \mathscr{W}_{l-1}$, $j < l$, 因此, $E(e_{l-1}(1)e_{j-1}(1)) = 0$, $j < l \leq k$ 。这就证明了 $\{e_{l-1}(1)\}$ 是 $\mathscr{W}_k$ 中的一组正交基。

$$\text{记 } \varepsilon_l \triangleq e_{l-1}(1) = w_l - \hat{w}_{l-1}(1) \quad (7.1.7)$$

稍后我们还将证明, 对于 ARMA(p, q) 序列, 还有

$$\varepsilon_l \equiv a_l, \quad l \leq k$$

这就是说, $\{a_l\}_{l \leq k}$ 恰巧就是空间 $\mathscr{W}_k$ 中的一组正交基。如果用 $\mathscr{A}_k$ 表示由 $a_k, a_{k-1}, \dots$ 的线性函数全体构成的空间, 那么, 显然有

$$\mathscr{W}_k \equiv \mathscr{A}_k \quad (7.1.8)$$

此一性质下面要经常用到。

基于以上的讨论, 我们就可以着手确定 (7.1.6) 式 $\hat{w}_k(l)$ 的, 系数 d_j^* 与估计误差 $e_k(l)$ 了。

由最小均方误差预报的定义可见, 应取 d_j^* 使均方误差

$$V(e_k(l)) = E(e_k(l))^2 = E(w_{k+l} - \hat{w}_k(l))^2$$

达到最小。

将 w_{k+l} 的传递形式 $w_{k+l} = \sum_{j=0}^{\infty} G_j a_{k+l-j}$ 及 (7.1.6) 式代入

上式(式中 e_j 用 a_j 代之), 利用白噪声 $\{a_j\}$ 的不相关性 $E a_i a_j = \delta_{ij} \sigma_a^2$, 即可算得

$$\begin{aligned} V[e_k(l)] &= E \left(\sum_{j=0}^{\infty} G_j a_{k+l-j} - \sum_{j=0}^{\infty} d_j^* a_{k-j} \right)^2 \\ &= E \left\{ \sum_{j=0}^{l-1} G_j a_{k+l-j} + \sum_{j=0}^{\infty} (G_{j+l} - d_j^*) a_{k-j} \right\}^2 \\ &= \sigma_a^2 \left\{ \sum_{j=0}^{l-1} G_j^2 + \sum_{j=0}^{\infty} (G_{j+l} - d_j^*)^2 \right\} \geq \sigma_a^2 \sum_{j=0}^{l-1} G_j^2 \end{aligned}$$

由此可见, 要使 $V[e_k(l)]$ 达最小, 必须且只须

$$d_j^* = G_{j+l} \quad j=0,1,2,\cdots \quad (7.1.9)$$

而预报误差为

$$e_k(l) = w_{k+l} - \hat{w}_k(l) = a_{k+l} + G_1 a_{k+l-1} + \cdots + G_{l-1} a_{k+1} \quad (7.1.10)$$

误差的均方为

$$V[e_k(l)] = E(e_k(l))^2 = \sigma_a^2(1 + G_1^2 + \cdots + G_{l-1}^2) \quad (7.1.11)$$

(7.1.11)式表明, 在(7.1.6)意义下的线性最小方差预报, 其 l 步预报的误差方差(7.1.11)仅与预报步长 l 有关, 而与预报起点 k 无关系。这一点体现了预报的平稳性质。由(7.1.11)式还可看出, 预报步长 l 越大, 预报误差方差也就越大, 预报准确性也越差。

由(7.1.2)与(7.1.10)还可看到, 序列 $\{w_k\}$ 的传递函数是由如下两个部分组成的:

$$\begin{aligned} w_{k+l} &= a_{k+l} + G_1 a_{k+l-1} + \cdots + G_{l-1} a_{k+1} \quad \vdots + G_l a_k + G_{l+1} a_{k-1} + \cdots \\ &= e_k(l) \quad \vdots + \hat{w}_k(l) \end{aligned} \quad (7.1.12)$$

式中的前 l 项恰巧就是 l 步预报的误差, 其余即为 l 步预报值。因此, 根据格林函数与模型参数之间的递推关系式(2.2.4), 就不难由(7.1.12)去计算模型第 l 步预报值 $\hat{w}_k(l)$ 。

§ 1.3 条件期望与预报的关系·平稳线性最小方差预报的若干性质

在§ 1.1 中, 我们已经阐明, 线性最小方差估计 $\hat{w}_k(l)$ 就是 w_{k+l} 在线性空间 $\mathscr{W}_k$ 上的投影。对于正态情形, 还可证明 ([6] p45~46) $\hat{w}_k(l)$ 恰恰就是在给定 $\mathscr{W}_k$ 时 w_{k+l} 的条件期望 $E(w_{k+l} | \mathscr{W}_k)$, 也就是说, 在正态情况下, 线性最小方差预报、正交投影、条件期望这三者是完全等价的。利用关系式(7.1.8), 还可得到如下的等式

$$\begin{aligned} \hat{w}_k(l) &= E(w_{k+l} | w_k, w_{k-1}, \cdots) = E(w_{k+l} | \mathscr{W}_k) \\ &= E(w_{k+l} | a_k, a_{k-1}, \cdots) = E(w_{k+l} | \mathscr{A}_k) \end{aligned}$$

根据以上概念, 并利用第一章 § 4.3 中列出的条件期望性质, 我们将对平稳线性最小方差预报作进一步的讨论, 得出它的一系列简单性质:

$$i) E\left(\sum_{j=0}^{\infty} c_j w_{k-j} \mid \mathscr{H}_l\right) = \sum_{j=0}^{\infty} c_j E(w_{k-j} \mid \mathscr{H}_l), \quad l \leq k \quad (7.1.13)$$

$$ii) E(w_{k+l} \mid \mathscr{H}_k) = E(w_{k+l} \mid \mathscr{A}_k) = \begin{cases} \hat{w}_k(l) & l > 0 \\ w_{k+l} & l \leq 0 \end{cases} \quad (7.1.14)$$

$$iii) E(a_{k+l} \mid \mathscr{A}_k) = E(a_{k+l} \mid \mathscr{H}_k) = \begin{cases} 0 & l > 0 \\ a_{k+l} & l \leq 0 \end{cases} \quad (7.1.15)$$

i) 表明平稳线性最小方差预报是线性的。ii) 和iii) 表明对现在和过去的观测值(或“冲量”)的预报就是它们各自本身；对未来观测值的预报可通过求条件期望得到，对未来“冲量”的预报就是它的(无条件)期望值零。

从以上三个基本性质出发，不难得出如下一系列结论：

$$iv) \hat{w}_k(l) = \varphi_1 \hat{w}_k(l-1) + \varphi_2 \hat{w}_k(l-2) + \cdots + \varphi_p \hat{w}_k(l-p) \quad l > q \quad (7.1.16)$$

依据此式，当 $w_k, w_{k-1}, \cdots$ 给定时，可以对长于 q 步的预报进行递推。

特殊地，如果 $\{w_k\}$ 为 $MA(q)$ 序列，(7.1.16)则为

$$\hat{w}_k(l) = 0 \quad l > q$$

这就意味着，对于 q 阶滑动平均序列，其 q 步以上的预报值恒等于零。

$$v) \hat{w}_k(l) = \sum_{j=1}^{l-1} I_j \hat{w}_k(l-j) + \sum_{j=l}^{\infty} I_j w_{k+l-j} \quad (7.1.17)$$

此式可由i)---iii)及逆转表示 $w_k = \sum_{j=1}^{\infty} I_j w_{k-j} + a_k$ 推得。

由于 $\hat{w}_k(l-j)$ ($j=1, 2, \cdots, l-1$)也是 w_{k-j} ($j=0, 1, 2, \cdots$)的线性和，所以可令

$$\hat{w}_k(l) \triangleq \sum_{j=1}^{\infty} I_j^{(l)} w_{k+l-j} = I^{(l)}(B) w_k \quad (7.1.18)$$

式中 $I^{(l)}(B) \triangleq \sum_{j=1}^{\infty} I_j^{(l)} B^{j-1}$

将(7.1.18)代入(7.1.17),对比等式两边的系数,不难得到

$$\begin{cases} I_j^{(l)} = I_{j+l-1} + \sum_{i=1}^{l-1} I_i I_{j-i}^{(l-i)} & l > 1 \\ I_j^{(1)} = I_j \end{cases} \quad (7.1.19)$$

由逆函数 I_j 的递推公式(2.2.14)及(7.1.19), (7.1.18)即可直接从已知的观测值出发,对未来观测值实现线性平稳最小方差预报。

$$\text{vi)} \quad e_{k+1}(1) = w_{k+1} - \hat{w}_{k+1}(1) = a_k \quad (7.1.20)$$

此式和(7.1.7)一起,即可证得

$$e_k \equiv a_k \quad (7.1.21)$$

从而得到(7.1.8)的结论。

最后,我们引出下面一个公式,它对于预报实现递推运算很有用处。

$$\begin{aligned} \text{vii)} \quad \hat{w}_{k+1}(l) &= \sum_{j=0}^{\infty} G_{j+l} a_{k+1-j} \\ &= G_l a_{k+1} + \sum_{j=1}^{\infty} G_{l+j} a_{k+1-j} \\ &= G_l w_{k+1} - G_l \hat{w}_k(1) + \sum_{j=0}^{\infty} G_{l+1+j} a_{k-j} \\ &= \hat{w}_k(l+1) - G_l \hat{w}_k(1) + G_l w_{k+1} \quad l > 0 \end{aligned} \quad (7.1.22)$$

根据以上性质和公式,即可对于各类线性模型的平稳序列,实现平稳的线性最小方差预报。

由(7.1.1)与(7.1.11)可见,在正态意义下,给定 $w_k, w_{k-1}, \dots$ 之后, w_{k+l} 的条件分布服从 $\mathcal{N}(\hat{w}_k(l), V[e_k(l)])$, 因此在得到 $\hat{w}_k(l)$ 之后,还可给出 w_{k+l} 的预报区间:

$$\begin{aligned} 95\% \text{ 的置信上下限是 } & \hat{w}_k(l) \pm 1.96 \sigma_a (1 + G_1^2 + \dots + G_{l-1}^2)^{\frac{1}{2}} \\ 90\% \text{ 的置信上下限是 } & \hat{w}_k(l) \pm 1.65 \sigma_a (1 + G_1^2 + \dots + G_{l-1}^2)^{\frac{1}{2}} \end{aligned} \quad (7.1.23)$$

§ 2 各类模型序列的平稳线性最小方差预报

§ 2.1 AR(p)序列的预报

由(7.1.16)式(注意, AR(p)模型的 $q=0$), 可得

$$\hat{w}_k(l) = \varphi_1 \hat{w}_k(l-1) + \varphi_2 \hat{w}_k(l-2) + \cdots + \varphi_p \hat{w}_k(l-p), l > 0 \quad (7.2.1)$$

且由(7.1.14)式得

$$\hat{w}_k(-l) = w_{k-l} \quad (l \geq 0) \quad (7.2.2)$$

这就给出了AR(p)序列预报的递推公式

$$\begin{aligned} \hat{w}_k(1) &= \varphi_1 w_k + \varphi_2 w_{k-1} + \cdots + \varphi_p w_{k-p+1} \\ \hat{w}_k(2) &= \varphi_1 \hat{w}_k(1) + \varphi_2 w_k + \cdots + \varphi_p w_{k-p+2} \\ &\dots\dots\dots \\ \hat{w}_k(p) &= \varphi_1 \hat{w}_k(p-1) + \varphi_2 \hat{w}_k(p-2) + \cdots + \varphi_{p-1} \hat{w}_k(1) + \varphi_p w_k \\ &\dots\dots\dots \\ \hat{w}_k(l) &= \varphi_1 \hat{w}_k(l-1) + \varphi_2 \hat{w}_k(l-2) + \cdots \\ &\quad + \varphi_{p-1} \hat{w}_k(l-p+1) + \varphi_p \hat{w}_k(l-p) \quad l > p \end{aligned}$$

由上可见, 只要知道 $w_k, w_{k-1}, \dots, w_{k-p+1}$ 这 p 个时刻的观测值, 无需掌握更多的历史资料, 就可根据这套公式递推求得关于AR(p)序列的任意步平稳最小方差预报。

下面举几个低阶AR(p)模型的预报例子, 说明公式(7.2.1)与(7.2.2)的应用。

例 1 AR(1) $w_t - \varphi_1 w_{t-1} = a_t$

由公式(7.2.1)得 $\hat{w}_k(l+1) = \varphi_1 \hat{w}_k(l) \quad l > 0$

因为初值 $\hat{w}_k(0) = w_k$, 由上公式可算得

$$\hat{w}_k(l) = w_k \varphi_1^l$$

例 2 AR(2) $w_t - \varphi_1 w_{t-1} - \varphi_2 w_{t-2} = a_t$

由公式(7.2.1)得 $\hat{w}_k(l) = \varphi_1 \hat{w}_k(l-1) + \varphi_2 \hat{w}_k(l-2) \quad l > 0$

初值 $\hat{w}_k(0) = w_k, \hat{w}_k(-1) = w_{k-1}$, 由此可推算出任意 l 步预报 $\hat{w}_k(l)$ 。

另一方面,由于 $\hat{w}_k(l)$ 满足形如(7.2.1)的差分方程,也可根据差分方程求根理论(第一章§9.1)直接求得 $\hat{w}_k(l)$ 。为此,令

$$\varphi(B) = 1 - \varphi_1 B - \varphi_2 B^2 = (1 - F_1 B)(1 - F_2 B)$$

其中 F_1^{-1} 和 F_2^{-1} 为 $\varphi(B)=0$ 的两个根。下面,依据 F_1, F_2 的不同情形,分别讨论 $\hat{w}_k(l)$ 的形式。

1. F_1 和 F_2 为不同实数:由差分方程求根理论得知

$$\hat{w}_k(l) = b_1^{(k)} F_1^l + b_2^{(k)} F_2^l \quad l > -2$$

其中 $b_1^{(k)}$ 与 $b_2^{(k)}$ 满足

$$\begin{cases} b_1^{(k)} + b_2^{(k)} = w_k \\ b_1^{(k)} F_1^{-1} + b_2^{(k)} F_2^{-1} = w_{k-1} \end{cases}$$

由此解出

$$b_1^{(k)} = \frac{w_k - F_2 w_{k-1}}{1 - F_2 F_1^{-1}} \quad b_2^{(k)} = \frac{w_k - F_1 w_{k-1}}{1 - F_1 F_2^{-1}}$$

得

$$\hat{w}_k(l) = \frac{F_1^{l+1} - F_2^{l+1}}{F_1 - F_2} w_k - \frac{F_1 F_2 (F_1^l - F_2^l)}{F_1 - F_2} w_{k-1}$$

2. $F_1 = F_2$, 即为二重根。由实系数二次方程性质得,它们必定为实数。

$$\hat{w}_k(l) = b_1^{(k)} F_1^l + l b_2^{(k)} F_1^l$$

$b_1^{(k)}$ 和 $b_2^{(k)}$ 满足

$$\begin{cases} b_1^{(k)} = w_k \\ (b_1^{(k)} - b_2^{(k)}) F_1^{-1} = w_{k-1} \end{cases}$$

由此解得

$$b_1^{(k)} = w_k \quad b_2^{(k)} = w_k - F_1 w_{k-1}$$

$$\hat{w}_k(l) = w_k F_1^l (l+1) - w_{k-1} F_1^{l+1} l$$

3. F_1 和 F_2 为一对共轭复数,这时 $\bar{F}_1 = \bar{F}_2 = \rho(\cos r + i \sin r)$, 其中 ρ 为复数 F_1 与 F_2 的模长, r 为幅角。

根据差分方程求根理论,经过整理,不难得到 $\hat{w}_k(l)$,并可以表示成

$$\hat{w}_k(l) = b_1^{(k)} \rho^l \cos lr + b_2^{(k)} \rho^l \sin lr \quad (l > -2)$$

系数 $b_1^{(k)}$ 和 $b_2^{(k)}$ 满足方程组

$$\begin{cases} b_1^{(k)} = w_k \\ b_1^{(k)} \rho^{-1} \cos r - b_2^{(k)} \rho^{-1} \sin r = w_{k-1} \end{cases}$$

解此方程组, 即得

$$b_1^{(k)} = w_k$$

$$b_2^{(k)} = \frac{1}{\sin r} (w_k \cos r - \rho w_{k-1})$$

因此得

$$\hat{w}_k(l) = w_k \rho^l \frac{\sin(l+1)r}{\sin r} - w_{k-1} \rho^{l+1} \frac{\sin l r}{\sin r}.$$

§ 2.2 MA(q) 序列的预报

由 § 1 中 (7.1.16) 与 (7.1.18) 式可知, 对于 MA(q) 序列, 有

$$\hat{w}_k(l) = \begin{cases} \sum_{j=1}^{\infty} I_j^{(l)} w_{k+1-j}, & 0 < l \leq q \\ 0 & l > q \end{cases} \quad (7.2.3)$$

表面看来, 似乎很简单, MA(q) 序列对于每一时刻 k 除了前 q 步外, 以后的预报值都为零。但是, 仔细研究 (7.2.3), 不难发现它与 AR(p) 序列预报的一个根本区别, 在于 MA(q) 序列的预报 $\hat{w}_k(l)$ 依赖全部历史数据 $w_{k-j}, j \geq 0$ 。然而实际数据是有限的, 因此我们只能用有穷和代替, 得到近似的平稳最小方差预报, 即

$$\hat{w}_k(l) \approx \sum_{j=1}^M I_j^{(l)} w_{k+1-j}, \quad 0 < l \leq q$$

$I_j^{(l)}$ 与 I_j 之间的关系式 (7.1.19) 式以及 I_j 的负指数收敛性保证了 $I_j^{(l)}$ 也是负指数衰减的, 因而可以根据 I_j 收敛速度适当选择 M , 以保证预报的精度。

式 (7.2.3) 表明, MA(q) 序列的预报值 $\hat{w}_k(l) (l \leq q)$ 需要对于大量历史数据加权求和, 这对于采样间隔较短 (例如一分钟、一秒钟), 资料积累又较丰富的连续性适时预报将会带来困难。为此, 有必要给出一种关于平稳预报的递推方法, 以达到减少存贮, 缩短计算时间的效果。

由(7.1.21)式及 $G_k = -\theta_k$ ($1 \leq k \leq q$) 立即可得 MA(q) 的递推预报公式

$$\hat{\mathbf{W}}_{k+1}^{(q)} = \begin{pmatrix} \theta_1 & 1 & 0 \\ \vdots & \ddots & \vdots \\ \theta_{q-1} & 0 & 1 \\ \theta_q & 0 & \cdots & 0 \end{pmatrix} \hat{\mathbf{W}}_k^{(q)} - \begin{pmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_q \end{pmatrix} w_{k+1} \quad (7.2.4)$$

式中 $\hat{\mathbf{W}}_k^{(q)}$ 称作预报矢量, 记为

$$\hat{\mathbf{W}}_k^{(q)} = (\hat{w}_k(1), \hat{w}_k(2), \dots, \hat{w}_k(q))^T \quad (7.2.5)$$

它和 $\hat{w}_k(l) = 0$, $l > q$ 一起, 描述了 MA(q) 序列以时刻 k 为起点对未来进行任意 l 步预报所应具有的全部结果。

式(7.2.4)中, 对于每一个时刻 k , $\hat{\mathbf{W}}_k^{(q)}$ 都具有相同的计算量。递推初值可通过直接计算求得, 也可(当初始时刻 k_0 很小时)取 $\hat{\mathbf{W}}_{k_0}^{(q)} = 0$ 。可以证明, 模型的可逆性保证了上逆推式渐近稳定, 即当 k 增加到充分大后, 初始误差的影响会逐渐消失。因此如果进行长期递推预报, 从初值经过一段时间后, 预报值就可以用了。

举两个简单的例子, 说明 MA(q) 序列预报的特点。

例 3 MA(1) $w_t = a_t - \theta_1 a_{t-1}$

由(7.2.2)知, MA(1)只有一阶预报, 又由(7.1.19)及第二章(2.2.18)式知

$$I_j^{(1)} = I_j = -\theta_1^j (j \geq 1), \text{ 因此得}$$

$$\hat{w}_k(1) = \sum_{j=1}^{\infty} I_j w_{k+1-j} = -\theta_1 \sum_{i=0}^{\infty} \theta_1^i w_{k-i} \approx -\theta_1 \sum_{i=0}^M \theta_1^i w_{k-i}$$

其中 M 的大小应由预先所给的误差精度来确定, 以便使

$$\sum_{i=M+1}^{\infty} |\theta_1^i| \text{ 可以忽略不计。}$$

如果采用矢量递推方法, 由(7.2.4)与(7.2.5)可得, 对于 MA(1), 有

$$\hat{w}_{k+1}(1) = \theta_1 \hat{w}_k(1) - \theta_1 w_{k+1}$$

在此计算公式中, $\hat{w}_{k+1}(1)$ 只需进行两个乘法与一个减法即可算

得。当 k 增加到很大后, $\hat{w}_k(1)$ 同样有很好的精度。因此, 只需用直接法算得某个 $\hat{w}_{k_0}(1)$, 即可用矢量递推来预报任意的 $\hat{w}_k(1)$, $k \geq k_0$ 了。

$$\text{例 4 } \text{MA}(2) \quad w_t = a_t + a_{t-1} + 0.24 a_{t-2}$$

$$\text{由于 } 1 - B + 0.24 B^2 = (1 - 0.4 B)(1 - 0.6 B)$$

$$\text{所以 } 1 = \sum_{j=1}^{\infty} I_j B^j = \theta^{-1}(B) = (1 - 0.4 B)^{-1} (1 - 0.6 B)^{-1}$$

$$= \frac{3}{1 - 0.6 B} - \frac{2}{1 - 0.4 B} = \sum_{j=0}^{\infty} (3(0.6)^j - 2(0.4)^j) B^j$$

比较等式两端关于 B^j 的同幂次项的系数, 得

$$I_j = 2(0.4)^j - 3(0.6)^j \quad (j \geq 1)$$

$$I_j^{(1)} = I_j$$

$$I_j^{(2)} = I_{j+1} + I_1 I_j = 1.2((0.6)^j - (0.4)^j) \quad (j \geq 1)$$

由此可得本例中 MA(2) 的一、二步平稳最小方差预报

$$\hat{w}_k(1) = \sum_{j=1}^{\infty} I_j w_{k+1-j}$$

$$\hat{w}_k(2) = \sum_{j=1}^{\infty} I_j^{(2)} w_{k+1-j}$$

容易验证, 当 $k \geq 13$ 后, $\sum_{j > k} |I_j|$ 和 $\sum_{j > k} |I_j^{(2)}|$ 都不超过 0.01, 若

以 0.01 为要求的精度, 即可选 M 为 13, 于是得 $\hat{w}_k(1)$ 和 $\hat{w}_k(2)$ 的近似值

$$\hat{w}_k(1) \approx \sum_{j=1}^{13} [2(0.4)^j - 3(0.6)^j] w_{k+1-j}$$

$$\hat{w}_k(2) \approx 1.2 \sum_{j=1}^{13} [(0.6)^j - (0.4)^j] w_{k+1-j}$$

如果用递推法进行预报, 则由 (7.2.4) 与 (7.2.5) 可得

$$\hat{\mathbf{W}}_{k+1}^{(2)} = \begin{pmatrix} \theta_1 & 1 \\ \theta_2 & 0 \end{pmatrix} \hat{\mathbf{W}}_k^{(2)} = \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix} w_{k+1}$$

$$= \begin{pmatrix} 1 & 1 \\ 0.24 & 0 \end{pmatrix} \hat{\mathbf{W}}_k^{(2)} + \begin{pmatrix} -1 \\ 0.24 \end{pmatrix} w_{k+1}$$

初值 $\hat{\mathbf{W}}_{k_0}^{(2)}$ 可用直接法算得。

§ 2.3 ARMA(p, q)序列的预报

ARMA 序列的预报与 MA 序列的预报方法类似,可以直接由(7.1.18)式进行预报,也可用预报矢量来递推,只是预报时要比 MA 序列复杂。比如,MA(q)序列除前 q 步外, $\hat{w}_k(l)$ 恒为零,而 ARMA(p, q)序列的 $\hat{w}_k(l)$ 就无此特征,即 q 步之后 $\hat{w}_k(l)$ 仍可不为零。不过由(7.1.16)式可见,当 $l > q$ 之后, $\hat{w}_k(l)$ 可以递推求得,因此我们只要用预报矢量法计算出 $\hat{w}_k(1), \hat{w}_k(2), \dots, \hat{w}_k(q)$ 就够了。

定义预报矢量为

$$\hat{\mathbf{W}}_k^{(q)} = (\hat{w}_k(1), \hat{w}_k(2), \dots, \hat{w}_k(q))^T$$

由(7.1.16)与(7.1.21)可得

$$\begin{aligned} \hat{\mathbf{W}}_{k+1}^{(q)} = & \begin{pmatrix} -G_1 & 1 & & & 0 \\ -G_2 & & \ddots & & \\ \vdots & & & \ddots & \\ -G_{q-1} & 0 & & & \\ -G_q + \varphi'_q & \varphi'_{q-1} & \varphi'_{q-2} & \dots & \varphi'_1 \end{pmatrix} \hat{\mathbf{W}}_k^{(q)} + \\ & + \begin{pmatrix} G_1 \\ G_2 \\ \vdots \\ G_q \end{pmatrix} w_{k+1} + \begin{pmatrix} 0 \\ \vdots \\ 0 \\ \sum_{j=q+1}^p \varphi_j' w_{k+q-j+1} \end{pmatrix} \end{aligned}$$

其中

$$\varphi_j' = \begin{cases} \varphi_j & 0 \leq j \leq p \\ 0 & j > p \end{cases} \quad (7.2.6)$$

当 $p \leq q$ 时,上式第三项为零。递推初值

$(\hat{w}_k(1), \hat{w}_k(2), \dots, \hat{w}_k(q))^T = \hat{\mathbf{W}}_{k_0}^{(q)}$ 可由直接计算得到。

当然,在可逆性条件保证下,也可取 $\hat{\mathbf{W}}_{k_0}^{(1)} = 0$ 。

例 5 ARMA(1,2)

$$(1 - 0.8B)w_t = (1 - B + 0.24B^2)a_t$$

将原模型写做

$$\begin{aligned} w_t &= (1 - 0.8B)^{-1}(1 - B + 0.24B^2)a_t \\ &= \sum_{j=0}^{\infty} (1 - B + 0.24B^2)(0.8B)^j a_t \end{aligned}$$

由此易见, $|G_j|$ 与 $(0.8)^j$ 为相同量级。因此,为保证有限和的误差精度为 0.01,只需在

$\hat{w}_{k_0}(l) = \sum_{j=0}^{\infty} G_{l+j} a_{k_0-j}$ 中,取前 30 项左右,即可直接求得预报矢量的递推初值:

$$\hat{\mathbf{W}}_{k_0}^{(2)} = (\hat{w}_{k_0}(1), \hat{w}_{k_0}(2))^T$$

然后由 (7.2.6) 可得到任意的 $\hat{\mathbf{W}}_k^{(2)}, k \geq k_0$

$$\begin{aligned} \hat{\mathbf{W}}_{k+1}^{(2)} &= \begin{pmatrix} -G_1 & 1 \\ -G_2 & \varphi_1 \end{pmatrix} \hat{\mathbf{W}}_k^{(2)} + \begin{pmatrix} G_1 \\ G_2 \end{pmatrix} w_{k+1} \\ &= \begin{pmatrix} 0.2 & 1 \\ -0.08 & 0.8 \end{pmatrix} \hat{\mathbf{W}}_k^{(2)} + \begin{pmatrix} -0.2 \\ 0.08 \end{pmatrix} w_{k+1} \end{aligned}$$

对于 $l > 2$ 的其余各步预报值 $\hat{w}_k(l)$,可由 (7.1.16) 式来递推,即

$$\hat{w}_k(l) = \varphi_1 \hat{w}_k(l-1) \quad l > 2$$

因此

$$\hat{w}_k(l) = \varphi_1^{l-2} \hat{w}_k(2) = (0.8)^{l-2} \hat{w}_k(2).$$

§ 2.4 一类非平稳序列的预报

至此为止,我们都是讨论的平稳零均值序列 $\{w_k\}$ 的预报。然而有些非平稳序列,可以经过适当处理产生 ARMA 序列,对此新序列用前三节的方法做出预报后,再进一步对原序列进行预报。ARIMA 序列及一类带趋势性季节性的非平稳序列,都可用此方法进行预报。

例如, 设序列 $\{z_t\}$ 满足如下模型

$$\nabla^d \nabla_s^D \varphi(B) z_t = \theta(B) a_t$$

其中 $\nabla^d = (1-B)^d$ $\nabla_s^D = (1-B^s)^D$

当 $D=0$ 时, 它是普通的 ARIMA(p, d, q) 模型, $D>0$ 时, 便为季节模型。

记 $w_t = \nabla^d \nabla_s^D z_t$, 则 $\{w_t\}$ 为 ARMA(p, q) 序列, $\hat{w}_k(l)$ 可用 § 2.3 介绍的方法来计算。由于 $\hat{w}_k(l)$ 具有线性性质, 因此有

$$\hat{w}_k(l) = \nabla^d \nabla_s^D \hat{z}_k(l) \quad (k \geq d + D \times s, l \geq 0)$$

式中 k 为某一固定整数, 算子 ∇ 和 ∇_s 都作用在 l 上, 由此便可利用 $\hat{w}_k(l)$ 来求得 $\hat{z}_k(l)$ 了。为了具体说明这一预报原则, 下面举两个简单的例子。

例 6 $(1-B)z_t = (1-\theta_1 B)a_t$

令 $w_t = (1-B)z_t = z_t - z_{t-1} \quad t \geq 2$, 则 $\{w_t\}$ 为 MA(1) 序列, 由例 3 可知, 对于任意时刻 k , w_k 仅有一阶预报 $\hat{w}_k(1)$, 即

$$\hat{w}_k(1) = -\theta_1 \sum_{i=0}^{\infty} \theta_1^i w_{k-i}; \quad \hat{w}_k(l) = 0, \quad l \geq 1$$

将 $\hat{w}_k(l) = \hat{z}_k(l) - \hat{z}_k(l-1)$ 代入上式, 并注意 $\hat{z}_k(0) = z_k$, 不难得到

$$\hat{z}_k(1) = z_k - \theta_1 \sum_{i=0}^{\infty} \theta_1^i (z_{k-i} - z_{k-i-1})$$

$$\hat{z}_k(l) = \hat{z}_k(l-1) \equiv \hat{z}_k(1) \quad l \geq 1$$

同样地, 也可利用 (7.1.21) 推出 $\hat{z}_k(1)$ 的递推公式

$$\begin{aligned} \hat{z}_{k+1}(1) &= z_{k+1} + \hat{w}_{k+1}(1) \\ &= z_{k+1} + \theta_1 \hat{w}_k(1) - \theta_1 w_{k+1} \\ &= z_{k+1} + \theta_1 [\hat{w}_k(1) - z_{k+1} + z_k] \\ &= (1-\theta_1) z_{k+1} + \theta_1 \hat{z}_k(1) \end{aligned}$$

由此可见, 只要对某一个 k_0 直接计算出 $\hat{z}_{k_0}(1)$, 则对任一 $k > k_0$ 都可用预报矢量递推法计算出 $\hat{z}_k(1)$ 来。

例 7 $(1-\varphi_1 B)(1-B)z_t = a_t$

记 $w_t = (1-B)z_t = z_t - z_{t-1}$, 则 $\{w_k\}$ 是 AR(1) 序列, 由例 1 知, $\hat{w}_k(l) = w_k \varphi_1^l, l \geq 0$, 由此得

$$\begin{aligned}\hat{z}_k(l) &= \hat{z}_k(l-1) + w_k \varphi_1^l = \cdots \\ &= z_k + \sum_{j=1}^l w_k \varphi_1^j \\ &= z_k + \frac{\varphi_1(1-\varphi_1^l)}{1-\varphi_1} (z_k - z_{k-1}) \\ &= \frac{1-\varphi_1^{l+1}}{1-\varphi_1} z_k - \frac{\varphi_1(1-\varphi_1^l)}{1-\varphi_1} z_{k-1}.\end{aligned}$$

§ 2.5 平稳预报的步骤

§ 1 和 § 2 前 4 小节中, 对于平稳最小方差预报的原理及各种模型的预报方法进行了详细的讨论, 并计算了简单的例子。为了帮助读者适当运用上述原理方法去处理实际数据, 本节将数字序列进行平稳预报的程序步骤和注意事项整理出来, 供大家参考。

首先要注意的是, 本章所讨论的预报, 都是在序列服从某一线性模型的前提之下进行的。因此, 为欲对某一时间序列的未来值进行平稳预报, 必先根据第三~六章中介绍的方法, 对数据建立 ARMA(p, q) 模型或其它准线性模型: 如 ARIMA(p, d, q) 模型、季节性乘积模型或含有确定性趋势项的叠合模型等。

如果序列服从准线性模型, 则需要经过适当变化整理, 才能应用平稳预报的方法。例如, 对于 ARIMA(p, d, q) 模型的序列 $\{z_t\}$, 要先将 z_t 作 d 阶差分处理: $w_t = \nabla^d z_t$, 再对 $\{w_t\}$ 进行预报; 对于季节性乘积模型, 要按第四章 § 2 介绍的方法, 化为高阶疏系数 ARMA 模型, 再进行预报。

经过上述处理后, 对于 ARMA(p, q) 序列, 就可按本章介绍的方法来进行平稳预报了。就其平稳预报的方式而言, 可以分为直接预报和递推预报两大类。后者是指根据公式 (7.2.4) 和 (7.2.6), 关于预报起始点 k 实现预报矢量递推, 即对于每个时刻 k , 可以同时得到以预报矢量形式表示的 q 步预报

$$\hat{W}_k^{(q)} = (\hat{w}_k(1), \hat{w}_k(2), \dots, \hat{w}_k(q))^T$$

随着 k 的增长, 预报不断向前延续递推。这种预报方法便于计算机上使用, 但递推出发点的

$$\hat{\mathbf{W}}_{k_0}^{(q)} = (\hat{w}_{k_0}(1), \hat{w}_{k_0}(2), \dots, \hat{w}_{k_0}(q))^T$$

仍需由直接预报法求得。直接预报顾名思义, 就是从模型本身出发进行预报, 由于 $\text{ARMA}(p, q)$ 模型有三种等价形式, 因此, 又分为由格林函数预报, 由逆转形式预报以及由差分方程(7.1.6)进行预报这三类。

所谓用格林函数形式来预报, 就是用白噪声冲量的线性和对未来时刻的随机变量进行预报。这里, l 步平稳预报 $\hat{w}_k(l)$ 由下式算得

$$\hat{w}_k(l) = G_l a_k + G_{l+1} a_{k-1} + \dots = \sum_{i=0}^{\infty} G_{l+i} a_{k-i} \quad (7.2.7)$$

预报误差为

$$e_k(l) = a_{k+l} + G_1 a_{k+l-1} + \dots + G_{l-1} a_{k+1} \quad (7.2.8)$$

其中格林函数 G_l 由下式递推(模型为 $\text{ARMA}(p, q)$)

$$G_l = -\theta_l^* + \sum_{j=1}^l \varphi_j^* G_{l-j}; \quad G_0 = 1 \quad (7.2.9)$$

$$\begin{aligned} \varphi_j^* &= \begin{cases} \varphi_j & 1 \leq j \leq p \\ 0 & j > p \end{cases} \\ \theta_l^* &= \begin{cases} \theta_l & 1 \leq l \leq q \\ 0 & l > q \end{cases} \end{aligned} \quad (7.2.10)$$

白噪声 a_k 由下式迭代(初始值取 0)

$$a_k = w_k - \varphi_1 w_{k-1} - \dots - \varphi_p w_{k-p} + \theta_1 a_{k-1} + \dots + \theta_q a_{k-q} \quad (7.2.11)$$

在(7.2.7)式中, 求和项个数为无穷, 在实际计算中只能用符合精度要求的 M 来代替, 具体选法可以参照 § 2.2 例 3。由此可见, 对于实际数字序列, 格林函数形式一般只能进行近似预报。

所谓用逆转函数形式来进行预报, 就是用现在和全部历史的

观测数据,直接对未来值进行预报。 l 步预报 $\hat{w}_k(l)$ 由下面公式计算

$$\hat{w}_k(l) = \sum_{j=1}^{\infty} I_j^{(l)} w_{k+1-j} \quad (7.2.12)$$

式中

$$I_j^{(l)} = \begin{cases} I_{j+l-1} + \sum_{i=1}^{l-1} I_i I_{j+l-i}^{(l-i)} & l > 1 \\ I_j & l = 1 \end{cases} \quad (7.2.13)$$

逆函数 $\{I_j\}$ 由模型系数求得

$$I_j = \varphi_j^* + \sum_{i=1}^{j_*} \theta_i^* I_{j-i} \quad (7.2.14)$$

$$I_0 \triangleq -1$$

式中 φ_j^*, θ_i^* 的定义同(7.2.10)式。

对于一般情形(AR序列除外),由(7.2.11)式可见,进行平稳预报需要用到全部历史数据,因此实际上也只能实现近似平稳预报。

由差分方程(7.1.16)

$$\hat{w}_k(l) - \varphi_1 \hat{w}_k(l-1) - \varphi_2 \hat{w}_k(l-2) - \cdots - \varphi_p \hat{w}_k(l-p) = 0, \quad l > q$$

可以通过求解差分方程直接得到 $\hat{w}_k(l)$,也可在给定初值的情形下由 $\hat{w}_k(l-1), \cdots, \hat{w}_k(l-p)$ 来递推 $\hat{w}_k(l)$,还可与预报矢量法结合,实现时间 k 向前推移时,对于任意步长 l 的递推预报。从这一差分方程还可得到如下一系列结果:对于AR(p)模型,可根据有限个历史数据 $w_k, w_{k-1}, \cdots, w_{k-p+1}$ 进行任意 l 步的严格平稳预报 $\hat{w}_k(l)$;对于MA(q)序列,虽没有AR(p)序列的上述特点,但由差分方程(7.1.6)可见,当 $l > q$ 时, $\hat{w}_k(l) \equiv 0$,因此只需计算前 q 步预报即可;对于ARMA(p, q)序列,那就既不可能由有限数据进行严格平稳预报,又不能在有限步预报后得出预报值恒为零的结论。

最后还需再强调的一点是,在预报前对数据若进行了平稳化处理,到预报结束时,一定要相应地还原。例如我们对 $w_k = z_k - \mu$ (μ 为某常数)进行预报,得 $\hat{w}_k(l)$ 之后必须还原到 $\hat{z}_k(l) = \hat{w}_k(l) + \mu$ 。

预报实例请参见第五章。

§ 3 时间序列的新息预报^{[22][23]}

§ 1 和 § 2 讨论了 ARMA(p, q) 序列的平稳预报。所谓预报的平稳性就体现在估计误差的均方值只和预报步长有关,而与预报起始点 k 无关(见(7.1.11)式)。除 AR(p)模型外,平稳线性最小方差预报需要根据无穷个历史数据 $w_k, w_{k-1}, \dots$ 来进行。然而实际问题中只能获得有限资料,故而只能(当 $q > 0$)得到 $\hat{w}_k(l)$ 的近似值,且仅当 k 适当大以后,由近似所带来的误差才可以被忽略。有些实际问题,特别是那些要求连续进行的适时预报问题,常常希望依据实际上获得的有限个数据 $w_k, w_{k-1}, \dots, w_1$ 给出 w_{k+l} 的严格的线性最小方差预报,并希望随 k 的增加,实现预报的适时递推。本节向大家介绍的新息预报方法,就是一种适应上述要求的适时预报方法。

§ 3.1 新息预报的原理

与 § 1.1 中的无穷序列 $w_k, w_{k-1}, \dots$ 相应,对有限个数据 $w_k, w_{k-1}, \dots, w_1$ 可以平行地引入一系列概念和记号

$$\mathscr{W}_k^1 \triangleq \left\{ w; w = \sum_{j=1}^k c_j w_j, c_j \text{ 为实数} \right\} \quad (7.3.1)$$

用 $\hat{w}_{k+l,k}$ 表示根据 $w_k, w_{k-1}, \dots, w_1$ 对 w_{k+l} 所做的线性最小方差预报,自然地, $\hat{w}_{k+l,k} \in \mathscr{W}_k^1$, 且使误差方差 $E(w_{k+l} - \hat{w}_{k+l,k})^2$ 达到最小。

类似于(7.1.7),记一步预报误差为

$$e_k = w_k - \hat{w}_{k,k-1} \quad (7.3.2)$$

如果把 $\hat{w}_{k,k-1}$ 看成是 k 时刻前的“老”数据 $w_{k-1}, w_{k-2}, \dots, w_1$

提供的关于 w_k 的最大信息,那么 e_k 就可直观地理解为是 w_k 中所含有的真正“新”信息。因此,我们将 $\{e_1, e_2, \dots\}$ 称为由 $\{w_1, w_2, \dots, w_k, \dots\}$ 产生的新息序列。

记

$$\mathcal{E}_k^1 \triangleq \left\{ e, e = \sum_{i=1}^k d_i e_i, d_i \text{ 为实数} \right\} \quad (7.3.3)$$

则由(7.3.1)和(7.3.2)显然有

$$\mathcal{W}_{k+1,k}^1 = \mathcal{E}_k^1 \quad (7.3.4)$$

由于 $\hat{w}_{k+1,k}$ 实质上就是 w_{k+1} 在线性空间 $\mathcal{W}_{k+1,k}^1$ 上的正交投影,因此,根据线性空间理论,很容易证明

$$E e_k w_j = 0, E e_k e_j = 0, j < k \quad (7.3.5)$$

(7.3.5)中第二式表明,新息序列 $\{e_j, j=1, 2, \dots, k\}$ 是线性空间 $\mathcal{W}_k^1$ 中的一组正交基。因此 $\hat{w}_{k+1,k}$ 可表为 $e_k, e_{k-1}, \dots, e_1$ 的线性组合

$$\hat{w}_{k+1,k} = \sum_{j=1}^k J_{k+1,j} e_j \quad (7.3.6)$$

式中系数 $J_{k+1,j}$ 可由极小化 $E(w_{k+1} - \hat{w}_{k+1,k})^2$ 求得

$$\begin{aligned} 0 &= \frac{\partial}{\partial J_{k+1,j}} E \left(w_{k+1} - \sum_{j=1}^k J_{k+1,j} e_j \right)^2 \\ &= 2 E \left\{ \left(w_{k+1} - \sum_{j=1}^k J_{k+1,j} e_j \right) (-e_j) \right\} \end{aligned}$$

从而得

$$J_{k+1,j} = (E w_{k+1} e_j) (E e_j^2)^{-1} \quad (7.3.7)$$

由此可见,只要能够得到 $E w_{k+1} e_j$ 与 $E e_j^2$,便可算出新息预报值 $\hat{w}_{k+1,k}$ 。

§ 3.2 新息定理

新息预报方法基于以下定理

新息定理 设 $\{w_k\}$ 是满足 $\text{ARMA}(p, q)$ 模型的平稳零均值序列,记

$$Q \triangleq \max(p, q) \quad (7.3.8)$$

$$y_k \triangleq \begin{cases} w_k & k \leq Q \\ \varphi(B)w_k & k > Q \end{cases} \quad (7.3.9)$$

则新息序列 $\{e_k\}$ 满足如下递推关系式

$$e_k = \begin{cases} y_1 - w_1 & k=1 \\ y_k - \sum_{j=1}^{k-1} J_{kj} e_j & 1 < k \leq Q \\ y_k - \sum_{j=k-Q}^{k-1} J_{kj} e_j & k > Q \end{cases} \quad (7.3.10)$$

其中

$$J_{kj} = \begin{cases} \left[\gamma_{kj}(y) - \sum_{i=1}^{j-1} J_{ji} J_{ki} \gamma_{ii}(e) \right] [\gamma_{jj}(e)]^{-1} & 1 < k \leq Q, 1 \leq j \leq k-1 \\ \left[\gamma_{kj}(y) - \sum_{i=k-Q}^{j-1} J_{ji} J_{ki} \gamma_{ii}(e) \right] [\gamma_{jj}(e)]^{-1} & k > Q, k-Q \leq j \leq k-1 \end{cases} \quad (7.3.11)$$

$$\text{式中 } \gamma_{kj}(y) \triangleq E y_k y_j, \quad \gamma_{jj}(e) \triangleq E e_j^2 \quad (7.3.12)$$

且

$$\gamma_{kk}(e) = \begin{cases} \gamma_{11}(e) & k=1 \\ \gamma_{kk}(y) - \sum_{j=1}^{k-1} J_{kj}^2 \gamma_{jj}(e) & 1 < k \leq Q \\ \gamma_{kk}(y) - \sum_{j=k-Q}^{k-1} J_{kj}^2 \gamma_{jj}(e) & k > Q \end{cases} \quad (7.3.13)$$

上列各式中,当求和上限小于下限时,约定和为零。

下面,我们来证明这个定理。

先证明 $\{y_k\}$ 和 $\{w_k\}$ 有相同的新息序列 $\{e_k\}$ 。由 y_k 的定义 (7.3.9) 得

$$\mathcal{Y}_k^1 \triangleq \left\{ y: y = \sum_{i=1}^k \delta_i y_i, \delta_i \text{ 为实数} \right\} \equiv \mathcal{W}_k^1 \equiv \mathcal{E}_k^1 \quad (7.3.14)$$

当 $k \leq Q$ 时

$$y_k - \hat{y}_{k,k-1} = w_k - \hat{w}_{k,k-1} = e_k \quad (7.3.15)$$

当 $k > Q$ 时

$$\begin{aligned} y_k - \hat{y}_{k,k-1} &= \varphi(B)w_k - E(\varphi(B)w_k | \mathcal{H}_{k-1}^1) \\ &= \varphi(B)w_k (\hat{w}_{k,k-1} - \sum_{j=1}^p \varphi_j w_{k-j}) \\ &= w_k - \hat{w}_{k,k-1} = \varepsilon_k \end{aligned} \quad (7.3.16)$$

由此可见, $\{y_k\}$ 与 $\{w_k\}$ 具有相同的新息序列 $\{\varepsilon_k\}$ 。类似于 (7.3.6) 与 (7.3.7), 也可得到

$$\hat{y}_{k+l,k} = \sum_{j=1}^k J_{k+l,j} \varepsilon_j \quad (7.3.17)$$

$$J_{k+l,j} = (E y_{k+l} \varepsilon_j) (E \varepsilon_j^2)^{-1} \quad (7.3.18)$$

由 $\{y_j\}$ 的定义知, 当 $k > Q$ 时

$$y_k = \varphi(B)w_k \equiv \theta(B)a_k$$

即 $\{y_k\}$ 是一个 q 阶滑动平均序列, 因此有

$$E y_k y_j = 0 \quad k > Q, 1 \leq j < k - q$$

由 (7.3.14) 得

$$E y_k \varepsilon_j = 0 \quad k > Q, 1 \leq j < k - q \quad (7.3.19)$$

由 (7.3.15) ~ (7.3.19) 即得 (7.3.10)。

又当 $k > j$ 时

$$\begin{aligned} E y_k \varepsilon_j &= E y_k \left(y_j - \sum_{i=1}^{j-1} J_{ji} \varepsilon_i \right) \\ &= \gamma_{kj}(y) - \sum_{i=1}^{j-1} J_{ji} E y_k \varepsilon_i \\ &= \gamma_{kj}(y) - \sum_{i=1}^{j-1} J_{ji} E \left\{ \left(\varepsilon_k - \sum_{l=1}^{k-1} J_{kl} \varepsilon_l \right) \varepsilon_i \right\} \\ &= \gamma_{kj}(y) - \sum_{i=1}^{j-1} J_{ji} J_{ki} \gamma_{ii}(\varepsilon) \end{aligned} \quad (7.3.20)$$

由 (7.3.18) ~ (7.3.20) 得 (7.3.11)。

$$\begin{aligned} \text{最后, } \gamma_{kk}(\varepsilon) &= E \varepsilon_k^2 = E \left(y_k - \sum_{j=1}^{k-1} J_{kj} \varepsilon_j \right)^2 \\ &= E y_k^2 - 2 \sum_{j=1}^{k-1} J_{kj} E y_k \varepsilon_j + E \left(\sum_{j=1}^{k-1} J_{kj} \varepsilon_j \right)^2 \end{aligned}$$

由此式及(7.3.5), (7.3.12), (7.3.18), (7.3.19)得(7.3.13)。

至此证明了新息定理。由此定理可见, 时刻 k 的新息 e_k 是随着样本数据 W_k 的输入经递推而获得的。

§ 3.3 新息预报及与平稳预报的比较

由§ 3.2 的新息定理, 可以推导出基于新息序列的适时预报递推公式。

由(7.3.10)式可得

$$e_{k+l} = \begin{cases} w_{k+l} - \sum_{j=1}^{k+l-1} J_{k+l,j} e_j & k+l \leq Q \\ w_{k+l} - \sum_{j=1}^p \varphi_j w_{k+l-j} - \sum_{j=k+l-q}^{k+l-1} J_{k+l,j} e_j & k+l > Q \end{cases}$$

将上式右边的求和项都移到等式左边, 求 w_{k+l} 在给定 $\mathscr{W}_k^1$ 时的线性最小方差估计, 便得到 l 步的适时预报公式

$$\hat{w}_{k+l,k} = \begin{cases} \sum_{j=1}^k J_{k+l,j} e_j & k+l \leq Q \\ \sum_{j=1}^p \varphi_j \hat{w}_{k+l-j,k} + \sum_{j=k+l-q}^k J_{k+l,j} e_j & k+l > Q \end{cases} \quad (7.3.21)$$

式中当 $l-j \leq 0$ 时, 取 $\hat{w}_{k+l-j,k} = w_{k+l-j}$, 并约定求和上限小于下限时, 取和值为零。

下面, 我们对于平稳预报和新息预报进行比较。

由(7.3.21)式可见, 当 $k+l > Q$ 时, 有

$$\varphi(B) \hat{w}_{k+l,k} = 0, \quad l > q \quad (7.3.22)$$

其中, 后移算子 B 作用在 l 上。

对于 $AR(p)$ 序列, 由于 $q=0, Q=\max(p, q)=p$, (7.3.22) 即为

$$\varphi(B) \hat{w}_{k+l,k} = 0, \quad l > 0, k > p$$

初值 $\hat{w}_{k+j,k} = w_{k+j}$ ($j=0, -1, \dots, -p+1$)。将此式与 $AR(p)$ 情形的(7.2.1)式比较, 可见当 $k > p$ 时, $AR(p)$ 序列的新息预报与平稳预报是完全相同的。因此

$$e_k = w_k - \hat{w}_{k,k-1} \equiv w_k - \hat{w}_{k-1}(1) = a_k, \quad k > p \quad (7.3.23)$$

这个结论从直观上也不难想见。因为我们在 §2 中已经讨论过，只有 AR 序列才可能从有限资料出发，对未来值实现严格的最小方差预报。

当 $\{w_k\}$ 是 MA 或 ARMA 序列时，一般 $e_k \neq a_k$ ，然而，由于 $\hat{w}_{k,k-1}$ 与 $\hat{w}_{k-1}(1)$ 分别是基于线性空间 $\mathscr{W}_{k-1}^1$ 或 $\mathscr{W}_{k-1}$ 的线性最小方差估计，显然 $\mathscr{W}_{k-1}^1 \subset \mathscr{W}_{k-1}$ ，从而得

$$\begin{aligned}\sigma_a^2 &= E[w_k - \hat{w}_{k-1}(1)]^2 \\ &\leq E[w_k - \hat{w}_{k,k-1}]^2 = E e_k^2 \\ &\leq E \left[w_k - \sum_{i=1}^{k-1} I_i w_{k-i} \right]^2 \\ &= E \left[a_k + \sum_{i=k}^{\infty} I_i w_{k-i} \right]^2 \\ &= \sigma_a^2 + E \left(\sum_{i=k}^{\infty} I_i w_{k-i} \right)^2\end{aligned}$$

由于逆函数 I_i 是负指数函数控制的，所以上式右边最后一个求和项的方差将随 k 的增长而趋于零，由此便得到

$$\sigma_a^2 = E(w_k - \hat{w}_{k-1}(1))^2 = \lim_{k \rightarrow \infty} E e_k^2 \quad (7.3.24)$$

另外，由于

$$E(a_k e_k) = E a_k (w_k - \hat{w}_{k,k-1}) = E a_k w_k = \sigma_a^2$$

故而

$$E(a_k - e_k)^2 = E a_k^2 + E e_k^2 - 2 E a_k e_k = E e_k^2 - \sigma_a^2 \rightarrow 0 \quad (7.3.25)$$

可见，当 $k \rightarrow \infty$ 时，平稳预报与新息预报不仅有渐近相等的一步预报误差方差，而且，两种预报的一步预报误差本身，也是渐近相等的。对于多步预报，运用类似的手法，也可得到相应的性质，这里不一一论证了。

上述分析和证明告诉我们，无论对于 AR、MA 或 ARMA 序列，当 k 充分大后，新息适时预报都与平稳预报渐近趋于一致。因此，在实际应用中，遇到连续预报问题时，如果要求从较少的数

据开始预报,并希望尽可能给出精确的预报值,那么,在开始一个阶段,可以进行适时预报。而当 k 增长到一定数量之后,为了减少每步的计算量,可以改用矢量递推法进行平稳预报。这样两种方法结合使用,既可提高预报精度,又可节省计算量。

对于 ARIMA 序列及带季节性趋势性的非平稳序列,也可类似于 § 2.4,经过适当的处理,从它们与平稳序列的关系出发,得到相应的新息预报公式。

§ 3.4 新息预报的程序设计

由新息定理可见,新息预报的计算过程是比较复杂的。本节对于有关的计算方法与技巧,进行简单的讨论。

1. 计算步骤: 我们假设在进行新息递推预报之前,已经根据已获得的有限长度数据序列,建立了 ARMA(p, q)模型,并由公式(7.3.9)产生了序列 $\{y_k\}$ 。设 N 为 $\{y_k\}$ 序列的总长度, L 为依据 $y_1, y_2, \dots, y_N$ 向未来进行预报的最大步长。由新息定理可知,随着 $\{y_k\}$ 的序贯输入,新息定理中的各数学量依如下次序进行计算

$$\begin{array}{ccccccc}
 y_1 & & y_2 & & y_3 & & J_{41} \\
 \downarrow & & \downarrow & & \downarrow & & \\
 \varepsilon_1 \rightarrow \gamma_{11}(\varepsilon) \rightarrow J_{21} \rightarrow \varepsilon_2 \rightarrow \gamma_{22}(\varepsilon) \rightarrow J_{31} \rightarrow \varepsilon_3 \rightarrow \gamma_{33}(\varepsilon) \rightarrow J_{41} & & & & & & \\
 & & & & J_{32} & & J_{42} \\
 & & & & & & J_{43} \\
 & & & & & & \rightarrow \dots
 \end{array}
 \quad (7.3.26)$$

其中,计算初值为

$$\varepsilon_1 = y_1 - w_1, \quad \gamma_{11}(\varepsilon) = \gamma_0(w) = \frac{1}{N} \sum_{k=1}^N w_k^2 \quad (7.3.27)$$

2. $\gamma_{kj}(y)$ 的计算: 利用 ARMA(p, q)序列的平稳性和零均值性, $\gamma_{kj}(y)$ 可以借助于 $\gamma_{kj}(w)$ 直接计算得到。

设 $k \geq j$, 则

$$\gamma_{kj}(y) = E y_k y_j = \begin{cases} E w_k w_j = \gamma_{k-j}(w) & j \leq k < Q \\ E y_k w_j = \varphi(B) \gamma_{k-j}(w) & j \leq Q < k \\ E y_k y_j = \varphi(B) \varphi(B^{-1}) \gamma_{k-j}(w) & Q < j \leq k \end{cases} \quad (7.3.28)$$

其中, $\varphi(B^{-1}) \triangleq 1 - \varphi_1 B^{-1} - \varphi_2 B^{-2} - \dots - \varphi_p B^{-p}$ (7.3.29)

算子 B 作用在 $\gamma_{k-j}(w)$ 的下标 $(k-j)$ 上, 例如

$$B^l \gamma_{k-j}(w) = \gamma_{k-j-l}(w)$$

具体计算时, $\gamma_{k-j}(w)$ 由它的样本估计值

$$\frac{1}{N} \sum_{l=1}^{N-(k-j)} w_l w_{l+(k-j)} \text{ 代替}$$

由(7.3.29)可见, 对于平稳序列 $\{y_k\}$, $\gamma_{k,j}(y)$ 只是 $k-j$ 的函数, 而和 k, j 的具体取值无关。而且, 由于 $\gamma_{k,j}(y)$ 的计算只和自回归系数及样本值有关, 而和滑动平均系数无关, 如果模型是纯滑动平均的, 只要能判断出模型阶数, 就可不必对模型参数进行估计, 直接计算 $\gamma_{k,j}(y)$, 进行新息预报。因此, 新息预报对于滑动平均模型具有更特殊的意义。

由新息定理可见, 当 $k \leq Q$ 时, 需要用到 $\gamma_{k1}(y), \gamma_{k2}(y), \dots, \gamma_{kk}(y)$ 这 k 个 $\gamma_{k,j}(y)$, 因此, $\gamma_{k,j}(y)$ 的需要量是随着 k 的增加而增加的。然而, 由于 $\{y_k\}$ 具有平稳性, $\gamma_{k,j}(y)$ 仅和 $k-j$ 的数值有关, 因此, 对于相同的 $k-j$ 值, $\gamma_{k,j}(y)$ 均取同一数值。利用这一规律, 又可减少 $\gamma_{k,j}(y)$ 的计算量。现将 $k \leq Q$ 时 $\gamma_{k,j}(y)$ 的计算量与运算规律列成下表, 为简单起见, 一律省略括号 (y) 。

表 7.1 $K \leq \alpha$ 时新息递推中 $\gamma_{k,j}(y)$ 的计算规律




表 7.1 中,虚线相联结的 $\gamma_{k,j}(y)$ 都有相同的 $k-j$ 值。因此,只要计算出 $\gamma_{k,1}(y)$,同一斜虚线上的 $\gamma_{k,j}(y)$ 数值就已知了。对于 $k \leq Q$ 的情形,需要计算的 $\gamma_{k,1}(y)$ 全体在表 7.1 中用长方框标出,计算公式见(7.3.28)情形 1。

由新息定理可见,当 $k > Q$ 后,递推计算中只要得到 $\gamma_{k,j}(y)$, $k-q < j \leq k$ 这 $q+1$ 个值就够了。因此,当 $k > Q$ 后,随着 k 的增加, $\gamma_{k,j}(y)$ 需要的计算机存贮单元不再增加。而且由于 $\gamma_{k,j}(y)$ 仅与 $k-j$ 有关,并仅在 $j=Q+1$ 处产生间断,所以只有当 $Q < k < Q+q+1$ 时,对于 $\gamma_{k,q+1}(y)$ 要重新计算,其余的 $\gamma_{k,j}(y)$ 可以根据本身的规律推算出来。为了形象地说明这一特点,我们将 $k > Q$ 后所需计算的 $\gamma_{k,j}(y)$ 排列成下表

表 7.2 $k > Q$ 时 $\gamma_{k,j}(y)$ 的计算规律

$k = Q+1$	$\gamma_{Q+1,Q+1}$	$\gamma_{Q+1,Q+2}$	$\gamma_{Q+1,Q+3}$	$\gamma_{Q+1,Q+4}$
$k = Q+2$	$\gamma_{Q+2,Q+1}$	$\gamma_{Q+2,Q+2}$	$\gamma_{Q+2,Q+3}$	$\gamma_{Q+2,Q+4}$
$k = Q+3$	$\gamma_{Q+3,Q+1}$	$\gamma_{Q+3,Q+2}$	$\gamma_{Q+3,Q+3}$	$\gamma_{Q+3,Q+4}$
$k = Q+4$	$\gamma_{Q+4,Q+1}$	$\gamma_{Q+4,Q+2}$	$\gamma_{Q+4,Q+3}$	$\gamma_{Q+4,Q+4}$
$k = Q+5$	$\gamma_{Q+5,Q+1}$	$\gamma_{Q+5,Q+2}$	$\gamma_{Q+5,Q+3}$	$\gamma_{Q+5,Q+4}$
$k = Q+q+1$	$\gamma_{Q+q+1,Q+1}$	$\gamma_{Q+q+1,Q+2}$	$\gamma_{Q+q+1,Q+3}$	$\gamma_{Q+q+1,Q+4}$

$k = Q+q+1$

表 7.2 中,每一行中排列的是所需要用到的 $\gamma_{k,j}(y)$, 第一行上的长方框标志着其中的 $\gamma_{Q+1,j}$ 要按公式(7.3.28)中的情形 2 计算。用斜虚线相联结的 $\gamma_{k,j}(y)$ 都具有相同的 $k-j$ 值,因此,后排的 $\gamma_{k,j}(y)$ 其值与前排斜上方的 $\gamma_{k,j}(y)$ 相同,无需再进行计算。这种延续关系,在虚线伸延到 $j=Q+1$ 这一列时(表中用竖着的长方框标出),就会发生间断,依据公式(7.3.28)中第三种情形,计算出新的 $\gamma_{k,q+1}(y)$ 值后,同一斜虚线上的 $\gamma_{k,j}(y)$ 又有相等的关系了。从 $k > Q+q+1$ 后, $\gamma_{k,j}(y)$ 不再发生间断,也就无需再计


算了。

3. $J_{k,j}$ 的计算:新息递推公式中,计算量最大、计算过程最复杂的要算 $J_{k,j}$ 。由公式 (7.3.10)~(7.3.13) 可见, $J_{k,j}$ 的计算分为以下三种情形:

i) $k \leq Q$ ii) $Q < k \leq N$ iii) $N < k \leq N + L$

下面我们对各种情形分别进行讨论。


i) $k \leq Q$ 。这种情形,每算一个 ε_k , 需要用到 $J_{k1}, J_{k2}, \dots, J_{k,k-1}$ 。而计算 $J_{k,j} (j > 1)^*$ 时,又要用到 $J_{j1}, J_{j2}, \dots, J_{j,j-1}$ 和 $J_{k1}, J_{k2}, \dots, J_{k,j-1}$ 。计算量是随着 k 的增加而增加的。如果将这时需用的 $J_{k,j}$ 排列成如下形状




那么,每计算一行 $J_{k,j}, j=1, 2, \dots, k-1$,就要用到以 $k-1$ 这一行为底边的直角三角形内全部的 $J_{k,j}$ 值。在 $2 \leq k \leq Q$ 范围内,三角阵元素总个数为 $\frac{1}{2}Q(Q-1)$ 。

ii) $Q < k \leq N$ 。这种情形,计算每个 ε_k ,只要求计算 $J_{k,k-q}, \dots, J_{k,k-1}$ 这 q 个值,计算量不再随着 k 增加;计算每一个 $J_{k,j}$,需要依次用到 $J_{j,k-q}, \dots, J_{j,j-1}$ 和 $J_{k,k-q}, \dots, J_{k,j-1}$ 。将计算 $J_{k,k-q}, \dots, J_{k,k-1}$ 所依次用到的全体 $J_{k,i}$ 与 J_{ji} 排列起来,恰巧也是一个三角阵,阵中元素个数为 $\frac{1}{2}q(q-1)$ 。

* 当 $j=1$ 时, (7.3.11) 式中的求和项按约定取零值,故 $J_{k1} = \gamma_{k1}(y) / \gamma_{k1}(e)$ 。



iii) $N < k \leq N + L$ 。当 k 属于这一范围时, 计算已进入新息预报阶段。由于这时不再输入新资料, 因此, 显然有 $\varepsilon_k = 0$ 。为计算 $\hat{w}_{k,N}$, 只要知道 $J_{k, k-Q}, \dots, J_{k, N}$ 就够了。 $J_{k,j}$ 的计算步骤同于情形 ii), 只是随着 k 的增加, 需要计算的 $J_{k,j}$ 个数是递减的。将这个范围内用到的 $J_{k,j}$ 排列起来, 可以得到如下一个倒置的直角梯形。




将以上分析的三种情形综合起来, 关于 $J_{k,j}$ 的计算量和计算规律可由表 7.3 表示。

由表 7.3 可见, 当 $k \leq N$ 时, 每计算某三角形 ABC 底边 BC 上的元素, 就要依次取用到 $\triangle ABC$ 内的每一个元素。 $k \leq Q$ 时, 直角边 BC 的长度随 k 而增长, 而顶点 A 在 J_{21} 处保持不动。当 $Q < k \leq N$ 时, 随着 k 的增加, 三角形 ABC 在两条平行线内往斜下方滑动。当 $k > N$ 之后, 所需要的 $J_{k,j}$ 不再排列成三角形, 而是构成一个随 k 增加渐次变小的直角梯形。

如果在实际计算中按此图形来安排存贮, 那就应该准备 $(N + L) \times N$ 个存贮单元, 显然是既很浪费, 又非常地不合理。比较自

表 7.3 J_{kj} 的计算规律



然而又直观的设计是以三角形 ABC 的形状和大小来安排二维数组 J_{kj} 的存贮, 即采用下三角矩阵存贮。然而, 对计算公式 (7.3.11) 进行分析后, 发现三角阵 ABC 中的 J_{kj} 是很有规律地按行依次参加计算的。这就启发我们, 可以将三角形 ABC 中元素按行改为一维数组来排列。当 $k \leq Q$ 时, 数组长为 $\frac{1}{2}Q(Q-1)$; $Q < k \leq N$ 时, 长为 $\frac{1}{2}q(q-1)$, 这样可以大大节省存贮。采用一维数组来存贮 J_{kj} 后, J_{kj} 的下标 k 和 j 不再含有行和列的意思, 而只表示它在数组中的相对位置。在依次计算底边 BC 上各个 J_{kj} 时, 所需用到的 J_{ji} 就在一维数组中顺次取用; 而所需用到的 J_{ki} , 就在一维数组中从倒数第 Q (或 q) 个开始依次取用。如此设计, 节省了计算机中搜索时间, 减少了计算量。


4. 移位技巧: 下面, 我们简单介绍一下在新息递推预报设计

中的移位技巧。仍旧对公式中的三类计算量分别进行讨论。

i) e_k 的移位: 当 $k \leq Q$ 时, e_k 的需要量随 k 增加, 这时不需要移位。当 $k > Q$ 后, 每计算一个新的 e_{k+1} , 需要用到 $\{e_{k-q}, e_{k-q+1}, \dots, e_k\}$, 因此对于每一个 k , 只要存贮这样一个长为 $q+1$ 的一维数组就够了, 当 e_{k+1} 计算出来后, 将原数组左移一位, 产生新的数组 $\{e_{k+1-q}, e_{k+1-q+1}, \dots, e_{k+1}\}$ 就为计算 e_{k+1} 做好了准备。

ii) $\gamma_{kk}(e)$ 的移位: 为简单记, 用 $\gamma_k(e)$ 代替 $\gamma_{kk}(e)$ 。这一数学量的移位与 e_k 完全类似。当 $k \leq Q$ 时, 不予讨论; $k > Q$ 后, 每计算一个新的 $\gamma_{k+1}(e)$, 需要用到一个长为 $q+1$ 的一维数组 $\{\gamma_{k-q}(e), \dots, \gamma_k(e)\}$ 。当 $\gamma_{k+1}(e)$ 计算得后, 将原数组左移一位, 产生新数组 $\{\gamma_{k+1-q}(e), \dots, \gamma_{k+1}(e)\}$, 即为 $\gamma_{k+2}(e)$ 的计算做好了准备。

iii) J_k 的移位: 在讨论 J_k 的计算方法时, 我们已采用了一维数组来代替三角阵 ABC 。当 k 增加时, 三角形 ABC 沿平行线向斜下方的滑动, 也可以通过相应的一维数组有规律的位移来实现。我们将时刻 k 与时刻 $k+1$ 所相应的两个三角形之间的关系形象地用下图表示。



标号 $1, 2, \dots$ 表示 $\triangle ABC$ 中元素在一维数组中排列的次序。不难看出, 当 k 增至 $k+1$ 后, 三角阵中一维数组要进行如下的移位:

新位	1	2 3	4 5 6	7 8 9 10	11 12 13 14 15	
	↑	↑ ↑	↑ ↑ ↑	↑ ↑ ↑ ↑	↑ ↑ ↑ ↑ ↑	
旧位	3	5 6	8 9 10	12 13 14 15	17 18 19 20 21	

当 k 从 Q 增加到 $Q+1$ 时, 直角三角形要取消原 AB 边方向上的前 $Q-q$ 列所有元素, 位移规律同上。所有这一切都可与 $J_{k,}$ 的计算同时实现。

最后还需强调的一点是, 对于 w_i 得到新息预报的结果之后, 仍需进行还原变换, 反演到原始资料 z_i 的预报去。

§ 3.5 电力负荷的新息预报^[24]

电力系统要求对于未来 24 小时的负荷情况进行较准确的预测。我们将一周以内(每小时一个数据) 所获得的负荷资料 $z_1, z_2, \dots, z_N$ 作为时间序列的样本值, 长度 $N=24 \times 7=168$ 。

数据 $z_1, z_2, \dots, z_N$ 有一个长度为 24 的明显周期和逐渐增长的趋势。因此在建立模型之前, 先对数据进行平稳化处理

$$w_{t-25} = \nabla \nabla_{24} z_t = (1-B)(1-B^{24})z_t \quad t \geq 25$$

新序列 $\{w_t\}$ 的平稳性可被接受。对样本协方差函数进行相关分析的结果, 还发现其具有很好的规律, 例如对某组数据, 算得样本自相关函数 $\hat{\rho}_1, \hat{\rho}_2, \dots, \hat{\rho}_{31}$, 按行依次记录于下:

-0.4166	-0.0205	-0.0524	-0.0075	-0.0135
-0.0304	-0.0355	0.0128	0.0007	0.0130
-0.0256	0.0089	0.0184	0.0033	0.0129
0.0143	0.0032	0.0177	-0.0418	0.0251
0.0085	0.0007	0.2463	0.4925	0.1525
-0.0279	0.0033	-0.0074	0.0220	0.0227
0.0294				

$\hat{\rho}_k, k > 31$ 均在 0.0 * 以下。

由上可见, 除了 $\hat{\rho}_1, \hat{\rho}_{23}, \hat{\rho}_{24}, \hat{\rho}_{25}$ 外, 其余的自相关函数都很小, 而且可判断在 25 步截尾, 对于多组数据进行计算, 都得到同样的




图 7.1 某电力系统负荷实测值与新息预报、人工预报的比较

结果。因此认为可采用 25 阶滑动平均模型 MA(25) 来描述电力系统的负荷序列。即

$$\nabla \nabla_{24} z_t = \theta(B) a_t$$

$$\theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_{25} B^{25}$$

由 §3.4 第 2 点的讨论得知, 我们不必估计 $\theta_1, \theta_2, \dots, \theta_{25}$, 便可直接对此模型进行新息预报。

图 7.1 给出了某电力系统负荷实测值与新息预报、人工预报的比较。我们知道, 电力系统次日 24 小时预报和安全控制所需的负荷预报是电网调度中安全、经济控制的基础。目前, 国内外多数电力系统主要依靠人工预报。图 7.1 的结果表明, 在正常情况下, 24 小时预报的相对误差为 2~4%, 故可代替人工预报。而且, 有经验的预报员根据过去负荷数据对未来 24 小时进行负荷人工估计, 一般要花费两个小时, 但采用平均速度为 15 万次/秒的 6912 数字机进行数值计算, 次日 24 小时预报包括打印结果, 总共只需 2.5 分钟。用同一程序, 还可进行电力系统在线安全控制所需的半小时~2 小时预报, 相对误差也在 2% 以内。故用新息法进行电力负荷值预报, 将可能代替人工劳动, 而成为电网数字机安全、经济控制中的重要一环。

第八章 多维动态数据分析

前几章讨论了一个因素即一维的时间序列及模型辨识。对于许多实际问题,仅仅考虑一个因素往往是不够的。譬如,对于某地区月平均气温的预报,根据历年月平均气温资料 $\{c_t\}$,可以用前几章的办法,对这个一维的动态数据进行模型辨识,确定出平均气温的动态数据适合的模型,并可作出预报。但是仅根据气温数据的历史值作预报,往往得不到理想结果。事实上,气温与其它一些气象动态数据,如气压、雨量等动态数据密切相关,如果将气温、气压和雨量等多种指标综合考虑,就会提高预报的准确性。我们分别记 $\{c_t\}$, $\{p_t\}$ 和 $\{h_t\}$ 为气温,气压和雨量动态数据,对这三种指标综合考虑,就需要处理一个三维的随机序列

$$z_t = \begin{pmatrix} c_t \\ p_t \\ h_t \end{pmatrix}$$

即要对 $\{z_t\}$ 进行模型辨识,参数估计并通过它们来预报我们感兴趣的量,如 c_t 。

又如,要分析一个比较复杂的控制系统,在 t 时刻它有 r 个输入 $y_t^{(1)}, \dots, y_t^{(r)}$, l 个输出 $x_t^{(1)}, \dots, x_t^{(l)}$,在有些场合,前者是可控制的。为了对这个系统进行较好的控制,就需要对

$$z_t = \begin{pmatrix} x_t^{(1)} \\ \vdots \\ x_t^{(l)} \\ y_t^{(1)} \\ \vdots \\ y_t^{(r)} \end{pmatrix}$$

进行模型辨识,其中 z_t 是 $l+r$ 维的。

本章将对 k 维动态数据序列讨论模型辨识与预报问题。为了

简单起见,只考虑多维自回归模型的辨识;本章还引入了自回归模型定阶的最终预报误差(Final Prediction Error)准则,或简称为FPE 准则;并将一维情形的 AIC 准则推广到对多维 ARMA 模型进行定阶。指出了在自回归模型情形 AIC 与 FPE 准则二者的等价性;本章最后,还结合实例介绍了多维时间序列的计算方法。

§ 1 多维线性时间序列分析模型

§ 1.1 多维 ARMA 模型

现在我们一般地考虑一个 k 维零均值平稳序列 $\{z_t\}$, 如果它包含季节性或其它趋势性,就需要先按第五、六章的办法进行季节差分或差分办法,或者分离出确定性部分,使处理后产生的序列满足零均值平稳条件。设 $\{z_t\}$ 满足下面的模型方程

$$z_t = A_1 z_{t-1} + \cdots + A_p z_{t-p} + u_t + M_1 u_{t-1} + \cdots + M_q u_{t-q} \quad (8.1.1)$$

其中 $A_i (i=1, 2, \cdots, p), M_j (j=1, 2, \cdots, q)$ 是 $k \times k$ 矩阵, $A_p \neq 0, M_q \neq 0, \{u_t\}$ 是 k 维白噪声序列,即

$$\begin{aligned} E u_t &= 0 \\ E u_t u_s^T &= \begin{cases} S, & \text{当 } t=s \\ 0, & \text{当 } t \neq s \end{cases} \end{aligned} \quad (8.1.2)$$

S 是 $k \times k$ 正定阵。又设 $E u_t z_{t-j}^T = 0, j=1, 2, \cdots$ 。记算子 B 的 $k \times k$ 矩阵多项式

$$A(B) \triangleq I - A_1 B - \cdots - A_p B^p$$

$$M(B) \triangleq I - M_1 B - \cdots - M_q B^q$$

其中 I 为 $k \times k$ 单位阵,若 $\det A(B) = 0$ 的根全在单位圆外,则称模型(8.1.1)具有平稳性。类似地,若 $\det M(B) = 0$ 的根全在单位圆外,则称(8.1.1)具有可逆性。如果 $\{z_t\}$ 满足(8.1.1)及上述平稳可逆条件,且 B 的多项式矩阵 $A(B)$ 与 $M(B)$ 是左互质的(即若有 B 的多项式矩阵 $C(B)$,使得 $A(B) = C(B)A_1(B), M(B) = C(B)M_1(B)$, 则必定有 $|C(B)| \equiv \text{常数}$), 那么,称 $\{z_t\}$ 为 k 维

ARMA (p, q) 序列或称 $\{z_t\}$ 是 k 维的 ARMA (p, q) 模型。特别 $q=0$ 时, $\{z_t\}$ 就是 p 阶的 k 维 AR 序列; $p=0$ 时, $\{z_t\}$ 就是 q 阶的 k 维 MA 序列。一般地, ARMA (p, q) 序列 $\{z_t\}$ 相应的谱密度函数矩阵为

$$f(\lambda) = K(e^{-i2\pi\lambda}) S K^*(e^{-i2\pi\lambda}) \quad (8.1.3)$$

其中, $K(e^{-i2\pi\lambda}) = A^{-1}(e^{-i2\pi\lambda}) M(e^{-i2\pi\lambda})$, $*$ 号表示矩阵的共轭转置, $f(\lambda)$ 是 $k \times k$ 的函数矩阵。

与一维情形类似, 模型 (8.1.1) 也存在平稳域或可逆域的问题。因为多维情形比较复杂, 本章不予讨论。

在一定的情形下, 多维情形也可对各分量引入差分, 季节差分或二者的乘积运算, 再建立 ARMA 模型。即 z_t 的各分量作如下运算

$$\begin{pmatrix} (1-B)^{d_1} z_t^{(1)} \\ (1-B)^{d_2} z_t^{(2)} \\ \vdots \\ (1-B)^{d_k} z_t^{(k)} \end{pmatrix}, \begin{pmatrix} (1-B^{s_1})^{D_1} z_t^{(1)} \\ (1-B^{s_2})^{D_2} z_t^{(2)} \\ \vdots \\ (1-B^{s_k})^{D_k} z_t^{(k)} \end{pmatrix}$$

或

$$\begin{pmatrix} (1-B)^{d_1} (1-B^{s_1})^{D_1} z_t^{(1)} \\ (1-B)^{d_2} (1-B^{s_2})^{D_2} z_t^{(2)} \\ \vdots \\ (1-B)^{d_k} (1-B^{s_k})^{D_k} z_t^{(k)} \end{pmatrix} \quad (8.1.3)''$$

之后再建立 ARMA 模型, 其中 $z_t = \begin{pmatrix} z_t^{(1)} \\ z_t^{(2)} \\ \vdots \\ z_t^{(k)} \end{pmatrix}$

§ 1.2 多维自回归模型

由于一般地讨论多维 ARMA (p, q) 模型比较困难, 因此, 本章只限于讨论多维 AR (p) 模型, 即满足

$$z_t - A_1 z_{t-1} - \cdots - A_p z_{t-p} = u_t$$

其中 $A_p \neq 0$, 且 $A(B)$ 满足平稳性。与一维情形类似, 在许多情况

下, 只讨论多维 AR 模型通常是够用的。因为它可以逼近多维 ARMA 模型或更一般的多维平稳模型。

我们回忆一下, 在一维情形, AR 模型的阶是如何辨识的? 考虑一维 p 阶 AR 模型

$$w_t - \varphi_1 w_{t-1} - \cdots - \varphi_p w_{t-p} = a_t$$

零均值平稳序列 $\{w_t\}$ 的自相关函数和偏相关函数分别记为 $\{\rho_k\}$ 和 $\{\varphi_{kk}\}$ 。如果 $\{\varphi_{kk}\}$ 是 p 步截尾的, 即 $\varphi_{pp} \neq 0$, 而 $k > p$ 时, $\varphi_{kk} = 0$, 于是可以确定 $\{w_t\}$ 满足 p 阶 AR 模型。识别自回归模型的具体方法是先求出样本自相关函数 $\{\hat{\rho}_k\}$, 再由下面 Yule-Walker 方程计算出 $\{\hat{\varphi}_{kk}\}$

$$\begin{pmatrix} \hat{\gamma}_0 & \hat{\gamma}_1 & \cdots & \hat{\gamma}_{k-1} \\ \hat{\gamma}_1 & \hat{\gamma}_0 & \cdots & \hat{\gamma}_{k-2} \\ \vdots & \vdots & & \vdots \\ \hat{\gamma}_{k-1} & \hat{\gamma}_{k-2} & \cdots & \hat{\gamma}_0 \end{pmatrix} \begin{pmatrix} \hat{\varphi}_{k1} \\ \hat{\varphi}_{k2} \\ \vdots \\ \hat{\varphi}_{kk} \end{pmatrix} = \begin{pmatrix} \hat{\gamma}_1 \\ \hat{\gamma}_2 \\ \vdots \\ \hat{\gamma}_k \end{pmatrix}$$

然后判断 $\{\hat{\varphi}_{kk}\}$ 在那一步截尾。若在 $k > p$ 以后可以认为 $\hat{\varphi}_{kk} = 0$, 而 $\hat{\varphi}_{pp} \neq 0$ (不能认为是零), 那么, 就识别 $\{x_t\}$ 是 p 阶自回归模型, 并且 $\hat{\varphi}_{p1}, \hat{\varphi}_{p2}, \cdots, \hat{\varphi}_{pp}$ 是自回归系数 $\varphi_1, \varphi_2, \cdots, \varphi_p$ 的 Yule-Walker 估计。其中 $\hat{\varphi}_{p1}, \hat{\varphi}_{p2}, \cdots, \hat{\varphi}_{pp}$ 可由如下递推公式计算

$$\begin{cases} \hat{\varphi}_{11} = \hat{\gamma}_1 \hat{\gamma}_0^{-1} \\ \hat{\varphi}_{p+1,p+1} = \left(\hat{\gamma}_{p+1} - \sum_{j=1}^p \hat{\varphi}_{pj} \hat{\gamma}_{p+1-j} \right) \left(\hat{\gamma}_0 - \sum_{j=1}^p \hat{\varphi}_{pj} \hat{\gamma}_j \right)^{-1} \\ \hat{\varphi}_{p+1,j} = \hat{\varphi}_{pj} - \hat{\varphi}_{p+1,p+1} \hat{\varphi}_{p,p+1-j} \quad j=1, 2, \cdots, p \end{cases} \quad (8.1.4)$$

问题在于如何判断 $\hat{\varphi}_{kk} = 0$ 。根据 $\hat{\varphi}_{kk}$ 的渐近正态的性质, 提出的办法是: 如果样本动态数据序列长度为 N , 自某个正整数 p 以后

有 95.5% 以上的 $|\hat{\varphi}_{kk}| < \frac{2}{\sqrt{N}}$, 而在之前不满足, 就认为 $\{\hat{\varphi}_{kk}\}$ 是

p 步截尾, 即判断 $k > p$ 时 $\hat{\varphi}_{kk} = 0$; 如果这样的 p 找不到, 就认为 $\{\hat{\varphi}_{kk}\}$ 是拖尾。上述识别方法多少有些不确定性和人为性。譬如, 到底 k 考察到多大才能看出正确的百分比? 处于临界状态应如何

判定? 此外,把这种思想推广到多维 AR 模型的辨识,显然是既困难又复杂的。

1971 年, H. Akaike^[15] 提出了另一种辨识 AR 模型的阶的准则,称为最小最终预报误差准则,简称为最小 FPE 准则(MFPEC)。1973 年又推广到辨识 ARMA 模型的阶的准则,称为最小信息准则,简称为最小 AIC 准则(MAIC)。最小 FPE 准则的这种想法是比较自然的。因为想要辨识或拟合一个实际对象的数学模型,目的是从这个模型出发推导出未知的结果,即用现今已掌握的有关实际对象的信息去预报未来。因此,如果预报误差方差越小,显然就可认为模型拟合得越好。以下几节我们将详细讨论多维 AR 模型的辨识和预报问题。

§ 1.3 多输入多输出的多维线性模型

本节我们讨论一类带有输入输出的开环多维自回归模型。这类模型便于带有控制变量的模型辨识,它的特殊情形还提供了研究一类多维输入单个输出问题的简便办法。

设 k 维随机序列($k=l+r$)

$\mathbf{z}_i = (x_i^{(1)}, \dots, x_i^{(l)}, y_i^{(1)}, \dots, y_i^{(r)})^T$, 其中 $y_i^{(1)}, \dots, y_i^{(r)}$ 为 r 个输入量, $x_i^{(1)}, \dots, x_i^{(l)}$ 为 l 个输出量, $\{\mathbf{z}_i\}$ 满足如下形式的自回归模型

$$\mathbf{z}_i = \sum_{j=1}^p A_{pj} \mathbf{z}_{i-j} + \mathbf{u}_i \quad (8.1.5)$$

如果系数矩阵 A_{pj} ($j=1, 2, \dots, p$) 用分块表示为

$$A_{pj} = \begin{pmatrix} A_{pj}^{(1,1)} & A_{pj}^{(1,2)} \\ A_{pj}^{(2,1)} & A_{pj}^{(2,2)} \end{pmatrix} \quad j=1, 2, \dots, p \quad (8.1.6)$$

其中 $A_{pj}^{(1,1)}$ 为 $l \times l$ 矩阵, $A_{pj}^{(1,2)}$ 为 $l \times r$ 矩阵, $A_{pj}^{(2,1)}$ 为 $r \times l$ 矩阵, $A_{pj}^{(2,2)}$ 为 $r \times r$ 矩阵。那么,将(8.1.5)分块表示后,立即可以得到输出量与输入量之间的如下关系式

$$\mathbf{z}_i = \sum_{j=1}^p A_{pj}^{(1,1)} \mathbf{z}_{i-j} + \sum_{j=1}^p A_{pj}^{(1,2)} \mathbf{y}_{i-j} + \mathbf{u}_i^{(1)} \quad (8.1.7)$$

其中 $x_i = (x_i^{(1)}, \dots, x_i^{(l)})^T, y_i = (y_i^{(1)}, \dots, y_i^{(r)})^T$

$$u_i = \begin{pmatrix} u_i^{(1)} \\ u_i^{(2)} \end{pmatrix}$$

$u_i^{(1)}$ 为 u_i 的前 l 个分量组成的 l 维向量, (8.1.7) 式是一种带有输入量 $\{y_i\}$ 的自回归模型, 因此, 称为开环自回归模型。在讨论控制问题时, (8.1.7) 式右端的 y_i 常常代表控制变量, 因此, 这类模型是研究控制问题的模型辨识的一个较好办法。

特别地, 如果输出量 x_i 是标量, 则系统是单输出多输入的情形。由于 $l=1$, 模型 (8.1.7) 将是标量形式, 若记

$$A_{pj} = (a_{pj}^{(i,l)})_{k \times k}$$

上式表示 p 和 j 固定, $i, l=1, 2, \dots, k$ 的 $k \times k$ 矩阵, 则 (8.1.7) 经整理可表为

$$x_i = \sum_{j=1}^p a_{pj}^{(1,1)} x_{i-j} + \sum_{j=1}^r \sum_{l=1}^p a_{pj}^{(l,i+1)} y_{i-j}^{(l)} + u_i^{(1)} \quad (8.1.8)$$

这是一类带有多输入的一维自回归模型, 它是第二章中介绍过的 $AR(p)$ 模型的推广, 其参数估计、模型定阶及预报完全可以用第三章和第七章的方法来进行。因此, 对于单输出多输入的多维时间序列的问题, 可以利用 (8.1.8) 这种模型来描述, 将本来比较复杂的多维序列辨识问题转化为简单的一维情形去处理, 这在实用上是有很多方便之处的。例如, 我们仅对雨量预报感兴趣, 而参照同期气温、气压等资料, 便可以雨量为输出, 气温、气压为输入, 建立 (8.1.8) 式的模型, 再进行雨量预报。

§ 2 多维自回归模型参数估计

对 k 维动态数据建立 k 维 AR 模型, 就是依据 k 维平稳序列 $\{x_i\}$ 的样本值估计出 AR 模型的阶数 p , 估计出系数矩阵 A_j ($j=1, 2, \dots, p$) 及 k 维平稳白噪声方差矩阵 S 。关于如何定阶的问题将在后面讨论, 现在先假定 p 为已知, 求 A_j ($j=1, 2, \dots, p$) 和 S 的估计。

§ 2.1 系数矩阵的 Yule-Walker 估计

设 $\{z_t\}$ 为 p 阶 AR 模型, 即

$$z_t = A_1 z_{t-1} + \cdots + A_p z_{t-p} + u_t \quad (8.2.1)$$

等式(8.2.1)两边乘以 z_{t-h}^T , 并求数学期望得

$$\gamma_h = \sum_{i=1}^p A_i \gamma_{h-i} \quad h=1, 2, \cdots \quad (8.2.2)$$

$$\gamma_0 = \sum_{i=1}^p A_i \gamma_{i-i} A_i^T + S = \sum_{i=1}^p \gamma_i A_i^T + S$$

其中, γ_h ($h=0, 1, 2, \cdots$) 都是 $k \times k$ 矩阵。由(8.2.2)取 $h=1, 2, \cdots, p$, 利用 $\gamma_{-h} = \gamma_h^T$, 可得下面矩阵型的线性方程组

$$\begin{pmatrix} \gamma_1^T \\ \gamma_2^T \\ \vdots \\ \gamma_p^T \end{pmatrix} = \begin{pmatrix} \gamma_0 & \gamma_1 & \cdots & \gamma_{p-1} \\ \gamma_1^T & \gamma_0 & \cdots & \gamma_{p-2} \\ \vdots & \ddots & \ddots & \vdots \\ \gamma_{p-1}^T & \gamma_{p-2}^T & \cdots & \gamma_0 \end{pmatrix} \begin{pmatrix} A_1^T \\ A_2^T \\ \vdots \\ A_p^T \end{pmatrix} \quad (8.2.3)$$

由此可见, 假若我们能求得 γ_h 的估计值 $\hat{\gamma}_h$, 并将此样本估计值 $\hat{\gamma}$ 代入上面的矩阵线性方程组(8.2.3), 只要能保证(8.2.3)式系数矩阵可逆, 就能解得 A_j ($j=1, 2, \cdots, p$) 的估计值 $\hat{A}_j$ ($j=1, 2, \cdots, p$)。在统计学上这类估计称为矩估计。对于多维 AR 模型, 这样得到的 A_j ($j=1, 2, \cdots, p$) 的估计 $\hat{A}_j$ ($j=1, 2, \cdots, p$) 也称为 Yule-Walker 估计。

当样本的长度 N 充分大时, 可取

$$\hat{\gamma}_h = \frac{1}{N} \sum_{t=h+1}^N z_t z_{t-h}^T \quad (8.2.4)$$

作为 γ_h 的估计。从理论上可知这个估计量有很多优点, 如正定性、渐近无偏性、弱相容性和渐近正态性等等, 并且它的估计误差方差阵

$$E(\hat{\gamma}_h - \gamma_h)(\hat{\gamma}_h - \gamma_h)^T$$

的数量级为 $\frac{1}{N}$, 令

$$\hat{\Gamma}_p = \begin{pmatrix} \hat{\gamma}_0 & \hat{\gamma}_1 & \cdots & \hat{\gamma}_{p-1} \\ \hat{\gamma}_1^T & \hat{\gamma}_0 & \cdots & \hat{\gamma}_{p-2} \\ \vdots & & \ddots & \\ \hat{\gamma}_{p-1}^T & \hat{\gamma}_{p-2}^T & \cdots & \hat{\gamma}_0 \end{pmatrix}, \quad \hat{\eta}_p = \begin{pmatrix} \hat{\gamma}_1^T \\ \hat{\gamma}_2^T \\ \vdots \\ \hat{\gamma}_p^T \end{pmatrix}, \quad \hat{\mathcal{A}}_p = \begin{pmatrix} \hat{A}_1^T \\ \hat{A}_2^T \\ \vdots \\ \hat{A}_p^T \end{pmatrix} \quad (8.2.5)$$

(8.2.3)式可表为

$$\hat{\Gamma}_p \hat{\mathcal{A}}_p = \hat{\eta}_p \quad (8.2.3)'$$

由 $\hat{\gamma}_k, k=0, 1, 2, \cdots$ 是正定列, 故 $\hat{\Gamma}_p$ 可逆, (8.2.3)' 解为

$$\hat{\mathcal{A}}_p = \hat{\Gamma}_p^{-1} \hat{\eta}_p \quad (8.2.6)$$

这就得到 $A_j (j=1, 2, \cdots, p)$ 的矩估计。

§ 2.2 系数矩阵的最小二乘估计

对 k 维自回归模型系数矩阵 $A_j (j=1, 2, \cdots, p)$ 的另一种估计方法, 即所谓最小二乘估计方法, 就是求一组 $\hat{A}_j (j=1, 2, \cdots, p)$, 使得

$$\begin{aligned} J(A_1, A_2, \cdots, A_p) &= \\ &= \frac{1}{N} \sum_{t=p+1}^N (\mathbf{z}_t - \sum_{j=1}^p A_j \mathbf{z}_{t-j})^T (\mathbf{z}_t - \sum_{j=1}^p A_j \mathbf{z}_{t-j}) \end{aligned}$$

达到最小, 为此, $\hat{A}_j (j=1, 2, \cdots, p)$ 须满足如下的方程组

$$\left. \frac{\partial J}{\partial A_i(l, m)} \right|_{\mathcal{A}_j = \hat{\mathcal{A}}_j} = 0 \quad l, m = 1, 2, \cdots, k$$

$$i = 1, 2, \cdots, p$$

其中 $A_i(l, m)$ 表示系数矩阵 A_i 的第 l 行第 m 列的元素, 上式可表为

$$\frac{1}{N} \sum_{t=p+1}^N (\mathbf{z}_t - \sum_{j=1}^p \hat{A}_j \mathbf{z}_{t-j}) \mathbf{z}_{t-i}^T = 0 \quad (8.2.7)$$

$$i = 1, 2, \cdots, p$$

记

$$\hat{\gamma}'_k = \frac{1}{N} \sum_{t=p+1}^N \mathbf{z}_t \mathbf{z}_{t-k}^T \quad (8.2.8)$$

那么, (8.2.7) 为

$$\hat{\gamma}_i' = \sum_{j=1}^p \hat{A}_{ij} \hat{\gamma}_j', \quad (8.2.9)$$

由此可见, (8.2.8) 虽然与 (8.2.4) 不同, 但当 N 充分大时 $\hat{\gamma}_i'$ 与 $\hat{\gamma}_i$ 相差甚微。同样, 由 (8.2.9) 解出最小二乘估计与 (8.2.5) 解出的矩估计也是相差甚微, 而它们的渐近性质是完全一致的。由 (8.2.2) 和 (8.2.5) 知

$$S = \gamma_0 - \sum_{i=1}^p A_i \gamma_{i-1}, \quad A_i' = \gamma_0 - \mathcal{A}_p' \Gamma_p \mathcal{A}_p$$

如果 $\hat{A}_j (j=1, 2, \dots, p)$ 已估计出, 代入上式则 S 的相应估计为

$$\hat{S} = \hat{\gamma}_0 - \sum_{i,j=1}^p \hat{A}_{ij} \hat{\gamma}_j', \quad \hat{A}_i' = \hat{\gamma}_0 - \hat{\mathcal{A}}_p' \hat{\Gamma}_p \hat{\mathcal{A}}_p, \quad (8.2.10)$$

§ 3 多维自回归模型参数矩阵的递推算法

从 § 2.1 可以看出, 如果直接采用 (8.2.6) 式, 先求出 $\hat{\Gamma}_p^{-1}$, 再去求出 $\hat{\mathcal{A}}_p$, 这样的运算量是很繁重的。当 p 较大时, 上述算法甚至难以实现, 况且下面将会看到, 阶数 p 并非一下子就能确定下来, 而是令 p 从 1 开始逐步增大到某个适当大的 Q (从经验看来 Q 取在 $\frac{N}{10k}$ 到 $\frac{N}{5k}$), 因此对每个 p 值都要求出相应的系数矩阵 $\mathcal{A}_p$ 和平稳白噪声方差矩阵 S_p (因为 S 依赖于阶数 p) 的估计 $\hat{\mathcal{A}}_p$ 和 $\hat{S}_p$, 然后再根据某种最优准则决定合适的阶数 p 。这样的程序用 (8.2.6) 式来实现是极为困难的。为解决这一困难, 我们将采取如下的递推算法——由 § 3.1 和 § 3.2 导出的递推公式统称 Whittle 递推公式。

§ 3.1 自回归模型系数矩阵的递推

为了表示自回归系数矩阵 $A_j (j=1, 2, \dots, p)$ 随着模型阶数 p 而变, 故将 (8.2.1) 表为

$$\mathbf{z}_t = A_{p1}\mathbf{z}_{t-1} + \cdots + A_{pp}\mathbf{z}_{t-p} = \mathbf{u}_t \quad (8.3.1)$$

相应(8.2.5)的解 $\hat{\mathcal{A}}_p$ 改为 $\hat{\mathcal{A}}_{pp} = (\hat{A}_{p1}, \hat{A}_{p2}, \cdots, \hat{A}_{pp})^T$, 又记

$$\hat{\mathcal{A}}_{pj} = (\hat{A}_{p1}, \hat{A}_{p2}, \cdots, \hat{A}_{pj})^T \quad j=1, 2, \cdots, p$$

则(8.2.3)'可表为

$$\hat{\Gamma}_p \hat{\mathcal{A}}_{pp} = \hat{\eta}_p \quad (8.3.2)$$

为了实现系数矩阵的递推运算, 还需用到(8.3.2)的对偶方程

$$\hat{\Gamma}_p^T \hat{\mathcal{B}}_{pp} = \hat{\xi}_p \quad (8.3.3)$$

其中

$$\hat{\xi}_p = \begin{pmatrix} \hat{\gamma}_p \\ \hat{\gamma}_{p-1} \\ \vdots \\ \hat{\gamma}_1 \end{pmatrix} \quad \hat{\mathcal{B}}_{pj} = \begin{pmatrix} \hat{B}_{pj}^T \\ \hat{B}_{p,j-1}^T \\ \vdots \\ \hat{B}_{p1}^T \end{pmatrix} \quad j=1, 2, \cdots, p$$

方程(8.3.3)的解为

$$\hat{\mathcal{B}}_{pp} = \hat{\Gamma}_p^{-1} \hat{\xi}_p$$

下面我们证明多维 AR 模型系数矩阵有如下递推公式

$$\left\{ \begin{array}{l} \hat{A}_{11} = \hat{\gamma}_1 \hat{\gamma}_0^{-1} \\ \hat{A}_{p+1,p+1} = \left(\hat{\gamma}_{p+1} - \sum_{i=1}^p \hat{A}_{pi} \hat{\gamma}_{p+1-i} \right) \left(\hat{\gamma}_0 - \sum_{i=1}^p \hat{B}_{pi} \hat{\gamma}_i \right)^{-1} \\ \hat{A}_{p+1,j} = \hat{A}_{pj} - \hat{A}_{p+1,p+1} \hat{B}_{p,p+1-j}, \quad j=1, 2, \cdots, p \\ \hat{B}_{11} = \hat{\gamma}_1^T \hat{\gamma}_0^{-1} \\ \hat{B}_{p+1,p+1} = \left(\hat{\gamma}_{p+1} - \sum_{i=1}^p \hat{A}_{pi} \hat{\gamma}_{p+1-i} \right)^T \left(\hat{\gamma}_0 - \sum_{i=1}^p \hat{A}_{pi} \hat{\gamma}_i \right)^{-1} \\ \hat{B}_{p+1,j} = \hat{B}_{pj} - \hat{B}_{p+1,p+1} \hat{A}_{p,p+1-j}, \quad j=1, 2, \cdots, p \end{array} \right. \quad (8.3.4)$$

证明: 由(8.3.2)和(8.3.3)知, 当 $p=1$ 时有

$$\hat{A}_{11}^T = \hat{\gamma}_0^{-1} \hat{\gamma}_1^T, \quad \hat{B}_{11}^T = \hat{\gamma}_0^{-1} \hat{\gamma}_1$$

因而得到

$$\hat{A}_{11} = \hat{\gamma}_1 \hat{\gamma}_0^{-1}, \quad \hat{B}_{11} = \hat{\gamma}_1^T \hat{\gamma}_0^{-1}$$

现在假定对某个 p , 已求得 $\hat{\mathcal{A}}_{pp}$ 和 $\hat{\mathcal{B}}_{pp}$, 则由(8.3.2)、(8.3.3)及分块矩阵得

$$\hat{\Gamma}_{p+1} \hat{\mathcal{A}}_{p+1, p+1} = \hat{\eta}_{p+1} \text{ 和 } \hat{\Gamma}_{p+1} \hat{\mathcal{B}}_{p+1, p+1} = \hat{\xi}_{p+1}$$

分别可表为

$$\begin{pmatrix} \hat{\Gamma}_p & \hat{\xi}_p \\ \hat{\xi}_p^T & \hat{\gamma}_0 \end{pmatrix} \begin{pmatrix} \hat{\mathcal{A}}_{p+1, p} \\ \hat{A}_{p+1, p+1}^T \end{pmatrix} = \begin{pmatrix} \hat{\eta}_p \\ \hat{\gamma}_{p+1}^T \end{pmatrix} \quad (8.3.5)$$

和

$$\begin{pmatrix} \hat{\gamma}_0 & \hat{\eta}_p^T \\ \hat{\eta}_p & \hat{\Gamma}_p \end{pmatrix} \begin{pmatrix} \hat{B}_{p+1, p+1}^T \\ \hat{\mathcal{B}}_{p+1, p} \end{pmatrix} = \begin{pmatrix} \hat{\gamma}_{p+1} \\ \hat{\xi}_p \end{pmatrix} \quad (8.3.6)$$

(8.3.5)的第一组方程为

$$\hat{\Gamma}_p \hat{\mathcal{A}}_{p+1, p} + \hat{\xi}_p \hat{A}_{p+1, p+1}^T = \hat{\eta}_p$$

故

$$\begin{aligned} \hat{\mathcal{A}}_{p+1, p} &= \hat{\Gamma}_p^{-1} (\hat{\eta}_p - \hat{\xi}_p \hat{A}_{p+1, p+1}^T) \\ &= \hat{\mathcal{A}}_{pp} - \hat{\mathcal{B}}_{pp} \hat{A}_{p+1, p+1}^T \end{aligned} \quad (8.3.7)$$

(8.3.7)的第 j 个分量矩阵为

$$\hat{A}_{p+1, j}^T = \hat{A}_{pj}^T - \hat{B}_{p, p+1-j}^T \hat{A}_{p+1, p+1}^T \quad j=1, 2, \dots, p$$

经转置后即为(8.3.4)的第3式。(8.3.5)的第二组方程为

$$\hat{\xi}_p^T \hat{\mathcal{A}}_{p+1, p} + \hat{\gamma}_0 \hat{A}_{p+1, p+1}^T = \hat{\gamma}_{p+1}^T$$

将(8.3.7)代入上式,得

$$\hat{\xi}_p^T (\hat{\mathcal{A}}_{pp} - \hat{\mathcal{B}}_{pp} \hat{A}_{p+1, p+1}^T) + \hat{\gamma}_0 \hat{A}_{p+1, p+1}^T = \hat{\gamma}_{p+1}^T \quad (8.3.8)$$

故

$$\hat{A}_{p+1, p+1}^T = (\hat{\gamma}_0 - \hat{\xi}_p^T \hat{\mathcal{B}}_{pp})^{-1} (\hat{\gamma}_{p+1}^T - \hat{\xi}_p^T \hat{\mathcal{A}}_{pp})$$

即得

$$\begin{aligned} \hat{A}_{p+1, p+1} &= (\hat{\gamma}_{p+1} - \hat{\mathcal{A}}_{pp}^T \hat{\xi}_p) (\hat{\gamma}_0 - \hat{\mathcal{B}}_{pp}^T \hat{\xi}_p)^{-1} \\ &= \left(\hat{\gamma}_{p+1} - \sum_{j=1}^p \hat{A}_{pj} \hat{\gamma}_{p+1-j} \right) \left(\hat{\gamma}_0 - \sum_{j=1}^p \hat{B}_{pj} \hat{\gamma}_j \right)^{-1} \end{aligned}$$

此式为(8.3.4)的第2式。

(8.3.6)的第二组方程为

$$\hat{\eta}_p \hat{B}_{p+1, p+1}^T + \hat{\Gamma}_p \hat{\mathcal{B}}_{p+1, p} = \hat{\xi}_p$$

故

$$\hat{\mathcal{B}}_{p+1, p} = \hat{\Gamma}_p^{-1} (\hat{\xi}_p - \hat{\eta}_p \hat{B}_{p+1, p+1}^T)$$

$$= \hat{\mathcal{B}}_{pp} - \hat{\mathcal{A}}_{pp}^T \hat{B}_{p+1,p+1}^T \quad (8.3.9)$$

此式的第 j 个分量矩阵为

$$\hat{B}_{p+1,j}^T = \hat{B}_{pj}^T - \hat{A}_{p,p+1-j}^T \hat{B}_{p+1,p+1}^T, j=1,2,\dots,p$$

转置后即为(8.3.4)的第6式。

(8.3.6)的第一组方程为

$$\hat{\gamma}_0 \hat{B}_{p+1,p+1}^T + \hat{\eta}_p^T \hat{\mathcal{B}}_{p+1,p} = \hat{\gamma}_{p+1}$$

将(8.3.9)代入上式得

$$\hat{\gamma}_0 \hat{B}_{p+1,p+1}^T + \hat{\eta}_p^T (\hat{\mathcal{B}}_{pp} - \hat{\mathcal{A}}_{pp}^T \hat{B}_{p+1,p+1}^T) = \hat{\gamma}_{p+1}$$

故

$$\hat{B}_{p+1,p+1}^T = (\hat{\gamma}_0 - \hat{\eta}_p^T \hat{\mathcal{A}}_{pp})^{-1} (\hat{\gamma}_{p+1} - \hat{\eta}_p^T \hat{\mathcal{B}}_{pp})$$

即

$$\begin{aligned} \hat{B}_{p+1,p+1} &= (\hat{\gamma}_{p+1} - \hat{\mathcal{B}}_{pp}^T \hat{\eta}_p) (\hat{\gamma}_0 - \hat{\mathcal{A}}_{pp}^T \hat{\eta}_p)^{-1} \\ &= \left(\hat{\gamma}_{p+1} - \sum_{j=1}^p \hat{B}_{pj} \hat{\gamma}_{p+1-j} \right) \left(\hat{\gamma}_0 - \sum_{j=1}^p \hat{A}_{pj} \hat{\gamma}_j \right)^{-1} \end{aligned} \quad (8.3.10)$$

又由

$$\begin{aligned} \hat{\gamma}_{p+1} &= \sum_{i=1}^p \hat{B}_{pi} \hat{\gamma}_{p+1-i} + \hat{\gamma}_{p+1} - \hat{\mathcal{B}}_{pp}^T \hat{\eta}_p \\ &= \hat{\gamma}_{p+1} - \hat{\xi}_p^T \hat{F}_p^{-1} \hat{\eta}_p = \hat{\gamma}_{p+1} - \hat{\xi}_p^T \hat{\mathcal{A}}_{pp} \\ &= \left(\gamma_{p+1} - \sum_{j=1}^p \hat{A}_{pj} \hat{\gamma}_{p+1-j} \right)^T \end{aligned}$$

故(8.3.10)可表为

$$\hat{B}_{p+1,p+1} = \left(\hat{\gamma}_{p+1} - \sum_{j=1}^p \hat{A}_{pj} \hat{\gamma}_{p+1-j} \right)^T \left(\hat{\gamma}_0 - \sum_{j=1}^p \hat{A}_{pj} \hat{\gamma}_j \right)^{-1}$$

即为(8.3.4)的第5式。

由递推公式(8.3.4)可知,系数矩阵递推计算步骤如下:

首先由多维动态数据算出 $\{\hat{\gamma}_i\}$, 再由(8.3.4) 计算 $\hat{A}_{11}$ 、 $\hat{B}_{11}$, 然后, 计算 $\hat{A}_{22}$ 、 $\hat{B}_{22}$ 及 $\hat{A}_{21}$ 、 $\hat{B}_{21}$, 再算 $\hat{A}_{33}$ 、 $\hat{B}_{33}$ 及 $\hat{A}_{31}$ 、 $\hat{A}_{32}$ 和 $\hat{B}_{31}$ 、 $\hat{B}_{32}$, $\dots$ 。依此类推, 在算出 $\hat{A}_{pp}$ 、 $\hat{B}_{pp}$ 及 $\hat{A}_{p1}$, $\dots$, $\hat{A}_{p,p-1}$ 、

$\hat{B}_{p1}, \dots, \hat{B}_{pp-1}$ 后, 就可以计算 $\hat{A}_{p+1,p+1}$ 和 $\hat{B}_{p+1,p+1}$, 并可对每个 $j < p+1$ 算出 $\hat{A}_{p+1,j}, \hat{B}_{p+1,j}$ 。

递推算法与(8.2.6)式直接算法相比, 大大地减少了计算量。因为由(8.2.6)直接估计 $\mathcal{A}_{pp}$, 要用到逆矩阵 Γ_p^{-1} , 而 Γ_p 是 $kp \times kp$ 矩阵, 当阶数 p 由低至高增加时, Γ_p^{-1} 的计算量是随 p 而增大的。但是, 在递推算法(8.3.4)中, 需要求逆的矩阵都是 $k \times k$ 矩阵, 逆运算的计算量不随 p 的增大而改变, 因此, 计算量大大地减少。

当维数 $k=1$ 时, 易见(8.3.4)即为(8.1.4)。事实上, 显然有 $\hat{B}_{11} = \hat{A}_{11}$, 若设对 p 有

$$\hat{B}_{pj} = \hat{A}_{pj}, \quad j=1, 2, \dots, p$$

则由(8.3.4)知 $\hat{B}_{p+1,j} = \hat{A}_{p+1,j}, j=1, 2, \dots, p+1$ 。

§ 3.2 模型白噪声方差矩阵的递推

记 k 维 AR(p)模型(8.2.1)的平稳白噪声方差矩阵为 S_p , 可以证明 S_p 的估计 $\hat{S}_p$ 有如下递推公式

$$\hat{S}_{p+1} = (I_k - \hat{A}_{p+1,p+1} \hat{B}_{p+1,p+1}) \hat{S}_p \quad (8.3.11)$$

其中 I_k 为 k 阶单位阵。

证明: 由(8.2.10)知

$$\begin{aligned} \hat{S}_{p+1} &= \hat{\gamma}_0 - \hat{\mathcal{A}}_{p+1,p+1}^r \hat{\Gamma}_{p+1} \hat{\mathcal{A}}_{p+1,p+1} \\ &= \hat{\gamma}_0 - (\hat{A}_{p+1,1}, \hat{A}_{p+1,2}, \dots, \hat{A}_{p+1,p+1}) \hat{\Gamma}_{p+1} \begin{pmatrix} \hat{A}_{p+1,1}^r \\ \hat{A}_{p+1,2}^r \\ \vdots \\ \hat{A}_{p+1,p+1}^r \end{pmatrix} \end{aligned}$$

由(8.3.4)第三式知

$$\begin{aligned} &(\hat{A}_{p+1,1}, \dots, \hat{A}_{p+1,p}, \hat{A}_{p+1,p+1}) \\ &= (\hat{A}_{p1}, \dots, \hat{A}_{pp}, 0) - \hat{A}_{p+1,p+1} (\hat{B}_{pp}, \dots, \hat{B}_{p1}, -I_k) \end{aligned}$$

代入前式得

$$\hat{S}_{p+1} = \hat{\gamma}_0 - (\hat{A}_{p1}, \dots, \hat{A}_{pp}) \hat{\Gamma}_p \begin{pmatrix} \hat{A}_{p1}^r \\ \vdots \\ \hat{A}_{pp}^r \end{pmatrix}$$

$$\begin{aligned}
& + \hat{A}_{p+1,p+1}(\hat{B}_{pp}, \dots, \hat{B}_{p1}, -I_k) \hat{\Gamma}_{p+1} \begin{pmatrix} \hat{A}_{p1}^r \\ \vdots \\ \hat{A}_{pp}^r \\ 0 \end{pmatrix} \\
& + (\hat{A}_{p1}, \dots, \hat{A}_{pp}, 0) \hat{\Gamma}_{p+1} \begin{pmatrix} \hat{B}_{pp}^r \\ \vdots \\ \hat{B}_{p1}^r \\ -I_k \end{pmatrix} \hat{A}_{p+1,p+1}^r \\
& - \hat{A}_{p+1,p+1}(\hat{B}_{pp}, \dots, \hat{B}_{p1}, -I_k) \hat{\Gamma}_{p+1} \begin{pmatrix} \hat{B}_{pp}^r \\ \vdots \\ \hat{B}_{p1}^r \\ -I_k \end{pmatrix} \hat{A}_{p+1,p+1}^r \quad (8.3.12)
\end{aligned}$$

由 $\hat{\Gamma}_p \hat{\mathcal{B}}_{pp} = \hat{\xi}_p$ 知

$$\hat{\Gamma}_{p+1} \begin{pmatrix} \hat{B}_{pp}^r \\ \vdots \\ \hat{B}_{p1}^r \\ -I_k \end{pmatrix} = \begin{pmatrix} \hat{\Gamma}_p & \hat{\xi}_p \\ \hat{\xi}_p^r & \hat{\gamma}_0 \end{pmatrix} \begin{pmatrix} \hat{B}_{pp}^r \\ \vdots \\ \hat{B}_{p1}^r \\ -I_k \end{pmatrix} = \begin{pmatrix} 0 \\ \vdots \\ 0 \\ \sum_{j=1}^p \hat{\gamma}_j^r \hat{B}_{pj}^r - \hat{\gamma}_0 \end{pmatrix}$$

于是(8.3.12)式中第三,四项为零,由(8.3.8)知第五项为

$$\begin{aligned}
& - \hat{A}_{p+1,p+1}(\hat{B}_{pp}, \dots, \hat{B}_{p1}, -I_k) \begin{pmatrix} 0 \\ \vdots \\ 0 \\ \sum_{j=1}^p \hat{\gamma}_j^r \hat{B}_{pj}^r - \hat{\gamma}_0 \end{pmatrix} \hat{A}_{p+1,p+1}^r \\
& = - \hat{A}_{p+1,p+1} \left(\hat{\gamma}_0 - \sum_{j=1}^p \hat{\gamma}_j^r \hat{B}_{pj}^r \right) \hat{A}_{p+1,p+1}^r \\
& = - \hat{A}_{p+1,p+1} \left(\hat{\gamma}_{p+1} - \sum_{j=1}^p \hat{A}_{pj} \hat{\gamma}_{p+1-j} \right)^r
\end{aligned}$$

又由(8.3.4)第五式知,上式等于

$$\begin{aligned}
& -\hat{A}_{p+1,p+1}\hat{B}_{p+1,p+1}\left(\hat{\gamma}_0-\sum_{i=1}^p\hat{A}_{pi}\hat{\gamma}_i^r\right) \\
& =-\hat{A}_{p+1,p+1}\hat{B}_{p+1,p+1}(\hat{\gamma}_0-\hat{\mathcal{A}}_{pp}^r\hat{\Gamma}_p\hat{\mathcal{A}}_{pp})
\end{aligned}$$

所以由(8.3.12)知

$$\begin{aligned}
\hat{S}_{p+1} &= \hat{\gamma}_0 - \hat{\mathcal{A}}_{pp}^r \hat{\Gamma}_p \hat{\mathcal{A}}_{pp} - \hat{A}_{p+1,p+1} \hat{B}_{p+1,p+1} (\hat{\gamma}_0 - \hat{\mathcal{A}}_{pp}^r \hat{\Gamma}_p \hat{\mathcal{A}}_{pp}) \\
&= (I_k - \hat{A}_{p+1,p+1} \hat{B}_{p+1,p+1}) (\hat{\gamma}_0 - \hat{\mathcal{A}}_{pp}^r \hat{\Gamma}_p \hat{\mathcal{A}}_{pp}) \\
&= (I_k - \hat{A}_{p+1,p+1} \hat{B}_{p+1,p+1}) \hat{S}_p \quad \text{证毕。}
\end{aligned}$$

§ 4 多维自回归模型的预报误差

设 k 维 $\text{AR}(p)$ 模型为

$$\mathbf{x}_t = A_{p1}\mathbf{x}_{t-1} + \cdots + A_{pp}\mathbf{x}_{t-p} + \mathbf{u}_t$$

已知观测为 $\mathbf{x}_{t-1}, \mathbf{x}_{t-2}, \cdots$, 对 $\mathbf{x}_t$ 的一步线性预报记为 $\hat{\mathbf{x}}_{t-1}(1)$, 由正交投影知

$$\hat{\mathbf{x}}_{t-1}(1) = A_{p1}\mathbf{x}_{t-1} + \cdots + A_{pp}\mathbf{x}_{t-p} \quad (8.4.1)$$

因此, 一步预报误差为

$$\tilde{\mathbf{x}}_t \triangleq \mathbf{x}_t - \hat{\mathbf{x}}_{t-1}(1) = \mathbf{u}_t$$

一步预报误差方差阵为

$$E\tilde{\mathbf{x}}_t\tilde{\mathbf{x}}_t^r = E\mathbf{u}_t\mathbf{u}_t^r = S, \quad (8.4.2)$$

这里所指的是对真实 $\text{AR}(p)$ 模型的一步预报和一步预报误差方差阵, 即模型系数矩阵为真实时所得结果。如果模型系数矩阵 $A_{p1}, A_{p2}, \cdots, A_{pp}$ 由估计 $\hat{A}_{p1}, \hat{A}_{p2}, \cdots, \hat{A}_{pp}$ 代替, 那么所得的一步预报应该是将 $\hat{A}_{pj} (j=1, 2, \cdots, p)$ 代入(8.4.1)得到

$$\hat{\mathbf{x}}_{t-1}(1) = \hat{A}_{p1}\mathbf{x}_{t-1} + \cdots + \hat{A}_{pp}\mathbf{x}_{t-p} \quad (8.4.3)$$

而这时实际的一步预报误差应该为

$$\tilde{\mathbf{x}}_t = \mathbf{x}_t - \hat{\mathbf{x}}_{t-1}(1) = (A_{p1} - \hat{A}_{p1})\mathbf{x}_{t-1} + \cdots + (A_{pp} - \hat{A}_{pp})\mathbf{x}_{t-p} + \mathbf{u}_t \quad (8.4.4)$$

为了计算一步预报方差阵 $D_p = E\tilde{\mathbf{x}}_t\tilde{\mathbf{x}}_t^r$, 首先我们不加证明的介绍如下定理^[31]

定理 设 $A_{pl}(i, j)$ 表示矩阵 A_{pl} 的第 i 行第 j 列元素, $(l=1, 2, \dots, p)$, $\Gamma_p(l_1, j_1; l_2, j_2)$ 表示 Γ_p 的第 $(l_1-1)k+j_1$ 行第 $(l_2-1)k+j_2$ 列的元素, 也就是 $\Gamma_p(l_1, j_1; l_2, j_2)$ 是 $E\mathbf{z}_{t-l_1}\mathbf{z}_{t-l_2}^T = \mathbf{r}_{l_2-l_1}$ 的第 j_1 行第 j_2 列的元素, $S_p(i, j)$ 和 $\Gamma_p^{-1}(l_1, j_1; l_2, j_2)$ 的涵意类似, 则

$$\begin{aligned} E\{\sqrt{N}[A_{pl}(i, j) - \hat{A}_{pl}(i, j)]\} &\approx 0 \\ E\{N[A_{pl_1}(i_1, j_1) - \hat{A}_{pl_1}(i_1, j_1)][A_{pl_2}(i_2, j_2) - \hat{A}_{pl_2}(i_2, j_2)]\} \\ &\approx S_p(i_1, i_2)\Gamma_p^{-1}(l_1, j_1; l_2, j_2) \end{aligned} \quad (8.4.5)$$

其中 N 是样本的长度, $\hat{A}_{pl}$ 表示 A_{pl} 的矩估计或最小二乘估计, (8.4.5) 的近似相等“ $\approx$ ”的意义是当 $N \rightarrow \infty$ 时等式成立。故只要 N 充分大时, 就可以认为等式成立。

在以下运算过程中, 首先要作一个假定, 就是 $\hat{A}_{pl}(l=1, 2, \dots, p)$ 和 $\{\mathbf{z}_t\}$ 相互独立, 即假定用以求估计 $\hat{A}_{pl}$ 的样本与进行预报的样本是相互独立的, 如果用很久以前的数据来估计 A_{pl} , 而用最近获得的数据作预报, 由于这两组数据相隔时间很长可以近似地看作是相互独立的。

记

$$\tilde{A}_{pl} = A_{pl} - \hat{A}_{pl}, l=1, 2, \dots, p$$

则由独立性假设知

$$\begin{aligned} D_p &= E\tilde{\mathbf{z}}_t\tilde{\mathbf{z}}_t^T = \\ &= S_p + \sum_{l_1=1}^p \sum_{l_2=1}^p E(\tilde{A}_{pl_1}\mathbf{z}_{t-l_1}\mathbf{z}_{t-l_2}^T\tilde{A}_{pl_2}^T) \\ &= S_p + \sum_{l_1=1}^p \sum_{l_2=1}^p E[\tilde{A}_{pl_1}(E\mathbf{z}_{t-l_1}\mathbf{z}_{t-l_2}^T) \cdot \tilde{A}_{pl_2}^T] \end{aligned} \quad (8.4.6)$$

D_p 的第 i 行第 j 列元素为

$$\begin{aligned} D_p(i, j) &= \\ &= S_p(i, j) + \sum_{l_1=1}^p \sum_{l_2=1}^p \sum_{m_1=1}^k \sum_{m_2=1}^k E[\tilde{A}_{pl_1}(i, m_1)\Gamma_p(l_1, m_1; l_2, m_2) \\ &\quad \tilde{A}_{pl_2}(j, m_2)] = \end{aligned}$$

$$S_p(i, j) + \sum_{l_1=1}^p \sum_{l_2=1}^p \sum_{m_1=1}^k \sum_{m_2=1}^k E[\tilde{A}_{pl_1}(i, m_1) \tilde{A}_{pl_2}(j, m_2)] \\ \cdot \Gamma_p(l_1, m_1; l_2, m_2)$$

由(8.4.5)得

$$D_p(i, j) \approx \\ S_p(i, j) + \sum_{l_1=1}^p \sum_{l_2=1}^p \sum_{m_1=1}^k \sum_{m_2=1}^k \frac{1}{N} S_p(i, j) \Gamma_p^{-1}(l_1, m_1; l_2, m_2) \\ \cdot \Gamma_p(l_1, m_1; l_2, m_2) \\ = S_p(i, j) \left[1 + \frac{1}{N} \sum_{l_1=1}^p \sum_{l_2=1}^p \sum_{m_1=1}^k \sum_{m_2=1}^k \Gamma_p^{-1}(l_1, m_1; l_2, m_2) \right. \\ \left. \cdot \Gamma_p(l_1, m_1; l_2, m_2) \right] \\ = S_p(i, j) \left(1 + \frac{kp}{N} \right)$$

所以有

$$D_p \approx \left(1 + \frac{kp}{N} \right) S_p \quad (8.4.7)$$

(8.4.7)与(8.4.2)比较可知,实际模型的一步预报误差方差阵比按真实模型的一步预报误差方差阵大了一些。这也是很自然的,因为把系数矩阵估计 $\hat{\mathcal{A}}_{pp}$ 的误差也考虑在内了。将(8.2.10)中用 $\hat{\mathcal{A}}_{pp}$ 代替 $\mathcal{A}_{pp}$ 得 $\hat{S}_p = \hat{\gamma}_0 - \hat{\mathcal{A}}_{pp}^T \hat{\Gamma}_p \hat{\mathcal{A}}_{pp}$ 可作为 S_p 的估计。我们现在来计算一下它的均值,由(8.4.5)及渐近性质知

$$E \hat{S}_p = E(\hat{\gamma}_0 - \hat{\mathcal{A}}_{pp}^T \hat{\Gamma}_p \hat{\mathcal{A}}_{pp}) \approx \hat{\gamma}_0 - E(\hat{\mathcal{A}}_{pp}^T \Gamma_p \hat{\mathcal{A}}_{pp}) \\ = S_p + \mathcal{A}_{pp}^T \Gamma_p \mathcal{A}_{pp} - E(\hat{\mathcal{A}}_{pp}^T \Gamma_p \hat{\mathcal{A}}_{pp}) \\ = S_p - E[(\mathcal{A}_{pp} - \hat{\mathcal{A}}_{pp})^T \Gamma_p (\mathcal{A}_{pp} - \hat{\mathcal{A}}_{pp})] \\ = S_p - E(\tilde{\mathcal{A}}_{pp}^T \Gamma_p \tilde{\mathcal{A}}_{pp}) \quad (8.4.8)$$

由(8.4.6)的第二等式知

$$D_p = S_p + E(\tilde{\mathcal{A}}_{pp}^T \Gamma_p \tilde{\mathcal{A}}_{pp})$$

故

$$E(\tilde{\mathcal{A}}_{pp}^T \Gamma_p \tilde{\mathcal{A}}_{pp}) = D_p - S_p$$

将(8.4.7)代入上式得

$$E(\tilde{\mathcal{A}}_{pp}^T \Gamma_p \tilde{\mathcal{A}}_{pp}) \approx \frac{kp}{N} S_p$$

因此,代入(8.4.8)得

$$E\hat{S}_p = E(\hat{\gamma}_0 - \hat{\mathcal{A}}_{pp}^T \Gamma_p \hat{\mathcal{A}}_{pp}) \approx \left(1 - \frac{kp}{N}\right) S_p \quad (8.4.9)$$

可见, $\hat{\gamma}_0 - \hat{\mathcal{A}}_{pp}^T \Gamma_p \hat{\mathcal{A}}_{pp}$ 是 S_p 的渐近无偏估计量。为了进一步克服偏倚性,我们取它的无偏估计量 $\left(1 - \frac{kp}{N}\right)^{-1} (\hat{\gamma}_0 - \hat{\mathcal{A}}_{pp}^T \Gamma_p \hat{\mathcal{A}}_{pp})$ 作为 S_p 的估计。

在(8.2.10)中用 $\hat{\mathcal{A}}_{pp}$ 代替 $\mathcal{A}_p$, 得

$$\begin{aligned} \hat{\mathcal{A}}_{pp}^T \hat{\Gamma}_p \hat{\mathcal{A}}_{pp} &= \sum_{i=1}^p \sum_{j=1}^p \hat{A}_{pi} \hat{\gamma}_{i-j}^T \hat{A}_{pj}^T \\ &= \sum_{i=1}^p \hat{A}_{pi} \left(\sum_{j=1}^p \hat{\gamma}_{i-j}^T \hat{A}_{pj}^T \right) \end{aligned}$$

由于 $\hat{A}_{pj} (j=1, 2, \dots, p)$ 满足 Yule-Walker 方程, 即

$$\hat{\gamma}_i = \sum_{j=1}^p \hat{A}_{pj} \hat{\gamma}_{i-j} \quad i=1, 2, \dots, p$$

故有

$$\hat{\mathcal{A}}_{pp}^T \hat{\Gamma}_p \hat{\mathcal{A}}_{pp} = \sum_{i=1}^p \hat{A}_{pi} \hat{\gamma}_i^T = \sum_{i=1}^p \hat{\gamma}_i \hat{A}_{pi}^T$$

最后,我们用 $\left(1 - \frac{kp}{N}\right)^{-1} \left(\hat{\gamma}_0 - \sum_{i=1}^p \hat{A}_{pi} \hat{\gamma}_i^T\right)$ 作为 S_p 的估计,将它代入(8.4.7),以 $\hat{D}_p$ 表示用估计出来的模型进行预报的一步预报误差方差阵 D_p 的估计,那么

$$\hat{D}_p = \left(1 + \frac{kp}{N}\right) \left(1 - \frac{kp}{N}\right)^{-1} \left(\hat{\gamma}_0 - \sum_{i=1}^p \hat{A}_{pi} \hat{\gamma}_i^T\right) \quad (8.4.10)$$

综合上述可知, k 维 AR(p) 模型序列 $\{\mathbf{z}_i\}$ 的一步预报和它的一步预报误差方差阵的估计可分别由(8.4.2)和(8.4.10)求得,其中系

数矩阵 $\hat{A}_{pi} (i=1, 2, \dots, p)$ 可由(8.3.4)递推计算。

§ 5 多维线性模型的定阶

§ 5.1 多维自回归模型定阶的 FPE 准则

本章前几节我们都是模型阶数 p 已知的假定下进行讨论的。但是实际上,对于长度为 N 的样本序列 $\{z_t\}$ 来说,它所适合的自回归阶数预先并不知道,而是要由样本序列去估计的。本节就来讨论由样本对模型定阶的问题。我们介绍一种模型定阶的 FPE 准则(最小最终预报误差准则)。这个准则是以模型输出的一步预报误差方差来判定模型阶数的。这种想法也很自然,因为我们要用一个自回归模型去描述或拟合一串实际的 k 维动态数据序列,往往是希望凭借模型由已知资料去预测未来,因此,预报效果好坏就可反过来作为模型拟合优劣的检验标准。一步预报误差方差阵的行列式越小,就认为模型拟合得越理想。使这误差方差阵行列式达最小的阶数便可认为是最合适的阶数。

对于长度为 N 的 k 维动态数据 $\{z_t\}$, 它的一步预报误差方差阵的估计量 $\hat{D}_p$, 已由(8.4.10)式给出。 $\hat{D}_p$ 是 $k \times k$ 矩阵, 其行列式定义为最终预报误差, 记为

$$\text{FPE}_p(z_t) = \det \hat{D}_p = \left(1 + \frac{kp}{N}\right)^k \left(1 - \frac{kp}{N}\right)^{-k} \det \left(\hat{p}_0 - \sum_{i=1}^p \hat{A}_{pi} \hat{p}_i^T\right) \quad (8.5.1)$$

这是一个关于阶数 p 的函数,它可以作为一步预报误差方差大小的一种度量。所谓最小最终预报误差准则,就是分别对于 $p=1, 2, \dots, Q$ 来计算(8.5.1)式中的 $\text{FPE}_p(z_t)$, 取其最小值相应的 p 为模型阶数。(8.5.1)达到最小的比较范围 Q 是预先适当选取的阶数上界,对于长度为 N 的 k 维序列来说,一般取 $\frac{N}{10k}$ 到 $\frac{N}{5k}$ 之间的数即可。

(8.5.1)式中的 $\hat{A}_{pi} (i=1, 2, \dots, p)$ 是对应于阶为 p 时, A_{pi}

($i=1, 2, \dots, p$) 的 Yule-Walker 估计, 即它们满足方程

$$\begin{pmatrix} \hat{\gamma}_0 & \hat{\gamma}_1 & \cdots & \hat{\gamma}_{p-1} \\ \hat{\gamma}_1^* & \hat{\gamma}_0 & \cdots & \hat{\gamma}_{p-2} \\ \vdots & \vdots & & \vdots \\ \hat{\gamma}_{p-1}^* & \hat{\gamma}_{p-2}^* & \cdots & \hat{\gamma}_0 \end{pmatrix} \begin{pmatrix} \hat{A}_{p1}^* \\ \hat{A}_{p2}^* \\ \vdots \\ \hat{A}_{pp}^* \end{pmatrix} = \begin{pmatrix} \hat{\gamma}_1^* \\ \hat{\gamma}_2^* \\ \vdots \\ \hat{\gamma}_p^* \end{pmatrix}$$

由本章§ 3 知, $\hat{A}_{pi}$ ($i=1, 2, \dots, p$) 可由 (8.3.4) 式的一组递推公式计算得到。

(8.5.1) 式中, $FPE_p(\mathbf{z}_i)$ 作为阶数 p 的函数, 是由两部分构成的, 其系数部分 $\left(1 - \frac{kp}{N}\right)^k \left(1 - \frac{kp}{N}\right)^{-k} = \left(\frac{N+kp}{N-kp}\right)^k$ 是 p 的单调增函数, 而后面部分是 $\det\left(\hat{\gamma}_0 - \sum_{i=1}^p \hat{A}_{pi} \hat{\gamma}_i^*\right)$, 它是 $\mathbf{z}_i$ 基于 $\mathbf{z}_{i-1}, \dots, \mathbf{z}_{i-p}$ 的线性估计误差方差阵的行列式, 即由 (8.2.2) 知它为 $\det \hat{S}_p$ 。如果模型真实阶数为某个 p_0 , 那么, 当阶数由低阶至高阶增加时, $\hat{S}_p$ 开始是应该随着阶数升高而下降的, 即 $\hat{S}_p \geq \hat{S}_{p+1} \geq 0$, $p=1, 2, \dots, p_0-1$, 因此 $\det \hat{S}_p$ 也是 p 的单调非增函数。而当 p 超过 p_0 后, $\det \hat{S}_p$ 的值在某种概率意义下, 从理论上可证明是不会再减小了。这两个部分结合起来, 就会使 $FPE_p(\mathbf{z}_i)$ 的曲线在 p_0 处呈现一个凹点 (见图 8.1)。如果序列 $\{\mathbf{z}_i\}$ 真实模型不是 AR 模型, 而是用 AR 模型来对它近似描述, 那么, $\det \hat{S}_p$ 就一直随着 p 的增大而减小。然而一般 $\det \hat{S}_p$ 下降的速率要比 $FPE_p(\mathbf{z}_i)$ 的系数因




图 8.1

于 $\left(1 + \frac{kp}{N}\right)^k \left(1 - \frac{kp}{N}\right)^{-k}$ 上升的速率来得慢, 因此不难想象 $FPE_p(\mathbf{z}_t)$ 作为 p 的函数也应是下面形式: 使 $FPE_p(\mathbf{z}_t)$ 取最小值的那个对应的 p , 可以判定为是序列 $\{\mathbf{z}_t\}$ 所适合的 AR 模型的阶数。这时相应的 $\hat{A}_{pi}(i=1, 2, \dots, p)$ 就是 $A_{pi}(i=1, 2, \dots, p)$ 的估计。

归纳起来, 对于 k 维长度为 N 的样本序列 $\{\mathbf{z}_t\}$, 可按如下步骤进行自回归模型的辨识和估计。

- i) 取一个适当的正整数 Q , 一般 Q 在 $\frac{N}{10k}$ 至 $\frac{N}{5k}$ 范围内。
- ii) 求长度为 N 的样本序列 $\{\mathbf{z}_t\}$ 的样本自协方差阵 $\hat{\rho}_0, \hat{\rho}_1, \dots, \hat{\rho}_Q$ 。
- iii) 对 $p=1, 2, \dots, Q$, 依次由 (8.3.4) 式递推计算出 $\hat{A}_{pi}(i=1, 2, \dots, p)$ 及 $\hat{\rho}_0 - \sum_{i=1}^p \hat{\rho}_i^T \hat{A}_{pi}$, 并代入 (8.5.1) 式计算出 $FPE_p(\mathbf{z}_t)$ 。
- iv) 求出 $FPE_p(\mathbf{z}_t)$ 的最小值相应的 p , 并以其作为 k 维 AR 模型的阶数, 相应的 $\hat{A}_{pi}(i=1, 2, \dots, p)$ 就是自回归系数矩阵的估计, 相应 $\hat{\rho}_0 - \sum_{i=1}^p \hat{A}_{pi} \hat{\rho}_i^T$ 就是一步预报误差方差阵 S_p 的估计。

如果 $FPE_p(\mathbf{z}_t)$ 的值从 $p=1$ 就开始一直上升, 则可判定模型为一阶自回归模型; 如果 $FPE_p(\mathbf{z}_t)$ 的值随 p 增加而一直下降, 则可能是由于样本序列不能用 AR 模型来描述; 如果在某一 p 值, $FPE_p(\mathbf{z}_t)$ 下降很快, 以后又有缓慢地下降, 则可把这个 p 作为 AR 模型的阶; 如果随着 p 的增加, $FPE_p(\mathbf{z}_t)$ 的值上下剧烈跳动着, 看不出具有最小值, 这很可能是由于样本长度 N 太小引起的, 可增大样本长度再进行定阶。

为了考察 k 维序列 $\{\mathbf{z}_t\}$ 的规律能否由其部分分量, 比如说前 l 个分量(记为 $\mathbf{z}_t^{(l)} (l < k)$), 来充分描述, 我们进一步引入最终预报误差方差的子方阵, 它的行列式

$$\text{FPE}_{p,l,k}(\mathbf{z}_t) = \left(1 + \frac{kp}{N}\right)^l \left(1 - \frac{kp}{N}\right)^{-l} \det\left(\hat{\mathbf{p}}_0 - \sum_{i=1}^p \hat{A}_{pi} \hat{\mathbf{p}}_i^T\right)_l \quad (8.5.2)$$

其中 $\left(\hat{\mathbf{p}}_0 - \sum_{i=1}^p \hat{A}_{pi} \hat{\mathbf{p}}_i^T\right)_l$ 表示 $k \times k$ 矩阵 $\hat{\mathbf{p}}_0 - \sum_{i=1}^p \hat{A}_{pi} \hat{\mathbf{p}}_i^T$ 的左上角 l 阶子方阵。当 $l=k$ 时即为 (8.5.1)。

如果 $\min_p \text{FPE}_{p,l,k}(\mathbf{z}_t) \leq \min_p \text{FPE}_{p,l,l}(\mathbf{z}_t^{(1)})$, 则认为没有必要考察 k 维序列 $\{\mathbf{z}_t\}$ 的建模, 仅考察前 l 维序列 $\{\mathbf{z}_t^{(1)}\}$ 就行了。因为从最小最终预报误差准则的角度看, 考察 k 维序列并未比仅考察前 l ($l < k$) 维序列带来显著好处。换言之, 第 $l+1, l+2, \dots, k$ 个分量起的作用极小, 可以把它们略去; 反之如果成立

$$\min_p \text{FPE}_{p,l,k}(\mathbf{z}_t) < \min_p \text{FPE}_{p,l,l}(\mathbf{z}_t^{(1)}) \quad (8.5.3)$$

则就有必要考察 k 维序列。上述讨论为我们提供了如何选择多维序列进行建模的具体办法, 例如我们关心的是雨量这个指标, 那么温度是否对雨量有较大影响? 这个温度指标是否要参加建模与预报就可用上述方法去判断。令 $\mathbf{z}_t = \begin{pmatrix} x_t \\ y_t \end{pmatrix}$, 其中 $\{x_t\}$ 为雨量, $\{y_t\}$ 为温度, 若

$$\min_p \text{FPE}_{p,1,2}(\mathbf{z}_t) \geq \min_p \text{FPE}_{p,1,1}(\mathbf{z}_t^{(1)}) = \min_p \text{FPE}_p(x_t)$$

则认为温度对雨量影响较小, 在考虑雨量预报时, 无需考察温度。否则, 若

$$\min_p \text{FPE}_{p,1,2}(\mathbf{z}_t) < \min_p \text{FPE}_{p,1,1}(\mathbf{z}_t^{(1)}) = \min_p \text{FPE}_p(x_t)$$

成立, 则认为温度对雨量有较大影响, 在考察雨量问题时, 应把温度一起考虑在内。其它多维情况可如法炮制。这种选择相关因子的思想与统计学中逐步回归思想是类似的。

§ 5.2 多维 ARIMA 模型拟合的 AIC 准则

模型拟合的最小信息准则, 简称为最小 AIC 估计, 记为 MAICE。对于 k 维 ARMA(p, q) 序列, 相应于第四章的一维情形

的推广，它的 AIC 定义为

$$\begin{aligned} \text{AIC}(\mathbf{z}_t) &= N \log |\hat{S}_{pq}| + 2(p+q)k^2 + k(k+1) \\ &= N \log |\hat{S}_{pq}| + 2\left(p+q + \frac{1}{2} + \frac{1}{2k}\right)k^2 \end{aligned} \quad (8.5.4)$$

其中 $|\hat{S}_p|$ 为 k 维平稳白噪声序列方差阵的极大似然估计的行列式。

如果序列均值不为零，则它应作为一个独立参数向量参加估计，此时，(8.5.4)相应地改为

$$\begin{aligned} \text{AIC}(\mathbf{z}_t) &= N \log |\hat{S}_{pq}| + 2(p+q)k^2 + k(k+1) + 2k \\ &= N \log |\hat{S}_{pq}| + 2\left(p+q + \frac{1}{2} + \frac{3}{2k}\right)k^2 \end{aligned} \quad (8.5.5)$$

如果序列是 ARIMA(p, d, q) 序列，即经过 d 阶差分后为 ARMA(p, q) 序列。原样本长为 N ，经 d 阶差分后，真正有效的样本长度为 $N-d$ ，并且经差分后，均值已化为零，因此对 ARIMA(p, d, q) 序列相应于 (8.5.5) 有

$$\begin{aligned} \text{AIC}(\mathbf{z}_t) &= (N-d) \log |\hat{S}_{pq}| + 2(p+q)k^2 + k(k+1) + 2k\delta_{d,0} \\ &= (N-d) \log |\hat{S}_{pq}| + 2\left(p+q + \frac{1}{2} + \frac{1}{2k} + \frac{\delta_{d,0}}{k}\right)k^2 \end{aligned} \quad (8.5.6)$$

如果序列是 k 维乘积模型，特别 $d_1=d_2=\cdots=d_k=d$ ， $D_1=D_2=\cdots=D_k=D$ 。 $S_1=S_2=\cdots=S_k=S$ 时，相应地有

$$\begin{aligned} \text{AIC}(\mathbf{z}_t) &= (N-d-DS) \log |\hat{S}_{pq}| + 2(p+q+P+Q)k^2 \\ &\quad + k(k+1) + 2\delta_{d,0}\delta_{D,0}k \\ &= (N-d-DS) \log |\hat{S}_{pq}| + 2\left(p+q+P+Q + \frac{1}{2} + \frac{1}{2k} \right. \\ &\quad \left. + \frac{\delta_{d,0}\delta_{D,0}}{k}\right)k^2 \end{aligned} \quad (8.5.7)$$

通过对各类模型计算相应的 AIC 值，找出相应的最小 AIC 值的模型阶数和对应的参数估计值，从而完成了对多维动态数据的模型辨识。

从(8.5.5)——(8.5.7)式可以看出, 多维情形所需估计的自由参数个数, 和序列维数的平方成正比, 又和模型阶数成正比, 因此, 建模和预报时的计算量都远远大于一维标量情形。然而, 有些实际问题又需要建立高维数多步长的时序模型, 例如气象数据往往存在年以上周期, 影响因素也很众多, 若不建立高维数多步长时序模型, 往往不能反映气象要素的内在规律。然而由于多步长高维数模型所需估计的参数太多, 导致了庞大的计算量和复杂的计算程序, 甚至因之累积和产生的计算误差大大影响模型精度, 使所建模型无法反映客观事物的内在规律。为了克服上述困难, [44]提供了一种疏系数混合回归模型, 这一模型在实际应用中两个很明显的优点。第一, 其利用对多维回归模型系数矩阵进行分块运算的手段, 将 r 维自回归模型

$$\mathbf{z}_t = A_1 \mathbf{z}_{t-1} + \cdots + A_p \mathbf{z}_{t-p} + \mathbf{u}_t, \quad A_p \neq 0$$

$$\mathbf{z}_t = \begin{pmatrix} z_{1t} \\ \vdots \\ z_{rt} \end{pmatrix} \quad A_l = \begin{pmatrix} a_{11}^{(l)} & \cdots & a_{1r}^{(l)} \\ \vdots & & \vdots \\ a_{r1}^{(l)} & \cdots & a_{rr}^{(l)} \end{pmatrix} \quad \mathbf{u}_t = \begin{pmatrix} u_{1t} \\ \vdots \\ u_{rt} \end{pmatrix}$$

分解成 r 个多输入单输出的混合回归模型来研究

$$z_{kt} = \sum_{j=1}^r a_{kj}^{(1)} z_{j,t-1} + \cdots + \sum_{j=1}^r a_{kj}^{(p)} z_{j,t-p} + u_{kt}$$

其中 z_{kt} 是标量输出, $\mathbf{z}_{t-l}$ 中其量为输入 ($l=1, 2, \cdots, p$)。显然, 这种模型形式是多元统计回归模型与一维时序自回归模型的结合和推广, 其参数估计、模型定阶、因子选择和预报问题, 完全可以借用这两个分支中已有成效的手段来实现和结合使用。而用一维标量情形的研究手段来处理多维的问题, 避免了§3中复杂的矩阵迭代运算。其本身就已有效地简化了计算。这是混合回归模型的明显优越之处。

其次, 本模型提出了“疏系数”的思想。其对于模型参数的计算和取舍, 借用了多元分析中逐步回归的消去变换技巧和自回归定阶的AIC准则, 用此法来建立疏系数混合回归模型, 大大减少了

模型实在参数,有利于抓住主要矛盾,减少计算量和实现有效预报。[44]给出了疏系数混合回归模型的建模方法和计算程序,并对“剔除”和“加入”这两种不同的因子选择手段进行了渐近性理论研究。书中还介绍了这些方法在回归、自回归分析中的应用,以及相应的理论成果。

§ 5.3 多维 AR 模型 MAICE 与 MFPEC 的等价性

在§ 5.1 中曾经给出 k 维 AR 模型的 FPE 准则为

$$\text{FPE}_p(\mathbf{z}_t) = \left(1 + \frac{kp}{N}\right)^k \left(1 - \frac{kp}{N}\right)^{-k} \det \hat{S}_p,$$

对上式两边取对数得

$$\log \text{FPE}_p(\mathbf{z}_t) = k \log \frac{1 + \frac{kp}{N}}{1 - \frac{kp}{N}} + \log |\hat{S}_p|$$

当 $|x| < 1$ 时,有如下展式

$$\log \frac{1+x}{1-x} = 2 \left(x + \frac{x^3}{3} + \frac{x^5}{5} + \cdots \right)$$

而当 N 充分大时, $0 < \frac{kp}{N} \ll 1$ (即 $\frac{kp}{N}$ 与 1 相比为极小),因此有

$$\log \text{FPE}_p(\mathbf{z}_t) = 2k \left(\frac{kp}{N} + o\left(\frac{1}{N^2}\right) \right) + \log |\hat{S}_p| \quad (8.5.8)$$

故

$$\begin{aligned} N \log \text{FPE}_p(\mathbf{z}_t) &= N \log |\hat{S}_p| + 2pk^2 + o\left(\frac{1}{N}\right) \\ &= N \log |\hat{S}_p| + 2 \left(p + \frac{1}{2} + \frac{1}{2k} \right) k^2 - k(k+1) + o\left(\frac{1}{N}\right) \\ &= \text{AIC}(\mathbf{z}_t) - k(k+1) + o\left(\frac{1}{N}\right) \end{aligned} \quad (8.5.9)$$

其中 N 和 k 是常量。由于对数函数是单调增函数,因此,(8.5.9)式左端与 $\text{FPE}_p(\mathbf{z}_t)$ 应取相同的极值点,这就证明了 MFPEC 和 MAICE 在同一参数达到最小值,故二者是等价的。

§ 6 计算方法与实例

§ 8.1 参数矩阵计算方法

在递推公式(8.3.4)式中涉及到 $\hat{\psi}_0, \hat{\psi}_0 - \sum_{j=1}^p \hat{B}_{pj} \hat{\psi}_j, \hat{\psi}_0 -$

$\sum_{j=1}^p \hat{A}_{pj} \hat{\psi}_j^T$ 诸 $k \times k$ 矩阵的求逆, 其中 $\hat{\psi}_0$ 显然是对称阵, 从下面容易看出后两个矩阵也是对称阵。

事实上, 由(8.3.2)和(8.3.3)得知

$$\begin{aligned} (\hat{A}_{p1}, \dots, \hat{A}_{pp})^T &= \hat{\mathcal{A}}_{pp} = \hat{F}_p^{-1} \hat{\eta} \\ (\hat{B}_{pp}, \dots, \hat{B}_{p1})^T &= \hat{\mathcal{B}}_{pp} = \hat{F}_p^{-1} \hat{\xi}_p \end{aligned}$$

又 $\hat{F}_p^{-1}$ 是对称阵, 由上面两式可得

$$\begin{aligned} \sum_{j=1}^p \hat{A}_{pj} \hat{\psi}_j^T &= (\hat{A}_{p1}, \dots, \hat{A}_{pp}) \hat{\eta}_p = \hat{\mathcal{A}}_{pp}^T \hat{\eta}_p \\ &= \hat{\eta}_p^T \hat{F}_p^{-1} \hat{\eta}_p \\ \sum_{j=1}^p \hat{B}_{pj} \hat{\psi}_j &= (\hat{B}_{pp}, \dots, \hat{B}_{p1}) \hat{\xi}_p = \hat{\mathcal{B}}_{pp}^T \hat{\xi}_p \\ &= \hat{\xi}_p^T \hat{F}_p^{-1} \hat{\xi}_p \end{aligned}$$

由此可见上面两式是对称阵。

将(8.3.4)式中第二、五两式转置后, 得到

$$\begin{aligned} \hat{A}_{p+1, p+1}^T &= \left(\hat{\psi}_0 - \sum_{j=1}^p \hat{B}_{pj}^T \hat{\psi}_j \right)^{-1} \left(\hat{\psi}_{p+1} - \sum_{j=1}^p \hat{A}_{pj}^T \hat{\psi}_{p+1-j} \right)^T \\ \hat{B}_{p+1, p+1}^T &= \left(\hat{\psi}_0 - \sum_{j=1}^p \hat{A}_{pj} \hat{\psi}_j^T \right)^{-1} \left(\hat{\psi}_{p+1} - \sum_{j=1}^p \hat{A}_{pj} \hat{\psi}_{p+1-j} \right) \end{aligned}$$

相应初值为

$$\begin{aligned} \hat{A}_{11}^T &= \hat{\psi}_0^{-1} \hat{\psi}_1 \\ \hat{B}_{11}^T &= \hat{\psi}_0^{-1} \hat{\psi}_1 \end{aligned}$$

因此在编制程序时, 对于 $\hat{A}_{p+1, p+1}^T, \hat{B}_{p+1, p+1}^T$ 的递推就转化为考虑

形如 $AX=B$ 的线性矩阵方程组求解的问题。这里 A 是 $k \times k$ 正定阵, B 是 $k \times k$ 矩阵。这类 $k \times k$ 矩阵线性方程组可以分解成 k 个有相同系数矩阵的线性方程组, 利用专有程序直接求解, 可使问题大大减化。如果我们不是采用上述解线性方程组的方法, 而是直接由公式出发解 $\hat{A}_{p+1, p+1}^T, \hat{B}_{p+1, p+1}^T$, 那么首先要求逆矩阵

$$\left(\hat{\gamma}_0 - \sum_{j=1}^p \hat{B}_{pj} \hat{\gamma}_j\right)^{-1}, \left(\hat{\gamma}_0 - \sum_{j=1}^p \hat{A}_{pj} \hat{\gamma}_j^T\right)^{-1}, \text{再经矩阵相乘得出}$$

$\hat{A}_{p+1, p+1}$ 和 $\hat{B}_{p+1, p+1}$, 这样在运算速度上就会慢得多。计算出 $\hat{A}_{p+1, p+1}, \hat{B}_{p+1, p+1}$ 后, 由 (8.3.11) 可递推算出 $\hat{S}_{p+1}$, 其初值为 $\hat{S}_1 = \hat{\gamma}_0 - \hat{A}_{11} \hat{\gamma}_0 \hat{A}_{11}^T$ 。

具体计算时, 首先要将序列 $\{x_t\}$ 的协方差阵 $\hat{\gamma}_0, \hat{\gamma}_1, \dots, \hat{\gamma}_Q$ 求出, Q 一般取在 $\frac{N}{10k}$ 至 $\frac{N}{5k}$ 之间范围, 由 $\hat{\gamma}_0^{-1}, \hat{\gamma}_1$ 给出初值 $\hat{A}_{11}, \hat{B}_{11}$, 然后对 $p=1, 2, \dots, Q$ 顺序按 (8.3.4) 迭代计算。例如计算到第 p 步时, 首先计算 $\hat{A}_{p+1, p+1}, \hat{B}_{p+1, p+1}$, 然后对 $j=1, 2, \dots, \left[\frac{p}{2}\right]$ ($[x]$ 表示 x 的整数部分), 成对的计算 $\hat{A}_{p+1, p+1-j}, \hat{B}_{p+1, p+1-j}$ 及 $\hat{A}_{p+1-j, p+1-j}, \hat{B}_{p+1-j, p+1-j}$ 。注意, 求 $\hat{A}_{p+1, p+1-j}$ 和 $\hat{B}_{p+1, p+1-j}$ 时, 只用到 $\hat{B}_{pj}$ 及 $\hat{A}_{p, p+1-j}$, 当 p 为奇数时, 还得计算 $\hat{A}_{p+1, \frac{p+1}{2}}$ 和 $\hat{B}_{p+1, \frac{p+1}{2}}$, 且只用到 $\hat{A}_{p, \frac{p+1}{2}}$ 和 $\hat{B}_{p, \frac{p+1}{2}}$ 。在编制程序时, 注意这些特点, 就可以做到既节省存储单元, 又可保证运算速度。图 8.2 给出了计算技巧的示意, 详细的程序框图见图 8.3。

多维自回归模型求系数矩阵的递推计算方法, 与一维时间序列求偏相关函数递推算法是完全类似的。

§ 6.2 实例: 气温与气压自回归模型的建立

我们希望分析气温、气压两种量测资料的相互关系, 并考察等压面高度与两者之间关系。

我们采用 1954—1975 年浙江嘉兴月平均气温、气压和 500 毫巴网格高度三种量测, 建立三维自回归模型。这三种量测序列分




图 8.2

别用 $\{z_t^{(i)}\}$, $i=1,2,3$ 表示, $t=1,2,\dots,N$, $N=264$ 。

表 8.1 中列出了这三种资料的样本相关阵 $\hat{\rho}_j$, $j=0,1,2,\dots,25$, 表 8.1 中的每一行是各个分量相关阵 (3×3 矩阵) 的元素 (按行排列)。由表中可以看出, 每个时间序列本身不同时刻之间, 各个序列之间相关性都是很强的, 而且有明显的季节变化。

按照 (8.5.2) 式计算的最终预报误差列在表 8.2 中。从这个表的第一行的数值结果可以看出, 如果采用三维 (气温、气压和毫巴) 模型, 定出的自回归模型阶数 $p=6$, 比较第二行与第四行结果, $FPE_{7,2,3}=11.63$, $FPE_{7,2,2}=14.19$ 分别是第二行第四行中最终预报误差最小值, 而前者又比后者小。这说明, 如果我们考察气温与气压这两个因素的变化规律时, 毫巴对二者影响是不可忽略的。现在再来考察第三第五第六行, $FPE_{7,1,3}=4.06$, $FPE_{7,1,2}=4.02$, $FPE_{7,1,1}=4.06$ 分别是这三行的最终预报误差的最小值, 而这三个数中 $FPE_{7,1,2}$ 最小。这说明, 如果我们关心的只是气温的变化, 那么, 应取气温与气压二维量测, 而不必取气温, 气压和毫巴三维量测, 并构造 7 阶自回归模型, 这时的最终预报误差较小。




图 8.3 多维自回归模型系数矩阵递推计算框图

表 8.1 气温、气压和毫巴的样本相关阵

	气温/ 气温	气温/ 气压	气温/ 毫巴	气压/ 气温	气压/ 气压	气压/ 毫巴	毫巴/ 气温	毫巴/ 气压	毫巴/ 毫巴
$\hat{\rho}_0$	1.00	-0.94	0.95	-0.94	1.00	-0.83	0.95	-0.83	1.00
$\hat{\rho}_1$	0.84	-0.66	0.99	-0.92	0.82	-0.92	0.73	-0.52	0.82
$\hat{\rho}_2$	0.47	-0.22	0.51	-0.68	0.46	-0.76	0.33	-0.86	0.45
$\hat{\rho}_3$	-0.01	0.27	0.14	-0.25	-0.01	-0.40	-0.15	0.37	-0.03
$\hat{\rho}_4$	-0.48	0.67	-0.34	0.24	-0.46	0.08	-0.58	0.73	-0.46
$\hat{\rho}_5$	-0.83	0.91	-0.73	0.66	-0.79	0.54	-0.86	0.90	-0.77
$\hat{\rho}_6$	-0.95	0.90	-0.91	0.90	-0.90	0.84	-0.91	0.84	-0.87
$\hat{\rho}_7$	-0.82	0.65	-0.85	0.89	-0.77	0.90	-0.72	0.53	-0.76
$\hat{\rho}_8$	-0.47	0.22	-0.58	0.65	-0.44	0.72	-0.33	0.08	-0.46
$\hat{\rho}_9$	0.00	-0.26	0.14	0.24	0.01	0.35	0.14	-0.39	-0.02
$\hat{\rho}_{10}$	0.47	-0.67	0.33	-0.23	0.45	-0.09	0.58	-0.75	0.44
$\hat{\rho}_{11}$	0.81	-0.89	0.71	-0.64	0.78	-0.51	0.85	-0.89	0.78
$\hat{\rho}_{12}$	0.94	-0.88	0.91	-0.88	0.90	-0.80	0.90	-0.79	0.91
$\hat{\rho}_{13}$	0.80	-0.63	0.85	-0.88	0.76	-0.88	0.69	-0.49	0.78
$\hat{\rho}_{14}$	0.45	-0.21	0.56	-0.64	0.43	-0.72	0.32	-0.08	0.43
$\hat{\rho}_{15}$	-0.01	0.25	0.13	-0.24	-0.02	-0.37	-0.14	0.35	-0.02
$\hat{\rho}_{16}$	-0.46	0.64	-0.33	0.23	-0.45	0.10	-0.55	0.69	-0.44
$\hat{\rho}_{17}$	-0.79	0.86	-0.70	0.63	-0.75	0.53	-0.82	0.86	-0.74
$\hat{\rho}_{18}$	-0.91	0.86	-0.88	0.86	-0.86	0.81	-0.87	0.80	-0.84
$\hat{\rho}_{19}$	-0.78	0.62	-0.82	0.85	-0.74	0.86	-0.69	0.52	-0.73
$\hat{\rho}_{20}$	-0.45	0.22	-0.55	0.62	-0.43	0.68	-0.32	0.08	-0.43
$\hat{\rho}_{21}$	0.00	-0.25	-0.13	0.23	-0.01	0.33	0.13	-0.38	-0.02
$\hat{\rho}_{22}$	0.45	-0.64	0.32	-0.22	0.42	-0.09	0.55	-0.71	0.42
$\hat{\rho}_{23}$	0.78	-0.85	0.69	-0.61	0.76	-0.49	0.82	-0.85	0.76

续表

	气温/ 气温	气温/ 气压	气温/ 毫巴	气压/ 气温	气压/ 气压	气压/ 毫巴	毫巴/ 气温	毫巴/ 气压	毫巴/ 毫巴
$\hat{\rho}_{21}$	0.89	-0.84	0.86	-0.84	0.86	-0.76	0.80	-0.75	0.81
$\hat{\rho}_{22}$	0.76	-0.60	0.81	-0.84	0.73	-0.84	0.67	-0.47	0.74

表 8.2 最终预报误差计算数值结果

P	$k=3$ $l=3$	$k=3$ $l=2$	$k=3$ $l=1$	$k=2$ $l=2$	$k=2$ $l=1$	$k=1$ $l=1$
1	120.39	41.70	11.15	50.54	11.48	22.50
2	62.18	22.05	6.51	25.75	6.64	8.15
3	43.62	16.73	5.62	22.42	5.75	6.32
4	39.60	15.00	5.03	19.80	5.03	5.13
5	32.87	12.44	4.36	16.32	4.37	4.36
6	30.61	11.67	4.15	14.37	4.11	4.11
7	30.74	11.63	4.06	14.19	4.02	4.07
8	32.14	12.09	4.14	14.43	4.08	4.09
9	33.17	12.24	4.23	14.31	4.13	4.12
10	34.54	12.54	4.30	14.70	4.19	4.15
11	35.61	12.94	4.38	15.06	4.23	4.16
12	36.16	12.93	4.36	15.10	4.22	4.12
13	37.97	13.34	4.44	15.44	4.25	4.10
14	38.72	13.31	4.50	15.45	4.32	4.13
15	39.31	13.31	4.51	15.53	4.31	4.12
16	40.22	13.63	4.61	15.74	4.37	4.13
17	41.29	13.68	4.64	15.85	4.41	4.17
18	42.90	14.23	4.73	16.13	4.45	4.20
19	44.36	14.68	4.81	16.41	4.49	4.23
20	46.15	15.10	4.92	16.57	4.56	4.26

第九章 非线性模型

§ 1 概 述

前面八章我们讨论的是一些线性模型。许多动态数据可以用前面各类线性模型去描述,并且在不少领域获得良好的效果。但是更深入的研究发现许多现象和问题,仅仅停留在用线性模型去描述是很不够的,其效果也比较差。因此,近几年来,许多人开始研究非线性现象,提出了几种非线性模型。由于非线性模型类比较线性模型,其范围之大有如空间中各种各样的曲面比之于平面,绝对不可能用某几种形式完全表达出来。目前所涉及到的也只是很少几类,对于客观的非线性现象,我们还只能用已有所研究的有限几种模型试着去拟合相应的动态数据,如效果好,便采用之,否则就应别寻新路。因此,非线性模型是一片广阔的未曾开发的天地,它吸收着许多时间序列分析工作者为之而献身。

§ 1.1 非线性现象

我们先来看一个例子




图 9.1

图 9.1 是某时间序列的一个实现(一组动态数据),可以看出,它很难用我们学过的线性模型来描述它,因为图中曲线既没有趋势性又不像有季节性,只有一些宽窄不大相同的“锯齿”。事实上,

它是如下模型的一组模拟数据

$$x_i = \begin{cases} 0.5 + x_{i-1} + a_i & \text{当 } -3.5 < x_{i-1} \leq 3.5 \\ -3.0 + a_i & \text{其它} \end{cases} \quad (9.1.1)$$

其中 $\{a_i\}$ 为正态白噪声, 且 $a_i \sim N(0, \frac{1}{4})$ 。

显然, (9.1.1) 式这样的非线性模型不可能简单地化成线性模型, 且 (9.1.1) 可以描述一些不能用线性模型描述的自然现象。最近几年来, 非线性模型已越来越受到人们的关注, 就是因为许多现象用线性模型来描述已不够深刻, 用线性模型作预报或控制已不能满足精度要求。

我们知道, 对于一个线性系统 L , 当输入是 $y(t)$, 系统的输出是 $x(t)$, 那么它们的频谱的关系为

$$x(\omega) = k(\omega)y(\omega) \quad (9.1.2)$$

其中, $k(\omega)$ 是线性系统 L 的频率响应函数。

(9.1.2) 式表明, 在某一频率上, 输出振幅总是输入振幅的某个倍数。对于这样的系统, 总可以用一个 ARMA 模型来拟合它。但是对如下一类现象用 ARMA 模型难以描述。

我们考虑 Duffing 方程

$$\frac{d^2 x_i}{dt^2} + c \frac{dx_i}{dt} + \alpha x_i + \beta x_i^3 = F \cos \omega t \quad (9.1.3)$$

其中 c, α, β 都是常数, F 为输入振幅, ω 为输入频率; 对 $\beta > 0$, 令 F 固定, ω 随 t 慢慢地均匀地减少, 则 x_i 的幅度变化沿着图 9.2a 中的 1—2—3—4—5 路线变化, 在频率 ω_1 处有一跳跃。但若令 ω 慢慢地增加, 则 x_i 的幅度将沿着 5—4—6—2—1 路线变化, 在 ω_2 处有一跳跃, 于是在 ω_1, ω_2 之间频率响应函数 $k(\omega)$ 不是唯一的。这种现象称为“共振跳跃”, 它表示了系统的一种“回复能力”, 如图 9.2a 所示, 称为“软跳”。对于 $\beta < 0$, 类似地有相应的现象, 如图 9.2b 所示, 称为“硬跳”。

如果我们考察一个自激励线性系统, 例如二阶线性系统

$$\frac{d^2 x_i}{dt^2} + \phi_1 \frac{dx_i}{dt} + \phi_2 x_i = 0 \quad (9.1.4)$$




图 9.2 a ($\beta > 0$)




图 9.2 b ($\beta < 0$)

(9.1.4) 相应的特征方程为 $\lambda^2 + \phi_1 \lambda + \phi_2 = 0$, 有两根为 $-\frac{\phi_1}{2} \pm i \frac{\sqrt{4\phi_2 - \phi_1^2}}{2}$, 若 $4\phi_2 - \phi_1^2 > 0$, 则对非零的初值, x_i 将以频率为 $\omega_0 = \frac{\sqrt{4\phi_2 - \phi_1^2}}{2}$ 进行振荡, 当 $\phi_1 > 0$ 时, 振荡按指数衰减; 当 $\phi_1 < 0$ 时,

振荡按指数上升; 当 $\phi_1 = 0$ 时是等幅振荡, 其中 ω_0 是系统的固有频率。如果我们考察(9.1.3)型的齐次方程

$$\frac{d^2 x_i}{dt^2} + c \frac{dx_i}{dt} + \alpha x_i + \beta x_i^3 = 0 \quad (9.1.5)$$

那么可以看出, 对非零初值, x_i 的振动频率也在不断变化。对此我们只要将 $\alpha x_i + \beta x_i^3$ 写成 $(\alpha + \beta x_i^2)x_i$, 把 $\alpha + \beta x_i^2$ 放在 ϕ_2 的地位来考虑, 就很容易理解。这就是说, (9.1.5) 的解其振动频率依赖它

的振幅,这种现象称为“幅频依赖”。

虽然上面的例子是连续时间的,我们很容易看到,对于离散时间也有类似的非线性现象产生。对这些现象,线性模型是不能从本质上加以刻划的,但形如(9.1.1)或其它一些非线性模型可以刻划这些非线性现象。

§ 1.2 非线性模型

最一般的非线性模型有如下形式

$$x_t = f(x_{t-1}, x_{t-2}, \dots, a_{t-1}, a_{t-2}, \dots) \quad (9.1.6)$$

其中, $f(\cdot)$ 为满足某些解析条件的非线性函数, $\{a_t\}$ 是白噪声序列。对于这种一般形式,无从下手研究。下面我们介绍几种特殊的非线性模型,它们都是近年来才提出来的。

1. 非线性自回归模型: 它的一般形式为

$$x_t = f(x_{t-1}, \dots, x_{t-p}) + a_t \quad (9.1.7)$$

$f(\cdot)$ 称为模型的 p 阶自回归函数,一般约定函数 $f(\cdot)$ 的类型已知,而参数由动态数据来估出。显然,如果不给出 $f(\cdot)$ 以具体函数形式,估计问题往往无从谈起。所以对这类模型,除参数估计问题外,主要讨论对函数 $f(\cdot)$ 和 $\{a_t\}$ 的分布施加什么条件,才使 $\{x_t\}$ 具有平稳性、遍历性,同时研究 $\{x_t\}$ 的分布和矩的性质等等。

2. 门限自回归模型(Threshold Autoregressive Model): 此模型由 H. Tong^[34] 于 1978 年提出,模型一般地表为

$$x_t = \phi_0^{(j)} + \sum_{i=1}^{p_j} \phi_i^{(j)} x_{t-i} + a_t^{(j)}, \text{ 当 } r_{j-1} < x_{t-d} \leq r_j, \\ j=1, 2, \dots, l \quad (9.1.8)$$

其中 $-\infty = r_0 < r_1 < \dots < r_l = \infty$, r_j ($j=1, 2, \dots, l-1$) 称为门限或阈值, d 称为延迟参数,对每一固定 j , $\{a_t^{(j)}\}$ 是方差为 σ_j^2 的白噪声序列,当 $j \neq j'$ 时 $\{a_t^{(j)}\}$ 与 $\{a_t^{(j')}\}$ 为相互独立。模型(9.1.8)表明,若把实数轴 $(-\infty, \infty)$ 依门限划分为 l 段,则当 x_{t-d} 落入第 j 段时, x_t 就采用第 j 个阶数为 p_j 的自回归模型描述,其中 $j=1, 2, \dots, l$ 。模型(9.1.8)简记为 SETAR($d, l; p_1, \dots, p_l$), 最常用的是 $l=2$ 。

这类模型(9.1.8)可以刻画共振跳跃、幅频依赖等非线性现象,为说明这点,我们考察如下三个例子。

例 1 设 SETAR(6,2,3,8) 模型为

$$x_i = \begin{cases} 1.3003 + 1.3243 x_{i-1} - 0.7023 x_{i-2} - 0.0750 x_{i-3} \\ \quad + \text{输入} & \text{当 } x_{i-6} \leq 3.31 \\ 0.2004 + 1.2112 x_{i-1} - 0.6971 x_{i-2} + 0.6191 x_{i-3} - \\ 1.0178 x_{i-4} + 0.9967 x_{i-5} - 0.7688 x_{i-6} + 0.6119 x_{i-7} \\ - 0.0551 x_{i-8} + \text{输入} & \text{当 } x_{i-6} > 3.31 \end{cases} \quad (9.1.9)$$

则图 9.3 给出了(9.1.9)模型的相应输入、输出的样本曲线,它表明“软跳”。

例2 设 SETAR (5,2,9,3) 模型为

$$x_i = \begin{cases} 0.4655 + 1.1448 x_{i-1} - 0.4801 x_{i-2} + 0.1273 x_{i-3} \\ \quad - 0.3580 x_{i-4} + 0.2565 x_{i-5} - 0.0781 x_{i-6} \\ \quad - 0.0493 x_{i-7} + 0.2186 x_{i-8} + 0.0526 x_{i-9} + \text{输入} \\ \quad \quad \quad \text{当 } x_{i-5} \leq 3.05 \\ 1.1940 + 1.1181 x_{i-1} - 0.5017 x_{i-2} - 0.0594 x_{i-3} + \\ \quad \quad \quad \text{输入} \quad \text{当 } x_{i-5} > 3.05 \end{cases} \quad (9.1.10)$$

则图 9.4 给出了(9.1.10)模型的相应的输入、输出样本曲线。

图 9.3a 表示输入频率由大变小时, 输出 x_i 的变化, 图 9.3b 表示输入频率由小变大时, 输出 x_i 的变化。可以看出, 图 9.3 发生了“软跳”, 其中 $\omega_1 = 0.1052$, $\omega_2 = 0.1100$ 。

图 9.4 a 表示输入频率由大变小时输出 x_1 变化, 图 9.4 b 表示输入频率由小变大时, 输出 x_1 的变化。可以看出, 图 9.4 发生了“硬跳”, 其中 $\omega_2=0.1008, \omega_2=0.1034$ 。

例 3 设有两个 SETAR(1,2;3,3) 模型,它们分别为

$$x_t = \begin{cases} 1.2270 - 1.0516 x_{t-1} - 0.5901 x_{t-2} \\ - 0.2149 x_{t-3} + a^{(1)}_t & \text{当 } x_{t-1} \leq 0.5 \\ 1.6734 - 0.8295 x_{t-1} + 0.1309 x_{t-2} \\ - 0.0276 x_{t-3} + a^{(2)}_t & \text{当 } x_{t-1} > 0.5 \end{cases} \quad (9.1.11a)$$







图 9.3 共振跳跃、软跳



a



b

图 9.4 共振跳跃, 硬跳

$$\text{var} a_i^{(j)} = (0.003)^2, j=1,2$$

$$x_i = \begin{cases} 0.15 + 0.85 x_{i-1} + 0.22 x_{i-2} - 0.70 x_{i-3} + a_i^{(1)} & \text{当 } x_{i-1} \leq 3.05 \\ 0.30 - 0.80 x_{i-1} + 0.20 x_{i-2} + 0.70 x_{i-3} + a_i^{(2)} & \text{当 } x_{i-1} > 3.05 \end{cases}$$


(9.1.11 b)

$$\text{var} a_i^{(j)} = (0.003)^2 \quad j=1,2$$

图 9.5 a 和图 9.5 b 分别为模型(9.1.11 a) 和 (9.1.11 b) 的输出实现。图中表现出幅频依赖。



a 高(低) 频相应高(低) 振幅



b 高(低) 频相应低(高) 振幅

图 9.5 幅频依赖

关于门限自回归模型将在第三节进一步讨论。

3. 指数自回归模型(Exponential Autoregressive Model),

它是由T. Ozaki^[36]提出,它的一般形式可表为

$$x_t = \sum_{i=1}^p (\phi_i + \pi_i e^{-\tau x_{t-1}^2}) x_{t-i} + a_t \quad (9.1.12)$$

其中 $\phi_i, \pi_i (i=1, 2, \dots, p), \tau > 0$ 都是常数, $\{a_t\}$ 为白噪声序列。

容易看出, (9.1.12)模型可以刻画幅频依赖现象, 例如二阶模型($p=2$), 它相应的特征方程为

$$\lambda^2 - (\phi_1 + \pi_1 e^{-\tau x_{t-1}^2}) \lambda - (\phi_2 + \pi_2 e^{-\tau x_{t-1}^2}) = 0$$

该方程的根依赖于 x_{t-1} , 即频率依赖于 x_{t-1} , 也可进一步验证它具有共振跳跃现象。

特别, $\pi_i (i=1, 2, \dots, p)$ 全为零时, (9.1.12)变为线性 p 阶自回归模型即AR(p)。

对于(9.1.12)模型的辨识仍然是利用AIC准则, 即

$$AIC(p) = -2 \log (\text{极大似然函数}) + 2(\text{独立参数个数})$$

当序列满足一定条件时, 参数的极大似然估计与非线性最小二乘估计是渐近相等的。从而当动态数据个数 N 充分大时, 用非线性最小二乘及AIC就可辨识指数自回归模型, 本书不作详细讨论。

4. 双线性模型(Bilinear Model): 最早从事这类模型研究的是C. W. Granger和A. P. Anderson^[38], 它的一般形式可表为

$$x_t = \sum_{j=1}^p \phi_j x_{t-j} + \sum_{i=0}^q \theta_i a_{t-i} + \sum_{k=1}^P \sum_{i=0}^Q \beta_{ki} x_{t-k} a_{t-i} \quad (9.1.13)$$

其中 $\{a_t\}$ 是严格白噪声, 即 $\{a_t\}$ 为相互独立的白噪声序列。

关于双线性模型, 我们将在第三节中较详细地介绍。

5. 状态依赖模型(State Dependent Model): 这类模型是M.B.Priestley^[40]于1980年提出的, 它的定义如下:

$$x_t = \mu(x_{t-1}) + \sum_{j=1}^p \phi_j(x_{t-1}) x_{t-j} + \sum_{i=1}^q \psi_i(x_{t-1}) a_{t-i} + a_t \quad (9.1.14)$$

其中 $x_{t-1} = (a_{t-q}, \dots, a_{t-1} \mid x_{t-p}, \dots, x_{t-1})^T$, (9.1.14) 模型简

记为SDM(p, q)。当函数 $\phi_j(x_{t-1}) (j=1, 2, \dots, p)$, $\psi_i(x_{t-1}) (i=1, \dots, q)$, $\mu(x_{t-1})$ 选择各种特殊形式时, SDM(p, q) 模型将变为 ARMA(p, q) 模型, 门限自回归模型, 指数自回归模型以及双线性模型。事实上

i) 如果 $\mu(\cdot), \phi_j(\cdot) (j=1, 2, \dots, p), \psi_i(\cdot) (i=1, 2, \dots, q)$ 为常数, 即它们都不依赖于 x_{t-1} , 显然, 这时 SDM(p, q) 变为通常的 ARMA(p, q) 模型。

ii) 如果 $\psi_u(\cdot) = 0 (u=1, 2, \dots, q)$, 并且当 $x_{t-d} \in R^{(i)}$ 时, $\mu(x_{t-1}) = \mu^{(i)}, \phi_j(x_{t-1}) = \phi_j^{(i)}, j=1, 2, \dots, p$ 。其中 $R^{(i)} = (\tau_{i-1}, \tau_i], i=1, 2, \dots, l, -\infty = r_0 < r_1 < \dots < r_{l-1} < r_l = \infty$, 则 SDM(p, q) 模型变为

$$x_t = \mu^{(i)} + \sum_{j=1}^p \phi_j^{(i)} x_{t-j} + a_t^{(i)} \quad \text{当 } x_{t-d} \in R^{(i)}$$

$$i=1, 2, \dots, l$$

显然它是门限自回归模型。

iii) 如果 $\psi_u(x_{t-1}) = 0 (u=1, 2, \dots, q)$ $\mu(x_{t-1}) = 0$,
 $\phi_j(x_{t-1}) = \phi_j + \pi_j e^{-\tau x_{t-1}^2}, (j=1, 2, \dots, p)$

则 SDM(p, q) 模型变为 (9.1.12) 式的指数自回归模型。

iv) 如果 $\mu(x_{t-1}), \phi_j(x_{t-1}) (j=1, 2, \dots, p)$ 为常数,

$$\psi_j(x_{t-1}) = \theta_j + \sum_{k=1}^P \beta_{jk} x_{t-k} \quad j=1, \dots, \max(q, Q)$$

共 P, Q 为正整数, 当 $q < Q$ 时 $\theta_j = 0$; 当 $q > Q$ 时 $\beta_{jk} = 0 (j=1, \dots, \max(q, Q))$, 则 SDM(p, q) 模型变为 (9.1.11) 的双线性模型。

M.B. Priestley 对 SDM(p, q) 模型中的函数 $\mu(\cdot), \phi_j(\cdot), \psi_i(\cdot)$ 事先不作类型假设, 只要求它们具有一定的平滑性, 而将 SDM(p, q) 模型化成一个推广的 Kalman 滤波模型, 其系数矩阵是由 0, 1 和 $\mu(x_{t-1}), \phi_j(x_{t-1}) (j=1, 2, \dots, p), \psi_i(x_{t-1}) (i=1, 2, \dots, q)$ 组成。以状态空间表示的推广的 Kalman 滤波模型形式为

其中 $\{a_i\}$ 和 $\{\tilde{a}_i\}$ 都是相互独立相同正态分布,它们分别为 $a_i \sim \mathcal{N}(\mathcal{N}(0, (\frac{1}{2})^2))$, $\tilde{a}_i \sim \mathcal{N}(0, 1)$ 。显然 $x_i, \tilde{x}_i$ 可以分别表为

$$x_i = a_i + \frac{1}{2}a_{i-1} + \frac{1}{4}a_{i-2} + \cdots \quad (9.1.18)$$

$$\tilde{x}_i = \frac{1}{2}(\tilde{x}_{i+1} + \tilde{a}_{i+1}) = \frac{1}{2}\left(\tilde{a}_{i+1} + \frac{1}{2}\tilde{a}_{i+2} + \frac{1}{4}\tilde{a}_{i+3} + \cdots\right) \quad (9.1.19)$$

由条件不难验证 x_i 和 $\tilde{x}_i$ 都是正态 $N(0, \frac{1}{3})$,且具有相同的协方差函数。由于在正态情况下,前二阶矩完全决定了整个概率结构,所以 x_i 和 $\tilde{x}_i$ 的概率结构是完全一样的。这样对于 $\{\tilde{x}_i\}$ 的一个实现,我们亦可以用(9.1.16)来拟合,而(9.1.16)模型在最小方差意义下的一步预报为

$$\hat{x}_{i-1}(1) = \frac{1}{2}x_{i-1}$$

给出了最佳线性预报。由于是正态,故也是最佳预报。但在非正态时,情况就不同了,例如若在(9.1.16)和(9.1.17)中 a_i 和 $\tilde{a}_i$ 分别为

$$a_i = \begin{cases} \frac{1}{2}, & \text{以概率为 } \frac{1}{2} \\ 0, & \text{以概率为 } \frac{1}{2} \end{cases} \quad (9.1.16)'$$

$$\tilde{a}_i = \begin{cases} 1, & \text{以概率为 } \frac{1}{2} \\ 0, & \text{以概率为 } \frac{1}{2} \end{cases} \quad (9.1.17)'$$

相应模型记为(9.1.16')和(9.1.17'),则 x_i 和 $\tilde{x}_i$ 具有相同的前二阶矩。因为由(9.1.18)和(9.1.19)知

$$\begin{aligned} E a_i &= \frac{1}{4} & E \tilde{a}_i &= \frac{1}{2} \\ E a_i^2 &= \frac{1}{8} & E \tilde{a}_i^2 &= \frac{1}{2} \end{aligned}$$

$$E x_i = E \tilde{x}_i = \frac{1}{2}$$

$$E x_i^2 = E \tilde{x}_i^2 = \frac{1}{6}$$

由于线性最小方差预报仅和前一、二阶矩有关,于是 x_i 和 $\tilde{x}_i$ 的最佳线性预报是一样的。另一方面,由(9.1.16')得

$$\hat{x}_{i-1}(1) = \frac{1}{2}x_{i-1} + E a_i = \frac{1}{2}x_{i-1} + \frac{1}{4} \quad (9.1.20)$$

一步预报误差方差为

$$E(x_i - \hat{x}_{i-1}(1))^2 = E\left(a_i - \frac{1}{4}\right)^2 = \frac{1}{16}$$

根据定义,得(9.1.16')的一步最佳预报为

$$E(x_i | x_{i-1}, x_{i-2}, \dots) = \frac{1}{2}x_{i-1} + E a_i = \frac{1}{2}x_{i-1} + \frac{1}{4} \quad (9.1.21)$$

所以(9.1.16')的最佳线性预报与最佳预报是相等,但(9.1.17')的一步最佳预报为

$$\begin{aligned} E(\tilde{x}_i | \tilde{x}_{i-1}, \tilde{x}_{i-2}, \dots) \\ = 2\tilde{x}_{i-1} - E\tilde{a}_i = 2\tilde{x}_{i-1} \pmod{1} = \tilde{x}_i \end{aligned} \quad (9.1.22)$$

其中(mod 1)表示同模 1,即只取该数的小数部分。(9.1.22)式成立是因为由(9.1.17')知 $\tilde{x}_{i-1} = \frac{1}{2}(\tilde{x}_i + \tilde{a}_i)$,由于我们总讨论稳态

情况,如果给某一 $\tilde{x}_i$ 以任何初值,又 $\tilde{a}_i$ 以 $\frac{1}{2}$ 概率取 0 或 1,易见按

$\tilde{x}_{i-1} = \frac{1}{2}(\tilde{x}_i + \tilde{a}_i)$ 递推 $\tilde{x}_{i-1}, \tilde{x}_{i-2}, \dots$, 以概率为 1 地从某步开

始,并从此后 $\tilde{x}_{i-1}$ 都落在 $[0, 1]$ 之中,因而我们可设 $\tilde{x}_i$ 只在 $[0, 1]$ 之中取值。但 $\tilde{a}_i$ 只取 0 或 1,所以由(9.1.17')知,若 $0 \leq 2\tilde{x}_{i-1} < 1$, 则 $\tilde{a}_i$ 必取 0; 若 $2\tilde{x}_{i-1} \geq 1$, 则 $\tilde{a}_i$ 必取 1。于是得到(9.1.22)式。

(9.1.22)式说明(9.1.17')的最佳预报是完全没有误差。如果我们用通常 ARMA(p, q)模型去拟合,判定它为(9.1.16')而进行一步预报,那么就不合算了。

由以上讨论可知,线性性和正态性有着密切的关系。如果 $\{x_t\}$ 是正态序列,一般用线性模型就可以了,如果是非正态序列,用线性模型一般不合适。我们可以利用以前第四章§1讲过的方法来检验正态性,有时不仅要检验一维边缘分布,也要看看二维边缘分布。譬如可以画出数据 (x_{t-1}, x_t) 的直方图,即把平面上的一定范围分成均匀的格子网,落在某一格子中的 (x_{t-1}, x_t) 点数作为直方图在这个格子上的取值,如果直方图的形状比较对称,并且近似于一个椭圆顶草帽时,可以认为 (x_{t-1}, x_t) 为二维正态;如果奇峰屹立或者即使是单峰,但峰的等位线奇形怪状,那么认为非正态。这仅仅是一种直观的参考性的方法,实际中正态性常常难于判定。近年来还有比较严格的检验非线性的方法,这要用到“双谱”的概念,检验程序也比较复杂,这里就不再叙述,感兴趣的读者可参考^[43]。

下面我们将给出一种判别模型是否线性的简单易行的办法,称为条件期望估计法。我们所给出的具体步骤是这种方法的一种特殊形式。此方法对统计回归模型有严格的理论根据,可参考^[42]。对于时间序列,我们只是套用它,到底其误差分布如何?还不能给出具体的公式。

由第一章(1.4.15)式知,对于正态序列,有

$E(x_n | x_{n-i}) = E x_n + \text{cov}(x_n, x_{n-i}) (\text{var} x_{n-i})^{-1} (x_{n-i} - E x_{n-i})$
经改写可表为

$$E(x_n | x_{n-i}) = E x_n - \text{cov}(x_n, x_{n-i}) (\text{var} x_{n-i})^{-1} E x_{n-i} \\ + \text{cov}(x_n, x_{n-i}) (\text{var} x_{n-i})^{-1} x_{n-i} \quad (9.1.23)$$

由此可见,对于正态序列,当分布的一、二阶矩已知时, x_n 关于 x_{n-i} 的条件期望应该是 x_{n-i} 的线性函数。利用这一原理,我们可以构造模型是否为线性的一种简单判别方法。因为在本节开头我们已经分析过,序列的正态性和模型的线性性往往是相互依存的,如果由序列的实现计算出 $E(x_n | x_{n-i})$ ((9.1.23)中一、二阶矩由样本估计值来代替)关于 x_{n-i} 是线性关系,则可接受 (x_n, x_{n-i}) 为联合正态分布的假设,从而可用线性模型来描述时间序列 $\{x_n\}$ 。否则,就

不能认为 $\{x_n\}$ 为正态序列,从而不能用线性模型来描述 $\{x_n\}$ 。当然这是种粗略的看法,细心的读者会知道,欲判定随机序列为正态序列,由第一章知,要对序列的任意有限维分布都检验其正态性才是。

我们将上述条件期望检验方法的步骤归纳如下:

i) 将动态数据 $x_1, x_2, \dots, x_N$ 的取值范围等分为 L 个区间:
 $R_1, R_2, \dots, R_L$ 。

ii) 对 $j=1, 2, \dots, J$, 填制如下表格

$x_n \backslash x_{n-j}$	R_1	R_2	...	R_L
R_1	n_{11}	n_{12}	...	n_{1L}
R_2	n_{21}	n_{22}	...	n_{2L}
$\vdots$	$\vdots$	$\vdots$	...	$\vdots$
R_L	n_{L1}	n_{L2}	...	n_{LL}
和	n_1	n_2	...	n_L

其中

n_{kl} 表示 $\{x_n \in R_k, x_{n-j} \in R_l\}$ 的 (x_n, x_{n-j}) ($n = j+1, \dots, N$) 的个数。

n_l 表示 $\{x_{n-j} \in R_l\}$ 中 x_{n-j} ($n = j+1, \dots, N$) 的个数。

iii) 令 $E^{(j)}(x_n | x_{n-j}) \triangleq E(x_n | x_{n-j} \in R_l)$, 则 $E^{(j)}(x_n | x_{n-j})$ 可用下面的式子估计

$$\begin{aligned}
 & \sum_{k=1}^L M_k \hat{P}(x_n \in R_k | x_{n-j} \in R_l) \\
 &= \sum_{k=1}^L M_k \frac{\hat{P}(x_n \in R_k, x_{n-j} \in R_l)}{\hat{P}(x_{n-j} \in R_l)}
 \end{aligned}$$

$$= \sum_{k=1}^L M_k \frac{n_{kl}/N}{n_l/N} = \frac{1}{n_l} \sum_{k=1}^L M_k n_{kl}$$

其中 M_k 是第 k 个区间 R_k 的中点值, 而 $\hat{P}(\cdot)$ 为相应的 $P(\cdot)$ 的估计值。

iv) 以 x_{n-j} 为横轴, $E(x_n | x_{n-j})$ 为纵轴, 作点值图 $(M_l, E^{(l)}(x_n | x_{n-j}))$, $l=1, 2, \dots, L$




图 9.6 条件期望估计值点值图

v) 判断图 9.6 中点值曲线是否可认为是直线, 这里可用统计中线性回归的方法, 计算残差平方和 S , 当 S 适当地小时, 可认为点值图是直线状。否则认为非直线状。

vi) 当对 $j=1, 2, \dots, J$ 依上法作出的点值图 $E(x_n | x_{n-j})$ 都可接受为直线时, 就认为模型可采用线性的, 否则模型用非线性的。通常取 $J=4$ 即可。

§ 2 双线性模型

§ 2.1 双线性模型的特点与分类

最一般的双线性模型为

$$x_t = \sum_{i=1}^p \phi_i x_{t-i} + \sum_{j=0}^q \theta_j a_{t-j} + \sum_{k=0}^Q \sum_{l=1}^P \beta_{kl} a_{t-k} x_{t-l} \quad (9.2.1)$$

其中, 在双线性模型中白噪声序列要求是严格白噪声序列, 即对任

意 s, t 整数, a_s 与 a_t 为相互独立零均值方差为 σ_a^2 的随机变量。显然, 这一条件比通常在线性模型中对白噪声序列所要求的条件要强些。当然在 $\{a_t\}$ 为正态白噪声序列时, 二者等价。如果 ARMA 模型中的白噪声序列 $\{a_t\}$ 是严格的, 称它为严格白噪声的 ARMA 模型。由 (9.2.1) 模型形式可见, 当 a_{t-1} 固定时, 它是 x_{t-1} 的线性函数, 当 x_{t-1} 固定时, 它是 a_{t-1} 的线性函数, 故称双线性模型。显然, 双线性模型是线性模型的直接推广。运用双线性模型来逼近某些非线性模型, 比用线性模型更精确, 从所采用的分析方法来看, 与线性模型大体相似。由于人们还不能给出辨识双线性模型的强有力的判别准则, 它的应用目前只限于最简单的几种类型。

双线性模型最早来自一些经济学上的问题, 譬如第 t 年的某物资产量为 x_t , 把它投入再生产。第 t 年回收率为 y_t , 可以认为是严格的 MA(1) 模型, 即

$$y_t = \frac{x_t - x_{t-1}}{x_{t-1}} = a_t + \theta a_{t-1}$$

从而第 t 年的该物资产量 x_t 应有如下的模型形式

$$x_t = x_{t-1} + a_t x_{t-1} + \theta a_{t-1} x_{t-1}$$

显然, 它是一个双线性模型。

对于双线性模型, 如果 $\{a_t\}$ 是正态白噪声序列, x_t 不会是正态的。下面我们用一个例子来说明它与正态有多大差别。考虑如下双线性模型

$$x_t = \phi x_{t-1} - \beta a_t x_{t-1} + a_t \quad (9.2.2)$$

其中 $\{a_t\}$ 为正态白噪声序列。于是

$$\begin{cases} a_t = \frac{x_t - \phi x_{t-1}}{1 - \beta x_{t-1}} \\ x_{t-1} = x_{t-1} \end{cases} \quad (9.2.3)$$

由 (x_t, x_{t-1}) 到 (a_t, x_{t-1}) 的变换的 Jacobi 为 $\frac{1}{1 - \beta x_{t-1}}$ 。由于 x_{t-1} 与 a_t 是相互独立, 以 $\psi(x)$ 表示 x_{t-1} 的分布密度, $N(a)$ 表示 a_t 的正态分布密度, $\varphi(y, x)$ 表示 (x_t, x_{t-1}) 的联合分布密度, 则

$$\varphi(y, x) = \frac{1}{|1 - \beta x|} N\left(\frac{y - \phi x}{1 - \beta x}\right) \psi(x) \quad (9.2.4)$$

我们得到 x_i 的边缘分布密度为

$$\begin{aligned} \psi(y) &= \int_{-\infty}^{\infty} \varphi(y, x) dx \\ &= \int_{-\infty}^{\infty} \frac{1}{|1 - \beta x|} N\left(\frac{y - \phi x}{1 - \beta x}\right) \psi(x) dx \end{aligned} \quad (9.2.5)$$

要给出 $\psi(y)$ 的明确表达式是不容易的, 但可以知道它的大致的样子, 从而看出与正态差异多少。

当 $y = \frac{\phi}{\beta}$ 时, $N\left(\frac{y - \phi x}{1 - \beta x}\right) = N\left(\frac{\phi}{\beta}\right)$ 此时 (9.2.5) 式为

$$\psi\left(\frac{\phi}{\beta}\right) = N\left(\frac{\phi}{\beta}\right) \int_{-\infty}^{\infty} \frac{1}{1 - \beta x} \psi(x) dx \quad (9.2.6)$$

$1/\beta$ 可能是 (9.2.6) 式被积函数的奇点, 因此, 有两种可能

第一种 $\psi(\phi/\beta) < \infty$, 此时必有 $\psi(1/\beta) = 0$ 。

第二种 $\psi(\phi/\beta) = \infty$ 。第一种可能性不存在, 因 (9.2.5) 右端积分号下的第一个因子恒大于零, 第二个因子 $\psi(x)/|1 - \beta x| \geq 0$, 所以积分后得到 $\psi(1/\beta) > 0$, 故 $\psi(x)$ 在 ϕ/β 处必趋于 ∞ 。另外, 当 $\beta \rightarrow 0$ 时, (9.2.2) 趋于线性模型

$$x_i = \phi x_{i-1} + a_i.$$

由于 a_i 为正态, 故 x_i 趋于正态, 虽然分布密度函数在 $1/\beta$ 处仍有一奇点, 但这一点附近的分量变得越来越小, 而这一点越来越向 ∞ 处移去 (即 $\beta \rightarrow 0$), 如图 9.7 所示, 其中 $\beta_2 < \beta_1$ 。




图 9.7

虚线相应 $\beta = \beta_2$, 实线相应 $\beta = \beta_1$ 。因此当 β 较大时, $\psi(x)$ 与正态分布相差大, 当 β 较小时, 分布和正态分布相近, 当 $\beta \rightarrow 0$ 时, 分布趋于正态分布。此时, 失去了采用双线性模型的意义, 可采用线性模型。

当 $x_{i-1} = x$ 已知时, x_i 的条件密度 $\varphi(y|x)$ 为

$$\varphi(y|x) = \frac{\varphi(y, x)}{\psi(x)} = N\left(\frac{y - \phi x}{1 - \beta x}\right) / |1 - \beta x| \quad (9.2.7)$$

是正态。这从模型(9.2.2)也可直接看出, 因这时 $x_{i-1} = x$ 可看成常数, 如果 a_i 是服从标准正态 $\mathcal{N}(0, 1)$, 则(9.2.2)的条件均值为 ϕx , 条件方差为 $(1 - \beta x)^2$, 当 $x = \frac{1}{\beta}$ 时, 条件方差为零, 也就是说, 当 $x_{i-1} = \frac{1}{\beta}$ 时, 由条件均值来对 x_i 所作的预报是准确无误的, 即此时有

$$\hat{x}_i = E(x_i | x_{i-1}) = \phi x_{i-1} = \phi / \beta = x_i$$

当 x_{i-1} 离 $\frac{1}{\beta}$ 越远, 预报误差越大。这种性质是线性模型绝对不会有。

在最一般的双线性模型(9.2.1)式中, 如果 $q < 0$, (9.2.1)即为

$$x_i = \sum_{s=1}^P \phi_s x_{i-s} + \sum_{k=0}^Q \sum_{l=1}^P \beta_{kl} a_{i-k} x_{i-l} \quad (9.2.8)$$

我们称(9.2.8)式为关于 x_i 齐次的, 如果 β_{0i} 不全为零, 则(9.2.1)

式中 a_i 的系数为 $\theta_0 + \sum_{i=1}^P \beta_{0i} x_{i-1}$, 此时预报误差的大小依赖于过

去的值, 这种误差称为异样误差, 称这种模型为异样的。如果 β_{0i} 全为零, 我们称模型为非异样的。我们用 (p, q, P, Q) 表示一个非异样的双线性模型的阶数。在 $q \geq 0$ 时, 我们总约定 $\theta_0 = 1$, 把非 1 因子吸收到 a_i 中去。因此, $(0, 0, P, Q)$ 阶的双线性模型为

$$x_i = \sum_{k=1}^Q \sum_{l=1}^P \beta_{kl} a_{i-k} x_{i-l} + a_i \quad (9.2.9)$$

称它为全双线性模型。

令 $B = (\beta_{kl})_{q \times p}$, 则(9.2.9)的右端的第一项可表为

$$(a_{t-1}, \dots, a_{t-q})B(x_{t-1}, \dots, x_{t-p})^T$$

如果 $\beta_{kl} = 0$, 对一切 $k > l$, 即 B 中主对角线(由于 B 不一定是方阵, B 的主对角线是指从左上角开始, 但不一定终于矩阵右下角元)下方的元都为零, 我们称这样的模型为右上角模型。如果 $\beta_{kl} = 0$ 对一切 $k < l$, 则 B 中主对角线上方的元都为零, 我们称这样的模型为左下角模型。如果 $\beta_{kl} = 0$ 对一切 $k \neq l$, 我们称这样的模型为对角线模型。

右上角模型的处理比其它各种情况都要方便。这是因为 $k < l$ 时, a_{t-k} 和 x_{t-l} 独立, 故每一双线性项 $a_{t-k}x_{t-l}$ 都是两个独立的随机变量。

§ 2.2 简单的双线性模型及其辨识

考虑一种最简单的双线性模型

$$x_t = \beta a_{t-k} x_{t-l} + a_t \quad k, l > 0, \quad (9.2.10)$$

其中 $\{a_t\}$ 是严格的白噪声序列, 即对任意 t , $E a_t = 0$, $E a_t^2 = \sigma_a^2$, 且任意 $s \neq t$, a_s 和 a_t 相互独立。又设 a_t 的各阶矩都存在, x_t 对不同的 t 各阶矩都相等, 当 $s > t$ 时 a_s 与 x_t 相互独立。为方便起见, 令 $\lambda = \beta \sigma_a$, 下面分别对右上角模型, 左下角模型和对角线模型加以讨论。

1. 首先考虑第一种模型。我们以

$$x_t = \beta a_{t-1} x_{t-2} + a_t \quad (9.2.11)$$

为例。易见, $E x_t = 0$, $E x_t^2 = \beta^2 \sigma_a^2 E x_{t-2}^2 + \sigma_a^2$, 由于 $E x_t^2 = E x_{t-2}^2$, 故

$$\text{var } x_t = \frac{\sigma_a^2}{1 - \lambda^2} \quad (9.2.12)$$

可见, x_t 的方差存在的充要条件是

$$|\lambda| = |\beta \sigma_a| < 1 \quad (9.2.13)$$

考虑自协方差函数, 对 $s > 0$ 有

$$\begin{aligned} \text{cov}(x_t, x_{t-s}) &= E x_t x_{t-s} \\ &= E (\beta a_{t-1} x_{t-2} + a_t) (\beta a_{t-1-s} x_{t-2-s} + a_{t-s}) \end{aligned}$$

$$=0 \quad (9.2.14)$$

事实上,当 $s>1$ 时,由于对 $k<l$, a_{t-k} 与 x_{t-l} 独立, (9.2.14) 式显然成立。当 $s=1$ 时,

$$\text{cov}(x_t, x_{t-1}) = E x_{t-2} a_{t-1}^2 - E x_{t-2} E a_{t-1}^2 = 0$$

所以 $\{x_t\}$ 为白噪声序列。再考察 x_t 的高阶矩

$$\begin{aligned} E x_t^k &= \sum_{j=0}^k \beta^j c_j^k E(a_{t-1}^j x_{t-2}^{k-j} a_t^{k-j}) \\ &= \beta^k E a_{t-1}^k E x_{t-2}^k + w_t^{(k-1)} \end{aligned} \quad (9.2.15)$$

其中 c_j^k 表示 k 个中取 j 个的组合数, $w_t^{(k-1)}$ 表示只含有 x_t 的低于 k 阶的矩。现在若低于 k 阶的矩都存在, 那么当 k 为奇数时, $E a_{t-1}^k = 0$ (因为 a_t 的分布为零均值的对称分布), 显然, j 和 $k-j$ 中必有一个是奇数, 因此 $w_t^{(k-1)} = 0$, 即 $E x_t^k = 0$ 。如果 k 是偶数, 那么由 $E x_{t-2}^k = E x_t^k$ 知

$$E x_t^k = \frac{w_t^{(k-1)}}{1 - \beta^k E a_t^k}$$

且由 (9.2.15) 式及 a_t 的奇数阶矩为零, 可以得到 $w_t^{(k-1)}$ 的和项全由 $\beta a_{t-1} x_{t-2}$ 和 a_t 的偶数阶矩的乘积组成, 因此, $w_t^{(k-1)} > 0$, 从而得 k 为偶数时, k 阶矩存在的充要条件是

$$\beta^k E a_t^k < 1 \quad (9.2.16)$$

例如, $a_t \sim N(0, \sigma_a^2)$ 时, 由于 $E a_t^4 = 3(E a_t^2)^2 = 3 \sigma_a^4$ (注意此式用到这样的事实, 设 x_1, x_2, x_3, x_4 为零均值正态随机变量, 则 $E x_1 x_2 x_3 x_4 = E x_1 x_2 E x_3 x_4 + E x_1 x_3 E x_2 x_4 + E x_1 x_4 E x_2 x_3$)。由 (9.2.16)

知四阶矩存在充要条件为 $3 \beta^4 \sigma_a^4 < 1$ 或 $\lambda^4 < \frac{1}{3}$ 。显然它比 (9.2.13)

的条件更严格。一般当 k 增加时, 由于 $E x_t^k$ 增加很快, 使得 $E x_t^k$ 存在的条件越来越严, 或者说 β 所允许的范围越来越小。

当 $E x_t^4 < \infty$ 时, 由 (9.2.11)、(9.2.12) 知, 对于 $s>1$,

$$\begin{aligned} \tilde{\gamma}_s &= \text{cov}(x_t^2, x_{t-s}^2) = E x_t^2 x_{t-s}^2 - (E x_t^2)^2 \\ &= E (\beta a_{t-1} x_{t-2} + a_t)^2 x_{t-s}^2 - (E x_t^2)^2 \\ &= \beta^2 \sigma_a^2 E x_{t-2}^2 x_{t-s}^2 + \sigma_a^2 E x_{t-s}^2 - (E x_t^2)^2 \end{aligned}$$

$$\begin{aligned}
&= \lambda^2 E x_{i-2}^2 x_{i-s}^2 + \frac{\sigma_a^4}{1-\lambda^2} - \frac{\sigma_a^4}{(1-\lambda^2)^2} \\
&= \lambda^2 \left[E x_{i-2}^2 x_{i-s}^2 - \frac{\sigma_a^4}{(1-\lambda^2)^2} \right] \\
&= \lambda^2 (E x_{i-2}^2 x_{i-s}^2 - E x_{i-2}^2 E x_{i-s}^2) \\
&= \lambda^2 \text{cov}(x_{i-2}^2, x_{i-s}^2) = \lambda^2 \tilde{\gamma}_{s-2}
\end{aligned} \tag{9.2.17}$$

即当 $s > 1$ 时, $\tilde{\gamma}_s$ 满足齐次差分方程

$$\tilde{\gamma}_s - \lambda^2 \tilde{\gamma}_{s-2} = 0$$

由第二章(2.4.13)式可见 x_t^2 是 ARMA(2,1) 模型。用类似的方法可以证明, 如果 x_t 是满足(9.2.10), 且 $k < l$, 则 x_t^2 是 ARMA(l, k) 模型。 x_t^2 的自协方差函数满足

$$\tilde{\gamma}_s = \lambda^2 \tilde{\gamma}_{s-1}, \quad s > k \tag{9.2.18}$$

由此可得, 如果 x_t 的模型为右上角模型(9.2.10), 就可以利用 x_t^2 建立线性 ARMA 模型, 其模型的阶确定为 l, k 。

顺便指出, 对一般的右上角全双线性模型

$$x_t = \sum_{i=1}^p \sum_{k=1}^l \beta_{ki} \alpha_{i-k} x_{t-i} + a_t \tag{9.2.19}$$

用类似的方法可以得到 x_t^2 的协方差函数满足

$$\tilde{\gamma}_s = \sigma_a^2 \sum_{i=1}^p \left(\sum_{k=1}^{l-1} \beta_{ki}^2 \right) \tilde{\gamma}_{s-i} \tag{9.2.20}$$

其中 s 大于使 $\beta_{ki} \neq 0$ 的最大的 k , 即

$$s > \max\{k; \beta_{ki} \neq 0\}.$$

利用 x_t^2 来帮助我们辨识 l, k 是一种很好的办法, 请看下面的模拟例子:

$$\begin{aligned}
x_t &= 0.5 a_{t-1} x_{t-2} + a_t \\
a_t &\sim \mathcal{N}(0, 1)
\end{aligned}$$

设 $\{z_t\}$ 为某个严格的白噪声序列, 对 x_t, z_t 分别都用 200 个样本点, 得到 x_t, z_t, x_t^2, z_t^2 的样本相关函数 $\rho_{x_t}^2, \rho_{z_t}^2, \rho_{x_t^2}^2, \rho_{z_t^2}^2$ 如表 9.1。

表 9.1 x_t 、 z_t 、 x_t^2 和 z_t^2 的样本相关函数

s	ρ_s^x	ρ_s^z	$\rho_s^{x^2}$	$\rho_s^{z^2}$
0	1	1	1	1
1	-0.10	-0.01	0.30	-0.03
2	-0.03	-0.05	0.45	-0.13
3	0.09	0.03	0.08	0.03
4	0.02	0.10	0.14	-0.09
5	0.05	0.06	0.01	-0.08
6	0.00	0.12	0.08	-0.04
7	0.06	-0.04	-0.02	-0.03
8	-0.02	-0.13	0.05	0.03
9	0.05	-0.06	-0.02	0.05
10	0.03	0.02	-0.10	-0.06

可以看出, $\{z_t^2\}$ 仍然是白噪声序列, 而 $\{x_t^2\}$ 可以认为是 ARMA 序列。

2. 讨论(9.2.10)是左下角情形。这时(9.2.10)式可表为

$$x_t = \beta a_{t-nl+j} x_{t-l} + a_t \quad (9.2.21)$$

其中 $n \geq 2, 0 \leq j < l$, 由它逐步叠代, 直至等式右端 a 的下标第一次大于 x 的下标时为止, 利用 a_t 的相互独立性得

$$E x_t = \beta^n E a_{t-nl+j} a_{t-(n+1)l+j} \cdots a_{t-(2n-1)l+j} x_{t-nl} = 0 \quad (9.2.22)$$

$$0 < j < l$$

$$E x_t = \beta^{n+1} E a_{t-nl} a_{t-(n+1)l} \cdots a_{t-(2n)l} x_{t-(n+1)l} = 0$$

可见, x_t 的均值为零, 用类似的方法求方差, 对 $0 < j < l$, 有

$$\begin{aligned} E x_t^2 &= \beta^{2(n-1)} E a_{t-(n)l+j}^2 \cdots a_{t-(2n-1)l+j}^2 x_{t-(n-1)l}^2 \\ &\quad + \sigma_a^2 + \beta^2 \sigma_a^4 + \cdots + \beta^{2(n-2)} \sigma_a^{2(n-1)} \\ &= \beta^{2n} \sigma_a^2 E a_{t-nl+j}^2 \cdots a_{t-2nl+j}^2 x_{t-nl}^2 + \sigma_a^2 + \beta^2 \sigma_a^4 + \\ &\quad + \cdots + \beta^{2(n-1)} \sigma_a^{2n} \end{aligned} \quad (9.2.23)$$

由于平稳性,在(9.2.23)的 $E x_t^2$ 的右端两个表达式中所示的期望值相同,记为 μ , (9.2.23)两端约去相同的项后,有

$$\beta^{2(n-1)}\mu = \beta^{2n}\sigma_a^2\mu + \beta^{2(n-1)}\sigma_a^{2n}.$$

即 $\mu = \frac{\sigma_a^{2n}}{1-\lambda^2}$, 其中 $\lambda = \beta\sigma_a$, 于是(9.2.23)式可表为

$$\begin{aligned} E x_t^2 &= \beta^{2(n-1)}\sigma_a^{2n}/1-\lambda^2 + \sigma_a^2(1-\lambda^{2(n-1)})/1-\lambda^2 \\ &= \frac{\sigma_a^2}{1-\lambda^2}, \quad 0 < j < l \end{aligned} \quad (9.2.24)$$

对于 $j=0$ 的情形, 由类似方法得

$$E x_t^2 = \sigma_a^2(1+2\lambda^{2(n+1)})/1-\lambda^2$$

由上述知, x_t 的二阶矩存在的充分必要条件仍为 $|\lambda| < 1$ 。对 $0 < j < l$, 且 $s \neq 0$ 的情形, 类似地可证明

$$\begin{aligned} \text{cov}(x_t, x_{t-s}) &= E(\beta a_{t-nl+s}x_{t-l} + a_t)(\beta a_{t-s-nl+s}x_{t-s-l} + a_{t-s}) \\ &= 0 \end{aligned} \quad (9.2.25)$$

也就是说, $\{x_t\}$ 是白噪声序列。对 $j=0$, x_t 可表为

$$\begin{aligned} x_t &= a_t + \beta a_{t-nl}a_{t-l} \\ &\quad + \beta^2 a_{t-nl}a_{t-(n+1)l}a_{t-2l} \\ &\quad + \beta^3 a_{t-nl}a_{t-(n+1)l}a_{t-3l} + \cdots \end{aligned}$$

当 $n=2$, $\text{cov}(x_t, x_{t-3l}) = \beta^2 E a_{t-2l}^2 E a_{t-3l}^2 = \beta^2 \sigma_a^4 = \sigma_a^2 \lambda^2$ 。当 $n \neq 2$ 时, $\text{cov}(x_t, x_{t-3l}) = 0$, 故

$$\text{cov}(x_t, x_{t-3l}) = \begin{cases} \sigma_a^2 \lambda^2, & \text{当 } n=2 \\ 0 & \text{当 } n \neq 2 \end{cases} \quad (9.2.26)$$

此外, 容易验证, $\text{cov}(x_t, x_s) = 0$, 当 $t-s \neq 3$ 。由此可见, 在 $n=2$ 时, $\{x_t\}$ 为 $\text{MA}(3l)$ 序列, 且

$$\rho_k = \begin{cases} \frac{\lambda^2(1-\lambda^2)}{1+2\lambda^6}, & \text{当 } k=3l \\ 0 & \text{, 当 } k \neq 3l. \end{cases}$$

当 $n \neq 2$ 时, $\{x_t\}$ 为白噪声序列, 和以前类似的方法可以处理高阶矩, 并可证明 $\{x_t^2\}$ 不是白噪声序列, 而是 ARMA 序列, 这里不再细说了。

3. 讨论(9.2.10)是对角线情形。例如

$$x_t = \beta a_{t-1} x_{t-1} + a_t \quad (9.2.27)$$

(9.2.27)又可表为

$$x_t = a_t + \sum_{j=1}^{\infty} \beta^j \left(\prod_{i=1}^{j-1} a_{t-i} \right) a_{t-j}^2$$

由此可见, $E x_t a_t = E a_t^2 = \sigma_a^2$, 于是有

$$E x_t = \beta E a_{t-1} x_{t-1} = \beta \sigma_a^2 \quad (9.2.28)$$

$$x_t^2 = \beta^2 a_{t-1}^2 x_{t-1}^2 + 2 \beta a_t a_{t-1} x_{t-1} + a_t^2 \quad (9.2.29)$$

$$E a_t^2 x_t^2 = \beta^2 \sigma_a^2 E a_{t-1}^2 x_{t-1}^2 + 2 \beta E a_t^3 E a_{t-1} x_{t-1} + E a_t^4$$

由于 $E a_t^2 x_t^2 = E a_{t-1}^2 x_{t-1}^2$, $E a_t^3 = 0$ 和 $\beta \sigma_a = \lambda$, 故

$$E a_t^2 x_t^2 = \frac{E a_t^4}{1 - \lambda^2}$$

代入(9.2.29), 得到 $E x_t^2 = \beta^2 \frac{E a_t^4}{1 - \lambda^2} + \sigma_a^2$, 则

$$\begin{aligned} \text{var } x_t &= E x_t^2 - (E x_t)^2 = \beta^2 \frac{E a_t^4}{1 - \lambda^2} + \sigma_a^2 - \beta^2 \sigma_a^4 \\ &= \beta^2 \frac{E a_t^4}{1 - \lambda^2} + (1 - \lambda^2) \sigma_a^2 \end{aligned} \quad (9.2.30)$$

特别在 $\{a_t\}$ 为正态白噪声序列时, 有 $E a_t^4 = 3 \sigma_a^4$, 上式可表为

$$\begin{aligned} \text{var } x_t &= \frac{3 \lambda^2 \sigma_a^2}{1 - \lambda^2} + (1 - \lambda^2) \sigma_a^2 \\ &= \frac{\lambda^4 + \lambda^2 + 1}{1 - \lambda^2} \sigma_a^2 \end{aligned} \quad (9.2.31)$$

故 x_t 的方差存在的充要条件是 $|\lambda| < 1$.

考虑自协方差, 由于

$$\begin{aligned} E x_t x_{t-1} &= E (\beta a_{t-1} x_{t-1} + a_t) x_{t-1} = \beta E a_{t-1} x_{t-1}^2 \\ &= \beta E a_{t-1} (\beta^2 a_{t-2}^2 x_{t-2}^2 + 2 \beta a_{t-1} a_{t-2} x_{t-2} + a_{t-1}^2) \\ &= 2 \beta^2 E a_{t-1}^2 E a_{t-2} x_{t-2} = 2 \beta^2 E a_{t-1}^2 E a_{t-2}^2 \\ &= 2 \beta^2 \sigma_a^4 = 2 \lambda^2 \sigma_a^2 = 2 (E x_t)^2. \end{aligned}$$

$$\begin{aligned} \text{故 } \text{cov}(x_t, x_{t-1}) &= E x_t x_{t-1} - (E x_t)^2 = (E x_t)^2 \\ &= \lambda^2 \sigma_a^2. \end{aligned} \quad (9.2.32)$$

对于 $s > 1$ 时,

$$\begin{aligned}
 E x_t x_{t-s} &= \beta E a_{t-1} x_{t-1} x_{t-s} + E a_t x_{t-s} \\
 &= \beta E a_{t-1} x_{t-1} x_{t-s} \\
 &= \beta E a_{t-1} (\beta a_{t-2} x_{t-2} + a_{t-1}) x_{t-s} \\
 &= \beta^2 E a_{t-1} a_{t-2} x_{t-2} x_{t-s} + \beta E a_{t-1}^2 x_{t-s} \\
 &= \beta \sigma_a^2 E x_{t-s} = \beta^2 \sigma_a^4 = \lambda^2 \sigma_a^2 = (E x_t)^2
 \end{aligned}$$

从而得到

$$\text{cov}(x_t, x_{t-s}) = E x_t x_{t-s} - (E x_t)^2 = 0 \quad (9.2.33)$$

这说明了只看二阶矩时, 由(9.2.32)和(9.2.33)知满足(9.2.27)的 $\{x_t\}$ 是 MA(1)序列。在正态情形下, 由(9.2.31), (9.2.32)和(9.2.33)知, $\{x_t\}$ 的自相关函数为

$$\begin{cases} \rho_1 = \frac{\lambda^2(1-\lambda^2)}{1+\lambda^2+\lambda^4} \\ \rho_s = 0, \text{ 当 } s > 1 \end{cases}$$

类似的方法可以验证, 比(9.2.27)更一般的对角形模型

$$x_t = \beta a_{t-k} x_{t-k} + a_t \quad (9.2.34)$$

的 $\{x_t\}$ 是 MA(k)序列, 且当 $j \neq k$ 时 $\rho_j = 0$, 在正态情形下,

$$\rho_k = \frac{\lambda^2(1-\lambda^2)}{1+\lambda^2+\lambda^4}$$

我们再考察(9.2.27)模型的 x_t 的高阶矩, 先作变换, 使两个非独立的相乘因子变换为独立因子。为此, 令 $\eta_t = \beta a_t$, $y_t = \beta x_t$, 则(9.2.27)变为

$$y_t = \eta_{t-1} y_{t-1} + \eta_t \quad (9.2.35)$$

再令

$$z_t = y_t - \eta_t$$

则(9.2.35)式可表为

$$z_t = \eta_{t-1} z_{t-1} + \eta_{t-1}^2 \quad (9.2.36)$$

这样的 z_t 只依赖于过去, 所以 z_t 和 η_t 独立, 显然, 若 a_t (即 η_t) 的 k 阶矩存在, 则 x_t 的 k 阶矩存在的条件与 z_t 的 k 阶矩存在的条件等价, 并且可从 $E z_t^k$ 算出 $E x_t^k$ 。其中

$$E z_t^k = \sum_{j=0}^k c_k^j E[\eta_{t-1}^{k-j} z_{t-1}^{j-j} (\eta_{t-1}^2)^j]$$

这里 c_k^j 是 k 个中取 j 个的组合数。

$$\begin{aligned} \text{故} \quad E z_t^k &= \sum_{j=1}^k c_k^j E \eta_{t-1}^{k-j} E z_{t-1}^{j-j} + E \eta_{t-1}^k E z_{t-1}^0 \\ &= w_t^{(k-1)} + E \eta_{t-1}^k E z_{t-1}^0 \end{aligned} \quad (9.2.37)$$

其中 $w_t^{(k-1)} \triangleq \sum_{j=1}^k c_k^j E \eta_{t-1}^{k-j} E z_{t-1}^{j-j}$, $w_t^{(k-1)}$ 只含有 x_t 的低于 k 阶的矩。由 $\eta_t = \beta a_t$ 的分布的对称性, 可看出 $w_t^{(k-1)} \geq 0$, 因此, 若低于 k 阶矩都存在, 则 k 阶矩存在的条件是 $E \eta_{t-1}^k < 1$, 仍然导致条件 $\beta^k E a_{t-1}^k < 1$ (k 为奇数时为零)。当条件满足时, k 阶矩可用 (9.2.37) 递推得到。下面给出当 a_t 为正态 $N(0, \sigma_a^2)$ 时, 三阶、四阶矩的计算结果为

$$\begin{aligned} E(x_t - E x_t)^3 &= 2 \lambda^3 (4 + 5 \lambda^2) / (1 - \lambda^2), \quad |\lambda| < 1 \quad (9.2.38) \\ E(x_t - E x_t)^4 &= \frac{3(1 + \lambda^2 + 57 \lambda^4 + 93 \lambda^6 + 117 \lambda^8 + 135 \lambda^{10}) \sigma_a^2}{(1 - \lambda^2)(1 - 3 \lambda^4)}, \\ \lambda^4 &< \frac{1}{3}. \end{aligned}$$

可以看出, 高阶矩可以区别这种简单的对角形双线性模型和严格白噪声下的 MA 模型。因为严格白噪声下的 MA(1) 模型的 $\{z_t\}$, 具有 $E(z_t - E z_t)^3 = 0$, 而 (9.2.38) 不为零。另外, 还可以证明, 如果令 $y_t = x_t^2$, 则对 (9.2.27) 模型有

$$\text{cov}(y_t, y_{t-s}) = \lambda^2 \text{cov}(y_t, y_{t-s+1}), s > 1$$

由第二章知 $\{x_t^2\}$ 满足 ARMA(1,1) 模型。对于严格的 MA(1) 模型, $\{z_t^2\}$ 仍然是 MA(1) 模型。设由

$$x_t = 0.5 a_{t-1} x_{t-1} + a_t$$

产生 200 个样本点, $\{z_t\}$ 是和 $\{x_t\}$ 具有相同方差的严格白噪声序列, 它也有 200 个样本点, 比较 x_t, z_t, x_t^2 及 z_t^2 的样本自相关函数 ρ_s 。如下比例从数值上验证了上述结论。

在只看二阶矩时, 表 9.3 给出了 (9.2.10) 模型可当成相应的

表 9.2 x_t, x_t, x_t^2 及 x_t^2 的样本自相关函数 ρ_s

s	ρ_s^x	$\rho_s^{x^2}$	$\rho_s^{x^2}$	$\rho_s^{x^2}$
0	1	1	1	1
1	0.18	0.17	0.55	0.13
2	-0.06	-0.03	0.21	-0.01
3	0.05	-0.06	0.09	-0.08
4	-0.00	-0.04	-0.05	-0.06
5	-0.04	-0.01	-0.12	-0.01
6	0.10	0.00	-0.09	-0.02
7	0.05	0.05	-0.08	-0.06
8	-0.02	0.00	-0.05	-0.07
9	-0.07	-0.04	0.01	-0.04
10	-0.01	-0.01	-0.00	-0.03

表 9.3 (9.2.10)模型当成相应MA(q)的 q 值

$k \backslash q$	1	2	3	4	5	6	...
1	1	0	0	0	0	0	...
2	3	2	0	0	0	0	...
3	0	0	3	0	0	0	...
4	0	6	0	4	0	0	...
5	0	0	0	0	5	0	...
6	0	0	9	0	0	6	...
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	

MA(q)时的阶数 q 值。

§ 2.3 稳定性可逆性和双线性模型预报

1. 稳定性: 对于一个线性系统 $\varphi(B)x_t = \eta_t$, 其中 η_t 为系统的

输入, x_i 为系统的输出, $\varphi(B) = 1 - \varphi_1 B - \cdots - \varphi_p B^p$ 。如果去掉输入 η_i , 只考虑相应的齐次部分

$$\varphi(B)x_i = 0 \quad (9.2.39)$$

并给予不全为零的初值 $(x_{-p}, \cdots, x_{-1})$, 用(9.2.37)式递推, 若有

$$\lim_{i \rightarrow \infty} x_i = 0 \quad (9.2.40)$$

则称系统(9.2.39)是渐近稳定(俗称稳定), 可以证明线性系统 $\varphi(B)x_i = 0$ 稳定的充要条件就是第二章 §3 中所说的系统的参数 $\varphi_1, \cdots, \varphi_p$ 在平稳域内。对于稳定的线性系统, 加上非齐次部分, 即由

$$x_i = \varphi_1 x_{i-1} + \cdots + \varphi_p x_{i-p} + \eta_i \quad (9.2.41)$$

来递推, 经过一段时间后, 输出 x_i 将只依赖于输入, 初值 $(x_{-p}, \cdots, x_{-1})$ 的影响趋于零, 而且只要 η_i 不是发散的, x_i 也不会发散。

对于双线性模型或其它的非线性模型, 我们可以类似地来定义它的稳定性。

设 x_i 和不超过时刻 t 的输出 $x_{i-1}, \cdots, x_{i-p}$ 及输入 $e_i, e_{i-1}, \cdots, e_{i-q}$, 有如下函数表示

$$x_i = f(x_{i-1}, \cdots, x_{i-p}; e_i, \cdots, e_{i-q}) \quad (9.2.42)$$

给 $(x_{i-1}, \cdots, x_{i-p})$ 以任意初值 $(\hat{x}_{i-1}, \cdots, \hat{x}_{i-p})$ 并递推

$$\hat{x}_i = f(\hat{x}_{i-1}, \cdots, \hat{x}_{i-p}; e_i, \cdots, e_{i-q})$$

令 $e_i = x_i - \hat{x}_i$, 即由初值选取所带来的误差, 如果 e_i 在某种概率意义下收敛于零, 比如 e_i 依概率为 1 地收敛于零, 即

$$e_i \xrightarrow{a.s.} 0, t \rightarrow \infty \text{ 时}$$

或 e_i 依概率收敛于零, 即

$$e_i \xrightarrow{p} 0, t \rightarrow \infty \text{ 时}$$

或 e_i 均方收敛于零, 即

$$\lim_{i \rightarrow \infty} E e_i^2 = 0 \quad (9.2.43)$$

则称系统(9.2.42)为稳定的。也就是说输出在上述某种概率意义下逐渐地不依赖于初值的选取, 而只依赖于输入。对于双线性模

型,可以去掉非齐次项,考虑其输出 x_t ,效果也是一样的,下面用一个例子加以说明。

设双线性模型为

$$x_t = \varphi x_{t-1} + \beta a_{t-1} x_{t-1} + a_t \quad (9.2.44)$$

由此可见,

$$\begin{aligned} e_t = x_t - \hat{x}_t &= \varphi(x_{t-1} - \hat{x}_{t-1}) + \beta a_{t-1}(x_{t-1} - \hat{x}_{t-1}) \\ &= \varphi e_{t-1} + \beta a_{t-1} e_{t-1} \end{aligned} \quad (9.2.45)$$

对(9.2.45)式进行迭代,得

$$\begin{aligned} e_t &= (\varphi + \beta a_{t-1})e_{t-1} = (\varphi + \beta a_{t-1})(\varphi + \beta a_{t-2})e_{t-2} \\ &= \cdots = \prod_{j=0}^{t-1} (\varphi + \beta a_{j-1})e_{-1} \end{aligned}$$

$$\begin{aligned} E e_t^2 &= \prod_{j=1}^t E(\varphi + \beta a_{j-1})^2 \cdot E(\varphi + \beta a_{-1})^2 e_{-1}^2 \\ &= (\varphi^2 + \beta^2 \sigma_a^2)^t E(\varphi + \beta a_{-1})^2 e_{-1}^2 \end{aligned}$$

故(9.2.43)满足的条件是

$$\varphi^2 + \lambda^2 < 1 \quad (9.2.46)$$

其中 $\lambda = \beta \sigma_a$, 这就是(9.2.44)式的稳定条件。显然, 去掉非齐次项 a_t 后, 用

$$x_t = \varphi x_{t-1} + \beta a_{t-1} x_{t-1}$$

由(9.2.45)直接来讨论, 结论也是完全一致的。

2. 可逆性: 在第二章曾讨论了 ARMA 模型可逆性的问题, 给出了模型是可逆的充要条件是, 滑动平均部分所相应的方程 $\theta(B)=0$, 它的根全在单位圆外。当一个 ARMA(p, q)模型

$$\varphi(B)x_t = \theta(B)a_t$$

是可逆时, 给 $(a_{-q}, \cdots, a_{-1})$ 以任意初值 $(\hat{a}_{-q}, \cdots, \hat{a}_{-1})$, 用数据 $x_1, x_2, \cdots$ 进行递推来得到 $\hat{a}_t$, 当 t 趋于 ∞ 时, 初值选取的影响趋于零。因此, 当 t 充分大时, $\hat{a}_t$ 可以作为 a_t 的近似值。

对于双线性模型, 我们也可以定义它的可逆性, 就是在双线性方程中, 将输入 a_t 与输出 x_t 互换它们的位置后, 如果新的方程为

稳定的, 则称原来双线性模型是可逆的。因此, 只要模型是可逆的, 那末当 t 充分大时, 我们同样可以得到 a_t 在某种概率意义下的近似值。下面我们仍用一个例子来加以说明。

设双线性模型为

$$x_t = \beta a_{t-1} x_{t-1} + a_t$$

其中 $\{a_t\}$ 是正态白噪声序列。把上述模型表为

$$a_t = x_t - \beta a_{t-1} x_{t-1}$$

任给 a_0 以初值 $\hat{a}_0$, 并将由此递推得到的 a_t 值记为 $\hat{a}_t$ 。令 $\tilde{a}_t = a_t - \hat{a}_t$, 得到

$$\tilde{a}_t = -\beta x_{t-1} \tilde{a}_{t-1} = \cdots = (-1)^t \prod_{i=1}^t (\beta x_{t-i}) \tilde{a}_0$$

令 $G_t = \prod_{j=0}^{t-1} (\beta x_{t-j})^2$, 有 $\tilde{a}_t^2 = G_t \tilde{a}_0^2$, 则 $\tilde{a}_t \xrightarrow[t \rightarrow \infty]{a.s.} 0$ 等价于

$$G_t \xrightarrow[t \rightarrow \infty]{a.s.} 0 \quad (9.2.47)$$

或 $G_t^{\frac{1}{t}} \xrightarrow[t \rightarrow \infty]{a.s.} c$, 其中 $0 < c < 1$, 由于几何平均小于算术平均即

$$G_t^{\frac{1}{t}} \leq \frac{1}{t} \beta^2 \sum_{j=0}^{t-1} x_j^2$$

由强大数定律知, $\frac{1}{t} \sum_{j=1}^t x_j^2 \xrightarrow[t \rightarrow \infty]{a.s.} E x_j^2$, 因此, 由条件 $0 < c < 1$ 知, 在 $\beta^2 E x_j^2 < 1$ 时, 可以保证 (9.2.47) 成立。由于 $\{a_t\}$ 是正态白噪声序列, 故有

$$\beta^2 E x_j^2 = \beta E (\beta a_{j-1} x_{j-1} + a_j)^2 = \beta^4 E a_{j-1}^2 x_{j-1}^2 + \beta^2 E a_j^2$$

又由本章 § 2.2 (9.2.29) 式推导过程知

$$E a_j^2 x_j^2 = E a_j^4 / (1 - \lambda^2) = 3 \sigma_a^4 / (1 - \lambda^2)$$

故有

$$\begin{aligned} \beta^2 E x_j^2 &= \beta^4 3 \sigma_a^4 / (1 - \lambda^2) + \beta^2 \sigma_a^2 = \frac{3 \lambda^4}{1 - \lambda^2} + \lambda^2 \\ &= \frac{\lambda^2 (2 \lambda^2 + 1)}{1 - \lambda^2} \end{aligned}$$

于是 $\beta^2 E x_i^2 < 1$ 等价于 $\left(\lambda^2 - \frac{-1 + \sqrt{3}}{2}\right) \left(\lambda^2 + \frac{1 + \sqrt{3}}{2}\right) < 1$ 和 $|\lambda| < 1$ 同时成立, 从而得到

$$\lambda^2 < \frac{\sqrt{3}-1}{2} \quad (9.2.48)$$

或近似地有 $|\lambda| < 0.605$ 。注意, 这仅是双线性模型 $x_t = \beta a_{t-1} x_{t-1} + a_t$ 可逆性的充分条件。

对于更一般的双线性模型, 分析它的可逆性是很难的或很繁琐的。在实际应用时, 我们可以采取试验法, 即给 a_t 两组不同初值, 然后进行递推, 经过一段时间后, 如果所获得的相应的 a_t 取值几乎相同, 那么模型可以看成是可逆的。

讨论模型可逆性的主要目的是用于预报, 设到时刻 t 为止的 x_j 都已量测到, 当模型是可逆时, 我们可以给 a_t 以任意初值, 例如取 $\hat{a}_0, \hat{a}_{-1}, \dots$ 等为零, 由模型可逆推得到 $\hat{a}_j, j=1, 2, \dots, t$, 当 t 充分大时, 可认为接近于 t 的那些所相应的 $\hat{a}_j$ 就是 a_j , 因此也可认为 $a_t, a_{t-1}, \dots$ 等都是已知量。

我们把到时刻 t 为止全部已知信息记为 $\mathcal{F}_t$, 由第一章知, 条件期望 $E(x|\mathcal{F}_t)$ 为基于这些信息 $\mathcal{F}_t$ 对某一随机变量 x 所做的最佳预报。利用第一章 § 4.3 介绍的条件期望性质, 就可得到双线性模型的预报公式, 下面我们用几个例子来说明。

我们今后称 $E(x_{t+h}|\mathcal{F}_t)$ 为 $\{x_t\}$ 到时刻 t 为止的量测对 x_{t+h} 做的 h 步预报。

例 1 考察如下双线性模型

$$x_t = \beta a_{t-1} x_{t-1} + a_t$$

则

$$\begin{aligned} x_{t+1} &= \beta a_t x_t + a_{t+1} \\ x_{t+2} &= \beta a_{t+1} (\beta a_t x_t + a_{t+1}) + a_{t+2} \\ &= \beta^2 a_{t+1} a_t x_t + \beta a_{t+1}^2 + a_{t+2} \\ x_{t+3} &= \beta^3 a_{t+2} a_{t+1} a_t x_t + \beta^2 a_{t+2} a_{t+1}^2 + \beta a_{t+2}^2 + a_{t+3} \\ &\dots \end{aligned}$$

那么, 我们可以得到各步预报公式为

$$\begin{aligned} E(x_{i+1} | \mathcal{F}_i) &= \beta a_i x_i + E(a_{i+1} | \mathcal{F}_i) = \beta a_i x_i \\ E(x_{i+2} | \mathcal{F}_i) &= \beta^2 x_i E(a_{i+1} a_i | \mathcal{F}_i) + \beta E(a_{i+1}^2 | \mathcal{F}_i) + \\ &\quad + E(a_{i+2} | \mathcal{F}_i) \\ &= \beta^2 a_i x_i E a_{i+1} + \beta E a_{i+1}^2 + E a_{i+2} = \beta \sigma_a^2 \end{aligned}$$

类似地, 对于 $h > 2$, 都有 $E(x_{i+h} | \mathcal{F}_i) = \beta \sigma_a^2$, 而至于 $E(x_{i+1} | \mathcal{F}_i)$ 中 a_i 的计算, 正如前面所讲的, 可以由给 a_0 以初值, 再用 $a_i = x_i - \beta a_{i-1} x_{i-1}$ 递推得到。

例 2 考察如下双线性模型

$$x_i = \beta a_{i-2} x_{i-1} + a_i$$

我们有

$$\begin{aligned} x_{i+1} &= \beta a_{i-1} x_i + a_{i+1} \\ x_{i+2} &= \beta^2 a_i a_{i-1} x_i + \beta a_{i+1} a_i + a_{i+2} \\ x_{i+3} &= \beta^3 a_{i+1} a_i a_{i-1} x_i + \beta^2 a_{i+1}^2 a_i + \beta a_{i+2} a_{i+1} + a_{i+3} \\ x_{i+4} &= \beta^4 a_{i+2} a_{i+1} a_i a_{i-1} x_i + \beta^3 a_{i+2} a_{i+1}^2 a_i + \beta^2 a_{i+2}^2 a_{i+1} + \\ &\quad + \beta a_{i+3} a_{i+2} + a_{i+4} \\ &\dots \end{aligned}$$

那么, 各步预报公式为

$$\begin{aligned} E(x_{i+1} | \mathcal{F}_i) &= \beta a_{i-1} x_i \\ E(x_{i+2} | \mathcal{F}_i) &= \beta^2 a_i a_{i-1} x_i = \beta a_i E(x_{i+1} | \mathcal{F}_i) \\ E(x_{i+3} | \mathcal{F}_i) &= \beta^2 a_i E a_{i+1}^2 = \beta^2 a_i \sigma_a^2 \\ E(x_{i+4} | \mathcal{F}_i) &= \beta^2 E a_{i+2}^2 a_{i+1} = \beta^2 E a_{i+2}^2 E a_{i+1} = 0 \\ &\dots \end{aligned}$$

类似地, 当 $h > 4$ 时

$$E(x_{i+h} | \mathcal{F}_i) = 0.$$

例 3 考察如下双线性模型

$$x_i = \beta a_{i-1} x_{i-2} + a_i$$

我们有

$$\begin{aligned} x_{i+1} &= \beta a_i x_{i-1} + a_{i+1} \\ x_{i+2} &= \beta^2 a_{i+1} a_{i-1} x_{i-2} + \beta a_{i+1} a_i + a_{i+2} \end{aligned}$$

$$x_{i+3} = \beta^2 a_{i+2} a_i x_{i-1} + \beta a_{i+2} a_{i+1} + a_{i+3} \\ \dots\dots\dots$$

那么, 各步预报公式为

$$E(x_{i+1} | \mathcal{F}_i) = \beta a_i x_{i-1} \\ E(x_{i+2} | \mathcal{F}_i) = \beta^2 a_{i-1} x_{i-2} E a_{i+1} + \beta a_i E a_{i+1} + E a_{i+2} = 0 \\ E(x_{i+3} | \mathcal{F}_i) = 0 \\ \dots\dots\dots$$

类似地, 当 $h \geq 3$ 时

$$E(x_{i+h} | \mathcal{F}_i) = 0$$

上述三个模型的一步预报误差都是 a_{i+1} , 它们不依赖于 $x_i, x_{i-1}, \dots$ 的具体值, 而从第二步预报开始有依赖关系。这是和线性模型有很大区别的地方。

§ 2.4 参数估计

设 α 表示双线性模型中所有的参数构成的向量, 并且限制 α 在使模型为稳定和可逆的区域内。对固定的 α , 令 a_i 的初值为零, 比如 $a_0 = 0, a_{-1} = 0, \dots$, 可递推得到 $\hat{a}_1(\alpha), \hat{a}_2(\alpha), \dots$, 则使残差平方和

$$\hat{s}^2(\alpha) = \sum_{i=1}^t \hat{a}_i^2(\alpha)$$

达到最小的 α 记为 $\hat{\alpha}$, 就是我们所要求的参数估计。有时需要去掉最初若干个 $\hat{a}_i$ 带来影响, 因为它们严重地依赖于初值 $a_0, a_{-1}, \dots$ 的选择, 也可从某个 t_0 开始, 即取

$$\hat{s}^2(\alpha) = \sum_{i=t_0}^t \hat{a}_i^2(\alpha).$$

由 § 2.2 的讨论知, 单纯地从自相关函数来看, 双线性模型和 MA 模型是一样的。所以我们也可用比较残差平方和大小的办法去判定样本列 $\{x_n\}$ 应选择哪种模型来拟合。例如双线性对角形模型 $x_i = \beta a_{i-1} x_{i-1} + a_i$, 它的自相关函数和 MA(1) 模型 $y_i = \gamma \eta_{i-1} + \eta_i + m$ 有相同的特点, 其中 $\{\eta_i\}$ 为严格白噪声序列, m 是 y_i 的均

值。有人曾用每组 400 多个数据进行模拟,对每组数据按两种模型的参数进行估计,其 $\{a_i\}, \{\eta_i\}$ 为正态序列,可以看出后者MA(1)模型的残差平方和远远大于前者双线性模型,见表 9.4。因此,如果实际中碰到类似情况,也可以排除模型是 MA(1)的可能。

表 9.4 双线性对角型模型和 MA(1)模型的模拟

组 号	$\hat{\beta}$	$\hat{s}^2(\hat{\beta})/N$	$\hat{r}$	$\hat{m}$	$\hat{\sigma}^2(\hat{r}, \hat{m})/N$
1	0.600	1.115	0.14	0.700	2.63
2	0.601	0.976	0.14	0.559	2.08
3	0.600	1.022	0.12	0.623	2.73
4	0.599	0.965	0.16	0.659	2.51
5	0.600	1.087	-0.08	0.841	2.59
6	0.600	1.109	0.03	0.599	2.36
7	0.599	0.924	0.16	0.566	1.84
8	0.599	0.975	0.20	0.640	2.00
9	0.603	0.920	-0.01	0.549	2.06
10	0.598	0.955	0.19	0.630	2.15
真 值	0.600	1(即 σ_a^2)	0.159	0.600	2.27(即 σ_η^2)

原则上,双线性模型的参数估计和定阶都可沿用线性模型中的常用方法,如极大似然估计,最小二乘估计及模型定阶的AIC准则等。这里不再详述。

§ 3 门限自回归模型

门限自回归模型(Threshold Autoregressive Model),是1978年由汤家豪首先提出来的^[34]。近几年来,这一模型的研究不断深入和日益完善,并且在应用上也颇有成效。

门限自回归的基本思想,是利用门限值把非线性模型按状态

空间取值, 并采用逐段线性化手段来处理非线性系统, 同时将极限环的概念引入到非线性随机系统。由于门限的控制作用, 保证了系统的稳定性并有效地描述具有周期规律的系统, 且反映类似于跳跃共振的突变现象。

§ 3.1 门限自回归模型的定义

设 $\{x_n\}$ 是 k 维时间序列, 对于每一整数 n , 令 J_n 是可观测随机变量, 它取正整数 $1, 2, \dots, l$ 。

定义 1 $\{x_n, J_n\}$ 称为一般门限自回归模型, 如果满足如下模型

$$x_n = B^{(J_n)} x_{n-1} + A^{(J_n)} x_{n-1} + e_n^{(J_n)} + c^{(J_n)} \quad (9.3.1)$$

其中 $J_n = j$ 时, $A^{(j)}$ 和 $B^{(j)}$ 为 $k \times k$ 非随机系数矩阵, $c^{(j)}$ 是 $k \times 1$ 常数向量, $\{e_n^{(j)}\}$ 是 k 维白噪序列, 当 $j \neq j'$ 时, $\{e_n^{(j)}\}$ 与 $\{e_n^{(j')}\}$ 为相互独立, 即对任意 n, m , $e_n^{(j)}$ 与 $e_m^{(j')}$ 是两个相互独立的 k 维随机向量。并且对正整数 k 有 $E e_n^{(j)} x_{n-k}^T = 0$ 。

上述(9.3.1)是门限自回归模型的一个最一般的定义, 下面将给出经常采用的三个特殊表示形式。

设 $\{r_0, r_1, \dots, r_l\}$ 表示实数的有序子集, 即 $r_0 < r_1 < \dots < r_l$, $r_0 = -\infty$, $r_l = +\infty$, 由此 $\{r_0, r_1, \dots, r_l\}$ 确定了实轴 R 上的一个分割。

$$R = R_1 \cup R_2 \cup \dots \cup R_l$$

其中

$$R_j = (r_{j-1}, r_j), \quad j = 1, 2, \dots, l-1, \quad R_l = (r_{l-1}, +\infty)。$$

(9.3.1)式有如下三种常用的模型形式

1. 令 $x_n \triangleq (x_n, x_{n-1}, \dots, x_{n-k+1})^T$

$$A^{(j)} = \left(\begin{array}{c|c} a_1^{(j)} & a_2^{(j)} \cdots a_{k-1}^{(j)} \\ \hline I_{k-1} & 0 \end{array} \right)$$

$$B^{(j)} = 0, \quad e_n^{(j)} = (e_n^{(j)}, 0, \dots, 0)^T$$

$$c^{(j)} = (a_0^{(j)}, 0, \dots, 0)^T, \quad R_j^{(k)} = \underbrace{R \times \dots \times R}_k \times R_j \times R \times \dots \times R$$

$R_j^{(k)}$ 表示 k 维乘积空间上的柱集, 底 R_j 是在第 d 个坐标轴上的

区间, d 是某一固定正整数, $1 \leq d \leq k$ 。

若 $x_{n-1} \in R_j^{(k)}$, 取 $J_n = j$, 则(9.3.1)简化为如下模型

$$x_n = a_0^{(j)} + \sum_{i=1}^k a_i^{(j)} x_{n-i} + \varepsilon_n^{(j)}, \quad x_{n-d} \in R_j, \\ j = 1, 2, \dots, l \quad (9.3.2)$$

由于(9.3.2)中 l 个自回归模型的选择取决于 x_{n-d} 属于哪一个区间 R_j , 称满足(9.3.2)的时间序列 $\{x_n\}$ 是阶为 $(d, l; k, \dots, k)$ 的自激励门限自回归模型, 简记为 SETAR $(d, l; k, \dots, k)$, 其中 k 共有 l 重。若对 $j = 1, 2, \dots, l$, $i = k_j + 1, k_j + 2, \dots, k$ 有 $a_i^{(j)} = 0$ 这样 $\{x_n\}$ 用 SETAR $(d, l; k_1, \dots, k_l)$ 表示, $\{\tau_1, \tau_2, \dots, \tau_{l-1}\}$ 称为门限。特别在(9.3.2)式, 当 $l = 1$ 时, SETAR $(d, 1; k)$ 即为 k 阶自回归模型 AR (k) 。若一个系统可由(9.3.2)模型来拟合, 称该系统为自激励门限自回归系统。

2. 设 $\{x_n\}$ 为可观测输出, $\{y_n\}$ 为可观测输入, $\{\varepsilon_n^{(j)}\}$ 与 $\{y_n\}$ 相互独立, 记

$$x_n \triangleq (x_n, x_{n-1}, \dots, x_{n-m+1}, y_n, y_{n-1}, \dots, y_{n-m'+1})^T$$

$$A^{(j)} = \left(\begin{array}{ccc|c|ccc} a_1^{(j)} & a_2^{(j)} & \dots & a_{m-1}^{(j)} & a_m^{(j)} & b_1^{(j)} & b_2^{(j)} & \dots & b_{m'}^{(j)} \\ \hline & & & & 0 & & & & \\ I_{m-1} & & & & 0 & & & & 0 \\ \hline & & & & & & & & \\ 0 & & & & & & & & 0 \end{array} \right)$$

$$B^{(j)} = \left(\begin{array}{ccc|c|ccc} 0 & 0 & \dots & 0 & 0 & b_0^{(j)} & 0 & \dots & 0 \\ \hline & & & 0 & 0 & & 0 & & \\ 0 & & & & & & & & \\ \hline & & & & & & & & \\ 0 & & & & & & & & I_{m'} \end{array} \right)$$

其中 $A^{(j)}$, $B^{(j)}$ 分别为 $(m + m') \times (m + m')$ 矩阵, I_{m-1} 是 $m-1$ 阶单位阵。又记

$$e_n^{(j)} = (\varepsilon_n^{(j)}, 0, \dots, 0)^T \quad c^{(j)} = (a_0^{(j)}, 0, \dots, 0)^T$$

$$R_j^{(m+m')} = R \times \dots \times R \times R_j \times R \times \dots \times R$$

其中 $R_j^{(m+m')}$ 是底 R , 在第 $m+d$ 个坐标轴上的区间, d 是 $\{1,$

$2, \dots, m'$ 中某个正整数。

若 $x_{n-1} \in R^{(m+m')}$, 取 $J_n = j$, 将上述诸式代入(9.3.1)式得到如下模型

$$x_n = a_0^{(j)} + \sum_{i=1}^m a_i^{(j)} x_{n-i} + \sum_{i=0}^{m'} b_i^{(j)} y_{n-i} + e_n^{(j)}, \quad y_{n-d} \in R, \\ j = 1, 2, \dots, l \quad (9.3.3)$$

称(9.3.3)模型是阶为 $(d, l; (m, m'), \dots, (m, m'))$ 的 $\{x_n, y_n\}$ 开环门限自回归模型(Open-loop threshold autoregressive model), 简记为 TARSO $(d, l; (m, m'), \dots, (m, m'))$, 其中 (m, m') 共有 l 重。如果 $a_i^{(j)} = 0, j = 1, 2, \dots, l, i = m_j + 1, m_j + 2, \dots, m$ 和 $b_i^{(j)} = 0, j = 1, 2, \dots, l, i = m'_j + 1, m'_j + 2, \dots, m'$ 则(9.3.3)可表为如下模型

$$x_n = a_0^{(j)} + \sum_{i=0}^{m_j} a_i^{(j)} x_{n-i} + \sum_{i=0}^{m'_j} b_i^{(j)} y_{n-i} + e_n^{(j)}, \quad y_{n-d} \in R, \\ j = 1, 2, \dots, l \quad (9.3.4)$$

称 $\{x_n\}$ 为以 $\{y_n\}$ 为输入的 TARSO $(d, l; (m_1, m'_1), \dots, (m_l, m'_l))$ 模型。

3. 如果 $\{x_n\}$ 是以 $\{y_n\}$ 为输入的 TARSO $(d, l; (m_1, m'_1), \dots, (m_l, m'_l))$, $\{y_n\}$ 是以 $\{x_n\}$ 为输入的 TARSO $(d', l'; (s_1, s'_1), \dots, (s_{l'}, s'_{l'}))$, 并且假定所有白噪声序列为相互独立, 则称 $\{x_n, y_n\}$ 为闭环门限自回归模型(closed-loop threshold autoregressive model), 简记为 TARSC $(d, l; d', l'; (m_1, m'_1), \dots, (m_l, m'_l); (s_1, s'_1), \dots, (s_{l'}, s'_{l'}))$ 。TARSO 和 TARSC 的框图分别表示如下:




图 9.8 TARSO 模型框图




图 9.9 TARSC 模型框图

§ 3.2 门限自回归模型的特性

§ 3.1 TAR 模型是具有较广泛特性的非线性模型。事实上，我们考察一阶非线性自回归模型

$$x_n = f(x_{n-1}) + \varepsilon_n \quad (9.3.5)$$

其中 $f(\cdot)$ 是 $[a, b]$ 上的连续函数，则 $f(\cdot)$ 在 $[a, b]$ 上是一致连续函数。众所周知， $f(\cdot)$ 可由 $\tilde{f}(\cdot)$ 任意逼近，其中

$$\begin{aligned} \tilde{f}(x) &= \tilde{f}(x_{j-1}) + \alpha_j(x - x_{j-1}) \\ &= g(x_{j-1}) + \alpha_j x \quad x_{j-1} \leq x < x_j \\ j &= 1, 2, \dots, l \end{aligned}$$

其中 $a = x_0 < x_1 < \dots < x_l = b$ 。这里我们得到了关于在 $[a, b]$ 上的一种分割，它是由逼近的精确程度决定的。在给定的逼近精度下，对一阶非线性自回归模型，可以由如下 SETAR(1, l, 1, $\dots$, 1) 近似

$$\begin{aligned} x_n &= g(x_{j-1}) + \alpha_j x_{n-1} + \varepsilon_n, \quad x_{j-1} \leq x_{n-1} < x_j \\ j &= 1, 2, \dots, l \end{aligned} \quad (9.3.6)$$

其门限值为 $(x_1, x_2, \dots, x_{l-1})$ 。

对于一般的 k 阶非线性自回归模型

$$x_n = f(x_{n-1}, \dots, x_{n-k}) + \varepsilon_n \quad (9.3.7)$$

可表为向量形式

$$x_n = f(x_{n-1}) + \varepsilon_n$$

其中 $x_n = (x_n, x_{n-1}, \dots, x_{n-k+1})^T$

$$\varepsilon_n = (\varepsilon_n, 0, \dots, 0)^T$$

$$f(x_{n-1}) = (f(x_{n-1}, \dots, x_{n-k}), x_{n-1}, \dots, x_{n-k+1})^T$$

同理可由如下形式的模型逼近

$$x_n = g(x_{n-1}) + A^{(j)} x_{n-1} + \varepsilon_n, \quad x_{n-1} \in R^k$$

其中 $R^k = \bigcup_{j=1}^l R_j^k$, R^k 为 k 维欧氏空间, R_j^k 是 k 维矩形, 以 g_1

记 g 的第一分量, 则有

$$x_n = g_1(x_{n-1}) + \sum_{i=1}^k \alpha_{1i}^{(j)} x_{n-i} + \varepsilon_n, \quad (x_{n-1}, \dots, x_{n-k}) \in R_j^k$$

$$j = 1, 2, \dots, l \quad (9.3.8)$$

即 $\{x_n\}$ 为 SETAR($l; k, \dots, k$)。

为了讨论 TAR 模型的特性, 我们需要介绍差分方程的极限环的概念。

令 x_n 表示一个 k 维(状态)向量, 它满足

$$x_n = f(x_{n-1}) \quad (9.3.9)$$

对于(9.3.9)这样的非随机系统, 我们介绍极限点和极限环的定义。

定义 1 一个 k 维向量 x^* 称为系统(9.3.9)的极限点, 如果存在一个 $x_0 (x_0 \neq x^*)$, 使得从 x_0 开始, 由 $x_n = f(x_{n-1})$ 生成 $\{x_n\}$, 有

$$\lim_{n \rightarrow \infty} x_n = x^*, \quad \text{即} \quad \lim_{n \rightarrow \infty} \|x_n - x^*\| = 0$$

其中 $\|\cdot\|$ 表示 k 维欧氏空间的范数。

设 $\mathcal{C} = \{c_i; i = 1, 2, \dots, T; c_i \text{ 是 } k \text{ 维向量}, \|c_i\| < \infty, T \text{ 为正整数}\}$ 。

定义 2 $\mathcal{C}$ 称周期为 T 的极限环, 如果满足以下三个条件

i) 存在 $x_0 \in \overline{\mathcal{C}}$, 以 x_0 作为初值, 由 $x_n = f(x_{n-1})$ 生成 $\{x_n\}$, 则必有 N , 对 $n \geq N$ 时, $x_n \in \mathcal{C}$, 即 x_n 终将进入 $\mathcal{C}$ 。

ii) $c_i = f(c_{i-1}) \quad i = 2, 3, \dots, T$

$$c_{T+i} = c_i \quad i = 1, 2, \dots, T$$

iii) T 是满足条件 i) 和 ii) 的最小正整数。

例, 设

$$x_n = \begin{cases} \frac{1}{2} x_{n-1}, & \text{当 } |x_{n-1}| \leq \frac{1}{2} \\ x_{n-1}, & \text{当 } |x_{n-1}| > \frac{1}{2} \end{cases} \quad (9.3.10)$$

取 $x_0 = 4$, 由系统 (9.3.10) 知 $x_1 = 2$, $x_2 = 1$, $x_3 = \frac{1}{2}$, $x_4 = 2$, $x_5 = 1$, $x_6 = \frac{1}{2} \cdots$, 故 $\{x_n, n \geq 0\}$ 的变化规律为 $\left\{4, 2, 1, \frac{1}{2}, 2, 1, \frac{1}{2}, \cdots\right\}$ 。所以存在着周期为 3 的极限环 $\mathcal{C} = \left\{2, 1, \frac{1}{2}\right\}$ 。若取 $x_0 = 5$, 由系统 (9.3.10) 知 $x_1 = \frac{5}{2}$, $x_2 = \frac{5}{4}$, $x_3 = \frac{5}{8}$, $x_4 = \frac{5}{16}$, $x_5 = \frac{5}{4}$, $x_6 = \frac{5}{8}$, $x_7 = \frac{5}{16}$, $\cdots$ 故 $\{x_n, n \geq 0\}$ 的变化规律为 $\left\{5, \frac{5}{2}, \frac{5}{4}, \frac{5}{8}, \frac{5}{16}, \frac{5}{4}, \frac{5}{8}, \frac{5}{16}, \cdots\right\}$, 所以又存在着周期为 3 的又一个极限环 $\mathcal{C} = \left\{\frac{5}{4}, \frac{5}{8}, \frac{5}{16}\right\}$ 。

有了非随机系统的极限环的概念后, 可以对于有随机输入和确定性输入的随机系统引入极限环的概念。

设一个随机系统

$$x_n = f(x_{n-1}, e_n^{(1)}, e_{n-1}^{(1)}, \cdots, e_{n-p_1}^{(1)}, u_n^{(1)}, u_{n-1}^{(1)}, \cdots, u_{n-p_q}^{(q)}, i = 1, 2, \cdots, q) \quad (9.3.11)$$

其中 $\{x_n\}$ 是可观测量 k 维时间序列, 对于 $i = 1, 2, \cdots, q$, $\{e_n^{(i)}\}$ 是不可观测的一维时间序列, $\{u_n^{(i)}\}$ 是一维确定性序列, 它也可看作控制量。

定义 3 称 $\{x_n\}$ 存在着极限环, 如果

$$x_n = f(x_{n-1}, \hat{e}_n^{(1)}, \hat{e}_{n-1}^{(1)}, \cdots, \hat{e}_{n-p_1}^{(1)}, \mathbf{0}^{(1)}, i = 1, 2, \cdots, q) \quad (9.3.12)$$

所导致的关于 x_n 的递推关系为

$$\mathbf{x}_n = \mathbf{g}(\mathbf{x}_{n-1}) \quad (9.3.13)$$

按定义 2 的意义下存在着一个极限环, 其中

$$\hat{\varepsilon}_m^{(i)} = E(\varepsilon_m^{(i)} | \mathbf{x}_{n-1}, \mathbf{x}_{n-2}, \dots)$$

$$m = n, n-1, \dots, n-p_i, \quad i = 1, 2, \dots, q$$

$\mathbf{0}^{(i)}$ 是 $p_i' + 1$ 维的零向量表示 $(u_n^{(i)}, \dots, u_{n-p_i'}^{(i)})$ 取 $(0, \dots, 0)$, $i = 1, 2, \dots, q$.

注: 如果对每一个 $i = 1, 2, \dots, q$, $\varepsilon_m^{(i)}$ 为零均值随机变量, 且与 $\mathbf{x}_{n-1}, \mathbf{x}_{n-2}, \dots$ 独立, 则有 $\hat{\varepsilon}_m^{(i)} = 0$, (9.3.12) 为

$$\mathbf{x}_n = \mathbf{f}(\mathbf{x}_{n-1}, \mathbf{0})$$

其中 $\mathbf{0}$ 是 k 维零向量, $k = \sum_{i=1}^q (p_i + p_i' + 2)$.

我们用一个简单的 TAR 模型来叙述门限自回归模型与稳定循环和极限环的关系。

考虑一个稳定 SETAR($d, 3; k, k, k$) 模型

$$\mathbf{x}_n = \sum_{j=1}^d \mathbf{a}_j^{(i)} \mathbf{x}_{n-j} + \varepsilon_n^{(i)}, \text{ 当 } \mathbf{x}_{n-d} \in R_i$$

$$i = 1, 2, 3 \quad (9.3.14)$$

其中 $R_1 = (-\infty, r_1]$, $R_2 = (r_1, r_2]$, $R_3 = (r_2, +\infty)$, 且 $-\infty < r_1 < 0 < r_2 < +\infty$, 此时 $\mathbf{x}_n = \mathbf{g}(\mathbf{x}_{n-1})$ 可取为如下特殊形式

$$\mathbf{x}_n = \mathbf{A}^{(i)} \mathbf{x}_{n-1}, \text{ 当 } \mathbf{x}_{n-1} \in R_i^{(k)}, i = 1, 2, 3$$

令 $\lambda(A)$ 表示矩阵 A 的特征值的最大模, 假定

$$\lambda(A^{(1)}) < 1, \lambda(A^{(2)}) > 1, \lambda(A^{(3)}) < 1$$

因此, 对于定常系统

$$\mathbf{x} = \mathbf{A}^{(i)} \mathbf{x} \quad \text{当 } \mathbf{x} \in R_i^{(k)}, i = 1, 2, 3$$

只有当 $\lambda(A^{(i)}) < 1$ 时, 可能有平稳解 $\mathbf{x} = 0$ 。由门限值 r_1, r_2 的条件知 $\mathbf{0} \in R_2^{(k)}$, 然而, $\lambda(A^{(2)}) > 1$, 故解不可能稳定递推。另一方面, 尽管当 $\mathbf{x} \in R_2^{(k)}$, 递推是发散的, 但一旦 $\mathbf{x}$ 落入 $R_1^{(k)}$ 或 $R_3^{(k)}$, 由于 $\lambda(A^{(1)}) < 1, \lambda(A^{(3)}) < 1$, 在递推时, $\mathbf{x}$ 趋向于 $\mathbf{0}$, 这样就构成了一个周期性的稳定循环, 因而形成了极限环。

§ 3.3 门限自回归的建模

1. 由第三章可知, 对于稳定线性系统, 当给定动态数据 $\{x_n, 1 \leq n \leq N\}$ 后, 可遵循一定的程序建立与辨识 ARMA (p, q) 模型, 对于非线性系统, 不可能找到一种建模的一般方法, 只可能在一些特定的限制条件下建立某种类型的非线性模型。门限自回归模型可用以描述含有较复杂周期规律的循环动态数据。它虽是一种非线性模型, 但又是基于对非线性系统依状态取值逐段线性处理。因此, 门限自回归的建模可借助于线性自回归建模的参数估计与定阶准则, 不存在本质上的困难。这是门限自回归模型相比其它一些非线性模型的一大优点。

本小节用 SETAR $(d, l; k_1, k_2, \dots, k_l)$ 模型去拟合动态数据 $\{x_n, 1 \leq n \leq N\}$, 即给出从动态数据 $\{x_n, 1 \leq n \leq N\}$ 出发去辨识 SETAR $(d, l; k_1, k_2, \dots, k_l)$ 模型的具体步骤。

i) 令 d 和 L 固定, L 表示逐段自回归的最大允许阶数, L 的大小通常人为地选定, 应与动态数据的长度 N 有关, L 的取值还应该由门限值 τ_i 的不同而异, 不过为了方便起见, 这里都是选取相同的 L 。

记 $n_0 \triangleq \max(d, L)$ 。设 $\{x_n, 1 \leq n \leq N\}$ 为给定的动态数据, $t_1, t_2, \dots, t_{l-1}$ 为实轴 $R = (-\infty, +\infty)$ 上一组分点, 且 $-\infty < t_1 < t_2 < \dots < t_{l-1} < +\infty$ 。对 $t_1, t_2, \dots, t_{l-1}$ 在 R 中的每一种选择, 动态数据都将分为 l 类, 它们分别属于 $R_1, R_2, \dots, R_l$, 其中 $R_j = (t_{j-1}, t_j]$, $j = 1, 2, \dots, l-1$, $R_1 = (-\infty, t_1]$, $R_l = (t_{l-1}, +\infty)$ 。

设动态数据中有 $x_{n_0-d+i_{11}}, x_{n_0-d+i_{12}}, \dots, x_{n_0-d+i_{1N_1}}$ 是小于等于 t_1 ; $x_{n_0-d+i_{21}}, x_{n_0-d+i_{22}}, \dots, x_{n_0-d+i_{2N_2}}$ 小于等于 t_2 而大于 t_1 ; $\dots$; $x_{n_0-d+i_{l1}}, x_{n_0-d+i_{l2}}, \dots, x_{n_0-d+i_{lN_l}}$ 大于 t_{l-1} , 其中 $\sum_{j=1}^l i_{jN_j} = N$

则 l 个分段线性自回归模型分别为

$$\begin{pmatrix} x_{n_0+i_{11}} \\ x_{n_0+i_{12}} \\ \vdots \\ x_{n_0+i_{1N_1}} \end{pmatrix} = \begin{pmatrix} 1 & x_{n_0+i_{11}-1} & \cdots & x_{n_0+i_{11}-k_1} \\ 1 & x_{n_0+i_{12}-1} & \cdots & x_{n_0+i_{12}-k_1} \\ & & \cdots & \\ 1 & x_{n_0+i_{1N_1}-1} & \cdots & x_{n_0+i_{1N_1}-k_1} \end{pmatrix} \begin{pmatrix} a_0^{(1)} \\ a_1^{(1)} \\ \vdots \\ a_{k_1}^{(1)} \end{pmatrix} + \begin{pmatrix} \varepsilon_{n_0+i_{11}}^{(1)} \\ \varepsilon_{n_0+i_{12}}^{(1)} \\ \vdots \\ \varepsilon_{n_0+i_{1N_1}}^{(1)} \end{pmatrix} \\
\cdots \cdots \cdots \\
\begin{pmatrix} x_{n_0+i_{l1}} \\ x_{n_0+i_{l2}} \\ \vdots \\ x_{n_0+i_{lN_l}} \end{pmatrix} = \begin{pmatrix} 1 & x_{n_0+i_{l1}-1} & \cdots & x_{n_0+i_{l1}-k_l} \\ 1 & x_{n_0+i_{l2}-1} & \cdots & x_{n_0+i_{l2}-k_l} \\ & & \cdots & \\ 1 & x_{n_0+i_{lN_l}-1} & \cdots & x_{n_0+i_{lN_l}-k_l} \end{pmatrix} \begin{pmatrix} a_0^{(l)} \\ a_1^{(l)} \\ \vdots \\ a_{k_l}^{(l)} \end{pmatrix} + \begin{pmatrix} \varepsilon_{n_0+i_{l1}}^{(l)} \\ \varepsilon_{n_0+i_{l2}}^{(l)} \\ \vdots \\ \varepsilon_{n_0+i_{lN_l}}^{(l)} \end{pmatrix}$$

它们分别可表示为

$$\begin{aligned}
x_j &= A_j a^{(j)} + \varepsilon^{(j)} \\
j &= 1, 2, \cdots, l
\end{aligned} \quad (9.3.15)$$

其中

$$\begin{aligned}
x_j &= \begin{pmatrix} x_{n_0+i_{j1}} \\ x_{n_0+i_{j2}} \\ \vdots \\ x_{n_0+i_{jN_j}} \end{pmatrix}, \quad A_j = \begin{pmatrix} 1 & x_{n_0+i_{j1}-1} & \cdots & x_{n_0+i_{j1}-k_j} \\ 1 & x_{n_0+i_{j2}-1} & \cdots & x_{n_0+i_{j2}-k_j} \\ & & \cdots & \\ 1 & x_{n_0+i_{jN_j}-1} & \cdots & x_{n_0+i_{jN_j}-k_j} \end{pmatrix} \\
a^{(j)} &= (a_0^{(j)}, a_1^{(j)}, \cdots, a_{k_j}^{(j)})^T \\
\varepsilon^{(j)} &= (\varepsilon_{n_0+i_{j1}}^{(j)}, \varepsilon_{n_0+i_{j2}}^{(j)}, \cdots, \varepsilon_{n_0+i_{jN_j}}^{(j)})^T
\end{aligned}$$

分别限定阶数为 $k_j (j=1, 2, \cdots, l)$, 用最小二乘法可估计出参数 $a^{(j)} (j=1, 2, \cdots, l)$ 。

ii) 对于固定的 d, L 和 $t_1, t_2, \cdots, t_{l-1}$, 用 AIC 准则来确定这 l 个分段线性自回归模型的阶数 $\hat{k}_1, \hat{k}_2, \cdots, \hat{k}_l$ 。即使

$$\begin{aligned}
\text{AIC}(k_j) &= N_j \ln \frac{\text{Rss}_j(k_j)}{N_j} + 2(k_j - 1) \\
j &= 1, 2, \cdots, l
\end{aligned} \quad (9.3.16)$$

达到最小的一组 $k_1, k_2, \cdots, k_l$ 记为 $\hat{k}_1, \hat{k}_2, \cdots, \hat{k}_l$ 。其中 $\text{Rss}_j(k_j)$ 表示第 j 个模型的残差平方和 $\|x_j - A_j a^{(j)}\|^2$, $\|\cdot\|$ 表示模, N_j

表 x_i 的维数。

iii) 由于 $\{e_n^{(j)}\} j=1, 2, \dots, l$ 是 l 个相互独立白噪声序列, 因此, 对固定 d, L 和 $t_1, t_2, \dots, t_{l-1}$ 定义

$$AIC(d, l; t_1, t_2, \dots, t_{l-1}) = \sum_{j=1}^l AIC(\hat{k}_j) \quad (9.3.17)$$

从而可由下式

$$AIC(d, l; \hat{\tau}_1, \hat{\tau}_2, \dots, \hat{\tau}_{l-1}) = \min_{-\infty < t_1 < t_2 < \dots < t_{l-1} < +\infty} AIC(d, l; t_1, t_2, \dots, t_{l-1}) \quad (9.3.18)$$

得到门限值 $\tau_1, \tau_2, \dots, \tau_{l-1}$ 的估计 $\hat{\tau}_1, \hat{\tau}_2, \dots, \hat{\tau}_{l-1}$, 至此, 对于固定的 d, L 和 l , 选出了 $SETAR(d, l; \hat{k}_1, \hat{k}_2, \dots, \hat{k}_l)$ 的模型。

iv) 我们可以根据下式来选择 l

$$AIC(d, \hat{l}; \hat{\tau}_1, \hat{\tau}_2, \dots, \hat{\tau}_{\hat{l}-1}) = \min_{2 \leq l} AIC(d, l; \hat{\tau}_1, \hat{\tau}_2, \dots, \hat{\tau}_{l-1}) \quad (9.3.19)$$

$\hat{l}$ 作为 l 的估计。然而实际上 l 不宜太大, 因为对于有限 N 个动态数据, 用过多模型去描述一般无大的必要, 一般处理实际问题时, 只要取 $l=2, 3$ 也就够了。

v) 从上述可知, 动态数据的实际有效个数不是 N , 而是 $N - n_0$, 其中 $n_0 = \max(d, L)$, 因此, $AIC(d)$ 应取 $AIC(d, \hat{l}; \hat{\tau}_1, \hat{\tau}_2, \dots, \hat{\tau}_{\hat{l}-1})$ 的规范化, 即

$$AIC(d) = \frac{AIC(d, \hat{l}; \hat{\tau}_1, \hat{\tau}_2, \dots, \hat{\tau}_{\hat{l}-1})}{N - n_0} \quad (9.3.20)$$

对于不同的 d , 比较 (9.3.20) 式中 AIC 值, 其最小值相应的 $\hat{d}$ 作为 d 的估计。

通过上述五个辨识步骤, 从动态数据 $\{x_n, 1 \leq n \leq N\}$ 出发最终可获得满意的模型

$SETAR(\hat{d}, \hat{l}; \hat{k}_1, \hat{k}_2, \dots, \hat{k}_{\hat{l}-1})$, 相应的门限估计为 $\hat{\tau}_1, \hat{\tau}_2, \dots, \hat{\tau}_{\hat{l}-1}$, 自回归系数的估计为 $\hat{a}_0^{(1)}, \dots, \hat{a}_{\hat{k}_1}^{(1)}, \dots, \hat{a}_0^{(l)}, \dots, \hat{a}_{\hat{k}_l}^{(l)}$, 各个模型的白噪声方差为

$$\text{var}(e_n^{(j)}) = R_{ss_j}(\hat{k}_j) / N, \quad j=1, 2, \dots, \hat{l}$$

还可算出相应的参数估计的置信区间。

2. 对于输入和输出可观测到的系统, 可用以下二种方法建模:

i) 设 $\{x_n, 1 \leq n \leq N\}$ 为系统的可观测输出的动态数据, $\{y_n, 1 \leq n \leq N\}$ 为系统的可观测输入的动态数据, 按上述 1. 的方法可建立如下的 TARSO($d, l; (k_1, k'_1) \cdots, (k_l, k'_l)$) 模型

$$x_n = a_0^{(j)} + \sum_{i=1}^{k_j} a_i^{(j)} x_{n-i} + \sum_{i=1}^{k'_j} b_i^{(j)} y_{n-i} + e_n^{(j)}, \quad \text{当 } y_{n-d} \in R_j^y$$

$$j = 1, 2, \cdots, l \quad (9.3.21)$$

ii) 设 $\{x_n, 1 \leq n \leq N\}, \{y_n, 1 \leq n \leq N\}$ 如同 i), 那么令

$$\mathbf{z}_n = \begin{pmatrix} x_n \\ y_n \end{pmatrix}$$

得到二维动态数据 $\{\mathbf{z}_n, 1 \leq n \leq N\}$, 按上述 1. 的步骤可以建立 TAR 模型

$$\mathbf{z}_n = \mathbf{c}_0^{(j)} + \sum_{i=1}^{k_j} c_i^{(j)} \mathbf{z}_{n-i} + \mathbf{e}_n^{(j)} \quad \text{当 } \mathbf{z}_{n-d} \in R_j$$

$$j = 1, 2, \cdots, l$$

其中 $c_i^{(j)}$ 为 2×2 矩阵, R_j 为二维矩形区域, $\mathbf{c}_0^{(j)}, \mathbf{e}_n^{(j)}$ 为二维向量, 则第一分量可表为

$$x_n = a_0^{(j)} + \sum_{i=1}^{k_j} a_i^{(j)} x_{n-i} + \sum_{i=1}^{k'_j} b_i^{(j)} y_{n-i} + e_n^{(j)} \quad \text{当 } y_{n-d} \in R_j^y$$

$$j = 1, 2, \cdots, l \quad (9.3.22)$$

其中 $a_0^{(j)}, a_i^{(j)}, b_i^{(j)}, e_n^{(j)}$ 为如下元素

$$\mathbf{c}_0^{(j)} = \begin{pmatrix} a_0^{(j)} \\ b_0^{(j)} \end{pmatrix}, \quad c_i^{(j)} = \begin{pmatrix} a_i^{(j)} & b_i^{(j)} \\ d_i^{(j)} & h_i^{(j)} \end{pmatrix}$$

$$\mathbf{e}_n^{(j)} = \begin{pmatrix} e_n^{(j)} \\ \eta_n^{(j)} \end{pmatrix}$$

R_j^y 是 R_j 在 y 轴上投影。上述 (9.3.22) 模型就是 $\{x_n, y_n\}$ 所满足

的 TARSO($d, l; (k_1 k_1), \dots, (k_l k_l)$) 模型。同理有

$$y_n = b_0^{(j)} + \sum_{i=1}^{k_j} d_i^{(j)} x_{n-i} + \sum_{i=1}^{k_j} h_i^{(j)} y_{n-i} + \eta_n^{(j)} \quad \text{当 } x_{n-d} \in R_j^*$$

$$j = 1, 2, \dots, l \quad (9.3.23)$$

其中 R_j^* 是 R_j 在 x 轴上投影。(9.3.22) 和 (9.3.23) 两个模型合并在一起, 得到 $\{x_n, y_n\}$ 的闭环门限自回归模型即 TARSC 模型。

以上叙述了门限自回归建模的一般方法。在实际问题中用动态数据去建立 TAR 模型时, 一般取 $l=2$ 或 3 , 且设动态数据最大值为 $x_{\max}$, 最小值为 $x_{\min}$, 两者之差记为 $\Delta \triangleq x_{\max} - x_{\min}$, 门限 r_1 或 r_2 的预选值可取为 $x_{\min}$ 加上 Δ 的 30% , 40% , 50% , 60% , 70% , 由 AIC 准则确定出 $\hat{r}_1$ 或 $\hat{r}_1, \hat{r}_2$ 。如果精度不够, 再在上述粗分的最优值附近细分, 再用同样手续选择最优值作为 $\hat{r}_1$ 或 $\hat{r}_1, \hat{r}_2$ 。当然预选门限值也可用某种最优化方法去求得, 例如对一个门限的情形, 可采用 0.618 方法。

由于门限自回归模型描述的对象是非线性的, 因此, 对动态数据选用门限自回归模型来描述之前, 也需要按本章 §1 中所要求的, 进行适当的检验。此外, 对于用原数据建模效果不佳时, 可经过适当数据变换后再行建模, 这里介绍一种常用的 Box-Cox 变换。

设原动态数据 $x_n > 0, 1 \leq n \leq N$, (对有负数的动态数据, 可先平移为正的数据, 再用 Box-Cox 变换)。

令

$$z_n(\lambda) = \begin{cases} \frac{x_n^\lambda - 1}{\lambda} & \lambda \neq 0 \\ \log x_n & \lambda = 0 \end{cases} \quad (9.3.24)$$

其中 $\lambda \leq 1$, 称 λ 为 Box-Cox 参数。取 $\lambda = 0, 0.1, 0.2, \dots, 1$, 分别计算出新的序列 $\{z_n(\lambda)\}$, 并对它建模, 得到相应的 $AIC^{(\lambda)}$ 值, 令

$$AIC_{(\lambda)} = AIC^{(\lambda)} - 2 \log |J(\lambda)| \quad (9.3.25)$$

其中 $J(\lambda) = \prod_{i=1}^N x_i^{\lambda-1}$ 。最后取满足下式的 $\hat{\lambda}$ 作为所求的变换参数,

$$\text{AIC}_{(\hat{\lambda})} = \min_{\lambda} \text{AIC}_{(\lambda)}.$$

§ 3.4 门限自回归模型的预报

由实际的动态数据建立数学模型的主要目的之一是为了进行预报。

设对 $\{x_n\}$ 已建立了 $\text{SETAR}(d, l; k_1, \dots, k_l)$ 模型

$$x_n = a_0^{(j)} + \sum_{i=1}^{k_j} a_i^{(j)} x_{n-i} + e_n^{(j)}, \quad \text{当 } x_{n-d} \in R_j$$

$$j = 1, 2, \dots, l$$

由第七章知, 则 m 步最小方差预报为条件期望

$$\hat{x}_{N+m|N} = E(x_{N+m} | x_1, x_2, \dots, x_N) \quad (9.3.26)$$

如果 $m \leq d$, x_{N+m-d} 的样本值是已获得的数据, 它属于哪一个区间 R_j 是确定的, x_{N+m} 就用相应的 $\text{AR}(k_j)$ 模型来预报。所以有

$$\begin{aligned} \hat{x}_{N+m|N} &= a_0^{(j)} + a_1^{(j)} \hat{x}_{N+m-1|N} + \dots + a_{m-1}^{(j)} \hat{x}_{N+1|N} \\ &\quad + a_m^{(j)} x_N + \dots + a_{k_j}^{(j)} x_{N+m-k_j} \end{aligned} \quad (9.3.27)$$

这样用实测数据和逐步递推预报可以得 m 步预报值。

如果 $m > d$ 时, x_{N+m-d} 的样本值尚未观测到, 无法判断它属于哪一个区间, 也就无法用上述方法作出 m 步预报。在这种情形下预报可依下面方法实现。

首先看一步预报 $\hat{x}_{N+1|N}$, 因 x_{N+1-d} 是已观测到, 因此它属于哪一个区间 R_j 是已知的, $\hat{x}_{N+1|N}$ 便可用 R_j 的相应模型得到。此后把 $\hat{x}_{N+1|N}$ 的值当作 x_{N+1} 的观测值 (实际上并未观测到), 像求 $\hat{x}_{N+2|N+1}$ 那样来求得 $\hat{x}_{N+2|N}$ 的值, 再把它作为 x_{N+2} 的观测值, 依此类推, 可以求得任意 m 步预报。

用上述的预报方法, 我们可以得到各步预报仍记为 $\hat{x}_{N+m|N}$, $m = 1, 2, \dots$ 。但是要注意在 $m > d$ 时, 它不一定是真正的 $E(x_{N+m} | x_1, \dots, x_N)$ 。我们把各步预报值用折线连接起来的曲线称为最

终预报曲线,记为 $\text{Eff}(d)$ 。除非拟合模型不稳定, $\text{Eff}(d)$ 总将趋于一个常数或周期函数,前者标志为极限点,后者标志为极限环。

§ 3.5 门限自回归模型的实例

1. 加拿大山猫皮动态数据(1831~1934年)的建模。1831年—1934年的数据为

269	321	585	871	1475	2821	3928	5943	4950
2577	523	98	184	279	409	2285	2685	3409
1824	409	151	45	68	213	546	1033	2129
2536	957	361	377	225	360	731	1638	2725
2871	2119	684	299	236	245	552	1623	3311
6721	4254	687	255	473	358	784	1594	1676
2251	1426	756	299	201	229	469	736	2042
2811	4431	2511	389	73	39	49	59	188
1292	4031	3495	587	105	153	387	758	1307
3465	6991	6313	3794	1836	345	382	808	1388
2713	3800	3091	2985	3790	674	71	80	108
229	399	1132	2432	3574	2935	1537	529	485
662	1000	1590	2657	3396				

许多统计学家都曾经对这批动态数据分析产生过较大兴趣。由图 9.10 可以看出,数据本身变化幅度有近于 10 年的明显周期,而且从每一个极小到下一个极大的增长段长度超过从一个极大到下一个极小的下降段长度。

由于数据起伏变化很大,在建模前对数据作以 10 为底的对数变换后,再建模为 SETAR(2,2;8,3)模型

$$x_n = \begin{cases} 0.5239 + 1.0359 x_{n-1} - 0.1756 x_{n-2} + 0.1753 x_{n-3} \\ - 0.4339 x_{n-4} + 0.3457 x_{n-5} - 0.3632 x_{n-6} + 0.2165 x_{n-7} \\ + 0.0043 x_{n-8} + e_n^{(1)} & \text{当 } x_{n-2} \leq 3.1163 \\ 2.6559 + 1.4246 x_{n-1} - 1.1618 x_{n-2} - 0.1094 x_{n-3} + e_n^{(2)} & \text{当 } x_{n-2} > 3.1163 \end{cases} \quad (9.3.28)$$

其中 $\text{var}\varepsilon_n^{(1)} = 0.0255, \text{Var}\varepsilon_n^{(2)} = 0.0516$ 。




图 9.10 山猫数据(1831~1934 年)的 SETAR
(2,2;8,3) 模型

* 模型拟合, □ 最终预报函数, + 实测数据。

由图 9.10 表明,模型 SETAR(2,2;8,3) 所算出的最终预报函数 $\text{Eff}(2)$ 是一个 9 年为周期的非对称函数,即表明模型存在着一个按定义 2 确定的 9 年周期的极限环,上升和下降段长度分别为 6 年和 3 年,它的极限环为 (2.6226, 2.8945, 3.2525, 3.4601, 3.4257, 3.2281, 2.9793, 2.7884, 2.6639)。

这 $d=2$ 表明门限依赖于 x_{n-2} ,这一事实从下面一个观点看来是非常有趣的,即山猫数量的增减与捕食之间存在着滞后两年的关系。

2. 太阳黑子动态数据(1700~1979 年)。设原始数据为 $\{w_n, 1 \leq n \leq 280\}$, 具体数据见第三章 §3.3。

原始数据经过 Box-Cox 变换(选取 $\lambda = \frac{1}{2}$)为

$$x_n = 2[(w_n)^{\frac{1}{2}} - 1], n = 1, 2, \dots, 280$$

对变换后的数据 $\{x_n, 1 \leq n \leq 280\}$ 建立门限自回归模型为 SETAR(8,2;11,3) 模型。

$$x_n = \begin{cases} 1.9191 + 0.8416 x_{n-1} + 0.0728 x_{n-2} - 0.3152 x_{n-3} \\ + 0.1479 x_{n-4} - 0.1985 x_{n-5} - 0.0005 x_{n-6} + 0.1875 x_{n-7} \\ - 0.2701 x_{n-8} + 0.2116 x_{n-9} + 0.0091 x_{n-10} + 0.0873 x_{n-11} \\ + e_n^{(1)} & \text{当 } x_{n-8} \leq 11.9284 \\ 4.2746 + 1.4431 x_{n-1} - 0.8408 x_{n-2} + 0.0554 x_{n-3} + e_n^{(2)} & \text{当 } x_{n-8} > 11.9284 \end{cases} \quad (9.3.29)$$

其中 $\text{var } e_n^{(1)} = 1.946$, $\text{var } e_n^{(2)} = 6.302$ 。由 (9.3.29) 模型得到 1980 年~1987 年的 8 年的预报值为

表 9.5 太阳黑子预报值与实测值比较

年	1980	1981	1982	1983	1984	1985	1986	1987
预报值	160.1	141.8	96.4	61.8	31.1	18.1	18.9	29.9
实测值	154.6	140.5	115.9	66.6	45.9			

另外由 1700 年~1920 年太阳黑子的观测数据,直接用 SETAR (3,2;4,12) 模型来拟合,建立的模型为

$$x_n = \begin{cases} 10.5440 + 1.6920 x_{n-1} - 1.1592 x_{n-2} + 0.2367 x_{n-3} \\ + 0.1503 x_{n-4} + e_n^{(1)} & \text{当 } x_{n-3} \leq 36.6 \\ 7.8041 + 0.7432 x_{n-1} - 0.0409 x_{n-2} - 0.2020 x_{n-3} + \\ + 0.1730 x_{n-4} - 0.2256 x_{n-5} - 0.0189 x_{n-6} + 0.1612 x_{n-7} - \\ 0.2564 x_{n-8} + 0.3105 x_{n-9} - 0.3891 x_{n-10} + 0.4306 x_{n-11} - \\ - 0.0397 x_{n-12} + e_n^{(2)} & \text{当 } x_{n-3} > 36.6 \end{cases} \quad (9.3.30)$$

其中 $\text{var } e_n^{(1)} = 254.64$, $\text{var } e_n^{(2)} = 66.84$ 。

图 9.11 表明了拟合状况,一步预报和最终预报函数 (1921~1955 年)。注意 $\text{Eff}(3)$ 是一个 31 年周期的预报函数,由三个极大




图 9.11 太阳黑子数据(1700~1920 年)的 SETAR
(3,2; 4,12)模型

* 模型拟合, ◻ 一步预报(1921~1955), ◻ 最终预报函数,
+ 实测数据。

与三个极小组成,即有三个局部循环。这三个局部循环的上升和下降的长度是不对称的,可用 $\frac{31}{3}=10.3$ 年作为太阳黑子的分周期。

3. 煤矿坑道压力的动态数据的建模。在地下煤矿开采过程中,已开采的坑道常引起地层压力的变化。由于各种地质因素的影响,引起坑道压力的变化是复杂的,这对矿工的安全和生产影响极大,需要对坑道压力变化进行预报,从而必须要建立它的数学模型。

设原始数据为 $\{w_n, 1 \leq n \leq 205\}$ 作 Box-Cox 变换

$$x_n = 2(\sqrt{w_n} - 1), \quad 1 \leq n \leq 205$$

我们用 SETAR(6,3;6,10,10)模型去拟合 $\{x_n, 1 \leq n \leq 205\}$, 其模型为

$$\begin{aligned}
 & -5.2240 + 0.5835 x_{n-1} + 0.0281 x_{n-2} + 0.1159 x_{n-3} \\
 & -0.1383 x_{n-4} - 0.0698 x_{n-5} + 0.1970 x_{n-6} + e_n^{(1)} \\
 & \quad \text{当 } x_{n-6} \leq 20.9695 \\
 & 1.7344 - 0.0297 x_{n-1} + 0.1098 x_{n-2} - 0.1885 x_{n-3} \\
 & -0.3170 x_{n-4} + 1.1791 x_{n-5} + 0.6246 x_{n-6} - 0.5902 x_{n-7} \\
 & -0.4687 x_{n-8} - 0.4279 x_{n-9} + 0.2801 x_{n-10} + e_n^{(2)} \\
 & \quad \text{当 } 20.9695 < x_{n-6} \leq 23.3929 \\
 & 62.6842 + 0.9871 x_{n-1} - 0.3589 x_{n-2} + 0.6257 x_{n-3} \\
 & -0.6911 x_{n-4} \\
 & + 0.7981 x_{n-5} + 2.2151 x_{n-6} + 0.3734 x_{n-7} - 0.6518 x_{n-8} \\
 & -0.0231 x_{n-9} + 0.2591 x_{n-10} + e_n^{(2)} \quad \text{当 } x_{n-6} > 23.3929
 \end{aligned}$$

(9.3.31)

其中 $\text{var}e_n^{(1)} = 8.8702$, $\text{var}e_n^{(2)} = 4.8600$, $\text{var}e_n^{(3)} = 9.3174$ 。

表 9.6 矿压实测值与预报值比较表

n	206	207	208	209	210	211	212	213	214	215
w_n 实测值	139.3	177.0	118.7	118.4	122.8	118.6	92.5	97.9	128.0	105.8
w_n 预报值	151.9	148.8	128.5	104.1	188.7	292.2	74.1	113.0	119.7	83.8



图 9.12 SETAR(6,3;6,10,10)矿压预报图

由于坑道压力数据变化剧烈，结果在预报5步内比较理想，

更多的步数预报不理想,我们可以认为 SETAR(6,3;6,10,10) 模型基本上反映坑道压力的变化规律。

4. 貂类与麝香鼠的生态平衡。设它们从 1848 年至 1909 年的二组动态数据分别为 $\{u_j, 1848 \leq j \leq 1909\}$, 和 $\{v_j, 1848 \leq j \leq 1909\}$ 。对这二组数据分别作如下变换

$$x_n = \ln u_{1847+n}, \quad n = 1, 2, \dots, 62$$

$$y_n = \nabla(\ln v_{1848+n}), \quad n = 1, 2, \dots, 61$$

其中 ∇ 是一阶差分算子。对 $\left\{ \begin{pmatrix} x_n \\ y_n \end{pmatrix}, n = 1, 2, \dots, 61 \right\}$ 建立闭环门

限自回归模型,即用 TARSC 模型拟合二组变换后的数据,它们分别由 TARSO(5,2;(4,3),(4,3))和 TARSO(5,2;(3,2),(2,1))组成。其模型为

$$x_n = \begin{cases} 8.1624 + 0.3437 x_{n-1} + 0.4510 y_{n-1} + 0.0696 x_{n-2} - \\ \quad - 0.0713 y_{n-2} - 0.4119 x_{n-3} + 0.5353 y_{n-3} + \\ \quad 0.2228 x_{n-4} + \varepsilon_n^{(1)} & \text{当 } y_{n-5} \leq -0.0433 \\ 5.4058 + 0.5266 x_{n-1} + 0.4653 y_{n-1} + 0.3631 x_{n-2} - \\ \quad - 0.2820 y_{n-2} - 0.2207 x_{n-3} + 0.2009 y_{n-3} - \\ \quad - 0.1585 x_{n-4} + \varepsilon_n^{(2)} & \text{当 } y_{n-5} > -0.0433 \end{cases}$$

其中 $\text{var} \varepsilon_n^{(1)} = 0.0369$, $\text{var} \varepsilon_n^{(2)} = 0.0234$ 。

和

$$y_n = \begin{cases} 2.9045 - 0.0212 y_{n-1} - 0.6994 x_{n-1} - 0.3047 y_{n-2} + \\ \quad + 0.4254 x_{n-2} + 0.0485 y_{n-3} + \eta_n^{(1)} & \text{当 } x_{n-5} \leq 10.9616 \\ 5.8527 + 0.3032 y_{n-1} - 0.5387 x_{n-1} - 0.1289 y_{n-2} + \eta_n^{(2)} & \text{当 } x_{n-5} > 10.9616 \end{cases}$$

其中 $\text{var} \eta_n^{(1)} = 0.0385$, $\text{var} \eta_n^{(2)} = 0.0841$ 。

上述拟合模型对于貂类有 10 年为周期的极限环,它是 6 年上升和 4 年下降。对于麝香鼠也有 10 年为周期的极限环,它是 4 年上升 3 年下降随后 2 年上升 1 年下降。

此模型在某种程度上反映了这两种动物之间相互依存相互制约的关系。

§ 4 门限自回归滑动平均模型^[46]

类似于线性模型由 AR 模型扩充到 ARMA 模型,自然地,在非线性模型中门限自回归模型也可相应地扩充到门限自回归滑动平均模型,简记为 TARMA 模型。下面我们简单地给出 TARMA 模型的定义,具体的建模步骤和参数估计的计算方法。TARMA 模型与 ARMA 模型计算复杂性相当,它比 TAR 模型计算要复杂得多,但它便于更好地刻划某些物理现象。

设 $\{x_n\}$ 为随机序列,若它满足

$$x_n = a_0^{(j)} + \sum_{i=1}^{p_j} a_i^{(j)} x_{n-i} + \varepsilon_n^{(j)} - \sum_{i=1}^{q_j} \theta_i^{(j)} \varepsilon_{n-i}^{(j)}, \text{ 当 } x_{n-d} \in R_j, \\ j=1, 2, \dots, l \quad (9.4.1)$$

称 $\{x_n\}$ 服从自激励的门限自回归滑动平均模型,简记为 SETARMA($d, l; p_1, \dots, p_l, q_1, \dots, q_l$) 模型。(9.4.1) 模型中的记号类似于 (9.3.2), 这里不再重复。若 $l=1$ 时, (9.4.1) 就是 ARMA 模型, 若 $q_1 = \dots = q_l = 0$ 时, (9.4.1) 就是一般 SETAR($d, l; p_1, \dots, p_l$) 模型。

下面给出对动态数据 $\{x_n, 1 \leq n \leq N\}$ 如何去辨识 SETARMA 模型的步骤。

1. 预先选定 d 和 L_1, L_2 , L_1, L_2 分别为最大允许的自回归和滑动平均的阶数。令 $n_0 = \max(d, L_1, L_2)$, 任意选择一组 $t_1, t_2, \dots, t_{l-1}$, 使得满足 $-\infty = t_0 < t_1 < t_2 < \dots < t_{l-1} < t_l = +\infty$ 。我

们这里采用 BIC 准则来辨识 SETARMA 模型 (当然也可以采用 AIC 准则, 但 BIC 准则效果要好一些)。记

$$\text{BIC}_{d,l}(\hat{p}_j, \hat{q}_j) = \min_{\substack{1 \leq p_j \leq L_1 \\ 1 \leq q_j \leq L_2}} \text{BIC}_{d,l}(p_j, q_j) \quad (9.4.2)$$

其中

$$\text{BIC}_{d,l}(p_j, q_j) = N_j \ln \frac{\text{RSS}_j(p_j, q_j)}{N_j} + (p_j + q_j + 2) \ln N_j \quad (9.4.3)$$

$\text{RSS}_j(p_j, q_j)$ 是第 j 个自回归滑动平均模型的残差平方和 (见第三章), N_j 是后 $N - n_0$ 个动态数据落在 $(t_{j-1}, t_j]$ 内的数据的个数。

2. 在 d 和 L_1, L_2 固定下, 令

$$\begin{aligned} \text{BIC}_{d,l}(\hat{r}_1, \hat{r}_2, \dots, \hat{r}_{l-1}) = \min_{-\infty < t_1 < \dots < t_{l-1} < +\infty} \sum_{j=1}^l \frac{N_j}{N - n_0} \\ \cdot \text{BIC}_{d,l}(\hat{p}_j, \hat{q}_j) \end{aligned} \quad (9.4.4)$$

这样得到了在分段段数为 l 时的门限值的估计 $\hat{r}_1, \hat{r}_2, \dots, \hat{r}_{l-1}$ 。

3. 我们根据下式来选择 l 的估计 $\hat{l}$ 。

$$\text{BIC}_d(\hat{l}; \hat{r}_1, \hat{r}_2, \dots, \hat{r}_{\hat{l}-1}) = \min_{l \geq 2} \text{BIC}_{d,l}(\hat{r}_1, \hat{r}_2, \dots, \hat{r}_{l-1}) \quad (9.4.5)$$

实际上, l 不宜过大, 因为动态数据只有有限 N 个。用过多模型去描述是无必要, 在一般处理实际问题时, 只要取 $l=2, 3$ 也就够了。

4. 令

$$\text{BIC}(\hat{d}) = \min_d \frac{\text{BIC}_d(\hat{l}; \hat{r}_1, \hat{r}_2, \dots, \hat{r}_{\hat{l}-1})}{N - n_0} \quad (9.4.6)$$

其中对 d 求最小值是 d 取 $1, 2, \dots$ 到某个正整数, 一般不超过 10。这样得到延迟参数 d 的估计 $\hat{d}$ 。

用以上四个步骤可辨识 SETARMA 模型, 即得到模型中参数的最佳估计值为

$(\hat{p}_1, \hat{q}_1), \dots, (\hat{p}_l, \hat{q}_l), \hat{l}, \hat{d}$ 门限估计值 $\hat{r}_1, \hat{r}_2, \dots, \hat{r}_{l-1}$ 以及 $\text{var} \hat{\alpha}_n^{(j)}$, $j=1, 2, \dots, \hat{l}$ 的估计值。

下面给出一个实例：我们仍然采用本章 § 3.5 中加拿大山猫皮的数据(1831~1934 年),采用前 95 个数据(1831 年~1925 年)进行 SETARMA 模型辨识,留下 9 个数据作预报时进行比较。这例子我们固定的取 $d=2, l=2$, 只对 p_1, p_2, q_1, q_2 和 r_1 进行估计。首先对原始数据作以 10 为底的对数变换, 然后建立 SETARMA $(2, 2; (1, 1), (3, 1))$ 模型如下

$$x_n = \begin{cases} 0.1865 + 1.0525 x_{n-1} + e_n^{(1)} + 1.1131 e_{n-1}^{(1)} & \text{当 } x_{n-2} \leq 2.3599 \\ 2.7705 + 0.6510 x_{n-1} + 0.0808 x_{n-2} - 0.6504 & \\ x_{n-3} + e_n^{(2)} + 1.7660 e_{n-1}^{(2)}, & \text{当 } x_{n-2} > 2.3599 \end{cases} \quad (9.4.7)$$

其中 $\text{var}e_n^{(1)} = 0.0162$, $\text{var}e_n^{(2)} = 0.0569$ 。

对照 § 3.5 的例 1 建立的 SETAR(2, 2; 8, 3) 模型, 比较可以看出二个分段模型的残差平方和分别为 0.0771 和 0.0731, SETARMA 模型要小于 SETAR 模型, 况且 SETARMA 是在固定 $d=2$ 的条件下得到, 还可求得更佳模型, 使残差平方和更进一步下降。

由(9.4.7)模型, 给出 1 至 9 步预报值如下

表 9.7 SETARMA(2, 2; (1, 1), (3, 1))模型预报值与实测值比较表

	1925	1927	1928	1929	1930	1931	1932	1933	1934
实 测 值	2925	1537	529	485	662	1000	1590	2667	3296
$\log_{10}$ 实测值	3.4676	3.1866	2.7234	2.6857	2.8208	3.000	3.2014	3.4266	3.53096
预 报 值	3267.6	1380	609	353.8	407.6	728	1528.6	2366.6	2289.2
$\log_{10}$ 预报值	3.5142	3.1298	2.7846	2.5487	2.6102	2.8521	3.1842	3.3741	3.3596

第十章 基于0-1序列的时序分析

本书前九章研究的对象，都是由连续时间过程经离散时间间隔均匀采样所得的时间序列。目的在于对动态数据讨论建模和预报的实现。在本书结束之前，我们将从另一角度，用有别于前九章的方法和工具，通过两种状态变化的研究，来探讨动态数据本身的内部规律。同时也向读者介绍这种基于两种状态分析处理动态数据的简便有趣的手段和方法。为了叙述清晰和便于读者理解问题，本章随机变量用大写 X 表示，样本值用小写 x 表示。

§ 1 引言

许多实际事物常常呈现两种状态，如人的性别分为男、女两类；扔硬币时，可能出现正面或反面等等。这两种状态不妨分别用 0 和 1 来标志，因此，0-1 是对事物状态的一种抽象和简化的表征。

如果上述两种状态可随时间而变，则可由此而得相应的一串 0-1 序列。另外，有些实际问题常可按某一水平而划分为两种状态，因此，由这类时间序列的样本列即可产生与之相应的长度相同的 0-1 序列。例如

在气象研究中，考虑某一地区下雨或不下雨的变化过程。设“1”表示下雨，“0”表示不下雨，则某段时期内这种天气变化的情形，就可由 0-1 序列来表征。

在地震研究中，考察某一地区地震发生变化的规律，设“1”表征大于 5 级的地震，“0”表征不大于 5 级的地震，则某时期内地壳震动规律也可由 0-1 序列来描述。

在神经系统研究中，考虑某 n 个神经元在时刻 t 的兴奋程度对附近另一个神经元的兴奋敏感程度的影响，也可转化为某一个

0-1 序列的讨论：

设被考察的神经元为 $u(t)$ ，其周围的 n 个神经元为 $u_1(t)$ ， $u_2(t)$ ， $\dots$ ， $u_n(t)$ 。若当这 n 个周围神经元兴奋程度总和大于 α 时，被考察的神经元处于兴奋状态，我们就称此神经元处于状态“1”，否则称其处于状态“0”，即

$$u(t) = \begin{cases} 1 & \text{当 } \sum_{i=1}^n u_i(t) > \alpha \\ 0 & \sum_{i=1}^n u_i(t) \leq \alpha \end{cases}$$

当 t 变化时，即可得到 0-1 序列。

国际股票市场价格常常处于涨价和跌价两种状态，其随时间的变化也呈 0-1 序列。

显然，对于 0-1 序列进行研究，或是基于 0-1 序列分析而对原序列进行研究，无疑在理论探讨和实际应用两方面都是很有意义的。

我们可运用以下手段由一个平稳序列产生与之相应的 0-1 序列：

设 $\{X_i\}$ 为平稳随机序列， $E X_i = \mu$ 。对 $\{X_i\}$ 作硬判决

$$W_i = \begin{cases} 1, & X_i > \mu \\ 0, & X_i \leq \mu \end{cases} \quad (10.1.1)$$

则称 $\{W_i\}$ 是 $\{X_i\}$ 的水平为均值 μ 的 0-1 序列。由此可见，若 $x_1, x_2, \dots, x_N$ 是 $\{X_i\}$ 的长为 N 的样本列，则经硬判决后可得到长度为 N 的 0-1 序列 $w_1, w_2, \dots, w_N$ ，

$$w_i = \begin{cases} 1 & x_i > \bar{x} \\ 0 & x_i \leq \bar{x} \end{cases} \quad \text{其中 } \bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

一般地，如果以任意实数 u 作为硬判决的水平数，则由原平稳序列 $\{X_i\}$ 及其样本列 $\{x_1, \dots, x_N\}$ 也可产生相应的 0-1 序列 $\{W_i^*\}$ 及 $\{w_1^*, \dots, w_N^*\}$ 。

在 0-1 序列中，称由“1”（“0”）连续组成的不能再长的子序列为“1”-游程（“0”-游程）；每个“1”-游程（“0”-游程）中数字

“1”(“0”)的个数,称为此游程的长度;整个 0-1 序列中的任一连续部分称为 0-1 子序列,此部分之长度(即其“0”,“1”的总个数)为该 0-1 子序列的长度。显然,一个长为 $l(l \geq 2)$ 的“1”-游程中包含 $l-1$ 个由两元素(1,1)所成的子序列。例如, 0-1 序列

110101010111000

序列总长: 15 游程个数 10

“1”-游程个数: 5, 其中三个长为 1, 一个长为 2, 一个长为 3。

“0”-游程个数: 5。其中四个长为 1, 一个长为 3。

“101”: 为此序列的长为 3 的两端为 1 中间为 0 的子序列, 其在全序列中出现四次。

“11”: 为此序列中长为 2 的“1”-游程, 此子序列在原序列中出现了三次。

本章将研究正态平稳序列经硬判决后所得的 0-1 序列, 给出原序列与 0-1 序列的相关函数间的关系式。基于 0-1 序列分析, 对原序列建立各类线性时序模型, 并实现递推预报。借助以下几节的分析, 我们将会了解到, 在一定的条件下, 这种分析方法不仅具有快速简便的明显优点, 而且具有细致可靠的理论依据。当样本长度 N 足够大时, 其建模精度和预报效果并不亚于原序列分析, 因此, 确实是十分令人感兴趣的时序分析手段。

§ 2 二维平稳正态序列的互相关函数

设 $\{X_i\}$ 为二维平稳正态序列, $X_i = \begin{pmatrix} X_i^{(1)} \\ X_i^{(2)} \end{pmatrix}$, $E X_i = 0$, $\{W_i^{(i)}\}$

是 $\{X_i^{(i)}\}(i=1,2)$ 的水平为零的 0-1 序列, 记 $W_i = \begin{pmatrix} W_i^{(1)} \\ W_i^{(2)} \end{pmatrix}$,

称 $\{W_i\}$ 是 $\{X_i\}$ 的水平为零的二维 0-1 序列。

引理 1 在以上的条件下, 可证明 $\{W_i\}$ 为二维平稳序列, $\{W_i^{(i)}\}, i=1,2$ 为一维平稳序列, 且

$$P(W_i^{(i)}=1) = P(W_i^{(i)}=0) = \frac{1}{2}, \quad EW_i^{(i)} = \frac{1}{2},$$

$$\gamma_0^{(i)} = \frac{1}{4} \quad i=1,2 \quad (10.2.1)$$

证明：由正态分布的对称性知，

$$P(W_i^{(i)}=1) = P(X_i^{(i)} > 0) = \frac{1}{2}$$

$$P(W_i^{(i)}=0) = P(X_i^{(i)} \leq 0) = \frac{1}{2}$$

$$EW_i^{(i)} = 1 \cdot P(W_i^{(i)}=1) + 0 \cdot P(W_i^{(i)}=0)$$

$$= P(W_i^{(i)}=1) = \frac{1}{2}$$

$$\gamma_0^{(i)} = E\left(W_i^{(i)} - \frac{1}{2}\right)^2$$

$$= \frac{1}{4} P(W_i^{(i)}=1) + \frac{1}{4} P(W_i^{(i)}=0) = \frac{1}{4}$$

$$EW_i^{(2)}W_{i-k}^{(1)} = P(W_i^{(2)}=1, W_{i-k}^{(1)}=1)$$

$$= P(X_i^{(2)} > 0, X_{i-k}^{(1)} > 0)$$

由 $\{X_t\}$ 是二维平稳列可推知， $EW_i^{(2)}W_{i-k}^{(1)}$ 仅与 k 有关，与 t 无关，故 W_t 的分量互协方差仅为时间间隔的函数。特别，若取各分量求自身协方差，也依同法可推得上述结论，由此可知， $\{W_t\}$ 是二维平稳序列，各分量也为平稳序列。

以上有关平稳性的结论对于以任意实数 u 为水平的硬判决序列也是正确的。

$$\text{引理 2} \quad \text{记 } \nu_k = P(W_i^{(2)}=1 | W_{i-k}^{(1)}=1) \quad (10.2.2)$$

则 $\{W_i^{(2)}\}$ 与 $\{W_i^{(1)}\}$ 的互相关函数 $\rho_k^{w^{(2)}w^{(1)}}$ 满足

$$\rho_k^{w^{(2)}w^{(1)}} = 2\nu_k - 1 \quad (10.2.3)$$

$$\text{证明： } EW_i^{(2)}W_{i-k}^{(1)} = P(W_i^{(2)}=1, W_{i-k}^{(1)}=1)$$

$$= P(W_{i-k}^{(1)}=1) P(W_i^{(2)}=1 | W_{i-k}^{(1)}=1) = \frac{1}{2} \nu_k$$

由此得 $\{W_i^{(2)}\}$ 与 $\{W_i^{(1)}\}$ 的互协方差函数为

$$\gamma_k^{w^{(2)}w^{(1)}} = E\left(W_i^{(2)} - \frac{1}{2}\right)\left(W_{i-k}^{(1)} - \frac{1}{2}\right) = EW_i^{(2)}W_{i-k}^{(1)} - \frac{1}{4}$$

$$= \frac{1}{2} \nu_k - \frac{1}{4} \quad (10.2.4)$$

故 $\rho_k^{w^{(2)}w^{(1)}} = \gamma_k^{w^{(2)}w^{(1)}} / \sqrt{\gamma_0^{(2)}\gamma_0^{(1)}} = 2\nu_k - 1$

特别, $\{W_i^{(i)}\}$ 的自协方差函数为

$$\gamma_k^{w^{(i)}} = \frac{1}{2} \lambda_k^{(i)} - \frac{1}{4} \quad (10.2.5)$$

其中

$$\lambda_k^{(i)} = P(W_i^{(i)} = 1 | W_{i-k}^{(i)} = 1) \quad (10.2.6)$$

自相关函数为

$$\rho_k^{w^{(i)}} = 2 \lambda_k^{(i)} - 1 \quad (10.2.7)$$

定理 1 条件同前, 记 $\rho_{i-s}^{x^{(1)}x^{(2)}}$ 为 $\{X_i^{(1)}\}$ 与 $\{X_s^{(2)}\}$ 的互相关函数, 则

$$E W_i^{(1)} W_s^{(2)} = \frac{1}{4} + \frac{1}{2\pi} \sin^{-1} \rho_{i-s}^{x^{(1)}x^{(2)}} \quad (10.2.8)$$

证明

$$E W_i^{(1)} W_s^{(2)} = P(W_i^{(1)} = 1, W_s^{(2)} = 1) = P(X_i^{(1)} > 0, X_s^{(2)} > 0)$$

$$= \frac{1}{2\pi \left| \begin{array}{cc} \gamma_0^{x^{(1)}} & \gamma_{i-s}^{x^{(1)}x^{(2)}} \\ \gamma_{i-s}^{x^{(1)}x^{(2)}} & \gamma_0^{x^{(2)}} \end{array} \right|^{\frac{1}{2}}} \int_0^\infty \int_0^\infty \exp \left[-\frac{1}{2} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \begin{pmatrix} \gamma_0^{x^{(1)}} & \gamma_{i-s}^{x^{(1)}x^{(2)}} \\ \gamma_{i-s}^{x^{(1)}x^{(2)}} & \gamma_0^{x^{(2)}} \end{pmatrix}^{-1} \right. \\ \left. (x_1, x_2) \right] dx_1 dx_2$$

$$= \frac{1}{2\pi \sqrt{\gamma_0^{x^{(1)}} \gamma_0^{x^{(2)}}} \sqrt{1 - (\rho_{i-s}^{x^{(1)}x^{(2)}})^2}} \int_0^{\frac{\pi}{2}} \int_0^\infty \exp \left\{ -\frac{\gamma_0^{x^{(1)}} \sin^2 \theta - \gamma_{i-s}^{x^{(1)}x^{(2)}} \sin 2\theta + \gamma_0^{x^{(2)}} \cos^2 \theta}{2 \gamma_0^{x^{(1)}} \gamma_0^{x^{(2)}} [1 - (\rho_{i-s}^{x^{(1)}x^{(2)}})^2]} r^2 \right\} r dr d\theta$$

$$= \frac{\sqrt{1 - (\rho_{i-s}^{x^{(1)}x^{(2)}})^2}}{2\pi} \int_0^{\frac{\pi}{2}} \left(\sqrt{\frac{\gamma_0^{x^{(2)}}}{\gamma_0^{x^{(1)}}}} \sin^2 \theta - \rho_{i-s}^{x^{(1)}x^{(2)}} \sin 2\theta + \sqrt{\frac{\gamma_0^{x^{(1)}}}{\gamma_0^{x^{(2)}}}} \cos^2 \theta \right)^{-1} d\theta$$

$$\begin{aligned}
&= \frac{\sqrt{1 - (\rho_{i-s}^{x^{(1)}x^{(2)}})^2}}{2\pi} \int_0^{\frac{\pi}{2}} \left(\sqrt{\frac{\gamma_0^{x^{(2)}}}{\gamma_0^{x^{(1)}}}} \operatorname{tg}^2 \theta - 2 \rho_{i-s}^{x^{(1)}x^{(2)}} \operatorname{tg} \theta + \right. \\
&\quad \left. \sqrt{\frac{\gamma_0^{x^{(1)}}}{\gamma_0^{x^{(2)}}}} \right)^{-1} d \operatorname{tg} \theta \\
&= \frac{\sqrt{1 - (\rho_{i-s}^{x^{(1)}x^{(2)}})^2}}{2\pi} \frac{1}{\sqrt{1 - (\rho_{i-s}^{x^{(1)}x^{(2)}})^2}} \operatorname{tg}^{-1} \\
&\quad \left. \frac{\sqrt{\frac{\gamma_0^{x^{(2)}}}{\gamma_0^{x^{(1)}}}} \operatorname{tg} \theta - \rho_{i-s}^{x^{(1)}x^{(2)}}}{\sqrt{1 - (\rho_{i-s}^{x^{(1)}x^{(2)}})^2}} \right|_0^{\frac{\pi}{2}} \\
&= \frac{1}{4} + \frac{1}{2\pi} \operatorname{tg}^{-1} \frac{\rho_{i-s}^{x^{(1)}x^{(2)}}}{\sqrt{1 - (\rho_{i-s}^{x^{(1)}x^{(2)}})^2}} \\
&= \frac{1}{4} + \frac{1}{2\pi} \sin^{-1} \rho_{i-s}^{x^{(1)}x^{(2)}} \quad \text{证毕。}
\end{aligned}$$

特别有

$$E W_i^{(i)} W_s^{(i)} = \frac{1}{4} + \frac{1}{2\pi} \sin^{-1} \rho_{i-s}^{x^{(i)}}, \quad i=1,2 \quad (10.2.9)$$

定理 2 在引理 1 的条件下

$$\rho_k^{x^{(2)}x^{(1)}} = \sin\left(\frac{\pi}{2} \rho_k^{w^{(2)}w^{(1)}}\right) \quad (10.2.10)$$

证明：由(10.2.2)~(10.2.4)得

$$\rho_k^{w^{(1)}w^{(1)}} = 2\nu_k - 1 = 4E W_i^{(2)} W_{i-k}^{(1)} - 1 = \frac{2}{\pi} \sin^{-1} \rho_k^{x^{(2)}x^{(1)}}$$

故

$$\rho_k^{x^{(2)}x^{(1)}} = \sin\left(\frac{\pi}{2} \rho_k^{w^{(2)}w^{(1)}}\right)$$

特别，对各分量自相关函数有关系式

$$\rho_k^{x^{(i)}} = \sin\left(\frac{\pi}{2} \rho_k^{w^{(i)}}\right), \quad i=1,2 \quad (10.2.11)$$

由上可见，二维平稳正态序列各分量的互(自)相关函数，可由它们相应的 0-1 序列的互(自)相关函数而求得。(10.2.10)、(10.2.11)给我们提供了一种计算序列互(自)相关函数的十分简便快速的办法，这对许多问题的研究将会带来极大的方便。

§ 3 相关函数的估计

我们知道,在处理动态数据的实际问题中,我们往往只能获得序列本身的长度为 N 的样本列 $x_1, x_2, \dots, x_N$,并由此有限长的样本列去估计序列的样本自相关函数。例如,对于零均值平稳序列,可由下式计算样本自相关函数 ρ_k^x ,其中

$$\hat{\rho}_k^x = \frac{\hat{\gamma}_k^x}{\hat{\gamma}_0^x}, \quad \hat{\gamma}_k^x = \frac{1}{N} \sum_{j=k+1}^N x_j x_{j-k}.$$

当 N 很大时, $\hat{\rho}_k^x$ 的计算量是相当可观的。

前节给出了关系式

$$\rho_k^x = \sin\left(\frac{\pi}{2} \rho_k^w\right)$$

标志着由0-1序列自相关函数可推算出相应原序列的自相关函数。本节我们将推导0-1序列自(互)相关函数的渐近估计,并由此得出原序列自(互)相关函数的计算量极小的渐近估计公式。

§ 3.1 自相关函数估计

设 $\{X_t\}$ 为零均值平稳正态序列,自协方差函数为 $\gamma_t, t=0, \pm 1, \dots$ 。对于任意给定的正整数 M ,令

$$G_t^{(M)} = \begin{cases} 1 - \frac{|t|}{M}, & t=0, \pm 1, \dots, \pm(M-1) \\ 0, & \text{其它} \end{cases} \quad (10.3.1)$$

及 $\gamma_t^* = \gamma_t G_t^{(M)}, t=0, \pm 1, \dots, \quad (10.3.2)$

显然 $\gamma_{-t}^* = \gamma_t^*$ 。下面将证明 $\{\gamma_t^*\}$ 为非负定序列。设 $\{X_t\}$ 的谱密度函数为 $f(\lambda)$,由协方差函数的谱展式知 $\gamma_t = \int_{-\pi}^{\pi} e^{it\lambda} f(\lambda) d\lambda$ 。

$G_t^{(M)}$ 可表为

$$G_t^{(M)} = \int_{-\pi}^{\pi} e^{it\lambda} \frac{\sin^2 \frac{1}{2} M \lambda}{2 \pi \sin^2 \frac{1}{2} \lambda} d\lambda \quad (10.3.3)$$

由富氏积分的卷积公式知

$$\gamma_t^* = \int_{-\pi}^{\pi} e^{it\lambda} \left[\int_{-\pi}^{\pi} f(\mu) \frac{\sin^2 \frac{1}{2} M(\lambda - \mu)}{2\pi \sin^2 \frac{1}{2}(\lambda - \mu)} d\mu \right] d\lambda,$$

记

$$f^*(\lambda) = \int_{-\pi}^{\pi} f(\mu) \frac{\sin^2 \frac{1}{2} M(\lambda - \mu)}{2\pi \sin^2 \frac{1}{2}(\lambda - \mu)} d\mu,$$

显然 $f^*(\lambda) \geq 0$, 故 $\{\gamma_t^*\}$ 为非负定列。我们可以构造一个零均值平稳正态序列 $\{X_t^{(M)}\}$, 它的自协方差函数为

$$\gamma_t^{(M)} - \gamma_t^* = \gamma_t G_t^{(M)}, \quad t = 0, \pm 1, \dots \quad (10.3.4)$$

从(10.3.1)和(10.3.2)知 $\{X_t^{(M)}\}$ 是一个 M 独立序列, 即对任意整数 i, k, r, m , 其中 $i < k, k+r < m$, 只要 $r \geq M$ 时, $(X_i^{(M)}, \dots, X_k^{(M)})$ 与 $(X_{k+r}^{(M)}, \dots, X_m^{(M)})$ 相互独立。由(10.3.2)推出, 对于任意固定 t , 当 $M \rightarrow \infty$ 时都有

$$\gamma_t^{(M)} \rightarrow \gamma_t$$

所以对任意 $t_1, \dots, t_n$, 当 $M \rightarrow \infty$ 时有 $(X_{t_1}^{(M)}, \dots, X_{t_n}^{(M)})$ 依分布收敛于 $(X_{t_1}, \dots, X_{t_n})$, 从而对于似然函数有

$$L(X_{t_1}^{(M)}, \dots, X_{t_n}^{(M)}) \xrightarrow{M \rightarrow \infty} L(X_{t_1}, \dots, X_{t_n}). \quad (10.3.5)$$

设 $\{W_t\}$ 和 $\{W_t^{(M)}\}$ 分别是 $\{X_t\}$ 和 $\{X_t^{(M)}\}$ 的水平为零的 0-1 序列, 即

$$W_t = \begin{cases} 1, & \text{当 } X_t > 0 \\ 0, & \text{当 } X_t \leq 0 \end{cases} \quad (10.3.6)$$

$$W_t^{(M)} = \begin{cases} 1, & \text{当 } X_t^{(M)} > 0 \\ 0, & \text{当 } X_t^{(M)} \leq 0 \end{cases} \quad (10.3.7)$$

由(10.3.5)知

$$L(W_{i_1}^{(M)}, \dots, W_{i_n}^{(M)}) \xrightarrow{M \rightarrow \infty} L(W_{i_1}, \dots, W_{i_n}). \quad (10.3.8)$$

设 $x_1, x_2, \dots, x_N$ 是长度为 N 的样本, $w_1, \dots, w_N$ 是相应的硬判决得到的 0-1 样本, 则由 M 独立性和平稳性知

$$\begin{aligned} & P(W_1^{(M)} = w_1, \dots, W_{k+1}^{(M)} = w_{k+1}, W_{k+1+M}^{(M)} = w_2, \dots, \\ & \quad W_{2k+1+M}^{(M)} = w_{k+2}, \dots \\ & \quad W_L^{(M)} = w_{N-k}, \dots, W_{L+k}^{(M)} = w_N) \\ &= P(W_1^{(M)} = w_1, \dots, W_{k+1}^{(M)} = w_{k+1}) P(W_{k+1+M}^{(M)} \\ & \quad = w_2, \dots, W_{2k+1+M}^{(M)} = w_{k+2}) \\ & \quad \dots P(W_L^{(M)} = w_{N-k}, \dots, W_{L+k}^{(M)} = w_N) \quad (10.3.9) \end{aligned}$$

其中 $L = (N - k - 1)(k + M) + 1$ 。当 $M \rightarrow \infty$ 时, 由(10.3.8)和(10.3.9)知上式趋于

$$\begin{aligned} & P(W_1 = w_1, \dots, W_{k+1} = w_{k+1}) P(W_2 = w_2, \dots, W_{k+2} = w_{k+2}) \dots \\ & \quad P(W_{N-k} = w_{N-k}, \dots, W_N = w_N) \\ &= P(W_1 = w_1) P(W_{k+1} = w_{k+1} | W_1 = w_1) P(W_2 = w_2, \dots, W_k \\ & \quad = w_k | W_1 = w_1, W_{k+1} = w_{k+1}) \\ & \quad P(W_2 = w_2) P(W_{k+2} = w_{k+2} | W_2 = w_2) P(W_3 = w_3, \dots, W_{k+1} = \\ & \quad w_{k+1} | W_2 = w_2, W_{k+2} = w_{k+2}) \\ & \quad \dots \\ & \quad P(W_{N-k} = w_{N-k}) P(W_N = w_N | W_{N-k} = w_{N-k}) \\ & \quad P(W_{N-k+1} = w_{N-k+1}, \dots, W_{N-1} = w_{N-1} | \\ & \quad W_{N-k} = w_{N-k}, W_N = w_N) \\ &= \prod_{i=k+1}^N P(W_{i-k} = w_{i-k}) \prod_{i=k+1}^N P(W_i = w_i | W_{i-k} = w_{i-k}) \cdot \\ & \quad \cdot \prod_{i=k+1}^N P(W_{i-k+1} = w_{i-k+1}, \dots, W_{i-1} = w_{i-1} | W_{i-k} = w_{i-k}, \\ & \quad W_i = w_i) \quad (10.3.10) \end{aligned}$$

由于 $P(W_{i-k} = 1) = P(W_{i-k} = 0) = \frac{1}{2}$ (事实上 $P(w_{i-k} = 1) =$

$$P(X_{i-k} > 0) = \frac{1}{2}, \text{ 又 } P(X_{i-k} > 0) = P(X_{i-k} \leq 0) = P(W_{i-k} = 0),$$

$$\text{故 } P(W_{i-k} = w_{i-k}) = \frac{1}{2}. \text{ 令}$$

$$\lambda_k = P(W_i = 1 | W_{i-k} = 1),$$

因为 $P(X_i > 0, X_{i-k} > 0) = P(X_i \leq 0, X_{i-k} \leq 0)$, 所以有

$$\lambda_k = P(W_i = 1 | W_{i-k} = 1) = P(W_i = 0 | W_{i-k} = 0)$$

$$1 - \lambda_k = P(W_i = 0 | W_{i-k} = 1) = P(W_i = 1 | W_{i-k} = 0)$$

一般地有

$$\begin{aligned} & P(W_i = w_i | W_{i-k} = w_{i-k}) \\ &= \lambda_k^{w_i w_{i-k}} \lambda_k^{(1-w_i)(1-w_{i-k})} (1-\lambda_k)^{(1-w_i)w_{i-k}} (1-\lambda_k)^{(1-w_{i-k})w_i} \\ &= \lambda_k^{1-w_i-w_{i-k}+2w_i w_{i-k}} (1-\lambda_k)^{w_i+w_{i-k}+2w_i w_{i-k}} \end{aligned} \quad (10.3.11)$$

记 $s_2 = \sum_{i=k+1}^N (w_i + w_{i-k})$, $s_1 = \sum_{i=k+1}^N w_i w_{i-k}$, 将 (10.3.11) 代入

(10.3.10), 等式右端应为

$$\begin{aligned} & \left(\frac{1}{2}\right)^{N-k} \lambda_k^{N-k-s_1+2s_1} (1-\lambda_k)^{s_2-2s_1} \\ & \cdot \prod_{i=k+1}^N P(W_{i-k+1} = w_{i-k+1}, \dots, W_{i-1} = w_{i-1} | W_{i-k} = \\ & w_{i-k}, W_i = w_i) \end{aligned} \quad (10.3.12)$$

显然(10.3.12)乘积的最后一项连乘不包含参数 λ_k , 把(10.3.12)看作(10.3.9)右边式子的含有参数为 λ_k 的渐近表达式。因此, 以(10.3.12)作为渐近(对 M 而言渐近)似然函数对 λ_k 求得的极大似然估计 $\hat{\lambda}_k$, 可作为 λ_k 的渐近极大似然估计。记(10.3.12)式为 $g(w_1, \dots, w_N)$, 则由似然方程

$$\frac{\partial \log g}{\partial \lambda_k} = 0,$$

立即得到 λ_k 在上述意义下的渐近极大似然估计

$$\hat{\lambda}_k = \frac{N - k + 2 \sum_{i=k+1}^N w_i w_{i-k} - \sum_{i=k+1}^N (w_i + w_{i-k})}{N - k} \quad (10.3.13)$$

当 N 很大时, 为计算方便可将 (10.3.13) 近似为

$$\hat{\lambda}_k = \frac{N - 2 \left(\sum_{i=1}^N w_i - \sum_{i=k+1}^N w_i w_{i-k} \right)}{N - k} \quad (10.3.14)$$

因为 $w_i w_{i-k} = 1$ 等价于 $w_i = 1$ 和 $w_{i-k} = 1$ 同时成立, 故此时 $w_{i-k}, w_{i-k+1}, \dots, w_i$ 是 $(w_1, \dots, w_N)$ 中一个长度为 $k+1$ 且两端为 1 的 0-1 子序列, 故 $\sum_{i=k+1}^N w_i w_{i-k}$ 正是这种子序列的数目, 又

$\sum_{i=1}^N w_i$ 是 $(w_1, \dots, w_N)$ 中 1 的个数, 所以 (10.3.14) 又可表为

$$\hat{\lambda}_k = \frac{1}{N - k} \{ N - 2[(w_1, \dots, w_N) \text{ 中 } 1 \text{ 的个数} - (w_1, \dots, w_N) \text{ 中以 } 1 \text{ 为两端长度为 } k+1 \text{ 的 } 0-1 \text{ 子序列数目}] \} \quad (10.3.15)$$

特别 $k=1$ 时, (10.3.15) 式中方括号内却好是“1”-游程的数目, 所以有

$$\hat{\lambda}_1 = \frac{N - 2(\text{“1”-游程的数目})}{N - 1} \quad (10.3.16)$$

$k=2$ 时,

$$\hat{\lambda}_2 = \frac{N - 2(\text{两端为 } 1 \text{ 而长度不小于 } 2 \text{ 的游程数目} + 1)}{N - 2} \quad (10.3.17)$$

由 (10.2.7) 知 0-1 序列 $w_1, \dots, w_N$ 的样本自相关函数估计

$$\hat{\rho}_k^w = 2 \hat{\lambda}_k - 1 \quad (10.3.18)$$

进而由 (10.2.11) 得原序列 $x_1, \dots, x_N$ 的样本自相关函数估计

$$\hat{\rho}_k^x = \sin \frac{\pi}{2} (2 \hat{\lambda}_k - 1) = \sin \pi \left(\hat{\lambda}_k - \frac{1}{2} \right) \quad (10.3.19)$$

其中 $\hat{\lambda}_k$ 由(10.3.15)算出。

§ 3.2 互相关函数估计

设 $\{Z_t\}$ 为二维零均值平稳序列, 其中 $Z_t = \begin{pmatrix} X_t \\ Y_t \end{pmatrix}$, $\{X_t\}$ 与 $\{Y_t\}$ 的自协方差函数和互协方差函数分别为 $\{\gamma_t^x\}$, $\{\gamma_t^y\}$ 和 $\{\gamma_t^{xy}\}$, 令

$$R_t = \begin{pmatrix} \gamma_t^x & \gamma_t^{xy} \\ \gamma_t^{yx} & \gamma_t^y \end{pmatrix} \quad R_t^* = R_t G_t^{(M)}, \quad t=0, \pm 1, \dots, \quad (10.3.20)$$

类似于§ 3.1 的推导, 可以证明 $\{R_t^*\}$ 也是非负定序列。我们可以构造二维零均值平稳正态序列 $\{Z_t^{(M)}\}$, 其中 $Z_t^{(M)} = \begin{pmatrix} X_t^{(M)} \\ Y_t^{(M)} \end{pmatrix}$, 它的自协方差阵为

$$R_t^{(M)} = R_t^* = R_t G_t^{(M)},$$

$\{Z_t^{(M)}\}$ 是二维 M 独立序列, 且对任意固定 t , 有 $\lim_{M \rightarrow \infty} R_t^{(M)} = R_t$ 。所以对任意 n 及整数 $t_1, \dots, t_n$ 有

$$L(Z_{t_1}^{(M)}, \dots, Z_{t_n}^{(M)}) \xrightarrow{M \rightarrow \infty} L(Z_{t_1}, \dots, Z_{t_n}) \quad (10.3.21)$$

令

$$W_t = \begin{cases} 1, & \text{当 } X_t > 0 \\ 0, & \text{当 } X_t \leq 0, \end{cases} \quad V_t = \begin{cases} 1, & \text{当 } Y_t > 0 \\ 0, & \text{当 } Y_t \leq 0 \end{cases} \quad (10.3.22)$$

$$W_t^{(M)} = \begin{cases} 1, & \text{当 } X_t^{(M)} > 0 \\ 0, & \text{当 } X_t^{(M)} \leq 0, \end{cases} \quad V_t^{(M)} = \begin{cases} 1, & \text{当 } Y_t^{(M)} > 0 \\ 0, & \text{当 } Y_t^{(M)} \leq 0 \end{cases} \quad (10.3.23)$$

由(10.3.21)知, 当 $M \rightarrow \infty$ 有

$$L(W_{t_1}^{(M)}, \dots, W_{t_n}^{(M)}; V_{t_1}^{(M)}, \dots, V_{t_n}^{(M)}) \longrightarrow L(W_{t_1}, \dots, W_{t_n}; V_{t_1}, \dots, V_{t_n}). \quad (10.3.24)$$

设 $x_1, \dots, x_N$ 和 $y_1, \dots, y_N$ 分别为 $\{X_t\}$ 和 $\{Y_t\}$ 的长度为 N 的样本, $w_1, \dots, w_N$ 和 $v_1, \dots, v_N$ 分别为它们相应地经硬判决后所得 0-1 样本, 则由 M 独立性和平稳性知

$$P(W_1^{(M)} = w_1, \dots, W_{k+1}^{(M)} = w_{k+1}; V_1^{(M)} = v_1, \dots, V_{k+1}^{(M)} = v_{k+1}, \dots, W_{L-k}^{(M)} = w_{N-k}, \dots, W_{L+k}^{(M)} = w_N)$$

$$\begin{aligned}
& V_L^{(M)} = v_{N-k}, \dots, V_{L+k}^{(M)} = v_N) \\
& = P(W_1^{(M)} = w_1, \dots, W_{k+1}^{(M)} = w_{k+1}; V_1^{(M)} = v_1, \dots, V_{k+1}^{(M)} = v_{k+1}) \\
& \quad P(W_{k+1+M}^{(M)} = w_2, \dots, W_{2k+1+M}^{(M)} = w_{k+2}; V_{k+1+M}^{(M)} = \\
& \quad v_2, \dots, V_{2k+1+M}^{(M)} = v_{k+2}) \cdots P(W_L^{(M)} = w_{N-k}, \dots, \\
& \quad W_{L+k}^{(M)} = w_N; V_L^{(M)} = v_{N-k}, \dots, V_{L+k}^{(M)} = v_N)
\end{aligned}$$

当 $M \rightarrow \infty$ 时, 上式右端趋于

$$\begin{aligned}
& P(W_1 = w_1, \dots, W_{k+1} = w_{k+1}; V_1 = v_1, \dots, V_{k+1} = v_{k+1}) \\
& P(W_2 = w_2, \dots, W_{k+2} = w_{k+2}; V_2 = v_2, \dots, V_{k+2} = v_{k+2}) \cdots \\
& P(W_{N-k} = w_{N-k}, \dots, W_N = w_N; V_{N-k} = v_{N-k}, \dots, V_N = v_N) \\
& = P(W_1 = w_1) P(V_{k+1} = v_{k+1} | W_1 = w_1) P(W_2 = w_2, \dots, \\
& \quad V_k = v_k | W_1 = w_1, V_{k+1} = v_{k+1}) P(W_2 = w_2) P(V_{k+2} = \\
& \quad v_{k+2} | W_2 = w_2) P(W_3 = w_3, \dots, V_{k+1} = v_{k+1} | W_2 = w_2, \\
& \quad V_{k+2} = v_{k+2}) \cdots P(W_{N-k} = w_{N-k}) P(V_N = v_N | W_{N-k} = \\
& \quad w_{N-k}) P(W_{N-k+1} = w_{N-k+1}, \dots, V_{N-1} = v_{N-1} | \\
& \quad W_{N-k} = w_{N-k}, V_N = v_N) \\
& = \prod_{i=k+1}^N P(W_{i-k} = w_{i-k}) \prod_{i=k+1}^N P(V_i = v_i | W_{i-k} = w_{i-k}) \cdot \\
& \quad \cdot \prod_{i=k+1}^N P(W_{i-k+1} = w_{i-k+1}, \dots, V_{i-1} = v_{i-1} | \\
& \quad W_{i-k} = w_{i-k}, V_i = v_i) \quad (10.3.25)
\end{aligned}$$

令

$$p_k = P(V_i = 1 | W_{i-k} = 1) = P(V_i = 0 | W_{i-k} = 0)$$

$$\text{故 } 1 - p_k = P(V_i = 0 | W_{i-k} = 1) = P(V_i = 1 | W_{i-k} = 0)$$

因此, 有

$$\begin{aligned}
P(V_i = v_i | W_{i-k} = w_{i-k}) &= p_k^{1-v_i-w_{i-k}+2v_iw_{i-k}} \\
&\quad (1-p_k)^{v_i+w_{i-k}-2v_iw_{i-k}}
\end{aligned}$$

从而(10.3.25)式右端为

$$\left(\frac{1}{2}\right)^{N-k} p_k^{N-k - \sum_{i=k+1}^N (v_i + w_{i-k}) + 2 \sum_{i=k+1}^N v_i w_{i-k}}$$

$$\begin{aligned}
 & (1-\nu_k)^{\sum_{i=k+1}^N (v_i + w_{i-k}) - 2 \sum_{i=k+1}^N v_i w_{i-k}} \\
 & \cdot \prod_{i=k+1}^N P(W_{i-k+1}=w_{i-k+1}, \dots, V_{i-1}=v_{i-1} | \\
 & \quad W_{i-k}=w_{i-k}, V_i=v_i) \quad (10.3.26)
 \end{aligned}$$

记(10.3.26)为 $h(w_1, \dots, w_N, v_1, \dots, v_N)$ 得到似然方程为

$$\frac{\partial \log h}{\partial \nu_k} = 0$$

立即可得 ν_k 的渐近极大似然估计为

$$\hat{\nu}_k = \frac{N-k - \sum_{i=k+1}^N (v_i + w_{i-k}) + 2 \sum_{i=k+1}^N v_i w_{i-k}}{N-k}$$

当 N 很大时, 为方便起见, 上式可近似为

$$\hat{\nu}_k = \frac{N - \left(\sum_{i=1}^N w_i + \sum_{i=1}^N v_i - 2 \sum_{i=k+1}^N v_i w_{i-k} \right)}{N-k} \quad (10.3.27)$$

即 $\hat{\nu}_k$ 由二组 0-1 样本列 $w_1, \dots, w_N$ 和 $v_1, \dots, v_N$ 所确定。

$\{V_i\}$ 和 $\{W_i\}$ 的互相关函数为

$$\begin{aligned}
 \rho_k^{vw} &= \frac{E\left(V_i - \frac{1}{2}\right)\left(W_{i-k} - \frac{1}{2}\right)}{\frac{1}{4}} = 4 E V_i W_{i-k} - 1 \\
 &= 4 P(V_i=1, W_{i-k}=1) - 1 \\
 &= 4 P(W_{i-k}=1) P(V_i=1 | W_{i-k}=1) - 1 = 2 \nu_k - 1 \quad (10.3.28)
 \end{aligned}$$

把(10.3.27)代入(10.3.28), 得到 $\{V_i\}$ 和 $\{W_i\}$ 的样本互相关函数估计

$$\hat{\rho}_k^{vw} = 2 \hat{\nu}_k - 1 \quad (10.3.29)$$

再将(10.3.29)代入(10.2.10), 得到 $\{X_i\}$ 和 $\{Y_i\}$ 的样本互相关函数估计

$$\hat{\rho}_k^{rx} = \sin \frac{\pi}{2} (2 \hat{p}_k - 1) = \sin \pi \left(\hat{p}_k - \frac{1}{2} \right) \quad (10.3.30)$$

显然(10.3.30)的计算量很小, 可以快速得到。

§ 4 基于任意水平 u 的 0-1 序列时序分析

前面几节基于 0-1 序列的时序分析都是以均值为水平的。然而实际问题中, 常常选择某一个与问题有关的异于均值的特定值 u 作为硬判决的水平, 如将 50 毫米以上的雨量定为暴雨, 将六级以上地震作为大震, 我们要对暴雨与非暴雨, 大震与非大震这两种状态进行分析。因此, 必须将前几节中的结果推广, 对基于任意水平 u 的 0-1 序列的时序分析进行研究。

引理 设 $(X, Y)^T$ 为二维正态随机向量, $EX = EY = 0$, $\text{Var} X = \text{Var} Y = 1$, $\text{cov}(X, Y) = \rho$, 记

$$f(x, y, \rho) = \frac{1}{2\pi(1-\rho^2)} \exp \left[-\frac{x^2 - 2\rho xy + y^2}{2(1-\rho^2)} \right]$$

则

$$f(x, y, \rho) = \sum_{n=0}^{\infty} \frac{\Phi^{(n+1)}(x) \Phi^{(n+1)}(y)}{n!} \rho^n$$

其中

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt \text{ 为标准正态 } \mathcal{N}(0, 1) \text{ 的分布函数,}$$

$$\Phi'(x) = \Phi^{(1)}(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \Phi_{(x)}^{(n+1)} = \frac{1}{\sqrt{2\pi}} \frac{d^n}{dx^n} e^{-\frac{x^2}{2}}$$

证明 记

$$H_n(x) = (-1)^n e^{\frac{x^2}{2}} \frac{d^n}{dx^n} e^{-\frac{x^2}{2}} \quad (10.4.1)$$

称 $H_n(x)$ 为 n 次埃米特 (Hermite) 多项式。显然 $H_0(x) = 1$, $H_1(x) = x$, $H_2(x) = x^2 - 1, \dots$ 。重复应用分部积分法有

$$\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} H_m(x) H_n(x) e^{-\frac{x^2}{2}} dx = \begin{cases} n!, & \text{当 } m=n \\ 0, & \text{当 } m \neq n \end{cases} \quad (10.4.2)$$

那么 $\left\{ \frac{1}{\sqrt{n!}} H_n(x) \right\}$ 构成了以 $\frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$ 为权的正交多项式序列,

可以证明

$$\sum_{n=0}^{\infty} \frac{H_n(x) H_n(y)}{n!} t^n = \frac{1}{\sqrt{1-t^2}} e^{-\frac{t^2 x^2 + t^2 y^2 - 2txy}{2(1-t^2)}}, |t| < 1 \quad (10.4.3)$$

级数当 $|t| < 1$ 时关于 x, y 一致收敛。由(10.4.1)知

$$\Phi^{(n+1)}(x) = (-1)^n \frac{1}{\sqrt{2\pi}} H_n(x) e^{-\frac{x^2}{2}} \quad (10.4.4)$$

或

$$H_n(x) = (-1)^n \sqrt{2\pi} e^{\frac{x^2}{2}} \Phi^{(n+1)}(x) \quad (10.4.5)$$

将(10.4.5)代入(10.4.3)得

$$\begin{aligned} 2\pi \sum_{n=0}^{\infty} \frac{e^{\frac{x^2+y^2}{2}} \Phi^{(n+1)}(x) \Phi^{(n+1)}(y)}{n!} t^n &= \\ &= \frac{1}{\sqrt{1-t^2}} e^{-\frac{t^2 x^2 + t^2 y^2 - 2txy}{2(1-t^2)}}, |t| < 1 \end{aligned}$$

所以

$$\begin{aligned} \sum_{n=0}^{\infty} \frac{\Phi^{(n+1)}(x) \Phi^{(n+1)}(y)}{n!} t^n &= \\ \frac{1}{2\pi} \frac{1}{\sqrt{1-t^2}} e^{-\frac{t^2 x^2 + t^2 y^2 - 2txy}{2(1-t^2)}} \cdot e^{-\frac{x^2+y^2}{2}} &= \\ = \frac{1}{2\pi \sqrt{1-t^2}} e^{-\frac{x^2 - 2txy + y^2}{2(1-t^2)}}, |t| < 1 \end{aligned} \quad (10.4.6)$$

由条件知 $|\rho| < 1$ 。将 ρ 代入(10.4.6)式得

$$\sum_{n=0}^{\infty} \frac{\Phi^{(n+1)}(x)\Phi^{(n+1)}(y)}{n!} \rho^n = \frac{1}{2\pi\sqrt{1-\rho^2}} e^{-\frac{x^2-2\rho xy+y^2}{2(1-\rho^2)}}, \quad (10.4.7)$$

引理得证。

设 $\{X_i\}$ 为零均值的平稳正态序列, 不失一般性, 假定方差为1, u 为任一实数, 在水平为 u 的硬判决后 0-1 序列记为 $\{W_i\}$, 即

$$W_i = \begin{cases} 1, & \text{当 } X_i > u \\ 0, & \text{当 } X_i \leq u \end{cases}, \quad (10.4.8)$$

定理 设 $\{X_i\}$ 和 $\{W_i\}$ 为上述假定, 记

$p = P(W_i = 1) = P(X_i > u)$, $\rho_k^x = E X_i X_{i-k}$, 则

$$E W_i W_{i-k} = p^2 + \frac{1}{2\pi} \int_0^{\rho_k^x} \frac{1}{\sqrt{1-t^2}} e^{-\frac{u^2}{1+t}} dt \quad (10.4.9)$$

证明 $E W_i W_{i-k} = P(W_i = 1, W_{i-k} = 1) =$

$$= P(X_i > u, X_{i-k} > u)$$

$$= \frac{1}{2\pi} \int_u^\infty \int_u^\infty \frac{1}{\sqrt{1-(\rho_k^x)^2}} e^{-\frac{x^2-2\rho_k^x xy+y^2}{2(1-(\rho_k^x)^2)}} dx dy$$

$$(10.4.10)$$

由(10.4.7)及级数一致收敛性, (10.4.10)式可表为

$$\begin{aligned} E W_i W_{i-k} &= \sum_{n=0}^{\infty} \int_u^\infty \int_u^\infty \frac{\Phi^{(n+1)}(x)\Phi^{(n+1)}(y)}{n!} (\rho_k^x)^n dx dy \\ &= \sum_{n=0}^{\infty} \frac{(\rho_k^x)^n}{n!} \left(\int_u^\infty \Phi^{(n+1)}(x) dx \right)^2 \\ &= \left(\int_u^\infty \Phi^{(1)}(x) dx \right)^2 + \sum_{n=1}^{\infty} \frac{(\rho_k^x)^n}{n!} \left(\int_u^\infty d\Phi^{(n)}(x) \right)^2 \\ &= [P(X_i > u)]^2 + \sum_{n=1}^{\infty} \frac{(\rho_k^x)^n}{n!} (-\Phi^{(n)}(u))^2 \\ &= p^2 + \sum_{n=0}^{\infty} \frac{[\Phi^{(n+1)}(u)]^2}{(n+1)!} (\rho_k^x)^{n+1} \end{aligned} \quad (10.4.11)$$

由引理知

$$\begin{aligned}
 \int_0^{\rho_k^*} f(u, u, t) dt &= \int_0^{\rho_k^*} \sum_{n=0}^{\infty} \frac{[\Phi^{(n+1)}(u)]^2}{n!} t^n dt \\
 &= \sum_{n=0}^{\infty} \frac{[\Phi^{(n+1)}(u)]^2}{n!} \frac{t^{n+1}}{n+1} \Big|_0^{\rho_k^*} = \\
 &= \sum_{n=0}^{\infty} \frac{[\Phi^{(n+1)}(u)]^2}{(n+1)!} (\rho_k^*)^{n+1} \quad (10.4.12)
 \end{aligned}$$

将(10.4.12)代入(10.4.11),由引理知

$$\begin{aligned}
 EW_i W_{i-k} &= p^2 + \int_0^{\rho_k^*} f(u, u, t) dt \\
 &= p^2 + \frac{1}{2\pi} \int_0^{\rho_k^*} \frac{1}{\sqrt{1-t^2}} e^{-\frac{u^2}{1+t}} dt
 \end{aligned}$$

定理证毕。

特别, 当 $u=0$ 时, 此时 $p = P(X_i > 0) = \frac{1}{2}$, 那么(10.4.9)

可表为

$$\begin{aligned}
 EW_i W_{i-k} &= \frac{1}{4} + \frac{1}{2\pi} \int_0^{\rho_k^*} \frac{1}{\sqrt{1-t^2}} dt \\
 &= \frac{1}{4} + \frac{1}{2\pi} \sin^{-1} \rho_k^* \quad (10.4.13)
 \end{aligned}$$

这就是(10.2.8)式。

由 $EW_i = P(W_i = 1) = P(X_i > u) = p$, $EW_i^2 = P(W_i = 1) = p$, 得到

$$\text{var } W_i = p(1-p) \quad (10.4.14)$$

由(10.4.9)和(10.4.14)可得

$$\begin{aligned}
 \rho_k^* &= \frac{E(W_i - p)(W_{i-k} - p)}{\text{var } W_i} = \frac{EW_i W_{i-k} - p^2}{p(1-p)} \\
 &= \frac{1}{2\pi p(1-p)} \int_0^{\rho_k^*} \frac{1}{\sqrt{1-t^2}} e^{-\frac{u^2}{1+t}} dt \quad (10.4.15)
 \end{aligned}$$

在 $u=0$ 时,那么(10.4.15)即为(10.2.10)式,即

$$\rho_k^w = \frac{2}{\pi} \sin^{-1} \rho_k^x.$$

令 $\lambda_k = P(W_t = 1 | W_{t-k} = 1)$, 那么从(10.4.15)的中间等式知

$$\begin{aligned} \lambda_k &= \frac{P(W_t = 1, W_{t-k} = 1)}{P(W_{t-k} = 1)} = \frac{E W_t W_{t-k}}{p} \\ &= \frac{p(1-p)\rho_k^w + p^2}{p} = (1-p)\rho_k^w + p \end{aligned}$$

所以

$$\rho_k^w = \frac{\lambda_k - p}{1-p} \quad (10.4.16)$$

将(10.4.16)代入(10.4.15)左端即可得到

$$p(\lambda_k - p) = \frac{1}{2\pi} \int_0^{\rho_k^x} \frac{1}{\sqrt{1-t^2}} e^{-\frac{u^2}{1+t}} dt \quad (10.4.17)$$

如果 λ_k 可依据硬判决获得的 0-1 数据 $w_1, \dots, w_N$ 来估计, 则由(10.4.17)可由近似积分计算 ρ_k^x 的估计。因此, 对 ρ_k^x 的估计就转化为利用 $w_1, \dots, w_N$ 对 λ_k 的估计。类似于 § 3 的讨论也可得到 M 独立序列 $\{W_t^{(M)}\}$ (以 u 为水平), 当 $M \rightarrow \infty$ 时, 渐近地成立

$$\begin{aligned} P(W_1^{(M)} = w_1, \dots, W_{k+1}^{(M)} = w_{k+1}, \dots, W_L^{(M)} = w_{N-k}, \dots, \\ W_{L+k}^{(M)} = w_N) \end{aligned}$$

$$\sim \prod_{i=k+1}^N P(W_{i-k} = w_{i-k}) \prod_{i=k+1}^N P(W_i = w_i | W_{i-k} = w_{i-k})$$

$$\prod_{i=k+1}^N P(W_{i-1} = w_{i-1}, \dots, W_{i-k+1} = w_{i-k+1} | W_{i-k} = w_{i-k}, W_i = w_i) \quad (10.4.18)$$

由(10.4.14)和 λ_k 的定义知

$$P(W_t = 0) = 1-p, \quad P(W_t = 0 | W_{t-k} = 1) = 1-\lambda_k \quad (10.4.19)$$

由二维联合分布函数公式知

$$P(X_t > u, X_{t-k} > u) = 1 - P(X_t \leq u) - P(X_{t-k} \leq u)$$

$$+ P(X_i \leq u, X_{i-k} \leq u)$$

由此式及(10.4.9)、(10.4.17)得到

$$\begin{aligned} P(W_i = 0 | W_{i-k} = 0) &= \frac{P(W_i = 0, W_{i-k} = 0)}{1-p} \\ &= \frac{P(X_i \leq u, X_{i-k} \leq u)}{1-p} \\ &= \frac{1}{1-p} \left[p^2 + \frac{1}{2\pi} \int_0^{p^2} \frac{1}{\sqrt{1-t^2}} e^{-\frac{u^2}{1+t}} dt + 2(1-p) - 1 \right] \\ &= \frac{1}{1-p} [p^2 + p(\lambda_k - p) + 2(1-p) - 1] = \frac{1-2p+p\lambda_k}{1-p} \\ &= 1 - \frac{p}{1-p}(1-\lambda_k) \end{aligned} \quad (10.4.20)$$

所以

$$P(W_i = 1 | W_{i-k} = 0) = 1 - P(W_i = 0 | W_{i-k} = 0) = \frac{p}{1-p}(1-\lambda_k) \quad (10.4.21)$$

从以上诸式立即得到

$$\begin{aligned} P(W_i = w_i | W_{i-k} = w_{i-k}) &= \lambda_k^{w_i w_{i-k}} (1-\lambda_k)^{(1-w_i)w_{i-k}} \\ &\quad \left[1 - \frac{p}{1-p}(1-\lambda_k) \right]^{w_i(1-w_{i-k})} \\ &\quad \cdot \left[1 - \frac{p}{1-p}(1-\lambda_k) \right]^{(1-w_i)(1-w_{i-k})} \\ &= \left(\frac{p}{1-p} \right)^{w_i(1-w_{i-k})} \lambda_k^{w_i w_{i-k}} (1-\lambda_k)^{w_i + w_{i-k} - 2w_i w_{i-k}} \\ &\quad \left[1 - \frac{p}{1-p}(1-\lambda_k) \right]^{(1-w_i)(1-w_{i-k})} \end{aligned} \quad (10.4.22)$$

又

$$P(W_i = w_i) = p^{w_i} (1-p)^{(1-w_i)} \quad (10.4.23)$$

记 $1-p=q$, $s_1 = \sum_{i=k+1}^N w_i w_{i-k}$, $s_2 = \sum_{i=k+1}^N (w_i + w_{i-k})$, 将(10.4.

22)和(10.4.23)代入(10.4.18)右端经整理后为

$$q^{N-k} \left(\frac{p}{q} \right)^{s_2+s_1} \lambda_k^{s_1} (1-\lambda_k)^{s_2-2s_1} \left[1 - \frac{p}{q} (1-\lambda_k) \right]^{N-k-s_2+s_1} \\ \cdot \prod_{i=k+1}^N P(W_{i-1}=w_{i-1}, \dots, W_{i-k+1}=w_{i-k+1} | \\ W_{i-k}=w_{i-k}, W_i=w_i) \quad (10.4.24)$$

记它为 $\psi(w_1, \dots, w_N)$, 由于 $p=1-\Phi(u)$, 在给定 u 时, 可查 $\mathcal{N}(0,1)$ 分布表得到 p 值, 故把 p 作为已知值, 那么渐近似然方程为

$$0 = \frac{\partial \log \psi}{\partial \lambda_k} = \frac{s_1}{\lambda_k} - \frac{s_2-2s_1}{1-\lambda_k} + \frac{p(N-k-s_2+s_1)}{1-2p+p\lambda_k}$$

经整理后得到 λ_k 的二次方程式

$$(N-k)p\lambda_k^2 - [s_1 - qs_2 + (N-k)p]\lambda_k - (q-p)s_1 = 0 \quad (10.4.25)$$

那么, λ_k 的渐近极大似然估计为

$$\hat{\lambda}_k = \frac{(N-k)p + s_1 - qs_2 \pm \sqrt{[(N-k)p + s_1 - qs_2]^2 + 4(N-k)p(q-p)s_1}}{2(N-k)p} \quad (10.4.26)$$

特别, 当 $u=0$ 时, $p=\frac{1}{2}$, (10.4.26) 与 (10.3.13) 应该一致, 由此得到 (10.4.26) 中应舍去根号前“ $-$ ”号, 即

$$\hat{\lambda}_k = \frac{(N-k)p + s_1 - qs_2 + \Delta}{2(N-k)p} \quad (10.4.27)$$

其中 $\Delta = \sqrt{[(N-k)p + s_1 - qs_2]^2 + 4(N-k)p(q-p)s_1}$

把 (10.4.27) 的 $\hat{\lambda}_k$ 代入 (10.4.17) 的 λ_k , 得到 ρ_k^* 的估计 $\hat{\rho}_k^*$ 应满足

$$\frac{1}{2\pi} \int_0^{\hat{\rho}_k^*} \frac{1}{\sqrt{1-t^2}} e^{-\frac{u^2}{1+t}} dt = p(\hat{\lambda}_k - p) \quad (10.4.28)$$

从而用近似积分求出 $\hat{\rho}_k^*$ 的值。对于任意水平下二维平稳正态序列的互相关函数估计, 也可类似于 § 3.2 的讨论而实现。

§ 5 动态数据建模

利用 § 3 和 § 4 的结果, 可给出线性模型的快速简便的建模方

法。为方便起见,本节的讨论是对均值水平的 0-1 序列来进行的,其结果可以完全平行地用于对任意水平所得的 0-1 序列。

§ 5.1 一维 AR (p) 建模

设动态数据 $x_1, x_2, \dots, x_N$ 取自于零均值平稳正态序列 $\{x_i\}$, 利用 § 3 结果, 可由零水平的硬判决序列来建立原序列的 AR (p) 模型(如果原序列均值非零, 可按第四章给的办法进行预处理后再用 § 3 的结果建模)。

具体步骤如下:

第一步 对 $x_1, x_2, \dots, x_N$ 作硬判决, 得 0-1 序列 $w_1, w_2, \dots, w_N$

$$w_j = \begin{cases} 1 & \text{当 } x_j > 0 \\ 0 & \text{当 } x_j \leq 0 \end{cases} \quad j=1, 2, \dots, N$$

第二步 对 $w_1, \dots, w_N$ 计算

$$m_k = (w_1, \dots, w_N \text{ 中的 } 1 \text{ 的数目}) -$$

($w_1, \dots, w_N$ 中以 1 为两端, 长度为 $k+1$ 的 0-1 子序列数)

并计算
$$\hat{\lambda}_k = \frac{N - 2m_k}{N - k}$$

第三步 计算 $\hat{\rho}_k^* = \sin \pi \left(\hat{\lambda}_k - \frac{1}{2} \right)$, 选择适当的阶数上限 P , 将 $\hat{\rho}_k^*$ 代入 (2.5.3) 式递推计算 $\hat{\phi}_{k1}, \dots, \hat{\phi}_{kk}$

$1 \leq k \leq P$, 即

$$\begin{cases} \hat{\phi}_{1,1} = \sin \pi \left(\hat{\lambda}_1 - \frac{1}{2} \right) \\ \hat{\phi}_{k+1,k+1} = \frac{\sin \pi \left(\hat{\lambda}_{k+1} - \frac{1}{2} \right) - \sum_{j=1}^k \hat{\phi}_{kj} \sin \pi \left(\hat{\lambda}_{k+1-j} - \frac{1}{2} \right)}{1 - \sum_{j=1}^k \hat{\phi}_{kj} \sin \pi \left(\hat{\lambda}_j - \frac{1}{2} \right)} \\ \hat{\phi}_{k+1,j} = \hat{\phi}_{kj} - \hat{\phi}_{k+1,k+1} \hat{\phi}_{k,k+1-j} \end{cases}$$

第四步 递推计算 AR (k) 模型的白噪声方差

$$\hat{\sigma}_a^2(k) = \hat{\gamma}_0^* \left(1 - \sum_{j=1}^k \hat{\phi}_{kj} \hat{\rho}_j^* \right) \quad k=1, 2, \dots, P$$

第五步 由 BIC 准则去确定 AR 模型阶的估计,即

$$\text{BIC}_k(X_t) = N \log \hat{\sigma}_a^2(k) + (k+1) \log N \quad k=1, \dots, P$$

取其最小值相应的 p 作为 AR 模型阶的估计,而相应的 $\hat{\phi}_{p1}, \dots, \hat{\phi}_{pp}$ 即为 AR(p)模型系数的估计, $\hat{\sigma}_a^2(p)$ 为模型白噪声方差的估计。全部建模过程结束。

可以证明,基于均值水平的 0-1 序列所建立的原序列的 AR(p)模型中,其参数估计量具有很好的统计性质,如具有渐近无偏性

$$E\hat{\phi} = \phi + o\left(\frac{1}{N}\right), \text{var}\hat{\phi} = o\left(\frac{1}{N}\right)$$

又 $\hat{\phi}$ 具有渐近正态性,即 $\hat{\phi} \sim \mathcal{N}(\phi, \sigma_a^2(p)/N \cdot \Gamma_p^{-1})$

下面举两个实算的例题:

例 1 设原序列 $\{X_t\}$ 取自模型

$$x_t = 0.75 x_{t-1} + a_t, \quad a_t \sim \mathcal{N}(0, 0.25)$$

由模拟实验所得的 $\{X_t\}$ 的 296 个样本获得相应的零水平硬判决 0-1 序列

```
00100000000000011111111111110000000111111111111111100000
00110110000000101111111111101100000000000011101111111111
10011011111111110011010000000010000000000000111100000000
111111001111111100100011111111000001000000111111101001000
00001101000001111000000000011111111000011111100001011111
1000000111101010
```

它的“1”-游程数为 34, 即 $m_1 = 34$, 因此 $\hat{\lambda}_1 \approx 0.773$, 且 $\rho_1^* = 0.756 \approx 0.75$ 。

例 2 1749~1924 年太阳黑子数 (第三章表 3.1) 样本长为 $N=176$, 样本列为 $z_1, \dots, z_{176}$, 令

$$\bar{z} = \frac{1}{176} \sum_{j=1}^{176} z_j = 44.48 \quad x_j = z_j - \bar{z} \quad j=1, 2, \dots, 176$$

$x_1, x_2, \dots, x_{176}$ 经零水平硬判决后产生的 0-1 序列为

```
1111000001111110000111110000111110000111111100000000101
00000000000100000000001111100011111100000111111100000111
```

11010000111111000000111110000001111000000000111100000011
11000000

其中 1 的个数为 78, 1 的游程数 $m_1=18$

且经计算得

$$\begin{aligned} m_2=30 \quad m_3=45 \quad m_4=58 \quad m_5=63 \quad m_6=61 \\ m_7=53 \quad m_8=43 \quad m_9=32 \quad m_{10}=27 \end{aligned}$$

由

$$\hat{\rho}_k^x = \sin \pi \left(\hat{\lambda}_k - \frac{1}{2} \right), \hat{\lambda}_k = \frac{N-2}{N-k} m_k$$

得

$$\begin{aligned} \hat{\rho}_1^x &= 0.809 & \hat{\rho}_2^x &= 0.500 & \hat{\rho}_3^x &= -0.00908 \\ \hat{\rho}_4^x &= -0.457 & \hat{\rho}_5^x &= -0.607 & \hat{\rho}_6^x &= -0.542 \\ \hat{\rho}_7^x &= -0.267 & \hat{\rho}_8^x &= 0.112 & \hat{\rho}_9^x &= 0.510 \\ \hat{\rho}_{10}^x &= 0.673 \end{aligned}$$

太阳黑子数的原线性模型为 AR(2)

$$x_t = \varphi_{21}x_{t-1} + \varphi_{22}x_{t-2} + a_t$$

其中 $x_t = z_t - \bar{z}$ 。可由 §3 的公式计算参数 φ_{21} 和 φ_{22} 的估计值:

$$\hat{\varphi}_{22} = \frac{\sin \pi \left(\hat{\lambda}_2 - \frac{1}{2} \right) - \sin^2 \pi \left(\hat{\lambda}_1 - \frac{1}{2} \right)}{\sin^2 \pi \hat{\lambda}_1}$$

$$\hat{\varphi}_{21} = (1 - \hat{\varphi}_{22}) \sin \pi \left(\hat{\lambda}_1 - \frac{1}{2} \right)$$

其中

$$\hat{\lambda}_k = \frac{N-2}{N-k} \hat{m}_k$$

$\hat{m}_1 = (\{x_1, \dots, x_N\} \text{ 中的“1”-游程数})$

$\hat{m}_2 = 1 + (\{x_1, \dots, x_N\} \text{ 中两端为 1 中间长度不小于 2 的游程数})$

经计算得

$$\hat{\varphi}_{22} = -0.447 \quad \hat{\varphi}_{21} = 1.171 \quad \hat{\sigma}_a^2(2) = 331.42$$

结果与第五章 §2.4 相近, 可以想见, 若样本长度 N 取得更大一些, 可望得到更接近于原序列所估计出的参数值。

由前面的一系列讨论,不难得出以下几点认识:

1. 某些实际问题往往得不到原序列本身的样本列 $x_1, x_2, \dots, x_N$, 而仅可得知其以某值为水平的两种状态间的变化序列 $w_1, w_2, \dots, w_N$. 利用 $\hat{\rho}_k^x$ 与 $\hat{\rho}_k^w$ 间的关系, 由本节可建立原序列的 AR(p) 模型 $x_t = \sum_{j=1}^p \varphi_{pj} x_{t-j} + a_t$, 这对于了解原实际问题的随机变化规律, 常常提供方便。

2. 基于 0-1 序列而对原序列建立时序模型, 可以避免数据量测不准所带来的技术性误差, 增强所建模型的稳健性(原序列在状态范围内的变化并不影响硬判决的结果)。

3. 由 $\hat{\rho}_k^w = \frac{2}{\pi} \sin^{-1} \hat{\rho}_k^x$ 可见, $|\hat{\rho}_k^w| \leq |\hat{\rho}_k^x|$, 即 0-1 序列的相关性比原序列的相关性有所减弱。这一结果和直观是相一致的。由此看到, 这种简便算法对于模型精度会产生一些影响。然而经验表明, 如果将 0-1 序列样本长度取为 $2N$, 就能与长为 N 的原序列所建的模型精度一致。

§ 5.2 多维 AR 建模

设 K 维 AR(p) 模型为

$$\mathbf{X}_t = \sum_{i=1}^p A_i \mathbf{X}_{t-i} + \mathbf{u}_t, \text{ 其中 } \mathbf{X}_t = \begin{pmatrix} X_t^{(1)} \\ \vdots \\ X_t^{(k)} \end{pmatrix}$$

$x_1, x_2, \dots, x_N$ 是长度为 N 的 k 维样本。其经硬判决所得的 k 维 0-1 序列为 $w_1, \dots, w_N, w_t = (w_t^{(1)}, \dots, w_t^{(k)})^T$,

$$w_t^{(i)} = \begin{cases} 1 & \text{当 } x_t^{(i)} > 0 \\ 0 & \text{当 } x_t^{(i)} \leq 0 \end{cases} \quad i=1, 2, \dots, k$$

由第八章知, 模型系数矩阵可从递推公式(8.3.4)得到, 其中

$$\hat{\mathbf{p}}_k(x) = \begin{pmatrix} \hat{p}_k^{(1)}(x) & \hat{p}_k^{(1,2)}(x) & \dots & \hat{p}_k^{(1,k)}(x) \\ \dots & \dots & \dots & \dots \\ \hat{p}_k^{(k,1)}(x) & \hat{p}_k^{(k,2)}(x) & \dots & \hat{p}_k^{(k,k)}(x) \end{pmatrix}$$

$$\hat{p}_k^{(i)}(x) = \hat{p}_0^{(i)}(x) \sin \pi \left(\hat{\lambda}_k^{(i)} - \frac{1}{2} \right)$$

$$\hat{p}_k^{(i,j)}(x) = \hat{p}_0^{(i)}(x) \hat{p}_0^{(j)}(x) \sin \pi \left(\hat{p}_k^{(i,j)} - \frac{1}{2} \right)$$

$$\hat{\lambda}_k^{(i)} = \frac{N-2}{N-h} m_k^{(i)}$$

$$\hat{p}_k^{(i,j)} = \frac{N - \left(\sum_{i=1}^N w_i^{(i)} + \sum_{j=1}^N w_i^{(j)} - 2 \sum_{i=h+1}^N w_i^{(i)} w_{i-h}^{(j)} \right)}{N-h}$$

$$i, j = 1, 2, \dots, k$$

$$m_k^{(i)} = (\text{在 } w_1^{(i)}, \dots, w_N^{(i)} \text{ 中“1”的数目}) - (\text{在 } w_1^{(i)}, \dots, w_N^{(i)} \text{ 中以“1”为两端, 长度为 } h+1 \text{ 的 } 0-1 \text{ 子序列的数目})$$

式中 $\hat{p}_0^{(i)}(x)$ 可由样本算出:

$$\hat{p}_0^{(i)}(x) = \frac{1}{N} \sum_{i=1}^N x_i^{(i)}$$

利用以上结果, 由(8.3.4)可得到 $\hat{A}_{k1}, \dots, \hat{A}_{kk}$ 。再由递推公式(8.3.11)可得到 $\hat{S}_k$, 从而由 BIC 准则可确定模型阶的估计值

$$\text{BIC}_k(X_i) = N \log |\hat{S}_k| + \left(h k^2 + \frac{k(k+1)}{2} \right) \log N$$

对于 $h=1, 2, \dots, H$ 计算以上 $\text{BIC}_k(X_i)$ 的值, 使其值达最小的相应的 h_0 值, 即为所求的阶数估计值。由上可见, 对原序列各分量的互协方差函数的估计, 可化为相应硬判决的 0-1 序列之间相关函数的估计。这样可大大减少计算量, 使许多实际问题, 例如在线控制问题得以实现。

§ 5.3 一维 ARMA 建模

根据第三章 § 5.4 给出的长自回归白噪声建模方法, 利用 (10.2.10), (10.2.11), (10.2.4), (10.2.7) 等公式类似于 § 4.1 的讨论, 我们也可基于 0-1 序列 (以均值为水平) 建立原序列的 ARMA(p, q) 模型。

具体步骤如下:

第一步 用 § 4.1 的方法, 基于对样本作零判决所得的 0-1

序列, 建立长自回归模型 $AR(p_N)$ 。其自回归参数估计值为

$$\hat{\alpha} = (\hat{\alpha}_1, \dots, \hat{\alpha}_{p_N})^T = \hat{\Gamma}_{p_N}^{-1(x)} \hat{\eta}_{p_N}^{(x)}$$

其中

$$\hat{\Gamma}_{p_N}^{(x)} = \begin{pmatrix} \hat{\gamma}_0^{(x)} & \hat{\gamma}_{p_N-1}^{(x)} \\ & \ddots \\ & \ddots & \ddots \\ \hat{\gamma}_{p_N-1}^{(x)} & \hat{\gamma}_0^{(x)} \end{pmatrix} \quad \eta_{p_N}^{(x)} = \begin{pmatrix} \hat{\gamma}_1^{(x)} \\ \vdots \\ \hat{\gamma}_{p_N}^{(x)} \end{pmatrix}$$

模型白噪声方差的估计量为

$$\hat{\sigma}_{p_N}^2 = \hat{\gamma}_0^{(x)} - \hat{\eta}_{p_N}^{(x)T} \hat{\Gamma}_{p_N}^{-1(x)} \hat{\eta}_{p_N}^{(x)}$$

第二步 应用第一步所得的 $\hat{\alpha}$ 及样本值 $x_1, \dots, x_N$ 计算

$$\hat{\alpha}_i = x_i - \sum_{j=1}^{p_N} \hat{\alpha}_j x_{i-j}, \quad j=1, 2, \dots, N$$

其中 $x_t = 0, t \leq 0$ 。将 $\hat{\alpha}_1, \dots, \hat{\alpha}_N$ 经硬判决后得到的 0-1 序列记为 $v_1, \dots, v_N$ 。

第三步 极小化平方和值, 当 N 很大时, 得 $ARMA(p, q)$ 的参数估计值

$$\hat{\beta} = \begin{pmatrix} \hat{\phi} \\ \hat{\theta} \end{pmatrix} = \begin{pmatrix} \hat{\Gamma}_{pp}^x & \hat{\Gamma}_{pq}^{xa} \\ \hat{\Gamma}_{qp}^{ax} & \hat{\Gamma}_{qq}^{aa} \end{pmatrix}^{-1} \begin{pmatrix} \hat{\eta}_p^x \\ \hat{\eta}_q^{xa} \end{pmatrix}$$

$$\hat{\sigma}_{pq}^2 = \hat{\gamma}_0^x - \hat{\beta}^T \begin{pmatrix} \hat{\eta}_p^x \\ \hat{\eta}_q^{xa} \end{pmatrix}$$

其中

$$\begin{aligned} \hat{\Gamma}_{pp}^x &= (\hat{\gamma}_{j-k}^x) & \hat{\Gamma}_{qq}^{aa} &= (\hat{\gamma}_{j-k}^a) & \hat{\Gamma}_{pq}^{xa} &= (\hat{\gamma}_{j-k}^{xa}) \\ 1 \leq j, k \leq p & & 1 \leq j, k \leq q & & 1 \leq j \leq p, 1 \leq k \leq q \\ \hat{\eta}_p^x &= (\hat{\gamma}_1^x, \dots, \hat{\gamma}_p^x)^T & \eta_q^{xa} &= (\hat{\gamma}_1^{xa}, \dots, \hat{\gamma}_q^{xa}) \\ \hat{\gamma}_l^x &= \hat{\gamma}_0^x \sin \pi \left(\hat{\lambda}_l^{(w)} - \frac{1}{2} \right) & \hat{\gamma}_l^a &= \hat{\gamma}_0^a \sin \pi \left(\hat{\mu}_l^{(v)} - \frac{1}{2} \right) \\ \hat{\gamma}_l^{xa} &= \sqrt{\hat{\gamma}_0^x \hat{\gamma}_0^a} \sin \pi \left(\hat{\nu}_l^{(wv)} - \frac{1}{2} \right) \end{aligned}$$

这里

$$\begin{aligned}\hat{\gamma}_0^x &= \frac{1}{N} \sum_{i=1}^N x_i^2 & \hat{\gamma}_0^y &= \frac{1}{N} \sum_{i=1}^N \hat{a}_i^2 \\ \hat{\lambda}_l^{(w)} &= \frac{N-2}{N-l} m_l^{(w)} & \hat{\mu}_l^{(v)} &= \frac{N-2}{N-l} m_l^{(v)} \\ \hat{\gamma}_l^{(wv)} &= \frac{N - \left(\sum_{i=1}^N w_i + \sum_{i=1}^N v_i - 2 \sum_{i=l+1}^N w_i v_{i-l} \right)}{N-l}\end{aligned}$$

$m_l^{(w)} = (w_1, \dots, w_N$ 中的 1 的数目) - $(w_1, \dots, w_N$ 中以 1 为两端, 长度为 $l+1$ 的 0-1 子序列的数目), 相应地有 $m_l^{(v)}$ 。

第四步 在适当阶数范围内 (如 $0 \leq p \leq p_N$, $0 \leq q \leq q_N$) 由 $\text{BIC}_{p,q}(X_i) = N \log \hat{\sigma}_{p,q}^2 + (p+q+1) \log N$ 达最小来选择 $\hat{p}$, $\hat{q}$, 作为 ARMA 模型的阶的估计值, 相应的 $\hat{\phi}$, $\hat{\theta}$ 和 $\hat{\sigma}_{\hat{p},\hat{q}}^2$ 可作为参数 $\varphi, \theta, \sigma_{p,q}^2$ 的估计。

由上可见, 对于动态数据 $x_1, \dots, x_N$, 基于两组 0-1 序列 $w_1, \dots, w_N$ 和 $v_1, \dots, v_N$, 可较快地建立 ARMA(p, q) 模型。

§ 6 预 报

由于本章给出的建模方法, 都是基于 0-1 序列来对原序列建模。因此, 若要从原始数据出发, 对动态数据序列本身作预报, 则可依本书第七章所给的方法来实现。本节仅就 0-1 状态的预报作些简单的讨论。

设硬判决后得到 0-1 序列为 $w_1, \dots, w_N$, 经计算得 0-1 序列自相关函数估计值为 $\hat{\rho}_l^w$, 可以证明, 一个平稳序列可以由一个 l 阶马氏链充分逼近, 这里 l 为正整数, 可通过类似于第三章所给的方法来寻求 (相当于用 Y-W 估计定 AR 的阶)。

根据上述原理, 我们可以给出一种对于 0-1 序列进行一步预报的方法。

考察 0-1 序列 $w_1, w_2, \dots, w_N$ 中长为 $l+1$ 的子序列 $\{w_1, \dots, w_l, w_{l+1}\}; \{w_2, \dots, w_{l+1}, w_{l+2}\}; \dots; \{w_{N-l}, \dots, w_{N-1}, w_N\}$ 。

将这 $N-l$ 个子序列的前 l 个数与 $\{w_{N-l+1}, \dots, w_N\}$ 作比较, 计算其中与 $\{w_{N-l+1}, \dots, w_N\}$ 相同的子序列的个数, 将其记为 N_l 。

这 N_l 个前 l 个数与 $\{w_{N-l+1}, \dots, w_N\}$ 全同的子序列中, 最后一个数为 1 的子序列个数记为 N_1 , 最后一个数为 0 的子序列个数记为 N_0 。

当 N 充分大时, 以下两个条件概率可由其频率来近似

$$P(W_{N+1}=1 | W_{N-l}=w_{N-l}, \dots, W_N=w_N) \approx \frac{N_1}{N_l}$$

$$P(W_{N+1}=0 | W_{N-l}=w_{N-l}, \dots, W_N=w_N) \approx \frac{N_0}{N_l}$$

由此, 得出 0-1 序列的一步预报如下:

$$\begin{aligned} \text{若} \quad \frac{N_1}{N_l} &> \frac{N_0}{N_l} & \hat{W}_{N+1} &= 1 \\ \frac{N_1}{N_l} &< \frac{N_0}{N_l} & \hat{W}_{N+1} &= 0 \\ \frac{N_1}{N_l} &= \frac{N_0}{N_l} & & \text{不可预报} \end{aligned}$$

以上原则也可用于多步预报。

例 由 1749~1924 年太阳黑子数 (表 3.1) 的 0-1 序列 (§ 5 例 2) 作一步预报。

由 § 5.1 知, $l=2$

长为 3 的子序列个数为 $176-2=174$;

$$111; 111; 110; \dots, 000; 000。$$

这 174 个子序列中, 前两位等于“00”的子序列个数是 $N_l=81$ 。

其中第三个数为 1 的子序列个数 $N_1=15$, 第三个数为 0 的子序列个数 $N_0=65$

因 $N_0 > N_1$, 故第 $N+1$ 步预报值 $\hat{W}_{N+1}$

$=0$, 而 1925 年太阳黑子数的实况为 44.3, 应为 0, 预报和实况一致。

附表 F 分布表 (1)

 $\alpha=0.10$

$f_1 \backslash f_2$	1	2	3	4	5	6	8	12	24	∞
1	39.86	19.50	53.59	55.83	57.24	58.20	59.44	60.70	62.00	63.33
2	8.53	9.00	9.16	9.24	9.29	9.33	9.37	9.41	9.45	9.49
3	5.54	5.46	5.39	5.34	5.31	5.28	5.25	5.22	5.18	5.13
4	4.54	4.32	4.19	4.11	4.05	4.01	3.95	3.90	3.83	3.76
5	4.06	3.78	3.62	3.52	3.45	3.40	3.34	3.27	3.19	3.10
6	3.78	3.46	3.29	3.18	3.11	3.05	2.98	2.90	2.82	2.72
7	3.59	3.26	3.07	2.96	2.88	2.83	2.75	2.67	2.58	2.47
8	3.46	3.11	2.92	2.81	2.73	2.67	2.59	2.50	2.40	2.29
9	3.36	3.01	2.81	2.69	2.61	2.55	2.47	2.38	2.28	2.16
10	3.28	2.92	2.73	2.61	2.52	2.46	2.38	2.28	2.18	2.06
11	3.23	2.86	2.66	2.54	2.45	2.39	2.30	2.21	2.10	1.97
12	3.18	2.81	2.61	2.48	2.39	2.33	2.24	2.15	2.04	1.90
13	3.14	2.76	2.56	2.43	2.35	2.28	2.20	2.10	1.98	1.85
14	3.10	2.73	2.52	2.39	2.31	2.24	2.15	2.05	1.94	1.80
15	3.07	2.70	2.49	2.36	2.27	2.21	2.12	2.02	1.90	1.76
16	3.05	2.67	2.46	2.33	2.24	2.18	2.09	1.99	1.87	1.72
17	3.03	2.64	2.44	2.31	2.22	2.15	2.06	1.96	1.84	1.69
18	3.01	2.62	2.42	2.29	2.20	2.13	2.04	1.93	1.81	1.66
19	2.99	2.61	2.40	2.27	2.18	2.11	2.02	1.91	1.79	1.63
20	2.97	2.59	2.38	2.25	2.16	2.09	2.00	1.89	1.77	1.61
21	2.96	2.57	2.36	2.23	2.14	2.08	1.98	1.88	1.75	1.59
22	2.95	2.56	2.35	2.22	2.13	2.06	1.97	1.86	1.73	1.57
23	2.94	2.55	2.34	2.21	2.11	2.05	1.95	1.84	1.72	1.55
24	2.93	2.54	2.33	2.19	2.10	2.04	1.94	1.83	1.70	1.53
25	2.92	2.53	2.32	2.18	2.09	2.02	1.93	1.82	1.69	1.52
26	2.91	2.52	2.31	2.17	2.08	2.01	1.92	1.81	1.68	1.50
27	2.90	2.51	2.30	2.17	2.07	2.00	1.91	1.80	1.67	1.49
28	2.89	2.50	2.29	2.16	2.06	2.00	1.90	1.79	1.66	1.48
29	2.89	2.50	2.28	2.15	2.06	1.99	1.89	1.78	1.65	1.47
30	2.88	2.49	2.28	2.14	2.05	1.98	1.88	1.77	1.64	1.46
40	2.84	2.44	2.23	2.09	2.00	1.93	1.83	1.71	1.57	1.38
60	2.79	2.39	2.18	2.04	1.95	1.87	1.77	1.66	1.51	1.29
120	2.75	2.35	2.13	1.99	1.90	1.82	1.72	1.60	1.45	1.19
∞	2.71	2.30	2.08	1.94	1.85	1.77	1.67	1.55	1.38	1.00

附表 F 分布表 (2)

 $\alpha=0.05$

$f_1 \backslash f_2$	1	2	3	4	5	6	8	12	24	∞
1	161.4	199.5	215.7	224.6	230.2	234.0	238.9	243.9	249.0	254.3
2	18.51	19.00	19.16	19.25	19.30	19.33	19.37	19.41	19.45	19.50
3	10.13	9.55	9.28	9.12	9.01	8.94	8.84	8.74	8.64	8.53
4	7.71	6.94	6.59	6.39	6.26	6.16	6.04	5.91	5.77	5.63
5	6.61	5.79	5.41	5.19	5.05	4.95	4.82	4.68	4.53	4.36
6	5.99	5.14	4.76	4.53	4.39	4.28	4.15	4.00	3.81	3.67
7	5.59	4.74	4.35	4.12	3.97	3.87	3.73	3.57	3.41	3.23
8	5.32	4.46	4.07	3.84	3.69	3.58	3.44	3.28	3.12	2.93
9	5.12	4.26	3.86	3.63	3.48	3.37	3.23	3.07	2.90	2.71
10	4.96	4.10	3.71	3.48	3.33	3.22	3.07	2.91	2.74	2.54
11	4.84	3.98	3.59	3.36	3.20	3.09	2.95	2.79	2.61	2.40
12	4.75	3.88	3.49	3.26	3.11	3.00	2.85	2.69	2.50	2.30
13	4.67	3.80	3.41	3.18	3.02	2.92	2.77	2.60	2.42	2.21
14	4.60	3.74	3.34	3.11	2.96	2.85	2.70	2.53	2.35	2.13
15	4.54	3.68	3.29	3.06	2.90	2.79	2.64	2.48	2.29	2.07
16	4.49	3.63	3.24	3.01	2.85	2.74	2.59	2.42	2.24	2.01
17	4.45	3.59	3.20	2.96	2.81	2.70	2.55	2.38	2.19	1.96
18	4.41	3.55	3.16	2.93	2.77	2.66	2.51	2.34	2.15	1.92
19	4.38	3.52	3.13	2.90	2.74	2.63	2.48	2.31	2.11	1.88
20	4.35	3.49	3.10	2.87	2.71	2.60	2.45	2.28	2.08	1.84
21	4.32	3.47	3.07	2.84	2.68	2.57	2.42	2.25	2.05	1.81
22	4.30	3.44	3.05	2.82	2.66	2.55	2.40	2.23	2.03	1.78
23	4.28	3.42	3.03	2.80	2.64	2.53	2.38	2.20	2.00	1.76
24	4.26	3.40	3.01	2.78	2.62	2.51	2.36	2.18	1.98	1.73
25	4.24	3.38	2.99	2.76	2.60	2.49	2.34	2.16	1.96	1.71
26	4.22	3.37	2.98	2.74	2.59	2.47	2.32	2.15	1.95	1.69
27	4.21	3.35	2.96	2.73	2.57	2.46	2.30	2.13	1.93	1.67
28	4.20	3.34	2.95	2.71	2.56	2.44	2.29	2.12	1.91	1.65
29	4.18	3.33	2.93	2.70	2.54	2.43	2.28	2.10	1.90	1.64
30	4.17	3.32	2.92	2.69	2.53	2.42	2.27	2.09	1.89	1.62
40	4.08	3.23	2.84	2.61	2.45	2.34	2.18	2.00	1.79	1.51
60	4.00	3.15	2.76	2.52	2.37	2.25	2.10	1.92	1.70	1.39
120	3.92	3.07	2.68	2.45	2.29	2.17	2.02	1.83	1.61	1.25
∞	3.84	2.99	2.60	2.37	2.21	2.10	1.94	1.75	1.52	1.00

附表 F 分布表 (3)

$\alpha=0.01$

$f_1 \backslash f_2$	1	2	3	4	5	6	8	12	24	∞
1	4052	4999	5403	5625	5764	5859	5982	6106	6234	6366
2	98.50	99.00	99.17	99.25	99.30	99.33	99.37	99.42	99.46	99.50
3	34.12	30.82	29.46	28.71	28.24	27.91	27.49	27.05	26.60	26.12
4	21.20	18.00	16.69	15.98	15.52	15.21	14.80	14.37	13.93	13.46
5	16.26	13.27	12.06	11.39	10.97	10.67	10.29	9.89	9.47	9.02
6	13.74	10.92	9.78	9.16	8.75	8.47	8.10	7.72	7.31	6.88
7	12.25	9.55	8.45	7.85	7.46	7.19	6.84	6.47	6.07	5.65
8	11.26	8.65	7.59	7.01	6.63	6.37	6.03	5.67	5.28	4.86
9	10.56	8.02	6.99	6.42	6.06	5.80	5.47	5.11	4.73	4.31
10	10.04	7.56	6.55	5.99	5.64	5.39	5.06	4.71	4.33	3.91
11	9.65	7.20	6.22	5.67	5.32	5.07	4.74	4.40	4.02	3.60
12	9.33	6.93	5.95	5.41	5.06	4.82	4.50	4.16	3.78	3.36
13	9.07	6.70	5.74	5.20	4.86	4.62	4.30	3.96	3.59	3.16
14	8.86	6.51	5.56	5.03	4.69	4.46	4.14	3.80	3.43	3.00
15	8.68	6.36	5.42	4.89	4.56	4.32	4.00	3.67	3.29	2.87
16	8.53	6.23	5.29	4.77	4.44	4.20	3.89	3.55	3.18	2.75
17	8.40	6.11	5.18	4.67	4.34	4.10	3.79	3.45	3.08	2.65
18	8.28	6.01	5.09	4.58	4.25	4.01	3.71	3.37	3.00	2.57
19	8.18	5.93	5.01	4.50	4.17	3.94	3.63	3.30	2.92	2.49
20	8.10	5.85	4.94	4.43	4.10	3.87	3.56	3.23	2.86	2.42
21	8.02	5.78	4.87	4.37	4.04	3.81	3.51	3.17	2.80	2.36
22	7.94	5.72	4.82	4.31	3.99	3.76	3.45	3.12	2.75	2.31
23	7.88	5.66	4.76	4.26	3.94	3.71	3.41	3.07	2.70	2.26
24	7.82	5.61	4.72	4.22	3.90	3.67	3.36	3.03	2.66	2.21
25	7.77	5.57	4.68	4.18	3.86	3.63	3.32	2.99	2.62	2.17
26	7.72	5.53	4.64	4.14	3.82	3.59	3.29	2.96	2.58	2.13
27	7.68	5.49	4.60	4.11	3.78	3.56	3.26	2.93	2.55	2.10
28	7.64	5.45	4.57	4.07	3.75	3.53	3.23	2.90	2.52	2.06
29	7.60	5.42	4.54	4.04	3.73	3.50	3.20	2.87	2.49	2.03
30	7.56	5.39	4.51	4.02	3.70	3.47	3.17	2.84	2.47	2.01
40	7.31	5.18	4.31	3.83	3.51	3.29	2.99	2.66	2.29	1.80
60	7.08	4.98	4.13	3.65	3.34	3.12	2.82	2.50	2.12	1.60
120	6.85	4.79	3.95	3.48	3.17	2.96	2.66	2.34	1.95	1.38
∞	6.64	4.60	3.78	3.32	3.02	2.80	2.51	2.18	1.79	1.00

参 考 文 献

- [1] H. Cramer, *Mathematical Methods of Statistics*. Princeton University Press, Princeton, N. J. 1946.
- [2] 复旦大学数学系, 概率论与数理统计, 上海科技出版社, 第二版, 1961.
- [3] G. E. P. Box and G. M. Jenkins, *Time Series Analysis; Forecasting and Control*. Halden-Day San Francisco, 1970.
- [4] S. M. Pandit and S. M. Wu, *Time Series and System Analysis with Applications*. John Wiley, 1983.
- [5] 安鸿志、陈兆国、杜金观、潘一民编著, 时间序列分析及其应用, 科学出版社, 1983.
- [6] 中国科学院数学研究所概率组编著, 离散时间系统滤波的数学方法, 国防出版社, 1975.
- [7] 南京大学数学系计算数学专业组编著, 最优化方法, 科学出版社, 1978.
- [8] 华罗庚, 华罗庚科普著作选集, 上海教育出版社, 1984.
- [9] 潘一民, 一类统计量的递推算法, 应用数学学报, 第4卷, 第2期, 191—195, 1981.
- [10] 吴方, 关于 Powell 方法的一个注, 数学学报, 第20卷, 第1期, 14—15, 1977.
- [11] 曹鸿兴、罗乔林, 气象历史序列的最大熵谱分析, 科学通报, 第8期, 351—355, 1979.
- [12] 郑大伟、赵铭, 自回归谱技术用于天文和地球动力学, 天文学报, 第20卷, 第3期, 301—307, 1979.
- [13] 郑大伟、黄惠玉、廖德春、罗时芳, 用 AR 序列改进世界时服务, 天文学报, 第21卷, 第2期, 122—129, 1980.
- [14] An. H-Z, Chen. Z-G. and E. J. Hannan, Autocorrelation, Autoregression and Autoregressive Approximation. *Ann. Statist.*, 10(3), 926—936, 1982.
- [15] H. Akaike, AR Model Fitting for Control. *Ann. Inst. Statist. Math.*, 23, 163—180, 1971.
- [16] H. Akaike, Information Theory and an Extension of the Maximum Likelihood Principle. In: 2nd International Symposium on Information theory. B. N. Petrov and F. Csaki (Ed.), Budapest, Akademiai Kiado, 261—281, 1973.
- [17] T. Ozaki, On the Order Determination of ARIMA Models. *Appl. Statist.*, 26(3), 290—301, 1977.
- [18] Chan C-W, C. J. Harris and P. E. Wellstead, An Order Testing Criterion for Mixed Autoregressive Moving Average Processes. *International Journal of control*, 20(5), 817—834, 1974.
- [19] R. Shibata, Selection of the Order of an Autoregression Model by Akaike's Information Criterion. *Biometrika*, 63, 117—126, 1976.
- [20] H. Wenjie et al, ARIMA Seasonal Model of Time Series and its

Application to Long Range Weather Forecasting. The collection of papers presented at the WMO Symposium on probabilistic and statistical methods in weather forecasting, Nice.

- [21] 黄文杰、曹鸿兴、顾岚、项静恬, 时间序列的 ARIMA 季节模型在长期预报中的应用, 科学通报, 第 25 卷 第 22 期, 1030—1032, 1980。
- [22] 杜金观, 潘一民, 协方差可分离随机序列的新息与滤波, 数学学报, 第 20 卷, 第 1 期, 16—27, 1977。
- [23] 杜金观、项静恬, 随机序列的适时预报方法——新息预报方法, 数学的实践与认识, 第 1 期, 1981。
- [24] 徐立子、杜金观、项静恬、顾岚, 随机序列的新息方法在电力系统负荷预报中的应用, 科学通报, 第 25 卷, 第 22 期, 1036—1038, 1980。
- [25] J. A. Edward and M. M. Fithlson, Notes on Maximum-Entropy Processing. IEEE Transaction on Information Theory -19, No.2, 232—233, 1973.
- [26] M. M. Ali, Analysis of Autoregressive Moving Average Models, Estimation and Prediction. Biometrika, 64(3), 535—545, 1977.
- [27] G. Kitagawa and H. Akaike, A Procedure for the Modeling of Non-stationary Time Series. Ann. Inst. Statist. Math., 30 Part B. 351—363, 1978.
- [28] D. J. Krause and D. Granpe, Identification of Autoregressive Moving-Average Predictor Models. In: Proceedings Second Symposium on Nonlinear Estimation Theory and its Applications, 1972.
- [29] B. J. Bhansali and D. Y. Downham, Some Properties of the order of an Autoregressive Model Selected by a Generalization of Akaike's FPE Criterion. Biometrika, 64(3), 547—551 1977.
- [30] P. Newbold, The Exact Likelihood Function for a Mixed Autoregressive-Moving Average Process. Biometrika, 61, 423—426, 1974.
- [31] H. B. Munn and A. Wold, On the Statistical Treatment of Linear Stochastic Difference Equations, Econometrica. 11(3)&(4), 173—220, 1943.
- [32] E. J., Hannan, Multiple Time Series. New York and London, Wiley 1970.
- [33] W. Dunsmuir and E. J. Hannan, Vector Linear Time Series Models.. Adv. Appl. Prob. 8 339—364, 1976.
- [34] H., Tong "On a Threshold Model" in "Pattern Recognition and Signal Processing, NATO ASI Series E: Applied SC. No. 29, ed. C. H. Chen. The Netherland: Sijthoff & Noordhoff 1978.
- [35] H. Tong and K. S. Lim, Threshold Autoregression, Limit Cycles and Cyclical Data. J. Roy. Statist. Soc. (B), 42(3), 245—292, 1980.
- [36] T., Ozaki Non-Linear Models for Non-Linear Random Vibrations. Department of Mathematics, UMIST Technical Report No. 92, 1978.
- [37] V. Haggan and T. Ozaki, Modeling Non-Linear vibrations using an Amplitude-Dependent Autoregressive Time Series Model. Biometrika. 68(1), 189—196, 1981.
- [38] C. W. J. Granger and A. P. Andersen, An Introduction to Bilinear

Time Series Models, Vandenhoeck and Ruprecht: Gottingen. 1978.

- [39] T. Subba Rao, On the Theory of Bilinear Models Department of Mathematics, UMIST Technical Report, No. 87, 1978.
- [40] M. B. Priestley, State-Dependent Models: A General Approach to Non-linear Time Series Analysis. J. Time Series Analysis, 1(1), 47—71, 1980.
- [41] M. M. Gabr and T. Subba Rao, The Estimation and Prediction of Subset Bilinear Time Series Models With Applications. J. Time Series Analysis, 2, 155—171, 1981.
- [42] M. Rosenblatt, Conditional Probability Density and Regression Estimations, Multivariate Analysis. Academic Press, Inc. New York, 2, 1969.
- [43] T. Subba Rao and M. M. Gabr, A Test for Linearity of Stationary Time Series. J. Time Series Analysis, 1(2), 1980.
- [44] 安鸿志、顾岚编著, 统计模型与预报方法, 气象出版社, 1986。
- [45] Benjamin Kedem, Binary Time Series, Marcel Dekker Inc., 1980.
- [46] 王文玉、杜金观、项静恬, 门限自回归滑动平均模型——TARMA, 计算数学, 第4期, 1984。
- [47] 项静恬、杜金观、王文玉, 间时序列非线性门限模型, 数学的实践与认识, 第二期, 1985。

后 记

我们编写这本书的目的是为了向广大科研人员、工程技术人员和高等院校师生介绍这门应用数学的分支，希望更多的读者能应用这一工具来为我国的四个现代化建设服务。

在本书编印期间，时间序列及动态数据处理的理论和应用方面都在迅速发展，并已深入到各有关学科中。对于新的理论和应用方面，本书已概括了其中的很大部分，尚有一部分我们在书末以参考文献的形式提供给读者，另一部分请参阅气象出版社即将出版的新书——统计模型与预报方法。

为了便于读者使用，本书所涉及的动态数据处理方法的有关计算程序，不久我们也将以附册的形式提供给读者。