

0211.61-43
W39



普通高等教育“九五”国家级重点教材

时间序列分析



主编 王振龙 主审 顾岚

复旦大学图书馆
藏书之章

中国统计出版社



FUDAN B0009030147484 复旦大学图书馆

(京)新登字 041 号

图书在版编目(CIP)数据

时间序列分析/王振龙主编.

—北京:中国统计出版社,2000.2

高等院校统计学专业规划教材

ISBN 7-5037-2926-0

I. 时… II. 王… III. 时间序列分析-高等学校-教材 IV. 0211.61

中国版本图书馆 CIP 数据核字(1999)第 10211 号

责任编辑/徐 颖

责任校对/刘开颜

出版发行/中国统计出版社

通信地址/北京市三里河月坛南街 75 号 邮政编码/100826

办公地址/北京市丰台区西三环南路甲 6 号

电 话/(010)63459084、63266600—22500(发行部)

印 刷/科伦克三莱印务(北京)有限公司

经 销/新华书店

开 本/787×1092mm 1/18

字 数/270 千字

印 张/14.5

印 数/1—5000 册

版 别/2000 年 2 月第 1 版

版 次/2000 年 2 月北京第 1 次印刷

书 号/ISBN 7-5037-2926-0/O. 32

定 价/24.00 元

中国统计版图书,版权所有,侵权必究。

中国统计版图书,如有印装错误,本社发行部负责调换。

出版说明

根据原国家教育委员会《普通高等教育“九五”国家级重点教材立项、管理办法》的要求,国家统计局经过专家评审,五种教材被立项,其中:三种教材是在“八五”期间规划统计教材的基础上进行修订的,二种教材属“九五”期间新编规划统计教材,这五本教材的编审工作由全国统计教材编审委员会负责审定。

“抓重点,出精品”是“九五”期间普通高等教育教材建设与改革工作的核心。按照教育部的要求,国家级重点教材都应建设成“九五”普通高等教育的精品教材。根据这一精神,这批教材力求适应我国政治、经济、科技、教育等改革的形势,充分反映改革的成果,同时适应专业目录调整及专业面拓宽以后教学改革的实际需要,科学、合理地设置教材体系和安排教材内容,努力提高教材质量。

相信通过这批教材的出版、发行,对我国普通高等教育统计教材建设工作将起到较好的示范、导向作用;对提高统计教育水平和培养面向 21 世纪的统计人才也将发挥积极的促进作用。

限于水平和经验,这批教材的编审、出版工作还会有缺点和不足之处,诚恳欢迎教材的使用单位、广大教师和同学们提出批评和建议。


全国统计教材编审委员会

1999 年 3 月

1

第三节	模型参数估计·····	(103)
第四节	模型的适应性检验·····	(108)
第五节	建模的其它方法·····	(113)
第六节	实例·····	(118)
第五章	平稳时间序列预测·····	(126)
第一节	正交投影预测(几何预测法)·····	(126)
第二节	条件期望预测·····	(129)
第三节	适时修正预测·····	(137)
第四节	指数平滑预测—ARMA 模型特例 ·····	(139)
第六章	非平稳时间序列分析·····	(143)
第一节	非平稳性的检验·····	(144)
第二节	平稳化方法·····	(151)
第三节	齐次非平稳序列模型·····	(159)
第四节	非平稳时间序列的组合模型·····	(168)
第七章	季节性时间序列分析方法·····	(181)
第一节	简单随机时序模型·····	(181)
第二节	乘积季节模型·····	(184)
第三节	季节时序模型的建立·····	(186)
第四节	X-11 方法简介 ·····	(193)
第八章	传递函数模型·····	(200)
第一节	模型简介·····	(201)
第二节	传递函数模型的识别·····	(204)
第三节	传递函数模型的拟合与检验·····	(211)
附录 I	延伸自相关函数·····	(217)
附录 II	TSP 软件简介·····	(224)
附录 III	数据资料·····	(230)
附录 IV	常用统计量分布表·····	(243)
主要参考书目·····		(250)

时间序列分析



前言

《时间序列分析》是普通高等教育“九五”国家重点教材,也是全国统计教材编审委员会“九五”本科规划教材。本教材的编写大纲几经编审委员会和专家组讨论、修改,专家们对教材的内容体系和写法提供了许多具体的宝贵意见和有价值的参考书目与材料,为本书的完成奠定了坚实的基础。

近几年来,时间序列分析引起了国内外学者及科研和管理人员的极大兴趣,特别是随着计算机的普及和软件的开发应用,对于只具一般数学知识的学者和广大的工程技术及管理人员学习和掌握时间序列分析方法,并用以分析、探索社会经济现象的动态结构和发展变动规律,进而对未来状态进行预测控制,提供了现实可能性,且在诸多应用领域已取得了可喜成果。

由于社会经济现象往往受许多因素的影响,且这些因素之间又保持着错综复杂的联系,因而,运用结构式的因果模型进行分析和预测往往比较困难,而根据其自身的变动规律建立动态模型(即时间序列分析)则是一种行之有效的方法。但是,近几年国内已出版(包括翻译)的这方面的专著教材,主要是面向数学及理工类读者,因而所涉及的数学理论较深奥,往往使经济和管理类的学生和实际工作者望而生畏,客观上迫切需要一本通俗、易懂、实用的教材。因此,“通俗、易懂、实用”就成了编写本教材的主要指导思想,也是煞费苦心,竭尽全力追求的终极目的。

本书从应用的角度出发,试图借助计算机的存贮功能和计算功能来抽象掉其深奥的数学理论和复杂的运算,从而使只具一般数学知识的读者便可掌

握和运用时间序列分析方法。在阐述中,尽可能回避严格的数学推导和证明,而从系统运动的惯性(即记忆性)加以解释和展开,或者说,本书把时序分析看作是一种统计分析工具,而不是数学的一个分支理论。对于“工具”来说,使用者只要知道其特性、功能和使用方法以及使用过程中应注意的有关事项就足够了,至于其制造原理及过程,当然熟悉更好,不了解也无关乎其使用。鉴于这样的认识,全书没有运用深奥的定理,因而也就勿需定理证明。模型的形成来自于对系统记忆性的长短及其特性的剖析,一些数学推导也只涉及高等数学、线性代数和概率论与数理统计的一般知识。

为了使读者通过建模练习来掌握时间序列分析的基本思路和方法,书中除了给出“时间序列分析软件”(TSP)的使用说明外,还搜集了近 20 个实际数据,以供读者练习之用。

当然,说本书强调应用,是相对于数学定理推证而言的,在阐述中力图做到理论严谨,逻辑严密,以形成相应于读者认知结构的时间序列分析理论和方法体系。不过,这仅是我们的愿望而已,由于才疏学浅,水平有限,书中一定会有错误和不妥之处,尤其是为了尽量避免使用数学语言和定理及证明手段,在用描述语言和系统机理表述模型结构及其原理和特性时,可能从数学的角度看会有不准确、不严密之处,恳请读者批评指正。

本书由王振龙同志任主编,全书共八章。其中第一、二、三章由王振龙编写;第四、五、八章由胡永宏编写;第六章由胡永宏和王佐仁编写;第七章由王振龙和王佐仁编写。全书由王振龙总纂、修改定稿。

初稿形成后由顾岚教授主审,提出了很多宝贵的修改意见,同时在编写过程中参阅了大量的资料,并引用了一些现成的数据和科研成果,除书中提到的主要参考书目以外,还需提到的是美国芝加哥大学商学院刁锦寰教授、美国费城大学管理学院陈江教授和台湾辅仁大学管理学院统计系主任谢邦昌教授 1997 年 11 月在国家统计局教育中心和统计教育学会举办的“时间序列分析高级研究班”上的讲座,对我们有很大的启发和帮助,其它资料恕不列举。此外,国家统计局教育中心的领导和教材处同志以及我的同仁和学生给予了很多的支持和帮助,在此,一并致以真诚的感谢。

王 振 龙

1999 年 7 月于西安

[illegible]

1

第一节 时间序列分析的一般问题

一、时间序列的含义

从统计意义上讲,所谓时间序列就是将某一个指标在不同时间上的不同数值,按照时间的先后顺序排列而成的数列。这种数列由于受到各种偶然因素的影响,往往表现出某种随机性,彼此之间存在着统计上的依赖关系。如表 1.1 中列出的是某地电风扇 1994 年到 1996 年间各月的销售量(单位:万台),按时间顺序排成一个数列,就是一个时间序列。相对于时间的数据图如图 1.1 所示。

表 1.1 电风扇月销售量

单位:万台

月 份 年 份	1	2	3	4	5	6
1994 年	10	20	41	64	148	230
1995 年	16	20	58	90	139	235
1996 年	15	23	66	91	140	253
月 份 年 份	7	8	9	10	11	12
1994 年	203	127	41	22	16	12
1995 年	240	89	42	23	16	17
1996 年	198	96	78	50	25	19

值得注意的是,时间顺序中的“时间”也可以具有不同的物理意义,例如长度、温度、速度等等。

从数学意义上讲,如果我们对某一过程中的某一个变量或一组变量 $X(t)$ 进行观察测量,在一系列时刻 $t_1, t_2, \dots, t_N$ (t 为自变量,且 $t_1 < t_2 < \dots < t_N$) 得到的离散有序数集合 $X_{t_1}, X_{t_2}, \dots, X_{t_i}, \dots, X_{t_N}$ 称为离散数字时间序列,即随机过程的一次样本实现。设 $X(t; t \in T)$ 是一个随机过程, $X_{t_i} (i=1, 2, \dots)$ 是在时刻 i 对过程 $X(t)$ 的观察值,则 $X_{t_i} (i=1, 2, \dots)$ 称为一次样本实现,也就是一个时间序列。

从系统意义上看,时间序列就是某一系统在不同时间(地点、条件等)的响应。这个定义从系统运行的观点出发,不仅指出时间序列是按一定顺序排列而




图 1.1 电风扇月销售量数据图

成的；这里的“一定顺序”既可以是时间顺序，也可以是具有各种不同意义的物理量，如代表温度，速度或其它单调递增地取值的物理量。可见，时间序列只强调顺序的重要性，而并非强调必须以时间顺序排列。例如：材料裂纹长度与其承受的压力有关，将材料裂纹长度按其所受压力周期数排列，也是一个时间序列（见附录Ⅲ），其散点图见图 1.2。




图 1.2 某材料裂纹长度

而且时间序列是所研究系统的历史行为的客观记录,因而它包含了系统结构特征及其运行规律。所以我们可以通过对时间序列的研究来认识所研究系统的结构特征(如周期波动的周期、振幅、趋势的种类等);揭示其运行规律,进而用以预测、控制其未来行为;修正和重新设计系统(如改变其周期、参数),使之按照新的结构运行。

综上所述,时间序列具有如下特点:首先,序列中的数据或数据点的位置依赖于时间,即数据的取值依赖于时间的变化,但不一定是时间 t 的严格函数。其次,每一时刻上的取值或数据点的位置具有一定的随机性,不可能完全准确地用历史值预测。再次,前后时刻(不一定是相邻时刻)的数值或数据点的位置有一定的相关性,这种相关性就是系统的动态规律性。最后,从整体上看,时间序列往往呈现某种趋势性或出现周期性变化的现象。

二、时间序列的主要分类

时间序列根据所研究的依据不同,可有不同的分类。

1. 按所研究的对象的多少分,有一元时间序列和多元时间序列。表 1.1 中,我们所研究的只是某种商品销售量这一数列,即为一元时间序列;但是,如果我们所研究的对象不仅仅是这一数列,而是多个变量,如是按年、月顺序排列的气温、气压、雨量数据,每个时刻 t 对应着多个变量,则这种序列为多元时间序列。多元时间序列不仅描述了各个变量的变化规律,而且还揭示了各变量间相互依存关系的动态规律性。

2. 按时间的连续性可将时间序列分为离散时间序列和连续时间序列两种。如果某一序列中的每一个序列值所对应的时间参数为间断点,则该序列就是一个离散时间序列,如果某一序列中的每个序列值所对应的时间参数为连续函数,则该序列就是一个连续时间序列。我们主要研究离散时间序列,并用 X_t 表示,对于连续时间序列,可通过等间隔采样使之转化为离散时间序列后加以研究。

3. 按序列的统计特性分,有平稳时间序列和非平稳时间序列两类。如果一个时间序列的概率分布与时间 t 无关,则称该序列为严格的(狭义的)平稳时间序列。如果序列的一、二阶矩存在,而且对任意时刻 t 满足:

(1)均值为常数

(2)协方差为时间间隔 τ 的函数

则称该序列为宽平稳时间序列,也叫广义平稳时间序列,如图 1.3 所示。我们以后所研究的时间序列主要是宽平稳时间序列。如果不明确提出严平稳,所谓

的平稳即指宽平稳。反之,不具有平稳性即序列均值或协方差与时间有关的序列称之为非平稳序列,如图 1.1、图 1.2 所示。




图 1.3 列车运行数量平稳化后数据图

4. 按序列的分布规律来分,有高斯型(Gaussian)时间序列和非高斯型(non-Gaussian)时间序列。服从高斯分布(正态分布)的时间序列叫做高斯型时间序列,否则叫做非高斯型时间序列。本书所介绍的模型多数是假设服从高斯分布的高斯型时序模型。对于一些非高斯序列,往往通过适当变换,则可近似地看成是高斯型时间序列。

三、时间序列分析

不论是经济领域中每年的产值、国民收入、某一商品在某一市场上的销量、某一商品在某一市场上的价格变动等,或是社会领域中某一地区的人口数、医院患者人数、铁路客流量等,还是自然领域的太阳黑子数、月降水量、河流流量等等,都形成了一个时间序列。所有这些序列的基本点就是每一个序列包含了产生该序列的系统的历史行为的全部信息。问题在于怎样才能根据这些时间序列,较精确地找出相应系统的内在统计特性和发展规律性,尽可能多地从中提取出我们所需要的准确信息。用来实现上述目的整个方法称为时间序列分析。它是一种根据动态数据揭示系统动态结构和规律的统计方法,是统计学科的一个分支。其基本思想是根据系统的有限长度的运行记录(观察数据),建立能够比较精确地反映时间序列中所包含的动态依存关系的数学模

型,并借以对系统的未来行为进行预报。

人们为了根据时间序列揭示所研究现象的动态规律性,在认识——实践——再认识的不断循环过程中,产生了一系列分析研究时间序列的方法。最朴素的动态思想认为现象的未来行为与现在的行为有关,于是,人们便用现象的现在值作为其下一时刻的预测值。这种方法对于平稳发展变化的现象来说,是可行的。例如,要预测下周某种销售额较稳的产品的需求量,就用最近一周的实际需求量作为下周的预测值。按照这种思想,对于具有季节性的序列也可以先将最近的观察值去掉季节性,然后再赋予要预测时刻的季节性进行预测。遗憾的是,观察值含有偶然因素的随机影响,因而,据这种思想进行预测,受随机影响较大。为了弥补这一不足,一种有效的方法就是取一段时间上的观察值的平均数。于是,产生了移动平均法和指数平滑法。


随着科学技术的不断发展,人们在实践中认识到时间序列的变动,主要是由长期趋势(随着时间的变化,按照某种规则稳步地增长、下降或保持在某一水平上)、季节变动(在一个年度内依一定周期规则性变化)、循环波动(以若干年为周期的波动变化)和随机型变动(许多不可控的偶然因素共同作用的结果)而形成的。前三种变动的一个共同特点,就是依一定的规则而变化,随机波动在综合中可以消除。基于这种认识,时间序列分析就是设法消除随机型波动,拟合确定型趋势,因而形成了长期趋势分析、季节变动分析和循环波动测定等一系列确定型时间序列分析方法。

虽然确定型趋势控制着时间序列变动的基本样式,但毕竟不是时间序列变动模式的全貌。另一方面,用随机理论来考察,许多偶然因素共同作用的随机型波动,其实也并非完全杂乱无章,而有一定的规律性。人们根据随机理论,对随机时间序列进行分析,就叫作随机时间序列分析,其相应的方法,称之为随机时间序列分析方法。自从本世纪 20 年代问世以来,随机时间序列分析的理论和方法,引起了广大理论研究和实际工作者的极大重视,其理论和方法不断发展且得到了广泛的应用。

随机时间序列分析丰富和发展了时间序列分析的理论和方法。但不能取代确定型时序分析,也不能认为时间序列分析因此而就完善了。从系统的观点来看,影响时间序列总变动的各个要素并非独立地发生作用,而是在相互影响中共同发生作用,因而,分别测定的各种因素的变动的简单综合,不等于时间序列的总变动。应该将时间序列看作某一系统的动态行为的客观记录,从整体上来考察其动态结构和变动规律性。这是当前和今后时间序列分析研究的一个重大课题。此外,对一组(多维)相关随机变量的动态过程同时进行观测,并

将其作为整体加以研究的多元时间序列分析,也是时序分析研究的一个广阔领域。

为了对时间序列分析方法有一个比较全面的了解,便于进一步学习和研究,现将时间序列分析的主要方法归纳如下:



时间序列分析方法如果按其采用的手段不同可概括为数据图法、指标法和模型法三类。数据图法是将时间序列在平面坐标系中绘出坐标图,根据图形直接观察序列的总趋势和周期变化以及异常点、升降转折点等。这种方法简单、直观、易懂易用;但获取的信息少且肤浅和粗略;需要有相当丰富的分析经验,否则难以获得更深层次的信息;分析结果的主观性较大。指标法是指通过计算一系列核心指标来反映所研究系统的动态特征。如反映变化率的发展速度和增长速度,反映均衡性和节奏性的动态平均指标和变异指标等等。虽然指标法较数据图法客观,但它所提取的信息仍是肤浅的、有限的。模型法是对给定的时间序列,根据统计理论和数学方法,建立描述该序列的适应或最优统计模型,并进而据以进行预测或控制。这是本书将要介绍的主要内容。

时间序列分析的基本特征就是研究序列随时间发展的模式。其区别于其他统计分析的重要特征之一,就是明确重视顺序的重要性。时间序列与其它变量数列不同,序列中的观察值是按照一定顺序取得的,并保持其顺序不变。只有这样,才能保证所研究现象的历史发展过程不改变。其次,时间序列中的观

察值之间存在着一定的依存关系。这是时序分析区别于其他统计分析的又一重要特征。数理统计研究的其他变量数列,一般要求每一变量各自独立。但是,由于任何现象的发展,一般都具有一定的惯性(延续性),因而,相应的时间序列中各时刻的观察值之间就体现为一定的依存关系。从某种意义上说,时间序列分析就是要定量地描述这种依存关系。再次,时间序列分析区别于其他统计分析的重要特征还表现在对所研究系统未来行为的分析即预测推断的依据不同。时序分析不是根据某一变量与其它变量之间的静态相关关系来预测该变量的未来变化,而是根据预测变量本身或其它相关变量过去的变化规律来预测未来的变化。就一元时间序列分析而言,它就是根据该变量本身的变化规律来预测未来变化的。

时间序列分析与数理统计学的主要区别表现在如下三个方面。首先,数理统计学的样本值是对同一随机变量进行 n 次独立重复试验的结果,或是 n 个相互独立、同分布的随机变量序列的一个实现;而时间序列则是某一随机过程的一次样本实现。其次,在数理统计学中,进行统计推断的目的主要是对一个随机变量的分布参数进行估计或假设检验;而在时间序列分析中,则是对某一时间序列建立统计模型。最后,数理统计学中的回归模型描述的是因变量与其它自变量之间的统计静态依存关系;而时序分析中的自回归模型描述的是某一变量自身变化的统计规律性。是某一系统的现在的行为与其历史行为之间的统计动态依存关系。

时间序列分析是一种重要的现代统计分析方法,广泛地应用于自然领域、社会领域、科学研究和人类思维。不论是自然现象,还是社会经济现象,都是一个有规律的辩证发展过程。任何运动都有一定的惯性,这种惯性就表现为系统的动态性即记忆性。时间序列是系统历史行为的客观记录,它包含了系统动态特征的全部信息。这些信息,具体地表现为时间序列中观察值之间的统计相关性。因而,人们可以通过研究时间序列中数值上的统计相关关系,来揭示相应系统的动态结构特征及其发展变化规律。基于上述观点,时间序列分析就是用历史的观点,通过量的手段揭示所研究现象的动态结构和动态规律。这不仅是可能的,而且也是合理的,科学的。

系统的动态特性即事物运动的惯性,决定了时序分析理论和方法的客观性。同时,时序分析也是其他统计分析方法的客观要求。一方面,利用变量之间的因果关系预测某一变量的未来行为时,这些自变量或前导(领先)变量本身的未来值需要预测;另一方面,在许多情况下,很难或不可能利用变量之间的因果关系模型(即结构模型)来说明某一变量的变化。如某商品的销售量,它

随着价格、个人收入和利率的变化而上下起伏,但是,影响其变化的其他许多因素如天气变化、顾客爱好的变化等,则可能是无法说明的。对于这种情况,时序模型则是用于预测的一个很有效的工具。一元时序模型不象回归模型那样是根据因果关系,而是根据被预测变量过去的变化规律性来建立模型,然后利用这个模型来预测该变量未来的变化。因此,时序模型是一种先进的统计方法。利用时序模型不需要知道影响预测变量的因果关系,在系统的动态性较强,关于影响预测变量的决定性因素的信息很少,且有足够多的数据量可以用来构成一个合理长度的时间序列的情况下,运用时序分析往往可达到事半功倍之功效。

概括起来,时序分析的作用主要有以下几个方面:

1. 对理论性模型与数据进行适度检验,以讨论模型是否能正确地表示所观测的现象。
2. 刻划系统所处的状态及其结构性,从而达到认识和解释系统之目的。
3. 描述系统的运行规律性,从而达到认识规律和掌握规律性之目的。
4. 预测系统的未来行为,从而达到利用规律之目的。
5. 控制系统的未来行为,从而达到利用和支配系统之目的。

第二节 时间序列的建立

时间序列分析处理加工的是来自所研究系统的时间序列数据。因此,建立一个时间序列是时间序列分析的第一步。一般来说,研究者是运用记录仪或通过观察测量来获取所研究系统的真实有限的数据集合的。有时也可以直接运用次级资料。但是,不论是通过哪一种途径获得的时间序列,在进行分析处理前,必须对所依据的资料进行认真的检查、整理,有时还需要进行适当的预处理(如缺少数据的补足等)。我们把获取时间序列以及对其进行检查、整理和预处理等工作,称为时间序列的建立。

一、时间序列数据的采集

对于所研究系统来说,相应于时间的连续性,系统在不同时刻上的响应常常是时间 t 的连续函数。为了数字计算处理上的方便,往往只按照一定的时间间隔对所研究系统的响应进行记录和观察,我们称之为采样。相应地把记录和观察的时间间隔称为采样间隔,并用 Δ 表示。例如,对某市场某种水果的价格

每隔一日进行一次记录,则采样间隔为一日($\Delta=1$ 日或 24 小时),每个观察值也称为采样值,第 k 个采样值为 X_k ,也就是连续函数 $X(t)$ 的值 $X(t_0+k\Delta)$ 。如图 1.4 所示。




图 1.4 以 Δ 为采样间隔对 X_t 的采样

在对时间序列 $X(t)$ 的采样过程中,取不同的采样间隔 Δ 可以得到不同的数字时间序列 $X_t, t=1, 2, \dots$ 。采样间隔既可以相等,也可以不等。我们这里只讨论等间隔采样,因此,在本书中将“采样间隔相等”作为建立时间序列的一条重要原则。

如前所述,时间序列包含了系统的全部信息,因而人们可以藉以研究系统的动态结构和运行规律。但是,采样得到的离散时间序列 X_t 失去了 $X(t)$ 在 $t_0+(i-1)\Delta$ 和 $t_0+i\Delta$ 之间的值,即这个区间内系统的信息在采样之后丢失了。显然,在合理的范围内,采样间隔 Δ 越小,采样值就越多,信息损失就越小,数据处理量越大,处理时间、人力、财力消耗越大。相反,采样间隔越大,采样值越少,处理时间、人力、财力消耗越小,但信息损失越大。因此,选择合适的采样间隔是建立时间序列的关键,理想的采样间隔就是既没有损失信息,也没有出现信息冗余。在实际中,研究者只能根据所研究系统的具体特性和经验,在不过分减少信息损失和不过分增加数据量之间作出合理选择。

二、离群点的检验与处理

离群点(Outlier)是指一个时间序列中,远离序列一般水平的极端大值和极端小值。因此,也称之为奇异值,有时也称其为野值。如图 1.5 所描述的是 1949 年到 1997 年间,我国的人口自然增长率(X_t)。从图形中可以直观地看出,1960 年的人口自然增长率大大低于其它年份的自然增长率。从序列来看, X_{12} (即 1960 年的观察值)远离了序列 X_t ,我们称 X_{12} 为离群点。

概括地说,是由于系统受外部干扰而造成的。但是,形成离群点的系统外部干扰是多种多样的。首先可能是采样中的误差,如记录仪出现偏误、工作人员出现笔误、计算差错等,都有可能产生极端大值或极端小值。其次可能是被




图 1.5 我国人口自然增长率数据图

研究现象本身由于受各种偶然非正常的因素影响而引起的,例如,在人口死亡序列中,由于某年发生了地震,使得该年的死亡人数急剧增加,形成了离群点;在股票价格序列中,由于受某项政策出台或某种谣传的刺激,都会出现极增、极减现象,表现为序列中的离群点。

不论是何种原因引起的离群点,对以后的时间序列分析都会造成一定的影响。从造成分析中的困难来看,统计分析人员是不希望序列中出现离群点的,离群点会直接影响模型的拟合精度,甚至会得到一些虚假的信息。例如,两个相距很近的离群点将在谱分析中产生许多虚假的频率。因此,离群点往往被分析人员看作是一个“坏值”。但是,从获得信息来看,离群点提供了很重要的信息,它不仅提示我们认真检查采样中是否有差错,在进行时间序列分析前,认真确认序列,而且,当确认离群点是由于系统受外部突发因素刺激而引起的时候,它会提供关于系统稳定性、灵敏性等重要信息。

在时间序列分析中,通常把各种各样的离群点分为四种类型进行处理。第一种是加性离群点(Additive Outlier),造成这种离群点的干扰,只影响该干扰发生的那一个时刻 T 上的序列值,即 X_T ,而不影响该时刻以后的序列值, $X_{T+1}, X_{T+2}, \dots$;第二种是更新离群点(Innovational Outlier),造成离群点的干扰不仅作用于 X_T ,而且影响 T 时刻以后序列的所有观察值 $X_{T+1}, X_{T+2}, \dots$,它的出现意味着一个外部干扰作用于系统的开始,并且其作用方式与系统的动态模型有关;第三种是水平移位离群点(Level Shift Outlier),造成这种离群

点的干扰是在某一时刻 T , 系统的结构发生了变化, 并持续影响 T 时刻以后的所有行为, 在数列上往往表现出 T 时刻前后的序列均值发生水平位移; 第四种是暂时变更离群点 (Temporary Change Outlier), 造成这种离群点的干扰是在 T 时刻干扰发生时具有一定初始效应, 以后随时间根据衰减因子 δ 的大小呈指数衰减的一类干扰事件。

显然, 在得到时间序列以后, 首先要检验是否存在离群点, 如果存在的话, 还需要进一步判明在何时出现了离群点, 以及所出现的离群点属于何种类型。检验离群点并对其进行处理的方法很多, 但归纳起来大致有两类: 一是根据数据取值进行检查, 如果某一时刻的数值超出了一定的范围, 则认为该点是一个离群点, 并用一定的方法进行剔点 (剔除离群点) 处理; 另一类是对数据进行模型分析, 然后根据拟合模型后的剩余序列计算特定的统计量, 测出显著的离群点及其类型, 并用相应的模型进行修正, 然后再对修正模型的剩余序列重复上述程序, 依次测出各个离群点。关于后一类分析方法通常也称为干预分析法, 有兴趣的读者可参阅有关参考书目, 下面仅就前一类方法作一些简单介绍。

一种方法是将序列值与平滑值进行比较, 检测其是否显著地大 (或小)。这种方法是假定正常的序列值是平滑的, 而离群点是突变的。我们用 $\bar{X}_t^2$ 表示先对序列 X_t 进行平滑再平方得到的数值, $\overline{X_t^2}$ 表示先对序列 X_t 取平方再作平滑而得到的数值, 并用 S_t^2 表示样本方差, 有 $S_t^2 = \bar{X}_t^2 - \overline{X_t^2}$, S_t 表示标准差, 如果

$$\bar{X}_t - kS_t < X_{t+1} < \bar{X}_t + kS_t \quad (1.2.1)$$

则认为 X_{t+1} 是正常的, 否则, 认为 X_{t+1} 是一个离群点。 k 是统计分析研究人员根据序列和研究目的设定的一个常数, 一般取 3—9 的整数, 开始时不妨可取 $k=6$ 。

如果 X_{t+1} 是一个离群点, 则可用 $\hat{X}_{t+1}$ 来代替, 即

$$\hat{X}_{t+1} = 2\bar{X}_t - X_{t-1} \quad (1.2.2)$$

这实际上是线性外推。这种方法需要事先规定连续外推的次数, 以免出现无休止的外推。因为连续检测到一些离群点后, 最终的外推结果可能偏差很远, 以致会排除本来是正常的数据点。

另一种方法是检测序列值与其相应的曲线平滑估计值的绝对离差是否大于某一预先设定值 k 。其具体检测步骤如下: 首先根据序列 X_t 从首项开始取 5 项移动中位数生成一个新序列 X'_t , 即取 X_1, X_2, X_3, X_4, X_5 的中位数作为 X'_3 , 然后舍去 X_1 , 加入 X_6 取中位数得 X'_4 , 依次类推, 直到加入序列最后一个数 X_N 。其次, 用同样的方法根据序列 X'_t , 从首项开始取 3 项移动中位数构成

序列 X''_i 。再次,由序列 X'' 按照如下公式构成序列 X'''_i :

$$X'''_i = \frac{1}{4}X''_{i-1} + \frac{1}{2}X''_i + \frac{1}{4}X''_{i+1} \quad (1.2.3)$$

最后,检测是否存在 $|X_i - X'''_i| > k$ (其中 k 为预先设定值),若有,则该点是一个离群点。

三、缺损值的补足

在采集时间序列时,有时会由于仪器故障,操作失误,观测问题等种种原因,引起在某些观测点上未能记录下来观测值,这种缺少的观测值称为缺损值(Missing Value)。这种缺损值在使用次级资料时也会出现。当序列中存在缺损值时,就破坏了系统运行的连续性,违背了时间序列“顺序的重要性”原则。严格地说,我们不能依据一个“残缺”的序列进行分析,即使强制性地进行了分析,其结果也是无意义的,可是,由于时间的不可逆性,我们又无法重新观测,因此,我们所能做的就是依据其运动轨迹或变化趋势,运用一定的方法对缺损值进行估计、推测,以补足缺损的数值。具体估算、推测方法很多,如增长量推算法、发展速度推算法、比例推算法、平滑法、插值估算法等等,分析人员可根据具体序列选择运用。鉴于这些方法已在先修课程中作过详细介绍,故这里不再赘述。

此外,在对一序列进行分析之前,还要对序列中的每一个数据的指标口径、计算范围、计算方法、计量单位等进行认真检查,对经济时间序列来说,还必须检查计算价格等方面是否一致。若存在不一致,则要运用科学的方法进行调整,使整个序列中的每一个数据除时间属性不同之外,其所代表的实际意义完全一致。

时间序列分析不是做数学游戏,也不是做数学练习,因此,不能盲目地对一个序列建立模型进行分析。在建模分析之前,对所研究的时间序列进行认真检查和科学地预处理,也就是建立一个规范的时间序列是十分重要的,是做好时间序列分析的基础。分析研究人员千万不可忽视。

下面我们以前述我国人口自然增长率为例,简要说明建立时间序列的一般过程。就人口增长率来说,它是报告期人口的自然增减数与报告期内平均人口数之比。显然,相应于时间的连续性,它是时间 t 的连续函数,但是我们没有必要对每时每刻的人口变动都进行了解和掌握。从一般管理的需要和人口变动往往含有周期性这一特点考虑,该序列用自然年度(即1月至12月)为采样间隔,也叫年度序列。既然是自然年度序列,那么序列中不仅不允许出现其它

间隔(如半年、五年等)的序列值,而且年间隔也必须是自然年度,而不能是其它年度。

时间间隔确定之后,指标的计算范围在同一序列中也必须保持一致。该序列习惯叫“我国人口数”,实际上是以境内为核算范围的,而不是以领土内为核算范围的。也就是说,只是大陆人口数,而不包括港、澳、台地区的人口数。因此,虽然1997年香港已经回归祖国,但是为了保持序列值计算范围的一致性,在计算1997年的人口自然增长率时,不能包含香港特别行政区的人口情况。

就指标的计算方法来说,计算平均人口数的方法很多,用各种方法计算的结果也不完全一致,在同一序列中,各年的平均人口数必须采用相同的计算方法,本序列是用(年初人口数+年末人口数) $\div 2$ 来计算的。

至于指标口径,也必须一致。如出生人数是指活产婴儿数,即离开母体有生命现象的活婴数总和。凡出生后有呼吸、心跳、脐带蠕动、随意肌抽动等现象之一者,皆称为活产。出生后有上述一种生命现象但随后死亡者,也列入出生人数之中,同时也计入死亡人数之中。

这样,使序列中的每个数据除时间属性不同之外,其所代表的实际意义完全一致。

根据图1.5可以看出,1960年的人口自然增长率极端异常,从数值上看为 -4.57% ,下面我们用第一种方法来检测该序列是否存在离群点。

我们对原序列作一次指数平滑。设平滑常数为 $\alpha=0.3$,并取 $k=6$,根据(1.2.1)式, $\bar{X}_t - ks_t, X_{t+1}, \bar{X}_t + ks_t$ 的数据如图1.6所示。




图1.6 人口自然增长率的离群点检测图

可见,在 X_{12} 处, $X_{12} < \bar{X}_{11} - 6S_{11}$, 即 $-4.57\% < 3.38\%$, 除此之外,所有的观测值均满足(1.2.1)式。所以,我们认为 X_{12} 为一个离群点,根据(1.2.2)式,我们可以用

$$2X_{11} - X_{10} = 2 \times 10.19\% - 17.24\% = 3.14\%$$

代替原序列 X_{12} 的观测值 -4.57% 。

第三节 确定性时序分析方法概述

时间序列预测技术就是通过对预测目标自身时间序列的处理,来研究其变化趋势的。当我们刚接触到某一个观测序列时,会觉得它是杂乱无章,无规律可循的。其实不然,大量事实表明,一个时间序列往往是以下几类变化形式的叠加或耦合:

(1)长期趋势变动。它是指时间序列朝着一定的方向持续上升或下降,或停留在某一水平上的倾向,它反映了客观事物的主要变化趋势。

(2)季节变动。即指一年或更短的时间之内,由于受某种固定周期性因素(如自然、生产、消费等季节性因素)的影响而呈现出有规律的周期性波动。

(3)循环变动。通常是指周期为一年以上,由非季节因素引起的涨落起伏波形相似的波动。

(4)不规则变动。通常它分为突然变动和随机变动。所谓突然变动是指战争、自然灾害或是其它社会因素等意外事件引起的变动。随机变动是指由于大量的随机因素产生的宏观影响。根据中心极限定理,通常认为随机变动近似服从正态分布。

通常用 T_t 表示长期趋势项, S_t 表示季节变动趋势项, C_t 表示循环变动趋势项, R_t 表示随机干扰项。常见的确定性时间序列模型有以下几种类型:

(i)加法模型

$$y_t = T_t + S_t + C_t + R_t \quad (1.3.1)$$

(ii)乘法模型

$$y_t = T_t \cdot S_t \cdot C_t \cdot R_t \quad (1.3.2)$$

(iii)混合模型

$$y_t = T_t \cdot S_t + R_t \quad (1.3.3)$$

$$y_t = S_t + T_t \cdot C_t \cdot R_t$$

其中 y_t 是观测目标的观测记录, $E(R_t)=0$, $E(R_t^2)=\sigma^2$ 。

如果在预测时间范围以内,无突然变动且随机变动的方差 σ^2 较小,并且有理由认为过去和现在的历史演变趋势将继续发展到未来时,可用一些经验方法进行预测,具体方法如下:

1. 移动平均法

设观测序列为 $y_1, \dots, y_T$, 正整数 $N < T$ 。一次移动平均值计算公式为:

$$\begin{aligned} M_t^{(1)} &= \frac{1}{N} (y_t + y_{t-1} + \dots + y_{t-N+1}) \\ &= \frac{1}{N} (y_{t-1} + \dots + y_{t-N}) + \frac{1}{N} (y_t - y_{t-N}) \\ &= M_{t-1}^{(1)} + \frac{1}{N} (y_t - y_{t-N}) \end{aligned} \quad (1.3.4)$$

二次移动平均值计算公式为:

$$\begin{aligned} M_t^{(2)} &= \frac{1}{M} (M_t^{(1)} + \dots + M_{t-N+1}^{(1)}) \\ &= M_{t-1}^{(2)} + \frac{1}{N} (M_t^{(1)} - M_{t-N}^{(1)}) \end{aligned} \quad (1.3.5)$$

当预测目标的基本趋势是在某一水平上上下波动时,可用一次移动平均方法建立预测模型:

$$\hat{y}_{T+m} = M_T^{(1)} = \frac{1}{N} (\hat{y}_t + \dots + \hat{y}_{t-N+1}), \quad m=1, 2, \dots \quad (1.3.6)$$

它表明最近 N 期序列值的平均值作为未来各期的预测结果。一般 N 取值范围: $5 \leq N \leq 200$ 。当历史序列的基本趋势变化不大且序列中随机变动成分较多时, N 的取值应较大一些。否则 N 的取值应小一些。在有确定的季节变动周期的资料中,移动平均的项数应取周期长度。选择最佳 N 值的一个有效方法是,比较若干模型的预测误差。均方预测误差最小者为好。

当预测目标的基本趋势与某一线性模型相吻合时,常用二次移动平均法,但序列同时存在线性趋势与周期波动时,可用趋势移动平均法建立预测模型:

$$\hat{y}_{T+m} = a_T + b_T m, \quad m=1, 2, \dots \quad (1.3.7)$$

其中: $a_T = 2M_T^{(1)} - M_T^{(2)}$

$$b_T = \frac{2}{N-1} (M_T^{(1)} - M_T^{(2)})$$

上述移动平均法在数据处理中常用它作为预处理,消除周期波动(取 N 为周期长度)和减弱随机干扰的影响往往是有效的。

2. 指数平滑法

一次移动平均实际上认为最近 N 期数据对未来值影响相同,都加权 $\frac{1}{N}$; 而 N 期以前的数据对未来值没有影响,加权为 0。但是,二次及更高次移动平均数的权数却不是 $\frac{1}{N}$,且次数越高,权数的结构越复杂,但永远保持对称的权数,即两端项权数小,中间项权数大,不符合一般系统的动态性。一般说来历史数据对未来值的影响是随时间间隔的增长而递减的。所以,更切合实际的方法应是对各期观测值依时间顺序进行加权平均作为预测值。指数平滑法可满足这一要求,而且具有简单的递推形式。

设观测序列 $y_1, \dots, y_T$, α 为加权系数, $0 < \alpha < 1$, 一次指数平滑公式为:

$$S_t^{(1)} = \alpha y_t + (1-\alpha)S_{t-1}^{(1)} = S_{t-1}^{(1)} + \alpha(y_t - S_{t-1}^{(1)}) \quad (1.3.8)$$

假定历史序列无限长,则(1.3.8)式可写为

$$\begin{aligned} S_t^{(1)} &= \alpha y_t + (1-\alpha)[\alpha y_{t-1} + (1-\alpha)S_{t-2}^{(1)}] = \dots \\ &= \alpha \sum_{j=0}^{\infty} (1-\alpha)^j y_{t-j} \end{aligned} \quad (1.3.9)$$

(1.3.9)式表明 $S_t^{(1)}$ 是全部历史数据的加权平均,加权系数分别为 $\alpha, \alpha(1-\alpha), \alpha(1-\alpha)^2, \dots$; 显然有

$$\sum_{j=0}^{\infty} \alpha(1-\alpha)^j = \frac{\alpha}{1-(1-\alpha)} = 1$$

由于加权系数序列呈指数函数衰减,加权平均又能消除或减弱随机干扰的影响,所以(1.3.8)称为指数平滑,类似地,二次指数平滑公式为:

$$S_t^{(2)} = \alpha S_t^{(1)} + (1-\alpha)S_{t-1}^{(2)} \quad (1.3.10)$$

同理,三次指数平滑公式为:

$$S_t^{(3)} = \alpha S_t^{(2)} + (1-\alpha)S_{t-1}^{(3)} \quad (1.3.11)$$

一般 P 次指数平滑公式为:

$$S_t^{(P)} = \alpha S_t^{(P-1)} + (1-\alpha)S_{t-1}^{(P)} \quad (1.3.12)$$

利用指数平滑公式可以建立指数平滑预测模型。原则上说,不管序列的基本趋势多么复杂,总可以利用高次指数平滑公式建立一个逼近很好的模型,但计算量很大。因此用的较多的是几个低阶指数平滑预测模型。

(1)水平趋势预测模型:

$$\hat{y}_{T+m} = S_T^{(1)}, \quad m=1, 2, \dots \quad (1.3.13)$$

(2)线性趋势预测模型—Brown 单系数线性平滑预测:

$$\hat{y}_{T+m} = \alpha_T + b_T M, \quad m=1, 2, \dots \quad (1.3.14)$$

其中 $a_T = 2S_T^{(1)} - S_T^{(2)}$, $b_T = \frac{\alpha}{1-\alpha}(S_T^{(1)} - S_T^{(2)})$

(3)二次曲线趋势预测模型—Brown 单系数二次式平滑预测:

$$\hat{y}_{T+m} = a_T + b_T \cdot m + \frac{1}{2}C_T \cdot m^2, \quad m=1,2,\dots \quad (1.3.15)$$

其中 $a_T = 3S_T^{(1)} - 3S_T^{(2)} + S_T^{(3)}$

$$b_T = \frac{\alpha}{2(1-\alpha)^2} [(6-5\alpha)S_T^{(1)} - 2(5-4\alpha)S_T^{(2)} + (4-3\alpha)S_T^{(3)}]$$

$$C_T = \frac{\alpha^2}{(1-\alpha)^2} [S_T^{(1)} - 2S_T^{(2)} + S_T^{(3)}]$$

指数平滑预测模型是以当前时刻 T 为起点,综合历史序列的信息,对未来进行预测的。选择合适的加权系数 α 是提高预测精度的关键环节。根据实践经验, α 的取值范围一般以 $0.1 \sim 0.3$ 为宜。如何进一步确定 α 的最佳取值,通常要结合理论分析和模型对比的方法来进行。

由(1.3.8)不难看出,

$$\begin{aligned} \hat{y}_{t+1} &= S_t^{(1)} = S_{t-1}^{(1)} + \alpha(y_t - S_{t-1}^{(1)}) \\ &= \hat{y}_t + \alpha y'_t \end{aligned}$$

其中 $y'_t = y_t - \hat{y}_t$

它表明指数平滑预测是用预测误差对上期预测值的修正, α 的大小体现了修正的幅度。由(1.3.6)式可知, α 值愈大,加权系数序列衰减速度愈快,所以实际上 α 取值大小起着控制参加平均的历史数据的个数的作用。 α 值愈大意味着采用的数据愈少。由此,可以得到选择 α 值的一些基本准则:

(1)如果序列的基本趋势比较稳,预测偏差由随机因素造成,则 α 值应取小一些,以减少修正幅度,使预测模型能包含更多历史数据的信息。

(2)如果预测目标的基本趋势已发生系统地变化,则 α 值应取得大一些。这样,可以偏重新数据的信息对原模型进行大幅度修正,以使预测模型适应预测目标的新变化。

上述原则可结合模型对比方法来进行。通常将历史数据分成两段,前一段 $y_1, \dots, y_K$, 用于建立预测模型,第二段 $y_{K+1}, \dots, y_T$ 用于事后预测,以事后预测误差平方和为评价标准,确定最佳 α 值。

另外,由于指数平滑公式是递推计算公式,所以必须确定初始值 $S_0^{(1)}$, $S_0^{(2)}$, $S_0^{(3)}$ 。初始值实质上应该是序列起始点 $t=0$ 以前所有历史数据的加权平均值。但在实际工作中,由于获得历史数据多少的不同,往往采用经验方法来

确定。我们可以通过在最初预测时,选择较高的 α 值来减小由初始值选择不当所造成的预测偏差,以使预测模型迅速调整到当前水平。

例如, $\alpha=0.5$,一般取前3—5个数据的算术平均值作为初始值:

$$S_0^{(1)}=S_0^{(2)}=S_0^{(3)}=\frac{1}{3}(y_1+y_2+y_3)$$

为了克服初始值选择不当,最初预测选择较大 α 值:

$$\alpha_1=\frac{1}{3}, \quad \alpha_2=\frac{1}{4}, \quad \alpha_3=\frac{1}{5}, \quad \alpha_4=\frac{1}{6}, \quad \alpha_5=0.15, \quad \alpha_t=0.15 \quad (t>5)$$

3. 时间回归法

指数平滑应用广泛。一般说来当序列具有其它类型变化形式时,指数平滑法计算量很大,此时用时间回归法更为方便和适用。

常用来描述时间序列的趋势变动的拟合模型有以下几种:

(1)线性方程: $y_t=a+bt$

(2)二次曲线: $y_t=a+bt+ct^2$

(3)指数曲线: $y_t=e^{a+bt}$

(4)修正指数曲线: $y_t=k+ab^t$

(5)Gompertz(龚帕兹)曲线: $\ln y_t=K+ab^t$ $(0<b<1)$

(6)Logistic(逻辑斯谛)曲线:

$$y_t^{-1}=K+ab^t \quad (0<b<1)$$

(7)振动曲线:

$$y_t=f(t)+A\cos(\omega t+\varphi), (f(t) \text{ 多项式})$$

在上述拟合模型中,人们常用(5),(6)来描述其发展具有一定成长过程的变动趋势。一般产品的发展、社会对某种产品的需求都满足“成长”模型所有的规律:

$$\frac{dy}{ydt}=a-by \quad (a>0, \quad b>0) \quad (1.3.16)$$

即 y 的增长率 $\frac{dy}{ydt}$ 开始按增长率 a 发展,随着 y 的逐渐增高,增长率逐渐下降。

当 $y=\frac{a}{b}$ 时, y 增长到极限,然后 y 逐渐下降。(1.3.16)的一种特例即为(6)的形式。所以,(5)、(6)常被称为是“成长”曲线预测模型。一个运动员(田径运动员)的成绩也可以用(5)、(6)来描述其演变规律。

4. 季节周期预测法

由于气候条件、社会风俗习惯等原因,许多预测对象表现出明显的季节周

期波动。如蔬菜销量、服装、电风扇的销售量,某城市用电量,用水量等都呈现出一定的季节性波动。有的以年度为周期,有的以季度、月、日为周期,总之这些序列容易观察到它的周期性,当周期性不甚明显时,可用序列的自相关函数来帮助识别。

季节周期预测与上述各种方法类似,首先建立预测模型,常用的模型有两种:

(i)乘法型季节模型

$$y_t = f(t) \cdot F_j \quad (1.3.17)$$

其中 $f(t)$ 是序列长期变动趋势项, F_j 是季节指数,它表示季节性变动幅度的大小, $j=1, \dots, k$; 如月度为周期 $K=12$; 季度为周期 $K=4$ 。

(ii)加法型季节模型

$$y_t = A \sin \omega(t + \lambda) = b_1 \sin \omega t + b_2 \cos \omega t \quad (1.3.18)$$

或

$$y_t = f(t) + b_1 \sin \omega t + b_2 \cos \omega t$$

当季节周期波动呈现一种脉冲形式时,加法模型便不适用了。建立季节性预测模型(1.3.17)归结为根据已知周期 K 的序列 $y_1, \dots, y_T$, 分别求出 $f(t)$ 与季节性指数 $F_1, \dots, F_k$, 可以先求 $f(t)$, 也可以先求出 $F_1, \dots, F_k$ 。

从总体上来说,确定性时序分析方法刻画了序列的主要趋势,且直观、简单,易于计算,便于运用。但是,相对说来,刻画较为粗略,其假定,尤其是对于时间函数模型来说,比较严格,现实问题很难完全满足。

第四节 随机时序分析的几个基本概念

作为学习随机时序分析的预备知识,我们将简单介绍一些时序分析的基本概念。首先从随机过程说起。

一、随机过程(Stochastic Process)

随机过程并不神秘,它也是描述随机现象的。有一些简单的随机现象用一个随机变量(Random Variable)就可以很好地描述。如某班一天的学生出勤人数(X)学院一天的耗电量(Y)等。一些较复杂的随机现象若用一个变量来描述就不够了,而需要若干个随机变量来描述。例如,在平面上描述一个随机点,就必须用一组(两个)随机变量(X, Y)来描述。同样,一个随机点在空间上的位置就需要用三个变量来描述。而某个企业一天的工作情况:产量、出勤人数、次品

率、原材料消耗量、耗电量、耗水量……等,这就是多维随机变量(向量)。

但是,当我们想描述一学期内各日学生缺勤数时,就难以用随机变量来表示。同样,用随机变量描述一个企业一年各日的工作情况,也是不可能的。为什么呢?仔细观察,前者考虑的是静态(即特定时刻——某一日)状态;而后者则要研究动态(即某一个时期内各个时刻)状态,即是随机现象的一个发展过程。这就是随机过程。可见,随机过程可以简单地理解为随机现象的动态变化过程。这是用由静到动的观点对随机过程的解释。也可以从动态过程来理解。所谓过程就是事物的发展变化过程,尽管过程形式各异,但归纳起来不外乎两种,一种是确定性的,一种是随机性的。所谓确定性过程,就是指事物的发展有必然的变化规律,用数学语言来说,就是事物变化的过程可以用一个(或几个)时间 t 的确定的函数来描述。如真空中的自由落体运动,设物体以零初速度开始下落,据力学的基本定律或根据重复观测,有如下的函数关系式 $X(t) = \frac{1}{2}gt^2, t > 0$ 。这个函数关系式确定了物体在任意时刻 $t > 0$ 时,物体离开初始点的精确位置 $X(t)$,因此,自由落体运动中物体离初始点的距离变化过程是个确定性过程。再如加热时水温变化也是确定性过程。

所谓随机过程,就是说现象的变化没有确定形式,没有必然的变化规律。用数学语言来讲,就是事物变化过程不能用一个(或几个)时间 t 的确定的函数来描述。也就是说,如果对事物变化的全过程进行一次观测得到结果是一个时间 t 的函数;但对同一事物的变化过程独立地重复进行多次观测所得的结果是不相同的,如造纸生产中,纸的厚度、重量等都是如此。

下面我们给出随机过程的科学定义:

定义 1 (从时间变化角度来考察)若对于每一个特定的 $t \in T$ (T 是一个无穷集合,称为参数集), $X(t)$ 是一个随机变量,则称这一族无穷多个随机变量 $\{X(t), t \in T\}$ 是一个随机过程。可见,随机过程 $X(t)$ 是依赖于时间 t 的一族随机变量。

定义 2 (从试验结果来看)若对事物变化的全过程进行一次观测,得到的结果是一个时间 t 的函数,但对同一事物的变化过程独立地重复进行多次观测,所得的结果是不相同的,则称这种变化过程为随机过程。

定义 3 设 E 是随机试验, S 是它的样本空间,如果对于每一个 $e \in S$, 我们总可以依某种规则确定一时间 t 的函数

$$X(e, t), t \in T$$

与之对应(T 是时间 t 的变化范围),于是,对于所有的 $e \in S$ 来说,就得到一族

时间 t 的函数,我们称这族时间 t 的函数为随机过程,而族中每一个函数为这个随机过程的样本函数(或一次实现、现实)。

随机变量与随机过程既有区别又有联系,主要区别有:

(1)随机变量 (R, V) 是定义在样本空间上的一个单值实函数,随机过程 (S, P) 则是一族时间 t 的函数。

(2)对应于一定随机试验和样本空间的随机变量与时间 t 无关;而 (S, P) 则与时间密切相关。

(3)随机变量 (R, V) 描述事物在某一特定时刻上的静态;随机过程 (S, P) 描述事物发展变化的动态。

其主要联系表现为:

(1)随机过程 (S, P) 具有随机变量 (R, V) 的特性,同时还具有普通函数的特性。

(2)随机变量是随机过程的特例。即一元随机变量可视为参数集为单元素集的随机过程。

(3)当随机过程固定某一个时刻时,就得到一个随机变量。

(4)随机过程是 n 维随机向量、随机变量列的一般化,它是随机变量 $X(t)$ 的集 $t \in T$ 。

二、平稳随机过程

随机过程的基本类型很多,主要有:

(1)纯随机过程——白噪声:随机过程 $X(t)$ ($t=1, 2, \dots$),如果是由一个不相关的随机变量的序列构成的,即对于所有 $s \neq t$,随机变量 X_s 和 X_t 的协方差均为零,则称其为纯随机过程。对于一个纯随机过程来说,若其期望和方差均为常数,则称之为白噪声过程。白噪声过程的样本实现称为白噪声序列,简称白噪声(White noise)。之所以称之为白噪声,是因为它与白光的特性类似,白光的光谱在各个频率上有相同的强度,白噪声的谱密度在各个频率上的值相同。对不具备这种特性的噪声,称为有色噪声(colour noise)。图 1.7 是一个具有零均值,单位方差阵正态白噪声序列(100 个数据)的示意图。

(2)独立增量(可加)随机过程:对于任意正整数 n ,任意 $t_i \in T$ ($i=1, 2, \dots, n, t_1 < t_2 < \dots < t_n$),随机变量 $X(t_2) - X(t_1), X(t_3) - X(t_2), \dots, X(t_n) - X(t_{n-1})$ 相互独立。简单地讲,就是任意两相邻时刻上的随机变量之差(增量)是相互独立的。

(3)二阶矩过程:若随机过程 $\{X(t), t \in T\}$ 对每个 $t \in T, X(t)$ 的均值和方




图 1.7 正态白噪声序列

差存在,则称之为二阶矩过程。

(4)正态过程:若 $\{X(t)\}$ 的有限维分布都是正态分布,即若 $X(t)$ 的 n 维概率密度为

$$f_n(x_1, x_2, x_3, \dots, x_n, t_1, t_2, \dots, t_n) \\ = \frac{1}{(2\pi)^{\frac{n}{2}} |C|^{\frac{1}{2}}} e^{-\frac{1}{2}(x-\mu)' C^{-1}(x-\mu)}$$

则称 $\{X(t)\}$ 为正态随机过程。

其中 $X = (x_1, x_2, \dots, x_n)'$

$$\mu = (\mu_x(t_1), \mu_x(t_2), \dots, \mu_x(t_n))'$$

C 为协方差阵,即:

$$C = \begin{Bmatrix} C_x(t_1, t_1) & C_x(t_1, t_2) & \dots & C_x(t_1, t_n) \\ C_x(t_2, t_1) & C_x(t_2, t_2) & \dots & C_x(t_2, t_n) \\ \dots & \dots & \dots & \dots \\ C_x(t_n, t_1) & C_x(t_n, t_2) & \dots & C_x(t_n, t_n) \end{Bmatrix}$$

矩阵元素

$$C_x(t_i, t_j) = E\{[X(t_i) - \mu_x(t_i)][X(t_j) - \mu_x(t_j)]\} \\ = C_x(t_j, t_i) \quad i, j = 1, 2, \dots, n$$

(5)平稳过程:简单地讲,就是统计特性不随时间的平移而变化的过程。用

数学语言来描述,就是:如果对于时间 t 的任意 n 个值 $t_1, t_2, \dots, t_n$ 和任意实数 ϵ , 随机过程 $X(t)$ 的 n 维分布函数满足关系式:

$$\begin{aligned} F_n(x_1, x_2, \dots, x_n; t_1, t_2, \dots, t_n) \\ = F_n(x_1, x_2, \dots, x_n; t_1 + \epsilon, \dots, t_n + \epsilon) \end{aligned}$$

则称 $X(t)$ 为平稳过程。

由于分布函数完整地描述了随机变量的统计特性,所以,这里要求平稳随机过程的所有的统计特性都不随时间的平移而变化。这一要求是相当严格的,故称之为严平稳(狭义平稳)。那么,如何来判定一个随机过程是否是一个平稳随机过程呢?显然就是看其是否满足上述条件。可这在实际中是十分困难的。一般来说,所研究的随机过程,若前后的环境和主要条件都不随时间变化,就可以认为它是平稳随机过程。例如,在工农业生产中,若原料的质量,机器的性能、工艺过程、工人的技术水平、自然条件(气温、雨量等)没有剧烈的变化,就可以认为相应的过程是平稳的。

这样要求未免有点过分,当把条件适当放宽时,便得到了宽平稳随机过程。定义如下:若随机过程 $\{X(t), t \in T\}$ 的均值(一阶矩)和协方差存在,且满足:

$$(i) \quad E[X(t)] = a \quad \forall t \in T$$

$$(ii) \quad E[x_{t+\tau} - a][X_t - a] = R(\tau)$$

$$\forall t, t + \tau \in T$$

则称 $\{X(t), t \in T\}$ 为宽平稳随机过程, $R(\tau)$ 为 $X(t)$ 的协差函数。

例如,白噪声就是一个宽平稳随机过程。设 $X_k (k = \dots, -2, -1, 0, 1, 2, \dots)$ 是一列独立同分布的随机变量, $E(X_k) = 0, E(X_k^2) = \sigma^2, K = \dots, -2, -1, 0, 1, 2, \dots$ 。随机变量序列(离散参数随机过程) $X_t (t \in \{\dots, -2, -1, 0, 1, 2, \dots\})$ 的平稳性证明如下:由已知得

$$EX_t = 0$$

$$E(X_{t+\tau} X_t) = \begin{cases} E(X_k^2) = \sigma^2, & \tau = 0 \\ 0, & \tau \neq 0 \quad (X_k \text{ 独立}) \end{cases}$$

所以 X_k 的自相关函数仅与 τ 有关,故是宽平稳过程。宽平稳与严平稳有严格的区别,主要表现在:

宽平稳对时间推移的不变性表现在统计平均的一、二阶矩上,严平稳对时间推移的不变性表现在统计平均的概率分布上;二者的要求不同,一般说来,严平稳比宽平稳要求要“严”。

二者也有一定的联系:

(i) 严 $\nRightarrow$ 宽: 因为宽平稳要求期望和协方差存在, 而严平稳要求概率分布存在, 并不断言一、二阶矩存在。而事实上很多存在概率分布的变量不存在期望和方差。如柯西分布, 一、二阶矩均不存在。

(ii) 宽 $\nRightarrow$ 严: 这是不言而喻的。

(iii) 严平稳 + 二阶矩存在 $\Rightarrow$ 宽平稳。但反过来一般不成立。

(iv) 对于正态过程来说, 有: 严平稳 $\Leftrightarrow$ 宽平稳

“ $\Rightarrow$ ”: 正态过程一、二阶矩存在

$\therefore$ 由 (iii) 知, 显然成立。

“ $\Leftarrow$ ” 由于正态过程的概率密度是由均值和自协方差函数完全确定的, 因而若均值和自协方差函数不随时间平移而变化, 概率密度也不随时间的平移而变化。因此一个宽平稳的正态过程必然也是严平稳的。

三、非平稳随机过程

不具有平稳性的过程就是非平稳过程。一般来说, 当环境及主要条件随时间变化时, 就可以认为是非平稳的。如工艺革新、原材料质量提高(或下降)、设备更新等现象发生时, 产品某一质量指标 $X(t)$ 就是一个非平稳过程。

四、自相关

就是指时间序列观察资料相互之间的依存关系。这种依存关系既可以用相关函数来表示, 称为自相关函数(详见第三章); 也可以用一个回归模型来表示。这个回归模型把现在的观测值表示为独立的两部分: 一部分依赖于以前(过去)的观测值, 一部分是独立的序列。例如: 设 X_t 只与其前一期有关(比如一个患者服药), 则有

$$X_t = \varphi X_{t-1} + a_t \quad (1.4.1)$$

可见, 这个模型表示的是 X_t 对它自身过去值的依存关系, 所以称之为自回归模型。在刻画相关性方面, 这个模型与静态回归模型具有本质的区别。

众所周知, 在静态回归模型中, 设 X 为解释变量, Y 为依变量, 则有

$$Y_t = \beta + \alpha X_t + \varepsilon_t \quad (1.4.2)$$

称为一元线性回归模型。其中 Y 是随机变量, X 是确定变量, 是 Y 对 X 的回归, 描述的是两个不同现象之间的统计依存关系。现在, 解释变量是依变量的滞后变量, 也就是说是它自身的前期值, 因而它表示 X_t 对其前期值 X_{t-1} 的回归, 描述的是同一过程在 t 时刻的实现和 $t-1$ 时刻的实现之间的相关性。

其次, 静态回归模型主要是揭示两个现象之间内在的相关关系, 因而刻画

的是静态相关关系。

在(1.4.1)式中,由于 X_{t-1} 为已知,从而它是一个确定性变量,所以在 $t-1$ 时,模型(1.4.1)式是一个普通回归模型。当固定 X_{t-1} 时,自回归模型是一个条件回归模型。当 X_{t-1} 不固定时,方程(1.4.1)变成了一个动态模型。因 X_{t-1} 本身依赖于 X_{t-2} ,即

$$X_{t-1} = \varphi X_{t-2} + a_{t-1}$$

X_{t-2} 又依赖于 X_{t-3} ,即


$$X_{t-2} = \varphi X_{t-3} + a_{t-2}$$

等等。它描述的是一种动态相关性。

五、动态性(即记忆性)

所谓动态性,从统计观点来看,就是指系统现在的行为与其历史行为的相关性。体现在时序中,就是观测值之中蕴含着的相关关系,因此,可用相关函数来刻画系统(时序)的动态性。

从系统的观点来看,动态性就是指系统的记忆性。具体地说,就是在某一时刻进入系统的输入对系统后继行为的影响。如果该输入只影响系统的下一时刻的行为,而对下一时刻以后的行为不发生作用,那么系统就有一阶动态性(或一期记忆性)。依次类推,如果该输入对系统后继 n 个时刻的行为都有影响,那么就说该系统具有 n 阶动态性。例如:一个患者服用镇痛药,在时刻 t 服用,相当于在时刻 t 进入神经系统的一个输入——镇痛药;结构图如下:



假如,此药仅在下一个时刻有效,此后而无效,该系统的动态性可图示如下:




图 1.8 一期记忆

即 T 时刻服药, $T+1$ 时刻精神很好, $T+1$ 以后又恶化,则该系统具有一阶动态性或一期记忆性。假设此药在服药后四个小时内有效,且效力递减,第五个小时后无效,则系统的动态性可图示如下:




图 1.9 四期记忆

即该系统有四阶动态性或四期记忆性。

系统的记忆性如何量化,这是时间序列分析的主要内容,时间序列模型就是系统记忆性的具体描述,建模过程就是记忆性的量化过程。例如,某一系统的输入、输出如下:

时间	t	1	2	3	4	5	6
输入	W_t	0	0	c	0	0	0
输出	X_t	0	0	$\phi_0 c$	0	0	0

显然,这是一个即时响应系统,即本期的输入只影响本期的输出,而不影响系统的后继行为(输出)。可用 $X_t = \phi_0 W_t$ 模型来描述。

假设另一系统的运行情况如下:

时间	t	1	2	3	4	5	6
输入	W_t	0	0	c	0	0	0
输出	X_t	0	0	0	$\phi_1 c$	0	0

可见,该系统本期的输入不影响当期的输出,而只影响下一期的输出。对于这样的系统,可用 $X_t = \phi_1 W_{t-1}$ 模型来描述。

我们再看一个更复杂一点的系统,假设其输入、输出关系如下:

时间	t	1	2	3	4	5	6
输入	W_t	0	0	c	0	0	0
输出	X_t	0	0	$\phi_0 c$	$\phi_1 c$	0	0

不难看出,该系统本期输入除影响本期输出(影响程度为 ϕ_0)之外,还影响下一期输出(影响程度为 ϕ_1)。因而,可用 $X_t = \phi_0 W_t + \phi_1 W_{t-1}$ 模型来描述。

类推下去,许多系统的记忆性,可用以下模型来描述:

$$X_t = \phi_0 W_t + \phi_1 W_{t-1} + \phi_2 W_{t-2} + \dots$$

其中 $\phi_j (j=0,1,2,\dots)$ 为 W_{t-j} 对 X_t 的影响程度,换句话说,就是在 t 时刻系统对 W_{t-j} 的记忆程度。因此, ϕ_j 称为记忆函数(memory function)。可见,时间序列中客观存在着记忆函数,是人们可以根据时间序列认识系统运行规律和预测其未来态势的根本原因;求解记忆函数是时间序列分析的主要内容。在对时

间序列进行具体分析时,应根据所掌握的信息建立相应的模型,寻找出具体的记忆函数。如果既有输出变量的信息,又有输入变量的信息 W_t ,则应考虑建立以下模型:

$$X_t = \phi_0 W_t + \phi_1 W_{t-1} + \phi_2 W_{t-2} + \cdots + e_t$$

并设法求出 ϕ_j 及 e_t 对 X_t 的影响;如果无法取得输入变量 W_t 的信息,那么,我们只能依据输出变量自身的信息来建立模型,这就是单变量时间序列分析问题。此时,若时间序列是平稳的,则可考虑以后章节将要详细介绍的自回归模型(Auto Regressive model),简称 AR 模型,移动平均模型(Moving Average model)简称 MA 模型和自回归移动平均模型(Auto Regressive Moving Average model)简称 ARMA 模型。

AR(n)即 n 阶自回归模型为:

$$X_t = \varphi_1 X_{t-1} + \varphi_2 X_{t-2} + \cdots + \varphi_n X_{t-n} + a_t$$

MA(m)即 m 阶移动平均模型为:


$$X_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \cdots - \theta_m a_{t-m}$$

ARMA(n, m)即 n 阶自回归 m 阶移动平均模型为:

$$\begin{aligned} X_t - \varphi_1 X_{t-1} - \varphi_2 X_{t-2} - \cdots - \varphi_n X_{t-n} \\ = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \cdots - \theta_m a_{t-m} \end{aligned}$$

若时间序列是非平稳的,则可先对序列进行差分运算,然后再建立 ARMA 模型,即求和自回归移动平均模型(Auto Regressive Integrated Moving Average model)简称 ARIMA 模型。

显然,从模型形式上可以直观地看出,AR 模型描述的是系统对过去自身状态的记忆,MA 模型描述的是系统对过去时刻进入系统的噪声的记忆,而 ARMA 模型则是系统对过去自身状态以及各时刻进入的噪声的记忆。事实上,上述各种模型,包括 ARIMA 在内,都可以概括成如下结构:



这一点将在第二、三章进一步论述。

第二章

平稳时间序列模型

时间序列的模型类型很多,我们这里只讨论平稳时间序列模型。这里讲的平稳是指宽平稳,其特性是序列的统计特性不随时间的平移而变化,即均值和协方差不随时间的平移而变化。

第一节 一阶自回归模型

一、一阶自回归模型

如果时间序列 $X_t(t=1, 2, \dots)$ 是独立的, 没有任何依赖关系, 那就是说事物的后一时刻的行为主要与其前一时刻的行为毫无关系。这样的资料所揭示的统计规律就是事物独立地随机变动, 系统无记忆能力。如果情况不是这样, 资料之间有一定的依存性, 那么最简单的关系就是后一时刻的行为主要与其前一时刻的行为有关, 而与其前一时刻以前的行为无直接关系, 即已知 X_{t-1} , X_t 主要与 X_{t-1} 相关。用记忆性来说, 就是最短的记忆, 即一期记忆, 也就是一阶动态性。描述这种关系的数学模型就是一阶自回归模型。即

$$X_t = \phi_1 X_{t-1} + a_t \quad (2.1.1)$$

记作 $AR(1)$ 。其中, X_t 为零均值(即中心化处理后的)平稳序列(以后章节中若无特别说明, X_t 均指零均值平稳序列), φ_1 为 X_t 对 X_{t-1} 的依赖程度, a_t 为随机扰动。

这种模型有什么特点呢? 或者说, 如何知道是一阶动态, 而不是二阶或其它, 也不是时间函数模型呢?

1. 一阶自回归模型的特点

我们知道, 在时间函数模型中, 如果我们将一组观察值及其相应的时间, 在平面上标绘出来, 就会显示出一定的趋势性。




图 2.1 X_t 与 t 的散点图

这是因为 X 对 t 有一定的依赖性。现在是 X_t 对 X_{t-1} 有一定的依赖性, 按照同样的思想, 我们可以把 X_t 与 X_{t-1} 在平面上标绘出来。如图 2.2 所示。

这表明, X_t 对 X_{t-1} 有直线相关关系; a_t 为独立正态同分布序列, 记作 $a_t \sim NID(0, \sigma_a^2)$; a_t 与 X_{t-j} ($j=2, 3, \dots$) 独立。前两者是一阶自回归模型的基本假设。

用类似于分析普通一元线性回归模型的方法来考察(2.1.1)可知, $AR(1)$ 模型也把 X_t 分解为独立的两部分: 一是依赖于 X_{t-1} 的部分, $\varphi_1 X_{t-1}$; 二是与 X_{t-1} 不相关的部分, a_t 。

2. $AR(1)$ 与普通一元线性回归的关系

普通一元线性回归模型可表示为




图 2.2 X_t 与 X_{t-1} 的散点图

$$Y_i = bX_i + \epsilon_i \quad i=1, 2, \dots \quad (2.1.2)$$

其中 Y_i 与 X_i 为中心化处理后的序列。

从形式上看,模型(2.1.1)与(2.1.2)非常相似,但是二者既有联系,又有区别,其主要区别有:

(1)普通线性回归模型需要一组确定性变量值和相应的观测值;AR(1)模型只需要一组随机变量的观测值。

(2)普通一元线性回归表示的是一个随机变量对另一个确定性变量的依存关系;而AR(1)表示的是一个随机变量对其自身过去值的依存关系。

(3)普通线性回归是在静态的条件下研究的;AR(1)是在动态的条件下研究的。

(4)二者的假定不同。普通回归模型要求: ϵ_i 独立,且 ϵ_i 与 X_i 独立, X_i 为确定变量, Y_i 是独立的随机变量,对于每一个 X_i , ϵ_i 的方差是一个正常数, $\text{Var}(\epsilon_i | X_i) = E(\epsilon_i^2)$ 。AR(1)只要求 a_i 为独立序列; X_i 是个随机变量序列,两个时刻上的随机变量之间存在一定的相关性。

(5)普通回归模型,实质上是一种条件回归,而AR(1)是无条件回归。

主要联系表现为:

固定时刻 $t-1$,且观察值 X_{t-1} 已知时,AR(1)就是一个普通的一元线性

回归模型了。

3. 相关序列的独立化过程

这里 x_t 是相关的, 而我们所用的许多统计方法却都是以资料独立为基础的。如果我们直接用以资料独立为基础的统计方法来处理相关的序列是不合理的。怎么办? 我们来看(2.1.1)式的另一种形式:

$$a_t = X_t - \varphi_1 X_{t-1} \quad (2.1.3)$$

虽然(2.1.3)式仅是(2.1.1)式的一个简单变形, 但它却揭示了 AR(1)的一个实质性问题: AR(1)模型是一个使相关数据转化为独立数据的变化器。那么, 这是怎样转化的呢? 由于就 AR(1)系统来说, 仅有一阶动态性, 即在 X_{t-1} 已知的条件下, X_t 的依赖性主要表现为 X_t 对 X_{t-1} 的直接依赖性, 而 X_t 与 X_{t-j} ($j=2, \dots$) 不存在直接的依存关系。显然, 只要把 X_t 中依赖于 X_{t-1} 的部分消除以后, 剩下的部分 $(X_t - \varphi_1 X_{t-1})$ 自然就是独立的了。

二、AR(1)模型的特例——随机游动

1. $\varphi_1=1$ 时的 AR(1)模型:

考察(2.1.1)式, 当 $\varphi_1=1$ 时, 有

$$X_t = X_{t-1} + a_t \quad (2.1.4)$$

即

$$X_t - X_{t-1} = a_t$$

或

$$\nabla X_t = a_t$$

其中符号 ∇ 表示差分算子。所谓差分, 就是 X_t 与其前一期值的差, 从统计上讲, 差分结果所得到的序列就是逐期增长量。 $Y_t = X_t - X_{t-1}$, 叫作一阶差分, 记作 $Y_t = \nabla X_t$; $Z_t = Y_t - Y_{t-1}$, 叫作 X_t 的二阶差分, 记作 $Z_t = \nabla Y_t = \nabla^2 X_t$; 类似地, 设 X_t 的第 $k-1$ 次的差分结果为 W_t , 则称 $W_t - W_{t-1}$ 为 X_t 的 k 阶差分。可见, 差分的次数就是差分的阶数, 一般地 k 阶差分, 可记作 $\nabla^k X_t$ 。例如:

时刻 t :	1	2	3	4	5	6	7	8	9	10
序列 X_t :	1	2	3	4	5	6	7	8	9	10
∇X_t :	/	1	1	1	1	1	1	1	1	1
$\nabla^2 X_t$:	/	/	0	0	0	0	0	0	0	0

顺便指出, 除了差分的概念之外, 经常还用到季节差分的概念。所谓 k 阶季节差分, 就是指 $X_t - X_{t-k}$, 记作 $\nabla_k X_t$, 也就是 X_t 与其前 k 期观察值的差。如上例, $\nabla_1 X_t = \nabla X_t$, 即一阶季节差分与一阶差分相同, 那么, $\nabla_2 X_t$ 为: / / 2 2 2

2 2 2 2 2。从上例中,可以看出:差分可以使非平稳序列转化为平稳序列。Box—Jenkins(简记为B—J),就是利用类似于这种数学工具来处理非平稳序列的。

2. 特例形式的特性

(1)系统具有极强的一期记忆性,即惯性。也就是说,系统在 $t-1$ 和 t 时刻的响应,除随机扰动外,完全一致。差异完全是由扰动引起的。

(2)在时刻 $t-1$ 时,系统的一步超前预测就是系统在 $t-1$ 时的响应 X_{t-1} ,即 $\hat{X}_{t-1}^{(1)}=X_{t-1}$ 。

(3)系统行为是一系列独立随机变量的和,即

$$X_t = \sum_{j=0}^{\infty} a_{t-j} \quad (2.1.5)$$

第二节 一般自回归模型

对于自回归系统来说,当 X_t 不仅与前期值 X_{t-1} 有关,而且与 X_{t-2} 相关时,显然,AR(1)模型就不再是适应(即符合其假设)模型了。如果对这种情形拟合AR模型, a_t 不仅对 X_{t-1} ,而且对 X_{t-2} 呈现出一定的相关性,这说明, X_t 不仅依赖于 X_{t-1} ,还依赖于 X_{t-2} ,因此,AR(1)模型就不适应了。

一、 a_t 对 X_{t-2} 的依赖性

由于AR(1)模型:

$$X_t = \varphi_1 X_{t-1} + a_t$$

不适应了,即 a_t 与 X_{t-2} 不独立,所以,这里的剩余 a_t 不是我们所假设的 a_t ,记作 a'_t ,于是有

$$X_t = \varphi_1 X_{t-1} + a'_t \quad (2.2.1)$$

由于 a'_t 与 X_{t-2} 存在相关关系,所以,我们对 a'_t 进行分解:

一部分依赖 X_{t-2} 用 $\varphi_2 X_{t-2}$ 表示;另一部分是独立于前一部分的 a_t ,即

$$a'_t = \varphi_2 X_{t-2} + a_t \quad (2.2.2)$$

将(2.2.2)式代入(2.2.1)式,得

$$X_t = \varphi_1 X_{t-1} + \varphi_2 X_{t-2} + a_t \quad (2.2.3a)$$

即

$$X_t - \varphi_1 X_{t-1} - \varphi_2 X_{t-2} = a_t \quad (2.2.3)$$

可见, X_t 与 X_{t-1} 和 X_{t-2} 有关,所以(2.2.3)式是一个AR(2)模型。

二、AR(2)模型的假设和结构

1. AR(2)模型的基本假设

与AR(1)模型相类似,对于AR(2)模型来讲,假设 X_t 仅与 X_{t-1} 和 X_{t-2} 有直接关系,而在 X_{t-1} 和 X_{t-2} 已知的条件下, X_t 与 $X_{t-j}(j=3,4,\dots)$ 无关; a_t 是一个白噪声序列。这就是AR(2)模型的两个基本假设。

2. AR(2)模型的结构

由(2.2.3a)式可以看出,AR(2)模型是由三个部分组成的:第一部分是依赖于 X_{t-1} 的部分,用 $\varphi_1 X_{t-1}$ 表示;第二部分是依赖于 X_{t-2} 的部分,用 $\varphi_2 X_{t-2}$ 表示;第三部分是独立于前两部分的白噪声 a_t 。

(2.2.3)式可以等价地表示为:

$$a_t = X_t - \varphi_1 X_{t-1} - \varphi_2 X_{t-2}$$

可见,AR(2)系统的响应 X_t 具有二阶动态性,AR(2)模型通过把 X_t 中的依赖于 X_{t-1} 和 X_{t-2} 的部分消除掉之后,使得具有二阶动态性(即数据中的相关性)的序列 X_t 转化为独立的序列 a_t 。因此,拟合AR(2)模型的过程也就是使相关序列独立化的过程。

三、一般自回归模型

(2.2.2)式对于自回归系统来说,当AR(2)模型的基本假设被违背以后,即 X_t 不仅与 X_{t-1} 、 X_{t-2} 相关,而且与 X_{t-3} 也相关时,从而 a_t 不独立,显然,AR(2)模型同样不再是适应模型了。如果我们对这种情形继续拟合AR模型,则由于AR(2)模型:

$$X_t = \varphi_1 X_{t-1} + \varphi_2 X_{t-2} + a_t$$

不适应了,即 a_t 与 X_{t-3} 不独立,所以这里的剩余 a_t 不是我们所假设的 a_t ,记作 a'_t ,于是有

$$X_t = \varphi_1 X_{t-1} + \varphi_2 X_{t-2} + a'_t \quad (2.2.4)$$

因 a'_t 与 X_{t-3} 存在相关关系,所以,我们对 a'_t 进行分解:

一部分依赖于 X_{t-3} ,用 $\varphi_3 X_{t-3}$ 表示;另一部分是独立于前一部分的白噪声 a_t ,即

$$a'_t = \varphi_3 X_{t-3} + a_t \quad (2.2.5)$$

将(2.2.5)式代入(2.2.4)式得:

$$X_t = \varphi_1 X_{t-1} + \varphi_2 X_{t-2} + \varphi_3 X_{t-3} + a_t \quad (2.2.6a)$$

即

$$X_t - \varphi_1 X_{t-1} - \varphi_2 X_{t-2} - \varphi_3 X_{t-3} = a_t \quad (2.2.6)$$

可见, X_t 与 $X_{t-1}, X_{t-2}, X_{t-3}$ 有关, 因此, (2.2.6) 式是一个 AR(3) 模型。

那么, 如果 AR(3) 模型中的 a_t 不再是白噪声序列, 而且 X_t 不仅与 $X_{t-1}, X_{t-2}, X_{t-3}$ 有关, 且与 $X_{t-j} (j=4, \dots, n)$ 相关时, AR(3) 模型同样也不再是适应模型了, 我们运用类似的方法进行类推, 对这种情形拟合 AR 模型, 那么, 就可以得到一般自回归模型: 即 AR(n) 模型

$$X_t - \varphi_1 X_{t-1} - \varphi_2 X_{t-2} - \dots - \varphi_n X_{t-n} = a_t \quad (2.2.7)$$

一般地, 对于 AR(n) 模型来说, 假设 X_t 仅与 $X_{t-1}, X_{t-2}, \dots, X_{t-n}$ 有线性关系, 而在 $X_{t-1}, X_{t-2}, \dots, X_{t-n}$ 已知条件下, X_t 与 $X_{t-j} (j=n+1, n+2, \dots)$ 无关, a_t 是一个白噪声序列。这就是一般自回归模型 AR(n) 的基本假设。

由 (2.2.7) 式可以很容易地得到

$$X_t = \varphi_1 X_{t-1} + \varphi_2 X_{t-2} + \dots + \varphi_n X_{t-n} + a_t \quad (2.2.8)$$

可见, (2.2.8) 式所表明的 AR(n) 模型是由 $n+1$ 个部分组成的: 第一部分是依赖于 X_{t-1} 的部分, 用 $\varphi_1 X_{t-1}$ 表示; 第二部分是依赖于 X_{t-2} 的部分, 用 $\varphi_2 X_{t-2}$ 表示; $\dots$, 第 n 部分是依赖于 X_{t-n} 的部分, 用 $\varphi_n X_{t-n}$ 表示; 第 $n+1$ 部分是独立于前 n 部分的白噪声 a_t 。

(2.2.7) 式还可以表示为

$$a_t = X_t - \varphi_1 X_{t-1} - \varphi_2 X_{t-2} - \dots - \varphi_n X_{t-n}$$

可见, AR(n) 系统的响应 X_t 具有 n 阶动态性。AR(n) 模型通过把 X_t 中的依赖于 $X_{t-1}, X_{t-2}, \dots, X_{t-n}$ 的部分消除掉之后, 使得具有 n 阶动态性的序列 X_t 转化为独立的序列 a_t 。因此, 拟合 AR(n) 模型的过程也就是使相关序列独立化的过程。

我们在得到了 AR(n) 模型之后, 那么, 这个模型是否与实际符合呢? 判别这个问题的标准就是看其是否违背前面给定的基本假设。检验的方法很多, 如前面提到的标绘图法和估计相关系数法等, 在以后的章节中我们将详细介绍。

第三节 移动平均模型

前面我们介绍的 AR 系统, 其特征是系统在 t 时刻的响应 X_t 仅与其以前时刻的响应 $X_{t-1}, X_{t-2}, \dots, X_{t-n}$ 有关, 而与其以前时刻进入系统的扰动无关。如果一个系统在 t 时刻的响应 X_t , 与其以前时刻 $t-1, t-2, \dots$ 的响应 $X_{t-1}, X_{t-2}, \dots$ 无关, 而与其以前时刻 $t-1, t-2, \dots$ 进入系统的扰动 $a_{t-1}, a_{t-2}, \dots$ 存在着一

定的相关关系,那么,这一类系统则为 MA 系统。下面,我们将介绍 MA 系统的模型。

一、一阶移动平均模型 MA(1)

对于一个 MA 系统来说,如果系统的响应 X_t 仅与其前一时刻进入系统的扰动 a_{t-1} 存在一定的相关关系,我们就得到模型

$$X_t = a_t - \theta_1 a_{t-1} \quad (2.3.1)$$

其中: a_t 为白噪声。显而易见,(2.3.1)式是一个一阶移动平均模型,简记为 MA(1)。可见 MA(1)模型的基本假设为:系统的响应 X_t 仅与其前一时刻进入系统的扰动 a_{t-1} 有一定的依存关系;而且 a_t 为白噪声。那么,(2.3.1)式所表明 MA(1)模型就将 X_t 分解为两个部分:一部分是依赖于 a_{t-1} 的部分,由 $-\theta_1 a_{t-1}$ 表示;另一部分是与 a_{t-1} 独立的部分 a_t 。

二、一般移动平均模型

对于移动平均系统来说,如果系统在 t 时刻的响应 X_t ,不仅与其前一时刻进入系统的扰动 a_{t-1} 有一定的相关关系,而且与 a_{t-2} 也存在一定的依存关系,那么,这就违背了一阶移动平均模型的基本假设,因此,MA(1)模型也就不再是适应模型了。如果针对这种情形拟合 MA 模型,则得

$$X_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} \quad (2.3.2)$$

这就是 MA(2)模型。

与 MA(1)模型相类似,其基本假设为: X_t 仅与 a_{t-1} 和 a_{t-2} 有关,而与 a_{t-j} ($j=3, \dots, m$) 无关,且 a_t 为白噪声序列。那么,相应地,(2.3.2)式将 X_t 分解为三个部分:一部分依赖于 a_{t-1} 的部分,用 $-\theta_1 a_{t-1}$ 表示;一部分是依赖于 a_{t-2} 的部分,用 $-\theta_2 a_{t-2}$ 表示;一部分是独立于前两部分的 a_t , a_t 为白噪声序列。

如果 MA 系统在时刻 t 的响应 X_t ,不仅仅依赖于上述两个部分,即 a_{t-1} 和 a_{t-2} ,而且还与 a_{t-j} ($j=3, \dots, m$) 存在一定的相关关系,那么,MA(2)模型的基本假定至此也被违背了,相应地,MA(2)模型也将不再是适应模型。对于这种情形,我们继续拟合 MA 模型,则可得到一般的 MA(m)模型,即:

$$X_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \dots - \theta_m a_{t-m} \quad (2.3.3)$$

由(2.3.3)式可以看出, X_t 仅与 $a_{t-1}, a_{t-2}, \dots, a_{t-m}$ 有关,而与 a_{t-j} ($j=m+1, m+2, \dots$) 无关,且 a_t 为白噪声序列,这就是一般移动平均模型的基本假设。同时,(2.3.3)式还表明, X_t 由 $m+1$ 个部分组成:第一部分是依赖于 a_{t-1} 的部分,用 $-\theta_1 a_{t-1}$ 表示;第二部分是依赖于 a_{t-2} 的部分,用 $-\theta_2 a_{t-2}$ 表示;……第 m

部分是依赖于 a_{t-m} 的部分, 用 $-\theta_m a_{t-m}$ 表示; 第 $m+1$ 部分则是独立于前 m 部分的 a_t 。

我们可以看一个关于产科医院的例子。设 a_t 是在第 t 天新住院的病员人数, 而且, 假设这个病员人数构成的序列是一个白噪声序列, 那么, 某一天的住院病员人数与第二天的住院病员人数是无关的。再假设典型的情形是: 10% 的病人住院一天, 50% 的病人住院两天, 30% 的病人住院三天, 10% 的病人住院四天, 那么, 第 t 天住院的病员人数 X_t 将由下式给出

$$X_t = a_t + 0.9a_{t-1} + 0.4a_{t-2} + 0.1a_{t-3}$$

式中, 由于这一典型情形中的各项是随机变化的, 故 $X_t \sim \text{MA}(3)$ 。因此, 我们能够预测一天、两天、三天后的出院人数, 四天以后, 各天出院人数的预测值均为序列的均值。

第四节 自回归移动平均模型

一个系统, 如果它在时刻 t 的响应 X_t , 不仅与其以前时刻的自身值有关, 而且还与其以前时刻进入系统的扰动存在一定的依存关系, 那么, 这个系统就是自回归移动平均系统, 相应的模型记作 ARMA。显然, 对于这样的系统来说要使响应 X_t 转化为独立序列 a_t , 不仅要消除 X_t 依赖于 t 时刻以前的自身部分, 而且还必须消除 X_t 依赖于 t 时刻以前进入系统的扰动的部分。

具体来讲, 当 X_t 不仅与其前期值 X_{t-1} 有关, 而且与 X_{t-2} 及 a_{t-1} 也有关时, 显然 AR(1) 模型就不再是合适的了。例如, 对太阳黑子资料拟合 AR(1) 模型, 参数估计值为 $\varphi_1 = 0.81$, $\sigma_a^2 = 409.08$, 利用散点图法进行适度检验, 可见, a_t 对 a_{t-1} 呈现一种正相关, 而 a_t 对 X_{t-2} 呈现出一种负相关, 若计算 $\hat{\rho}(a_t, a_{t-1}) = 0.53$, $\hat{\rho}(a_t, X_{t-2}) = -0.38$, 这说明, X_t 不仅依赖于 X_{t-1} , 还依赖于 X_{t-2} 和 a_{t-1} , 当然, AR(1) 模型就不适应了。

一、ARMA(2,1)模型

1. a_t 对 X_{t-2} 和 a_{t-1} 的相关性

由于 AR(1) 模型:

$$X_t = \varphi_1 X_{t-1} + a_t$$

已不是适应模型, 即 a_t 与 X_{t-2} 和 a_{t-1} 不独立, 所以, 这里的剩余 a_t 不是我们所假设的 a_t , 将其记作 a'_t , 于是有

$$X_t = \varphi_1 X_{t-1} + a'_t \quad (2.4.1)$$

由于 a_t 与 X_{t-2} 和 a_{t-1} 存在相关关系, 所以, 我们对 a'_t 进行分解:

一部分依赖于 X_{t-2} , 用 $\varphi_2 X_{t-2}$ 表示;

一部分依赖于 a_{t-1} , 用 $\theta_1 a_{t-1}$ 表示;

最后一部分是独立于前两部分的 a_t , 则

$$a'_t = \varphi_2 X_{t-2} - \theta_1 a_{t-1} + a_t \quad (2.4.2)$$

这等价于: X_t 与 X_{t-1} 和 X_{t-2} 有关, 所以从 X_t 中减去这两个因素, 即

$$X_t - \varphi_1 X_{t-1} - \varphi_2 X_{t-2}$$

消除这两部分之后, 得到的剩余 a''_t 与其自身相关, 故再从 a''_t 中消除 $\theta_1 a_{t-1}$, 便有 $a_t - \theta_1 a_{t-1}$ 。将 (2.4.2) 式代入 (2.4.1) 式, 得

$$X_t = \varphi_1 X_{t-1} + \varphi_2 X_{t-2} - \theta_1 a_{t-1} + a_t \quad (2.4.3)$$

即

$$X_t - \varphi_1 X_{t-1} - \varphi_2 X_{t-2} = a_t - \theta_1 a_{t-1}$$

这就是 ARMA(2,1) 模型。

2. ARMA(2,1) 模型的基本假设

在 ARMA 模型中, 若 X_t 中确实除了对 X_{t-1} , X_{t-2} 和 a_{t-1} 的依存关系以外, 在 X_{t-1} 和 X_{t-2} 已知条件下对其它的 X_{t-j} ($j=3, 4, \dots$) 和 a_{t-j} ($j=2, 3, \dots$) 不存在相关关系, 那么, (2.4.3) 式中的 a_t 一定独立于 a_{t-j} ($j=2, 3, \dots$), 当然也就独立于 X_{t-j} ($j=3, 4, \dots$), 这就是 ARMA(2,1) 模型的基本假设。

3. ARMA(2,1) 模型的结构

从模型

$$X_t = \varphi_1 X_{t-1} + \varphi_2 X_{t-2} + a_t - \theta_1 a_{t-1}$$

中不难看出, ARMA(2,1) 模型把 X_t 分解成了独立的四个部分, 所以, 其结构概括地讲, 是由一个 AR(2) 和一个 MA(1) 两部分构成的, 具体地说, 是由上述四部分构成的。

4. 相关序列的独立化过程

将 (2.4.3) 式作如下变形:

$$a_t = X_t - \varphi_1 X_{t-1} - \varphi_2 X_{t-2} + \theta_1 a_{t-1} \quad (2.4.4)$$

可见, ARMA(2,1) 是通过从 X_t 中消除 X_t 对 X_{t-1} , X_{t-2} 以及 a_{t-1} 的依赖性之后, 使得相关序列 X_t 转化成为独立序列 a_t , 即它是一个使相关序列转化为独立序列的变换器。

5. ARMA(2,1) 与 AR(1) 的区别

从模型形式看, ARMA(2,1) 比 AR(1) 的项数多; 从模型的动态性看, ARMA(2,1) 比 AR(1) 具有更长的记忆; 从计算 a_t 所需的资料看, ARMA(2,

1) 需要用 t 期以前的 $a_{t-1}, a_{t-2}, \dots$, 这就需要从初期开始递归地计算出 a_t 来, 通常 $t=0$ 时的 a_t 取序列 a_t 的均值零; 从参数估计来看, ARMA(2,1) 比 AR(1) 困难得多。

二、ARMA(2,1)模型的非线性回归

为了计算 X_t 的值, 必须知道 a_{t-1} 的值, 然而在动态的条件下, a_{t-1} 本身又取决于 $X_{t-1}, X_{t-2}, X_{t-3}$ 和 a_{t-2} 。这是因为在时刻 $t-1$, 有

$$X_{t-1} = \varphi_1 X_{t-2} + \varphi_2 X_{t-3} - \theta_1 a_{t-2} + a_{t-1} \quad (2.4.5)$$

变形, 得

$$a_{t-1} = X_{t-1} - \varphi_1 X_{t-2} - \varphi_2 X_{t-3} + \theta_1 a_{t-2} \quad (2.4.6)$$

将(2.4.6)式代入(2.4.3)式, 有

$$\begin{aligned} X_t &= \varphi_1 X_{t-1} + \varphi_2 X_{t-2} - \theta_1 (X_{t-1} - \varphi_1 X_{t-2} - \varphi_2 X_{t-3} + \theta_1 a_{t-2}) + a_t \\ &= (\varphi_1 - \theta_1) X_{t-1} + (\varphi_2 + \theta_1 \varphi_1) X_{t-2} + \theta_1 \varphi_2 X_{t-3} - \theta_1^2 a_{t-2} + a_t \end{aligned} \quad (2.4.7)$$

在(2.4.7)式中, 对于待估参数 φ_1, φ_2 和 θ_1 , 不再是一次的了, 而出现了二次项, 所以不再是线性的, 更何况, (2.4.7)式中仍含有 a_{t-2} 项, a_{t-2} 又取决于 $X_{t-2}, X_{t-3}, X_{t-4}$ 和 a_{t-3} , 依次类推。既然是非线性的, 那么估计参数时, 只能用非线性最小二乘法, 其基本思想就是在曲面上搜索使得剩余平方和最小的参数值, 有计算程序, 多次迭代即可。

三、ARMA(2,1)模型的其他特殊情形

1. ARMA(1,1)

当 ARMA(2,1) 中的 $\varphi_2 = 0$ 时, 有

$$X_t = \varphi_1 X_{t-1} - \theta_1 a_{t-1} + a_t \quad (2.4.8)$$

即为 ARMA(1,1) 模型。

2. MA(1)

当 ARMA(2,1) 中的 $\varphi_1 = \varphi_2 = 0$ 时, 有

$$X_t = a_t - \theta_1 a_{t-1} \quad (2.4.9)$$

即为 MA(1) 模型。

3. AR(1)

当 ARMA(2,1) 中的 $\varphi_2 = \theta_1 = 0$ 时, 有

$$X_t = \varphi_1 X_{t-1} + a_t \quad (2.4.9)$$

即为 AR(1) 模型。

因此, 在建立模型时, 首先拟合一个 ARMA(2,1) 模型, 然后根据其参数

值 φ_1, φ_2 和 θ_1 是否显著小这一信息, 来寻找较合理的模型, 然后拟合出那个较合理的模型, 并检验其适应性。比如, 假定 φ_2 和 θ_1 较小, 即拟合 AR(1) 并检验剩余平方和是否显著增加。

四、ARMA($n, n-1$)模型

如果一个 ARMA(2, 1) 模型是不适应的, 那就是说违背了基本假设, 即 a_t 与 $a_{t-2}, a_{t-3}, \dots$ 不独立, 从而与 $X_{t-3}, X_{t-4}, \dots$ 也不独立。按照和推导 ARMA(2, 1) 模型相同的思路, 可以考虑 X_t 不仅依赖于 X_{t-1}, X_{t-2} 和 a_{t-1} , 可能比 ARMA(2, 1) 的记忆长。消除这三部分以后的剩余仍不独立, 首先可以想到它还依赖于 X_{t-3} 和 a_{t-2} , 于是, 将不独立的 a'_t 分解成三部分:

$$a'_t = \varphi_3 X_{t-3} - \theta_2 a_{t-2} + a_t \quad (2.4.10)$$

将 (2.4.10) 式代入 ARMA(2, 1), 得

$$X_t = \varphi_1 X_{t-1} + \varphi_2 X_{t-2} + \varphi_3 X_{t-3} + a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} \quad (2.4.11)$$

或

$$X_t - \varphi_1 X_{t-1} - \varphi_2 X_{t-2} - \varphi_3 X_{t-3} = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2}$$

上式左端为 AR(3), 右端为 MA(2), 故称为 ARMA(3, 2)。

按照同样的思想, 一直如此类推下去, 便可得到 ARMA($n, n-1$) 模型, 模型的左端应为 AR(n), 右端应为 MA($n-1$), 即

$$X_t - \varphi_1 X_{t-1} - \dots - \varphi_n X_{t-n} = a_t - \theta_1 a_{t-1} - \dots - \theta_{n-1} a_{t-n+1} \quad (2.4.12)$$

从 (2.4.12) 式可以看出, X_t 也可由下式表述:

$$X_t = \varphi_1 X_{t-1} + \dots + \varphi_n X_{t-n} + a_t - \theta_1 a_{t-1} - \dots - \theta_{n-1} a_{t-n+1}$$

则 X_t 被分解成 $(n+n-1+1) = 2n$ 部分。如果在 $t-1$ 时刻, $X_{t-1}, X_{t-2}, \dots, X_{t-n}$ 和 $a_{t-1}, \dots, a_{t-n+1}$ 均为已知, 且固定下来时, ARMA($n, n-1$) 就是一个条件回归。

将 (2.4.12) 式作如下变形

$$a_t = X_t - \varphi_1 X_{t-1} - \dots - \varphi_n X_{t-n} + \theta_1 a_{t-1} + \dots + \theta_{n-1} a_{t-n+1} \quad (2.4.13)$$

在消除了 X_t 对其自身前 n 期值的依存关系和对前 $n-1$ 期 a_t 的依存关系以后, 使相关序列 X_t 转化为独立序列 a_t 。

相类似, ARMA($n, n-1$) 模型的基本假设为: a_t 独立于 a_{t-j} ($j = n, n+1, \dots$), 从而 a_t 独立于 X_{t-j} ($j = n+1, n+2, \dots$)。

五、ARMA($n, n-1$)与 ARMA(n, m)

1. 建模策略

利用上述 ARMA 模型的生成过程及其特性,我们可以得到对某一系统的一系列动态观察数据拟合 ARMA 模型的基本策略。即通过逐渐增加 $ARMA(n, n-1)$ 模型的阶数,使得越来越接近一组数据的依存关系,停止在不能使这种逼近更有效地得到改善的 n 的数值上。

2. $ARMA(n, m)$ 模型

$ARMA(n, n-1)$ 模型总是自回归阶数比移动平均阶数大 1。我们在第三章将会看到 $ARMA(n, n-1)$ 模型就是一个 n 阶非齐次差分方程。欲求得 n 阶非齐次方程的一个特解,必须有 n 个初始条件,其中有一个条件必须是 $1 = g_1 + g_2 + \cdots + g_n$, 因此,只剩下 $n-1$ 个条件待定。这是一般情况,有没有移动平均阶数不等于 $n-1$ 的时候呢? 答案是肯定的。从前边所述可以看出, $m \neq n-1$ 的模型实际上是 $ARMA(n, n-1)$ 模型的某些参数 φ_i 或 θ_i 为零的特殊情形,所以建模策略仍适应。

六、 $ARMA(n, n-1)$ 模型的合理性

为什么我们以 $ARMA(n, n-1)$ 模型为一般形式来建立时序模型呢? 难道一个 $ARMA(n, n-1)$ 模型总可以描述一个时间序列吗? 对于平稳系统来说,这是毫无疑问的。之所以以 $ARMA(n, n-1)$ 为基本模型是因为下述理由:

第一, AR、MA、 $ARMA(n, m)$ 模型都是 $ARMA(n, n-1)$ 模型的特殊情形。

第二, 理论依据: 用 Hilbert 空间线性算子的基本理论可以证明, 对于任何平稳随机系统, 我们都可以用一个 $ARMA(n, n-1)$ 模型近似到我们想要达到的程度; 用差分方程的理论也可以证明, 对于 n 阶自回归, MA 模型的阶数应该是 $n-1$ 。

第三, 从连续系统的离散化过程来看, $ARMA(n, n-1)$ 也是合理的。在一个 n 阶自回归线性微分方程和任意阶的移动平均数的形式下, 如果一个连续自回归移动平均过程在一致区间上抽样, 那么, 这个抽样过程的结果是 $ARMA(n, n-1)$ 。

思考与练习

2.1 下面是对一个化学反应器每分钟所做的温度测量值 X :

200 202 208 204 204 207 207 204 202 199 201 198

200 202 203 205 207 211 204 206 203 203 201 198

200 206 207 206 200 203 203 200 200 195 202 204

(a) 画出该时间序列的图形;

(b) 画出 X_{t+1} 对 X_t 的图形;

(c) 画出 X_{t+2} 对 X_t 的图形。

在对这些图进行观察之后,你认为该序列是自相关的吗?

2.2 有 $t=1,2,\dots,8$ 的数据序列如下:

7.0 6.8 7.3 7.5 8.3 5.8 6.3 6.4

(a) 求均值 $\bar{x}$ 和减去均值后的序列 X_t ;

(b) 用 AR(1) 模型拟合 X_t , 求 φ_1 的估计;

(c) 计算残差序列 $a_t, t=2,3,\dots,8$;

(d) 求 σ_a^2 的估计;

(e) 作 X_t 对 X_{t-1} 的图形,并在同一图上画出直线 $\hat{X}_t = \hat{\varphi}_1 X_{t-1}$;

(f) 作出 a_t 对 a_{t-1} 的图形,并计算其相关函数;

(g) 作出 a_t 对 X_{t-2} 的图形,并计算其相关函数。

2.3 对 2.2 题的结论:

(a) 在时刻 $t=8$ 求 X_t 的一步超前预测及 95% 的概率限;

(b) 给定 X_8 条件下 X_9 的分布是什么?

(c) 若 $t=9$ 时, $X_9=0.4$, 试求 (a) 的预测误差。

2.4 对于一个 AR(1) 模型, $X_t=25$, 且 $\hat{X}_t(1)$ 的 95% 的概率限为 (15.5, 9.5), 求模型中的 φ_1 和 σ_a^2 的值。

2.5 (a) 对于一个 AR(1) 模型, 证明

$$\text{Var}(X_t) = \frac{\sigma_a^2}{1 - \varphi_1^2}$$

(b) 在上面的证明过程中, 哪里用到了平稳性?

(c) 对于一个随机走动模型, X_t 的方差是多少?

2.6 一个有 200 个观测值的序列, 方差为 10, 假设其适合一个 $\hat{\varphi}_1=0.8$ 的 AR(1) 模型, 试求

(a) $\hat{\sigma}_a^2$;

(b) 剩余平方和 Q 。

性,我们先简单介绍线性差分方程的一般知识。

我们知道常系数线性微分方程是描述连续时间系统动态性的工具,相应的描述线性定常离散时间系统的主要数学工具是常系数差分方程。“定常”是指系统参数是常数。

$$y(k+n)+a_{n-1}y(k+n-1)+\cdots+a_0y(k)=u(k) \quad (3.1.1)$$

是普通的 n 阶差分方程,其中 $a_0, \cdots, a_{n-1}$ 为系统参数的函数,当 $a_0, \cdots, a_{n-1}$ 为常数时,就是常系数 n 阶差分方程。 $u(k)$ 是个离散序列,也叫做驱动函数; $y(k)$ 是系统的响应。当 $u(k)=0$ 时,(3.1.1)式变为

$$y(k+n)+a_{n-1}y(k+n-1)+\cdots+a_0y(k)=0 \quad (3.1.2)$$

(3.1.2)式称为 n 阶齐次差分方程。求解 n 阶齐次差分方程就是在给定输出时间序列 n 个初始条件 $y(0), y(1), \cdots, y(n-1)$ 下,求出输出时间序列 $y(n), y(n+1), \cdots$ 来。当然,最好是求出一般解。回想一下,我们的时序模型不正是在给定 $X_{t-1}, X_{t-2}, \cdots, X_{t-n}$ 的条件下求出 X_t 的吗?所以 ARMA 模型完全等价于一个差分方程,驱动函数可以看作是

$$a_t + \theta_1 a_{t-1} + \theta_2 a_{t-2} + \cdots + \theta_{n-1} a_{t-n+1} = u(t)$$

那么,如何求解差分方程呢?与微分方程一样,先求相应的齐次方程的通解,然后求一个原方程的特解,原方程的解等于通解与特解的线性组合。

求通解,首先设

$$Y(k) = \lambda^k \quad (3.1.3)$$

如果(3.1.3)是(3.1.2)的一个解,则必有

$$\lambda^{k+n} + a_{n-1}\lambda^{k+n-1} + \cdots + a_0\lambda^k = 0$$

同除以 λ^k ,得

$$\lambda^n + a_{n-1}\lambda^{n-1} + \cdots + a_0 = 0 \quad (3.1.4)$$

(3.1.4)称为(3.1.2)的特征方程,左端为特征多项式,多项式的根为特征根。如果能求出特征方程(3.1.4)的 n 个特征根 $\lambda_1, \lambda_2, \cdots, \lambda_n$,就可求得 n 阶齐次差分方程的通解

$$Y(k) = \sum_{i=1}^n C_i \lambda_i^k$$

其中, C_i 为任意实数, λ_i 既可能是实数,也可能是复数,若是复数就应成对出现,如 $\lambda_{1,2} = a \pm ib$;若 $\lambda_i = \lambda_j, i \neq j$ 时,表示差分方程有重根。

求特解,要根据驱动函数的具体形式而定,一般令 $y(k)=i$ 常数即可。

例 3.1 $y(k+1) - ay(k) = b$

显然是一个一阶非齐次差分方程。

解:求相应的齐次差分方程的通解,设 $y(k)=\lambda^k$,则有

$$\lambda^{k+1}-a\lambda^k=0, \quad \lambda=a$$

$\therefore y(k)=a^k$ 是相应的齐次方程的通解。

下面求特解,设 $Y(k)=\text{常数}=d$,则

$$d-ad=b, \quad d=\frac{b}{1-a}$$

故原方程的通解为 $y(k)=Ca^k+\frac{b}{1-a}$ 。

例 3.2 $Y(k+2)-3y(k+1)+2y(k)=3^k$

是一个二阶非齐次差分方程。

解:求齐次方程的通解,设 $Y(k)=\lambda^k$,则有

$$\lambda^{k+2}-3\lambda^{k+1}+2\lambda^k=0$$

$$\lambda^2-3\lambda+2=0$$

$$\lambda_1=1, \quad \lambda_2=2$$

也就是说, $y(k)=C_1\lambda_1^k=C_1 \cdot 1^k=C_1$ 和 $y(k)=C_2\lambda_2^k=C_22^k$ 都是该齐次方程的解,所以,它们的和也必是一个解。则通解为

$$y(k)=C_1\lambda_1^k+C_2\lambda_2^k=C_1+C_22^k$$

求特解。令 $y(k)=C3^k$,得

$$C3^{k+2}-3C3^{k+1}+2C3^k=3^k$$

$$C(9-9+2)=1$$

$$\therefore C=\frac{1}{2}$$

特解为 $y(k)=C3^k=\frac{1}{2}3^k$

原方程的通解为 $y(k)=C_1+C_22^k+\frac{1}{2}3^k$

例 3.3 $Y(k+2)-6Y(k+1)+9Y(k)=0$

解:本例是一个二阶齐次方程。为求其通解,同样设 $Y(k)=\lambda^k$,则有

$$\lambda^{k+2}-6\lambda^{k+1}+9\lambda^k=0$$

显然有重根 $\lambda_1=\lambda_2=3$ 。

当 n 阶齐次差分方程存在 l 个相等的实根(为方便起见,设 $\lambda_1=\lambda_2=\cdots=\lambda_l$,而 $\lambda_{l+1}, \lambda_{l+2}, \cdots, \lambda_n$ 为两两不相等的实根)时,则方程的通解为

$$Y(k)=(C_1+C_2k+C_3k^2+\cdots+C_lk^{l-1})\lambda_1^k+C_{l+1}\lambda_{l+1}^k+\cdots+C_n\lambda_n^k$$

所以,对本例来说,有通解

$$Y(k)=(C_1+C_2k)\times 3^k$$

二、AR(1)系统的格林函数

1. AR(1)系统格林函数的形式

格林函数就是描述系统记忆扰动程度的函数。

我们知道,AR(1)模型为

$$X_t - \varphi_1 X_{t-1} = a_t \quad (3.1.5)$$

设 $x_{t-1} = y(t)$, 则有

$$y(t+1) - \varphi_1 y(t) = a_t$$

显然是一个一阶非齐次差分方程。

由于在动态条件下,

$$X_{t-1} = \varphi_1 X_{t-2} + a_{t-1}$$

$$X_t = \varphi_1 (\varphi_1 X_{t-2} + a_{t-1}) + a_t = \varphi_1^2 X_{t-2} + \varphi_1 a_{t-1} + a_t$$

$$X_{t-2} = \varphi_1 X_{t-3} + a_{t-2}$$

$$X_t = \varphi_1^3 X_{t-3} + \varphi_1^2 a_{t-2} + \varphi_1 a_{t-1} + a_t$$

... ..

依次推下去,并代入(3.1.5)式,可得到:

$$X_t = \sum_{j=0}^{\infty} \varphi_1^j a_{t-j} \quad (3.1.6)$$

显然(3.1.6)式是差分方程(3.1.5)的解。

不妨将(3.1.6)代入(3.1.5)式,得

$$\sum_{j=0}^{\infty} \varphi_1^j a_{t-j} - \varphi_1 \left(\sum_{j=1}^{\infty} \varphi_1^{j-1} a_{t-j} \right) = a_t$$

变形得:

$$\begin{aligned} & \left(\varphi_1^0 a_{t-0} + \sum_{j=1}^{\infty} \varphi_1^j a_{t-j} \right) - \sum_{j=1}^{\infty} \varphi_1^j a_{t-j} = a_t \\ & a_t + \sum_{j=1}^{\infty} \varphi_1^j a_{t-j} - \sum_{j=1}^{\infty} \varphi_1^j a_{t-j} = a_t \end{aligned}$$

得证。

方程的解(3.1.6)式是驱动函数 a_t 的一个线性组合,或者说系统是怎样记忆扰动 a_t 的。同样也可以解释为,在某一时刻进入系统的 a_t 对后继行为的影响程度,也就是过去扰动的权重函数。如若 $\varphi_1 \rightarrow 1$, 则 φ_1^j 随着 j 的增大而缓慢减小,表明系统的记忆较强;相反,若 $\varphi_1 \rightarrow 0$, 则 φ_1^j 随着 j 的增大而急剧减小,表明系统的记忆较弱。

设两个 AR(1)系统的参数分别为 0.9 和 0.1,则这两个系统对扰动 a_t 的记忆情况如下:

$\varphi \backslash j$	1	2	3	4	5	6
0.9	0.9	0.81	0.729	0.6561	0.59049	0.531441
0.1	0.1	0.01	0.001	0.0001	0.00001	0.000001

$\varphi \backslash j$	7	8	9	10
0.9	0.4782969	0.43046721	0.38742089	0.34867841
0.1	0.0000001	0.00000001	0.000000001	0.0000000001

可见,方程解的系数函数 φ_j^i 客观地描述了该系统的动态性,故这个系数函数就叫做记忆函数,也叫格林函数(Green's function)。若用 G_j 表示,则AR(1)模型的格林函数可以表示为

$$G_j = \varphi_j^i \quad (3.1.7)$$

这样(3.1.6)式可等价地写成:

$$X_t = \sum_{j=0}^{\infty} G_j a_{t-j} \quad (3.1.8)$$

这里,我们是用 a_t 表示当前值,用 a_{t-j} 表示前 j 期的值。若用 k 表示前 j 期的值时,即设 $t-j=k$ 时,则(3.1.8)式还可写成

$$X_t = \sum_{k=-\infty}^t G_{t-k} a_k$$

在这里可以清楚地看出 $G_0 = \varphi_1^1 = 1$ 。

另外,由于

$$\begin{aligned} X_t &= \sum_{j=0}^{\infty} \varphi_j^1 a_{t-j} \\ &= a_t + \varphi_1 a_{t-1} + \varphi_1^2 a_{t-2} + \cdots \\ &= a_t + \theta_1 a_{t-1} + \theta_2 a_{t-2} + \cdots \quad (\text{令 } \varphi_1 = \theta_1) \end{aligned}$$

可见,AR(1)模型可用一个无限阶 MA 来逼近。

2. AR(1)模型的后移算子表达式及格林函数

后移算子 B ,就是“Back”算子, B 的次数表示后移期数。如 $BX_t = X_{t-1}$, $B^2 X_t = X_{t-2}$,…。这样,AR(1)可写成

$$(1 - \varphi_1 B) X_t = a_t \quad (3.1.9)$$

它的解为

$$\begin{aligned}
 X_t &= \frac{a_t}{1 - \varphi_1 B} \\
 &= (1 + \varphi_1 B + \varphi_1^2 B^2 + \varphi_1^3 B^3 + \cdots) a_t \\
 &= a_t + \varphi_1 a_{t-1} + \varphi_1^2 a_{t-2} + \varphi_1^3 a_{t-3} + \cdots \\
 &= \sum_{j=0}^{\infty} \varphi_1^j a_{t-j} \\
 &= \sum_{j=0}^{\infty} G_j a_{t-j}
 \end{aligned}$$

3. 格林函数的意义

由于格林函数就是差分方程解的系数函数,如前所述,格林函数的意义可概括如下:

(1) G_j 是前 j 个时间单位以前进入系统的扰动 a_{t-j} 对系统现在行为(响应)影响的权数。

(2) G_j 客观地刻画了系统动态响应衰减的快慢程度。

(3) G_j 是系统动态的真实描述。系统的动态性就是蕴含在时间序列中的数据依存关系。具体地讲,对于一个平稳系统来说,就是系统在某一时刻,由于受到进入系统的扰动 a_t 的作用,离开其平衡位置(即平均数—零), G_j 描述系统回到均衡位置的速度, φ_1 的值较小,速度较快; φ_1 的值较大,回复的速度就较慢。

(4) 格林函数所描述的动态性完全取决于系统参数 φ_1 。

三、根据格林函数形成系统响应(时间序列)

既然格林函数描述了系统的动态性,那么在随机扰动序列已知的条件下,格林函数完全确定了系统的行为。故根据已知的扰动序列和格林函数便可确定系统的响应。

1. 根据 $X_t = \sum_{j=-\infty}^t G_{t-j} a_j$ 生成序列 X_t

说明实例:见下表 3.1。

该题设 $\varphi_1 = 0.5$, 表的第一行是时刻 t , 取值为 0—14; 第二行是各时刻 t 进入系统的扰动; 第三行是按 $G_t = \varphi_1^t$ 计算的格林函数的值; 第四行是 $G_{t-0} a_0$ 在各时刻的值, 就是 a_0 对系统后继行为的作用结果; 第五行是 $G_{t-1} a_1$ 在各时刻的值, 是 a_1 对系统后继行为的作用结果; …; 第十八行是 $G_{t-14} a_{14}$ 在各时刻的值, 就是 a_{14} 对系统后继行为的作用结果。

在表的第四行到第十八行这一部分中, 若从列看, 第 j 列就是在第 j 时刻以前进入系统的扰动, 对 j 时刻系统响应 X_j 的影响值, 显然各列的和便是各

表 3.1 根据 $X_t = \sum_{j=0}^t G_{t-j} a_j$ 生成序列的数字展示

$j=$	t	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
	a_t	0	0	-1	2	-2	0	-1	0	1	-1	2	0	-2	1	1
	G_t	1	.5	.25	.125	.0625	.0313	.0156	.0078	.0039	.0020	.0010	.0005	.0002	.0001	.0001
0	$G_{t-0} a_0$	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
1	$G_{t-1} a_1$	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
2	$G_{t-2} a_2$	-1	-5	-25	-125	-625	-313	-156	-78	-39	-20	-10	-5	-2	-1	-1
3	$G_{t-3} a_3$	2	1	.5	.25	.125	.0625	.0313	.0156	.0078	.0039	.0020	.0010	.0005	.0002	.0001
4	$G_{t-4} a_4$	-2	-1	-5	-25	-125	-625	-313	-156	-78	-39	-20	-10	-5	-2	-1
5	$G_{t-5} a_5$	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
6	$G_{t-6} a_6$	-1	-5	-25	-125	-625	-313	-156	-78	-39	-20	-10	-5	-2	-1	-1
7	$G_{t-7} a_7$	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
8	$G_{t-8} a_8$	1	.5	.25	.125	.0625	.0313	.0156	.0078	.0039	.0020	.0010	.0005	.0002	.0001	.0001
9	$G_{t-9} a_9$	-1	-5	-25	-125	-625	-313	-156	-78	-39	-20	-10	-5	-2	-1	-1
10	$G_{t-10} a_{10}$	2	1	.5	.25	.125	.0625	.0313	.0156	.0078	.0039	.0020	.0010	.0005	.0002	.0001
11	$G_{t-11} a_{11}$	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
12	$G_{t-12} a_{12}$	-2	-1	-5	-25	-125	-625	-313	-156	-78	-39	-20	-10	-5	-2	-1
13	$G_{t-13} a_{13}$	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
14	$G_{t-14} a_{14}$	1	.5	.25	.125	.0625	.0313	.0156	.0078	.0039	.0020	.0010	.0005	.0002	.0001	.0001

$$X_t = \sum_{j=0}^t G_{t-j} a_j \quad \begin{matrix} 0 & 0 & -1 & 1.5 & -1.25 & -.625 & -1.3125 & -.656 & -.627 & -.664 & 1.668 & .834 & -1.583 & .2085 & 1.104 \end{matrix}$$




图 3.1 AR(1), $\phi_1 = 0.5$

以前时刻进入系统的扰动,对 j 时刻系统响应的作用结果之和,那就是 X_j 的值。

$a_1 \sim a_6$ 各个扰动对系统后继行为的作用描述在图 3.1(b)~(g)中。

2. 根据 $X_t = \sum_{j=0}^{\infty} G_j a_{t-j}$ 生成序列 X_t

表 3.2 中,第四行, $G_0 a_{t-0}$ 是 a_t 对系统当期的行为 X_t 的影响;第五行, $G_1 a_{t-1}$ 是前一时刻进入系统的扰动对 X_t 的作用;...;第十八行, $G_{14} a_{t-14}$ 是在前

表 3.2 根据 $X_t = \sum_{j=0}^{14} G_j a_{t-j}$ 生成序列的数字展示

$j =$	t	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
	a_t	0	0	-1	2	-2	0	-1	0	1	-1	2	0	-2	1	1
	G_t	1	.5	.25	.125	.0625	.0313	.0156	.0078	.0039	.0020	.0010	.0005	.0002	.0001	.0001
0	$G_0 \ a_{t-0}$	0	0	-1	2	-2	0	-1	0	1	-1	2	0	-2	1	1
1	$G_1 \ a_{t-1}$	0	0	0	-5	1	-1	0	-5	0	.5	-5	1	0	1	.5
2	$G_2 \ a_{t-2}$	0	0	0	0	-25	.5	-5	0	-25	.0	.25	-25	-5	0	.5
3	$G_3 \ a_{t-3}$	0	0	0	0	0	-125	.25	-25	0	-125	0	.125	-125	.25	0
4	$G_4 \ a_{t-4}$	0	0	0	0	0	0	-625	.125	-125	0	-625	0	0.625	-625	.125
5	$G_5 \ a_{t-5}$	0	0	0	0	0	0	0	-313	-625	-625	0	-313	0	.313	-.313
6	$G_6 \ a_{t-6}$	0	0	0	0	0	0	0	0	-0156	.313	-.313	0	-.0156	0	.0156
7	$G_7 \ a_{t-7}$	0	0	0	0	0	0	0	0	0	-0078	.0156	-.0156	0	-0078	0
8	$G_8 \ a_{t-8}$	0	0	0	0	0	0	0	0	0	0	-0039	.0078	-.0078	0	-.0039
9	$G_9 \ a_{t-9}$	0	0	0	0	0	0	0	0	0	0	0	-0020	.0039	-.0039	0
10	$G_{10} \ a_{t-10}$	0	0	0	0	0	0	0	0	0	0	0	0	-0010	.0020	-.0020
11	$G_{11} \ a_{t-11}$	0	0	0	0	0	0	0	0	0	0	0	0	0	-0005	.0010
12	$G_{12} \ a_{t-12}$	0	0	0	0	0	0	0	0	0	0	0	0	0	0	-.0002
13	$G_{13} \ a_{t-13}$	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
14	$G_{14} \ a_{t-14}$	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

$$X_t = \sum_{j=0}^t G_j a_{t-j} \quad \begin{matrix} 0 & 0 & -1 & 1.5 & -1.25 & -.625 & -1.3125 & -.656 & -.627 & -.664 & 1.668 & .834 & -1.583 & .2085 & 1.104 \end{matrix}$$

14 期进入系统的扰动对 X_t 的作用。

从列看,是以前各时刻进入系统的扰动对系统当前行为的影响;从对角线看,可作 15 条平行的对角线。仔细观察,自下而上第一条是 $G_{t-0}a_0$,第二条是 $G_{t-1}a_1$ 的值,第三条是 $G_{t-2}a_2$ 的值,第 i 条是 $G_{t-(i-1)}a_{i-1}$ 的值,最后一条是 $G_{t-14}a_{14}$ 的值。

将各对角线与表 3.1 的各行相比较,可以发现,表 3.1 的第 i 行的值就是表 3.2(从下到上)第 i 条对角线的值。各对角线的值分别是 $a_j(j=0,1,\dots,14)$ 对系统各时刻响应的影响,所以与表 3.1 各行的意义完全相同。故在图 3.1 中同时标绘出来。




图 3.2 AR(1), $\varphi_1 = -0.5$

这个例子说明 AR(1)模型的两个无限和的完全一致性。

3. 系统参数对系统响应的影响

对此用实例加以说明,对前面的 a_t 序列,分别用 $\varphi_1 = -0.5$ 和 $\varphi_1 = 0.9$ 生成了两个序列,分别描绘在图 3.2 和图 3.3 中,比较图 3.2、图 3.1 和图 3.3 可以看出:

- (1) φ_1 取负值时,响应波动较大。
- (2) φ_1 取正值时,响应变得较平坦。
- (3) φ_1 越大,系统响应回到均衡位置的速度越慢,时间越长。




图 3.3 AR(1), $\varphi_1 = 0.9$

四、AR(1)系统的平稳性

为了能够直观地根据系统响应的动态性得出平稳性的判别条件,下面我们给出系统稳定性的概念以及稳定性与平稳性的关系。

1. 系统稳定性与非稳定性

渐近稳定性是指系统受扰后达到任意初始状态,由此出发的状态向量都随时间的增长而趋于平衡状态。渐近稳定系统一定是平稳的。而系统的不稳定性则是指,如果系统受扰后达到任意初始状态,由此出发的状态向量将随时间而趋向无穷。不稳定系统一定是非平稳的。

如果系统受扰后达到任意初始状态,由此出发的状态向量随时间的增长既不回到均衡位置,又不趋于无穷,这就是系统的临界稳定性。一个边界稳定系统其响应可能是等幅振荡,也可能是常数,因而一定存在趋势或季节性。但这些趋势和季节性可能是随机的也可能是确定的,所以,一个临界稳定系统既可能是平稳的,也可能是非平稳的。本书以后所讨论的平稳系统就是指渐近稳定系统。

2. AR(1)系统的平稳性条件

根据渐近稳定性的含义可知,对于 AR(1)系统来说,如果系统受扰后,该扰动的作用渐渐减小,直至趋于零,即系统响应随着时间的增长回到均衡位置,那么,该系统就是渐近稳定的,也就是平稳的。相对于格林函数来说,就是随着 $j \rightarrow \infty$,扰动的权数 $G_j \rightarrow 0$,由于 $G_j = \varphi^j$,故必有 $j \rightarrow \infty, \varphi \rightarrow 0$,显然,

$$|\varphi| < 1 \quad (3.1.10)$$

这就是 AR(1)系统的渐近稳定条件,也就是平稳性条件。反过来,若 $|\varphi| < 1$,则称 AR(1)为渐近稳定的,也必是平稳的。

$|\varphi| = 1$ 时,

$$G_j = \begin{cases} 1 & \varphi = 1 \\ (-1)^j & \varphi = -1 \end{cases}$$

这时,虽然响应不回到其均衡位置,但仍是有界的,这时系统为临界稳定的。如前所述,系统可能存在某种趋势或季节性。

当 $|\varphi| > 1$ 时, $j \rightarrow \infty, G_j \rightarrow \infty$,任意小的扰动只要给定足够的时间,就会使系统响应正负趋于无穷,永远不会回到其均衡位置,这时系统便是不稳定的,当然是非平稳的。

五、格林函数与 Wold 分解

所谓 Wold 分解也叫正交分解,其核心就是把一个平稳过程分解成不相关的随机变量的和。正交和不相关是一致的。由于这一思想是由 Wold 引入 (1938 年)到时序分析中的,故叫做 Wold 分解。他认为可以用线性空间来解释 ARMA 模型的解。在 n 维线性空间 L_n 中, n 个线性无关的向量 $\alpha_1, \alpha_2, \dots, \alpha_n$ 称为空间的一组基。设 β 可由 $\alpha_1, \alpha_2, \dots, \alpha_n$ 线性表示:

$$\beta = k_1 \alpha_1 + k_2 \alpha_2 + \dots + k_n \alpha_n$$

其中 k_i 由向量 β 和 α_i 唯一确定, k_i 称为向量 β 关于基 α_i 的坐标。如果用线性空间的观点来看 AR(1)模型的解

$$X_t = \sum_{j=0}^{\infty} G_j a_{t-j}$$

由于 a_{t-j} 是相互独立的,可看作线性空间的基 a_j (或无限维坐标轴),显然 X_t 可由 a_{t-j} 线性表示,其系数 G_j 就是 X_t 对于 a_{t-j} 的坐标, X_t 就是 $G_j a_{t-j}$ 的正交向量的和。因而上式也叫做 Wold 分解式,其系数叫 Wold 系数。

可见,格林函数和 Wold 系数是同一客体从不同角度观察的结果,二者是完全一致的。Wold 系数是线性空间解释,格林函数是系统解释。

在这里需要指出,在理论上, X_t 是 a_{t-j} 的无限和,也就是说,在无限维空间将 X_t 分解。但是就平稳系统来说,由于系统参数 $|\varphi_1| < 1$,特别是当 $|\varphi_1|$ 较小时,格林函数(Wold)系数将很快减小,因而无限和事实上是有限的,无限维空间成了有限维空间。

例如,当 $\varphi_1 = 0.2$ 时,

$$G_0 = \varphi_1^0 = 1, \quad G_1 = \varphi_1^1 = 0.2, \quad G_2 = \varphi_1^2 = 0.2^2 = 0.04, \quad G_3 = \varphi_1^3 = 0.008,$$

那么

$$X_t \approx a_t + 0.2a_{t-1} + 0.04a_{t-2}, \text{ 可以在三维空间内分解。}$$

综上所述,利用 Wold 分解式可以很容易地得到时间序列的所有统计特征,因为 Wold 分解式可以看作是独立随机变量的和。如 AR(1)过程 X_t 的方差为

$$\begin{aligned} \gamma_0 &= \text{Var}(X_t) = \text{Var}\left(\sum_{j=0}^{\infty} \varphi_1^j a_{t-j}\right) \\ &= \sum_{j=0}^{\infty} \text{Var}(\varphi_1^j a_{t-j}) \end{aligned}$$

$$= \sum_{j=0}^{\infty} \varphi_1^{2j} \sigma_a^2$$

其中,和式可以看作是一个等比级数的和,其公比为 φ_1^2 ,于是有

$$\text{Var}(X_t) = \frac{\sigma_a^2}{1 - \varphi_1^2}$$

从 X_t 的方差可以看出,当 $|\varphi_1| > 1$ 时,序列的方差无限增大,当 $|\varphi_1| = 1$ 时, X_t 的方差为无限,因而 X_t 的二阶矩不存在,于是 X_t 不再是宽平稳了。作为随机游动,其方差就是无限的,所以我们把它看作是 AR(1) 的一种特殊形式——严格地讲,它不是平稳的。

六、ARMA(2,1)系统的格林函数

1. ARMA(2,1)系统的格林函数的隐式

在研究 AR(1) 时,我们是从动态角度出发,逐期代替得到了 AR(1) 系统的格林函数。对于 ARMA(2,1) 模型来说,当然同样可以采用逐期代换递推下去,但是很不方便。这时,我们可以利用比较系数法来求得 ARMA(2,1) 模型的格林函数。具体推导如下:

ARMA(2,1) 模型是一个二阶非齐次差方程

$$X_t - \varphi_1 X_{t-1} - \varphi_2 X_{t-2} = a_t - \theta_1 a_{t-1} \quad (3.1.11)$$

那么(3.1.11)的解必然存在。设该二阶非齐次差分方程的解为

$$X_t = \sum_{j=0}^{\infty} G_j a_{t-j}$$

那么代入方程(3.1.11)必然成立。我们的目的在于求出格林函数 G_j , 为方便起见,可用 B 算子式:

$$(1 - \varphi_1 B - \varphi_2 B^2) X_t = (1 - \theta_1 B) a_t \quad (3.1.12)$$

而 $X_t = G_0 a_t + G_1 a_{t-1} + G_2 a_{t-2} + \dots$

$$= (G_0 + G_1 B + G_2 B^2 + G_3 B^3 + \dots) a_t$$

$$= \left(\sum_{j=0}^{\infty} G_j B^j \right) a_t \quad (3.1.13)$$

把(3.1.13)式代入(3.1.12),便得

$$(1 - \varphi_1 B - \varphi_2 B^2) \left(\sum_{j=0}^{\infty} G_j B^j \right) a_t = (1 - \theta_1 B) a_t \quad (3.1.14)$$

即

$$(1 - \varphi_1 B - \varphi_2 B^2) (G_0 + G_1 B + G_2 B^2 + G_3 B^3 + \dots) a_t \equiv (1 - \theta_1 B) a_t$$

$(G_0 + G_1 B + G_2 B^2 + \cdots - \varphi_1 G_0 B - \varphi_1 G_1 B^2 - \cdots - \varphi_2 G_0 B^2 - \cdots) a_t = (1 - \theta_1 B) a_t$
 既然等式成立,那么 B 的同次幂的系数必相等,于是有:

B 的指数:

$$0: G_0 = 1$$

$$1: G_1 - \varphi_1 G_0 = -\theta_1 \Rightarrow G_1 = \varphi_1 - \theta_1$$

$$2: G_2 - \varphi_1 G_1 - \varphi_2 G_0 = 0 \Rightarrow G_2 = \varphi_1(\varphi_1 - \theta_1) + \varphi_2 = \varphi_1^2 - \varphi_1 \theta_1 + \varphi_2$$

$$3: G_3 - \varphi_1 G_2 - \varphi_2 G_1 = 0 \Rightarrow G_3 = \varphi_1 G_2 + \varphi_2 G_1$$

$$4: G_4 - \varphi_1 G_3 - \varphi_2 G_2 = 0 \Rightarrow G_4 = \varphi_1 G_3 + \varphi_2 G_2$$

$$j: \Rightarrow G_j = \varphi_1 G_{j-1} + \varphi_2 G_{j-2}, \quad j \geq 3$$

将上式变形得 $G_j - \varphi_1 G_{j-1} - \varphi_2 G_{j-2} = 0$

利用 B 算子式得 $(1 - \varphi_1 B - \varphi_2 B^2) G_j = 0, \quad j \geq 2$

这样,在已知系统参数的情况下,我们便可递推地计算出所有的 G_j 。当 j 充分大时,格林函数 G_j 满足(3.1.11)式自回归部分相应的差分方程。

2. ARMA($n, n-1$)系统的格林函数的隐式

与 ARMA(2,1)系统相类似,将

$$X_t = \left(\sum_{j=0}^{\infty} G_j B^j \right) a_t$$

代入 ARMA($n, n-1$)模型,得

$$(1 - \varphi_1 B - \varphi_2 B^2 - \cdots - \varphi_{n-1} B^{n-1} - \varphi_n B^n)(G_0 + G_1 B + G_2 B^2 + \cdots) \\ \equiv (1 - \theta_1 B - \theta_2 B^2 - \cdots - \theta_{n-1} B^{n-1})$$

展开左边并整理,得

$$G_0 + (G_1 - \varphi_1 G_0)B + (G_2 - \varphi_1 G_1 - \varphi_2 G_0)B^2 + (G_3 - \varphi_1 G_2 - \varphi_2 G_1 - \varphi_3 G_0)B^3 \\ + \cdots + (G_{n-1} - \varphi_1 G_{n-2} - \varphi_2 G_{n-3} - \varphi_3 G_{n-4} - \cdots - \varphi_{n-1} G_0)B^{n-1} \\ + (G_n - \varphi_1 G_{n-1} - \varphi_2 G_{n-2} - \varphi_3 G_{n-3} - \cdots - \varphi_n G_0)B^n + \cdots$$

使左端和右端的 B 的同次幂系数相等,得:

B 的幂指数

$$0: G_0 = 1$$

$$1: G_1 - \varphi_1 G_0 = -\theta_1 \Rightarrow G_1 = \varphi_1 G_0 - \theta_1 = \varphi_1 - \theta_1$$

$$2: G_2 - \varphi_1 G_1 - \varphi_2 G_0 = -\theta_2 \Rightarrow G_2 = \varphi_1(\varphi_1 - \theta_1) + \varphi_2 - \theta_2$$

$$3: G_3 - \varphi_1 G_2 - \varphi_2 G_1 - \varphi_3 G_0 = -\theta_3$$

$$\dots \quad \dots \quad \dots \quad \dots$$

$$n-1: G_{n-1} - \varphi_1 G_{n-2} - \varphi_2 G_{n-3} - \varphi_3 G_{n-4} - \cdots - \varphi_{n-1} G_0 = -\theta_{n-1}$$

$$n: G_n - \varphi_1 G_{n-1} - \varphi_2 G_{n-2} - \varphi_3 G_{n-3} - \cdots - \varphi_n G_0 = 0$$

$$\text{即} \quad (1 - \varphi_1 B - \varphi_2 B^2 - \varphi_3 B^3 - \cdots - \varphi_n B^n) G_j = 0, \quad j \geq n$$

这样,便可递推地计算出格林函数 G_j 。

3. ARMA(2,1)系统的格林函数的显式

我们知道,ARMA(2,1)模型实质上是一个二阶非齐次差分方程:

$$X_t - \varphi_1 X_{t-1} - \varphi_2 X_{t-2} = a_t - \theta_1 a_{t-1}$$

欲求其解,必须先求出其相应的齐次差分方程的通解。

求通解的一般方法,是令 $X_{t-2} = \lambda^k$,代入上式,得

$$\lambda^{k+2} - \varphi_1 \lambda^{k+1} - \varphi_2 \lambda^k = 0$$

同除以 λ^k ,得

$$\lambda^2 - \varphi_1 \lambda - \varphi_2 = 0$$

即为特征方程。

若能求出特征多项式

$$\lambda^2 - \varphi_1 \lambda - \varphi_2 = f(\lambda)$$

的根,就可得到齐次差分方程的通解。特征多项式是个二次多项式,根据二次多项式的根的性质

$$\lambda_1, \lambda_2 = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a} = \frac{\varphi_1 \pm \sqrt{\varphi_1^2 + 4\varphi_2}}{2} \quad (3.1.15)$$

求出这两个根后,则说明 λ_1^k 和 λ_2^k 都是二阶齐次差分方程的解,那么,它们的代数和也是方程的解,即通解为

$$G_j = g_1 \lambda_1^j + g_2 \lambda_2^j$$

其中 g_1 和 g_2 是任意常数,其值由初始条件唯一地确定。这里的初始条件为:

$$\begin{cases} G_0 = 1 \\ G_1 - \varphi_1 = -\theta_1 \Rightarrow G_1 = \varphi_1 - \theta_1 \end{cases}$$

于是有

$$\begin{cases} G_0 = g_1 + g_2 = 1 \\ G_1 = g_1 \lambda_1 + g_2 \lambda_2 = \varphi_1 - \theta_1 \end{cases}$$

$$\text{而} \quad \lambda_1 + \lambda_2 = \varphi_1$$

$$\text{所以} \quad G_1 = \lambda_1 + \lambda_2 - \theta_1$$

即

$$\begin{cases} g_1 + g_2 = 1 \\ g_1 \lambda_1 + g_2 \lambda_2 = \lambda_1 + \lambda_2 - \theta_1 \end{cases}$$

解之,得

$$g_2 = \frac{\lambda_2 - \theta_1}{\lambda_2 - \lambda_1}$$

$$g_1 = \frac{\lambda_1 - \theta_1}{\lambda_1 - \lambda_2}$$

则 ARMA(2,1)系统的格林函数为:

$$G_j = \left(\frac{\lambda_1 - \theta_1}{\lambda_1 - \lambda_2} \right) \lambda_1^j + \left(\frac{\lambda_2 - \theta_1}{\lambda_2 - \lambda_1} \right) \lambda_2^j$$

下面我们进一步分析如何根据 Wold 分解求 ARMA(2,1)系统的格林函数。

既然 ARMA(2,1)是平稳的,根据 Wold 分解可知, X_t 总可以用相互无关的向量(基)线性表出,即:

$$(1 - \varphi_1 B - \varphi_2 B^2)X_t = (1 - \theta_1 B)a_t$$

可写为

$$X_t = \frac{1 - \theta_1 B}{1 - \varphi_1 B - \varphi_2 B^2} a_t$$

设分母可分解为 $(1 - \lambda_1 B)(1 - \lambda_2 B)$, 其中 λ_1, λ_2 为两个不相等的特征根,则

$$X_t = \frac{1 - \theta_1 B}{(1 - \lambda_1 B)(1 - \lambda_2 B)} a_t \quad (3.1.16)$$

由 $1 - \lambda_1 B = 0$ 可得 $B_1 = \frac{1}{\lambda_1}$, 由 $1 - \lambda_2 B = 0$ 可得 $B_2 = \frac{1}{\lambda_2}$ 对(3.1.16)式作部分分式,得

$$\begin{aligned} X_t &= \left[\frac{1 - \theta_1 \frac{1}{\lambda_1}}{1 - \lambda_2 \left(\frac{1}{\lambda_1} \right)} \cdot \frac{1}{1 - \lambda_1 B} + \frac{1 - \theta_1 \frac{1}{\lambda_2}}{1 - \lambda_1 \left(\frac{1}{\lambda_2} \right)} \cdot \frac{1}{1 - \lambda_2 B} \right] \cdot a_t \\ &= \left[\frac{\lambda_1 - \theta_1}{\lambda_1 - \lambda_2} \cdot \frac{1}{1 - \lambda_1 B} + \frac{\lambda_2 - \theta_1}{\lambda_2 - \lambda_1} \cdot \frac{1}{1 - \lambda_2 B} \right] \cdot a_t \end{aligned}$$

其中 $\frac{1}{1 - \lambda_1 B}$ 是公比为 $\lambda_1 B$ 的无穷等比级数的和,而 $\frac{1}{1 - \lambda_2 B}$ 是公比为 $\lambda_2 B$ 的无穷等比级的和。所以,

$$\begin{aligned} X_t &= \sum_{j=0}^{\infty} \left[\frac{\lambda_1 - \theta_1}{\lambda_1 - \lambda_2} \lambda_1^j + \frac{\lambda_2 - \theta_1}{\lambda_2 - \lambda_1} \lambda_2^j \right] B^j a_t \\ &= \sum_{j=0}^{\infty} \left[\frac{\lambda_1 - \theta_1}{\lambda_1 - \lambda_2} \lambda_1^j + \frac{\lambda_2 - \theta_1}{\lambda_2 - \lambda_1} \lambda_2^j \right] a_{t-j} \end{aligned} \quad (3.1.17)$$

可见, (3.1.17) 式将 X_i 描述为扰动 a_i 的和, 其系数就是相应的格林函数, 即

$$G_j = \frac{\lambda_1 - \theta_1}{\lambda_1 - \lambda_2} \lambda_1^j + \frac{\lambda_2 - \theta_1}{\lambda_2 - \lambda_1} \lambda_2^j.$$

例如, $\varphi_1 = 1.3, \varphi_2 = -0.4, \theta_1 = 0.4$, 用显式求格林函数。

解: 求特征根, 即求 $\lambda^2 - 1.3\lambda + 0.4 = 0$ 的根

$$\begin{aligned} \lambda_1, \lambda_2 &= \frac{1}{2} (1.3 \pm \sqrt{1.69 - 1.6}) \\ &= \frac{1}{2} (1.3 \pm 0.3) \end{aligned}$$

即 $\lambda_1 = 0.8, \lambda_2 = 0.5$

于是, 格林函数为

$$\begin{aligned} G_j &= \frac{0.8 - 0.4}{0.8 - 0.5} \times 0.8^j + \frac{0.5 - 0.4}{0.5 - 0.8} \times 0.5^j \\ &= \frac{1}{3} (4 \times 0.8^j - 0.5^j) \end{aligned}$$

$$G_0 = \frac{1}{3} (4 \times 1 - 1) = 1$$

$$G_1 = 0.9$$

$$G_2 = 0.77$$

$$G_3 = 0.641$$

.....

可见, 当 $\varphi_1^2 + 4\varphi_2 \geq 0$ 时, 特征根 λ_1 和 λ_2 为实数, 且格林函数是一个指数的和, 但是, 若当 $\varphi_1^2 + 4\varphi_2 < 0$ 时, 在实数域无根, 但在复数域内该二次多项式有两个共轭复根, 记作:

$$\lambda_1 = \gamma e^{i\omega}, \quad \lambda_2 = \gamma e^{-i\omega}$$

设复数 $Z = a + ib$, 其中 i 为虚数单位 $i = \sqrt{-1}$ 。在复平面 $X-Y$ 上可表示为一点 P , 如下图 3.4, P 点离开原点 o 的距离称之为 Z 的模, 记作 γ 。则有

$$\gamma = |Z| = \sqrt{a^2 + b^2}$$

于是, 复数 Z 的三角函数形式为

$$\begin{aligned} Z &= a + ib \\ &= \sqrt{a^2 + b^2} \left[\frac{a}{\sqrt{a^2 + b^2}} \pm i \frac{b}{\sqrt{a^2 + b^2}} \right] \\ &= \gamma (\cos \omega \pm i \sin \omega) \end{aligned}$$




图 3.4 复平面图

根据尤拉(Euler)公式,

$$e^{\pm i\omega} = \cos\omega \pm i\sin\omega$$

这样使得三角函数与指数函数之间建立了互换关系,

$$\cos\omega = \frac{e^{i\omega} + e^{-i\omega}}{2}$$

$$\sin\omega = \frac{e^{i\omega} - e^{-i\omega}}{2i}$$

于是,复数 Z 可用指数函数表示为

$$Z = \gamma[\cos\omega + i\sin\omega] = \gamma e^{i\omega}$$

那么,对于 ARMA(2,1)模型说,

$$\lambda_1, \lambda_2 = \frac{1}{2}\varphi_1 \pm \frac{1}{2}\sqrt{\varphi_1^2 + 4\varphi_2}$$

因为

$$\varphi_1^2 + 4\varphi_2 < 0$$

所以

$$-\varphi_1^2 - 4\varphi_2 > 0$$

故

$$\begin{aligned} \lambda_1, \lambda_2 &= \frac{1}{2}\varphi_1 \pm \frac{1}{2}\sqrt{(-1)(-\varphi_1^2 - 4\varphi_2)} \\ &= \frac{1}{2}\varphi_1 \pm \frac{1}{2}i\sqrt{-\varphi_1^2 - 4\varphi_2} \end{aligned} \quad (3.1.18)$$

显然是一对共轭复数,它的三角函数表示式

$$\lambda_1, \lambda_2 = \gamma(\cos\omega \pm i\sin\omega) \quad (3.1.19)$$

其中

$$\begin{aligned}
 \gamma &= |\lambda_1| = |\lambda_2| = \sqrt{\left(\frac{1}{2}\varphi_1\right)^2 + \left(\frac{1}{2}\sqrt{-\varphi_1^2 - 4\varphi_2}\right)^2} \\
 &= \sqrt{-\varphi_2} \\
 \omega &= \cos^{-1}(a/\gamma) \\
 &= \cos^{-1}\left(\frac{\lambda_1 + \lambda_2}{2\sqrt{\lambda_1\lambda_2}}\right)
 \end{aligned}$$

其指数式

$$\lambda_1, \lambda_2 = \gamma e^{\pm i\omega} \quad (3.1.20)$$

这时, 格林函数

$$\begin{aligned}
 G_j &= g_1 \lambda_1^j + g_2 \lambda_2^j \\
 g_1 &= \frac{\lambda_1 - \theta_1}{\lambda_1 - \lambda_2} = \frac{\gamma e^{i\omega} - \theta_1}{\gamma e^{i\omega} - \gamma e^{-i\omega}} = \frac{1}{2} + i \frac{1}{2} \frac{-\varphi_1 + 2\theta_1}{\sqrt{-\varphi_1^2 - 4\varphi_2}} \\
 g_2 &= \frac{\lambda_2 - \theta_1}{\lambda_2 - \lambda_1} = \frac{\gamma e^{-i\omega} - \theta_1}{\gamma e^{-i\omega} - \gamma e^{i\omega}} = \frac{1}{2} - i \frac{1}{2} \frac{-\varphi_1 + 2\theta_1}{\sqrt{-\varphi_1^2 - 4\varphi_2}} \\
 g &= |g_1| = |g_2| = \sqrt{\left(\frac{1}{2}\right)^2 + \left[\frac{1}{2} \frac{-\varphi_1 + 2\theta_1}{\sqrt{-\varphi_1^2 - 4\varphi_2}}\right]^2} \\
 &= \frac{1}{2} \sqrt{1 + \left[\frac{-\varphi_1 + 2\theta_1}{\sqrt{-\varphi_1^2 - 4\varphi_2}}\right]^2}
 \end{aligned}$$

设相位为 β , 则

$$\beta = \operatorname{tg}^{-1} \left[\frac{\frac{1}{2} \frac{-\varphi_1 + 2\theta_1}{\sqrt{-\varphi_1^2 - 4\varphi_2}}}{\frac{1}{2}} \right] = \operatorname{tg}^{-1} \left[\frac{-\varphi_1 + 2\theta_1}{\sqrt{-\varphi_1^2 - 4\varphi_2}} \right]$$

于是有

$$g_1, g_2 = g e^{\pm i\beta}$$

代入格林函数, 则

$$\begin{aligned}
 G_j &= g_1 \lambda_1^j + g_2 \lambda_2^j \\
 &= g e^{i\beta} (\gamma e^{i\omega})^j + g e^{-i\beta} (\gamma e^{-i\omega})^j \\
 &= g \gamma^j [e^{i(\beta + j\omega)} + e^{-i(\beta + j\omega)}] \\
 &= g \gamma^j 2 \cos(\beta + j\omega) \\
 &= \gamma^j A \cos(\beta + j\omega), \quad A = 2g
 \end{aligned}$$

这是一个阻尼余弦波, 阻尼为 A , 即 $2g$, 相位为 β , 频率为 ω 。

例如, 对于 $\varphi_1 = 1.43, \varphi_2 = -0.61, \theta_1 = -0.54$ 的 ARMA(2,1) 系统来说,
 $G_j = 2g\gamma^j \cos(\beta + j\omega)$

$$\gamma = \sqrt{-\varphi_2} = \sqrt{0.61} = 0.78$$

$$\begin{aligned} g &= \frac{1}{2} \sqrt{1 + \left[(-1) \frac{-\varphi_1 - 2\theta_1}{\sqrt{-\varphi_1^2 - 4\varphi_2}} \right]^2} \\ &= \frac{1}{2} \sqrt{1 + \frac{[1.43 - 2 \times (-0.54)]^2}{-1.43^2 - 4 \times (-0.61)}} \\ &= \frac{1}{2} \sqrt{16.95} = 2.058 \end{aligned}$$

$$\begin{aligned} \omega &= \cos^{-1} \left[\frac{\varphi_1}{2\sqrt{-\varphi_2}} \right] = \cos^{-1} \left(\frac{1.43}{2 \times 0.77} \right) \\ &= \cos^{-1} 0.928571 \\ &= 22.69^\circ \approx 0.38 \text{ 弧度} \end{aligned}$$

$$\begin{aligned} \beta &= \text{tg}^{-1} \left[\frac{-\varphi_1 + 2\theta_1}{\sqrt{-\varphi_1^2 - 4\varphi_2}} \right] \\ &= \text{tg}^{-1} \left[\frac{-1.43 - 2 \times 0.54}{\sqrt{0.3951}} \right] \\ &= \text{tg}^{-1}(-3.99931) = -75.94077^\circ \approx -1.3254 \text{ 弧度} \end{aligned}$$

因此, $G_j = 2 \times 2.058 \times 0.78^j \cos(0.38j - 1.33)$

4. AR(2) 和 ARMA(1,1) 系统的格林函数

由于 AR(2) 和 ARMA(1,1) 模型是 ARMA(2,1) 模型的特殊形式, 当然描述动态性的格林函数也有上述关系。

ARMA(2,1) 的格林函数

$$\begin{aligned} G_j &= g_1 \lambda_1^j + g_2 \lambda_2^j \\ &= \frac{\lambda_1 - \theta_1}{\lambda_1 - \lambda_2} \lambda_1^j + \frac{\lambda_2 - \theta_1}{\lambda_2 - \lambda_1} \lambda_2^j \end{aligned}$$

当 $\theta_1 = 0$ 时, ARMA(2,1) 系统成为 AR(2) 系统, 那么, 当 $\theta_1 = 0$ 时, ARMA(2,1) 的格林函数就是描述 AR(2) 系统动态性的格林函数, 即

$$\begin{aligned} G_j &= \frac{\lambda_1}{\lambda_1 - \lambda_2} \lambda_1^j + \frac{\lambda_2}{\lambda_2 - \lambda_1} \lambda_2^j \\ &= \frac{1}{\lambda_1 - \lambda_2} (\lambda_1^{j+1} - \lambda_2^{j+1}) \end{aligned} \quad (3.1.21)$$

当 $\varphi_2=0$ 时, ARMA(2,1)系统成为 ARMA(1,1)系统,即

$$\begin{cases} \lambda_1 \lambda_2 = -\varphi_2 = 0 \\ \lambda_1 + \lambda_2 = \varphi_1 \end{cases}$$

得

$$\lambda_1 = \varphi_1, \quad \lambda_2 = 0$$

可见, $\lambda_2=0$ 是显然的, 因为, 当 $\varphi_2=0$ 时, 特征方程 $\lambda - \varphi_1 = 0$, 显然只有一个特征值 $\lambda_1 = \varphi_1$, 所以, ARMA(1,1)系统的格林函数为:

$$\begin{aligned} G_j &= \left(\frac{\lambda_1 - \theta_1}{\lambda_1 - 0} \right) \lambda_1^j + \left(\frac{0 - \theta_1}{0 - \lambda_1} \right) 0^j \\ &= \begin{cases} (\lambda_1 - \theta_1) \lambda_1^{j-1}, & j \geq 1 \\ (\lambda_1 - \theta_1) \lambda_1^{j-1} + \frac{\theta_1}{\lambda_1} = 1, & j=0 \text{ 并定义 } 0^0=1 \end{cases} \quad (3.1.22) \\ &= \begin{cases} 1, & j=0 \\ (\varphi_1 - \theta_1) \varphi_1^{j-1}, & j \geq 1 \end{cases} \end{aligned}$$

5. ARMA($n, n-1$)系统的格林函数

比较 AR(1)和 ARMA(2,1)可以发现, 动态性增加是通过把一个带有适当系数的项 λ_2^j 加到 AR(1)系统的格林函数之上实现的, 那么, 与此相类似, ARMA($n, n-1$)系统的格林函数则为

$$\begin{aligned} G_j &= g_1 \lambda_1^j + g_2 \lambda_2^j + \cdots + g_n \lambda_n^j \quad (3.1.23) \\ g_i &= \frac{(\lambda_i^{n-1} - \theta_1 \lambda_i^{n-2} - \cdots - \theta_{n-1})}{(\lambda_i - \lambda_1)(\lambda_i - \lambda_2) \cdots (\lambda_i - \lambda_{i-1})(\lambda_i - \lambda_{i+1}) \cdots (\lambda_i - \lambda_n)} \end{aligned}$$

七、ARMA(2,1)系统的平稳性

1. 用特征根表示的平稳性条件

在前面讨论 AR(1)时, 我们曾经看到, 由于 $x_t = \sum_{j=0}^{\infty} G_j a_{t-j}$, 所以, 随着 $j \rightarrow \infty$ 时, $G_j \rightarrow 0$, 则系统是平稳的。这个推论对 ARMA(2,1)模型也依然适应。这时, 格林函数为:

$$G_j = g_1 \lambda_1^j + g_2 \lambda_2^j$$

显然, 只有当 $|\lambda_1| < 1, |\lambda_2| < 1$ 时, 才能使得

$$j \rightarrow \infty \text{ 时, } G_j \rightarrow 0$$

这就是 ARMA(2,1)系统的平稳性条件, 即

$$|\lambda_1| < 1, \quad |\lambda_2| < 1$$

也就是,特征方程的特征根的模在单位圆内。对于 ARMA($n, n-1$)模型,类似地有

$$|\lambda_i| < 1, \quad i=1, 2, \dots, n$$

2. 用自回归系数表示的平稳性条件

对于 AR(1)系统,平稳性条件为

$$|\varphi_1| < 1$$

当然, $\lambda_1 = \varphi_1$, 亦有 $|\lambda_1| < 1$ 。

对于 ARMA(2,1)模型来说,由于平稳性条件为

$$|\lambda_1| < 1, |\lambda_2| < 1$$

而

$$\lambda_1 \lambda_2 = -\varphi_2$$

显然

$$|\varphi_2| < 1$$

又因为

$$\lambda_1(1-\lambda_2) < 1-\lambda_2$$

即 $\lambda_1 - \lambda_1 \lambda_2 < 1 - \lambda_2$

$$\Rightarrow \lambda_1 + \lambda_2 - \lambda_1 \lambda_2 < 1$$

$$\Rightarrow \varphi_1 - (-\varphi_2) < 1$$

又因为

$$-(1+\lambda_2) < \lambda_1(1+\lambda_2)$$

$$\Rightarrow -1 - \lambda_2 < \lambda_1 + \lambda_1 \lambda_2$$

$$\Rightarrow -(\lambda_1 + \lambda_2) - \lambda_1 \lambda_2 < 1$$

$$\Rightarrow -\varphi_1 + \varphi_2 < 1$$

$$\text{即: } \varphi_2 - \varphi_1 < 1$$

故, ARMA(2,1)系统的平稳性条件的系统参数形式为:

$$\begin{cases} \varphi_1 + \varphi_2 < 1 \\ \varphi_2 - \varphi_1 < 1 \\ |\varphi_2| < 1 \end{cases}$$

这说明系统的平稳性仅与自回归参数有关,而与移动平均参数无关。特征值的表示形式也说明了这一点,由于特征值仅与自回归参数有关,而与移动平均参数无关,所以,一切 ARMA(2, m)系统的平稳性条件均为上式。这样,给定系统参数,我们就可判定其平稳性。

3. ARMA(2, m)系统的平稳区域

前面所论述的是平稳性条件的代数表达式,为直观起见,我们来看一下平稳性条件的几何图,即平稳区域。

在直角坐标系中,我们用纵轴表示 ϕ_2 ,用横轴表示 ϕ_1 ,则:

条件 1,要求 $\phi_1 + \phi_2 < 1$,即直线 $\phi_1 + \phi_2 = 1$ 下面的部分;

条件 2,要求 $\phi_2 - \phi_1 < 1$,即直线 $\phi_2 - \phi_1 = 1$ 下面的部分;

条件 3,要求 $|\phi_2| < 1$,即 $-1 < \phi_2 < 1$,就是在 $\phi_2 = -1$ 上方和 $\phi_2 = 1$ 下方之间的部分。

可见,ARMA(2,1)模型的平稳区域是一个三角形。在这个平稳区域作出根的判别条件:

$$\phi_1^2 + 4\phi_2 = 0$$

这是一条二次曲线。这时,整个平稳区域被分成六个部分,如图 3.5 所示。




图 3.5 ARMA(2, m) 的平稳域

- (1) 当 $\phi_1 > 0$, 平稳区域为 1, 2, 3。
- (2) 当 $\phi_1 < 0$, 平稳区域为 4, 5, 6。
- (3) 当 $\phi_2 > 0$, 平稳区域为 1, 4。
- (4) 当 $\phi_2 < 0$, 平稳区域为 2, 3, 5, 6。

第二节 逆函数和可逆性

前面讲的格林函数,它把 X_t 表示为过去 a_t 对 X_t 的影响,或者说系统对过去 a_t 的记忆性,也就是用一个 MA 模型来逼近 X_t 的行为。平稳序列 X_t 的这种表达形式称为 X_t 的“传递形式”。使 G_t 趋于零(即有界)便得到了 ARMA 模型的平稳性,同样我们也可以用过去的 X_t 的一个线性组合来逼近系统现在时刻的行为。即:

$$X_t = I_1 X_{t-1} + I_2 X_{t-2} + \cdots + a_t$$

$$= \sum_{j=1}^{\infty} I_j X_{t-j} + a_t$$

$$\text{或} \quad a_t = (1 - \sum_{j=1}^{\infty} I_j B^j) X_t \\ = (1 - I_1 B - I_2 B^2 - \cdots) X_t$$

我们把这种表达形式称为 X_t 的“逆转形式”。其中的系数函数 I_j ($I_0=1$) 称为逆函数。可见它是一个无穷阶的自回归模型。一个过程是否具有逆转形式,也就是说逆函数是否存在的性质,通常称为过程是否具有可逆性,如果一个过程可以用一个无限阶的自回归模型逼近,即逆函数存在,我们就称该过程具有可逆性,也就是可逆的,否则,就是不可逆的。

一、AR(1)模型和 MA(1)模型的逆函数

1. AR(1)模型的逆函数

我们知道,AR(1)模型为

$$X_t - \varphi_1 X_{t-1} = a_t$$

显然, $I_1 = \varphi_1, I_j = 0, j > 1$ 。对于 AR(1)的格林函数:

$$(1 - \varphi_1 B) X_t = a_t$$

$$X_t = \frac{1}{1 - \varphi_1 B} a_t \\ = (1 + \varphi_1 B + \varphi_1^2 B^2 + \cdots) a_t \\ = \sum_{j=0}^{\infty} \varphi_1^j a_{t-j}$$

$$\text{则} \quad G_j = \varphi_1^j$$

可见, G_j 是由算子 $\frac{1}{1 - \varphi_1 B}$ 求得的。而 AR(1)的逆函数 I_j 的算子是 $(1 - \varphi_1 B)$ 。

由于形成 I_j 的算子是形成 G_j 的算子的倒数,所以称为逆函数。

对于 AR(2)模型

$$X_t - \varphi_1 X_{t-1} - \varphi_2 X_{t-2} = a_t$$

有

$$X_t = \varphi_1 X_{t-1} + \varphi_2 X_{t-2} + a_t$$

$$I_1 = \varphi_1, \quad I_2 = \varphi_2, \quad I_j = 0, \quad j \geq 3$$

可见,所谓可逆性,是指移动平均模型可以用 AR 模型表示。

2. MA(1)模型的逆函数

MA(1)模型:

$$X_t = (1 - \theta_1 B) a_t$$

$$\begin{aligned} \text{那么, } a_t &= \frac{X_t}{(1 - \theta_1 B)} \\ &= (1 + \theta_1 B + \theta_1^2 B^2 + \cdots) X_t \\ &= X_t + \sum_{j=1}^{\infty} \theta_1^j X_{t-j} \end{aligned}$$

$$\text{即 } X_t = \sum_{j=1}^{\infty} (-\theta_1^j X_{t-j}) + a_t$$

$$\text{可见 } I_j = -\theta_1^j$$

显然, 只有 $|\theta_1| < 1$ 时, 才有 $j \rightarrow \infty, I_j \rightarrow 0$, 故 MA(1) 的可逆性条件为

$$|\theta_1| < 1$$

MA(1) 的格林函数

$$\begin{aligned} X_t &= (1 - \theta_1 B) a_t \\ &= a_t - \theta_1 a_{t-1} \end{aligned}$$

可见, $G_0 = 1, G_1 = -\theta_1, G_j = 0, j > 1$, 同样, 形成 G_j 和 I_j 的算子互为倒数。

3. G_j 和 I_j 之间的关系

我们注意到

格林函数	逆函数
AR(1): $G_j = \varphi_1^j$	$\begin{cases} I_1 = \varphi_1 \\ I_j = 0, j > 1 \end{cases}$
MA(1): $\begin{cases} G_0 = 1 \\ G_1 = -\theta_1 \\ G_j = 0, j > 1 \end{cases}$	$I_j = -\theta_1^j$

可以看出, AR(1) 的 G_j 与 MA(1) 的 I_j 形式一致, 只是符号相反, 参数互换, 即可以根据 G_j 求得 I_j , 就是用 $-I_j$ 代替 G_j , 用 θ_1 代替 φ_1 。同样, AR(1) 的 I_j 和 MA(1) 的 G_j 的形式也是一致的。

这种对偶性并非偶然, 也不是一阶模型所特有。对于任意阶模型都是正确的。比如:

ARMA(2, 1) 和 ARMA(1, 2)

ARMA(2, 1) 格林函数为

$$\begin{cases} G_0 = 1 \\ G_1 - \varphi_1 = -\theta_1 \Rightarrow G_1 = \varphi_1 - \theta_1 \\ G_2 - \varphi_1 G_1 - \varphi_2 = 0 \Rightarrow G_2 = G_1 \varphi_1 + \varphi_2 \\ G_j = \varphi_1 G_{j-1} + \varphi_2 G_{j-2}, \quad j \geq 3 \end{cases}$$

$$(1 - \varphi_1 B - \varphi_2 B^2) G_j = 0, \quad j \geq 2$$

ARMA(1,2)的逆函数可推得如下:

$$X_t - \varphi_1 X_{t-1} = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2}$$

$$(1 - \varphi_1 B) X_t = (1 - \theta_1 B - \theta_2 B^2) a_t$$

将 $a_t = (1 - I_1 B - I_2 B^2 - \dots) X_t$ 代入上式并整理,得

$$\begin{aligned} (1 - \varphi_1 B) &= 1 - (I_1 + \theta_1) B - (I_2 - I_1 \theta_1 + \theta_2) B^2 - (I_3 - I_2 \theta_1 - I_1 \theta_2) B^3 \\ &\quad - (I_4 - I_3 \theta_1 - I_2 \theta_2) B^4 - \dots \end{aligned}$$

那么,逆函数:

$$\begin{cases} -(I_1 + \theta_1) = -\varphi_1 & \Rightarrow I_1 = \varphi_1 - \theta_1 \\ -(I_2 - I_1 \theta_1 + \theta_2) = 0 & \Rightarrow I_2 = I_1 \theta_1 - \theta_2 \\ -(I_3 - I_2 \theta_1 - I_1 \theta_2) = 0 & \Rightarrow I_3 = I_2 \theta_1 + I_1 \theta_2 \\ -(I_4 - I_3 \theta_1 - I_2 \theta_2) = 0 & \Rightarrow I_4 = I_3 \theta_1 + I_2 \theta_2 \\ I_j = I_{j-1} \theta_1 + I_{j-2} \theta_2, & j \geq 3 \end{cases}$$

同样,在格林函数的表达式中,用 $-I_j$ 代替 G_j ,用 φ 代替 θ , θ 代替 φ ,即可得到逆函数 I_j 。

对于模型

$$(1 - \varphi_1 B - \varphi_2 B^2 - \dots) X_t = (1 - \theta_1 B - \theta_2 B^2 - \dots) a_t$$

$$\text{令} \quad \varphi(B) = 1 - \varphi_1 B - \varphi_2 B^2 - \dots$$

$$\theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \dots$$

则有

$$\varphi(B) X_t = \theta(B) a_t$$

$$X_t = \frac{\theta(B)}{\varphi(B)} a_t$$

$$= \sum_{j=0}^{\infty} G_j a_{t-j} \quad G_0 = 1$$

同样,

$$a_t = \frac{\varphi(B)}{\theta(B)} X_t$$

$$= \sum_{j=0}^{\infty} (-I_j) X_{t-j} \quad I_0 = -1$$

通过格林函数的显式,也可得出:

$$\text{令: } a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} = 0$$

解之,得 $V^2 - \theta_1 V - \theta_2 = 0$, V_1, V_2 是特征根。

则有:

$$\begin{cases} V_1 + V_2 = \theta_1 \\ V_1 V_2 = -\theta_2 \end{cases}$$

$$V_1, V_2 = \frac{1}{2} \left(\theta_1 \pm \sqrt{\theta_1^2 + 4\theta_2} \right)$$

由
得

$$G_j = \frac{\lambda_1 - \theta_1}{\lambda_1 - \lambda_2} \lambda_1^j + \frac{\lambda_2 - \theta_1}{\lambda_2 - \lambda_1} \lambda_2^j$$

$$I_j = - \left(\frac{V_1 - \varphi_1}{V_1 - V_2} \right) V_1^j - \left(\frac{V_2 - \varphi_1}{V_2 - V_1} \right) V_2^j$$

显然有:

$$\theta_1^2 + 4\theta_2 \geq 0$$

V_1, V_2 为两个实根, I_j 是一个指数和。

当 $\theta_1^2 + 4\theta_2 < 0$, V_1, V_2 为共轭复根, I_j 是一个阻尼正弦波。

这时,模型的可逆性表示为:

$$j \rightarrow \infty, \quad I_j \rightarrow 0$$

只有这样,才能用一个 AR 模型来近似 MA 模型,可逆性条件为:

$$|V_1| < 1, |V_2| < 1$$

或

$$\begin{cases} \theta_1 + \theta_2 < 1 \\ \theta_1 - \theta_2 < 1 \\ |\theta_2| < 1 \end{cases}$$

对于一般模型来说,根据格林函数与逆函数的关系,同样可得到逆函数。
类似地,可逆性为

$$|V_k| < 1$$

这时,我们发现格林函数的平稳性仅与 AR 模型的特征根有关,而逆函数的可逆性仅与 MA 的特征根有关系。如果系统具有平稳性 $|\lambda_k| < 1$,说明系统对某一时刻进入的扰动的记忆逐渐衰减,时间越远,它的影响作用越小,逐渐被完全忘掉;而可逆性表示某一时刻的系统响应对后继时刻的响应的影响呈递减状态,离该时刻时间越远,影响作用越小,显然,对于 ARMA 模型来说,只有平稳且可逆才是有意义的,即

$$|\lambda_k| < 1, |V_k| < 1$$

例如,我们不难推得 ARMA(2,1)的逆函数为:

$$I_1 = \varphi_1 - \theta_1$$

$$I_2 = \varphi_2 + I_1 \theta_1$$

$$I_j = I_{j-1} \theta_1 \quad j \geq 3$$

对于前述的 $\varphi_1 = 1.3, \varphi_2 = -0.4, \theta_1 = 0.4$ 的模型来说,有

$$I_1 = 0.9$$

$$I_2 = -0.04$$

$$I_3 = -0.016$$

$$I_4 = -0.0064$$

.....




图 3.6 模型的格林函数




图 3.7 模型的逆函数

可见,随着 j 的增大, I_j 趋于零,说明系统某一时刻的响应对于后继时刻的影响是递减状态,逐渐趋于零,因而,该模型是可逆的。图 3.6 和图 3.7 直观地显示了该模型的平稳性和可逆性。

第三节 自协方差函数

一、自协方差函数客观地描述了系统响应的分布特征

1. 直观解释

若前 k 期的行为对现在时刻行为有一定的影响作用,则 X_{t-k} 与 X_t 可能是相关的而不是无关的,其作用程度具体表现为相关程度的高低;相关程度高,影响作用大,反之亦然。若某一时刻的值对其 k 期以后的值没有影响作用,则在数值上应该表现为毫无关系,即不相关的。可见,系统的动态性完全可用自相关函数来刻画。

2. 理论依据

我们知道, X_t 可以用 a_t 的线性组合表出,而 $a_t \sim NID(0, \sigma_a^2)$, 则 $a_t (t=1, 2, \dots)$ 是一个正态过程,此时

$$E(a_t) = 0$$

$$E(a_t, a_{t-k}) = \begin{cases} \sigma_a^2, & k=0 \\ 0, & k \neq 0 \end{cases}$$

a_t 是一个严平稳正态过程,因而它的概率特性完全由自协方差函数来描述,显然 X_t 也是一个正态过程,它的特性也完全取决于自协方差函数。

$$R(k) = \gamma_k = E(X_k, X_{t-k})$$

二、理论自相关函数和样本自相关函数

1. 理论自相关函数

我们知道,随机变量 X 与 Y 的协方差函数为

$$\gamma_{XY} = E(X - \mu_x)(Y - \mu_y)$$

其中, μ_x 为 X 的期望, μ_y 为 Y 的期望, X, Y 的相关函数为

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$$

对于 ARMA 系统来说,设 X_t 为零均值化序列,则自协方差函数

$$\gamma_k = E(X_k, X_{t-k})$$

自相关函数

$$\rho_k = \frac{\gamma_k}{\gamma_0}$$

2. 样本自相关函数

在拟合模型之前,我们所占有的仅是 X_t 的一个有限样本数据,因而无法求得理论自相关函数,唯一的办法是就某一个样本数据计算样本自相关函数。样本自协方差一般有下面两种形式:

$$\hat{\gamma}_k = \frac{1}{N} \sum_{t=k+1}^N X_t X_{t-k}, \quad k=0, 1, 2, \dots, N-1 \quad (3.3.1)$$

或

$$\hat{\gamma}_k^* = \frac{1}{N-k} \sum_{t=k+1}^N X_t X_{t-k} \quad (3.3.2)$$

样本自相关函数便有

$$\hat{\rho}_k = \frac{\hat{\gamma}_k}{\hat{\gamma}_0} = \frac{\frac{1}{N} \sum_{t=k+1}^N X_t X_{t-k}}{\frac{1}{N} \sum_{t=1}^N X_t^2} = \frac{\sum_{t=k+1}^N X_t X_{t-k}}{\sum_{t=1}^N X_t^2} \quad (3.3.3)$$

$$\begin{aligned} \hat{\rho}_k^* &= \frac{\hat{\gamma}_k^*}{\hat{\gamma}_0} = \frac{\frac{1}{N-k} \sum_{t=k+1}^N X_t X_{t-k}}{\frac{1}{N} \sum_{t=1}^N X_t^2} \\ &= \frac{N}{N-k} \cdot \frac{\sum_{t=k+1}^N X_t X_{t-k}}{\sum_{t=1}^N X_t^2} \end{aligned} \quad (3.3.4)$$

可以证明:

(1)当序列均值为零或常数且已知时,(3.3.1)式是有偏的

$$E(\hat{\gamma}_k) = (1 - \frac{k}{N})\gamma_k \quad (3.3.5)$$

偏差的期望 $E(\gamma_k - \hat{\gamma}_k) = \frac{k}{N}\gamma_k$,与样本长度成反比,与滞后及理论自相关成正比。当 k 取某一个固定常数时, γ_k 才是一个渐近无偏估计量,无有效可言,只是一个弱一致估计。而(3.3.2)式是无偏的。

(2)在实际中大多数序列并非零均值,且理论均值往往未知,只好用样本均值来近似代替,这时,样本自协方差为

$$\hat{\gamma}_k' = \frac{1}{N} \sum_{t=k+1}^N (X_t - \bar{x})(X_{t-k} - \bar{X}) \quad (3.3.1a)$$

$$\hat{\gamma}_k^{*'} = \frac{1}{N-k_{t-k+1}} \sum_{t=k+1}^N (X_t - \bar{X})(X_{t-k} - \bar{X}) \quad (3.3.2a)$$

当考虑序列均值估计偏差的情况下,对于(3.3.1a)式和(3.3.2a)式分别有

$$E(\hat{\gamma}') = (1 - \frac{k}{N})\gamma_k + (1 - \frac{k}{N})O(\frac{1}{N})$$

和

$$E(\hat{\gamma}_k^{*'}) = \gamma_k + O(\frac{1}{N})$$

都是有偏的,但后者是渐近无偏的,通常粗略地称 $\hat{\gamma}_k^{*'}$ 为无偏估计, $\hat{\gamma}_k'$ 为有偏估计。

(3)虽然(3.3.1)式是有偏的,但是它的方差却比(3.3.2)式小。

$$\text{Var}(\hat{\gamma}_k) = O(\frac{1}{N}) \quad (\text{对于所有的 } k)$$

$$\text{Var}(\hat{\gamma}_k^*) = O(\frac{1}{N-k})$$

可见,(3.3.1)式对任何 k 均保持 $O(\frac{1}{N})$,所以 $\hat{\gamma}_k$ 的波动在整个 k 的范围内都保持很少。而(3.3.2)式则不然,当 k 接近 $(N-1)$ 时, $\text{Var}(\hat{\gamma}_k^*)$ 增大很多。

(4)当样本观测值 $x_1, x_2, \dots, x_N$ 不全为零时,(3.3.1)式必定是正定序列,但(3.3.2)式却不一定具备正定性。对平稳序列而言,自协方差的正定性是最本质的,常常是相关分析和参数估计的条件。

因此,在时间序列分析中通常使用有偏估计(3.3.1)式。其理由除以上所述之外,还在于我们主要关心的往往不是某一个 k 值时的 γ_k 的估计值,而是以 0 到 $(N-1)$ 范围内所有 k 值的函数 γ_k 的估计。

3. 格林函数与自协方差函数之间的关系

为了便于理解,我们先研究简单模型的自协方差函数。

(1)AR(1)模型的自协方差函数

AR(1)模型为

$$X_t = \varphi_1 X_{t-1} + a_t \quad (3.3.6)$$

假设 X_t 为零均值序列。将(3.3.6)式两端乘以 X_{t-k} ,并取期望,得

$$E(X_t X_{t-k}) = \varphi_1 E(X_{t-1} X_{t-k}) + E(a_t X_{t-k}) \quad (3.3.7)$$

当 $k=0$ 时,有

$$E(X_t X_t) = \varphi_1 E(X_{t-1} X_t) + E(a_t X_t)$$

即

$$\gamma_0 = \varphi_1 \gamma_1 + \sigma_a^2 \quad (3.3.8)$$

当 $k=1$ 时,有

$$E(X_t X_{t-1}) = \varphi_1 E(X_{t-1} X_{t-1}) + E(a_t X_{t-1})$$

$$\text{即} \quad \gamma_1 = \varphi_1 \gamma_0 \quad (3.3.9a)$$

当 $k=2$ 时,

$$E(X_t X_{t-2}) = \varphi_1 E(X_{t-1} X_{t-2}) + E(a_t X_{t-2})$$

$$\gamma_2 = \varphi_1 \gamma_1 \quad (3.3.9b)$$

依此类推,便有一般式:

$$\gamma_k = \varphi_1 \gamma_{k-1}, \quad k > 0 \quad (3.3.9)$$

将(3.3.9a)代入(3.3.8)式,有

$$\left. \begin{aligned} \gamma_0 &= \varphi_1 (\varphi_1 \gamma_0) + \sigma_a^2 \Rightarrow \gamma_0 = \frac{\sigma_a^2}{1 - \varphi_1^2} \\ \gamma_k &= \varphi_1 \gamma_{k-1}, \quad k > 0 \end{aligned} \right\} \quad (3.3.10)$$

相应的自相关函数为 γ_k/γ_0 , 即

$$\begin{cases} \rho_0 = \gamma_0/\gamma_0 = 1 \\ \rho_k = \gamma_k/\gamma_0 = \varphi_1 \gamma_{k-1}/\gamma_0 = \varphi_1 \rho_{k-1} \end{cases}$$

(2) MA(1)模型的自协方差函数:

将 MA(1)模型

$$X_t = a_t - \theta_1 a_{t-1}$$

两端同乘以 X_{t-k} , 取期望, 得

$$\begin{aligned} E(X_t X_{t-k}) &= E(a_t X_{t-k}) - \theta_1 E(a_{t-1} X_{t-k}) \\ &= E[a_t (\sum_{j=0}^{\infty} G_j a_{t-k-j})] - \theta_1 E[a_{t-1} (\sum_{j=0}^{\infty} G_j a_{t-k-j})] \\ &= \sum_{j=0}^{\infty} G_j E(a_t a_{t-k-j}) - \theta_1 [\sum_{j=0}^{\infty} G_j E(a_{t-1} a_{t-k-j})] \\ &= G_0 E(a_t a_t) + G_1 E(a_{t-k-1} a_t) - \theta_1 [G_0 E(a_{t-1} a_{t-k}) + G_1 E(a_{t-1} a_{t-k-1})] \\ &= E(a_t a_{t-k}) - \theta_1 E(a_t a_{t-k-1}) - \theta_1 E(a_{t-1} a_{t-k}) + \theta_1^2 E(a_{t-1} a_{t-k-1}) \quad (3.3.11) \end{aligned}$$

当 $k=0$ 时, 有

$$\begin{aligned} \gamma_0 &= E(X_t X_t) \\ &= E(a_t a_t) - \theta_1 E(a_t a_{t-1}) - \theta_1 E(a_{t-1} a_t) + \theta_1^2 E(a_{t-1} a_{t-1}) \\ &= \sigma_a^2 + \theta_1^2 \sigma_a^2 = (1 + \theta_1^2) \sigma_a^2 \end{aligned}$$

当 $k=1$ 时, 有

$$\begin{aligned} \gamma_1 &= E(X_t X_{t-1}) \\ &= E(a_t a_{t-1}) - \theta_1 E(a_t a_{t-2}) - \theta_1 E(a_{t-1} a_{t-1}) + \theta_1^2 E(a_{t-1} a_{t-2}) \end{aligned}$$

$$= -\theta_1 \sigma_a^2$$

当 $k=2$ 时,有

$$\begin{aligned}\gamma_2 &= E(X_t X_{t-2}) \\ &= E(a_t a_{t-2}) - \theta_1 E(a_t a_{t-3}) - \theta_1 E(a_{t-1} a_{t-2}) - \theta_1^2 E(a_{t-1} a_{t-3}) \\ &= 0\end{aligned}$$

可见,对于 MA(1)模型来说

$$\left. \begin{aligned}\gamma_0 &= (1 + \theta_1^2) \sigma_a^2 \\ \gamma_1 &= -\theta_1 \sigma_a^2 \\ \gamma_k &= 0, \quad k \geq 2\end{aligned} \right\} \Rightarrow \begin{cases} \rho_0 = 1 \\ \rho_1 = -\frac{\theta_1}{1 + \theta_1^2} \\ \rho_k = 0, \quad k \geq 2 \end{cases} \quad (3.3.12)$$

这时,我们发现,MA(1)模型的自相关函数在滞后 1 期以后为零,即截尾性。是否 MA(q)模型的自相关函数在 q 步后也会截尾呢?可以证明确实如此。

为了证明这一点,我们给出 G_j 与 γ_k 之间的关系:

$$\begin{aligned}\gamma_k &= E(X_t X_{t-k}) \\ &= E\left[\sum_{i=0}^{\infty} G_i a_{t-i} \left(\sum_{j=0}^{\infty} G_j a_{t-(j+k)}\right)\right] \\ &= E\left[\sum_{i=0}^{\infty} \sum_{j=0}^{\infty} G_i G_j a_{t-i} a_{t-(j+k)}\right] \\ &= \sum_{i=0}^{\infty} \sum_{j=0}^{\infty} G_i G_j E(a_{t-i} a_{t-(j+k)}) \\ &= \sum_{j=0}^{\infty} G_{j+k} G_j \sigma_a^2\end{aligned} \quad (3.3.13)$$

这就是二者的关系,所以,就理论自协方差来说,它完全描述了系统的动态特征。

现在我们来研究 MA(q)模型的自协方差函数。我们知道,对于 MA(1)模型

$$\begin{cases} G_0 = 1 \\ G_j = -\theta_j, \quad j > 0 \end{cases}$$

那么,对于 MA(q)模型来说,有

$$G_0 = 1, \quad G_1 = -\theta_1, \quad G_2 = -\theta_2, \quad \dots, \quad G_q = -\theta_q, \quad G_k = 0, \quad k > q$$

于是,根据(3.3.13)式,有

$$\begin{aligned}\gamma_k &= \sum_{j=0}^{\infty} G_{j+k} G_j \sigma_a^2 \\ &= (G_k G_0 + G_{k+1} G_1 + G_{k+2} G_2 + \dots + G_q G_{q-k}) \sigma_a^2\end{aligned}$$

此时,当 $k=0$ 时,

$$\begin{aligned}\gamma_0 &= (1 + G_1^2 + G_2^2 + \cdots + G_q^2) \sigma_a^2 \\ &= (1 + \theta_1^2 + \theta_2^2 + \cdots + \theta_q^2) \sigma_a^2\end{aligned}\quad (3.3.14)$$

当 $1 \leq k \leq q$ 时,

$$\gamma_k = (-\theta_k + \theta_{k+1}\theta_1 + \theta_{k+2}\theta_2 + \cdots + \theta_q\theta_{q-k})\sigma_a^2 \quad (3.3.15)$$

当 $k > q$ 时,

$$\gamma_k = 0$$

但对于 AR 及 ARMA 系统来说,由于 $G_j G_{j+k}$ 永远不会精确地等于零。因而 AR 模型的表现为拖尾而不是截尾。可见,截尾性唯 MA 模型所特有。那么,怎样识别 AR 模型呢? 这就需要研究偏自相关函数。

4. 偏自相关函数

对于 $k=1, 2, \cdots$ 我们分别考虑用 $X_{t-k}, X_{t-k+1}, \cdots, X_{t-1}$, 对 X_t 作最小方差估计,即选择系数 $\varphi_{kj} (j=1, 2, \cdots, k)$, 使得

$$\begin{aligned}\delta &\equiv E(X_t - \sum_{j=1}^k \varphi_{kj} X_{t-j})^2 \\ &= \gamma_0 - 2 \sum_{j=1}^k \varphi_{kj} \gamma_j + \sum_{i,j=1}^k \varphi_{ki} \varphi_{kj} \gamma_{j-i}\end{aligned}\quad (3.3.16)$$

达到极小值,“就是使残差的方差达到极小的 k 阶自回归(AR)模型的第 k 项系数”,为什么又称偏自相关函数? 请看下面的推导:

$$\begin{aligned}\delta &\equiv E(X_t - \sum_{j=1}^k \varphi_{kj} X_{t-j})^2 \\ &= E \left[X_t - (\varphi_{k1}, \varphi_{k2}, \cdots, \varphi_{kk}) \begin{bmatrix} X_{t-1} \\ X_{t-2} \\ \vdots \\ X_{t-k} \end{bmatrix} \right]^2 \\ &= E \left\{ X_t^2 - 2X_t(\varphi_{k1} \cdots \varphi_{k2} \cdots \varphi_{kk}) \begin{bmatrix} X_{t-1} \\ X_{t-2} \\ \vdots \\ X_{t-k} \end{bmatrix} \right. \\ &\quad \left. + (\varphi_{k1} \cdots \varphi_{kk}) \begin{bmatrix} X_{t-1} \\ X_{t-2} \\ \vdots \\ X_{t-k} \end{bmatrix} (X_{t-1} X_{t-2} \cdots X_{t-k}) \begin{bmatrix} \varphi_{k1} \\ \vdots \\ \varphi_{kk} \end{bmatrix} \right\}\end{aligned}$$

$$\begin{aligned}
&= E[X_t^2] - 2(\varphi_{k1} \varphi_{k2} \cdots \varphi_{kk}) E \left[X_t \begin{pmatrix} X_{t-1} \\ \vdots \\ X_{t-k} \end{pmatrix} \right] \\
&\quad + (\varphi_{k1} \varphi_{k2} \cdots \varphi_{kk}) E \begin{pmatrix} X_{t-1} \\ X_{t-2} \\ \vdots \\ X_{t-k} \end{pmatrix} \cdot (X_{t-1} X_{t-2} \cdots X_{t-k}) \begin{pmatrix} \varphi_{k1} \\ \varphi_{k2} \\ \vdots \\ \varphi_{kk} \end{pmatrix} \\
&= \gamma_0 - 2(\varphi_{k1} \varphi_{k2} \cdots \varphi_{kk}) \begin{pmatrix} \gamma_1 \\ \gamma_2 \\ \vdots \\ \gamma_k \end{pmatrix} + (\varphi_{k1} \cdots \varphi_{kk}) \begin{pmatrix} \gamma_0 & \gamma_1 \cdots \gamma_{k-1} \\ \gamma_1 & \gamma_0 \cdots \gamma_{k-2} \\ \cdots & \cdots \\ \gamma_{k-1} & \gamma_{k-2} \cdots \gamma_0 \end{pmatrix} \begin{pmatrix} \varphi_{k1} \\ \varphi_{k2} \\ \vdots \\ \varphi_{kk} \end{pmatrix} \\
\frac{\partial \delta}{\partial \varphi_{kj}} &= -2 \begin{pmatrix} \gamma_1 \\ \gamma_2 \\ \vdots \\ \gamma_k \end{pmatrix} + 2 \begin{pmatrix} \gamma_0 & \gamma_1 \cdots \gamma_{k-1} \\ \gamma_1 & \gamma_0 \cdots \gamma_{k-2} \\ \cdots & \cdots \\ \gamma_{k-1} & \gamma_{k-2} \cdots \gamma_0 \end{pmatrix} \begin{pmatrix} \varphi_{k1} \\ \varphi_{k2} \\ \vdots \\ \varphi_{kk} \end{pmatrix}
\end{aligned}$$

令 $\frac{\partial \delta}{\partial \varphi_{kj}} = 0$, 得

$$\begin{pmatrix} \gamma_0 & \gamma_1 & \cdots & \gamma_{k-1} \\ \gamma_1 & \gamma_0 & \cdots & \gamma_{k-2} \\ \cdots & \cdots & \cdots & \cdots \\ \gamma_{k-1} & \gamma_{k-2} & \cdots & \gamma_0 \end{pmatrix} \begin{pmatrix} \varphi_{k1} \\ \varphi_{k2} \\ \vdots \\ \varphi_{kk} \end{pmatrix} = \begin{pmatrix} \gamma_1 \\ \gamma_2 \\ \cdots \\ \gamma_k \end{pmatrix}$$

将矩阵展开得:

$$\begin{cases} \varphi_{k1}\gamma_0 + \varphi_{k2}\gamma_1 + \cdots + \varphi_{kk}\gamma_{k-1} = \gamma_1 \\ \varphi_{k1}\gamma_1 + \varphi_{k2}\gamma_0 + \cdots + \varphi_{kk}\gamma_{k-2} = \gamma_2 \\ \cdots \quad \cdots \quad \cdots \\ \varphi_{k1}\gamma_{k-1} + \varphi_{k2}\gamma_{k-2} + \cdots + \varphi_{kk}\gamma_0 = \gamma_k \end{cases}$$

同除以 γ_0 , 则

$$\begin{cases} \varphi_{k1}\rho_0 + \varphi_{k2}\rho_1 + \cdots + \varphi_{kk}\rho_{k-1} = \rho_1 \\ \varphi_{k1}\rho_1 + \varphi_{k2}\rho_0 + \cdots + \varphi_{kk}\rho_{k-2} = \rho_2 \\ \cdots \quad \cdots \quad \cdots \\ \varphi_{k1}\rho_{k-1} + \varphi_{k2}\rho_{k-2} + \cdots + \varphi_{kk}\rho_0 = \rho_k \end{cases} \quad (3.3.17)$$

此方程称为 Yule-Wolker 方程, 其中序列 φ_{kk} 称为 X_t 的偏自相关函数。

当 $k=1$ 时, 直接由第一个方程式可得

$$\varphi_{11} = \rho_1$$

当 $k=2$ 时, 有

$$\begin{cases} \rho_1 = \varphi_{21}\rho_0 + \varphi_{22}\rho_1 \\ \rho_2 = \varphi_{21}\rho_1 + \varphi_{22}\rho_0 \end{cases}$$

利用克莱姆(Cramer)法则得

$$\Delta = \begin{vmatrix} \rho_0 & \rho_1 \\ \rho_1 & \rho_0 \end{vmatrix} \quad \Delta\varphi_{22} = \begin{vmatrix} \rho_0 & \rho_1 \\ \rho_1 & \rho_2 \end{vmatrix}$$

则

$$\varphi_{22} = \frac{\begin{vmatrix} \rho_0 & \rho_1 \\ \rho_1 & \rho_2 \end{vmatrix}}{\begin{vmatrix} \rho_0 & \rho_1 \\ \rho_1 & \rho_0 \end{vmatrix}} = \frac{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & \rho_2 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{vmatrix}}$$

当 $k=3$ 时,有

$$\begin{cases} \rho_1 = \varphi_{31}\rho_0 + \varphi_{32}\rho_1 + \varphi_{33}\rho_2 \\ \rho_2 = \varphi_{31}\rho_1 + \varphi_{32}\rho_0 + \varphi_{33}\rho_1 \\ \rho_3 = \varphi_{31}\rho_2 + \varphi_{32}\rho_1 + \varphi_{33}\rho_0 \end{cases}$$

利用克莱姆(Cramer)法则,得

$$\varphi_{33} = \frac{\begin{vmatrix} \rho_0 & \rho_1 & \rho_1 \\ \rho_1 & \rho_0 & \rho_2 \\ \rho_2 & \rho_1 & \rho_3 \end{vmatrix}}{\begin{vmatrix} \rho_0 & \rho_1 & \rho_2 \\ \rho_1 & \rho_0 & \rho_1 \\ \rho_2 & \rho_1 & \rho_0 \end{vmatrix}}$$

类似地递推下去,得

$$\varphi_{kk} = \frac{\begin{vmatrix} \rho_0 & \rho_1 & \rho_2 & \cdots & \rho_{k-2} & \rho_1 \\ \rho_1 & \rho_0 & \rho_1 & \cdots & \rho_{k-3} & \rho_2 \\ \cdots & \cdots & \cdots & \cdots & \cdots & \cdots \\ \rho_{k-1} & \rho_{k-2} & \rho_{k-3} & \cdots & \rho_1 & \rho_k \end{vmatrix}}{\begin{vmatrix} \rho_0 & \rho_1 & \rho_2 & \cdots & \rho_{k-1} \\ \rho_1 & \rho_0 & \rho_1 & \cdots & \rho_{k-2} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ \rho_{k-1} & \rho_{k-2} & \rho_{k-3} & \cdots & \rho_0 \end{vmatrix}}$$

当用样本自相关函数代替 Yule-Wolker 方程中的理论自相关函数后,得到的偏自相关函数就称为样本偏自相关函数。

由(3.3.16)式可以看出:

$$\delta = E[X_t - (\varphi_{k1}X_{t-1} + \varphi_{k2}X_{t-2} + \cdots + \varphi_{kk}X_{t-k})]^2$$

φ_{kk} 是使在模型中已经包含了滞后期较短的滞后值 $X_{t-1}, X_{t-2}, \dots, X_{t-k+1}$ 之后, 再增加一期滞后 X_{t-k} 所增加的模型的解释能力, 因为它是 $AR(k)$ 模型中 X_{t-k} 的回归系数。如 $AR(4)$ 模型, φ_{44} 就是在 $AR(3)$ 模型的基础上, 再增加 X_{t-4} , X_{t-4} 与 X_t 的相关关系, 不是完整的 X_t 与 X_{t-4} 的相关关系, 故称之为部分相关函数, 即偏自相关函数。可见, 偏相关函数是条件相关, 是在给定 $X_1, X_2, \dots, X_{t-k+1}$ 的条件下, X_t 和 X_{t-k} 的条件相关。例如, 对于 $AR(2)$ 模型来说, X_t 和 $X_{t-j} (j>2)$ 的偏相关为 0, 实际上, 就是在给定 X_{t-1}, X_{t-2} 的条件下 X_t 与 $X_{t-j} (j>2)$ 的条件相关为 0, 换句话说, 偏自相关函数是对 X_t 与 X_{t-k} 之间未被 $X_{t-1}, X_{t-2}, \dots, X_{t-k+1}$ 所解释的相关的度量。所以 AR 模型描述的是 $X_{t-1}, X_{t-2}, \dots, X_{t-k}$ 对 X_t 的影响, 其系数 $\varphi_{kj} (j=1, 2, \dots, k)$ 是在考虑长期记忆的时候, X_{t-j} 对 X_t 的解释能力, 也就是 X_t 对 X_{t-j} 的记忆程度。

既然对于 AR 模型来说, 第 k 个偏自相关系数 φ_{kk} 就是 AR 模型中 X_{t-k} 的回归系数, 那么, 对于 $AR(P)$ 模型, 有

$$\varphi_{11}=\varphi_1, \quad \varphi_{22}=\varphi_2, \quad \dots \quad \varphi_{pp}=\varphi_p, \quad \varphi_{kk}=0, \quad K>P$$

可见, $AR(P)$ 模型偏相关函数 P 步截尾。

* 第四节 自 谱

自相关函数是在时域中分析平稳序列 X_t 的统计规律的数字特征。若在频率域描述平稳序列 X_t 的统计规律性, 主要数字特征就是功率谱密度(也叫自谱密度或谱密度), 这是频域分析中使用的主要工具。频域分析将时间序列看成是不同谐波的叠加, 并通过研究波动的频率特征来刻画时间序列的特性, 是研究系统的周期波动的重要工具, 但是鉴于本书的对象和篇幅, 对频域分析方法将不作详细的讨论。为了完整起见, 我们将简要介绍谱和谐密度。本书中我们并不使用这些方法, 初学者可以略去此节。为了便于理解谱密度先看以下几个概念:

一、几个概念

1. 有限离散傅立叶变换(Discrete Fourier Transform, 简记为 DFT)

设 $X_t (t=0, 1, \dots, N-1)$ 为离散确定性时间序列, 则称

* 此星号系该节的标号, 表示该节在教学中可以自由选择!

$$A(k) = \frac{1}{N} \sum_{j=0}^{N-1} X_j \omega^{jk}, \quad k=0, \dots, N-1 \quad (3.4.1)$$

为序列 X_j 的有限离散傅立叶变换 DFT, 其中

$$\omega = e^{-\frac{2\pi i}{N}}, \quad i = \sqrt{-1}$$

(3.4.1) 式逆变换为

$$X_j = \sum_{k=0}^{N-1} A(k) \omega^{-jk}, \quad j=0, 1, \dots, N-1 \quad (3.4.2)$$

$$X_j^* = \sum_{k=0}^{N-1} A^*(k) \omega^{jk}, \quad * \text{ 表示共轭。}$$

序列 X_j 和 $A(k)$ 称作傅立叶变换对, 可用 $\{X_j\} \longleftrightarrow \{A(k)\}$ 表示。

DFT 的线性: 若序列 X_{1j} 的 DFT 是 $A_1(K)$, X_{2j} 的 DFT 是 $A_2(K)$, a, b 为常数, 且

$$X_j = aX_{1j} + bX_{2j}$$

则 X_j 的 DFT 为 $A(K) = aA_1(K) + bA_2(K)$, 若 X_j 是实数列, 那么, X_j 的 DFT $A(K)$ 有下面的性质:

$$A(K) = A^*(N-K), \quad * \text{ 表示共轭复数}$$

因而计算实序列 DFT, 只要计算前 $[\frac{N}{2}] + 1$ 个点即可。

2. 周期图

根据傅立叶的基本思想, 确定性的周期函数在一定条件下可以看成是由一些正余弦 $(\sin(ks) \cos(ks), k=0, 1, 2, \dots)$ 波构成的。如果我们把时间序列 X_j 看成是由不同频率的正余弦波叠加而成的, 那么 X_j 可以表示为

$$X_j = \sum_{i=1}^k C_i \cos(2\pi f_i t + \varphi_i) + \epsilon_i \quad (3.4.3)$$

其中 k 为常数, 是周期分量的个数即主周期(基波)及其谐波的个数; $C_i (i=1, 2, \dots, k)$ 也是常数, 是第 i 个周期波的振幅; $f_i (i=1, 2, \dots, k)$ 也是常数, 表示第 i 个周期波的频率, f_1 为主周期即基波的频率, $f_i (i=2, 3, \dots, k)$ 为第 i 个谐波的频率, $\frac{1}{f_i}$ 即为第 i 个周期波的周期; $\varphi_i (i=1, 2, \dots, k)$ 是第 i 个周期波的相位, 是在 $(-\pi, \pi)$ 内均匀分布的独立随机变量; ϵ_i 是独立于 $\varphi_i (i=1, 2, \dots, k)$ 的纯随机序列, $E(\epsilon_i) = 0, E(\epsilon_i^2) = \sigma_\epsilon^2$ 。

对式 (3.4.3) 进行再系数化, 可得

$$X_j = \sum_{i=1}^k (a_i \cos 2\pi f_i t + b_i \sin 2\pi f_i t) + \epsilon_i \quad (3.4.4)$$

其中 $a_i = C_i \cos \varphi_i, b_i = -C_i \sin \varphi_i$ 。

显然, $C_i = \sqrt{a_i^2 + b_i^2}, \varphi_i = \tan^{-1}(-\frac{b_i}{a_i})$ 。

当频率给定时,式(3.4.4)可以看作是一个多变量线性回归模型,未知参数 a_i 和 b_i 的最小二乘估计为

$$\hat{a}_i = \frac{2}{N} \sum_{t=1}^N X_t \cos 2\pi f_i t \quad (3.4.5)$$

$$\hat{b}_i = \frac{2}{N} \sum_{t=1}^N X_t \sin 2\pi f_i t \quad (3.4.6)$$

其中 N 为观测值个数。

可以证明: $E(\hat{a}_i) = a_i$ (所有 i), $E(\hat{b}_i) = b_i$ (所有 i)

$$\text{Var}(\hat{a}_i) = 2\sigma_\epsilon^2/N, \quad \text{Var}(\hat{b}_i) = 2\sigma_\epsilon^2/N, \quad \text{Cov}(\hat{a}_i, \hat{b}_i) = 0 \text{ (所有 } i)$$

$$\hat{\sigma}_\epsilon^2 = \frac{1}{N-2k} \sum_{t=1}^N [X_t - \sum_{i=1}^k (\hat{a}_i \cos 2\pi f_i t + \hat{b}_i \sin 2\pi f_i t)]^2 \quad (3.4.7)$$

在此基础上,我们将具有 N 个观测值的序列 X_t 的周期图定义为

$$I(f_i) = \frac{N}{2} (a_i^2 + b_i^2) \quad i=1, 2, \dots, k \quad (3.4.8)$$

可见,周期图是由 k 个值构成的, $I(f_i)$ 称为在频率 f_i 处的强度,在实际计算中,频率取离散值: $0, \frac{1}{N}, \frac{2}{N}, \dots$ 。

如果时间序列是纯随机的,不含周期分量,即

$$X_t = \mu + \epsilon_t \quad (3.4.9)$$

其中 μ 为均值随机变量, $\epsilon_t (t=1, 2, \dots, N)$ 是零均值,方差为 σ_ϵ^2 的独立正态随机变量。这时,每一分量 $I(f_i)$ 的期望为 $2\sigma_\epsilon^2$,服从 $\sigma_\epsilon^2 \chi^2(2)$ 分布,且与其它分量独立。反之,如果序列包含频率为 f_i ,振幅为 C_i ,相位为 φ_i 的周期分量时,

$$E[I(f_i)] = \frac{N}{2} C_i^2 + 2\sigma_\epsilon^2 \quad (3.4.10)$$

此时, $I(f_i)$ 将会陡增。

事实上,一个未知系统周期分量的频率不大可能与上述频率 f_i (其强度为 $I(f_i)$) 完全匹配。这时,在最邻近真频率处周期图将明显增大。我们可以利用这一性质检测序列 X_t 可能存在的周期分量。为了说明周期图的应用及其计算过程,我们只选用某地某年 1—12 月份(实际应用中,为了保证估计的准确性,需要用更长的数据资料)鲜蛋销售量零均值化后的资料(计量单位为千吨,均值为 2.076 千吨)。

表 3.3 某地某年鲜蛋月销售量

t	1	2	3	4	5	6
X_t	1.361	1.562	1.693	2.526	4.805	2.942
t	7	8	9	10	11	12
X_t	2.579	1.949	1.724	1.608	1.012	1.154

为了直观起见,我们先分别计算出不同 f_i 下的 $\cos(2\pi f_i t)$ 和 $\sin(2\pi f_i t)$, 见表 3.4 和表 3.5。(见下页)

根据(3.4.5)式和(3.4.6)式,鲜蛋销售数据 X_t (12个月)的不同谐波正弦余弦的振幅见表 3.6。

表 3.6 X_t 的不同谐波正弦余弦的振幅

i	1	2	3	4	5	6
a_i	-1.130	0.2892	-0.0803	-0.1981	0.3165	-0.2388
b_i	0.2859	-0.3608	0.4344	-0.1809	0.1329	0.0000

根据周期图的定义(3.4.8)式, $I(f_i)$ 的计算结果见表 3.7。

表 3.7 $I(f_i)$ 的计算结果

i	f_i	周 期	$I(f_i)$
1	1/12	12	8.1509
2	1/6	6	1.2829
3	1/4	4	1.1710
4	1/3	3	0.4318
5	5/12	12/5	0.7070
6	1/2	2	0.3424

可见,在 $f_1=1/12$ 处,强度 $I(f_1)$ 陡增,故该数据 X_t 可能存在 12 个月的周期。

3. 频谱

设有时间函数 $X_t(-\infty < t < +\infty)$, 若 X_t 满足

$$\int_{-\infty}^{+\infty} |X_t| d_t < +\infty$$

表 3.4 对应于 f_i 的 $\cos(2\pi f_i t)$ 值

$t \backslash f_i$	1	2	3	4	5	6	7	8	9	10	11	12
$f_1=1/12$	0.8660	.5000	0.0000	-0.5000	-0.8660	-1.0000	-0.8660	-0.5000	1.000	0.5000	0.8660	1.0000
$f_2=1/6$	0.5000	-0.5000	-1.000	-0.5000	0.500	1.000	0.5000	-0.5000	-1.000	-0.500	0.5000	1.000
$f_3=1/4$	0.0000	-1.000	1.000	1.000	0.000	-1.000	0.000	1.000	0.000	-1.000	0.000	1.000
$f_4=1/3$	-0.5000	-0.5000	1.000	-0.5000	-0.5000	1.000	-0.500	-0.500	1.000	-0.5000	-0.5000	1.000
$f_5=5/12$	-0.8660	0.5000	0.000	-0.5000	0.8660	-1.000	0.8660	-0.5000	0.000	0.000	-0.8660	1.000
$f_6=1/2$	-1.000	1.000	-1.000	1.000	-1.000	1.000	-1.000	1.000	-1.000	1.000	-1.000	1.000

表 3.5 对应于 f_i 的 $\sin(2\pi f_i t)$

$t \backslash f_i$	1	2	3	4	5	6	7	8	9	10	11	12
$f_1=1/12$	0.5000	0.8660	1.000	0.8660	0.5000	0.000	-0.5000	-0.8660	-1.000	-0.8660	-0.5000	0.0000
$f_2=1/6$	0.8660	0.8660	0.000	-0.8660	-0.8660	0.000	0.8660	0.8660	0.000	-0.8660	-0.8660	0.000
$f_3=1/4$	1.000	0.000	-1.000	0.000	1.000	0.000	-1.000	0.000	1.000	0.000	-1.000	0.000
$f_4=1/3$	0.8660	-0.8660	0.000	0.8660	-0.8660	0.000	0.8660	-0.8660	0.000	0.8660	-0.8660	0.000
$f_5=5/12$	0.5000	-0.8660	1.000	-0.8660	0.5000	0.000	-0.5000	0.8660	-1.000	0.8660	-0.5000	0.000
$f_6=1/2$	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000

那么 X_t 的傅立叶变换存在或者说具有频谱:

$$F_x(\omega) = \int_{-\infty}^{+\infty} X_t e^{-j\omega t} dt \quad (3.4.11)$$

$F_x(\omega)$ 一般是复数量, 其共轭函数 $F_x^*(\omega) = F_x(-\omega)$, 在 X_t 和 $F_x(\omega)$ 之间有等式(Parseval 等式):

$$\int_{-\infty}^{+\infty} X_t^2 dt = \frac{1}{2\pi} \int_{-\infty}^{+\infty} |F_x(\omega)|^2 d\omega \quad (3.4.12)$$

(若将 X_t 看作是电流, X_t^2 将是这个电流在单位电阻上产生的瞬时功率), (3.4.12) 式左端表示 X_t 在 $(-\infty, +\infty)$ 上的总能量, 而右端的被积式 $|F_x(\omega)|^2$ 相应地称为 X_t 的能谱密度。可见, Parseval 等式可理解为总能量的谱表示式。

鉴于许多时间函数总能量是无限的, 因而一般研究 X_t 的平均功率, 即

$$\lim_{T \rightarrow +\infty} \frac{1}{2T} \int_{-T}^T X_t^2 dt$$

现在我们来研究平均功率的谱表示式。为了能用傅立叶变换给出, 我们先由给定的 X_t 构造一个截尾函数

$$X_t(T) = \begin{cases} X_t, & |t| \leq T \\ 0, & |t| > T \end{cases}$$

记 $X_t(T)$ 的傅立叶变换为

$$\begin{aligned} F_x(\omega, T) &= \int_{-\infty}^{+\infty} X_t(T) e^{-j\omega t} dt \\ &= \int_{-T}^T X_t(T) e^{-j\omega t} dt \end{aligned} \quad (3.4.13)$$

其相应的 Parseval 等式为

$$\int_{-\infty}^{+\infty} X_t^2(T) dt = \frac{1}{2\pi} \int_{-\infty}^{+\infty} |F_x(\omega, T)|^2 d\omega$$

将上式两边同除以 $2T$, 便有

$$\frac{1}{2T} \int_{-T}^T X_t^2 dt = \frac{1}{4\pi T} \int_{-\infty}^{+\infty} |F_x(\omega, T)|^2 d\omega$$

令 $T \rightarrow \infty$, X_t 在 $(-\infty, +\infty)$ 上的平均功率即可表示为

$$\lim_{T \rightarrow \infty} \frac{1}{2T} \int_{-T}^T X_t^2 dt = \frac{1}{2\pi} \int_{-\infty}^{+\infty} \left\{ \lim_{T \rightarrow \infty} \frac{1}{2T} |F_x(\omega, T)|^2 \right\} d\omega \quad (3.4.14)$$

上式右端的被积函数称为 X_t 的平均功率谱密度, 简称为功率谱密度。记作

$$S_x(\omega) = \lim_{T \rightarrow \infty} \frac{1}{2T} |F_x(\omega, T)|^2 \quad (3.4.15)$$

二、平稳过程的谱密度

对于随机过程来说, X_t 为一族随机变量, 我们只能对其样本函数(即一次实现)进行研究。一般说来, 不能保证其绝对可积, 因而, 不能直接运用傅立叶变换。但是, 如上所述, 我们可以对样本函数进行截取, 构造一个截尾函数, 于是, 其傅立叶变换为

$$F_x(\omega, T) = \int_{-T}^T X_t e^{-j\omega t} dt$$

同样有

$$\frac{1}{2T} \int_{-T}^T X_t^2 dt = \frac{1}{4\pi T} \int_{-\infty}^{+\infty} |F_x(\omega, T)|^2 d\omega \quad (3.4.16)$$

这时, 积分均是随机积分。(3.4.16) 式左端的均值的极限, 即量

$$\lim_{T \rightarrow \infty} E \left\{ \frac{1}{2T} \int_{-T}^T X_t^2 dt \right\} \quad (3.4.17)$$

叫做平稳过程 X_t 的平均功率, (3.4.17) 式可等价地表示为

$$\lim_{T \rightarrow \infty} E \left\{ \frac{1}{2T} \int_{-T}^T X_t^2 dt \right\} = \lim_{T \rightarrow \infty} \frac{1}{2T} \int_{-T}^T E[X_t^2] dt = \phi_x^2 \quad (3.4.18)$$

即平稳过程的平均功率就等于该过程的均方值。将(3.4.16) 式代入上式, 得

$$\begin{aligned} \phi_x^2 &= \lim_{T \rightarrow \infty} E \left\{ \frac{1}{2T} \int_{-T}^T X_t^2 dt \right\} \\ &= \lim_{T \rightarrow \infty} E \left\{ \frac{1}{4\pi T} \int_{-\infty}^{+\infty} |F_x(\omega, T)|^2 d\omega \right\} \\ &= \frac{1}{2\pi} \int_{-\infty}^{+\infty} \lim_{T \rightarrow \infty} \frac{1}{2T} E\{|F_x(\omega, T)|^2\} d\omega \end{aligned} \quad (3.4.19)$$

则上式中的被积函数称为平稳过程 X_t 的功率谱密度, 记作

$$S_x(\omega) = \lim_{T \rightarrow \infty} \frac{1}{2T} E\{|F_x(\omega, T)|^2\}$$

通常称为自谱密度或谱密度。

三、谱密度与自相关函数的关系

谱密度与自相关函数, 二者是一傅立叶变换对, 即

$$\begin{aligned} S_x(\omega) &= \int_{-\infty}^{+\infty} R_x(\tau) e^{-j\omega\tau} d\tau \\ R_x(\tau) &= \frac{1}{2\pi} \int_{-\infty}^{+\infty} S_x(\omega) e^{-j\omega\tau} d\omega \end{aligned}$$

称之为维纳—辛钦公式或平稳过程自相关函数的谱表示式。它揭示了从时间

角度描述平稳过程 X_t 的统计规律和从频率角度描述 X_t 的统计规律之间的联系。因为 $R_x(\tau)$ 和 $S_x(\omega)$ 均为偶函数, 所以还可写成

$$\begin{cases} S_x(\omega) = 2 \int_0^{\infty} R_x(\tau) \cos \omega \tau d\tau \\ R_x(\tau) = \frac{1}{\pi} \int_0^{+\infty} S_x(\omega) \cos \omega \tau d\omega \end{cases}$$

当 γ_k 满足条件

$$\sum_{k=-\infty}^{\infty} |\gamma_k| < \infty$$

则 $g(\lambda)$ 一定存在, 且

$$g(\lambda) = \sum_{k=-\infty}^{\infty} \gamma_k e^{-i2\pi k\lambda}$$

四、ARMA 模型的谱密度

对于平稳序列, 只讨论谱分布 $G(\lambda)$ 可微且导函数(谱密度)

$$g(\lambda) \equiv \frac{dG(\lambda)}{d\lambda}$$

为 $e^{-i2\pi\lambda}$ 的有理函数

$$g(\lambda) = \sigma_a^2 \left| \frac{\theta(e^{-i2\pi\lambda})}{\varphi(e^{-i2\pi\lambda})} \right|^2$$

其中 $\theta(\omega)$ 和 $\varphi(\omega)$ 为 ω 的实系数多项式

$$\theta(\omega) = 1 - \theta_1 \omega - \theta_2 \omega^2 - \cdots - \theta_q \omega^q$$

$$\varphi(\omega) = 1 - \varphi_1 \omega - \varphi_2 \omega^2 - \cdots - \varphi_p \omega^p$$

$$\gamma_k = \sigma_a^2 \int_{-\frac{1}{2}}^{\frac{1}{2}} \left| \frac{\theta(e^{-i2\pi\lambda})}{\varphi(e^{-i2\pi\lambda})} \right|^2 \cdot e^{i2\pi k\lambda} d\lambda \quad k=0, 1, 2, 3, \dots$$

以上分别从系统、时域和频域三个角度分析了平稳过程的动态特性。格林函数与自相关函数和谱密度之间的关系, 揭示了系统分析、时域分析和频域分析的一致性。应用中可以根据实际问题的具体特性灵活选择。

思考与练习

3.1 将下列模型用记号 B 写出:

(a) $X_t - 0.5X_{t-1} = a_t$

(b) $X_t = a_t - 1.3a_{t-1} + 0.4a_{t-2}$

$$(c) X_t - 0.5X_{t-1} = a_t - 1.3a_{t-1} + 0.4a_{t-2}$$

3.2 对习题 3.1 中的各个模型, 求出

- (a) 前 5 个格林函数;
- (b) 前 5 个自相关函数;
- (c) 模型的格林函数形式。

3.3 给出 AR(1)模型的格林函数 G_j 对 j 的散点图。

- (a) $\varphi_1 = 0.5$
- (b) $\varphi_1 = -0.8$
- (c) $\varphi_1 = 1$
- (d) $\varphi_1 = -1$

3.4 设 $X_0 = 20$, 且随机干扰序列如下:

t	-1	0	1	2	3	4	5	6
a_t	0	-0.3	0.6	0.9	0.2	0.1	-0.6	1.7
t	7	8	9	10	11	12		
a_t	-0.9	1.3	-0.6	-0.4	0.9	0.0		

试利用模型的差分方程形式和格林函数形式对 3.1 中模型求出 $X_1, X_2, \dots, X_{12}$ 。

3.5 判定 3.1 中模型及以下模型的稳定性:

- (a) $X_t - 1.3X_{t-1} + 0.4X_{t-2} = a_t - 0.9a_{t-1}$
- (b) $X_t - 0.7X_{t-1} + 0.1X_{t-2} = a_t - 1.7a_{t-1} + 0.6a_{t-2}$
- (c) $X_t - 1.6X_{t-1} + 0.6X_{t-2} = a_t - a_{t-1} + 0.2a_{t-2}$
- (d) $X_t - 1.1X_{t-1} = a_t$
- (e) $(1-B)^2 X_t = a_t$

3.6 (a) 求 3.1 中模型的前 5 个逆函数;

(b) 写出 3.1 中模型的逆转形式。

3.7 判定 3.1 及 3.5 中模型的可逆性。

3.8 某过程的逆函数 $I_1 = 0.5, I_j = 0.3(0.7)^{j-2}, j \geq 2$, 试求相应的 ARMA 模型表达式。

3.9 一个 ARMA 模型的格林函数由下式给出, 试求出相应的 ARMA 模型及参数。

- (a) $G_j = 0.4(0.9)^{j-1}, j \geq 1$
- (b) $G_j = A(0.4)^j \cos(0.6 + 0.8j)$

3.10 试求 ARMA(1,1)模型自协方差函数的表达式。

3.11 设有如下 AR(2)过程: $X_t = X_{t-1} - 0.5X_{t-2} + a_t, a_t \sim NID(0, 0.5)$ 。

- (a) 写出该过程的 Yule-Walker 方程, 并由此解出 ρ_1 和 ρ_2 ;
- (b) 求 X_t 的方差。

3.12 用 ρ_1, ρ_2 的允许范围来规定 AR(2)过程的平稳条件, 并画出以 ρ_1, ρ_2 为坐标的平稳域图。

❖ ❖

在前面的讨论中,为不失一般性,我们假定所讨论的平稳过程 $\{X_t\}$ 是零均值的(即 $\mu=0$)。而对实际的序列,我们所有的只是一段样本数据,序列的均值是未知的,对此我们可以有两种处理方法,一种方法是用样本的均值 $\bar{X}$ 作为序列均值 μ 的估计,建模前先用样本数据减去其均值,然后对所得到的零均值序列建模。另一种较为恰当的方法是把序列均值 μ 当作另外一个未知参数进行估计,模型可写为

所要估计的有 $n+m+1$ 个参数。一般来说,后一种方法拟合的效果较好。

对一个观察序列,从各种模型族中选择一个与其实过程相吻合的模型

结构,就是模型的识别问题。关于模型识别的方法很多,这里我们只介绍 Box—Jenkins 的模型识别方法即根据样本自相关、偏自相关函数的截尾、拖尾性初步判断序列 X_t 所适合的模型类型。这种方法可以对 $AR(n)$ 和 $MA(m)$ 以及低阶 $ARMA$ 模型进行初步识别。该方法简单易懂,但精度不够,尤其是当样本序列未达到足够长度时,其精度更不理想。

初步识别需要计算样本均值及其标准差、自相关和偏自相关函数,从而确定模型的初步类型。如果序列均值显著非零,则要么用样本均值作为其估计对序列进行零均值化,要么将其作为一个参数进行估计。为检查 $\mu = E[X_t] = 0$ 是否成立,可以将样本均值 $\bar{X}$ 和均值的标准差 $S.E. [\bar{X}]$ 比较,而

$$\begin{aligned}\text{Var}[\bar{X}] &= E[\bar{X} - \mu]^2 = E\left[\frac{1}{N} \sum_{t=1}^N X_t - \mu\right]^2 \\ &= \frac{1}{N^2} \sum_{s=1}^N \sum_{t=1}^N E[(X_t - \mu)(X_s - \mu)] \\ &= \frac{1}{N^2} \sum_{s=1}^N \sum_{t=1}^N \gamma_{t-s}\end{aligned}$$

令 $k = t - s$, 则有

$$\begin{aligned}\text{Var}[\bar{X}] &= \frac{1}{N^2} \sum_{k=-(N-1)}^{N-1} (N - |k|) \gamma_k \\ &= \frac{1}{N} \sum_{k=-(N-1)}^{N-1} \left(1 - \frac{|k|}{N}\right) \gamma_k\end{aligned}\quad (4.1.1)$$

当 N 很大时,有

$$\text{Var}[\bar{X}] \approx \frac{1}{N} \sum_{k=-\infty}^{\infty} \gamma_k \quad (4.1.2)$$

因而

$$S.E. [\bar{X}] = \sqrt{\text{Var}[\bar{X}]} \approx \left[\frac{1}{N} \sum_{k=-(N-1)}^{N-1} \hat{\gamma}_k \right]^{\frac{1}{2}} \quad (4.1.3)$$

如果样本均值在 $0 \pm 2S.E. [\bar{X}]$ 范围内可以认为是零均值过程。具体对时间序列作零均值检验时,可结合初步判断的模型和该模型自相关函数的理论特性来计算 $\text{Var}[\bar{X}]$ 。例如,我们初步判断某时间序列适合 $AR(1)$ 模型,由上章理论可知 $AR(1)$ 模型的理论自相关函数满足

$$\rho_k = \varphi_1^{k-1} \rho_1$$

依(4.1.2)式可得

$$\text{Var}[\bar{X}] \approx \frac{\gamma_0}{N} \left[1 + 2 \sum_{k=1}^{\infty} \rho_k \right]$$

$$\begin{aligned}
&= \frac{\gamma_0}{N} \left[1 + 2 \sum_{k=1}^{\infty} \varphi_1^{k-1} \rho_1 \right] \\
&= \frac{\gamma_0}{N} \left[1 + \frac{2\rho_1}{1-\rho_1} \right] \\
&= \frac{\gamma_0}{N} \left[\frac{1+\rho_1}{1-\rho_1} \right]
\end{aligned}$$

在上式中用由该序列所得的估计值 $\hat{\gamma}_0, \hat{\rho}_1$ 代替 γ_0, ρ_1 , 即可得到 $\text{Var}[\bar{X}]$ 。下面我们给出其它几种常用的低阶模型的 $\text{Var}[\bar{X}]$ 的计算公式, 供实际中选用。其推导留给读者。

$$\text{AR}(2) \text{ 模型, } \text{Var}[\bar{X}] \approx \frac{\gamma_0(1+\rho_1)(1-2\rho_1^2+\rho_2)}{N(1-\rho_1)(1-\rho_2)}$$

$$\text{MA}(1) \text{ 模型, } \text{Var}[\bar{X}] \approx \frac{\gamma_0}{N}(1+2\rho_1)$$

$$\text{MA}(2) \text{ 模型, } \text{Var}[\bar{X}] \approx \frac{\gamma_0}{N}(1+2\rho_1+2\rho_2)$$

$$\text{ARMA}(1,1) \text{ 模型, } \text{Var}[\bar{X}] \approx \frac{\gamma_0(\rho_1-\rho_2+2\rho_1^2)}{N(\rho_1-\rho_2)}$$

在第三章我们已经讨论了平稳序列的自相关和偏自相关函数的形式及其统计特性。这里不再重述, 为了便于运用, 现将零均值平稳序列的自相关函数和偏自相关函数的统计特性归纳如下:

模 型	AR(n)	MA(m)	ARMA(n, m)
自相关函数	拖尾	截尾	拖尾
偏自相关函数	截尾	拖尾	拖尾

掌握 ARMA 序列的自相关和偏自相关函数的统计特性, 我们就可依据这些性质来初步确定模型的类型。

1. 若 ρ_k 序列在 q 步截尾(即 $k < q$ 时, ρ_k 不显著地接近于零, 而当 $k > q$ 时, ρ_k 显著地等于零)并且 φ_{kk} 序列被负指数函数控制收敛到零, 则可判断 X_t 为 MA(q) 序列, 具体作法是: 若 $k > q$, 应有 $\rho_k = 0$, 此时 $\hat{\rho}_k$ 渐近于正态分布:

$$\hat{\rho}_k \sim N\left[0, \frac{1}{N} \left(1 + 2 \sum_{i=1}^q \rho_i^2\right)\right] \quad (4.1.4)$$

由此来检验 $\hat{\rho}_k$ 是否显著地等于零。由 (4.1.4) 式可知

$$P[|\hat{\rho}_k| \leq \frac{1}{\sqrt{N}} (1 + 2 \sum_{i=1}^q \hat{\rho}_i^2)^{\frac{1}{2}}] = 68.3\%$$

$$P[|\hat{\rho}_k| \leq \frac{2}{\sqrt{N}} (1 + 2 \sum_{i=1}^q \hat{\rho}_i^2)^{\frac{1}{2}}] = 95.5\%$$

对于每个 $k > 0$, 分别检验 $\hat{\rho}_{k+1}, \hat{\rho}_{k+2}, \dots, \hat{\rho}_{k+M}$ (通常取 $M = [\sqrt{N}]$, 或 $M = [N/10]$) 中满足

$$|\hat{\rho}_{k+i}| \leq \frac{1}{\sqrt{N}} (1 + 2 \sum_{l=1}^q \hat{\rho}_l^2)^{\frac{1}{2}}, \quad i=1, 2, \dots, M$$

的比例是否达到 68.3%, 若 $k=1, \dots, q-1$ 都未达到, 而 $k=q$ 达到了, 我们就说 ρ_k 在 q 步截尾。

2. 若 φ_{kk} 序列在 p 步截尾, 并且 ρ_k 序列被负指数函数控制收敛到零, 则可判断 X_t 为 $AR(p)$ 序列。具体作法是:

若 $k > p$, 应有 $\varphi_{kk} = 0$ 。此时, $\hat{\varphi}_{kk}$ 的分布渐近于 $N(0, 1/N)$, N 为样本序列长度, 于是有

$$P(|\hat{\varphi}_{kk}| > \frac{1}{\sqrt{N}}) = 31.7\%, \quad P(|\hat{\varphi}_{kk}| > \frac{2}{\sqrt{N}}) = 4.5\%$$

对于每一个 $k > 0$, 检验 $\hat{\varphi}_{k+1, k+1}, \dots, \hat{\varphi}_{k+M, k+M}$ 中满足 $|\hat{\varphi}_{kk}| > \frac{1}{\sqrt{N}}$ 的个数所占的百分比是否超过 31.7%, 若 $k=1, \dots, p-1$ 时都超过了, 而 $k=p$ 时没有超过, 则可以认为 $\hat{\varphi}_{kk}$ 在 p 步截尾。

3. 若 ρ_k 序列与 φ_{kk} 序列皆不截尾, 但都被负指数函数控制收敛到零, 则 X_t 很有可能是 ARMA 序列。




图 4.1 磨轮剖面资料

若 ρ_k, φ_{kk} 序列无以上特征,而是出现了缓慢衰减或周期性衰减等情况,则说明序列不是平稳的,可以采用第六、七章介绍的方法分析。

例 4.1 图 4.1 是一磨轮剖面资料的数据图,共 250 个,具体数据见附录 II。




图 4.2 磨轮剖面资料的相关函数

从数据图可初步断定该序列是平稳的,且样本均值显著非零。用 Y_t 表示原序列, $\bar{Y}$ 表示样本均值, $\bar{Y}=9.42$ 。以下考虑序列 $X_t=Y_t-\bar{Y}$ 。用 Micro TSP (6.5)软件包计算 X_t 的自相关函数(ACF)和偏相关函数(PACF)如图 4.2。

我们发现 $\hat{\varphi}_{kk}$ 在 $k=2$ 以后波动于零值附近,且满足 $|\hat{\varphi}_{kk}|>\frac{2}{\sqrt{250}}$ 的值未出现,可以认为 $\hat{\varphi}_{kk}$ 于 $k=2$ 后截尾。又注意到 $\hat{\rho}_k$ 序列有收敛到零的趋势,可以认为是拖尾的,故可初步断定序列适合 AR 模型。

第二节 模型定阶

在确定了模型类型之后,为了建立具体模型,还需知道模型的阶数,下面介绍一些模型定阶的方法。

一、残差方差图定阶法

在 AR 模型的情况下,很自然地会想到按照统计学中多元回归分析的方法,通过假设检验来确定阶数。也就是以 $AR(n)$ 模型作为零假设,而以 $AR(n+1)$ 模型作为对立假设,然后增大 n 值,直到检验结果不显著为止。

假定模型是有限阶的自回归模型,如果选择的 n 小于真正的阶数,则是一种不足拟合,因而剩余平方和 Q 必然偏大, $\hat{\sigma}_a^2$ 将比真正模型的残差方差 σ_a^2 大。这是因为我们把模型中本来应有的一些高阶项略去了,而这些项对于减小残差方差是有明显贡献的。另一方面,如果 n 已经达到真值,那么再进一步增加阶数,就是过度拟合,这并不会使 $\hat{\sigma}_a^2$ 有显著减小,甚至还略有增加。

这样用一系列阶数逐渐递增的模型进行拟合,每次都求出 $\hat{\sigma}_a^2$,然后画出 n 和 $\hat{\sigma}_a^2$ 的图形——称为残差方差图。开始时 $\hat{\sigma}_a^2$ 会下降,当达到 n 的真值后渐趋平缓。Jenkins 和 Watts 曾使用这种方法,并且也用来确定 MA 及 ARMA 模型的阶数,残差方差的估计式为

$$\hat{\sigma}_a^2 = \frac{\text{模型的剩余平方和}}{\text{实际观察值个数} - \text{模型的参数个数}}$$

式中的“实际观察值个数”是指拟合模型时实际使用的观察值项数。例如,对于一个具有 N 个观察值的序列,若拟合 $AR(n)$ 模型,则实际使用的观察值最多为 $N-n$ 项。

式中的“参数个数”是指所建立的模型中实际包含的参数个数,若模型中

不含有均值项(μ),则模型的参数个数就等于模型的阶数;若模型中含有均值项,则模型的参数个数为模型阶数加1,具体说来,对于 N 个观察值的序列,相应于 AR、MA 和 ARMA 三种模型的残差方差的估计式分别为:

$$\text{AR 模型: } \hat{\sigma}_a^2(n) = \frac{Q(\hat{\mu}, \hat{\varphi}_1, \dots, \hat{\varphi}_n)}{(N-n) - (n+1)}$$

$$\text{MA 模型: } \hat{\sigma}_a^2(m) = \frac{1}{N - (m+1)} Q(\hat{\mu}, \hat{\theta}_1, \dots, \hat{\theta}_m)$$

ARMA 模型:

$$\hat{\sigma}_a^2(n, m) = \frac{1}{(N-n) - (n+m+1)} Q(\hat{\mu}, \hat{\varphi}_1, \dots, \hat{\varphi}_n, \hat{\theta}_1, \dots, \hat{\theta}_m)$$

上边各式中的参数估计及剩余平方和的计算将在下节给出。这种方法的最大不足,就是没有一个定量的准则,判定的阶数具有主观性。

图 4.3 是对例 4.1 中数据拟合 AR(n)模型所得的残差方差图。由此可以看出,模型阶数 n 从 1 升至 2,残差方差大幅度减小; n 继续升至 5,残差方差非但不再减少,反而略有增加;继续升高模型阶数,在 $n=6$ 时,残差方差略有回落后继续增加。虽然在 $n=6$ 时残差方差也较小,但从建模的“约简”性原则出发我们初步判断合适的模型为 AR(2)。




图 4.3 残差方差图

二、自相关函数(ACF)和偏自相关函数(PACF)定阶法

既然平稳序列的自相关及偏自相关函数具有较为规范的统计特性,因而我们就可以由实际序列的样本自相关及偏自相关函数来推断模型的信息。对于单纯的 AR 或 MA 模型,如上节所述,在判定模型形式的同时也就初步断定了模型的阶数。对于混合的 ARMA 模型来说,用 ACF 和 PACF 判定其阶次有一定的困难,需要用其它的方法来判定。需要强调的一点是,即使对 AR 或 MA 模型,用该法判定的阶数也只能是作为初步的参考值,还需结合其它方法确定出精确的阶数。对于例 4.1,用该法初步判定 AR 模型的阶次为 2。

三、F 检验定阶法

在统计检验中经常用到如下两种分布:

1. χ^2 分布——如果随机变量 $X_1, \dots, X_v$ 相互独立且服从标准正态分布,即 $X_t \sim N(0, 1), t=1, 2, \dots, v$, 则平方和

$$X = \sum_{t=1}^v X_t^2 \quad (4.2.1)$$

遵从自由度为 v 的 χ^2 分布,记作

$$X \sim \chi^2(v)$$

2. F 分布——如果 $X \sim \chi^2(v_1), Y \sim \chi^2(v_2)$, X 与 Y 独立,则统计量

$$F = \frac{X/v_1}{Y/v_2} \quad (4.2.2)$$

的分布称为自由度为 (v_1, v_2) 的 F 分布,记作 F_{v_1, v_2} 或 $F(v_1, v_2)$ 。

利用 F 分布进行假设检验是实践中经常使用的统计检验方法。在作回归分析中,往往用 F 检验来考察两个回归模型是否有显著差异,因此常被用来判定 ARMA 模型的阶数。

假定我们有 N 个独立的随机观察值

$$Y = (y_1, y_2, \dots, y_N)^T$$

另外有 γ 个回归因子

$$X_i = (X_{i1}, X_{i2}, \dots, X_{iN})^T \quad i=1, 2, \dots, \gamma$$

我们建立回归模型

$$y = \alpha_1 X_1 + \alpha_2 X_2 + \dots + \alpha_\gamma X_\gamma + \varepsilon \quad (4.2.3)$$

其中 $\varepsilon = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_N)^T$ 是模型残差,设 $\hat{\alpha}$ 是模型(4.2.3)参数 $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_N)^T$ 的最小二乘估计,那么,回归残差平方和为

$$Q_0 = \sum_{i=1}^N (y_i - \hat{a}_1 X_{1i} - \hat{a}_2 X_{2i} - \cdots - \hat{a}_\gamma X_{\gamma i})^2$$

假若我们舍弃后面 S 个因子,另建立一个回归模型,回归方程是

$$y = a'_1 X_1 + a'_2 X_2 + \cdots + a'_{\gamma-s} X_{\gamma-s} + \epsilon' \quad (4.2.4)$$

类似地,模型(4.2.4)参数 a' 的最小二乘估计为 $\hat{a}'$,相应的残差平方和是

$$Q_1 = \sum_{i=1}^N (y_i - \hat{a}'_1 X_{1i} - \hat{a}'_2 X_{2i} - \cdots - \hat{a}'_{\gamma-s} X_{\gamma-s i})^2$$

我们要检验回归因子

$$X_{\gamma-s+1}, X_{\gamma-s+2}, \cdots, X_\gamma$$

对 Y 的影响是否显著,即等价于检验原假设

$$H_0: a_{\gamma-s+1} = a_{\gamma-s+2} = \cdots = a_\gamma = 0$$

是否成立,借助于 F 检验我们就可以判断应该拒绝或接受原假设 H_0 。

关于回归分析中残差平方和的分布及假设检验有下面的定理:

1) $Q_0 \sim \sigma^2 \chi^2(N-\gamma)$ (σ^2 为残差方差)

2) Q_0 和 $Q_1 - Q_0$ 相互独立,且若原假设 H_0 为真,则 $Q_1 - Q_0 \sim \sigma^2 \chi^2(s)$,从

而

$$\frac{Q_1 - Q_0}{S} / \frac{Q_0}{N - \gamma} \sim F(S, N - \gamma)$$

有了这些结论我们可以着手检验回归因子对 Y 的影响是否显著,对于预先给定的显著性水平 α (一般 α 为 0.05 或 0.01),由 F 分布表查出相应的 F_α 值,应有下面关系式:

$$P(F \geq F_\alpha) = \alpha$$

计算统计量

$$F = \frac{Q_1 - Q_0}{S} / \frac{Q_0}{N - \gamma}$$

若算得的值 F 大于 F_α ,那就意味着统计量 F 不是 $F(S, N - \gamma)$ 分布(否则就意味着发生了以 α 为概率的小概率事件,而小概率事件在一次取样中一般被认为是不会发生的),由前述定理知原假设 H_0 为谬误,应予以拒绝,也就是说后 S 个回归因子 $X_{\gamma-s+1}, X_{\gamma-s+2}, \cdots, X_\gamma$,对于随机变量 Y 的影响是显著的;反之,则认为不能拒绝原假设,也就是说这些因素是可以忽略的。

我们把 F 检验用于 ARMA 模型定阶,现在以 ARMA(n, m) 模型为例加以说明,我们采用过拟合的办法,先对观察数据用 ARMA(n, m) 模型进行拟合,再假定 φ_n, θ_m 高阶系数中某些取值为零,用 F -检验准则来判定阶数降低

之后的模型与 $\text{ARMA}(n, m)$ 模型之间是否存在显著性差异。如果差异显著, 则说明模型的阶数仍存在升高的可能性; 若差异不显著, 则模型阶数可以降低, 低阶模型与高阶模型之间的差异用残差平方和来衡量。

例如, 假定原假设为

$$H_0: \varphi_n = 0, \quad \theta_m = 0$$

记 Q_0 为 $\text{ARMA}(n, m)$ 模型的残差平方和, Q_1 为 $\text{ARMA}(n-1, m-1)$ 模型的残差平方和, 则

$$F = \frac{Q_1 - Q_0}{2} / \frac{Q_0}{N - m - n} \sim F(2, N - m - n)$$

其中 N 为样本长度, $\gamma = m + n$ 是模型参数总个数, $S = 2$ 是被检验的参数个数。如果 $F > F_\alpha$, 则 H_0 不成立, 模型阶数仍有上升的可能, 否则 H_0 成立, 即 $\text{ARMA}(n-1, m-1)$ 是适合的模型, 严格地说, 只有当两个模型中有一个是适应模型时, 用这种方法来定阶才是可行的。

下面用 F 检验来考虑例 4.1 模型的定阶问题。首先对 X_t 分别拟合 $\text{AR}(1)$ 和 $\text{AR}(2)$ 模型, 残差平方和 Q_1 和 Q_0 分别为 1619.236 和 1474.032, 则

$$F = \frac{1619.236 - 1474.032}{1} / \frac{1474.032}{250 - 4} \\ = 24.23$$

给定显著性水平 $\alpha = 0.05$, 查 F 分布表可得 $F_\alpha(1, \infty) = 3.84$, 而 $F \gg F_\alpha$, 说明 $\text{AR}(1)$ 和 $\text{AR}(2)$ 之间存在显著的差异, 模型阶数还有上升的可能。再拟合 $\text{AR}(3)$ 模型, 残差平方和为 1473.748。与 $\text{AR}(2)$ 比较, 则有

$$F = \frac{1474.032 - 1473.748}{1} / \frac{1473.748}{250 - 6} \\ = 0.05$$

同理, 查表可得 $F_\alpha(1, \infty) = 3.84$, 而 $F \ll F_\alpha$, 故 $\text{AR}(3)$ 与 $\text{AR}(2)$ 无显著差异。实际上, 模型 $\text{AR}(3)$ 中的系数 $\varphi_3 = -0.012 \pm 0.064$, 系数非常小且置信区间包括零。

四、最佳准则函数定阶法

最佳准则函数法, 即确定出一个准则函数, 该函数既要考虑用某一模型拟合时对原始数据的接近程度, 同时又要考虑模型中所含待定参数的个数。建模时按照准则函数的取值确定模型的优劣, 以决定取舍, 使准则函数达到极小的是最佳模型。

准则函数方法首先由日本学者赤池 (Akaike) 提出的。1971 年他提出了一

种识别 AR 模型阶数的准则,称为最小最终预报误差准则,简称为最小 FPE (Final Prediction Error) 准则。1973 年赤池又将此方法推广到辨识 ARMA 模型阶数,称为最小信息准则或 AIC (A-Information Criterion) 准则。近年来 AIC 准则得到广泛应用,进而又推广为 BIC 准则等等。

1. FPE 准则。FPE 准则是由模型的预报误差来判明自回归模型的阶数是否恰当。其判据就是最终预报误差最小。这个准则的合理性是不难理解的。我们用一个自回归模型去拟合某组观察数据,主要目的往往是希望借助于模型,根据所掌握的信息,对系统的未来行为作出预测,因此,预报效果的好坏,就是模型拟合优劣的检验准则。

若数据所符合的真实模型应是 $AR(n)$, 而我们用模型 $AR(p)$ ($p < n$ 或 $p > n$) 去进行拟合。事实上,不论是缺参数拟合 ($p < n$) 或是超参数拟合 ($p > n$) 都会使预报误差的方差增大,为使问题简化,我们考虑一步预报误差方差,要找出合理的 AR 模型阶数,就是寻求使一步预报误差方差达到极小的最佳 AR 模型阶数。

设 $\{X_t; 1 \leq t \leq N\}$ 所适合的真实模型为 $AR(n)$

$$X_t = \varphi_1 X_{t-1} + \varphi_2 X_{t-2} + \cdots + \varphi_n X_{t-n} + a_t \quad (4.2.5)$$

其中 $Ea_t = 0, Ea_t^2 = \sigma_a^2$, 设 φ_i 的估计值为 $\hat{\varphi}_i$ ($1 \leq i \leq n$), 用 $X_{t-1}(1)$ 表示 $t-1$ 时对 X_t 的一步预报值(即对 t 时刻的预报值), 应有

$$\hat{X}_{t-1}(1) = \hat{\varphi}_1 X_{t-1} + \cdots + \hat{\varphi}_n X_{t-n} \quad (4.2.6)$$

可以证明,一步预报误差方差为

$$E[X_t - \hat{X}_{t-1}(1)]^2 \approx (1 + n/N) \sigma_a^2 \quad (4.2.7)$$

用 $\hat{\sigma}_a^2$ 表示以 $\hat{\varphi}_i$ ($1 \leq i \leq n$) 为参数的拟合模型残差方差,可证明当 N 充分大时有

$$E(\hat{\sigma}_a^2) \approx (1 - n/N) \sigma_a^2 \quad (4.2.8)$$

换句话说,当 N 充分大时, $\hat{\sigma}_a^2 / (1 - n/N)$ 是 σ_a^2 的近似无偏估计,在式(4.2.7)中,用无偏估计代替 σ_a^2 ,便得到:

$$\begin{aligned} E[X_t - \hat{X}_{t-1}(1)]^2 &\approx (1 + n/N)(1 - n/N)^{-1} \hat{\sigma}_a^2 \\ &= \frac{N+n}{N-n} \hat{\sigma}_a^2 \end{aligned} \quad (4.2.9)$$

式中第一个因式 $\frac{N+n}{N-n}$, 随着阶数增加而增大; 第二个因式 $\hat{\sigma}_a^2$, 一般说来随着阶数增加而减少, 反映了模型的拟合程度。

对于以 $\hat{\varphi}_i$ ($1 \leq i \leq n$) 为参数的 $AR(n)$ 模型应有

$$\hat{\sigma}_a^2 = \gamma(0) - \sum_{i=1}^n \hat{\varphi}_i \gamma_i$$

其中 $\gamma_0, \gamma_1, \dots, \gamma_n$ 是数据序列的样本协方差函数在不同滞后时的值。

由上述可知,以 $\hat{\varphi}_1, \dots, \hat{\varphi}_n$ 为参数的 $AR(n)$ 模型,其最终预报误差定义为

$$FPE(n) = (1 + \frac{n}{N})(1 - \frac{n}{N})^{-1}(\gamma_0 - \sum_{i=1}^n \hat{\varphi}_i \gamma_i) \quad (4.2.10)$$

在具体应用时,通常是对观察数据从低阶到高阶建立 AR 模型,并计算出相应的 FPE 值,由此确定出使最终预报误差达到极小的 AR 模型。

拟合的最高阶数 $M(N)$ 通常取为 $[\frac{1}{3}N] \sim [\frac{2}{3}N]$ 之间的某个整数,对 $n = 1, 2, \dots, M(N)$ 逐个建立 $AR(n)$ 模型并求出 $FPE(n)$, 若

$$FPE(n_0) = \min_{1 \leq n \leq M(N)} FPE(n) \quad (4.2.11)$$

则满足(4.2.11)的 $AR(n_0)$ 模型是在 FPE 准则之下的最佳模型。

2. AIC 准则

AIC 定阶准则是赤池首先提出并成功地应用于 AR 模型的分析定阶中,该方法也可用来辨识 $ARMA$ 模型的阶数。

设 $\{X_t, 1 \leq t \leq N\}$ 为一随机序列,我们用 $AR(n)$ 模型来描述它, $\hat{\sigma}_a^2$ 是拟合残差方差,我们认为它是模型阶数 n 的函数,定义 AIC 准则函数如下:

$$AIC(n) = \ln \hat{\sigma}_a^2(n) + 2n/N \quad (4.2.12)$$

当阶数 n 增高时,(4.2.12)式中的第一项拟合残差方差 $\hat{\sigma}_a^2(n)$ 是下降的。式中 $\ln$ 表示取自然对数,它是单调函数,因此整个第一项是单调下降的;对给定的观察数据个数 N , (4.2.12)式中的第二项随 n 而增长。可以想象,从 $n=1$ 开始,逐次增加模型阶数对数据进行自回归模型拟合时, $AIC(n)$ 的值是有下降趋势的,因为这时起决定性作用的是模型残差方差。当达到某一阶数 n_0 时, $AIC(n_0)$ 值达到极小。随后,随着模型阶数继续增高,残差方差改进甚微,于是模型阶数起关键性作用, $AIC(n)$ 的值随 n 而增长,对事先给定的最高阶数 $M(N)$, 若

$$AIC(n_0) = \min_{1 \leq n \leq M(N)} AIC(n)$$

我们便取 n_0 为最佳自回归模型阶数。

将 AIC 准则函数用于 $ARMA$ 模型定阶,方法与前述完全类似,假定我们用 $ARMA(n, m)$ 模型对随机序列 $\{X_t, 1 \leq t \leq N\}$ 进行拟合, $\hat{\sigma}_a^2(n, m, \mu)$ 是残差方差,如果序列均值 μ 也是待估参数,那么参数个数为 $n+m+1$, 定义 AIC 函数为

$$AIC(n, m, \mu) = \ln \hat{\sigma}_a^2(n, m, \mu) + 2(n+m+1)/N \quad (4.2.13)$$

我们选取不同的 n, m 及模型参数,对 $\{X_t\}$ 进行拟合,并用(4.2.13)计算

该模型相应的 AIC 值。然后改变模型的阶数及参数, (4.2.13) 达到极小的模型, 认为是最佳模型。

3. BIC 准则及其它准则

在对数据序列进行模型拟合及定阶时, 还可以定义与 AIC 函数类似的其它准则函数, BIC 准则函数定义如下:

$$\text{BIC}(n) = \ln \hat{\sigma}_a^2(n) + \frac{n}{N} \ln N \quad (4.2.14)$$

若某一阶数 n'_0 满足 $\text{BIC}(n'_0) = \min_{1 \leq n \leq M(N)} \text{BIC}(n)$

其中 $M(N)$ 含义同前, 则取 n'_0 为最佳阶数。

与 (4.2.12) 定义的 AIC 准则函数相比, 式 (4.2.14) 右边第一项用 $\ln N$ 代替了系数 2, 一般说来, $\ln N > 2$, 因此 AIC 达到极小时所对应的阶数往往比 BIC 准则相应定出的阶数高, 即是说一般将会

$$n'_0 \leq n_0$$

这说明对同一数据序列进行拟合, 用 AIC 准则往往比用 BIC 准则确定的阶数高。

我们还可以定义其它类型的准则函数, 如

$$\text{BIC}_1(n) = \ln \hat{\sigma}_a^2(n) + C \frac{n}{N} \ln(\ln N) \quad (4.2.15)$$

其中 C 是给定常数。定义不同的准则函数, 其目的是为了对拟合残差与参数个数之间进行不同的权衡, 以体现使用者对残差与阶数二者重要性的不同侧重。当然, 用不同准则挑选出的最优模型, 其渐近性质是不同的。例如当样本个数 N 趋于无穷时, 用 AIC 准则挑选的最佳模型的阶数往往比真实模型阶数高; 而用 BIC 准则确定的最佳模型阶数往往与真实模型的阶数相一致。

对例 4.1 逐个拟合 $\text{AR}(n)$ 模型, 并求出相应的 $\text{FPE}(n)$, $\text{AIC}(n)$, $\text{BIC}(n)$, 结果如图 4.4 所示, 最佳模型为 $\text{AR}(2)$ 。

前面介绍的几种定阶方法用于判断单纯的 AR 或 MA 模型的阶次还是比较有效的, 但是要判断混合的 ARMA 模型的阶次却是不大方便的。1984 年 Tiao and Tsay 提出了一种可同时鉴定平稳的 ARMA 模型和非平稳的 ARIMA 模型阶数的方法, 详见附录 I。




图 4.4(a)




图 4.4(b) 最佳准则函数定阶图

第三节 模型参数估计

根据已掌握的一组样本数据序列 $X_1, X_2, \dots, X_N$ 建立 ARMA 模型, 其含义就是对模型的阶数 (n, m) 和参数作出判断和估计。

一、模型参数的相关矩估计

1. AR 模型参数的矩估计

将 Yule-Wolker 方程 (3.3.17) 变形为:

$$\begin{bmatrix} \rho_0 & \rho_1 & \cdots & \rho_{k-1} \\ \rho_1 & \rho_0 & \cdots & \rho_{k-2} \\ \cdots & \cdots & \cdots & \cdots \\ \rho_{k-1} & \cdots & \cdots & \rho_0 \end{bmatrix} \cdot \begin{bmatrix} \varphi_{k1} \\ \varphi_{k2} \\ \vdots \\ \varphi_{kk} \end{bmatrix} = \begin{bmatrix} \rho_1 \\ \rho_2 \\ \vdots \\ \rho_k \end{bmatrix}$$

则

$$\begin{bmatrix} \varphi_{k1} \\ \varphi_{k2} \\ \vdots \\ \varphi_{kk} \end{bmatrix} = \begin{bmatrix} \rho_0 & \rho_1 & \cdots & \rho_{k-1} \\ \rho_1 & \rho_0 & \cdots & \rho_{k-2} \\ \cdots & \cdots & \cdots & \cdots \\ \rho_{k-1} & \cdots & \cdots & \rho_0 \end{bmatrix}^{-1} \cdot \begin{bmatrix} \rho_1 \\ \rho_2 \\ \vdots \\ \rho_k \end{bmatrix} \quad (4.3.1)$$

根据自协方差函数

$$\gamma_k = E(X_t X_{t-k}) = E[X_{t-k}(\varphi_1 X_{t-1} + \varphi_2 X_{t-2} + \cdots + \varphi_n X_{t-n} + a_t)]$$

当 $k=0$ 时,

$$\gamma_0 = \varphi_1 \gamma_1 + \varphi_2 \gamma_2 + \cdots + \varphi_n \gamma_n + \sigma_a^2 \quad (4.3.2)$$

即

$$\sigma_a^2 = \gamma_0 - \varphi_1 \gamma_1 - \varphi_2 \gamma_2 - \cdots - \varphi_n \gamma_n \quad (4.3.3)$$

将 $\hat{\varphi}_1, \dots, \hat{\varphi}_n$ 代替 $\varphi_1, \dots, \varphi_n, \hat{\gamma}_0, \dots, \hat{\gamma}_n$ 代替 $\gamma_0, \dots, \gamma_n$ 代入 (4.3.3) 式得

$$\sigma_a^2 = \hat{\gamma}_0 - \sum_{i=1}^n \hat{\varphi}_i \hat{\gamma}_i = \hat{\gamma}_0 (1 - \sum_{i=1}^n \hat{\varphi}_i \hat{\rho}_i) \quad (4.3.4)$$

例如, AR(1) 模型参数的矩估计为, $n=1$, Yule-Wolker 方程:

$$\gamma_1 - \varphi_1 \gamma_0 = 0$$

则

$$\varphi_1 = \frac{\gamma_1}{\gamma_0} = \rho_1$$

根据(4.3.4)式有 $\hat{\sigma}_a^2 = \gamma_0(1 - \rho_1^2)$

2. MA 模型参数的矩估计

根据(3.3.14)和(3.3.15)式,有

$$\left. \begin{aligned} \gamma_0 &= (1 + \theta_1^2 + \theta_2^2 + \cdots + \theta_m^2) \sigma_a^2 \\ \gamma_k &= (-\theta_k + \theta_{k+1}\theta_1 + \theta_{k+2}\theta_2 + \cdots + \theta_m\theta_{m-k}) \sigma_a^2 \end{aligned} \right\} \quad k=1, 2, \cdots, m \quad (4.3.5)$$

可见(4.3.5)式是 $m+1$ 个方程,对于其参数而言,这 $m+1$ 个方程是非线性的。求解 $\theta_1, \cdots, \theta_m$ 和 σ_a^2 的方法有以下三种:

(1) 直接解法,当 $m=1$ 时,有

$$\gamma_0 = (1 + \theta_1^2) \sigma_a^2 \quad (1)$$

$$\gamma_1 = -\theta_1 \sigma_a^2 \quad (2)$$

由②式,得

$$\theta_1 = -\gamma_1 / \sigma_a^2$$

将上式代入①式,有

$$\gamma_0 = (1 + \frac{\gamma_1^2}{\sigma_a^4}) \sigma_a^2$$

即

$$\sigma_a^4 - \gamma_0 \sigma_a^2 + \gamma_1^2 = 0$$

因此,

$$\begin{aligned} \sigma_a^2 &= \frac{\gamma_0 \pm \sqrt{\gamma_0^2 - 4\gamma_1^2}}{2} \\ &= \frac{1}{2} \gamma_0 (1 \pm \sqrt{1 - 4\rho_1^2}) \\ \theta_1 &= (-2\rho_1) / (1 \pm \sqrt{1 - 4\rho_1^2}) \end{aligned}$$

这样求得的模型参数是多值的,但是根据可逆性条件($|\theta_1| < 1$)可以排除 θ 的多值性。求得

$$\begin{aligned} \theta_1 &= -\frac{2\rho_1}{1 + \sqrt{1 - 4\rho_1^2}} \\ \sigma_a^2 &= \frac{1}{2} \gamma_0 (1 + \sqrt{1 - 4\rho_1^2}) \end{aligned}$$

当 $m=2$ 时,有

$$\begin{aligned} \gamma_0 &= (1 + \theta_1^2 + \theta_2^2) \sigma_a^2 \\ \gamma_1 &= (-\theta_1 + \theta_2\theta_1) \sigma_a^2 \end{aligned}$$

$$\gamma_2 = -\theta_2 \sigma_a^2$$

显然有:

$$\theta_2 = -\gamma_2 / \sigma_a^2$$

$$\theta_1 = -\frac{\gamma_1}{\sigma_a^2 + \gamma_2^2}$$

$$\sigma_a^2 \left(1 + \frac{\gamma_1^2}{(\sigma_a^2 + \gamma_2^2)^2} + \frac{\gamma_2^2}{\sigma_a^4} \right) = \gamma_0$$

可见,这是 σ_a^2 的四次方程,因而有四个根,从而 θ_1, θ_2 有四种可能解。同样可根据可逆性条件求得唯一解。

从上面不难看出,用直接计算,需要解 $2m$ 次方程,在 $m \geq 3$ 时,解高次方程非常困难,一般只能用数值解法。

(2) 线性迭代法,(4.3.5)式可以等价地写成:

$$\sigma_a^2 = \gamma_0 / (1 + \theta_1^2 + \theta_2^2 + \cdots + \theta_m^2) \quad (4.3.6)$$

$$\theta_k = -\frac{\gamma_k}{\sigma_a^2} + \theta_{k+1}\theta_1 + \theta_{k+2}\theta_2 + \cdots + \theta_m\theta_{m-k} \quad (4.3.7)$$

$$k=1, 2, \cdots, m$$

给定 $\theta_1, \theta_2, \cdots, \theta_m$ 和 σ_a^2 的一组初始值(如 $\theta_1 = \theta_2 = \cdots = \theta_m = 0, \sigma_a^2 = \gamma_0$,等),代入(4.3.6)式与(4.3.7)式的右边,左边所得到的值为一步迭代值,记作: $\sigma_a^{(1)}, \theta_1^{(1)}, \cdots, \theta_m^{(1)}$,再将这些值代入上两式的右边,便得到第二步迭代值: $\sigma_a^{(2)}, \theta_1^{(2)}, \cdots, \theta_m^{(2)}$,依此类推,直到相邻两次迭代值结果相差不大时便停止迭代,取最后结果作为上式近似解。

(3) 牛顿-拉普森(Newton-Raphson)算法。将(4.3.5)式改写成

$$\left. \begin{aligned} \gamma_0 &= \sigma_a^2 + (-\theta_1 \sigma_a)^2 + (-\theta_2 \sigma_a)^2 + \cdots + (-\theta_m \sigma_a)^2 \\ \gamma_1 &= \sigma_a(-\theta_1 \sigma_a) + (-\theta_1 \sigma_a)(-\theta_2 \sigma_a) + \cdots \\ &\quad + (-\theta_{m-1} \sigma_a)(-\theta_m \sigma_a) \\ \cdots \quad \cdots \quad \cdots \quad \cdots \quad \cdots \quad \cdots \\ \gamma_m &= \sigma_a(-\theta_m \sigma_a) \end{aligned} \right\} \quad (4.3.8)$$

我们暂令 $\sigma_k = -\sigma_a \theta_k (1 \leq k \leq m)$ 和 $\sigma_0 = \sigma_a$,于是,(4.3.8)式又可写成

$$\left. \begin{aligned} \sigma_0^2 + \sigma_1^2 + \sigma_m^2 - \gamma_0 &= 0 \\ \sigma_0 \sigma_1 + \sigma_1 \sigma_2 + \sigma_{m-1} \sigma_m - \gamma_1 &= 0 \\ \cdots \quad \cdots \quad \cdots \quad \cdots \quad \cdots \quad \cdots \\ \sigma_0 \sigma_m - \gamma_m &= 0 \end{aligned} \right\} \quad (4.3.9)$$

将上述方程组左边各式分别记作 $\hat{f}_k = \hat{f}_k(\sigma_0, \sigma_1, \cdots, \sigma_m) (k=0, 1, \cdots, m)$,并记

$$\sigma = (\sigma_0, \sigma_1, \dots, \sigma_m)^T, \quad \hat{f} = (\hat{f}_0, \hat{f}_1, \dots, \hat{f}_m)^T$$

$$F = \frac{\partial f}{\partial \sigma} = \begin{bmatrix} \frac{\partial \hat{f}_0}{\partial \sigma_0} & \dots & \dots & \frac{\partial \hat{f}_0}{\partial \sigma_m} \\ \dots & \dots & \dots & \dots \\ \frac{\partial \hat{f}_m}{\partial \sigma_0} & \dots & \dots & \frac{\partial \hat{f}_m}{\partial \sigma_m} \end{bmatrix}$$

显然

$$F = \begin{bmatrix} \sigma_0 & \sigma_1 & \dots & \sigma_{m-1} & \sigma_m \\ \sigma_1 & \sigma_2 & \dots & \sigma_m & \\ \dots & \dots & & & \\ \sigma_m & & & & \end{bmatrix} + \begin{bmatrix} \sigma_0 & \sigma_1 & \dots & \sigma_m \\ & \sigma_0 & \dots & \sigma_{m-1} \\ & & \dots & \dots \\ & & & \sigma_0 \end{bmatrix}$$

按照 Newton-Raphson 迭代原则, 如果第 i 步迭代值为 $\sigma(i)$, 那么第 $i+1$ 步的 $\sigma(i+1)$ 必须满足

$$\hat{f}(i) + F(i)[\sigma(i+1) - \sigma(i)] = 0$$

即

$$\sigma(i+1) = \sigma(i) - F^{-1}(i)\hat{f}(i) \quad (4.3.10)$$

只要给出初始值 $\sigma(0)$ 便可根据 (4.3.10) 式进行迭代计算, 直到相邻两次迭代值相差不大时便停止迭代, 并以最后的迭代结果 $\sigma(m)$ 做为 (4.3.9) 式的近似解。于是, (4.3.5) 式的近似解为 $\sigma_a^2 = \sigma_0^2(m)$ 。

$$\theta_k = -\frac{\sigma_k(m)}{\sigma_0(m)} \quad 1 \leq k \leq m$$

3. ARMA 模型参数的矩估计

为了估计 ARMA 模型的参数, 我们分以下三步进行。

第一步: 先给出 AR 部分 $\varphi_1, \varphi_2, \dots, \varphi_n$ 的矩估计。首先我们来研究 ARMA 模型的自相关函数。在 ARMA(n, m) 模型

$$X_t - \varphi_1 X_{t-1} - \varphi_2 X_{t-2} - \dots - \varphi_n X_{t-n} = a_t - \theta_1 a_{t-1} - \dots - \theta_m a_{t-m}$$

两端同乘以 X_{t-k} , 并取期望, 得:

$$\begin{aligned} \gamma_k - \varphi_1 \gamma_{k-1} - \dots - \varphi_n \gamma_{k-n} \\ = E(X_{t-k} a_t) - \theta_1 E(X_{t-k} a_{t-1}) - \dots - \theta_m E(X_{t-k} a_{t-m}) \end{aligned}$$

由于

$$E(X_{t-k} a_t) = E\left(\sum_{j=0}^m G_j a_{(t-k)-j} a_t\right) = \begin{cases} G_{-k} \sigma_a^2, & k \leq 0 \\ 0 & k > 0 \end{cases}$$

于是, 代入上式后, 并同除以 γ_0 即得:

$$k=0, (1 - \varphi_1 \rho_1 - \dots - \varphi_n \rho_n) = (1 - \theta_1 G_1 - \dots - \theta_m G_m) \sigma_a^2$$

$$k=1, (\rho_1 - \varphi_1 \rho_0 - \cdots - \varphi_n \rho_{n-1}) = (-\theta_1 - \theta_2 G_1 - \theta_3 G_2 - \cdots - \theta_m G_{m-1}) \sigma_a^2$$

$$k=2, (\rho_2 - \varphi_1 \rho_1 - \cdots - \varphi_n \rho_{n-2}) = (-\theta_2 - \theta_3 G_1 - \cdots - \theta_m G_{m-2}) \sigma_a^2$$

... ..

$$k=m, (\rho_m - \varphi_1 \rho_{m-1} - \cdots - \varphi_n \rho_{n-m}) = -\theta_m \sigma_a^2$$

$$k>m, (\rho_k - \varphi_1 \rho_{k-1} - \cdots - \varphi_n \rho_{k-n}) = 0$$

显然, 用 $\hat{\rho}_k$ 代替上式中的 ρ_k , k 取 $m+1, m+2, \cdots, m+n$, 便可求得 $\varphi_1, \varphi_2, \cdots, \varphi_n$, 即:

$$\begin{bmatrix} \varphi_1 \\ \varphi_2 \\ \vdots \\ \varphi_n \end{bmatrix} = \begin{bmatrix} \rho_m & \rho_{m-1} & \cdots & \rho_{m-n+1} \\ \rho_{m+1} & \rho_m & \cdots & \rho_{m-n+2} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{m+n-1} & \rho_{m+n-2} & \cdots & \rho_m \end{bmatrix}^{-1} \begin{bmatrix} \rho_{m+1} \\ \rho_{m+2} \\ \vdots \\ \rho_{m+n} \end{bmatrix} \quad (4.3.11)$$

$$\text{第二步: } y_t = X_t - \varphi_1 X_{t-1} - \cdots - \varphi_p X_{t-p} \quad (4.3.12)$$

其协方差函数为

$$\begin{aligned} \gamma_k(y_t) &= E(y_t y_{t+k}) \\ &= E[(X_t - \varphi_1 X_{t-1} - \cdots - \varphi_p X_{t-p})(X_{t+k} - \varphi_1 X_{t+k+1} - \cdots - \varphi_p X_{t+k-p})] \\ &= \sum_{i,j=0}^p \varphi_i \varphi_j \gamma_{k+j-i} \end{aligned}$$

其中有 $\varphi_0 = -1$, 再以 $\hat{\gamma}_k$ 代替 γ_k , 便有

$$\gamma_k(y_t) = \sum_{i,j=0}^p \varphi_i \varphi_j \hat{\gamma}_{k+j-i} \quad (4.3.13)$$

第三步: 把 y_t 近似看作 MA(q) 序列, 即

$$y_t \cong a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \cdots - \theta_m a_{t-m}$$

利用前面介绍的关于 MA 参数估计方法解下列方程:

$$\gamma_0(y_t) = (1 + \sigma_a^2 + \cdots + \theta_m^2)$$

$$\gamma_k(y_t) = \sigma_a^2 (-\theta_k + \theta_1 \theta_{k+1} + \cdots + \theta_{m-k} \theta_m)$$

$$k=1, 2, \cdots, m$$

其解就是 ARMA 模型的移动平均参数 $\theta_1, \theta_2, \cdots, \theta_m$ 和 σ_a^2 的矩估计, 可见, 这种参数估计方法对 ARMA 模型来说, 其精度更差。

二、最小二乘估计

最小二乘估计的基本方法在数理统计课程中已有全面讲述, 本书不再重述。

三、极大似然估计

这二种方法的估计精度较高, 因而一般称之为模型参数的精估计。计算方

法较为复杂,一般都有现成计算程序(软件)。故具体内容不予详述,可参阅文献[4]。

对例 4.1 的 AR(2)模型参数进行最小二乘估计,TSP 输出的主要结果为

参数	估计值	标准差	T-检验值	95%的置信区间
φ_1	0.79	0.06	13.17	(0.67,0.91)
φ_2	-0.22	0.06	-3.67	(-0.34,0.10)

残差平方和与残差方差分别为 1474.03 和 5.99,模型可写为

$$X_t = 0.79X_{t-1} - 0.22X_{t-2} + a_t$$

第四节 模型的适应性检验

所谓模型的适应性是指一个 ARMA 模型已经完全或基本上解释了系统的动态性(即数据的相关性),从而模型中的 a_t 是独立的。显然模型的适应性检验实质上就是 a_t 的独立性检验。方法主要有以下几种。

一、散点图法

就是作出 a_t 对 a_{t-j} 和 a_t 对 X_{t-j} 的散点图,然后分析 a_t 的独立性。例如,对于 AR(1)模型来说,可以作 a_t 对 X_{t-j} ($j=2, \dots$) 和 a_t 对 a_{t-j} ($j=1, 2, \dots$) 的散点图。若两类散点图都呈现不相关的趋势,则可认为 a_t 是独立的,即 AR(1)模型是适应的。

对例 4.1 拟合 AR(1)模型,残差 a_t 对 X_{t-2} 的散点图如图 4.5 所示,拟合 AR(2)模型 a_t 对 X_{t-3} 和 a_t 对 a_{t-1} 的散点图如图 4.6、图 4.7 所示。图 4.5 有微弱的负相关趋势,说明 AR(1) 不是适应模型,而从图 4.6 和图 4.7 看不出有相关的趋势,说明 AR(2)是适应的模型。

二、估计相关系数法

就是计算 a_t 与 a_{t-j} 和 a_t 与 X_{t-j} 之间的相关系数来分析判断。若相关系数较小,则认为 a_t 独立,即模型为适应模型;否则认为不适应。

例 4.1 中, a_t 与 X_{t-j} ($j=3, 4, \dots, 10$) 的相关函数及 a_t 的自相关函数如图 4.8、图 4.9 所示。除极个别的以外,相关函数的绝对值均比 0.1 小,可以看出模型是适应的。该方法比较粗略,主要凭经验来判断,精确的可用下面的 χ^2 检验。




图 4.5 a'_t 对 X_{t-2} 的散点图




图 4.6 a_t 对 X_{t-3} 的散点图

三、F 检验

从统计假设检验来考察,就是假设 $H_0: a_t$ 独立。备择假设 $H_1: a_t$ 不独立,欲使假设 H_0 成立,往往检验备择假设 H_1 ,可是这个假设非常复杂,于是




图 4.7 a_t 对 a_{t-1} 的散点图




图 4.8 a_t 对 X_{t-j} 的相关函数图

我们设法找一种近似的简单检验来代替。

从前面数据独立化过程可以看出,如果一个模型中的 a_t 不是独立的,那么通过增加模型的阶数可以提高模型的解释能力,将 a_t 中的不独立部分分离出来,从而使 a_t 成为独立的。如果得到的模型已经是适应模型,那么 a_t 一定是




图 4.9 a_i 的自相关函数图

完全或基本上接近于独立的。这时若再增加模型的阶数,新增加的参数可能接近或等于零,剩余平方和也不会因增加模型阶数而显著减小。因此拟合一个更高阶模型之后,若剩余平方和显著减小,则说明那个较低阶模型中的 a_i 不是独立的,从而相应的模型是不适应的;若剩余平方和并没有因增加阶数而显著减小,则说明那个较低阶模型中的 a_i 是独立的,从而它是适当可行的。这样我们就可以通过检验更高阶模型的剩余平方和减小的显著性来间接地检验 a_i 的独立性。

假设我们来检验模型 $\text{ARMA}(2n, 2n-1)$ 的适应性,我们将拟合一个更高阶的 $\text{ARMA}(2n+2, 2n+1)$ 模型(下一节将讨论为什么阶次升高 2 阶),看看剩余平方和是否显著减少。一个 $\text{ARMA}(2n, 2n-1)$ 模型等价于当 $\varphi_{2n+2} = \varphi_{2n+1} = \theta_{2n} = \theta_{2n+1} = 0$ 时的 $\text{ARMA}(2n+2, 2n+1)$ 模型,于是我们可构造如下统计假设:

$$H_0: \varphi_{2n+2} = 0, \quad \varphi_{2n+1} = 0, \quad \theta_{2n} = 0, \quad \theta_{2n+1} = 0$$

$$H_1: \varphi_{2n+2} \neq 0, \quad \varphi_{2n+1} \neq 0, \quad \theta_{2n} \neq 0, \quad \theta_{2n+1} \neq 0$$

由于我们假设 a_i 为独立正态变量,即

$$a_i \sim \text{NID}(0, \sigma_a^2)$$

那么, $\sum a_i^2$ 也是一个随机变量

$$A_0 = (\sum a_i^2) \sim \sigma_a^2 \chi^2(n-r)$$

r 为 $\text{ARMA}(2n+2, 2n+1)$ 模型的参数个数,即

$$r=2n+2+2n+1=4n+3$$

那么, ARMA(2n, 2n-1)模型的剩余平方和

$$\sum a_t^2 = A_1 \sim \sigma_a^2 \chi^2(n-k)$$

k 为 ARMA(2n, 2n-1)的参数个数, 即

$$k=2n+2n-1=4n-1$$

则

$$(A_1 - A_0) \sim \sigma_a^2 \chi^2((N-k) - (N-r))$$

因为

$$(N-k) - (N-r) = N-k-N+r = -4n+1+4n+3=4$$

所以

$$(A_1 - A_0) \sim \sigma_a^2 \chi^2(4)$$

那么

$$\frac{A_1 - A_0}{4} / \frac{A_0}{N-r} \sim F(4, N-4n-3)$$

若 F 统计量的值大于 $F_\alpha(4, N-4n-3)$, 则说是 H_0 不成立, 即增加阶数, 模型剩余平方和的减小是显著的, 从而 ARMA(2n, 2n-1)是不适应的, 应当拟合更高阶的模型; 若上述统计量的值小于 $F_\alpha(4, N-4n-3)$, 则说明在 α 显著水平上, ARMA(2n, 2n-1)是适应的。

四、 χ^2 检验法

将 a_t 的自相关函数记为 $\rho_k(N, a_t)$, 自协方差函数记为 $\gamma_k(N, a_t)$, 则:

$$\gamma_k(N, a_t) = \frac{1}{N} \sum_{t=k+1}^N a_t a_{t-k}$$

$$\rho_k(N, a_t) = \gamma_k(N, a_t) / \gamma_0(N, a_t)$$

可以证明, 当 N 很大时

$$(\sqrt{N}\rho_1, \sqrt{N}\rho_2, \dots, \sqrt{N}\rho_k) \sim N(0, I_k)$$

其中 I_k 为 k 阶单位阵。所以当 N 较大时, 这 k 个量近似为相互独立的正态 $n(0, 1)$ 随机变量, 于是检验 $\{a_t\}$ 独立的问题转化为检验

$$\sqrt{N}\rho_k(N, a_t) \sim NID(0, 1)$$

$$k=1, 2, \dots, L(N), \quad L(N) = \left[\frac{N}{10}\right] \text{ 或 } \left[\sqrt{N}\right]$$

假设

$$H_0: \sqrt{N}\rho_k(N, a_t) \sim NID(0, 1)$$

那么
即

$$\sum_{k=1}^{L(N)} [\sqrt{N} \rho_k(N, a_t)]^2 \sim \chi^2(L(N) - p - q)$$

$$Q = N \sum_{k=1}^{L(N)} \rho_k^2(N, a_t)$$

服从自由度为 $L(N) - p - q$ 的 χ^2 分布, $L(N)$ 为自相关函数个数, $p + q$ 为模型的参数个数, 于是, 在给定显著性水平 α 下

若 $Q \leq \chi_{1-\alpha}^2(L(N) - p - q)$ 接受 H_0 ;

$Q > \chi_{1-\alpha}^2(L(N) - p - q)$ 拒绝 H_0 , 即否定 a_t 独立。

也可用下列方法判别:

因为 $P\{|\sqrt{N} \rho_k(N, a_t)| < 2\} = 0.955$

所以检验这 $L(N)$ 个 $\sqrt{N} \rho_k(N, a_t)$ 的绝对值是否有 95.5% 个小于 2, 若有, 则 a_t 独立; 否则, 可判定 a_t 不独立。

对例 4.1 有 $Q = 10.252$ ($L(N) = [\sqrt{250}] = 15$), 给定显著性水平 $\alpha = 0.05$, 查表可得 $\chi_{0.95}^2(15 - 2) = 22.36$, 而 $Q < \chi_{0.95}^2(15 - 2)$, 故 a_t 是独立的。

第五节 建模的其它方法

一、Pandit—Wu 的建模方法

Box—Jenkins 建模法, 是以自相关函数、偏自相关函数的统计特性为依据的, 以统计的观点来看, 理论自相关函数完全刻划了系统的动态性(即数据序列中的相关性), 但是, 在建模之前, 无论如何我们也无法知道序列的理论自相关(偏自相关)函数。因而只能用一个样本自相关函数、偏自相关函数作为近似。这种近似代替不可避免地会产生一定的误差。Pandit—Wu 在 Box—Jenkins 方法的基础上, 经过实践和进一步发展, 于 1977 年提出了系统建模的新方法。这种方法是以下面的认识为依据的。即任一平稳序列总可以用一个 $ARMA(n, n-1)$ 模型来表示。而 $AR(n)$, $MA(m)$ 以及 $ARMA(n, m)$ ($m \neq n-1$) 都是 $ARMA(n, n-1)$ 模型的特例。其建模思想可概括为: 逐渐增加模型的阶数, 拟合较高阶 $ARMA(n, n-1)$ 模型, 直到再增加模型的阶数而剩余平方和不显著减小为止。

主要建模步骤如下:

1. 零均值化

即对所研究的时间序列,计算其样本均值,若均值不为零,则对序列进行变换,即序列的每一个值减去其均值,使得到的新序列的均值为零。如果我们把序列的均值作为一个参数估计,则可省去零均值化。

2. 从 $n=1$ 开始,逐渐增加模型阶数,拟合 $AR(2n, 2n-1)$ 模型,即两阶、两阶增加模型阶数。

可见要拟合的第一个模型就是 $ARMA(2,1)$;第二个就是 $ARMA(4,3)$;第三个是 $ARMA(6,5)$;…。这种方法之所以两阶两阶地增加模型的阶数,而不一阶一阶地增加,就是因为以 2 增加模型的阶数更经济。以 2 增加模型的阶数,不会遗漏模型阶数确实为奇数的模型。如果系统的确是一个阶数为奇数的模型,那么,拟合的较高阶数为偶数的模型的第 $2n$ 个自回归系数的绝对值必然相当接近于零。所以我们可以删去较高阶的偶数阶模型的小参数得到较低奇数阶模型。如若一个系统是 $ARMA(5,4)$,那么我们拟合 $(2,1), (4,3), (6,5)$ 后, $ARMA(6,5)$ 模型中的 φ_6 和 θ_5 的绝对值必然很小,从而可以删去 φ_6 和 θ_5 而拟合 $ARMA(5,4)$ 模型。但是,对于高阶模型来说,这样可以大大节约建模时间。比如,一个适应模型为 $(13,12)$,若拟合 $ARMA(2n, 2n-1)$,得到适应模型之前只需拟合 $(2,1), (4,3), (6,5), (8,7), (10,9), (12,11), (14,13)$ 七个模型;若拟合 $ARMA(n, n-1)$,则要拟合 $AR(1), ARMA(2,1), (3,2), (4,3), (5,4), (6,5), (7,6), (8,7), (9,8), (10,9), (11,10), (12,11), (13,12), (14,13)$ 十四个模型,时间节约了一半。

再者,以 2 增加模型的阶数,可以确保揭示系统结构的特征根的客观性不受人为的主观约束。我们知道一个 $ARMA(n, n-1)$ 的自回归部分的特征方程为

$$\lambda^n - \varphi_1 \lambda^{n-1} - \varphi_2 \lambda^{n-2} - \cdots - \varphi_n = 0$$

该方程的特征根 $\lambda_i (i=1, 2, \dots, n)$ 可以客观地刻划系统的结构特征。若 $|\lambda_i| < 1$, 则系统是稳定的, 否则就是非稳定的。一般来说, λ_i 既可能是实数, 也可能是复数。但是由于 $\varphi_i (i=1, 2, \dots, n)$ 总是实数, 这就使得复根只能以共轭的形式成对地出现。显然, 若一阶一阶地增加模型的阶数, 在拟合 n 为奇数的模型时, 人为地迫使其中一个特征根为实数, 这是不科学的、不合理的。如, 设一个 $ARMA(6, 5)$ 系统的自回归的特征根为三对共轭复数, 当我们拟合 $AR(1)$ 时, 事实上强迫 λ_1 为实根; 拟合 $ARMA(3, 2)$ 时, 强迫 λ_3 为实根; 拟合 $ARMA(7, 6)$, 强迫 λ_7 为实根。不仅如此, 这样拟合的 $ARMA(5, 4)$ 的近似程度会低于 $ARMA(4, 3)$, 从而达不到真正的 $ARMA(6, 5)$ 模型。鉴于特征根的复根必然成对出现这一特点, 我们拟合 $ARMA(2n, 2n-1)$ 模型, 以避免这种人为的不合理。

3. 模型适应性检验

模型适应性检验的具体方法已在前面详细阐述,在这里不再重复。

4. 求最优模型

检验为适应模型仅是统计意义,要从系统意义上考察,即整体最优,起码应用时具备适应和经济两个方面,即检验是否有小参数,若有,可删去参数,拟合较低阶模型,并进行 F 检验,作出判断。

同时还应考虑有无奇异值和外部干扰。

表 4.1 对磨轮剖面资料拟合 $ARMA(2n, 2n-1)$ 模型的计算机输出结果

参数	ARMA 阶次		
	(2,1)	(4,3)	(2,0)
φ_1	0.84 ± 0.41	1.37 ± 1.12	0.79 ± 0.12
φ_2	-0.26 ± 0.27	-1.39 ± 0.51	-0.22 ± 0.12
φ_3		0.64 ± 0.86	
φ_4		-0.16 ± 0.31	
θ_1	-0.06 ± 0.41	-0.60 ± 1.41	
θ_2		0.71 ± 1.02	
θ_3		0.08 ± 0.39	
残差平方和	1473.505	1438.284	1474.032

注:带(±)的值表示 $1.96 \times$ 参数估计的标准差。

对例 4.1 用 Pandit—Wu 方法建模,计算机输出结果如表 4.1。

F 检验表明 $ARMA(4,3)$ 和 $ARMA(2,1)$ 没有显著差异,又 $ARMA(2,1)$ 中系数 θ_1 非常小且置信区间包含零, F 检验表明 θ_1 是多余的参数。故合适的模型为 $AR(2)$ 。

二、用长阶自回归法建立近似模型

我们知道,不论是 Box—Jenkins 方法,还是 Pandit—Wu 方法都存在建立 $ARMA$ 、 MA 模型,对于这两种模型的参数估计需要用非线性最小二乘估计。这种估计是一种不断搜索反复迭代的过程。计算相当复杂。一般需要给定合适的初始值,方能加快收敛速度,或达到收敛。这时,可用逆函数来近似估计参数,并作为初始值再作非线性最小二乘估计。

这种方法的理论依据是:任一序列,都可以用一个足够高阶的 $AR(P)$ 模型来逼近到我们所要求的精度。

如果一序列本身就是 AR 模型,那么,无疑是正确的;如果一个序列本身是一个 MA 序列,即 $X_1 = \Theta(B)a_i$,那么,

$$a_t = \frac{1}{\Theta(B)} X_t$$

$\frac{1}{\Theta(B)}$ 是该 MA 模型的逆函数; 如果一个序列本身是一个 ARMA 序列, 即

$$\Phi(B)X_t = \Theta(B)a_t, \text{ 则}$$

$$a_t = \frac{\Phi(B)}{\Theta(B)} X_t = (1 - I_1 B - I_2 B^2 - \dots) X_t$$

而 AR 模型的参数估计是线性的, 因而计算相对容易, 所以很容易得到 I_j 的估计值。有了 I_j 的值, 就可以利用逆函数与 φ_i 和 θ_j 的关系, 来求得相应的 ARMA($n, n-1$) 模型的 φ_i 和 θ_j 的近似值。

建模的具体步骤:

1. 零均值化

方法与 Pandit-Wu 方法一致。

2. 建立 AR($2n$) 模型, 直至达到所要求的精度为止。

这时的 F 统计量为

$$\text{AR}(2n+2): A_0 = (\sum a_i^2) \sim \chi^2(N-2n-2)$$

$$\text{AR}(2n): A_1 = (\sum a_i^2) \sim \chi^2(N-2n)$$

$$(A_1 - A_0) \sim \chi^2(2)$$

于是

$$\left(\frac{A_1 - A_0}{2} \right) / \left(\frac{A_0}{N - 2n - 2} \right) \sim F(2, N - 2n - 2)$$

假设:

$H_0: \varphi_{2n+2} = 0, \varphi_{2n+1} = 0$ 即 AR($2n$) 是适应的。

$H_1: \varphi_{2n+2} \neq 0, \varphi_{2n+1} \neq 0$ 即 AR($2n$) 是不适应的。

若 $F \geq F_\alpha(2, N - 2n - 2)$, 则拒绝 H_0 , AR($2n$) 不适应。

若 $F < F_\alpha(2, N - 2n - 2)$, 则接受 H_0 , AR($2n$) 适应。

这里值得注意的是, 如果是一个 ARMA($n, n-1$) 模型, 而我们要用一个 AR 模型来逼近, 往往剩余平方和大于 ARMA($n, n-1$) 模型的剩余平方和。因而应提高模型的精度、降低置信度, 甚至人为地规定比值 F , 如 0.1 或更小, 以提高 AR 模型的精度。

3. 根据拟合的 AR 模型求 ARMA($n, n-1$)

在第三章我们已经看到, 所谓逆函数, 事实上就是自回归模型的系数。因为我们把逆函数定义为用响应 X_t 过去值的线性组合表示 X_t 的函数系数。显

然一个 AR(2n) 的逆函数 $I_j = \varphi_j (j=1, \dots, 2n)$, 而对于一个 ARMA(n, n-1) 模型来说, 有

$$(1 - \varphi_1 B - \varphi_2 B^2 - \dots - \varphi_n B^n) X_t = (1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_{n-1} B^{n-1}) a_t$$

而用逆函数表示有:

$$a_t = (1 - I_1 B - I_2 B^2 - \dots) X_t$$

代入上式得: $(1 - \varphi_1 B - \varphi_2 B^2 - \dots - \varphi_n B^n)$

$$= (1 - \theta_1 B - \dots - \theta_{n-1} B^{n-1}) (1 - I_1 B - I_2 B^2 - \dots)$$

上式的右端展开如下:

$$\begin{aligned} & 1 - I_1 B - I_2 B^2 - I_3 B^3 - \dots - I_{n-1} B^{n-1} - I_n B^n - I_{n+1} B^{n+1} \\ & - \theta_1 B + \theta_1 I_1 B^2 + \theta_1 I_2 B^3 + \dots + \theta_1 I_{n-1} B^{n-1} + \dots \\ & - \theta_2 B^2 + \theta_2 I_1 B^3 + \theta_2 I_2 B^4 + \dots + \theta_2 I_{n-2} B^n + \dots \\ & - \theta_3 B^3 + \theta_3 I_1 B^4 + \dots + \theta_{n-1} B^{n-1} + \theta_{n-1} I_1 B^n + \dots \\ & = 1 - (\theta_1 + I_1) B - (\theta_2 - \theta_1 I_1 + I_2) B^2 - (\theta_3 - \theta_1 I_2 - \theta_2 I_1 + I_3) B^3 - \dots \\ & - (\theta_{n-1} - \theta_1 I_{n-2} - \theta_2 I_{n-3} - \dots - \theta_{n-2} I_1 + I_{n-1}) B^{n-1} + (\theta_1 I_{n-1} + \theta_2 I_{n-2} + \dots \\ & + \theta_{n-1} I_1 - I_n) B^n + (\theta_1 I_n + \theta_2 I_{n-1} + \theta_3 I_{n-2} + \dots + \theta_{n-1} I_2 - I_{n+1}) B^{n+1} + \dots \end{aligned}$$

比较系数

$$\begin{aligned} & \left\{ \begin{array}{l} B^1: -\varphi_1 = -(\theta_1 + I_1) \rightarrow \varphi_1 = \theta_1 + I_1 \\ B^2: \varphi_2 = \theta_2 - \theta_1 I_1 + I_2 \\ B^3: \varphi_3 = \theta_3 - \theta_1 I_2 - \theta_2 I_1 + I_3 \\ \dots \quad \dots \quad \dots \quad \dots \\ B^{n-1}: \varphi_{n-1} = \theta_{n-1} - \theta_1 I_{n-2} - \theta_2 I_{n-3} - \dots - \theta_{n-2} I_1 + I_{n-1} \\ B^n: \varphi_n = I_n - \theta_1 I_{n-1} - \theta_2 I_{n-2} - \dots - \theta_{n-1} I_1 \\ B^{n+1}: 0 = \theta_1 I_n + \theta_2 I_{n-1} + \theta_3 I_{n-2} + \dots + \theta_{n-1} I_2 - I_{n+1} \end{array} \right. \\ (1) & \left\{ \begin{array}{l} \rightarrow 0 = -(\theta_{n+1} - \theta_1 I_n - \theta_2 I_{n-1} - \dots - \theta_{n-1} I_2) \\ \rightarrow (1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_{n-1} B^{n-1}) I_j = 0 \quad j > n \end{array} \right. \\ (2) & \end{aligned}$$

于是, 将 AR(2n) 中的 $\varphi_j (j=n+1, \dots, 2n-1)$ 代入 (2) 式, 便得到 $n-1$ 个线性方程组

$$\begin{aligned} j=n+1 & \quad I_{n+1} - \theta_1 I_n - \theta_2 I_{n-1} - \dots - \theta_{n-1} I_2 = 0 \\ j=n+2 & \quad I_{n+2} - \theta_1 I_{n+1} - \theta_2 I_n - \dots - \theta_{n-1} I_1 = 0 \\ \dots & \quad \dots \quad \dots \quad \dots \quad \dots \\ j=2n-1 & \quad I_{2n-1} - \theta_1 I_{2n-2} - \theta_2 I_{2n-3} - \dots - \theta_{n-1} I_n = 0 \end{aligned}$$

解之即得 $\theta_i (i=1, 2, \dots, n-1)$, 再将 θ_i 和 I_j 代入 (1) 式, 便得到了 $\varphi_j (j=1, 2, \dots, n)$, 于是得到了一个 ARMA(n, n-1)。

可以用同样的方式,根据已经拟合的 $AR[2(n-1)]$ 求得一个 $ARMA(n-1, n-2)$ 模型。

4. $ARMA(n, n-1)$ 的可逆性检验

建立 $ARMA(n, n-1)$ 模型所得到的 θ_i 不一定满足可逆条件,为此,求

$$V^{n-1} - \theta_1 V^{n-2} - \theta_2 V^{n-3} - \dots - \theta_{n-1} = 0$$

的特征根,若 $|V_i| < 1 (i=1, 2, \dots, n-1)$,则表示求得的 θ_i 是可逆的;若某个 $|V_i| > 1$,则用其倒数 $1/V_i$ 代之从而使之满足可逆性,然后再将所有的 V_i 代入

$$(1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_{n-1} B^{n-1}) = (1 - V_1 B)(1 - V_2 B) \dots (1 - V_{n-1} B)$$

便可求得满足可逆性条件的新的 θ_i

$$\theta_l = (-1)^{l+1} \sum_{\substack{i_1, i_2, \dots, i_l=1 \\ i_1 < i_2 < \dots < i_l}}^m V_{i_1} V_{i_2} \dots V_{i_l} \quad l=1, 2, \dots, m$$

将这些新的 θ_i 代入(1)式,便得到了满足可逆条件的 φ_i ,这时得到的模型 $ARMA(n, n-1)$ 是可逆的。

5. 检验 $ARMA(n, n-1)$ 的适应性

检验 $ARMA(n, n-1)$ 的适应性主要是进行 F 检验,这种方法已在前有所论述,这里不再重复。

第六节 实 例

本节涉及的两个时间序列都是由非平稳时间序列经平稳化而得到的。

例 4.2 某市 1985—1994 年各月的工业生产总值见附录 III。我们对 1985—1993 年的数据建模,1994 年的数据留作检验模型的预测效果。平稳化后得到的序列记为 $\{Y_t\}$,共有 96 个数据,如图 4.10 所示。原序列如图 6.7 所示。

从数据图可以看出,该序列是比较平稳的,可求得其均值为 $\bar{Y}=1.509$,对 $\{Y_t\}$ 零均值化(即 $X_t=Y_t-\bar{Y}$)。先用 Box-Jenkins 方法建模, X_t 的自相关和偏自相关函数见表 4.2,从中可以看出,当 $k>2$ 时,有 $|\hat{\varphi}_{kk}| < \frac{2}{\sqrt{96}} \approx 0.204$,并且 $\hat{\rho}_k$ 呈现拖尾现象,故可初步断定序列 X_t 适合 $AR(2)$ 模型。

对 X_t 拟合 $AR(n)$ 模型,可得残差方差图如图 4.11 所示,从图中可以看出合适的阶数为 $n=3$,对 X_t 拟合 $AR(3)$ 模型,发现参数 $\varphi_3=0.04$, T 检验值




图 4.10 平稳化后的的某市工业生产总值




图 4.11 残差方差图

仅为 0.39, 将不显著的参数删掉, 拟合 AR(2) 模型, 结果见表 4.3。

F 检验值为

$$F = \frac{89.64 - 86.96}{1} \bigg/ \frac{86.96}{96 - 6} = 2.77$$

查 F 分布表可得 $F_{0.05}(1, 120) = 3.92 > F = 2.77$, 这表明 AR(3) 与

表 4.2 自相关与偏自相关函数表

k	$\hat{\rho}_k$	$\hat{\varphi}_{kk}$	k	$\hat{\rho}_k$	$\hat{\varphi}_{kk}$
1	0.428	0.428	13	-0.070	0.135
2	0.291	0.131	14	-0.057	-0.002
3	0.188	0.029	15	-0.006	0.048
4	0.042	-0.093	16	0.152	0.170
5	0.087	0.086	17	0.141	0.071
6	0.048	-0.001	18	0.117	-0.046
7	0.002	-0.038	19	0.065	-0.066
8	0.046	0.045	20	0.085	0.113
9	0.085	0.085	21	-0.060	-0.136
10	0.004	-0.083	22	-0.088	-0.120
11	-0.048	-0.086	23	-0.011	0.097
12	-0.197	-0.188	24	-0.064	-0.072

表 4.3 例 4.2 建模输出结果

参 数	AR(3)	AR(2)
φ_1	0.40±0.21	0.40±0.21
φ_2	0.07±0.22	0.12±0.20
φ_3	0.04±0.20	
残差平方和	86.96	89.64

AR(2)没有显著差异,故适应的模型为 AR(2)。下面再考虑用 Pandit—Wu 方法建模,结果如表 4.4 所示。 F 检验表明 ARMA(4,3)与 ARMA(2,1)没有显著的差异($F=1.50 < F_{0.05}(4,120)=2.45$),将 ARMA(2,1)中较小的参数 θ_1 删去后拟合 AR(2)模型,残差平方和几乎没有改变,故适应的模型为 AR(2),即

$$X_t - 0.40X_{t-1} - 0.12X_{t-2} = a_t$$

残差方差为 $\hat{\sigma}_a^2 = \frac{89.64}{96-4} = 0.97$ 。

表 4.4 例 4.2 建模输出结果

参 数	ARMA(4,3)	ARMA(2,1)	AR(2)
φ_1	0.36±1.23	0.25±1.39	0.40±0.21
φ_2	0.34±1.23	0.19±0.64	0.12±0.20
φ_3	0.29±0.91		
φ_4	-0.26±0.37		
θ_1	0.02±1.27	0.15±1.41	
θ_2	-0.26±0.98		
θ_3	-0.36±0.79		
残差平方和	83.67	89.56	89.64

例 4.3 某车站 1993—1997 年各月的列车运行数量数据见附录,经平稳化后如图 4.12 所示,共 59 个数据。原数据如图 6.15 所示。

表 4.5 例 4.3 中序列的自相关和偏自相关函数

k	$\hat{\rho}_k$	$\hat{\varphi}_{kk}$	k	$\hat{\rho}_k$	$\hat{\varphi}_{kk}$
1	-0.685	-0.685	11	-0.036	-0.130
2	0.341	-0.243	12	0.156	0.139
3	-0.193	-0.139	13	-0.165	0.136
4	0.042	-0.208	14	0.038	-0.184
5	-0.068	-0.313	15	0.001	-0.120
6	0.199	0.046	16	-0.027	-0.012
7	-0.221	-0.030	17	0.143	0.196
8	0.185	-0.037	18	-0.132	0.025
9	-0.132	-0.002	19	0.004	-0.143
10	0.037	-0.042	20	0.021	-0.073




图 4.12 例 4.3 数据图

先用 Box—Jenkins 方法建模。从数据图可以看出没有明显的趋势性和周期性,是比较平稳的。经计算可得样本均值 $\bar{X} = -0.098$, 方差 $\hat{\gamma}_0 = 3319.906$, X_t 的自相关和偏自相关函数如表 4.5 和图 4.13 所示。可以看出, $\hat{\varphi}_{kk}$ 呈现出拖尾性。

我们来依据(4.14)式判断 $\hat{\rho}_k$ 的截尾性。取 $M = [\sqrt{59}] = 7$, 当 $k=1$ 时,

$$\frac{1}{\sqrt{N}}(1+2\hat{\rho}_1^2)^{\frac{1}{2}} = \frac{1}{\sqrt{59}}(1+2 \times 0.685^2)^{\frac{1}{2}} = 0.181$$




图 4.13 例 4.3 中序列的相关函数图

在 $\hat{\rho}_k (k=2,3,4,5,6,7,8)$ 中满足 $|\hat{\rho}_k| < 0.181$ 的仅占 $\frac{2}{7} = 28.6\%$, 当 $k=2$ 时,

$$\begin{aligned} \frac{1}{\sqrt{N}} [1 + 2(\hat{\rho}_1^2 + \hat{\rho}_2^2)]^{\frac{1}{2}} &= \frac{1}{\sqrt{59}} [1 + 2(0.685^2 + 0.341^2)]^{\frac{1}{2}} \\ &= 0.192 \end{aligned}$$

在 $\hat{\rho}_k(k=3,4,5,6,7,8,9)$ 中满足 $|\hat{\rho}_k|<0.192$ 的仅占 $\frac{4}{7}=57.1\%$, 当 $k=3$ 时,

$$\frac{1}{\sqrt{N}}[1+2(\hat{\rho}_1^2+\hat{\rho}_2^2+\hat{\rho}_3^2)]^{\frac{1}{2}}=0.195$$

在 $\hat{\rho}_k(k=4,5,6,7,8,9,10)$ 中满足 $|\hat{\rho}_k|<0.195$ 的比例达到 $\frac{5}{7}=71.4\%>68.3\%$, 因而 $\hat{\rho}_k$ 为 3 步截尾, 可初步判断出序列 X_t 适合 MA(3) 模型。

为了检验样本均值是否非零, 由 (4.1.3) 式和 MA 模型自相关函数的截尾性, 可得

$$\begin{aligned} S.E. [\bar{X}] &\approx \left[\frac{\hat{\gamma}_0}{N} (1+2\hat{\rho}_1+2\hat{\rho}_2+2\hat{\rho}_3+2\hat{\rho}_4) \right]^{\frac{1}{2}} \\ &= \left[\frac{3319.906}{59} (1-2\times 0.685+2\times 0.341-2 \right. \\ &\quad \left. \times 0.193+2\times 0.042) \right]^{\frac{1}{2}} \\ &= 0.75 \end{aligned}$$

这里利用了前四个自相关, 之所以这样, 是因为用前三个自相关计算的 $\text{Var}[\bar{X}]$ 是负的, 而这显然是不可能的。可以看出, 序列的均值没有超出 $0\pm 2\times 0.75$, 故可以认为 X_t 为零均值过程。对 X_t 拟合 MA(3) 模型, 结果见表 4.6, 为了检查 MA(3) 的适应性, 继续增加阶数 m , 可得残差方差图如图 4.14 所示, 可以看出 MA(5) 的残差方差最小, 拟合 MA(5) 后发现 θ_4 和 θ_5 不显著, 将其删除后, 拟合 MA(3), 系数都比较显著, 结果见表 4.6, 因而合适的模型为 MA(3)。下面再用 Pandit—Wu 方法建模, 结果见表 4.7。

F 检验 ($F=1.45<F_{0.05}(4,60)=2.53$) 表明 ARMA(4,3) 和 ARMA(2,1) 没有显著差异, 在 ARMA(2,1) 模型中, φ_1 和 μ 不显著, 将其删除后, 残差平方和变化不大, 残差方差反而减小, 故合适的模型为

$$X_t-0.16X_{t-2}=a_t+0.97a_{t-1}$$

表 4.6 例 4.3 建模输出结果

参 数	MA(5)	MA(3)
θ_1	-1.10 ± 0.27	-1.10 ± 0.26
θ_2	0.46 ± 0.27	0.40 ± 0.27
θ_3	-0.33 ± 0.27	-0.22 ± 0.26
θ_4	0.07 ± 0.27	
θ_5	0.12 ± 0.27	
残差平方和	75916.34	79231.24
残差方差	1405.86	1414.84




图 4.14 例 4.3 的残差方差图

表 4.7 例 4.3 建模输出结果

参 数	ARMA(2,1)	ARMA(4,3)	ARMA(2,1), $\varphi_1=0$
φ_1	-0.11 ± 0.66	-0.48 ± 0.70	0.16 ± 0.18
φ_2	0.31 ± 0.49	-0.51 ± 0.64	
φ_3		-0.16 ± 0.50	
φ_4		0.02 ± 0.34	
θ_1	-0.91 ± 0.75	-0.65 ± 0.75	-0.97 ± 0.72
θ_2		0.49 ± 0.67	
θ_3		-0.63 ± 0.53	
μ	0.38 ± 12.32	0.65 ± 4.78	
残差平方和	75697.07	67399.60	77842.03
残差方差	1428.25	1434.03	1415.31

该模型的残差方差比 MA(3)稍大一点。综上所述,用不同的方法得到了不同的模型,如果以残差方差衡量模型的适应性,则这两个不同的模型几乎没有什么差别。事实上,从 X_t 的自相关和偏自相关函数来看,也可以认为其均呈现一定拖尾性,因而用 ARMA 模型描述也是可以的。

思考与练习

4.1 以下是三个序列的自相关和偏自相关函数,试对它们各识别出一个模型。

	1	2	3	4	5
<i>acf</i>	-0.800	0.670	-0.518	0.390	-0.310
<i>pacf</i>	-0.800	0.085	0.112	-0.046	-0.061
<i>acf</i>	0.449	-0.056	-0.023	0.028	0.013
<i>pacf</i>	0.449	-0.324	0.218	-0.118	0.077
<i>acf</i>	-0.719	0.337	-0.083	0.075	-0.088
<i>pacf</i>	-0.719	-0.375	-0.048	0.239	0.173

- 4.3 已知 $\hat{\rho}_1=0.90, \hat{\rho}_2=0.70, \hat{\rho}_3=0.45$, 求一个 ARMA(2,1) 模型参数的初始值。
- 4.4 根据下面 AR(4) 模型的估计值, 求关于一个 ARMA(2,1) 模型的可逆初始猜测值。
 (a) $\varphi_1=0.8, \varphi_2=-0.4, \varphi_3=-0.2, \varphi_4=0.2$
 (b) $\varphi_1=0.5, \varphi_2=-0.4, \varphi_3=-0.5, \varphi_4=0.3$
- 4.5 对一个 $N=80$ 的观测值序列拟合 ARMA(2,1) 模型, 得到的残差自相关如下:

k	1	2	3	4	5	6	7	8
$\rho_k(\hat{a}_t)$	0.10	0.08	0.09	0.04	-0.13	0.05	0.02	-0.06

试用不同的方法检验该模型的适应性。

平稳时间序列预测

本章讨论平稳时间序列的预测问题。设当前时刻为 t ，我们已经知道平稳时间序列 X_t 在时刻 t 及以前时刻的观察值 $X_t, X_{t-1}, X_{t-2}, \dots$ ，现在用序列 X_t 对时刻 t 以后的观察值 $X_{t+l} (l > 0)$ 进行预测，这种预测称为以 t 为原点，向前期（或步长）为 l 的预测，预测值记为 $\hat{X}_t(l)$ 。以下各节我们将从不同的角度考虑平稳时间序列的预测问题，并与指数平滑进行比较。

一、从几何角度提出预测问题

126

前时刻的取值 $X_t, X_{t-1}, X_{t-2}, \dots$ 所提供的信息,也就是说,应把 $\hat{X}_t(l)$ 作为 $X_t, X_{t-1}, X_{t-2}, \dots$ 的函数来计算,一般考虑比较简单的线性函数,即用 $X_t, X_{t-1}, X_{t-2}, \dots$ 的线性函数来表述 $\hat{X}_t(l)$ 。

$$\hat{X}_t(l) = g_0^* X_t + g_1^* X_{t-1} + \dots \quad (5.1.1)$$

现在的问题是如何求得系数 $g_0^*, g_1^*, \dots$ 使得 $\hat{X}_t(l)$ 与 X_{t+l} 最接近? 如果我们将 $X_t, X_{t-1}, \dots$ 看成向量,并定义向量间的距离为向量的均方差,那么 $X_t, X_{t-1}, \dots$ 的线性组合将构成一个“平面” M ,用平面 M 上的哪一个向量(即哪一个组合)作为 $\hat{X}_t(l)$ 呢? 很自然地我们会想到用 X_{t+l} 在平面 M 上的正交投影作为 $\hat{X}_t(l)$,因为在平面 M 上的所有向量中只有 X_{t+l} 的正交投影与 X_{t+l} 的距离最小(如图 5.1 所示)。即 $E[X_{t+l} - \hat{X}_t(l)]^2 = E[e_t(l)]^2$ 达到最小, $e_t(l)$ 为预测误差。有了这样的思想,我们不难求出 $g_0^*, g_1^*, g_2^*, \dots$ 。




图 5.1 几何预测示意图

二、求解正交投影

我们在预测前已经对 X_t 建立了合适的平稳时序模型,也就是知道了 X_t 的结构,假设其结构可用正交分解表示为(为不失一般性,取 X_t 的均值为零)

$$X_t = a_t + G_1 a_{t-1} + G_2 a_{t-2} + \dots \quad (5.1.2)$$

a_t 满足 $E(a_t, a_{t-k}) = 0, k \neq 0$ 。由此可以看出由 $X_t, X_{t-1}, X_{t-2}, \dots$ 形成的平面就是由 $a_t, a_{t-1}, a_{t-2}, \dots$ 形成的平面,但是 $X_t, X_{t-1}, \dots$ 之间是相互依赖的,而 $a_t, a_{t-1}, a_{t-2}, \dots$ 之间则是相互正交的,因而 $a_t, a_{t-1}, a_{t-2}, \dots$ 是平面 M 的一组正交基。式(5.1.1)中的 $\hat{X}_t(l)$ 是用 $X_t, X_{t-1}, X_{t-2}, \dots$ 表示的,当然也可以由正交基来表示:

$$\hat{X}_t(l) = G_0^* a_t + G_1^* a_{t-1} + G_2^* a_{t-2} + \cdots \quad (5.1.3)$$

借助于(5.1.2),理论上我们可以由 g_j^* 求 G_j^* ,或由 G_j^* 求 g_j^* ,因此求解 g_j^* 的问题也就转化为求 G_j^* 的问题。而 G_j^* 是 X_{t+l} 在平面 M 上的正投影相对于平面 M 的一组正交基的坐标,因此要容易求一些。如图 5.1 所示, $\hat{X}_t(l)$ 为 X_{t+l} 在平面 M 上的正投影,预测误差 $e_t(l) = X_{t+l} - \hat{X}_t(l)$ 应与平面 M 正交,当然与正交基中的每个向量正交,即有

$$E[e_t(l)a_{t-j}] = E[(X_{t+l} - \hat{X}_t(l))a_{t-j}] = 0 \quad j=0,1,2,\cdots \quad (5.1.4)$$

由于

$$X_{t+l} = a_{t+l} + G_1 a_{t+l-1} + \cdots + G_l a_t + G_{l+1} a_{t-1} + \cdots \quad (5.1.5)$$

当 $j=0$ 时,将(5.1.5)和(5.1.3)代入(5.1.4)式,有

$$\begin{aligned} E\{[a_{t+l} + G_1 a_{t+l-1} + \cdots + G_{l-1} a_{t+1} + (G_l - G_0^*) a_t + (G_{l+1} - G_1^*) a_{t-1} + \cdots] a_{t-j}\} \\ = 0 \end{aligned} \quad (5.1.6)$$

由于 a_t 之间的正交性,故有

$$E[(G_l - G_0^*) a_t^2] = (G_l - G_0^*) \sigma_a^2 = 0$$

亦即 $G_0^* = G_l$ 。

同理 $j=1$ 时,可得

$$E[(G_{l+1} - G_1^*) a_{t-1}^2] = (G_{l+1} - G_1^*) \sigma_a^2 = 0$$

亦即 $G_1^* = G_{l+1}$,一般有

$$G_j^* = G_{l+j}, \quad j=0,1,2,\cdots \quad (5.1.7)$$

这样就从几何的角度解决了预测问题,由于这种预测使得 $\hat{X}_t(l)$ 与 X_{t+l} 的均方误差最小,因而也称为最小均方误差预测。

上面我们从几何的角度得到了 X_{t+l} 的最小均方误差预测,当然也可以从代数的角度考虑,殊途同归。由(5.1.3)和(5.1.5)可得

$$\begin{aligned} E[X_{t+l} - \hat{X}_t(l)]^2 \\ = E[a_{t+l} + G_1 a_{t+l-1} + G_2 a_{t+l-2} + \cdots + G_{l-1} a_{t+1} + \sum_{j=0}^{\infty} (G_{l+j} - G_j^*) a_{t-j}]^2 \end{aligned} \quad (5.1.8)$$

显然,当 $G_j^* = G_{l+j}$ ($j=0,1,2,\cdots$) 时,上式达到最小,由此再一次得到(5.1.7)式。

综上所述, X_{t+l} 的最小均方误差预测为

$$\hat{X}_t(l) = G_l a_t + G_{l+1} a_{t-1} + G_{l+2} a_{t-2} + \cdots \quad (5.1.9)$$

预测误差为

$$e_t(l) = X_{t+l} - \hat{X}_t(l) = a_{t+l} + G_1 a_{t+l-1} + \cdots + G_{l-1} a_{t+1} \quad (5.1.10)$$

其方差为

$$D(e_t(l)) = E(e_t(l))^2 = \sigma_a^2(1 + G_1^2 + G_2^2 + \cdots + G_{l-1}^2) \quad (5.1.11)$$

它是在时刻 t 用 $X_t, X_{t-1}, \dots$ 对 X_{t+l} 的所有线性预测中最小的方差, 因而也称 (5.1.9) 为平稳线性最小方差预测。从 (5.1.11) 式可以看出 l 步线性最小方差预测误差的方差和预测步长 l 有关而与预测的时间原点 t 无关, 这一点也体现了预测的平稳性质。同时还可以看出预测的步长 l 越大, 预测误差的方差也越大, 即预测的准确性越差。

至此, 我们已从理论上解决了平稳序列的预测问题, 从 (5.1.9) 式可以看出, l 步最小方差预测包含无穷项求和, 而实际中我们只可能有有限的数据, 因此, 只能用充分多项的有穷和近似, 即

$$\hat{X}_t(l) \cong \sum_{j=0}^T G_{l+j} a_{t-j} \quad (5.1.12)$$

因为 G_j 是指数衰减的, T 的取值只要使 $\sum_{j=T+1}^{\infty} |G_{l+j} a_{t-j}|$ 小于允许值即可。这样我们在对实际数据建立了 ARMA 模型后就可以利用 (5.1.12) 式在计算机上实现预测了, 格林函数可递推计算, a_t 可按

$$a_t = x_t - \varphi_1 x_{t-1} - \varphi_2 x_{t-2} - \cdots - \varphi_n x_{t-n} + \theta_1 a_{t-1} + \theta_2 a_{t-2} + \cdots + \theta_m a_{t-m} \quad (5.1.13)$$

式递推计算, 开始时可取 $a_{t-1} = a_{t-2} = \cdots = a_{t-m} = 0$

我们把 (5.1.9) 式称为 l 步线性最小方差预测的格林函数形式, 这是预测的一种算法, 在实际中只能近似计算, 下面我们将从条件期望的角度介绍另一种算法: 差分方程形式的预测, 利用这种算法可以直接从模型出发求出 l 步线性最小方差预测。

第二节 条件期望预测

我们要解决的问题是在时刻 t 用 $X_t, X_{t-1}, \dots$ 对 X_{t+l} 的取值进行预测, 而 X_{t+l} 是一个未知的随机变量, 因此一个直观的想法是用其条件期望值作为预测值。由于 X_t 之间具有相关性, 因而 X_{t+l} 的概率分布是有条件的 (即在 $X_t, X_{t-1}, \dots$ 已给定的条件下), 其期望也是有条件的, 即

$$\hat{X}_t(l) = E(X_{t+l} | X_t, X_{t-1}, \dots) \quad (5.2.1)$$

有关 X_t 和 a_t 的条件期望具有以下定则:

- (1) 常量的条件期望是其本身

对 ARMA 序列而言,现在时刻与过去时刻的观测值及扰动的条件期望是其本身,即

$$E(X_k | X_{t-1}, X_{t-2}, \dots) = X_k \quad (k \leq t)$$

$$E(a_k | X_{t-1}, X_{t-2}, \dots) = a_k \quad (k \leq t)$$

(2) 未来扰动的条件期望为零,即

$$E(a_k | X_t, X_{t-1}, \dots) = 0 \quad (k > t)$$

(3) 未来取值的期望为未来取值的预测值,即

$$E(X_{k+l} | X_t, X_{t-1}, \dots) = \hat{X}_{t+l} \quad (l \geq 1)$$

利用以上性质对(5.1.5)求条件期望,有

$$\begin{aligned} \hat{X}_t(l) &= E(X_{t+l} | X_t, X_{t-1}, \dots) \\ &= G_l a_t + G_{l+1} a_{t-1} + G_{l+2} a_{t-2} + \dots \end{aligned}$$

即为(5.1.9)式,这说明在正态条件下条件期望预测与正交投影预测是一致的。下面我们利用条件期望来进行预测。

一、用模型的逆转形式预测

从第三章我们知道,任一 ARMA 模型可用逆转形式来表示,即将 X_t 表示为过去观测值的线性组合再加一个随机扰动:

$$X_t = \sum_{j=1}^{\infty} I_j X_{t-j} + a_t$$

因而

$$\begin{aligned} X_{t+l} &= \sum_{j=1}^{\infty} I_j X_{t+l-j} + a_{t+l} \\ \hat{X}_t(l) &= E(X_{t+l} | X_t, X_{t-1}, \dots) \\ &= \sum_{j=1}^{\infty} I_j E(X_{t+l-j} | X_t, X_{t-1}, \dots) \\ &= \sum_{j=1}^{l-1} I_j \hat{X}_t(l-j) + \sum_{j=l}^{\infty} I_j X_{t+l-j} \end{aligned} \quad (5.2.2)$$

从上式可以看出,预测要用到所有过去 X_t 的信息。实际上,ARMA 模型的可逆性保证了 I_j 构成收敛级数,按预定的精度要求,可取某个 k 值,当 $j > k$ 时,令 $I_j = 0$,即忽略 X_{t+l} 对 X_{t+l-j} 的依赖性,进而得出预测值。

二、用模型(即差分方程形式)进行预测

1. AR(1)模型

设序列 X_t 适合如下 AR(1) 模型

$$\begin{aligned} X_t &= \varphi_1 X_{t-1} + a_t \\ \hat{X}_t(1) &= E(X_{t+1}) \\ &= E(\varphi_1 X_t + a_{t+1}) \\ &= \varphi_1 X_t \\ \hat{X}_t(2) &= E(X_{t+2}) \\ &= E(\varphi_1 X_{t+1} + a_{t+2}) \\ &= \varphi_1 \hat{X}_t(1) \\ &= \varphi_1^2 X_t \end{aligned}$$

一般地, 有

$$\begin{aligned} \hat{X}_t(l) &= E(X_{t+l}) \\ &= E(\varphi_1 X_{t+l-1} + a_{t+l}) \\ &= \varphi_1 \hat{X}_t(l-1) \end{aligned}$$

即 $l > 0$ 时, 预测值满足模型差分方程形式的自回归部分

$$\hat{X}_t(l) - \varphi_1 \hat{X}_t(l-1) = 0 \quad (\text{其中 } \hat{X}_t(0) = X_t)$$

因而

$$\hat{X}_t(l) = \varphi_1^l X_t$$

2. ARMA(1,1) 模型

模型可写为

$$\begin{aligned} X_t &= \varphi_1 X_{t-1} + a_t - \theta_1 a_{t-1} \\ \hat{X}_t(1) &= E(X_{t+1}) \\ &= E(\varphi_1 X_t + a_{t+1} - \theta_1 a_t) \\ &= \varphi_1 X_t - \theta_1 a_t \end{aligned}$$

其中, $a_t = X_t - \hat{X}_{t-1}(1) = X_t - \varphi_1 X_{t-1} + \theta_1 a_{t-1}$, 可以看出 a_t 需要递推计算, 但实际中数据是有限的, 过于靠前的 a_{t-j} 是未知的, 因而我们往往给定初始值, 取以前某时刻 $a_{t-j} = 0$, 即假定 $X_{t-j} = \hat{X}_{t-j-1}(1)$, 这样就可以递推算出 a_t , 进而得到 $\hat{X}_t(1)$ 。

$$\begin{aligned} \hat{X}_t(2) &= E(X_{t+2}) \\ &= E(\varphi_1 X_{t+1} + a_{t+2} - \theta_1 a_{t+1}) \\ &= \varphi_1 \hat{X}_t(1) \end{aligned}$$

一般地, 有

$$\hat{X}_t(l) = E(X_{t+l})$$

$$\begin{aligned}
 &= E(\varphi_1 X_{t+l-1} + a_{t+l} - \theta_1 a_{t+l-1}) \\
 &= \varphi_1 \hat{X}_t(l-1)
 \end{aligned}$$

即 $l > 1$ 时, 预测值满足模型差分方程形式的自回归部分

$$\hat{X}_t(l) - \varphi_1 \hat{X}_t(l-1) = 0 \quad (5.2.3)$$

故预测值为如下形式(差分方程(5.2.3)的通解):

$$\hat{X}_t(l) = b_0^{(t)} \varphi_1^l \quad (l > 0) \quad (5.2.4)$$

又

$$\hat{X}_t(1) = \varphi_1 X_t - \theta_1 a_t$$

故

$$\begin{aligned}
 b_0^{(t)} \varphi_1 &= \varphi_1 X_t - \theta_1 a_t \\
 &= \varphi_1 \left(X_t - \frac{\theta_1}{\varphi_1} a_t \right)
 \end{aligned}$$

因而

$$b_0^{(t)} = X_t - \frac{\theta_1}{\varphi_1} a_t$$

当 $l > 0$ 时, 预测值(差分方程(5.2.3)的特解)为

$$\hat{X}_t(l) = \left(X_t - \frac{\theta_1}{\varphi_1} a_t \right) \varphi_1^l \quad (5.2.5)$$

可以看出, 如果把预测值 $\hat{X}_t(l)$ 看作 l 的函数, 则预测函数的形式是由模型的自回归部分决定的, 滑动平均部分用于确定预测函数中的待定系数, 使得预测函数“适应”于观测数据。

3. MA(1)模型

$$\begin{aligned}
 X_t &= a_t - \theta_1 a_{t-1} \\
 \hat{X}_t(1) &= E(X_{t+1}) \\
 &= E(a_{t+1} - \theta_1 a_t) \\
 &= -\theta_1 a_t
 \end{aligned}$$

其中 $a_t = X_t - \hat{X}_{t-1}(1) = X_t + \theta_1 a_{t-1}$, 可递推算出。

$$\begin{aligned}
 \hat{X}_t(2) &= E(X_{t+2}) \\
 &= E(a_{t+2} - \theta_1 a_{t+1}) \\
 &= 0
 \end{aligned}$$

一般地有

$$\hat{X}_t(l) = 0 \quad (l \geq 2)$$

类似的对于 MA(m)模型而言超过 m 步的预测值均为零, 这与 MA 序列的短

记忆性是吻合的。

例 5.1 设 X_t 适合以下 ARMA(2,1)模型

$$X_t - 0.8X_{t-1} + 0.5X_{t-2} = a_t - 0.3a_{t-1}$$

已知: $X_{t-3}, X_{t-2}, X_{t-1}, X_t$ 分别为 $-1, 2, 2.5, 0.6$, $a_{t-2} = 0$, 求 $\hat{X}_t(1), \hat{X}_t(2)$ 和预测函数 $\hat{X}_t(l)$ 。

解: 先求 a_{t-1} 和 a_t 。

$$\text{由于 } X_{t-1} - 0.8X_{t-2} + 0.5X_{t-3} = a_{t-1} - 0.3a_{t-2}$$

$$\begin{aligned} \text{故 } a_{t-1} &= X_t - 0.8X_{t-2} + 0.5X_{t-3} + 0.3a_{t-2} \\ &= 2.5 - 0.8 \times 2 + 0.5 \times (-1) + 0.3 \times 0 \\ &= 0.4 \end{aligned}$$

$$\begin{aligned} \text{同理 } a_t &= X_t - 0.8X_{t-1} + 0.5X_{t-2} + 0.3a_{t-1} \\ &= 0.6 - 0.8 \times 2.5 + 0.5 \times 2 + 0.3 \times 0.4 \\ &= -0.28 \end{aligned}$$

$$\begin{aligned} \therefore \hat{X}_t(1) &= E(X_{t+1}) \\ &= E(0.8X_t - 0.5X_{t-1} + a_{t+1} - 0.3a_t) \\ &= 0.8 \times 0.6 - 0.5 \times 2.5 + 0 - 0.3 \times (-0.28) \\ &= 0.07 \end{aligned}$$

$$\begin{aligned} \hat{X}_t(2) &= E(X_{t+2}) \\ &= E(0.8X_{t+1} - 0.5X_t + a_{t+2} - 0.3a_{t+1}) \\ &= 0.8 \times E(X_{t+1}) - 0.5X_t \\ &= 0.8 \times 0.07 - 0.5 \times 0.6 \\ &= -0.244 \end{aligned}$$

当 $l > 1$ 时, 预测值满足由模型自回归部分决定的差分方程

$$\hat{X}_t(l) - 0.8\hat{X}_t(l-1) + 0.5\hat{X}_t(l-2) = 0$$

其中, $\hat{X}_t(0) = X_t$, 特征方程 $\lambda^2 - 0.8\lambda + 0.5 = 0$ 的根为 $0.4 \pm 0.58i$, 故预测函数为如下形式:

$$\hat{X}_t(l) = (\sqrt{0.4^2 + 0.58^2})^l (b_0^{(t)} \sin \theta l + b_1^{(t)} \cos \theta l) \quad (l > 0)$$

其中, $\theta = \arctg \frac{0.58}{0.4} = 55.41^\circ$, $b_0^{(t)}$ 和 $b_1^{(t)}$ 的确定要用到模型的滑动平均部分, 请读者自己完成。可以看出, 随着 l 的增大, 预测值将振荡衰减趋于零(序列均值)。

三、ARMA(n,m)模型预测的一般结果

一般地, 对于适合如下 ARMA(n, m)模型的序列, 我们可以通过

$$X_t - \varphi_1 X_{t-1} - \cdots - \varphi_n X_{t-n} = a_t - \theta_1 a_{t-1} - \cdots - \theta_m a_{t-m}$$

求 X_{t+l} 的条件期望逐一求出 $\hat{X}_t(l)$ 。

$$\begin{aligned}\hat{X}_t(1) &= E(X_{t+1}) \\ &= E(\varphi_1 X_t + \varphi_2 X_{t-1} + \cdots + \varphi_n X_{t+1-n} + a_{t+1} - \theta_1 a_t - \cdots - \theta_m a_{t+1-m}) \\ &= \varphi_1 X_t + \varphi_2 X_{t-1} + \cdots + \varphi_n X_{t+1-n} - \theta_1 a_t - \cdots - \theta_m a_{t+1-m}\end{aligned}$$

$$\begin{aligned}\hat{X}_t(2) &= E(X_{t+2}) \\ &= E(\varphi_1 X_{t+1} + \varphi_2 X_t + \cdots + \varphi_n X_{t+2-n} + a_{t+2} - \theta_1 a_{t+1} - \theta_2 a_t - \cdots - \theta_m a_{t+2-m}) \\ &= \varphi_1 \hat{X}_t(1) + \varphi_2 X_t + \cdots + \varphi_n X_{t+2-n} - \theta_2 a_t - \cdots - \theta_m a_{t+2-m}\end{aligned}$$

.....

当 $l \leq \max\{m, n\}$ 时

$$\begin{aligned}\hat{X}_t(l) &= \varphi_1 \hat{X}_t(l-1) + \varphi_2 \hat{X}_t(l-2) + \cdots + \varphi_{l-1} \hat{X}_t(1) + \varphi_l X_t + \cdots + \varphi_n X_{t+l-n} \\ &\quad - \theta_l a_t - \cdots - \theta_m a_{t+l-m}\end{aligned}$$

上式中, 当 $l > m$ 时, 滑动平均部分全部消失, 有

$$\hat{X}_t(l) = \varphi_1 \hat{X}_t(l-1) + \varphi_2 \hat{X}_t(l-2) + \cdots + \varphi_n \hat{X}_t(l-n) \quad (5.2.6)$$

其中, 对于 $j \geq 0$ 理解为 $\hat{X}_t(-j) = X_{t-j}$, 即各步的预测结果满足差分方程的自回归部分。(5.2.6)的通解(即预测函数形式)为

$$\hat{X}_t(l) = b_0^{(l)} f_0(l) + b_1^{(l)} f_1(l) + \cdots + b_{n-1}^{(l)} f_{n-1}(l) \quad (5.2.7)$$

这里 $l > m - n$, 其中 $f_0(l), f_1(l), \dots, f_{n-1}(l)$ 的形式由模型特征方程 $\lambda^n - \varphi_1 \lambda^{n-1} - \cdots - \varphi_{n-1} \lambda - \varphi_n = 0$ 的根决定, 作为 l 的函数, 通常它们可能包含多项式、指数、正弦和余弦以及这些函数的乘积。当预测原点 t 给定时, 系数 $b_0^{(l)}, b_1^{(l)}, \dots, b_{n-1}^{(l)}$ 都是常数, 并由模型的滑动平均部分确定, 随着预测原点的变化, 这些系数也将改变, 以使预测值适应于序列已观测部分的特性。综上所述, 对于 ARMA(n, m)模型, 自回归部分决定了预测函数的形式, 而滑动平均部分则用于确定预测函数中的系数。预测误差及其方差如(5.1.10)、(5.1.11)所示, 预测误差具有如下分布:

$$e_t(l) \sim \text{NID}(0, D(e_t(l)))$$

由于 $X_{t+l} = \hat{X}_t(l) + e_t(l)$, 因而 X_{t+l} 的分布完全由 $e_t(l)$ 的分布所决定, 如图 5.2 所示。

$$\begin{aligned}(X_{t+l} | X_t, X_{t-1} \cdots \text{已知}) &\sim \text{NID}(\hat{X}_t(l), D^*(e_t(l))) \\ &\sim \text{NID}(\hat{X}_t(l), \sigma_a^2(1 + G_1^2 + \cdots + G_{l-1}^2))\end{aligned} \quad (5.2.8)$$

X_{t+l} 预测的 95% 的置信区间为

$$\hat{X}_t(l) \pm 1.96 \sigma_a (1 + G_1^2 + \cdots + G_{l-1}^2)^{\frac{1}{2}} \quad (5.2.9)$$

$\hat{X}_t(l)$ 可由模型求条件期望得到。




图 5.2 X_{t+l} 的条件分布

例 5.2 利用例 4.1 所建模型进行预测,模型为

$$X_t = 0.79X_{t-1} - 0.22X_{t-2} + a_t, \sigma_a = 2.45$$

我们在 $t=250$ 作超前一步、两步和三步预测,首先由 φ_1 和 φ_2 求出格林函数 G_0, G_1 和 G_2 。

$$G_0 = 1$$

$$G_1 = \varphi_1 = 0.79$$

$$G_2 = \varphi_1 G_1 + \varphi_2 = 0.79 \times 0.79 - 0.22 = 0.404$$

然后利用模型来预测

$$\begin{aligned}\hat{X}_{250}(1) &= 0.79X_{250} - 0.22X_{249} \\ &= 0.79 \times 4.58 - 0.22 \times 3.78 \\ &= 2.787\end{aligned}$$

$$\begin{aligned}\hat{X}_{250}(2) &= 0.79\hat{X}_{250}(1) - 0.22X_{250} \\ &= 0.79 \times 2.787 - 0.22 \times 4.58 \\ &= 1.194\end{aligned}$$

$$\begin{aligned}\hat{X}_{250}(3) &= 0.79\hat{X}_{250}(2) - 0.22\hat{X}_{250}(1) \\ &= 0.79 \times 1.194 - 0.22 \times 2.787 \\ &= 0.33\end{aligned}$$

这些预测的 95% 的置信区间为

$$\begin{aligned}\hat{X}_{250}(1) \pm 1.96\sigma_a &= 2.787 \pm 1.96 \times 2.45 \\ &= 2.787 \pm 4.802\end{aligned}$$

$$\begin{aligned}\hat{X}_{250}(2) \pm 1.96\sigma_a \sqrt{1+G_1^2} \\ = 1.194 \pm 1.96 \times 2.45 \sqrt{1+0.79^2}\end{aligned}$$

$$=1.194 \pm 6.12$$

$$\hat{X}_{250}(3) \pm 1.96\sigma_a \sqrt{1+G_1^2+G_2^2}$$

$$=0.33 \pm 1.96 \times 2.45 \sqrt{1+0.79^2+0.404^2}$$

$$=0.33 \pm 6.42$$

再利用 $Y_t = X_t + \bar{Y}$ ($\bar{Y}=9.42$) 得到原序列 Y_t 的预测分别为

$$\hat{Y}_{250}(1) = 12.207 \pm 4.802$$

$$\hat{Y}_{250}(2) = 10.614 \pm 6.12$$

$$\hat{Y}_{250}(3) = 9.75 \pm 6.42$$




图 5.3 例 5.2 预测图示

四、预测的稳定性

下面我们来考虑一下,随着超前步数 l 的增大,预测值将有怎样的变化趋势,也就是预测的稳定性问题。显然这与系统(序列)本身的稳定性有密切的关系,从第三章我们知道,系统的稳定性可以由格林函数来刻画,即有

$$G_j \rightarrow 0 (j \rightarrow \infty) \Leftrightarrow \text{系统是渐近稳定的}$$

$$G_j \rightarrow \text{常数} (j \rightarrow \infty) \Leftrightarrow \text{系统是稳定的而不是渐近稳定的}$$

$$G_j \rightarrow \infty (j \rightarrow \infty) \Leftrightarrow \text{系统是不稳定的}$$

从(5.2.6)和第三章理论可知格林函数与预测值满足同样的关系式,格林函数

描述系统的记忆性,而预测所依赖的正是这种记忆性,因而预测值的变化趋势与格林函数的变化是一致的。

1. 当 ARMA 系统渐近稳定时

此时,所有特征根的绝对值均小于 1,随着 $j \rightarrow \infty, G_j \rightarrow 0$,系统的记忆性逐渐衰减为零,预测值 $\hat{X}_t(l)$ 随着超前步数 l 的增大,也将趋于零(实际上是序列 X_t 的均值)。

例如,对于如下的一类 ARMA(1,1)系统, $\varphi_1 = 0.5$ 满足

$$X_t - 0.5X_{t-1} = a_t - \theta_1 a_{t-1}$$

$|\varphi_1| < 1$,系统是渐近稳定的,其预测值

$$\begin{aligned}\hat{X}_t(l) &= 0.5\hat{X}_t(l-1) \quad (l \geq 2) \\ &= 0.5^{l-1}\hat{X}_t(1) \\ &= 0.5^{l-1}(0.5X_t - \theta_1 a_t) \\ &\rightarrow 0 \quad (l \rightarrow \infty)\end{aligned}$$

2. 当 ARMA 系统边界稳定时

此时,所有特征根中至少有一个的绝对值为 1,而其它的绝对值均小于 1,随着 $j \rightarrow \infty, G_j \rightarrow C$ (常数),系统的记忆性趋于恒定,预测值 $\hat{X}_t(l)$ 随着 l 的增大也将趋于常数,比如对如下一类 ARMA(1,1)系统,有

$$\begin{aligned}X_t - X_{t-1} &= a_t - \theta_1 a_{t-1} \\ \hat{X}_t(l) &\equiv \hat{X}_t(1) = X_t - \theta_1 a_t \quad (l \geq 2)\end{aligned}$$

3. 当 ARMA 系统不稳定时

此时,至少有一个特征根的绝对值比 1 大, $j \rightarrow \infty$ 时, $G_j \rightarrow \infty$ 系统记忆性无限增强,预测值 $\hat{X}_t(l)$ 随着 l 的增大也趋于无穷。比如对如下一类 ARMA(1,1)系统,有

$$\begin{aligned}X_t - 1.2X_{t-1} &= a_t - \theta_1 a_{t-1} \\ \hat{X}_t(l) &= 1.2^{l-1}(1.2X_t - \theta_1 a_t) \\ &\rightarrow \infty \quad (l \rightarrow \infty)\end{aligned}$$

第三节 适时修正预测

实际中我们常常遇到这样的问题,以时刻 t 为原点进行向前预测,得到 $\hat{X}_t(1), \hat{X}_t(2), \hat{X}_t(3), \dots$,而当到了时刻 $t+1$ 的时候, X_{t+1} 已成为已知,对于 $t+2, t+3, \dots$ 时刻的预测我们还用原来的 $\hat{X}_t(2), \hat{X}_t(3), \dots$ 吗? 显然不能直接

利用而要加以修正,因为它们只利用了 t 时刻及以前的信息,并未利用 X_{t+1} ,而 X_{t+1} 才是最新的信息。当然我们可以 $t+1$ 为原点,再进行预测,得到 $\hat{X}_{t+1}(1), \hat{X}_{t+1}(2) \dots$ 。但是有没有更为方便的办法呢? 即能否对原来的预测 $\hat{X}_t(2), \hat{X}_t(3), \dots$ 加以利用呢? 答案是肯定的。

对于一个 ARMA 系统,由式(5.1.9)可得

$$\begin{aligned}\hat{X}_{t+1}(l) &= G_l a_{t+1} + G_{l+1} a_t + G_{l+2} a_{t-1} + \dots \\ \hat{X}_t(l+1) &= G_{l+1} a_t + G_{l+2} a_{t-1} + G_{l+3} a_{t-2} + \dots\end{aligned}$$

因而有

$$\hat{X}_{t+1}(l) = \hat{X}_t(l+1) + G_l a_{t+1}$$

其中 $a_{t+1} = X_{t+1} - \hat{X}_t(1)$ 。如果我们把 $t+1$ 时刻的观察值和预测值 $\hat{X}_{t+1}(l)$ 称为“新”的,而把 t 时刻的预测值 $\hat{X}_t(l+1)$ 称为旧的,则(5.19)式说明新的预测值可以由新的观察值(新息)和旧的预测值推算出来,即新的预测值是在旧的预测值基础上加一个修正项,而这一修正项比例于旧的一步预测误差,比例系数随预测超前步数而变化。这样,如果我们已经有了旧的预测结果,则在重新预测时只需要对旧的预测加以修正,而不必对全部数据重新计算,因为旧的预测值已经反映了过去的信息。通过这种修正大大减少了对数据的存储量,并提高了计算速度,有利于在计算机上实现。

例 5.3 对例 5.2,假设我们已知道观测值 $X_{251}(1) = Y_{251} - \bar{Y} = 3.0$, 试计算 $\hat{X}_{251}(1)$ 和 $\hat{X}_{251}(2)$ 。

$$\begin{aligned}a_{251} &= X_{251} - \hat{X}_{250}(1) \\ &= 3.0 - 2.787 \\ &= 0.213 \\ \hat{X}_{251}(1) &= \hat{X}_{250}(2) + G_1 a_{251} \\ &= 1.194 + 0.79 \times 0.213 \\ &= 1.362 \\ \hat{X}_{251}(2) &= \hat{X}_{250}(3) + G_2 a_{251} \\ &= 0.33 + 0.404 \times 0.213 \\ &= 0.416\end{aligned}$$

我们将以上结果用表 5.2 来表示。

表中每一列上面的数据,是在 $t=250$ 时进行的预测,下面的数据是当 $X_{251}=3.0$ 变为已知后对前边所进行预测的修正。当后边的 X_t 逐渐变为已知对可以利用此表不断地对以前的预测进行修正,得到最新的预测。

表 5.2 预测表

超前期 l	1	2	3	...
格林函数 G_l	0.79	0.404	0.145	
预测特性	$\hat{X}_{t-1}(1)$	$\hat{X}_{t-2}(2)$	$\hat{X}_{t-3}(3)$	
95%置信区间±	4.802	6.12	6.42	
t X_t a_t				
249 3.78				
原点 250 4.58				
251 3.00 0.213	2.787			
252	1.362	1.194		
253		0.416	0.33	
254			0.029	

第四节 指数平滑预测—ARMA 模型特例

式(5.2.3)告诉我们,超前 l 步的预测值实际上是 X_t 过去的观测值及部分预测值(超前 $1, 2, \dots, l-1$)的一种“平滑”,特别地,超前一步的预测值 $\hat{X}_t(1)$ 是 X_t, X_{t-1} 一种“平滑”,到此我们自然会想到一种在实际中应用非常广泛的经验预测方法:指数平滑预测。那么指数平滑预测与 ARMA 模型预测之间有没有什么联系呢?本节将考虑这一问题,我们将会看到:指数平滑预测是我们利用 ARMA 模型预测的一种特例。

一、指数平滑预测

指数平滑作为一种经验预测方法,已有许多学者对其作过研究,比如 Holt, Brown, Abraham 与 Ledolton, Horvey 等,提出了不少的计算方法:单指数平滑,双指数平滑, Holt 氏双参数平滑, Winters 氏相乘季节性指数平滑……,下面仅对较为简单的单指数平滑作一考察。

为了对一个序列进行预测,首先人们想到的是用该序列的平均数来代替。可是进一步分析,取所有资料的平均数又不尽合理。因为,离预测较远的资料对预测期的值可能没有影响,因而就产生了利用“移动平均数”折扣过去资料的思想。即选一个 N , N 的大小取决于我们想要研究多远的过去,并取最近 N 个观察值的平均数作为下一个观察值的预测值。

$$\hat{X}_t(1) = \frac{1}{N} \sum_{j=0}^{N-1} X_{t-j}$$

$$= \sum_{j=0}^{N-1} \frac{1}{N} X_{t-j}$$

即简单移动平均法。可见,这个预测值事实上是对 $X_t \sim X_{t-N+1}$ 给定一个相等的权数 $\frac{1}{N}$, 而对 X_{t-N} 及其以前的观察值给一个零权数的加权平均数。这种权数是不尽合理的,因为一般来说某一观察值对其后继行为的影响作用是逐渐衰减的,而不是一直为 $\frac{1}{N}$, 突然间为零。用系统动态性来说,平稳系统对它的过去值的记忆是衰减的。这样,就想到利用递减权数,而不用相等权数,使得时间越远,其权数越小。能满足这一条件就是指数权数,且其底的绝对值小于 1,即以 θ^j 为权数。由于 $|\theta| < 1$, 因而,随着 $j \rightarrow \infty, \theta^j \rightarrow 0$, θ 的大小,取决于我们想使权数以多快的速度缩减。如果 $|\theta| \rightarrow 1$, 则 θ^j 衰减缓慢,相反, $|\theta| \rightarrow 0$, 则 θ^j 衰减很快。

这样的话,预测则为

$$\hat{X}_t(1) = \sum_{j=0}^{\infty} \theta^j X_{t-j}$$

可是,这 $\hat{X}_t(1)$ 不再是个加权平均数了。因为加权平均数的权数之和为 1, 而现在

$$\sum_{j=0}^{\infty} \theta^j = \frac{1}{1-\theta}$$

显然,为了使预测值仍为一个加权平均数,不应该用 θ_j 为权数,而应用 $(1-\theta)\theta^j$ 为权数,这时

$$\sum_{j=0}^{\infty} (1-\theta)\theta^j = (1-\theta) \cdot \frac{1}{1-\theta} = 1$$

于是,预测公式应为

$$\hat{X}_t(1) = \sum_{j=0}^{\infty} (1-\theta)\theta^j X_{t-j}$$

这是一个著名的指数加权移动平均数(EWMA)。

若令 $\lambda = 1 - \theta$, 则上式变为

$$\hat{X}_t(1) = \sum_{j=0}^{\infty} \lambda(1-\lambda)^j X_{t-j}$$

这就是我们所熟悉的指数平滑式。因为运用上式的结果,得到的是一系列平滑平均数,而用的权数又是指数形式,故称之为指数平滑。若得到的不是加权平均数,即权数之和不等于 1 时,只能称作指数加权。

我们知道,指数平滑有两个极为重要的公式:

$$\hat{X}_t(1) = \lambda X_t + (1-\lambda) \hat{X}_{t-1}(1) \quad (5.4.1)$$

$$= \hat{X}_{t-1}(1) + \lambda [X_t - \hat{X}_{t-1}(1)] \quad (5.4.2)$$

(5.4.1)式,即为下期的预测值是本期实际与本期预测的加权平均数;

(5.4.2)式则用 λ 倍的预测误差来加以修正。

二、指数平滑与 ARMA 模型的关系

用指数平滑作一步预测,公式为

$$\hat{X}_t(1) = \sum_{j=0}^{\infty} \lambda(1-\lambda)^j X_{t-j}$$

如果预测误差为 a_{t+1} 的话,则有

$$X_{t+1} = \hat{X}_t(1) + a_{t+1}$$

$$= \sum_{j=0}^{\infty} \lambda(1-\lambda)^j X_{t-j} + a_{t+1}$$

若在 $t-1$ 时刻预测,则

$$X_t = \sum_{j=1}^{\infty} \lambda(1-\lambda)^{j-1} X_{t-j} + a_t$$

我们不难发现,上式很象一个 ARMA 模型的逆转形式,该模型具有逆函数

$$I_j = \lambda(1-\lambda)^{j-1}$$

若令 $1-\lambda=\theta, \lambda=1-\theta$, 则

$$I_j = (1-\theta)\theta^{j-1}$$

而这正是模型 $X_t - X_{t-1} = a_t - \theta a_{t-1}$ 的逆函数。反过来,若用该模型的逆转形式进行预测,由式(5.2.2)可得

$$\begin{aligned} \hat{X}_t(1) &= \sum_{j=1}^{\infty} I_j E(X_{t+1-j}) \\ &= \sum_{j=1}^{\infty} (1-\theta)\theta^{j-1} (X_{t+1-j}) \\ &= \sum_{j=0}^{\infty} (1-\theta)\theta^j X_{t-j} \\ &= \sum_{j=0}^{\infty} \lambda(1-\lambda)^j X_{t-j} \end{aligned}$$

这与指数平滑预测是一致的,可见指数平滑预测是 ARMA 模型在 $n=m=1$ 且 $\varphi_1=1$ 时的特殊情况,模型参数 θ_1 与平滑常数之和为 1。因此,只有当观察资料适合于 $\varphi_1=1$ 的 ARMA(1,1)模型时,可以用指数平滑进行较好的预测,预

测的平滑常数 $\lambda=1-\theta$, 这也给出了求平滑常数的一种科学方法。实际中当我们判断出某资料适合 φ_1 接近于 1 的 ARMA(1,1) 模型时就可以用指数平滑来预测并取平滑常数为 $1-\theta_1$, 否则应用一个更好的 ARMA 模型来预测。

上面探讨了单指数平滑与 ARMA 模型的关系, 其它的指数平滑法与 ARIMA 模型也有类似的各种关系, 本书不予详述, 可参考有关资料。

思考与练习

5.1 对模型 $(1-0.6B)X_t = a_t - 0.5a_{t-1}$ 表示出超前期 $l=1$ 和 $l=2$ 的预测。

- (a) 用差分方程形式;
- (b) 用格林函数形式;
- (c) 用逆转形式。

5.2 对于 ARMA(2,1) 模型

$X_t - X_{t-1} + 0.3X_{t-2} = a_t + 0.4a_{t-1}$, $a_t \sim \text{NID}(0, 256)$, 给定 $X_{t-5} = 34$, $X_{t-4} = 36$,

$X_{t-3} = X_{t-2} = 1$, $X_{t-1} = -16$, $X_t = -35$, 并假定 $a_{t-4} = 0$

- (a) 计算 $\hat{X}_t(l)$ ($l=1, 2, 3, 4$) 及 95% 的概率限;
- (b) 给定 $X_{t+1} = -37$, 修正 $\hat{X}_t(l)$ ($l=2, 3, 4$)。

5.3 现有一个 $N=100$ 的观测值序列适合 AR(2) 模型:

$$X_t = 0.5X_{t-1} - 0.5X_{t-2} + a_t$$

又知 $X_{100} = 0.8$, $X_{99} = 1.8$, $\hat{X}_{100}(1)$ 的 95% 的置信区间为 $(-1.5, 0.5)$

- (a) 求 $\hat{X}_{100}(2)$, $\hat{X}_{100}(3)$;
- (b) 如果 $X_{101} = 0$, 修正上面的预测。

5.4 说明是否可能有一个 ARMA 模型, 其特征根 $|\lambda_i| \leq 1$, 且 X_t 的均值为零, 当 $l \rightarrow \infty$ 时的 $\hat{X}_t(l)$ 可以

- (a) 趋于零;
- (b) 趋于常量;
- (c) 趋于无穷。

对于这些情况, 你若认为可能, 试举一例。若认为不可能, 请说明原因。

5.5 (a) 对以下 ARMA(1,1) 模型

$$X_t - X_{t-1} = (1 - \theta_1 B)a_t$$

导出预测公式

$$\hat{X}_t(l) = \hat{X}_{t-1}(l) + \lambda[X_t - \hat{X}_{t-1}(l)]$$

其中 $\lambda = 1 - \theta_1$

- (b) 对于这个模型, 给定 $X_{t-3} = 457$, $X_{t-2} = 452$, $X_{t-1} = 459$, $X_t = 462$, $\lambda = 0.9$, 求 $\hat{X}_t(l)$, $l=1, 2, 3$ 。

些较为特殊的非平稳性。

第一节 非平稳性的检验

判断一个序列是否平稳,严格来讲,要看其在不同时刻的分布函数是否完全一致。如果将条件再放宽些,则要看其一、二阶矩是否与时间的变化无关。我们常常是从平稳性的直观意义出发或利用间接反推的方法来判断序列的平稳性。对判断出的非平稳性还需结合具体系统的机理来分析。因为特征根 λ_i 是根据样本数据计算出来的。 $|\lambda_i| \geq 1$,说明样本数据存在非平稳趋势或周期性。但这种趋势或周期性不一定就体现为确定性趋势或周期性,也可能是由于系统的随机性而产生的随机趋势或周期性。显然随机趋势和确定性趋势对系统行为的影响是不同的:确定性趋势将固定地对系统起作用,因而系统必然是非平稳的;如果是随机趋势,则该趋势或周期性仅属系统在特定时间范围内的特性,从总体来看,系统并不具有这种特性,因而系统仍是平稳的。

下面介绍几种较为简单的方法:

一、数据图检验法

该法是在 $t-X_t$ 平面直角坐标系中将所研究的时间序列绘成连线图,观




图 6.1 上证所综合指数数据图

察其是否存在趋势性或周期性。若无明显的趋势性或周期性,就认为序列是平稳的。这种方法具有简单、直观、运用方便等优点,但是对图形的观察要靠实际经验,并且带有很强的主观意识,往往不同的分析者会得出不同的结论。

例 6.1 图 6.1 是 1996 年 5 月 20 至 1996 年 9 月 27 日上海证券交易所每日收盘的综合指数数据图,共 93 个数据(见附录)。

从图中可以看出,数据具有一定的上升趋势,周期性不很明显,可以初步断定序列是非平稳的。

二、自相关、偏自相关函数检验法




图 6.2 相关函数图

从第三章我们知道,一个零均值平稳序列的自相关函数和偏自相关函数要么是截尾的,要么是拖尾的。因此,如果一个序列零均值化以后的自相关函数或偏自相关函数既不截尾,又不拖尾,则可以断定该序列是非平稳的。比如自相关函数或偏自相关函数出现了缓慢衰减或周期性的衰减的情况,则说明序列可能存在某种趋势或周期性。

图 6.2 是例 6.1 中序列的自相关与偏自相关函数图,可以看出偏自相关函数是截尾的,但自相关函数缓慢衰减,这说明序列存在一定的非平稳性。

三、特征根检验法

这种方法是先拟合序列的适应模型,然后求由该适应模型的参数组成的特征方程的特征根,若所有的特征根 λ_i 都满足平稳性条件,即

$$|\lambda_i| < 1$$

则可以认为该序列是平稳的,否则该序列就是非平稳的。

四、参数检验法

从第三章我们知道,系统的平稳性条件既可以用特征根表示,也可以用模型的自回归参数表示。因此,要检验一个系统的稳定性,可以先拟合适应的模型,然后再根据求出的自回归参数来检验。首先要用自回归参数构造一个列阵如下:

行	参 数					
1	φ_0	φ_1	φ_2	...		φ_n
2	φ_n	φ_{n-1}	φ_{n-2}	...		φ_0
3	a_0	a_1	a_2	...		a_{n-1}
4	a_{n-1}	a_{n-2}	a_{n-3}	...		a_0
5	b_0	b_1	b_2	...	b_{n-2}	
6	b_{n-2}	b_{n-3}	b_{n-4}	...	b_0	
...	...	...	...	...	...	...
$2n-3$	l_0	l_1	l_2			

其中 $\varphi_0 = -1$, 第一行其余元素是模型的自回归参数,第二行是第一行的逆排列;第三行元素分别为:

$$a_i = \begin{vmatrix} \varphi_0 & \varphi_{n-i} \\ \varphi_n & \varphi_i \end{vmatrix} = \varphi_0 \varphi_i - \varphi_n \varphi_{n-i} \quad i=0,1,2,\dots,n-1$$

求 a_i 的行列式中第一列为上边列阵中由第 1、2 行组成的子阵的第一列,第二列为子阵的倒数第 i 列。第四行元素是第三行元素的逆排列,同理,第五行元

素分别为：

$$b_i = \begin{vmatrix} a_0 & a_{n-1-i} \\ a_{n-1} & a_i \end{vmatrix} \\ = a_0 a_i - a_{n-1} a_{n-1-i} \quad i=0,1,2,\cdots,n-2$$

第六行元素是第五行元素的逆排列。依次类推，直到第 $2n-3$ 行时，只剩下三个元素，当且仅当满足下述三个条件时，序列才是平稳的：

$$\begin{aligned} (1) \quad & \varphi_1 + \varphi_2 + \varphi_3 + \cdots + \varphi_n < 1 \\ (2) \quad & -\varphi_1 + \varphi_2 - \varphi_3 + \cdots + (-1)^n \varphi_n < 1 \\ (3) \quad & |\varphi_n| < |\varphi_0|, \quad |a_{n-1}| < |a_0| \\ & |b_{n-2}| < |b_0| \\ & \cdots \cdots \\ & |l_2| < |l_0| \end{aligned} \tag{6.1.1}$$

特别地，当 $n=2$ 时，以上条件变为：

$$\begin{aligned} (1) \quad & \varphi_1 + \varphi_2 < 1 \\ (2) \quad & \varphi_2 - \varphi_1 < 1 \\ (3) \quad & |\varphi_2| < 1 \end{aligned} \tag{6.1.2}$$

即为第三章讨论的 $ARMA(2,m)$ 系统的平稳性条件。

例 6.2 对某序列拟合的适应模型为

$$X_t - 2X_{t-1} + 0.6X_{t-2} - 0.2X_{t-3} = a_t - 0.6a_{t-1} - 0.5a_{t-2}$$

试检验该序列的平稳性。

解： $\varphi_1=2, \quad \varphi_2=-0.6, \quad \varphi_3=0.2, \quad n=3$

可构造列阵如下：

行	参 数			
1	-1	2	-0.6	0.2
2	0.2	-0.6	2	-1
3	0.96	-1.88	0.2	

第三行计算如下：

$$\begin{aligned} l_0 = a_0 &= \begin{vmatrix} -1 & 2 \\ 0.2 & -1 \end{vmatrix} = 0.96 \\ l_1 = a_1 &= \begin{vmatrix} -1 & -0.6 \\ 0.2 & 2 \end{vmatrix} = -1.88 \\ l_2 = a_2 &= \begin{vmatrix} -1 & 2 \\ 0.2 & -0.6 \end{vmatrix} = 0.2 \end{aligned}$$

检验条件(6.1.1):

$$\varphi_1 + \varphi_2 + \varphi_3 = 2 - 0.6 + 0.2 = 1.6 > 1$$

第一条不满足,因此没有必要再往下检验,可以断定该序列是非平稳的。

五、逆序检验法

逆序检验法可以检验出均值或方差可能存在的某种趋势,下面介绍这种方法的一般步骤。

首先,由时间序列求出一个大致不相关的均值或方差值的序列。具体地可以将整个序列分成 M 段,然后求出每段数据按时间平均的均值和方差,设所得序列为 $y_1, y_2, \dots, y_M$ 。

第二步,计算均值序列(或方差序列)的逆序总数。对于 $y_i (i=1, 2, \dots, M-1)$ 来说,若后边有一个值大于它,即 $y_j (j>i)$,则称为一个逆序,记 y_i 的逆序数为 A_i (即后边有 A_i 个值大于它),逆序总数为

$$A = \sum_{i=1}^{M-1} A_i$$

例如有序列:7,5,8,9。对7而言,有两个值8和9大于它,则 $A_1=2$,同理 $A_2=2, A_3=1$,逆序总数 $A=A_1+A_2+A_3=5$ 。

第三步,计算统计量进行统计检验。

可以证明,一个随机序列的逆序总数 A 具有以下的期望和方差:

$$E(A) = \frac{1}{4}M(M-1) \quad (6.1.3)$$

$$D(A) = \frac{M(2M^2+3M-5)}{72} \quad (6.1.4)$$

其中, M 为数据个数,并且统计量

$$Z = \frac{\left[A + \frac{1}{2} - E(A)\right]}{\sqrt{D(A)}} \quad (6.1.5)$$

渐近服从于 $N(0,1)$ 分布。因此,对于均值(或方差)序列 $y_1, y_2, \dots, y_M$ 可以依据以上三式求出统计量 Z 的值,在显著性水平 $\alpha=0.05$ 情况下,若 $|Z| < 1.96$,则认为序列无明显的趋势,否则认为序列是非平稳的。显然, A 过大,则表明序列有上升的趋势;而 A 过小,表明序列有下降趋势。

逆序检验法在检验序列是否存在单调趋势方面是有效的,比如图 6.3 所示的情形。但在有些情况下具有局限性,例如图 6.4 所示的情形,在序列的前一部分,逆序数较多(少)而在后一部分逆序数较少(多),而逆序数总数的检验却可能是

正常的,这种情况下,逆序检验是无效的,须结合其它方法作进一步检验。




图 6.3 趋势变化图




图 6.4 趋势变化图

例 6.3 判断例 6.1 中序列的平稳性。

该序列共 93 个数据,将其分为 12 段,前 9 段每段 8 个数据,后三段每段 7 个数据,可得均值序列如下:

656.43	682.94	773.76	787.89	798.80	842.53
844.41	871.93	815.95	803.99	774.03	818.16

逆序总数为

$$\begin{aligned}
 A &= \sum_{i=1}^{11} A_i \\
 &= 11 + 10 + 9 + 7 + 6 + 2 + 1 + 0 + 1 + 1 + 1 \\
 &= 49
 \end{aligned}$$

由 (6.1.3) 和 (6.1.4) 可得

$$\begin{aligned}
 E(A) &= \frac{1}{4} \times 12(12-1) \\
 &= 33
 \end{aligned}$$

$$D(A) = \frac{1}{72} [12 \times (2 \times 12^2 + 3 \times 12 - 5)]$$

$$=53.17$$

因而

$$Z = \frac{49 + \frac{1}{2} - 33}{\sqrt{53.17}} = 2.26 > 1.96$$

故序列有一定上升趋势,是非平稳的。

六、游程检验法

1. 游程

设序列 X_t 的均值为 $\bar{X}$, 对序列中比 $\bar{X}$ 小的观察值记“—”号, 其余的记“+”号, 这样相应于原序列就可得到一个符号序列。在记号序列中每一段连续的记号序列就叫做一个游程。比如, 有如下序列 N_t :

5 6 6 9 5 6 4 8 3 8

其平均数 $\bar{X}=6$, 则相应的记号序列为

— + + + — + — + — +

共有 8 个游程。

2. 游程检验法的基本思想

作为一个随机平稳序列, 各观察值应在均值附近随机波动, 因而高于平均数或低于平均数的变化应该适当。如果游程太少, 则观察值连续高于或低于平均数。这说明序列中可能存在某种趋势性或周期性波动; 例如, 作为一种极端情形, 设有如下序列:

1 2 3 4 5 6 7 8 9

其均值为 $\bar{X}=5$ 。容易看出该序列只有两个游程显然存在着趋势性。同样, 如果游程太多, 也可能存在某种趋势。如 n 个数据有 n 个游程, 说明序列中存在着此小彼大, 此大彼小的必然趋势。那么, 究竟游程数为多少才算适当? 这是一个统计规律, 因而需要统计检验来回答。

3. 游程检验

设序列长度为 N , $N=N_1+N_2$, N_1 和 N_2 分别是记号序列中“+”与“—”出现的次数, 游程总数为 r 。对于随机序列, 可以证明: 当 N_1 和 N_2 均不超过 15 (小样本) 时, 游程总数服从 r 分布

$$E(r) = \frac{2N_1N_2}{N} + 1 \quad (6.1.6)$$

$$D(r) = \frac{2N_1N_2(2N_1N_2 - N)}{N^2(N-1)} \quad (6.1.7)$$

当 N_1, N_2 大于 15(大样本)时,统计量

$$Z = \frac{r - E(r)}{\sqrt{D(r)}} \quad (6.1.8)$$

渐近服从于 $N(0,1)$ 分布。

因此,对所检验序列可以计算出统计量 r 或 Z ,在给定显著水平 α 下,若 $r_L < r < r_U$ (r_L 和 r_U 为 r 的上限和下限,可查附表 5 得到)或 $|Z| < 1.96$,则认为序列是平稳的,否则,序列是非平稳的。

例 6.4 判断上面 N_t 序列平稳性。

$$N_1 = 4, N_2 = 6, r = 8$$

取 $\alpha = 0.05$,查 r 分布表可得 $r_L = 2, r_U = 9$,而 $r_L < r < r_U$,故可以认为序列是平稳的。

例 6.5 判断例 6.1 中序列的平稳性。

$$\text{该序列有 } N = 93, N_1 = 56, N_2 = 37, r = 10$$

$$\begin{aligned} \mu_r &= \frac{2N_1N_2}{N} + 1 \\ &= \frac{2 \times 56 \times 37}{93} + 1 \\ &= 45.56 \\ \sigma_r &= \sqrt{\frac{2N_1N_2 \times (2N_1N_2 - N)}{N^2(N-1)}} \\ &= \sqrt{\frac{2 \times 56 \times 37 \times (2 \times 56 \times 37 - 93)}{93^2(93-1)}} = 4.6 \\ Z &= \frac{r - \mu_r}{\sigma_r} = \frac{10 - 45.56}{4.6} = -7.73 \end{aligned}$$

在显著性水平 $\alpha = 0.05$ 时, $Z = -7.73$,超出了临界值 ± 1.96 的范围,故该序列是非平稳的。

第二节 平稳化方法

由于序列非平稳性表现的多样性和复杂性,平稳化的方法也是多种多样的。对于不同形式的非平稳性,应采取不同的平稳化方法。本节介绍三种常用的方法。

一、差分

在第二章我们已经接触到了差分的概念,下面将从实例出发,对其作进一步的分析。比如对某地 1984 年 2 月 1 日—8 月 18 日每天中午的温度值(见附录 III)序列 X_t ,做一次差分后记为 ∇X_t ,则




图 6.5 日温度及增量趋势图

$$\nabla X_t = X_t - X_{t-1} \quad (6.2.1)$$

序列如下:

t	1	2	3	4	5		199	200
X_t	-5.1	-10.1	-0.3	-1.1	-0.1		8.2	9.7
∇X_t		-5	9.8	-0.8	1		1.1	1.5

X_t 和 ∇X_t 的趋势图形如图 6.5 所示。可以看出 X_t 具有线性上升趋势, 而其差分后的序列 ∇X_t 则可以认为是稳定在零点附近。一般而言, 若某序列具有线性的趋势, 则可以通过对其进行一次差分而将线性趋势剔除掉(这一点从线性函数的性质是不难理解的), 然后对差分后的序列拟合 ARMA 模型进行分析与预测, 最后再通过差分的反运算得到 X_t 的有关结果。由 (6.2.1) 式可得

$$X_t = \nabla X_t + X_{t-1}$$

因而

$$\hat{X}_t = \nabla \hat{X}_t + X_{t-1} \quad (6.2.2)$$

以上对 X_t 作一次差分称为一阶差分, 如果在一阶差分结果再进行差分, 则称为高阶差分, 差分的次数称为差分的阶, d 阶差分记为 $\nabla^d X_t$ 。例如对由模型 ARIMA(0, 2, 0) 产生的仿真序列 X_t 及一阶差分与二阶差分如图 6.6 所示。可以看出 X_t 具有二次抛物线趋势, ∇X_t 具有一次线性趋势, 而 $\nabla^2 X_t$ 则可以认为是平稳的序列。一般而言, 若序列 X_t 具有二次趋势, 则两次差分后可变换为平稳序列; 若序列 X_t 具有 d 次多项式趋势, 则通过 d 次差分后可变为平稳序列。下面讨论 X_t 与 $\nabla^d X_t = W_t$ 的关系。

当 $d=2$ 时, 有

$$\begin{aligned} W_t &= \nabla^2 X_t \\ &= \nabla X_t - \nabla X_{t-1} \\ &= (X_t - X_{t-1}) - (X_{t-1} - X_{t-2}) \\ &= X_t - 2X_{t-1} + X_{t-2} \end{aligned}$$

因而

$$X_t = W_t + 2X_{t-1} - X_{t-2} \quad (6.2.3)$$

一般有

$$\begin{aligned} W_t &= \nabla^d X_t \\ &= (1-B)^d X_t \\ &= [1 + \sum_{k=1}^d (-1)^k C_d^k B^k] X_t \end{aligned}$$




图 6.6 ARIMA(0,2,0)仿真序列及其差分

因而

$$X_t = W_t - \sum_{k=1}^d (-1)^k C_d^k X_{t-k} \quad (6.2.4)$$

其中 $C_d^k = \frac{d!}{k! (d-k)!}$ 。

二、季节差分

反映经济现象的序列,不少都具有周期性,例如,刚收获的小麦,由于供应充足,价格一般是较低的,然后随着供应量的减少,价格会逐渐上涨,直至下一个收获季节又重新开始这一周期。设 X_t 为一含有周期为 S 的周期性波动序列,则 $X_t, X_{t+S}, X_{t+2S}, \dots$ 为各相应周期点的数值,它们则表现出非常相近或呈现某一趋势的特征,如果把每一观察值同下一周期相应时刻的观察值相减,这就叫季节差分,它可以消除周期性的影响。季节差分常用 ∇_s 表示, $\nabla_s X_t = X_t - X_{t-S}$, 其中 S 为周期。

例 6.6 某市 1985 年—1993 年各月工业生产总产值(数据见附录)如图 6.7 所示,可以看出 Z_t 具有明显的周期性,做一次差分, $Y_t = Z_t - Z_{t-12}$, Y_t 如图 4.10 所示,周期性明显被消除掉。对 Y_t 的建模过程及结果详见例 4.2,下面我们利用模型对 1994 年的工业生产总产值作一预测。




图 6.7 工业生产总产值数据图

我们以 1993 年 12 月份为原点向前作 1—12 期的预测。首先由模型 $X_t - 0.40X_{t-1} - 0.12X_{t-2} = a_t$ 进行预测,再将 X_t 的预测结果转化为 Y_t 的预测结果,进而转化为 Z_t 的预测结果,详见表 6.1,并见图 6.8,除过 1994 年 2 月的预测误差较大以外,其余的预测相对误差均在 5% 以内,可以说模型的预测效果是不错的。

表 6.1 例 6.6 预测结果表

向前步数	时期 t	$\hat{X}_t$	$\hat{Y}_t$ $=\hat{X}_t+1.509$	$\hat{Z}_t$ $=\hat{Y}_t+Z_{t-12}$	实际值 Z_t	相对误差(%)
1	1994.1	0.799	2.308	21.92	20.99	4.4
2	1994.2	0.574	2.083	19.23	17.04	12.9
3	1994.3	0.326	1.836	24.30	23.16	4.9
4	1994.4	0.201	1.710	24.90	24.96	-0.2
5	1994.5	0.120	1.629	25.03	26.20	-4.5
6	1994.6	0.073	1.581	27.84	27.89	-0.2
7	1994.7	0.043	1.552	24.46	24.77	-1.2
8	1994.8	0.026	1.535	25.57	26.32	-2.7
9	1994.9	0.015	1.524	25.46	26.75	-4.8
10	1994.10	0.010	1.518	25.64	26.51	-3.3
11	1994.11	0.005	1.514	27.38	28.57	-4.1
12	1994.12	0.003	1.512	29.76	31.14	-4.4




图 6.8 例 6.6 预测图

三、对数变换与差分运算的结合运用

如果序列 X_t 含有指数趋势, 则可以通过取对数将指数趋势转化为线性趋势, 然后再进行差分以消除线性趋势。图 6.9 是我国 1952—1994 年社会消费品零售总额(见附录)数据图。可以看出, 有一定指数趋势。取对数后如图 6.10(a)所示, 具有明显的非线性增长趋势, 前期和后期增长速度较快, 而中期





图 6.9 我国 1952—1994 年社会消费品零售总额







图 6.10 $\ln Y_t$ 、 $\nabla \ln Y_t$ 、 $\nabla^2 \ln Y_t$

稍慢。一阶差分后如图 6.10(b)所示,前期和后期数据偏大,而中期稍小,具有一定的非平稳性。二阶差分后如图 6.10(c)所示, $\nabla^2 \ln(Y_t)$ 基本平稳。

第三节 齐次非平稳序列模型

一、齐次非平稳

在除去局部水平或趋势以外,某些非平稳时间序列显示出一定的同质性,即序列的某一部分与任何其它部分极其相似。这样的序列往往经过若干次差分后可转化为平稳序列,这种非平稳性称为齐次非平稳性,差分的次数称为齐次性的阶。实际中较为常见的是一阶和二阶的齐次非平稳性,表现为两种情形:第一种是序列呈现出水平非平稳性,除了局部水平不同,序列是同质的,也就是说序列的一部分和其它部分非常相似,只是在垂直方向上位置不同。这样的序列经过一次差分后可转化为平稳序列,前边提到的温度序列(图 6.5(a))就属于这种情形。第二种是序列呈现出水平和斜率的非平稳性,序列既没有固定的水平,也没有固定的斜率,除此之外,序列是同质的,这样的序列经过两次差分后可转化为平稳序列,前边提到的仿真序列(图 6.6(a))和我国社会消费品零售总额取对数后数据序列(图 6.10(a))就属于这种情形。

二、ARIMA 模型

对于 d 阶齐次非平稳序列 X_t 而言, $\nabla^d X_t$ 是一个平稳序列,设其适合 ARMA(n, m)模型,即

$$\Phi(B)(\nabla^d X_t) = \Theta(B)a_t \quad (6.3.1)$$

或者

$$\Phi(B)(1-B)^d X_t = \Theta(B)a_t$$

其中 $\Phi(B) = 1 - \varphi_1 B - \varphi_2 B^2 - \dots - \varphi_n B^n$

$$\Theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_m B^m$$

称模型 (6.3.1) 为求和自回归滑动平均模型 (Integrated Autoregressive Moving Average Model), 简记为 ARIMA(n, d, m), 其中 n, d, m 分别表示自回归阶数、差分阶数和移动平均阶数。之所以称为求和自回归滑动平均模型, 是因为差分的反运算即为求和运算。常见的 ARIMA 模型有以下几种:

1. ARIMA(0, 1, 1)

$$(1-B)X_t = (1-\theta_1 B)a_t \quad (6.3.2)$$

即

$$X_t - X_{t-1} = a_t - \theta_1 a_{t-1}$$

这就是说, X_t 是 1 阶齐次非平稳序列, 一次差分后适合 MA(1) 模型, 值得注意的是, 不能认为 X_t 是平稳 ARMA(1,1) 序列, 因为其特征根 $\lambda=1$, 不在单位圆内。

该模型可以用来描述经济学方面常用的理性预期模型:

$$X_t = X_t^* + a_t \quad (6.3.3)$$

上式中 X_t^* 为对 X_t 的理性预期, 即假定实际观察值是理性预期 X_t^* 和误差 a_t 的结合。而理性预期是通过对前期预期用其误差调整而形成的, 即

$$\begin{aligned} X_t^* &= X_{t-1}^* + \alpha(X_{t-1} - X_{t-1}^*) \\ &= X_{t-1}^* + \alpha a_{t-1} \end{aligned} \quad (6.3.4)$$

二式结合起来, 有

$$\begin{aligned} X_t &= X_{t-1}^* + \alpha a_{t-1} + a_t \\ &= (X_{t-1} - a_{t-1}) + \alpha a_{t-1} + a_t \\ &= X_{t-1} + a_t - (1-\alpha)a_{t-1} \end{aligned}$$

即

$$X_t - X_{t-1} = a_t - (1-\alpha)a_{t-1}$$

显然是一个 ARIMA(0,1,1) 模型, 其中 $\theta_1 = 1-\alpha$ 。这说明由理性预期模型导出的结构关系式, 可以用 ARIMA 模型来表达, 这就为理性预期模型找到了理论基础, 也为误差调整参数 α 的选取提供了科学的方法。

2. ARIMA(0,2,2)

$$(1-B)^2 X_t = (1-\theta_1 B - \theta_2 B^2) a_t \quad (6.3.5)$$

即序列 X_t 两次差分后适合 MA(2) 模型。

3. ARIMA(1,1,1)

$$(1-\varphi_1 B)[(1-B)X_t] = (1-\theta_1 B)a_t \quad (6.3.6)$$

即 X_t 经一次差分适合 ARMA(1,1) 模型。

三、ARMA(n, m) 与 ARIMA(n, d, m) 的区别与联系

很显然当 $d=0$ 时, ARIMA(n, d, m) 模型就是 ARMA 模型, 可见 ARMA(n, m) 和 ARIMA(n, d, m) 的区别就在于 d 是否等于零, 即序列是否平稳, 前者是平稳模型, 后者是非平稳模型。另一方面, 任一 ARIMA 模型展开后, 从形式看颇像一个 ARMA 模型, 但是可以验证其参数并不满足稳定性条件, 比如 (6.3.6) 展开为

$$X_t - (1+\varphi_1)X_{t-1} + \varphi_1 X_{t-2} = a_t - \theta_1 a_{t-1}$$

形式为 ARMA(2,1), 但其自回归参数和为 $(1+\varphi_1) - \varphi_1 = 1$, 不满足稳定性条

件,这就说明不论序列是否平稳,我们总可以从形式上拟合适应的ARMA模型。事实上,在本章第一节平稳性检验中,我们就是对序列先拟合适应的ARMA模型,再由自回归参数断定序列的平稳性的。

到此,读者也许会问,能否对一些非平稳的序列直接拟合ARMA模型的形式进行分析与预测呢?答案是肯定的。Pandit, S. M 和 Wu, S. M 等“不鼓励在建模前对数据使用这类算子以便把一个看来是非平稳的或不平稳的序列




图 6.11 日温度增量序列的自相关和偏自相关函数

简化为一个认为更易建模的,明显平稳的稳定序列。”^[2]

例 6.7 对前面提到的温度值序列建模。

从图 6.5 可以看出,原序列 X_t 具有上升趋势,经一次差分后平稳。 ∇X_t 的自相关及偏自相关函数如图 6.11 所示,偏自相关函数是拖尾的,自相关函数在两期后截尾,因此,可初步确定 ∇X_t 的适应模型为 MA(2)。F 检验表明 MA(3)与 MA(2)没有显著差异,模型阶数没有升高的必要,残差自相关(图 6.12)表明 MA(2)是 ∇X_t 的适应模型。因而 X_t 的适应模型为 ARIMA(0,1,2),即

$$(1-B)X_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2}$$

参数估计为

$$\hat{\theta}_1 = 0.18 \pm 0.14$$

$$\hat{\theta}_2 = 0.25 \pm 0.14$$

$$\hat{\sigma}_a = 2.36$$




图 6.12 日温度序列模型的残差相关

例 6.8 我们考虑 Box 与 Jenkins 1970 年研究的资料:化工生产过程中的浓度读数(见附录 III)。

图 6.13(a)为数据曲线图,有一定的升降趋势,图 6.13(b)为差分后的曲线图,升降趋势消失。图 6.14 为差分数据的自相关与偏自相关函数。可以看出有较大的差异,差分后的数据适合 MA(1)模型。经拟合与检验,数据的适应




图 6.13(a) 化工生产过程浓度数据图




图 6.13(b) 浓度数据差分图

模型为 $ARIMA(0,1,1)$, 即

$$X_t - X_{t-1} = a_t - \theta_1 a_{t-1}$$

参数估计为




图 6.14 浓度数据差分后的自相关与偏自相关函数图

$$\hat{\theta}_1 = 0.59 \pm 0.14, \quad \hat{\delta}_a = 0.3188$$

由于原序列的变化趋势并不是非常明显,我们也可以考虑对原序列直接建立 ARMA 模型,经过 Pandit-Wu 系统建模方法建模,最终的适应模型为 ARMA(1,1),即

$$(X_t - \mu) = \varphi_1(X_{t-1} - \mu) + a_t - \theta_1 a_{t-1}$$

参数估计为

$$\hat{\mu} = 17.10 \pm 0.39$$

$$\hat{\varphi}_1 = 0.89 \pm 0.18$$

$$\hat{\theta}_1 = 0.51 \pm 0.23$$

$$\hat{\sigma}_a = 0.3136$$

如果以残差的标准差为判断模型优劣的标准的话,直接建立 ARMA 模型要比差分后建模效果好些。事实上,ARMA 模型中的 $\hat{\varphi}_1$ 很接近于 1,差分相当于事先让 $\hat{\varphi}_1$ 取 1。

例 6.9 某车站 1993 年至 1997 年各月的列车运行数量数据如图 6.15 所示,从图中可以看出具有分段线性趋势,一次差分后得 X_t 如图 4.14 所示,对 X_t 的建模过程及结果详见例 4.3,即序列适合 ARIMA(0,1,3)或 ARIMA(2,1,1)(其中 $\varphi_1=0$)模型。




图 6.15 例 6.9 列车运行数量数据图

例 6.10 对我国社会消费品零售总额数据建模

$\nabla^2 \ln(Y_t)$ 的原序列 Y_t 如图 6.9 所示, $\ln(Y_t)$ 、 $\nabla \ln(Y_t)$ 及 $\nabla^2 \ln(Y_t)$ 如图 6.10 所示, $\nabla^2 \ln(Y_t)$ 基本平稳,其自相关与偏自相关函数如图 6.16 所示,用低阶 ARMA 模型对其进行拟合,结果见表 6.2。AIC 值表明合适的模型为:

$$\nabla^2 \ln Y_t = X_t$$

$$X_t + 0.42X_{t-1} = a_t - 0.59a_{t-2}$$

残差自相关如图 6.17 所示,与图 6.16 相比,残差序列接近于白噪声序列。




图 6.16 $\nabla^2 \ln(Y_t)$ 的相关函数图




图 6.17 例 6.10 的残差自相关图

表 6.2 对 $\nabla^2 \ln Y_t$ 的建模结果

参 数	ARMA(2,2)	ARMA(2,1)	ARMA(2,1) $\varphi_1=0$	ARMA(1,2)
φ_1	-0.61 ± 0.50	-0.60 ± 0.62		-0.06 ± 0.73
φ_2	-0.002 ± 0.43	-0.43 ± 0.30	-0.31 ± 0.27	
θ_1	0.24 ± 0.60	0.29 ± 0.70	-0.43 ± 0.33	-0.40 ± 0.81
θ_2	-0.68 ± 0.59			-0.35 ± 0.47
残差平方和	0.147905	0.171069	0.172697	0.170555
残差方差	0.004226	0.00475	0.00467	0.00461
AIC 值	-5.271	-5.203	-5.270	-5.233
参 数	ARMA(1,2) $\theta_1=0$	ARMA(2,0)	ARMA(0,2)	ARMA(1,1)
φ_1	-0.42 ± 0.29	-0.37 ± 0.29		0.45 ± 0.68
φ_2		-0.38 ± 0.28		
θ_1			-0.37 ± 0.31	-0.87 ± 0.81
θ_2	-0.59 ± 0.36		-0.40 ± 0.32	
残差平方和	0.169589	0.174227	0.185930	0.178090
残差方差	0.00446	0.00471	0.00477	0.00469
AIC 值	-5.314	-5.261	-5.248	-5.265

第四节 非平稳时间序列的组合模型

本章开始我们已提到,一个非平稳序列可表示为

$$X_t = \mu_t + Y_t$$

其中 μ_t 是 X_t 随时间变化的均值,刻画非平稳序列中的确定性组成部分, Y_t 是一个平稳序列,可以拟合一个 ARMA 模型,描述 X_t 中的随机组成部分,具体的处理方法有两大类,前三节我们讨论了第一类处理方法,即设法消除确定性因素(长期趋势,周期趋势)的作用,然后对剩余序列拟合一个 ARMA 模型。本节将介绍第二类处理非平稳序列的方法,即从系统分析的观点出发,用确定性模型描述序列中确定性因素的变动规律,用 ARMA 模型刻画序列中随机因素的一般规律性,从而建立起确定性加随机的组合模型。在组合模型中既有确定部分,又有随机部分,因而用以描述某些类型的非平稳过程,往往能得到令人满意的效果。建立组合模型的基本方法,概括起来,有以下三个步骤:

1. 根据时间序列的特征,用一定的函数形式拟合序列的确定性组成部分,直至剩余序列平稳为止;
2. 对剩余序列拟合适应的 ARMA 模型;
3. 将分别拟合的确定性模型和 ARMA 模型结合起来并以其参数作为初始值,用非线性最小二乘法估计组合模型的参数,得到最终的组合模型。

一、确定性趋势的判定

为了拟合组合模型,首先要知道确定性因素的样式,怎样识别序列中存在某种确定性趋势呢?

最简单的方法是画出序列的趋势图,然后进行观察分析。例如对图 6.5 的温度数据曲线和图 6.18 的裂纹长度观测值曲线进行细致观察,可以看出有明显的线性上升趋势。

再一个方法就是根据特征根来判别。前面我们介绍平稳性检验时,已经提到过特征根检验法。即当所有特征根的绝对值均小于 1 时,序列是平稳的,否则就是非平稳的。事实上,特征根不仅告诉我们序列是否平稳,当不平稳时,它还告诉我们可能存在某种确定性趋势。因为格林函数决定了序列的具体模式。

1. 长期增减趋势的判定

如果存在绝对值接近于或者大于 1 的实特征根,则说明序列中可能存在




图 6.18 裂纹长度观测值

长期增减趋势,具体的有:

(1) 常数趋势

如果一个序列中存在着常数趋势,但是,由于系统的随机性,因而序列呈现在某一常数水平上下波动。对于这种系统来说,它在时刻 t 的响应,如果没有随机扰动的话,则它就等于其前一时刻的值 X_{t-1} ,即

$$X_t = X_{t-1}$$

但是由于扰动的作用,有

$$X_t = X_{t-1} + a_t$$

这个模型事实上是一个 $\varphi_1=1$ 的 AR(1),即 AR(1)的极限形式:随机走动。可见,对于 AR(1)系统来说,若 $\varphi_1 \rightarrow 1$,则序列中存在着常数趋势。从格林函数的形式来看, $G_j = \varphi_1^j = \lambda_1^j$,当 $\varphi_1 \rightarrow 1$ 时, $\lambda_1 \rightarrow 1$, $G_j \equiv 1$ 。那么,当 $\lambda_1 = -1$,即 $\varphi_1 = -1$,有

$$X_t = -X_{t-1} + a_t$$

这时

$$G_j = \varphi_1^j = (-1)^j = \begin{cases} 1, & j \text{ 为偶数} \\ -1, & j \text{ 为奇数} \end{cases}$$

事实上,这时系统响应为两个常数序列:

$$\begin{cases} X_t = X_{t-2} + a_t, & t \text{ 为偶数} \\ X_t = -X_{t-2} + a_t, & t \text{ 为奇数} \end{cases}$$

综上所述,当 $|\lambda_1| \rightarrow 1$ 时,系统可能存在常数趋势,因此,对于高阶模型来说,若其中有一个根(实数)的绝对值接近于1,则系统存在常数趋势。

(2) 线性趋势

前面我们曾经讨论了 ARMA(2,1)模型,当特征根 $\lambda_1 = \lambda_2 = 1$ 时,格林函数为

$$G_j = (1 - \theta_1)j + 1$$

X_t 可表示为

$$\begin{aligned} X_t &= \sum_{j=0}^{\infty} G_j a_{t-j} \\ &= \sum_{j=0}^{\infty} [(1 - \theta_1)j + 1] a_{t-j} \end{aligned}$$

这说明随着 j 的增大, X_t 以线性形式 $1 + (1 - \theta_1)j$ 而变化。可见,对于一个高阶模型,若其中有两个实特征根的绝对值接近于1时,序列中可能存在线性趋势,推而广之,若有三个实特征根的绝对值接近于1,序列中可能存在二次趋势...若有 $n+1$ 个实特征根的绝对值接近于1,则序列中可能存在 n 次多项式趋势,因而我们可以用一个

$$X_t = \beta_0 + \beta_1 t + \beta_2 t^2 + \cdots + \beta_n t^n + Y_t \quad (6.4.1)$$

来描述。

(3)若有 l 个绝对值大于1的实特征根,则序列中可能存在 l 个指数增减趋势。于是我们可以用

$$X_t = \sum_{j=1}^l R_j e^{r_j t} + Y_t \quad (6.4.2)$$

来拟合。

比如,若序列的合适模型为

$$X_t - 1.2X_{t-1} = a_t$$

特征根 $\lambda_1 = 1.2$,格林函数 $G_j = 1.2^j$, X_t 可表示为

$$X_t = \sum_{j=0}^{\infty} 1.2^j a_{t-j}$$

这说明随着 j 的增大, X_t 以指数形式 1.2^j 而变化。

2. 周期趋势的判定

如果存在绝对值接近于或大于1的复共轭根时,则序列中可能存在周期性波动规律。在第三章我们已对 ARMA(2,1)模型作过讨论。为了用一个数学函数来描述序列中存在的周期性变化部分,仅知道它存在周期性是不够的,还

必须进一步判明周期的长度。在这方面特征根同样能给我们提供有用的信息。下面我们通过 ARMA(2,1)模型来说明通过特征根来判别周期长度的理论依据及具体方法。我们先来看看存在不同周期时特征根的具体形式,对于 ARMA(2,1)模型来说,其特征方程为

$$\lambda^2 - \varphi_1 \lambda - \varphi_2 = 0 \quad (6.4.3)$$

因而,其特征根有关系式

$$\lambda_1, \lambda_2 = \frac{1}{2}(\varphi_1 \pm \sqrt{\varphi_1^2 + 4\varphi_2})$$

由于我们假设该序列有周期性,因而 λ_1 与 λ_2 必为复共轭,于是有

$$\begin{aligned} \lambda_1, \lambda_2 &= \frac{1}{2}(\varphi_1 \pm i \sqrt{-\varphi_1^2 - 4\varphi_2}) \\ &= \frac{1}{2} \sqrt{-\varphi_2} \left[\frac{\varphi_1}{\sqrt{-\varphi_2}} \pm i \frac{\sqrt{-\varphi_1^2 - 4\varphi_2}}{\sqrt{-\varphi_2}} \right] \\ &= r(\cos \omega \pm i \sin \omega) \end{aligned}$$




图 6.19

其中

$$\begin{aligned} r &= \sqrt{\left(\frac{1}{2}\varphi_1\right)^2 + \left(\frac{1}{2}\sqrt{-\varphi_1^2 - 4\varphi_2}\right)^2} \\ &= \sqrt{-\varphi_2} \end{aligned}$$

由图 6.19 可知

$$\cos \omega = \frac{\frac{1}{2}\varphi_1}{\sqrt{-\varphi_2}} = \frac{\varphi_1}{2\sqrt{-\varphi_2}} \quad (6.4.4)$$

(1) 周期为 12。

在这种情形下 $\omega = \frac{2\pi}{P} = \frac{2\pi}{12}$

因而

$$\cos \omega = \cos \left(\frac{2\pi}{12} \right) = \frac{\sqrt{3}}{2}$$

因此,有关系式

$$\frac{\varphi_1}{2\sqrt{-\varphi_2}} = \frac{\sqrt{3}}{2}$$

即

$$\varphi_1 = \frac{\sqrt{3}}{2} \times 2\sqrt{-\varphi_2} = \sqrt{3}$$

这时,我们不难求出特征根 λ_1 和 λ_2 的值,由关系式

$$\lambda_1 + \lambda_2 = \varphi_1 = \sqrt{3}$$

$$\lambda_1 \lambda_2 = -\varphi_2 = 1$$

于是有 $\lambda_1 = \sqrt{3} - \lambda_2$, 并代入第二关系式,得

$$(\sqrt{3} - \lambda_2)\lambda_2 = 1$$

即

$$\lambda_2^2 - \sqrt{3}\lambda_2 + 1 = 0$$

解此方程,得:

$$\lambda_2^{(1)}, \lambda_2^{(2)} = \frac{1}{2}(\sqrt{3} \pm \sqrt{3-4})$$

$$= \frac{\sqrt{3}}{2} \pm i0.5$$

$$= 0.866 \pm i0.500$$

$$\lambda_1^{(1)}, \lambda_1^{(2)} = \sqrt{3} - \lambda_2$$

$$= 0.866 \pm i0.500$$

即,特征方程(6.4.3)式的特征根为

$$\lambda_1^{(1)}, \lambda_2^{(1)} = 0.866 \pm i0.500$$

可见,当 ARMA(2,1)模型的一对复共轭根接近 $0.866 \pm i0.500$ 时,序列中可能存在周期为 12 的周期波动规律。那么,对于高阶模型来说,当特征根中有一对复共轭根接近于 $0.866 \pm i0.500$ 时,则序列中可能存在周期为 12 的周期性。这里, $0.866 \pm i0.500$ 是序列在周期为 12 时其特征根的理论值,在研究实际问题时,由于我们一般所拥有的是系统的一部分样本值,因而,我们不可能要求绝对等于,只要接近于理论值即可。

(2)周期为 6

这时 $\omega = \frac{2\pi}{6}$, 因而

$$\cos \omega = \cos \omega \left(\frac{2\pi}{6} \right) = \frac{1}{2}$$

根据(6.4.4)式,有关系式

$$\frac{\varphi_1}{2\sqrt{-\varphi_2}} = \frac{1}{2}$$

即

$$\varphi_1 = \frac{1}{2} \times 2\sqrt{-\varphi_2} = 1$$

类似地,有

$$\lambda_1 + \lambda_2 = 1$$

$$\lambda_1 \lambda_2 = 1$$

解此方程组,得特征根

$$\lambda_1, \lambda_2 = 0.500 \pm i0.866$$

可见,当 ARMA(2,1)模型的一对复共轭根接近 $0.500 \pm i0.866$ 时,序列可能有周期为 6 的周期波动规律。同样,对于高阶模型来说,若特征根中有一对复共轭根接近 $0.500 \pm i0.866$ 时,则说明系统(序列)可能存在周期为 6 的周期性。

(3)任意周期 P

显而易见,给定任意周期 P , ARMA(2,1)模型的自回归参数就唯一地确定了:

$$\varphi_2 = -1$$

$$\varphi_1 = 2\cos \frac{2\pi}{P}$$

从而特征根也被唯一地确定了:

$$\lambda_1, \lambda_2 = \frac{1}{2}(\varphi_1 \pm i\sqrt{\varphi_1^2 - 4\varphi_2}) \quad (6.4.5)$$

这说明含有周期波动的随机序列,其 ARMA 模型的特征方程的特征根与序列中的周期一一对应;给定周期长度,从而也就确定了一对复共轭特征根的值,反过来,一对绝对值等于 1 的复共轭特征根,确切地刻画了序列中周期波动规律的周期长度。因此,在实际应用中,如果某一对复共轭特征根的值,接近于周期为 P 的理论值,那么,我们就可以认为所研究的序列可能含有周期为 P 的周期波动规律。表 6.3 给出了一些典型周期所对应的特征根的理论值及其相应的算子,供学习和应用参考。

表 6.3 一些典型周期所对应的特征根及算子

周期 P	$\varphi_1 = 2\cos(\frac{2\pi}{P})$	算子: $1 - \varphi_1 B + B^2$	特征根: λ_1, λ_2
2	-2	$1 + 2B + B^2$	-1, -1
3	-1	$1 + 2B + B^2$	$-500 \pm i0.866$
4	0	$1 + B^2$	$\pm i$
5	0.618	$1 - 0.618B + B^2$	$0.039 \pm i0.951$
6	1.000	$1 - B + B^2$	$0.500 \pm i0.866$
7	1.247	$1 - 1.247B + B^2$	$0.624 \pm i0.782$
8	1.414	$1 - 1.414B + B^2$	$0.707 \pm i0.707$
9	1.532	$1 - 1.532B + B^2$	$0.766 \pm i0.463$
10	1.618	$1 - 1.618B + B^2$	$0.809 \pm i0.588$
12	1.732	$1 - 1.732B + B^2$	$0.866 \pm i0.500$
14	1.802	$1 - 1.802B + B^2$	$0.901 \pm i0.434$
15	1.827	$1 - 1.827B + B^2$	$0.914 \pm i0.407$
20	1.902	$1 - 1.902B + B^2$	$0.951 \pm i0.309$
21	1.911	$1 - 1.911B + B^2$	$0.956 \pm i0.295$
24	1.932	$1 - 1.932B + B^2$	$0.966 \pm i0.259$
25	1.937	$1 - 1.937B + B^2$	$0.969 \pm i0.249$
28	1.950	$1 - 1.950B + B^2$	$0.975 \pm i0.222$
30	1.956	$1 - 1.956B + B^2$	$0.978 \pm i0.209$
38	1.968	$1 - 1.968B + B^2$	$0.984 \pm i0.178$
50	1.984	$1 - 1.984B + B^2$	$0.992 \pm i0.126$
60	1.989	$1 - 1.989B + B^2$	$0.995 \pm i0.105$
∞	2.000	$1 - 2.000B + B^2$	1.000, 1.000

当我们已经确认序列中含有周期趋势且已判明周期长度以后,就可以拟合模型

$$X_t = B \sin(\omega t + \phi) + Y_t \quad (6.4.6)$$

其中

B ——刻画该周期波动的振幅

ϕ ——为该周期波动的相位

ω ——为该周期波动的频率

且

$$\omega = \frac{2\pi}{p} \quad (6.4.7)$$

这里 p 为周期, Y_t 为一个平稳序列。在用非线性最小方法估计(6.4.6)式中的参数时,估计 ϕ 是非常困难的。因而我将(6.4.6)式进行再参数化,即令

$C = \cos\phi$, 由于

$$\sin(A+B) = \sin A \cos B + \cos A \sin B$$

于是(6.4.6)式可表示为

$$\begin{aligned} X_t &= B[\sin(\omega t)\cos\phi + \cos(\omega t)\sin\phi] + Y_t \\ &= B[C\sin(\omega t) + \sqrt{1-C^2}\cos(\omega t)] + Y_t \end{aligned} \quad (6.4.8)$$

这就是常用的确定性加随机性季节时间序列模型。

在这个模型中, 事实上是假设序列 X_t 在同一水平上等幅周期性波动, 也就是说周期项没有增(减)趋势。当序列中的周期项存在某种增长(或减少)趋势时, (6.4.8)式不再是适应模型了。如果用 e^{bt} 表示其增(减)趋势, (6.4.6)式变为

$$X_t = Be^{bt}\sin(\omega t + \phi) + Y_t \quad (6.4.9)$$

相应的再参数化模型为

$$X_t = Be^{bt}[C\sin(\omega t) + \sqrt{1-C^2}\cos(\omega t)] + Y_t \quad (6.4.10)$$

式中, B 表示起始点的振幅, 当 $B=0$ 时, 说明波动的振幅为零, 因而不存在周期波动。 b 表示周期项振幅指数增(减)变化趋势的指数, 反映振幅增(减)率的快慢。 C 是相位角 ϕ 的余弦, 它控制周期循环的起始点。

(6.4.9)式描述的是仅含有一个周期的时间序列模型, 当序列除含有一个主周期之外, 还存在若干谐波的时候, (6.4.9)式变成

$$X_t = \sum_{j=1}^k B_j e^{b_j t} \sin(j\omega t + \phi_j) + Y_t \quad (6.4.11)$$

式中, k 为周期项及其谐波的个数。类似地, 相应于(6.4.11)式的再参数化模型为

$$X_t = \sum_{j=1}^k B_j e^{b_j t} [c_j \sin(j\omega t) + \sqrt{1-c_j^2} \cos(j\omega t)] + Y_t \quad (6.4.12)$$

二、组合模型的建立

当我们判明序列中存在的确定性趋势后, 就要用合适的函数形式来拟合确定性部分, 直到剩余序列平稳为止, 然后对剩余序列拟合适应的 $ARMA$ 模型, 最后建立起组合模型。

$$\begin{cases} X_t = f(t) + Y_t \\ Y_t = \varphi_1 Y_{t-1} + \varphi_2 Y_{t-2} + \cdots + \varphi_n Y_{t-n} + a_t - \theta_1 a_{t-1} - \cdots - \theta_m a_{t-m} \end{cases} \quad (6.4.13)$$

下面我们来看一个实例:

例 6.11 对 1946—1970 年美国各季生产者耐用品支出(见附录,数据取自文献[2])建模。




图 6.20 耐用品支出曲线图

图 6.20 为数据曲线图,可以看出具有指数上升趋势,因此,我们对确定性部分先拟合一个指数增长模型,即

$$X_t = \mu_t + Y_t$$

$$\mu_t = R_1 e^{r_1 t}$$

显然需要用非线性最小二乘估计,为了保证迭代能够很好地收敛,我们要赋予 R_1 和 r_1 初始值,由图 6.20 可以看出,指数曲线大致要过 (0,10) 点,因此可取 R_1 的初始值为 10,另外,当 $t=43$ 时, $X_t=27=R_1 \times e=10 \times 2.7$,此时 $r_1 t=1$,因此 $r_1=1/t=1/43=0.023$ 。故可取 r_1 的初始值为 0.023, TSP 输出的估计结果为

$$\hat{R}_1 = 11.650 \pm 0.359$$

$$\hat{r}_1 = 0.017 \pm 0.0004$$

剩余平方和为 953.95。剩余序列 Y_t 如图 6.21 所示,可以认为是平稳的。 Y_t 的自相关与偏自相关如图 6.22 所示,可初步断定 Y_t 的适应模型为 AR 模型,逐步增加 AR 模型阶数进行拟合,其残差方差图如图 6.23 所示,因此,合适的模型为 AR(2),即

$$Y_t = \varphi_1 Y_{t-1} + \varphi_2 Y_{t-2} + a_t$$




图 6.21 例 6.11 对 X_t 拟合指数模型后的剩余序列数据图

参数估计为

$$\hat{\varphi}_1 = 1.15 \pm 0.22$$

$$\hat{\varphi}_2 = -0.25 \pm 0.22$$

残差平方和为 149.70, 残差 a_t 的自相关表明模型是适应的。最后我们要以已估计出来的 $R_1, r_1, \varphi_1, \varphi_2$ 的值为初始值用非线性最小二乘法对模型参数进行整体估计, 模型整体可写为

$$\begin{aligned} X_t &= \mu_t + Y_t \\ &= R_1 e^{r_1 t} + \varphi_1 Y_{t-1} + \varphi_2 Y_{t-2} + a_t \\ &= R_1 e^{r_1 t} + \varphi_1 (X_{t-1} - R_1 e^{r_1 (t-1)}) + \varphi_2 (X_{t-2} - R_1 e^{r_1 (t-2)}) + a_t \end{aligned}$$

最终的参数整体估计为

$$\hat{R}_1 = 13.02 \pm 3.4$$

$$\hat{r}_1 = 0.016 \pm 0.003$$

$$\hat{\varphi}_1 = 1.15 \pm 0.23$$

$$\hat{\varphi}_2 = -0.246 \pm 0.226$$

残差平方和为 147.17, 残差自相关(如图 6.24 所示)表明整体模型是适应的。我们用所建的模型以 1970 年第 4 季度即 $t=100$ 为原点进行预测, 结果如表 6.4 所示。




图 6.22 对 X_t 拟合指数模型后的剩余序列的相关函数图

表 6.4 耐用品支出预测表

t	0	1	2	3	4	5	6	7	8
$t=100$	$t=100$	$t+1$	$t+2$	$t+3$	$t+4$	$t+5$	$t+6$	$t+7$	$t+8$
时期	70.4	71.1	71.2	71.3	71.4	72.1	72.2	72.3	72.4
$\hat{X}_t(t)$	62.1	61.8	62.7	64.0	65.4	66.8	68.1	69.5	70.8




图 6.23 残差方差图




图 6.24 拟合整体模型后的残差自相关图

对于周期趋势的组合模型,其模型结构和建模过程更为复杂,限于篇幅,本书不予举例,读者可参考其它资料。

思考与练习

- 6.1 用参数法检验例 4.4 中序列的平稳性。
- 6.2 用游程法检验习题 2.1 中序列的平稳性。
- 6.3 用逆序法检验例 6.5 中的温度值序列的平稳性。
- 6.4 对造纸过程入口开关调节器的观察值建模
(a) 直接拟合 ARMA 模型;
(b) 一阶差分后拟合 ARMA 模型。
(c) 对以上两种结果进行比较并提出自己的看法。
- 6.5 给定 $\mu(t) = Be^{bt}(C \sin \omega t + \sqrt{1-C^2} \cos \omega t)$, 其中 $B=10, b=-0.5, C=0.5$, 周期为 4, 绘出 $\mu(t)$ 的草图。
- 6.6 一个经济时间序列适应如下模型:
 $\nabla X_t = (1 - 1.0B + 0.5B^2)a_t, a_t \sim NID(0, 0.04)$
给定 $X_{48}=130, a_{47}=-0.3, a_{48}=0.2$,
计算 $\hat{X}_{48}(l), l=1, 2, 3, 4$ 。

季节性时间序列分析方法

周期点：一季度、二季度、三季度、四季度。 S 也可能取其它一些值，例如， $S = 7$ （星期因素）等。

上面所讨论的是在一个序列中只含有一种周期的简单情况，有的时间序列也可能同时含有长度不同的若干种周期。例如，对于客运资料来说，既含有 $S = 12$ 的周期，同时在月度内又含有 $S = 7$ 的周期。对于含有两种周期以上的时间序列，我们通常根据周期长度及其作用程度称之为主周期、谐波、次谐波等。

对于季节时间序列按周期进行重新排列是极为有益的，不仅有助于加理解序列的周期特性，而且对于形成建模思想和理解季节模型的结构也都是很有帮助的。

设序列存在规则的周期（比如，周期为 S ），如果我们把原序列按周期重新排列，即可得到一个所谓的二维表（Two - Way Table）（见表 7.1）。

例如，对于一个 $S = 12$ 的月份资料，按周期排列的二维表如表 7.2（假设序列的起始点为 1978 年 1 月）。

表 7.1 周期性资料的二维表

周 期 点	1	2	3	4	5	...	S
1	X_1	X_2	X_3	X_4	X_5	...	X_S
2	X_{S+1}	X_{S+2}	X_{S+3}	X_{S+4}	X_{S+5}	...	X_{2S}
3	X_{2S+1}	X_{2S+2}	X_{2S+3}	X_{2S+4}	X_{2S+5}	...	X_{3S}
4	X_{3S+1}	X_{3S+2}	X_{3S+3}	X_{3S+4}	X_{3S+5}	...	X_{4S}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

表 7.2 月份资料的二维表 ($S = 12$)

周 期 点	1	2	3	4	...	12
1978	X_1	X_2	X_3	X_4	...	X_{12}
1979	X_{13}	X_{14}	X_{15}	X_{16}	...	X_{24}
1980	X_{25}	X_{26}	X_{27}	X_{28}	...	X_{36}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

二、随机季节模型

在确定性时序分析中，常用的处理方法是对季节时间序列的季节分量拟合一个三角函数模型或求一个固定的季节指数。随机季节模型，是对季节性随

机序列中不同周期的同一周期点之间的相关关系的拟合。如周期为 12 个月的月份资料,就是研究不同年份的同一个月份的观察值之间的记忆性。显然和一般的一阶自回归模型

$$X_t = \varphi_1 X_{t-1} + a_t$$

相类似,若将 $(1 - B^S)^D X_t$ 记作 W_t , 则一阶自回归季节模型为

$$W_t = \varphi_1 W_{t-S} + e_t \quad (7.1.1)$$

或

$$(1 - \varphi_1 B^S) W_t = e_t$$

若还原为 X_t 序列,等价地,有

$$(1 - \varphi_1 B^S) \nabla_S^D X_t = e_t \quad (7.1.2)$$

同样,一阶移动平均模型

$$W_t = e_t - \theta_1 e_{t-S} \quad (7.1.3)$$

或

$$W_t = (1 - \theta_1 B^S) e_t$$

还原为 X_t 序列,有

$$\nabla_S^D X_t = (1 - \theta_1 B^S) e_t \quad (7.1.4)$$

推而广之,季节模型的 ARMA 形式为

$$U(B^S) W_t = V(B^S) e_t \quad (7.1.5)$$

或

$$U(B^S) \nabla_S^D X_t = V(B^S) e_t \quad (7.1.6)$$

其中,

$$U(B^S) = 1 - u_1 B^S - u_2 B^{2S} - \dots - u_p B^{pS}$$

$$V(B^S) = 1 - v_1 B^S - v_2 B^{2S} - \dots - v_q B^{qS}$$

这里值得注意的是 e_t 的内容与性质。 e_t 是原序列消除了周期点之间相关部分(即季节分量)之后的剩余序列。特别需要注意的是序列 e_t 不一定独立。因为我们仅消除了不同周期的同一周期点上的相关部分,作为系统响应,除了不同周期的同一周期点之间具有一定相关关系外,同一周期的不同周期点之间也有可能具有一定的相关关系。以周期为一年的月份资料为例,不同年份的同月资料(即各年同月的资料)可能存在一定的依存关系,同年各月的资料也有可能有一定的动态性。因此,随机季节模型有一定的不足,在一定程度上说,它是一个不完备的模型。

第二节 乘积季节模型

一、乘积季节模型的一般形式

在随机季节模型中,由于序列 e_t 不是独立的,因此不妨假设 e_t 适合一个 $ARIMA(n, d, m)$ 。则有

$$\Phi(B)\nabla^d e_t = \Theta(B)a_t \quad (7.2.1)$$

其中

$$\Phi(B) = 1 - \varphi_1 B - \varphi_2 B^2 - \cdots - \varphi_n B^n$$

$$\Theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \cdots - \theta_m B^m$$

a_t 为白噪声序列。若将(7.1.6)式与(7.2.1)式结合起来,即先在(7.1.6)式的两端同乘以 $\Phi(B)\nabla^d$,得

$$\Phi(B)U(B^S)\nabla^d \nabla_S^D X_t = V(B^S)\Phi(B)\nabla^d e_t \quad (7.2.2)$$

再将(7.2.1)式代入(7.2.2)式,得

$$\Phi(B)U(B^S)\nabla^d \nabla_S^D X_t = V(B^S)\Theta(B)a_t \quad (7.2.3)$$

这里 $\Phi(B)\nabla^d X_t$ 仅表示同一周期内不同周期点的相关关系;而 $U(B^S)\nabla_S^D$ 则描述不同周期的同一周期点上的相关关系;二者结合起来,便同时刻画了两个因素的作用。另一方面,从(7.2.3)式的结构形式上看,它是随机季节模型与 $ARIMA$ 模型的结合式,故称之为乘积季节模型,其阶数用 $(n, d, m) \times (p, D, q)_s$ 表示。

将(7.2.3)式展开,则可得到一般的 $ARIMA$ 模型,例如将

$$(1 - B)X_t = (1 - \theta_1 B)(1 - v_1 B^S)a_t$$

展开,得

$$(1 - B)X_t = 1 - \theta_1 B - v_1 B^S + \theta_1 v_1 B^{S+1} a_t$$

上式是一个 $(0, 1, S+1)$ 阶 $ARIMA$ 模型,且系数 $\theta_1, \theta_2, \dots, \theta_{S+1}$ 中有许多为零。即 $\theta_1 = \theta_1, \theta_2 = \theta_3 = \cdots = \theta_{S-1} = 0, \theta_S = v_1, \theta_{S+1} = -\theta_1 v_1$ 。可见,尽管模型的阶数很高,但除了 θ_1, θ_S 和 θ_{S+1} 外,其它系数的值均为零。而且 $-\theta_{S+1} = \theta_1 v_1$, 所以,事实上只有两个自由参数 θ_1 和 v_1 。故上述乘积季节模型也称为疏系数模型。

同样, (7.2.3) 式也可以化成类似的带有一定约束条件的疏系数模型

$$\Phi^*(B)\nabla^d X_t = \Theta^*(B)a_t \quad (7.2.4)$$

式中 $\Phi^*(B)$ 和 $\Theta^*(B)$ 的各参数由相应的 $\Phi(B)$ 、 $U(B)$ 、 ∇_s^D 、 $V(B)$ 、 $\Theta(B)$ 确定,模型阶数为 $(n + ps + Ds, d, m + qs)$ 。当季节模型的阶 p, D, q 均为零时,就得到了一个 $ARIMA(n, d, m)$ 模型。可见, $ARIMA$ 模型是乘积季节模型的一个特例。

二、常用的随机季节模型

在实际问题中,由于具体系统的组成要素和动态性不同,因而模型的形式也是多种多样的。下面我们介绍几类最常用的随机季节模型。

$$1. (1 - B^{12})(1 - B)X_t = (1 - \theta_1 B)(1 - \theta_{12} B^{12})a_t \quad (7.2.5)$$

这个模型事实上是由两个模型组合而成的:一个是

$$(1 - B^{12})X_t = (1 - \theta_{12} B^{12})e_t \quad (7.2.5a)$$

它是只考虑不同年份同月之间的资料之间的相关关系;另一个是

$$(1 - B)e_t = (1 - \theta_1 B)a_t \quad (7.2.5b)$$

它刻画的是同年不同月之间的相关关系。将二者结合起来:

由(7.2.5a)式,得

$$\begin{aligned} X_t - X_{t-12} &= e_t - \theta_{12} e_{t-12} \\ X_{t-1} - X_{t-13} &= e_{t-1} - \theta_{12} e_{t-13} \end{aligned}$$

将上述二式相减,得

$$X_t - X_{t-1} - X_{t-12} + X_{t-13} = e_t - e_{t-1} - \theta_{12} e_{t-12} + \theta_{12} e_{t-13}$$

即

$$(1 - B)(1 - B^{12})X_t = (1 - B)e_t - \theta_{12}[(1 - B)e_{t-12}]$$

将(7.2.5b)式代入上式,整理后,得

$$(1 - B)(1 - B^{12})X_t = (1 - \theta_1 B)(1 - \theta_{12} B^{12})a_t$$

显然(7.2.5)式,就是同时考虑各年同月和同年各月之间相关关系的模型。这个模型最早用于国际航运资料,故也称之为 $Airline$ 模型,是一个应用最广的季节模型。

$$2. (1 - B^{12})X_t = (1 - \theta_1 B)(1 - \theta_{12} B^{12})a_t \quad (7.2.6)$$

显然这个模型也是由两个模型组合而成的:一个是

$$(1 - B^{12})X_t = (1 - \theta_{12} B^{12})e_t$$

它刻画不同年份同月的资料之间的相关关系;另一个是

$$e_t = (1 - \theta_1 B)a_t$$

它表示同年不同月之间几乎不存在依赖关系,但受前一期扰动的影响,即时间序列资料消除了季节因素之后适合于一个 MA(1) 模型。

更一般的情况是(7.2.5)和(7.2.6)两个模型中的周期长度 12 可以用 S 替代。同时,以下各模型的构成和适用条件,读者可作类似的分析,书中不再赘述。

$$3. (1 - B^S)X_t = C + (1 - \theta_1 B)(1 - \theta_S B^S)a_t \quad (7.2.7)$$

$$4. (1 - B)X_t = (1 - \theta_S B^S)a_t \quad (7.2.8)$$

$$5. (1 - B^S)X_t = (1 - \theta_S B^S)a_t \quad (7.2.9)$$

$$6. (1 - \varphi B)(1 - B^S)X_t = (1 - \theta_S B^S)a_t \quad (7.2.10)$$

$$7. (1 - \varphi B^S)X_t = C + (1 - \theta B)a_t \quad (7.2.11)$$

$$8. (1 - B^S)^2 X_t = C + \theta_{2S}(B)a_t \quad (7.2.12)$$

第三节 季节时序模型的建立

积型季节模型的识别、定阶、参数估计及适应性检验,基本上也是以随机序列的样本自相关、偏自相关函数为依据的。因此,我们需要讨论季节模型周期点的自相关和偏自相关函数。

一、季节性 MA 模型的自相关函数

假设某一季节性时间序列的季节性,即各周期点之间的相关性可用

$$X_t = (1 - \theta_S B^S)e_t \quad (7.3.1)$$

来描述,而 e_t 又适合于一个 MA(1),即

$$e_t = (1 - \theta_1 B)a_t \quad (7.3.2)$$

将(7.3.2)式代入(7.3.1)式,得

$$X_t = (1 - \theta_1 B)(1 - \theta_S B^S)a_t \quad (7.3.3)$$

这是一个周期为 S 的季节性 MA(1) 模型,即 $(0,0,1) \times (0,0,1)_S$ 模型。

将(7.3.3)式展开,可得

$$X_t = a_t - \theta_1 a_{t-1} - \theta_S a_{t-S} + \theta_1 \theta_S a_{t-S-1} \quad (7.3.4)$$

当 $S = 12$ 时,(7.3.4)式为

$$X_t = a_t - \theta_1 a_{t-1} - \theta_{12} a_{t-12} + \theta_1 \theta_{12} a_{t-13} \quad (7.3.5)$$

显然(7.3.5)式是一个 MA(13) 模型,但除 θ_1 和 θ_{12} 外,其余系数均为零。

根据第三章的内容,不难求得其自相关系数:

$$\begin{aligned}
\gamma_0 &= \text{Var}(X_t) \\
&= (1 + \theta_1^2 + \theta_{12}^2 + \theta_1^2 \theta_{12}^2) \sigma_a^2 \\
&= (1 + \theta_1^2)(1 + \theta_{12}^2) \sigma_a^2 \\
\rho_1 &= (-\theta_1 - \theta_1 \theta_{12}^2) / [(1 + \theta_1^2)(1 + \theta_{12}^2)] \\
&= \frac{-\theta_1}{1 + \theta_1^2} \\
\rho_2 &= \rho_3 = \dots = \rho_{10} = 0 \\
\rho_{11} &= \theta_1 \theta_{12} / [(1 + \theta_1^2)(1 + \theta_{12}^2)] \\
\rho_{12} &= (-\theta_1^2 \theta_{12} - \theta_{12}^2) / [(1 + \theta_1^2)(1 + \theta_{12}^2)] \\
&= \frac{-\theta_{12}}{1 + \theta_{12}^2} \\
\rho_{13} &= \theta_1 \theta_{12} / [(1 + \theta_1^2)(1 + \theta_{12}^2)] \\
\rho_{14} &= \rho_{15} = \dots = 0
\end{aligned}$$

可见, ρ_1 事实上是模型 (7.3.2) 的一阶自相关系数, 而 ρ_{12} 则是模型 (7.3.1) 式的一阶自相关系数。

因此, 不难求得 θ_1, θ_{12} 的估计式。

类似地, 当各周期点之间的关系适合于一个 $\text{MA}(m)$ 模型时, 有

$$X_t = \Theta(B)(1 - \theta_s B^s) a_t \quad (7.3.6)$$

其中, $\Theta(B) = 1 - \theta_1 B - \dots - \theta_m B^m$ 。

因此, 上式可以等价地写成

$$\begin{aligned}
X_t &= (1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_m B^m)(1 - \theta_s B^s) a_t \\
&= (1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_m B^m - \theta_s B^s + \theta_1 \theta_s B^{s+1} + \dots \\
&\quad + \theta_m \theta_s B^{s+m}) a_t
\end{aligned}$$

这样, 就可很容易地求得自相关函数。当然, 还可以推广为更一般的情形。

$$X_t = \Theta(B)V(B^s) a_t \quad (7.3.7)$$

其中, $V(B^s) = 1 - V_1 B^s - V_2 B^{2s} - \dots - V_q B^{qs}$

二、季节性 AR 模型的偏自相关函数

利用同样的思路, 我们可以得到季节性 $\text{AR}(1)$ 模型。

$$(1 - \varphi_1 B)(1 - \varphi_s B^s) X_t = a_t \quad (7.3.8)$$

展开, 得

$$(1 - \varphi_1 B - \varphi_s B^s + \varphi_1 \varphi_s B^{s+1}) X_t = a_t$$

于是, 可求得偏自相关函数。

同样,可以推广到 AR(n) 模型

$$(1 - \varphi_1 B - \varphi_2 B^2 - \cdots - \varphi_n B^n)(1 - \varphi_s B^s)X_t = a_t \quad (7.3.9)$$

或更一般的情形

$$\Phi(B)U(B^s)X_t = a_t \quad (7.3.10)$$

即

$$(1 - \varphi_1 B - \varphi_2 B^2 - \cdots - \varphi_n B^n)(1 - \nu_1 B^s - \nu_2 B^{2s} - \cdots - \nu_p B^{ps})X_t = a_t \quad (p \leq s)$$

当求得第($n+1$)阶、($n+2$)阶……等偏自相关函数,可根据其在周期点的截尾性来判定模型的阶数。但是,这里需要注意的是样本的第($n+1$)阶、($n+2$)阶……偏自相关函数不可能精确为零,因而偏自相关函数的截尾性,只能提供一些定阶信息。

三、季节性模型的建模方法

根据以上讨论可知,若利用 $B-J$ 建模方法来建立季节性时间序列模型,首先需要判明周期性,即 S 的取值,然后根据自相关和偏自相关函数提供的信息来判别模型的类型(AR、MA 或 ARMA)和阶数,最后进行参数估计和检验,具体步骤可概括如下:

第一步,对时间序列进行差分 ∇ 和季节差分 ∇_s ,以得到一个平稳序列。

第二步,计算差分后序列的自相关函数和偏自相关函数,选择一个暂定(尝试性的)模型。

第三步,由差分序列的适当自相关和偏自相关值求得模型的初始估计值,并将这些估计值作为最小二乘估计的初始值,对模型参数进行最小二乘估计。

第四步,对估计得到的暂定模型的剩余进行适应性检验,决定是否接受暂定模型。当模型的适应性检验表明暂定模型不是最优模型时,可根据检验所提供的有关改进模型的信息,重新拟合改进模型,并对其进行适应性检验,直至得到最优模型为止。

这里需要指出的是,从理论上说季节差分的阶数 D 可以是任意数字,但是从实际建模经验来看, $B-J$ 曾指出:通常 D 不会超过一阶;特别是对于 $S=12$ 的月份序列,季节 AR 算子 $U(B^s)$ 和 MA 算子 $V(B^s)$ 的阶数很少超过一阶;当可利用数据的序列长度不足以支持 $p > 1$ 或 $q > 1$ 的复杂模型时,尤为如此。这对于我们应用时序分析研究周期规律性是很有意义的。

在具体建模过程中,要特别注意利用自相关函数提供的信息。例如,假设

$$W_t = (1 - B)(1 - B^{12})X_t$$

则(7.2.5)式变为

$$W_t = (1 - \theta_1 B)(1 - \theta_{12} B^{12})a_t \quad (7.3.11)$$

$$= a_t - \theta_1 a_{t-1} - \theta_{12} a_{t-12} + \theta_1 \theta_{12} a_{t-13}$$

由(7.3.11)式可知,若一个序列适合于(7.3.11)模型,则其理论自相关函数满足

$$\rho_1 \neq 0, \quad \rho_{12} \neq 0$$

$$\rho_{11} = \rho_{13} = \rho_1 \rho_{12} \quad (7.3.12)$$

$$\text{其它 } \rho_k = 0$$

在具体应用中,如果序列 X_t 的样本自相关函数持续较大,那么,启示我们应该对序列 X_t 进行一阶差分处理,即

$$Y_t = (1 - B)X_t$$

如果 Y_t 序列滞后 12、24、36、48、... 期的样本自相关函数值较大,则应该对 Y_t 序列进行 12 阶季节差分,即

$$W_t = (1 - B^{12})Y_t$$

再计算 W_t 序列的样本自相关函数,若计算结果与条件(7.3.12)式基本一致,则可以认为对 X_t 序列拟合模型(7.2.5)是适合的。我们以 1987 年到 1996 年甲地某商品各月销售量资料为例,来说明这种建模方法。

图 7.1 是该序列 $x_t (t = 1, 2, \dots, 120)$ 的数据图。从图中可以看出,该序列存在着明显的增长趋势和季节性(季节周期 $s = 12$)。为了更加明确起见,我们




图 7.1 甲地某商品月销售量

计算原序列 X_t 的滞后 1 ~ 48 期自相关系数,结果如表(7.3.(a))。

从表中可以看出,前 48 期自相关系数在 12 的整数倍上的值一直较大,这说明序列确实存在周期为 12 的季节性。此外,虽然自相关函数除了 12 的整数倍上的点以外,数值并不明显地大,但也没有明显地快速衰减,结合图 7.1,可以认为存在着增长趋势,所以应该对 X_t 序列进行一次差分。即

$$(1 - B)X_t = Y_t$$

并计算序列 Y_t 的自相关系数,计算结果见表 7.3(b)。显然滞后期 $k = 12n, n = 1, 2, 3, 4$ 时,自相关系数明显较大,这提示我们应该对序列 Y_t 进行 12 阶季节差分,即

$$(1 - B^{12})Y_t = (1 - B^{12})(1 - B)X_t = W_t$$

W_t 序列的前 48 期自相关系数见表 7.3(c)。从表 7.3(c) 可以看出, $\hat{\rho}_1 = -0.49, \hat{\rho}_{12} = -0.33$,明显地不等于零, $\hat{\rho}_{13} = 0.24$,接近于 $\hat{\rho}_1 \times \hat{\rho}_{12} = (-0.49) \times (-0.33) = 0.16$ 。故我们可以认为对该序列拟合(7.2.5)模型是适合的。

表 7.3(a) X_t 的自相关系数

序列	滞后	样 本 自 相 关 系 数 值											
X_t	1 ~ 12	.22	—	.20	.08	—	.06	—	.23	—	.12	—	.20
	13 ~ 24	.19	—	.19	.07	—	.07	—	.21	—	.12	—	.19
	25 ~ 36	.15	—	.18	.05	—	.07	—	.20	—	.11	—	.17
	37 ~ 48	.12	—	.17	.03	—	.07	—	.18	—	.10	—	.16

表 7.3(b) Y_t 的自相关系数

序列	滞后	样 本 自 相 关 系 数 值											
Y_t	1 ~ 12	—	.23	—	.45	.28	.02	—	.18	.11	—	.15	.01
	13 ~ 24	—	.21	—	.41	.25	.02	—	.16	.10	—	.13	.01
	25 ~ 36	—	.19	—	.36	.22	.02	—	.14	.09	—	.11	.01
	37 ~ 48	—	.16	—	.32	.19	.01	—	.13	.08	—	.10	.01

表 7.3(c) W_t 的自相关系数

序列	滞后	样 本 自 相 关 系 数 值											
W_t	1 ~ 12	—	.49	.05	—	.10	.15	—	.12	—	.02	.06	.12
	13 ~ 24	—	.24	.05	—	.11	.16	—	.25	—	.12	.10	—
	25 ~ 36	—	.17	.03	—	.11	.06	—	.19	.15	.00	—	.03
	37 ~ 48	—	.19	.15	.00	.04	.08	—	.13	.05	—	.07	.13

关于参数估计、适应性检验及预测方法与前述相似,只是推导和计算更复杂一些而已,限于篇幅和本书研究的目的主要是在于应用,因此这里不作详述。

利用1987年到1996年的资料借助TSP软件拟合(7.2.5)模型,输出结果为 $\theta_1 = -0.7929, \theta_{12} = -0.5089$,即模型为 $(1 - B^{12})(1 - B)x_t = (1 + 0.7929B)(1 + 0.5089B^{12})a_t$ 。模型的剩余序列如图7.2所示。




图 7.2 模型的剩余序列

显然,从应用的角度来看,由于估计和检验以及预测可以借助计算机统计分析软件来完成,因此,应用的关键问题有两个:一是如何知道所研究的序列含有周期性规律以及周期的长度;二是拟合一个什么样的模型最为适合。

关于第一个问题,解决的方法就是对所研究序列进行检验。最简单易行的方法就是绘制数据图,也可根据序列的相关系数所提供的信息和建立试探性的三角函数模型来判断。但是,不论是用什么方法得到的判断,都要符合所研究系统的机理,如果没有一定的理论分析能够支持定量测试的结论,则一般不易建立季节时序模型,除非是要对现有理论进行突破性实证研究,否则,不采用季节模型。

当判明周期以后,就需要回答第二个问题,如前所述,主要依靠自相关函数提供的信息来选择暂定模型。为了便于应用, $B-J$ 给出了一些常用的季节模型的自协方差,见参考书目。

当然,不论是如何选择的暂定模型,拟合模型之后都要进行适应性检验,直至得到最优模型为止。对于本例来说,所拟合的模型的剩余序列的自相关如图 7.3 所示,可以认为是一个白噪声序列。因此,我们认为得到的模型为适应模型。




图 7.3 剩余序列的自相关

也可以运用 Pandit — Wu 方法,经过试误检验探寻最适应模型。

对于季节时间序列来说,除了建立随机时序模型来刻画周期规律外,还可以在理论分析证明系统确实存在确定性的周期波动的情况下,用一个确定性的模型予以描述。关于确定性时间序列分析方法在《统计学原理》和《统计预测》等教材中都有介绍,故本书不再重复。这里需要强调两点:一是在对序列进行因素分解分析时, $X-11$ 方法借助计算机手段,越来越显示出其优越性,因而,越来越引起普遍关注和广泛应用。虽然本书以介绍随机时序分析方法为主,但是,为了有助于读者进一步学习和应用,本章第四节将对 $X-11$ 方法做一些简单介绍。二是确定性时间序列模型和随机时间序列模型相结合的组合模型也引起了一系列讨论。就其建模思想和第六章讲的组合模型的建模思想是完全一致的,并已提及。但进一步的讨论和研究已超出了本书的范围,有兴趣的读者请参阅有关文献。

第四节 X - 11 方法简介

X - 11 的全称是“X - 11”变量的第二类调查统计方法季节调整方案,通常简称为 X - 11 方案。这是美国商业部普查局 40 年代开发的一种时间序列季节调整的方法。在原理上它与传统分解法相似,但是 X - 11 不仅考虑季节结构变化的可能性,而且自动估计工作日数、星期因素等的变化。因而 X - 11 方法更加精密和细致,结果也更加准确和实用。被应用者公认为是一种极为有效的短、中期预测技术之一。

一、X - 11 方法的基本思想

经济数据一般受季节、节假日、各月(季)的星期数量以及其它偶然因素的影响,因而来自经济现象的动态数据往往不具有可比性。例如:二月份的生产量与三月份的生产量就不具有可比性,因为二月份的工作日数大大小于三月份的工作日数;二月份的商品零售额与三月份的商品零售额也不具有可比性,因为二月份有一个春节。如果不注意这些因素进行简单比较分析,就有可能得出错误的结论。

传统的统计方法为了增强可比性,采用不同周期的同一周期点比较的方法。如年距增长量、年距发展速度、年距增长速度等,也就是“同期比”。这样处理直观上看,上述不足似乎得到了较好的改进,但是,这样的结果所描述的只是相对于较远的过去的变动情况,而没有提供系统近期的变化情况。比如说,1997 年 11 月份工业产值较去年同期增长了 16%,但最近三个月是增长了,还是降低了;是平稳地,有节奏地持续发展,还是波动起伏,松紧不匀,涨弛无度;增长速度是加快了,还是放慢了等等。同时,这种方法还容易造成对经济形势的错误判断。如 1997 年 11 月和 12 月工业产值分别较去年同期增长了 16% 和 17%,这就给人一种经济发展似乎又开始超高速的印象,而实际上,这两个高增长率是由于 1996 年同期工业产值较低造成的。更何况,经济现象即使在同期(同月、同季)所受的影响也不尽完全相同。

鉴于上述不足,X - 11 方法利用一系列处理技术将上述不可比因素一一分离出来,大大提高数据的可比性,以便于对系统作出正确的分析和客观的评价;同时,通过分离,获得了关于系统动态结构和规律的大量信息,使我们对系统的认识更加深刻,通过恢复损失的信息,使预测结果更为准确。

二、X - 11 方法

1. 模型。原始时间序列 X_t 一般可分解为如下四种因素：

趋势因素(T_t)——反映时间序列在长时期中所呈现出来的趋势性；

季节因素(S_t)——各种以一年为周期的外界变化的因素；

星期构成因素(D_t)——指由于一星期中各天的经济活动对原始数据所做的贡献不同，形成的星期构成对月度统计数据的影响；

不规则因素(I_t)——除上述因素以外的诸多偶然因素的变化对原始数据的影响。

上述四个因素与原时间序列的一般关系有两种形式：

$$\text{乘法模型} \quad X_t = T_t \cdot S_t \cdot D_t \cdot I_t \quad (7.4.1)$$

$$\text{加法模型} \quad X_t = T_t + S_t + D_t + I_t \quad (7.4.2)$$

2. 构成因素的分解方法

(1) 分离趋势项。即从原序列 X_t 中分离长期趋势 T_t 。为实现上述目的，常用的方法是中心移动平均法。即新生成的平滑序列的值对应于被平均的各个数值的中心点。比如，对于月份资料，应作十二项移动平均，其第一个移动平均值对应于原序列第六项和第七项的中间；而第二项应对应于七、八两项的中间，依次类推。对于季度资料，应作四项移动平均，其第一个移动平均值应对应于原序列的第二和第三项中间。这时，往往失去经济意义，因而，通常在偶数项移动平均的基础上再进行一次两项移动平均。这种先做十二项移动平均，再做二项移动平均的方法，常称为十二乘二移动平均。此外，在 X - 11 方法中，还会遇到三乘三项，三乘九项、三乘五项移动平均等。选择哪种方法要根据数据样式、不规则因素的大小以及研究目的等来确定。

在实际应用中，特别是当采用计算机来完成的时候，上述两次移动平均可直接依据原列 X_t 计算。例如：

对于 (12×2) ，有：

$$T_{6.5} = (X_1 + X_2 + X_3 + X_4 + \cdots + X_{12})/12$$

$$T_{7.5} = (X_2 + X_3 + \cdots + X_{12} + X_{13})/12$$

因而

$$\begin{aligned} T_7 &= \frac{T_{6.5} + T_{7.5}}{2} \\ &= (X_1 + 2X_2 + \cdots + 2X_{12} + X_{13})/24 \end{aligned} \quad (7.4.3)$$

对于 (3×3) ，有：

$$T'_2 = (X_1 + X_2 + X_3)/3, T'_3 = (X_2 + X_3 + X_4)/3$$

$$T'_4 = (X_3 + X_4 + X_5)/3$$

因而

$$T_3 = \frac{T'_2 + T'_3 + T'_4}{3} = (X_1 + 2X_2 + 3X_3 + 2X_4 + X_5)/9 \quad (7.4.4)$$

其它方法读者可以类推。不难看出,十二乘二项移动平均方法,实质上是一种加权移动平均。

(2) 剔除不规则因素。从原序列分离出长期趋势之后,若不存在星期因素的影响,其结果为 $X_i/T_i = S_i I_i$, 即季节因素和不规则因素。显然对 $S_i I_i$ 进行移动平均,便可剔除 I_i 而分离出 S_i 来。这里的关键是移动平均项数的选择问题。一方面项数 N 值越大,剔除不规则因素的效果越好;另一方面, N 越大,损失的信息(项数 $N - 1$) 越大,特别是末尾的 $(N - 1)/2$ 项数据的损失更为重要。因为这是最新信息。为了解决上述矛盾,项数 N 值不易过大。 $X - 11$ 中,可以选择 (3×3) , (3×5) 或 (3×9) 项移动平均,究竟选择哪一种,视不规则因素的大小和研究目的而定。可能有人会担心这样处理,不规则因素消除得不够彻底。其实我们仔细地考虑一下, $S_i I_i$ 中的不规则因素已经很小了,因为我们已经做过 12×2 项移动平均了。假设 $I_i \sim N(0, \sigma^2)$, 则十二项移动平均后, $\frac{I_i + I_{i+1} + \dots + I_{i+11}}{12} \sim N(0, \frac{\sigma^2}{12})$, 再进行两项移动平均,不规则因素遵从

$N(0, \frac{\sigma^2}{24})$, 几乎接近于零了。

(3) 调整星期构成因素。调整方法是先确定一星期中各天的加权值,然后进一步形成一个月的权值,即得到一个月份的星期因素。

确定星期中各天的加权值一般有两种方法:一种方法是根据历史经验确定,另一种方法是通过回归求得,回归公式如下:

$$ID_i - 1 = \frac{B_1 X_{i1} + B_2 X_{i2} + \dots + B_7 X_{i7} + I_i}{N_i} \quad (7.4.5)$$

其中, ID_i 是原始数据除以暂定趋势和季节因素 $(X/(T \cdot S))$ 的商;

X_{ij} 是 i 月星期 j 的天数, $j = 1, 2, \dots, 7$;

B_j 是星期 j 的回归系数;

I_i 是 i 月的不规则因素真值;

N_i 是 i 月的天数(2 月为 28.25 天)。

得到回归结果后,即得到星期因素

$$D_i = \sum_{j=1}^7 \frac{B_j}{N_i} X_{ij} - 1 \quad (7.4.6)$$

(4) 修正不规则因素的特殊项。由于我们理论上假定季节因素是一个稳定的因素,即规则地变动。因此,当我们求得季节因素后,若其变化较大,则往往归因于没有完全剔除不规则因素。为了获得稳定的季节因素,通常要对不规则因素的特殊项进行修正,以减少特殊项对季节调整的影响。具体修正方法如下:

确定特殊项判据。首先计算不规则因素 I_t 或 $D_t I_t = \frac{X_t}{T_t S_t}$ 的标准差:

$$\sigma_I = \sqrt{\frac{\sum (I_t - 1)^2}{N}} \quad (7.4.7)$$

然后确定判断标准的上限 U (一般取 ± 2.5) 和下限 L (一般取 ± 1.5)。

计算特殊项的修正加权值。计算公式如下:

$$W_t = \begin{cases} 0, & |I_t - 1| > U \\ 1, & |I_t - 1| < L \end{cases}$$

$$\frac{U}{U - L} - \frac{|I_t - 1|}{(U - 1)\sigma_I}, \quad L \leq |I_t - 1| \leq U \quad (7.4.8)$$

修正不规则因素。修整公式如下:

$$I_t^W = 1 + W_t(I_t - 1) \quad (7.4.9)$$

修正特殊项后的原始数据:

$$X_t = T_t \cdot S_t \cdot D_t \cdot I_t^W \quad (7.4.10)$$

(5) 增补损失项。进行移动平均两端各损失 $(N - 1)/2$ 项。如进行 12×2 移动平均,则首尾各损失 6 项。鉴于季节因素比较稳定,因此,用相邻两个周期的相应周期点上的数值的平均数来代替,如

$$M_1 = (M_{13} + M_{25})/2, \dots, M_n = (M_{n-24} + M_{n-12})/2$$

3. $X - 11$ 方法的迭代过程

上述内容仅是具体计算方法。 $X - 11$ 运用上述方法对数据进行分解是一个复杂的迭代过程。整个迭代过程分两个阶段:

第一阶段为修正星期因素和不规则因素阶段。下面为了叙述方便,在表示各因素的字母后面加 (i) , 表示第 i 次迭代结果。首先从原序列 $X(1)$ 出发,运用上述方法,得到 $T(1)$ 、 $S(1)$ 、 $D(1)$ 、 $I(1)$ 和 $I^W(1)$; 进而通过 $\frac{X(1)}{S(1)}$ 并对其做移动平均得到 $T(2)$; $\frac{X(1)}{T(2)}$ 并做移动平均得到 $S(2)$; 其次,对原序列调整星期因

素得到 $X(2) = \frac{X(1)}{D(1)}$; 再次, 调整不规则因素的特殊项, 得到 $X(3) = X(2) \times \frac{I^w(1)}{I(1)}$; 然后从 $X(3)$ 出发, 重复上述过程, 直至剔除了星期因素和不规则因素的特殊项为止。假设为 $X(5)$ 。




图 7.4 乙地某商品销售量




图 7.5 趋势因子

第二阶段,从 $X(5)$ 出发,分解趋势因素、季节因素和不规则因素。迭代过程与上述相似。

例如,对于乙地商品销售量资料来说,根据乘法模型进行季节调整。在调整过程中运用 $X-11$ 程序设定的标准参数,且不做星期调整,运行结果得到的趋势因子、季节因子和不规则扰动因子,如图 7.5、图 7.6 和图 7.7 所示。




图 7.6 季节因子




图 7.7 不规则因子

思考与练习

7.1 证明(7.3.12)式。

7.2 对于如下过程

$$(1 - \varphi B)(1 - B^s)X_t = (1 - \theta, B^s)a_t$$

$W_t = (1 - B^s)X_t$ 的自相关函数有何特征?

7.3 X_t 是一季节性产品销售量的时间序列,经取对数并差分后变为平稳序列; $W_t = \nabla \nabla_{12} \ln(X_t)$ 。下表是由包含 102 个月度观测值的序列 W_t 的前 48 个自相关函数。

滞后	自 相 关											
1 - 12	- 0.39	- 0.24	0.17	0.21	- 0.27	- 0.03	0.26	- 0.10	- 0.20	0.07	0.44	- 0.58
13 - 24	0.09	0.17	0.01	- 0.24	0.16	0.04	- 0.12	- 0.01	0.11	0.08	- 0.33	0.28
25 - 36	0.01	- 0.14	- 0.02	0.18	- 0.13	0.04	- 0.01	0.10	- 0.13	- 0.09	0.27	- 0.22
37 - 48	0.00	0.09	0.02	- 0.18	0.17	- 0.05	0.0	- 0.06	0.06	0.06	- 0.13	0.11

$\bar{\omega} = 0.241, S_{\omega}^2 = 106.38$, 试识别该序列的合适模型。

第八章 ※※※※※※※※※※※※※※※※※※※※※※※※

传递函数模型

前面我们讨论的均为单变量时间序列分析,即仅考虑一个时间序列其目前观测值受过去观测值影响的情况。而在许多实际问题中会遇到这样的情形:一个时间序列其目前的表现不仅受过去行为的影响,而且与另一个时间序列相关联。比如经济总量的变化不仅与过去有关,而且受投资等因素的影响,这种影响往往是滞后的,又比如消费情况除有自身的规律外,还受到收入等因素的影响。这种情形在工业过程中则更为普遍,生产过程的输出除有自身的规律外,当然要受到输入情况的影响。我们把这种过程称为动态系统,其变化称为动态系统的响应,描述这种动态系统的响应则要用到传递函数模型。




图 8.1 动态系统图示

本章我们介绍离散的线性传递函数模型,用它们可以表示经常遇到的动态情形。

第一节 模型简介

一、模型形式

我们先具体的例子来说明。设 Y_t 表示经济总量与其均衡状态的偏差,经济总量的变化有其自身的记忆性,可用一个 ARMA 模型来描述其目前值与前期值的关系。为便于例示,不妨用如下简单的模型:

$$Y_t = 0.95Y_{t-1} + a_t$$

除此之外,经济总量的变化还与其它一些输入变量有关,这里我们考虑投资,用 X_t 表示投资与均衡状态的偏差,投资对经济总量的影响具有一定的滞后性,假设滞后为 1 期,将投资的影响加到上述模型中,若取系数为 0.8,则可得简单的输入输出关系为

$$Y_t = 0.95Y_{t-1} + 0.8X_{t-1} + a_t \quad (8.1.1)$$

当上述模型为合适的模型时,它表明在时刻 t 的输出可分为三部分:一部分取决于自身的过去值 Y_{t-1} ,一部分取决于前一时刻的输入 X_{t-1} ,另一部分与这两部分都无关,为随机扰动,用 a_t 表示。利用 B 算子,可将模型(8.1.1)写成

$$(1 - 0.95B)Y_t = 0.8BX_t + a_t$$

亦即

$$Y_t = \underbrace{\frac{0.8B}{1 - 0.95B}}_{\text{传递函数}} X_t + \underbrace{\frac{1}{1 - 0.95B}}_{\text{扰动}} a_t \quad (8.1.2)$$

该模型即为一个简单的传递函数模型,可用图 8.2 表示,传递函数用算子 $\frac{0.8B}{1 - 0.95B}$ 表示,它将输入 X_t 传递到输出,算子 $\frac{1}{1 - 0.95B}$ 将随机扰动叠加到经传递后的输出上,得到实际的输出 Y_t 。

上述模型是一个特殊的例子,更一般的模型可表示为

$$\begin{aligned} Y_t &= V(B)X_t + N_t \\ V(B) &= \sum_{i=0}^{\infty} v_i B^i \\ N_t &= \frac{\Theta(B)}{\Phi(B)} a_t \end{aligned} \quad (8.1.3)$$




图 8.2 动态系统图示

其中 X_t, Y_t 分别是系统输入和输出对均衡的偏离, N_t 为干扰序列与 X_t 相互独立, a_t 为白噪声序列。 $V(B)$ 中的权数 v_i 称为动态系统的脉冲响应函数, 它可以看作在时刻 $i \geq 0$ 对于 0 时刻的单位脉冲的输出或响应, 即如果 X_t 在 $t = 0$ 时为 1, 其它时刻为 0, 则在不考虑干扰的情况下, 系统在 $t = 0, t = 1, t = 2, \dots$ 的输入响应分别为 $v_0, v_1, v_2, \dots$, 实际中, 系统的输出偏差可以看作是系统对输入偏差的一系列脉冲响应与干扰叠加所形成的整体输出响应。

在实际的应用中, 由于 $V(B)$ 含有太多的参数, 无法使用有限的资料得到适当的估计, 因此我们用有理函数来近似它

$$V(B) \cong \frac{\Omega(B)B^b}{E(B)} \quad (8.1.4)$$

其中

$$\Omega(B) = \omega_0 - \omega_1 B - \omega_2 B^2 - \dots - \omega_s B^s$$

$$E(B) = 1 - \epsilon_1 B - \epsilon_2 B^2 - \dots - \epsilon_r B^r$$

式中 b 代表 X_t 延后 b 期影响 Y_t , 因此, 实际应用的传递函数模型为

$$Y_t = \frac{\Omega(B)B^b}{E(B)} X_t + \frac{\Theta(B)}{\Phi(B)} a_t \quad (8.1.5)$$

其中, $\Omega(B), E(B), \Theta(B), \Phi(B)$ 均为 B 的多项式, 次数分别为 s, r, q 及 p , 输入与输出关系可图示为图 8.3。

下面是几个传递函数的例子。本节开始的例子是一种特殊情况。

$$Y_t = \omega_0 X_t + a_t$$

$$Y_t = \omega_2 B^2 X_t + \frac{1}{1 - \varphi B} a_t$$

$$Y_t = \frac{\omega_1 B}{1 - \epsilon B} X_t + \frac{1}{1 - \varphi B} a_t$$




图 8.3 传递函数模型(8.1.5) 示意图

二、传递函数的性质

我们假设传递函数 $V(B)$ 可以约简表示为两个多项式比

即

$$V(B) = \frac{\Omega(B)B^b}{E(B)}$$

可得如下恒等式

$$\begin{aligned} (1 - \varepsilon_1 B - \varepsilon_2 B^2 - \cdots - \varepsilon_r B^r)(v_0 + v_1 B + v_2 B^2 + \cdots) \\ = (\omega_0 - \omega_1 B - \omega_2 B^2 - \cdots - \omega_s B^s)B^b \end{aligned} \quad (8.1.6)$$

令 B 的系数相等, 则有

$$v_j = \begin{cases} 0, & j < b \\ \varepsilon_1 v_{j-1} + \varepsilon_2 v_{j-2} + \cdots + \varepsilon_r v_{j-r} + \omega_0, & j = b \\ \varepsilon_1 v_{j-1} + \varepsilon_2 v_{j-2} + \cdots + \varepsilon_r v_{j-r} + \omega_{j-b}, & j = b+1, b+2, \dots, b+s \\ \varepsilon_1 v_{j-1} + \varepsilon_2 v_{j-2} + \cdots + \varepsilon_r v_{j-r}, & j > b+s \end{cases} \quad (8.1.7)$$

(8.1.7) 中最后一式即为差分方程

$$E(B)v_j = 0 \quad j > b+s$$

r 个脉冲响应权数 $v_{b+s}, v_{b+s-1}, \dots, v_{b+s-r+1}$ 为其提供了初值。差分方程的解 $v_j = f(\varepsilon, \omega, j)$ 适合于 $j \geq b+s-r+1$ 的所有 v_j 。

由上可知, 脉冲响应函数的构成为:

1. 前 b 个值为零, 即 $v_0 = v_1 = v_2 = \cdots = v_{b-1} = 0$;
2. 随后的 $s-r+1$ 个值 $v_b, v_{b+1}, \dots, v_{b+s-r}$ 形式不固定。如果 $s < r$ 则不出现这样的值。

3. 当 $j \geq b + s - r + 1$ 时, v_j 的形式取决于 r 阶差分方程, 其 r 个初值为 $v_{b+s}, v_{b+s-1}, \dots, v_{b+s-r+1}$ 。当 $j < b$ 时, 初值为零。

这些性质是下一节判别传递函数模式的依据。

三、传递函数模型的稳定性

传递函数模型的稳定性要求与 ARMA 随机模型的平稳性要求完全类似, 对于动态系统 (8.1.5), 其稳定性的直观含义为: 输入的有限变化将导致输出的有限变化, 其稳定性条件为: 方程

$$\lambda^r - \epsilon_1 \lambda^{r-1} - \dots - \epsilon_{r-1} \lambda - \epsilon_r = 0$$

$$\lambda^q - \varphi_1 \lambda^{q-1} - \dots - \varphi_{q-1} \lambda - \varphi_q = 0$$

的根在单位圆内。也可用参数来表示, 比如对于 $E(B)$ 为二阶时, 稳定性条件为

$$\epsilon_2 + \epsilon_1 < 1$$

$$\epsilon_2 - \epsilon_1 < 1$$

$$-1 < \epsilon_2 < 1$$

对于 $\Phi(B)$, 其参数表示情况与第四章中的相同。

第二节 传递函数模型的识别

传递函数模型的识别包括传递函数模式的识别和干扰模式的识别, 本节主要介绍前者, 所用的工具是输入序列与输出序列的互相关函数。

一、互协方差和互相关函数

设 (X_t, Y_t) 为双变量随机过程, 经 d 阶差分后可化为平稳过程 (x_t, y_t) , $x_t = \nabla^d X_t, y_t = \nabla^d Y_t$, x_t 与 y_t 相差 k 期的协方差函数定义为

$$\gamma_{xy}(k) = E[(x_t - \mu_x)(y_{t+k} - \mu_y)] \quad (8.2.1)$$

$$k = 0, 1, 2, \dots$$

y_t 与 x_t 之间相差 k 期的互协方差函数定义为

$$\gamma_{yx}(k) = E[(y_t - \mu_y)(x_{t+k} - \mu_x)] \quad (8.2.2)$$

$$k = 0, 1, 2, \dots$$

由于

$$\begin{aligned}\gamma_{xy}(k) &= E[(x_{t-k} - \mu_x)(y_t - \mu_y)] \\ &= E[(y_t - \mu_y)(x_{t-k} - \mu_x)] \\ &= \gamma_{yx}(-k)\end{aligned}$$

因此,只需要考虑 $\gamma_{xy}(k), k = 0, \pm 1, \pm 2, \dots$ 的情形。 x_t 与 y_t 之间相差 k 期的互相关函数定义为

$$\rho_{xy}(k) = \frac{\gamma_{xy}(k)}{\sigma_x \sigma_y} \quad k = 0, \pm 1, \pm 2, \dots \quad (8.2.3)$$

其中

$$\begin{aligned}\sigma_x &= \sqrt{\sigma_x^2} = [E(x_t - \mu_x)^2]^{\frac{1}{2}} \\ \sigma_y &= \sqrt{\sigma_y^2} = [E(y_t - \mu_y)^2]^{\frac{1}{2}}\end{aligned}$$

对于双变量过程的样本数据 $(X_1, Y_1), \dots, (X_N, Y_N)$, 经 d 阶差分后变为 $(x_1, y_1), \dots, (x_n, y_n), n = N - d$, 我们可以计算其样本互相关函数作为总体互相关函数的估计。

$$\hat{\rho}_{xy}(k) = r_{xy}(k) = \frac{C_{xy}(k)}{S_x S_y} \quad k = 0, \pm 1, \pm 2, \dots \quad (8.2.4)$$

其中, $C_{xy}(k)$ 为样本互协方差函数,

$$C_{xy}(k) = \begin{cases} \frac{1}{n} \sum_{t=1}^{n-k} (x_t - \bar{x})(y_{t+k} - \bar{y}) & k = 0, 1, 2, \dots \\ \frac{1}{n} \sum_{t=1}^{n+k} (y_t - \bar{y})(x_{t+k} - \bar{x}) & k = 0, 1, 2, \dots \end{cases}$$

式中, $\bar{x}, \bar{y}, S_x, S_y$ 分别为序列 x 和 y 的样本均值与样本标准差。

在实际中为了获得互相关函数有意义的估计,一般至少需要 50 对观测值。为了对以上算法加以说明,我们用 5 对观测值的序列计算相差 1 和 -1 期的样本互相关函数。

例 8.1 对如下的 x_t 和 y_t , 计算 $r_{xy}(\pm 1)$ 。

t	1	2	3	4	5
x_t	11	7	8	12	14
y_t	7	10	6	7	10

首先可计算出 $\bar{x} = 10.4, \bar{y} = 8$, 序列对均值的离差为

t	1	2	3	4	5
$x_t - \bar{x}$	-0.6	-3.4	-2.4	1.6	3.6
$y_t - \bar{y}$	-1.0	2.0	-2.0	-1.0	2.0

进一步可得 $S_x=2.577, S_y=1.673$, 且

$$\begin{aligned} C_{xy}(1) &= \frac{1}{5} \sum_{t=1}^4 (x_t - \bar{x})(y_{t+1} - \bar{y}) \\ &= \frac{1}{5} [(-0.6) \times 2.0 + (-3.4) \times (-2.0) + (-2.4) \\ &\quad \times (-1.0) + 1.6 \times 2.0] \\ &= 2.720 \end{aligned}$$

$$\begin{aligned} C_{xy}(-1) &= \frac{1}{5} \sum_{t=1}^4 (y_t - \bar{y})(x_{t+1} - \bar{x}) \\ &= \frac{1}{5} [(-1.0) \times (-3.4) + 2.0 \times (-2.4) \\ &\quad + (-2.0) \times 1.6 + (-1.0) \times 3.6] \\ &= -1.64 \end{aligned}$$

所以

$$\begin{aligned} r_{xy}(1) &= \frac{C_{xy}(1)}{S_x S_y} = \frac{2.720}{2.577 \times 1.673} = 0.63 \\ r_{xy}(-1) &= \frac{C_{xy}(-1)}{S_x S_y} = \frac{-1.64}{2.577 \times 1.673} = -0.38 \end{aligned}$$

例 8.2 我们考虑一个传递函数模型的典型例子, 即 Box 与 Jenkins 1970 年对销售额和领先指标数据建立的传递函数模型。用 X_t 表示领先指标, Y_t 表示销售额, 共有 150 对观测数据 (见附录), 一阶差分后变为平稳序列, 设 $x_t = \nabla X_t, y_t = \nabla Y_t$, 计算机输出的 x_t 与 y_t 之间部分的样本互相关函数如表 8.1 所示。(由于 TSP 不具有某些功能, 本章的计算结果由 SCA 输出。)

可以看出当 $k \leq 0$ 时, $r_{xy}(k)$ 显著为零 (标准差为 $\hat{\sigma}(r) = 0.082$, 计算方法见文献 [4] 第 472 页), 而当 $k > 0$ 时, 则存在显著非零的 $r_{xy}(k)$, 这说明 x_t 与 y_t 的关系是单向的, 即 x_t 影响 y_t , 而 y_t 不影响 x_t 。

表 8.1

k	0	-1	-2	-3	-4	-5	-6
$r_{xy}(k)$	-0.026	0.099	-0.060	0.063	-0.043	0.077	-0.104
k	1	2	3	4	5	6	7
$r_{xy}(k)$	0.078	-0.361	0.720	0.095	0.121	0.033	0.145

二、传递函数模式的识别

传递函数模式的识别主要是判定 (8.1.4) 中分子、分母多项式的阶数 r, s




图 8.4 销售额和领先指标数据图

及延迟参数 b , 基本思路是先估计出脉冲响应函数 $\hat{v}_j (j=0, 1, 2, \dots)$, 然后与理论值比较以决定适当的 r, s 及 b 。具体方法主要有: 预白噪化法与最小平方方法 (亦称线性转换函数法)。下面介绍预白噪化法。

此法是 Box 与 Jenkins 于 1976 年提出的, 具体步骤为:

1. 对经过适当差分后平稳的输入序列 x_t 建立一个 ARMA 模型, 以产生白噪声序列 a_t 。

$$\alpha_t = \frac{\Phi_x(B)}{\Theta_x(B)} x_t \triangleq T(B)x_t \quad (8.2.5)$$

如果将 $T(B)$ 视作一个变换, 则它将 x_t 变换为白噪声序列。

2. 对经过差分后平稳的输出序列 y_t 实施 $T(B)$ 变换产生 β_t 数列。

$$\beta_t = T(B)y_t = \frac{\Phi_x(B)}{\Theta_x(B)} y_t \quad (8.2.6)$$

于是模型

$$y_t = V(B)x_t + n_t \quad (8.2.7)$$

(此处 $y_t = \nabla^d Y_t, x_t = \nabla^d X_t, n_t = \nabla^d N_t$) 可写为

$$\beta_t = V(B)\alpha_t + e_t \quad (8.2.8)$$

其中 $e_t = \Theta_x^{-1}(B)\Phi_x(B)n_t$

3. 估计脉冲响应函数。

对(8.2.8)两边同乘 α_{t-k} 并取期望可得

$$r_{\alpha\beta}(k) = v_k \sigma_\alpha^2$$

于是

$$v_k = \frac{\gamma_{\alpha\beta}(k)}{\sigma_\alpha^2} = \frac{\rho_{\alpha\beta}(k)\sigma_\beta}{\sigma_\alpha} \quad k=0,1,2,\dots \quad (8.2.9)$$

由此可以看出, 将输入白噪声化后, 在白噪声化输入和经相应变换的输出之间的互相关函数直接与脉冲响应函数成正比。在实际应用中我们只能用样本来估计。

$$\hat{v}_k = \frac{r_{\alpha\beta}(k)S_\beta}{S_\alpha} \quad k=0,1,2,\dots \quad (8.2.10)$$

由此获得的初步估计可以为我们识别传递函数模式提供大略的基础。

4. 依据脉冲响应函数的情况判定 r, s 和 b 。

依据传递函数的性质可得如下判定 r, s, b 的方法: 由(8.1.7)中第一式(性质1)可知, b 等于前边几个显著为零的 $\hat{v}_k$ 的个数; 由(8.1.7)中第四式(性质3)可知, r 为 $\hat{v}_k$ 所满足的差分方程的阶数, 如果 $\hat{v}_k$ 不呈现任何模式, 则 $r=0$; 由(8.1.7)中第四式(性质3)可知, 若 $\hat{v}_k (j \geq k')$ 的形式取决 r 阶差分方程, 则 $b+s-r+1=k'$, 因而 $s=k'-b+r-1$; 若 $\hat{v}_k$ 不呈现任何形式(即 $r=0$), 则(8.1.6)式变为

$$v_0 + v_1 B + v_2 B^2 + \dots = \omega_0 B^b + \omega_1 B^{b+1} + \dots + \omega_s B^{b+s} \quad (8.2.11)$$

令(8.2.11)两边系数相等可知, b 为显著为零的 $\hat{v}_k$ 的个数, s 为显著非零的 $\hat{v}_k$ 的个数减去1。

下面继续例8.2, 判定传递函数模式。

(1) 对输入序列 x_t 拟合 ARMA 模型, 结果为

$$x_t = (1 - 0.45B)\alpha_t$$

$$\alpha_t = \frac{1}{1 - 0.45B} x_t$$

$$S_\alpha = 0.2918$$

(2) 对输出序列 y_t 实施同样变换, 得

$$\beta_t = \frac{1}{1 - 0.45B} y_t$$

$$S_\beta = 2.0464$$

(3) 计算 α_t 与 β_t 的互相关函数, 并估计脉冲响应权数, 结果为

k	0	1	2	3	4	5
$r_{\alpha\beta}(k)$	0.06	0.08	0.02	0.07	0.45	0.34
$\hat{\sigma}(r_{\alpha\beta}(k))$	0.08	0.08	0.08	0.08	0.08	0.08
$\hat{v}_k$	0.449	0.568	0.157	4.733	3.186	2.409

k	6	7	8	9	10
$r_{\alpha\beta}(k)$	0.26	0.27	0.20	0.17	0.10
$\hat{\sigma}(r_{\alpha\beta}(k))$	0.08	0.08	0.08	0.08	0.08
$\hat{v}_k$	0.822	1.891	1.460	1.223	0.694

(4) 判定 r, s, b

由 (8.2.10) 可得脉冲响应函数 $\hat{v}_k$ 的标准差为

$$\begin{aligned} \hat{\sigma}(\hat{v}_k) &= \frac{S_\beta}{S_\alpha} \cdot \hat{\sigma}(r_{\alpha\beta}(k)) \\ &= \frac{2.0464}{0.2918} \times 0.08 \\ &= 0.561 \end{aligned}$$

而 $\hat{v}_0 = 0.449$, $\hat{v}_1 = 0.568$, $\hat{v}_2 = 0.157$, 它们与其标准差相比并不显著, 因而可以认为 $v_0 = v_1 = v_2 = 0$, 根据传递函数的性质 1, 可初步断定 $b = 3$ (两个延迟期)。另外, $\hat{v}_3 = 4.733$, $\hat{v}_4 = 3.186$, $\hat{v}_5 = 2.409, \dots$, 即从 $j = 3$ 开始, $\hat{v}_j$ 逐渐减小, 因此, 可以认为 $j \geq 3$ 时, v_j 由一阶差分方程 $v_j = \varepsilon v_{j-1}$ (即 $v_j - \varepsilon v_{j-1} = 0$) 所确定, $\hat{v}_7, \hat{v}_8, \hat{v}_9$ 偏大些可以认为其与真值 v_7, v_8, v_9 偏差较大。由传递函数性质

3 可知, $r=1$ (即差分方程阶数), $b+s-r+1=3$ (即从 $j=3$ 开始 v_j 由一阶差分方程决定), 因而 $s=0$, 这样经初步识别可得传递函数模式为

$$y_t = \frac{\omega_0 B^3}{1 - \varepsilon_1 B} x_t + n_t$$

关于传递函数模式的判定还有 1982 年 Liu 与 Hanssens 提出的最小平方方法, 限于篇幅此处不予详述, 读者可参阅有关资料。

三、参数的初估计

在识别了传递函数模式后, 我们可以由关于脉冲响应函数的方程 (8.1.7) 得到其参数的初估计, 该初估计可以作为最终模型参数整体估计的初始值。

对于例 8.2, (8.1.7) 式为

$$v_j = 0 \quad (j < 3)$$

$$v_3 = \omega_0$$

$$v_4 = \varepsilon_1 v_3 \quad (j > 3)$$

将上边估计出来的 $\hat{v}_k$ 代入, 可得

$$4.733 = \hat{\omega}_0$$

$$3.186 = \hat{\varepsilon}_1 \times 4.733$$

所以初估计 $\hat{\omega}_0 = 4.73$, $\hat{\varepsilon}_1 = 0.67$, 这样经初步识别的传递函数模式为

$$y_t = \frac{4.73B^3}{1 - 0.67B} x_t + n_t$$

四、干扰序列模式的识别

判定并估计出传递函数模式后, 就可得到干扰序列

$$\hat{n}_t = y_t - \frac{\Omega(B)}{E(B)} x_t$$

依据 $\hat{n}_t$ 的 ACF, PACF 和 EACF 等可判定一个合适的 ARMA 模型。

继续例 8.2, 将 $\frac{4.73B^3}{1 - 0.67B} x_t$ 记为 $\hat{y}_t$, 则

$$\hat{y}_t = 0.67\hat{y}_{t-1} + 4.73x_{t-3}$$

可由上式递推计算出 $\hat{y}_t$, 再由 $\hat{n}_t = y_t - \hat{y}_t$ 得到 $\hat{n}_t$; 其自相关函数表明适合模型为 MA(1), 估计出的参数与前边 ω_0 、 ε_1 的初估计可作为最终模型参数整体估计的初始值。

第三节 传递函数模型的拟合与检验

对于尝试性传递函数模型

$$y_t = E^{-1}(B)\Omega(B)x_{t-b} + n_t \quad (8.3.1)$$

其中 $y_t = \nabla^d Y_t$, $x_t = \nabla^d X_t$, $n_t = \nabla^d N_t$ 都是平稳序列, 且

$$n_t = \Phi^{-1}(B)\Theta(B)a_t$$

我们本节考虑上述模型参数 $\varepsilon, \omega, \varphi, \theta$ 的同时有效的估计。与 ARMA 模型类似, 对于 x_t, y_t 的均值都是显著为零的, 即使估计出来参数也相当小, 且不显著。有时候, 我们在模型中加入常数项会对模型有所改进。

一、非线性估计

上述模型关于参数显然是非线性的, 我们可用上节的估计为初始值, 对参数进行非线性最小二乘估计, 以得到参数同时有效的整体估计, 其方法较繁, 本书从略。

对例 8.2, 最终模型整体估计为

$$y_t = 0.034 + \frac{4.70B^3}{1-0.73B}x_t + (1-0.63B)a_t$$

T 检验的 T 统计量值分别为 $T_c = 4.36$, $T_{\omega_0} = 94.63$, $T_{\varepsilon_1} = 209.64$, $T_{\theta_1} = 9.51$, 若用原序列表示即为

$$(1-B)Y_t = 0.034 + \frac{4.70B^3}{1-0.73B}(1-B)X_t + (1-0.63B)a_t$$

二、模型的检验

通过非线性最小二乘估计出来的模型是否正确需要进行检验, 方法仍然是通过残差来进行。如果传递函数模式不正确或干扰序列模式不正确, 将会使残差序列出现自相关, 并且残差序列与输入 x_t 及生成 x_t 的 a_t 之间互相关。

1. 自相关检验

假设一个传递函数模型已经估计出来, 我们可以计算残差序列 $\hat{a}_t$ 的自相关函数 $r_{\hat{a}\hat{a}}(k)$, 如果 $r_{\hat{a}\hat{a}}(k)$ 表现出显著相关则意味着模型不恰当, 可能是由于传递函数模式不合适, 也可能是由于干扰序列的模式不合适, 需要用互相关来检验。若互相关检验表明传递函数模式是合适的, 则需要对干扰序列模式进行

修改。

可以证明,如果模型是合适的,则残差序列是白噪声,其自相关函数相互独立地以方差 $\frac{1}{m}$ 分布在零附近(这里 m 是可用于计算的观测值的个数, $m=n-u-p$, $u=\max\{r,s+b\}$),且统计量近似服从于自由度为 $K-p-q$ 的 χ^2 分布,即

$$\begin{aligned}\bar{Q} &= m(m+2) \sum_{k=1}^K (m-k)^{-1} r_{a,a}^2(k) \\ &\sim \chi^2(K-p-q)\end{aligned}\quad (8.3.2)$$

p 和 q 为干扰模式中的参数个数, K 一般取得足够大,使得当 $k>K$ 时, $r_{a,a}(k)$ 可望被忽略。因此,我们可以观察残差的自相关是否显著为零,并计算 $\bar{Q}$ 统计量,然后与一定显著水平 α 下的 $\chi_{1-\alpha}^2(K-p-q)$ 比较,如果 $\bar{Q}<\chi_{1-\alpha}^2(K-p-q)$,则模型是合适的,否则模型需要修正。

2. 互相关检验

模型估计出来后,我们可以计算残差序列与输入 x_t 序列及生成 x_t 的 a_t 序列的互相关函数 $r_{x,a}(k)$ 和 $r_{a,a}(k)$,如果它们显著非零,则意味着传递函数模式不正确,需要进行修正。可以证明,如果传递函数模式恰当的话,残差 a_t 将是一个与 x_t 无关的白噪声, $r_{x,a}(k)$ 将以近似方差 $\frac{1}{m}$ 分布在零附近,并且由 $r_{a,a}(k)$ 形成的统计量 $\tilde{S}$ 近似服从于自由度为 $k+1-(r+s+1)$ 的 χ^2 分布, ($r+s+1$ 是传递函数模式中参数的个数),即

$$\begin{aligned}\tilde{S} &= m(m+2) \sum_{k=0}^K (m-k)^{-1} r_{a,a}^2(k) \\ &\sim \chi^2(K+1-r-s-1)\end{aligned}\quad (8.3.3)$$

K 要选得足够大,使得当 $j>K$ 的模型 $y_t = V(B) - \Psi(B) a_t$ (其中 $\Psi(B) = \frac{\Theta(B)}{\Phi(B)}$)中权数 v_j 和 ϕ_j 可以忽略。因此,我们可以通过对 $r_{x,a}(k)$ 和 $r_{a,a}(k)$ 的检验来判定传递函数模式的适应性。

下面我们对例8.2估计出的模型进行检验,其残差序列的自相关见下表。

可以看出 $r_{a,a}(k)$ 均显著为零,(全部在两倍标准差以内且大部分在1个标准差内),另外,再计算统计量 $\bar{Q}$, $n=N-d=150-1=149$, $u=\max\{r,s+b\}=\max\{1,0+3\}=3$, $p=0$,因此 $m=n-u-p=149-3-0=146$,我们取 $K=24$,由(8.3.2)可得 $\bar{Q}=20.25$,取显著性水平 $\alpha=0.05$,查 χ^2 分布可得 $\chi_{0.95}^2(k-p-q)=\chi_{0.95}^2(24-0-1)=\chi_{0.95}^2(23)=35.17$,而 $\bar{Q}=$

K	1	2	3	4	5	6	7	8
$r_{\hat{a}a}(k)$	0.02	0.00	-0.07	-0.06	0.13	0.06	-0.07	-0.02
$\hat{\sigma}(r)$	0.08	0.08	0.08	0.08	0.09	0.09	0.09	0.09
K	9	10	11	12	13	14	15	16
$r_{\hat{a}a}(k)$	-0.12	0.05	-0.02	-0.08	-0.12	-0.00	-0.01	-0.09
$\hat{\sigma}(r)$	0.09	0.09	0.09	0.09	0.09	0.09	0.09	0.09
K	17	18	19	20	21	22	23	24
$r_{\hat{a}a}(k)$	-0.10	0.07	0.07	-0.02	-0.01	-0.09	-0.07	0.10
$\hat{\sigma}(r)$	0.09	0.09	0.09	0.09	0.09	0.09	0.09	0.09

20. 25 < 35. 17, 因此, 可以认为对例 8. 2 估计出的模型是合适的。

当估计出合适的传递函数模型后, 我们自然就想到利用它来预测。通常在利用了某相关输入序列 X_t 的信息后, 对于输出序列 Y_t 的预测会得到相当程度的改善, 特别是 Y_t 的变化可以由 X_t 的变化预测时更是如此, 这种情况下常称 X 为 Y 的领先指标。传递函数模型(8. 1. 5)已将 Y 与 X 联系起来, 为了能利用 X 和 Y 的信息得到 Y 的最优预测, 我们要先对 X 拟合恰当的模型(8. 2. 5)并得到 X 的预测值, 再由传递函数模型进行预测。限于篇幅, 在此不预展开。

例 8. 3 我国 1950 年—1983 年的农业总产值指数和轻工业总产值指数数据见附录, 试建立传递函数模型。

我国的轻工业基本上是加工工业, 它的发展同农业的发展有密切的关系。设农业总产值指数为 X_t , 轻工业总产值指数为 Y_t , 我们可以建立以 X_t 为自变量, 以 Y_t 为因变量的传递函数模型。

(1) 从数据图(图 8. 5)可以看出 X_t 和 Y_t 有明显的上升趋势, 并且数据偏大。对数据作如下变换:

$$y_t = (1-B)\ln Y_t - \frac{1}{n} \sum_t (1-B)\ln Y_t \quad (8. 3. 4)$$

$$x_t = (1-B)\ln X_t - \frac{1}{n} \sum_t (1-B)\ln X_t \quad (8. 3. 5)$$

即 $X_t, Y_t \rightarrow$ 取对数 $\rightarrow$ 一阶差分 $\rightarrow$ 零均值化 $\rightarrow x_t, y_t, x_t, y_t$ 呈现出平稳性(如图 8. 6 所示)。

(2) 对 x_t 建立 ARMA 模型, x_t 的自相关函数和偏自相关函数表明其适合 ARMA(0, 2)模型, 具体结果如下





图8.5 农业和轻工业总产值指数图





图8.6 平稳化数据图

$$x_t = (1 - \hat{\theta}_1 B - \hat{\theta}_2 B^2) a_t \quad (8.3.6)$$

其中 $\hat{\theta}_1 = -0.6386705$, $\hat{\theta}_2 = -0.171216$, $\hat{\sigma}_a^2 = 0.534833$ 。

(3) 对 y_t 实施 $T(B)$ 变换, 得到 β_t 序列。

$$\beta_t = T(B)Y_t = \frac{1}{1 + 0.6386705B + 0.171216B^2} y_t \quad (8.3.7)$$

(4) 计算 α_t 和 β_t 的互相关函数, 结果见下表。

k	0	1	2	3	4	5	6	7	8	9
$r_{\alpha\beta}(k)$	0.136	0.349	0.271	0.023	0.066	-0.024	-0.021	0.148	0.196	-1.00
$\hat{\sigma}(r)$	0.17	0.17	0.17	0.17	0.17	0.17	0.17	0.17	0.17	0.17
$\hat{v}_k$	0.28	0.72	0.55	0.05	0.14	-0.049	-0.04	0.30	0.40	-0.21

k	10	11	12	13	14	15	16	17
$r_{\alpha\beta}(k)$	-0.193	-0.071	-0.100	0.095	0.067	0.178	-0.167	0.105
$\hat{\sigma}(r)$	0.17	0.17	0.17	0.17	0.17	0.17	0.17	0.17
$\hat{v}_k$	-0.31	-0.15	-0.21	0.20	0.37	-0.35	0.25	0.22

(5) 利用(8.2.9)式估计脉冲响应函数 $\hat{v}_k$ 。结果见上表。

(6) 判定 r, s, b 。利用(8.2.9)式可得 $\hat{v}_k$ 的标准差为 0.35, $\hat{v}_0 = 0.28$, 显著为零, 故可认为 $v_0 = 0$, 因而可判定 $b = 1$, 又由于 $\hat{v}_k$ 不呈现出差分方程模式, 故 $r = 0$ 。不显著为零的 $\hat{v}_k$ 有 2 个, 故 $s = 2 - 1 = 1$, 初步判定传递函数模式为

$$y_t = (\omega_0 - \omega_1 B)x_{t-1} + n_t$$

(7) 对干扰序列模式进行判别, 结果为 MA(1)。

(8) 按所识别模式进行参数估计, 结果如下

$$y_t = (\omega_0 - \omega_1 B)x_{t-1} + a_t - \theta_1 a_{t-1}$$

$$\hat{\omega}_0 = 0.717582047$$

$$\hat{\omega}_1 = -0.557660162$$

$$\hat{\theta}_1 = -0.099573731$$

$$\hat{\sigma}_a^2 = 0.008444934$$

(9) 适应性检验, 按(8.3.2)式和(8.3.3)式可算得 $\tilde{Q} = 21.4$ 。这里 $K = 21$, $K - p - q = 20$, 查 χ^2 表可得 $\chi_{0.95}^2(20) = 31.4$, 而 $\tilde{Q} = 21.4 < 31.4$, 故可以为 a_t 为白噪声序列; $\tilde{S} = 33.85$, $K = 31$, $K - r - s = 30$, 查表得 $\chi_{0.95}^2(30) = 43.8$, 而 $\tilde{S} = 33.85 < 43.8$, 故可以为 α_t 与 a_t 不存在互相关。

思考与练习

8.1 证明以下传递函数模型是稳定的：

$$(a) Y_t = 10 + \frac{25}{1-0.7B} X_{t-1}$$

$$(b) Y_t = 10 + \frac{22-12.5B}{1-0.85B} X_{t-2}$$

$$(c) Y_t = 10 + \frac{20-8.5B}{1-1.2B+0.4B^2} X_{t-3}$$

8.2 利用习题 8.1 中模型 (a) 计算对下列输入的响应 (填表)。

t	(a)		(b)	
	输入 X_t	输出 Y_t	输入 X_t	输出 Y_t
0	0	0	0	0
1	1		1.5	
2	0		0.5	
3	0		2.0	
4	0		1.0	
5	0		-2.5	
6	0		0.5	

8.3 利用方程 (8.1.7) 计算出习题 8.1 中每个模型的脉冲响应权数, 并对 (a) 的结果与习题 8.2 中的 (a) 的结果进行比较。

8.4 对输入序列 X_t 预白噪化 $\theta_x^{-1}(B)\varphi_x(B)X_t = \alpha_t$ 后, 再对输出序列 Y_t 进行变换得到 $\beta_t = \theta_y^{-1}\varphi_y(B)Y_t$, α_t 和 β_t 的互相关函数 $\gamma_{\alpha\beta}(k)$ 如下:

k	$\gamma_{\alpha\beta}(k)$	k	$\gamma_{\alpha\beta}(k)$
0	0.05	5	0.24
1	0.31	6	0.07
2	0.52	7	-0.03
3	0.43	8	0.10
4	0.29	9	0.07

且 $\tilde{\sigma}_\alpha = 1.26$, $\tilde{\sigma}_\beta = 2.73$, 互相关函数标准差近似为 0.075。

(a) 计算脉冲响应权数的粗估计。

(b) 给出传递函数的一个模式及参数的粗估计。

...

$$\rho_q - \varphi_1 \rho_{q-1} = -\theta_q G_0 v \triangleq C_q$$

$$\rho_{q+1} - \varphi_1 \rho_q = 0 \quad (1.2)$$

$$\rho_{q+2} - \varphi_1 \rho_{q+1} = 0$$

...

记方程(1.2)的解为 $\rho_{q+2}/\rho_q \triangleq \varphi_1^{(q)}$, 并用 $\varphi_1^{(q)}$ 对序列 X_t 进行转换, 得到 $W_t^{(q)}$ 序列

$$W_t^{(q)} = X_t - \varphi_1^{(q)} X_{t-1} \quad (1.3)$$

由于 $\varphi_1^{(q)} = \varphi_1$, 故 $W_t^{(q)}$ 为一个 $MA(q)$ 序列, 其相差 q 期的自我相关函数为

$$\frac{-\theta_q}{1 + \theta_1^2 + \dots + \theta_q^2} \neq 0$$

同理, $\rho_{q+2}/\rho_{q+1} \triangleq \varphi_1^{(q+1)}$ 也为方程(1.2)的解, 用 $\varphi_1^{(q+1)}$ 对序列 X_t 进行转换, 得到序列 $W_t^{(q+1)}$

$$W_t^{(q+1)} = X_t - \varphi_1^{(q+1)} X_{t-1}$$

由于 $\varphi_1^{(q+1)} = \varphi_1$, 故 $W_t^{(q+1)}$ 为 $MA(q)$ 序列, 其相差 $q+1$ 期的自我相关为零。

我们将 $W_t^{(j)} = X_t - \varphi_1^{(j)} X_{t-1}$ (其中 $\varphi_1^{(j)} = \rho_{j+1}/\rho_j$) 的相差 j 期的自我相关函数称为序列 X_t 的相差 j 期的第一阶延伸自我相关函数(EACF), 记为 $\rho_j(1)$, 于是, 对于 $ARMA(1, q)$ 序列可得

$$\rho_j(1) \neq 0, \quad j = q$$

$$\rho_j(1) = 0, \quad j > q$$

即第一阶 EACF 具有截断性质, 并且 $\rho_j(1)$ 是 X_t 的自我相关函数 $\rho_1, \rho_2, \dots, \rho_{j+1}$ 的函数。

我们再来考虑 $ARMA(2, q)$ 序列

$$X_t - \varphi_1 X_{t-1} - \varphi_2 X_{t-2} = a_t - \theta_1 a_{t-1} - \dots - \theta_q a_{t-q} \quad (1.4)$$

同上我们可以得到如下方程式

$$\rho_0 - \varphi_1 \rho_1 - \varphi_2 \rho_2 = C_0$$

...

$$\rho_q - \varphi_1 \rho_{q-1} - \varphi_2 \rho_{q-2} = C_n$$

$$\rho_{q+1} - \varphi_1 \rho_q - \varphi_2 \rho_{q-1} = 0 \quad (1.5)$$

$$\rho_{q+2} - \varphi_1 \rho_{q+1} - \varphi_2 \rho_q = 0 \quad (1.6)$$

$$\rho_{q+3} - \varphi_1 \rho_{q+2} - \varphi_2 \rho_{q+1} = 0$$

...

记方程(1.5)和(1.6)的解为

$$\begin{pmatrix} \varphi_1^{(q)} \\ \varphi_2^{(q)} \end{pmatrix} = \begin{pmatrix} \rho_q & \rho_{q-1} \\ \rho_{q+1} & \rho_q \end{pmatrix}^{-1} \begin{pmatrix} \rho_{q+1} \\ \rho_{q+2} \end{pmatrix} \triangleq \varphi^{(q)}$$

用 $\varphi^{(q)}$ 对 X_t 进行转换得到 $W_t^{(q)}$

$$W_t^{(q)} = X_t - \varphi_1^{(q)}X_{t-1} - \varphi_2^{(q)}X_{t-2}$$

于是 $W_t^{(q)}$ 为 $MA(q)$ 序列,其相差 q 期的自我相关函数不为零。

我们将 $W_t^{(j)} = X_t - \varphi_1^{(j)}X_{t-1} - \varphi_2^{(j)}X_{t-2}$ 的相差 j 期的自我相关函数称为序列 X_t 的相差 j 期的第二阶延伸自我相关函数,记为 $\rho_j(2)$,其中

$$\varphi^{(j)} = \begin{pmatrix} \varphi_1^{(j)} \\ \varphi_2^{(j)} \end{pmatrix} = \begin{pmatrix} \rho_j & \rho_{j-1} \\ \rho_{j+1} & \rho_j \end{pmatrix}^{-1} \begin{pmatrix} \rho_{j+1} \\ \rho_{j+2} \end{pmatrix}$$

于是,对于 $ARMA(2,q)$ 序列而言,有

$$\rho_j(2) \neq 0, \quad j = q$$

$$\rho_j(2) = 0, \quad j > q$$

即第二阶的延伸自我相关函数具有截断性质,并且 $\rho_j(2)$ 为 $\rho_1, \rho_2, \cdots, \rho_{j+1}, \rho_{j+2}$ 的函数。

继续考虑 $ARMA(3,q), ARMA(4,q), \cdots$ 序列,可得到类似的结果,将各阶延伸自我相关函数可汇于表 1.1 中。

表 1.1 EACF 表

MA RA					
	0	1	2	3	...
0	$\rho_1(0)$	$\rho_2(0)$	$\rho_3(0)$	$\rho_4(0)$	一般的 ACF
1	$\rho_1(1)$	$\rho_2(1)$	$\rho_3(1)$	$\rho_4(1)$	一阶的 EACF
2	$\rho_1(2)$	$\rho_2(2)$	$\rho_3(2)$	$\rho_4(2)$	二阶的 EACF
3	$\rho_1(3)$	$\rho_2(3)$	$\rho_3(3)$	$\rho_4(3)$	三阶的 EACF
⋮					

对于 $ARMA(p,q)$ 而言

$$\rho_j^{(q)} = \begin{cases} C & j = q \\ 0 & j > q \end{cases}$$

二、样本延伸自相关函数

下面介绍对一个具体的序列 X_t 而言,如何求出样本延伸自我相关函数,由于求解诸如(1.2),(1.5),(1.6)的方程式非常困难,Tiao 和 Tsay 提出了另一种方法求取样本的 EACF。

1. 求第一阶的 EACF

(1) 估计 $\varphi_1^{(1)}, \dots, \varphi_1^{(j)}$

a. 求 $X_t = \alpha^{(0)} X_{t-1} + e_t^{(0)}$ 中的参数估计值 $\hat{\alpha}^{(0)}$ 及 $\hat{e}_t^{(0)}$ 。

b. 求 $X_t = \alpha^{(1)} X_{t-1} + \beta e_{t-1}^{(0)} + e_t^{(1)}$ 中的参数估计值 $\hat{\alpha}^{(1)}$ 及 $\hat{e}_t^{(1)}$ 。

c. 求 $X_t = \alpha^{(2)} X_{t-1} + \beta_1 e_{t-1}^{(0)} \beta_2 \hat{\rho}_{t-2}^{(1)} + e_t^{(2)}$ 中的参数估计值 $\hat{\alpha}^{(2)}$ 及 $\hat{e}_t^{(2)}$ 。

⋮

如果 $\hat{e}_t^{(q)}$ 独立, 则 $\hat{\alpha}^{(q)}$ 为 α 的一致估计量。

(2) 将 X_t 转换成 $W_t^{(j)} = X_t - \hat{\varphi}^{(j)} X_{t-1}$

$$W_t^{(1)} = X_t - \hat{\alpha}^{(1)} X_{t-1}$$

$$W_t^{(2)} = X_t - \hat{\alpha}^{(2)} X_{t-1}$$

$$W_t^{(3)} = X_t - \hat{\alpha}^{(3)} X_{t-1}$$

⋮

(3) 计算 $W_t^{(j)}$ 的相差 j 期的样本自相关函数, 得到第一阶的样本延伸自我相关函数 $\hat{\rho}_j(1)$ 。

2. 求第二阶的样本 EACF

(1) 将上述(1)中的 X_{t-1} 换为 X_{t-1} 及 X_{t-2} , 并重复 a, b, ⋯

(2) 将 X_t 转换成 $W_t^{(j)} = X_t - \hat{\alpha}_1^{(j)} X_{t-1} - \hat{\alpha}_2^{(j)} X_{t-2}$ 。

(3) 计算 $W_t^{(j)}$ 的相差 j 期的样本自相关函数, 得到第二阶的样本延伸自我相关函数 $\hat{\rho}_j(2)$ 。

同理可计算出第三、四 ⋯ 阶的样本延伸的自相关函数 $\hat{\rho}_j(3), \hat{\rho}_j(4), \dots$ 从而获得样本 EACF 表, 其中第一行为 X_t 的样本自相关函数。

在 1984 年的 JASA 期刊中, Tiao 和 Tsay 对 EACF 的性质有详尽的讨论, 并说明了 EACF 表呈现三解形的型式, 有关性质的介绍此处从略。

三、延伸自我相关函数定阶法

表 1.1 中第一行为自相关函数 ACF, 第二行为第一阶延伸自我相关函数, 第三行为第二阶 EACF ⋯ ⋯, 经由 EACF 表可判定 ARMA 模型适合的最大阶数。将 EACF 表中数值与两倍的标准差相比较, 若与零的差异不显著, 则可简记为“0”, 否则, 简记为“X”, 这样可得到简记的 EACF 表。然后在简记的 EACF 表中寻找一个以“0”为左上角顶点的三角形, 而三角形内的值应为“0”, 该三角形左上角顶点所对应的行与列的标值即为 ARMA 模型适合的最大阶数。下面通过一个例子来说明。




图 1.1 某化工生产过程的产量数据图

表 1.2(a) 延伸自相关函数表

MA \ AR	0	1	2	3	4	5	6	7	8	9	10
0	-.39	.30	-.17	.07	-.10	-.05	.04	-.04	-.00	0.1	.11
1	.36	.11	-.06	-.09	-.10	-.14	-.00	-.04	.04	-.05	.13
2	-.04	.21	-.08	.01	-.14	-.13	-.01	-.04	.06	-.06	.12
3	.16	.12	-.07	.04	-.23	-.02	-.02	-.06	.02	-.06	.08
4	-.45	-.28	-.02	.13	-.24	-.00	-.03	-.05	.04	-.08	-.05
5	-.36	-.10	.12	.26	-.25	.02	.05	-.04	.08	-.13	.03
6	.26	.10	-.31	-.05	.14	.14	.04	.01	-.03	.02	-.03

表 1.2(b) 简记的 EACF 表($\alpha = 0.05$)

MA \ AR	0	1	2	3	4	5	6	7	8	9	10
0	X	X	0	0	0	0	0	0	0	0	0
1	X	0	0	0	0	0	0	0	0	0	0
2	0	0	0	0	0	0	0	0	0	0	0
3	0	0	0	0	0	0	0	0	0	0	0
4	X	X	0	0	0	0	0	0	0	0	0
5	X	0	0	0	0	0	0	0	0	0	0
6	X	0	X	0	0	0	0	0	0	0	0

例 1.1 图 1.1 是某化工生产过程的产量数据图,该数据是博克斯、詹金斯和瑞恩色尔所研究的数列之一,具体数据见附录。

该序列的 *ACF* 及 *PACF* 如图 1.2 所示,粗看起来,似乎既可以是 AR 模型,也可以是 MA 模型。我们再来看由 *SCA* 软件输出的 *EACF* 情况,如表 1.2 所示。

在简记的 *EACF* 表中,我们可以找到三个零三角形,根据其左上角顶点所在的位置,可以考虑的模型为 AR(2),MA(2) 和 ARMA(1,1),这是 *EACF* 建议我们的一些合理模式,再由其中选择一最合适的模式,具体建模结果见表 1.3。

F 统计量表明 AR(2),ARMA(1,1),MA(2) 三个模型没有显著的差别,并且模型阶数再没有升高的必要,因此三个模型都可以认为是适应的模型。如果我们以残差方差的大小来衡量模型的优劣,则在三种模型中较优的是 ARMA(1,1) 模型。进一步考虑我们发现在 ARMA(1,1) 中参数 θ_1 不很显著(*T* 检验值为 1.70),取掉该参数后我们拟合 AR(1) 模型,*F* 统计量为 2.99,在 $\alpha = 0.05$ 的水平下,差异也不显著。因此,如果从模型尽量简单的角度考虑,AR(1) 也是一个适应的模型。模型可写为

$$X_t - 51.29 = -0.42(X_{t-1} - 51.29) + a_t$$

表 1.3 对化工生产过程产量建模的计算机输出

参数	ARMA 模型阶数			
	(1,0)	(2,0)	(1,1)	(0,2)
μ	51.29 ± 1.82	51.10 ± 2.27	51.20 ± 1.44	51.17 ± 2.72
φ_1	- 0.42 ± 0.23	- 0.34 ± 0.25	- 0.78 ± 0.46	
φ_2		0.19 ± 0.25		
θ_1			0.46 ± 0.53	- 0.36 ± 0.25
θ_2				0.31 ± 0.25
残差平方和	8146.71	7757.56	7793.17	8019.24
σ_a	11.03	10.92	10.87	10.94




图 1.2 化工生产过程产量数据的相关函数图

提示信息

(U) UNDATED

(A) ANNUAL

(Q) QUARTERLY

(M) MONTHLY

FREQUENCY?

(2)若文件为非时间序列,则键入“U”,屏幕提示。

MAXIMUM OBSERVATIONS? 要求回答观察数据的个数。

(3)若文件是以年为间隔的时间序列,键入“A”,若文件是以季为间隔的时间序列,键入“Q”;若文件是以月为间隔的时间序列,键入“M”。

(4)屏幕继续提示“STARTING DATE”?

回答时间序列的起始日期

(5)之后,屏幕提示“ENDING DATE”?

回答结束时日期

注意:回答日期时,序列以年为间隔的,用四位或两位整数表示,以季为间隔的,在年后加一位小数,以月为间隔的,在年后加两位小数。

这时,屏幕上显示一个状态窗口,屏幕左边显示“>”表示软件包已经处于准备接受下一个命令的状态,内存中已经建立一个工作文件。

2. 输入时间序列

(1)键入“DATA”或按“DATA”相应的功能键后,数据编辑程序开始运行。

(2)屏幕提示“SERIES LIST?”

要求用户回答输入序列名称,可以同时输入容量相同的六个文件。

(3)用户输入观察值后,键入“END”,退出文件状态,软件包进入准备接受下一个命令的状态。

(4)输入观察值过程中,若出现操作错误可以修改,键入“B”,光标返回到上一个观察点,以修改刚刚输入的观察值,键入“Ni”,使光标定位到由*i*表示的观察点上,进行修改。

(5)若文件建立后发现错误,可以键入“DATA”命令和所要修改的文件名,当屏幕显示文件中的观察值后,再键入“Ni”进行修改。

3. 根据内存中序列生成新的序列

CENR 命令可以根据内存中已有的序列生成一个新的序列。

(1)键入“CENR”命令后,屏幕提示“EQUATION?”

要求用户输入用于生成新序列的计算方程:左边为新时间序列名,右边为生成新时间序列的计算公式,当左边的序列名已经存在时,新生成的观察值将代替序列中原有的观察值。GENR 命令允许使用下列运算符号或函数:

·:乘,/ :除,^:乘幂,LOG:求自然对数,EXP:指数运算,ABS:绝对值,SQR:求平方根,COEF:取出最后一次计算出的回归方程系数。

GENR 命令的公式中允许出现括号说明计算顺序,也可以在序列名称后的括号里给出一个正整数或负整数表示前置或滞后序列。注意:在运用滞后变量时,必须先对时间序列的范围重新确定使得滞后变量序列是存在的,此时,可键入“SMPL”定义日期。

(2)键入“STORE 和序列名”将内存中序列保存到磁盘数据库文件中,长期保存。由“STORE”命令存入的文件,必须用“FETCH”命令调入内存,调入方式:在输入“CREATE”命令,回答软件包提示后,键入“FETCH 及工作盘符:序列名”,即可将文件调入内存备用。

(3)键入“CAT”可以在屏幕上显示工作盘上的所有文件名称。

(4)键入“SMPL”和数据时间区间左端点及右端点,可以确定数据的时间范围。

(5)键入“DEL 和文件名.后缀”,可以删除当前盘上的文件,后缀有:

H 表示工作文件的标头文件或存有多少个序列的 TEXT 格式文件

DB 表示存有一个数据序列文件

EQ 存有方程的文件

DIF 和其它软件包交换信息的文件

WF 存有数据的工作文件

(6)键入“REN 原文件名.后缀和新文件名.后缀”,可以更换磁盘中数据文件的名称。

(7)键入“D 和欲删除文件名”,可以删除内存中若干时间序列。

(8)键入“R 和原序列名称以及新序列名称”,可以变换内存中工作文件的名称。

三、回归分析与模型拟合

1. 回归分析

(1)开始操作时,首先从数据库中取出来数据“FETCH 文件名”

(2)键入“LS”命令进行回归分析

应用时键入:LS、被解释变量、C 及各解释变量。

注意:各解释变量间要用空格隔开,输入完毕后回车。

(3)对于解释变量和被解释变量中的滞后变量序列,用原变量序列符号后边加括号,括号内用“-数字”来表示滞后期

(4)屏幕上即显示回归分析结果,其中的定义:

COEFFICIENT:回归系数

STD. ERROR:回归系数标准差

T-STAT:T 检验值

R-SQUARED:可决系数 R^2

ADJUSTED R-SQUARED:校正可决系数 R^2

DURBIN-WATSON STAT:D-W 检验值

F-STAT.:F 检验值

(5)显示分析结果后,继续提示

“DO YOU WANT TO SEE THE COVARIANCE MATRIX? (P, S, <CR>)”

是否显示协方差矩阵

选择 P 要求打印协方差矩阵,选择(CR)不输出协方差矩阵,软件包准备接受下一工作。键入“S”,屏幕显示协方差矩阵,继续提示

“DO YOU WANT TO SEE THE RESIDUAL PLOT(P, S, <CR>)”

是否显示残差图形

若键入“S”屏幕显示残差图形,同时继续提示

“DO YOU WANT TO SEE THE OUTPUT REPEATED (P, S, <CR>)”? .

是否再次显示分析结果

通常键入(CR),软件包停止输出统计分析结果,准备接受下一个工作。

2. 两阶段最小二乘法

键入“TSLS 被解释变量名称 C 解释变量名称 @工具变量名称”以计算两阶段最小二乘法模型,其中常量 C 总是一个合适的工具变量,即使工具变量表中不包括 C 变量,TSLS 也自动把它加上。

3. 拟合 ARMA 模型

在拟合模型之前,一定要用 SMPL 命令来改变起止时间以保证方程中使用的滞后值存在,对于高版本 TSP,软件所将自动改变。

(1)拟合 ARMA(n,m)模型,输入命令

LS 序列名 C AR(1) AR(2) ...AR(n) MA(1) MA(2) ... MA(m)

(2)拟合 AR(n)模型,输入命令

LS 序列名 C AR(1) AR(2) ... AR(n)

(3)拟合 MA(m)模型,输入命令

LS 序列名 C MA(1) MA(2) ... MA(m)

4. 其它命令

在回归分析过程中将会用到以下命令:

(1)键入“COVA 时间序列名称”,计算并打印多个序列各自的均值、最大值、最小值、标准差以及它们的协方差矩阵和相关矩阵。

(2)键入“IDENT(需要计算的相关系数的数目)序列名”,计算一个序列的自相关和偏自相关系数。

(3)键入“CROSS(需要计算的相关系数数目)一个序列名,另一个序列名”,计算两个序列的相关系数。

(4)用 PLOT 命令可以在屏幕上显示时间序列图形,一个图形最多只能表示六个时间序列,横轴用于表示时间,纵轴表示序列中的观察值。

键入“PLOT 序列名称”命令后,屏幕上显示如下信息供选择:

(A) AUTOMATIC

(G) AUTOMATIC WITH GRID

(M) MANUAL

(N) NORMALIZED

(R) RESIDUALS

SCALING METHOD?

一般选择“A”,“G”或“M”其中之一,PLOT 命令自动根据用于制图的一个序列中的数值确定度量单位。

(5)键入“GRAPH 第一个序列名 第二个序列名”可生成两个序列之间关系的散点图,横轴表示第一个序列,纵轴表示第二个序列,若“GRAPH(C)第一序列 第二序列名”则显示为折线图形。

(6)图形中加入标识信息

执行 PLOT 或 GRAPH 命令后,键入字“T”,即可用方向键把光标定在图形中的合适位置,然后键入标识信息,标识完毕后按(CR)键。

(7)图形打印

执行 PLOT 或 GRAPH 命令后选择“P”,可将图形及图形标识信息打印输出。

(8)图形存盘

执行 PLOT 或 GRAPH 命令后选择“S”，并给出图形名称，可将当前的图形存入磁盘。

(9) 统计分析结果打印输出

键入“PON”可在每估计一个新的方程后，将屏幕上已经显示出的统计分析结果打印输出，直到键入“POFF”命令之后，“PON”命令失效。

注意：输入“PON”命令以前应先打开打印机，PON 和 POFF 命令对 PRINT 命令无任何影响。

(10) 打印信息输出到磁盘文件里

键入“OPTION OUTPUT FILENAME”可以将需打印输出信息存贮到磁盘文件之中

键入“OPTION OUTPUT OFF”命令后，OPTION OUTPUT 命令失效

键入“OPTION OUTPUT NONE”用于断开打印机与主机间的联系。

四、预测

1. 预测前必须：

(1) 根据观测值，用“LS”或“TSL”命令估计回归方程

(2) 用 SMPL 命令，确定预测区间

(3) 对于预测值构成的新序列应配置一个新的序列名，键入“FORCST 新序列名”，预测值被记入新序列中去。

2. 显示当前方程

3. 存贮方程

输入“STOREQ 存贮方程的 FILENAME”，对已经估计的一个方程存盘以便今后进行预测。

4. 加载方程

输入“FETEQ 方程 FILENAME”将一个方程从磁盘读入内存，为预测做好准备。

附录 III

数据资料

1. 某车站 1993—1997 年各月列车运行数量数据(单位:千列公里)

obs	KY				
1	1196.8	1181.3	1222.6	1229.3	1221.5
6	1148.4	1250.2	1174.4	1234.5	1209.7
11	1206.5	1204.0	1234.1	1146.0	1304.9
16	1221.9	1244.1	1194.4	1281.5	1277.3
21	1238.9	1267.5	1200.9	1245.5	1249.9
26	1220.1	1267.4	1182.3	1221.7	1178.1
31	1261.6	1274.5	1196.4	1222.6	1174.7
36	1212.6	1215.0	1191.0	1179.0	1224.0
41	1183.0	1288.0	1274.0	1218.0	1263.0
46	1205.0	1210.0	1243.0	1266.0	1200.0
51	1306.0	1209.0	1248.0	1208.0	1231.0
56	1244.0	1296.0	1221.0	1287.0	1191.0

2. 某市 1985—1993 年各月工业生产总值(单位:万元)

obs	GY					
1985.01	10.93	9.34	11.00	10.98	11.29	11.84
1985.07	10.62	10.90	12.77	12.15	12.24	12.30
1986.01	9.91	10.24	10.41	10.47	11.51	12.45
1986.07	11.32	11.73	12.61	13.04	13.14	14.15
1987.01	10.85	10.30	12.74	12.73	13.08	14.27
1987.07	13.18	13.75	14.42	13.95	14.53	14.91
1988.01	12.94	11.43	14.36	14.57	14.25	15.86
1988.07	15.18	15.94	16.54	16.90	16.88	18.10
1989.01	13.70	10.88	15.79	16.36	17.22	17.75
1989.07	16.62	16.96	17.69	16.40	17.51	19.73
1990.01	13.73	12.85	15.68	16.79	17.59	18.51
1990.07	16.80	17.27	20.83	19.18	21.40	23.76
1991.01	15.73	13.14	17.24	17.93	18.82	19.12
1991.07	17.70	19.87	21.17	21.44	22.14	22.45
1992.01	17.88	16.00	20.29	21.03	21.78	22.51
1992.07	21.55	22.01	22.68	23.02	24.55	24.67
1993.01	19.61	17.15	22.46	23.19	23.40	26.26
1993.07	22.91	24.03	23.94	24.12	25.87	28.25

3. 我国 1949—1983 年的农业总产值指数

obs	NYZS				
1945					67.4
1950	79.3	86.8	100.0	103.1	106.6
1955	114.7	120.5	124.8	127.8	110.4
1960	96.4	94.1	99.9	111.6	126.7
1965	137.1	149.0	151.2	147.5	149.2
1970	166.3	171.4	171.1	185.5	193.2
1975	202.1	207.1	210.6	229.6	249.4
1980	259.1	276.2	306.8	386.2	

4. 我国 1949—1983 年轻工业总产值指数

obs	GYZS				
1945					46.6
1950	60.6	81.0	100.0	126.7	144.8
1955	144.8	173.3	183.3	245.1	299.0
1960	269.7	211.4	193.6	198.1	233.4
1965	344.7	394.7	366.7	348.7	436.6
1970	515.6	549.1	583.1	644.9	662.3
1975	748.4	766.4	876.0	970.6	1063.8
1980	1259.5	1437.1	1519.0	1651.2	

5. 上证所每日收盘综合指数(1996.5.20—1996.9.27)

obs	ZQ				
1	703.0800	661.8500	668.6200	642.6700	639.80
6	637.9600	646.9100	650.5500	636.3600	643.65
11	641.0900	651.5100	696.9700	702.6400	727.34
16	764.3900	752.2600	755.7700	768.6800	777.27
21	752.0000	793.5600	796.9100	793.5900	796.11
26	793.3400	780.6500	801.4600	806.4600	804.25
31	761.1200	759.7100	786.1300	785.4300	785.38
36	807.3400	817.6100	820.0500	792.0700	796.41
41	789.1600	823.0800	808.9900	818.0400	856.93
46	884.9400	871.4900	887.6000	868.1600	845.12
51	855.4200	836.9300	822.4800	835.1100	838.88
56	853.1900	862.2200	867.2700	876.0000	871.60
61	886.0500	874.8000	871.6400	865.8300	853.87
66	835.2100	822.4400	833.6100	818.2000	803.69
71	773.0700	787.4700	796.8400	788.7300	809.94
76	804.7800	812.0100	814.3800	801.2300	793.59
81	764.4500	769.2500	757.0900	779.0700	778.29
86	776.4800	760.7600	769.1000	805.5400	851.99
91	849.9200	835.1800	854.6600		

6. ARIMA(0,2,0)仿真序列

obs	FZ				
1	83.20000	78.90000	75.14169	71.60206	67.34122
6	63.15296	58.70039	55.75041	52.65775	49.19041
11	46.14016	43.96088	39.72739	36.55711	33.67466
16	31.76764	31.71332	33.04005	35.65921	38.50339
21	40.72801	42.64761	44.28576	47.19530	47.52817
26	47.22476	47.26056	47.69858	47.47670	48.87956
31	49.72448	50.13145	50.54267	50.18407	51.62555
36	52.34824	52.30994	51.34595	51.96163	53.37444
41	54.48325	55.86534	56.55856	57.64930	58.52429
46	59.22116	60.39257	61.59089	62.82328	64.42742
51	67.38915	68.44519	69.76994	70.71950	72.74545
56	74.85120	77.97546	79.91817	82.72930	85.69017
61	88.63636	91.47984	95.58726	99.23627	103.4132
66	107.4462	111.4441	117.0561	122.3093	127.4947
71	133.7172	139.0592	145.0848	151.0595	156.3883
76	161.3761	166.3072	170.9679	176.0247	181.3089
81	186.6674	193.9462	203.7996	213.5940	222.8660
86	230.0133	238.6225	247.9761	256.0214	263.4889
91	271.3817	278.1996	284.6757	291.8849	298.3792
96	305.5437	312.0804	318.1269	324.1592	331.0449

7. 化工生产过程的产量数据

obs	BF				
1	47	64	23	71	38
6	64	55	41	59	48
11	71	35	57	40	58
16	44	80	55	37	74
21	51	57	50	60	45
26	57	50	45	25	59
31	50	71	56	74	50
36	58	45	54	36	54
41	48	55	45	57	50
46	62	44	64	43	52
51	38	59	55	41	53
56	49	34	35	54	45
61	68	38	50	60	39
66	59	40	57	54	23

8. 化工生产过程的浓度读数

obs	A				
1	17.0	16.6	16.3	16.1	17.1
6	16.9	16.8	17.4	17.1	17.0
11	16.7	17.4	17.2	17.4	17.4
16	17.0	17.3	17.2	17.4	16.8
21	17.1	17.4	17.4	17.5	17.4
26	17.6	17.4	17.3	17.0	17.8
31	17.5	18.1	17.5	17.4	17.4
36	17.1	17.6	17.7	17.4	17.8
41	17.6	17.6	16.5	17.8	17.3
46	17.3	17.6	17.4	16.9	17.3
51	17.6	16.8	16.7	16.8	16.8
56	17.2	16.8	17.6	17.2	16.6
61	17.1	16.9	16.6	18.0	17.2
66	17.3	17.0	16.9	17.3	16.8
71	17.3	17.4	17.7	16.8	16.9
76	17.0	16.9	17.0	16.6	16.7
81	16.8	16.0	16.4	16.5	16.4
86	16.6	16.5	16.7	16.4	16.4
91	16.2	16.4	16.3	16.4	17.0
96	16.9	17.1	17.1	16.7	16.9
101	16.5	17.2	16.4	17.0	17.0
106	16.7	16.2	16.6	16.9	16.5
111	16.6	16.6	17.0	17.1	17.1
116	16.7	16.8	16.3	16.6	16.8
121	16.9	17.1	16.8	17.0	17.2
126	17.3	17.2	17.3	17.2	17.2
131	17.5	16.9	16.9	16.9	17.0
136	16.5	16.7	16.8	16.7	16.7
141	16.5	16.5	17.0	16.7	16.7
146	16.9	17.4	17.1	17.0	16.8
151	17.2	17.2	17.2	16.9	16.8
156	17.0	17.4	17.2	17.2	17.2
161	17.1	17.1	17.1	17.4	17.2
166	16.9	16.9	17.0	16.7	16.9
171	17.3	17.8	17.8	17.6	17.5
176	17.0	16.9	17.1	17.2	17.4
181	17.5	17.9	17.0	17.0	17.0
186	17.2	17.3	17.4	17.4	17.0
191	18.0	18.2	17.6	17.8	17.7
196	17.2	17.4			

9. 销售额的领先指标数据

obs	X ₁				
1	10.01	10.07	10.32	9.75	10.33
6	10.13	10.36	10.32	10.13	10.16
11	10.58	10.62	10.86	11.20	10.74
16	10.56	10.48	10.77	11.33	10.96
21	11.16	11.70	11.39	11.42	11.94
26	11.24	11.59	10.96	11.40	11.02
31	11.01	11.23	11.33	10.83	10.84
36	11.14	10.38	10.90	11.05	11.11
41	11.01	11.22	11.21	11.91	11.69
46	10.93	10.99	11.01	10.84	10.76
51	10.77	10.88	10.49	10.50	11.00
56	10.98	10.61	10.48	10.53	11.07
61	10.61	10.86	10.34	10.78	10.80
66	10.33	10.44	10.50	10.75	10.40
71	10.40	10.34	10.55	10.46	10.82
76	10.91	10.87	10.67	11.11	10.88
81	11.28	11.27	11.44	11.52	12.10
86	11.83	12.62	12.41	12.43	12.73
91	13.01	12.74	12.73	12.76	12.92
96	12.64	12.79	13.05	12.69	13.01
101	12.90	13.12	12.47	12.47	12.49
106	13.10	12.91	13.39	13.13	13.34
111	13.34	13.14	13.49	13.87	13.39
116	13.59	13.27	13.70	13.20	13.32
121	13.15	13.30	12.94	13.29	13.26
126	13.08	13.24	13.31	13.52	13.02
131	13.25	13.12	13.26	13.11	13.30
136	13.06	13.32	13.10	13.27	13.64
141	13.58	13.87	13.53	13.41	13.25
146	13.50	13.58	13.51	13.77	13.40

10. 销售额数据

obs	Y ₁				
1	200.1	199.5	199.4	198.9	199.0
6	200.2	198.6	200.0	200.3	201.2
11	201.6	201.5	201.5	203.5	204.9
16	207.1	210.5	210.5	209.8	208.8
21	209.5	213.2	213.7	215.1	218.7
26	219.8	220.5	223.8	222.8	223.8
31	221.7	222.3	220.8	219.4	220.1
36	220.6	218.9	217.8	217.7	215.0
41	215.3	215.9	216.7	216.7	217.7
46	218.7	222.9	224.9	222.2	220.7
51	220.0	218.7	217.0	215.9	215.8
56	214.1	212.3	213.9	214.6	213.6
61	212.1	211.4	213.1	212.9	213.3
66	211.5	212.3	213.0	211.0	210.7
71	210.1	211.4	210.0	209.7	208.8
76	208.8	208.8	210.6	211.9	212.8
81	212.5	214.8	215.3	217.5	218.8
86	220.7	222.2	226.7	228.4	233.2
91	235.7	237.1	240.6	243.8	245.3
96	246.0	246.3	247.7	247.6	247.8
101	249.4	249.0	249.9	250.5	251.5
106	249.0	247.6	248.8	250.4	250.7
111	253.0	253.7	255.0	256.2	256.0
116	257.4	260.4	260.0	261.3	260.4
121	261.6	260.8	259.8	259.0	258.9
126	257.4	257.7	257.9	257.4	257.3
131	257.6	258.9	257.8	257.7	257.2
136	257.5	256.8	257.5	257.0	257.6
141	257.3	257.5	259.6	261.1	262.9
146	263.3	262.8	261.8	262.2	262.7

11. 国际航运乘客资料

1949 年 1 月—1960 年 12 月各月总数(千人)

年	1 月	2 月	3 月	4 月	5 月	6 月	7 月	8 月	9 月	10 月	11 月	12 月
1949	112	118	132	129	121	135	148	148	136	119	104	118
1950	115	126	141	135	125	149	170	170	158	133	114	140
1951	145	150	178	163	172	178	199	199	184	162	146	166
1952	171	180	193	181	183	218	230	242	209	191	172	194
1953	196	196	236	235	229	243	264	272	237	211	180	201
1954	204	188	235	227	234	264	302	293	259	229	203	229
1955	242	233	267	269	270	315	364	347	312	274	237	278
1956	284	277	317	313	318	374	413	405	355	306	271	306
1957	315	301	356	348	355	422	465	467	404	347	305	306
1958	340	318	362	348	363	435	491	505	404	359	310	337
1959	360	342	406	396	420	472	548	559	463	407	362	405
1960	417	391	419	461	472	535	622	606	508	461	390	432
共 144 个观察值												

12. 裂纹扩散资料

10.9800	11.0800	11.2400	11.3300	11.4600
11.5100	11.5800	11.6500	11.7700	11.8600
11.9900	12.0900	12.1900	12.3701	12.5401
12.6301	12.8101	12.9801	13.1301	13.2801
13.3901	13.5401	13.6401	13.7401	13.8301
14.0201	14.1101	14.1801	14.2601	14.4001
14.4501	14.5101	14.6102	14.6602	14.7502
14.8602	14.9902	15.1202	15.2802	15.4802
15.5702	15.7002	15.7502	15.8602	15.9402
15.9702	16.1202	16.0902	16.4102	16.5102
16.6102	16.7102	16.8103	16.9103	17.0103
17.1103	17.1903	17.2803	17.3703	17.4603
17.5603	17.6603	17.6603	17.8103	17.9103
18.0103	18.1103	18.2103	18.3103	18.4103
18.5103	18.6103	18.7104	18.8104	18.9104
19.0604	19.2104	19.3104	19.4004	19.4604
19.5804	19.7104	19.8104	19.9104	20.0104
20.1104	20.2604	20.3104	20.4104	20.5104
共 90 个观察值(横读)				

13. 1946—1970年美国各季生产者耐用品支出资料

年 度	季 度			
	一季	二季	三季	四季
	243,私人国内固定投资总额,耐用生产设备			
	(按年率计,十亿美元)			
1946	7.5	8.9	11.1	13.4
1947	15.5	15.7	15.6	16.7
1948	18.0	17.4	17.9	18.8
1949	17.6	17.0	16.1	15.7
1950	15.9	17.9	20.3	20.4
1951	20.2	20.5	20.9	20.9
1952	21.1	21.4	18.2	20.1
1953	21.4	21.3	21.9	21.3
1954	20.4	20.4	20.7	20.7
1955	20.9	23.0	24.9	26.5
1956	25.6	26.1	27.0	27.2
1957	28.1	28.0	29.1	28.3
1958	25.7	24.5	24.4	25.5
1959	27.0	28.7	29.1	29.0
1960	29.6	31.2	30.6	29.8
1961	27.6	27.7	29.0	30.3
1962	31.0	32.1	33.5	33.2
1963	33.2	33.8	35.5	36.8
1964	37.9	39.0	41.0	41.6
1965	43.7	44.4	46.6	48.3
1966	50.2	52.1	54.0	56.0
1967	53.9	55.6	55.4	56.2
1968	57.9	57.3	58.8	60.4
1969	63.1	83.5	64.8	65.7
1970	64.8	65.6	67.2	62.1

14. 磨轮剖面资料:(采样间隔 $\Delta=0.002$)

13.5	4.0	4.0	4.5	3.0	3.0	10.0	10.2	9.0	10.0
8.5	7.0	10.5	7.5	7.0	10.5	9.5	7.0	12.0	13.5
12.5	15.0	13.0	11.0	9.0	10.5	10.5	11.5	10.5	9.0
8.2	8.5	9.2	8.5	10.0	14.5	13.0	2.0	6.0	6.0
11.0	9.5	12.5	13.8	12.0	12.0	12.0	13.0	12.0	14.0
14.5	13.5	12.3	7.0	7.0	7.0	6.5	12.5	15.0	12.5
11.6	11.0	10.0	8.5	3.0	11.5	11.5	11.5	11.0	9.0
2.5	7.0	6.0	6.6	14.0	11.0	9.0	6.5	4.0	6.0
12.0	11.0	12.0	12.5	12.5	13.6	13.0	8.0	6.5	6.8
6.0	7.2	10.2	8.0	7.5	11.0	11.8	11.8	6.5	8.0
9.0	8.0	8.0	9.0	9.5	10.0	9.0	12.0	13.5	13.8
15.0	12.5	11.0	11.5	14.5	11.5	11.8	13.0	15.0	14.5
13.0	9.0	11.0	9.0	10.0	14.0	13.5	3.0	2.2	6.0
8.0	9.0	9.0	9.0	7.0	6.0	6.5	7.0	7.5	8.5
9.0	9.5	10.0	11.5	11.2	12.5	11.6	8.0	7.0	6.0
6.0	6.0	9.0	12.0	13.5	13.0	3.5	1.8	1.6	7.5
8.0	7.9	11.6	12.5	10.5	8.0	9.0	11.6	11.8	12.6
10.2	10.0	5.0	7.0	-1.0	0.0	0.0	3.0	11.0	12.0
12.2	11.0	8.0	7.0	5.5	10.0	11.5	7.0	4.0	7.0
7.0	10.0	9.0	8.0	10.0	13.0	10.0	6.5	11.0	13.0
13.0	14.0	13.0	12.5	12.0	9.0	8.5	7.0	8.5	10.0
8.0	4.0	3.0	10.0	13.0	13.0	13.0	12.0	11.0	11.0
11.0	14.5	14.0	14.0	13.5	10.0	9.5	10.0	12.5	10.0
9.0	9.0	4.0	3.0	6.0	5.0	7.0	6.0	5.0	8.5
10.5	11.1	11.0	10.0	11.2	8.0	2.5	5.0	13.2	14.0

共 250 个观察值(横续)

15. 某地 1984 年 2 月 1 日—8 月 18 日每天中午温度值(℃)

-5.1	-10.1	-3	-1.1	-0.1	-0.6	-7.6	-4.6	-0.2	-7.3
-7.3	-0.1	-0.5	-2.8	-5.0	-6.7	-5.8	-4.6	-5.1	-4.0
-6.4	-3.4	-4.3	-5.1	-4.9	-4.6	-7.1	-7.7	-9.7	-5.2
-6.6	-7.4	-3.9	-3.8	-1.1	-1.4	-4.8	-6.4	-8.0	-9.6
-4.2	-0.2	0	0.8	2.9	2.6	-0.4	-3.0	-4.6	-5.6
-2.8	-3.9	-3.4	-0.8	-3.8	-5.7	-6.3	-6.0	-5.3	-4.3
-3.4	-1.6	2.0	0.1	-1.2	-0.8	0.3	1.7	-0.7	1.9
0.4	-2.6	-3.7	-2.4	-1.5	-2.9	-4.2	-4.9	-0.7	-3.1
-4.5	-4.1	-4.2	-2.2	-3.3	-2.6	-2.4	-2.4	-2.8	-4.3
-3.2	-3.5	-3.7	-2.3	-2.5	-3.9	-4.7	-0.2	-2.1	1.8
3.8	-0.4	0.3	0	0.6	-0.1	1.7	-2.4	-0.5	-2.9
-0.6	3.7	5.4	7.6	2.2	3.6	7.8	7.8	5.8	1.8
2.7	0.7	1.4	4.2	3.7	0.3	0.6	0.6	-0.6	-0.7
2.8	2.7	1.5	2.1	-0.2	0	3.3	5.8	3.4	1.8
3.6	4.9	3.9	1.2	5.5	0.1	5.5	7.6	13.6	9.7
7.9	10.5	8.4	10.5	12.2	10.5	7.7	6.2	7.2	9.1
9.2	4.9	5.3	7.6	4.8	4.8	2.8	2.3	1.1	0.1
1.2	1.2	5.5	4.3	1.7	-0.1	1.6	4.3	3.9	6.1
6.9	5.9	7.3	5.0	2.8	3.1	5.0	7.2	8.8	13.6
13.1	12.3	11.4	11.3	7.2	4.9	5.1	7.1	8.2	9.7

共 200 个观察值(横续)

16. 我国社会消费品零售总额

obs	SHXZ				
1950			262.7	328.8	356.1
1955	364.0	424.0	441.6	481.2	556.5
1960	595.4	537.7	543.7	544.8	572.7
1965	590.1	632.8	679.1	649.2	698.2
1970	728.8	776.9	853.5	917.7	967.4
1975	1046.4	1099.0	1174.3	1264.9	1476.0
1980	1794.0	2002.5	2181.5	2426.1	2899.2
1985	3801.4	4374.0	5115.0	6534.6	7074.2
1990	7250.3	8245.7	9704.8	12462.1	16264.7

17. 甲地某商品月销售量

obs	SPXL					
1987.01	565.7880	602.1000	671.0000	601.0000	582.0000	671.3000
1987.07	502.3100	218.1500	558.3200	590.1000	549.1360	574.1200
1988.01	577.6530	610.1881	679.7322	610.3728	592.8210	681.4035
1988.07	510.7355	227.0364	565.8856	600.4348	556.7070	583.9951
1989.01	586.4032	618.3755	688.0472	618.5826	600.4841	690.4011
1989.07	520.9200	235.8070	575.7081	609.8273	566.4122	591.1332
1990.01	594.9673	626.1514	697.9186	626.9127	609.3660	698.1413
1990.07	531.1883	243.9958	583.5424	617.2897	575.9749	601.5099
1991.01	603.2225	636.8149	707.1452	638.0379	620.6295	707.2703
1991.07	539.0789	252.8602	591.7836	626.9935	582.6923	611.3965
1992.01	612.8489	645.9645	715.9899	646.1702	628.2095	717.1703
1992.07	549.4425	259.8826	601.1425	637.4908	592.8298	620.8653
1993.01	620.2722	655.7020	723.8026	654.8081	636.0499	725.7692
1993.07	557.4150	270.9799	611.3857	646.0962	602.6265	630.0778
1994.01	629.6026	663.0500	733.8522	664.6104	645.5190	735.4458
1994.07	566.1298	279.3648	620.6696	654.9507	611.4662	637.0239
1995.01	640.5817	672.2036	743.0334	675.1520	655.5609	741.9791
1995.07	573.6024	288.2158	627.7034	663.0892	620.7718	647.4319
1996.01	649.4008	681.6999	752.3501	684.5226	663.9633	753.3347
1996.07	583.9347	297.6162	639.4998	672.4449	629.9501	655.4984

18. 每隔 20 分钟进行一次观察的造纸过程人口开关调节器的观察值

33.5	34.0	33.5	33.5	33.5	33.0	33.0	33.5	33.5	33.3
33.3	33.5	33.0	32.5	32.5	32.8	32.8	32.5	32.5	32.2
32.5	32.5	32.5	32.3	32.0	32.5	32.5	32.5	34.0	33.3
33.0	32.5	32.5	32.5	32.8	32.8	32.8	32.2	32.7	33.0
33.0	33.0	32.5	32.0	32.0	31.8	31.8	31.8	32.5	32.7
32.7	32.0	32.0	32.6	32.4	32.4	32.5	32.5	32.5	32.5
32.8	32.5	32.5	32.4	32.4	32.4	32.4	32.0	32.1	32.1
32.1	31.6	31.6	31.5	31.5	31.2	31.2	31.4	31.4	31.4
31.4	31.6	31.2	31.8	32.2	32.0	32.3	32.0	31.5	31.2
31.2	31.2	31.2	31.2	31.2	31.0	31.0	31.2	31.2	32.2
32.2	32.2	31.5	31.5	31.5	31.6	31.6	31.8	31.6	31.4
31.4	31.4	31.8	32.0	31.8	31.8	31.6	31.6	31.8	31.8
31.8	31.8	32.5	32.3	32.0	32.0	32.0	31.5	31.5	31.5
31.5	31.5	32.0	32.0	32.3	32.3	32.3	30.7	32.0	31.2
31.2	31.0	30.7	30.7	30.7	30.7	30.7	31.0	31.7	31.0
30.7	30.7	31.0	31.0	31.3	31.3	32.0	31.3	31.5	31.5

共 160 个观察值(横读)

19. 我国人口自然增长率

obs	ZZL				
1945					16.00000
1950	19.00000	20.00000	20.00000	23.00000	24.00000
1955	20.32000	20.50000	23.23000	17.24000	10.19000
1960	-4.570000	3.780000	26.99000	33.33000	27.64000
1965	28.38000	26.22000	25.53000	27.38000	26.08000
1970	25.83000	23.33000	22.16000	20.89000	17.48000
1975	15.69000	12.66000	12.06000	12.00000	11.61000
1980	11.87000	14.55000	14.49000	11.54000	10.81000
1985	13.08000	14.26000	15.57000	16.61000	15.73000
1990	15.04000	14.39000	12.98000	11.60000	11.45000
1995	11.21000	10.50000	10.42000	10.06000	



20. 乙地某商品月销售量

obs	YS2					
1987.01	526.3987	556.0709	617.2659	558.5538	542.3851	616.7453
1987.07	470.5933	223.4062	519.9192	549.4421	512.5740	536.9828
1988.01	539.1855	568.1818	628.2266	568.6274	552.0534	632.0725
1988.07	481.6308	229.4143	530.8540	560.5250	521.2866	547.3271
1989.01	550.2667	576.2448	640.5750	579.8681	564.7891	644.5893
1989.07	492.4651	230.0486	541.8510	571.4490	533.8619	559.1920
1990.01	560.5261	591.0433	655.1954	591.7454	574.4050	658.0079
1990.07	501.1520	236.7997	548.8442	582.3910	542.6987	567.8044
1991.01	569.4335	600.7332	667.3147	604.4360	583.9062	669.6766
1991.07	509.9894	242.0661	560.4958	594.9420	553.6306	579.7051
1992.01	581.4083	611.8552	680.6451	614.5814	597.0051	683.3079
1992.07	520.5683	246.0247	567.9114	605.7431	564.0059	591.5355
1993.01	593.0916	623.1721	691.8281	624.4797	608.9286	694.1287
1993.07	528.8229	248.1450	582.2176	616.3854	575.4156	603.4721
1994.01	602.5389	637.6888	706.6971	635.7217	617.7324	706.5585
1994.07	539.8796	255.6750	593.3485	627.7528	585.2082	611.4493
1995.01	612.7556	646.3898	719.0649	648.4842	629.2500	720.0668
1995.07	547.5514	261.0133	604.1880	640.0220	593.5602	622.7147
1996.01	625.3325	658.6443	730.5227	661.5298	641.5368	732.0021
1996.07	558.3789	265.7508	614.9130	649.8342	605.5983	635.3240

附录 IV

常用统计量分布表

1. t 分布表




$$P\{t(n) > t_{\alpha}(n)\} = \alpha$$

$$P\{|t(n)| > t_{\alpha/2}(n)\} = \alpha$$

$\begin{matrix} p \\ n \end{matrix}$		单 边 检 验 显 著 性 水 平 p							
		.005	.01	.025	.05	.1	.15	.2	.25
1		63.66	31.82	12.71	6.31	3.08	1.96	1.38	1.00
2		9.93	6.97	4.30	2.92	1.89	1.39	1.06	0.82
3		5.84	4.54	3.18	2.35	1.64	1.25	0.98	0.77
4		4.60	3.75	2.78	2.18	1.53	1.19	0.94	0.74
5		4.03	3.37	2.57	2.02	1.48	1.16	0.92	0.73
6		3.71	3.14	2.45	1.94	1.44	1.13	0.91	0.72
7		3.50	3.00	2.37	1.90	1.42	1.12	0.90	0.71
8		3.36	2.90	2.31	1.86	1.40	1.11	0.89	0.71
9		3.25	2.82	2.26	1.83	1.38	1.10	0.88	0.70
10		3.17	2.71	2.23	1.81	1.37	1.09	0.88	0.70
11		3.11	2.72	2.20	1.80	1.36	1.09	0.88	0.70
12		3.06	2.68	2.18	1.78	1.36	1.08	0.87	0.70
13		3.01	2.65	2.16	1.77	1.35	1.08	0.87	0.69
14		2.98	2.62	2.15	1.76	1.35	1.08	0.87	0.69
15		2.95	2.60	2.13	1.75	1.34	1.07	0.87	0.69
16		2.92	2.58	2.12	1.75	1.34	1.07	0.87	0.69
17		2.90	2.57	2.11	1.74	1.33	1.07	0.86	0.69
18		2.88	2.55	2.10	1.73	1.33	1.07	0.86	0.69
19		2.86	2.54	2.09	1.73	1.33	1.07	0.86	0.69
20		2.85	2.53	2.09	1.73	1.33	1.06	0.86	0.69
21		2.83	2.52	2.08	1.72	1.32	1.06	0.86	0.69
22		2.82	2.51	2.07	1.72	1.32	1.06	0.86	0.69
23		2.81	2.50	2.07	1.71	1.32	1.06	0.86	0.69
24		2.80	2.49	2.06	1.71	1.32	1.06	0.86	0.69
25		2.79	2.49	2.06	1.71	1.32	1.06	0.86	0.68
26		2.78	2.48	2.06	1.71	1.32	1.06	0.86	0.68
27		2.77	2.47	2.05	1.70	1.31	1.06	0.86	0.68
28		2.76	2.47	2.05	1.70	1.31	1.06	0.86	0.68
29		2.76	2.46	2.05	1.70	1.31	1.06	0.85	0.68
30		2.75	2.46	2.04	1.70	1.31	1.06	0.85	0.68
		2.58	2.33	1.96	1.65	1.28	1.04	0.84	0.68
$\begin{matrix} n \\ p \end{matrix}$		.01	.02	.05	.10	.20	.30	.40	.50
		双 边 检 验 显 著 性 水 平 p							


2. χ^2 分布表



本表给出 χ_0^2 值使 $P(\chi^2 \geq \chi_0^2) = \alpha$ (阴影面积)

α	0.995	0.990	0.975	0.950	0.900	0.500	0.100	0.050	0.025	0.010	0.005
ν											
1	0.00	0.00	0.00	0.00	0.02	0.45	2.71	3.84	5.02	6.63	7.88
2	0.01	0.02	0.05	0.10	0.21	1.39	4.61	5.99	7.38	9.21	10.60
3	0.07	0.11	0.22	0.35	0.58	2.37	6.25	7.81	9.35	11.34	12.84
4	0.21	0.30	0.48	0.71	1.06	3.36	7.78	9.49	11.14	13.28	14.86
5	0.41	0.55	0.83	1.15	1.61	4.35	9.24	11.07	12.83	15.09	16.75
6	0.68	0.87	1.21	1.64	2.20	5.35	10.65	12.59	14.45	16.81	18.55
7	0.99	1.24	1.69	2.17	2.83	6.35	12.02	14.07	16.01	18.48	20.23
8	1.34	1.65	2.18	2.73	3.49	7.34	13.36	15.51	17.53	20.09	21.96
9	1.73	2.09	2.70	3.33	4.17	8.34	14.68	16.92	19.02	21.67	23.59
10	2.16	2.56	3.25	3.94	4.87	9.34	15.99	18.31	20.48	23.21	25.19
11	2.60	3.05	3.82	4.57	5.58	10.31	17.28	19.68	21.92	24.72	26.76
12	3.07	3.57	4.40	5.23	6.30	11.34	18.55	21.03	23.34	26.22	28.30
13	3.57	4.11	5.01	5.89	7.04	12.34	19.81	22.36	24.74	27.69	29.82
14	4.07	4.66	5.63	6.57	7.79	13.34	21.06	23.68	26.12	29.41	31.32
15	4.60	5.23	6.27	7.26	8.55	14.34	22.31	25.00	27.49	30.58	32.80
16	5.14	5.81	6.91	7.96	9.31	15.34	23.54	26.30	28.85	32.00	34.27
17	5.70	6.41	7.56	8.67	10.00	16.34	24.77	27.59	30.19	33.41	35.72
18	6.26	7.01	8.23	9.39	10.87	17.34	25.99	28.87	31.53	34.81	37.16
19	6.84	7.63	8.91	10.12	11.65	18.34	27.20	30.14	32.85	36.19	38.58
20	7.43	8.26	9.59	10.85	12.44	19.38	28.41	31.41	34.17	37.57	40.00
21	8.03	8.90	10.23	11.50	13.24	20.38	29.62	32.67	35.48	38.93	41.40
22	8.64	9.54	10.98	12.34	14.04	21.34	30.81	33.92	36.78	40.29	42.80
23	9.29	10.20	11.69	13.09	14.85	22.34	32.01	35.17	38.08	44.64	44.18
24	9.89	10.86	12.40	13.85	15.66	23.34	33.20	36.42	39.36	42.98	45.56
25	10.50	11.52	13.12	14.61	16.47	24.34	34.33	37.65	40.65	44.31	46.93
26	11.16	12.20	13.84	15.38	17.29	25.34	35.56	38.89	41.92	45.64	48.29
27	11.81	12.88	14.57	16.15	18.11	26.34	36.74	40.11	43.19	46.96	49.65
28	12.46	13.57	15.31	16.93	18.94	27.34	37.92	41.34	44.46	48.28	50.99
29	13.12	14.26	16.05	17.71	19.77	28.34	39.09	43.56	45.72	49.59	52.34
30	13.79	14.95	16.79	18.49	20.60	29.34	40.26	43.77	46.98	50.89	53.67
40	20.71	22.16	24.43	26.51	29.05	39.34	51.80	55.76	59.34	63.69	66.77
50	27.99	29.71	32.36	34.76	37.69	49.33	63.17	67.50	71.42	76.15	79.49
70	43.28	45.44	48.76	51.74	55.33	69.33	85.53	90.53	95.02	100.42	104.22
100	67.33	70.06	74.22	77.93	82.36	99.33	118.50	124.34	129.56	135.81	140.17

3. F 分布表



本表给出 $F_{v_1, v_2, p}$ 使 $P(F \geq F_{v_1, v_2, 0.95}) = 0.05$

$v_1 \backslash v_2$	1	2	3	4	5	6	7	8	9
1	161.4	199.5	215.7	224.6	230.2	234.0	236.8	238.9	240.5
2	18.51	19.00	19.61	19.25	19.30	19.33	19.35	19.37	19.38
3	10.13	9.55	9.28	9.12	9.01	8.94	8.89	8.85	8.81
4	7.71	6.94	6.59	6.39	6.26	6.16	6.09	6.04	6.00
5	6.61	5.79	5.41	5.19	5.05	4.95	4.88	4.82	4.77
6	5.99	5.14	4.76	4.53	4.39	4.28	4.21	4.15	4.10
7	5.59	4.74	4.35	4.12	3.97	3.87	3.79	3.73	3.68
8	5.32	4.46	4.07	3.84	3.69	3.58	3.50	3.44	3.39
9	5.12	4.26	3.86	3.63	3.48	3.37	3.29	3.23	3.18
10	4.96	4.10	3.71	3.48	3.33	3.22	3.14	3.07	3.02
11	4.84	3.98	3.59	3.36	3.20	3.09	3.01	2.95	2.90
12	4.75	2.89	3.49	3.26	3.11	3.00	2.91	2.85	2.80
13	4.67	3.81	3.41	3.18	3.03	2.92	2.83	2.77	2.71
14	4.60	3.74	3.34	3.11	2.96	2.85	2.76	2.70	2.65
15	4.54	3.68	3.29	3.06	2.90	2.79	2.71	2.64	2.59
16	4.49	3.63	3.24	3.01	2.85	2.74	2.66	2.59	2.54
17	4.45	3.59	3.20	2.96	2.81	2.70	2.61	2.55	2.49
18	4.41	3.55	3.16	2.93	2.77	2.66	2.58	2.51	2.46
19	4.38	3.52	3.13	2.90	2.74	2.63	2.54	2.48	2.42
20	4.35	3.49	3.10	2.87	2.71	2.60	2.51	2.45	2.39
21	4.32	3.47	3.07	2.84	2.68	2.57	2.49	2.42	2.37
22	4.30	3.44	3.05	2.82	2.66	2.55	2.46	2.40	2.34
23	4.28	3.42	3.03	2.80	2.64	2.53	2.44	2.37	2.32
24	4.26	3.40	3.01	2.78	2.62	2.51	2.42	2.36	2.30
25	4.24	3.39	2.99	2.76	2.60	2.49	2.40	2.34	2.28
26	4.23	3.37	2.98	2.74	2.59	2.47	2.39	2.32	2.27
27	4.21	3.35	2.96	2.73	2.57	2.46	2.37	2.31	2.25
28	4.20	3.34	2.95	2.71	2.56	2.45	2.36	2.29	2.24
29	4.18	3.33	2.93	2.70	2.55	2.43	2.35	2.29	2.22
30	4.17	3.32	2.92	2.69	2.53	2.42	2.33	2.27	2.21
40	4.08	3.23	2.84	2.61	2.45	2.34	2.25	2.18	2.12
60	4.00	3.15	2.76	2.53	2.37	2.25	2.17	2.10	2.04
120	3.92	3.07	2.68	2.45	2.29	2.17	2.09	2.02	1.96
∞	3.84	3.00	2.60	2.37	2.21	2.10	2.01	1.94	1.88

4. Durbin-Watson 统计量 d (d_L 和 d_U 的显著点:1%)

n	$k'=1$		$k'=2$		$k'=3$		$k'=4$		$k'=5$	
	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U
15	0.81	1.07	0.70	1.25	0.59	4.46	0.49	1.70	0.39	1.96
16	0.84	1.09	0.74	1.25	0.63	1.44	0.53	1.66	0.44	1.90
17	0.87	1.10	0.77	1.25	0.67	1.43	0.57	1.63	0.48	1.85
18	0.90	1.12	0.80	1.26	0.71	1.42	0.61	1.60	0.52	1.80
19	0.93	1.13	0.83	1.26	0.74	1.41	0.65	1.58	0.56	1.77
20	0.95	1.15	0.86	1.27	0.77	1.41	0.58	1.67	0.60	1.74
21	0.97	1.16	0.89	1.27	0.80	1.41	0.72	1.55	0.63	1.71
22	1.00	1.17	0.91	1.28	0.83	1.40	0.75	1.54	0.66	1.69
23	1.02	1.19	0.94	1.29	0.86	1.40	0.77	1.53	0.70	1.67
24	1.04	1.20	0.96	1.30	0.88	1.41	0.80	1.53	0.72	1.66
25	1.05	1.21	0.98	1.30	0.90	1.41	0.83	1.52	0.75	1.65
26	1.07	1.22	1.00	1.31	0.93	1.41	0.85	1.52	0.78	1.64
27	1.09	1.23	1.02	1.32	0.95	1.41	0.88	1.51	0.81	1.63
28	1.10	1.24	1.04	1.32	0.97	1.41	0.90	1.51	0.83	1.62
29	1.12	1.25	1.05	1.33	0.99	1.42	0.92	1.51	0.85	1.61
30	1.13	1.26	1.07	1.34	1.01	1.42	0.94	1.51	0.88	1.61
31	1.15	1.27	1.08	1.34	1.02	1.42	0.96	1.51	0.90	1.60
32	1.16	1.28	1.10	1.35	1.04	1.43	0.98	1.51	0.92	1.60
33	1.17	1.29	1.11	1.36	1.05	1.43	1.00	1.51	0.94	1.59
34	1.18	1.30	1.13	1.36	1.07	1.43	1.01	1.51	0.97	1.59
35	1.19	1.31	1.14	1.37	1.08	1.44	1.03	1.51	0.97	1.59
36	1.21	1.32	1.15	1.38	1.10	1.44	1.04	1.51	0.99	1.59
37	1.22	1.32	1.16	1.38	1.11	1.45	1.06	1.51	1.00	1.59
38	1.23	1.33	1.18	1.39	1.12	1.45	4.07	1.52	1.02	1.58
39	1.24	1.34	1.19	1.39	1.14	1.45	1.09	1.52	1.03	1.58
40	1.25	1.34	1.20	1.40	1.15	1.46	1.10	1.52	1.05	1.58
45	1.29	1.38	1.24	1.42	1.20	1.48	1.16	1.53	1.11	1.58
50	1.32	1.40	1.28	1.45	1.24	1.49	1.20	1.54	1.16	1.59
55	1.36	1.43	1.32	1.47	1.28	1.51	1.25	1.55	1.21	1.59
60	1.38	1.45	1.35	1.48	1.32	1.52	1.28	1.56	1.25	1.60
65	1.41	1.47	1.38	1.50	1.35	1.53	1.31	1.57	1.28	1.61
70	1.43	1.49	1.40	1.52	1.37	1.55	1.34	1.58	1.31	1.61
75	1.45	1.50	1.42	1.53	1.39	1.56	1.37	1.59	1.34	1.62
80	1.47	1.52	1.44	1.54	1.42	1.57	1.39	1.69	1.36	1.62
85	1.48	1.53	1.46	1.55	1.43	1.58	1.41	1.60	1.39	1.63
90	1.50	1.54	1.47	1.56	1.45	1.59	1.43	1.61	1.41	1.64
95	1.51	1.55	1.49	1.57	1.47	1.60	1.45	1.62	1.42	1.64
100	1.52	1.56	1.50	1.58	1.48	1.60	1.46	1.63	1.44	1.65

n = 观测值的个数

k' = 说明变量的个数

本表摘自 J Durbin and G. S. Watson (1951): "Testing for Serial Correlation in Squares Regression", Biometrika Vol. 38, 150—177.


续 4: Durbin-Watson 统计量 $d(d_L$ 和 d_U 的显著点: 5%)

n	$k'=1$		$k'=2$		$k'=3$		$k'=4$		$k'=5$	
	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U
15	1.08	1.36	0.95	1.54	0.82	1.75	0.69	1.97	0.56	2.21
16	1.10	1.37	0.98	1.54	0.86	1.73	0.74	1.93	0.62	2.15
17	1.13	1.38	1.02	1.54	0.90	1.71	0.78	1.90	0.67	2.10
18	1.16	1.39	1.05	1.53	0.93	1.69	0.82	1.87	0.71	2.06
19	1.18	1.40	1.08	1.53	0.97	1.68	0.86	1.85	0.75	2.02
20	1.20	1.41	1.10	1.54	1.00	1.68	0.90	1.83	0.79	1.99
21	1.22	1.42	1.13	1.54	1.03	1.67	0.93	1.81	0.83	1.96
22	1.24	1.43	1.15	1.54	1.05	1.66	0.96	1.80	0.86	1.94
23	1.26	1.44	1.17	1.54	1.08	1.66	0.99	1.79	0.90	1.92
24	1.27	1.45	1.19	1.55	1.10	1.66	1.01	1.78	0.93	1.90
25	1.29	1.45	1.21	1.55	1.12	1.66	1.04	1.77	0.95	1.89
26	1.30	1.46	1.22	1.55	1.14	0.65	1.06	1.76	0.98	1.88
27	1.32	1.47	1.24	1.56	1.16	1.65	1.08	1.76	1.01	1.86
28	1.33	1.48	1.26	1.56	1.18	1.65	1.10	1.75	1.03	1.85
29	1.34	1.48	1.27	1.56	1.20	1.65	1.12	1.74	1.05	1.84
30	1.35	1.49	1.28	1.57	1.21	1.65	1.14	1.74	1.07	1.83
32	1.37	1.50	1.31	1.57	1.24	1.65	1.18	1.73	1.11	1.82
33	1.38	1.51	1.32	1.58	1.26	1.65	1.19	1.73	1.13	1.81
34	1.39	1.51	1.33	1.58	1.27	1.65	1.21	1.73	1.15	1.81
35	1.40	1.52	1.34	1.58	1.28	1.65	1.22	1.73	1.16	1.80
36	1.41	1.52	1.35	1.59	1.29	1.65	1.24	1.73	1.18	1.80
37	1.42	1.53	1.36	1.59	1.31	1.66	1.25	1.72	1.19	1.80
38	1.43	1.54	1.37	1.59	1.32	1.66	1.26	1.72	1.21	1.79
39	1.43	1.54	1.38	1.60	1.33	1.66	1.27	1.72	1.22	1.79
40	1.44	1.54	1.39	1.60	1.34	1.66	1.29	1.72	1.23	1.79
45	1.48	1.57	1.43	1.62	1.38	1.67	1.34	1.72	1.29	1.78
50	1.50	1.59	1.46	1.63	1.42	1.67	1.38	1.72	1.34	1.77
55	1.53	1.60	1.49	4.64	1.45	1.68	1.41	1.72	1.38	1.77
60	1.55	1.62	1.51	1.65	1.48	1.69	1.44	1.73	1.41	1.77
65	1.57	1.63	1.54	1.66	1.50	1.70	1.47	1.73	1.44	1.77
70	1.58	1.64	1.55	1.67	1.52	1.70	1.49	1.74	1.46	1.77
75	1.60	1.65	1.57	1.68	1.54	1.71	1.51	1.74	1.49	1.77
80	1.61	1.66	1.59	1.69	1.56	1.72	1.53	1.74	1.51	1.77
85	1.62	1.67	1.60	1.70	1.57	1.72	1.55	1.75	1.52	1.77
90	1.63	1.68	1.61	1.70	1.59	1.73	1.57	1.75	1.54	1.78
95	1.64	1.69	1.62	1.71	1.60	1.93	1.58	1.75	1.56	1.78
100	1.65	1.69	1.63	1.72	1.61	1.74	1.59	1.76	1.57	1.78

n = 观测值的个数

k' = 说明变量的个数

5. 游程检验用 r 分布表



给定 n_1 和 n_2 , 表中给出下限 r_L 和上限 r_U 使得它们左右对应的概率为 $\alpha/2=0.025$ 即

$$P(r \leq r_L) + P(r \geq r_U) = 0.05$$

$n_1 \backslash n_2$		$L \quad U$													
		2	3	4	5	6	7	8	9	10	11	12	13	14	15
2	L											2	2	2	2
	U														
3	L					2	2	2	2	2	2	2	2	2	2
	U														
4	L				2	2	2	3	3	3	3	3	3	3	3
	U				9	9									
5	L		2	2	3	3	3	3	3	3	4	4	4	4	4
	U		9	10	10	11	11								
6	L	2	2	3	3	3	3	4	4	4	4	4	5	5	5
	U		9	10	11	12	12	13	13	13	13				
7	L	2	2	3	3	3	4	4	5	5	5	5	5	5	5
	U			11	12	13	13	14	14	14	14	15	15	15	15
8	L	2	3	3	3	4	4	5	5	5	6	6	6	6	6
	U			11	12	13	14	14	15	15	16	16	16	16	16
9	L	2	3	3	4	4	5	5	5	6	6	6	7	7	7
	U				13	14	14	15	16	16	16	17	17	18	18
10	L	2	3	3	4	5	5	5	6	6	7	7	7	7	7
	U				13	14	15	16	16	17	17	18	18	18	18
11	L	2	3	4	4	5	5	6	6	7	7	7	8	8	8
	U				13	14	15	16	17	17	18	19	19	19	19
12	L	2	2	3	4	4	5	6	6	7	7	7	8	8	8
	U				13	14	16	16	17	18	19	19	20	20	20
13	L	2	2	3	4	5	5	6	6	7	7	8	8	9	9
	U					15	16	17	18	19	19	20	20	21	21
14	L	2	2	3	4	5	5	6	7	7	8	8	9	9	9
	U					15	16	17	18	19	20	20	21	22	22
15	L	2	3	3	4	5	6	6	7	7	8	8	9	9	10
	U					15	16	18	18	19	20	21	22	22	22

主要参考书目

- [1] Box, G. E. P. and Jenkins, G. M. (1970), Time Series Analysis, Forecasting and Control, Holden-Day, San Francisco.
- [2] S. M Pandit and Shien Ming Wu (1983), Time Series and Analysis with Applications, MacLison John Wiley and Sons.
- [3] 安鸿志, 陈兆国, 杜金观, 潘一民 (1983):《时间序列的分析与应用》, 科学出版社。
- [4] 杨位钦, 顾岚 (1988):《时间序列分析与动态数据建模》, 北京理工大学出版社。
- [5] 施仁杰, 卢科学 (1988):《时间序列分析引论》, 西安电子科技大学出版社。
- [6] 陈兆国 (1988):《时间序列分析及其谱分析》, 科学出版社。
- [7] 谢衷洁 (1990):《时间序列分析》, 北京大学出版社。
- [8] 陈家鑫 (1989):《时间序列分析基础》, 暨南大学出版社。
- [9] (日)百川源四郎著, 姜兴起等译 (1996):《现代时间序列分析方法及其实用计算机程序》, 大连海事大学出版社。
- [10] 王耀东, 张德远, 张海雄 (1996):《经济时间序列分析》, 上海财经大学出版社。
- [11] 杜丹青 (1995):《时间序列分析》, 西南财经大学出版社。
- [12] Box, G. E. Jenkins, G. M. and Reinsel, G. C. (1994):《时间序列分析、预测与控制》(顾岚主译), 中国统计出版社 (1997)。
- [13] 冯文权 (1994):《经济预测与决策技术》, 武汉大学出版社。
- [14] 张崇甫, 陈述云, 胡希铃 (1995):《统计分析方法及其应用》, 重庆大学出版社。