

分类号 _____ 密级 _____

UDC _____

西華大學

硕士学位论文

基于区域聚类分析的改进神经网络短期风电功率预测研究



作者姓名： _____ 赵 帆

学科、专业： _____ 电力系统及其自动化

学 号： _____ 212012080802014

指导教师： _____ 杨燕翔

完成日期： _____ 2015 年 4 月


西华大学学位论文独创性声明

作者郑重声明：所呈交的学位论文，是本人在导师的指导下进行研究工作所取得的成果。尽我所知，除文中已经注明引用内容和致谢的地方外，本论文不包含其他个人或集体已经发表的研究成果，也不包含其他已申请学位或其他用途使用过的成果。与我一同工作的同志对本研究所做的贡献均已在论文中做了明确的说明并表示了谢意。

若有不实之处，本人愿意承担相关法律责任。

学位论文作者签名：

指导教师签名：



日期：2015.6.10

日期 2015.6.10

西华大学学位论文版权使用授权书


本学位论文作者完全了解学校有关保留、使用学位论文的规定，在校攻读学位期间论文工作的知识产权属于西华大学，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅，西华大学可以将本论文的全部内容编入有关数据库进行检索，可以采

用影印、缩印或扫描等复印手段保存和汇编本学位论文。（保密的论文在解密后遵守此规定）

学位论文作者签名：



指导教师签名：



日期：2015.6.10

日期 2015.6.10

Classified Index: _____

UDC: _____

Xihua University

Master Degree Dissertation

**Forecast Studies on Improving Short-term
Wind Power of Neural Nets Based on
Regional Cluster Analysis**

Candidate : Zhao Fan

Major : Electric power system and its automation

Student ID: 212012080802014

Supervisor: Prof. Yang Yanxiang

April, 2015

摘 要

科技高速发展,促使国家对环保重视程度越来越高,国民对洁净能源需求不断增加。新能源产业发展非常迅速,其中,风力发电作为一种新兴的发电方式并入电网已经越来越成为一种常态。风能本身波动性会直接导致风电场出力具有较大不可预知性,向电力系统安全运行、合理调度和发电质量提出不小考验。

如果能够预先了解风电场未来一段时间内出力,相关调配人员就可以根据预测数据提前调整调度计划,这样就可以积极、有效降低风电并网对电网稳定运行造成影响。所以,要想消除风能固有性质对电网的影响,就需要对并网的风电系统进行精确的输出功率的预测。

基于上述诸多情况,本文选择将地形较为复杂风电场短期的功率预测作为探究对象,前期研究工作发现:空间分布特征、风电场特性数据特征、训练样本相关性特征这三个数据特征量对预测结果有重要的影响。本文筛选具体风电场数据,提取出对出力影响较大特征数据,考虑风电机组空间分布的因素运用聚类的方法将风电场进行区域划分,搭建 BP 神经网络模型进行区域性的功率预测,从而得到整个总区域的预测功率,提高预测精度,本文所做研究工作如下:

(1) 首先考虑将风电机组总区域进行划分:采用谱聚类的方式将环境因素、运行工况纳入考虑,降低迭代次数,提高划分效率。

(2) 本文考虑用划分的风电机组分区域功率对全区域风电功率进行预测,分区域风电机组的出力是由和分区域相关性大标准风电机组确定,将相关系数较大的确定为标准机组。

(3) 以广西某风场数据为例找出与风电场出力最为密切特征数据,选取标准风电机组为基础搭建 MATLAB 仿真模型,收集数值天气预报提供的天气参数,利用编程搭建 BP 神经网络预测得到分区域功率以及整个区域的功率预测值。

(4) 将本文预测模型得到的分区域提前 8、4、2、1 小时的预测值与实测值进行对比,选择科学的预测周期,采用遗传算法优化神经网络再次进行预测,然后获取整个风电场预测功率,进行对比,验证本文预测方式可靠性。

(5) 分析本文预测方式的不足,总结该方法存在的问题以及探讨该方法需要提高的关键点。

关键词: 风电功率预测; 分区域; 聚类; BP 神经网络; 遗传算法

Abstract

With the rapid development of science and technology, our country attached more importance to environmental protection which also brings about an increasing demand for clean energy. New energy industry grows up fast. Being a new way of power generation, the wind power's accessing to the electrical power grid is apt to be the norm. The volatility and intermittency of wind power leads to the output fluctuation of wind farm. The operation security, economical dispatching and quality of the power are being challenged by this way.

If the coming output of the wind farm could be accurately forecast in advance, related personnel could adjust the dispatching plan timely, to reduce the detrimental effects of the wind power integration to the stability of grid-connected wind power system. Consequently, the precise prediction of the output power of grid-connected wind power system could eliminate the effect of inherent nature of wind energy.

In view of the above-mentioned facts, I choose the short-term wind power prediction with complex topographic as my object of study. In earlier work, we found the significant influence of space distribution, wind farm feature data, and the relativity of collection sample on the results. This article sifts through the specific data and extracts data which has great influence. It divides the wind farm into sections by method of clustering based on the distribution of wind turbine generator. This main aims of this paper are as follows:

Firstly, divide the entire wind farm into sub domain: clustering environmental factors, operating conditions, reducing iterations and improving the efficiency of division;

Secondly, use regional wind turbines power predict the wind power of all, regional wind turbine output is determined by the wind generator and sub- regional of greater relevance, the standard unit is stetted by the greater one;

Thirdly, find the closest data of the output by studying one example of Guangxi wind farm, selecting standard unit to build MATLAB simulation model, collecting weather parameters from numerical weather prediction, obtaining the prediction of regional and the whole area power by building BP neural network;

What's more, chose the scientific forecast cycle by contrasting the predictive value of 8 hours, 4 hours, 2 hours, and 1 hour with the measured values of traditional methods. And then obtaining the whole wind power forecast, carrying error index evaluation to verify reliability forecasting method in this paper

Last but not least, analyze the shortage of the prediction method used in this paper, summarizes the existing problems and discusses the key points to improve the method.

Key Words : Wind Power Prediction; Sub regional ; Clustering; The BP Neural Network

目 录

摘 要.....	I
Abstract.....	II
1 绪 论.....	1
1.1 风电功率预测研究背景.....	1
1.2 风电功率预测研究现状.....	2
1.2.1 国外风电功率预测研究现状.....	2
1.2.2 国内风电功率预测研究现状.....	3
1.3 课题研究意义.....	3
1.4 课题研究内容.....	4
2 风电功率输出特性及影响因素分析.....	6
2.1 风电功率理论计算.....	6
2.2 输出功率的影响因素.....	7
2.3 实例分析.....	10
2.4 本章小结.....	11
3 预测方法探究.....	12
3.1 常用预测方法介绍.....	12
3.1.1 定性预测技术.....	12
3.1.2 定量预测技术.....	13
3.2 风电功率预测方法.....	14
3.3 预测精度评价指标.....	16
3.4 本章小结.....	17
4 神经网络简介及 BP 神经网络模型.....	18
4.1 神经网络概述.....	18
4.2 BP 神经网络及建模基础.....	21
4.3 模型实例分析.....	25
4.4 本章小结.....	26
5 基于聚类思想的风电机群划分研究.....	27
5.1 概述.....	27
5.2 风力机组风速空间特征分析.....	27
5.3 风电场区域归类技术手段探究.....	28
5.4 基于扩散理论的机组谱聚类划分方法探究.....	29

5.4.1	马尔科夫转移矩阵的创建.....	29
5.4.2	马尔科夫概率转移矩阵的谱分析.....	30
5.4.3	扩散距离的计算.....	31
5.5	本章小结.....	32
6	基于区域聚类分析的改进神经网络短期风电功率预测.....	33
6.1	模型概述.....	33
6.2	基于区域聚类分析的改进神经网络风电功率预测流程.....	33
6.2.1	分区域划分.....	34
6.2.2	标准机群功率预测.....	34
6.2.3	分区域及总区域风电功率预测.....	36
6.3	实例验证.....	36
6.3.1	分区域划分.....	36
6.3.2	确定标准风电机组群.....	37
6.3.3	基于遗传算法改进的神经网络标准机组功率预测.....	38
6.3.4	风电场分区域及总区域功率预测.....	48
6.4	本章小结.....	49
7	结论与展望.....	51
7.1	结论.....	51
7.2	展望.....	52
	参考文献.....	53
	附录 A 遗传算法优化神经网络部分代码及气象数据.....	55
	攻读硕士学位期间发表学术论文情况.....	58
	致 谢.....	59

1 绪 论

1.1 风电功率预测研究背景

科技的飞速发展以及全世界对低碳环保的呼吁,使得诸如太阳能、地热能、潮汐能、风能等新能源逐步介入到国民的生产生活中来,而且普及势头迅猛。其中风能以其蕴藏丰富、洁净无污染、分布广泛、可再生的优势成为人类所利用新能源中的中坚力量^[1, 2],风力发电则是风能利用的一种主要形式;然而风能自身固有的缺陷增加了风电并网的风险,所以预测风力机组输出功率是规避风电并网风险的重要措施。

据权威机构统计:1999年至2012年期间^[3],世界范围内机组整体装机容量的平均增长速度为28.6%,2004年到2009年新增装机容量的平均增长速度为36.1%;2009年,全球风电新增装机容量达3820.9万,增长率高达44.4%;2010年全球风电新增装机容量为3940万KW,增长率为3.1%,风力发电并网第一次呈现放缓的趋势。加之欧债危机的影响,风电传统强国的发展速度明显放缓^[4, 5]。至今年年底,世界风机装机容量的年均增长率在15.5%左右,届时,全球风电装机总量将达到513.6GW,其中欧洲为179GW,东南亚188.3GW,美洲地区121.7GW。预计,2016—2020年,5年间风电市场每年平均增长速度为12%。而亚洲将在未来五年时间里成为世界风电并网运行的引领者,中国和印度将在风电普及的潮流中扮演极其重要的角色。权威咨询机构BTM对今年世界机组装机容量预测比重情况如图1.1所示。




图 1.1 各区域装机容量示意图

Fig.1.1 Schematic diagram of wind power installed capacity in different area

风力发电与常规发电方法不相同^[6],风能来源于空气的流动。风在运动的过程中,空间要素对其影响是很显著的,所以风能的随意性导致风电机组发出的风电具有未知

性；电力系统中风电的比例逐年增加，让电网中风电的比例不断增加，风电的穿透功率势必会超过一定的阈值。风电功率超过一定值后^[7]，电网的安全状况将面临严峻的挑战。

具体说来，我国的风电情况同国外相比又有自己的特殊性^[8]：我国的风资源分布呈现集中性，因此大部分的风电场建设也相对集中；风能的波动性对电网的影响尤为突出，国外的预测方法与我国风能的特点无法匹配；所以，开发出适合我国具体地理情况的风力发电预测系统势在必行。本文选择中国风电场风电功率的短期预测作为研究内容，在这样的背景下具有一定的现实意义

1.2 风电功率预测研究现状

1.2.1 国外风电功率预测研究现状

国外对风电功率预测研究发展较快^[9,10]，比较有代表性的方法主要有：丹麦 *RisQ* 国家实验室的 *Prediktor* 预测系统，西班牙 *Local Pred* 预测系统和德国 *AWPT* 预测系统等。其主体思想均是利用数值天气预报提供风机轮毂高度处的风速、风向等预测信息，然后利用风电功率预测模块提供风电功率预测值。时至今日，其他各风电强国也都意识到对风电功率预测的深远意义，竞相开发自己的商用预测系统并运用在国民生产和生活中来。

丹麦 *Predictor* 是世界上第一个风电功率预测评估系统^[11]，其预测基础是运用物理模型进行预测。利用数值天气系统的 *HIRLAM* 提供大范围的空气流动数据，然后考虑障碍物和粗糙程度的影响、粗糙度的变化、山头的加速和山谷的减速等因素提供更精确的风速预测，在风速预测的基础上得出风电场输出功率，后来，丹麦国家实验室与丹麦技术大学进行合作，联合开发了短期风电功率预测系统 *Zephyr*，该系统集合了 *Prediktor* 和 *WPPT* 的功能。

西班牙 *Local Pred* 体系充分利用高分辨率的中尺度模式的 *MM5* 或 *NWP* 模式结合流体力学软件预测风速等气象信息，再通过统计模块对预测风速进行修正，最后通过历史风电功率数据与风向、风速等气象信息建立的风电功率模型进行预测。此外，*Local Pred* 还可以通过时间序列法利用即时观测到的风电场运行记录资料提供6到8小时的风速或风电功率预测。

美国 *eWind* 风电预测系统是由 *AWSTruewind* 公司开发的^[3]预测系统。其组成模块为高精度三维大气物理数学模型、适应性统计模型、风电场输出模型和预测分发系统；该系统能够预测未来48小时内的情况，其对宾夕法尼亚州的5个风堡范围内持续12—36小时的预测值表明该系统具有较高的可靠性。

风力发电项目的迅速增长,使世界各国都将目光集中在风力发电预测领域,纷纷发出自己的预测系统或者方法,表 1.1 列举出国外典型的预测系统、所用方法及其所属研发机构^[12]。

表 1.1 国外典型短期风电功率预测体系

Tab.1.1 Foreign typical short-term wind power prediction system

预报模型	开发单位	使用方法
Predicktor	丹麦 RisQ	物理
WPPT	哥本哈根大学: IMM	统计
Zephyr、Predicktor、WPPT 组合	RisQ	物理、统计
Previento	德国 Oldenburg 大学	物理、统计
FORECASTER	英国 Garrad Hassan	统计(自适应回归)
HIRPOM	科克大学、爱尔兰、丹麦气象院	物理
LocalPred-RegioPres	西班牙马德里 CENER	物理
WPPS (AWPT)	德国 ISET	统计(神经网络)
AWPPS(More-Care)	巴黎 ARmine/Ecole des Mines de	模糊神经网络
ANEMOS	欧洲 7 个国家 26 个单位	统计、物理
Honeymoon	爱尔兰	统计、物理
eWind	美国 AWSTruewind 公司	物理

1.2.2 国内风电功率预测研究现状

我国地大物博、幅员辽阔,复杂的地形地貌、多样的自然环境决定了我国丰富的风能资源储备^[13],据统计,在我国内陆离地面 10 米高度处的风能,其可开发量合计接近 3 亿千瓦;近海风力资源是内陆的 4 倍。但是我国风电技术的发展程度与如此巨大的风能储量极不匹配,尤其是功率预测方面,与国外相比,研究尚处在起始的初级阶段。研究工作集中在对预测时刻前的一段时间功率历史数据实施预测工作,从而实现对功率的预测,预测精度不高。主要有二点原因:一、温度、气压、地形等多重因素的影响,国内尚未配备齐全的风电功率预测的软硬件设施;二、我国风电场分布辽阔,地形复杂,建立准确的模型存在相当的难度。

1.3 课题研究意义

风电功率预测的本质是以各个气象参数为基础^[14],同机组运行特性曲线相结合,对风电场未来一定运行时间内的功率进行预测并将预测结果提交电网调度机构的过程。可见,预测的实质就是借助先进的技术获取气象数据,通过数据的分析、跟踪,来达到让

随机性极强的风电可以被电力人员掌控的目的，使电网的调度管理更加高效，电网的运行状态更加稳定。

我国风能呈现极强的地域分布特点，使风电场配置密度较大，在这样的背景下，风能不可控制的特性对电网的影响更大。而又由于近地层风能的变化趋向，让我国的风电场与欧洲风电场相比，具备迥异的特性。综上：开发出具备自主知识产权的预测系统具有深刻的现实意义^[15-19]：

(1) 功率预测使电力调度部门能够提前为功率的变化做出反应并且及时的调整配电规划；这样一来，既降低了系统本身的维护成本、又能够明显减轻功率突变对电网造成的冲击；

(2) 可以保证机组始终处在有效的风速区间运行，提高发电效益，提升电能品质，提供更加优质的电能产品和服务；

(3) 可以为风电场统筹维护工作提供有力的数据支持，使风电机组运行保持在较高的盈利水平。

1.4 课题研究内容

通过对传统方法的分析，我们发现对于一个机群的短期风电功率的预测，各风电机组的区域分布是不容忽视的因素，研究区域分布和输出功率之间的关系很有必要，同时将区域分布因素纳入预测工作势必能提高预测精度。本文各章节研究的内容如下：

第一章分析课题研究背景意义，探讨世界范围内该课题发展进程以及研究现状并对广泛存在的预测方式进行列举。

第二章首先对风能进行理论分析，进而讨论了影响风力机组输出功率的各种因素，最后通过实例，运用相关系数的方法分析了各特征数据对风力机组输出功率的影响大小，通过分析认为：风力机组所处的区域位置能够表征各个影响因素的综合效果。因此对于风电场机群输出功率的预测，空间分布是一个不可忽视的作用，所以本文决定在预测中将各个机群的区域分布纳入考虑。

第三章对目前应用广泛且行之有效的各种预测方法进行具体分析，阐述各种方法的优劣，结合风电功率预测非线性特征明显、映射关系复杂、不确定性突出等特点，决定采用神经网络的方法作为基础的预测方法，通过一定的准确度评判指标来衡量方法的优劣。

第四章对神经网络发展、结构、学习方式、适用范围进行介绍，分析了其具备的各个优势，并且决定采用适用范围较广的 BP 网络作为预测的基础算法，通过编程搭建算法模型。

第五章具体探究将区域分布因素纳入考虑的具体方法，决定采用谱聚类的方式对整个风电场进行各个分区域的划分，用 Markov 矩阵对各个机组进行特征性分析，将运行情况类似、所处环境相似度高的机组归类为同一个分区域。

第六章以广西某风电场为例，收集该风电场在一定时间段内的数值天气预报，以选取的某一分区域的标准风电机组为基础在 MATLAB 中搭建预测模型，通过编程建立 BP 神经网络模型，确定网络的七个输入向量，网络训练完毕后，进行不同预测周期的标准机组的功率预测，选取科学的预测周期，采用基于遗传算法改进神经网络的方法进行各个分区域的预测工作，获取整个风电场的预测值，与实测值及传统神经网络预测法相比较，论证本文预测模型的可行性。

第七章进行全文的总结工作，并对今后的研究关注点和所涉及的重要领域进行探讨。

2 风电功率输出特性及影响因素分析

2.1 风电功率理论计算

在以往的研究中^[20]，风能的大小和空气的密度、风速、气温、压强以及流动横截面积呈现出一定的比例关系。例如：单位时间内通过与风运动方向矢量垂直界面的 $A(m^2)$ 的风能功率 P 表示为：

$$P = \frac{1}{2} \rho V^3 A \quad (2.1)$$

式(2.1)中： P 为风能，单位为 W； ρ 为空气密度，单位为 kg/m^3 ； V 为风速，单位为 m/s 。可见，风能功率与风速的三次方成正比^[21, 22]，当风速通过单位面积的空间，即： $A=1$ 时，式 (2.1) 可简化为：

$$P = \frac{1}{2} \rho V^3 \quad (2.2)$$

但是，风速具有波动性、突变性，所以，上述风能密度公式中的 V 是一个统计范畴的概念，即是一段时期范围内风速的平均水平。然而，由于风力发电机组本身构造的原因^[23]，例如：叶片数量有限、气流通过风力发电机组时遭受的阻力等原因，导致风力发电机组并不能提取风能所有的功率，根据 Bets 定律：风电机组所能吸收风能的最高效率 $\eta_{\max}$ 可用式(2.3)来计算：

$$\eta_{\max} = \frac{P_{\max}}{\frac{1}{2} \rho v_1^3 A} = \frac{\frac{8}{27} \rho A v_1^3}{\frac{1}{2} \rho v_1^3 A} = \frac{16}{27} \approx 0.593 \quad (2.3)$$

由式(2.3)可知，理论上风力发电机组能够提取的最大风能仅占全部风能的 59.3%，而大多数风力发电机组只能提取全部风能的 40%或者更少。

风电并网技术中，把让机组能够启动做功的风速称为切入风速；使风力机达到额定功率时候的确定风速称为额定风速。此时，机组的输出功率达到最大；若风速继续增大，达到一定的程度，机组就会停止运行，切出网络，避免被破坏。此时的风速称为切出风速。理论上讲，风速与风电机组有如下的关系：

$$P_M = \begin{cases} 0 & v < v_{cut-in} \text{ 或 } v \geq v_{out} \\ \frac{v - v_{cut-in}}{v_r - v_{cut-in}} P_r & v_{cut-in} \leq v < v_r \\ P_r & v_r \leq v < v_{out} \end{cases} \quad (2.4)$$

式 (2.4) 中: v 为机组轮毂高度处的风速; v_{cut-in} 是切入风速; $v_{cut-out}$ 是切出风速; v_r 是额定风速; P_r 是机组额定出力。此式只是表达出了风速与机组输出功率的理想状态下的关系, 远不能准确的描述出风机的实际输出。

2.2 输出功率的影响因素

风力发电的输出功率是外部环境因素综合作用的结果, 受外部条件的制约和影响。为提高预测精度首先应该进行的是对各类影响因素进行提取及对各类因素的影响比重进行分析。具体的影响因素有: 海拔高度、环境温度、阵风、湍流、尾流。

对影响输出功率各项因素进行提取和阐述如下:

(1) 空气温度

环境温度与输出特性作用关系如下: 温度升高会降低空气密度, 导致同样风速条件下风电机组输出功率降低。而且水蒸气对空气密度影响使潮湿空气比干燥空气轻。所以, 空气中的水蒸气含量越高, 气体密度就会降低, 促使机组功率降低。温度及机组功率关系如图 2.1 所示。




图 2.1 温度对风电机组输出功率的影响

Fig.2.1 The influence of temperature on the wind turbine output power

(2) 海拔高度

研究表明: 空气密度同海拔高度呈负相关的关系。即: 海拔升高, 空气密度数值就下降。大气压强随之降低, 如图 2.2 所示。




图 2.2 空气密度与海拔相关性示意图

Fig.2.2 Schematic diagram of correlation between air density and altitude

设置在高海拔地区的机组，周围环境空气密度低，输出功率减小，相比低海拔的机组的输出功率小。如图 2.3 所示。对于特殊的变桨距机组^[24]，只要没有达到最大出力，在风速一样的情况下，地势越高功率越低。




图 2.3 空气密度对风电机组输出影响

Fig.2.3 Air density on the influence of wind turbine output power

(3) 阵风因素

阵风是近地空气活动速度不稳定所导致的。由统计规律可知，一定地域阵风的风速比同区域平均风速大一倍；而且若平均风速本来就很大，加之复杂的地面环境，阵风风

速超过平均风速的幅度就越大。由于阵风的突变性，一次阵风达到最大风速 1s-2s 后，风速会在较短的时间内小于平均风速的一半，再出现另一次最大风速。通常情况下，当输出功率小于额定功率时，风电机组可以调整发电机转差率来适应当下的风速，使叶轮的转速达到最佳叶尖速比，优化输出功率，提高风电机组发电效率；但是，由于叶轮惯性大，且阵风风速变化很快，使风机转速不能及时反馈阵风变化，从而使风电机组效率降低。

（4）湍流因素

湍流是的一种运动状态。空气动力学意义的湍流是指短时间内的风速波动。湍流的产生是综合因素作用的结果，其重点原因有两个：一是气流经过突兀形态的地貌与地表产生摩擦；二是空气上下密度的差异以及气温升高促使气流垂在竖直方向上运动。

湍流强度是风电场重要特性指标之一，是刻画空气湍流运动特性的重要指标。通常来说，机组主要受到湍流的如下影响：一是降低风力机组输出功率；二是提高机组的多余荷载；三是对机组造成物理性伤害。

（5）尾流因素

以上所列举的四种对风电机组输出功率影响的主要因素考虑的是自然环境对独立风机的影响，事实上一个风电场的装机数量基本上是十至百台不等，除了环境对单位机组的影响以外，机组之间由于所处的地形地貌的差异，还会相互影响，而尾流效应则是相互影响的主要形式^[25]：风经过机组后，会有部分能量损失；导致位于下游的机组风速低于位于上游机组的风速，而且所处位置相隔愈近，机组之间风速影响作用愈加突出，这种情况称为尾流效应。研究表明：尾流使处在风电场下游的机组工作效率下降。尾流区域机组因为气流速度降低也使机组功率输出减小。所以尾流应该在功率预测过程中被考虑。

如上所述，一个风电场出力被多方面因素来决定，要想提高预测准确度，势必筛选出对输出功率影响较大的关键因素，并且在预测的同时尽可能多的将这些因素纳入考虑，作为输入向量和训练向量，如此一来就能够达到较高预测水平。

2.3 实例分析

采集某风电场所在地区在某个确定时刻提前 10、20、30、60 分钟的风速值和预测时刻压强、温度、湿度作为分析要点，考察其与输出功率关系的密切程度。用（2.5）式来进行分析：

$$r_{x,y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (2.5)$$

其中, $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$; $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ 。由 (2.5) 式得到计算结果^[26], 确定时刻功率和各筛选要素的相关系数计算如表 (2.1) 所示。

表 2.1 不同时刻各因素与输出相关程度

Tab.2.1 Level of the factors related to the output power at the different point

时刻 相关因素	1:00	5:30	11:00	15:00	17:30
前 10 分钟风速	0.991	0.979	0.98	0.97	0.984
前 20 分钟风速	0.979	0.97	0.978	0.948	0.955
前 30 分钟风速	0.958	0.973	0.919	0.961	0.953
前 1 小时风速	0.919	0.916	0.917	0.936	0.931
预测时刻温度	0.87	0.924	0.854	0.887	0.77
预测时刻压强	0.62	0.77	0.71	0.491	0.553
预测时刻湿度	0.371	-0.558	0.512	0.111	0.172

从实例数据可以得出如下结论: 与确定时刻功率关系密切的要素有提前 10、20、30 分钟的风速值。易知: 与前 1 小时的风速值也有较高的相关性^[27]。同预测时刻的温度、压强湿度也存在较突出的相关程度。因此在预测过程中应该尽可能多的将影响机组输出功率的因素纳入到输入向量中来, 使得构造的模型能够更为精确的映射输入-输出关系, 从而提高准确度。

2.4 本章小结

本章首先从理论的角度阐述了决定风能大小的关系式, 以及风力发电机的功率特性; 然后逐个讨论对机组功率产生影响的各个要素的影响原理和所占比重; 通过实例, 运用相关系数进行定量验证。

可以得出的结论是: 风能的大小主要是由风速来决定的, 然而具体到实际的风电场, 整个输出功率是压强、气温、尾流、湍流、湿度等因素综合作用的结果, 区域分布对于

整个电场出力影响非常大，所以在预测工作中，应该充分考虑自然因素以及各机组相互作用因素。

3 预测方法探究

3.1 常用预测方法介绍

预测是科学管理工作中不可或缺的部分。现代社会科技发展日新月异，如何对社会生活、团队运转进行有效的科学管理，实现社会进步和经济增长，是目前各前沿学科都在不断探索的命题。紧密跟踪实际数值的预测结果能够为正确的措施提供有力的佐证。从战略层面来看：预测技术是一个国家谋求发展壮大所必须深入探索的课题，它的研究进度、核心技术掌握程度将直接影响国计民生和国家大政方针的实施。

预测技术又分为定性和定量两大层面。

3.1.1 定性预测技术

(1) 头脑风暴法

没有约束的状况下，集体发言最能够启发发言人的新颖观点。头脑风暴的实施要点有：①组织形式：参与者应该是涉足不同领域的专家，人数为十人到二十人，所有参与者均具备相同的权利；②会议类型：思想发掘类、创意探讨类；③会议时间：60—120分钟；④会议议程：组织人首先提出议题，在座全体与会人员提出意见。有时会议主题可事先通知，也可不通知；⑤遵循宗旨：庭外判决、自由畅想、量质同求、全面考量。

(2) 集合意见法

把与预测内容有关的人员集合起来，集中探讨，发表看法。最后决策者完成对所有建议的收集，依据提出人所从事领域、科研项目、个人习惯等，展开所有建议综合审核工作，通过审查形成一个整体意见倾向。该方法优势是意见集思广益、意见渠道广泛、没有复杂的程序。适合搭建时间不长，缺乏经验的系统。

(3) 德尔菲法

该方法又称为专家意见法：通过向该系统以外相关领域科研人员发送详细的资料和预测意见表，请这些科研人员对需要预测的问题提出意见，并按规定的时间将预测表格返回。商讨总结以后，将综合建议再次发送给各位科研人员，科研人员可就综合结论提出看法，做深入的更正。通过反复进行“提出意见—总结”的工作流程，直至专家们的得到大致相同的意见，该意见即可作为预测结论。

德尔菲法可以规避相关人员受到外界意见威慑的风险，让每位科研人员都能坚持自己的看法。但该方法得出的预测结果精确与否很大程度上受到所选定专家自身素质的制约和主观情绪的影响。结论的准确程度不高。而且往返讨论提高时间成本。通常用于周期较长的事件。

3.1.2 定量预测技术

定量预测技术是基于已经获取的较为全面的资料参数，进行科学的取样分析，推测出各个参数内在关联，用于预测和推测未来趋势的一类方法。

(1) 时间序列法

通过根据时间关系模型预测目标(Y)与时间过程(t)之间的演变关系^[28]，函数表示为 $Y=f(t)$ ，简称 $Y \leftarrow t$ ；它是根据历史发展的统计资料，来预测未来一定时间内的变化趋向和可能得到的某种结果的方法。

存在于时间序列里各个阶段的具体参数，均为各种要素综合触发的结果。这些因素可分为三大类：

长期趋势：这是参数在一段很长时期发展趋势。可能表现为工作效率的提高，也可呈现出朝负方向延展，如能耗的减少，也可呈现出向正方向延伸转为向负方向延伸，例如房价的变化。这样的整体趋势都是从量的角度表现出研究对象的转变，所以它是需要重点关注的对象。

季节变化：存在于周期里一段时间内较为规律的变化。也就是说一次变化出现后，经历一定的时期再一次发生，呈现一定规律性，可预测性较强。对这种在一定时间段内反复发生的波动，称之为季节变化。

不规则变动，又称随机变动。此种变动无规则可循。多是因为突发事件所触发，例如环境剧变、新政实施、社会运动等群体性活动所引发的变动。不规则变动的势头通常较猛，波及范围较广，很难预测。

(2) 因果关系分析法

搭建模型研究相关自变量(X)同预测目标(Y)间关系。函数表示是 $Y = f(X)$ ；这种处理方式着重寻求引起事件发生改变的缘由，揭示激励与响应之间的规律，将这种规律用于估计未来形态。常用的方法有：数学经济法等。数学经济法的思想是：按照市场定律，运用众多经济元素之间相互依存的关系采用模型对未来的指标进行估测。回归分析法在采集参数以后，寻找各个参数内在联系以及依存方式，来进行提取和估算。

定量预测有其自身的特点及优势，总的说来：

侧重参数提炼，突出之处在于观测目标的波动幅度，可以从数量的角度对波动幅度做出阐述；将经验参数和实测数据视作运算基础，科学的分析方式组织筛查工作，从而排除心理要素干扰；依靠成熟算法模式，具备较高效率。

可以得到这样的结论：采用定量的方式进行估测的过程中，收集经验参数是首要任务，其次将具体参量，按照时间推进的顺序进行综合、分析，从而总结出其运行的趋向。上述步骤即是时间尺度的改进工作，随后结合从上述改进中总结出来的变化规律，辅以拓展，来预测今后可能达到的水平。

3.2 风电功率预测方法

上一节阐述了应用在各个领域的各类经典预测方法。在风力发电并网领域，如何进行准确度较高的预测是并网研究的热点。常用的预测方式有神经网络法、持续预测法、时间序列法、支持向量机法等方法^[29、30]等：

(1) 持续预测法

该方法为属于较为常见的方法，函数表示如下：

$$v_f(t+T) = PF(P) \quad (3.1)$$

v_f 表示预测值， t 表示即时时刻， T 表示预测周期， P 表示模型阶数。通常情况，只利用最近的一个历史统计数据来做预测工作，把相邻几点的风电出力的统计值视为估测值。该方法虽然简便，但是预测效果不理想。

(2) 时间序列法

时间序列法是在大量观测到的历史数据基础上建立模型，通过数据统计、模型识别、参数估计、模型检验等一系列流程确定能够准确描述所研究对象的时间序列数学模型，利用准备好的数学模型推导出预测系统。对该方法所含模型运用范围最为广泛的是累积式自回归—滑动平均模型。

(3) 逻辑模糊法

应用模糊逻辑和预报人员的专业知识将数据和语言形成模糊规则库，然后选用一个线性模型来逼近非线性动态变化的风电输出功率。从实际应用来看，单纯模糊方法对于风速和风电输出功率预测的精度往往不尽如人意，这主要是因为模糊预测学习能力较弱、泛化能力不强、模糊的是未形成完善的理论，因此在预测系统中选择模糊系统来进行预测尚需做更为深入的研究，这一点特别不适用于不断变化的风速和风电输出功率。一般来说模糊预测法势必与其他预测方法配合，相互补充才能达到较好的预测精度。

(4) 支持向量机法

它由Vapnik和Corinna Cortes于1995年首先提出。该方法是一种监督模型，能够极大解决非线性、过学习等问题。可以用于参数观测、模式选择、回归分析。支持向量机是SLT典型成功范例，其能够建立在SLT和风险极小化原理基础上。实用性突出。但也存在着两大缺陷：一是对数量巨大的参数组难以实施运算；二是处理多分类问题具备充分难度。

(5) 人工神经网络法

人工神经网络法宗旨的第一步是完成信息到概念的转化，随即做好标记；第二步按照运算规则用串行方式来指导推导工作。概念分布存储和信息并行是其最大特色。单个神经元构造简单，处理能力有限；但是大量汇聚的神经元能够实现众多功能。神经网络

可以完成非线性映射、联想记忆、分类与识别、优化计算等功能，特别是对随机性较强难以把握内在规律的问题非常适用。目前，技术比较纯熟的为多层前馈神经网络。

（6）空间相关法

该方法是要对考察地点以及与其相近地域历史风速时间序列进行提取分析，同时利用这几个地点风速之间空间相关性，对风速进行预测，进而和机组功率特性曲线相结合来实现对功率进行预测。由于空间相关性法需要利用不止一个地点的历史风速数据，使得历史数据获取尤为重要。目前，将此种方法同其他常规或者改进的预测算法相结合使用，可以让风速预测模型的输入信息更加丰富，从而使搭建的模型更精确的逼近映射关系，提高预测精度。

按照业界共识，前面介绍的用于预测的方法通常都分成两类：物理方法、统计方法。

统计预测应为最简单的一种风电预测办法，忽略气流形态变化过程，依据历史统计数据找出天气状况与风电场出力的关系，然后根据实测数据和数值天气预报数据对风电场输出功率进行预测，常用的预测方法有人工神经网络法、混合专家经验法、最近邻搜索、蚁群优化等。统计预报通过建立风电场大气资料和风电量输出资料间经验关系以及合理经验系数，进行外推直接得到风电量预报值。但是，统计预报也有局限性，主要在于郭峰依赖观测资料，观测资料质量和长度是决定统计预报质量重要前提条件。预报质量的重要前提条件。

统计方法根据历史数据，利用人工智能方法建立数值天气预报数据与风力机功率输出间关系。物理方法是根据特定区域三维气象模型和数字天气预报数据，使用微观气象模型、中尺度模型或计算流体力学模型等，并结合风电机组功率曲线，计算风电场功率输出。统计方法不需要理解物理特性，计算速度快；但依赖合适和足够多的观测点，以及高质量与长期实测数据。对物理方法来说，测量数据不是很重要，但它需要理解物理特性，需要风电场大量信息，因此要有气象、地理方面的基础理论。

社会生产和经济活动向低碳、环保提出的要求越来越高。世界各国越来越重视风能的优质和可再生的特性，并且日益加大开发力度，对于机组输出功率的定量预测俨然成为能源开发的重要命题。引入跨专业算法对风力机组预测技术进行研究，成为一种新趋势。观察机组特性曲线及输出，可知：机组的出力与风速具有密切关联。把对机组输出功率的预测调整为对风能密度预测是常用处理方式。牛津大学SAMP研究中心则考虑运用三种主要方式对单次风速和风速概率密度进行预测。第一种采用基于环境模型的预测方法。为了进行风速概率密度预测，采用一种相对新颖的天气预测方式，称为天气全体预测。根据全球气候的大规模气象学模型，采用多组不同初始条件，生成多组天气变量预测结果。然后基于其频率分布，做出概率密度函数估测。第二种方式为运用统计学时间序列模型，基于风速变化和其发散性统计模型，通过仿真，对风力产能功率密度进行预

测；第三种为混合型预测方法，主要考虑统计学时间序列模型和基于环境模型的预测，各有其优缺点，同时其预测准确性随着不同的预测标准而有所不同。将两者按照适当的方式结合，变成混合型预测模型。这种模型将有望成为一种更优的预测系统。

各国对循环洁净资源的追求让风能成为增长速度最迅速部分。我国陆地面积巨大，具备多种类型地理环境，这样让我国的风能资源储量巨大。加大风力研究和投产力度符合我国国情，对环保发展和风电并网带来空前契机。当下常用方式，其输入向量主要为：温度、气压、湿度等系统实时采集数据。为了保证提高预测精度^[4]，现有的预测系统几乎都运用了数值天气预报所提供的数据。机组输出特性结合数值天气预报提供的数据，同时依靠机组特性曲线对风场输出进行测算的基础上，加入神经网络方法对历史功率数据和天气数据进行建模分析，通过多维训练，达到准确映射激励-相应关系的效果，从而能够明显改善预测性能。

3.3 预测精度评价指标

机组出力预测的初衷就是为了增加系统运行调度的稳定程度。最终结果优劣由准确程度来决定，结果精确度是评估预测方法的重要尺度。通常情况下，如果仅通过某一单一的误差指标来对最终结果进行判断，就会造成评估片面的结果。因为单项的误差水平只能表征预测方法某一方面的优劣，而风电场输出功率的因素是由多方面决定的，所以单项指标表述太过片面^[31]，研究可知：误差主要来自数值天气预报数据片面和方式的局限性，还受影响于评估区域内机组数量、评测周期长短和数据的精确与否等要素。常用的误差评价指标有如下几类：

(1) 平方和误差：

$$\delta_{SSE} = \sum_{i=1}^n (p_{simu,i} - p_{trag,i})^2 \quad (3.2)$$

(2) 平均绝对误差：

$$\delta_{MAE} = \frac{1}{n} \sum_{i=1}^n |p_{simu,i} - p_{trag,i}| \quad (3.3)$$

(3) 平均相对误差：

$$\delta_{MAPE} = \frac{1}{N} \sum_{i=1}^N \frac{|P_{simu,i} - P_{trag,i}|}{P_{trag,i}} \quad (3.4)$$

(4) 均方根相对误差：

$$\delta_{RMAPE} = \frac{1}{N} \sqrt{\sum_{i=1}^N \left[\frac{|p_{simu,i} - p_{trag,i}|}{p_{trag,i}} \right]^2} \quad (3.5)$$

在进行实际工作中，还需用到其他指标来对预测数值进行综合评判。具体视情况而定。而且在不同的时间尺度情况下，上述评价指标极有可能只会被用到一部分。

3.4 本章小结

本章介绍了各种当下主流的预测算法，各种预测算法也都存在自己的优势和不足，鉴于本课题所研究的短期风电功率输出的如下特点：

（1）机组输出预测是统计意义的概念，某一时刻输出具有偶然性，但是在某一段时期内、处在某一特定地理位置的风电场其输出功率又存在着统计的规律和趋势。

（2）上一章节已经阐述，诸多因素决定机组输出功率，如：阵风、温度、压强、湍流以及机组自身运行情况等。也就是说风电场的输出功率是一个由自然条件、机组情况综合作用的结果，各种因素与最终输出功率数值存在着必然的映射关系，但是，这种映射关系非常复杂。

（3）因为决定风电场输出功率的因素很多，由此就有必要将预测时刻前一段时期的表征各种因素的数据作为切入点进行分析、处理，而这样的数据量较为庞大。

综合风机平均出力的以上特征，本课题决定将筛选人工神经网络法作为预测基础算法。

4 神经网络简介及 BP 神经网络模型

4.1 神经网络概述

人工神经网络^[32]本质是模拟自然界中高等生命体神经系统对数据进行处理。迄今为止对大脑的探索水平,是神经网络算法理论的基石。该算法的目标是模拟大脑进行思考,使模型具备同大脑一样的思考能力;大量构造极其简单的一个个神经元互连成一个非线性并行处理系统,这样的智能处理系统的触角几乎已经延伸到各个工程领域,其运行特性和具备的功能和人脑极其相似,对信息的处理都不是按照给定命令按部就班履行。

(1) 发展与适合领域

该方法的发展历经三个时期:1947~1969 年是发展的起始阶段,此期间研究者们提出了许多神经元模型和学习规则,如 MP 模型、HEBB 学习规则和感知器等;60 年代末期至 80 年代中期,神经网络控制与整个神经网络研究一样,处于低潮。在此期间,科学家们做了大量的工作,如 Hopfield 教授对网络引入能量函数的概念,给出了网络的稳定性判据,提出了用于联想记忆和优化计算的途径。1984 年,Hiton 教授提出 Boltzman 机模型;1986 年 Kumeihart 等人提出误差反向传播神经网络,简称 BP 网络。目前,BP 网络已成为广泛使用的网络。1987 年至今为发展期,在此期间,神经网络受到各个群体单位的重视,各国都着重开发,推动了其迅速进步。

ANN 诞生是仿生学启发结果,亦是对生物神经系统一种高度近似等价,在组成、实现机理和功能上模拟生物神经网络。从系统观点看,人工神经元网络是由大量神经元通过极其丰富和完善的连接而构成的自适应非线性动态系统。人工神经网络,因为生物的学习系统是由相互连接的神经元组成的异常复杂的网络,其中每一个神经元单元有一定数量的实值输入,并产生单一的实数值输出。1960 年威德罗和霍夫率先把神经网络用于自动控制研究。神经网络以其独特的结构和处理信息的方法,在许多实际应用领域中取得了显著的成效,最近十多年来,人工神经网络的研究工作不断深入,已经取得了很大的进展,其在模式识别、智能机器人、自动控制、预测估计、生物、医学、经济等领域已成功地解决了许多现代计算机难以解决的实际问题,表现出了良好的智能特性。

(2) 基本特征

人工神经网络是在现代人工智能推进到一定程度提出,它是由数目众多的基本单元互联而成的有机系统。采用的方法是仿照大脑对信息的采集、解读、处理、记忆的方法处理输入参数。其具备四类特性:

a 非线性:我们周围环境中诸多事物间的联系无不体现出非线性关系。人类大脑对于数据思考、分析即为非线性活动。研究表明:人工神经元处于抑制或者兴奋状态性质

体现也出非线性关系。而且设定界限的单元所组成网络具有极大的优势，有着更加合理容量。

b 非局限性：在科学研究中，神经网络常常被设置成结构复杂的综合性系统。由此，系统的每一个行为是许多单元所共同表现出来群体性特征，是神经元之间作用力与反作用力来决定。所以搭建神经网络系统都是采用将单个神经元进行多方位联系措施来模仿生物大脑思考模式非局限性。

c 自适应性：自适应、自启发能力，是人工神经网络实现功能支撑和根本属性。受处理信息在存续期间变化时刻进行，与之相适应的是，人工神经网络自身会适应数据调整权重，发生相应改变。

d 非凸性：是导致系统发生多方向演变的原因。神经网络变化趋向，通常将由预先设定的指标值来决定。其极值处于较为平稳的形态。非凸性说明函数具备不止一个极值，因此系统就有较多稳定状态，如此一来，学习能力也就更强。人工神经网络中，神经元处理单元可表示不同的对象，例如特征、字母、概念，或者一些有意义的抽象模式。网络中处理单元分为三类：输入单元、输出单元和隐含单元。输入单元接受外部世界信号和数据；输出单元实现系统处理结果的输出；人工神经网络是一种非程序化、适应性的信息处理模型，其本质是通过网络的变换和动力学行为得到一种并行分布式的信息处理功能，并在不同程度和层次上模仿人脑神经系统的信息处理功能。它是涉及神经科学、思维科学、人工智能、计算机科学等多个领域的交叉学科。

(3) 基本结构

组成网络的神经元具有单一输出，一个神经元输出信息传递给其他一个神经元，称之为互连，互连存在很多方法，每种方法的标志就是一个设定权值。因此，可以把神经网络作为以单元为各个基点，用权重连成有向图。下面以其中一个单元来进行分析，设：来自其它兄弟单元 i 的输出为 x_i ，和基础单元互连干预度设为 w_i ， $i = 0, 1, \dots, n-1$ ，处理单元的内部阈值为 θ 。那么本神经元的输入为：

$$\sum_{i=0}^{n-1} w_i x_i \quad (4.1)$$

而进行处理的神经元的输出如下：

$$y = f\left(\sum_{i=0}^{n-1} w_i x_i - \theta\right) \quad (4.2)$$

式 (4.2) 中, x_i 为第 i 个单元输入, w_i 为第 i 个单元与目标单元互联权重。 f 为作用函数或者激励函数。它决定目标神经元的输出。若所有输入合计大于预先设定限定值 θ , 该输出为 1, 反之, 输出为 0, 如图 4.1 所示。




图 4.1 神经元结构图

Fig.4.1 Schematic diagram of the structure of the neuron

(4) 网络模型

按照相异互连方式, 网络划分成两种类型, 即: 分层网络和相互连接网络。

a 分层型网络

此种类型所有组成单元按照其发挥的相应作用分成一定数量处理层, 通常来讲, 由输入层、隐层、输出层组成; 其中隐含层有单隐层、同多隐层种类分别。

b 相互连接型网络

与分层型理念不同, 相互连接说明模型内任意两个神经元都是互通, 即任意两个单元都能进行信息传递。全互连模型, 每个单元均同其他单元存在通路, 局部互连网络中, 部分单元并不存在连通。

(5) 算法优势

人工神经网络优势可以用以下四个方面^[33]来进行概括:

a 非线性映射能力强: 究其本质属性而言, 是并行非线性信息处理模型: 所有单元都具备接受输入能力, 而且产生输出对余下的单元实施影响。但是某一个单位产生信号的前提是: 该神经元对所有输入信息综合处理结果超过预先设定好的某个限定值。所以说其具有非线性变换能力。

b 高度的并行性: 该系统其实是众多处理单位组成, 各个单元能够对信息进行同步处理。因此整体处理效率非常突出。

c 自学习能力和自适应能力强：对神经网络的训练以所研究系统的历史数据经验为基础，一定程度训练的系统具吸收所有参数的容量。所以说，神经网络可以解决由一般模型难以表征和阐明其连接关系的难题。而且，不断吸收所该领域经典处理经验，神经网络就能具备处理同类事件移植处理能力。不仅如此，其自适应能力，能够在获取学习数据内完善结构。

d 具有良好的容错性：不因为个别单元消失丧失原始数据处理能力，其具备良好自我修复能力，使得无论何种问题实现过程中非重要单元功能丢失时，全系统仍然能够稳定运行。

（6）神经网络类型

在研究过程中，人们根据拓扑结构、连接模式、运行方法差异，从不同的角度对神经网络的类型进行了划分。

a 前馈型神经网络。单元之间相互输送信息，全体神经元组成较为复杂的结构，系统具备分析、学习、存储功能。此种类型是目前研究最为广泛、以监督性方法作为学习途径进行训练网络。

b 递归型神经网络。根据其性质以及整体特征此种类型又称为反馈网络；在该网络结构中，若干基础神经单位互联，部分响应信号被反馈至相邻或上层单元。这样，实现信息双向传递。

c 随机型神经网络。这类型网络组成、学习模式、训练方法都与递归型神经网络类似，其最大的不同点就是其工作模式呈现随机性特点。

d 自组织竞争型神经网络。组成结构方面，该类型既不像全连接网络没有间隔；也不似阶层型神经网络那样各层神经元之间只有单向连接，和一般由输入层和竞争层构成两层网络一致。

截止到目前，已经提出三十多种模型并且通过验证，投入实际运用，其中特性突出的代表模型有：感知器、误差反向传播、径向基函数等^[34]。

4.2 BP 神经网络及建模基础

BP 网络是多层前馈网络^[4]，权重设定调整原则采取逆向传播学习方法，也就是说利用偏差反向扩散调整权重，称为 BP 学习算法。BP 学习算法是 Rumelhart、hinton 和 Williams 在 1986 年提出来的。据统计^[35]，目前千分之 80 到千分之 90 神经网络模型是采用 BP 网络或者演进形式。BP 神经网络是一种单向传播多层前向网络，结构如图 4.2 所示。




图 4.2 典型 BP 神经网络结构

Fig.4.2 The structure of typical BP neural network

通常情况下，该类型包含有三层及三层以上的层次，分别是输入层、中间层、输出层。各层神经元仅和相邻层神经元之间相互全连接，同一层内神经元之间无连接，各层神经元之间无反馈连接，由此构成具有层次结构的前馈型神经网络系统。BP神经网络学习过程由两部分组成：正向传播和反向传播。正向传播过程中，输入层各神经元负责接收输入信息，并传递给中间层各神经元；中间层是内部信息处理层，负责信息变换，根据信息变化能力的需求，中间层可以设计为单隐层或多隐层；最后一个隐层传递到输出层各神经元信息，经过进一步处理后，完成一次学习的正向传播处理流程。把实际值与期望值进行对比，当存在差异时，随即进入反向扩散阶段。误差网络结果沿初始路径返回，在传递过程中，调整各个单元权重一直到其符合设定输出。循环往复不断进行这样一个过程，又是网络自身进行学习的过程。误差满足条件训练结束。

BP 网络学习规则的核心思想是：对权值不断调整和限定并适时更改沿着跟踪负梯度方向。即是函数下降最快的方向：

$$x_{k+1} = x_k - \alpha_k g_k \quad (4.4)$$

x_k 是权值和阈值矩阵， α_k 是学习速率， g_k 是当前变现函数的梯度数值。

简要阐述三层网络运行步骤：输入层是 x_i ，中间层是 s_j ，输出层是 y_l 。输入层和中间层权值是 w_{ji} ，中间层和输出层的网络权值为 v_{lj} 。输出层的目标值为 t_l 时，各个层次计算表示为：

输出节点的输出，有：

$$y_l = f(net_l) \quad l=1,2,...,l \quad (4.5)$$

$$net_l = \sum_j v_{lj} y_j - \theta_l \quad l=1,2,\dots,l \quad (4.6)$$

隐层节点的输出，有：

$$s_j = f(net_j) \quad j=1,2,\dots,j \quad (4.7)$$

$$net_j = \sum_i w_{ji} - \theta_j \quad j=1,2,\dots,j \quad (4.8)$$

经验可知，转移函数一般采用单极性 *Sigmoid* 函数：

$$f(x) = \frac{1}{1+e^{-x}} \quad (4.9)$$

若实际输出与期望输出不相同，定义误差 E 为：

$$E = \frac{1}{2} \sum_l (t_l - z_l)^2 \quad (4.10)$$

把式 (4.10) 展开到中间层，可以表示为：

$$E = \frac{1}{2} \sum_l [t_l - f(net_j)]^2 = \frac{1}{2} \sum_l [t_l - f(\sum_j v_{lj} y_j - \theta_l)]^2 \quad (4.11)$$

在输出层展开有：

$$E = \frac{1}{2} \sum_l [t_l - f(\sum_j v_{lj} y_j - \theta_l)]^2 = \frac{1}{2} \sum_l [t_l - f(\sum_j v_{lj} f(\sum_i w_{ji} x_i - \theta_j) - \theta_l)]^2 \quad (4.12)$$

由式 (4.12) 可知：误差 E 是关于权重 w_{ji} ， v_{lj} 函数，于是我们想到，要想缩小误差 E 的值，可以通过调整权重的方式来实现。调整权值初衷是减小误差，符合这样的条件而且具备较高效率的方法是梯度下降法，该方法使权值改变量和误差负梯度成正比，表示为：

$$\begin{cases} \Delta w_{ji} = -\eta \frac{\partial E}{\partial w_{ji}} \\ \Delta v_{lj} = -\eta \frac{\partial E}{\partial v_{lj}} \end{cases} \quad (4.13)$$

式子中的负号表示的是下降的梯度， $\eta \in (0,1)$ 是学习速率。

把样本数据输入网络，按照上述步骤进行训练，设定误差限值 E ，训练结果与期望输出之差小于 E ，模型收敛训练结束。训练次数已经达到之前设置最大次数，则也终止，判定为网络不能收敛，学习仍然告一段落。

本文所采用的训练 BP 算法，流程如图 4.3 所示。




图 4.3 BP 神经网络训练步骤图

Fig.4.3 The flow chart of training of BP neural network

4.3 模型实例分析

如前所述，可知 BP 网络的组成结构也就决定了每设计、搭建一个 BP 神经网络，就需要根据样本数据以及处理模型确定这几层的相关参数，同时应该选择相邻层次间传递函数。

根据BP网络搭建的理念^[32]，对于一般事件，单隐层网络就能够得到较为准确结果。本节依据采集得到的实测参数值构造简单网络，并进行粗略的预测。采用三层网络，数据是采样时间间隔为10分钟的240个风电功率数据，在此搭建BP神经网络模型利用历史功率估计即刻功率方式，将全体数据分为40组，每组含6个数据；考虑到相近功率值变化几率较小，因此采取运用6个数据中前5个数据来预测第6个数据的方式，输入数据是一个5维向量，第6个数据设定为目标输出向量。

按照设计安排，输入数据有五组参数，即设计此网络输入神经元有五个。依据 *Kolmogorov* 定律，易得出，中间层神经元是 $2 \times 5 + 1 = 11$ 个。而设计输出参数为一组，则输出层单元个数是 1。另外以预测结果均方根误差最小为目标，中间层采用 S 型正切函数，输出层传递函数用线型一次函数。

以下代码创建要求的网络：

```
net=newff([minmax(pp)], [11, 1], {'tansig', 'purelin'}, 'trainlm');
```

以上代码中，*pp* 代表输入参数，'*trainlm*' 是网络隐含层训练函数调用 *trainlm* 函数，采用 '*Levenberg – Marquardt*' 算法进行训练。

在网络学习过程中，参数可以按照预测要求完成设置，还可以确认为默认值。因为本小节采用功率估量功率的训练，涉及的参数较少，因此，误差限值自行设定，网络其他参数按默认值设定。将 40 组参数中的前 20 组用于网络学习。在 MATLAB 中编程搭建 BP 神经网络模型如图 4.4 所示。




图 4.4 MATLAB 中搭建 BP 神经网络模型

Fig.4.4 The BP neural network model set up in MATLAB

将剩下的 20 组参数用于测试学习后网络，测试结果如图 4.5 所示：




图 4.5 历史功率预测功率结果

Fig.4.5 The result of historical power predict power

4.4 本章小结

本章着重介绍了神经网络作为一种新兴运算模型的出现背景、发展历史、模型优势、运算结构、模型分类。结合本课题选择了最为常用 BP 网络来作为短期风电功率预测基础预测算法，其具备可以模拟和存储非线性映射关系，而不需要事前就能够探寻出描述这种映射关系数学方程的优势成为了本文选择 BP 神经网络作为预测基础算法有力的依据和支撑点。

最后实例分析当中，运用数据比较简单，只是采用历史数值预测下时刻的功率。所以得到的预测结果是差强人意的，因为输入的参数只是单纯的考虑了历史功率，并没有将前面章节所列举的其他因素纳入考虑，因此误差较大。

5 基于聚类思想的风电机群划分研究

5.1 概述

理论上讲，十台甚至上百台机组可以组成一个基本的风电场^[36]，每个单元就是一个非线性时变系统，在对机组进行仿真模型搭建的工作中，如果对每台机组均建立模型，势必很大程度上加大复杂程度，而且效率低下；所以，将整个风电场所有机组进行等值划分为若干类，再对各类型进行等效，作为功率预测的基础意义重大。

当下对风电功率的预测主要是以用单位机组模型等效于整个电场区域为基础^[37]，但是大型风电场，天然环境因素和湍流效应作用更加突出，直接导致各个机组之间风能差异较大。所以，传统的等效模式精度很低。

5.2 风力机组风速空间特征分析

本小节对风电场中风速的空间分布模型进行简单讨论^[38]，设 A 、 B 两处为相同风向上两个点，而且处于同一高度， A 处为风向上游的一点， B 处为风向下游的一点， AB 的间距离为 $\overline{AB}$ ；当然，风是随时间变化的三维向量，在这里由于只做定性分析，为了便于计算，在这里忽略垂直方向上的分量。在此基础上进一步简化：不考虑地形、气象等外界自然因素的影响、风向为主导风向的情况，易知： A 处的风速会经过一段时间到达 B 处，即， $V_b(t) = V_a(t + \tau)$ ，时间延迟：

$$\tau = \frac{\overline{AB}}{\overline{V_a}} \quad (5.1)$$

式 (5.1) 中， $\overline{V_a}$ 是时域区间 τ 内 A 处平均风速。显然，延迟时间 τ 并不是固定的，其值依附风速的大小进行变化。实际上，风向也并不总是与 AB 两点直线方向平行，同时还会受地形地貌、温度、压强等外部因素的影响，而且，空间相关点的风速并不会都相等，但它们之间依然保持较强的相似性。而风速的这种空间相关特性，使得自然风到达风电场内每机组的时间是不尽相同的，有的相对超前，有的相对滞后。图 5.1 为截取的风电场两风机间的在某一时间段内的风速曲线图。易知两台机组风速具有较强相似性；风机 1 的风速是超前风机 2 的，超前的时间大概是 20min。




图 5.1 示例风机风速曲线

Fig.5.1 The wind speed curve of typical wind turbines

上述分析揭示的规律说明：在预计机组输出功率的过程中，对风电场各机组采取区域划分的措施具备科学性和可行性。

5.3 风电场区域归类技术手段探究

把风电场内所有机组纳入区域划分，即是说将风电场划成若干分区域，对同分区域机组进行等值处理，同单机等值法相比，能够有效降低误差。文献[39、40]认为机组工作状态主要是由风速所决定，地形地貌、各单元分布所带来尾流效应是造成处于不同地理位置机组风速不同使不同位置机组出力不一致的重要缘由，从而提出考虑尾流效应作为因素对风电机组进行划分，把在相同风速作用风电机群作为具有相同、相近动态过程单元。而文献[41]认为在配置风电场时，和风速相比，机组转速可以更准确跟踪机组的运行曲线。本文认为各个机组输出特征，结合机组运行周围地形、尾流影响诸多信息可以直接、准确反映出工作状态。因此可以利用统计方法对工作情况相近的机组进行归类以便于后续功率预测。

按照惯例，配置在开阔地势的风电场其机组是在主风方向上按照行列规则排列的，本文针对地形地貌复杂或非常规机组分布的风电场。介绍一种机组分类划分方法：用聚类思想进行划分工作。该方法以具备相似程度高运行状况一类机组为划分原则，利用基

于马尔科夫矩阵分析聚类方法对区域内各机组采集数据进行提取、运算，分析出每一机组运行工况的相似性，将运行情况相近甚至相同的机组划分到同一分区域，达到对区域中运行情况不一机组的聚类。

5.4 基于扩散理论的机组谱聚类划分方法探究

把物理或抽象对象^[42]集合分成由类似的对象组成的多个类的过程称之为聚类划分。聚类是发现众多复杂元素内在联系进行归类分析的有效手段，而谱聚类算法是众多聚类方式中颇为高效实用的方法。它首先根据采样参数集合形成一个描述成对数据点相似矩阵，随即通过运算得到矩阵特征值以及特征向量，然后筛选合理特征向量分别组成各个不同的数据点，从而找出数据样本的内在联系。

本章采用谱聚类方式对风电场划分步骤如下：

(1) 基于对风电场各机组实际运行采样数据。构建一个带有高斯权重值分布图来表示出各机组之间数据的相似性。以此为基础构建 *Markov* 转移矩阵，以此表征机组运行状况相似程度；

(2) 通过对得到的 *Markov* 转移矩阵进行谱分解和特征降维工作来得到聚类类数，即是分区域的个数；

(3) 保持各机组所对应节点随机运动^[36]，定义出相似距离用来描述各机组运行状况接近程度，通过比较机组两两间相似距离和预先设定阈值大小，将每个机组对应的节点聚类到相应分区域，从而得到各个分区域包含的节点，各节点对应机组就在此分区域。

5.4.1 马尔科夫转移矩阵的创建

设若风电场内有 n 台风机，则待划分的样本集合为 $X = \{X_1, X_2, \dots, X_i, \dots, X_n\} \in R^{m \times n}$ ，其中 X_i 为等待进行聚类划分的对象即：各个风电机组。 X_i 是第 i 台风机采样参数 $x_i(t)$ 集合构成一个高维向量， $X_i = \{x_i(1), x_i(2), \dots, x_i(t), \dots, x_i(m)\}^T$ ， $t \in T$ ，这样由采样数据集 X 为依据带高斯权重图 G ，如图5.2所示。



 图 5.2 样本集 X 构造带高斯权重图 G

 Fig.5.2 Graph G with Gaussian weighted built by sample collection X

可以看到： G 是个连通图， G 中各个顶点对应各个风电机组，顶点间连线上权重值表示各机组间相似程度，这样可以得到 G 的相似性矩阵 $A \in R^{n \times n}$ 如下：

$$A_{ij} = e^{-\|x_i - x_j\|^2 / (2\sigma^2)} \quad (5.2)$$

其中， $\|x_i - x_j\|^2$ 表示两点之间的欧几里得距离； σ 为尺度参数，作用是用来控制数据点 x_i 和 x_j 之间的距离对 A_{ij} 的影响，这样才能将相似矩阵控制在不背离原始数据离散程度的范围中。

设数据点 x_i 是一个带有 *Markov* 性质的随机过程向量，根据式 (5.2) 定义随机过程样本集合 X 的转移矩阵如下：

$$P_{ij} = A_{ij} / \sum_{j=1}^n A_{ij} \quad (5.3)$$

5.4.2 马尔科夫概率转移矩阵的谱分析

设 λ_i 、 φ_i 、 ψ_i 分别代表 P 的第 i 个特征值和其对应的左特征向量和右特征向量。首先，将所得特征值按数值大小进行排列，要保证 $1 \geq \lambda_1 \geq \lambda_2 \geq \lambda_3 \geq \dots \geq \lambda_i \geq \dots \geq \lambda_n \geq 0$ ，用 φ_1 、 φ_2 、 φ_3 、 $\dots$ 、 φ_i 、 $\dots$ 、 φ_n 和 ψ_1 、 ψ_2 、 ψ_3 、 $\dots$ 、 ψ_i 、 $\dots$ 、 ψ_n ，代表相应左特征向量和右特征向量^[24]。则根据 *Markov* 矩阵性质，*Markov* 概率转移矩阵 P 分解公式如下所示：

$$P = \sum_{i=1}^n \lambda_i \psi_i \varphi_i^T \quad (5.4)$$

随即，对 P 进行进一步分析：

(1) 如果矩阵 P 存在 $q < n$ 个主要特征值，而且 $\lambda_1, \lambda_2, \dots, \lambda_q$ 这 q 个特征值的数值非常相近并都接近于 1，且 $\lambda_{q+1} \ll \lambda_q$ ，就可用前 q 个特征值和特征向量形成矩阵 P 的秩为 q 的近似矩阵 P_q ；

(2) 若不满足条件(1)，则观察矩阵 P 各个相邻特征值之间的差值，如果存在特征值 λ_{q+1} 突然变小情况，即 $\lambda_q - \lambda_{q+1} \gg \lambda_k - \lambda_{k+1}$ ，其中 $q+1 \leq k \leq n$ ，且 λ_{q+1} 的值很小，则仍旧可按照第一种情况进行处理。

综上：由式 (5.4) 矩阵 P 秩为 q 近似矩阵 P_q 谱分解形式为

$$P_q = \sum_{i=1}^q \lambda_i \psi_i \varphi_i^T \quad (5.5)$$

由式 (5.5) 可知，等待划分对象样本集的划分组数即为 q ，预测之前划分的分区域的数量就为 q 。

5.4.3 扩散距离的计算

定义映射 $\psi : x \rightarrow \begin{bmatrix} \lambda_1 x \psi_1 \\ \vdots \\ \lambda_n x \psi_n \end{bmatrix}$ ，其中 ψ 仍然是 $R^n \rightarrow R^n$ 。设任意两个机组 x_i, x_j 的扩散

距离：

$$D^2(x_i, x_j) = D^2(e_i^T, e_j^T) = \|\psi(e_i^T) - \psi(e_j^T)\|^2 = \left\| \begin{bmatrix} \lambda_1[\psi_1(i) - \psi_1(j)] \\ \vdots \\ \lambda_n[\psi_n(i) - \psi_n(j)] \end{bmatrix} \right\|^2 \quad \text{其中, } e_1, \dots, e_n \text{ 为}$$

对应于 $x_1, \dots, x_n$ 的单位向量。

由前 q 个主导特征值和相应特征向量，能够将 x_i, x_j 扩散距离简化表示为：

$$D^2(x_i, x_j) \approx \left\| \begin{bmatrix} \lambda_1[\psi_1(i) - \psi_1(j)] \\ \vdots \\ \lambda_q[\psi_q(i) - \psi_q(j)] \end{bmatrix} \right\|^2 \quad (5.6)$$

根据分区域数目和风机之间扩散距离的数值，设定限值 $\eta > 0$ 。若 $D^2(x_i, x_j) \leq \eta$ ，则表明第 i 台和第 j 台机组属于同一个分区域，应该划分在同一个风电场分区域中，反之则表明不属于同一个分区域，就不应该划分在同一个分区域。

当然，对风电场实施具体分区域分组过程中，需要注意的是：应该依据实际运行工况。在本节方法指导下进行聚类分析之前，还应作这样一些考虑：模式、运行原理不同的机组不得划入同一区域；外部环境非常相似的机组应存在于相同的分区域；容量相似的机组也应该考虑在同一个分区域。这样对于显而易见的机组就不用再使用本节方法，既保证了准确性又提高了划分效率。

5.5 本章小结

本章提出了一种对相似运行点以及相似运行工况的机组，运用聚类运算方式对风电区域进行划分的方法，该算法特别适用于所处地形地貌情况较为复杂、布局不规则、面积广大的风电场。通过更加有针对性的探讨，使得对整个风电场等效方式更为贴近实际运行情况；并且可以较为客观地体现出风电并网的运行过程，从而为后续进行功率预测奠定客观、有效的基础。

6 基于区域聚类分析的改进神经网络短期风电功率预测

6.1 模型概述

在众多的预测算法中，由于 BP 神经网络模型简单、物理意义明确等特点，所以成为本文所选定的基础预测算法。前面的章节建立简单的预测模型，仅仅考虑用历史输出功率来估量即刻输出功率，即只是将历史功率作为神经网络模型的输入向量，建立的是“功率预测功率”的模型，所考虑的只是单一的数据，因此才导致了准确度较低的输出数值。如前面章节所作的阐述，风电场现场的数据多种多样，并且所有的数据都影响着风电场的输出功率。因此本章着重采取两方面措施来实现提高精确度的目的：一是进行本文所用基础算法优化设计工作，二是筛选出同输出功率关系较为密切的因素，将其数值纳入到具体算法当中来提高准确度。经过分析实测数据^[3]，可知：训练数据相对不足，则存在神经网络学习不完善。若学习样本过多时，又会使模型搭建工作过于繁琐^[43]，我们对影响风电输出功率的各个因素进行分析后发现自然参数和空间参数对输出功率影响最大，因此本文将这样的两个因素纳入到预测当中来：自然参数由数值天气预报提供，空间参数由对处在风电场中的各个机组运用上一章谱聚类的划分方式进行分区域划分来达到纳入考虑的目的。

6.2 基于区域聚类分析的改进神经网络风电功率预测流程

基于前面几章的讨论，我们得出这样的结论，即：在风电场功率预测过程中，只要能够尽可能多的将影响因素考虑进来，并且遴选出相对更为科学的预测算法，就能够提高预测精度。鉴于此，本文提出基于区域聚类分析的改进神经网络风电功率预测的方法，将空间因素考虑到预测过程中来，本文所提出预测方法的整体步骤如图6.1所示。




图 6.1 基于区域聚类风电功率预测整体流程图

Fig.6.1 The whole flow chart of wind power prediction based on regional clustering

本文所提出的基于区域聚类分析的改进神经网络风电场输出功率预测方法总体思路如下：

首先按照上一章所述采用聚类方法将整个风电场进行区域划分^[26]，将风力状况、所处地理位置相似的机组纳入到同一个区域。

第二步分析相关性。筛选出与分区域出力相关系数较大的对应机组作为标准机组，组成每一个分区域的标准机组群。

第三步把对标准机群功率预测转换成对所包含各标准机组功率预测。本文通过和传统神经网络进行对比决定采用基于遗传算法改进的神经网络预测方法对机组进行预测。

第四步利用标准机群^[26]功率预测值得出分区域的功率预测值，由于采用选取标准机组进行预测方式，有针对性忽略非标准风电机组影响，减小运算量，使预测工作能够更加高效。

把上述结果相加就是整个区域功率预测值。具体展开如下：

6.2.1 分区域划分

分区域功率预测是本文提出方法的重要环节；是衔接标准机群功率预测与整体区域功率预测的桥梁，因此，划分依据是首先应该考虑的问题。

首先，考察各区域所含机组所处的地域特性、风电场群分布位置等情况^[26]：如果机组位置相对集中、历史风速数据趋于统一化，可以不必设置分区域，代之的是直接采用叠加法展开预测。如果各风机组位置相对分散、历史风力情况有较大差别，应该采用聚类方法划分。本文讨论的是相对复杂的第二种情况，更具备普遍性。

6.2.2 标准机群功率预测

前文已经阐明：本文主要思路是由分区域的功率水平来对整个区域的功率进行预测，而分区域的出力水平若是分区域中各机组预测值的简单叠加势必会降低效率。本文提出的分区域功率预测值是由与分区域功率相关系数较大的机组预测值来决定的^[26]，这样的机组定义为标准机组，标准风电机组的精确定是本文所述后续计算正确性的有力前提，所选择的标准风电机组的接入位置、所处外部环境、额定容量等都将影响到分区域出力预测的准确性。

(1) 确定标准机组群^[26]

标准机组群由确定标准机组构成。确立标准机组群有多种方法，由于运用相关系数研究相关性具有运算简便、易于实现的功能特点，则本文采取用相关系数来衡量各分区域中机组和分区域的相关性，计算各分区域中各机组功率与分区域总功率之间的相关系数，筛选出相关系数较大的机组，作为标准机组，直到功率达到一定规模，组成机组群，来对整个分区域的功率进行预测。

a 设某一分区域内有 m 个机组，编号为 1、2、3、...、 m 号，第 i 个机组与分区域功率的相关系数 r_i 定义如 (6.1) 式。

$$r_i = \frac{\sum_{k=1}^n (x_{ik} - \bar{x}_i)(y_k - \bar{y})}{\sqrt{\sum_{k=1}^n (x_{ik} - \bar{x}_i)^2 \sum_{k=1}^n (y_k - \bar{y})^2}} \quad (6.1)$$

式中， n 为测量功率采集点数， x_{ik} 为该分区域第 i 个风电场第 k 个采集点功率实测值； y_k 为第 k 个测量点分区域实际测量功率； $\bar{x}_i$ 为第 i 个风电场 n 个采集点功率平均值； $\bar{y}$ 为分区域 n 个时刻功率的平均值。若存在异常数据的机组，则将对应的相关系数设置为 0。

b 将上述步骤中所计算得到的相关系数值进行排序^[26]，本文采用相关性分析并设定阈值的方法对标准机组进行选取^[44]：标准机组就是所筛选出的相关系数绝对值较大的机组，由标准机组组成的标准机组群（本文设定标准机组群中各机组功率总和达到所在分区域总额定功率的 60%）。具体条件如下（6.2）式：

$$\sum_{i=1}^S p_i > p_t \times 60\% ; \sum_{i=1}^{S-1} p_i < p_t \times 60\% \quad (6.2)$$

S 为计算出相关系数绝对值排名前 S 机组， P_i 为第 i 个机组的额定出力； P_t 为 P_i 所在分区域总额定功率。

（2）标准机组群功率预测

标准风电机组群的功率预测是本文的基础，风电机组发出的功率受即刻风速、温度、压强等因素的影响，因此，对于标准机组群的功率预测，本文综合考虑各因素的影响状况，筛选出对风速影响较大的因素。如（6.3）式所示：

$$r_{x,y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (6.3)$$

其中， $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ ； $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ 。由相关系数公式得出计算结果，选择相关系数大的因素作为神经网络的输入以及训练向量，对网络进行训练后得到标准机组的预测功率。

6.2.3 分区域及总区域风电功率预测

在得到各分区域标准风电机组群预测功率的基础上，本文采取通过标准机组的预测功率来预测所在分区域的功率的方法，来确定各分区域的预测功率。和对各标准机组预

测方法相似，对分区域的风电功率预测也采用神经网络的方法。最终得到总区域的风电功率预测值。

6.3 实例验证

本文将广西某风电场实际测量数据作为运算依据，该风电场装设23台风力发电机组，总体容量是21.5 MW。对本文提出方式进行验证。

6.3.1 分区域划分

(1) 建立Markov矩阵

由式(5.2)和(5.3)对全区域机组建立Markov概率转移矩阵，分别用 P_p 和 P_q 来表示：

$$P_p = \begin{bmatrix} 0.2244 & 0.0731 & \cdots & 0.0296 & 0.0176 \\ 0.0563 & 0.2917 & \cdots & 0.0253 & 0.0137 \\ \vdots & \vdots & & \vdots & \vdots \\ 0.0200 & 0.0222 & \cdots & 0.3315 & 0.0265 \\ 0.0116 & 0.0117 & \cdots & 0.0258 & 0.3400 \end{bmatrix}$$

$$P_q = \begin{bmatrix} 0.2948 & 0.0534 & \cdots & 0.0149 & 0.0076 \\ 0.0717 & 0.3954 & \cdots & 0.0165 & 0.0075 \\ \vdots & \vdots & & \vdots & \vdots \\ 0.0234 & 0.0192 & \cdots & 0.4610 & 0.0197 \\ 0.0117 & 0.0086 & \cdots & 0.0194 & 0.4545 \end{bmatrix}$$

(2) Markov概率转移矩阵的谱分析

求取Markov概率转移矩阵特征值以及其特征向量。计算 P_p 和 P_q 特征值：

$$\lambda_p = [\lambda_1, \lambda_2, \lambda_3, \cdots, \lambda_{23}] = [1, 0.904, 0.798, 0.4187, \cdots, 0.1135];$$

$$\lambda_q = [\lambda_1, \lambda_2, \lambda_3, \cdots, \lambda_{23}] = [1, 0.812, 0.735, 0.554, 0.52, \cdots, 0.158]$$

通过观察：相比之下 P_p 前三个特征值较大，第四个特征值变小，而从第四个特征值开始，后面数值之差相对较小。根据前面章节阐述原则，该风电场宜划分为3个分区域。再观察 P_q 的特征值也有相似的特点，因此可以证实以上观点。

(3) 分区域划分

设定限值 η 为0.4。有划分争议的风电机组是WT13、WT18，其与三个分区域有功、无功相似距离如表6.1所示。

表 6.1 争议机组扩散距离

Tab.6.1 The spread of distance of controversial units

分区域 机组编号	1 号分区域		2 号分区域		3 号分区域	
	有功距离	无功距离	有功距离	无功距离	有功距离	无功距离
WT13	0.4128	0.3583	0.3675	0.4174	0.3897	0.4415
WT18	0.4344	0.3609	0.3941	0.4064	0.3713	0.4132

采取用有功、无功算术平均值方法得出WT13、WT18和三个分区域的相似距离分别是：0.3855, 0.3924, 0.4156；0.3977, 0.4002, 0.3922。因此WT13应该纳入1号分区域，WT18应该纳入到3号分区域，最后得到如表6.2分区域分配情况：

表 6.2 分区域划分结果

Tab.6.2 The results of subregional division

对象	相关参数		
机组编号	1—23		
主要特征值个数	3		
分区域编号	1号分区域	2号分区域	3号分区域
所含机组编号	14、17、19、21、1、3、7、9、13	2、6、11、16、23、4、5、8、10	15、18、20、22、12、10

6.3.2 确定标准风电机群

某区域内所有标准风电机组成标准风电机组群。确立标准风电机群有多种方法，由于运用相关系数研究相关性具有运算简便、易于实现的功能特点，因此本文采取用相关系数来衡量各分区域中各机组输出功率和分区域总的输出功率的相关性，即：计算各分区域中各风电机功率与分区域总功率之间的相关系数^[15]，筛选出相关系数较大的风电机组，作为标准风电机群，直到达到一定的装机容量，组成机群。步骤如下：

(1) 假如某一分区域包含 m 个机组，编号分别为1、2、3、...、 m ，第 i 个机组和分区域功率相关系数 r_i 定义如下：

$$r_i = \frac{\sum_{k=1}^n (x_{ik} - \bar{x}_i)(y_k - \bar{y})}{\sqrt{\sum_{k=1}^n (x_{ik} - \bar{x}_i)^2 \sum_{k=1}^n (y_k - \bar{y})^2}} \quad (6.4)$$

其中： n 表示测量功率抽样点的个数， x_{ik} 表示该分区域第 i 个机组第 k 个抽样点的实际测量功率； y_k 表示第 k 个观测点时分区域实测功率； $\bar{x}_i$ 表示第 i 个机组 n 个抽样点功率平均值； $\bar{y}$ 表示分区域 n 个时刻点的功率平均值。

(2) 基于上述步骤计算得到相关系数数据进行大小比较，标准机组就是筛选出相关系数绝对值较大的机组，如式 (6.2)。以3号分区域为例，计算六个机组输出功率同分区域的相关系数，得到15、18、20、22、12、10号机组的相关系数为0.200、0.010、1.028、0.828、0.17、0.38。可以看出：与3号分区域功率相关系数从大到小的机组依次是20、22、10、15、12、18号。由于15、18、12、10号机组相关性很小，并且20号、22号机组符合式 (6.2) 的限制条件，因此将20、22号作为标准机组，组成标准机组群。

6.3.3 基于遗传算法改进的神经网络标准机组功率预测

(1) 基于 BP 神经网络的标准机组预测

如前叙述：影响机组出力要素组成为“风力为主导，其他自然因素综合作用”。而数值天气预报内容包含气压、气温、湿度、风力以及雨水情况，所以本章采用数值天气预报数据来建立对标准机组群的预测模型。

结合前面章节对影响因素的分类，以3号分区域的20号机组为例，结合其运行参数，本章考虑选择风速、气压、气温、风向参数、历史功率、湿度，作为输入变量，网络性质决定通常时间均能够通过单隐层实现。因此，本节的BP神经网络有三层，即：输入层、隐含层、输出层。结构图如图6.2所示。




图6.2 BP神经网络模型预测风电功率模型结构图

Fig.6.2 The structure of BP neural network model predict wind power

本章对标准机组的功率预测在 MATLAB 中进行,搭建 simulink 的仿真模型如图 6.3 所示。




图6.3 加入BP神经网络预测单元的20号机组仿真模型

Fig.6.3 The 20th unit simulation model with BP neural network predictive module

实例验证选取整个数据集全部源于标准电机组 27 天内采集得到数据,采样时间间隔也都是 10 分钟,并且选取风速、风向、温度等作为输入从结构可知,本文算法模型采用的各个数据量纲不一致,所以搭建模型前,应对各类数据实施归一化处理。

归一化就是将数据处理为区间[0, 1]之间的数据,以方便进行预测工作,归一采用如下方法如式子 (6.5) :

$$\hat{x} = \frac{x - 0.5 \times (x_{\max} - x_{\min})}{0.5 \times (x_{\max} - x_{\min})} \quad (6.5)$$

筛选部分数据进行归一化如表6.3所示:

表6.3 20号机组部分参数

Tab.6.3 Some parameters of 20th unit

风向正弦	风向余弦	风速	温度	压强	湿度	历史功率	实际功率
0.3915	0.4714	0.7700	0.5	0.5	1	0.3158	0.5313
0.2835	0.5402	0.6800	0	0.67	1	0.3158	0.5938
0.6210	1.0000	0.6300	1	0.5	1	1	0.9375
0.4185	0.4183	0.6700	1	0.5	1	0.7368	0.4375
0.2610	0.4948	0.7100	0	1	0.35	0.2632	0.5
0.9990	0.0383	0.7500	0.5	1	0.74	0.9474	1
0.5805	0.4925	0.7100	0	0	1	0.3684	0.3570
0.0810	0.0692	0.7600	0	0	0.31	0.0526	0.3215
0.3915	0.1230	0.9800	0.5	0	1	0.8974	0.6563

因为之前确定的输入样本是7维的输入向量，即搭建的网络n值取7，因此，即：输入部分一共有数量包含7个处理单元，由 *Kolmogorov* 定理，网络中间层单元数量应该设定为 $2n+1=15$ ，而输出单元只有一个：是风电功率的输出。因此该神经网络是 $7 \times 15 \times 1$ 的网络。

于是创建神经网络，代码如下所示：

```
threshold=[0 1;0 1;0 1;0 1;0 1;0 1;0 1];
```

```
net=newff(threshold,[15,1],{'tansig','logsig'},'traingdx');
```

其中，*threshold* 规定归一化输入数据取值范围是[0,1]，网络所用的训练函数为 *traingdx()*，拥有自适应的学习速率。

在实际预测之前，网络需要进行训练，才能够达到精度要求，综合考虑网络的设定情况，参数设置如表6.4所示：

表6.4 神经网络参数设定

Tab.6.4 Parameter setting of neural network

训练次数	训练目标
1000	0.01

网络的训练代码如下：

```
net.trainParam.epochs=1000;
```

```
net.trainParam.goal=0.01;
```

```
%init进行网络初始化工作
```

```
net=train(net,P,T)
```

其中, P 和 T 分别指所搭建网络输入向量和目标向量, 由表6.3提供, 训练仿真结果如图6.4所示。




图6.4 训练结果

Fig.6.4 results of training

初步训练后, 网络学习达到预期的效果, 尚且需要引入另外一组数据对通过学习网络进行检测, 网络检测就是引入一定的原始参数作为输入, 通过训练后模型得到结果, 然后分析输出和实测值间误差是否处于预设误差限值之内, 测试数据如表6.5所示, 测试代码如下:

```
Y=sim(net,P_test)
```

表6.5 部分测试数据

Tab.6.5 Part of testing data

风向正弦	风向余弦	风速	温度	压强	湿度	历史功率	实际功率
0.0270	0.0742	0.62	0	0	1	0.2105	0.1875
0.1755	0.3667	0.77	0	0.5	0.69	0.7368	0.4062
0.4320	0.3790	0.68	0.5	0.43	0.82	0.2632	0.4375
0.4995	0.4347	0.63	0	0.5	1	0.6842	0.5938
0.6885	0.5842	0.67	0.5	0.6	0.35	0.4211	0.625
0.5400	0.2038	0.71	0.5	0.5	0.74	0.5789	0.7187
0.1620	0.5565	0.75	0	0	1	0.4737	0.375

网络预报误差曲线如图6.5所示:




图6.5 预报误差曲线图

Fig.6.5 Predictive error curve

本章筛选出连续5天,即120个小时的数据作为预测数据,分别提前不同的时间来进行预测,图6.6是提前八个小时的预测对比图,实线表示实际值,虚线是预测值,容易得出:预测值曲线和实际曲线误差较大,预测曲线对实际曲线跟踪较差。




图6.6 预测结果 (提前8小时)

Fig.6.6 Results of prediction (8 hours in advance)

图6.7是提前四小时的对比曲线，和图6.6一样，实线是实际值，虚线是预测值，相比之下，提前4小时的估量数值能够大致跟踪实际出力趋势，但是在个别点的数据对比上，误差非常大。




图 6.7 预测结果（提前 4 小时）

Fig.6.7 Results of prediction (4 hours in advance)

图6.8是提前二小时功率预测与实际对比结果图，相比图6.7提前2小时预测的精度提高了很多，除个别点有一定的误差，功率预测曲线能够较为客观的反映出实际功率曲线。




图 6.8 预测结果（提前 2 小时）

Fig.6.8 Results of prediction (2 hours in advance)

图6.9是提前1小时估算结果,和已经仿真的结果相比较,精度最高,几乎完全能够跟踪实际的输出功率,吻合程度很高。




图 6.9 预测结果 (提前 1 小时)

Fig.6.9 Results of prediction (an hour in advance)

从以上提前不同时间对20号标准机组预测结果相比较可以得出这样的结论:①测算周期越短,相应曲线就越能够准确跟踪实测曲线,说明模型预测水平达到较高的水平。②训练网络的样本数据、网络参数的设定值对预测结果也存在一定影响。

(2) 基于遗传算法改进的BP网络功率预测

上一小节详尽阐述了运用普通BP神经网络对标准风电机组功率进行预测的工作流程,通过仿真结果可以看到:提前一小时进行预测的结果相对最为理想,但是仍然存在一些缺陷:学习收敛速度太慢、不能保证收敛至全局最小点等。而网络结构、初始连接权值和阈值的确定对网络的影响很大,要想准确的获取存在一定的难度,针对这些特点本小节决定采用遗传算法对BP神经网络进行优化^[45]。

本小节提出的利用遗传算法来对BP神经网络的初始权值和阈值进行优化,使优化后的BP神经网络能够更好的映射输入-输出关系。运用遗传算法优化BP神经网络的重要步骤包括:种群初始化、适应度函数、选择操作、交叉操作、变异操作。

a 种群初始化

个体编码的方法为实数编码。每个个体,即优化对象,由输入层与隐含层连接权值、隐含层阈值、隐含层与输出层连接权值和输出层阈值四个部分组成。个体包含了神经网络全部权值和阈值,在网络结构已知的情况下,就可以构成一个结构、权值、阈值确定的神经网络。

b 适应度函数

根据个体得到BP神经网络的初始权值和阈值，用训练数据训练BP神经网络后预测系统输出，把预测输出和期望输出之间的误差绝对值和E作为个体适应度值F，计算公式为：

$$F = k(\sum_{i=1}^n \text{abs}(y_i - o_i)) \quad (6.6)$$

式(6.6)中， n 为网络输出节点数； y_i 为神经网络第 i 个节点的期望输出； o_i 为第 i 个节点的预测输出； k 为系数；

c 选择操作

遗传算法选择操作有轮盘赌法、锦标赛法等多种方法，本文采用轮盘赌法，即基于适应度比例的选择策略，每个个体 i 的选择概率 p_i 为

$$f_i = k / F_i \quad (6.7)$$

$$p_i = \frac{f_i}{\sum_{j=1}^N f_j} \quad (6.8)$$

式(6.7)中， F_i 为个体 i 的适应度值，由于适应度值越小越好，所以在个体选择前对适应度值求倒数； k 为系数； N 为种群个体数目。

d 交叉操作

由于个体采用实数编码，所以交叉操作方法采用实数交叉法，第 k 个染色体 a_k 和第 l 个染色体 a_l 在 j 位的交叉操作方法如下：

$$\begin{cases} a_{kj} = a_{kj}(1-b) + a_{lj}b \\ a_{lj} = a_{lj}(1-b) + a_{kj}b \end{cases} \quad (6.9)$$

式(6.9)中， b 是[0,1]间的随机数。

e 变异操作

选取第 i 个个体的第 j 个基因 a_{ij} 进行变异，变异操作方法如下：

$$a_{ij} = \begin{cases} a_{ij} + (a_{ij} - a_{\max}) * f(g) & r > 0.5 \\ a_{ij} + (a_{\min} - a_{ij}) * f(g) & r \leq 0.5 \end{cases} \quad (6.10)$$

式(6.10)中， $a_{\max}$ 为基因 a_{ij} 的上界； $a_{\min}$ 为基因 a_{ij} 的下界； $f(g) = r_2(1 - g / G_{\max})^2$ ； r_2 为一个随机数； g 为当前迭代次数； $G_{\max}$ 为最大进化次数； r 是[0,1]间的随机数。遗传算法优化BP神经网络流程图如图6.10所示。




图 6.10 遗传算法改进 BP 神经网络流程图

Fig.6.10.The flow chart of genetic algorithm improving BP neural network

在 MATLAB 环境下编写以遗传算法为主函数的程序，来优化之前搭建的神经网络。（程序见附录），得到最优个体适应度函数值变化曲线图 6. 11。




图 6.11 适应度值变化曲线图

Fig.6.11 The curve of the variable fitness value

将优化后的网络用于预测 20 号机组，作为对总区域功率预测的基础。精度对比在最后的总区域功率预测当中给出，在此不再赘述。

6.3.4 风电场分区域及总区域功率预测

上一小节以对3号分区域的20号标准机组运用优化后的BP神经网络进行预测，阐述了对各分区域标准机组的预测方法，证明运用通过遗传算法优化后的神经网络对标准机组的预测方法是切实可行的，而且精度相较普通BP神经网络来说确实有提高。因为标准机组输出功率和整个分区域输出关系密切，所以可以通过预测标准机组输出来预测分区域出力。

以 20 机组所在 3 号分区域为例，实际操作流程为：将与 3 号分区域输出功率相关性高的两个标准机组 20 号与 22 号的预测功率乘以相应的权值 μ_1 、 μ_2 作为输入样本，依旧用优化后的 BP 神经网络进行预测，如图 6.10 所示。




图 6.12 3 号分区域神经网络预测结构图

Fig.6.12 Schematic diagram of neural network prediction to 3th regional

其他分区域数值结果也都是如此，最后将得到各分区域出力估量值，加在一起就得出风电场出力预测值，对实例风电场总区域输出功率BP预测方法、GABP预测方法以及同实际输出功率的对比情况，如图6.13所示。




图 6.13 总区域预测结果

Fig.6.13 Predictive results of entire region

通过图6.13对比可知：传统预测方式未考虑电场空间分布的影响，让预测输入数据信息包络程度不高，进而精度变低。本文搭建区域聚类分析的改进BP神经网络预测模型能有效筛选并集合与输出功率相关程度高的因素，最大程度减少误差介入几率，相比改进之前传统BP网络的预测结果准确度更高，能使预测误差下降4%左右。如表6.6所示：

表6.6 本文预测模型对比结果

Tab.6.6 The comparing results of predictive model of the article

方 法	平均绝对误差	均方根误差
BP 预测模型	2.4MW	24.89%
GABP 预测模型	1.92MW	21.12%

6.4 本章小结

本章是本文的核心部分，具体阐述了基于区域谱聚类分析的改进神经网络短期风电功率预测方法的具体实现过程。通过在Matlab中搭建标准机组的仿真模型，与实际输出功率、传统神经网络方法预测功率的对比，证明本文提出的预测模型能在较大程度上提高短期风电输出功率的预测精度，优势如下：

(1) 风电场的输出功率受地形地貌的影响较大，因此空间分布是功率预测不可忽略的因素，本文一改传统预测方式对整个风力发电场整体等效建模的方法，通过分区建模，充分考虑风电场中各机组的环境影响，客观得反映出每一分区域影响因素的差异，是整个预测精度提高的基础。

(2) 本章在众多主流方法中选用BP神经网络作为基础方式，正是利用了其具备较强学习能力、对数据有极强敏感性、能够较为精确的拟合出非线性事件间的联系，对于风速变化能够快速反馈并且适应，非常适合功率预测这样具备非线性动力的系统。运用遗传算法对传统BP神经网络进行改进，使原网络的权值和阈值配置更加贴近预测环境，从而进一步提高预测精度。

(3) 在对各分区域的预测工作中，运用采集相关系数的方式筛选出和分区域关联度高的标准风电机组，将其作为预测的重点，简便且可靠性高，提高了预测效率。

7 结论与展望

7.1 结论

风能具有的较大随机性和波动性,直接导致风电场出力具有较大的不确定性。当风电场装机容量达到一定规模,这一不确定性将成为威胁电力系统安全稳定运行的重大隐患。较高准确度和可信度的风电功率预测,可以为并网规划和运行部门拟定科学配电方案做好充分理论准备,有效降低对系统自动控制装置及其执行元件相应速度等性能方面的要求,而成为确保风电高效并网的必然手段。

本文即是在这样背景下,选择风电机群出力预测作为研究课题。现对本文主要进程以及获取成果总结如下:

(1) 决定短期风电机群功率预测结果的误差除了风能本身所具备的随机性外,还与所选数据类型、预测方法、预测周期有关。通过建模分析,针对风电功率预测非线性特征明显,映射关系复杂、不确定性突出等特点选择 BP 神经网络法作为预测基础方法来进行预测,首先只是将单一的风电机群的历史功率作为输入向量,而并未考虑风速、压强、温度、风向等环境因素,预测精度不高。由此看来,输入向量的长度在很大程度上影响着输出。

(2) 基于数值天气预报的 BP 神经网络的预测方法能增加输入向量维数,较单一数据预测精度更高,可是通过分析发现:一个风电场就是一个风电机群,这样的一个风电机群由 10 至 100 台不等的机组构成,覆盖范围较大,各机组运行工况也不尽相同,若仅仅用一组数据来表征整个机群,预测精度远不能达到预期效果,因此,需要对风电机群的各机组进行具体分析,可是逐台进行建模分析,势必会降低预测效率,本文提出对一定地域内各个机组进行区域分析。

(3) 对于区域划分,本文将各机组输出特性结合运行环境因素,提出将谱聚类作为分区域划分的依据和途径,对具有相同或者相近运行工况机组进行聚类划分,实现机群分区域划分^[46]。通过实例验证可以得出该方法搭建模型可以较为客观地反映风电场的运行状态,是可靠的区域划分方法。

(4) 通过将考虑区域分布同 BP 神经网络相结合的预测方式,选择科学的预测周期可以较大程度地跟踪实际值,本文分别提前 8、4、2 以及 1 小时进行预测,得出提前 1 小时进行预测精度较高,此结论具备实际应用参考意义;并且在这样的基础上运用遗传算法对 BP 神经网络进行了优化,优化后的网络预测精度进一步提高。

(5) 模型的建立以及运用遗传算进行改进、仿真和应用是在 MATLAB2010a 环境下实现的, MATLAB 数值计算的能力强^[47]、操作简便、能够快捷高效的处理大量的数据;编

程调用神经网络工具箱以及实现遗传算法对 BP 网络的改进，完成公式运算、矩阵操作以及方程求解等子程序的构造用于网络的设计和训练，使用方便，大大的减小了原本极其复杂和费时的神经网络预测难度和训练时间。

7.2 展望

研究过程中也发现部分问题需要在后续的探索中来解决：

（1）本文所采用的改进BP神经网络预测方法存在着只能有限提高原有BP神经网络的预测精度，并不能把原来误差较大的网络优化为能够准确预测的网络这样的缺陷，因此有必要对改进的算法进行完善；

（2）本文在构造神经网络过程中，对网络参数的设定，并没有经过严格的论证而是根据以往的实践经验来进行的，所以需要对神经网络的理论实质进行探索，使设定参数及对网络搭建的方式更加科学，更加贴近风电功率预测的实际环境。

（3）预测风电功率输出，以及对网络的训练所用到的输入数据需要进一步完善，使得神经网络能够尽可能精确的映射所预测风电机群的输入输出关系；

（4）我国幅员辽阔，风力充沛的地域环境千差万别，因此需要对我国的风力资源做出更加深入的考察，收集尽可能多的第一手数据，充分掌握不同地域风能特点，为预测工作做好更加充分的数据支持。

随着风电装机功率的规模日益扩大^[48]，风能的利用在电网中的地位和作用日益凸显，对于机组出力预测研究实际意义也日益重大，进一步提高预测精度，为电力事业做出贡献将是风电功率预测坚定不移的奋斗目标。

参考文献

- [1] 葛珊珊, 张韧. 全球气候变化背景下灾害性天气变化及对海上风电的影响[J]. 中国工程科学, 2010, 12(11): 71-77.
- [2] Jia-bing HU Yi-kang HE, Lie XU et al. Dynamic modeling and direct power control of wind turbine driven DFIG under unbalanced network voltage conditions[J]. 浙大学学报(英文版) (A), 2008.
- [3] 徐伟燕. 智能神经网络在大型风电场短期功率预测中的应用[D]. 北京: 北京交通大学, 2012.
- [4] 戴慧珠, 陈默子, 王伟胜等. 中国风电发展现状及有关技术服务[J]. 中国电力. 2005, 38(1): 80-84.
- [5] 张勇, 郭培源, 陈浩军等. 中欧风电规程有功和无功控制的比较研究[J]. 电力系统保护与控制. 2011, 39(15): 141-145.
- [6] 黄金花. 基于神经网络的风电场短期风电功率预测研究[D]. 南京: 东南大学, 2010.
- [7] 曹磊. 考虑风电并网的超短期负荷预测[D]. 保定: 华北电力大学, 2007.
- [8] 方江晓. 周晖. 黄梅. 基于统计聚类分析的短期风电功率预测[J]. 电力系统保护与控制. 2011, 39(11): 46-52.
- [9] 龚民焯. 风力发电的全球展望[J]. 上海节能. 2008(3): 28-31.
- [10] 刘永前, 韩爽, 胡永生. 风电场出力短期预报研究综述[J]. 现代电力. 2007, 24(5): 6-11.
- [11] 柯拥勤. 风电场风速及风电场功率预测研究[D]. 保定: 华北电力大学, 2012.
- [12] 韩爽. 风电功率短期预测方法研究[D]. 北京: 华北电力大学, 2008.
- [13] 崔建红, 许健, 刘京爱. 我国风力发电的现状和趋势[J]. 科技情报开发与经济. 2009, 19(10): 121-123.
- [14] 赵东. 风电预报之困[J]. 科技创业, 2012, (8): 68-69.
- [15] 谢建华, 崔新维. 风力发电机设计成本研究现状及进展[J]. 新疆农机化. 2006, (3): 37-39.
- [16] 高赐威, 何叶, 胡荣等. 考虑大规模风电接入的电力规划研究[J]. 电网与清洁能源. 2011, 27(10): 53-59.
- [17] 王秀丽. 风力发电系统发展现状分析[J]. 华电技术. 2010, 32(8): 73-75.
- [18] 高阳, 欧阳群, 关慧敏等. 风电场接入电网技术研究综述[J]. 东北电力技术. 2010, 31(2): 14-17.
- [19] 曹张洁, 向荣, 谭谨等. 大规模并网型风电场等值建模研究现状[J]. 电网与清洁能源. 2011, 27(2): 56-60.
- [20] 叶杭治. 风力发电机组的控制技术[M]. 北京: 机械工业出版社, 2006.
- [21] 李智, 韩学山. 计及风电预测误差分布特性的概率机组组合[C]. 电力系统及其自动化. 全国博士生学术论坛电气工程论文集. 2008: 395-401.
- [22] 杨文佳, 康重庆等. 基于预测误差分布特性统计分析概率性短期负荷预测[J]. 电力系统自动化, 2006, 30(19): 47-52.
- [23] 袁铁江 晁勤. 风电并网技术[M]. 北京: 机械工业出版社, 2012.
- [24] 何显富, 卢震, 杨越进, 刘万琨. 风电机组设计、运行与维护[M]. 北京: 电子工业出版社. 2009.
- [25] 王明军, 高原生. 风电机组实际运行功率曲线影响因素分析[J]. 风能. 2013(4): 74-79.
- [26] 赵帆, 杨燕翔. 基于相关因素及空间分布的风电功率预测研究[J]. 电子世界, 2014(11): 138-139.

- [27] 栗然, 陈倩, 徐宏锐. 考虑相关因素的最小二乘支持向量机风速预测方法[J]. 电力系统保护与控制, 2010, 38(21): 146-151.
- [28] 潘红宇. 时间序列分析[M]. 北京: 对外经济贸易大学出版社, 2006.
- [29] 王丽婕, 廖晓钟, 高阳等. 风电场发电功率的建模和预测研究综述[J]. 电力系统保护与控制, 2009, 37(13): 118-123.
- [30] 肖永山. 风电场短期产能预测研究[D]. 新疆: 新疆大学, 2007.
- [31] 杜力博. 基于 RS—SVM 风电场风速估计的方法研究[D]. 西安: 西安科技大学, 2009.
- [32] 张德丰. MATLAB 神经网络应用设计[M]. 北京: 机械工业出版社, 2009.
- [33] 谌爱文. 基于 BP 和 RBF 神经网络的数据预测方法研究[D]. 长沙: 中南大学, 2007.
- [34] 高飞. MATLAB 智能算法超级学习手册[M]. 北京: 人民邮电出版社, 2014.
- [35] 飞思科技产品研发中心. 神经网络理论和 MATLAB7 实现[M]. 北京: 电子工业出版社, 2005.
- [36] 林俐, 陈迎. 基于扩散映射理论的谱聚类算法的风电场机群划分[J]. 电力自动化设备, 2013, (6): 113-118.
- [37] 乔嘉赓, 鲁宗相, 闵勇, 等. 风电场并网的新型使用等效方法[J]. 电工技术学报, 2009, 24(4): 209-213.
- [38] 岑添云. 风电场数据特征提取及风电功率实时预测研究[D]. 保定: 华北电力大学, 2014.
- [39] AKHMATOV, KNUDSEN H. An aggregate model of a grid-connected, large-scale, offshore wind farm for power stability investigations: importance of windmill mechanical system[J]. Electrical Power Energy Systems, 2002(24): 709-717.
- [40] FERNANDEZ L M, SAENZ J R, URADO F. Dynamic models of wind farms with fixed speed wind turbines[J]. Renewable Energy, 2006, 31(8): 1203-1230.
- [41] 米增强, 苏勋文, 杨奇逊, 等. 风电场动态等值模型的多机表征方法[J]. 电工技术学报, 2010, 25(5): 162-167.
- [42] JAIN A, MURTY M, FLYNN P. Data clustering: a review[J]. ACM Computing Survey, 1999, 31(3): 264-323.
- [43] 武海巍, 于海业, 张蕾, 等. 基于参数优化支持向量机的林下参净光合速率预测模型[J]. 光谱学与光谱分析, 2011, 31(5): 1414-1418.
- [44] Gong Li, Jing Shi. On comparing three artificial neural networks for wind speed forecasting [J]. Applied Energy, 2010, 7(87): 2313-2320.
- [45] 史峰, 王辉, 郁磊, 等. MATLAB 智能算法 30 个案例分析[M]. 北京: 北京航空航天大学出版社, 2011.
- [46] 别朝红, 安佳坤, 陈筱中, 等. 一种考虑时空分布特性的区域风电功率预测方法[J]. 西安交通大学学报, 2013, 47(10): 68-74.
- [47] 王小川, 史峰, 郁磊, 等. MATLAB 43 个神经网络案例分析[M]. 北京: 北京航空航天大学出版社, 2013.
- [48] 杨敏, 邓英. 基于变桨距的双馈风电机组并网运行特性研究[D]. 保定: 华北电力大学, 2013.

附录 A 遗传算法优化神经网络部分代码及气象数据

1. 遗传算法主函数:

```

[Chrom,ObjV]=reins(Chrom,SelCh,1,1,ObjV,ObjVSel);
X=bs2rv(Chrom,FieldD);
gen=gen+1;
[Y,I]=min(ObjV);
trace(1:N,gen)=X(I,:);
trace(end,gen)=Y;
end

```

2. 神经网络子函数 Bpfun

```

function err=Bpfun(x,P,T,hiddennum,P_test,T_test)
    inputnum=size(P,1);
    outputnum=size(T,1);
    net=newff(minmax(P),[hiddennum,outputnum],{'tansig','logsig'},'trainlm');
    net.trainParam.epochs=1000;
    net.trainParam.goal=0.01;
    LP.lr=0.1;
    net.trainParam.show=NaN;
    w1num=inputnum*hiddennum;
    w2num=outputnum*hiddennum;
    w1=x(1:w1num);
    B1=x(w1num+1:w1num+hiddennum);
    w2=x(w1num+hiddennum+1:w1num+hiddennum+w2num);
    B2=x(w1num+hiddennum+w2num+1:w1num+hiddennum+w2num+outputnum);
    net.iw{1,1}=reshape(w1,hiddennum,inputnum);
    net.lw{2,1}=reshape(w2,outputnum,hiddennum);
    net.b{1}=reshape(B1,hiddennum,1);
    net.b{2}=reshape(B2,outputnum,1);
    net=train(net,P,T);
    Y=sim(net,P_test);
    err=norm(Y-T_test);

```

3. 子函数 Objfun

```

function Obj=Objfun(X,P,T,hiddennum,P_test,T_test)
    [M,N]=size(X);
    Obj=zeros(M,1);
    for i=1:M
        Obj(i)=Bpfun(X(i,:),P,T,hiddennum,P_test,T_test);
    end

```

二、部分气象数据

风速：（米/秒）

1.7463	1.8155	2.3074	2.9736	3.9364	3.7183	4.4545	4.7833	1.6512
3.4956	2.9836	3.6055	4.6453	3.7654	2.8946	2.5157	3.3765	4.6143
5.4345	4.3747	3.3568	2.8687	2.7574	3.2944	3.8336	3.3268	4.7274
3.2465	3.3455	3.0565	3.6054	3.9256	4.0758	4.2767	4.3467	3.3688
4.2753	3.8582	3.6965	3.4398	3.6195	3.7847	3.9665	3.7487	4.1476
4.2453	4.6276	4.4755	4.6436	4.2775	3.6764	3.0985	2.8547	4.0845
2.4666	2.8878	2.8075	3.1774	2.8767	3.3057	3.5139	3.2058	3.2987
2.5987	1.9355	2.4238	3.4967	2.7965	3.0084	2.6549	2.1134	3.4869
2.6152	2.2873	1.9985	1.5624	1.5662	1.5243	2.0023	1.7153	2.1734
1.9272	1.5657	1.4643	1.4445	1.4744	1.5245	1.3863	1.5256	1.9642
1.4642	1.7872	2.4288	3.9044	4.0735	3.3534	2.6168	2.2263	1.2635
1.1154	1.1643	1.0243	1.3265	1.6175	1.6734	1.6644	2.1753	1.6884
2.0254	2.6366	2.6967	1.9089	1.4246	2.1464	3.7315	3.9338	4.7293
3.3083	3.5146	2.4246	2.3544	1.8184	1.7595	6.2225	8.5293	8.6293
1.6363	1.3836	2.2254	1.7023	1.4132	1.8444	3.0315	6.4338	3.6338
1.5065	3.4233	2.4322	4.7642	4.2342	4.5674	7.4293	7.3276	9.2270
8.5225	4.9393	5.4270	5.4225	8.5225	5.4225	2.4225	5.7293	4.9293
4.4315	6.3338	4.6338	3.5827	4.4225	5.4293	1.9359	3.2359	2.3359
5.5315	6.3338	5.2338	5.8338	4.5338	2.7359	0.1359	2.0315	4.2338
2.9338	2.5315	1.6270	2.5315	2.2315	6.5293	5.7315	5.8315	6.8315
5.8227	6.0277	6.8027	8.4275	7.9225	4.7225	11.531	10.231	5.9315
8.6225	6.7225	7.7225	10.422	8.3203	8.2225	5.2527	5.7315	5.8315
2.0277	2.8248	1.5248	1.2248	6.6272	6.4277	8.4276	7.1293	8.4315
2.8276	7.3293	8.8293	8.5293	8.6293	6.0293	5.3272	7.2273	6.8275
4.8315	6.0293	3.7315	3.9338	4.7293	5.4277	7.4315	7.7315	6.1315
5.9272	6.7274	6.9275	7.3272	5.6276	5.9293	5.4277	5.1272	4.4274
9.2315	8.1315	9.9315	8.9315	7.7315	7.4315	6.0293	7.6293	8.6315
8.4327	7.5727	6.5293	7.4293	6.9293	5.3272	6.4277	6.8274	6.0274
7.6273	8.8273	9.1277	7.6274	8.3273	8.4276	8.2225	6.6315	7.8338

攻读硕士学位期间发表学术论文情况

- 1 赵帆, 基于相关因素及空间分布的风电功率预测研究. 电子世界, 2014 (11): 138—139. 主办单位: 中国电子学会。

致 谢

本论文的工作是在我的导师杨燕翔教授悉心指导下完成的，论文从选题到完成，都凝聚着导师的辛勤工作和心血。在这三年的研究生期间，杨老师无论是学习科研上，还是生活上都给了我很多的指导和帮助，在此，谨向恩师表示深深的敬意和衷心的感谢！

感谢实验室的所有同学和师兄师姐师弟师妹们，他们在我研究生期间给予了无私的帮助，共同创造了良好的学习环境。

感谢同学易忠尧、邓强、鲁位。这三年来我们相互扶持，见证了彼此的成长，这份纯真的友情将永远留在我心中。

求是 明德 卓越

