

分类号: TM614

单位代码: 10220

密 级:



东北石油大学

NORTHEAST PETROLEUM UNIVERSITY

专业学位研究生学位论文

专业类别: 能源动力 (领域: 电气工程)

论文题目: 改进海鸥算法优化 BP 神经网络

在大庆地区风电功率预测的应用

学生姓名: 韩星

指导教师: 闫丽梅 教授 (校外: 张立伟 高级工程师)

论文类型: 应用研究

研究方向: 新能源并网

培养类别: ☒ 全日制 ☐ 非全日制

入学时间: 2020 年 9 月

论文完成时间: 2023 年 6 月

Optimized BP Neural Network Based on Improved Seagull Algorithm and its Application in Wind Power Forecasting in Daqing Region

by Han_Xing

Supervisor: Professor Yan Limei

Pluralistic Supervisor: Senior Engineer Zhang Liwei



A Thesis Submitted to the **Northeast Petroleum University**

In partial fulfillment of the requirement

For the Professional Master of *Electrical Engineering*

Full-time

June, 2023

改进海鸥算法优化 BP 神经网络在大庆地区风电功率预测的应用

摘 要

风力发电作为主要的新能源发电的途径之一，因具有短建设周期，低技术需求，成本回收较快，产生污染较少等优点而被各国大力提倡。风电功率预测对于风力发电厂的运营和管理至关重要，准确的功率预测结果可以帮助风力发电厂进行日常运营决策，例如如何安排发电机组的启停、如何进行负荷调度等。为保证电能质量，减小风电并网对电网的影响，需要对风电功率预测的准确性有着较高的要求。

本文在研读了众多国内外学者对风电功率预测的研究现状后，确定研究路线，寻找数据集来源及获取数据集，再用皮尔逊（Pearson）相关分析法分析各因素与风电功率的相关性，根据相关性确定使用的数据集相关参数。传统的反向传播神经网络可以用来做预测模型，但它存在精确度不高的缺点。为了提高风电功率预测模型的准确性，本文提出了一种基于优化海鸥算法改进的 BP 神经网络的风电功率预测模型。本文将 Logistic 混沌映射引入基础海鸥算法中，引入混沌映射可以使初始海鸥种群中的个体分布更均匀，对初始海鸥种群的位置进行随机扰动，可以避免算法陷入局部最优解。改变海鸥算法中海鸥个体的运动方式，使其从线性运动改为非线性运动，从而提高算法的收敛能力。利用改进后的海鸥算法寻找最优适应度个体作为 BP 神经网络初始的权值和阈值建立预测模型，可以大大提高 BP 神经网络的性能，将上述模型应用于大庆地区风电功率预测中，提高大庆地区风电功率预测的准确性。本文还对比了提出的改进海鸥算法优化 BP 神经网络模型与其他风电功率预测模型的结果，结果表明，本文提出的模型能够有效地提高风电功率预测的准确性，降低预测误差的波动性。

关键词：风电功率预测，海鸥优化算法，Logistic 混沌映射，BP 神经网络

Optimized BP Neural Network Based on Improved Seagull Algorithm and its Application in Wind Power Forecasting in Daqing Region

ABSTRACT

As one of the main ways of new energy power generation, wind power generation has the advantages of short construction period, low technical requirements, fast cost recovery, and less pollution, which is strongly advocated by various countries. Wind power forecasting is crucial to the operation and management of wind power plants. Accurate power forecasting results can help wind power plants make daily operational decisions, such as how to schedule the start-up and shutdown of generator sets, and how to perform load scheduling. In order to ensure the quality of wind power and reduce the impact of wind power grid-connected on the grid, there are also high requirements for the accuracy of wind power prediction.

This paper first introduces the research status of many scholars at home and abroad on wind power prediction, finds the source of data sets and obtains data sets, and then uses Pearson correlation analysis method to analyze the correlation between various factors and wind power, finally determines the use of wind power according to the correlation.

The traditional backpropagation (BP) neural network can be used as a prediction model, but it has the shortcoming of low accuracy. So as to improve the accuracy of the wind power forecasting model, this paper proposes a wind power forecasting model that optimizes the Seagull algorithm and improves the BP neural network. This paper also introduces the Logistic chaotic map into the basic seagull algorithm, which can make the individual distribution more uniform in the initial seagull population. By randomly perturbing the position of the initial seagull population, the algorithm can be prevented from falling into a local optimal solution. Changing the movement mode of individual seagulls in the seagull algorithm from linear movement to nonlinear movement, so as to improve the convergence ability of the algorithm. By using the improved seagull algorithm to find the optimal fitness individual as the initial weight and threshold of the BP neural network to establish a prediction model can greatly improve the performance of the BP neural network. This above model of the wind power prediction improves the accuracy of wind power forecasting when applying in Daqing area. This paper also compares the results of the proposed optimized the BP neural network model by improved seagull algorithm with other wind power forecasting models. The results show that the model proposed in this paper can effectively improve the accuracy of wind power forecasting and reduce the volatility of forecasting errors.

Keywords: wind power prediction; seagull optimization algorithm; Logistic chaotic map; BP neural network

目 录

第一章 绪论.....	1
1.1 选题背景.....	1
1.2 课题研究的意义及发展现状	2
1.2.1 风电功率预测的研究意义.....	2
1.2.2 风电功率预测的研究现状.....	2
1.2.3 BP 神经网络的发展现状及应用.....	5
1.2.4 海鸥算法的发展现状和应用.....	6
1.3 本文的研究内容.....	7
第二章 数据的采集及处理	9
2.1 气象数据来源.....	9
2.2 数据处理.....	10
2.2.1 数据清洗.....	10
2.2.2 数据集质量分析.....	12
2.2.3 数据分割.....	13
2.2.4 数据归一化.....	13
2.3 本章小结.....	14
第三章 BP 神经网络模型及海鸥算法模型	15
3.1 BP 功率预测模型.....	15
3.1.1 BP 神经网络的网络结构.....	15
3.1.2 BP 神经网络的优缺点.....	16
3.1.3 BP 神经网络的基本原理.....	16
3.1.4 BP 风电功率预测模型预测步骤及流程图.....	20
3.1.5 BP 风电功率预测模型效果.....	21
3.2 SOA-BP 功率预测模型	23
3.2.1 海鸥算法基本原理.....	23
3.2.2 海鸥算法的优缺点分析.....	28
3.3 SOA-BP 功率预测模型	29
3.3.1 SOA-BP 风电功率预测模型预测步骤及流程图	29
3.3.2 SOA-BP 风电功率预测模型效果	30
3.4 本章小结.....	33
第四章 风电功率预测模型的建立与误差分析	34
4.1 改进海鸥算法.....	34
4.1.1 Logistic 混沌映射初始化海鸥种群.....	34
4.1.2 非线性惯性权重改进海鸥算法.....	35

4.1.3 优化后海鸥算法收敛情况对比.....	36
4.2 ISOA-BP 功率预测模型	37
4.2.1 ISOA-BP 风电功率预测模型预测步骤及流程图	37
4.2.2 ISOA-BP 风电功率预测模型效果	38
4.3 各功率预测模型拟合效果对比	41
4.4 各功率预测模型误差.....	43
4.4.1 各预测模型误差对比图.....	43
4.4.2 各预测模型误差对比表.....	45
4.4.3 模型训练效果比较与评价.....	48
4.5 本章小结.....	49
结论.....	50
展望.....	51
参考文献.....	52

第一章 绪论

1.1 选题背景

近年来,我国经济的快速增长一直归功于电力生产的增加,传统发电方式离不开化石燃料的燃烧,但由于化石燃料燃烧会导致空气污染,臭氧消耗和全球变暖,所以,越来越多的反对者反对从化石燃料中提取能源。各种可再生能源中,如太阳能、风能、潮汐能、核能和生物质能等均已进入发电领域。其中,由于风力资源丰富,对环境影响较小,高效且低成本,使得风力发电变得越来越受欢迎,渐渐在新能源发电生产中占主导地位^[1-3]。截至 2022 年,中国电力总体规模持续扩大,2022 年全国发电总量达到了 8.4 万亿千瓦时,同比增长 2.2%。同时,中国的装机容量也在不断增加,2022 年底全国电力总装机容量达到了 25.6 亿千瓦,同比增长 7.8%。近年来,我国政府提出了“绿色发展”和“能源革命”的目标,鼓励清洁能源的发展^[4]。目前,我国已经成为全球最大的风力发电和光伏发电国家。在风能成为越来越重要的能源来源同时,弃风现象也逐渐成为一个不容忽视的问题。弃风现象指的是风力发电厂在产生电力时,由于电网负载过轻或者风速过高,导致发电厂不得不关闭部分或者全部的风力发电机组,从而造成风能资源的浪费。为有效解决弃风现象^[5],准确的风电功率预测尤为重要。下图为 2013 年到 2023 年我国风电装机容量和我国弃风现象数据图,其中,图 1.1 为 2013-2022 风电装机容量,图 1.2 为 2013-2022 我国弃风电量数据。



图 1.1 2013—2022 风电装机容量图



图 1.2 2013—2022 我国弃风电量数据

中国电力行业正在向清洁、智能、市场化、互联网化的方向不断发展,电网覆盖面积已经达到了全国 98%以上,电力市场逐步向竞争性市场转型。目前,中国已经建立了全国性的电力市场和区域性的电力交易市场。能源互联网建设加速推进,通过信息技术和能源互联网技术的应用,提高能源的利用效率和清洁化程度。同时,中国也在加速推进智能电网建设,提高电网的可靠性和安全性^[6]。中国电力行业的市场化改革不断深化,这些发展趋势为中国电力行业的未来发展提供了良好的机遇。准确的风电功率预测对于评估未来的能源开采具有极其重要的意义,然而,风电场生产的电力由于风速和风向的

波动而迅速变化，它取决于地形，温度，风速^[7]和风向^[8]等因素。这种不断的变化使得风力发电管理对于配电网来说是一个挑战，因为在配电网中，电力供应之间的平衡是非常重要的需求^[9]。因此，进行风力发电功率预测的主要原因之一就是降低风速的不确定性，这对于更好的调度和维护也是至关重要的计划。

1.2 课题研究的意义及发展现状

1.2.1 风电功率预测的研究意义

风能是一种可再生能源，利用风力发电已经成为全球能源转型中不可或缺的一部分。然而，由于风速、风向和温度等自然因素的影响，风电发电量的不确定性很大，这给风电产业的发展带来了很大的挑战。风电功率预测对于电网的安全稳定运行^[10]非常重要，在电力系统中，电力调度员需要制定合理的电力调度计划，以保障电网的安全稳定运行。如果风电功率预测不准确，可能会导致电力调度计划出现偏差，从而影响电网的安全稳定运行。除了对电力系统的影响，风电功率预测还可以提高能源的利用效率。预测未来风力发电的功率可以帮助电力系统调度员合理规划风电、火电等不同能源的供应比例，减少弃风现象，从而最大化利用可再生能源，减少化石能源的使用，降低温室气体的排放。风电功率预测还可以降低风电发电的成本，通过预测风力发电功率的变化，电力公司可以将风电发电量与传统能源发电计划进行协调，避免了风电机组的过载或欠载运行，减少了电力系统中的不稳定性和故障率。最后，准确的功率预测还可以减少电力系统中的频率偏差、电压波动、谐波等问题^[11]，保证了电网的安全稳定运行，同时提高电力质量。风电功率预测可以通过优化风电机组的发电计划，提高风电发电的效率、保证电能质量和电网安全稳定运行，从而节省经济成本。以下是一些实际的例子：美国加利福尼亚州的一家能源公司使用风电功率预测技术，优化风电机组的发电计划，将风电发电量提高了约 10%，并减少了燃料成本和二氧化碳排放量；德国一家风电场使用高精度的风电功率预测技术，将风电机组的发电计划与电力市场需求进行匹配，从而最大化风电发电量和收益，这一技术的应用使该风电场的收益增加了约 5%；欧洲的一些国家使用风电功率预测技术，优化电力系统调度计划，从而降低了电力调度成本和系统的稳定性风险；法国一家电力公司使用风电功率预测技术，将风电发电量与传统能源发电计划进行协调，从而避免了电力系统中的电压波动等问题，提高了电能质量。通过以上实例均可表明，准确的风电功率预测可以简化工作人员的工作任务，降低发电成本，减少化石燃料燃烧和提高电网的安全性等等。

1.2.2 风电功率预测的研究现状

风电功率预测是指利用各种方法和技术，对未来一定时间内风电场的电力输出进行预测。目前，风电功率预测的研究可以分为以下几个方向：

1. 基于统计方法的预测：该方法一般建立 NWP 数据（如风速、风向和温度）与发

电量之间的非线性和线性关系。为了定义这种统计关系，将使用以前的历史数据作为训练数据，然后通过比较模型预测和在线测量的功率来调整模型。在此之后，通过 NWP 对未来几个小时的预测和在线测量，模型就可以进行预测，统计方法易于建模且价格低廉^[12]。它是一种短期的预测模型，随着估计时间的增加它的预测精度会逐渐降低^[13]。统计方法可以分为两个主要的子分类：基于时间序列和建立的神经网络（ANN）时间序列模型。该模型由 Box-Jenkins 提出，利用历史数据生成数学模型，以建立模型、估计参数和检查仿真特性。该模型的一般形式可描述为：

$$X_t = \sum_{i=1}^p \varphi_i X_{t-i} + \alpha_t - \sum_{j=1}^q \theta_j \alpha_{t-j} \quad (1.1)$$

其中， φ_i 表示自回归参数， θ_j 为移动平均参数， α_t 为白噪声， p 为自回归阶数， q 为移动平均模型阶数， X_t 为 t 时刻的预测风电功率。整个方程表示（ARMA，AutoRegressive Moving Average）自回归移动平均模型，假设 p 为零，则表示移动平均模型（MA），当 q 假设为零时，将表示自回归模型（AR）^[14]。基于这种原理的统计方法易于制定，只需要较低的计算时间，所以在短期风电预测中非常适用^[15]。然而，当时时间序列是非平稳时^[16]，它们可能无法提供足够的预测性能。Firat 等人^[17]提出了基于独立分量分析的统计模型和用于风速预测 AR 模型。作者利用荷兰一个风电场 6 年每小时的风速，得出所提出的模型可以比提前几小时的直接预测方法提供更高的精度。

2. 基于物理模型的预测：物理方法使用详细的物理特征来模拟风电场。这种建模方法通常是通过缩小数值天气预报（NWP）数据来实现的，这需要对区域进行描述，如地形条件和障碍位置，以及温度、压力等天气预报数据。上述变量用于物理预测模型的输入，而后输出预测出来的风速，然后将预测风速和相关的风力机功率曲线结合的方法来预测风电功率。这种方法不需要用历史数据进行训练，但它们确实也依赖于物理数据，近几十年来，许多物理方法被提出。例如，Focken 等人^[18]创建了一种物理风力发电预测方法，其时间尺度可提前 48 小时，该方法建立在一种从天气预报模型中接收输入数据的物理方法之上。DeFelice 等人^[19]使用一个物理模型来预测意大利的电力需求，考虑 14 个月每小时的温度作为输入，与单纯的平均绝对误差（MAE）方法的比较结果表明，NWP 模型可以提高预测性能，特别是在最热的地区效果更为明显。虽然这种方法可以作为中长期风力发电预测的最佳选择，但它需要大量的计算资源，计算方法很复杂^[20]。

3. 基于机器学习的预测：人工神经网络是最常用的风力发电预测方法之一，它可以识别输入特征与输出数据^[21]之间的非线性关系，倾向于使用神经网络的原因之一是为了避免风力涡轮机^[22]机械结构的复杂性。通常，人工神经网络模型由一个输入层、一个或多个隐藏层^[23]和一个输出层组成，其中的历史数据用于训练和测试。人工神经网络通过训练过程来调整这些相互联系的权重，如果需要输出在过程的开始时是已知的，它将被命名为监督；相反，它将被称为无监督^[24]。人工神经网络的性能依赖于许多不同的因素，

包括数据预处理、数据结构、学习方法、输入和输出数据之间的连接等^[25]。人工神经网络有 50 多种形式,包括多层感知器 (MLP)^[26],小波神经网络 (WNN)^[27],反向传播神经网络 (BPNN)、径向基函数神经网络 (RBFNN)^[28]、Elman 神经网络 (ENN)^[29]、长短期记忆 (LSTM)^[30]和卷积神经网络 (CNN)^[31]等。设计一个神经网络模型需要处理两个步骤:首先选择正确的网络结构,然后指定传递信息的方向。然后是在有监督、无监督和强化学习^[32]中选择正确的学习算法。机器学习有两种主要的拓扑,包括用于从输入层向输出层向一个方向传递数据的前馈和对返回方向的循环。Jyothi^[33]使用自适应小波神经网络 (AWNN) 进行短期风功率预测,得出的准确度高于当时学者的其他模型。结果可以表明,除风速外,空气温度也是对模型准确度的影响很大的因素。Mao^[34]等人则利用 ENN 研究了中国西部风力发电场的一个 15kW 风力涡轮机。利用风速、风向、湿度、温度等输入变量,在 ENN 上应用粒子群优化算法后,作者得出了令人满意的精确度。在另一项调查中,Chang W^[35]则开发了一个基于 BPNN 的 10min 提前风力发电预测模型,该模型在与其他模型的对比中均方误差 (MSE) 最小。

4. 基于混合方法的预测:动态预测方法的组合,如人工神经网络和模糊逻辑结合的模型,被称为混合方法。该方法的主要目的是保留每种技术的优点,提高整体准确度。在统计学和机器学习^[36]中,不同的预测模型通常通过使用多种算法和不同的训练数据集开发。这个过程被称为集成建模,一个组合可能并不总是会导致更好的结果,所以许多混合方法已经基于延迟模型的组合而被提出,这是一种更先进的混合预测类型。Hong^[37]提出了一种基于卷积神经网络 (CNN) 的混合超前风力发电预测模型,在 CNN 中使用卷积、池化和内核等发散操作来提取输入特征,然后将定义的特征输入一个径向基函数神经网络 (RBFNN),实现双高斯函数 (DGF) 作为激活函数。作者还利用自适应矩估计 (ADAM) 进一步改进了 CNN 和 RBFNN。利用台湾中一个风电场提供的一年历史功率数据,与多层前馈神经网络 MFNN-GA (遗传算法)、RBFNN-GA、RBFNN-DGF 等其他方法相比,结果表明,该方法提供了最好的性能。作者还得出结论,DGF 在 RBFNN 中的应用比传统的高斯函数在 RBFNN 中的应用产生了更好的结果。林等人^[38]实现了隔离森林 (IF) 和深度学习神经网络来检测异常值,以实现更准确的风力发电预测风速、风向、气温等。从一个风力涡轮机的监控和数据采集 (SCADA) 的数据集中提取作为输入,同时使用风力发电作为预测模型的输出。比较结果表明,当被调查的数据不遵循正态分布^[39]时,IF 是一种更有效的准确预测方法。在另一篇论文中,作者评估了苏格兰一个 7MWh 风力涡轮机的 11 个特征,包括 4 个不同高度风机的风速、平均叶片俯仰角、三个叶片的 3 个测量俯仰角、环境温度、偏航误差和机舱方向。结果表明,叶片变桨角对预测模型性能的影响最大,甚至大于风速和风切变。相反,风向和空气密度的影响最小,所以消除它们可以减少计算时间。张等人^[40]利用 LSTM 网络预测了一个风电场的风电功率,以三个月的 NWP 和风速数据作为输入,以产生的风力发电作为输出。在国家电网公司标准下,将模型与径向基函数 (RBF)、小波、深度信念网络 (DBN)、

反向传播 (BP) 和 Elman 进行了比较, 结果表明, 该模型虽然运行时间较长, 但提高了预测准确度。它还表明, 该模型的性能在很大程度上取决于风速的范围, 在高速条件下, 小波的性能更好, 而其他方法在较低速区域的预测效果较好。采用混合密度神经网络 (MDN)、相对向量机 (RVM) 和高斯混合模型 (GMM) 三种不同的方法评估了预测功率的不确定性, 结果表明, GMM 的性能最好。赵等人^[41]提出了 1-6 小时风力预报的双向模型。在他们的模型中, 来自前向模型的预测功率被用作后向模型的优化算法的输入。然后, 通过比较反向结果之间的差异, 作者得出最终的预测功率。将该模型与正向、逆向、持久性方法的评价标准进行比较, 发现其评价结果均优于其他模型。

1.2.3 BP 神经网络的发展现状及应用

BP 神经网络的发展可以追溯到上世纪 80 年代, 当时提出了反向传播算法, 这使得神经网络的训练变得可行, 也使得神经网络开始受到广泛关注。在接下来的几十年里, BP 神经网络经历了多次发展和改进。其中, 最显著的进步之一是 1990 年代末期到 2000 年代初期提出的基于增量式学习的 BP 神经网络, 如递增式学习算法 (Incremental Learning Algorithm)^[42]、快速 BP 算法 (Quickprop Algorithm)^[43] 和高效 BP 算法 (Conjugate Gradient BP Algorithm)^[44] 等, 这些算法在处理大规模数据和高维特征时效果更好。另外, 为了处理序列数据, 出现了循环神经网络 (Recurrent Neural Network, RNN)^[45], 它在 BP 神经网络的基础上引入了时序信息。而为了处理图像数据, 出现了卷积神经网络 (Convolutional Neural Network, CNN)^[46], 它利用卷积运算来提取图像中的特征, 然后通过 BP 算法来进行训练。这些网络的出现极大地拓展了 BP 神经网络的应用范围, 最近几年, 随着深度学习的兴起, BP 神经网络得到了更广泛的应用。为了更好地训练深度神经网络, 出现了一些优化算法, 如 Adam 算法、Adagrad 算法、RMSProp 算法等, 这些算法基于梯度下降的思想, 能够更有效地训练神经网络。

BP 神经网络是一种应用于机器学习和人工智能领域的人工神经网络。它被广泛用于分类、回归、图像处理、自然语言处理、时间序列预测、信号处理等方面。以下是 BP 神经网络的一些应用:

BP 神经网络可以用于分类^[47-48]任务, 例如将一张图片分类为狗或猫, 通过输入图片像素值作为神经网络的输入, 训练网络来识别不同类别的图像; BP 神经网络可以用于图像处理^[49]任务, 例如图像识别和图像分割, 通过训练神经网络来学习图像的特征和结构, 可以对图像进行分类和分割; BP 神经网络可以用于自然语言处理^[50]任务, 例如情感分析和文本分类, 通过输入不同的文本作为神经网络的输入, 训练网络来识别不同的情感和主题; BP 神经网络可以用于信号处理^[51]任务, 例如语音识别和音乐分析, 通过输入不同的信号数据作为神经网络的输入, 训练网络来识别不同的声音和音乐元素。总的来说, BP 神经网络在各种机器学习和人工智能领域都有广泛的应用, 它的灵活性和强大的建模能力使其成为解决复杂问题的有力工具。

本文是利用 BP 神经网络可以用于预测和预测建模的特点，以下是 BP 神经网络在预测中的应用场景和方法：

股票价格预测^[52]，用于预测股票价格走势，通常情况下，输入数据包括历史股票价格、市场指数、公司基本面数据等，输出数据为未来一段时间内股票价格的预测值；货币汇率预测^[53]，BP 神经网络可以用于预测货币汇率的变化趋势，输入数据包括历史汇率数据、经济指标、政治事件等，输出数据为未来一段时间内汇率的预测值；交通流量预测^[54]，BP 神经网络可以用于预测道路交通流量，输入数据包括历史交通流量、天气、时间等，输出数据为未来一段时间内道路交通流量的预测值；销售预测^[55]，BP 神经网络可以用于预测商品的销售量，输入数据包括历史销售数据、市场环境、促销活动等，输出数据为未来一段时间内销售量的预测值；电力负荷预测^[56-57]，BP 神经网络可以用于预测电力负荷，输入数据包括历史电力负荷、天气、季节等，输出数据为未来一段时间内电力负荷的预测值。

在使用 BP 神经网络进行预测时，需要将历史数据用于训练模型，然后将训练好的模型用于预测未来的数据。为了提高预测的准确性，可以通过优化网络结构、选择合适的激活函数、调整学习率等方式来优化 BP 神经网络的性能。但需要注意的是，BP 神经网络的预测结果也会受到数据质量和模型参数的影响，需要进行合理的模型设计和调优。

1.2.4 海鸥算法的发展现状和应用

海鸥算法是一种新兴的群智能优化算法，它拥有简单的算法结构和广泛的适用性。由于其简单的算法结构，该算法具有较低的复杂度，计算效率高，易于改进和融合，受到了众学者的广泛欢迎。孙培胜^[58]等人提出一种基于海鸥算法优化支持向量机的光伏阵列故障诊断方法，可以在更快的寻优收敛迭代速度下拥有更高的故障诊断准确率。Samal^[59]等人使用改进的海鸥算法对互联配电网中配电网静止同步补偿器的位置布局进行优化。罗浩^[60]为了提高矿震定位精度，保证算法能快速收敛且具有较强鲁棒性，提出了一种基于改进非线性海鸥算法的矿震定位算法。通过海鸥间相互作用求解震源点位置，为某煤矿的一次大能量矿震事件提供了能量源。Long^[61]等人将改进的海鸥算法应用于光伏电池模型的参数估计问题。商俊杰^[62]就无功优化问题结合了海鸥算法，最后实现了提升电能质量，降低线路损耗的目的。Abdelhamid^[63]等人将改进的海鸥算法应用于组合式距离继电器和方向性过电流继电器在近端和远端的协调优化问题。刘双^[64]为提高室内定位精度，提出了一种基于黄金正弦与 Sigmoid 连续化海鸥优化算法（GSCSOA）的接收信号强度可见光室内定位技术。改进后的室内定位算法精度更高，可应用于大部分的室内定位场所。Gang^[65]等人将改进的海鸥算法用于包括太阳能电池板、风力涡轮机、逆变器、整流器、电解槽和燃料电池的新型混合能源系统的多目标优化问题以最小化污染排放和成本，实验结果表明优化后的系统能够以较高的可靠性和远低于规定阈值

的电源损耗率运行。梁家琦^[75]等人将自适应噪声完备经验模态分解和改进深度置信网络相结合,得出了一种具有更好的诊断效果的新型的故障诊断方法。

1.3 本文的研究内容

在仔细阅读国内外现状的情况下,系统地回顾了风电功率预测的物理方法、统计方法、机器学习、群智能算法和混合方法^[66],用以了解在预测模型中影响预测结果准确度和预测计算时间的因素,继而确定本文的研究方向。本文第二章主要介绍了数据集的质量分析、气象数据和风电功率数据的采集、数据处理、数据分割以及数据归一化等工作^[67]。这些是降低模型的错误率和提高预测准确性的预处理工作,是提高模型的整体性能和可靠性的重要一环。数据集的质量分析是为了确定相关因素的相关程度,用以确定本文使用的数据都包括哪些方面。数据处理则是对原始数据进行清洗、去噪和修补等工作,以保证数据的准确性和完整性^[68]。数据分割则是将数据集分为训练集和测试集,以用于模型的训练和测试。数据归一化^[69]则是将数据进行标准化处理,以消除数据的尺度差异,提高模型的预测准确性。第三章首先介绍了神经网络^[70]和原始海鸥算法,然后建立了BP预测模型和SOA-BP预测模型。BP神经网络作为一种重要的机器学习算法,在计算机视觉、自然语言处理、语音识别、推荐系统、智能问答等多个领域中得到了广泛应用^[71]。神经网络具有训练过程自动化、非线性映射能力强、适用于大规模数据等优点,因此被广泛用于处理复杂的实际问题。同时,神经网络也存在着一些缺点,例如训练时间较长、需要大量的数据和计算资源等。海鸥算法^[72]作为一种新兴的优化算法,其原理是通过模拟海鸥的行为寻找最优解。通过建立BP和SOA-BP预测模型,通过对比不难看出,其预测准确度并没有达到很高的要求。第四章首先从两方面改进了海鸥算法:一是采用logistic混沌映射随机扰动海鸥^[73]的初始位置,使初始位置更加均匀;二是将原本的线性运动改为非线性运动^[74],以更好更快地收敛到最优解,在陷入局部最优的情况下迅速跳出。然后利用改进的海鸥算法作为优化方法,建立了一个风电功率预测模型。该模型利用BP神经网络对风电功率进行预测,并使用海鸥算法来寻找最优的权值和阈值,以提高模型的预测准确性。建立大庆地区风电功率预测实验模型后,得出预测功率并进行误差分析,结果表明,本文所提出的模型能够显著提高预测准确性,降低预测误差波动性,进而有减小电力系统故障^[75]的可能性。本文的研究技术路线如图1.3所示。




图 1.3 研究技术路线图

第二章 数据的采集及处理

数据来源的可靠性对于数据分析和决策制定至关重要。可靠的数据来源应当满足以下几个决定因素：首先，数据来源应该具有高精度；其次，数据来源应该具有高完整性，不遗漏或出错，以确保数据分析和决策制定是基于全面且完整的信息；第三，数据来源应该具有高一致性，没有不一致或冲突的数据，以确保数据分析和决策制定的准确性和可信度；第四，数据来源应该具有高可追溯性，提供数据的来源和处理方法的详细信息，帮助分析人员更好地理解数据，并确定数据是否可以用于特定的目的；最后，数据来源应该具有高可验证性，即可以验证其数据的来源和准确性，帮助分析人员确认数据是否真实可信，并根据需要进行更多的验证和调整。因此，使用可靠的数据来源可以提高数据分析和决策制定的质量和可靠性，减少错误和误解，促进更好的决策制定。

2.1 气象数据来源

获取天气信息数据有多种途径，可以从气象部门或机构，各国气象部门或机构会定期发布气象数据，包括温度、风速、风向、湿度等信息。例如，中国气象局、美国国家气象局（NOAA）等。还有一些机构或组织提供免费的开放数据平台，可以获取一些公开的气象数据。例如，美国国家航空航天局(NASA)提供的气象数据集(NASA Earthdata)、欧洲中期天气预报中心（ECMWF）提供的气象数据集等。除了从气象部门或机构、气象数据服务提供商和开放数据平台获取气象信息数据之外，还有其他一些途径可以获取气象信息。例如，一些气象应用程序和网站，如 Weather Channel、AccuWeather、Weather Underground 等，提供实时和预测天气信息。这些数据可以帮助个人用户更好地了解当地的气象状况，并在日常生活中做出更好的决策。

本文使用的气象信息包括风速、风向、湿度、温度、气压和光照强度，均是来源于欧洲中期天气预报中心（ECMWF）的历史数据。部分数据集概览如表 2-1 所示。

表 2-1 部分数据集

序号	风速（ $\text{m}\cdot\text{s}^{-1}$ ）	风向（ $^{\circ}$ ）	温度（ $^{\circ}\text{C}$ ）
1	13.70137939	347.336700	17.2566
2	13.61696777	344.939636	17.2489
3	13.49883423	345.159301	18.1218
序号	气压（MPa）	光强（lx）	湿度（RH）
1	0.10126	28739.142	35%
2	0.10152	31243.632	42%
3	0.10131	29113.59	51%

可以获取风电功率数据的途径有几种,例如:能源部门或机构,各国能源部门或机构通常会发布有关风力发电的数据和报告,包括风电场的装机容量、发电量、风电机组的运行状况等信息。国家能源局和国家统计局是中国风电数据的主要提供者,可以通过其官方网站获取风电数据。电力公司也是风电数据的重要来源,可以通过各大电力公司的官方网站或数据平台获取风电数据。其他能源相关的组织或协会,如美国风能协会(AWEA)、欧洲风能协会(EWEA)等,也会发布有关风能的数据和报告。这些组织通常具有更多的行业内部信息和趋势分析,对于分析市场和商业机会非常有帮助。一些大型互联网公司也提供有关可再生能源和环境的数据和报告。

本文的研究对象为中国黑龙江省大庆市某风电场,数据采集区间为2021年6月1日00:00至2022年5月31日23:59期间的风电功率数据。历史风电功率数据记录间隔为60分钟,一天共有24个采样点数据。基于数据全面准确性的重要性,本文选择使用的风力发电功率数据来源于羲和能源数据平台提供的黑龙江省大庆地区风电场一个风力发电机每间隔一小时测量记录而得。

为更明显的观察风电功率走势,将风电功率数据进行可视化,部分风电功率原始数据可视化如图2.1所示:




图 2.1 部分原始风电数据

2.2 数据处理

2.2.1 数据清洗

1. Savitzky-Golay 滤波

数据清洗是数据分析中不可或缺的步骤之一,其目的是消除数据中的异常值,噪声,缺失值和错误值等问题,以确保数据品质和准确性。常用的数据清洗方法包括将填充过

后的完整数据输入 Savitzky-Golay 滤波器中进行去噪处理，这可以显著地减少数据的异常值。Savitzky-Golay 滤波器是一种低通滤波器，它通过对数据局部区间进行 k 次多项式拟合的最小二乘卷积来实现，这种技术可以提高信噪比。在数据预测中，采用平滑和去噪技术可以有效地改善高频噪声。这种方法需要调整两个关键参数：多项式拟合阶数 k 和滤波器窗口长度 w 。如果 w 过长，则会导致信号丢失；如果 w 过短，则会影响滤波器的降噪能力。另一方面，如果选择过高的 k 值，则可能产生新噪声；如果选择过低的 k 值，则可能导致信号失真。因此，应该适当地选择 k 和 w 的值，以实现随机去噪的同时保持有效信号的平衡。Savitzky-Golay 滤波器实现数据去噪的基本原理如式 2.1 所示：

$$P_t = \sum_{i=\frac{1-w}{2}}^{\frac{w-1}{2}} C_i \times P_{t+i} \quad (2.1)$$

式中 P_t 表示第 t 次的平滑值； w 是窗口大小； C_i 是加权函数的系数； P_{t+i} 是时间的未过值； $t+i$ 在 $t=1, \dots, n$ 目标时间间隔内。经过数据清洗后和数据纠正后风电数据可可视化如图 2.2。




图 2.2 处理后风电数据

2. 填充缺失值

为了辅助预测，我们会采用均值填充法来处理实测数据中的缺失和噪声问题。在填补所有缺失点后，我们会对数据集进行重新采样，使其变为每小时的数据。其中，缺失数据可以通过插值法进行填充，在填充完缺失数据后，可以将异常数据清洗掉，以建立

完整的预测数据集。线性插值法假设在两个已知数据点之间的数据变化是线性的，因此可以通过这两个点的值来计算中间点的值。公式如下：

$$x_t = \frac{x_{t-1} + x_{t+1}}{2} \quad (2.2)$$

式中， x_{t-1} 与 x_{t+1} 为缺失或异常数据前后时刻得风电功率数据。

2.2.2 数据集质量分析

在数据清洗之后，需要进行数据质量分析，以筛选出与风电功率相关性最强的气象因素，为了分析数据的相关性，本研究选择使用皮尔逊（Pearson）相关分析法。皮尔逊分析法是通过计算两个变量之间的距离来衡量它们之间的相关性，使用 Pearson 相关分析时，需要考虑满足 5 个假设：

1. 两个变量都是连续变量。
2. 两个连续变量应当是配对的，即来源于同一个个体。
3. 两个连续变量之间存在线性关系，通常做散点图检验该假设。
4. 两个变量均没有明显的异常值，否则 Pearson 相关系数易受异常值影响。
5. 两个变量符合双变量正态分布。

具体的函数表达式如公式 2.3 所示。

$$\rho_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (2.3)$$

Pearson 相关系数取值范围在 $[-1, +1]$ ，负数代表负相关，正数代表正相关，0 则代表不存在相关关系。相关系数越接近 0，相关关系越弱；越接近-1 或+1，相关关系越强。表 2-2 为皮尔逊相关系数取值范围与相关程度对照表：

表 2-2 相关系数取值范围与相关程度对照表

相关系数取值范围	实体建模
0.8-1.0	极强相关
0.6-0.8	强相关
0.4-0.6	中等程度相关
0.2-0.4	弱相关
0.0-0.2	极弱相关或无相关

对黑龙江省大庆市风电场的风电数据进行质量分析，本文选取同时刻的风速、气压、光强、风向、温度和空气湿度与风电功率分别进行皮尔逊相关系数计算，结果如表 2-3 所示。

表 2-3 大庆风电场风电功率与各因素的相关性

数据规模	2000	4000	8000
温度	0.0887	0.0955	0.1709
风速	0.7626	0.7865	0.8018
风向	0.1839	0.2165	0.2577
湿度	-0.1055	-0.1458	-0.1806
气压	-0.0551	-0.0160	-0.0584
光强	0.0031	0.0052	0.0074

从上表中可以看出，温度、风向和风速与风电功率成正相关，其中，风速与风电功率为强相关关系。所以，本文将选取温度、风向和风速作为数据集进行下一步模型的输入。

2.2.3 数据分割

本文为对后续提出的风电功率预测模型的验证探究其可行性，将使用大庆市风电场的风电数据进行算例分析，数据包括 NWP 数据和风电功率数据，时间跨度为 2021 年 6 月 1 日 0:00 到 2022 年 5 月 31 日 23:59，采样间隔为 60 分钟。将选取春季典型日和夏季典型日进行预测，2022 年 3 月 1 日 0:00 到 2022 年 3 月 29 日 23:59 的 696 个采样点的数据作为春季典型日的训练集，2022 年 1 月 30 日 0:00 到 2022 年 1 月 31 日 23:59 的 48 个采样点作为春季典型日的验证集。同理，夏季典型日的数据集为 7 月数据，结构与春季典型日相同。研究目标为短期预测风电功率点，预测未来两天内 48 个风电功率点的值，函数对应关系如公式 2.4 所示：

$$f(x_1, x_2, \dots, x_{n-1}, x_n) = (y_1, y_2, \dots, y_{n-1}, y_n) \quad (2.4)$$

式中 $x_1, x_2, \dots, x_{n-1}, x_n$ 训练集中的输入数据， $y_1, y_2, \dots, y_{n-1}, y_n$ 为两天预测目标的风电功率预测数据，长度为 48。

2.2.4 数据归一化

数据归一化是将不同规模的数据转化为同一规模的过程。在机器学习中，对数据进行归一化可以提高模型的训练速度和准确性，同时避免数据规模差异对模型的影响。常见的数据归一化方法包括：线性归一化（Min-Max Scaling）：将数据按照最小值和最大值进行线性变换，将数据缩放到[0,1]的区间内；零均值归一化（Z-score Normalization）：将数据按照均值和标准差进行线性变换，将数据缩放到均值为 0，标准差为 1 的分布上；小数定标归一化（Decimal Scaling）：将数据除以一个基数的幂次方，将数据缩放到[-1,1]或[0,1]的区间内。在选择数据归一化方法时，需要考虑数据的特点和业务需求，选择合适的方法对于提高模型的准确性和稳定性非常重要。本文选择使用的是线性归一化，其

公式 2.5 如下：

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)} \quad (2.5)$$

式中， x' 为归一化后的数据； $\max(x)$ 为同一因素下最大数据； $\min(x)$ 为同一因素下最小数据； x 为归一化前的数据。

2.3 本章小结

本章旨在选取相关因素数据和对数据进行清洗，以便为后续的风电功率预测模型提供可靠的数据集。为此，对数据集进行了异常值清洗，除了异常值清洗外，还使用插值法对缺失数据进行了填充。通过这种方法，不仅能够填充原始数据集中的缺失值，还能填充在异常值清洗过程中被删除的数据，这一步骤在保证数据集完整性的同时，还提高了数据集的可用性，从而提高数据集的可靠性和为做相关分析做好铺垫。接下来，我们首先采用 Pearson 相关分析法来确定与风电功率相关程度最强的气象因素，结果显示风速是最相强关的因素，温度和风向也与风电功率呈正相关。总的来说，本章通过数据清洗和填充方法，对原始数据集进行了有效的处理，从而为后续的风电功率预测模型提供了一个高质量的数据集。数据清洗则是为了使数据集更可靠，只选用相关性较强的因素数据则是为了降低后续模型训练的时间。

第三章 BP 神经网络模型及海鸥算法模型

3.1 BP 功率预测模型

3.1.1 BP 神经网络的网络结构

神经网络是一种由许多相互连接的神经元（或称为节点或单元）组成的模型。这些神经元通常被组织成层次结构，每一层都与前一层和后一层相连。BP 神经网络是一种广泛应用于模式分类、函数逼近、模式识别等领域的神经网络模型。其基本结构由输入层、隐藏层、输出层三层神经元构成。图 3.1 是 BP 神经网络的网络结构拓扑图。




图 3.1 神经网络拓扑图

其中，输入层用于接收外部输入信号，例如图像的像素值、音频的频谱，输入层的神经元个数等于输入的信号维度；隐藏层由一定数量的神经元组成，是 BP 神经网络中的核心层，隐藏层的神经元数量通常比输入层和输出层多，可以有效提取输入信号的特征，并将其转化为更高层次的抽象表示；输出层由一定数量的神经元组成，用于输出网络的结果，输出层的神经元个数根据具体的任务而定，例如分类任务需要与分类类别数量相同的输出神经元。BP 神经网络的训练过程通过反向传播算法实现，在每次迭代中，通过将输入信号前向传播至输出层，计算网络的输出结果，并将其与实际输出结果进行比较，然后根据误差反向传播至网络的每一层，并根据误差对每个神经元的权值和偏置进行更新，从而实现网络的优化。

3.1.2 BP 神经网络的优缺点

BP 神经网络的优点:

BP 神经网络是一种强大的机器学习算法,与传统的线性模型不同,BP 神经网络可以通过多层神经元之间的非线性转换,学习和适应数据的变化,这种能力使得 BP 神经网络在处理非线性数据时十分奏效。

BP 神经网络的网络结构比较灵活,可以通过增加或减少隐层的节点数量,或者改变网络的拓扑结构来适应不同的数据集。例如,增加隐藏层的节点数量可以提高网络的拟合能力,而减少隐层的节点数量则可以减少网络的计算复杂度。此外,BP 神经网络的参数也可以通过不断的训练和调整来优化网络的性能。

BP 神经网络在理论上具有普适逼近能力,即可以逼近任何连续函数。这是由于 BP 神经网络可以通过多层的非线性变换,将任何复杂的输入数据映射到输出空间中。这种能力使得 BP 神经网络在处理各种类型的数据时非常有用,如分类、回归、聚类等问题。

BP 神经网络的计算过程可以进行并行化处理,这意味着可以使用并行计算的硬件(如 GPU)来加速网络的训练过程。这种并行化处理方式可以大大缩短网络的训练时间,提高网络的效率和性能。因此,BP 神经网络在处理大规模数据集时非常有优势。

BP 神经网络的缺点:

BP 神经网络的训练过程通常使用梯度下降算法,这种算法只能保证在当前的权重和偏置下沿着梯度的反方向更新网络的参数,无法保证找到全局最小值,而只能保证找到局部最小值。如果网络的初始参数设置不佳,梯度下降算法容易被卡在局部最小值,从而导致网络无法达到最佳状态,性能不佳。

对初始权重和偏置敏感,BP 神经网络的初始权重和偏置设置可能对网络的训练结果产生重要影响。这是因为神经网络的性能很大程度上取决于它的初始权重和偏置,如果初始参数设置不合适,网络的性能就会受到限制。因此,为了获得更好的训练结果,需要通过试验和调整找到最佳的初始参数设置,这增加了网络的训练复杂度。

BP 神经网络需要大量的数据进行训练。这是因为神经网络的训练需要大量的数据样本,以便网络可以从中学习到有效的特征表示。如果训练数据不足,则网络容易出现过拟合现象,即在训练数据上表现良好但在测试数据上表现差。因此,为了避免过拟合,需要准备足够的数据进行训练,这增加了训练的难度和成本。

BP 神经网络需要通过反向传播算法来优化参数,这是一种迭代算法,需要反复调整网络的参数直到误差达到最小。这个过程可能需要多次迭代,并且每次迭代需要对所有样本进行计算和反向传播,因此训练时间较长。

3.1.3 BP 神经网络的基本原理

BP 神经网络是一种常用的人工神经网络模型,它的训练过程通过不断地调整网络连接权值,减小输出误差,使得网络输出值更接近期望输出值。误差逆向传播算法是一

种基于梯度下降的优化算法，通过链式法则将输出误差沿着网络层次进行反向传播，并动态调整各层节点之间的连接权值，从而逐渐减小误差。BP 神经网络在学习过程中不需要建立准确的数学关系，而是通过逐步调整连接权值来学习输入输出之间的非线性映射关系。这个过程会持续多次迭代，直到网络输出误差达到预设的精度或训练次数达到设定值为止。在对 BP 神经网络标准算法各步骤说明前，首先叙述各变量代表含义，其详细内容见表（3-1）。

表 3.1 BP 神经网络标准算法变量定义表

变量	含义
x_n	输入层输入向量
h_i	隐含层输入向量
h_o	隐含层输出向量
y_i	输出层输入向量
y_o	输出层输出向量
d_o	期望输出向量
w_{ih}	输入层至隐含层连接权值
w_{ho}	隐含层至输出层连接权值
b_h	隐含层节点阈值
b_o	输出层节点阈值
m	训练样本数目

此外激活函数设置为：

$$f(x) = \frac{1}{1 + e^{-x}} \quad (3.1)$$

误差函数设为：

$$e = \frac{1}{2} \sum_{o=1}^q (d_o(k) - y_{o_o}(k))^2 \quad (3.2)$$

BP 神经网络标准算法的计算过程可表述如下：

第一步：网络初始化。

在对 BP 神经网络进行训练前，需赋予各层节点初始连接权值，通常在[-1,1]之间随机选择，根据实际需求设置全局最大误差和最大学习次数，主要用于判断在符合条件下结束训练网络。

第二步：BP 神经网络学习时需确定输入样本数据 $x(k)$ 和期望输出数据 $d_o(k)$ 。

$$x(k) = (x_1(k), x_2(k), \dots, x_n(k)) \quad (3.3)$$

$$d_0(k) = (d_1(k), d_2(k), \dots, d_q(k)) \quad (3.4)$$

第三步：对输入层数据进行权值加成和计算，确定隐含层各节点的输入 $hi_h(k)$ 和输出 $ho_h(k)$ 。

$$hi_h(k) = \sum_{i=1}^n w_{ih} x_i(k) \quad (3.5)$$

$$ho_h(k) = f(hi_h(k)) \quad (3.6)$$

第四步：经隐含层计算后，数据将会传至输出层，因此需要确定输出层的输入 $yi_o(k)$ 和输出 $yo_o(k)$ 。

$$(yi_o(k)) = \sum_{h=1}^p w_{ho} ho_h(k) \quad (3.7)$$

$$yo_o(k) = f(yi_o(k)) \quad (3.8)$$

第五步：在前四步中已经完成了 BP 神经网络标准算法的正向传输阶段，接下来将进入逆向反馈阶段。此算法实质为梯度下降法，通过每次调整权值使输出误差符合要求，而调整权值便是利用误差函数分别对隐含层至输出层、输入层至隐含层求偏导的方式进行修正，因此在逆向反馈阶段便是首先调整隐含层至输出层的权值，即求误差函数对权值 w_{ho} 的偏导。根据复合函数求导法则推导如下：

$$\frac{\partial e}{\partial w_{ho}} = \frac{\partial e}{\partial yi_o} \frac{\partial yi_o(k)}{\partial w_{ho}} \quad (3.9)$$

首先对 $\frac{\partial yi_o(k)}{\partial w_{ho}}$ 进行求偏导：

$$\frac{\partial yi_o(k)}{\partial w_{ho}} = \frac{\partial \left(\sum_h^p w_{ho} ho_h(k) \right)}{\partial w_{ho}} = ho_h(k) \quad (3.10)$$

其次对 $\frac{\partial e}{\partial yi_o}$ 进行求偏导：

$$\begin{aligned}\frac{\partial e}{\partial y_{i_o}} &= \frac{\partial \left(\frac{1}{2} \sum_{o=1}^q (d_o(k) - y_{o_o}(k))^2 \right)}{\partial y_{i_o}} = - (d_o(k) - y_{o_o}(k)) y_{o_o}'(k) \\ &= - (d_o(k) - y_{o_o}(k)) f'(y_{i_o}(k)) \triangleq - \delta_o(k)\end{aligned}\quad (3.11)$$

因此隐含层至输出层间误差函数对权值的偏导结果为：

$$\frac{\partial e}{\partial w_{ho}} = -h_{o_h}(k) \delta_o(k) \quad (3.12)$$

第六步：在此步骤中，计算误差函数 e 对输入层至隐含层各神经元权值 w_{ih} 的偏导。推导公式如下：

$$\frac{\partial e}{\partial w_{ih}} = \frac{\partial e}{\partial h_{i_h}(k)} \frac{\partial h_{i_h}(k)}{\partial w_{ih}} \quad (3.13)$$

首先对 $\frac{\partial h_{i_h}(k)}{\partial w_{ih}}$ 进行求偏导：

$$\frac{\partial h_{i_h}(k)}{\partial w_{ih}} = \frac{\partial \left(\sum_{i=1}^n w_{ih} x_i(k) - b_n \right)}{\partial w_{ih}} = x_i(k) \quad (3.14)$$

对 $\frac{\partial e}{\partial h_{i_h}(k)}$ 进行求偏导：

$$\frac{\partial e}{\partial h_{i_h}(k)} = \frac{\partial \left(\frac{1}{2} \sum_{o=1}^q (d_o(k) - y_{o_o}(k))^2 \right)}{\partial h_{o_h}(k)} \frac{\partial h_{o_h}(k)}{\partial h_{i_h}(k)} \quad (3.15)$$

因此输入层至隐含层间误差函数对权值的求导结果为：

$$\frac{\partial e}{\partial w_{ih}} = -x_i(k) \delta_h(k) \quad (3.16)$$

第七步：在对输入层至隐含层，隐含层至输出层分别对应的权值求偏导后，接下来便利用偏导结果对各层连接权值进行修正，首先对输出层各节点和隐含层各节点的连接权值进行修正。

首先求得权值修改量 $\Delta w_{ho}(k)$ ：

$$\Delta w_{ho}(k) = -\eta \frac{\partial e}{\partial w_{ho}} = \eta \delta_o(k) h o_h(k) \quad (3.17)$$

因此更新后的权值 w_{ho}^{N+1} 为更新前权值和权值修改量之和。

$$w_{ho}^{N+1} = w_{ho}^N + \eta \delta_o(k) h o_h(k) \quad (3.18)$$

第八步：此步骤与上步同理，对隐含层各节点和输入层各节点的连接权值进行修正。
首先求得权值修改量 $\Delta w_{ih}(k)$ ：

$$\Delta w_{ih}(k) = -\eta \frac{\partial e}{\partial w_{ih}} = -\eta \frac{\partial e}{\partial h_i(k)} \frac{\partial h_i(k)}{\partial w_{ih}} = \eta \delta_h(k) x_i(k) \quad (3.19)$$

因此更新后的权值 w_{ih}^{N+1} 为更新前权值和权值修改量之和。

$$w_{ih}^{N+1} = w_{ih}^N + \eta \delta_h(k) x_i(k) \quad (3.20)$$

第九步：在对 BP 神经网络内部各权值进行修正后，再次对全局误差 E 进行计算，如下式所示：

$$E = \frac{1}{2m} \sum_{k=1}^m \sum_{o=1}^q (d_o(k) - y_o(k))^2 \quad (3.21)$$

第十步：BP 神经网络结束训练的判定方法包括两种，分别是输出误差符合要求或学习次数已达到设定数值，若未达到此两种情况，则将继续进行下一轮训练学习。

3.1.4 BP 风电功率预测模型预测步骤及流程图

BP 神经网络预测模型的步骤如下：

步骤 1：输入风电原始数据集，包括历史风电功率数据及气象数据，将数据集分为训练集和测试集。

步骤 2：按照上文进行数据预处理。

步骤 3：构建 BP 神经网络模型。

步骤 4：进行 BP 神经网络训练。

步骤 5：模型训练，将数据集中的训练集输入模型中进行训练，当低于预设误差时停止训练，否则继续训练。

步骤 6：预测结果输出，输出的预测数据与数据集中的测试集进行误差分析，计算是否达到精度。

BP 神经网络预测模型的流程如图 3.2：




图 3.2 BP 神经网络预测模型流程图

3.1.5 BP 风电功率预测模型效果

大庆地区春季和夏季功率曲线有明显不同, 本文研究将选取春季典型日和夏季典型日进行预测对比, 误差分析。为更清楚得出模型预测拟合情况, 将数据真实值、预测值及误差值呈现在同一图内。图 3.3 和图 3.4 为 BP 神经网络预测模型对训练集进行训练, 再将得出的预测值与测试集的真实值做误差分析, 得出误差、预测值与真实值对比如图。图中 BP 预测值用虚线表示, 真实值 T-test 用实线表示, 真实值与预测值的差值的绝对值即误差 error 用暗红色重实线表示, 细红线实线表示的是预测误差变化情况。




图 3.3 春季典型日 BP 预测模型真实值与预测值曲线




图 3.4 夏季典型日 BP 预测模型真实值与预测值曲线

从图 3.3 和图 3.4 可以看出, 在春季典型日风电功率的变化明显高于夏季典型日, 这与大庆地区风速的季节性有关, 在春日, 大庆地区风速大, 变化快, 所以在风功率曲线上表现出骤升和骤降趋势更明显, 相对来说, 夏季典型日的风功率平缓很多。从上面两个图可以看出, BP 预测模型的整体性能不佳, 偏离真实值的预测值为大多数, 且均偏离较远。

为更好的看出误差的大小, 将误差表示图 3.5 和图 3.6。




图 3.5 春季典型日 BP 预测误差曲线




图 3.6 夏季典型日 BP 预测误差曲线

从图 3.5 和图 3.6 中可以看出, BP 风电预测模型的误差无论在春季典型日还是在夏季典型日都表现的不佳, 只有在偶尔几个值附近的预测值略有接近真实值, 这代表少部分数据误差值小, 大部分数据预测曲线与真实值曲线差距远, 误差值大。图 3.5 可以看出在春季典型日误差最大可达到 0.25MW 左右, 图 3.6 可以看出在春季典型日误差最大可达到 0.16MW 左右, 且远离真实值即远离横坐标“0”值的数据居多。说明 BP 神经网络预测模型准确性差, 稳定性差, 波动性较大, 有很大的改进空间。

3.2 SOA-BP 功率预测模型

3.2.1 海鸥算法基本原理

海鸥是一种生活在沿海的鸟类, 其生存策略主要是以鱼类为食, 喜欢群体生活, 并能够通过声音进行信息交流。海鸥的迁徙行为是为了寻找食物资源, 根据其适应度值最低的最优海鸥方向进行移动, 攻击行为则是为了捕猎海面上的鱼类和虾类。在迁徙过程中, 海鸥会成群结队一起旅行, 但是它们在海洋上的初始位置差异很大, 相互之间不会挨得很近, 可以避免碰撞。每只海鸥都会向种群当中最适宜生存的个体靠拢, 即向“最优海鸥”靠拢, 以快速获得食物。海鸥群会朝着最优海鸥所在方向移动, 不断更新它们的位置。图 3.7 是海鸥全局搜索步骤。




图 3.7 海鸥算法全局搜索步骤

海鸥的攻击行为是通过螺旋形状的运动方式向目标移动，发起攻击。这种攻击行为可以帮助海鸥捕猎到更多的鱼类和虾类，从而增加它们的食物来源。基本海鸥优化算法包括种群随机初始化、适应度值评估和排序、迁徙阶段和攻击阶段的位置更新操作等过程，以下是海鸥算法基本原理：

1. 种群初始化

设定 N 为海鸥种群数量， dim 为搜索空间维度，则海鸥群的位置可以通过向量组的方式表示：

$$HS = \begin{bmatrix} HS_{1,1} & HS_{1,2} & \dots & HS_{1,dim} \\ HS_{2,1} & HS_{2,2} & \dots & HS_{2,dim} \\ \vdots & \vdots & \vdots & \vdots \\ HS_{N,1} & HS_{N,2} & \dots & HS_{N,dim} \end{bmatrix} \quad (3.22)$$

其中 $HS_i = [HS_{i,1}, HS_{i,2}, \dots, HS_{i,dim}]$ 表示第 i ($1 \leq i \leq N$) 只海鸥的位置矢量， $HS_{i,j}$ 表示第 i 只海鸥在第 j ($1 \leq j \leq dim$) 维度的位置分量。每只海鸥可以在任意维度上进行位置的变化从而实现空间中的移动。

海鸥种群通过均匀分布来随机初始化每只海鸥的位置：

$$HS_{i,j} = Lb_j + rand \times (Ub_j - Lb_j) \quad (3.23)$$

其中 Ub_j 和 Lb_j 分别为第 j 维定义域的上界和下界， $rand$ 为 $[0,1]$ 范围内服从均匀分布的一个随机数。

2. 适应度值评估和排序

每一只海鸥都是潜在的可能解，把海鸥的位置矢量作为目标函数的解向量带入实际优化问题所确定的适应度函数中计算函数值。

适应度函数用 f 表示，海鸥群的适应度值 $fitness$ 计算公式如下：

$$fitness = \begin{bmatrix} f([HS_{1,1}, HS_{1,2}, \dots, HS_{1,dim}]) \\ f([HS_{2,1}, HS_{2,2}, \dots, HS_{2,dim}]) \\ \vdots \\ f([HS_{N,1}, HS_{N,2}, \dots, HS_{N,dim}]) \end{bmatrix} \quad (3.24)$$

海鸥的适应度值大小反映了它们各自所处位置的食物资源的情况，适应度值越好的海鸥，其位置的食物资源越丰富。海鸥群共享着最优海鸥的位置信息，它们会向最优海鸥靠拢以寻求更好的食物源。因此，在每次完成海鸥群的适应度值计算之后，要把所有海鸥按照适应度值进行排序，适应度值最好的海鸥排在最前面，方便海鸥群获取最优海鸥的位置信息。

3. 海鸥迁徙阶段

海鸥算法模拟了海鸥群在迁徙阶段的行为特征，这一阶段对应着算法的全局搜索。海鸥群在迁徙过程中，每只海鸥为了避免和相邻海鸥的碰撞，会先找到一个与其他海鸥不冲突的新位置，为了实现这一点，算法通过控制因子 f_c 来计算每只海鸥的新位置：

$$C_s(t) = f_c \times HS(t) \quad (3.25)$$

式中， $C_s(t)$ 代表该海鸥与其他海鸥无位置冲突的新位置， $HS(t)$ 表示海鸥迁徙之前的位置， t 为当前迭代次数。

控制因子 f_c 的作用是调整海鸥的位置从而避免相邻海鸥发生碰撞，在一定程度上也能起到平衡全局搜索和局部搜索的作用，其计算公式如下：

$$f_c = 2 - \left[t \times \left(\frac{2}{MaxT} \right) \right] \quad (3.26)$$

式中， $MaxT$ 为算法的最大迭代次数。当前迭代次数 t 等于 $MaxT$ 时，算法寻优结束，输出最优解。可见， f_c 在算法迭代中呈现一个线性递减的变化过程： f_c 在前期的值为 2，这表示海鸥在位置由原始位置扩大到更远更大的空间，然后再进行迁徙操作；随着迭代的进行， f_c 的值不断减小，最后在末期接近 0，这表示海鸥在不断收缩它们的搜索范围。在避免了与其他海鸥的碰撞后，每只海鸥会判断最优海鸥所在的方向，然后向最优海鸥靠拢。图 3.8 和图 3.9 是海鸥群在三维空间的运动模拟图。





图 3.8 初始海鸥种群模拟图



3.9 海鸥群向最优位置移动模拟图

最优海鸥的方向通过式(3.27)来计算。

$$M_s(t) = f_b \times [HS_{best}(t) - HS(t)] \quad (3.27)$$

式中, $M_s(t)$ 表示最优海鸥的方向; $HS_{best}(t)$ 表示最优海鸥的位置。

f_b 是搜索平衡因子, 其表达式如下:

$$f_b = 2 \times f_c^2 \times r_d \quad (3.28)$$

式中, r_d 是[0,1]范围内服从均匀分布的随机数, 用来赋予 f_b 随机的属性; f_b 受随机数 r_d 和控制因子 f_c 影响, 用来调整每只海鸥的飞行距离。

海鸥个体在获取最优海鸥的方向之后, 可由式(3.29)来确定它们的距离:

$$D_s(t) = |C_s(t) + M_s(t)| \quad (3.29)$$

式中, $D_s(t)$ 表示海鸥个体与最优海鸥的距离。

4. 海鸥攻击阶段

海鸥攻击行为的描述对应着算法的局部开发。局部开发通常发生在算法搜索过程的后半段, 目的是利用算法搜索过程的历史和经验, 调整搜索范围, 从而提高算法的搜索精度。对于海鸥群来说, 每次迭代都是先通过迁徙行为来寻找更好的食物源, 然后对猎物发起攻击。为防止猎物逃脱, 海鸥以螺旋运动的方式靠近猎物, 如图 3.10 所示:




图 3.10 海鸥攻击时螺旋运动模拟图

海鸥的攻击行为贯穿每一次的迭代过程，决定了其在每次迭代后的新位置。当海鸥进行捕食的时候，它们会对猎物发起进攻，朝猎物的方向呈螺旋式运动。

在三维空间中，攻击区域的移动表现如上图所示，海鸥的螺旋运动方式在 xyz 平面中的数学描述如下：

$$x = r \times \cos \theta \quad (3.30)$$

$$y = r \times \sin \theta \quad (3.31)$$

$$z = r \times \theta \quad (3.32)$$

$$r = u \times e^{\theta v} \quad (3.33)$$

式中， r 是海鸥在空中螺旋飞行的半径； θ 是 $[0, 2\pi]$ 范围内服从均匀分布的随机数，表示海鸥的攻击角度； u 和 v 为螺旋系数，均取值常数 1。

海鸥的攻击位置如下：

$$HS(t+1) = D_s(t) \times x \times y \times z + HS_{\text{best}}(t) \quad (3.34)$$

式中 $HS(t+1)$ 是海鸥进攻的地点，保存了最优解并更新其他搜索代理的位置。第一代初始海鸥群的位置是随机的，每次迭代后的新位置都是通过式(3.34)来产生。

5. 算法结束判断

判断是否到达最大迭代次数，是则停止迭代，输出最优值。通过设置最大迭代次数的方式可以获取算法寻优过程的迭代收敛曲线，方便与其他算法进行收敛速度的对比。

6. 海鸥算法的实现步骤和算法流程图

步骤 1：参数设置，种群初始化；

步骤 2: 计算初始种群的适应度值, 标记最优个体;
步骤 3: 根据迁徙和攻击操作更新海鸥位置;
步骤 4: 计算新种群适应度值, 更新最优个体;
步骤 5: 判断是否达到最大迭代次数, 是则停止迭代并输出最优值, 否则跳转至步骤 3 继续迭代。

算法操作流程如图 3.11 所示:




图 3.11 海鸥算法流程图

3.2.2 海鸥算法的优缺点分析

海鸥算法是一种新兴的群智能优化算法, 它拥有简单的算法结构和广泛的适用性。由于其简单的算法结构, 该算法具有较低的复杂度, 计算效率高, 易于改进和融合。然而, 类似于其他群智能算法, 尤其是在解决复杂优化问题时, 海鸥算法也存在一些缺陷, 例如易陷入局部最优、收敛精度低以及鲁棒性差等问题。综合国内外相关文献以及个人的研究, 可以发现海鸥算法在实际应用中存在着一些挑战和限制。例如, 海鸥算法很容

易受到初始值的影响, 导致无法找到全局最优解。同时, 该算法的局部搜索能力较弱, 可能会导致陷入局部最优解, 难以跳出。此外, 海鸥算法在求解高维优化问题时也存在一定的困难, 其收敛速度和精度都有待提高。为了解决海鸥算法的局限性, 学者们提出了各种改进方法和混合算法, 如引入变异策略、增加多样性、提高局部搜索能力等, 以提高算法的鲁棒性和性能。总的来说, 虽然海鸥算法在优化问题中表现出良好的性能, 但仍需要更深入的研究和改进, 以满足不同应用场景的需求。本文将海鸥算法的主要缺陷总结如下:

1. 海鸥算法的搜索方式过于单一, 只采用以目标位置为中心的全局勘探和局部开发, 缺乏多样性, 容易陷入局部极值点, 无法全面搜索复杂的优化问题, 更新种群位置的容错率较低。

2. 海鸥算法过于依赖最优个体, 个体只能获取最优海鸥的位置信息, 并根据自身位置和最优海鸥的位置进行更新, 但最优个体往往只是局部最优解, 容易误导海鸥群偏离正确的迁徙路线, 导致算法陷入局部最优解, 特别是在多极值的优化问题中, 算法容易早熟收敛, 难以找到优质解。

3. 海鸥算法的局部搜索能力不足, 种群在每次迭代中先进行全局搜索, 再进行局部搜索, 但在进行全局搜索之后, 并未对当前位置进行评估, 直接进行局部搜索, 削弱了局部搜索的作用, 相当于算法在前中期都是在进行全局搜索, 在迭代后期控制因子较小的时候才过渡到局部搜索。此外, 海鸥算法采用的随机螺旋局部搜索方式过于依赖螺旋系数的选取, 导致局部搜索精度不足。

4. 海鸥算法的控制因子不匹配, 控制因子 f_c 以线性递减的变化方式控制整个算法的迭代过程, 在一定程度上可以平衡全局搜索和局部搜索。但是, 算法的寻优过程随机性很大, 种群的进化和收敛都不是线性变化, 因此控制因子 f_c 与算法的迭代过程可能不存在不匹配的情况。 f_c 的线性变化与种群搜索的实际情况不匹配, 会导致算法在勘探和开发之间的过渡不平稳, 从而影响寻优精度。

3.3 SOA-BP 功率预测模型

3.3.1 SOA-BP 风电功率预测模型预测步骤及流程图

SOA-BP 神经网络预测模型的步骤如下:

步骤 1: 输入风电原始数据集, 包括历史风电功率数据及气象数据, 将数据集分为训练集和测试集。

步骤 2: 按照上文进行数据预处理。

步骤 3: 构建 BP 神经网络模型。

步骤 4: 构造海鸥优化器, 将 BP 神经网络初始权重矩阵和偏置矩阵设置为海鸥位置。

步骤 5: 模型训练, 将数据集中的训练集输入模型中进行训练, 当低于预设误差时

停止训练，否则继续训练。

步骤 6：预测结果输出，输出的预测数据与数据集中的测试集进行误差分析，计算是否达到精度。

BP 神经网络预测模型的流程图如图 3.12 所示：




图 3.12 SOA-BP 神经网络预测模型流程图

3.3.2 SOA-BP 风电功率预测模型效果

本小节将继续选取春季典型日和夏季典型日进行预测对比研究，误差分析。图 3.13 和图 3.14 为 BP 神经网络预测模型对训练集进行训练，再将得出的预测值与测试集的真实值做误差分析，得出误差、预测值与真实值对比如图。图中 SOA-BP 预测值用虚线表示，真实值 T-test 用实线表示，真实值与预测值的差值的绝对值即误差 error 用暗红色重实线表示，细红线实线表示的是预测误差变化情况。




图 3.13 春季典型日 SOA-BP 预测模型真实值与预测值曲线




图 3.14 夏季典型日 SOA-BP 预测模型真实值与预测值曲线

从图 3.13 和图 3.14 可以看出，无论在春季典型日还是夏季典型日，SOA-BP 的预测模型拟合度完全好于 BP 模型，这是因为通过海鸥算法优化了 BP 神经网络的权值阈值，使得预测效果更好。在功率骤升和骤降阶段，SOA-BP 模型的预测效果也要好于 BP 模型，相对来说，SOA-BP 在整体预测性能方面优于 BP 模型，但依然没有达到想要的准确度。为更好的分析误差的大小，将误差表示图 3.15 和图 3.16。




图 3.15 春季典型日 SOA-BP 预测误差曲线




图 3.16 夏季典型日 SOA-BP 预测误差曲线

从图 3.15 和图 3.16 中可以看出，SOA-BP 风电预测模型的误差无论在春季典型日还是在夏季典型日都表现优于 BP 模型，SOA-BP 风电预测模型预测数据与真实数据差距缩小，大部分数据误差值变小，但仍没有达到预测所需的精确度。可以看出在春季典型日误差最大可达到 0.10MW 左右，图 3.16 可以看出在夏季典型日误差最大可达到 0.12MW 左右，且远离真实值即远离横坐标“0”值的数据居多。且在功率骤升和骤降阶段，预测效果差于功率平缓时期。说明用 SOA 改进过的 BP 神经网络预测模型准确性有所提升，但还是有改进的空间。

3.4 本章小结

本章分别介绍了海鸥算法和 BP 神经网络算法。首先根据大庆地区春季与夏季功率曲线的不同分别建立了春季典型日 BP 神经网络风电功率预测模型和夏季典型日 BP 神经网络风电功率预测模型，发现预测值与真实值相差很大，预测的准确度过低。然后建立了春季典型日 SOA-BP 神经网络风电功率预测模型和夏季典型日 SOA-BP 神经网络风电功率预测模型，SOA-BP 模型的预测效果均明显优于 BP 神经网络预测模型。可以说明，利用海鸥算法优化后的 BP 神经网络预测模型确实可以提高风电功率预测的精确度，但仍然没有达到预期的效果。

第四章 风电功率预测模型的建立与误差分析

本文的研究对象为中国黑龙江省大庆市某风电场在 2021 年 6 月 1 日 00:00 到 2022 年 5 月 31 日 23:59 期间的风电和天气数据，并对其进行清洗和分析。数据包括 NWP 数据和历史风电功率数据，记录间隔为 60 分钟，一天共有 24 个采样点数据。本文将选取春季典型日和夏季典型日进行预测，2022 年 3 月 1 日 0:00 到 2022 年 3 月 29 日 23:59 的 696 个采样点的数据作为春季典型日的训练集，2022 年 1 月 30 日 0:00 到 2022 年 1 月 31 日 23:59 的 48 个采样点作为春季典型日的验证集。同理，夏季典型日的数据集为 7 月数据，结构与春季典型日相同。研究目标为短期预测风电功率点，各模型预测值为未来两天 48 个测试点的数据。

4.1 改进海鸥算法

4.1.1 Logistic 混沌映射初始化海鸥种群

Logistics 混沌映射是一种经典的混沌映射方式，具有随机性、遍历性和强发散性等特点，被广泛应用于群智能算法的种群初始化。一维 Logistic 映射是一个非常简单的混沌映射，早在 20 世纪 50 年代，就有生态学家利用这个简单的差分方程来描述种群的变化。使用混沌映射进行种群初始化可以有效避免算法早熟和陷入局部最优值，从而提高算法的收敛速度和精度。混沌映射生成的初始种群具有更好的多样性，初始解更均匀地分布在搜索空间，可以有效提高算法的效率。

Logistics 混沌映射函数如公式(4.1)所示：

$$X_{n+1} = X_n \times \mu \times (1 - X_n), \mu \in [0, 4], X \in [0, 1] \quad (4.1)$$

混沌系统是描述确定的非线性系统所产生的一种复杂混沌现象，其对初值条件敏感、非周期性、内部随机性，一般分为高维混沌和低维混沌。高维混沌系统结构复杂，控制参数多，计算复杂度高。低维混沌系统结构简单，控制参数少，易实现，但存在问题，如混沌行为有限、混沌区间不连续、混沌序列非均匀分布等。为开发更好混沌性能的系统，有几位科研人员将多种低维混沌结合，形成新的复合混沌系统。该类系统可克服低维混沌不足，复杂度低，易实现。

Logistic-Sine-Cosine 混沌映射是其中之一，其数学公式如下：

$$x(i+1) = \cos\left(\pi\left(4rx(i)(1-x(i)) + (1-r)\sin(\pi x(i)) - 0.5\right)\right), r \in [0, 1] \quad (4.2)$$

图 4.1 和图 4.2 是改进混沌方式前后对比图：




图 4.1 改进前混沌方式




图 4.2 改进后混沌方式

对比图 4.1 和图 4.2，不难看出，在 $[0,1]$ 区间内原始的 Logistics 混沌映射曲线的遍历性不如高维的 Logistics 混沌映射曲线，因此在本文中将选用高维的 Logistics 混沌映射扰动初始海鸥种群，目的是使得海鸥在初始的位置上更加均匀地分布。

4.1.2 非线性惯性权重改进海鸥算法

海鸥算法在全局搜索即海鸥种群在迁徙过程中容易发生碰撞，为了避免上述情况的发生，因此采用 A 变量对其进行定位，用以反映海鸥在搜索范围内的运动状态。在原始海鸥算法中 A 是从 2 线性递减到 0 的，线性的运动方式使海鸥种群前期易早熟，后

期易陷入局部最优。

为了解决该问题，本文提出了一种非线性惯性权重的海鸥算法（ISOA）。在所述方法中，A 的可以形象化的描述为：

$$A = f_c - f_c \times (\arctan(0.25 \times \pi \times (t / T))) \quad (4.3)$$

式中， T 为迭代最大数值； t 为当前迭代次数。

本文改进的非线性方式可以使参数 A 在迭代前期以较小步长搜索，中后期用较大的步长搜索。这样做的好处是，可以使海鸥在相同的空间搜索时，用时更短速度更快，中期还可以扩大每只海鸥的搜索的范围，在后期还可以做到加强局部搜索能力的效果。改进前后的参数 A 对比如图 4.3 所示。




图 4.3 改进前后 A 参数对比图

4.1.3 优化后海鸥算法收敛情况对比

此次收敛情况对比的实验环境为：MacBook Air，芯片为 Apple M1，内存 8GB，使用 Matlab2022b 进行实验仿真，为增加实验的可靠性，在标准测试函数上独立运行每个算法 100 次。在本次实验中各参数设置为：SOA 和 ISOA 的控制因子 f_c 从 2 线性递减；SSA 的发现者比例为 0.7，感应危险的麻雀比例为 0.2，安全阈值为 0.6；施行交换算子的概率为 0.9，施行突变算子的概率为 0.01。图 4.4 列出了每个模型在训练和测试集上的实验结果：下图中横坐标表示迭代次数，纵坐标表示适应度的对数值，这种对数坐标通常用于在一个广泛的范围内显示数值，并且可以更清晰地显示数据的变化趋势。




图 4.4 收敛情况对比

图 4.4 对比了 SOA、SSA、GA 和 ISOA 算法的收敛能力。首先声明，函数下降的越快代表各算法收敛的越快，而与 x 轴的距离则代表各算法的精度。通过在标准函数上运行的对比，可以看出 ISOA 算法的收敛曲线相对于其他三种算法的收敛曲线，下降的更快，所以更早且更近的接近 x 轴，说明 ISOA 的收敛速度与精度优于其他三个算法。这是因为将改进后的 Logistics 混沌映射引入海鸥算法扰动初始海鸥种群，可以使得海鸥在初始的位置上更加均匀地分布，从而加快了算法的收敛速度。而利用参数 A 改进海鸥的运动方式则可以扩大海鸥的搜索空间，提高其算法的精度。在图中可以看出，GA 算法的停滞现象明显，且不能很快寻优。相比之下，ISOA 虽有停滞，但现象不明显，并且在有停滞现象后还能继续快速寻优，并达到高的精度，证明 ISOA 算法有着很好的跳出局部最优能力。

4.2 ISOA-BP 功率预测模型

4.2.1 ISOA-BP 风电功率预测模型预测步骤及流程图

通过海鸥算法来优化 BP 神经网络的初始权值和初始阈值，弥补基本 BP 神经网络随机赋值的缺陷，使模型参数接近最优设置，从而提高模型的泛化能力和预测精度。现将改进运动状态的海鸥算法和加入混沌初始值的海鸥算法，本文称之为 ISOA，将改进后的海鸥算法重新优化 BP 神经网络，建立风电功率预测模型，ISOA-BP 神经网络预测模型的步骤如下：

步骤 1：输入风电原始数据集，包括历史风电功率数据及气象数据，将数据集分为训练集和测试集。

步骤 2：按照上文进行数据预处理。

步骤 3: 构建 BP 神经网络模型。

步骤 4: 构造海鸥优化器, 将 BP 神经网络初始权重矩阵和偏置矩阵设置为海鸥位置。

步骤 5: 模型训练, 将数据集中的训练集输入模型中进行训练, 当低于预设误差时停止训练, 否则继续训练。

步骤 6: 预测结果输出, 输出的预测数据与数据集中的测试集进行误差分析, 计算是否达到精度。

ISOA-BP 神经网络预测模型的流程图如图 4.5 所示:




图 4.5 ISOA-BP 神经网络预测模型流程图

4.2.2 ISOA-BP 风电功率预测模型效果

将继续选取春季典型日和夏季典型日进行预测对比研究, 误差分析。图 4.6 和图 4.7 为 BP 神经网络预测模型对训练集进行训练, 再将得出的预测值与测试集的真实值做误差分析, 得出误差、预测值与真实值对比如图。图中 ISOA-BP 预测值用虚线表示, 真实值 T-test 用实线表示, 真实值与预测值的差值的绝对值即误差 error 用暗红色重实线表示, 细红线实线表示的是预测误差变化情况。




图 4.6 春季典型日 ISOA-BP 预测模型真实值与预测值曲线




图 4.7 夏季典型日 ISOA-BP 预测模型真实值与预测值曲线

从图 4.6 和图 4.7 可以看出，无论在春季典型日还是夏季典型日，ISOA-BP 的预测模型的预测值和真是值几乎重合，拟合度优于 BP 模型和 SOA-BP 模型，这是因为经过上文改进的 ISOA 算法较原始的 SOA 算法可以更优地寻找权值和阈值，使的预测效果更好。在功率骤升和骤降阶段，ISOA- BP 模型的预测效果也优于 SOA-BP 模型和 BP 模型，可以说，该模型可以达到想要的准确度。为更明显的分析误差的大小，将误差表示图 4.8 和图 4.9。




图 4.8 春季典型日 ISOA-BP 预测误差曲线




图 4.9 夏季典型日 ISOA-BP 预测误差曲线

从图 4.8 和图 4.9 中可以看出, ISOA-BP 风电预测模型的误差无论在春季典型日还是在夏季典型日都表现出优良的预测性能, 可以看出在春季典型日误差最大为 0.051MW 左右, 图 4.9 可以看出在夏季典型日误差最大在 0.045MW 左右, 且远离真实值即远离横坐标“0”值的数据少。可以看出本文提出的预测模型在这三种模型中预测值和真实值拟合最好, 说明用 ISOA 改进 BP 神经网络预测模型准确性得到进一步的提

高。

4.3 各功率预测模型拟合效果对比

本小节将原始 BP 神经网络预测模型，麻雀算法优化 BP 神经网络预测模型 (SSA-BP)，海鸥算法优化 BP 神经网络预测模型 (SOA-BP)，海鸥算法优化支持向量机预测模型 (SOA-SVM)、本文提出的改进海鸥算法优化 BP 神经网络预测模型 (ISOA-BP) 与测试集中的真实值放在同一尺度下进行对比，春季典型日各模型拟合情况如图 4.10 所示，夏季典型日各模型拟合情况如图 4.11 所示。此次收敛情况对比的实验环境为：MacBook Air，芯片为 Apple M1，内存 8GB，使用 Matlab2022b 进行实验仿真。在本次实验中各参数设置为：SOA 和 ISOA 的控制因子 f_c 从 2 线性递减；SSA 的发现者比例为 0.7，感应危险的麻雀比例为 0.2，安全阈值为 0.6；施行交换算子的概率为 0.9，施行突变算子的概率为 0.01。




图 4.10 春季典型日各模型拟合情况




图 4.11 夏季典型日各模型拟合情况

从图中可以看出 BP 神经网络预测模型的效果在其他模型的对比下劣势更加明显，在功率骤升和骤降阶段，暗红色虚线的 BP 神经网络预测模型的预测值与真实值之间有明显的差距。对于灰色虚线的 SSA-BP 预测模型和暗绿色虚线的 SOA-BP 预测模型与真实值之间的误差相似，需要更多数据的对比。暗蓝色虚线的 SOA-SVM 模型与真实值之间的误差在 SOA-BP 预测误差和 BP 神经网络预测误差之间。从图中可以明显地看出，暗棕色虚线的 ISOA-BP 预测模型几乎在真实值附近，拟合效果最好，即使在功率骤升和骤降阶段，ISOA-BP 模型的预测效果依然保持稳定。

全局图中，在预测细节方面不容易观察，图 4.12 和图 4.13 为 4.10 图 4.11 各部分细节图的放大。




图 4.12-1 春季预测对比放大图




图 4.12-2 春季预测对比放大图




图 4.12-3 春季预测对比放大图




图 4.13-1 夏季预测对比放大图




图 4.13-2 夏季预测对比放大图




图 4.13-3 夏季预测对比放大图

从放大的细节图我们可以看出除 BP 神经网络外,其他的几个模型均保持着与真实值极为相似的预测走势,在功率的骤升和骤降时刻,SSA-SVM 预测模型比其他预测模型误差更小,就表现而言,本文提出的 ISOA-BP 模型的误差很小,几乎与真实值曲线重合。从图中可以看出,BP 风电预测模型大部分预测数据与真实数据相差较远,只有在最大值附近的预测值略有接近真实值,这代表少部分数据误差值小,大部分数据预测曲线与真实值曲线差距远,误差值大。SOA-SVM, SOA-BP, SSA-BP 风电预测模型预测数据与真实数据差距缩小,大部分数据误差值变小,但仍没有达到预测所需的精确度。局部最大值附近的预测值偏离真实值较多,少部分数据误差值极小。可以看出,本文提出的预测模型在这三种模型中预测值和真实值拟合最好,说明用 ISOA 改进 BP 神经网络预测模型准确性得到进一步的提高。

4.4 各功率预测模型误差

4.4.1 各预测模型误差对比图

为更明显的观察对比几种算法的误差情况,将原始 BP 神经网络预测模型,SSA-BP 预测模型,SOA-BP 预测模型,SOA-SVM 预测模型,ISOA-BP 预测模型的预测误差放在同一尺度下进行对比,春季误差情况对比如图 4.14,夏季误差情况对比如图 4.15 所示。暗红色虚线为 BP 模型预测误差,灰色实线为 SSA-BP 模型预测误差,绿色实线为 SOA-BP 模型预测误差,蓝色虚线为 SOA-SVM 模型预测误差,暗紫色实线为 ISOA-BP 模型预测误差。




图 4.14 夏季各功率预测模型误差对比图




图 4.15 夏季各功率预测模型误差对比图

加入 SSA-BP 和 SOA-SVM 模型进行对比,有利于更全面的证明本文提出模型的优越性。从图中可以看出 BP 神经网络风电功率预测模型的误差远离真实值即远离横坐标“0”值的数据居多,且上下波动范围大,说明 BP 神经网络风电功率预测模型准确性差,稳定性差,波动性较大。SOA-BP 风电功率预测模型预测数据与真实数据差距缩小,大部分数据误差值变小,局部最大值附近的预测值偏离真实值较多,少部分数据误差值极小且远离真实值即远离横坐标数“0”值的数据居多。说明用 SOA 改进过的 BP 神经网络预测模型准确性有所提升。SSA-BP 和 SOA-SVM 风电功率预测模型预测数据与真实数据差距缩小,大部分数据误差值变小和 SOA-BP 的风电功率模型预测误差相近。局部最大值附近的预测值偏离真实值较多,少部分数据误差值变小。说明用 SSA-BP 和 SOA-SVM 风电功率预测模型预测准确性也有所提升。ISOA-BP 风电功率预测模型预测数据与真实数据几乎重合,且大部分数据在横坐标轴附近。可以得出本文提出的预测模型在这几种模型中误差最小,误差波动性也小,说明用 ISOA 改进 BP 神经网络预测模

型准确性得到进一步的提高。

4.4.2 各预测模型误差对比表

将 BP 神经网络预测模型，SOA-BP 预测模型，ISOA-BP 预测模型，SOA-SVM 预测模型和 SSA-BP 预测模型的预测误差放在同一尺度下进行对比，BP 神经网络预测模型误差数据如表 4.1 所示。

表 4.1 多次 BP 神经网络预测模型误差数据

序号	均方误差	最大误差值	最小误差值	平均误差 <i>MW</i>
1	1.18662	0.36301	0.02316	0.21379
2	1.59825	0.38890	0.03999	0.35623
3	1.75918	0.42104	0.05070	0.20125
4	1.34291	0.29836	0.02976	0.16137
5	1.40973	0.30984	0.03552	0.17907
6	1.39585	0.37112	0.02655	0.19886
7	1.44324	0.41535	0.04916	0.20537
8	1.62509	0.40987	0.04853	0.18182
9	1.46887	0.36112	0.03921	0.23355
10	1.63124	0.31781	0.041524	0.26001
平均值	1.486098	0.365642	0.0384104	0.219132

表 4.1 是 BP 风电预测模型多次训练的误差分析，均方误差在 1.34291~1.75918 之间，5 次训练均方误差的平均值为 1.459338，最大误差平均值为 0.35623MW，最小误差平均值为 0.03583MW。可以看出均方误差最大值与最小值之间差值在 0.42 左右，平均最大误差与平均最小误差之间相差 0.318MW 左右，差值较大，说明该模型在预测时不够稳定，不利于在实际风电场中预测应用。

SOA-BP 模型误差数据如表 4.2 所示。

表 4.2 多次 SOA-BP 神经网络预测模型误差数据

序号	均方误差	最大误差值	最小误差值	平均误差 <i>MW</i>
1	0.03987	0.06931	0.00532	0.03871
2	0.04521	0.06255	0.00677	0.03510
3	0.04679	0.07472	0.00879	0.04038
4	0.03218	0.05120	0.00621	0.02913
5	0.03055	0.04954	0.00609	0.02805
6	0.03819	0.06182	0.00391	0.03713

7	0.03811	0.05862	0.00399	0.04005
8	0.04128	0.05913	0.00437	0.03514
9	0.03324	0.05523	0.00528	0.03287
10	0.04572	0.05419	0.00504	0.03718
平均值	0.03987	0.06931	0.00532	0.03871

表 4.2 是 SOA-BP 风电预测模型多次训练的误差分析, 均方误差 0.03055~0.04679 之间, 5 次训练均方误差的平均值为 0.03987, 最大误差平均值为 0.06931MW, 最小误差平均值为 0.00532MW。可以看出均方误差最大值与最小值之间差值在 0.016 左右, 平均最大误差与平均最小误差之间相差 0.064MW 左右, 差距缩短, 说明该模型较 BP 风电预测模型已经有所改进。

SSA-BP 模型误差数据如表 4.3 所示。

表 4.3 多次 SSA-BP 神经网络预测模型误差数据

序号	均方误差	最大误差值	最小误差值	平均误差MW
1	0.03722	0.06712	0.00492	0.03423
2	0.04418	0.05635	0.00581	0.03612
3	0.04318	0.07092	0.00818	0.04182
4	0.03715	0.05257	0.00572	0.03021
5	0.03159	0.05013	0.00581	0.02931
6	0.03649	0.05943	0.00463	0.03452
7	0.03626	0.06102	0.00428	0.04005
8	0.03714	0.05701	0.00532	0.03592
9	0.04592	0.05928	0.00419	0.03287
10	0.04018	0.05391	0.00491	0.03518
平均值	0.03687	0.05915	0.00505	0.03615

表 4.3 是 SSA-BP 风电预测模型多次训练的误差分析, 均方误差 0.03159~0.04592 之间, 5 次训练均方误差的平均值为 0.03687, 最大误差平均值为 0.05915MW, 最小误差平均值为 0.00505MW。可以看出均方误差最大值与最小值之间差值在 0.014 左右, 平均最大误差与平均最小误差之间相差 0.054MW 左右, 差距缩短, 说明该模型较 BP 风电预测模型已经有所改进, 与 SOA-BP 预测模型的预测结果接近。

SOA-SVM 模型误差数据如表 4.4 所示。

表 4.4 多次 SOA-SVM 神经网络预测模型误差数据

序号	均方误差	最大误差值	最小误差值	平均误差MW
1	0.03015	0.06217	0.00502	0.03542

2	0.04523	0.05821	0.00471	0.03719
3	0.03921	0.06819	0.00432	0.04045
4	0.04016	0.05016	0.00524	0.03219
5	0.03159	0.05298	0.00509	0.03187
6	0.03201	0.05718	0.00498	0.03251
7	0.03124	0.06015	0.00436	0.04159
8	0.03528	0.05502	0.00436	0.03913
9	0.04432	0.05712	0.00516	0.03844
10	0.04171	0.04839	0.00414	0.03627
平均值	0.03218	0.05724	0.00513	0.03981

表 4.4 是 SSA-SVM 风电预测模型多次训练的误差分析,均方误差 0.03015~0.04523 之间,5 次训练均方误差的平均值为 0.03218,最大误差平均值为 0.05724MW,最小误差平均值为 0.00513MW。可以看出均方误差最大值与最小值之间差值在 0.015 左右,平均最大误差与平均最小误差之间相差 0.052MW 左右,差距缩短,说明该模型较 BP 风电预测模型已经有所改进,与 SOA-BP 预测模型和 SSA-BP 预测模型的预测结果接近。

ISOA-BP 模型误差数据如表 4.5 所示。

表 4.5 多次 ISOA-BP 神经网络预测模型误差数据

序号	均方误差	最大误差值	最小误差值	平均误差MW
1	0.009089	0.01722	0.00354	0.01041
2	0.007152	0.00981	0.00193	0.00756
3	0.008334	0.01491	0.00572	0.00932
4	0.007958	0.01826	0.00365	0.01005
5	0.008482	0.02776	0.00425	0.01523
6	0.007912	0.02251	0.00342	0.01742
7	0.007938	0.02615	0.00409	0.00513
8	0.007141	0.01744	0.00371	0.00941
9	0.008416	0.01603	0.00431	0.01732
10	0.008701	0.02005	0.00293	0.01543
平均值	0.008203	0.017592	0.003818	0.010514

表 4.5 是 ISOA-BP 风电预测模型多次训练的误差分析,均方误差在 0.00715~0.00909 之间,5 次训练均方误差的平均值为 0.008203,最大误差平均值为 0.017592MW,最小误差平均值为 0.003818MW。可以看出均方误差最大值与最小值之间差值在 0.002MW 左右,平均最大误差和平均最小误差之间相差 0.014MW 左右距大幅度减小,说明该模型较 BP 风电预测模型、SOA-BP 风电预测模型、SSA-BP 风电预测模型、

SOA-SVM 风电预测模型在准确性方面及稳定性方面都有明显改进。

4.4.3 模型训练效果比较与评价

本文使用三个常用的预测评价指标来对模型的回归预测性能进行综合的评估,包括了均方根误差 (Root Mean Square Error, RMSE)、平均绝对误差 (Mean Absolute Error, MAE)、平均绝对百分比误差 (Mean Absolute Percentage Error, MAPE)。RMSE、MAE 和 MAPE 较低的模型则被认为是性能最好的模型,其计算公式如下:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y}_i)^2} \quad (4.4)$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \bar{y}_i| \quad (4.5)$$

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_j - y_i}{\bar{y}_i} \right| \times 100\% \quad (4.6)$$

其中 y_j 是模型的预测值, y_i 为真实值, $\bar{y}_i$ 为 y_i 的平均值, n 为总样本数。为了进行多种模型优化方法的比较以及验证 ISOA-BP 的改进效果,使用改进海鸥算法 ISOA、海鸥算法 SOA、麻雀搜索算法 SSA 分别建立 ISOA-BP、SOA-BP、SOA-SVM 和 SSA-BP 预测模型,然后将各模型的训练和预测结果与基本的 BP 预测模型进行对比。本节使用的实验数据和上述文献使用的实验数据相同,并且训练集和测试集的划分也与该文献的方法保持一致。SOA-BP 和 SSA-BP 的模型优化步骤与 ISOA-BP 的模型优化步骤相同。各算法参数设置为: SOA 和 ISOA 的控制因子 f_c 从 2 线性递减; SSA 的发现者比例为 0.7, 感应危险的麻雀比例为 0.2, 安全阈值为 0.6。考虑到 BP 神经网络训练过程耗时较长,为提高 BP 网络优化的时效,各算法种群数量取 25, 最大迭代次数取 30。表 4.6 从平均绝对误差、均方误差、均方根误差方面分析模型的准确性,将五种模型进行多次仿真记录各误差并取平均值。每个模型在训练和测试集上的实验结果如表 4.6 所示:

表 4.6 误差比较

模型	平均绝对误差 MAE	均方误差 MSE	均方根误差 RMSE
BP	0.456	0.188	0.939
SSA-BP	0.293	0.104	0.501
SOA-BP	0.272	0.128	0.468
SSA-SVM	0.265	0.127	0.732
ISOA-BP	0.129	0.083	0.186

从表 4.6 中可以看出, 本文提出的风电功率预测模型无论从平均绝对误差、均方误差及均方根误差方面均优于其他模型的预测效果, 能满足提高风电功率预测准确率的需求。通过表的结果对各模型的性能进行分析, 模型的评价指标越小说明模型的泛化能力和预测精度越好。从表中可以看出: ISOA-BP 预测模型的 RMSE、MAE 和 MSE 指标都是最小的; 与基本 BP 预测模型相比, SOA-BP、SSA-BP、SOA-SVM 和 ISOA-BP 模型的泛化能力和预测精度都有明显提升, 说明使用智能优化算法对 BP 神经网络的初始权值和初始阈值进行优化可以提升模型的性能; 与 SOA-BP 和 SSA-BP 模型相比, ISOA-BP 模型具有更小的模型误差, 说明 ISOA 对 BP 网络的优化效果比 SOA、SSA 更好, 进一步验证了改进策略的有效性。综上所述, ISOA 在 BP 神经网络预测模型的优化问题当中具有一定优势和竞争力, 其优化的预测模型具有更好的泛化能力和预测精度, 验证了 ISOA-BP 在大庆地区的风电功率预测问题中的应用效果。

4.5 本章小结

本章通过对海鸥算法进行改进, 提出了使用 Logistics 混沌映射初始化种群和改进海鸥运动方式, 得到了一种新的优化算法 ISOA。通过在标准测试函数上的实验比较, 发现 ISOA 相对于 SOA、SSA 和 GA 等算法具有更高的寻优精度、更快的收敛速度和更强的跳出局部最优解能力, 然后利用了改进的海鸥算法寻找最优适应度个体作为 BP 神经网络初始的权值和阈值, 得到本文提出的风电功率预测模型。算例结果表明: 与其他风电功率预测模型进行比较, 本文提出的改进海鸥算法优化 BP 神经网络模型能够有效提高风电功率预测的准确度, 降低预测误差的波动性。

结 论

对于节约化石能源、减小环境污染、提高电能质量、降低发电成本和电网的稳定性，风力发电作为新能源发电的重要一环，准确的发电功率预测至关重要。本文为提高风电功率预测的准确性，提出了一种改进海鸥算法优化 BP 神经网络的预测模型并在黑龙江省大庆市进行验证应用，本文的研究内容和主要工作如下：

（1）在获取大庆地区的 NWP 信息和风电功率数据后，首先进行数据的预处理，用 Savitzky-Golay 去除异常值后，用线性插值法将数据集中的缺失数据和由于异常去除的数据补全。再计算各气象因素与风电功率的皮尔逊相关系数，利用其相关性确定数据集，最后选定风速、风向以及温度作为数据集中的输入数据。

（2）针对 SOA 搜索方式单一、依赖最优个体的问题，从优化搜索方式的角度提出了一种非线性惯性权重的海鸥优化算法 ISOA，通过最优个体的自适应变异来增强算法对局部陷阱的逃脱能力，提高搜索效率，通过引入非线性参数控制方法来平衡算法的全局勘探和局部开发。将 ISOA 和 GA、SSA、SOA 进行标准测试函数的寻优对比测试，测试结果表明 ISOA 在测试函数中相比其他算法具有更好的收敛精度和寻优稳定性，验证了改进策略的有效性。

（3）通过利用改进后的海鸥算法寻找最优适应度个体作为 BP 神经网络初始的权值和阈值建立预测模型，对比了该模型与其他风电功率预测模型的结果，结果表明，本文提出的方法能够显著地提高风电功率预测的准确度，并降低预测误差的波动性。将本文提出的模型应用于大庆地区风电功率预测中，证明了该方法能够有效地提高大庆地区风电功率预测的准确性。本文提出的改进海鸥算法优化 BP 神经网络模型是一种有效的风电功率预测方法，能够显著提高预测的准确性和稳定性，具有重要的应用价值。

展 望

未来,随着风力发电技术的不断发展和普及,风电功率预测的研究将越来越重要。因此,对风电功率预测模型的研究需要不断地完善和优化,以提高预测的准确性和稳定性。一方面,可以进一步深入探究海鸥算法和神经网络的结合,探索更加优化的算法模型,提高风电功率预测的准确性。另一方面,可以将其他优秀的算法方法引入到风电功率预测中,例如支持向量机、随机森林、回归树等,以实现更加精确和可靠的风电功率预测模型。此外,未来也需要继续完善风电功率预测的数据集,并对数据进行更加深入的分析,以找出更加有效的预测参数,提高预测模型的精确性。同时,还需要加强对风电场天气状况的监测和预测,以更好地预测风电场发电量,并为电力系统的稳定运行提供更为可靠的支持。总之,风电功率预测的研究是一个具有挑战性和重要性的课题,未来需要不断地探索和创新,以提高预测精度和稳定性,为电力系统的高效运行提供更为可靠的保障。

参考文献

- [1] 陆立明. 新能源发电技术的现状与发展趋势分析[J]. 工程建设与设计, 2020: 110-111.
- [2] Chen J, Wang J. Development Status Trends and Prospects of Offshore Wind Power in Some Foreign Countries[J]. World Sci-tech R & D, 2014.
- [3] 乐威. 新能源背景下我国风力发电现状和未来发展方向探索[J]. 绿色环保建材, 2020: 165-166.
- [4] 史伟扬. 华能新能源“风光”可期[J]. 英才, 2022(4): 28-29.
- [5] 冯泽深, 张曙光, 郭雁珩. 东北地区风电“弃风”现状及分析[J]. 电气技术, 2014: 1-3.
- [6] 范若愚. 基于风光柴储微网系统的可靠性评估[D]. 北京: 中国矿业大学, 2020.
- [7] 余平. 风电场风速及风电功率预测方法研究综述[J]. 电子技术与软件工程, 2019: 214.
- [8] Ferrero Bermejo J, Gómez Fernández J F, Olivencia Polo F. A review of the use of artificial neural network models for energy and reliability prediction. A study of the solar PV, hydraulic and wind energy sources[J]. Applied Sciences, 2019, 9(9):1844.
- [9] Wang Y, Zou R, Liu F. A review of wind speed and wind power forecasting with deep neural networks[J]. Applied Energy, 2021, 304(1):117766.
- [10] 孙李坚. 风电接入对配电网电能质量影响的仿真研究[D]. 长春: 吉林大学, 2017.
- [11] 戎骏. 大规模风电并网的谐波谐振与谐波不稳定研究[D]. 成都: 西南交通大学, 2017.
- [12] 赵泽妮, 云斯宁, 贾凌云. 基于统计模型的短期风能预测方法研究进展[J]. 太阳能学报, 2022, 43(11): 224-234.
- [13] Chang W Y. A Literature Review of Wind Forecasting Methods[J]. Journal of Power & Energy Engineering, 2014, 02(04):161-168.
- [14] 刘倩, 李时, 陈苗. 风电场短期功率预测研究[J]. 韶关学院学报, 2022, 43(3): 4.
- [15] Sungmoon J. Weighted error functions in artificial neural networks for improved wind energy potential estimation[J]. Applied Energy, 2013, 111(4):778-790.
- [16] Song, Xuri, Su. A novel bidirectional mechanism based on time series model for wind power forecasting[J]. Applied energy, 2016.
- [17] 洪翠, 林维明, 温步瀛. 风电场风速及风电功率预测方法研究综述[J]. 电网与清洁能源, 2011, 27(1): 7.
- [18] Focken U, Lange M, Waldl H P. Previento-A Wind Power Prediction System with an Innovative Upscaling Algorithm, 2001.
- [19] Felice M D, Alessandri A, Ruti P M. Electricity demand forecasting over Italy: Potential

- benefits using numerical weather prediction models[J]. *Electric Power Systems Research*, 2013, 104:71-79.
- [20] 向婕, 雍正, 闫涵. 基于物理-统计结合的中长期风力发电量预测方法及系统[P]. 2022.
- [21] Zhang J, Yan J, Infield D. Short-term forecasting and uncertainty analysis of wind turbine power based long short-term memory network and Gaussian mixture model[J]. *Applied Energy*, 2019, 241:229-244.
- [22] Lin Z, Liu X. Wind power forecasting of an offshore wind turbine based on high-frequency SCADA data and deep learning neural network[J]. *Energy*, 2020, 201.
- [23] Soman S, Zareipour H, Malik O. A review of wind power and wind speed forecasting methods with different time horizons[C]. *North American Power Symposium (NAPS)*, 2010.
- [24] Lee K, Booth D, Alam P. A comparison of supervised and unsupervised neural networks in predicting bankruptcy of Korean firms[J]. *Expert Systems with Application*, 2005, 29(1) :p.1-16.
- [25] Pliego M A, MFP García, Pinar P. A survey of artificial neural network in wind energy systems[J]. *Applied Energy*, 2018, 228:1822-1836.
- [26] Bilal B O, Adjallah K H, Sava A. Wind Turbine Power Output Prediction Model Design Based on Artificial Neural Networks and Climatic Spatiotemporal Data[C]. *International Conference on Industrial Technology*, 2018.
- [27] 杨世秦, 孙驷洲. 基于遗传优化的小波神经网络风电功率预测[J]. *安徽工程大学学报*, 2018, 33(1): 8.
- [28] 李光华. 基于皮尔逊理论与径向基函数神经网络的光伏功率预测[J]. *电气技术与经济*, 2022(1): 14-16.
- [29] 项航, 王新居, 李强. 基于神经网络的风电功率预测与模型优化方法[J]. *电气开关*, 2022(003): 060.
- [30] Zhang J, Yan J, Infield D. Short-term forecasting and uncertainty analysis of wind turbine power based long short-term memory network and Gaussian mixture model[J]. *Applied Energy*, 2019, 241:229-244.
- [31] Hong Y Y, Rioflorido C. A hybrid deep learning-based neural network for 24-h ahead wind power forecasting[J]. *Applied Energy*, 2019, 250(Pt.1) :530-539.
- [32] Jung J, Broadwater R P. Current status and future advances for wind speed and power forecasting[J]. *Renewable & Sustainable Energy Reviews*, 2014, 31:762-777.
- [33] Jyothi M N, Rao P. Very-short term wind power forecasting through Adaptive Wavelet Neural Network[C]. *Biennial International Conference on Power & Energy Systems*:

- Towards Sustainable Energy. IEEE, 2016.
- [34] Lei X, Mao J. Short-term wind power forecasting based on Elman neural network with particle swarm optimization[C] .2016 Chinese Control and Decision Conference (CCDC). IEEE, 2016.
- [35] Chang W Y. Application of Back Propagation Neural Network for Wind Power Generation Forecasting[J] .International Journal of Digital Content Technology and its Applications, 2013, 7(4) :502-509.
- [36] 崔杨, 陈正洪, 许沛华. 基于机器学习的集群式风光一体短期功率预测技术[J]. 中国电力, 2020, 53(3): 7.
- [37] 杨观赐, 杨静, 李少波. 基于 Dropout 与 ADAM 优化器的改进 CNN 算法[J]. 华中科技大学学报: 自然科学版, 2018, 46(7): 6.
- [38] Lin Z, Liu X, Collu M. Wind power prediction based on High-frequency SCADA data along with isolation forest and deep learning neural networks[J] .International Journal of Electrical Power & Energy Systems. 2020, 118:105835.
- [39] 杨茂, 董骏城. 基于混合高斯分布的风电功率实时预测误差分析[J]. 太阳能学报, 2016, 37(6): 9.
- [40] Zhang J, Yan J, Infield D. Short-term forecasting and uncertainty analysis of wind turbine power based long short-term memory network and Gaussian mixture model[J] .Applied Energy, 2019, 241:229-244.
- [41] Shao L H. A novel bidirectional mechanism based on time series model for wind power forecasting[J] .Applied energy, 2016.
- [42] 段倩倩. 面向大数据的增量式学习算法研究[D]. 太原: 山西财经大学, 2015.
- [43] Cheung C C, Ng S C, Lui A K. Improving the Quickprop algorithm[C] .International Joint Conference on Neural Networks.IEEE, 2012.
- [44] Can Z, Baklacioglu T, Zturk E. Artificial neural networks modeling of combustion parameters for a diesel engine fueled with biodiesel fuel[J] .Energy, 2022, 247.
- [45] 李璐, 瞿伟, 张勤. 优化循环神经网络在滑坡位移预测中的应用[J]. 地测量与地球动力学, 2022(006): 042.
- [46] 赵辉, 杨赛, 岳有军. 基于小波分解-卷积神经网络和支持向量回归的短期负荷预测[J]. 科学技术与工程, 2021, 21(25): 7.
- [47] 谢文兰, 石跃祥, 肖平. 应用 BP 神经网络对自然图像分类[J]. 计算机工程与应用, 2010(2): 4.
- [48] 田东霞, 曹久才. 基于逐步回归法和 BP 神经网络模型的苹果产量预测[J]. 现代农业科技, 2022(14): 4.
- [49] 崔云月, 管一弘, 孙娜. BP 神经网络在烟梗长短梗率检测中的应用[J]. 软件导刊,

2021.

- [50] 和思铭,李伟觐,曾文钰.一种双层 PID 优化的 BP 神经网络语音识别方法[P].2021.
- [51] 刘艳华. 基于 BP 神经网络的交通灯信号识别系统设计[J]. 电子产品世界, 2022, 29(2): 3.
- [52] 陈毅. 基于优化 BP 神经网络的股票趋势预测研究[J]. 2021(2020-15): 198-200.
- [53] 李滢.基于小波分析和 GA-BP 神经网络的美元兑人民币汇率预测[J].2021(2017-3): 43-47.
- [54] 王菲华,周梓渝,宋洁. 基于灰色模型和 BP 神经网络的交通量预测研究[J]. 工程与建设, 2021, 035(003): 429-432.
- [55] 孙艳文,詹天明. 基于优化 BP 神经网络的销售预测算法研究[J]. 计算机技术与发展, 2022, 32(1): 5.
- [56] 王天力. 人工蜂群算法 BP 神经网络模型在短期电力负荷预测中的应用研究[J]. 机电信息, 2022(000-003) .
- [57] 孙全, 孙渊. 一种基于樽海鞘群和 BP 神经网络的电力负荷预测方法[P]. 2022.
- [58] 孙培胜, 陈堂贤, 程陈. 基于 SOA-SVM 模型的光伏阵列故障诊断研究[J]. 电源学报, 2023: 1-13.
- [59] Samal P. Optimal DSTATCOM allocation using a hybrid seagull-differential evolution algorithm[C] .2020 IEEE 17th India Council International Conference, 2020:1-6.
- [60] 罗浩, 史金朋, 潘一山. 改进非线性海鸥算法在矿震定位中的应用[J]. 安全与环境学报, 2023, 23(01): 107-115.
- [61] Long W, Jiao J, Liang X. Parameters estimation of photovoltaic models using a novel hybrid seagull optimization algorithm[J] .Energy, 2022, 249(1) :1-16.
- [62] 商俊杰. 基于并行海鸥算法的电力系统无功功率优化[D]. 福州: 福建工程学院, 2021.
- [63] Abdelhamid M, Houssein E H, Mahdy M A. An improved seagull optimization algorithm for optimal coordination of distance and directional over-current relays[J] .Expert Systems with Applications, 2022, 200(1) :1-20.
- [64] 刘双, 余学祥, 刘宇. 基于改进海鸥优化算法的可见光室内定位研究[J]. 激光杂志, 2023, 44(02): 129-134.
- [65] Gang L A, Hs B, Dr C. Power generation cost minimization of the grid- connected hybrid renewable energy system through optimal sizing using the modified seagull optimization technique ScienceDirect[J] .Energy Reports, 2020, 6(1) :3365-3376.
- [66] 韩自奋, 景乾明, 张彦凯. 风电预测方法与新趋势综述[J]. 电力系统保护与控制, 2019, 47(24): 10.
- [67] 张东英, 李伟花, 刘燕华. 风电场有功功率异常运行数据重构方法[J]. 电力系统

- 自动化, 2014, 38(5): 14-18.
- [68] 娄建楼, 胥佳, 陆恒. 基于功率曲线的风电机组数据清洗算法[J]. 电力系统自动化, 2016, 40(10): 6.
- [69] 张戈. 课程推荐预测模型中的数据预处理方法研究[J]. 中国新通信, 2019, 21(19): 190.
- [70] 黄立威, 江碧涛, 吕守业. 基于深度学习的推荐系统研究综述[J]. 计算机学报, 2018, 41 (7): 29.
- [71] 王俊, 刘明哲, 庾先国. 遗传算法优化的 BP 神经网络在 EDXRF 中对钛铁元素含量的预测[J]. 原子能科学技术, 2015, 49(6): 6.
- [72] 陈伟楠, 杨程天. 基于主成分分析的 PSO-BP 模型在城市需水预测中的应用[J]. 信息与电脑, 2018(13): 3.
- [73] 张冰洁, 何庆, 戴松利. 多方向螺旋搜索的混沌海鸥优化算法[J]. 小型微型计算机系统, 2023, 44(3): 8.
- [74] 毛清华, 王迎港. 融合改进 Logistics 混沌和正弦余弦算子的自适应 t 分布海鸥算法[J]. 小型微型计算机系统, 2022, 43(11): 2271-2277.
- [75] 闫丽梅, 徐伟丽. 基于 Petri 网的电力系统故障诊断综述 [J]. 广东电力, 2022, 35 (4): 1-10.

艰苦创业 严谨治学

严谨朴实 勤奋创新



学校网址: <http://www.nepu.edu.cn>